




Universidad Nacional de Ingeniería

Facultad de Ciencias

Programación No Lineal – CM4E2

2026-I

Apuntes de Optimalidad y Algoritmos de Optimización

Análisis Convexo, Dualidad y Optimización

Campos Mendoza, D. Daniel

danicampsmen@gmail.pe

Profesor: La Vida

Jefe de Prácticas: El Gato

Referencias Principales

- Mikhail Izmailov Alexey y Solodov. *Otimização: Condições de Otimidade, Elementos de Análise Convexa e de Dualidade (Volume 1)*. Rio de Janeiro, Brasil: IMPA, 2020
- Roger J.-B. Rockafellar R. Tyrrell y Wets. *Variational Analysis*. Vol. 317. Grundlehren der mathematical Sciences. Springer Science & Business Media, 2009
- [bazaraa2013nonlinearprogrammingtheory](#)

Lima, Perú

Última Edición

Fecha: 2026-07-14

Hora: 12:30:18

Versión 2.0 (Refactorizada)

Índice general

I. Condiciones de Optimalidad	1
1. Introducción a la Optimización	2
1.1. Existencia de soluciones	2
1.2. Existencia de soluciones globales	3
1.3. Condiciones de optimalidad para problemas sin restricciones	5
1.4. Condiciones de optimalidad en forma primal para problemas con restricciones. El cono tangente	7
Ejercicios del Capítulo	9
Parte I: Conceptos Básicos y Existencia de Soluciones	9
Parte II: Condiciones de Optimalidad Irrestricida	10
Parte III: Cono Tangente y Condiciones Primitives	10
2. Restricciones de igualdad	11
2.1. El problema de optimización y el subespacio tangente	11
2.2. Condiciones de Primer Orden y Estructura Afin	14
2.3. Condiciones diferenciales de segundo orden	16
Ejercicios del Capítulo	18
Parte I: Mecánica Primal-Dual y Fallas Topológicas	18
Parte II: Condiciones Diferenciales de Segundo Orden y Matriz KKT	19
Parte III: Aplicaciones Físicas, Análisis de Sensibilidad y Variedades Matriciales	20
3. Análisis convexo	22
3.1. Definiciones de convexidad. El problema de minimización convexo	22
3.2. Conjuntos convexos y Teoremas de Separación	25
3.2.1. Propiedades básicas de conjuntos convexos	25
3.2.2. Cono de Recesión y Generadores Finitos	27
3.2.3. El operador de proyección	27
3.2.4. Teoremas de Separación	28
3.2.5. Puntos Extremos	28
3.3. Teoremas de alternativa	29
3.4. Funciones convexas	31
3.4.1. Propiedades básicas de las funciones convexas	31
3.4.2. Funciones convexas diferenciables	32
3.4.3. Funciones convexas no diferenciables	32
Ejercicios del Capítulo	33
Parte I: Definiciones y hechos básicos de convexidad	33
Parte II: Conjuntos convexos y Teoremas de separación	34
Parte III: Teoremas de alternativa	35
Parte IV: Funciones convexas	36
4. Problemas con Restricciones Mixtas	39
4.1. Cono tangente en el caso de restricciones de igualdad y desigualdad	39
4.2. Condiciones de optimalidad de Karush-Kuhn-Tucker	44
4.3. Condiciones de optimalidad de segundo orden	49
Ejercicios del Capítulo	55
Parte I: Mecánica Primal-Dual y Condición de Mangasarian-Fromovitz	55

Parte II: Condiciones de Segundo Orden	55
Parte III: Tópicos Avanzados - Dualidad, Conos Convexos y KKT Singular	56
5. Elementos de la Teoría de Dualidad	57
5.1. Dualidad en programación lineal	57
5.2. Dualidad para un problema general	60
5.2.1. Formulación Minimax del Problema Primal	60
5.2.2. El Problema Dual General	61
5.2.3. Teorema de Dualidad Débil	61
5.2.4. Patologías y Casos Límite en la Teoría de Dualidad	62
5.2.5. Teoría de Multiplicadores de Lagrange Globales	63
5.2.6. Dualidad Fuerte y la Condición de Slater	64
5.2.7. El Problema Dual de Wolfe	65
5.2.8. Caracterización mediante Puntos de Silla	65
5.2.9. Subgradiente de la Función Dual	66
Ejercicios del Capítulo	66
Parte I: Dualidad en Programación Lineal	66
Parte II: Dualidad en Problemas Generales y Puntos de Silla	67
 II. Métodos Computacionales	 70
6. Resumen Teórico y Preliminares Matemáticos	71
6.1. Existencia de soluciones	71
6.2. Condiciones de optimalidad	72
6.3. Convexidad	74
6.4. Dualidad	75
6.5. Algunos resultados del Análisis y del Álgebra Lineal	76
6.6. Elementos del Análisis no diferenciable	78
Ejercicios del Capítulo	81
7. Introducción a los Métodos de Optimización	83
7.1. Clasificación de los métodos. Nociones de convergencia	83
7.2. Tasas de convergencia. Reglas de parada	84
7.3. Métodos de optimización unidimensional	87
7.3.1. Método de comparación de puntos de red	87
7.3.2. Método de bisección. Método de la sección áurea	88
7.3.3. Interpolación polinomial	90
8. Optimización Irrestricta	92
8.1. Métodos de descenso	92
8.1.1. Esquema general de los métodos de descenso. Búsqueda lineal	92
8.1.2. El método del gradiente	99
8.2. El método de Newton. Métodos cuasi-Newton	107
8.2.1. El método de Newton para ecuaciones	108
8.2.2. El método de Newton para optimización irrestricta	110
8.2.3. Métodos cuasi-Newton	112
8.2.4. Métodos cuasi-Newton	116
8.3. Estrategias de globalización	119
8.3.1. Métodos con búsqueda lineal	119
8.3.2. Métodos de regiones de confianza	121
8.3.3. Métodos de continuación paramétricos	126
8.4. Métodos de direcciones conjugadas	131
8.4.1. Métodos de direcciones conjugadas para funciones cuadráticas	131

8.4.2. El método de los gradientes conjugados	134
8.5. Métodos que no utilizan derivadas	136
Ejercicios del Capítulo 3	138
9. Métodos para Optimización con Restricción	144
10. Métodos para Optimización con Restricciones	145
10.1. Métodos para conjuntos factibles de estructura simple	145
10.1.1. Métodos del gradiente proyectado	145
10.1.2. Direcciones factibles y métodos de descenso	148
10.1.3. Método del gradiente restringido. Método de Newton restringido	149
10.2. Métodos de direcciones factibles	150
10.3. Métodos de penalización	152
10.3.1. Penalización externa	153
10.3.2. Penalización externa exacta	160
10.3.3. Penalización interna. Métodos de barreras	165
10.4. Métodos para problemas con restricciones de igualdad	168
10.4.1. Métodos de Newton para el sistema de Lagrange	168
10.4.2. El método de penalización cuadrática	170
10.4.3. Lagrangianas aumentadas y funciones de penalización exacta diferenciables	173
10.5. Métodos para problemas con restricciones mixtas	176
10.5.1. Métodos de Newton generalizados	176
10.5.2. Métodos de Newton generalizados para el sistema de Karush-Kuhn-Tucker	177
10.6. Programación cuadrática secuencial	181
10.6.1. Restricciones de igualdad	181
10.6.2. Restricciones mixtas	183
10.6.3. Globalización de convergencia de SQP	189
10.6.4. Restauración de la convergencia local superlineal	196
10.6.5. Otras técnicas de globalización	200
11. Métodos para optimización no diferenciable	208
11.1. Métodos de subgradiente	210
11.2. El método de planos cortantes	213
11.3. Métodos de haces	216
12. Programación lineal y cuadrática	222
12.1. Programación lineal	222
12.1.1. Elementos de teoría de la programación lineal	222
12.1.2. El método del simplex	228
12.1.3. Métodos de puntos interiores	234
12.2. Programación cuadrática	244
12.2.1. Puntos especiales	244
12.2.2. El método de puntos especiales	245
Bibliografía	248

Parte I.

Condiciones de Optimalidad

1. Introducción a la Optimización

En este capítulo recordamos varios hechos de la teoría de Optimización, tales como la existencia de soluciones, las condiciones de regularidad de las restricciones y de optimalidad, convexidad de conjuntos y de funciones, y elementos de la teoría de dualidad. El objetivo de este capítulo es facilitar las referencias futuras a lo largo del libro. Las demostraciones no serán presentadas. Se espera que el lector ya posea conocimientos sólidos de estos asuntos teóricos y que, en particular, haya leído el primer volumen [Izm20] de este libro. Presentaremos también algunos hechos auxiliares del Análisis y del Álgebra Lineal, que serán utilizados a lo largo del libro.

1.1. Existencia de soluciones

Sean dados un conjunto $D \subset \mathbb{R}^n$ y una función $f : \Omega \rightarrow \mathbb{R}$, donde $D \subset \Omega$. Este libro está dedicado a métodos computacionales para el problema de hallar un minimizador de f en el conjunto D . Este problema será escrito como

$$\min f(x) \quad \text{sujeto a } x \in D. \quad (1.1)$$

El conjunto D será llamado **conjunto factible** del problema, los puntos de D serán llamados **puntos factibles**, y f será llamada **función objetivo**.

Definición 1.1. Decimos que un punto $\bar{x} \in D$ es

(a) **minimizador global** de (1.1), si

$$f(\bar{x}) \leq f(x) \quad \forall x \in D; \quad (1.2)$$

(b) **minimizador local** de (1.1), si existe una vecindad U de $\bar{x}$ tal que

$$f(\bar{x}) \leq f(x) \quad \forall x \in D \cap U. \quad (1.3)$$

Si para todo $x \neq \bar{x}$ la desigualdad (1.2) o (1.3) es estricta, $\bar{x}$ será llamado minimizador estricto (global o local, respectivamente).

Definición 1.2. Decimos que $\bar{v} \in [-\infty, +\infty]$ definido por

$$\bar{v} = \inf\{f(x) \mid x \in D\}$$

es el **valor óptimo** del problema (1.1), donde entendemos que $\bar{v} = +\infty$ si $D = \emptyset$.

Una función puede admitir varios minimizadores globales, pero el valor óptimo (global) del problema, naturalmente, siempre es el mismo. Por la definición, es claro que todo minimizador global también es minimizador local, pero no reciprocamente. Cuando en la Definición 1.2 tenemos $\bar{v} = +\infty$ o $\bar{v} = -\infty$, el problema (1.1) no posee solución global. En el primer caso, el conjunto factible del problema es vacío. En el segundo caso, f es ilimitada inferiormente en el conjunto $D \neq \emptyset$. Pero incluso cuando $\bar{v}$ es finito, el minimizador global puede no existir.

Algunas de las condiciones que garantizan la existencia de solución global son las siguientes.

Teorema 1.1 (Teorema de Weierstrass). Sean $D \subset \mathbb{R}^n$ un conjunto compacto no vacío y $f : D \rightarrow \mathbb{R}$ una función continua. Entonces, el problema de minimizar f en D tiene una solución global.

| **Prueba.** Véase el Teorema 1.2 en [izmailov1020otimizacaovolume1]. ■

Otro resultado importante se basa en la noción de conjunto de nivel de una función.

Definición 1.3. El conjunto de nivel de la función $f : D \rightarrow \mathbb{R}$ asociado a $c \in \mathbb{R}$, es el conjunto dado por

$$L_{f,D}(c) = \{x \in D \mid f(x) \leq c\}.$$

En particular, tenemos el siguiente resultado.

Corolario 1.1. Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ continua en el conjunto D . Supongamos que existe $c \in \mathbb{R}$ tal que el conjunto de nivel $L_{f,D}(c)$ sea no vacío y compacto. Entonces, el problema de minimizar f en D posee una solución global.

Prueba. Véase el Corolario 1.3 en [Izm20]. ■

Otro resultado de existencia utiliza la noción de función coercitiva.

Definición 1.4. Decimos que la función $f : D \rightarrow \mathbb{R}$ es coercitiva en el conjunto D , cuando para cada secuencia $\{x^k\} \subset D$ tal que $\|x^k\| \rightarrow \infty$ o $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$ ($k \rightarrow \infty$), se tiene que $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$.

Corolario 1.2. Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ una función continua coercitiva en D . Entonces, el problema de minimizar f en D posee una solución global.

1.2. Existencia de soluciones globales

Cuando en la Definición 1.2 tenemos $\bar{v} = -\infty$, el problema (1.1) no posee solución global (en este caso f es no acotada inferiormente en el conjunto factible). Pero incluso cuando $\bar{v}$ es finito, el minimizador global puede no existir. Este es el caso en que $\bar{v}$ no es alcanzado en ningún punto factible, es decir, cuando no existe $x \in D$ tal que $f(x) = \bar{v}$.

Por ejemplo, sean $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = e^x$, $D = \mathbb{R}$. Evidentemente, $\bar{v} = \inf_{x \in \mathbb{R}} e^x = 0$. Sin embargo, no existe $x \in \mathbb{R}$ tal que $e^x = 0$. Sean ahora $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = e^x$, $D = (0, 1]$. Se tiene que $\bar{v} = \inf_{x \in (0, 1]} e^x = 1$, pero de nuevo no existe $x \in (0, 1]$ tal que $e^x = 1$. Observamos que la función f es continua en D , pero en el primer ejemplo D no es acotado y en el segundo D no es cerrado.

A continuación estudiaremos algunos criterios que garantizan la existencia de solución global.

Teorema 1.2 (Weierstrass). Sean $D \subset \mathbb{R}^n$ un conjunto compacto no vacío y $f : D \rightarrow \mathbb{R}$ una función continua. Entonces los problemas de minimizar y de maximizar f en D tienen soluciones globales.

Prueba. Por lo observado en la sección anterior, es suficiente probar la existencia de un minimizador. Como la imagen de un conjunto compacto por una función continua es compacta, el conjunto $\{v \in \mathbb{R} \mid v = f(x) \text{ para algún } x \in D\}$ es compacto. En particular, este conjunto es acotado inferiormente, es decir,

$$-\infty < \bar{v} = \inf_{x \in D} f(x).$$

Por la definición de ínfimo, para todo $k \in \mathbb{N}$ existe un $x^k \in D$ tal que

$$\bar{v} \leq f(x^k) \leq \bar{v} + \frac{1}{k}.$$

Pasando al límite cuando $k \rightarrow \infty$, concluimos que

$$\lim_{k \rightarrow \infty} f(x^k) = \bar{v}. \quad (1.4)$$

Como $\{x^k\} \subset D$ y D es compacto, se sigue que $\{x^k\}$ es una sucesión acotada. Luego, posee una subsucesión $\{x^{k_j}\}$ que converge a un punto de D :

$$\lim_{j \rightarrow \infty} x^{k_j} = \bar{x} \in D.$$

Por la continuidad de f , tenemos $\lim_{j \rightarrow \infty} f(x^{k_j}) = f(\bar{x})$. Usando (1.4), concluimos que $f(\bar{x}) = \bar{v}$, es decir, f asume el valor mínimo en D en el punto $\bar{x} \in D$. En otras palabras, $\bar{x}$ es un minimizador global. ■

La hipótesis de que el conjunto factible sea compacto solo puede ser eliminada en los resultados de existencia de solución al costo de fortalecer las hipótesis sobre la función objetivo. En este sentido, la noción de conjunto de nivel es fundamental.

Definición 1.5 (Conjunto de nivel). El **conjunto de nivel** de la función $f : D \rightarrow \mathbb{R}$ asociado a $c \in \mathbb{R}$ es el conjunto dado por

$$L_{f,D}(c) = \{x \in D \mid f(x) \leq c\}.$$

Corolario 1.3 (Existencia vía compacidad del conjunto de nivel). Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ continua en D . Supongamos que existe $c \in \mathbb{R}$ tal que el conjunto de nivel $L_{f,D}(c)$ sea no vacío y compacto. Entonces el problema de minimizar f en D posee una solución global.

Prueba. Por el Teorema de Weierstrass (Teorema 1.2), el problema $\min f(x)$ sujeto a $x \in L_{f,D}(c)$ tiene una solución global, digamos $\bar{x}$. Para todo $x \in D \setminus L_{f,D}(c)$, tenemos que $f(x) > c \geq f(\bar{x})$, lo que muestra que $\bar{x}$ es un minimizador global de f no solo en $L_{f,D}(c)$, sino también en D . ■

A continuación mostraremos un importante ejemplo de aplicación del Corolario 1.3.

Definición 1.6 (Proyección ortogonal). Dados un conjunto $D \subset \mathbb{R}^n$ y un punto $y \in \mathbb{R}^n$, una **proyección** (ortogonal) de y sobre D es una solución global del problema

$$\min \|x - y\| \quad \text{sujeto a } x \in D.$$

En otras palabras, la proyección de y sobre D es uno de los puntos de D que está más cerca de y .

Corolario 1.4 (Existencia de la proyección). Sea $D \subset \mathbb{R}^n$ un conjunto cerrado no vacío. Entonces la proyección de y sobre D existe para todo punto $y \in \mathbb{R}^n$.

Prueba. Fijemos $y \in \mathbb{R}^n$ arbitrario. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}_+$, $f(x) = \|x - y\|$. Evidentemente, f es continua en $\mathbb{R}^n$ y

$$L_{f,D}(c) = D \cap B(y, c),$$

donde $B(y, c) = \{x \in \mathbb{R}^n \mid \|x - y\| \leq c\}$ es la bola cerrada de centro y y radio c . El conjunto de nivel $L_{f,D}(c)$ es la intersección del conjunto cerrado D con el conjunto compacto $B(y, c)$. Por lo tanto, $L_{f,D}(c)$ es compacto. Además, para $c > 0$ suficientemente grande, es obvio que la bola $B(y, c)$ contiene puntos de D . Luego, $L_{f,D}(c) \neq \emptyset$. La afirmación ahora sigue por el Corolario 1.3. ■

En el problema de minimización del Corolario 1.4, el conjunto factible del problema podría ser ilimitado, pero es cerrado. A continuación consideremos un ejemplo donde el conjunto factible no es ni limitado ni cerrado.

Ejemplo 1.1. Mostraremos que el problema (1.1), donde

$$D = \{x \in \mathbb{R}^2 \mid x_1 + x_2 > 0\}, \quad f : D \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + x_2^2 + \frac{1}{x_1 + x_2},$$

posee una solución global.

Observamos que D es ilimitado y abierto. Por lo tanto, el Teorema 1.2 no se aplica en este caso. Fijemos $c \in \mathbb{R}$ tal que $L(c) = L_{f,D}(c) \neq \emptyset$ (por ejemplo, tomando $c = f(x)$ para un $x \in D$ cualquiera). Verificaremos que $L(c)$ es compacto (es decir, acotado y cerrado), y aplicaremos el Corolario 1.3.

Supongamos primero que $L(c)$ sea ilimitado, es decir, que exista $\{x^k\} \subset L(c)$ tal que $\|x^k\| \rightarrow \infty$ cuando $k \rightarrow \infty$. Tenemos que $x_1^k + x_2^k > 0$ (porque $x^k \in D$) y $f(x^k) \leq c$ para todo k . Si $|x_1^k| \rightarrow \infty$ cuando $k \rightarrow \infty$, entonces $c \geq f(x^k) > (x_1^k)^2 + x_2^k > (x_1^k)^2 - x_1^k \rightarrow +\infty$, lo que es imposible. Si $\{x_1^k\}$ es acotada, entonces $x_2^k \rightarrow +\infty$ cuando $k \rightarrow \infty$, y para todo k suficientemente grande, tenemos que $c \geq f(x^k) > x_2^k \rightarrow +\infty$, lo que también es imposible. Acabamos de mostrar que $L(c)$ es acotado.

Supongamos ahora que $L(c)$ no sea cerrado, es decir, que exista $\{x^k\} \subset L(c)$ tal que $\{x^k\} \rightarrow x$ cuando $k \rightarrow \infty$, con $x \in \mathbb{R}^2 \setminus L(c)$. La función f es continua en D . Por lo tanto, $f(x^k) \leq c$ implica que $f(x) \leq c$. Entonces, como $x \notin L(c)$, debe ser $x \in \text{cl } D \setminus D$, es decir, $x_1 + x_2 = 0$, pero en este caso $c \geq f(x^k) \rightarrow +\infty$ cuando $k \rightarrow \infty$, lo que es imposible. Acabamos de mostrar entonces que $L(c)$ también es cerrado. Luego $L(c)$ es compacto y la existencia de minimizador global sigue.

A continuación formalizaremos los fenómenos observados en el análisis del Ejemplo 1.1.

Definición 1.7 (Sucesión crítica y coercitividad). Decimos que una sucesión $\{x^k\} \subset \mathbb{R}^n$ es **crítica** en relación al conjunto D , si $\{x^k\} \subset D$ y o bien $\|x^k\| \rightarrow \infty$ o bien $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$ cuando $k \rightarrow \infty$.

Decimos que la función $f : D \rightarrow \mathbb{R}$ es **coercitiva** en el conjunto D , cuando para toda sucesión $\{x^k\}$ crítica en relación a D , se tiene

$$\limsup_{k \rightarrow \infty} f(x^k) = +\infty.$$

En el Ejemplo 1.1, f es coercitiva en el conjunto D . Observamos que cuando D es cerrado, coercitividad de f en D significa que si $x^k \in D$ y $\|x^k\| \rightarrow \infty$ entonces $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$. Cuando D es acotado, coercitividad significa que cuando $x^k \in D$ y $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$, se tiene $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$. Finalmente, cuando D es compacto, no hay sucesiones críticas, por lo que cualquier función $f : D \rightarrow \mathbb{R}$ es coercitiva en D trivialmente.

Corolario 1.5 (Existencia vía coercitividad). Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ una función continua y coercitiva en $D \neq \emptyset$. Entonces el problema de minimizar f en D posee una solución global.

El Teorema de Weierstrass puede ser generalizado ligeramente en relación a las propiedades de continuidad de la función objetivo.

Definición 1.8 (Semicontinuidad). Decimos que la función $f : D \rightarrow \mathbb{R}$ es **semicontinua inferiormente** en el punto $x \in D \subset \mathbb{R}^n$, cuando para cualquier sucesión $\{x^k\} \subset D$ tal que $\{x^k\} \rightarrow x$ cuando $k \rightarrow \infty$, se tiene

$$\liminf_{k \rightarrow \infty} f(x^k) \geq f(x). \quad (1.5)$$

Decimos que f es **semicontinua superiormente** cuando, en las mismas condiciones,

$$\limsup_{k \rightarrow \infty} f(x^k) \leq f(x).$$

Ejemplo 1.2. Sean $D = [1/2, 2] \subset \mathbb{R}$ y $f : D \rightarrow \mathbb{R}$ dada por

$$f(x) = \begin{cases} 1/x, & x \in [1/2, 1), \\ 2, & x \in [1, 2], \end{cases}$$

El conjunto D es compacto. La función f no es semicontinua inferiormente en D , pues no lo es en el punto $x = 1$. Se tiene que $\bar{v} = 1$, pero no existe $x \in D$ tal que $f(x) = 1$. Sin embargo, es fácil ver que f es semicontinua superiormente y que posee maximizadores globales en D .

1.3. Condiciones de optimalidad para problemas sin restricciones

Consideremos el problema de minimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (1.6)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$. A continuación estudiaremos las condiciones que deben ser satisfechas cuando un $\bar{x} \in \mathbb{R}^n$ dado es minimizador (local) del problema (1.6). Condiciones de este tipo se llaman **condiciones necesarias de optimalidad**. También estudiaremos las condiciones que garantizan que un punto dado es minimizador local del problema (**condiciones suficientes de optimalidad**). Cabe notar que todos los resultados presentados a continuación son también verdaderos para un problema con restricciones $\min_{x \in D} f(x)$ siempre que el punto de interés $\bar{x}$ esté en el interior del conjunto factible D .

Teorema 1.3 (Condición necesaria de primer orden - Fermat). Supongamos que la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un minimizador local irrestricto de f , entonces

$$\nabla f(\bar{x}) = 0. \quad (1.7)$$

Prueba. Sea $d \in \mathbb{R}^n$ arbitrario. Por la definición de minimizador local, existe $\varepsilon > 0$ tal que

$$f(\bar{x}) \leq f(\bar{x} + td) \quad \forall t \in [0, \varepsilon].$$

Por la diferenciabilidad de f en $\bar{x}$,

$$f(\bar{x} + td) = f(\bar{x}) + t\langle \nabla f(\bar{x}), d \rangle + o(t).$$

Luego, $0 \leq t\langle \nabla f(\bar{x}), d \rangle + o(t)$. Dividiendo por $t > 0$ y tomando el límite cuando $t \rightarrow 0^+$, obtenemos

$$0 \leq \langle \nabla f(\bar{x}), d \rangle.$$

Como $d \in \mathbb{R}^n$ es arbitrario, podemos elegir $d = -\nabla f(\bar{x})$, lo que resulta en la condición $0 \leq \langle \nabla f(\bar{x}), -\nabla f(\bar{x}) \rangle = -\|\nabla f(\bar{x})\|^2$. De donde sigue que $\nabla f(\bar{x}) = 0$. ■

Definición 1.9 (Punto estacionario). Decimos que un punto $\bar{x} \in \mathbb{R}^n$ es **estacionario** (o **crítico**) para el problema (1.6), si vale la condición (1.7).

Por lo tanto, si f es diferenciable, las soluciones locales del problema (1.6) deben ser puntos estacionarios. Claramente, lo mismo vale para los problemas de maximización. A continuación, presentamos las condiciones de segundo orden.

Teorema 1.4 (Condición necesaria de segunda orden). Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea dos veces diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un minimizador local irrestricto de f , entonces vale (1.7) y la matriz Hessiana de f en el

punto $\bar{x}$ es **semidefinida positiva**, es decir,

$$\langle \nabla^2 f(\bar{x})d, d \rangle \geq 0 \quad \forall d \in \mathbb{R}^n. \quad (1.8)$$

Prueba. La condición (1.7) ya fue obtenida por el Teorema 1.3. Sea $d \in \mathbb{R}^n$ arbitrario. Si $\bar{x}$ es minimizador local del problema (1.6), entonces para todo $t > 0$ suficientemente pequeño

$$0 \leq f(\bar{x} + td) - f(\bar{x}) = \langle \nabla f(\bar{x}), td \rangle + \frac{1}{2} \langle \nabla^2 f(\bar{x})(td), td \rangle + o(t^2) = \frac{t^2}{2} \langle \nabla^2 f(\bar{x})d, d \rangle + o(t^2).$$

Dividiendo ambos lados por $t^2 > 0$ y pasando al límite cuando $t \rightarrow 0^+$, obtenemos (1.8). ■

Si en un punto estacionario $\bar{x}$ en vez de (1.8) vale una condición más fuerte (la matriz Hessiana es definida positiva), podemos afirmar que de hecho $\bar{x}$ es un minimizador local estricto con crecimiento cuadrático.

Teorema 1.5 (Condición suficiente de segunda orden). Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea dos veces diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un punto estacionario (es decir, si vale (1.7)) y si la matriz Hessiana de f en $\bar{x}$ es definida positiva, es decir,

$$\langle \nabla^2 f(\bar{x})d, d \rangle > 0 \quad \forall d \in \mathbb{R}^n \setminus \{0\}, \quad (1.9)$$

entonces f satisface en torno a $\bar{x}$ la condición de crecimiento cuadrático: existen una vecindad U de $\bar{x}$ y un número $\beta > 0$ tales que

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\|^2 \quad \forall x \in U. \quad (1.10)$$

En particular, $\bar{x}$ es minimizador local estricto del problema (1.6). Recíprocamente, si vale (1.10), entonces $\bar{x}$ satisface las condiciones (1.7) y (1.9).

Prueba. Supongamos que valgan las condiciones (1.7) y (1.9), pero no (1.10). Entonces existe $\{x^k\} \subset \mathbb{R}^n \setminus \{\bar{x}\}$ tal que $\{x^k\} \rightarrow \bar{x}$ cuando $k \rightarrow \infty$ y

$$f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|^2 \quad \forall k.$$

Como la sucesión $\{(x^k - \bar{x})/\|x^k - \bar{x}\|\}$ es acotada, posee puntos de acumulación. Escogiendo una subsucesión, podemos admitir que

$$\frac{x^k - \bar{x}}{\|x^k - \bar{x}\|} \rightarrow d \in \mathbb{R}^n \setminus \{0\} \quad (\|d\| = 1).$$

Obtenemos que

$$\frac{1}{k} \|x^k - \bar{x}\|^2 > f(x^k) - f(\bar{x}) = \frac{1}{2} \langle \nabla^2 f(\bar{x})(x^k - \bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|^2),$$

donde usamos (1.7). Dividiendo por $\|x^k - \bar{x}\|^2 > 0$ y tomando el límite cuando $k \rightarrow \infty$, obtenemos

$$0 \geq \frac{1}{2} \langle \nabla^2 f(\bar{x})d, d \rangle,$$

en contradicción con (1.9).

Supongamos ahora que valga la condición de crecimiento cuadrático (1.10). Como ella implica que $\bar{x}$ es un minimizador local, obtenemos (1.7) por el Teorema 1.3. Para cualquier $d \in \mathbb{R}^n$ y $t \in \mathbb{R}$ suficientemente pequeño, $\bar{x} + td \in U$. Utilizando (1.10) y (1.7), obtenemos que

$$\beta t^2 \|d\|^2 \leq f(\bar{x} + td) - f(\bar{x}) = \frac{t^2}{2} \langle \nabla^2 f(\bar{x})d, d \rangle + o(t^2).$$

Dividiendo por $t^2 > 0$ y tomando el límite cuando $t \rightarrow 0$, obtenemos $\beta \|d\|^2 \leq \frac{1}{2} \langle \nabla^2 f(\bar{x})d, d \rangle$, lo que significa que $\nabla^2 f(\bar{x})$ es definida positiva. ■

Cabe resaltar que las condiciones (1.7) y (1.8) no son suficientes para que un punto sea minimizador (ej: $f(x) = x^3$ en $x = 0$). Por otro lado, (1.7) y (1.9) no son necesarias para que un punto sea minimizador (ej: $f(x) = x^4$ en $x = 0$).

Ejemplo 1.3. Encontremos los minimizadores y maximizadores locales irrestrictos de la función $f(x) = x_1^3 + x_2^3 - 3x_1x_2$. Es fácil ver que f no es acotada ni inferior ni superiormente, por lo que no hay óptimos globales. Los puntos estacionarios son $x^1 = (0, 0)$ y $x^2 = (1, 1)$. Las matrices Hessianas son:

$$\nabla^2 f(x^1) = \begin{pmatrix} 0 & -3 \\ -3 & 0 \end{pmatrix}, \quad \nabla^2 f(x^2) = \begin{pmatrix} 6 & -3 \\ -3 & 6 \end{pmatrix}.$$

La matriz $\nabla^2 f(x^1)$ no es ni semidefinida positiva ni semidefinida negativa. Por el Teorema 1.4, x^1 no es ni minimizador ni maximizador. Como la matriz $\nabla^2 f(x^2)$ es definida positiva, por los Teoremas 1.3 y 1.5, x^2 es el único minimizador local estricto.

Ejemplo 1.4. Encontramos las soluciones globales del problema

$$\min f(x) = x_1 + \frac{x_2^2}{4x_1} + \frac{x_3^2}{x_2} + \frac{2}{x_3} \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^3 \mid x_i > 0\}.$$

El conjunto D es abierto, así que todo punto factible pertenece al interior. Resolviendo (1.7), encontramos que el único punto estacionario es $\bar{x} = (1/2, 1, 1)$. Se puede verificar que él es minimizador global comprobando que f es coercitiva en D (véase la Definición 1.7).

1.4. Condiciones de optimalidad en forma primal para problemas con restricciones. El cono tangente

Consideramos ahora un problema en formato general


$$\min f(x) \quad \text{sujeto a} \quad x \in D, \quad (1.11)$$

donde $D \subset \mathbb{R}^n$ es un conjunto dado (no vacío) y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es la función objetivo. Para desarrollar las condiciones de optimalidad necesitamos estudiar la estructura del conjunto factible mediante **direcciones viables** y **direcciones tangentes**.

Definición 1.10 (Dirección viable). Decimos que $d \in \mathbb{R}^n$ es una **dirección viable** en relación al conjunto D en el punto $\bar{x} \in D$, cuando existe $\varepsilon > 0$ tal que

$$\bar{x} + td \in D \quad \forall t \in [0, \varepsilon].$$

Denotamos por $\mathcal{V}_D(\bar{x})$ el conjunto de todas las direcciones viables en relación al conjunto D en el punto $\bar{x} \in D$.



Definición 1.11 (Cono). Un conjunto $K \subset \mathbb{R}^n$ se llama **cono** cuando

$$d \in K \implies td \in K \quad \forall t \in \mathbb{R}_+.$$

Es fácil ver que para $D \subset \mathbb{R}^n$ y $\bar{x} \in D$ cualesquiera, el conjunto $\mathcal{V}_D(\bar{x})$ siempre es un cono no vacío (al menos, $0 \in \mathcal{V}_D(\bar{x})$).

Definición 1.12 (Dirección de descenso). Decimos que $d \in \mathbb{R}^n$ es una **dirección de descenso** de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ en el punto $\bar{x} \in \mathbb{R}^n$, si existe $\varepsilon > 0$ tal que

$$f(\bar{x} + td) < f(\bar{x}) \quad \forall t \in (0, \varepsilon].$$

Denotamos por $\mathcal{D}_f(\bar{x})$ el conjunto de todas las direcciones de descenso de la función f en el punto $\bar{x}$.

El conjunto $\mathcal{D}_f(\bar{x})$ puede ser vacío, pero el conjunto $\mathcal{D}_f(\bar{x}) \cup \{0\}$ es siempre un cono.

Lema 1.1 (Direcciones de descenso). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Entonces:

1. Para todo $d \in \mathcal{D}_f(\bar{x})$, se tiene que $\langle \nabla f(\bar{x}), d \rangle \leq 0$.
2. Si $d \in \mathbb{R}^n$ satisface $\langle \nabla f(\bar{x}), d \rangle < 0$, entonces $d \in \mathcal{D}_f(\bar{x})$.

Prueba. Sea $d \in \mathcal{D}_f(\bar{x})$. Para todo $t > 0$ suficientemente pequeño, $0 > f(\bar{x} + td) - f(\bar{x}) = t(\langle \nabla f(\bar{x}), d \rangle + o(t)/t)$. Pasando al límite cuando $t \rightarrow 0^+$, obtenemos $0 \geq \langle \nabla f(\bar{x}), d \rangle$, lo que prueba el ítem (a). Si $\langle \nabla f(\bar{x}), d \rangle < 0$, tenemos que $f(\bar{x} + td) - f(\bar{x}) = t(\langle \nabla f(\bar{x}), d \rangle + o(t)/t) \leq \frac{t}{2} \langle \nabla f(\bar{x}), d \rangle < 0$ para todo $t > 0$ suficientemente pequeño, implicando que $d \in \mathcal{D}_f(\bar{x})$. ■

Si $\bar{x} \in D$ es un minimizador local de (1.11), obviamente $\mathcal{D}_f(\bar{x}) \cap \mathcal{V}_D(\bar{x}) = \emptyset$. Por el Lema 1.1, tenemos entonces que $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{V}_D(\bar{x})$. Sin embargo, esta condición no siempre proporciona información útil, porque $\mathcal{V}_D(\bar{x})$ puede contener solo al vector nulo. Necesitamos considerar las **direcciones tangentes**.

Definición 1.13 (Dirección tangente y cono tangente). Decimos que $d \in \mathbb{R}^n$ es una **dirección tangente** en relación al conjunto D en el punto $\bar{x} \in D$ cuando

$$\text{dist}(\bar{x} + td, D) = o(t), \quad t \in \mathbb{R}_+.$$

Denotamos por $\mathcal{T}_D(\bar{x})$ el conjunto de todas las direcciones tangentes, el cual forma un cono.

Claramente, $\mathcal{V}_D(\bar{x}) \subset \mathcal{T}_D(\bar{x})$. Otra noción útil es la del **cono de Bouligand**:

$$\mathcal{B}_D(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \exists \{t_k\} \subset \mathbb{R}_+, \{t_k\} \rightarrow 0^+, \right. \\ \left. \text{dist}(\bar{x} + t_k d, D) = o(t_k) \right\}. \quad (1.12)$$

De forma equivalente, $d \in \mathcal{B}_D(\bar{x})$ si existen sucesiones $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$ para todo k . En general, $\mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$.

Ejemplo 1.5. Sean $q \in (0, 1)$ y $D = \{0\} \cup \{q^0, q^1, q^2, \dots\} \subset \mathbb{R}$. En $\bar{x} = 0 \in D$, para todo $d > 0$, eligiendo $t_k = q^k/d$ y $d^k = d$, tenemos $\bar{x} + t_k d^k = q^k \in D$. Así que $d \in \mathcal{B}_D(\bar{x})$ y $\mathcal{B}_D(\bar{x}) = \mathbb{R}_+$. Sin embargo, se puede demostrar analíticamente que $\mathcal{T}_D(\bar{x}) = \{0\}$, probando que $\mathcal{T}_D(\bar{x}) \neq \mathcal{B}_D(\bar{x})$.

Teorema 1.6 (Condición necesaria en forma primal). Sean $D \subset \mathbb{R}^n$ y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en el punto $\bar{x} \in D$. Si $\bar{x}$ es una solución local del problema de minimizar f en D , entonces

$$\langle \nabla f(\bar{x}), d \rangle \geq 0 \quad \forall d \in \mathcal{B}_D(\bar{x}). \quad (1.13)$$

Prueba. Fijemos $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$ y las sucesiones asociadas $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$. Como $\bar{x}$ es un minimizador local, para todo k suficientemente grande:

$$0 \leq f(\bar{x} + t_k d^k) - f(\bar{x}) = t_k \langle \nabla f(\bar{x}), d^k \rangle + o(t_k).$$

Dividiendo por $t_k > 0$ y pasando al límite, obtenemos (1.13). ■

Decimos que $\bar{x} \in \mathbb{R}^n$ es un **punto estacionario** del problema (1.11) si $\bar{x} \in D$ y vale (1.13).

Corolario 1.6. Sea $\bar{x} \in \text{int } D$ una solución local del problema (1.11) tal que f es diferenciable en $\bar{x}$. Entonces $\nabla f(\bar{x}) = 0$.


La condición de optimalidad puede transformarse a la forma primal-dual usando el cono dual.

Definición 1.14 (Cono dual). El **cono dual** de un cono $K \subset \mathbb{R}^n$ se define por

$$K^* = \{y \in \mathbb{R}^n \mid \langle y, d \rangle \leq 0 \quad \forall d \in K\}.$$

Usando esta noción, la condición de optimalidad (1.13) es equivalente a

$$-\nabla f(\bar{x}) \in (\mathcal{B}_D(\bar{x}))^*. \quad (1.14)$$



Teorema 1.7 (Condición suficiente en forma primal). Sean $D \subset \mathbb{R}^n$ y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en $\bar{x} \in D$. Entonces

$$\langle \nabla f(\bar{x}), d \rangle > 0 \quad \forall d \in \mathcal{B}_D(\bar{x}) \setminus \{0\} \quad (1.15)$$

si, y solamente si, f satisface en D en torno a $\bar{x}$ la condición de crecimiento lineal:

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\| \quad \forall x \in D \cap U. \quad (1.16)$$

En particular, (1.16) implica que $\bar{x}$ es minimizador local estricto.

Prueba. Supongamos que (1.15) valga, pero no (1.16). Existe $\{x^k\} \subset D \setminus \{\bar{x}\}$ convergiendo a $\bar{x}$ tal que $f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|$. Definiendo $t_k = \|x^k - \bar{x}\|$ y $d^k = (x^k - \bar{x})/t_k$, podemos extraer una subsucesión convergente $d^k \rightarrow d$ ($\|d\| = 1$). Así $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. Evaluando el gradiente, obtenemos $0 \geq \langle \nabla f(\bar{x}), d \rangle$, en contradicción con (1.15). El recíproco es directo evaluando (1.16) a lo largo de las trayectorias que definen el cono de Bouligand y tomando el límite para el gradiente. ■

Proposición 1.1 (Relaciones entre conos). Sean $D \subset \mathbb{R}^n$ y $\bar{x} \in D$. Los conos $\mathcal{T}_D(\bar{x})$ y $\mathcal{B}_D(\bar{x})$ son cerrados y se tiene que

$$\{0\} \subset \text{cl } \mathcal{V}_D(\bar{x}) \subset \mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x}).$$

Ejercicios del Capítulo

Parte I: Conceptos Básicos y Existencia de Soluciones

Ejercicio 1.1. Mediante un dibujo geométrico, formular una hipótesis sobre la solución global del problema (1.1), donde:

1. $f(x) = -x_1 + x_2$, $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 \leq 1, x_1 \geq x_2^2, x_1 + x_2 \geq 0\}$;
2. $f(x) = \max\{|x_1 - 2|, |x_2|\}$, $D = \{x \in \mathbb{R}^2 \mid 2|x_1| - |x_2| \leq 2\}$;
3. $f(x) = (x_1 - 1)^2 + x_2^2$, $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 = 2\sigma x_1 x_2\}$ y $\sigma \in \mathbb{R}$ es un parámetro.

Ejercicio 1.2. Mediante un dibujo geométrico, responder a la siguiente pregunta: para qué valores del parámetro $\sigma \in \mathbb{R}$ el problema (1.1) con $f(x) = x_1 + \sigma x_2$ y $D = \{x \in \mathbb{R}^2 \mid x_1^3 + x_2^3 = 3x_1 x_2\}$, tiene una solución global y para cuáles solo una solución local.

Ejercicio 1.3. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función continua. Probar que $\bar{x} \in \mathbb{R}^n$ es un minimizador global de f en $\mathbb{R}^n$ si, y solo si, todo x tal que $f(x) = f(\bar{x})$ es un minimizador local de f .

Ejercicio 1.4. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función cualquiera y $D \subset \mathbb{R}^n$ un conjunto cualquiera. Probar que para cualesquiera $\alpha \in \mathbb{R}_+$ y $c \in \mathbb{R}$, el conjunto de soluciones (locales y globales) del problema $\min \alpha f(x) + c$ sujeto a $x \in D$ es el mismo que el del problema original.

Ejercicio 1.5. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función cualquiera y $D_1, D_2 \subset \mathbb{R}^n$ conjuntos tales que $D_2 \subset D_1$.

1. Mostrar que $\inf_{x \in D_1} f(x) \leq \inf_{x \in D_2} f(x)$.
2. Probar que si $\bar{x}$ es un minimizador de f en D_1 tal que $\bar{x} \in D_2$, entonces $\bar{x}$ también es minimizador de f en D_2 .

Ejercicio 1.6. Probar el Corolario 1.5. (Ayuda: Usar el razonamiento analítico del Ejemplo 1.1).

Ejercicio 1.7. Sea D un conjunto compacto no vacío. Suponiendo que f sea semicontinua inferiormente en D (ver Definición 1.8), probar que existe un minimizador global para el problema (1.1). Suponiendo que f sea semicontinua superiormente en D , probar que existe un maximizador global.

Ejercicio 1.8. Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ una función semicontinua inferiormente y coercitiva en $D \neq \emptyset$. Probar que el problema (1.1) posee una solución global.

Ejercicio 1.9. Sea f una función cuadrática $f(x) = \langle Qx, x \rangle + \langle q, x \rangle + c$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica. Probar:

1. Si el problema de minimización irrestricta de f tiene un minimizador local, entonces la matriz Q es semidefinida positiva y todo minimizador local es global.
2. Si Q es definida positiva, entonces f es coercitiva en $\mathbb{R}^n$. Mostrar que el problema de minimización de f sobre cualquier conjunto D no vacío y cerrado tiene un minimizador global, pero que en general, esto no es verdadero cuando D no es cerrado.

Ejercicio 1.10. Supóngase que el problema de minimización irrestricta de una función continua en $\mathbb{R}^n$ tenga una solución global. Determinar si esto implica o no que f tiene un minimizador global en cualquier conjunto cerrado en $\mathbb{R}^n$.

Ejercicio 1.11. Supóngase que las funciones $f_1, f_2 : \mathbb{R}^n \rightarrow \mathbb{R}$ sean continuas y tengan minimizadores globales. Determinar si esto implica que la suma $f_1(\cdot) + f_2(\cdot)$ también tiene un minimizador global.

Ejercicio 1.12. Probar que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es semicontinua inferiormente en el conjunto cerrado D si, y solo si, sus conjuntos de nivel $L_{f,D}(c)$ son cerrados para todo $c \in \mathbb{R}$.

Parte II: Condiciones de Optimalidad Irrestricita

Ejercicio 1.13. Encontrar todos los valores del parámetro $\sigma \in \mathbb{R}$ para los cuales el problema de minimización irrestricita de la función $f(x) = \sigma x_1^2 + 4x_1x_2 + 4x_2^2 + x_1 + x_2$ tiene una solución.

Ejercicio 1.14. Mostrar que la función $f(x) = (x_2 - x_1^2)^2 + x_1^5$ tiene un único punto estacionario que no es un maximizador ni un minimizador en $\mathbb{R}^2$.

Ejercicio 1.15. Sean $n \geq 2$ y $f(x) = (1 + x_n)^3 \sum_{i=1}^{n-1} x_i^2 + x_n^2$. Mostrar que $\bar{x} = 0$ es el único punto estacionario de f en $\mathbb{R}^n$ y que es un minimizador local estricto, pero no es minimizador global en $\mathbb{R}^n$.

Ejercicio 1.16. Determinar si puede o no existir una función $f : \mathbb{R} \rightarrow \mathbb{R}$ que tiene un único punto estacionario y este punto es minimizador local, pero no minimizador global.

Ejercicio 1.17. Probar que, para cualquier $\sigma > 1$, el sistema de ecuaciones:

$$\sigma \cos x_1 \sin x_2 + x_1 e^{x_1^2 + x_2^2} = 0, \quad \sigma \sin x_1 \cos x_2 + x_2 e^{x_1^2 + x_2^2} = 0$$

posee una solución $x \in \mathbb{R}^2 \setminus \{0\}$.

Parte III: Cono Tangente y Condiciones Primitives

Ejercicio 1.18. Sean $K_1 \subset K_2$ dos conos en $\mathbb{R}^n$. Mostrar que su cono dual verifica $K_2^* \subset K_1^*$.

Ejercicio 1.19. Sean K_1 y K_2 conos no vacíos en $\mathbb{R}^n$. Mostrar las siguientes propiedades:

1. $K_1 \times K_2$ es un cono, y $(K_1 \times K_2)^* = K_1^* \times K_2^*$.
2. $K_1 \cup K_2$ es un cono, y $(K_1 \cup K_2)^* = K_1^* \cap K_2^*$.
3. $K_1 + K_2$ es un cono, y $(K_1 + K_2)^* = K_1^* \cap K_2^*$.

Ejercicio 1.20. Mostrar que el cono de Bouligand $\mathcal{B}_D(\bar{x})$ admite la siguiente definición equivalente:

$$\mathcal{B}_D(\bar{x}) = \{0\} \cup \left\{ d \in \mathbb{R}^n \left| \begin{array}{l} \exists \{x^k\} \subset D \text{ tal que } \{x^k\} \rightarrow \bar{x}, \\ \left\{ \frac{x^k - \bar{x}}{\|x^k - \bar{x}\|} \right\} \rightarrow \frac{d}{\|d\|} \end{array} \right. \right\}.$$

Ejercicio 1.21. Mostrar que en $\mathbb{R}^n$ la condición de optimalidad primal (1.13) es equivalente a:

$$\forall \varepsilon > 0, \quad \langle \nabla f(\bar{x}), d \rangle > -\varepsilon \|d\| \quad \forall d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}.$$

Ejercicio 1.22. Sean $C \subset \mathbb{R}^n, D \subset \mathbb{R}^n$ conjuntos cualesquiera. Probar que:

$$\mathcal{B}_{C \cup D}(\bar{x}) = \mathcal{B}_C(\bar{x}) \cup \mathcal{B}_D(\bar{x}), \quad \mathcal{B}_{C \cap D}(\bar{x}) \subset \mathcal{B}_C(\bar{x}) \cap \mathcal{B}_D(\bar{x}).$$

Ejercicio 1.23. Sean $\emptyset \neq D \subset \mathbb{R}^n, C = \mathbb{R}^n \setminus D$. Denotamos por $\text{fr } D$ la frontera de D . Mostrar que si $\bar{x} \in \text{fr } D$, entonces:

$$\mathcal{B}_C(\bar{x}) \cup \mathcal{B}_D(\bar{x}) = \mathbb{R}^n, \quad \mathcal{B}_{\text{fr } D}(\bar{x}) = \mathcal{B}_C(\bar{x}) \cap \mathcal{B}_D(\bar{x}).$$

Ejercicio 1.24. Sean $D \subset \mathbb{R}^n$ un conjunto no vacío y cerrado, y $x \notin D$. Sea $P_D(x)$ el conjunto de proyecciones ortogonales de x sobre D . Mostrar que:

$$x - \bar{x} \in (\mathcal{B}_D(\bar{x}))^* \quad \forall \bar{x} \in P_D(x).$$

2. Restricciones de igualdad

Este capítulo presenta las condiciones teóricas de optimalidad para problemas con restricciones de igualdad, definidos sobre variedades diferenciables. A partir del Teorema de Lyusternik, se establece la relación entre la topología del cono tangente y el núcleo de la matriz Jacobiana, para luego deducir las condiciones de primer y segundo orden mediante multiplicadores de Lagrange.

Notación. Dada una función vectorial diferenciable $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$, denotaremos por $J_h(x) \in \mathbb{R}^{l \times n}$ a su matriz Jacobiana evaluada en el punto x . Consecuentemente, las filas de esta matriz corresponden a los gradientes transpuestos $\nabla h_i(x)^\top$, para $i = 1, \dots, l$.

2.1. El problema de optimización y el subespacio tangente

Definición 2.1 (Problema con restricciones de igualdad). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones de clase $\mathcal{C}^1$ (y de clase $\mathcal{C}^2$ cuando el análisis lo requiera). Se define el **conjunto factible** D como la variedad algebraica descrita por el sistema de igualdades:

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0\}.$$

El **problema de optimización con restricciones de igualdad** consiste en hallar un elemento en D que minimice a la función objetivo f . Este problema se denota formalmente mediante la expresión:

$$\min f(x) \quad \text{sujeto a} \quad x \in D. \quad (2.1)$$

Proposición 2.1. Supóngase que $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es diferenciable en $\bar{x} \in D$. Entonces, el cono de Bouligand está contenido en el núcleo del Jacobiano:

$$\mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x}).$$

Prueba. El vector nulo pertenece a ambos conjuntos. Sea $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. Por definición secuencial, existen sucesiones $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$, tales que $\bar{x} + t_k d^k \in D$ para todo $k \in \mathbb{N}$. Consecuentemente, $h(\bar{x} + t_k d^k) = 0$. Aplicando el desarrollo de Taylor de primer orden a la función vectorial h :

$$0 = h(\bar{x} + t_k d^k) - h(\bar{x}) = t_k J_h(\bar{x}) d^k + o(t_k \|d^k\|).$$

Dividiendo por el escalar $t_k > 0$ y tomando el límite cuando $k \rightarrow \infty$, la convergencia $d^k \rightarrow d$ implica que $J_h(\bar{x})d = 0$. Por consiguiente, $d \in \ker J_h(\bar{x})$. ■

Nota: Interpretación Geométrica del Núcleo

El álgebra lineal indica que $d \in \ker J_h(\bar{x})$ equivale a $\langle \nabla h_i(\bar{x}), d \rangle = 0$ para cada restricción i . Geométricamente, esto significa que cualquier movimiento en la dirección de d debe ser ortogonal a los gradientes de las superficies que definen a D . De este modo, d es tangente a la superficie en primer orden.

Definición 2.2 (Condiciones de regularidad). Decimos que el punto $\bar{x} \in D$ es **regular** (o satisface una calificación de restricciones) si cumple una de las siguientes propiedades:

- Independencia Lineal de los Gradientes (LICQ):** El operador lineal $J_h(\bar{x})$ es sobreyectivo; esto es, $\text{rk } J_h(\bar{x}) = l$. Algebraicamente, esto equivale a afirmar que la transformación transpuesta es inyectiva: $\ker(J_h(\bar{x})^\top) = \{0\}$. (Nótese que esto exige la condición topológica $l \leq n$).
- Linealidad afín:** La función h es afín, i.e., $h(x) = Ax - a$, con $A \in \mathbb{R}^{l \times n}$ y $a \in \mathbb{R}^l$.

Para establecer la topología local de la variedad, se requiere un resultado analítico preparatorio basado en el Teorema de la Función Implícita clásico.

Lema 2.1 (Existencia de Función Implícita Acotada). Sean $F : \mathbb{R}^s \times \mathbb{R}^n \rightarrow \mathbb{R}^l$ diferenciable en una vecindad de $(\bar{p}, \bar{y})$ y $\nabla_y F$ continua en dicho punto. Supóngase que $F(\bar{p}, \bar{y}) = 0$ y que el rango de la matriz Jacobiana parcial es máximo: $\text{rk } J_y F(\bar{p}, \bar{y}) = l$.

Entonces, existen una vecindad U de $\bar{p}$ y una constante $M > 0$ tales que, para todo $p \in U$, existe un único $y(p) \in \mathbb{R}^n$ que satisface $F(p, y(p)) = 0$ y la acotación:

$$\|y(p) - \bar{y}\| \leq M \|F(p, \bar{y})\|.$$

Prueba. Como $J_y F(\bar{p}, \bar{y}) \in \mathbb{R}^{l \times n}$ tiene rango l , sus filas son linealmente independientes. Sea $A \in \mathbb{R}^{(n-l) \times n}$ una matriz cuyas filas completan una base de $\mathbb{R}^n$. Construimos el operador extendido $\Phi : \mathbb{R}^s \times \mathbb{R}^n \rightarrow \mathbb{R}^l \times \mathbb{R}^{n-l}$ mediante:

$$\Phi(p, y) = \begin{pmatrix} F(p, y) \\ A(y - \bar{y}) \end{pmatrix}.$$

Evaluable en el punto base, $\Phi(\bar{p}, \bar{y}) = 0$. El Jacobiano parcial respecto a y es la matriz cuadrada $J_y \Phi(\bar{p}, \bar{y}) = \begin{pmatrix} J_y F(\bar{p}, \bar{y}) \\ A \end{pmatrix} \in \mathbb{R}^{n \times n}$, la cual es no singular por construcción.

Por el Teorema de la Función Implícita, existe una función diferenciable $y : U \rightarrow \mathbb{R}^n$ definida en una vecindad de $\bar{p}$ tal que $y(\bar{p}) = \bar{y}$ y $\Phi(p, y(p)) = 0$. Esto último implica que $F(p, y(p)) = 0$ y $A(y(p) - \bar{y}) = 0$.

Aplicando el Teorema del Valor Medio sobre el operador inverso local $\Phi(p, \cdot)$ y utilizando la desigualdad triangular para el difeomorfismo continuo, se deduce la existencia de una constante M dependiente de $\|J_y \Phi^{-1}\|$ que satisface la acotación requerida. ■

Nota: Justificación Geométrica de la Corrección Ortogonal

Si un punto x no cumple las restricciones ($h(x) \neq 0$), se busca una corrección Δx tal que $h(x + \Delta x) = 0$. Geométricamente, la trayectoria más corta para retornar a la variedad es ortogonal a ella. Dado que el espacio ortogonal al plano tangente ($\ker J_h$) coincide con la imagen de la matriz transpuesta ($\mathfrak{I}(J_h)^\top$), la corrección óptima tiene la forma $\Delta x = J_h(\bar{x})^\top \xi$, donde $\xi \in \mathbb{R}^l$ es un vector de ponderación. Este concepto fundamenta el desarrollo del Teorema de Lyusternik.

Ejemplo 2.1. Para ilustrar el Lema de la Función Implícita Acotada, consideremos la intersección de una circunferencia de radio paramétrico p con la recta vertical $y_1 = 1$. Modelamos esto mediante el campo vectorial $F : \mathbb{R} \times \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dado por:

$$F(p, y) = \begin{pmatrix} y_1^2 + y_2^2 - p^2 \\ y_1 - 1 \end{pmatrix}.$$

Fijemos el parámetro nominal $\bar{p} = \sqrt{2}$ y el punto de solución nominal $\bar{y} = (1, 1)^\top$. Se verifica de manera directa que $F(\sqrt{2}, (1, 1)) = 0$.

Evaluamos el Jacobiano parcial respecto a las variables espaciales y :

$$J_y F(p, y) = \begin{pmatrix} 2y_1 & 2y_2 \\ 1 & 0 \end{pmatrix} \implies J_y F(\bar{p}, \bar{y}) = \begin{pmatrix} 2 & 2 \\ 1 & 0 \end{pmatrix}.$$

El determinante de esta matriz es $-2 \neq 0$. Por lo tanto, $\text{rk } J_y F(\bar{p}, \bar{y}) = 2 = l$, por lo que las hipótesis del Lema 2.1 se cumplen.

Si se perturba el radio de la circunferencia ligeramente, pasando a un nuevo parámetro $p \approx \sqrt{2}$ y manteniendo el punto en $\bar{y} = (1, 1)$, el error algebraico inducido es:

$$F(p, \bar{y}) = \begin{pmatrix} 1^2 + 1^2 - p^2 \\ 1 - 1 \end{pmatrix} = \begin{pmatrix} 2 - p^2 \\ 0 \end{pmatrix}.$$

El lema asegura que existe una raíz exacta $y(p)$ para el sistema perturbado, y que la distancia desde el punto antiguo $\bar{y}$ a la nueva raíz $y(p)$ está acotada por este error: $\|y(p) - \bar{y}\| \leq M \|F(p, \bar{y})\| = M |2 - p^2|$. En este caso, la nueva raíz analítica es $y(p) = (1, \sqrt{p^2 - 1})^\top$, y mediante el desarrollo de Taylor se verifica que la distancia $|\sqrt{p^2 - 1} - 1|$ decae a la misma velocidad que la perturbación $|p^2 - 2|$.

Teorema 2.1 (Lyusternik: Estimación de Viabilidad). Supóngase que $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es continuamente diferenciable en una vecindad de $\bar{x} \in D$ y que satisface la condición LICQ. Entonces, existen una vecindad U de $\bar{x}$ y una constante

$M > 0$ tales que:

$$\text{dist}(x, D) \leq M \|h(x)\| \quad \forall x \in U.$$

Prueba. Definimos el campo paramétrico $F : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}^l$ mediante la traslación $F(x, \xi) = h(x + \xi)$. Tratando a x como el parámetro y a ξ como la variable, evaluamos en el punto base $(\bar{x}, 0)$. Se tiene $F(\bar{x}, 0) = h(\bar{x}) = 0$. El Jacobiano respecto a la variable ξ es $J_\xi F(\bar{x}, 0) = J_h(\bar{x})$, el cual, por la hipótesis LICQ, tiene rango máximo l . Las hipótesis del Lema 2.1 se verifican.

Por consiguiente, existen una vecindad U de $\bar{x}$ y un número $M > 0$ tales que, para cada $x \in U$, existe una perturbación $\xi(x) \in \mathbb{R}^n$ que cumple $0 = F(x, \xi(x)) = h(x + \xi(x))$. Esto asegura que el punto trasladado $x + \xi(x) \in D$. Además, el Lema 2.1 establece la cota $\|\xi(x)\| \leq M \|F(x, 0)\| = M \|h(x)\|$. Por la definición métrica de distancia a un conjunto:

$$\text{dist}(x, D) \leq \|x + \xi(x) - x\| = \|\xi(x)\| \leq M \|h(x)\|.$$

■

Ejemplo 2.2 (Acotación de Lyusternik en la Esfera). Considérese la variedad esférica unitaria en $\mathbb{R}^2$, definida por $h(x) = x_1^2 + x_2^2 - 1 = 0 \implies D = \{x \in \mathbb{R}^2 \mid \|x\|^2 = 1\}$. Tomemos un punto nominal en el polo norte, $\bar{x} = (0, 1) \in D$. El Jacobiano evaluado en este punto es $J_h(\bar{x}) = (0, 2)$. Dado que $\text{rk } J_h(\bar{x}) = 1$, la condición LICQ se cumple en $\bar{x}$. El Teorema 2.1 asegura la existencia de una constante $M > 0$ y una vecindad U de $\bar{x}$ tal que $\text{dist}(x, D) \leq M |h(x)|$ para todo $x \in U$.

Analíticamente, para $x \in \mathbb{R}^2 \setminus \{0\}$, la distancia es $\text{dist}(x, D) = |\|x\| - 1|$. La violación algebraica es $|h(x)| = |\|x\|^2 - 1| = \text{dist}(x, D) \cdot (\|x\| + 1)$. Despejando, obtenemos $\text{dist}(x, D) = \frac{1}{\|x\| + 1} |h(x)|$. En una vecindad U alrededor de $\bar{x} = (0, 1)$, la norma satisface $\|x\| \approx 1$. Si restringimos U a la bola de radio $1/2$ centrada en $\bar{x}$, para todo $x \in U$ se cumple que $\|x\| \geq 1/2$, lo que implica $\frac{1}{\|x\| + 1} \leq \frac{2}{3}$. Así, se obtiene la constante de Lyusternik $M = 2/3$. En este caso, el error algebraico $|h(x)|$ acota la distancia geométrica al conjunto.

Atención: Colapso de la Geometría por falta de Regularidad

La condición LICQ es un requisito fundamental para asegurar la regularidad del punto. Consideremos la restricción escalar $h(x) = x^2 = 0$, con el conjunto $D = \{0\}$. En $\bar{x} = 0$, el gradiente se anula ($h'(0) = 0$), por lo que no se cumple LICQ. Para cualquier $x \notin D$, se tiene:

$$\frac{\text{dist}(x, D)}{\|h(x)\|} = \frac{|x|}{x^2} = \frac{1}{|x|} \rightarrow +\infty \quad \text{cuando } x \rightarrow 0.$$

No existe ninguna constante M finita que acote esta relación, por lo que la equivalencia entre la caracterización algebraica y la topológica deja de cumplirse.

Teorema 2.2 (Teorema del Subespacio Tangente). Sea $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ de clase $\mathcal{C}^1$ en $\bar{x} \in D$.

1. Si se satisface la condición LICQ en $\bar{x}$, entonces los conos topológicos y el subespacio algebraico coinciden:

$$\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \ker J_h(\bar{x}).$$

2. Si las restricciones son afines, se tiene adicionalmente que $\mathcal{V}_D(\bar{x}) = \ker J_h(\bar{x})$.

Prueba. Parte (1): Por la Proposición 2.1, $\mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x})$. Inversamente, sea $d \in \ker J_h(\bar{x})$. Por el Teorema de Lyusternik (Teorema 2.1), para $t > 0$ suficientemente pequeño se tiene $\text{dist}(\bar{x} + td, D) \leq M \|h(\bar{x} + td)\|$. Expandiendo h por Taylor y utilizando que $h(\bar{x}) = 0$ y $J_h(\bar{x})d = 0$:

$$h(\bar{x} + td) = h(\bar{x}) + tJ_h(\bar{x})d + o(t) = o(t).$$

Consecuentemente, $\text{dist}(\bar{x} + td, D) \leq M \|o(t)\| = o(t)$. Esto corresponde a la definición de dirección tangente, por lo que $d \in \mathcal{T}_D(\bar{x})$. De la cadena de inclusiones $\ker J_h(\bar{x}) \subset \mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x})$, se deduce la igualdad de los conjuntos.

Parte (2): Para $h(x) = Ax - a$, se tiene $J_h(\bar{x}) = A$. Si $d \in \ker A$, para cualquier escalar $t \in \mathbb{R}$: $h(\bar{x} + td) = A(\bar{x} + td) - a = (A\bar{x} - a) + tAd = h(\bar{x}) = 0$. Luego $\bar{x} + td \in D$ para todo t , lo que demuestra que $d \in \mathcal{V}_D(\bar{x})$. ■

Ejemplo 2.3 (Colapso Analítico del Cono Tangente en $\mathbb{R}^3$). Considérese la curva en $\mathbb{R}^3$ formada por la intersección de un cilindro parabólico y un plano, definida por el sistema algebraico $h(x) = (x_1^2 - x_2, x_1 + x_3 - 1)^\top = 0$. Elegimos el punto $\bar{x} = (1, 1, 0)^\top \in D$. El subespacio nulo del Jacobiano evaluado en $\bar{x}$ está generado por el vector director $d = (1, 2, -1)^\top$. Es decir: $\ker J_h(\bar{x}) = \text{span} \langle (1, 2, -1)^\top \rangle$.

Verificamos que este vector pertenece a $\mathcal{T}_D(\bar{x})$. Construimos una curva $x(t) \in D$ parametrizada que pase por $\bar{x}$. Tomando $x_1 = 1 + t$, el sistema exige $x_2(t) = 1 + 2t + t^2$ y $x_3(t) = -t$. La curva factible es $x(t) = (1 + t, 1 + 2t + t^2, -t)^\top$. Desarrollando: $x(t) = \bar{x} + td + r(t)$, donde el residuo es $r(t) = (0, t^2, 0)^\top$. La norma del residuo satisface $\|r(t)\| = o(t)$. Por definición, se tiene que $d \in \mathcal{T}_D(\bar{x})$.

Teorema 2.3 (Condición necesaria en forma primal). Sea $\bar{x} \in D$ un minimizador local del problema (2.1). Si $\bar{x}$ es regular (cumple LICQ o linealidad), entonces el gradiente de la función objetivo se anula a lo largo de todo el subespacio tangente:

$$\langle \nabla f(\bar{x}), d \rangle = 0 \quad \forall d \in \ker J_h(\bar{x}). \quad (2.2)$$

Prueba. De acuerdo con la caracterización general del Capítulo 1, si $\bar{x}$ es un mínimo local, se cumple que $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{B}_D(\bar{x})$. Por la regularidad y el Teorema 2.2, se tiene $\mathcal{B}_D(\bar{x}) = \ker J_h(\bar{x})$. Esta desigualdad se aplica sobre el subespacio nulo. Dado que $\ker J_h(\bar{x})$ es un subespacio vectorial, si $d \in \ker J_h(\bar{x})$, su opuesto simétrico $-d$ también pertenece a $\ker J_h(\bar{x})$. Evaluando la desigualdad en dicho vector: $\langle \nabla f(\bar{x}), -d \rangle \geq 0 \implies \langle \nabla f(\bar{x}), d \rangle \leq 0$. De ambas desigualdades se deduce la igualdad a cero. ■

Ejemplo 2.4 (Ortogonalidad Primal en el Cilindro). Considérese el problema de minimizar la distancia al origen de un punto restringido a yacer sobre un cilindro desplazado en $\mathbb{R}^3$: $\min \frac{1}{2}(x_1^2 + x_2^2 + x_3^2)$ sujeto a $h(x) = (x_1 - 2)^2 + x_2^2 - 1 = 0$. Geométricamente, el punto del cilindro más cercano al origen es $\bar{x} = (1, 0, 0)^\top$. El Jacobiano de la restricción evaluado en $\bar{x}$ es $\nabla h(\bar{x}) = (-2, 0, 0)^\top$, por lo que se cumple LICQ. El subespacio tangente en $\bar{x}$ es el plano vertical $x_1 = 1$ generado por $d = (0, d_2, d_3)^\top$. El gradiente de la función objetivo en $\bar{x}$ es $\nabla f(\bar{x}) = (1, 0, 0)^\top$. El producto interno $\langle \nabla f(\bar{x}), d \rangle = 0$. De este modo se verifica la condición necesaria: el gradiente es ortogonal al subespacio de direcciones tangentes.

Corolario 2.1 (Singularidad Topológica por Exceso de Restricciones). Supóngase que el punto $\bar{x} \in D$ satisface la condición LICQ y que la dimensión de las restricciones es mayor o igual que la dimensión del espacio primal ($l \geq n$). Entonces, $\bar{x}$ es un **punto aislado** del conjunto factible D , y es un minimizador local estricto para cualquier función continua f .

Prueba. Por el Teorema del Rango de Álgebra Lineal, $\dim(\ker J_h(\bar{x})) = n - \text{rk } J_h(\bar{x})$. Bajo LICQ, el rango es máximo: $\text{rk } J_h(\bar{x}) = \min(l, n) = n$. Sustituyendo, se tiene que $\dim(\ker J_h(\bar{x})) = 0$, lo que implica $\ker J_h(\bar{x}) = \{0\}$. Aplicando el Teorema del Subespacio Tangente (Teorema 2.2), los conos topológicos se reducen a $\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \{0\}$. Al no existir direcciones tangentes no nulas, no es posible definir una sucesión en $D \setminus \{\bar{x}\}$ que converja a $\bar{x}$. Por lo tanto, existe una vecindad U de $\bar{x}$ tal que $D \cap U = \{\bar{x}\}$. Al ser el único punto factible en dicha vecindad, la condición $f(\bar{x}) \leq f(x)$ se cumple trivialmente para todo $x \in D \cap U$. ■

2.2. Condiciones de Primer Orden y Estructura Afín

Lema 2.2 (Dualidad del Núcleo). Para cualquier matriz $A \in \mathbb{R}^{l \times n}$, el cono dual de su subespacio nulo coincide con la imagen de su matriz transpuesta:

$$(\ker A)^* = \mathfrak{S}(A)^\top.$$

Prueba. Sea $y \in \mathfrak{S}(A)^\top$, esto es, $y = A^\top \lambda$ para algún $\lambda \in \mathbb{R}^l$. Para todo $x \in \ker A$:

$$\langle y, x \rangle = \langle A^\top \lambda, x \rangle = \langle \lambda, Ax \rangle = \langle \lambda, 0 \rangle = 0 \leq 0.$$

Por lo tanto, $\mathfrak{S}(A)^\top \subset (\ker A)^*$. Supóngase, por reducción al absurdo, que exista $z \in (\ker A)^* \setminus \mathfrak{S}(A)^\top$. Por el Teorema de Proyección Ortogonal en espacios de Hilbert, $\mathbb{R}^n = \ker A \oplus \mathfrak{S}(A)^\top$. Existen vectores únicos $u \in \ker A$ y $w \in \mathfrak{S}(A)^\top$ tales que $z = u + w$. Como $z \notin \mathfrak{S}(A)^\top$, la proyección $u \neq 0$.

Dado que $z \in (\ker A)^*$, se tiene $\langle z, x \rangle \leq 0$ para todo $x \in \ker A$. Evaluando en $x = u$:

$$0 \geq \langle z, u \rangle = \langle u + w, u \rangle = \|u\|^2 + \langle w, u \rangle.$$

Como los subespacios son ortogonales, $\langle w, u \rangle = 0$, lo que implica que $0 \geq \|u\|^2$. Esto fuerza a $u = 0$, lo cual contradice la hipótesis. Luego, $(\ker A)^* \subset \mathfrak{S}(A)^\top$. ■

Ejemplo 2.5 (Cálculo Explícito de la Dualidad). Considérese la transformación lineal definida por la matriz fila ($l = 1, n = 3$): $A = (1 \quad -1 \quad 0)$. El subespacio nulo $\ker A$ es el plano generado por $(1, 1, 0)^\top$ y $(0, 0, 1)^\top$. La imagen de la matriz transpuesta $\mathfrak{S}(A)^\top$ es la recta paramétrica $\lambda(1, -1, 0)^\top$.

Construimos el cono dual del núcleo $(\ker A)^*$ a partir de la definición de cono dual. Sea $y \in (\ker A)^*$. Debe cumplirse que $\langle y, x \rangle \leq 0$ para todo $x \in \ker A$. Al ser $\ker A$ un subespacio, si $x \in \ker A$, entonces $-x \in \ker A$.

Evaluando la desigualdad: $\langle y, x \rangle \leq 0$ y $\langle y, -x \rangle \leq 0 \implies \langle y, x \rangle = 0$. Evaluando la condición de ortogonalidad sobre los vectores que generan el núcleo obtenemos $y_1 + y_2 = 0$ y $y_3 = 0$. Deducimos que todo elemento del cono dual debe tener la forma $y = y_1(1, -1, 0)^\top$. Este conjunto coincide con la parametrización de $\mathfrak{S}(A)^\top$. Este resultado ilustra el cono dual de un subespacio vectorial y explica por qué los multiplicadores de Lagrange asociados a restricciones de igualdad pertenecen a $\mathbb{R}^l$ sin restricciones de signo.

Definición 2.3 (Función Lagrangiana). Se define la aplicación **Lagrangiana** asociada al problema (2.1), $L : \mathbb{R}^n \times \mathbb{R}^l \rightarrow \mathbb{R}$, como:

$$L(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle.$$

El gradiente respecto al vector primal x se expresa matricialmente mediante:

$$\nabla_x L(x, \lambda) = \nabla f(x) + J_h(x)^\top \lambda.$$

Nota: Equilibrio de Fuerzas y Precio Sombra

La ecuación estacionaria $\nabla f(\bar{x}) + \sum \lambda_i \nabla h_i(\bar{x}) = 0$ admite una interpretación física directa. Si se interpreta $-\nabla f$ como una fuerza que actúa sobre una partícula, y cada gradiente ∇h_i como la fuerza normal ejercida por la superficie de la restricción, el multiplicador λ_i representa la magnitud de la fuerza de reacción necesaria para mantener el equilibrio estático de la partícula.

Proposición 2.2 (Estructura Algebraica de los Multiplicadores). Para un punto $\bar{x} \in \mathbb{R}^n$ fijo, definase el conjunto de multiplicadores de Lagrange asociados como:

$$\mathcal{M}(\bar{x}) = \{\lambda \in \mathbb{R}^l \mid \nabla_x L(\bar{x}, \lambda) = 0\}.$$

Si $\mathcal{M}(\bar{x}) \neq \emptyset$ y $\bar{\lambda} \in \mathcal{M}(\bar{x})$ es un elemento particular, entonces $\mathcal{M}(\bar{x})$ constituye una variedad afin parametrizada por:

$$\mathcal{M}(\bar{x}) = \bar{\lambda} + \ker(J_h(\bar{x})^\top).$$

Prueba. De acuerdo con la Definición 2.3, la condición de estacionariedad respecto al vector primal x equivale a resolver el sistema lineal $J_h(\bar{x})^\top \lambda = -\nabla f(\bar{x})$. Procederemos por doble inclusión:

($\subset$): Sea $\lambda \in \mathcal{M}(\bar{x})$ un multiplicador arbitrario. Entonces, $J_h(\bar{x})^\top \lambda = -\nabla f(\bar{x})$. Por hipótesis, disponemos de un elemento $\bar{\lambda} \in \mathcal{M}(\bar{x})$, el cual satisface $J_h(\bar{x})^\top \bar{\lambda} = -\nabla f(\bar{x})$. Restando ambas ecuaciones se obtiene $J_h(\bar{x})^\top (\lambda - \bar{\lambda}) = 0$. Esto significa que $(\lambda - \bar{\lambda}) \in \ker(J_h(\bar{x})^\top)$. Despejando se obtiene $\lambda = \bar{\lambda} + v$ para algún $v \in \ker(J_h(\bar{x})^\top)$, lo que demuestra que $\mathcal{M}(\bar{x}) \subset \bar{\lambda} + \ker(J_h(\bar{x})^\top)$.

($\supset$): Recíprocamente, sea $\lambda \in \bar{\lambda} + \ker(J_h(\bar{x})^\top)$. Esto implica la existencia de un vector $v \in \ker(J_h(\bar{x})^\top)$ tal que $\lambda = \bar{\lambda} + v$. Evaluando la transformación lineal: $J_h(\bar{x})^\top \lambda = J_h(\bar{x})^\top \bar{\lambda} + J_h(\bar{x})^\top v = -\nabla f(\bar{x}) + 0 = -\nabla f(\bar{x})$. Esto equivale a $\nabla_x L(\bar{x}, \lambda) = 0$. Por consiguiente, $\lambda \in \mathcal{M}(\bar{x})$, lo que demuestra que $\bar{\lambda} + \ker(J_h(\bar{x})^\top) \subset \mathcal{M}(\bar{x})$. ■

Ejemplo 2.6 (Multiplicadores en Ausencia de Regularidad). Considérese el problema de minimizar $f(x) = x_1^2 + x_2^2$ sujeto a un sistema de dos restricciones afines linealmente dependientes en $\mathbb{R}^2$: $h_1(x) = x_1 + x_2 - 1 = 0$ y $h_2(x) = 2x_1 + 2x_2 - 2 = 0$. El minimizador global es $\bar{x} = (1/2, 1/2)^\top$. El Jacobiano evaluado en $\bar{x}$ es una matriz cuyas dos filas son $(1, 1)$ y $(2, 2)$. El rango de la matriz es 1. Como $l = 2$, no se cumple la condición LICQ y la matriz transpuesta tiene un núcleo no trivial generado por $(-2, 1)^\top$. Determinamos el conjunto de multiplicadores $\mathcal{M}(\bar{x})$ resolviendo $J_h(\bar{x})^\top \lambda = -\nabla f(\bar{x})$, resultando $\lambda_1 + 2\lambda_2 = -1$. Un multiplicador particular es $\bar{\lambda} = (-1, 0)^\top \in \mathcal{M}(\bar{x})$. La Proposición 2.2 asegura que el conjunto de multiplicadores es la variedad afin:

$$\mathcal{M}(\bar{x}) = \left\{ \begin{pmatrix} -1 - 2t \\ t \end{pmatrix} \mid t \in \mathbb{R} \right\}.$$

La falta de regularidad conduce a la pérdida de la unicidad del multiplicador.

Teorema 2.4 (Condiciones de Optimalidad de Lagrange). Sea $\bar{x} \in D$ un minimizador local del problema de optimización. Si el punto $\bar{x}$ es regular (Definición 2.2), entonces $\mathcal{M}(\bar{x}) \neq \emptyset$. Adicionalmente, si la regularidad proviene de la condición LICQ, el multiplicador es único ($\mathcal{M}(\bar{x}) = \{\bar{\lambda}\}$).

Prueba. Por el Teorema 2.3, el opuesto del gradiente de la función objetivo pertenece al cono dual del núcleo: $-\nabla f(\bar{x}) \in (\ker J_h(\bar{x}))^*$. Invocando el Lema 2.2, obtenemos $-\nabla f(\bar{x}) \in \mathfrak{S}(J_h(\bar{x}))^\top$. Por definición, existe un vector $\bar{\lambda} \in \mathbb{R}^l$ tal que $J_h(\bar{x})^\top \bar{\lambda} = -\nabla f(\bar{x})$, lo cual equivale a $\nabla_x L(\bar{x}, \bar{\lambda}) = 0$. Bajo la hipótesis LICQ, la matriz transpuesta es inyectiva ($\ker(J_h(\bar{x})^\top) = \{0\}$). Aplicando la Proposición 2.2, el subespacio afin $\mathcal{M}(\bar{x})$ se reduce a un único vector. ■

Pregunta de Control

Pregunta: Si se resuelve el sistema de Lagrange y se halla un punto $\bar{x}$ con su respectivo multiplicador $\bar{\lambda}$, ¿es posible asegurar que se trata de un mínimo local?

Respuesta: No. El Teorema de Lagrange establece únicamente una condición necesaria de primer orden. El punto obtenido podría corresponder a un máximo local o a un punto de silla sobre la variedad factible. Para determinar la naturaleza del punto, es indispensable realizar un análisis de segundo orden.

Ejemplo 2.7. Considérese el problema geométrico de proyectar un vector $y \in \mathbb{R}^n$ sobre el hiperplano afín $H = \{x \in \mathbb{R}^n \mid \langle a, x \rangle = c\}$, con $a \neq 0$. Esto se formula como $\min \frac{1}{2} \|x - y\|^2$ sujeto a $\langle a, x \rangle - c = 0$. Al ser la restricción afín, se verifica la condición de regularidad (Definición 2.2). El sistema de Lagrange impone $\nabla_x L(\bar{x}, \bar{\lambda}) = (\bar{x} - y) + \bar{\lambda}a = 0 \implies \bar{x} = y - \bar{\lambda}a$. Utilizando la condición de factibilidad ($\langle a, \bar{x} \rangle = c$) y la linealidad del producto interno, obtenemos $\bar{\lambda} = (\langle y, a \rangle - c) / \|a\|^2$. Sustituyendo este escalar, obtenemos la proyección ortogonal clásica:

$$\bar{x} = y + \left(\frac{c - \langle y, a \rangle}{\|a\|^2} \right) a.$$

Ejemplo 2.8. Determinéense los minimizadores y maximizadores globales de la función $f(x) = \frac{x_1^3}{3} + x_2$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 = 1\}$. El gradiente de la restricción, $\nabla h(x) = 2(x_1, x_2)^\top$, no se anula en D , lo que verifica la condición LICQ. El sistema de Lagrange requiere $x_1^2 + 2\lambda x_1 = 0$ y $1 + 2\lambda x_2 = 0$. La primera ecuación se puede factorizar como $x_1(x_1 + 2\lambda) = 0$, lo que permite dividir el análisis en dos casos:

1. Si $x_1 = 0$, la condición de factibilidad implica $x_2 = \pm 1$. La segunda ecuación determina $\lambda = \mp 1/2$. Esto genera los puntos estacionarios $(0, 1)$ y $(0, -1)$.
2. Si $x_1 \neq 0$, entonces $x_1 = -2\lambda$. La segunda ecuación exige $x_2 = -1/(2\lambda)$. Sustituyendo en la ecuación de la esfera se obtiene $16\lambda^4 - 4\lambda^2 + 1 = 0$. El discriminante de esta ecuación bicuadrática es negativo, por lo que no existen raíces reales en este caso.

Evaluando la función objetivo en los puntos obtenidos, $f(0, 1) = 1$ y $f(0, -1) = -1$, identificamos el máximo y el mínimo global sobre el conjunto factible.

2.3. Condiciones diferenciales de segundo orden

Teorema 2.5 (Condición necesaria de segundo orden). Supóngase que f, h son de clase $\mathcal{C}^2$ en una vecindad de $\bar{x} \in D$, siendo $\bar{x}$ un minimizador local regular. Entonces, para todo $\lambda \in \mathcal{M}(\bar{x})$, el operador Hessiano de la Lagrangiana es semidefinido positivo al restringirse sobre el subespacio tangente:

$$\langle \nabla_{xx}^2 L(\bar{x}, \lambda) d, d \rangle \geq 0 \quad \forall d \in \ker J_h(\bar{x}). \quad (2.3)$$

Prueba. Sea $d \in \ker J_h(\bar{x})$. Por el Teorema del Subespacio Tangente (Teorema 2.2), $d \in \mathcal{T}_D(\bar{x})$. Por definición secuencial, para todo $t \in \mathbb{R}$ suficientemente pequeño, existe un punto $x(t) \in D$ parametrizado por $x(t) = \bar{x} + td + r(t)$, donde $\|r(t)\| = o(t)$. Como la trayectoria yace en la variedad factible, $h(x(t)) = 0$ y $h(\bar{x}) = 0$. Por consiguiente, para cualquier $\lambda \in \mathcal{M}(\bar{x})$, la variación de la función objetivo coincide con la variación de la Lagrangiana: $f(x(t)) - f(\bar{x}) = L(x(t), \lambda) - L(\bar{x}, \lambda)$.

Aplicando el desarrollo de Fréchet de segundo orden a la Lagrangiana en torno a $\bar{x}$ (y denotando $\Delta x = td + r(t)$):

$$L(x(t), \lambda) - L(\bar{x}, \lambda) = \langle \nabla_x L(\bar{x}, \lambda), \Delta x \rangle + \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda) \Delta x, \Delta x \rangle + o(\|\Delta x\|^2).$$

Como $\lambda \in \mathcal{M}(\bar{x})$, el término lineal se anula. Al expandir la forma cuadrática, y dado que $\|r(t)\| = o(t)$, los términos cruzados y dependientes de $r(t)$ se incorporan al término residual $o(t^2)$, obteniéndose $f(x(t)) - f(\bar{x}) = \frac{t^2}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda) d, d \rangle + o(t^2)$. Dado que $\bar{x}$ es un mínimo local, se requiere que $f(x(t)) - f(\bar{x}) \geq 0$. Sustituyendo esta condición, dividiendo por $t^2 > 0$ y tomando el límite cuando $t \rightarrow 0$, se concluye que $\langle \nabla_{xx}^2 L(\bar{x}, \lambda) d, d \rangle \geq 0$. ■

Nota: Propiedad cancelativa de la Lagrangiana

En la demostración anterior ocurre una simplificación relevante. Si se aplicara el desarrollo de Taylor directamente a la función objetivo $f(x(t))$ usando el vector tangente $\Delta x = td + r(t)$, el término lineal $\langle \nabla f(\bar{x}), r(t) \rangle$ introduciría un error de orden $o(t)/t^2$ que no se anula al dividir por t^2 . Al emplear la función Lagrangiana, la

condición de primer orden garantiza que $\nabla_x L(\bar{x}, \lambda) = 0$. Este hecho **anula el efecto del término residual** $r(t)$ en primer orden, permitiendo que el término de segundo orden ($\nabla_{xx}^2 L$) determine el comportamiento asintótico de la función.

Ejemplo 2.9 (La curvatura de la restricción domina). Considérese el problema de maximizar la altura sobre una parábola invertida, equivalente a $\min f(x) = -x_2$ sujeto a $h(x) = x_2 - x_1^2 = 0$. El único punto estacionario geométrico es el vértice de la parábola, $\bar{x} = (0, 0)^\top$. El gradiente de la restricción es $\nabla h(x) = (-2x_1, 1)^\top$. Evaluado en el origen resulta en $(0, 1)^\top \neq 0$, lo que cumple la condición LICQ. Planteamos el sistema de Lagrange de primer orden: $\nabla f(\bar{x}) + \lambda \nabla h(\bar{x}) = (0, -1)^\top + \lambda(0, 1)^\top = (0, 0)^\top$, lo que implica $\bar{\lambda} = 1$.

Evaluamos ahora la Condición Necesaria de Segundo Orden. Las matrices Hessianas de las funciones individuales son nulas o constantes. La matriz Hessiana global de la Lagrangiana evaluada en $(\bar{x}, \bar{\lambda})$ es $\nabla_{xx}^2 L(\bar{x}, \bar{\lambda}) = \begin{pmatrix} -2 & 0 \\ 0 & 0 \end{pmatrix}$. Esta matriz es semidefinida negativa. Calculamos el núcleo de la matriz Jacobiana, obteniendo $\ker J_h(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \in \mathbb{R}\}$. Para una dirección tangente genérica $d = (d_1, 0)^\top$, proyectamos la Hessiana de la Lagrangiana: $\langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda})d, d \rangle = -2d_1^2$. Para todo $d_1 \neq 0$, esta forma cuadrática proyectada resulta en un valor estrictamente negativo. Por lo tanto, la condición necesaria de segundo orden (2.3) **no se cumple**. Se concluye entonces que $\bar{x} = (0, 0)^\top$ no es un mínimo local.

Teorema 2.6 (Condición suficiente de segundo orden). Sea $\bar{x} \in D$, con f, h de clase $\mathcal{C}^2$. Si la estructura diferencial en el punto satisface la condición estrictamente definida positiva sobre el núcleo:

$$\forall d \in \ker J_h(\bar{x}) \setminus \{0\}, \quad \exists \lambda \in \mathcal{M}(\bar{x}) \quad \text{t.q.} \quad \langle \nabla_{xx}^2 L(\bar{x}, \lambda)d, d \rangle > 0, \quad (2.4)$$

entonces $\bar{x}$ es un minimizador local estricto, y satisface la condición de crecimiento cuadrático local sobre D . Recíprocamente, si se verifica una de las condiciones de regularidad y el crecimiento cuadrático local rige, entonces la condición (2.4) se cumple necesariamente.

Prueba. Para demostrar la suficiencia, supóngase por reducción al absurdo que la condición (2.4) se verifica, pero el crecimiento cuadrático no se cumple. En tal caso, existe una sucesión factible $\{x^k\} \subset D \setminus \{\bar{x}\}$ que converge a $\bar{x}$ y que satisface $f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|^2$ para todo $k \in \mathbb{N}$. Por compacidad, se extrae una subsucesión de direcciones normalizadas d^k convergente a un vector unitario $d \in \mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x})$.

Sea $\lambda \in \mathcal{M}(\bar{x})$ el multiplicador cuya existencia asegura la hipótesis (2.4) para esta dirección particular. Sustituyendo el desarrollo de Fréchet de la Lagrangiana: $\frac{1}{k} \|x^k - \bar{x}\|^2 > \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda)(x^k - \bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|^2)$. Dividiendo la desigualdad por $\|x^k - \bar{x}\|^2 > 0$ y tomando el límite cuando $k \rightarrow \infty$, se obtiene $0 \geq \langle \nabla_{xx}^2 L(\bar{x}, \lambda)d, d \rangle$, lo cual contradice la hipótesis de positividad estricta.

Para probar el recíproco, supóngase que el crecimiento cuadrático se cumple con una constante $\beta > 0$, se sostiene la condición de regularidad, pero la condición (2.4) no se verifica. Esto implica la existencia de una dirección $d \in \ker J_h(\bar{x}) \setminus \{0\}$ tal que para todo $\lambda \in \mathcal{M}(\bar{x})$, la forma cuadrática es ≤ 0 . Dado que $d \in \mathcal{T}_D(\bar{x})$, existe una trayectoria factible $x(t) = \bar{x} + td + r(t) \in D$. Evaluando la condición de crecimiento cuadrático: $\beta \|td + r(t)\|^2 \leq f(x(t)) - f(\bar{x}) = \frac{t^2}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda)d, d \rangle + o(t^2) \leq o(t^2)$. Dividiendo la ecuación por t^2 y tomando el límite cuando $t \rightarrow 0^+$, el residuo se anula obteniéndose $\beta \|d\|^2 \leq 0$. Como $\beta > 0$, esto implica que $d = 0$, lo cual contradice la elección de un vector $d \neq 0$. ■

Ejemplo 2.10 (La silla de montar restringida). Considérese la minimización de una función de silla clásica sujeta a una restricción lineal: $\min f(x) = x_1^2 - x_2^2$ sujeto a $h(x) = x_1 - x_2 = 0$. El origen $\bar{x} = (0, 0)^\top$ es el único punto de intersección y candidato a análisis. El sistema de Lagrange se cumple para el multiplicador $\bar{\lambda} = 0$. A nivel irrestricto, la matriz Hessiana de la función objetivo es indefinida (con autovalores 2 y -2). Dado que la restricción es afín, $\nabla_{xx}^2 L(\bar{x}, \bar{\lambda}) = \nabla^2 f(\bar{x})$.

Aplicamos el Teorema 2.6 analizando el subespacio tangente (núcleo del Jacobiano), que está generado por $d = (d_1, d_1)^\top$. Evaluando la forma cuadrática proyectada de la Lagrangiana, se obtiene $2d_1^2 - 2d_1^2 = 0$. La forma cuadrática proyectada resulta ser idénticamente cero, por lo que la condición de positividad estricta no se cumple y el análisis diferencial de segundo orden no es concluyente. No obstante, si se sustituye la restricción $x_1 = x_2$ directamente en la función objetivo, se observa que $f(x(t)) = 0$. La función es constante a lo largo del subespacio tangente y el punto es un mínimo global no estricto.

Ejemplo 2.11 (La Hessiana proyectada positiva). Considérese el problema: $\min f(x) = x_1^2 - x_2^2$ sujeto a $h(x) = x_2 = 0$. El punto estacionario en el origen es $\bar{x} = (0, 0)^\top$. El sistema de Lagrange evaluado en el origen resulta en

$\bar{\lambda} = 0$. La matriz Hessiana de la Lagrangiana es indefinida en el espacio total. Aplicamos el Teorema 2.6 calculando el subespacio tangente: $\ker J_h(\bar{x}) = \{(d_1, 0)^T \mid d_1 \in \mathbb{R}\}$. Para una dirección tangente no nula, evaluamos la forma cuadrática proyectada obteniendo $2d_1^2 > 0$. Este resultado ilustra la aplicación del teorema: aunque la matriz Hessiana global presenta un autovalor negativo en la dirección de x_2 , la restricción descarta este eje de descenso. En el subespacio tangente permitido, la curvatura es estrictamente positiva. En consecuencia, se concluye que $\bar{x} = (0, 0)^T$ es un mínimo local estricto.

Atención: Ventaja sobre criterios clásicos

La literatura clásica frecuentemente exige una condición suficiente basada en un multiplicador único. Dicha formulación exige utilizar un único multiplicador común para todas las direcciones. El Teorema 2.6 resulta más general, ya que al ser $\mathcal{M}(\bar{x})$ un conjunto afín, permite asociar diferentes multiplicadores a distintas direcciones tangentes para verificar la condición de positividad.

Contraejemplo 2.1 (Colapso del multiplicador uniforme). Sean $f(x) = -x_1^2 - x_2^2$ y $h(x) = (x_1 x_2, x_1^2 - x_2^2)^T = 0$. El origen $\bar{x} = 0$ es el único punto factible. Los gradientes se anulan en dicho punto, lo que da lugar a $\ker J_h(0) = \mathbb{R}^2$ y $\mathcal{M}(0) = \mathbb{R}^2$. El operador Hessiano de la Lagrangiana tiene traza -4 para cualquier valor de λ . Dado que la traza es negativa, esta matriz no puede ser definida positiva. En consecuencia, no existe un multiplicador único $\bar{\lambda}$ que garantice la positividad de la forma cuadrática para toda dirección d . Sin embargo, para cada dirección específica $d \neq 0$, es posible elegir un vector $\lambda(d)$ adecuado que asegure la positividad de la forma cuadrática.

Ejercicios del Capítulo

Parte I: Mecánica Primal-Dual y Fallas Topológicas

Ejercicio 2.1. Determinéense los minimizadores y maximizadores globales del funcional lineal $f(x) = \sum_{i=1}^n x_i$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^n \mid \|x\|^2 = 1\}$.

Ejercicio 2.2. Hállense los minimizadores de la función $f(x) = \|x\|^2$ sujetos a las siguientes restricciones:

- El hiperplano afín $h(x) = 1 - \sum_{i=1}^n x_i = 0$.
- La superficie cuádrica $h(x) = 1 - \langle Qx, x \rangle = 0$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica.

Ejercicio 2.3. Verifíquese analíticamente que el punto $\bar{x} = (0, 0) \in \mathbb{R}^2$ es la solución global del problema $\min x_2$ sujeto a la intersección de las circunferencias $(x_1 - 1)^2 + x_2^2 = 1$ y $(x_1 + 1)^2 + x_2^2 = 1$. Demuestre que $\bar{x}$ no cumple con las condiciones de regularidad y que el sistema de Lagrange no admite solución en dicho punto.

Ejercicio 2.4. Demuestre que $\bar{x} = (0, 0) \in \mathbb{R}^2$ es la solución global del problema $\min x_1^2 + x_2^2$ sujeto a la restricción $(x_1 - 1)^3 = x_2^2$, y explique por qué las condiciones de optimalidad de Lagrange no se cumplen en este punto debido a la falta de regularidad (falta de LICQ).

Ejercicio 2.5 (Pérdida de la condición LICQ por reformulación no lineal). Sea el conjunto factible $D = \{x \in \mathbb{R}^n \mid h(x) = 0\}$, donde $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ cumple la condición LICQ en todo punto de D . Considérese el problema de minimización de $f(x)$ sobre D . Supóngase que se reformula el problema utilizando la restricción escalar equivalente: $\tilde{h}(x) = \frac{1}{2} \|h(x)\|^2 = 0$.

- Demuestre que el nuevo conjunto factible $\tilde{D} = \{x \in \mathbb{R}^n \mid \tilde{h}(x) = 0\}$ coincide con D .
- Pruebe analíticamente que ningún punto de $\tilde{D}$ cumple la condición de regularidad LICQ para la restricción $\tilde{h}$.
- Explique por qué el sistema de Lagrange asociado a $\tilde{h}$ no permite identificar los puntos óptimos del problema original, analizando la diferencia entre la representación algebraica y el conjunto geométrico.

Ejercicio 2.6 (El Cilindro y el Plano Tangente). Considérese la superficie descrita por $h(x) = x_1^2 + x_2^2 - x_3 = 0$ (un paraboloide).

- Evalúe el punto $\bar{x} = (1, 1, 2)^T$. Demuestre que se cumple LICQ y halle una base ortonormal para el subespacio tangente $\ker J_h(\bar{x})$.

2. Considere la curva parametrizada $x(t) = (\cos t, \sin t, 1)^T$. Verifique que la curva pertenece a la variedad para todo t , y demuestre que el vector velocidad $x'(0)$ es una combinación lineal de los vectores de la base obtenida en el inciso anterior.

Ejercicio 2.7 (Dependencia Funcional y Conjuntos de Nivel). Sea $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ una función escalar de clase $\mathcal{C}^1$. Considérese el problema de minimizar $f(x)$ sujeto a que el punto pertenezca a una curva de nivel de otra función suave: $h(x) = g(x) - c = 0$. Demuestre que, si el punto $\bar{x}$ es un óptimo regular, entonces las curvas de nivel de f y de g que pasan por $\bar{x}$ son tangentes entre sí en dicho punto. Interprete este resultado geoméricamente usando los gradientes.

Ejercicio 2.8 (Intersección de dimensión mixta y puntos aislados). Sea el conjunto factible en $\mathbb{R}^3$ definido por $h_1(x) = x_1^2 + x_2^2 - x_3 = 0$ y $h_2(x) = x_3 = 0$.

1. Describa geoméricamente el conjunto resultante D .
2. Demuestre que el único punto en D es el origen $(0, 0, 0)^T$.
3. Calcule la matriz Jacobiana $J_h(0)$. Determine si el origen es un punto regular y analice, desde una perspectiva geométrica y topológica, por qué la intersección de estas restricciones produce un punto aislado en lugar de una curva.

Parte II: Condiciones Diferenciales de Segundo Orden y Matriz KKT

Ejercicio 2.9. Determine los extremos locales y globales de la función $f(x) = x_1^3/3 + x_2$ restringida a la esfera $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 = 2\}$.

Ejercicio 2.10 (El Sistema Lineal de Karush-Kuhn-Tucker). Sea el funcional cuadrático generalizado $f(x) = \frac{1}{2}\langle Qx, x \rangle + \langle q, x \rangle$ sujeto a la restricción afín sobreyectiva $Ax = a$. Asumiendo que Q es simétrica y definida positiva, pruébese la unicidad de la solución primal-dual y determínese analíticamente el sistema matricial de bloques (Matriz KKT) que resuelven los vectores x y λ simultáneamente.

Ejercicio 2.11 (No-singularidad Numérica de la Matriz KKT). Generalizando el ejercicio anterior, sea $\bar{x} \in D$ un punto estacionario regular (LICQ) para un problema no lineal de optimización, con multiplicador único $\bar{\lambda}$. Definase el Hessiano $H = \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}) \in \mathbb{R}^{n \times n}$ y el Jacobiano $A = J_h(\bar{x}) \in \mathbb{R}^{l \times n}$. Supóngase que se cumple la condición suficiente de segundo orden estricta: $\langle Hd, d \rangle > 0$ para todo $d \in \ker A \setminus \{0\}$. Demuéstrese que la matriz de bloques KKT:

$$K = \begin{pmatrix} H & A^T \\ A & 0 \end{pmatrix} \in \mathbb{R}^{(n+l) \times (n+l)}$$

es invertible. (Ayuda: Suponga que $K \begin{pmatrix} d \\ y \end{pmatrix} = 0$, multiplique la primera fila de bloques por d^T y utilice la condición de positividad sobre el núcleo para deducir que $d = 0$).

Ejercicio 2.12 (Valores Propios como Extremos de Rayleigh). Sea $Q \in \mathbb{R}^{n \times n}$ una matriz simétrica. Utilícese el sistema de optimalidad para encontrar todos los minimizadores y maximizadores de la forma cuadrática $f(x) = \langle Qx, x \rangle$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^n \mid \|x\|^2 = 1\}$. Caracterícese el conjunto de multiplicadores de Lagrange en términos de los autovalores de la matriz Q .

Ejercicio 2.13 (Degeneración de la Condición Necesaria). Considérese el problema $\min f(x) = x_1^4 + x_2^4$ sujeto a $h(x) = x_1 + x_2 = 0$. Verifique analíticamente que $\bar{x} = (0, 0)$ es el minimizador global estricto del problema. Sin embargo, al calcular la matriz Hessiana de la Lagrangiana evaluada sobre el núcleo de la restricción, demuestre que el resultado es la matriz nula. Muestre que cuando las de menor orden se anulan, las aproximaciones cuadráticas no bastan para asegurar la suficiencia analítica de segundo orden.

Ejercicio 2.14 (Descomposición Espectral en Lagrange). Minimice la función $f(x) = x_1^2 + x_2^2 + x_3^2$ sujeta a la restricción no lineal $h(x) = x_1 x_2 x_3 - 1 = 0$.

1. Encuentre todos los puntos estacionarios y sus respectivos multiplicadores de Lagrange.
2. Calcule la matriz Hessiana de la Lagrangiana en dichos puntos.
3. Proyecte la matriz Hessiana sobre el subespacio tangente y utilice el criterio de los autovalores para determinar cuáles puntos son mínimos locales. (Ayuda: Analice la simetría de las coordenadas).

Ejercicio 2.15 (Puntos de Ensilladura Restringidos). Considere el problema $\min x_1 x_2$ sujeto a $x_1 + x_2 = 2$. Demuestre que el único punto estacionario del sistema de Lagrange es $\bar{x} = (1, 1)^T$. Evaluando las condiciones necesarias y suficientes de segundo orden, pruebe que este punto no es un minimizador local, sino que corresponde a un máximo global restringido.

Ejercicio 2.16 (La Matriz Fronteada (Bordered Hessian)). Sea un problema con restricciones afines $Ax = a$. La matriz KKT $K = \begin{pmatrix} H & A^T \\ A & 0 \end{pmatrix}$ es simétrica. Demuestre que, incluso si H es estrictamente definida positiva, la matriz de bloques completa K es siempre indefinida (posee tanto autovalores estrictamente positivos como estrictamente negativos). Este resultado explica por qué los algoritmos de optimización numérica suelen utilizar factorizaciones como LDL^T en lugar de la factorización de Cholesky.

Parte III: Aplicaciones Físicas, Análisis de Sensibilidad y Variedades Matriciales

Ejercicio 2.17 (Precio Sombra y Análisis de Sensibilidad). Considérese el problema parametrizado $\min f(x)$ sujeto a $h(x) = p$, donde $p \in \mathbb{R}^l$ es un vector de perturbaciones de frontera. Sea $\bar{x}$ un mínimo local estricto para el problema nominal ($p = 0$), regular (LICQ) y que satisface las condiciones suficientes de segundo orden con multiplicador único $\bar{\lambda}$. Invocando el Teorema de la Función Implícita sobre el sistema KKT, existe una trayectoria suave de minimizadores locales $x(p)$ con $x(0) = \bar{x}$. Definase la función valor óptimo $v(p) = f(x(p))$. Aplicando la regla de la cadena multivariable y la ecuación estacionaria de Lagrange, demuéstrese rigurosamente que: $\nabla_p v(0) = -\bar{\lambda}$. Interprete este resultado desde una perspectiva geométrica y económica, relacionando el multiplicador de Lagrange con la sensibilidad del valor óptimo frente a variaciones en el término independiente de la restricción.

Ejercicio 2.18 (Problema Isoperimétrico de Herón). Entre todos los triángulos de perímetro fijo $2p > 0$, utilícense las condiciones de optimalidad de Lagrange de primero y segundo orden para demostrar que el triángulo que maximiza el área es el triángulo equilátero. (Ayuda: Modele el problema maximizando el cuadrado del área mediante la fórmula de Herón $f(x, y, z) = p(p-x)(p-y)(p-z)$ sujeto a la restricción afín $x + y + z = 2p$).

Ejercicio 2.19 (Principio de Fermat y la Ley de Snell). Un rayo de luz viaja desde el punto $A = (0, y_A)$ en un medio isótropo con velocidad v_1 , hasta un punto $B = (x_B, y_B)$ en un medio con velocidad v_2 . La interfaz de refracción entre ambos medios es la recta horizontal $y = 0$. Modele el problema buscando el punto de cruce $P = (x, y) \in \mathbb{R}^2$ que minimiza el tiempo total de viaje $T(x, y) = \frac{\|P-A\|}{v_1} + \frac{\|B-P\|}{v_2}$ sujeto a la restricción de frontera $h(x, y) = y = 0$. Resolviendo el sistema de Lagrange, obténgase analíticamente la Ley de Snell.

Ejercicio 2.20 (Distribución Uniforme y Entropía de Shannon). En Teoría de la Información, la entropía de una distribución de probabilidad discreta $x \in \mathbb{R}^n$ (con $x_i > 0$) se define como el funcional $\mathcal{H}(x) = -\sum_{i=1}^n x_i \ln(x_i)$. Demuestre analíticamente que el problema de maximización de entropía $\max \mathcal{H}(x)$ sujeto a $\sum_{i=1}^n x_i = 1$ es resuelto unívocamente por la distribución uniforme $\bar{x}_i = 1/n$ para todo i . Verifique el carácter de máximo global analizando los autovalores de la matriz Hessiana.

Ejercicio 2.21 (Proyección sobre el Grupo Ortogonal: El Problema de Procrustes). Sea el espacio de matrices cuadradas $M_n(\mathbb{R})$ equipado con el producto de Frobenius $\langle X, Y \rangle_F = \text{Tr}(X^T Y)$. Considérese el problema de encontrar la matriz ortogonal más cercana a una matriz dada $A \in M_n(\mathbb{R})$:

$$\min \frac{1}{2} \|X - A\|_F^2 \quad \text{sujeto a} \quad X^T X - I = 0.$$

Haciendo uso de las derivadas de Fréchet para funciones matriciales, defina la Lagrangiana (donde el multiplicador de Lagrange es una matriz simétrica $\Lambda \in M_n(\mathbb{R})$) y derive la ecuación matricial estacionaria.

Ejercicio 2.22 (Mecánica Clásica: El Péndulo Simple). Un péndulo consiste en una masa m sujeta al extremo de una varilla rígida de longitud L sin masa, cuyo otro extremo está fijo en el origen $(0, 0)$. La posición de la masa se denota por (x, y) . La energía potencial es $V(x, y) = mgy$. Modele las posiciones de equilibrio del péndulo determinando los extremos de $V(x, y)$ sujetos a la restricción de longitud $x^2 + y^2 = L^2$. Interprete el multiplicador de Lagrange como la fuerza de tensión en la varilla.

Ejercicio 2.23 (Microeconomía: Maximización de Utilidad). Un consumidor desea maximizar su función de utilidad Cobb-Douglas $U(x_1, x_2) = x_1^\alpha x_2^\beta$ (con $\alpha, \beta > 0$), sujeto a su restricción presupuestaria $p_1 x_1 + p_2 x_2 = I$, donde p_i son los precios e I el ingreso disponible.

1. Encuentre las funciones de demanda marshallianas $x_1(p_1, p_2, I)$ y $x_2(p_1, p_2, I)$ resolviendo el sistema de Lagrange.
2. Calcule el multiplicador de Lagrange óptimo λ^* .
3. Demuestre analíticamente que $\lambda^* = \frac{\partial U^*}{\partial I}$, verificando que el multiplicador representa la “utilidad marginal del ingreso”.

Ejercicio 2.24 (Problema de Optimización de Carteras de Markowitz). Un inversor desea construir un portafolio con n activos financieros. Sea $x \in \mathbb{R}^n$ el vector de ponderación de cada activo (fracción del capital invertido), tal que $\sum x_i = 1$. Sea $\Sigma \in \mathbb{R}^{n \times n}$ la matriz de covarianza de los retornos (simétrica y definida positiva) y $\mu \in \mathbb{R}^n$ el vector de retornos esperados. El inversor desea minimizar la varianza de la cartera $\frac{1}{2}x^\top \Sigma x$, sujeto a obtener un retorno esperado objetivo $\mu^\top x = R$, y a que la suma de las ponderaciones sea igual a 1 ($e^\top x = 1$, donde e es el vector de unos). Escriba el sistema KKT, halle la solución analítica para las ponderaciones óptimas x^* y demuestre que dicha solución es única.

Ejercicio 2.25 (Mínimos Cuadrados Restringidos). En estimación estadística, a menudo se requiere estimar parámetros sujetos a un conjunto de restricciones lineales exactas. Considere el problema de regresión $\min \frac{1}{2} \|Y - X\beta\|^2$ sujeto a $C\beta = d$, donde $Y \in \mathbb{R}^m$, $X \in \mathbb{R}^{m \times n}$ (con rango de columnas completo), $C \in \mathbb{R}^{l \times n}$ (rango de filas completo) y $d \in \mathbb{R}^l$. Encuentre la expresión analítica cerrada del estimador restringido β^* resolviendo el sistema de ecuaciones de Lagrange y compárelo con el estimador de mínimos cuadrados ordinarios irrestricto $\hat{\beta} = (X^\top X)^{-1} X^\top Y$.

3. Análisis convexo

En este capítulo estudiamos conjuntos convexos y funciones convexas. La convexidad es una noción muy importante en la teoría de optimización. Con hipótesis de convexidad, las condiciones necesarias de optimalidad pasan a ser suficientes. En otras palabras, todo punto estacionario se convierte en una solución del problema. En particular, cualquier minimizador local es global. Además, en el caso convexo podemos desarrollar la teoría de dualidad en su forma más completa, es decir, asociar al problema original (primal) otro problema, llamado dual, que bajo ciertas hipótesis es equivalente al original y a veces es más fácil de resolver.

Finalmente, las herramientas del Análisis Convexo serán necesarias para la caracterización del cono dual al cono tangente en el caso de restricciones mixtas (de igualdad y desigualdad), lo que resulta en las condiciones de optimalidad primal-duales de Karush-Kuhn-Tucker. Cabe resaltar que este capítulo no constituye un curso de Análisis Convexo completo; además de resultados básicos, presentamos solo el material que será necesario a lo largo de este libro.

3.1. Definiciones de convexidad. El problema de minimización convexo

Un conjunto convexo se caracteriza por contener todos los segmentos cuyos extremos pertenecen al conjunto.

Definición 3.1 (Conjunto convexo). Un conjunto $D \subset \mathbb{R}^n$ se llama **conjunto convexo** si para cualesquiera $x \in D$, $y \in D$ y $\alpha \in [0, 1]$, se tiene que

$$\alpha x + (1 - \alpha)y \in D.$$

El punto $\alpha x + (1 - \alpha)y$, donde $\alpha \in [0, 1]$, se llama **combinación convexa** de x e y (con parámetro α).

El conjunto vacío, el espacio $\mathbb{R}^n$ y un conjunto que contiene un solo punto son trivialmente convexos. Cualquier conjunto no convexo es trivialmente no convexo.

A continuación mostramos que la dualización de un cono cualquiera (incluso no convexo) siempre produce un cono convexo.

Proposición 3.1. Para todo cono $\emptyset \neq K \subset \mathbb{R}^n$, el cono dual K^* siempre es convexo y cerrado.

Prueba. Sean $x \in K^*$ e $y \in K^*$, es decir, $\langle x, d \rangle \leq 0$ e $\langle y, d \rangle \leq 0$ para todo $d \in K$. Sea $\alpha \in [0, 1]$. Para cualquier $d \in K$, tenemos que:

$$\langle \alpha x + (1 - \alpha)y, d \rangle = \alpha \langle x, d \rangle + (1 - \alpha) \langle y, d \rangle \leq 0,$$

es decir, $\alpha x + (1 - \alpha)y \in K^*$. Por lo tanto, K^* es convexo.

Sea $\{y^k\} \subset K^*$, $\{y^k\} \rightarrow y$ ($k \rightarrow \infty$). Fijando $d \in K$ arbitrario, y pasando al límite cuando $k \rightarrow \infty$ en la relación $\langle y^k, d \rangle \leq 0$, obtenemos que $\langle y, d \rangle \leq 0$. Por lo tanto, como $d \in K$ era arbitrario, $y \in K^*$. Esto muestra que K^* es cerrado. ■

Otros criterios de convexidad de conjuntos se presentarán en la siguiente sección. Mostramos a continuación que, para un conjunto convexo, el cono tangente (usual o de Bouligand) está dado por la clausura de todas las direcciones viables. Pero primero introducimos la siguiente noción.

Definición 3.2 (Cápsula cónica o envoltura cónica). Dado un conjunto $D \subset \mathbb{R}^n$ cualquiera, la **cápsula cónica** de D , denotado por $\text{cone } D$, es el menor cono convexo en $\mathbb{R}^n$ que contiene a D (o, equivalentemente, la intersección de todos los conos convexos en $\mathbb{R}^n$ que contienen a D).

Para un conjunto convexo, la cápsula cónica está compuesto por todos los múltiplos no negativos de elementos del conjunto.

Proposición 3.2 (Cápsula cónica de un conjunto convexo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Se tiene que:

$$\text{cone } D = \{d \in \mathbb{R}^n \mid d = \alpha x, x \in D, \alpha \in \mathbb{R}_+\}.$$

Prueba. Denotamos $C = \{d \in \mathbb{R}^n \mid d = \alpha x, x \in D, \alpha \in \mathbb{R}_+\}$. Como el conjunto cone D es un cono, para todo $x \in D \subset \text{cone } D$, tenemos que $\alpha x \in \text{cone } D$ para todo $\alpha \in \mathbb{R}_+$. Luego, $C \subset \text{cone } D$.

Observamos que C es un cono que contiene a D (basta tomar $\alpha = 1$). Por lo tanto, si demostramos que C es convexo, C será un cono convexo que contiene a D , de donde la inclusión $\text{cone } D \subset C$ será obvia por la Definición 3.2.

Sean $d^1 \in C, d^2 \in C$, es decir, $d^i = \alpha_i x^i, \alpha_i \in \mathbb{R}_+ \text{ e } x^i \in D, i = 1, 2$. Sea $d = td^1 + (1-t)d^2 = t\alpha_1 x^1 + (1-t)\alpha_2 x^2$, con $t \in [0, 1]$. Cuando $t \in \{0, 1\}$ o $\alpha_i = 0$ para algún $i \in \{1, 2\}$, la inclusión $d \in C$ es obvia. Supongamos entonces que $t \in (0, 1), \alpha_i > 0, i = 1, 2$. Definimos:

$$\beta = \left(1 + \frac{\alpha_2(1-t)}{\alpha_1 t}\right)^{-1} \in (0, 1).$$

Por la convexidad de D , tenemos que $x = \beta x^1 + (1-\beta)x^2 \in D$. Además,

$$\frac{\alpha_1 t}{\beta} x = \alpha_1 t(x^1 + (1/\beta - 1)x^2) = t\alpha_1 x^1 + (1-t)\alpha_2 x^2 = d,$$

mostrando que $d \in C$. Esto prueba que C es convexo. ■

A continuación probaremos un resultado importante sobre el cono tangente de un conjunto convexo.

Teorema 3.1 (Direcciones viables y cono tangente de un conjunto convexo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo, $\bar{x} \in D$. Entonces:

$$\mathcal{V}_D(\bar{x}) = \text{cone}(D - \{\bar{x}\}),$$

$$\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \text{cl } \mathcal{V}_D(\bar{x}) = \text{cl } \text{cone}(D - \{\bar{x}\}).$$

En particular, $\mathcal{T}_D(\bar{x})$ es convexo y cerrado.

Prueba. Es fácil ver que el conjunto $D - \{\bar{x}\}$ es convexo. Por lo tanto, por la Proposición 3.2:

$$\text{cone}(D - \{\bar{x}\}) = \{d \in \mathbb{R}^n \mid d = \alpha(x - \bar{x}), x \in D, \alpha \in \mathbb{R}_+\}. \quad (3.1)$$

Sea $d \in \text{cone}(D - \{\bar{x}\}), d \neq 0$ (luego, $\alpha > 0$). Esto significa que $\bar{x} + d/\alpha = x \in D$. Por la convexidad de D , se sigue que $\bar{x} + td \in D$ para todo $t \in [0, 1/\alpha]$, es decir, $d \in \mathcal{V}_D(\bar{x})$. Recíprocamente, para $d \in \mathcal{V}_D(\bar{x})$ se tiene que $\bar{x} + td \in D$ para todo $t \in [0, \epsilon]$. Por lo tanto, existe $x \in D$ tal que $x = \bar{x} + td, t > 0$. Luego, $d = (x - \bar{x})/t$, es decir, $d \in \text{cone}(D - \{\bar{x}\})$. Así, $\mathcal{V}_D(\bar{x}) = \text{cone}(D - \{\bar{x}\})$.

Como se estableció en el Capítulo 1, siempre se tiene que $\text{cl } \mathcal{V}_D(\bar{x}) \subset \mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$. Probamos la afirmación mostrando que $\mathcal{B}_D(\bar{x}) \subset \text{cl } \mathcal{V}_D(\bar{x})$.

Sea $d \in \mathcal{B}_D(\bar{x})$, es decir, existen $\{t_k\} \rightarrow 0+$ e $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$ para todo k . Como ya mostramos, esto significa que $d^k \in \mathcal{V}_D(\bar{x})$. En particular, concluimos que $d = \lim_{k \rightarrow \infty} d^k \in \text{cl } \mathcal{V}_D(\bar{x})$. ■

A continuación mostramos que un cono y su clausura tienen el mismo cono dual.

Proposición 3.3. Sea $K \subset \mathbb{R}^n$ un cono cualquiera. Entonces $\text{cl } K$ es un cono y se tiene que:

$$K^* = (\text{cl } K)^*.$$

En particular, si $D \subset \mathbb{R}^n$ es un conjunto convexo y $\bar{x} \in D$, se tiene que:

$$(\mathcal{T}_D(\bar{x}))^* = (\mathcal{V}_D(\bar{x}))^* = (\text{cone}(D - \{\bar{x}\}))^*.$$

Prueba. El hecho de que $\text{cl } K$ sea un cono es fácil de verificar. Por la definición de cono dual, la inclusión $K \subset \text{cl } K$ implica que $(\text{cl } K)^* \subset K^*$.

Sean $y \in K^*$ y $d \in \text{cl } K$ cualesquiera. Existe $\{d^k\} \subset K$ tal que $\{d^k\} \rightarrow d$. Tenemos que $\langle y, d^k \rangle \leq 0$ para todo k . Pasando al límite cuando $k \rightarrow \infty$, obtenemos que $\langle y, d \rangle \leq 0$. Por lo tanto, $y \in (\text{cl } K)^*$, es decir, $K^* \subset (\text{cl } K)^*$. Ahora, la última afirmación se sigue del Teorema 3.1. ■

Otra noción útil en Análisis Convexo es la de cono normal.

Definición 3.3 (Cono normal). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y $\bar{x} \in D$. El **cono normal** (o cono de direcciones normales) en el punto $\bar{x}$ con respecto al conjunto D está dado por:

$$\mathcal{N}_D(\bar{x}) = \{d \in \mathbb{R}^n \mid \langle d, x - \bar{x} \rangle \leq 0 \forall x \in D\}.$$

A continuación, mostramos que, en el caso convexo, el dual del cono tangente es exactamente el cono normal.

Teorema 3.2 (El cono normal es el dual del cono tangente). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y $\bar{x} \in D$. Entonces:

$$(\mathcal{T}_D(\bar{x}))^* = (\mathcal{V}_D(\bar{x}))^* = (\text{cone}(D - \{\bar{x}\}))^* = \mathcal{N}_D(\bar{x}).$$

Prueba. Las primeras dos igualdades ya fueron probadas en la Proposición 3.3. Supongamos que $y \in (\text{cone}(D - \{\bar{x}\}))^*$, es decir, $\langle y, d \rangle \leq 0$ para todo $d \in \text{cone}(D - \{\bar{x}\})$. En particular, $\langle y, x - \bar{x} \rangle \leq 0$ para todo $x \in D$, es decir, $y \in \mathcal{N}_D(\bar{x})$. Supongamos que $y \in \mathcal{N}_D(\bar{x})$. Tenemos que $\langle y, x - \bar{x} \rangle \leq 0$ para todo $x \in D$, es decir, $\langle y, d \rangle \leq 0$ para todo $d \in (D - \{\bar{x}\})$. Luego, $\langle y, d \rangle \leq 0$ para todo $d \in \text{cone}(D - \{\bar{x}\})$. Concluimos que $y \in (\text{cone}(D - \{\bar{x}\}))^*$. ■

Como consecuencia de la caracterización del cono tangente y de su dual, obtenemos las siguientes condiciones de optimalidad para un problema con conjunto factible convexo.

Teorema 3.3 (Condición necesaria de primer orden). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $\bar{x} \in D$. Si $\bar{x}$ es un minimizador local de f en el conjunto D , entonces:

$$\langle \nabla f(\bar{x}), x - \bar{x} \rangle \geq 0 \quad \forall x \in D, \quad (3.2)$$

o, equivalentemente,

$$-\nabla f(\bar{x}) \in \mathcal{N}_D(\bar{x}). \quad (3.3)$$

Prueba. Por las condiciones primales de primer orden del Capítulo 1, $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{B}_D(\bar{x})$. Por el Teorema 3.1, tenemos que:

$$\{d \in \mathbb{R}^n \mid d = x - \bar{x}, x \in D\} \subset \text{cone}(D - \{\bar{x}\}) \subset \mathcal{B}_D(\bar{x}),$$

lo que implica (3.2). Por la Definición 3.3, (3.2) y (3.3) son equivalentes. ■

Si la función f es convexa, la condición necesaria de optimalidad dada en el Teorema 3.3 también es suficiente.

Definición 3.4 (Funciones convexas, estrictas y fuertes). Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Se dice que una función $f : D \rightarrow \mathbb{R}$ es **convexa** en D si para cualesquiera $x \in D$, $y \in D$ y $\alpha \in [0, 1]$, se tiene:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y).$$

La función f se dice **estrictamente convexa** cuando la desigualdad anterior es estricta para todos los $x \neq y$ y $\alpha \in (0, 1)$.

La función f se dice **fuertemente convexa** con módulo $\gamma > 0$, cuando para cualesquiera $x, y \in D$ y $\alpha \in [0, 1]$, se tiene:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) - \gamma \alpha(1 - \alpha)\|x - y\|^2.$$

Es obvio que una función fuertemente convexa es estrictamente convexa, y una función estrictamente convexa es convexa. La función $f(x) = x^2$ es fuertemente convexa. La función $f(x) = e^x$ es estrictamente (pero no fuertemente) convexa. Una función afín $f(x) = x$ es convexa (pero no estricta).

Definición 3.5 (Epígrafe). El **epígrafe** de la función $f : D \rightarrow \mathbb{R}$ es el conjunto:

$$E_f = \{(x, c) \in D \times \mathbb{R} \mid f(x) \leq c\}.$$

La relación entre convexidad de conjuntos y de funciones está dada por el siguiente teorema.

Teorema 3.4 (El epígrafe caracteriza la convexidad). Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Una función $f : D \rightarrow \mathbb{R}$ es convexa en D si, y solo si, el epígrafe de f es un conjunto convexo en $\mathbb{R}^n \times \mathbb{R}$.

Prueba. Supongamos primero que E_f es convexo. Sean $x \in D$ y $y \in D$ cualesquiera. Obviamente, $(x, f(x)) \in E_f$ y $(y, f(y)) \in E_f$. Por la convexidad de E_f , para todo $\alpha \in [0, 1]$ tenemos que:

$$\alpha(x, f(x)) + (1 - \alpha)(y, f(y)) \in E_f.$$

Por la definición de epígrafe, esto es equivalente a decir que $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$, es decir, f es convexa.

Supongamos ahora que f es convexa. Sean $(x, c_1) \in E_f$ y $(y, c_2) \in E_f$. Como $f(x) \leq c_1$ y $f(y) \leq c_2$, por la convexidad de f , para todo $\alpha \in [0, 1]$ se tiene $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) \leq \alpha c_1 + (1 - \alpha)c_2$, lo que significa que $(\alpha x + (1 - \alpha)y, \alpha c_1 + (1 - \alpha)c_2) \in E_f$, es decir, E_f es convexo. ■

Decimos que $\min_{x \in D} f(x)$ es un **problema de minimización convexo** cuando $D \subset \mathbb{R}^n$ es un conjunto convexo y $f : D \rightarrow \mathbb{R}$ es una función convexa. La importancia de la convexidad se puede ver en el siguiente resultado.

Teorema 3.5 (Teorema de minimización convexo). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y $f : D \rightarrow \mathbb{R}$ una función convexa en D . Entonces todo minimizador local del problema es global. Además, el conjunto de minimizadores es convexo. Si f es estrictamente convexa, no puede haber más de un minimizador.

Prueba. Supongamos que $\bar{x} \in D$ sea un minimizador local que no es global. Entonces existe $y \in D$ tal que $f(y) < f(\bar{x})$. Definimos $x(\alpha) = \alpha y + (1 - \alpha)\bar{x}$. Por la convexidad de D , $x(\alpha) \in D$ para todo $\alpha \in (0, 1)$. Por la convexidad de f , para todo $\alpha \in (0, 1)$, se tiene:

$$f(x(\alpha)) \leq \alpha f(y) + (1 - \alpha)f(\bar{x}) = f(\bar{x}) + \alpha(f(y) - f(\bar{x})) < f(\bar{x}).$$

Tomando $\alpha > 0$ suficientemente pequeño, $x(\alpha)$ está arbitrariamente próximo al punto $\bar{x}$, y aun así $f(x(\alpha)) < f(\bar{x})$. Esto contradice el hecho de que $\bar{x}$ es un minimizador local.

Sea $S \subset D$ el conjunto de los minimizadores (globales) e $\bar{v} \in \mathbb{R}$ el valor óptimo. Para cualesquiera $x, \bar{x} \in S$ y $\alpha \in [0, 1]$, por la convexidad de f obtenemos $f(\alpha x + (1 - \alpha)\bar{x}) \leq \alpha \bar{v} + (1 - \alpha)\bar{v} = \bar{v}$, lo que implica que de hecho $f(\alpha x + (1 - \alpha)\bar{x}) = \bar{v}$, por lo tanto, la combinación convexa pertenece a S . Luego S es convexo.

Si f es estrictamente convexa y existieran $x, \bar{x} \in S$ distintos, entonces para $\alpha \in (0, 1)$:

$$f(\alpha x + (1 - \alpha)\bar{x}) < \alpha f(x) + (1 - \alpha)f(\bar{x}) = \bar{v},$$

lo que resulta en una contradicción. Concluimos que en este caso el minimizador es único. ■

Definición 3.6 (Función cóncava). Si $D \subset \mathbb{R}^n$ es un conjunto convexo, decimos que una función $f : D \rightarrow \mathbb{R}$ es una **función cóncava** en D , cuando la función $(-f)$ es convexa en D .

Es fácil ver que las afirmaciones del Teorema 3.5 son verdaderas si sustituimos la minimización de una función convexa por la maximización de una función cóncava.

3.2. Conjuntos convexos y Teoremas de Separación

Estudiaremos los conjuntos convexos con más profundidad, abarcando la estructura de conjuntos, la proyección ortogonal y la separación mediante hiperplanos.

3.2.1. Propiedades básicas de conjuntos convexos

Proposición 3.4. Sean $D_i \subset \mathbb{R}^n$, $i \in I$, conjuntos convexos, donde I es un conjunto cualquiera (posiblemente infinito). Entonces la intersección $D = \bigcap_{i \in I} D_i$ también es un conjunto convexo.

Prueba. Sean $x \in D$ e $y \in D$. Por la definición de intersección, $x \in D_i$ e $y \in D_i$ para todo $i \in I$. Como los conjuntos D_i son convexos, $\alpha x + (1 - \alpha)y \in D_i$ para todo $i \in I$. Por la definición de la intersección, se sigue que la combinación convexa pertenece a D , es decir, D es convexo. ■

Corolario 3.1. Un conjunto poliédrico en $\mathbb{R}^n$ es convexo.

Prueba. Un conjunto poliédrico es el conjunto de soluciones de un sistema finito de ecuaciones e inecuaciones lineales, es decir, una intersección de semiespacios e hiperplanos que son conjuntos convexos. Por lo tanto, un conjunto poliédrico es convexo por la Proposición 3.4. ■

A continuación mostramos que la clausura y el interior de un conjunto convexo son conjuntos convexos.

Proposición 3.5. Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Entonces $\text{cl } D$ e $\text{int } D$ son conjuntos convexos.

Prueba. Sean $x, y \in \text{cl } D$, $\alpha \in [0, 1]$. Elegimos secuencias $\{x^k\}, \{y^k\} \subset D$ tales que $\{x^k\} \rightarrow x$ e $\{y^k\} \rightarrow y$. Por la convexidad de D , $\alpha x^k + (1 - \alpha)y^k \in D$. Pasando al límite obtenemos que $\alpha x + (1 - \alpha)y \in \text{cl } D$.

Sean $x, y \in \text{int } D$. Fijamos $\epsilon > 0$ tal que $B(x, \epsilon) \subset D$ y $B(y, \epsilon) \subset D$. Para mostrar que $z = \alpha x + (1 - \alpha)y \in \text{int } D$, tomamos un vector q con $\|q\| \leq \epsilon$. Observamos que $z + q = \alpha(x + q) + (1 - \alpha)(y + q)$. Obviamente, $x + q \in B(x, \epsilon) \subset D$ e $y + q \in B(y, \epsilon) \subset D$. Por la convexidad, concluimos que $z + q \in D$. Por lo tanto, $B(z, \epsilon) \subset D$, lo que significa que $z \in \text{int } D$. ■

Proposición 3.6. Sean $D_i \subset \mathbb{R}^n$, $i = 1, 2$, conjuntos convexos cerrados. Si uno de ellos también es acotado (luego, compacto), entonces la suma de Minkowski $D_1 + D_2$ es convexa y cerrada.

Prueba. Es fácil ver que el conjunto $D = D_1 + D_2$ es convexo. Mostraremos que D es cerrado, suponiendo que D_2 sea acotado.

Sea $\{x^k\} \rightarrow x$, con $x^k \in D$. Para todo k existen $x^{k,1} \in D_1$ e $x^{k,2} \in D_2$ tales que $x^k = x^{k,1} + x^{k,2}$. Es claro que la secuencia $\{x^{k,2}\}$ es acotada. Como la secuencia de la suma converge, se sigue que $\{x^{k,1}\}$ también es acotada. Luego, tiene un punto de acumulación, digamos $\bar{x}^1$. Sea $\{x^{k_j,1}\} \rightarrow \bar{x}^1$. Podemos admitir que $\{x^{k_j,2}\} \rightarrow \bar{x}^2$, eligiendo una subsecuencia si es necesario. Como D_1 y D_2 son cerrados, $\bar{x}^1 \in D_1$ y $\bar{x}^2 \in D_2$. Por lo tanto, $x = \bar{x}^1 + \bar{x}^2 \in D_1 + D_2 = D$, lo que muestra que D es cerrado. ■

Observamos que para D_1 y D_2 convexos y cerrados es posible que $D_1 + D_2$ no sea cerrado si ambos son no acotados (por ejemplo, si D_1 es el eje x_1 y D_2 es el epígrafe de $1/x_1$).

Definición 3.7 (Combinación convexa). Dados $x^i \in \mathbb{R}^n$, $\alpha_i \in [0, 1]$, $i = 1, \dots, p$, tales que $\sum_{i=1}^p \alpha_i = 1$, el punto $\sum_{i=1}^p \alpha_i x^i$ se llama **combinación convexa** de los puntos $x^i \in \mathbb{R}^n$ con parámetros α_i .

Teorema 3.6 (Caracterización por combinaciones convexas). Un conjunto $D \subset \mathbb{R}^n$ es convexo si, y solo si, para cualesquiera $p \in \mathbb{N}$, $x^i \in D$ y $\alpha_i \in [0, 1]$ tales que $\sum_{i=1}^p \alpha_i = 1$, la combinación convexa $\sum_{i=1}^p \alpha_i x^i$ pertenece a D .

Prueba. Si D contiene todas las combinaciones convexas de sus puntos, en particular contiene las combinaciones de dos puntos, luego D es convexo. Supongamos que D sea convexo. La prueba se realiza por inducción en p . Para $p = 1$ es trivial. Supongamos que vale para $j \geq 1$ puntos y consideremos $p = j + 1$. Sea $x = \sum_{i=1}^{j+1} \alpha_i x^i$. Si $\alpha_{j+1} = 1$, entonces $x = x^{j+1} \in D$. Si $\alpha_{j+1} \in [0, 1)$, escribimos

$$x = (1 - \alpha_{j+1})y + \alpha_{j+1}x^{j+1}, \quad (3.4)$$

donde $y = \sum_{i=1}^j \frac{\alpha_i}{1 - \alpha_{j+1}} x^i$. Como los coeficientes de y suman 1, $y \in D$ por hipótesis de inducción. Luego, (3.4) muestra que x es una combinación convexa de dos puntos de D , por lo que $x \in D$. ■

Corolario 3.2 (Desigualdad de Jensen). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y $f : D \rightarrow \mathbb{R}$ una función convexa en D . Entonces para cualesquiera $p \in \mathbb{N}$, $x^i \in D$ y $\alpha_i \in \mathbb{R}_+$ tales que $\sum_{i=1}^p \alpha_i = 1$, se tiene que:

$$f\left(\sum_{i=1}^p \alpha_i x^i\right) \leq \sum_{i=1}^p \alpha_i f(x^i). \quad (3.5)$$

Prueba. Por la definición de epígrafe, $(x^i, f(x^i)) \in E_f$. Por la convexidad de f , E_f es un conjunto convexo en $\mathbb{R}^n \times \mathbb{R}$ (Teorema 3.4). Por el Teorema 3.6, la combinación convexa pertenece a E_f :

$$\left(\sum_{i=1}^p \alpha_i x^i, \sum_{i=1}^p \alpha_i f(x^i)\right) = \sum_{i=1}^p \alpha_i (x^i, f(x^i)) \in E_f.$$

Usando la definición de epígrafe, obtenemos la (3.5). ■

Teorema 3.7 (Teorema de Carathéodory). Sea $x \in \mathbb{R}^n$ una combinación convexa de puntos del conjunto $D \subset \mathbb{R}^n$. Entonces existen $x^i \in D$ y $\alpha_i \in \mathbb{R}_+$, $i = 1, \dots, n + 1$, tales que $x = \sum_{i=1}^{n+1} \alpha_i x^i$ y $\sum_{i=1}^{n+1} \alpha_i = 1$.

Prueba. Supongamos que x es una combinación convexa de $p > n + 1$ puntos: $x = \sum_{i=1}^p \beta_i x^i$, con $\sum \beta_i = 1$ y $\beta_i > 0$. Como $p > n + 1$, los $p - 1$ vectores $\{x^i - x^p\}$ son linealmente dependientes, es decir, existen γ_i (no todos nulos) tales que $0 = \sum_{i=1}^{p-1} \gamma_i (x^i - x^p)$. Definiendo $\gamma_p = -\sum_{i=1}^{p-1} \gamma_i$, obtenemos $\sum_{i=1}^p \gamma_i = 0$ y $\sum_{i=1}^p \gamma_i x^i = 0$. Podemos admitir que algún $\gamma_j > 0$. Sea j el índice que maximiza la relación γ_i/β_i . Definimos $q_i = \beta_i - (\beta_j/\gamma_j)\gamma_i$. Por construcción, $q_j = 0$, $q_i \geq 0$, $\sum q_i = 1$ y $\sum q_i x^i = x$. Hemos expresado x como una combinación convexa de $p - 1$ puntos. Repitiendo este proceso, llegamos a $n + 1$ puntos. ■

Definición 3.8 (Cierre convexo o envoltura convexa). Sea $D \subset \mathbb{R}^n$ un conjunto cualquiera. El **cierre convexo** de D , denotado por $\text{conv } D$, es el menor conjunto convexo en $\mathbb{R}^n$ que contiene a D (o la intersección de todos los conjuntos convexos que contienen a D).

Proposición 3.7. El cierre convexo $\text{conv } D$ es el conjunto de todas las combinaciones convexas de puntos de D .

Prueba. Sea C el conjunto de todas las combinaciones convexas. Como $\text{conv } D$ es convexo y contiene a D , por el Teorema 3.6 debe contener a C , luego $C \subset \text{conv } D$. Por otro lado, es fácil demostrar que C es convexo (la combinación convexa de dos combinaciones convexas sigue siendo una combinación convexa cuyos coeficientes suman 1). Como $D \subset C$ y C es convexo, $\text{conv } D \subset C$. ■

Proposición 3.8. Sea $D \subset \mathbb{R}^n$ un conjunto compacto. Entonces $\text{conv } D$ es compacto.

Prueba. Primero mostraremos que $\text{conv } D$ es acotado. Todo $x \in \text{conv } D$ es una combinación convexa $\sum \alpha_i x^i$. Por la desigualdad triangular, $\|x\| \leq \sum \alpha_i \|x^i\| \leq \sup_{y \in D} \|y\| < +\infty$.

Para ver que es cerrado, sea $\{y^k\} \rightarrow y$ con $y^k \in \text{conv } D$. Por el Teorema 3.7, $y^k = \sum_{i=1}^{n+1} \alpha_{k,i} x^{k,i}$. Por compacidad, las secuencias $\{x^{k,i}\}$ y $\{\alpha_{k,i}\}$ son acotadas. Pasando a una subsecuencia convergente, los límites $x^i \in D$ y $\alpha_i \geq 0$ satisfacen $\sum \alpha_i = 1$ y $y = \sum \alpha_i x^i \in \text{conv } D$. ■

Proposición 3.9. Sea $K \subset \mathbb{R}^n$ un cono cualquiera. Se tiene:

$$K^* = (\text{cl } K)^* = (\text{conv } K)^*.$$

Prueba. La primera igualdad ya fue establecida en la Proposición 3.3. $\text{conv } K$ es un cono. De la inclusión $K \subset \text{conv } K$ obtenemos $(\text{conv } K)^* \subset K^*$. Si $y \in K^*$, para cualquier $d = \sum \alpha_i d^i \in \text{conv } K$ con $d^i \in K$, se tiene $\langle y, d \rangle = \sum \alpha_i \langle y, d^i \rangle \leq 0$. Luego $K^* \subset (\text{conv } K)^*$. ■

3.2.2. Cono de Recesión y Generadores Finitos

Definición 3.9 (Dirección de recesión). Decimos que $d \in \mathbb{R}^n$ es una **dirección de recesión** del conjunto convexo $D \subset \mathbb{R}^n$ cuando:

$$x + td \in D \quad \forall x \in D, \forall t \in \mathbb{R}_+.$$

Denotamos por $\mathcal{R}_D$ el **cono de recesión**.

Proposición 3.10 (Cono de recesión de un conjunto convexo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo, cerrado y no vacío. Entonces:

- (a) $\mathcal{R}_D$ es un cono convexo, cerrado y no vacío.
- (b) $d \in \mathcal{R}_D$ si, y solo si, existe $x \in D$ tal que $x + td \in D$ para todo $t \in \mathbb{R}_+$.
- (c) $\mathcal{R}_D \neq \{0\}$ si, y solo si, D es ilimitado.

Prueba. (a) Es obvio que $0 \in \mathcal{R}_D$. Si $d^1, d^2 \in \mathcal{R}_D$ y $\alpha \in [0, 1]$, para $x \in D$ y $t \geq 0$, $x + t(\alpha d^1 + (1 - \alpha)d^2) = \alpha(x + td^1) + (1 - \alpha)(x + td^2) \in D$, por lo que es convexo. La cerradura sigue por la cerradura de D .

(b) Si existe $\bar{x}$ tal que $\bar{x} + td \in D$ para todo t , para cualquier otro $x \in D$ definimos $d^k = \frac{\|d\|}{\|x^k - \bar{x}\|}(x^k - \bar{x})$ donde $x^k = x + ktd \in D$. Se puede demostrar (tomando convexidad con $\bar{x} + td^k$) que en el límite $x + td \in D$.

(c) Si D contiene una semirrecta, es ilimitado. Si D es ilimitado, tomamos una secuencia $\|x^k - x\| \rightarrow \infty$. Los vectores normalizados $d^k = (x^k - x)/\|x^k - x\|$ tienen un punto de acumulación $d \neq 0$. Por convexidad, $x + td^k \in D$ para k grande. En el límite $x + td \in D$, luego $d \in \mathcal{R}_D$. ■

Definición 3.10 (Cono con número finito de generadores). Un cono $K \subset \mathbb{R}^n$ tiene un **número finito de generadores** cuando existen $a^1, \dots, a^p \in \mathbb{R}^n$ tales que $K = \text{cone}\{a^i, i = 1, \dots, p\}$.

Proposición 3.11. Sean $a^i \in \mathbb{R}^n, i = 1, \dots, p$. Se tiene que:

$$\text{cone}\{a^i, i = 1, \dots, p\} = \left\{ x \in \mathbb{R}^n \mid x = \sum_{i=1}^p \mu_i a^i, \mu_i \geq 0, i = 1, \dots, p \right\}. \quad (3.6)$$

Prueba. Sea C el lado derecho de (3.6). C es un cono convexo y contiene los a^i , por lo que $\text{cone}\{a^i\} \subset C$. Por otro lado, cualquier $x \in C$ con $\sum \mu_i > 0$ se puede escribir como $(\sum \mu_i) \sum \beta_i a^i$, donde $\beta_i = \mu_i / \sum \mu_i$ suman 1. Así, x es un múltiplo positivo de una combinación convexa de los a^i , por lo que $x \in \text{cone}(\text{conv}\{a^i\}) = \text{cone}\{a^i\}$. Luego $C \subset \text{cone}\{a^i\}$. ■

Lema 3.1. Cualquier cono que tiene un número finito de generadores es convexo y cerrado.

Prueba. Se prueba por inducción en p . Para $p = 1$ es una semirrecta cerrada (o $\{0\}$). Para $p + 1$, o bien el cono es un subespacio (que es cerrado), o existe un generador que no puede ser negado dentro del cono. En ese caso, se descompone como $K_{p+1} = K_p + \text{cone}\{a^{p+1}\}$. Resolviendo un problema de minimización sobre la intersección compacta, se acotan los coeficientes y se asegura que el límite de secuencias convergentes pertenece al cono. ■

Definición 3.11 (Cono poliédrico). Decimos que un cono $K \subset \mathbb{R}^n$ es **poliédrico** si es el conjunto de soluciones de un sistema lineal homogéneo: $K = \{x \in \mathbb{R}^n \mid Q_1 x \leq 0, Q_2 x = 0\}$.

Teorema 3.8 (Teorema de Minkowski-Weyl). Un cono $K \subset \mathbb{R}^n$ tiene un número finito de generadores si, y solamente si, K es un cono poliédrico.

3.2.3. El operador de proyección

Teorema 3.9 (Teorema de la Proyección). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado. Para todo $x \in \mathbb{R}^n$, la proyección $P_D(x)$ existe y es única. Además, $\bar{x} = P_D(x)$ si, y solamente si,

$$\bar{x} \in D, \quad \langle x - \bar{x}, y - \bar{x} \rangle \leq 0 \quad \forall y \in D, \quad (3.7)$$

o, equivalentemente, $x - \bar{x} \in \mathcal{N}_D(\bar{x})$.

Prueba. Si $\bar{x}$ resuelve la proyección, para cualquier $y \in D$, el punto $x(\alpha) = (1 - \alpha)\bar{x} + \alpha y \in D$ para $\alpha \in [0, 1]$. Desarrollando $\|x - \bar{x}\|^2 \leq \|x - x(\alpha)\|^2$, dividiendo por α y tomando el límite, se obtiene $\langle x - \bar{x}, y - \bar{x} \rangle \leq 0$.

Si se cumple (3.7), entonces $\|x - y\|^2 = \|x - \bar{x}\|^2 + \|y - \bar{x}\|^2 - 2\langle x - \bar{x}, y - \bar{x} \rangle \geq \|x - \bar{x}\|^2$. Luego $\bar{x}$ minimiza la distancia.

Si existiera $\hat{x}$ otra proyección, $\langle x - \bar{x}, \hat{x} - \bar{x} \rangle \leq 0$ y $\langle x - \hat{x}, \bar{x} - \hat{x} \rangle \leq 0$. Sumando obtenemos $-\|\hat{x} - \bar{x}\|^2 \geq 0$, de donde $\hat{x} = \bar{x}$. ■

Corolario 3.3 (Operador de proyección no expansivo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado. Entonces $\forall x, y \in \mathbb{R}^n$:

$$\|P_D(x) - P_D(y)\| \leq \|x - y\|. \quad (3.8)$$

Prueba. Evaluando (3.7) dos veces y sumando, se obtiene $\|P_D(x) - P_D(y)\|^2 \leq \langle x - y, P_D(x) - P_D(y) \rangle$. Aplicando Cauchy-Schwarz, se deduce (3.8). ■

3.2.4. Teoremas de Separación

Definición 3.12 (Hiperplano de separación). El hiperplano $H(a, c) = \{x \in \mathbb{R}^n \mid \langle a, x \rangle = c\}$ **separa** los conjuntos D_1 y D_2 si:

$$\langle a, x^1 \rangle \leq c \leq \langle a, x^2 \rangle \quad \forall x^1 \in D_1, \forall x^2 \in D_2.$$

La separación es **estricta** cuando las desigualdades son estrictas.

Lema 3.2 (Lema de Minkowski). Sea $D \subset \mathbb{R}^n$ un conjunto convexo no vacío. Si $x \notin \text{cl } D$, entonces existen $a \in \mathbb{R}^n \setminus \{0\}$ y $c \in \mathbb{R}$ tales que:

$$\langle a, x \rangle = c, \quad \langle a, y \rangle > c \quad \forall y \in D.$$

Prueba. Sea $\bar{x} = P_{\text{cl } D}(x)$. Definimos $a = \bar{x} - x \neq 0$ y $c = \langle \bar{x} - x, x \rangle$. Para $y \in D$, por el Teorema 3.9, $\langle a, y \rangle = \langle \bar{x} - x, y \rangle \geq \langle \bar{x} - x, \bar{x} \rangle = c + \|\bar{x} - x\|^2 > c$. ■

Lema 3.3 (Separación en la frontera). Si $x \in \text{fr } D$, entonces existe un **hiperplano de soporte**: $a \in \mathbb{R}^n \setminus \{0\}$ tal que $\langle a, x \rangle = c$ y $\langle a, y \rangle \geq c$ para todo $y \in D$.

Prueba. Tomamos $\{x^k\} \rightarrow x$ con $x^k \notin \text{cl } D$. Por el Lema 3.2, existen a^k (normalizados) y c_k . Extraemos una subsucesión convergente $\{a^k\} \rightarrow a \neq 0$. En el límite, se cumple la separación. ■

Teorema 3.10 (Teorema de Separación). Sean $D_1, D_2 \subset \mathbb{R}^n$ conjuntos convexos disjuntos. Existen $a \in \mathbb{R}^n \setminus \{0\}$ y $c \in \mathbb{R}$ tales que $\langle a, x^1 \rangle \leq c \leq \langle a, x^2 \rangle$ para todo $x^1 \in D_1, x^2 \in D_2$.

Prueba. El conjunto $D = D_2 - D_1$ es convexo y $0 \notin D$. Si $0 \notin \text{cl } D$, aplicamos el Lema 3.2; si $0 \in \text{fr } D$, aplicamos el Lema 3.3. En ambos casos, existe $a \neq 0$ tal que $\langle a, x^2 - x^1 \rangle \geq 0$. Elegimos $c = (\sup_{D_1} \langle a, x^1 \rangle + \inf_{D_2} \langle a, x^2 \rangle)/2$. ■

Teorema 3.11 (Teorema de Separación Estricta). Sean $D_1, D_2 \subset \mathbb{R}^n$ convexos, cerrados y no vacíos, con uno de ellos compacto. Entonces $D_1 \cap D_2 = \emptyset$ si, y solamente si, pueden ser separados estrictamente.

Prueba. Sea D_2 compacto. La función distancia $\text{dist}(x, D_1)$ alcanza su mínimo en D_2 en un punto a^2 . Sea $a^1 = P_{D_1}(a^2)$. Como son disjuntos, $a = a^2 - a^1 \neq 0$. Usando propiedades de proyección para a^1 y a^2 , se demuestra que $\langle a, x^1 \rangle \leq \langle a, a^1 \rangle < \langle a, a^2 \rangle \leq \langle a, x^2 \rangle$, permitiendo una separación estricta con c en el punto medio. ■

Proposición 3.12. Sea $K \subset \mathbb{R}^n$ un cono cualquiera. Se tiene:

$$(K^*)^* = \text{cl conv } K.$$

Si D es convexo y $\bar{x} \in D$, $(\mathcal{N}_D(\bar{x}))^* = \mathcal{T}_D(\bar{x})$.

Prueba. Por definición, $\text{cl conv } K \subset (K^*)^*$. Si $x \notin \text{cl conv } K$, por separación estricta (Teorema 3.11), existe $a \neq 0$ tal que $\langle a, x \rangle > c > \langle a, d \rangle$ para todo $d \in \text{cl conv } K$. Tomando $d = 0$ resulta $c > 0$, por lo que $\langle a, x \rangle > 0$. Para $d \in K$, se deduce que $\langle a, d \rangle \leq 0$ (de lo contrario la semirrecta rompería la cota c). Así, $a \in K^*$, lo que muestra que $x \notin (K^*)^*$. La última afirmación sigue de identificar $\mathcal{N}_D(\bar{x}) = \mathcal{T}_D(\bar{x})^*$. ■

3.2.5. Puntos Extremos

Definición 3.13 (Punto extremo). Decimos que $x \in D$ es un **punto extremo** del conjunto convexo D cuando no puede ser representado por una combinación convexa de dos puntos diferentes de D (es decir, $x = \alpha x^1 + (1 - \alpha)x^2 \implies x = x^1 = x^2$). Denotamos el conjunto por $E(D)$.

Lema 3.4. Sea $D \subset \mathbb{R}^n$ un conjunto convexo no vacío y C un semiespacio cerrado tal que $D \subset C$. Entonces $E(D \cap \text{fr } C) \subset E(D)$.

Prueba. Sea $\bar{x} \in E(D \cap \text{fr } C)$. Si $\bar{x} = \alpha x^1 + (1 - \alpha)x^2$ para $x^i \in D$, evaluando el producto interno que define el hiperplano $\text{fr } C$ se deduce que ambos x^i deben yacer exactamente en la frontera, forzando a que $x^i \in D \cap \text{fr } C$, y por la extremidad relativa, $x^1 = x^2$. ■

Proposición 3.13. Sea $D \subset \mathbb{R}^n$ convexo, cerrado y no vacío. D tiene puntos extremos ($E(D) \neq \emptyset$) si, y solamente si, D no contiene ninguna recta.

Prueba. Si D contiene una recta que pasa por x , x se puede escribir como el punto medio de $x + d$ y $x - d$, por lo que no es extremo. El recíproco se demuestra por inducción en la dimensión n , interceptando el conjunto con hiperplanos de soporte y utilizando el Lema 3.4. ■

Teorema 3.12 (Teorema de Krein-Milman). Sea $D \subset \mathbb{R}^n$ un conjunto convexo compacto. Entonces:

$$D = \text{conv } E(D).$$

Prueba. Por inducción en n . Para $n = 1$ es obvio. Supongamos válido en $\mathbb{R}^n$. Para $D \subset \mathbb{R}^{n+1}$, si $\bar{x} \in \text{fr } D$, el hiperplano de soporte reduce la dimensión del problema, y por hipótesis inductiva y el Lema 3.4, $\bar{x}$ se forma por extremos de D . Si $\bar{x} \in \text{int } D$, cualquier recta que pase por $\bar{x}$ corta a la frontera en dos puntos (por compacidad); como $\bar{x}$ es combinación convexa de ellos, queda probado. ■

Proposición 3.14. Sea $x \in D$, donde $D = \{x \in \mathbb{R}^n \mid B_i x \leq b_i\}$ es un conjunto poliédrico. Entonces x es un vértice (punto extremo) de D si, y solamente si, las filas correspondientes a las restricciones activas ($I(x)$) tienen rango n .

Prueba. Si el rango es n , una perturbación $x \pm d$ viola las restricciones activas salvo que $d = 0$. Si el rango es menor que n , existe $d \in \ker B_I \setminus \{0\}$. Un desplazamiento $x \pm td$ se mantiene en la cara activa, demostrando que x no es extremo. ■

Corolario 3.4. El número de vértices de un conjunto poliédrico cualquiera es finito.

Teorema 3.13 (Representación de conjuntos poliédricos sin rectas). Sea D un conjunto poliédrico que no contiene ninguna recta. Entonces:

$$D = \text{conv } E(D) + \mathcal{R}_D.$$

3.3. Teoremas de alternativa

A continuación, consideramos sistemas de ecuaciones e inecuaciones lineales, relacionados en el sentido de que existen dos alternativas: si un sistema no posee soluciones, entonces el otro posee soluciones, y ambos sistemas no pueden poseer soluciones simultáneamente. Un resultado de este tipo será usado para caracterizar el cono dual del cono tangente en el caso de restricciones mixtas de igualdad y desigualdad y para formular las condiciones de optimalidad en forma primal-dual para problemas con este tipo de restricciones.

Teorema 3.14 (Teorema de la Alternativa de Motzkin). Para cualesquiera matrices $A_i \in \mathbb{R}^{m_i \times n}$, $i = 0, 1, 2$, con $A_0 \neq 0$, uno, y solamente uno, de los dos sistemas siguientes posee solución:

$$A_0 x > 0, \quad A_1 x = 0, \quad A_2 x \geq 0, \quad x \in \mathbb{R}^n, \quad (3.9)$$

o

$$\begin{aligned} A_0^T y^0 + A_1^T y^1 + A_2^T y^2 &= 0, \\ (y^0, y^1, y^2) &\in (\mathbb{R}_+^{m_0} \setminus \{0\}) \times \mathbb{R}^{m_1} \times \mathbb{R}_+^{m_2}. \end{aligned} \quad (3.10)$$

Prueba. Primero supongamos que (3.10) tenga una solución (y^0, y^1, y^2) . Si x fuese solución de (3.9), entonces:

$$0 = \langle A_0^T y^0 + A_1^T y^1 + A_2^T y^2, x \rangle = \langle y^0, A_0 x \rangle + \langle y^1, A_1 x \rangle + \langle y^2, A_2 x \rangle \geq \langle y^0, A_0 x \rangle > 0,$$

donde para obtener la primera desigualdad usamos el hecho de que todas las coordenadas de los vectores involucrados son no negativas, y para obtener la segunda usamos además los hechos de que $y_i^0 \geq 0$, $(A_0 x)_i > 0 \forall i$, y para algún índice la coordenada de y^0 es estrictamente positiva. La contradicción muestra que cuando (3.10) tiene solución, (3.9) no puede tenerla.

Supongamos ahora que (3.10) no tenga solución. Es decir,

$$0 \notin \left\{ z \in \mathbb{R}^n \mid \begin{array}{l} z = A_0^T y^0 + A_1^T y^1 + A_2^T y^2, \\ y^0 \in \mathbb{R}_+^{m_0} \setminus \{0\}, y^1 \in \mathbb{R}^{m_1}, y^2 \in \mathbb{R}_+^{m_2} \end{array} \right\}.$$

Como $y^0 \in \mathbb{R}_+^{m_0} \setminus \{0\}$, dividiendo z por $\sum y_i^0 > 0$, vemos que esta propiedad es equivalente a $0 \notin D$, donde $D = D_1 + D_2$, con:

$$D_1 = \left\{ z \in \mathbb{R}^n \mid z = A_0^\top y^0, y^0 \in \mathbb{R}_+^{m_0}, \sum_{i=1}^{m_0} y_i^0 = 1 \right\},$$

$$D_2 = \{ z \in \mathbb{R}^n \mid z = A_1^\top y^1 + A_2^\top y^2, y^1 \in \mathbb{R}^{m_1}, y^2 \in \mathbb{R}_+^{m_2} \}.$$

El conjunto D_1 es la clausura convexa de las columnas de $A_0^\top$ (que son finitas), por lo tanto, es compacto. El conjunto D_2 es un cono con un número finito de generadores; por lo tanto, es convexo y cerrado. La suma $D = D_1 + D_2$ es un conjunto convexo y cerrado (al sumar un compacto y un cerrado).

Como $0 \notin D$, por el Teorema de Separación Estricta, existe un hiperplano que separa 0 de D estrictamente; es decir, existe $x \in \mathbb{R}^n \setminus \{0\}$ y $c \in \mathbb{R}$ tales que:

$$\langle x, z \rangle > c > 0 \quad \forall z \in D.$$

Como D_2 es un cono, si existiera $y \in D_2$ tal que $\langle x, y \rangle < 0$, tomando múltiplos grandes contradeciríamos la separación. Así, $\langle x, y \rangle \geq 0$ para todo $y \in D_2$, lo que implica:

$$A_1 x = 0, \quad A_2 x \geq 0.$$

Finalmente, tomando $y^0 = e^i$ (vectores de la base canónica), deducimos que $\langle e^i, A_0 x \rangle > c > 0$, lo que implica $A_0 x > 0$. Hemos hallado una solución para (3.9). ■

El famoso Lema de Farkas se obtiene como una consecuencia del Teorema de Motzkin.

Lema 3.5 (Lema de Farkas). Para cualquier matriz $A \in \mathbb{R}^{m \times n}$ y cualquier $b \in \mathbb{R}^n$, uno, y solamente uno, de los siguientes sistemas posee solución:

$$Ax \leq 0, \quad \langle b, x \rangle > 0, \quad x \in \mathbb{R}^n, \quad (3.11)$$

o

$$A^\top y = b, \quad y \in \mathbb{R}_+^m. \quad (3.12)$$

Prueba. Aplicando el Teorema de Motzkin (Teorema 3.14) con las elecciones $A_0 = b^\top \in \mathbb{R}^{1 \times n}$ y $A_2 = -A \in \mathbb{R}^{m \times n}$ (y sin matriz A_1), la alternativa a (3.11) es:

$$y^0 b - A^\top y^2 = 0, \quad (y^0, y^2) \in (\mathbb{R}_+ \setminus \{0\}) \times \mathbb{R}_+^m.$$

Como $y^0 > 0$, dividiendo por y^0 y llamando $y = y^2/y^0$, obtenemos exactamente el sistema (3.12). ■

El Lema de Farkas ya permite probar las condiciones de optimalidad en forma primal-dual en el caso especial de restricciones de desigualdad lineales.

Corolario 3.5. Sea $\bar{x} \in \mathbb{R}^n$ una solución local del problema $\min f(x)$ sujeto a $Bx \leq b$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es diferenciable en $\bar{x}$, $B \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Entonces existe $\bar{\mu} \in \mathbb{R}_+^m$ tal que

$$\nabla f(\bar{x}) + B^\top \bar{\mu} = 0, \quad \bar{\mu}_i = 0 \text{ para } i \notin I(\bar{x}),$$

donde $I(\bar{x}) = \{i \mid \langle B_i, \bar{x} \rangle = b_i\}$.

Prueba. Sea $C = \{d \in \mathbb{R}^n \mid \langle B_i, d \rangle \leq 0, i \in I(\bar{x})\}$. Para todo $d \in C$, se tiene que $B(\bar{x} + td) \leq b$ para todo $t > 0$ suficientemente pequeño, por lo tanto $d \in \mathcal{V}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$. Por el Teorema de la condición necesaria primal (Teorema 1.6), $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in C$.

Es decir, el sistema $\langle \nabla f(\bar{x}), d \rangle < 0, \langle B_i, d \rangle \leq 0$ para $i \in I(\bar{x})$ no tiene solución. Por el Lema de Farkas (Lema 3.5), el sistema alternativo $(B_{I(\bar{x})})^\top \mu = -\nabla f(\bar{x})$ con $\mu \in \mathbb{R}_+^{|I(\bar{x})|}$ tiene solución. Definiendo $\bar{\mu}_i = 0$ para $i \notin I(\bar{x})$, obtenemos el resultado. ■

Nota: Otros Teoremas de Alternativa

Existen otros teoremas clásicos de alternativa que surgen como variantes lógicas del Lema de Farkas y el Teorema de Motzkin, muy útiles en teoría de juegos y economía matemática:

- **Teorema de Tucker:** Los sistemas $Ax \geq 0, Ax \neq 0$ y $A^\top y = 0, y > 0$ son mutuamente excluyentes.
- **Teoremas de Gale:** Alternativas puras sobre igualdades/desigualdades (ej. $Ax = b, x \geq 0$ vs $A^\top y \geq 0, \langle b, y \rangle < 0$).
- **Teorema de Gordan:** $Ax < 0$ vs $A^\top y = 0, y \in \mathbb{R}_+^m \setminus \{0\}$.

(Las demostraciones de estos teoremas se proponen como ejercicios en la sección final de este capítulo).

3.4. Funciones convexas

Ahora estudiaremos funciones convexas con más profundidad. Trataremos la estructura de estas funciones, caracterizaciones para funciones diferenciables, continuidad, y el concepto de subdiferencial para funciones no diferenciables.

3.4.1. Propiedades básicas de las funciones convexas

Mostramos primero que una suma de múltiplos no negativos de un número finito de funciones convexas es convexa, así como el supremo.

Proposición 3.15 (Convexidad de la suma y el supremo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y sean $f_i : D \rightarrow \mathbb{R}$ funciones convexas en D .

1. Para cualesquiera $\mu_i \in \mathbb{R}_+$, la función $f(x) = \sum_{i=1}^p \mu_i f_i(x)$ es convexa en D .
2. Si I es un conjunto de índices arbitrario (posiblemente infinito) y existe $\beta \in \mathbb{R}$ tal que $f_i(x) \leq \beta$ para todo $x \in D$ e $i \in I$, entonces la función $f(x) = \sup_{i \in I} f_i(x)$ es convexa en D .

Prueba. (1) Para $x, y \in D$ y $\alpha \in [0, 1]$, se tiene $f(\alpha x + (1-\alpha)y) = \sum \mu_i f_i(\alpha x + (1-\alpha)y) \leq \sum \mu_i (\alpha f_i(x) + (1-\alpha)f_i(y)) = \alpha f(x) + (1-\alpha)f(y)$, ya que $\mu_i \geq 0$.

(2) El epígrafe de un supremo de funciones es la intersección de los epígrafes individuales: $E_f = \{(x, c) \mid \sup f_i(x) \leq c\} = \bigcap_{i \in I} \{(x, c) \mid f_i(x) \leq c\} = \bigcap_{i \in I} E_{f_i}$. Al ser f_i convexas, los E_{f_i} son convexas, y la intersección de conjuntos convexas es convexa. Luego, el epígrafe E_f es convexo, lo que implica que f es convexa. ■

Proposición 3.16 (Composición convexa). Sean $g : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa, y $\psi : \mathbb{R} \rightarrow \mathbb{R}$ una función convexa y no decreciente. Entonces la composición $f(x) = \psi(g(x))$ es convexa en $\mathbb{R}^n$.

Prueba. Por convexidad de g y monotonía de ψ , se tiene $\psi(g(\alpha x + (1-\alpha)y)) \leq \psi(\alpha g(x) + (1-\alpha)g(y))$. Luego, por la convexidad de ψ , esto es $\leq \alpha \psi(g(x)) + (1-\alpha)\psi(g(y))$, demostrando la afirmación. ■

A continuación, mostraremos que los conjuntos de nivel de una función convexa son conjuntos convexas.

Teorema 3.15 (Convexidad de conjuntos de nivel). Supongamos que el conjunto $D \subset \mathbb{R}^n$ sea convexo y la función $f : D \rightarrow \mathbb{R}$ sea convexa en D . Entonces el conjunto de nivel

$$L_{f,D}(c) = \{x \in D \mid f(x) \leq c\}$$

es convexo para todo $c \in \mathbb{R}$.

Prueba. Sean $x, y \in L_{f,D}(c)$. Por definición, $f(x) \leq c$ y $f(y) \leq c$. Por convexidad de D y f , para todo $\alpha \in [0, 1]$ se tiene que $f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha)f(y) \leq \alpha c + (1-\alpha)c = c$. Luego $\alpha x + (1-\alpha)y \in L_{f,D}(c)$. ■

Observación. La convexidad de todos los conjuntos de nivel no es suficiente para afirmar que la función es convexa. Las funciones que cumplen la propiedad de tener todos sus conjuntos de nivel convexas se denominan **funciones cuasiconvexas**. Un ejemplo clásico es $f(x) = x^3$ en $\mathbb{R}$, cuyos conjuntos de nivel son intervalos (luego, convexas), pero la función no es convexa.

Teorema 3.16 (Continuidad de funciones convexas). Sean $D \subset \mathbb{R}^n$ un conjunto convexo abierto y $f : D \rightarrow \mathbb{R}$ convexa. Entonces f es localmente Lipschitz-continua en D . En particular, es continua en D .

Nota de Demostración. La prueba formal construye un simplex cerrado (caja) contenido en D en torno a un punto de interés y utiliza la convexidad para acotar superior e inferiormente las variaciones de f , limitando la constante de Lipschitz mediante el valor máximo de la función en los vértices del simplex. (Ver referencias estándar de Análisis Convexo). ■

El siguiente resultado es crucial computacionalmente, ya que garantiza que si un problema fuertemente convexo tiene solución, el conjunto de nivel se mantiene acotado.

Teorema 3.17 (Compacidad del nivel de funciones fuertemente convexas). Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es fuertemente convexa, entonces para todo $c \in \mathbb{R}$, el conjunto de nivel $L_{f,\mathbb{R}^n}(c)$ es compacto.

Corolario 3.6. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ fuertemente convexa y $\emptyset \neq D \subset \mathbb{R}^n$ un conjunto cerrado. Entonces f tiene un minimizador en D . Si D es convexo, el minimizador es único.

Finalizamos esta subsección con resultados de maximización. El problema de maximizar una función convexa sobre un conjunto convexo tiene una naturaleza diferente al de minimización: la solución tiende a ubicarse en la frontera o vértices.

Teorema 3.18 (Maximización de función convexa). Sea $D \subset \mathbb{R}^n$ convexo compacto y $f : D \rightarrow \mathbb{R}$ convexa. Entonces el problema $\max_{x \in D} f(x)$ tiene solución y se alcanza en un **punto extremo** de D (es decir, en $E(D)$).

Además, si D es polédrico y no contiene rectas, el máximo (si existe) se alcanza en un vértice de D .

3.4.2. Funciones convexas diferenciables

Cuando una función es diferenciable, la convexidad admite varias caracterizaciones algebraicas muy útiles.

Teorema 3.19 (Caracterizaciones de convexidad diferenciable). Sean $D \subset \mathbb{R}^n$ abierto y convexo, y $f : D \rightarrow \mathbb{R}$ diferenciable. Las siguientes propiedades son equivalentes:

1. f es convexa en D .
2. (Desigualdad del subgradiente): Para todo $x, y \in D$, $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$.
3. (Monotonía del gradiente): Para todo $x, y \in D$, $\langle \nabla f(y) - \nabla f(x), y - x \rangle \geq 0$.

Si f es dos veces diferenciable en D , las anteriores son equivalentes a:

4. La matriz Hessiana $\nabla^2 f(x)$ es semidefinida positiva en todo punto de D .

Prueba. (1) $\implies$ (2): Por convexidad, $f(x + \alpha(y - x)) \leq (1 - \alpha)f(x) + \alpha f(y)$. Reorganizando: $f(y) - f(x) \geq \frac{f(x + \alpha(y - x)) - f(x)}{\alpha}$. Tomando límite $\alpha \rightarrow 0^+$, el lado derecho es la derivada direccional $\langle \nabla f(x), y - x \rangle$.
 (2) $\implies$ (3): Evaluando (2) intercambiando x e y : $f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle$. Sumando ambas desigualdades se obtiene $0 \geq \langle \nabla f(x), y - x \rangle + \langle \nabla f(y), x - y \rangle$, de donde se deduce (3).
 (3) $\implies$ (1): Por el Teorema del Valor Medio, integrando la monotonía del gradiente en un segmento se deduce que la función yace por encima de cualquier secante. (La equivalencia con la Hessiana sigue de las propiedades clásicas de formas cuadráticas). ■

Observación (Condiciones para fuerte convexidad). Para funciones fuertemente convexas con módulo $\gamma > 0$, las caracterizaciones se adaptan:

- $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \gamma \|y - x\|^2$.
- $\langle \nabla f(y) - \nabla f(x), y - x \rangle \geq 2\gamma \|y - x\|^2$.
- $\langle \nabla^2 f(x)d, d \rangle \geq 2\gamma \|d\|^2$ (es decir, los autovalores de la Hessiana están acotados por 2γ).

Como ya sabemos, en un problema de minimización convexo, todo minimizador local es global. El siguiente teorema muestra que la condición necesaria de primer orden (Teorema 3.3) pasa a ser suficiente.

Teorema 3.20 (Condiciones KKT para problema convexo). Sean $D \subset \mathbb{R}^n$ convexo y f convexa y diferenciable en un abierto que contiene a D . Un punto $\bar{x} \in D$ es minimizador global si, y solo si:

$$\langle \nabla f(\bar{x}), x - \bar{x} \rangle \geq 0 \quad \forall x \in D \iff -\nabla f(\bar{x}) \in \mathcal{N}_D(\bar{x}).$$

Prueba. La necesidad ya fue demostrada en el Capítulo 1 (Teorema 1.3). Para la suficiencia, usamos la caracterización (2) del Teorema 3.19: $f(x) \geq f(\bar{x}) + \langle \nabla f(\bar{x}), x - \bar{x} \rangle$. Si la condición se cumple, el segundo término es ≥ 0 para todo $x \in D$, luego $f(x) \geq f(\bar{x})$, lo que prueba que $\bar{x}$ es mínimo global. ■

3.4.3. Funciones convexas no diferenciables

Cuando una función convexa pierde la diferenciable (por ejemplo, al tomar el supremo de varias funciones), las derivadas clásicas se reemplazan por derivadas direccionales y subdiferenciales.

Teorema 3.21 (Derivada direccional). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. Entonces para todo $x, d \in \mathbb{R}^n$, el límite

$$f'(x; d) = \lim_{\alpha \rightarrow 0^+} \frac{f(x + \alpha d) - f(x)}{\alpha}$$

siempre existe en $\mathbb{R} \cup \{-\infty, +\infty\}$. (Si f es finita, el límite es finito).

Definición 3.14 (Subgradiente y Subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. Decimos que un vector $y \in \mathbb{R}^n$ es un **subgradiente** de f en el punto x si:

$$f(z) \geq f(x) + \langle y, z - x \rangle \quad \forall z \in \mathbb{R}^n. \quad (3.13)$$

Al conjunto de todos los subgradiientes de f en x se le llama **subdiferencial** y se denota por $\partial f(x)$.

Geoméricamente, un subgradiente define un hiperplano afín que soporta al epígrafe de f en el punto $(x, f(x))$ y queda por debajo de la gráfica de la función globalmente.

Teorema 3.22 (Propiedades del Subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa finita en todo el espacio.

1. El conjunto $\partial f(x)$ es convexo, compacto y no vacío para todo $x \in \mathbb{R}^n$.
2. $\bar{x}$ es un minimizador global de f en $\mathbb{R}^n$ si, y solo si, $0 \in \partial f(\bar{x})$.
3. Para un conjunto D convexo cerrado, $\bar{x}$ es solución de $\min_{x \in D} f(x)$ si y solo si $0 \in \partial f(\bar{x}) + \mathcal{N}_D(\bar{x})$.
4. (Regla de la suma): Si f_1, f_2 son convexas en $\mathbb{R}^n$, entonces $\partial(f_1 + f_2)(x) = \partial f_1(x) + \partial f_2(x)$.

Prueba. El ítem (2) es inmediato de la definición (3.13): si $0 \in \partial f(\bar{x})$, entonces $f(z) \geq f(\bar{x}) + \langle 0, z - \bar{x} \rangle = f(\bar{x})$, por lo que $\bar{x}$ es óptimo global. Las demás pruebas requieren teoremas de separación que se omiten aquí por brevedad, pero que siguen estándares del análisis convexo de Rockafellar. ■

Teorema 3.23 (Relación entre derivada direccional y subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. La derivada direccional en x a lo largo de d equivale al máximo del producto interno sobre el subdiferencial:

$$f'(x; d) = \max_{y \in \partial f(x)} \langle y, d \rangle.$$

Finalmente, para el desarrollo de algoritmos de optimización no diferenciable, es útil relajar la noción de subgradiente.

Definición 3.15 (ϵ -subdiferencial). Para $\epsilon \geq 0$, el vector y es un ϵ -subgradiente de f en x si:

$$f(z) \geq f(x) + \langle y, z - x \rangle - \epsilon \quad \forall z \in \mathbb{R}^n.$$

El conjunto de todos los ϵ -subgradiientes se denota $\partial_\epsilon f(x)$. $\bar{x}$ es un ϵ -minimizador del problema si y solo si $0 \in \partial_\epsilon f(\bar{x})$.

Ejercicios del Capítulo

Parte I: Definiciones y hechos básicos de convexidad

Ejercicio 3.1. Mostrar que los siguientes conjuntos en $\mathbb{R}^n$ son convexas:

- (a) Cualquier subespacio de $\mathbb{R}^n$.
- (b) Cualquier semiespacio en $\mathbb{R}^n$, i.e., un conjunto $\{x \in \mathbb{R}^n \mid \langle a, x \rangle \leq c\}$, donde $a \in \mathbb{R}^n$ y $c \in \mathbb{R}$.
- (c) Cualquier hiperplano en $\mathbb{R}^n$, i.e., un conjunto $\{x \in \mathbb{R}^n \mid \langle a, x \rangle = c\}$, donde $a \in \mathbb{R}^n$ y $c \in \mathbb{R}$.
- (d) Una bola en $\mathbb{R}^n$, i.e., un conjunto $\{x \in \mathbb{R}^n \mid \|x\| \leq c\}$, donde $c \in \mathbb{R}_+$.

Ejercicio 3.2. Mostrar que el conjunto $\{x \in \mathbb{R}^n \mid \|x\| = c\}$, donde $c \in \mathbb{R}_+$, es convexo si, y solamente si, $c = 0$. (En particular, una esfera no trivial con $c > 0$ no es convexa).

Ejercicio 3.3. Sea $Q \in \mathbb{R}^{n \times n}$ una matriz simétrica semidefinida positiva. Probar que el conjunto $\{x \in \mathbb{R}^n \mid \langle Qx, x \rangle \leq c\}$ es convexo para todo $c \in \mathbb{R}_+$.

Ejercicio 3.4. Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Supongamos que $x \in \text{int } D$ y $y \in \text{fr } D$. Probar que

$$\left\{ \begin{array}{ll} ((1 - \alpha)x + \alpha y) \in \text{int } D, & \text{si } \alpha \in [0, 1), \\ ((1 - \alpha)x + \alpha y) \notin D, & \text{si } \alpha > 1. \end{array} \right.$$

Ejercicio 3.5. Sea $K \subset \mathbb{R}^n$ un cono. Probar que K es convexo si, y solamente si, $K = K + K$.

Ejercicio 3.6. Sean D un conjunto convexo en $\mathbb{R}^n$ y $c_1 > 0, c_2 > 0$. Probar que $(c_1 + c_2)D = c_1D + c_2D$. Mostrar que la afirmación puede ser falsa cuando D no es convexo.

Ejercicio 3.7. Probar que cuando $D = \mathbb{R}_+^n$, la condición de optimalidad en el Teorema 3.1.3 es equivalente a la siguiente condición de complementariedad:

$$\bar{x}_i \geq 0, \quad (\nabla f(\bar{x}))_i \geq 0, \quad \bar{x}_i (\nabla f(\bar{x}))_i = 0, \quad i = 1, \dots, n.$$

Ejercicio 3.8. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función (fuertemente) convexa y sean $x \in \mathbb{R}^n$ y $d \in \mathbb{R}^n$ cualesquiera. Probar que la función $\psi : \mathbb{R} \rightarrow \mathbb{R}$, $\psi(\alpha) = f(x + \alpha d)$, es (fuertemente) convexa.

Ejercicio 3.9. Sea $f : \mathbb{R}^m \rightarrow \mathbb{R}$ una función convexa. Sean $A \in \mathbb{R}^{m \times n}$ y $a \in \mathbb{R}^m$. Probar que la función $\phi(x) = f(Ax + a)$ es convexa en $\mathbb{R}^n$.

Ejercicio 3.10. Probar que la función $f(x) = \|x\|^2$ es fuertemente convexa con módulo $\gamma = 1$.

Ejercicio 3.11. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa y, al mismo tiempo, cóncava. Mostrar que esto implica que f es una función afín, i.e., $f(x) = \langle a, x \rangle + c$ para todo $x \in \mathbb{R}^n$, donde $a \in \mathbb{R}^n$ y $c \in \mathbb{R}$.

Parte II: Conjuntos convexos y Teoremas de separación

Ejercicio 3.12. Sean D y C conjuntos convexos en $\mathbb{R}^n$. Mostrar que los siguientes conjuntos son convexos:

- (a) $D + C = \{x \in \mathbb{R}^n \mid x = y + z, y \in D, z \in C\}$.
- (b) $cD = \{x \in \mathbb{R}^n \mid x = cy, y \in D\}$, con $c \in \mathbb{R}$ arbitrario.
- (c) $A(D) = \{y \in \mathbb{R}^m \mid y = Ax, x \in D\}$, con $A \in \mathbb{R}^{m \times n}$ arbitraria.
- (d) $A^{-1}(D) = \{x \in \mathbb{R}^m \mid Ax \in D\}$, con $A \in \mathbb{R}^{n \times m}$ arbitraria.

Ejercicio 3.13. Sean $\alpha_i > 0, i = 1, \dots, p$. Probar que

$$\frac{1}{p} \sum_{i=1}^p \alpha_i \geq \left(\prod_{i=1}^p \alpha_i \right)^{1/p}, \quad \left(\sum_{i=1}^p \alpha_i \right) \left(\sum_{i=1}^p \frac{1}{\alpha_i} \right) \geq p^2.$$

Ejercicio 3.14. Sea $D \subset \mathbb{R}^n$ un conjunto abierto. Probar que $\text{conv } D$ es abierto.

Ejercicio 3.15. Sea $\emptyset \neq D \subset \mathbb{R}^n$ un conjunto acotado. Probar que $\text{cl}(\text{conv } D) = \text{conv}(\text{cl } D)$.

Ejercicio 3.16. Sea $\emptyset \neq D \subset \mathbb{R}^n$. Probar que $\text{cone } D = \text{cone}(\text{conv } D)$.

Ejercicio 3.17. Construir un ejemplo mostrando que, aun siendo D un conjunto convexo y compacto, es posible que $\text{cone } D$ no sea cerrado.

Ejercicio 3.18. Sean C y D dos conjuntos no vacíos de $\mathbb{R}^n$. Probar que $\text{conv}(C+D) = \text{conv } C + \text{conv } D$ y $\text{conv}(C \times D) = \text{conv } C \times \text{conv } D$.

Ejercicio 3.19. Sean K_1 y K_2 conos convexos en $\mathbb{R}^n$. Probar que

$$K_1 + K_2 = \text{conv}(K_1 \cup K_2), \quad K_1 \cap K_2 = \bigcap_{\alpha \in [0,1]} (\alpha K_1 + (1-\alpha)K_2).$$

Ejercicio 3.20. Sea K un cono convexo en $\mathbb{R}^n$. Probar que $\text{int } K \cup \{0\}$ es un cono convexo y $(\text{int } K \cup \{0\})^* = K^*$ si $\text{int } K$ es no vacío.

Ejercicio 3.21. Sean $A \in \mathbb{R}^{l \times n}$, $a \in \mathbb{R}^l$, $B \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Probar que para el conjunto poliédrico $D = \{x \in \mathbb{R}^n \mid Ax = a, Bx \leq b\}$, se tiene $\mathcal{R}_D = \{d \in \mathbb{R}^n \mid Ad = 0, Bd \leq 0\}$.

Ejercicio 3.22. Sea $\emptyset \neq D \subset \mathbb{R}^n$ un conjunto convexo cerrado, y $x \in \mathbb{R}^n$ cualquiera. Probar que $\bar{x} = P_D(x)$ si, y solamente si, $\bar{x} \in D$, $\langle x - \bar{x}, y - \bar{x} \rangle \leq 0 \quad \forall y \in D$. (Nota: La expresión en la desigualdad estándar de proyección fue corregida respecto al original para reflejar la ortogonalidad geométrica usual).

Ejercicio 3.23. Sea $K \subset \mathbb{R}^n$ un cono cerrado (no necesariamente convexo) y $y \in K^*$. Probar que la proyección de y sobre K es única y es igual a 0.

Ejercicio 3.24. Sea $\emptyset \neq K \subset \mathbb{R}^n$ un cono convexo cerrado. Probar que $\bar{x} = P_K(x)$ si, y solamente si, $\bar{x} \in K$, $x - \bar{x} \in K^*$, $\langle \bar{x}, x - \bar{x} \rangle = 0$.

Ejercicio 3.25. Sea $\emptyset \neq K \subset \mathbb{R}^n$ un cono convexo cerrado. Probar que las siguientes afirmaciones son equivalentes:

- (a) $\bar{x} = P_K(x)$ y $\bar{x}^* = P_{K^*}(x)$.
- (b) $x = \bar{x} + \bar{x}^*$, donde $\bar{x} \in K$, $\bar{x}^* \in K^*$, $\langle \bar{x}, \bar{x}^* \rangle = 0$.

Ejercicio 3.26. Sea $\emptyset \neq D \subset \mathbb{R}^n$ un conjunto convexo cerrado. Probar que la función-distancia $\text{dist}(x, D) = \min_{z \in D} \|z - x\|$, $x \in \mathbb{R}^n$, es convexa en $\mathbb{R}^n$.

Ejercicio 3.27. Sea $D \subset \mathbb{R}^n$ un conjunto convexo cerrado. Probar que para todo $x \in D$ y todo $d \in \mathbb{R}^n$, la función $\phi_1 : \mathbb{R}_+ \rightarrow \mathbb{R}$, $\phi_1(t) = \|P_D(x + td) - x\|$, es monótona no decreciente, y la función $\phi_2 : \mathbb{R}_+ \setminus \{0\} \rightarrow \mathbb{R}$, $\phi_2(t) = \phi_1(t)/t$, es monótona no creciente.

Ejercicio 3.28. Sean $D_i \subset \mathbb{R}^n$, $i = 1, 2$, conjuntos convexos tales que $\text{int } D_i \neq \emptyset$, $i = 1, 2$, y $\text{int } D_1 \cap \text{int } D_2 = \emptyset$. Probar que D_1 y D_2 son separables.

Ejercicio 3.29. Sean D_1 y D_2 conjuntos convexos en $\mathbb{R}^n$ tales que $\text{int } D_1 \neq \emptyset$. Probar que D_1 y D_2 son separables si, y solamente si, $\text{int } D_1 \cap D_2 = \emptyset$.

Ejercicio 3.30. Sea $K \subset \mathbb{R}^n$ un cono y $x \in \text{fr } K$. Probar que si un hiperplano H separa x y K , entonces $0 \in H$.

Ejercicio 3.31. Sea $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado tal que $D \neq \emptyset$, $D \neq \mathbb{R}^n$ y $\mathbb{R}^n \setminus D$ es convexo. Probar que D es un semiespacio.

Ejercicio 3.32. Sean K_1 y K_2 conos convexos cerrados no vacíos en $\mathbb{R}^n$. Probar que $(K_1 \cap K_2)^* = \text{cl}(K_1^* + K_2^*)$. Considerando $K_1 = \{x \in \mathbb{R}^3 \mid x_1^2 + x_2^2 \leq x_3^2, x_3 \leq 0\}$ y $K_2 = \{x \in \mathbb{R}^3 \mid x_2 = -x_3\}$, mostrar que la operación “cl” no puede ser omitida en la relación de arriba.

Ejercicio 3.33. Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Probar que $\bar{x} \in D$ es un punto extremo de D si, y solamente si, el conjunto $D \setminus \{\bar{x}\}$ es convexo.

Ejercicio 3.34. Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Probar que si $\bar{x}$ es un punto extremo de D , entonces $\bar{x} \in \text{fr } D$ ($\bar{x}$ pertenece a la frontera de D). En particular, un conjunto abierto convexo no tiene puntos extremos.

Ejercicio 3.35. Sean $B \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ y $D = \{x \in \mathbb{R}^n \mid Bx \leq b\} \neq \emptyset$. Probar que D tiene puntos extremos si, y solamente si, $\ker B = \{0\}$.

Ejercicio 3.36. Sean $B \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ y $D = \{x \in \mathbb{R}^n \mid Bx \leq b, x \geq 0\}$. Definamos $\tilde{D} = \{(x, \sigma) \in \mathbb{R}^n \times \mathbb{R}^m \mid Bx + \sigma = b, x \geq 0, \sigma \geq 0\}$. Probar que (x, σ) es un punto extremo de $\tilde{D}$ si, y solamente si, x es un punto extremo de D .

Ejercicio 3.37. Sea U una caja en torno a $\bar{x} \in \mathbb{R}^n$, i.e., $U = \{x \in \mathbb{R}^n \mid -\delta \leq x_i - \bar{x}_i \leq \delta, i = 1, \dots, n\}$, $\delta > 0$. Mostrar que U es el cierre convexo de 2^n puntos cuyas coordenadas son $\bar{x}_i + \delta$ o $\bar{x}_i - \delta$ (en todas las combinaciones posibles).

Ejercicio 3.38. Probar que los vértices del conjunto $D = \{x \in \mathbb{R}_+^n \mid \sum_{i=1}^n x_i = 1\}$ son los elementos de la base canónica de $\mathbb{R}^n$.

Ejercicio 3.39. Sea $D \subset \mathbb{R}^n$ un conjunto poliédrico. Sea $A \in \mathbb{R}^{l \times n}$ una matriz cuyas columnas son linealmente independientes. Probar que x es un vértice de D si, y solamente si, Ax es un vértice del conjunto $A(D)$ en $\mathbb{R}^l$. Construir un ejemplo mostrando que la afirmación es falsa cuando las columnas de A son linealmente dependientes.

Parte III: Teoremas de alternativa

Ejercicio 3.40. Probar el Teorema de la Alternativa de Tucker: Para matrices $A_0 \in \mathbb{R}^{m_0 \times n}$ ($A_0 \neq 0$), $A_1 \in \mathbb{R}^{m_1 \times n}$ y $A_2 \in \mathbb{R}^{m_2 \times n}$, uno y solamente uno de los sistemas posee solución:

$$A_0 x \geq 0 \quad (A_0 x \neq 0), \quad A_1 x = 0, \quad A_2 x \geq 0, \quad x \in \mathbb{R}^n,$$

o

$$A_0^T y^0 + A_1^T y^1 + A_2^T y^2 = 0, \quad (y^0, y^1, y^2) \in \mathbb{R}_{++}^{m_0} \times \mathbb{R}^{m_1} \times \mathbb{R}_{++}^{m_2}.$$

Ejercicio 3.41. Probar el Teorema de la Alternativa de Gale I:

$$Ax = a, \quad x \in \mathbb{R}_+^n \quad \text{o} \quad A^T y \geq 0, \quad \langle a, y \rangle < 0, \quad y \in \mathbb{R}^m.$$

Ejercicio 3.42. Probar el Teorema de la Alternativa de Gale II:

$$Ax \leq a, \quad x \in \mathbb{R}_+^n \quad \text{o} \quad A^T y \geq 0, \quad \langle a, y \rangle < 0, \quad y \in \mathbb{R}_+^m.$$

Ejercicio 3.43. Probar el Teorema de la Alternativa de Gordan:

$$Ax < 0, x \in \mathbb{R}^n \quad \text{o} \quad A^T y = 0, \langle a, y \rangle \leq 0, y \in \mathbb{R}_+^m \setminus \{0\}.$$

Ejercicio 3.44. Probar el Teorema de la Alternativa de Stiemke:

$$Ax \leq 0, Ax \neq 0, x \in \mathbb{R}^n \quad \text{o} \quad A^T y = 0, \langle a, y \rangle \leq 0, y \in \mathbb{R}_{++}^m.$$

Parte IV: Funciones convexas

Ejercicio 3.45. Construir un ejemplo mostrando que, para una función ψ convexa que no sea no decreciente, la afirmación de la Proposición 3.4.3 (composición) puede ser falsa.

Ejercicio 3.46. Probar que, cuando en la Proposición 3.4.3 g es una función afín, la afirmación es verdadera para ψ convexa cualquiera.

Ejercicio 3.47. Sean $f_i : \mathbb{R}^n \rightarrow \mathbb{R}, i = 1, \dots, p$, funciones convexas en $\mathbb{R}^n$. Probar que para $q \geq 1$, la función $f : \mathbb{R}^n \rightarrow \mathbb{R}, f(x) = \sum_{i=1}^p (\max\{0, f_i(x)\})^q$ es convexa en $\mathbb{R}^n$.

Ejercicio 3.48. Probar que la función $f(x) = (\max\{e^x, x^2\} + 1/x)^2$ es convexa en $\mathbb{R}_+ \setminus \{0\}$.

Ejercicio 3.49. Sean $\alpha_i \geq 0, i = 1, \dots, n, \sum_{i=1}^n \alpha_i = 1$. Probar que la función $f(x) = \prod_{i=1}^n x_i^{\alpha_i}, x \in \mathbb{R}_+^n$, es cóncava en $\mathbb{R}_+^n$. (Esta función es importante en Economía Matemática y se llama función de Cobb-Douglas).

Ejercicio 3.50. Probar que para $a \in \mathbb{R}_+^n$ y $b > 0$ cualesquiera, la función $f(x) = \frac{1}{\langle a, x \rangle + b}$ es convexa en $\mathbb{R}_+^n$.

Ejercicio 3.51. Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Probar que $f : D \rightarrow \mathbb{R}$ es cuasiconvexa en D si, y solamente si, $f(\alpha x + (1 - \alpha)y) \leq \max\{f(x), f(y)\} \quad \forall x, y \in D, \forall \alpha \in [0, 1]$.

Ejercicio 3.52. Sea $f : D \rightarrow \mathbb{R}$ una función cuasiconvexa en el conjunto convexo D . Probar que todo minimizador local estricto de f en D es minimizador global. Probar que todo minimizador local estricto de f en D es un punto extremo de D .

Ejercicio 3.53. Sea $h : \mathbb{R}^n \rightarrow \mathbb{R}$ una función estrictamente convexa. Probar que si el conjunto $\{x \in \mathbb{R}^n \mid h(x) = 0\}$ contiene más de un punto, entonces él no es convexo.

Ejercicio 3.54. Probar el Teorema 3.4.4.

Ejercicio 3.55. Sean D y C conjuntos convexas en $\mathbb{R}^n$ y $\mathbb{R}^m$, respectivamente. Consideremos $\phi(x, y)$, una función convexa en $D \times C$ tal que $\inf_{y \in C} \phi(x, y) > -\infty$ para todo $x \in D$ fijo. Probar que la función $f(x) = \inf_{y \in C} \phi(x, y)$ es convexa en D .

Ejercicio 3.56. Sea f una función convexa en $\mathbb{R}_+$ que es limitada superiormente en $\mathbb{R}_+$. Probar que f es no creciente en $\mathbb{R}_+$.

Ejercicio 3.57. Sea $D \subset \mathbb{R}^n$ un conjunto convexo cerrado no vacío y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Suponiendo que $\bar{x} \in D$, mostrar que las siguientes afirmaciones son equivalentes:

- (a) $\bar{x}$ es una solución del problema $\min f(x)$ sujeto a $x \in D$.
- (b) $\exists \beta > 0$ tal que $\bar{x}$ es una solución del problema irrestricto $\min(f(x) + \beta \text{dist}(x, D)), x \in \mathbb{R}^n$.

Ejercicio 3.58. Resolver el problema $\min f(x)$ sujeto a $x \in D$, donde:

(a) $f(x) = 2x_1^2 + 4x_2^2 - 5x_1x_2, \quad D = \{x \in \mathbb{R}^2 \mid 0 \leq x_1 \leq 1, 0 \leq x_2 \leq 1\}.$

(b) $f(x) = 2x_1^4 + x_2^4, \quad D = \left\{x \in \mathbb{R}^2 \mid \begin{array}{l} -x_1 + 2x_2 \leq 3, \\ 3x_1 + x_2 \leq 5, \\ 2x_1 + 3x_2 \geq 1 \end{array} \right\}.$

(c) $f(x) = x_1^2 + x_2^2 + x_3^2 + x_4^2, \quad D = \left\{x \in \mathbb{R}^4 \mid \begin{array}{l} x_1 - 2x_2 + 4x_3 - x_4 = 1, \\ 2x_1 + 3x_2 + x_3 + 2x_4 = 3 \end{array} \right\}.$

Ejercicio 3.59. Probar que la función $f(x) = x_1^2/x_2$ es convexa en el conjunto $D = \{x \in \mathbb{R}^2 \mid x_2 > 0\}$.

Ejercicio 3.60. ¿Para cuáles valores del parámetro $\sigma \in \mathbb{R}$ la función $f(x) = (\sigma + 6)x_1^2 + 2\sigma x_1 x_2 + x_2^2$ es convexa en $\mathbb{R}^2$?

Ejercicio 3.61. ¿Para cuáles valores del parámetro $\sigma \in \mathbb{R}$ la función $f(x) = x_1^2 + 4x_2^2 + (\sigma + 2)x_3^2 + x_1 x_2 + 2x_1 x_3 + x_2 x_3$, $x \in \mathbb{R}^3$, es convexa en $\mathbb{R}^3$?

Ejercicio 3.62. Probar que las siguientes funciones son convexas en $\mathbb{R}^n$:

- (a) $f(x) = \ln(\sum_{i=1}^n e^{x_i})$.
- (b) $f(x) = e^{\langle Qx, x \rangle}$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz semidefinida positiva.
- (c) $f(x) = (1 + \|x\|^2)^{1/2}$.

Ejercicio 3.63. Sea $D \subset \mathbb{R}^n$ un conjunto convexo y abierto y $f : D \rightarrow \mathbb{R}$ una función diferenciable en D . Probar que las propiedades siguientes son equivalentes:

- (a) La función f es estrictamente convexa en D .
- (b) Para todo $x \in D$ y todo $y \in D$ tales que $x \neq y$, $f(y) > f(x) + \langle \nabla f(x), y - x \rangle$.
- (c) Para todo $x \in D$ y todo $y \in D$ tales que $x \neq y$, $\langle \nabla f(y) - \nabla f(x), y - x \rangle > 0$.

Cuando f es dos veces diferenciable en D , probar que f es estrictamente convexa en D si:

- (d) Para todo $x \in D$, $\langle \nabla^2 f(x)d, d \rangle > 0 \quad \forall d \in \mathbb{R}^n \setminus \{0\}$.

Ejercicio 3.64. Probar el Teorema 3.4.10.

Ejercicio 3.65. Resolver el problema $\min f(x)$ sujeto a $x \in D$, donde:

- (a) $f(x) = 2x_1^2 + x_1 x_2 + x_2^2$, $D = \{x \in \mathbb{R}^2 \mid -1 \leq x_1 \leq 1, x_2 \geq 2\}$.
- (b) $f(x) = 4x_1^2 - x_1 x_2 + 2x_2^2$, $D = \{x \in \mathbb{R}^2 \mid 4 \leq x_1 \leq 8, -1 \leq x_2 \leq 2\}$.

Ejercicio 3.66. Encontrar todos los valores de $\sigma \in \mathbb{R}$ para los cuales el punto $\bar{x} = 0$ es una solución del problema

$$\min e^{\sigma^2 x_1} + e^{\sigma^2 x_2} + 2\sigma x_1 - x_2 \quad \text{sujeto a} \quad 0 \leq x_1 \leq 1, -1 \leq x_2 \leq 0.$$

Ejercicio 3.67. Sea $\emptyset \neq D \subset \mathbb{R}^n$ un conjunto convexo cerrado y $f : \mathbb{R}^n \rightarrow \mathbb{R}_+$, $f(x) = (\text{dist}(x, D))^2$. Probar que f es convexa y diferenciable en $\mathbb{R}^n$ y que $\nabla f(x) = 2(x - P_D(x)) \quad \forall x \in \mathbb{R}^n$.

Ejercicio 3.68. Probar que, bajo las hipótesis del Teorema 3.4.8, además de las relaciones establecidas en ese teorema, las siguientes afirmaciones también son equivalentes:

- (a) $\bar{x}$ es un minimizador de f en D .
- (b) $P_{\mathcal{T}_D(\bar{x})}(-\nabla f(\bar{x})) = 0$.
- (c) $\langle \nabla f(\bar{x}), P_{\mathcal{T}_D(\bar{x})}(-\nabla f(\bar{x})) \rangle \geq 0$.

Ejercicio 3.69. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa diferenciable y $D \subset \mathbb{R}^n$ un conjunto convexo cerrado. Definimos la función $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$, $F(x) = P_D(x - \nabla f(x))$. Probar que $x \in \mathbb{R}^n$ es un punto fijo de F (i.e., $F(x) = x$) si, y solamente si, x es un minimizador de f en D .

Ejercicio 3.70. Sea f una función convexa y diferenciable en $\mathbb{R}^n$. Probar que para todo $\lambda > 0$, el sistema de ecuaciones $\nabla f(x) = -\lambda x$ posee una única solución.

Ejercicio 3.71. Sea f una función fuertemente convexa y diferenciable en $\mathbb{R}^n$. Probar que para el (único) minimizador $\bar{x}$ de f en $\mathbb{R}^n$, existe $M > 0$ tal que $\|x - \bar{x}\| \leq M\|\nabla f(x)\| \quad \forall x \in \mathbb{R}^n$.

Ejercicio 3.72. Sea f una función fuertemente convexa y diferenciable en $\mathbb{R}^n$ y $\bar{x}$ la (única) solución del problema $\min f(x)$ sujeto a $x \geq 0$. Probar que existe $M > 0$ tal que para todo $x \in \mathbb{R}^n$ se tiene

$$M\|x - \bar{x}\|^2 \leq (\langle x, \nabla f(x) \rangle)^2 + \sum_{i=1}^n (\max\{0, -(\nabla f(x))_i\})^2 + \sum_{i=1}^n (\max\{0, -x_i\})^2.$$

Ejercicio 3.73. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Probar que $\langle y^1 - y^2, x^1 - x^2 \rangle \geq 0 \quad \forall x^i \in \mathbb{R}^n \text{ e } \forall y^i \in \partial f(x^i), i = 1, 2$.

Ejercicio 3.74. Resolver el problema $\min f(x)$, $x \in \mathbb{R}^n$, donde

- (a) $f(x) = \max\{x_1^2 + x_2^2, x_1 + x_2 + 1\}$, $n = 2$;
- (b) $f(x) = \max\{x_1^2 + x_2, x_1 + x_2^2\}$, $n = 2$;
- (c) $f(x) = \max\{x^2, x^2 - 2x + \sigma\}$, $n = 1$ y $\sigma \in \mathbb{R}$ es un parámetro arbitrario;
- (d) $f(x) = \|x\| - \langle a, x \rangle$, $n = 2$ y $a \in \mathbb{R}^2$ es fijo, pero arbitrario;
- (e) $f(x) = \|x\|^2/2 + \|x - a\|$ y $a \in \mathbb{R}^n$ es fijo, pero arbitrario.

Ejercicio 3.75. Encontrar el punto $x \in \mathbb{R}^r$ tal que la suma de las distancias entre x y puntos $x^i \in \mathbb{R}^r$, $i = 1, \dots, p$, dados sea mínima.

Ejercicio 3.76. Encontrar el punto $x \in \mathbb{R}^2$ tal que la suma de los cuadrados de las distancias entre x y los vértices de un triángulo dado en $\mathbb{R}^2$ sea mínima.

Ejercicio 3.77. Sean $\psi : \mathbb{R}^l \rightarrow \mathbb{R}$ una función convexa y $A \in \mathbb{R}^{l \times n}$. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f(x) = \psi(Ax)$. Probar que $\partial f(x) = A^\top \partial \psi(Ax) = \{y \in \mathbb{R}^n \mid y = A^\top z, z \in \partial \psi(Ax)\}$.

Ejercicio 3.78. Sean $g : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa, y $\psi : \mathbb{R} \rightarrow \mathbb{R}$ una función convexa diferenciable y no decreciente. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f(x) = \psi(g(x))$. Probar que $\partial f(x) = \psi'(g(x))\partial g(x) = \{y \in \mathbb{R}^n \mid y = \psi'(g(x))z, z \in \partial g(x)\}$.

Ejercicio 3.79. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Mostrar que $\bar{y} \in \mathbb{R}^n$ es la solución del problema $\min \|y\|$ sujeto a $y \in \partial f(x)$ (equivalentemente, $\bar{y} = P_{\partial f(x)}(0)$) se, y solamente se, $\bar{y} = 0$ o $\bar{y}/\|\bar{y}\|$ es la solución del problema $\min f'(x; y)$ sujeto a $\|y\| \leq 1$.

Ejercicio 3.80. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Supongamos que $x \in \mathbb{R}^n$ sea tal que el conjunto de nivel asociado $L = L_{f, \mathbb{R}^n}(f(x)) = \{z \in \mathbb{R}^n \mid f(z) \leq f(x)\}$ sea no vacío. Mostrar que

$$\mathcal{T}_L(x) = \{d \in \mathbb{R}^n \mid f'(x; d) \leq 0\}, \quad \mathcal{N}_L(x) = \text{cl}(\text{cone } \partial f(x)).$$

Ejercicio 3.81. Sean $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$, $i = 1, \dots, p$, funciones convexas, y $f(x) = \sum_{i=1}^p f_i(x)$ y $\epsilon \in \mathbb{R}_+$. Probar que $\partial_\epsilon f(x) \subset \sum_{i=1}^p \partial_{\epsilon_i} f_i(x) \subset \partial_{p\epsilon} f(x)$.

Ejercicio 3.82. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa y $\epsilon \in \mathbb{R}_+$. Suponiendo que $\{x^k\} \rightarrow x$, $\{\epsilon_k \rightarrow 0\}$, y $\epsilon_k \geq 0$, para todo k , probar que si $\{y^k\}$ es tal que $y^k \in \partial_{\epsilon_k} f(x^k)$ para todo k , la sucesión $\{y^k\}$ es limitada y que todos sus puntos de acumulación pertenecen a $\partial f(x)$.

4. Problemas con Restricciones Mixtas

En este capítulo contamos con las herramientas necesarias para abordar el problema de optimización general con restricciones mixtas de igualdad y desigualdad. Estudiaremos la caracterización del cono tangente para los conjuntos definidos por este tipo de restricciones, lo que nos permitirá derivar las condiciones de optimalidad primal-dual de Karush-Kuhn-Tucker (KKT). Asimismo, desarrollaremos las condiciones necesarias y suficientes de segundo orden.

Consideramos el problema de optimización con restricciones mixtas de igualdad y desigualdad:

$$\min f(x) \quad \text{sujeto a} \quad x \in D, \quad (4.1)$$

donde el conjunto factible está dado por:

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\}, \quad (4.2)$$

y $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones dadas.

Nota: Transformación a restricciones de igualdad

Como se mencionó en el Capítulo 1, es posible convertir el problema (4.1)-(4.2) en uno con restricciones exclusivas de igualdad, introduciendo variables de holgura $\sigma \in \mathbb{R}^m$ mediante la siguiente transformación:

$$\tilde{D} = \left\{ (x, \sigma) \in \mathbb{R}^n \times \mathbb{R}^m \mid \begin{array}{l} h(x) = 0, \\ g_i(x) + \sigma_i^2 = 0, \quad i = 1, \dots, m. \end{array} \right\}.$$

Sin embargo, esta aproximación exige hipótesis de regularidad más restrictivas y produce condiciones de optimalidad de segundo orden más débiles que las obtenidas al estudiar las desigualdades de forma directa.

Para el estudio local del problema, es necesario identificar cuáles restricciones de desigualdad determinan la frontera del conjunto factible en un punto dado.

Definición 4.1 (Restricciones activas). Sea $\bar{x} \in D$. Diremos que la restricción de desigualdad correspondiente al índice $i \in \{1, \dots, m\}$ es **activa** en el punto $\bar{x}$ cuando $g_i(\bar{x}) = 0$.

El conjunto de índices de las restricciones activas en el punto $\bar{x} \in D$ se denota por:

$$I(\bar{x}) = \{i \in \{1, \dots, m\} \mid g_i(\bar{x}) = 0\}.$$

Notación. Las restricciones de igualdad no se incluyen en esta definición puesto que, por la propia definición del conjunto D , siempre se satisfacen como igualdades en cualquier punto factible.

4.1. Cono tangente en el caso de restricciones de igualdad y desigualdad

Por continuidad, un minimizador local $\bar{x}$ del problema (4.1)-(4.2) también es minimizador local del problema relajado que omite las restricciones inactivas en $\bar{x}$. Geométricamente, las restricciones activas determinan el comportamiento local del conjunto factible en torno a $\bar{x}$ y, por ende, son las únicas relevantes para el análisis diferencial.

Definición 4.2 (Cono de linealización). Supongamos que h y g son diferenciables en $\bar{x} \in D$. Se define el **cono de linealización** en $\bar{x}$ para las restricciones de igualdad y las desigualdades activas, denotado por $\mathcal{H}(\bar{x})$, como:

$$\mathcal{H}(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} \langle \nabla h_i(\bar{x}), d \rangle = 0, \quad i = 1, \dots, l \\ \langle \nabla g_i(\bar{x}), d \rangle \leq 0, \quad \forall i \in I(\bar{x}) \end{array} \right\}. \quad (4.3)$$

De manera equivalente, utilizando la matriz Jacobiana J_h :

$$\mathcal{H}(\bar{x}) = \{d \in \ker J_h(\bar{x}) \mid \langle \nabla g_i(\bar{x}), d \rangle \leq 0 \quad \forall i \in I(\bar{x})\}.$$

Ejemplo 4.1 (Cálculo del cono de linealización). Considérese el conjunto factible en $\mathbb{R}^2$ delimitado por una parábola y el eje horizontal:

$$D = \left\{ x \in \mathbb{R}^2 \mid \begin{array}{l} g_1(x) = x_2 - x_1^2 \leq 0 \\ g_2(x) = -x_2 \leq 0 \end{array} \right\}.$$

El conjunto D consta de un único punto factible, $\bar{x} = (0, 0)^\top$.

Para determinar el cono de linealización $\mathcal{H}(\bar{x})$, evaluamos las restricciones en el origen: $g_1(0, 0) = 0$ y $g_2(0, 0) = 0$, por lo que $I(\bar{x}) = \{1, 2\}$. Los gradientes son:

$$\nabla g_1(\bar{x}) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \nabla g_2(\bar{x}) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}.$$

Por la Definición 4.2, un vector $d = (d_1, d_2)^\top$ pertenece a $\mathcal{H}(\bar{x})$ si satisface:

$$\langle \nabla g_1(\bar{x}), d \rangle = d_2 \leq 0 \quad \text{y} \quad \langle \nabla g_2(\bar{x}), d \rangle = -d_2 \leq 0 \implies d_2 \geq 0.$$

El sistema implica que $d_2 = 0$. La coordenada d_1 no está acotada por las restricciones linealizadas. En consecuencia:

$$\mathcal{H}(\bar{x}) = \left\{ \begin{pmatrix} d_1 \\ 0 \end{pmatrix} \mid d_1 \in \mathbb{R} \right\}.$$

Este caso ilustra una discrepancia entre la topología y el álgebra: el cono tangente geométrico es $\mathcal{T}_D(\bar{x}) = \{0\}$, mientras que el cono de linealización $\mathcal{H}(\bar{x})$ es una recta completa.

Proposición 4.1 (Inclusión de conos). Sea $D \subset \mathbb{R}^n$ el conjunto definido en (4.2). Si las funciones $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son diferenciables en $\bar{x} \in D$, entonces los conos tangentes están contenidos en el cono de linealización:

$$\mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x}) \subset \mathcal{H}(\bar{x}).$$

Prueba. La inclusión $\mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$ es una propiedad topológica general. Para la segunda inclusión, es inmediato que $0 \in \mathcal{B}_D(\bar{x}) \cap \mathcal{H}(\bar{x})$.

Sea $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. Existen sucesiones $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$ para todo $k \in \mathbb{N}$. La condición de factibilidad exige que para todo k :

$$h(\bar{x} + t_k d^k) = 0 \quad \text{y} \quad g_i(\bar{x} + t_k d^k) \leq 0 \quad \forall i \in I(\bar{x}).$$

Utilizando el desarrollo de Taylor de primer orden en $\bar{x}$:

$$\begin{aligned} 0 &= h(\bar{x} + t_k d^k) - h(\bar{x}) = t_k J_h(\bar{x}) d^k + o(t_k \|d^k\|), \\ 0 &\geq g_i(\bar{x} + t_k d^k) - g_i(\bar{x}) = t_k \langle \nabla g_i(\bar{x}), d^k \rangle + o(t_k \|d^k\|). \end{aligned}$$

Dividiendo por $t_k > 0$ y tomando el límite cuando $k \rightarrow \infty$, se sigue que $d^k \rightarrow d$ y el término residual $\frac{o(t_k \|d^k\|)}{t_k} \rightarrow 0$. Se obtiene:

$$J_h(\bar{x})d = 0 \quad \text{y} \quad \langle \nabla g_i(\bar{x}), d \rangle \leq 0 \quad \forall i \in I(\bar{x}),$$

lo cual demuestra que $d \in \mathcal{H}(\bar{x})$. ■

Contraejemplo 4.1 (Falta de regularidad e inclusión estricta). El siguiente ejemplo muestra que la igualdad $\mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$ requiere hipótesis adicionales. Sea $D \subset \mathbb{R}^2$ definido por:

$$g(x) = -x_1^3 + x_2^2 \leq 0.$$

En el origen $\bar{x} = (0, 0)^\top \in D$, la restricción es activa y su gradiente es $\nabla g(\bar{x}) = (0, 0)^\top$. El cono de linealización es todo el espacio:

$$\mathcal{H}(\bar{x}) = \{d \in \mathbb{R}^2 \mid \langle (0, 0)^\top, d \rangle \leq 0\} = \mathbb{R}^2.$$

Sin embargo, el conjunto D presenta una cúspide orientada hacia la dirección positiva del eje x_1 . La dirección $d = (-1, 0)^\top \in \mathcal{H}(\bar{x})$ no es tangente, ya que para cualquier $t > 0$, evaluando en la restricción se tiene $-(-t)^3 + 0^2 = t^3 > 0$, por lo que $\bar{x} + td \notin D$. Por tanto, $d \notin \mathcal{B}_D(\bar{x})$, verificándose la inclusión estricta $\mathcal{B}_D(\bar{x}) \subsetneq \mathcal{H}(\bar{x})$.

Ejemplo 4.2 (Igualdad de conos bajo regularidad). Considérese el conjunto en $\mathbb{R}^2$ definido por:

$$D = \left\{ x \in \mathbb{R}^2 \mid \begin{array}{l} h(x) = x_2 - x_1^2 = 0 \\ g(x) = x_1 \leq 0 \end{array} \right\}.$$

Tomemos el punto $\bar{x} = (0, 0)^\top$. La restricción de desigualdad es activa ($I(\bar{x}) = \{1\}$). Los gradientes en $\bar{x}$ son $\nabla h(\bar{x}) = (0, 1)^\top$ y $\nabla g(\bar{x}) = (1, 0)^\top$. El cono de linealización $\mathcal{H}(\bar{x})$ requiere $d_2 = 0$ y $d_1 \leq 0$, de donde $\mathcal{H}(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \leq 0\}$.

Para el cono de Bouligand $\mathcal{B}_D(\bar{x})$, dada una sucesión $t_k \rightarrow 0^+$, los puntos de D admiten la forma $(-t_k, t_k^2)^\top$. La dirección secante es:

$$d^k = \frac{1}{t_k} \begin{pmatrix} -t_k \\ t_k^2 \end{pmatrix} = \begin{pmatrix} -1 \\ t_k \end{pmatrix}.$$

En el límite $k \rightarrow \infty$, se obtiene $d = (-1, 0)^\top$. Por homotecia de conos, $\mathcal{B}_D(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \leq 0\}$. Para el cono tangente estricto $\mathcal{T}_D(\bar{x})$, la curva $x(t) = (-t, t^2)^\top$ contenida en D para $t \geq 0$ tiene por vector director $d = (-1, 0)^\top$. Por lo tanto, en este punto se verifica $\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$.

Lema 4.1 (Lema de Farkas Generalizado). Sea $K \subset \mathbb{R}^n$ un cono poliédrico definido por el sistema:

$$K = \{x \in \mathbb{R}^n \mid A_1 x = 0, A_2 x \leq 0\},$$

con matrices $A_1 \in \mathbb{R}^{m_1 \times n}$ y $A_2 \in \mathbb{R}^{m_2 \times n}$.

El cono dual K^* equivale al conjunto de combinaciones lineales de las filas de A_1 y A_2 , donde los coeficientes correspondientes a A_2 son no negativos:

$$K^* = \left\{ z \in \mathbb{R}^n \mid \begin{array}{l} z = A_1^\top \lambda + A_2^\top \mu, \\ \lambda \in \mathbb{R}^{m_1}, \mu \in \mathbb{R}_+^{m_2} \end{array} \right\}. \quad (4.4)$$

Prueba. Sea Q el conjunto de la ecuación (4.4). Para todo $z \in Q$ y todo $x \in K$, existen $\lambda \in \mathbb{R}^{m_1}$ y $\mu \in \mathbb{R}_+^{m_2}$ tales que $\langle z, x \rangle = \langle A_1^\top \lambda + A_2^\top \mu, x \rangle = \langle \lambda, A_1 x \rangle + \langle \mu, A_2 x \rangle$. Dado que $x \in K$, se satisface $A_1 x = 0$ y $A_2 x \leq 0$. Como $\mu \geq 0$, se concluye que $\langle \mu, A_2 x \rangle \leq 0$. Luego, $\langle z, x \rangle \leq 0$, lo que implica la inclusión $Q \subset K^*$.

Para demostrar la inclusión $K^* \subset Q$, supongamos que existe $\xi \in K^*$ tal que $\xi \notin Q$. Al ser Q un cono convexo cerrado, por el Teorema de Separación Estricta (o Lema de Motzkin), existe $x \in \mathbb{R}^n$ que separa ξ de Q : $\langle \xi, x \rangle > 0$ y $\langle z, x \rangle \leq 0$ para todo $z \in Q$. Evaluando la segunda condición: $\langle \lambda, A_1 x \rangle + \langle \mu, A_2 x \rangle \leq 0$ para todo $\lambda \in \mathbb{R}^{m_1}, \mu \in \mathbb{R}_+^{m_2}$. La pertenencia de λ a todo el espacio requiere que $A_1 x = 0$. La condición $\mu \geq 0$ exige que $A_2 x \leq 0$. En consecuencia, $x \in K$. Sin embargo, la desigualdad $\langle \xi, x \rangle > 0$ contradice la hipótesis $\xi \in K^*$, que exige $\langle \xi, x \rangle \leq 0$ para todo $x \in K$. Esta contradicción demuestra que $K^* \subset Q$. ■

Ejemplo 4.3 (Lema de Farkas en $\mathbb{R}^2$). Sea el cono poliédrico $K \subset \mathbb{R}^2$ definido por:

$$A_2 x \leq 0 \implies \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \leq \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies x_1 \geq 0, x_2 \geq 0.$$

El cono primal es $K = \mathbb{R}_+^2$. Por definición, $z \in K^*$ si $z_1 x_1 + z_2 x_2 \leq 0$ para todo $x \in \mathbb{R}_+^2$. Evaluando en la base canónica, se concluye $z_1 \leq 0$ y $z_2 \leq 0$, es decir, $K^* = \mathbb{R}_-^2$.

Aplicando el Lema 4.1, K^* se expresa mediante combinaciones cónicas de las filas de A_2 :

$$K^* = \left\{ \mu_1 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} \mid \mu_1, \mu_2 \geq 0 \right\} = \left\{ \begin{pmatrix} -\mu_1 \\ -\mu_2 \end{pmatrix} \mid \mu_1, \mu_2 \geq 0 \right\} = \mathbb{R}_-^2.$$

Lema 4.2 (Estructura Dual del Cono de Linealización). Sea $\mathcal{H}(\bar{x})$ el cono poliédrico definido en (4.3). El cono dual $\mathcal{H}(\bar{x})^*$ está dado por:

$$\mathcal{H}(\bar{x})^* = \left\{ y \in \mathbb{R}^n \mid \begin{array}{l} y = J_h(\bar{x})^\top \lambda + \sum_{i \in I(\bar{x})} \mu_i \nabla g_i(\bar{x}), \\ \lambda \in \mathbb{R}^l, \mu_i \geq 0 \quad \forall i \in I(\bar{x}) \end{array} \right\}. \quad (4.5)$$

Prueba. El resultado se sigue directamente de la aplicación del Lema de Farkas (Lema 4.1). Definiendo la matriz $A_1 = J_h(\bar{x}) \in \mathbb{R}^{l \times n}$ y construyendo A_2 a partir de los gradientes transpuestos $\nabla g_i(\bar{x})^\top$ para $i \in I(\bar{x})$, un vector $y \in \mathcal{H}(\bar{x})^*$ se descompone como $A_1^\top \lambda + A_2^\top \mu$, con $\mu \geq 0$. ■

Ejemplo 4.4 (Construcción del cono dual). Considérese el origen $\bar{x} = (0, 0, 0)^\top$ en el sistema:

$$D = \left\{ x \in \mathbb{R}^3 \mid \begin{array}{l} h(x) = x_1 - x_2 = 0 \\ g(x) = x_1 + x_2 + x_3 \leq 0 \end{array} \right\}.$$

La desigualdad es activa ($g(0) = 0$). Los gradientes en $\bar{x}$ son $\nabla h(\bar{x}) = (1, -1, 0)^\top$ y $\nabla g(\bar{x}) = (1, 1, 1)^\top$. El cono de linealización $\mathcal{H}(\bar{x})$ requiere $d_1 = d_2$ y $2d_1 + d_3 \leq 0$.

Por el Lema 4.2, su cono dual $\mathcal{H}(\bar{x})^*$ toma la forma:

$$y = \lambda \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} + \mu \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} \lambda + \mu \\ -\lambda + \mu \\ \mu \end{pmatrix}, \quad \lambda \in \mathbb{R}, \mu \geq 0.$$

El parámetro λ , asociado a la igualdad, no tiene restricción de signo y genera un subespacio. La variable μ , asociada a la desigualdad, está restringida a $\mu \geq 0$, lo que define la estructura cónica del conjunto dual.

Teorema 4.1 (Condición suficiente de primer orden). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferenciables en $\bar{x} \in D$. Sea $\mathcal{H}(\bar{x})$ el cono definido en (4.3).

Si se cumple la condición:

$$\langle \nabla f(\bar{x}), d \rangle > 0 \quad \forall d \in \mathcal{H}(\bar{x}) \setminus \{0\}, \quad (4.6)$$

entonces f satisface la **condición de crecimiento lineal** en $\bar{x}$: existen un entorno U de $\bar{x}$ y un escalar $\beta > 0$ tales que

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\| \quad \forall x \in D \cap U.$$

Por lo tanto, $\bar{x}$ es un minimizador local estricto de (4.1).

Prueba. Supongamos, por reducción al absurdo, que se cumple (4.6) pero la condición de crecimiento lineal es falsa. Esto implica la existencia de una sucesión $x^k \in D \setminus \{\bar{x}\}$ convergiendo a $\bar{x}$ tal que

$$f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|.$$

Sea $t_k = \|x^k - \bar{x}\| > 0$ y considérese la dirección normalizada $d^k = (x^k - \bar{x})/t_k$. Por la compacidad de la esfera unitaria, existe una subsucesión convergente $d^k \rightarrow d$, con $\|d\| = 1$ (es decir, $d \neq 0$). Por la definición de direcciones tangentes secuenciales, $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. La inclusión del Proposición 4.1 establece que $d \in \mathcal{H}(\bar{x}) \setminus \{0\}$.

Utilizando el desarrollo de Taylor de primer orden para f :

$$\frac{t_k}{k} > \langle \nabla f(\bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|) = t_k \langle \nabla f(\bar{x}), d^k \rangle + o(t_k).$$

Dividiendo entre t_k y tomando el límite $k \rightarrow \infty$, dado que $o(t_k)/t_k \rightarrow 0$ y $d^k \rightarrow d$, se sigue que $0 \geq \langle \nabla f(\bar{x}), d \rangle$. Este resultado contradice la hipótesis (4.6). Se concluye la existencia de crecimiento lineal, garantizando que $\bar{x}$ es un mínimo estricto. ■

Ejemplo 4.5 (Aplicación de la condición suficiente). Sea el problema:

$$\min f(x) = x_2 \quad \text{sujeto a} \quad D = \left\{ x \in \mathbb{R}^2 \mid \begin{array}{l} g_1(x) = x_1 - x_2 \leq 0 \\ g_2(x) = -x_1 - x_2 \leq 0 \end{array} \right\}.$$

En el origen $\bar{x} = (0, 0)^\top$, ambas restricciones son activas ($I(\bar{x}) = \{1, 2\}$). Los gradientes son $\nabla g_1(\bar{x}) = (1, -1)^\top$ y $\nabla g_2(\bar{x}) = (-1, -1)^\top$. El cono de linealización $\mathcal{H}(\bar{x})$ requiere $d_1 - d_2 \leq 0$ y $-d_1 - d_2 \leq 0$, lo que implica $d_2 \geq |d_1|$.

El gradiente objetivo es $\nabla f(\bar{x}) = (0, 1)^\top$. El producto interno para $d \in \mathcal{H}(\bar{x}) \setminus \{0\}$ es $\langle \nabla f(\bar{x}), d \rangle = d_2$. Al ser $d \neq 0$ y $d_2 \geq |d_1|$, se tiene que $d_2 > 0$. Por tanto, $\langle \nabla f(\bar{x}), d \rangle > 0$ para todo $d \in \mathcal{H}(\bar{x}) \setminus \{0\}$. La condición del Teorema 4.1 se verifica, garantizando que $\bar{x}$ es un mínimo local estricto.

Para caracterizar adecuadamente el cono tangente y establecer $\mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$, se requiere la introducción de condiciones de regularidad.

Definición 4.3 (Condiciones de regularidad). Se dice que el punto $\bar{x} \in D$ es **regular** (o cumple una cualificación de restricciones) si satisface alguna de las siguientes condiciones:

1. **Linealidad:** Las funciones h y g son afines:

$$h(x) = Ax - a, \quad A \in \mathbb{R}^{l \times n}, a \in \mathbb{R}^l; \quad g(x) = Bx - b, \quad B \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m. \quad (4.7)$$

2. **Condición de Mangasarian-Fromovitz (MFCQ):** Los gradientes de igualdad $\{\nabla h_i(\bar{x})\}_{i=1}^l$ son linealmente independientes, y existe una dirección en el espacio nulo de las igualdades que es estrictamente interior para

las restricciones de desigualdad activas:

$$\exists \bar{d} \in \ker J_h(\bar{x}) \quad \text{tal que} \quad \langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0 \quad \forall i \in I(\bar{x}). \quad (4.8)$$

3. Condición de Slater (para problemas convexos): h es afín, g es convexa, y existe un punto que satisface estrictamente las desigualdades:

$$\exists \hat{x} \in \mathbb{R}^n \quad \text{tal que} \quad h(\hat{x}) = 0, \quad g_i(\hat{x}) < 0 \quad \forall i = 1, \dots, m. \quad (4.9)$$

Ejemplo 4.6 (Evaluación de MFCQ). Sea el sistema:

$$D = \left\{ x \in \mathbb{R}^2 \mid g_1(x) = -x_1 \leq 0, \quad g_2(x) = -x_2 \leq 0, \quad g_3(x) = x_1 + x_2 - 1 \leq 0 \right\}.$$

En $\bar{x} = (0, 0)^\top$, los índices activos son $I(\bar{x}) = \{1, 2\}$. Los gradientes activos correspondientes son $\nabla g_1(\bar{x}) = (-1, 0)^\top$ y $\nabla g_2(\bar{x}) = (0, -1)^\top$. El vector $\bar{d} = (1, 1)^\top$ cumple $\langle \nabla g_1, \bar{d} \rangle = -1 < 0$ y $\langle \nabla g_2, \bar{d} \rangle = -1 < 0$, lo que satisface la existencia del vector $\bar{d}$ requerido por la condición MFCQ.

Observación. La condición MFCQ es menos restrictiva que exigir la independencia lineal de todos los gradientes activos (LICQ). Mientras que LICQ garantiza la existencia del vector $\bar{d}$ por resolución de sistemas lineales, MFCQ permite que los gradientes de las desigualdades activas sean linealmente dependientes, lo cual abarca una clase más amplia de problemas.

Proposición 4.2 (Condición dual de MFCQ). El punto $\bar{x} \in D$ cumple la condición MFCQ (4.8) si y solo si el sistema lineal:

$$\sum_{i=1}^l \lambda_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \mu_i \nabla g_i(\bar{x}) = 0, \quad \mu_i \geq 0, \quad i \in I(\bar{x}), \quad (4.10)$$

tiene como única solución $(\lambda, \mu) = (0, 0)$.

Prueba. Supongamos que se cumple MFCQ. Si el sistema (4.10) admitiera una solución con $\mu \in \mathbb{R}_+^{|I(\bar{x})|} \setminus \{0\}$, al realizar el producto escalar de (4.10) con el vector $\bar{d}$ garantizado por (4.8), se obtendría:

$$0 = \sum_{i=1}^l \lambda_i \langle \nabla h_i(\bar{x}), \bar{d} \rangle + \sum_{i \in I(\bar{x})} \mu_i \langle \nabla g_i(\bar{x}), \bar{d} \rangle.$$

Dado que $\langle \nabla h_i(\bar{x}), \bar{d} \rangle = 0$, $\langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0$, y al menos un $\mu_i > 0$, el término derecho es estrictamente negativo, lo que es una contradicción. Si $\mu = 0$, la ecuación requiere que $\sum \lambda_i \nabla h_i = 0$ con $\lambda \neq 0$, lo cual contradice la independencia lineal de $\nabla h_i(\bar{x})$.

Recíprocamente, si la única solución de (4.10) es la nula, el sistema carece de soluciones para $\mu \neq 0$ o $\lambda \neq 0$. Por el Teorema de la Alternativa (Motzkin), esto garantiza la existencia de $\bar{d}$ tal que $\langle \nabla h_i(\bar{x}), \bar{d} \rangle = 0$ y $\langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0$. Además, los gradientes ∇h_i deben ser independientes. Por lo tanto, se satisface MFCQ. ■

Ejemplo 4.7 (Falla de MFCQ). Considérese el sistema:

$$D = \left\{ x \in \mathbb{R}^2 \mid g_1(x) = -x_1^2 + x_2 \leq 0, \quad g_2(x) = -x_2 \leq 0 \right\}.$$

En $\bar{x} = (0, 0)^\top$, los gradientes activos son $\nabla g_1(\bar{x}) = (0, 1)^\top$ y $\nabla g_2(\bar{x}) = (0, -1)^\top$. Resolviendo el sistema dual (4.10) con $\mu \geq 0$:

$$\mu_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \mu_1 = \mu_2.$$

Existen soluciones no nulas (e.g., $\mu_1 = 1, \mu_2 = 1$). Por la Proposición 4.2, el punto no satisface MFCQ. Geométricamente, los gradientes opuestos impiden la existencia de una dirección estrictamente interior.

Teorema 4.2 (Cono tangente para restricciones mixtas). Sea D definido por (4.2). Supongamos que h y g cumplen las condiciones de regularidad de la Definición 4.3. Entonces el cono tangente coincide con el de linealización: $\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$.

Teorema 4.3 (Condición necesaria en forma primal). Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son diferenciables en el punto $\bar{x} \in \mathbb{R}^n$, y que $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es una función diferenciable en una vecindad de este punto, con derivada continua en $\bar{x}$.

Si $\bar{x}$ es un minimizador local del problema (4.1)-(4.2) y si alguna de las condiciones de regularidad de las restricciones del Teorema 4.2 es satisfecha (i.e., linealidad (4.7), Mangasarian-Fromovitz (4.8) o Slater (4.9)), entonces se tiene que:

$$\langle \nabla f(\bar{x}), d \rangle \geq 0 \quad \forall d \in \mathcal{H}(\bar{x}),$$

donde el cono de linealización de las restricciones activas $\mathcal{H}(\bar{x})$ viene dado por (4.3).

Teorema 4.4 (Teorema de Robinson). Sean $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en una vecindad del punto $\bar{x} \in D$,

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\},$$

con derivadas continuas en este punto. Supongamos que $\bar{x}$ satisface la condición de regularidad de Mangasarian-Fromovitz (4.8).

Entonces, existen una vecindad U del punto $\bar{x}$ y un número $M > 0$ tales que

$$\text{dist}(x, D) \leq M \|\Psi(x)\| \quad \forall x \in U, \quad (4.11)$$

donde $\Psi : \mathbb{R}^n \rightarrow \mathbb{R}^l \times \mathbb{R}^m$ está dada por $\Psi(x) = (h(x), \max\{0, g_1(x)\}, \dots, \max\{0, g_m(x)\})$.

4.2. Condiciones de optimalidad de Karush-Kuhn-Tucker

En esta sección deducimos las condiciones analíticas de optimalidad de primer orden para problemas con restricciones mixtas a partir de la caracterización del cono tangente desarrollada en la sección anterior. Como se demostró, la condición necesaria primal (Teorema 4.3) establece que el opuesto del gradiente pertenece al cono dual del cono de linealización: $-\nabla f(\bar{x}) \in \mathcal{H}(\bar{x})^*$. Utilizando la parametrización de este cono dual obtenida en el Lema 4.2, expresaremos esta relación geométrica como un sistema algebraico de multiplicadores de Lagrange, conocido como condiciones de Karush-Kuhn-Tucker (KKT).

Teorema 4.5 (Condiciones de Karush-Kuhn-Tucker). Supongamos que $\bar{x} \in D$ es una solución local del problema (4.1)-(4.2), donde f, h, g son funciones continuamente diferenciables en $\bar{x}$.

Si el punto $\bar{x}$ satisface alguna de las condiciones de regularidad de las restricciones detalladas en la Definición 4.3 (independencia lineal, linealidad afín, Slater o MFCQ), entonces existen multiplicadores $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}^m$ con $\bar{\mu} \geq 0$, tales que:

$$\nabla f(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i=1}^m \bar{\mu}_i \nabla g_i(\bar{x}) = 0, \quad (4.12)$$

$$\bar{\mu}_i g_i(\bar{x}) = 0 \quad \forall i \in \{1, \dots, m\}. \quad (4.13)$$

Prueba. Bajo cualquiera de las condiciones de regularidad supuestas, el Teorema de la Condición Necesaria Primal (Teorema 4.3) establece que la derivada direccional es no negativa sobre todo el cono de linealización, es decir, $\langle \nabla f(\bar{x}), d \rangle \geq 0 \quad \forall d \in \mathcal{H}(\bar{x})$. En términos de conos duales, esto equivale a la afirmación geométrica:

$$-\nabla f(\bar{x}) \in \mathcal{H}(\bar{x})^*.$$

Por el Lema 4.2, conocemos la parametrización de los elementos de $\mathcal{H}(\bar{x})^*$. Por lo tanto, se garantiza la existencia de multiplicadores $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu}_i \geq 0$ para $i \in I(\bar{x})$ tales que:

$$-\nabla f(\bar{x}) = \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i \nabla g_i(\bar{x}).$$

Definimos el vector $\bar{\mu} \in \mathbb{R}^m$ haciendo $\bar{\mu}_i = \bar{\mu}_i$ si $i \in I(\bar{x})$, y $\bar{\mu}_i = 0$ si $i \notin I(\bar{x})$. Al agrupar los términos se obtiene la condición de estacionariedad (4.12).

Por otra parte, si la restricción i es activa ($i \in I(\bar{x})$), se tiene $g_i(\bar{x}) = 0$, lo que anula el producto $\bar{\mu}_i g_i(\bar{x})$. Si es inactiva ($i \notin I(\bar{x})$), por construcción se tiene $\bar{\mu}_i = 0$, lo que también anula el producto. Esto demuestra la condición de complementariedad (4.13). ■

Nota: La condición de holgura complementaria

La condición $\bar{\mu}_i g_i(\bar{x}) = 0$ establece que para cada restricción de desigualdad se debe cumplir al menos una de las dos condiciones siguientes:

- Si la restricción no es activa ($g_i(\bar{x}) < 0$), el multiplicador asociado es nulo ($\bar{\mu}_i = 0$).
- Si el multiplicador es estrictamente positivo ($\bar{\mu}_i > 0$), la restricción debe satisfacerse con igualdad ($g_i(\bar{x}) = 0$).

Esta relación introduce un componente combinatorio en el cálculo de los puntos estacionarios, al requerir el análisis de los distintos casos de restricciones activas e inactivas.

Definición 4.4 (Complementariedad Estricta). Sea $\bar{x}$ un punto estacionario KKT con multiplicadores $(\bar{\lambda}, \bar{\mu})$. Se dice que se satisface la **condición de complementariedad estricta** si:

$$\bar{\mu}_i - g_i(\bar{x}) > 0 \quad \forall i = 1, \dots, m.$$

Esta condición excluye el caso degenerado en el que coinciden $g_i(\bar{x}) = 0$ y $\bar{\mu}_i = 0$. Esto equivale a exigir que toda restricción activa en el punto tenga un multiplicador estrictamente positivo.

Ejemplo 4.8 (Análisis por casos del sistema KKT). Considérese el problema de minimizar la suma de las coordenadas sobre el hemisferio superior de la circunferencia unitaria:

$$\min f(x) = x_1 + x_2 \quad \text{sujeto a} \quad \begin{aligned} h(x) &= x_1^2 + x_2^2 - 1 = 0 \\ g(x) &= -x_2 \leq 0 \end{aligned}$$

El conjunto factible D es el arco semicircular definido por $x_2 \geq 0$. El gradiente de la igualdad es $\nabla h(x) = (2x_1, 2x_2)^\top \neq 0$ en todo punto factible, lo que garantiza la condición LICQ.

Cualquier mínimo local debe cumplir el sistema KKT. Con $\nabla f = (1, 1)^\top$ y $\nabla g = (0, -1)^\top$, el sistema se formula como:

$$\begin{cases} 1. \ 1 + 2\lambda x_1 = 0 \\ 2. \ 1 + 2\lambda x_2 - \mu = 0 \\ 3. \ \mu(-x_2) = 0 \\ 4. \ x_1^2 + x_2^2 = 1, \quad x_2 \geq 0, \quad \mu \geq 0 \end{cases}$$

Analizamos las soluciones mediante los dos casos que define la condición de complementariedad:

Caso 1: Restricción inactiva ($\mu = 0$). Suponiendo $x_2 > 0$, la condición de complementariedad exige $\mu = 0$. Las ecuaciones de estacionariedad se reducen a:

$$1 + 2\lambda x_1 = 0 \implies x_1 = -\frac{1}{2\lambda}, \quad 1 + 2\lambda x_2 = 0 \implies x_2 = -\frac{1}{2\lambda}.$$

Sustituyendo en la ecuación de la circunferencia: $\frac{2}{4\lambda^2} = 1 \implies \lambda = \pm \frac{1}{\sqrt{2}}$. Dado que asumimos $x_2 > 0$, la única raíz compatible es $\lambda = -1/\sqrt{2}$. Obtenemos el primer punto KKT: $\bar{x}^{(1)} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)^\top$, con $\lambda = -\frac{1}{\sqrt{2}}$, $\mu = 0$.

Caso 2: Restricción activa ($\mu > 0$). Esto implica que la restricción se cumple con igualdad, es decir, $x_2 = 0$. Por la ecuación de la circunferencia, se tiene $x_1^2 = 1 \implies x_1 = \pm 1$. Evaluamos ambos casos:

- Si $x_1 = 1, x_2 = 0$: $1 + 2\lambda = 0 \implies \lambda = -1/2$. Sustituyendo se obtiene $1 - \mu = 0 \implies \mu = 1 \geq 0$. Obtenemos: $\bar{x}^{(2)} = (1, 0)^\top$, con $\lambda = -\frac{1}{2}$, $\mu = 1$.
- Si $x_1 = -1, x_2 = 0$: $1 - 2\lambda = 0 \implies \lambda = 1/2$. Sustituyendo resulta $1 - \mu = 0 \implies \mu = 1 \geq 0$. Obtenemos: $\bar{x}^{(3)} = (-1, 0)^\top$, con $\lambda = \frac{1}{2}$, $\mu = 1$.

Evaluando la función objetivo $f(x) = x_1 + x_2$ en los tres puntos obtenidos: $f(\bar{x}^{(1)}) = \sqrt{2} \approx 1.41$, $f(\bar{x}^{(2)}) = 1$, y $f(\bar{x}^{(3)}) = -1$. Por el Teorema de Weierstrass, se concluye que el punto $\bar{x}^{(3)} = (-1, 0)^\top$ es el minimizador global del problema.

Definición 4.5 (Sistema KKT y Lagrangiana). La **función Lagrangiana** $L : \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R}$ para el problema con restricciones mixtas se define como:

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle.$$

El sistema de ecuaciones e inecuaciones:

$$\nabla_x L(x, \lambda, \mu) = 0, \quad h(x) = 0, \quad g(x) \leq 0, \quad \mu \geq 0, \quad \mu_i g_i(x) = 0 \quad \forall i = 1, \dots, m,$$

se denomina **Sistema de Karush-Kuhn-Tucker (KKT)**. El conjunto de todos los multiplicadores asociados a un punto estacionario $\bar{x} \in D$ se denota por:

$$\mathcal{M}(\bar{x}) = \left\{ (\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}^m \mid \begin{array}{l} \nabla_x L(\bar{x}, \lambda, \mu) = 0, \\ \mu \geq 0, \mu_i g_i(\bar{x}) = 0 \quad \forall i \end{array} \right\}.$$

Bajo condiciones de convexidad, las condiciones necesarias de primer orden pasan a ser también suficientes para garantizar la optimalidad global.

Teorema 4.6 (Suficiencia de KKT bajo Convexidad). Sea $\bar{x} \in \mathbb{R}^n$ un punto estacionario del problema (4.1)-(4.2) (es decir, $\mathcal{M}(\bar{x}) \neq \emptyset$).

Si las funciones f y g_i son funciones convexas en $\mathbb{R}^n$, y la función de igualdad h es afín, entonces $\bar{x}$ es un minimizador global del problema.

Prueba. Sea $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$ el vector de multiplicadores asociado. Dado que $\bar{\mu}_i \geq 0$ y las funciones g_i son convexas, la combinación cónica $\sum \bar{\mu}_i g_i(x)$ es convexa. Como h es afín, el término $\sum \bar{\lambda}_i h_i(x)$ también lo es. Por tanto, la función $x \mapsto L(x, \bar{\lambda}, \bar{\mu})$ es convexa en $\mathbb{R}^n$.

Al ser $\bar{x}$ un punto estacionario, se cumple $\nabla_x L(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$. Utilizando la propiedad de primer orden para funciones convexas diferenciables, se tiene:

$$L(x, \bar{\lambda}, \bar{\mu}) \geq L(\bar{x}, \bar{\lambda}, \bar{\mu}) \quad \forall x \in \mathbb{R}^n.$$

Para cualquier punto factible $x \in D$, evaluando las restricciones se cumple $h(x) = 0$ y $g(x) \leq 0$. Puesto que $\bar{\mu} \geq 0$, se verifica:

$$f(x) \geq f(x) + \sum_{i=1}^l \bar{\lambda}_i h_i(x) + \sum_{i=1}^m \bar{\mu}_i g_i(x) = L(x, \bar{\lambda}, \bar{\mu}).$$

Usando la minimalidad de la Lagrangiana en $\bar{x}$ y la condición de complementariedad $\bar{\mu}_i g_i(\bar{x}) = 0$:

$$L(x, \bar{\lambda}, \bar{\mu}) \geq L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x}).$$

Por transitividad, se concluye que $f(x) \geq f(\bar{x})$ para todo punto factible $x \in D$, lo que demuestra que $\bar{x}$ es un minimizador global. ■

Nota: Dualidad y condiciones de punto de silla

La demostración del Teorema 4.6 utiliza la propiedad de punto de silla de la función Lagrangiana:

$$L(\bar{x}, \lambda, \mu) \leq L(\bar{x}, \bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu}) \quad \forall x \in \mathbb{R}^n, \forall \lambda \in \mathbb{R}^l, \forall \mu \in \mathbb{R}_+^m.$$

Esta relación de min-max es fundamental en la teoría de dualidad y en el diseño de algoritmos primal-duales.

Ejemplo 4.9 (Falta de convexidad en las restricciones). Considérese el problema:

$$\min f(x) = x_2 \quad \text{sujeto a} \quad g(x) = -x_1^2 - x_2^2 \leq 0.$$

El conjunto factible es $\mathbb{R}^2$, el cual es convexo. Sin embargo, la función objetivo no está acotada inferiormente en $\mathbb{R}^2$, por lo que no existe un mínimo global.

El origen $\bar{x} = (0, 0)^\top$ es un punto estacionario, puesto que $\nabla g(\bar{x}) = (0, 0)^\top$, y el sistema de primer orden no admite solución con multiplicador estrictamente positivo para la restricción modificada $g(x) = -x_1^2 + x_2 \leq 0$.

No es posible aplicar el Teorema 4.6 en este caso debido a que la función $g(x) = -x_1^2 + x_2$ no es convexa en $\mathbb{R}^2$ (su Hessiano es indefinido). El teorema exige la convexidad de las funciones que definen las restricciones, no únicamente la del conjunto factible resultante.

Ejemplo 4.10 (Resolución de un problema convexo). Minimicemos la función $f(x) = x_1^2 + 3x_2^2$ sujeta a:

$$g_1(x) = 1 - x_1 - 2x_2 \leq 0, \quad g_2(x) = 1 - 2x_1 - x_2 \leq 0.$$

La función objetivo es estrictamente convexa y las restricciones son afines, lo que asegura que se satisfacen las condiciones de regularidad. El sistema KKT está dado por:

$$\begin{cases} 1. 2x_1 - \mu_1 - 2\mu_2 = 0 \\ 2. 6x_2 - 2\mu_1 - \mu_2 = 0 \\ 3. \mu_1(1 - x_1 - 2x_2) = 0 \\ 4. \mu_2(1 - 2x_1 - x_2) = 0 \\ 5. \mu_1 \geq 0, \mu_2 \geq 0 \\ 6. g_1(x) \leq 0, g_2(x) \leq 0 \end{cases}$$

Analizamos los posibles casos según la complementariedad:

- **Caso 1** ($\mu_1 = 0, \mu_2 = 0$): De las ecuaciones de estacionariedad se obtiene $x_1 = 0, x_2 = 0$. Evaluando las restricciones: $g_1(0, 0) = 1 > 0$, lo que es infactible.
- **Caso 2** ($\mu_1 = 0, \mu_2 > 0$): La complementariedad exige $2x_1 + x_2 = 1$. Con $\mu_1 = 0$, se tiene $2x_1 = 2\mu_2$ y $6x_2 = \mu_2$, de donde $x_1 = 6x_2$. Sustituyendo en la restricción activa se obtiene $x_2 = 1/13$ y $x_1 = 6/13$. Evaluando la restricción inactiva: $g_1(6/13, 1/13) = 5/13 > 0$, lo que es infactible.
- **Caso 3** ($\mu_1 > 0, \mu_2 = 0$): Se requiere $x_1 + 2x_2 = 1$. Las ecuaciones de estacionariedad implican $2x_1 = \mu_1$ y $6x_2 = 2\mu_1$, lo que da $x_1 = 1.5x_2$. Sustituyendo en la restricción se obtiene $x_2 = 2/7$ y $x_1 = 3/7$. Evaluando las condiciones restantes: $g_2(3/7, 2/7) = -1/7 \leq 0$ y el multiplicador es $\mu_1 = 6/7 \geq 0$.

Se verifican todas las condiciones. El punto estacionario único es $\bar{x} = (3/7, 2/7)^T$ con multiplicadores $\bar{\mu} = (6/7, 0)^T$, el cual corresponde al minimizador global.

Las propiedades algebraicas del conjunto de multiplicadores $\mathcal{M}(\bar{x})$ dependen del cumplimiento de las condiciones de regularidad en el punto estacionario.

Definición 4.6 (Condición Estricta de Mangasarian-Fromovitz - SMFCQ). Sea $\bar{x} \in D$ un punto estacionario y sea $\bar{\mu}$ un vector de multiplicadores en $\mathcal{M}(\bar{x})$. Definimos los conjuntos de índices activos según el signo del multiplicador:

$$I_+(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i > 0\}, \quad I_0(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i = 0\}.$$

El punto cumple **SMFCQ** si los gradientes $\{\nabla h_i(\bar{x})\}_{i=1}^l \cup \{\nabla g_i(\bar{x})\}_{i \in I_+(\bar{x})}$ son linealmente independientes y existe un vector $\bar{d} \in \mathbb{R}^n$ tal que $\langle \nabla h_i(\bar{x}), \bar{d} \rangle = 0$, $\langle \nabla g_i(\bar{x}), \bar{d} \rangle = 0$ para $i \in I_+(\bar{x})$, y $\langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0$ para $i \in I_0(\bar{x})$.

Proposición 4.3 (Propiedades del Conjunto de Multiplicadores). Sea $\bar{x} \in \mathbb{R}^n$ un punto estacionario del problema ($\mathcal{M}(\bar{x}) \neq \emptyset$).

1. El conjunto $\mathcal{M}(\bar{x})$ es compacto si y solo si se cumple la condición MFCQ.
2. El conjunto $\mathcal{M}(\bar{x})$ consta de un único punto si y solo si se cumple la condición SMFCQ.

Prueba. Demostramos (a). La propiedad de ser cerrado se deduce directamente de que $\mathcal{M}(\bar{x})$ está definido mediante igualdades e inequaciones continuas. Supongamos, por reducción al absurdo, que el conjunto no está acotado, por lo que existe una sucesión $\{(\lambda^k, \mu^k)\} \subset \mathcal{M}(\bar{x})$ tal que $\|(\lambda^k, \mu^k)\| \rightarrow \infty$.

Dividiendo las ecuaciones del sistema KKT correspondientes a cada k por el escalar $\|(\lambda^k, \mu^k)\| > 0$, se obtiene una sucesión en la esfera unitaria. Por el Teorema de Bolzano-Weierstrass, existe una subsucesión convergente hacia un vector límite $(\tilde{\lambda}, \tilde{\mu}) \in (\mathbb{R}^l \times \mathbb{R}_+^m)$ con $\|(\tilde{\lambda}, \tilde{\mu})\| = 1$. Pasando al límite en la ecuación normalizada, se obtiene:

$$0 = \sum_{i=1}^l \tilde{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \tilde{\mu}_i \nabla g_i(\bar{x}), \quad \text{con } \tilde{\mu}_i \geq 0.$$

Por la caracterización dual de Mangasarian-Fromovitz (Proposición 4.2), si se cumple MFCQ este sistema homogéneo admite únicamente la solución trivial $(\tilde{\lambda}, \tilde{\mu}) = 0$. Esto contradice que el vector límite tiene norma unitaria, concluyendo que el conjunto de multiplicadores es compacto. ■

Ejemplo 4.11 (Geometría del conjunto de multiplicadores). Considérese el problema en $\mathbb{R}^2$ con dos restricciones de desigualdad:

$$\begin{aligned} &\text{minimizar} && f(x) = x_1 \\ &\text{subject to} && g_1(x) = -x_1 + x_2 \leq 0, \\ &&& g_2(x) = -x_1 - x_2 \leq 0 \end{aligned}$$

El mínimo global se alcanza en $\bar{x} = (0, 0)^T$, donde ambas restricciones son activas. Los gradientes son $\nabla g_1 = (-1, 1)^T$ y $\nabla g_2 = (-1, -1)^T$. Dado que son linealmente independientes, se verifican MFCQ y SMFCQ.

Planteando el sistema KKT: $(1, 0)^T + \mu_1(-1, 1)^T + \mu_2(-1, -1)^T = 0$, cuya única solución es $\bar{\mu} = (1/2, 1/2)^T$. En este caso, el conjunto de multiplicadores es un único punto.

1. Incumplimiento de SMFCQ con MFCQ (Compatibilidad):

Añadiendo la restricción redundante $g_3(x) = -x_1 \leq 0$, en el origen se tiene $\nabla g_3 = (-1, 0)^T$. El conjunto de gradientes ya no es linealmente independiente, pero el vector $\bar{d} = (1, 0)^T$ sigue cumpliendo $\langle \nabla g_i, \bar{d} \rangle < 0$ para todo i , por lo que se mantiene MFCQ.

El sistema KKT resulta en:

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} -1 \\ -1 \end{pmatrix} + \mu_3 \begin{pmatrix} -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

De la segunda coordenada se deduce $\mu_1 = \mu_2$. Sustituyendo en la primera se obtiene $\mu_3 = 1 - 2\mu_1$. Dado que los multiplicadores deben ser no negativos, se requiere $0 \leq \mu_1 \leq 1/2$. El conjunto de multiplicadores es:

$$\mathcal{M}(\bar{x}) = \left\{ \begin{pmatrix} \mu_1 \\ \mu_1 \\ 1 - 2\mu_1 \end{pmatrix} \mid \mu_1 \in \left[0, \frac{1}{2}\right] \right\}.$$

Al no cumplirse SMFCQ no se cumple la unicidad, pero bajo MFCQ el conjunto $\mathcal{M}(\bar{x})$ es un segmento de recta compacto en $\mathbb{R}^3$.

2. Falta de acotamiento por incumplimiento de MFCQ:

Sustituyendo la tercera restricción por $g_4(x) = x_1 \leq 0$, se tiene $\nabla g_4 = (1, 0)^T$. En este caso, cualquier dirección factible con $d_1 > 0$ contradice la restricción g_4 , por lo que no se satisface MFCQ. El sistema KKT es:

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} -1 \\ -1 \end{pmatrix} + \mu_4 \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Esto implica $\mu_1 = \mu_2$ y $\mu_4 = 2\mu_1 - 1$. Como se requiere $\mu_4 \geq 0$, se tiene $\mu_1 \geq 1/2$. El conjunto de multiplicadores es:

$$\mathcal{M}(\bar{x}) = \left\{ \begin{pmatrix} \mu_1 \\ \mu_1 \\ 2\mu_1 - 1 \end{pmatrix} \mid \mu_1 \in \left[\frac{1}{2}, +\infty\right) \right\}.$$

Al no cumplirse MFCQ, el conjunto de multiplicadores es un rayo no acotado.

Si en un mínimo local no se cumple ninguna condición de regularidad, el sistema KKT clásico puede no tener solución. Para tratar estos casos se introducen las condiciones de Fritz John.

Teorema 4.7 (Condiciones de Fritz John). Sea $\bar{x} \in D$ un minimizador local de (4.1)-(4.2). Independientemente de las condiciones de regularidad, existe un vector no nulo $(\lambda_0, \bar{\lambda}, \bar{\mu}) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m$ tal que:

$$\begin{aligned} \lambda_0 \nabla f(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i=1}^m \bar{\mu}_i \nabla g_i(\bar{x}) &= 0, \\ \bar{\mu}_i g_i(\bar{x}) &= 0 \quad \forall i = 1, \dots, m, \\ \lambda_0 \geq 0, \quad \bar{\mu} \geq 0, \quad (\lambda_0, \bar{\lambda}, \bar{\mu}) &\neq 0. \end{aligned} \tag{4.14}$$

Prueba. Consideramos dos casos.

Caso 1: Si se cumple la condición de regularidad MFCQ, por el Teorema 4.5 se garantiza la existencia de multiplicadores KKT $(\bar{\lambda}, \bar{\mu})$. En este caso basta definir $\lambda_0 = 1$ para obtener la solución $(1, \bar{\lambda}, \bar{\mu}) \neq 0$.

Caso 2: Si no se cumple MFCQ, por la Proposición 4.2 existe una solución no nula del sistema dual homogéneo:

$$\sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i \nabla g_i(\bar{x}) = 0, \quad \text{con } \bar{\mu}_i \geq 0 \text{ y } (\bar{\lambda}, \bar{\mu}) \neq 0.$$

Definiendo el escalar $\lambda_0 = 0$ y completando $\bar{\mu}_i = 0$ para $i \notin I(\bar{x})$, se obtiene el vector no nulo $(\lambda_0, \bar{\lambda}, \bar{\mu})$ que satisface el sistema de Fritz John. ■

Ejemplo 4.12 (Puntos estacionarios con $\lambda_0 = 0$). Considérese el problema:

$$\begin{aligned} &\text{minimizar} && f(x) = -x_1 \\ &\text{subject to} && g_1(x) = -x_1^1 + x_2 \leq 0, \\ &&& g_2(x) = -x_1 - x_2 \leq 0 \end{aligned}$$

El único punto factible es el origen $\bar{x} = (0, 0)^\top$, que corresponde al mínimo global. Los gradientes activos en este punto son $\nabla g_1(\bar{x}) = (0, 1)^\top$ y $\nabla g_2(\bar{x}) = (0, -1)^\top$. Como se tiene $\nabla g_1 + \nabla g_2 = 0$, los gradientes son linealmente dependientes y no se cumple la condición MFCQ.

Intentando plantear el sistema KKT tradicional ($\lambda_0 = 1$):

$$\nabla f(\bar{x}) + \mu_1 \nabla g_1(\bar{x}) + \mu_2 \nabla g_2(\bar{x}) = \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

La primera ecuación requiere $-1 = 0$, lo que es una contradicción. Por lo tanto, no existen multiplicadores de KKT.

Sin embargo, planteando el sistema de Fritz John con $\lambda_0 = 0$:

$$0 \cdot \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ \mu_1 - \mu_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Cualquier elección con $\mu_1 = \mu_2 > 0$ proporciona una solución válida. El hecho de que $\lambda_0 = 0$ indica que el punto es geoméricamente singular, y el gradiente de la función objetivo no interviene en la estacionariedad.

Atención: Dificultades numéricas en presencia de multiplicadores singulares

Aunque el Teorema de Fritz John garantiza la existencia de multiplicadores en presencia de puntos singulares, este resultado suele ser indeseable desde el punto de vista algorítmico.

Si un método numérico converge a un punto donde $\lambda_0 = 0$, el algoritmo ignora la función objetivo $f(x)$ y realiza iteraciones destinadas únicamente a satisfacer la factibilidad de las restricciones. Por ello, en optimización no lineal es de gran importancia asegurar que se cumplan condiciones de regularidad como MFCQ para garantizar que $\lambda_0 = 1$ y mantener la convergencia hacia el óptimo de la función objetivo.

4.3. Condiciones de optimalidad de segundo orden

En esta sección se presentan las condiciones analíticas necesarias y suficientes de segundo orden para el problema de optimización con restricciones mixtas. Estas condiciones se evalúan sobre un subconjunto de direcciones factibles, denominado *cono crítico*, en el cual la información de primer orden no permite determinar la optimalidad debido a la anulación de las derivadas direccionales.

Definición 4.7 (Cono Crítico). Sea $\bar{x} \in D$ un punto estacionario del problema (4.1)-(4.2). Se define el **cono crítico** (o cono de direcciones críticas) asociado a $\bar{x}$, denotado por $K(\bar{x})$, como el conjunto de direcciones del cono de linealización $\mathcal{H}(\bar{x})$ que satisfacen la condición:

$$K(\bar{x}) = \{d \in \mathcal{H}(\bar{x}) \mid \langle \nabla f(\bar{x}), d \rangle \leq 0\}. \quad (4.15)$$

Utilizando la definición del cono de linealización, este conjunto equivale al sistema poliédrico:

$$K(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{cases} \langle \nabla f(\bar{x}), d \rangle \leq 0, \\ \langle \nabla g_i(\bar{x}), d \rangle \leq 0 & \forall i \in I(\bar{x}), \\ \langle \nabla h_i(\bar{x}), d \rangle = 0 & \forall i = 1, \dots, l \end{cases} \right\}.$$

Observación. Por la linealidad de las ecuaciones e inecuaciones que lo definen, $K(\bar{x})$ es un cono poliédrico cerrado. En adelante, supondremos que las funciones f, h y g son dos veces diferenciables en el punto $\bar{x}$.

El siguiente lema proporciona caracterizaciones algebraicas alternativas del cono crítico cuando se dispone de un vector de multiplicadores de Lagrange.

Lema 4.3 (Caracterización alternativa del cono crítico). Supongamos que $\bar{x}$ es un punto estacionario de Karush-Kuhn-Tucker y sea $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$ un vector de multiplicadores asociado.

El cono crítico $K(\bar{x})$ admite las siguientes representaciones equivalentes:

$$K(\bar{x}) = \{d \in \mathcal{H}(\bar{x}) \mid \langle \nabla f(\bar{x}), d \rangle = 0\} = \{d \in \mathcal{H}(\bar{x}) \mid \bar{\mu}_i \langle \nabla g_i(\bar{x}), d \rangle = 0 \quad \forall i \in I(\bar{x})\}. \quad (4.16)$$

Prueba. Sea $d \in \mathcal{H}(\bar{x})$. Multiplicando la condición de estacionariedad de KKT por el vector d , se obtiene:

$$\langle \nabla f(\bar{x}), d \rangle = - \left\langle \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i \nabla g_i(\bar{x}), d \right\rangle.$$

Dado que $\langle \nabla h_i(\bar{x}), d \rangle = 0$ para todo $d \in \mathcal{H}(\bar{x})$, el primer término es nulo:

$$\langle \nabla f(\bar{x}), d \rangle = - \sum_{i \in I(\bar{x})} \bar{\mu}_i \langle \nabla g_i(\bar{x}), d \rangle.$$

Puesto que $\bar{\mu}_i \geq 0$ por viabilidad dual y $\langle \nabla g_i(\bar{x}), d \rangle \leq 0$ para $d \in \mathcal{H}(\bar{x})$, la suma del miembro derecho es no positiva. Al antecederle el signo negativo, se deduce que $\langle \nabla f(\bar{x}), d \rangle \geq 0$. Por la definición de $K(\bar{x})$ se requiere $\langle \nabla f(\bar{x}), d \rangle \leq 0$, por lo que la única forma de satisfacer ambas condiciones es que $\langle \nabla f(\bar{x}), d \rangle = 0$. Asimismo, para que una suma de términos no negativos sea nula, cada término individual debe ser cero: $\bar{\mu}_i \langle \nabla g_i(\bar{x}), d \rangle = 0$ para todo $i \in I(\bar{x})$, lo que demuestra la caracterización (4.16). ■

Ejemplo 4.13 (Cálculo del cono crítico). Considérese el problema de minimizar una función lineal sobre el primer cuadrante:

$$\begin{aligned} &\text{minimizar} && f(x) = x_1 + x_2 \\ &\text{subject to} && g_1(x) = -x_1 \leq 0, \\ &&& g_2(x) = -x_2 \leq 0 \end{aligned}$$

El mínimo global se alcanza en el origen $\bar{x} = (0, 0)^T$, donde ambas restricciones son activas ($I(\bar{x}) = \{1, 2\}$). Los gradientes de las restricciones son $\nabla g_1 = (-1, 0)^T$ y $\nabla g_2 = (0, -1)^T$. El gradiente de la función objetivo es $\nabla f = (1, 1)^T$.

Primero, el cono de linealización $\mathcal{H}(\bar{x})$ se define por las condiciones:

$$\langle (-1, 0)^T, d \rangle = -d_1 \leq 0 \implies d_1 \geq 0, \quad \text{y} \quad -d_2 \leq 0 \implies d_2 \geq 0.$$

Es decir, $\mathcal{H}(\bar{x}) = \mathbb{R}_+^2$. Cualquier dirección con componentes no negativas es una dirección de linealización.

Para construir el cono crítico $K(\bar{x})$ añadimos la condición de no descenso de la función objetivo $\langle \nabla f(\bar{x}), d \rangle \leq 0$:

$$\langle (1, 1)^T, d \rangle = d_1 + d_2 \leq 0.$$

Dado que $d \in \mathbb{R}_+^2$, la única solución es que ambas componentes sean nulas. Por lo tanto, el cono crítico se reduce al origen: $K(\bar{x}) = \{(0, 0)^T\}$.

Para verificar la caracterización alternativa del Lema 4.3, resolvemos el sistema de primer orden $\nabla f + \mu_1 \nabla g_1 + \mu_2 \nabla g_2 = 0$:

$$\begin{pmatrix} 1 \\ 1 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \mu_1 = 1, \quad \mu_2 = 1.$$

Al ser ambos multiplicadores estrictamente positivos, las restricciones activas impiden el descenso de la función objetivo en cualquier dirección factible no nula. Dado que el cono crítico se reduce a $\{0\}$, las condiciones de segundo orden se satisfacen de forma vacía.

Corolario 4.1 (Cono crítico bajo complementariedad estricta). Supongamos que el punto estacionario $\bar{x}$ con multiplicador $(\bar{\lambda}, \bar{\mu})$ satisface la condición de complementariedad estricta (Definición 4.4).

Al ser $\bar{\mu}_i > 0$ para todo $i \in I(\bar{x})$, la caracterización del Lema 4.3 implica que $\langle \nabla g_i(\bar{x}), d \rangle = 0$. Bajo esta hipótesis, las restricciones de desigualdad activas se comportan localmente como restricciones de igualdad, por lo que el cono crítico es un subespacio vectorial:

$$K(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{cases} \langle \nabla h_i(\bar{x}), d \rangle = 0 & \forall i = 1, \dots, l \\ \langle \nabla g_i(\bar{x}), d \rangle = 0 & \forall i \in I(\bar{x}) \end{cases} \right\}.$$

Consideramos en primer lugar el caso donde los gradientes de las restricciones activas son linealmente independientes (LICQ) o las restricciones son afines, lo que garantiza la unicidad del vector de multiplicadores.

Teorema 4.8 (Condición necesaria de segundo orden bajo LICQ o linealidad). Supongamos que $\bar{x} \in D$ es un minimizador local del problema y que f, h, g son dos veces diferenciables en $\bar{x}$.

Si el punto satisface la condición de independencia lineal (LICQ) de las restricciones activas, o si todas las restricciones son afines, entonces, para el multiplicador de Lagrange $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$ (el cual es único bajo LICQ), la Hessiana de la función Lagrangiana es semidefinida positiva sobre el cono crítico:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}, \bar{\mu}) d, d \rangle \geq 0 \quad \forall d \in K(\bar{x}). \quad (4.17)$$

Prueba. Fijemos $d \in K(\bar{x})$. Bajo LICQ o linealidad, el cono de Bouligand coincide con el cono de linealización (Teorema 4.2), por lo que $d \in \mathcal{B}_D(\bar{x})$. Esto implica la existencia de una trayectoria factible $x(t) = \bar{x} + td + r(t) \in D$ para $t > 0$ suficientemente pequeño, donde $\|r(t)\| = o(t)$.

Al ser $\bar{x}$ un minimizador local, se tiene $f(x(t)) - f(\bar{x}) \geq 0$. Para el multiplicador $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$, se cumple $\bar{\mu}_i g_i(\bar{x}) = 0$. Dado que $x(t) \in D$, se verifica $h_i(x(t)) = 0$ y $g_i(x(t)) \leq 0$. Por lo tanto:

$$\begin{aligned} 0 &\leq f(x(t)) - f(\bar{x}) \\ &\leq f(x(t)) - f(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i h_i(x(t)) + \sum_{i=1}^m \bar{\mu}_i g_i(x(t)) \\ &= L(x(t), \bar{\lambda}, \bar{\mu}) - L(\bar{x}, \bar{\lambda}, \bar{\mu}). \end{aligned}$$

Utilizando el desarrollo de Taylor de la función Lagrangiana en torno a $\bar{x}$:

$$0 \leq \langle \nabla_x L(\bar{x}, \bar{\lambda}, \bar{\mu}), td + r(t) \rangle + \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}, \bar{\mu})(td + r(t)), td + r(t) \rangle + o(t^2).$$

Por la condición de estacionariedad $\nabla_x L(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$, el término de primer orden es nulo. Dividiendo por $t^2 > 0$ y tomando el límite cuando $t \rightarrow 0^+$, los términos dependientes de $r(t)$ se anulan, concluyendo que $\langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}, \bar{\mu}) d, d \rangle \geq 0$. ■

Ejemplo 4.14 (Hessiana de la Lagrangiana en el cono crítico). Considérese el problema de maximizar la altura sobre una región acotada por una parábola, formulado

$$\begin{aligned} &\text{minimizar} && f(x) = -x_2 \\ &\text{subject to} && g(x) = x_1^2 - x_2 \leq 0 \end{aligned}$$

El conjunto factible D es el área superior a la parábola $x_2 = x_1^2$. Evaluamos las condiciones en el origen $\bar{x} = (0, 0)^T$. La restricción es activa ($g(0) = 0$).

El gradiente de la restricción es $\nabla g(x) = (2x_1, -1)^T$, que en el origen resulta en $\nabla g(\bar{x}) = (0, -1)^T \neq 0$, por lo que se cumple LICQ. El sistema de primer orden $\nabla f(\bar{x}) + \mu \nabla g(\bar{x}) = 0$ exige $\mu = -1$. Dado que las condiciones KKT requieren $\mu \geq 0$, el punto no satisface las condiciones de primer orden.

Para ilustrar el análisis de segundo orden, modifiquemos el problema a:

$$\begin{aligned} &\text{minimizar} && f(x) = x_2 \\ &\text{subject to} && g(x) = x_1^2 - x_2 \leq 0. \end{aligned}$$

El sistema KKT es:

$$\begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \bar{\mu} = 1.$$

El multiplicador es admisible ($\bar{\mu} = 1 \geq 0$). Determinamos el cono crítico $K(\bar{x})$ mediante la caracterización alternativa. Al ser $\bar{\mu} = 1 > 0$, se requiere: $\langle \nabla g(\bar{x}), d \rangle = -d_2 = 0 \implies d_2 = 0$. Por lo tanto, el cono crítico es el eje horizontal: $K(\bar{x}) = \{(d_1, 0)^T \mid d_1 \in \mathbb{R}\}$.

La Hessiana de la Lagrangiana $L(x, \bar{\mu}) = x_2 + x_1^2 - x_2 = x_1^2$ en $\bar{x}$ está dada por:

$$\nabla_{xx}^2 L(\bar{x}, \bar{\mu}) = \nabla^2 f(\bar{x}) + \bar{\mu} \nabla^2 g(\bar{x}) = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} + (1) \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}.$$

Para cualquier dirección $d \in K(\bar{x})$, evaluamos la forma cuadrática:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\mu}) d, d \rangle = \begin{pmatrix} d_1 & 0 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} d_1 \\ 0 \end{pmatrix} = 2d_1^2 \geq 0.$$

La condición necesaria de segundo orden se verifica. Este ejemplo muestra cómo la curvatura de la restricción, representada en el término de segundo orden de la Lagrangiana por el multiplicador positivo, compensa la falta de curvatura de la función objetivo.

Observación (Multiplicadores no únicos bajo MFCQ). La demostración del Teorema 4.8 no se aplica directamente bajo la condición de Mangasarian-Fromovitz (MFCQ), dado que el conjunto de multiplicadores $\mathcal{M}(\bar{x})$ es un poliedro compacto pero no necesariamente un único punto. En este caso, se requiere un análisis basado en desarrollos de segundo orden y teoremas de separación.

Proposición 4.4 (Aproximación de segundo orden de curvas factibles). Sean h y g funciones dos veces diferenciables en $\bar{x} \in D$. Para que exista una sucesión $\{t_k\} \rightarrow 0^+$ tal que un par de vectores $(d, w) \in \mathbb{R}^n \times \mathbb{R}^n$ cumpla:

$$\text{dist}(\bar{x} + t_k d + t_k^2 w, D) = o(t_k^2), \quad (4.18)$$

es necesario que $d \in \mathcal{B}_D(\bar{x})$ y que el vector de segundo orden w satisfaga el sistema:

$$\langle \nabla h_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 h_i(\bar{x}) d, d \rangle = 0 \quad \forall i \in \{1, \dots, l\}, \quad (4.19)$$

$$\langle \nabla g_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 g_i(\bar{x}) d, d \rangle \leq 0 \quad \forall i \in I(\bar{x}, d), \quad (4.20)$$

donde $I(\bar{x}, d) = \{i \in I(\bar{x}) \mid \langle \nabla g_i(\bar{x}), d \rangle = 0\}$ representa el conjunto de restricciones activas a lo largo de la dirección d .

Prueba. La demostración se omite por brevedad; se basa en la aplicación del desarrollo de Taylor de segundo orden y la condición de factibilidad de la trayectoria $x^k = \bar{x} + t_k d + t_k^2 w + o(t_k^2)$. ■

Nota: Interpretación cinemática

La caracterización de la Proposición 4.4 admite una interpretación física al modelar la trayectoria $x(t)$ como el movimiento de una partícula en el tiempo t :

- El vector $d \in \mathbb{R}^n$ representa la **velocidad** (dirección tangente de primer orden), la cual debe cumplir la condición de no apuntar hacia el exterior del conjunto factible ($\langle \nabla g, d \rangle \leq 0$).
- El vector $w \in \mathbb{R}^n$ representa la **aceleración**. Las condiciones de segundo orden (4.19) y (4.20) determinan la curvatura necesaria de la trayectoria para mantener la factibilidad.

Ejemplo 4.15 (Ejemplo de trayectoria de segundo orden). Analicemos las condiciones de segundo orden para un punto restringido a yacer dentro del disco unitario:

$$D = \left\{ x \in \mathbb{R}^2 \mid g(x) = \frac{1}{2}(x_1^2 + x_2^2 - 1) \leq 0 \right\}.$$

Consideremos el punto $\bar{x} = (0, 1)^\top$, en el cual la restricción es activa ($g(0, 1) = 0$). Evaluando las derivadas en $\bar{x}$:

$$\nabla g(\bar{x}) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \nabla^2 g(\bar{x}) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Buscamos construir una trayectoria $x(t) = \bar{x} + t d + t^2 w + o(t^2)$ factible en D para $t > 0$.

1. Dirección de primer orden (Velocidad d):

Por la definición de $d \in \mathcal{H}(\bar{x})$, el vector velocidad debe cumplir $\langle \nabla g(\bar{x}), d \rangle \leq 0 \implies d_2 \leq 0$. Consideremos la dirección horizontal unitaria $d = (1, 0)^\top$, para la cual se tiene $\langle \nabla g(\bar{x}), d \rangle = 0$ (la restricción es activa a lo largo de d).

2. Dirección de segundo orden (Aceleración w):

Como la restricción es activa a lo largo de d , el índice pertenece a $I(\bar{x}, d)$. La Proposición 4.4 requiere que w satisfaga:

$$\langle \nabla g(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 g(\bar{x}) d, d \rangle \leq 0.$$

Sustituyendo los vectores correspondientes:

$$w_2 + \frac{1}{2}(1) \leq 0 \implies w_2 \leq -\frac{1}{2}.$$

Este resultado muestra que para una velocidad horizontal unitaria, la trayectoria requiere una aceleración con componente vertical negativa de al menos $1/2$ (aceleración centrípeta) para mantener la factibilidad en D .

Nota: Dificultad del análisis bajo MFCQ

Bajo la condición LICQ, el multiplicador de Lagrange es único, por lo que el análisis de la curvatura se realiza con un único operador. Bajo MFCQ, al no haber unicidad, el conjunto de multiplicadores es un poliedro. El

análisis requiere determinar si existe algún multiplicador que satisfaga la condición de semidefinición positiva para cada dirección crítica específica.

Teorema 4.9 (Condición necesaria de segundo orden bajo MFCQ). Sea $\bar{x}$ un minimizador local de (4.1)-(4.2) que satisface la condición de regularidad de **Mangasarian-Fromovitz (MFCQ)**.

Para cada dirección crítica $d \in K(\bar{x})$, existe un vector de multiplicadores de Lagrange $(\lambda, \mu) \in \mathcal{M}(\bar{x})$ tal que:

$$\langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle \geq 0. \quad (4.21)$$

Prueba. Fijemos $d \in K(\bar{x})$. Definimos los conjuntos:

$$S_1(d) = \left\{ (\alpha, y, z) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m \left| \begin{array}{l} \alpha = \langle \nabla f(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 f(\bar{x}) d, d \rangle \\ y_i = \langle \nabla h_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 h_i(\bar{x}) d, d \rangle, \quad i = 1, \dots, l \\ z_i = \langle \nabla g_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 g_i(\bar{x}) d, d \rangle, \quad i = 1, \dots, m \\ w \in \mathbb{R}^n \end{array} \right. \right\}$$

$$S_2(d) = \{ (\alpha, y, z) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m \mid \alpha < 0, y_i = 0 \forall i, z_i \leq 0 \forall i \in I(\bar{x}, d) \}.$$

El conjunto $S_1(d)$ es un espacio afín y $S_2(d)$ es un cono convexo abierto. Si la intersección de ambos fuera no vacía, existiría un vector $w \in \mathbb{R}^n$ tal que satisfaría las condiciones (4.19) y (4.20) con un decremento estricto de segundo orden en la función objetivo, lo que contradice la hipótesis de que $\bar{x}$ es un mínimo local. Por tanto, $S_1(d) \cap S_2(d) = \emptyset$. Por el Teorema de Separación de Conjuntos Convexos, existe un vector no nulo $(\lambda_0, \lambda, \mu) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m \setminus \{0\}$ tal que para todo $p_1 \in S_1(d)$ y $p_2 \in S_2(d)$:

$$\langle (\lambda_0, \lambda, \mu), p_2 \rangle \leq 0 \leq \langle (\lambda_0, \lambda, \mu), p_1 \rangle.$$

Analizando la geometría de los conjuntos, se deduce que $\lambda_0 \geq 0$ y $\mu_i \geq 0$ para $i \in I(\bar{x}, d)$, definiendo $\mu_i = 0$ para los índices restantes. Al ser la dirección w libre en el espacio afín, el término que la multiplica debe ser nulo para garantizar la acotación inferior, lo que da:

$$\lambda_0 \nabla f(\bar{x}) + \sum_{i=1}^l \lambda_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \mu_i \nabla g_i(\bar{x}) = 0.$$

Si $\lambda_0 = 0$, se tendría una combinación lineal nula de los gradientes de las restricciones con coeficientes no negativos, lo cual contradice la condición MFCQ (Proposición 4.2). Por lo tanto, $\lambda_0 > 0$. Dividiendo el sistema por λ_0 y redefiniendo las variables duales, se demuestra que (λ, μ) es un vector de multiplicadores en $\mathcal{M}(\bar{x})$.

Evaluando la desigualdad de separación para el término constante de $S_1(d)$ y normalizando por λ_0 , se obtiene:

$$\langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle \geq 0,$$

lo cual concluye la demostración. ■

Ejemplo 4.16 (Análisis de segundo orden bajo MFCQ). Considérese el problema de optimización en $\mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && f(x) = x_1^2 - x_2^2 \\ &\text{subject to} && g_1(x) = x_2 - x_1 \leq 0, \\ &&& g_2(x) = x_2 + x_1^2 \leq 0 \end{aligned}$$

La función objetivo tiene un punto de silla en el origen. Las restricciones exigen que $x_1^2 \leq x_2 \leq -x_1^2$, lo que restringe el conjunto factible al único punto $D = \{(0, 0)^\top\}$, el cual es el mínimo global.

Evaluamos las restricciones en el origen $\bar{x} = (0, 0)^\top$. Ambas son activas. Los gradientes son $\nabla g_1(\bar{x}) = (0, 1)^\top$ y $\nabla g_2(\bar{x}) = (0, 1)^\top$, por lo que no se satisface LICQ. Sin embargo, el sistema dual $\mu_1(0, 1)^\top + \mu_2(0, 1)^\top = 0$ con $\mu \geq 0$ tiene por solución única $\mu_1 = \mu_2 = 0$, de donde se verifica MFCQ.

Para el sistema de primer orden en $\bar{x}$, al ser $\nabla f(\bar{x}) = 0$, el único multiplicador de KKT es $\bar{\mu} = (0, 0)^\top$. El cono crítico se define por las inecuaciones $\langle \nabla g_i, d \rangle \leq 0$:

$$d_2 \leq 0 \implies K(\bar{x}) = \{(d_1, d_2)^\top \mid d_2 \leq 0\}.$$

El cono crítico corresponde al semiplano inferior. La Hessiana de la Lagrangiana en $\bar{x}$ con $\bar{\mu} = 0$ está dada por:

$$\nabla_{xx}^2 L(\bar{x}, \bar{\mu}) = \nabla^2 f(\bar{x}) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}.$$

Evaluable la forma cuadrática para $d = (d_1, d_2)^\top \in K(\bar{x})$:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\mu}) d, d \rangle = 2d_1^2 - 2d_2^2.$$

En este caso, la condición necesaria del Teorema 4.9 no se cumple para todas las direcciones críticas (por ejemplo, para $d = (0, -1)^\top \in K(\bar{x})$ la forma cuadrática es negativa). Esto ocurre debido a la geometría del conjunto factible, el cual está restringido a un único punto, impidiendo la existencia de curvas factibles no triviales en las direcciones críticas.

Ejemplo 4.17 (No existencia de un multiplicador universal). El siguiente ejemplo muestra por qué en el Teorema 4.9 los multiplicadores pueden depender de la dirección crítica considerada. Sea $n = m = 3$, $l = 0$. Consideremos el problema $\min f(x) = x_3$ sujeto a $g(x) \leq 0$, con:

$$g(x) = \begin{pmatrix} 2\sqrt{3}x_1x_2 - 2x_2^2 - x_3 \\ -2\sqrt{3}x_1x_2 - 2x_1^2 - x_3 \\ -3x_1^2 + x_2^2 - x_3 \end{pmatrix} \leq 0.$$

El origen $\bar{x} = (0, 0, 0)^\top$ es el mínimo global. Los gradientes en $\bar{x}$ son $\nabla f(0) = (0, 0, 1)^\top$ y $\nabla g_i(0) = (0, 0, -1)^\top$ para todo i . Se verifica la condición MFCQ (e.g., con $\bar{d} = (0, 0, 1)^\top$, $\langle \nabla g_i, \bar{d} \rangle = -1 < 0$). El conjunto de multiplicadores es:

$$\mathcal{M}(0) = \{\mu \in \mathbb{R}_+^3 \mid \mu_1 + \mu_2 + \mu_3 = 1\}.$$

El cono crítico es $K(0) = \{d \in \mathbb{R}^3 \mid d_3 = 0\}$. Evaluamos las direcciones críticas $d^1 = (1, 0, 0)^\top$ y $d^2 = (0, 1, 0)^\top$. Para un multiplicador $\mu \in \mathcal{M}(0)$, las formas cuadráticas correspondientes son:

$$\begin{aligned} \langle \nabla_{xx}^2 L(0, \mu) d^1, d^1 \rangle &= -4\mu_2 - 6\mu_3, \\ \langle \nabla_{xx}^2 L(0, \mu) d^2, d^2 \rangle &= -4\mu_1 + 2\mu_3. \end{aligned}$$

Para satisfacer la condición necesaria en d^1 se requiere que $-4\mu_2 - 6\mu_3 \geq 0$, lo que implica $\mu_2 = \mu_3 = 0$, y por tanto, $\mu_1 = 1$. Sin embargo, con este multiplicador, la forma cuadrática en la dirección d^2 resulta negativa.

Por lo tanto, no existe un único multiplicador de Lagrange que satisfaga la condición de semidefinición positiva para todas las direcciones críticas simultáneamente, lo que demuestra que la dependencia del multiplicador respecto a la dirección crítica es una propiedad fundamental bajo MFCQ y no un artefacto de la demostración.

Finalmente, la condición suficiente de segundo orden establece que si para cada dirección crítica no nula existe al menos un multiplicador que aporta curvatura estrictamente positiva, entonces el punto es un minimizador local estricto.

Teorema 4.10 (Condición suficiente de segundo orden). Sea $\bar{x} \in D$ un punto estacionario del problema (4.1)-(4.2) y supongamos que f, h, g son dos veces diferenciables en $\bar{x}$.

Si para toda dirección crítica $d \in K(\bar{x}) \setminus \{0\}$, existe un multiplicador $(\lambda, \mu) \in \mathcal{M}(\bar{x})$ tal que:

$$\langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle > 0, \quad (4.22)$$

entonces f satisface la condición de crecimiento cuadrático en D en torno a $\bar{x}$: existen un entorno U de $\bar{x}$ y un escalar $\beta > 0$ tales que

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\|^2 \quad \forall x \in D \cap U. \quad (4.23)$$

En particular, $\bar{x}$ es un minimizador local estricto.

Prueba. La demostración procede por contradicción. Suponiendo que la condición de crecimiento cuadrático falla, existe una sucesión de puntos factibles $x^k \rightarrow \bar{x}$ tales que $f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|^2$. Definiendo $t_k = \|x^k - \bar{x}\|$ y las direcciones $d^k = (x^k - \bar{x})/t_k$, se extrae una subsucesión convergente $d^k \rightarrow d \in \mathcal{B}_D(\bar{x})$ con $\|d\| = 1$.

Al analizar los desarrollos de Taylor de primer y segundo orden de la Lagrangiana a lo largo de la trayectoria x^k , y utilizando las propiedades del conjunto de multiplicadores $\mathcal{M}(\bar{x})$ y la definición del cono crítico $K(\bar{x})$, se demuestra que $d \in K(\bar{x})$ y que $\langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle \leq 0$ para todo $(\lambda, \mu) \in \mathcal{M}(\bar{x})$. Esto contradice la hipótesis (4.22) de que existe al menos un multiplicador con curvatura estrictamente positiva. ■

Ejercicios del Capítulo

Parte I: Mecánica Primal-Dual y Condición de Mangasarian-Fromovitz

Ejercicio 4.1. Completar los detalles algebraicos (específicamente la implicación recíproca mediante el Teorema de la Alternativa de Motzkin) omitidos en el texto para la demostración de la Proposición 4.2 (Condición dual de Mangasarian-Fromovitz).

Ejercicio 4.2. Mediante una representación geométrica, formular una hipótesis sobre la solución del problema $\min(x_1 - 1)^2 + (x_2 + 1)^2$ sujeto a $x_1 - x_2 \leq 0$ y $(x_1 - 2)^2 + (x_2 - 1)^2 \leq 1$. Confirmar la hipótesis resolviendo el sistema mediante KKT.

Ejercicio 4.3. Encontrar todos los valores del parámetro $\sigma \in \mathbb{R}$ para los cuales el punto $\bar{x} = (\sqrt{3}/2 + 1, 1/2) \in \mathbb{R}^2$ es una solución del problema $\min x_1 + x_2$ sujeto a $(x_1 - 1)^2 + (x_2 - 1)^2 \leq 1$ y $(x_1 - 2)^2 + x_2^2 \leq 1$.

Ejercicio 4.4. Encontrar todos los valores del parámetro $\sigma \in \mathbb{R}$ para los cuales el punto $\bar{x} = (1, 1) \in \mathbb{R}^2$ es una solución local del problema $\min -x_1 + \sigma x_2$ sujeto a $x_1^2 + x_2^2 \leq 2$ y $x_1^2 - x_2 \leq 0$.

Ejercicio 4.5. Encontrar de manera analítica la solución global del problema $\max 2x_1 + 4x_2 - \frac{1}{2}x_3^2$ sujeto a $x_1^2 + x_2^2 - x_3 \leq 4$ y $x_1 - x_2 + x_3^2 \leq 1$.

Ejercicio 4.6. Demostrar que la solución del problema $\min x_2$ sujeto a $(x_1 - 1)^2 + x_2^2 \leq 1$ y $(x_1 + 1)^2 + x_2^2 \leq 1$ no satisface las condiciones de KKT e interpretar el resultado en relación con el comportamiento con restricciones de igualdad analizado en el Capítulo 2.

Ejercicio 4.7. Sea $\bar{x}$ un minimizador local del problema sobre el simplex escalado: $\min f(x)$ sujeto a $x \geq 0$, $\sum_{i=1}^n x_i = t$. Demostrar que, si $I_+(\bar{x}) = \{i \mid \bar{x}_i > 0\}$ denota el soporte estrictamente positivo, entonces $\nabla_{x_i} f(\bar{x}) = \min_j \nabla_{x_j} f(\bar{x})$ para todo $i \in I_+(\bar{x})$.

Ejercicio 4.8. Sean $Q \in \mathbb{R}^{n \times n}$, $q \in \mathbb{R}^n$, $B \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$. Demostrar que el conjunto de puntos de KKT de un problema de programación cuadrática constituye una unión finita de conjuntos poliédricos en el espacio extendido $\mathbb{R}^n \times \mathbb{R}^m$.

Ejercicio 4.9. Demostrar que $\bar{x} \in \mathbb{R}^n$ es un punto KKT de $\min f(x)$ sujeto a $h(x) = 0$ y $g(x) \leq 0$ si, y solamente si, existe $(\bar{\beta}, \bar{\gamma}) \in \mathbb{R}^l \times \mathbb{R}^m$ tal que el siguiente sistema no lineal de ecuaciones se anula:

$$F(x, \beta, \gamma) = \begin{pmatrix} \nabla_x L(x, \beta, \max\{0, \gamma\}) \\ h(x) \\ -g(x) + \min\{0, \gamma\} \end{pmatrix} = 0.$$

Ejercicio 4.10. Sea $\bar{x} \in \mathbb{R}^n$ un punto factible de $\min f(x)$ sujeto a $g(x) \leq 0$. Supongamos que $\bar{x}$ satisface MFCQ pero no es estacionario. Demostrar que existe una dirección de descenso para f que apunta hacia el interior del conjunto factible D .

Ejercicio 4.11. Sean $(\bar{x}, \bar{\mu})$ y $(\hat{x}, \hat{\mu})$ dos pares KKT para un problema convexo. Demostrar que los pares cruzados $(\bar{x}, \hat{\mu})$ y $(\hat{x}, \bar{\mu})$ también satisfacen las condiciones KKT.

Ejercicio 4.12. Supongamos que un problema de minimización convexo satisface Slater. Dada una solución $\bar{x}$, determinar un escalar $M > 0$ tal que $\|\bar{\mu}\| \leq M$ para todo multiplicador de Lagrange.

Ejercicio 4.13. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa dos veces diferenciable y $D = \{x \in \mathbb{R}^n \mid Ax = a, x \geq 0\}$ un conjunto poliédrico acotado y no vacío. Demostrar que el problema modificado $\min \|\nabla f(x) + A^T y - z\|^2 + \|Ax - a\|^2 + \langle x, z \rangle^2$ sujeto a $x \geq 0, z \geq 0$ admite por lo menos un punto KKT que resuelve el problema original.

Parte II: Condiciones de Segundo Orden

Ejercicio 4.14. A partir de las demostraciones, demostrar la afirmación recíproca del Teorema 4.10: si $\bar{x}$ satisface MFCQ y la condición de crecimiento cuadrático, entonces se satisface la condición necesaria de segundo orden.

Ejercicio 4.15. Resolver de forma sistemática los siguientes problemas $\min f(x)$ sujeto a $x \in D$:

1. $f(x) = x_1^2 + x_2^2$, con $D = \{x \in \mathbb{R}^2 \mid 2x_1 + x_2 \geq 2, x_1 + 2x_2 \leq \sigma\}$.

2. $f(x) = \log x_1 - x_2$, con $D = \{x \in \mathbb{R}^2 \mid 2x_1 + x_2 \geq 1, -x_1 + x_2 \leq 1, 2x_1 - x_2 \leq 3\}$.
3. $f(x) = 2x_1^2 + x_2^2 + 2x_3^2 - x_1x_3$, con $D = \{x \in \mathbb{R}^3 \mid x_1 - 3x_2 + 2x_3 \leq 1, 2x_1 + x_2 \leq 10\}$.
4. $f(x) = \sum_{j=1}^n (x_j - a_j)^2$, sujeto a $\sum x_j^2 \leq 1$ y $\sum x_j = 0$.

Ejercicio 4.16. Demostrar analíticamente que $\min(x_1 + 1)^3$ sujeto a $0 \leq x_1 + x_2 \leq x_1^3 + \sigma$ tiene soluciones para todo $\sigma \in \mathbb{R}$ y determinar dichas soluciones.

Ejercicio 4.17. Considere un problema de programación cuadrática sobre la bola euclidiana $\|x\| \leq \delta$. Demostrar que $\bar{x}$ es un minimizador global si y solamente si existe $\bar{\mu} \in \mathbb{R}_+$ tal que $(Q + \bar{\mu}I)\bar{x} = -q$, $\|\bar{x}\| \leq \delta$, $\bar{\mu}(\|\bar{x}\| - \delta) = 0$, y la matriz Hessiana $(Q + \bar{\mu}I)$ es semidefinida positiva.

Ejercicio 4.18. Demostrar la desigualdad clásica de las medias aritmética y geométrica utilizando KKT en $\max \prod x_i$ sujeto a $\sum x_i = 1, x \geq 0$.

Ejercicio 4.19. Verificar que $\bar{x}$ es una solución local del problema modificado $\min f(x)$ sujeto a $h(x) = 0$ y $g_j(x) + \sigma_j^2 = 0$. Plantee las condiciones de KKT e interprete la pérdida de fuerza en el análisis de segundo orden comparado con el directo.

Parte III: Tópicos Avanzados - Dualidad, Conos Convexos y KKT Singular

Ejercicio 4.20. Considérese $\min x_1x_2$ sujeto a $x_1^2 + x_2^2 \leq 2$. Formule el sistema KKT, demuestre que hay 4 puntos estacionarios, proyecte la Hessiana sobre el cono crítico e identifique mínimos y máximos locales.

Ejercicio 4.21. Demuestre rigurosamente, utilizando la separación de conos convexos cerrados, el Lema de Farkas (Lema 4.1) para el sistema dual homogéneo y explique cómo garantiza la existencia de MFCQ.

Ejercicio 4.22. Sea $\min(x_1 - 2)^2 + x_2^2$ sujeto a $-x_1^3 + x_2 \leq 0$ y $-x_1^3 - x_2 \leq 0$. Demuestre que se viola LICQ, que KKT no tiene solución, y plantee el sistema de Fritz John (Teorema 4.7) hallando $(\lambda_0, \mu_1, \mu_2) \neq 0$.

Ejercicio 4.23. Demuestre, utilizando la regla de la cadena multivariable, que si un problema es sometido a una transformación afín biyectiva $x = Ay + b$, los multiplicadores de Lagrange KKT son invariantes.

Ejercicio 4.24. Considere $\min -x_1$ sujeto a $x_1^2 + x_2^2 = 1$ y su relajación convexa $x_1^2 + x_2^2 \leq 1$. Resuelva ambos sistemas KKT y demuestre por qué la relajación descarta al maximizador del problema original.

5. Elementos de la Teoría de Dualidad

La teoría de dualidad consiste en asociar a un problema de optimización original (primal) un problema alternativo (dual) cuyas propiedades aportan información cuantitativa y cualitativa sobre el primero. En el caso convexo, y muy especialmente en programación lineal, la relación entre ambos es simétrica y permite no solo resolver problemas complejos de forma indirecta, sino también fundamentar las técnicas computacionales. Incluso bajo ausencia de convexidad, el esquema dual proporciona cotas inferiores globales de gran utilidad en la resolución numérica de problemas combinatorios.

5.1. Dualidad en programación lineal

Sea el programa lineal en su forma de minimización, al cual nos referiremos como el **problema primal**:

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid Bx \geq b\}, \quad (5.1)$$

donde $B \in \mathbb{R}^{m \times n}$, $c \in \mathbb{R}^n$ y $b \in \mathbb{R}^m$. El **problema dual** asociado es el programa de maximización:

$$\max \langle b, \mu \rangle \quad \text{sujeto a} \quad \mu \in \Delta = \{\mu \in \mathbb{R}^m \mid B^T \mu = c, \mu \geq 0\}. \quad (5.2)$$

Si el problema primal tiene n variables y m restricciones, el dual se define sobre m variables (una por cada restricción primal) y cuenta con n restricciones de igualdad (una por cada variable primal).

Proposición 5.1 (Teorema de Dualidad Débil). Para cualesquiera puntos factibles $x \in D$ y $\mu \in \Delta$, se cumple:

$$\langle c, x \rangle \geq \langle b, \mu \rangle. \quad (5.3)$$

Prueba. Como $Bx \geq b$ y $\mu \geq 0$, es inmediato que $\langle \mu, Bx \rangle \geq \langle \mu, b \rangle$. Usando la definición de operador adjunto y la restricción dual $B^T \mu = c$:

$$\langle c, x \rangle = \langle B^T \mu, x \rangle = \langle \mu, Bx \rangle \geq \langle \mu, b \rangle = \langle b, \mu \rangle. \quad \blacksquare$$

Cualquier punto factible dual proporciona una cota inferior del valor óptimo primal, y recíprocamente, cualquier punto factible primal acota superiormente al problema dual.

Nota: Interpretación de la Dualidad Débil

Si encontramos $\bar{x} \in D$ y $\bar{\mu} \in \Delta$ tales que $\langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle$, la desigualdad (5.3) fuerza a que $\bar{x}$ sea un mínimo global del primal y $\bar{\mu}$ un máximo global del dual.

Teorema 5.1 (Caracterización de Optimalidad). Un punto $\bar{x}$ es una solución del problema primal (5.1) si, y solo si, existe un punto $\bar{\mu}$ que es factible para el problema dual (5.2) y tal que:

$$\langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle, \quad (5.4)$$

es decir, los valores de las funciones objetivo de ambos problemas coinciden.

Más aún, la última afirmación es equivalente a decir que $\bar{\mu}$ es una solución óptima del problema dual (5.2), o que $\bar{\mu}$ es un multiplicador de Lagrange asociado a la solución $\bar{x}$ del problema primal.

Prueba. Por las condiciones necesarias y suficientes de optimalidad de primer orden para problemas afines, $\bar{x}$ es una solución de (5.1) si, y solo si, existe $\bar{\mu} \in \mathbb{R}_+^m$ tal que:

$$c - B^T \bar{\mu} = 0, \quad b - B\bar{x} \leq 0, \quad \langle \bar{\mu}, b - B\bar{x} \rangle = 0.$$

Observamos de forma inmediata que la primera condición asegura que $\bar{\mu} \in \Delta$. Notemos también que el producto interno de la condición de holgura complementaria se puede expandir mediante la definición del operador adjunto:

$$\langle \bar{\mu}, b - B\bar{x} \rangle = \langle \bar{\mu}, b \rangle - \langle B^T \bar{\mu}, \bar{x} \rangle = \langle b, \bar{\mu} \rangle - \langle c, \bar{x} \rangle.$$

Por lo tanto, concluimos que:

$$\langle \bar{\mu}, b - B\bar{x} \rangle = 0 \iff \langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle.$$

Por último, la relación de dualidad débil de la Proposición 5.1 implica que $\bar{\mu}$ es necesariamente una solución del problema dual (5.2), ya que la función objetivo dual alcanza en el punto $\bar{\mu}$ su cota superior global dentro del conjunto factible. ■

Ejemplo 5.1 (Demostración del Lema de Farkas vía Dualidad). El Lema de Farkas establece que el sistema de desigualdades lineales:

$$Ax \leq 0, \quad \langle b, x \rangle > 0 \quad (5.5)$$

carece de solución $x \in \mathbb{R}^n$ si y solo si el sistema alternativo:

$$A^T \mu = b, \quad \mu \geq 0 \quad (5.6)$$

tiene solución $\mu \in \mathbb{R}^m$.

Para probarlo mediante dualidad, planteamos el problema lineal de minimización:

$$\min \langle -b, x \rangle \quad \text{sujeto a} \quad -Ax \geq 0.$$

El origen $x = 0$ siempre es factible y su valor óptimo es nulo. El sistema (5.5) no tiene solución si y solo si no existe ningún punto factible con valor objetivo estrictamente menor que cero. Esto equivale a decir que $\bar{x} = 0$ es un mínimo global, con valor óptimo $\bar{v} = 0$.

Por el Teorema 5.1, esto ocurre si y solo si el dual:

$$\max \langle 0, \mu \rangle \quad \text{sujeto a} \quad -A^T \mu = -b, \quad \mu \geq 0$$

es factible. La restricción de igualdad es exactamente $A^T \mu = b$. Así, el sistema (5.5) es incompatible si y solo si el sistema dual (5.6) es compatible.

Ejemplo 5.2 (Verificación numérica). Tomemos el problema de minimización:

$$\begin{aligned} &\text{minimizar} && 3x_1 + 4x_2 \\ &\text{subject to} && x_1 + 2x_2 \geq 5, \\ &&& 2x_1 + x_2 \geq 6, \\ &&& x_1, x_2 \geq 0 \end{aligned}$$

En el formato estándar (5.1), definimos:

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad c = \begin{pmatrix} 3 \\ 4 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 0 & 0 \end{pmatrix}, \quad b = \begin{pmatrix} 5 \\ 6 \\ 0 \end{pmatrix}.$$

La intersección de las dos restricciones activas proporciona el mínimo global $\bar{x} = (7/3, 4/3)^T$, con valor óptimo primal $\langle c, \bar{x} \rangle = 37/3$.

Buscamos un punto dual factible $\bar{\mu} \in \mathbb{R}^4$ tal que coincidan los objetivos. Dado que las restricciones de no negatividad no están activas en $\bar{x}$, sus multiplicadores asociados deben ser nulos por holgura complementaria: $\bar{\mu}_3 = 0$ y $\bar{\mu}_4 = 0$. Resolvemos la factibilidad dual $B^T \bar{\mu} = c$ para los componentes restantes:

$$\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} \bar{\mu}_1 \\ \bar{\mu}_2 \end{pmatrix} = \begin{pmatrix} 3 \\ 4 \end{pmatrix} \implies \bar{\mu}_1 = \frac{5}{3}, \quad \bar{\mu}_2 = \frac{2}{3}.$$

El vector $\bar{\mu} = (5/3, 2/3, 0, 0)^T$ es no negativo, por lo que es factible para el dual. Evaluando el objetivo dual en este punto:

$$\langle b, \bar{\mu} \rangle = 5\left(\frac{5}{3}\right) + 6\left(\frac{2}{3}\right) = \frac{37}{3}.$$

Al cumplirse $\langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle = 37/3$, el Teorema 5.1 garantiza que $\bar{x}$ y $\bar{\mu}$ son soluciones óptimas globales de sus respectivos problemas.

Teorema 5.2 (Teorema de Dualidad en Programación Lineal). Para cualquier par de problemas primal (5.1) y dual (5.2), se cumple exactamente una de las siguientes afirmaciones:

1. Ambos problemas son infactibles ($D = \emptyset$ y $\Delta = \emptyset$).
2. Uno de los problemas es ilimitado y el otro es infactible.
3. Ambos problemas son factibles. En este caso, ambos poseen soluciones óptimas y sus valores óptimos coinciden:

$$\min_{x \in D} \langle c, x \rangle = \max_{\mu \in \Delta} \langle b, \mu \rangle. \quad (5.7)$$

Prueba. Para comprobar la existencia del caso (1), basta definir un problema con $n = m = 1$ mediante $B = 0$, $b = 1$, $c = 1$. Aquí $D = \{x \in \mathbb{R} \mid 0 \geq 1\} = \emptyset$ y $\Delta = \{\mu \in \mathbb{R} \mid 0 = 1, \mu \geq 0\} = \emptyset$.

En el caso (2), si el primal es ilimitado ($\bar{v} = \inf_{x \in D} \langle c, x \rangle = -\infty$), la existencia de un punto factible dual $\mu \in \Delta$ contradice el teorema de dualidad débil, pues exigiría que $-\infty \geq \langle b, \mu \rangle$. Por tanto, $\Delta = \emptyset$. El razonamiento es análogo si el dual es ilimitado.

Para el caso (3), supongamos que $D \neq \emptyset$ y $\Delta \neq \emptyset$. Por dualidad débil, el valor óptimo primal es finito: $\bar{v} = \inf_{x \in D} \langle c, x \rangle > -\infty$. El sistema de desigualdades:

$$Bx \geq b, \quad \langle -c, x \rangle > -\bar{v} \quad (5.8)$$

no tiene solución por la definición de ínfimo. Al aplicar el Teorema de la Alternativa de Motzkin, la incompatibilidad de (5.8) implica que el sistema dual homogéneo asociado:

$$B^T \mu - y c = 0, \quad -\langle b, \mu \rangle + y \bar{v} + \eta = 0, \quad \mu \geq 0, \quad y \geq 0, \quad \eta \geq 0 \quad (5.9)$$

admite una solución con $(\mu, y, \eta) \neq 0$ tal que $(y, \eta) \geq 0$ no son nulos de manera simultánea.

Analizamos las posibilidades para el escalar y :

- Si $y = 0$, se requiere que $\eta > 0$. De (5.9) se obtiene el sistema homogéneo $B^T \mu = 0$, $\langle b, \mu \rangle = \eta > 0$, $\mu \geq 0$. Aplicando de nuevo el Teorema de la Alternativa de Motzkin, el sistema $z^0 b + Bz^1 + z^2 = 0$ no posee solución. Sin embargo, al tomar un punto factible $x_0 \in D$ y definir $z^1 = -x_0$, $z^0 = 1 > 0$ y $z^2 = Bx_0 - b \geq 0$, evaluamos $b + B(-x_0) + (Bx_0 - b) = 0$, lo que resulta en una contradicción directa. Así, es obligatorio que $y > 0$.
- Si $y > 0$, dividimos por y y definimos $\bar{\mu} = \mu/y$ y $\bar{\eta} = \eta/y$. Obtenemos $B^T \bar{\mu} = c$, $\bar{\mu} \geq 0$ y $\langle b, \bar{\mu} \rangle = \bar{v} + \bar{\eta}$. Esto demuestra que $\bar{\mu}$ es factible para el dual. Como $\bar{\eta} \geq 0$, se tiene $\langle b, \bar{\mu} \rangle \geq \bar{v}$. Por dualidad débil, debe cumplirse simultáneamente que $\langle b, \bar{\mu} \rangle \leq \bar{v}$, lo que fuerza a que $\bar{\eta} = 0$ y, por ende, $\langle b, \bar{\mu} \rangle = \bar{v}$.

La igualdad de los valores objetivos demuestra la existencia de soluciones óptimas con salto de dualidad nulo. ■

Ejemplo 5.3 (Problemas ilimitados e infactibles). Para ilustrar el caso (2) del teorema de dualidad, consideremos el programa lineal primal:

$$\begin{aligned} &\text{minimizar} && -x_1 \\ &\text{subject to} && -x_1 + x_2 \geq -1, \\ &&& x_1, x_2 \geq 0 \end{aligned}$$

La trayectoria paramétrica $x(t) = (t, t)^T$ con $t \geq 0$ es factible para cualquier valor de t . Al evaluar el objetivo en dicha dirección, obtenemos $\lim_{t \rightarrow \infty} (-t) = -\infty$, de modo que el problema primal es **ilimitado**.

El problema dual asociado viene dado por:

$$\begin{aligned} &\text{maximizar} && -\mu_1 \\ &\text{subject to} && -\mu_1 + \mu_2 = -1, \\ &&& \mu_1 + \mu_3 = 0, \\ &&& \mu_1, \mu_2, \mu_3 \geq 0 \end{aligned}$$

La condición $\mu_1 + \mu_3 = 0$ junto con la no negatividad de las variables fuerza a que $\mu_1 = 0$ y $\mu_3 = 0$. Al sustituir $\mu_1 = 0$ en la primera restricción, se obtiene $\mu_2 = -1$, lo cual es incompatible con la condición $\mu_2 \geq 0$. El problema dual es, por tanto, **infactible**.

Pregunta de Control: Verificación de dualidad

¿Es posible que un problema primal lineal de minimización tenga un punto factible con valor objetivo 10 y su dual correspondiente tenga un punto factible con valor objetivo 15? Justifique su respuesta utilizando la relación de dualidad débil.

Nota: Precios sombra

En economía, los multiplicadores óptimos del dual, $\bar{\mu}_i$, se interpretan como los **precios sombra** de los recursos. Representan la tasa de cambio marginal del valor óptimo de la función objetivo ante variaciones infinitesimales en la disponibilidad de los recursos correspondientes (b_i).

5.2. Dualidad para un problema general

El análisis de dualidad se extiende a problemas con restricciones no lineales de igualdad y desigualdad mediante la función Lagrangiana. Dado el problema general de optimización, al cual llamaremos **problema primal**:

$$\begin{aligned} & \underset{x}{\text{minimizar}} && f(x) \\ & \text{subject to} && x \in D = \{x \in \Omega \mid h(x) = 0, g(x) \leq 0\} \end{aligned} \quad (5.10)$$

donde $\Omega \subset \mathbb{R}^n$, $f: \Omega \rightarrow \mathbb{R}$, $h: \Omega \rightarrow \mathbb{R}^l$ y $g: \Omega \rightarrow \mathbb{R}^m$.

Definición 5.1 (Función Lagrangiana). Asociada al problema primal (5.10), se define la **función Lagrangiana** con respecto a las restricciones funcionales como la aplicación $L: \Omega \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R}$ dada por:

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle, \quad (5.11)$$

donde los vectores $\lambda \in \mathbb{R}^l$ y $\mu \in \mathbb{R}^m$ reciben el nombre de **multiplicadores de Lagrange**.

5.2.1. Formulación Minimax del Problema Primal

La Lagrangiana penaliza implícitamente la violación de las restricciones funcionales al buscar el peor escenario respecto a las variables duales.

Lema 5.1 (Penalización implícita). Para cualquier $x \in \Omega$, se verifica:

$$\sup_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} L(x, \lambda, \mu) = \begin{cases} f(x) & \text{si } x \in D, \\ +\infty & \text{si } x \in \Omega \setminus D. \end{cases} \quad (5.12)$$

Prueba. Si $x \in D$, entonces $h(x) = 0$ y $g(x) \leq 0$. Como $\mu \geq 0$, el término $\langle \mu, g(x) \rangle \leq 0$. El valor máximo de la Lagrangiana se alcanza de forma única con $\mu = 0$ (o en cualquier multiplicador si $g_i(x) = 0$), resultando $\sup L = f(x)$. Si $x \notin D$, alguna restricción se infringe. Si $h_j(x) \neq 0$, basta con tomar $\lambda_j = t \cdot \text{sgn}(h_j(x))$ con $t \rightarrow \infty$. Si $g_i(x) > 0$, tomamos $\mu_i = t \rightarrow \infty$. En ambos casos, el supremo diverge a $+\infty$. ■

Observación. El Lema 5.1 permite reescribir de forma equivalente el problema primal (5.10) como un problema (tipo minimax) sin restricciones funcionales, sobre el conjunto base Ω :

$$\min \left\{ \sup_{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m} L(x, \lambda, \mu) \right\} \quad \text{sujeto a } x \in \Omega. \quad (5.13)$$

Además, el **valor óptimo primal** $\bar{v}$ queda caracterizado por la ecuación:

$$\bar{v} = \inf_{x \in \Omega} \left\{ \sup_{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m} L(x, \lambda, \mu) \right\}, \quad (5.14)$$

donde es obligatorio el uso del operador ínfimo (inf), ya que, en ausencia de compacidad en Ω , el mínimo global podría no alcanzarse.

Ejemplo 5.4 (Evaluación del supremo de la Lagrangiana). Dado el problema en $\Omega = \mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && x_1 + x_2 \\ &\text{subject to} && x_1^2 + x_2^2 - 1 = 0, \\ &&& -x_1 \leq 0 \end{aligned}$$

la Lagrangiana asociada es $L(x, \lambda, \mu) = x_1 + x_2 + \lambda(x_1^2 + x_2^2 - 1) - \mu x_1$.

1. Para el punto factible $x^A = (1, 0)^T \in D$, se tiene $L(x^A, \lambda, \mu) = 1 - \mu$. Su supremo sobre $\mu \geq 0$ se alcanza en $\bar{\mu} = 0$, resultando $f(x^A) = 1$.
2. Para el punto infactible de igualdad $x^B = (2, 0)^T$, se tiene $L(x^B, \lambda, \mu) = 2 + 3\lambda - 2\mu$. El supremo respecto a $\lambda \in \mathbb{R}$ diverge trivialmente a $+\infty$.
3. Para el punto infactible de desigualdad $x^C = (-1, 0)^T$, se tiene $L(x^C, \lambda, \mu) = -1 + \mu$. Como la variable μ puede ser arbitrariamente grande, el supremo sobre $\mu \geq 0$ es $+\infty$.

5.2.2. El Problema Dual General

El **problema dual** se define alternando el orden de los operadores de optimización en la formulación minimax del primal (5.13):

$$\bar{w} = \max_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} \left\{ \inf_{x \in \Omega} L(x, \lambda, \mu) \right\}. \quad (5.15)$$

Para simplificar su análisis, introducimos la **función dual** $\varphi : \mathbb{R}^l \times \mathbb{R}^m \rightarrow [-\infty, +\infty)$ como el ínfimo parcial respecto a las variables primales:

$$\varphi(\lambda, \mu) = \inf_{x \in \Omega} L(x, \lambda, \mu). \quad (5.16)$$

El dominio de factibilidad dual es el conjunto $\Delta = \{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}^m \mid \mu \geq 0, \varphi(\lambda, \mu) > -\infty\}$, de modo que el problema dual se expresa como:

$$\max \varphi(\lambda, \mu) \quad \text{sujeto a} \quad (\lambda, \mu) \in \Delta. \quad (5.17)$$

Teorema 5.3 (Propiedades de la función dual). El conjunto de factibilidad dual Δ es convexo y la función dual φ es cóncava sobre Δ .

Prueba. Para cada punto fijo $x \in \Omega$, la función de multiplicadores $(\lambda, \mu) \mapsto L(x, \lambda, \mu)$ es afín y, por ende, cóncava. Como la función dual φ es el ínfimo puntual de una familia de funciones afines continuas, conserva la concavidad de estas. La convexidad del dominio Δ se deduce de forma inmediata al ser el dominio de definición de una función cóncava propia. ■

El problema dual siempre es un problema de optimización convexa (maximización de una función cóncava sobre un conjunto convexo), con independencia de las propiedades topológicas o de convexidad del problema primal original.

5.2.3. Teorema de Dualidad Débil

Teorema 5.4 (Teorema de Dualidad Débil). Para cualquier punto factible primal $x \in D$ y cualquier punto factible dual $(\lambda, \mu) \in \Delta$, se cumple:

$$\varphi(\lambda, \mu) \leq f(x). \quad (5.18)$$

Prueba. Evaluando el ínfimo parcial en el punto particular $x \in D$:

$$\varphi(\lambda, \mu) = \inf_{z \in \Omega} L(z, \lambda, \mu) \leq L(x, \lambda, \mu).$$

Como $h(x) = 0$ y $\langle \mu, g(x) \rangle \leq 0$ para todo $\mu \geq 0$, se deduce que $L(x, \lambda, \mu) \leq f(x)$. ■

Ejemplo 5.5 (Obtención analítica de la función dual). Sea el problema de optimización:

$$\min x^2 \quad \text{sujeto a} \quad x - 2 \leq 0.$$

La Lagrangiana para $\mu \geq 0$ es $L(x, \mu) = x^2 + \mu x - 2\mu$. Resolvemos el ínfimo sobre $\Omega = \mathbb{R}$ igualando la derivada respecto a x a cero:

$$2x + \mu = 0 \implies x^*(\mu) = -\frac{\mu}{2}.$$

Sustituyendo x^* en la Lagrangiana, se obtiene la función dual:

$$\varphi(\mu) = -\frac{\mu^2}{4} - 2\mu.$$

Dado que el ínfimo es finito para todo μ , el dominio dual es $\Delta = [0, +\infty)$, el cual es convexo. Además, $\varphi''(\mu) = -1/2 < 0$, confirmando que la función dual es estrictamente cóncava sobre su dominio.

Definición 5.2. La diferencia entre el valor óptimo primal $\bar{v}$ y el dual $\bar{w}$ se llama **salto de dualidad** ($\bar{v} - \bar{w} \geq 0$).

Corolario 5.1 (Ausencia de salto de dualidad). Si existen puntos factibles $\bar{x} \in D$ y $(\bar{\lambda}, \bar{\mu}) \in \Delta$ tales que $f(\bar{x}) = \varphi(\bar{\lambda}, \bar{\mu})$, entonces $\bar{x}$ y $(\bar{\lambda}, \bar{\mu})$ son soluciones óptimas globales de sus respectivos problemas, y el salto de dualidad es nulo.

5.2.4. Patologías y Casos Límite en la Teoría de Dualidad

Los siguientes tres ejemplos ilustran cómo la falta de convexidad o la estructura de los dominios pueden impedir el alcance de los óptimos o dar lugar a saltos de dualidad estrictamente positivos.

Ejemplo 5.6 (Mínimo primal no alcanzado, sin salto de dualidad). Sea el problema de optimización definido sobre el conjunto base abierto $\Omega = (0, +\infty)$:

$$\begin{aligned} &\text{minimizar} && 1/x \\ &\text{subject to} && -x \leq 0 \end{aligned}$$

El dominio factible es $D = (0, +\infty)$. El valor del ínfimo primal es $\bar{v} = 0$, pero no se alcanza para ningún x finito. El problema primal no tiene solución.

Para cualquier $\mu \geq 0$, la Lagrangiana es $L(x, \mu) = 1/x - \mu x$. Evaluamos la función dual $\varphi(\mu) = \inf_{x>0} (1/x - \mu x)$:

- Si $\mu > 0$, tomando $x \rightarrow \infty$ el término $-\mu x$ decae sin límite inferior, resultando $\varphi(\mu) = -\infty$.
- Si $\mu = 0$, se tiene $\varphi(0) = \inf_{x>0} 1/x = 0$.

Así, el dominio dual es el conjunto unitario $\Delta = \{0\}$. El problema dual consiste en evaluar $\varphi(0) = 0$, con valor óptimo dual $\bar{w} = 0$. No existe salto de dualidad ($\bar{v} = \bar{w} = 0$) y el dual admite solución óptima en $\bar{\mu} = 0$, pero el primal no es soluble.

Ejemplo 5.7 (Óptimo primal existente, sin salto, pero dual no soluble). Sea el problema en $\Omega = \mathbb{R}$:

$$\begin{aligned} &\text{minimizar} && x \\ &\text{subject to} && x^2 \leq 0 \end{aligned}$$

El único punto factible es $\bar{x} = 0$, por lo que $\bar{v} = f(0) = 0$. La Lagrangiana es $L(x, \mu) = x + \mu x^2$. Calculamos la función dual $\varphi(\mu) = \inf_{x \in \mathbb{R}} (x + \mu x^2)$:

- Si $\mu > 0$, el mínimo de la parábola se alcanza en $x = -1/(2\mu)$, dando $\varphi(\mu) = -1/(4\mu)$.
- Si $\mu = 0$, el ínfimo de la función lineal en $\mathbb{R}$ es $\varphi(0) = -\infty$.

El conjunto de factibilidad dual es el intervalo abierto $\Delta = (0, +\infty)$. El problema dual es $\max_{\mu>0} (-1/(4\mu))$. Al aproximar $\mu \rightarrow \infty$, el supremo es $\bar{w} = 0$. Sin embargo, este valor no se alcanza para ningún multiplicador finito en el dominio abierto Δ . El salto de dualidad es nulo, pero el problema dual no posee solución.

Ejemplo 5.8 (Salto de dualidad estrictamente positivo). Tomemos el problema de optimización discreta sobre el conjunto no convexo $\Omega = \{0, 1\}$:

$$\begin{aligned} &\text{minimizar} && x_1 + x_2 \\ &\text{subject to} && x_1^2 + x_2^2 - 2 \leq 0. \end{aligned}$$

El único punto factible es $\bar{x} = 0$, lo que determina un valor óptimo primal $\bar{v} = f(0) = 0$.

Para $\mu \geq 0$, la Lagrangiana es $L(x, \mu) = -x + \mu(x - 1/2)$. Evaluamos la función dual $\varphi(\mu)$ seleccionando el mínimo en el conjunto discreto Ω :

$$\varphi(\mu) = \min_{x \in \{0, 1\}} L(x, \mu) = \min \left\{ -\frac{1}{2}\mu, \frac{1}{2}\mu - 1 \right\}.$$

El máximo de esta función cóncava y continua por partes se localiza en la intersección de ambas rectas:

$$-\frac{1}{2}\mu = \frac{1}{2}\mu - 1 \implies \bar{\mu} = 1.$$

El valor óptimo dual es $\bar{w} = \varphi(1) = -1/2$. Obtenemos un salto de dualidad estrictamente positivo:

$$\bar{v} - \bar{w} = 0 - \left(-\frac{1}{2}\right) = \frac{1}{2} > 0.$$

5.2.5. Teoría de Multiplicadores de Lagrange Globales

Definición 5.3 (Multiplicador de Lagrange Global). Un vector $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}_+^m$ es un **multiplicador de Lagrange global** para el problema primal (5.10) si cumple:

$$\bar{v} = \inf_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu}). \quad (5.19)$$

Esta definición establece que las penalizaciones óptimas permiten hallar el valor óptimo del problema original mediante una minimización no restringida de la Lagrangiana sobre el conjunto base Ω .

Proposición 5.2 (Identidad entre Multiplicadores y Soluciones Duales). Supóngase que el valor óptimo primal $\bar{v}$ es finito y que el salto de dualidad es nulo. El conjunto de multiplicadores de Lagrange del problema primal coincide entonces con el conjunto de soluciones óptimas del problema dual.

Prueba. Si $(\bar{\lambda}, \bar{\mu})$ es un multiplicador de Lagrange, se tiene $\bar{\mu} \geq 0$ y $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{v}$. Como el salto de dualidad es nulo, se cumple $\bar{v} = \bar{w}$, lo que da $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{w}$. Esto demuestra que el par maximiza la función dual. Recíprocamente, si $(\bar{\lambda}, \bar{\mu}) \in \Delta$ es óptimo dual, entonces $\bar{\mu} \geq 0$ y $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{w}$. Al cumplirse $\bar{w} = \bar{v}$, resulta inmediato que $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{v}$, satisfaciendo la definición de multiplicador. ■

Ejemplo 5.9 (Identidad en un problema cuadrático bidimensional). Consideremos la minimización de una función afín sobre un disco euclidiano compacto en $\Omega = \mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && x_1 - x_2 \\ &\text{subject to} && x_1 + x_2 \leq 0. \end{aligned}$$

El mínimo de esta función sobre el disco de radio $\sqrt{2}$ se alcanza en $\bar{x} = (-1, -1)^\top$. En consecuencia, el **valor óptimo primal** está dado por $\bar{v} = f(-1, -1) = -2$.

Para cualquier escalar $\mu \geq 0$, la Lagrangiana es $L(x, \mu) = x_1 + x_2 + \mu(x_1^2 + x_2^2 - 2)$. Si $\mu = 0$, $\varphi(0) = -\infty$. Para $\mu > 0$, la función es estrictamente convexa. Anulando el gradiente respecto a x :

$$\nabla_x L(x, \mu) = \begin{pmatrix} 1 + 2\mu x_1 \\ 1 + 2\mu x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies x_1^*(\mu) = x_2^*(\mu) = -\frac{1}{2\mu}.$$

Sustituyendo, obtenemos la función dual $\varphi(\mu) = -\frac{1}{2\mu} - 2\mu$.

El problema dual exige maximizar esta función cóncava sobre el dominio $\mu > 0$. Derivando e igualando a cero: $\varphi'(\mu) = \frac{1}{2\mu^2} - 2 = 0 \implies \mu^2 = 1/4$. El único candidato admisible es $\bar{\mu} = 1/2$. Al evaluar, confirmamos que el **valor óptimo dual** es: $\bar{w} = \varphi(1/2) = -2$.

Observamos empíricamente que $\bar{v} = \bar{w} = -2$ (brecha nula). El óptimo dual $\bar{\mu} = 1/2$ debe satisfacer la definición topológica de un multiplicador global (Definición 5.3). Comprobémoslo:

$$\inf_{x \in \mathbb{R}^2} L\left(x, \frac{1}{2}\right) = \inf_{x \in \mathbb{R}^2} \left[\frac{1}{2}(x_1 + 1)^2 + \frac{1}{2}(x_2 + 1)^2 - 2 \right].$$

Es evidente que el valor mínimo de esta suma de cuadrados es -2 , alcanzado en $x = (-1, -1)^\top$. Hemos demostrado que el conjunto de multiplicadores de Lagrange y el de soluciones duales son idénticos.

Teorema 5.5 (Garantía de Existencia de Solución Dual). Supóngase que el conjunto factible del problema primal es no vacío ($D \neq \emptyset$) y que el problema primal posee al menos un multiplicador de Lagrange global.

1. Si el conjunto de factibilidad dual es no vacío ($\Delta \neq \emptyset$), entonces el problema dual posee una solución óptima.
2. Si el conjunto de factibilidad dual es vacío ($\Delta = \emptyset$), entonces el valor óptimo del problema primal es infinito negativo ($\bar{v} = -\infty$).

Prueba. Sea $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}_+^m$ un multiplicador de Lagrange. Por definición (Definición 5.3), $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{v}$.

Si $\Delta \neq \emptyset$, por el Teorema de Dualidad Débil (Teorema 5.4), $\bar{v}$ acota superiormente a cualquier valor factible dual.

Puesto que el par $(\bar{\lambda}, \bar{\mu})$ alcanza este límite superior, pertenece a Δ y es un maximizador global de la función dual.

Si $\Delta = \emptyset$, implica que para todo par (λ, μ) se tiene $\varphi(\lambda, \mu) = -\infty$. Evaluando en el multiplicador garantizado por hipótesis, obtenemos $\varphi(\bar{\lambda}, \bar{\mu}) = -\infty$. Por ende, $\bar{v} = -\infty$. ■

Ejemplo 5.10 (Infactibilidad dual y divergencia primal). Consideremos el siguiente problema lineal sobre $\Omega = \mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && x_1 - x_2 \\ &\text{subject to} && x_1 + x_2 \leq 0. \end{aligned}$$

El dominio factible D contiene a $(0, 0)$. Tomando $x(t) = (-t, t)^T$ para $t > 0$, la función objetivo evaluada en esta trayectoria es $-2t$. Al hacer $t \rightarrow \infty$, el problema es ilimitado: $\bar{v} = -\infty$.

Construyamos la función Lagrangiana para $\mu \geq 0$: $L(x, \mu) = x_1(1 + \mu) + x_2(\mu - 1)$. Para que el ínfimo sea finito, se requeriría $1 + \mu = 0$ y $\mu - 1 = 0$, lo cual es una contradicción. Concluimos que para cualquier $\mu \geq 0$, $\varphi(\mu) = -\infty$. Por tanto, $\Delta = \emptyset$, lo que corrobora el Teorema 5.5.

Teorema 5.6 (Condiciones de Kuhn-Tucker No Diferenciables). Un punto $\bar{x} \in D$ es solución óptima del problema primal y $(\bar{\lambda}, \bar{\mu})$ es un multiplicador de Lagrange si y solo si se cumplen las condiciones:

$$L(\bar{x}, \bar{\lambda}, \bar{\mu}) = \min_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu}), \quad (5.20)$$

$$\bar{\mu}_i g_i(\bar{x}) = 0, \quad \forall i = 1, \dots, m. \quad (5.21)$$

Prueba. ($\Rightarrow$) Como $\bar{x}$ es óptimo y $(\bar{\lambda}, \bar{\mu})$ es multiplicador, se tiene $f(\bar{x}) = \inf_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu})$. Como $\bar{x} \in D$, resulta $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x}) + \langle \bar{\mu}, g(\bar{x}) \rangle$. La condición $\bar{\mu} \geq 0, g(\bar{x}) \leq 0$ exige que $\langle \bar{\mu}, g(\bar{x}) \rangle \leq 0$. Al ser el ínfimo $f(\bar{x})$, se debe verificar de forma obligatoria que $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x})$, lo que prueba (5.20) y requiere $\bar{\mu}_i g_i(\bar{x}) = 0$.

($\Leftarrow$) Por holgura complementaria y factibilidad, se tiene $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x})$. Sustituyendo en la minimización global (5.20), resulta $f(\bar{x}) = \inf_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu})$, lo cual demuestra que $(\bar{\lambda}, \bar{\mu})$ es un multiplicador y $\bar{x}$ es óptimo global. ■

5.2.6. Dualidad Fuerte y la Condición de Slater

Definición 5.4 (Condición de Regularidad de Slater). Se dice que el problema primal (5.10) satisface la **condición de Slater** si las restricciones de igualdad son afines ($h(x) = Ax - a$), las restricciones de desigualdad g_i son funciones convexas en Ω , y existe un punto de regularidad $\hat{x} \in \text{int } \Omega$ tal que:

$$A\hat{x} - a = 0 \quad \text{y} \quad g_i(\hat{x}) < 0 \quad \forall i = 1, \dots, m. \quad (5.22)$$

Teorema 5.7 (Teorema de Dualidad Fuerte de Slater). Supóngase que en el problema primal (5.10) las funciones f y g_i son convexas, las restricciones de igualdad son afines dadas por $h(x) = Ax - a$ con $A \in \mathbb{R}^{l \times n}$, y el valor óptimo primal $\bar{v}$ es finito. Si se satisface la condición de regularidad de Slater (Definición 5.4), entonces el salto de dualidad es nulo ($\bar{v} = \bar{w}$), y el problema dual admite al menos una solución óptima $(\bar{\lambda}, \bar{\mu}) \in \Delta$.

Prueba. Supongamos, sin pérdida de generalidad, que las filas de la matriz A son linealmente independientes. Definamos el conjunto de valores admisibles para la función objetivo y las perturbaciones de las restricciones primales:

$$C = \left\{ (y, z, c) \in \mathbb{R} \times \mathbb{R}^m \times \mathbb{R}^l \mid \exists x \in \Omega \text{ t.q. } f(x) \leq y, g(x) \leq z, Ax - a = c \right\}.$$

La convexidad de f y g_i , sumada al carácter afín de h , garantizan que C es un conjunto convexo en $\mathbb{R} \times \mathbb{R}^m \times \mathbb{R}^l$. Dado que $\bar{v}$ es el valor óptimo primal, el punto $(\bar{v}, 0, 0)$ se encuentra en la frontera del conjunto convexo C .

Aplicamos el Teorema de Separación de Conjuntos Convexos (Lema de Minkowski). Existe un hiperplano de soporte en $(\bar{v}, 0, 0)$, caracterizado por un vector normal no nulo $(\beta, \bar{\mu}, \bar{\lambda}) \in \mathbb{R} \times \mathbb{R}^m \times \mathbb{R}^l$, tal que:

$$\beta \bar{v} \leq \beta y + \langle \bar{\mu}, z \rangle + \langle \bar{\lambda}, c \rangle \quad \forall (y, z, c) \in C. \quad (5.23)$$

Para que la desigualdad se cumpla asintóticamente es necesario que $\beta \geq 0$ y $\bar{\mu} \geq 0$.

Asumamos que $\beta = 0$. Evaluando (5.23) en el punto factible de Slater $\hat{x}$, se obtiene $0 \leq \langle \bar{\mu}, g(\hat{x}) \rangle$. Dado que $\bar{\mu} \geq 0$ y cada componente $g_i(\hat{x}) < 0$, la única posibilidad es que $\bar{\mu} = 0$. Sustituyendo $\beta = 0$ y $\bar{\mu} = 0$, nos queda $0 \leq \langle \bar{\lambda}, c \rangle$ para todo c factible. Como A tiene rango completo, esto es posible solo si $\bar{\lambda} = 0$. Esto implica que el vector normal es nulo, contradiciendo el Teorema de Separación. Por consiguiente, $\beta > 0$.

Dividiendo (5.23) por β y definiendo $\lambda^* = \bar{\lambda}/\beta \in \mathbb{R}^l$ y $\mu^* = \bar{\mu}/\beta \in \mathbb{R}_+^m$. Tomando $(y, z, c) = (f(x), g(x), Ax - a) \in C$, la inecuación se reduce a:

$$\bar{v} \leq f(x) + \langle \mu^*, g(x) \rangle + \langle \lambda^*, Ax - a \rangle = L(x, \lambda^*, \mu^*).$$

Tomando el ínfimo sobre todo $x \in \Omega$, concluimos que $\bar{v} \leq \varphi(\lambda^*, \mu^*)$. A su vez, por Dualidad Débil (Teorema 5.4), sabemos que $\varphi(\lambda^*, \mu^*) \leq \bar{v}$. Así, $\varphi(\lambda^*, \mu^*) = \bar{v}$, probando que no hay salto de dualidad y el óptimo dual se alcanza. ■

Ejemplo 5.11 (Verificación de la dualidad fuerte). Sea el problema de optimización en $\Omega = \mathbb{R}$:

$$\begin{aligned} &\text{minimizar} && (x - 3)^2 \\ &\text{subject to} && x - 2 \leq 0 \end{aligned}$$

El origen $\hat{x} = 0 \in \text{int } \mathbb{R}$ cumple $g(0) = -2 < 0$, satisfaciendo la condición de Slater. El mínimo restringido se alcanza en la frontera $\bar{x} = 2$, dando $\bar{v} = 1$.

Construimos la función dual para $\mu \geq 0$: $\varphi(\mu) = \inf_{x \in \mathbb{R}} \{(x - 3)^2 + \mu(x - 2)\} = -\frac{\mu^2}{4} + \mu$. Maximizando la función dual, calculamos el óptimo $\bar{\mu} = 2$. El valor óptimo dual es $\bar{w} = \varphi(2) = 1$. Verificamos que $\bar{v} = \bar{w} = 1$.

5.2.7. El Problema Dual de Wolfe

Definición 5.5 (Problema Dual de Wolfe). Asociado al problema primal (5.10), asumiendo que Ω es abierto en $\mathbb{R}^n$ y que f, g, h son continuamente diferenciables, el **problema dual de Wolfe** se define como:

$$\max_{\substack{x \in \Omega, \lambda \in \mathbb{R}^l \\ \mu \geq 0}} L(x, \lambda, \mu) \quad \text{sujeto a} \quad \nabla_x L(x, \lambda, \mu) = 0. \quad (5.24)$$

Denotaremos al conjunto de factibilidad de este problema como W .

Teorema 5.8 (Dualidad Débil de Wolfe). Si el problema primal original es de minimización convexa (es decir, f y g_i son convexas, y h es afín), entonces para cualquier punto factible primal $\bar{x} \in D$ y cualquier punto factible del dual de Wolfe $(x, \lambda, \mu) \in W$, se verifica que:

$$L(x, \lambda, \mu) \leq f(\bar{x}). \quad (5.25)$$

Prueba. Dado que f y g_i son convexas y h es afín, la Lagrangiana $x \mapsto L(x, \lambda, \mu)$ preserva la convexidad. Por la definición de W , sabemos que $\nabla_x L(x, \lambda, \mu) = 0$. En funciones convexas, la anulación del gradiente garantiza que x es un minimizador global: $L(x, \lambda, \mu) = \inf_{z \in \Omega} L(z, \lambda, \mu) = \varphi(\lambda, \mu)$. Aplicando el Teorema de Dualidad Débil General (Teorema 5.4), sabemos que $\varphi(\lambda, \mu) \leq f(\bar{x})$. Sustituyendo la igualdad previa, se concluye: $L(x, \lambda, \mu) \leq f(\bar{x})$. ■

Ejemplo 5.12 (Coincidencia del Dual de Wolfe en Programación Lineal). Sea el programa primal lineal: $\min \langle c, x \rangle$ sujeto a $Bx \geq b$. Adaptando a $g(x) = b - Bx \leq 0$, la Lagrangiana es $L(x, \mu) = \langle c - B^T \mu, x \rangle + \langle b, \mu \rangle$. La restricción del dual de Wolfe es $\nabla_x L(x, \mu) = 0$, lo que equivale a $c - B^T \mu = 0$. Evaluando la función objetivo $L(x, \mu)$ bajo esta condición, el término con x se anula, resultando $L(x, \mu) = \langle b, \mu \rangle$. El dual de Wolfe se simplifica a maximizar $\langle b, \mu \rangle$ sujeto a $B^T \mu = c$ y $\mu \geq 0$, que es la formulación dual estándar planteada en (5.2).

5.2.8. Caracterización mediante Puntos de Silla

Definición 5.6 (Punto de Silla). Un punto $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in \Omega \times \mathbb{R}^l \times \mathbb{R}_+^m$ es un **punto de silla** de la Lagrangiana si verifica la doble desigualdad topológica:

$$L(\bar{x}, \lambda, \mu) \leq L(\bar{x}, \bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu}) \quad (5.26)$$

para todo $x \in \Omega$, todo $\lambda \in \mathbb{R}^l$ y todo $\mu \geq 0$.

Teorema 5.9 (Teorema del Punto de Silla). Un punto $\bar{x} \in \Omega$ es solución óptima del problema primal y $(\bar{\lambda}, \bar{\mu})$ es solución óptima del problema dual asociado con salto de dualidad nulo si y solo si $(\bar{x}, \bar{\lambda}, \bar{\mu})$ es un punto de silla de la Lagrangiana.

Prueba. ($\implies$) : Por el Lema 5.1 y la factibilidad de $\bar{x}$, se tiene $L(\bar{x}, \lambda, \mu) \leq f(\bar{x}) = L(\bar{x}, \bar{\lambda}, \bar{\mu})$, probando la primera desigualdad. Para la segunda, la dualidad fuerte implica $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = \varphi(\bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu})$.

($\impliedby$) : Si es un punto de silla, al tomar el supremo en las variables duales de la primera desigualdad: $\sup L(\bar{x}, \lambda, \mu) \leq L(\bar{x}, \bar{\lambda}, \bar{\mu}) < +\infty$. Por el Lema 5.1, esto fuerza a que $\bar{x} \in D$ y $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x})$. De la segunda desigualdad, $f(\bar{x}) \leq L(x, \bar{\lambda}, \bar{\mu})$. Tomando el ínfimo sobre $x \in \Omega$, resulta $f(\bar{x}) \leq \varphi(\bar{\lambda}, \bar{\mu})$. Por el Teorema de Dualidad Débil, esto obliga a que $f(\bar{x}) = \varphi(\bar{\lambda}, \bar{\mu})$, anulando el salto de dualidad. ■

Ejemplo 5.13 (Punto de silla de la Lagrangiana). Tomemos el problema: $\min x^2 - 4x$ sujeto a $x - 1 \leq 0$. El mínimo restringido en $D = (-\infty, 1]$ se alcanza en $\bar{x} = 1$, con $\bar{v} = -3$. La Lagrangiana es $L(x, \mu) = x^2 - 4x + \mu(x - 1)$. Igualando a cero la derivada en $\bar{x} = 1$, obtenemos $\bar{\mu} = 2$.

Verificamos las condiciones de punto de silla para $(\bar{x}, \bar{\mu}) = (1, 2)$:

1. **Izquierda:** Para cualquier $\mu \geq 0$, $L(1, \mu) = -3 \leq L(1, 2) = -3$, lo cual se cumple.
2. **Derecha:** Para cualquier $x \in \mathbb{R}$, $L(1, 2) \leq L(x, 2) \implies -3 \leq x^2 - 2x - 2 \implies (x - 1)^2 \geq 0$, la cual se verifica siempre.

Esto confirma que la terna constituye un punto de silla de la Lagrangiana.

5.2.9. Subgradiente de la Función Dual

Proposición 5.3 (Subgradiente de la Función Dual). Sean $(\lambda, \mu) \in \Delta$ y sea $x(\lambda, \mu) \in \Omega$ tal que se alcanza el ínfimo parcial, es decir, $\varphi(\lambda, \mu) = L(x(\lambda, \mu), \lambda, \mu)$. El vector de violaciones funcionales:

$$-\begin{pmatrix} h(x(\lambda, \mu)) \\ g(x(\lambda, \mu)) \end{pmatrix} \in \partial(-\varphi)(\lambda, \mu) \quad (5.27)$$

es un subgradiente de la función dual negativa $-\varphi$ en el punto (λ, μ) .

Prueba. Un vector s es un subgradiente si $\varphi(\eta, \nu) \leq \varphi(\lambda, \mu) - \langle s, (\eta - \lambda, \nu - \mu)^T \rangle$. Partiendo de la definición de la función dual en un punto genérico $(\eta, \nu) \in \Delta$:

$$\varphi(\eta, \nu) = \inf_{z \in \Omega} L(z, \eta, \nu) \leq L(x(\lambda, \mu), \eta, \nu).$$

Desarrollando la expresión de la Lagrangiana evaluada en $x(\lambda, \mu)$:

$$L(x(\lambda, \mu), \eta, \nu) = \varphi(\lambda, \mu) + \langle \eta - \lambda, h(x(\lambda, \mu)) \rangle + \langle \nu - \mu, g(x(\lambda, \mu)) \rangle.$$

Esto verifica la desigualdad del subgradiente al tomar $s = -(h(x(\lambda, \mu)), g(x(\lambda, \mu)))^T$. ■

Pregunta de Control: Interpretación de puntos de silla

Si se encuentra un punto de silla para la función Lagrangiana de un problema no convexo, ¿se puede asegurar que dicho punto define la solución global del problema primal? Justifique su respuesta basándose en las hipótesis del Teorema 5.9.

Nota: Relajación Lagrangiana

El Teorema de Dualidad Débil sustenta la técnica conocida como **relajación Lagrangiana**, utilizada en optimización entera y combinatoria. Al trasladar restricciones difíciles a la función objetivo mediante multiplicadores fijos $\mu \geq 0$, se obtiene un problema relajado fácil de resolver cuyo óptimo proporciona siempre una cota inferior rigurosa para el valor mínimo del problema original.

Ejercicios del Capítulo

Parte I: Dualidad en Programación Lineal

Ejercicio 5.1 (Dualidad en formato lineal general). Sea el problema de programación lineal en formato general:

$$\begin{aligned} &\text{minimizar} && \langle c_1, x_1 \rangle + \langle c_2, x_2 \rangle \\ &\text{subject to} && (x_1, x_2) \in D \end{aligned}$$

donde el conjunto factible D está definido por:

$$D = \left\{ (x_1, x_2) \in \mathbb{R}^{n_1} \times \mathbb{R}_+^{n_2} \mid \begin{array}{l} B_{11}x_1 + B_{12}x_2 = b_1, \\ B_{21}x_1 + B_{22}x_2 \geq b_2 \end{array} \right\},$$

con $c_1 \in \mathbb{R}^{n_1}$, $c_2 \in \mathbb{R}^{n_2}$, $B_{11} \in \mathbb{R}^{l \times n_1}$, $B_{12} \in \mathbb{R}^{l \times n_2}$, $B_{21} \in \mathbb{R}^{m \times n_1}$, $B_{22} \in \mathbb{R}^{m \times n_2}$, $b_1 \in \mathbb{R}^l$ y $b_2 \in \mathbb{R}^m$.

Demuestre que el problema dual asociado viene dado por:

$$\begin{aligned} &\text{maximizar} \quad \langle b_1, \lambda \rangle \\ &\text{subject to} \quad (\lambda, \mu) \in \Delta \end{aligned}$$

donde el conjunto factible dual es:

$$\Delta = \left\{ (\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m \mid \begin{array}{l} B_{11}^\top \lambda + B_{21}^\top \mu = c_1, \\ B_{12}^\top \lambda + B_{22}^\top \mu \leq c_2 \end{array} \right\},$$

y verifique que se cumplen todas las relaciones de dualidad débil y fuerte para este par de problemas.

Ejercicio 5.2 (Verificación numérica de dualidad). Dado el problema de programación lineal de maximización:

$$\begin{aligned} &\text{maximizar} \quad \langle c, x \rangle \\ &\text{subject to} \quad Bx \leq b, \\ &\quad \quad \quad x \geq 0 \end{aligned}$$

donde:

$$B = \begin{pmatrix} 2 & 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 \end{pmatrix}, \quad c = \begin{pmatrix} 4 \\ 5 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \quad b = \begin{pmatrix} 8 \\ 7 \\ 3 \end{pmatrix}.$$

Formule el problema dual de minimización correspondiente y verifique que los puntos $\bar{x} = (3, 2, 0, 0, 1)^\top$ y $\bar{\mu} = (1, 2, 0)^\top$ son las soluciones óptimas de los problemas primal y dual, respectivamente.

Ejercicio 5.3 (Acotamiento y optimalidad en sistemas homogéneos). Demuestre que el problema de maximización lineal $\max \langle c, x \rangle$ sujeto a $Ax = 0, x \geq 0$ tiene un valor óptimo finito si y solo si $\bar{x} = 0$ es una solución óptima del problema.

Ejercicio 5.4 (Análisis de sensibilidad paramétrica). Para el problema lineal paramétrico:

$$\begin{aligned} &\text{minimizar} \quad 3x_1 + 4x_2 + x_3 + x_4 \\ &\text{subject to} \quad \begin{array}{l} x_1 + x_2 + x_3 - x_4 \geq 2, \\ -2x_1 + 2x_2 + x_3 + x_4 \geq \sigma, \\ x_i \geq 0, \quad i = 1, \dots, 4 \end{array} \end{aligned}$$

donde $\sigma \in \mathbb{R}$ es un parámetro real.

1. Formule el problema dual asociado.
2. Resuelva el problema dual analíticamente para cada valor posible de σ .
3. Utilizando la solución dual, determine el valor óptimo del problema primal en función de σ .

Parte II: Dualidad en Problemas Generales y Puntos de Silla

Ejercicio 5.5 (Dual de un problema de programación cuadrática). Dado el problema de programación cuadrática $\min \frac{1}{2} \langle Qx, x \rangle + \langle q, x \rangle$ sujeto a $Bx \leq b$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, $q \in \mathbb{R}^n$, $B \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$.

Demuestre que el problema dual asociado puede formularse como el siguiente problema de maximización cuadrática sobre el ortante no negativo:

$$\text{maximizar}_{\mu \geq 0} \quad \left\{ -\frac{1}{2} \langle (BQ^{-1}B^\top)\mu, \mu \rangle - \langle b + BQ^{-1}q, \mu \rangle - \frac{1}{2} \langle Q^{-1}q, q \rangle \right\}$$

Ejercicio 5.6 (Cálculo analítico de la función dual). Calcule analíticamente la función dual $\varphi(\mu)$ y resuelva de forma exacta el problema dual del problema general $\min f(x)$ sujeto a $x \in \Omega$ con $g(x) \leq 0$, para cada uno de los siguientes casos:

1. $f(x) = x_1 - x_2$, $g(x) = x_1 + x_2 - 1$, $\Omega = \mathbb{R}_+^2$.

$$2. f(x) = \frac{1}{2}(x_1^2 + x_2^2), \quad g(x) = x_1 - 1, \quad \Omega = \mathbb{R}^2.$$

$$3. f(x) = x, \quad g(x) = x^2, \quad \Omega = \mathbb{R}.$$

En cada caso, determine si existe salto de dualidad.

Ejercicio 5.7 (Dualidad en problemas de proyección). Sean $A \in \mathbb{R}^{m \times n}$ una matriz de rango completo de filas y $z \in \mathbb{R}^n$ un punto de proyección fijo. Demuestre que el problema dual asociado al problema de proyección ortogonal $\min \frac{1}{2\|z-x\|^2}$ sujeto a $Ax = 0$ es equivalente a un problema de proyección de un vector transformado sobre la imagen de la matriz transpuesta A^T (un subespacio afín).

Ejercicio 5.8 (Invariancia y dependencia de la formación dual). Considere las dos formulaciones matemáticamente equivalentes del mismo problema geométrico:

$$(P1) \quad \min \langle a, x \rangle \quad \text{sujeto a} \quad \|x\| \leq 1,$$

$$(P2) \quad \min \langle a, x \rangle \quad \text{sujeto a} \quad \|x\|^2 \leq 1.$$

Demuestre que sus respectivos problemas duales de Lagrange son algebraicamente diferentes y analice cómo influye la elección de la función de restricción en la suavidad de la función dual.

Ejercicio 5.9 (Teorema de Everett). Sean $(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m$ y sea $x(\lambda, \mu) \in \Omega$ una solución óptima del problema de optimización no restringido de la Lagrangiana $\min_{x \in D} L(x, \lambda, \mu)$. Demuestre que el punto $x(\lambda, \mu)$ es una solución óptima del problema perturbado $\min f(x)$ sujeto a $h(x) = y$ y $g(x) \leq z$, donde los vectores de perturbación están definidos por $y = h(x(\lambda, \mu))$ y $z_j = g_j(x(\lambda, \mu))$ si $\mu_j > 0$, o $z_j \geq g_j(x(\lambda, \mu))$ si $\mu_j = 0$.

Ejercicio 5.10 (Puntos de Silla e Igualdad Minimax). Demuestre algebraicamente que $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in \Omega \times \mathbb{R}^l \times \mathbb{R}_+^m$ es un punto de silla de la Lagrangiana si y solo si se verifica la igualdad de los valores minimax:

$$\min_{x \in \Omega} \sup_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} L(x, \lambda, \mu) = \max_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} \inf_{x \in \Omega} L(x, \lambda, \mu) = L(\bar{x}, \bar{\lambda}, \bar{\mu}).$$

Ejercicio 5.11 (Proyección sobre un semiespacio). Sean $a \in \mathbb{R}^n \setminus \{0\}$ y $b \in \mathbb{R}^n$. Formule y resuelva de manera analítica el problema dual asociado al problema de minimización $\min \frac{1}{2}\|x\|^2 - \langle b, x \rangle$ sujeto a $\langle a, x \rangle \leq 0$. Utilice la solución del problema dual para obtener la solución óptima del problema primal.

Ejercicio 5.12 (Descomposición dual en optimización separable). Considere un problema con estructura separable donde las variables y las funciones pueden dividirse en p bloques independientes:

$$\begin{aligned} & \text{minimizar} \quad \sum_{j=1}^p f_j(x_j) \\ & \text{subject to} \quad \sum_{j=1}^p h_j(x_j) = 0, \\ & \quad \quad \quad \sum_{j=1}^p g_j(x_j) \leq 0, \\ & \quad \quad \quad x_j \in \Omega_j, \quad j = 1, \dots, p \end{aligned}$$

donde $\Omega_j \subset \mathbb{R}^{n_j}$, $f_j : \Omega_j \rightarrow \mathbb{R}$, $h_j : \Omega_j \rightarrow \mathbb{R}^l$ y $g_j : \Omega_j \rightarrow \mathbb{R}^m$.

Demuestre que la función dual $\varphi(\lambda, \mu)$ de este problema general puede descomponerse en la suma de p funciones duales independientes $\varphi(\lambda, \mu) = \sum_{j=1}^p \varphi_j(\lambda, \mu)$, donde cada componente se calcula resolviendo un subproblema local:

$$\varphi_j(\lambda, \mu) = \inf_{x_j \in \Omega_j} \{f_j(x_j) + \langle \lambda, h_j(x_j) \rangle + \langle \mu, g_j(x_j) \rangle\}.$$

Explique la importancia de esta propiedad en el desarrollo de algoritmos de optimización distribuida (descomposición dual).

Ejercicio 5.13 (Formulación de Consenso y Descomposición Dual). Considere el problema de optimización no separable con acoplamiento por la variable de decisión única x :

$$\begin{aligned} & \text{minimizar} && \sum_{i=0}^m f_i(x) \\ & \text{subject to} && x \in D_i, \quad i = 0, \dots, m \end{aligned}$$

donde $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ son funciones convexas y $D_i \subset \mathbb{R}^n$ son conjuntos poliedrales acotados tales que $\bigcap_{i=0}^m D_i \neq \emptyset$.

Para transformar este problema primal en uno con estructura separable, introducimos variables locales independientes $x_i \in \mathbb{R}^n$ para cada bloque ($i = 1, \dots, m$) junto con una variable de consenso global $x_0 \in \mathbb{R}^n$, imponiendo las restricciones de acoplamiento $x_i = x_0$:

$$\begin{aligned} & \text{minimizar}_{x_0, x_1, \dots, x_m \in \mathbb{R}^n} && \sum_{i=0}^m f_i(x_i) \\ & \text{subject to} && x_i - x_0 = 0, \quad i = 1, \dots, m, \\ & && x_i \in D_i, \quad i = 0, \dots, m \end{aligned}$$

1. Demuestre que el problema dual de Lagrange asociado a esta formulación se puede escribir de la forma:

$$\max_{\lambda_1, \dots, \lambda_m \in \mathbb{R}^n} \left\{ \varphi_0 \left(\sum_{i=1}^m \lambda_i \right) + \sum_{i=1}^m \varphi_i(\lambda_i) \right\},$$

donde las funciones duales componentes vienen dadas por:

$$\varphi_0(u) = \min_{x_0 \in D_0} \{f_0(x_0) - \langle u, x_0 \rangle\}, \quad \varphi_i(\lambda_i) = \min_{x_i \in D_i} \{f_i(x_i) + \langle \lambda_i, x_i \rangle\}, \quad i = 1, \dots, m.$$

2. Demuestre que este par de problemas satisface la dualidad fuerte, justificando la nulidad del salto de dualidad.

Parte II.

Métodos Computacionales

6. Resumen Teórico y Preliminares Matemáticos

En este capítulo recordamos varios hechos de la teoría de Optimización, tales como la existencia de soluciones, las condiciones de regularidad de las restricciones y de optimalidad, convexidad de conjuntos y de funciones, y elementos de la teoría de dualidad. El objetivo de este capítulo es facilitar las referencias futuras a lo largo del libro. Las demostraciones no serán presentadas. Se espera que el lector ya posea conocimientos sólidos de estos asuntos teóricos y que, en particular, haya leído el primer volumen [Izm20] de este libro. Presentaremos también algunos hechos auxiliares del Análisis y del Álgebra Lineal, que serán utilizados a lo largo del libro.

6.1. Existencia de soluciones

Sean dados un conjunto $D \subset \mathbb{R}^n$ y una función $f : \Omega \rightarrow \mathbb{R}$, donde $D \subset \Omega$. Este libro está dedicado a métodos computacionales para el problema de hallar un minimizador de f en el conjunto D . Este problema será escrito como

$$\min f(x) \quad \text{sujeto a } x \in D. \quad (6.1)$$

El conjunto D será llamado **conjunto factible** del problema, los puntos de D serán llamados **puntos factibles**, y f será llamada **función objetivo**.

Definición 6.1. Decimos que un punto $\bar{x} \in D$ es

- (a) **minimizador global** de (6.1), si

$$f(\bar{x}) \leq f(x) \quad \forall x \in D; \quad (6.2)$$

- (b) **minimizador local** de (6.1), si existe una vecindad U de $\bar{x}$ tal que

$$f(\bar{x}) \leq f(x) \quad \forall x \in D \cap U. \quad (6.3)$$

Si para todo $x \neq \bar{x}$ la desigualdad (6.2) o (6.3) es estricta, $\bar{x}$ será llamado minimizador estricto (global o local, respectivamente).

Definición 6.2. Decimos que $\bar{v} \in [-\infty, +\infty]$ definido por

$$\bar{v} = \inf\{f(x) \mid x \in D\}$$

es el **valor óptimo** del problema (6.1), donde entendemos que $\bar{v} = +\infty$ si $D = \emptyset$.

Una función puede admitir varios minimizadores globales, pero el valor óptimo (global) del problema, naturalmente, siempre es el mismo. Por la definición, es claro que todo minimizador global también es minimizador local, pero no recíprocamente. Cuando en la Definición 6.2 tenemos $\bar{v} = +\infty$ o $\bar{v} = -\infty$, el problema (6.1) no posee solución global. En el primer caso, el conjunto factible del problema es vacío (la existencia de soluciones es obvia). En el segundo caso, f es ilimitada inferiormente en el conjunto $D \neq \emptyset$. Pero incluso cuando $\bar{v}$ es finito, el minimizador global puede no existir (un ejemplo es minimizar $f(x) = e^x$ en $\mathbb{R}$).

Algunas de las condiciones que garantizan la existencia de solución global son las siguientes.

Teorema 6.1 (Teorema de Weierstrass). Sean $D \subset \mathbb{R}^n$ un conjunto compacto no vacío y $f : D \rightarrow \mathbb{R}$ una función continua. Entonces, el problema de minimizar f en D tiene una solución global.

| **Prueba.** Véase el Teorema 1.2 en [Izm20]. ■

Otro resultado importante se basa en la noción de conjunto de nivel de una función.

Definición 6.3. El conjunto de nivel de la función $f : D \rightarrow \mathbb{R}$ asociado a $c \in \mathbb{R}$, es el conjunto dado por

$$L_{f,D}(c) = \{x \in D \mid f(x) \leq c\}.$$

En particular, tenemos el siguiente resultado.

Corolario 6.1. Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ continua en el conjunto D . Supongamos que existe $c \in \mathbb{R}$ tal que el conjunto de nivel $L_{f,D}(c)$ sea no vacío y compacto. Entonces, el problema de minimizar f en D posee una solución global.

Prueba. Véase el Corolario 1.3 en [Izm20]. ■

Otro resultado de existencia utiliza la noción de función coercitiva.

Definición 6.4. Decimos que la función $f : D \rightarrow \mathbb{R}$ es coercitiva en el conjunto D , cuando para cada secuencia $\{x^k\} \subset D$ tal que $\|x^k\| \rightarrow \infty$ o $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$ ($k \rightarrow \infty$), se tiene que $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$.

Observamos que cuando D es cerrado, la Definición 6.4 puede ser simplificada, afirmando que $x^k \in D$ e $\|x^k\| \rightarrow \infty$ implican en $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$. Cuando D es limitado, la definición también puede ser simplificada, afirmando que cuando $x^k \in D$ e $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$, se tiene que $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$. Finalmente, cuando D es compacto, no hay secuencias con propiedades descritas arriba y, por tanto, cualquier función es coercitiva en D trivialmente.

Corolario 6.2. Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ una función continua coercitiva en D . Entonces, el problema de minimizar f en D posee una solución global.

6.2. Condiciones de optimalidad

Cuando $D = \mathbb{R}^n$, decimos que el problema (6.1) es irrestricto, y cuando $D \neq \mathbb{R}^n$ hablamos de optimización con restricciones. Presentamos a continuación las condiciones de optimalidad para el problema de minimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n. \quad (6.4)$$

Cabe notar que estos resultados son también verdaderos para un problema con restricciones siempre que el punto de interés $\bar{x}$ esté en el interior del conjunto factible, i.e., $\bar{x} \in \text{int } D$.

Teorema 6.2 (Condiciones de optimalidad en el caso irrestricto). (a) Supongamos que la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Supongamos también que $\bar{x}$ sea un minimizador local del problema (6.4). Entonces

$$f'(\bar{x}) = 0. \quad (6.5)$$

Si f es dos veces diferenciable en $\bar{x}$, entonces además de (6.5) se tiene que la matriz Hessiana de f en el punto $\bar{x}$ es semidefinida positiva, i.e.,

$$\langle f''(\bar{x})d, d \rangle \geq 0 \quad \forall d \in \mathbb{R}^n. \quad (6.6)$$

(b) Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea dos veces diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ satisface (6.5) y si la matriz Hessiana de f en $\bar{x}$ es definida positiva, i.e., si existe $\gamma > 0$ tal que

$$\langle f''(\bar{x})d, d \rangle \geq \gamma \|d\|^2 \quad \forall d \in \mathbb{R}^n, \quad (6.7)$$

entonces $\bar{x}$ es minimizador local estricto del problema (6.4).

Prueba. Véanse los Teoremas de Condiciones Irrestrictas en [Izm20] (o equivalentemente, Teoremas 1.3 a 1.5). ■

A continuación presentamos las condiciones de optimalidad para el caso de restricciones de igualdad:

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}, \quad (6.8)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ son funciones dadas. La Lagrangiana del problema (6.8) es dada por

$$L(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle = f(x) + \sum_{i=1}^l \lambda_i h_i(x).$$

Las condiciones de regularidad que serán utilizadas son:

$$\{h'_i(\bar{x}), i = 1, \dots, l\} \quad \text{es un conjunto linealmente independiente,} \quad (6.9)$$

o bien

$$h \text{ es una función afín, i.e., } h(x) = Ax - a, \text{ donde } A \in \mathbb{R}(l, n), a \in \mathbb{R}^l. \quad (6.10)$$

Bajo cualquiera de las hipótesis anteriores, tenemos el siguiente resultado.

Teorema 6.3 (Condiciones de optimalidad en el caso de restricciones de igualdad). (a) Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea diferenciable en el punto $\bar{x} \in \mathbb{R}^n$ y que $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ sea diferenciable en una vecindad de este punto, con derivada continua en $\bar{x}$. Supongamos también que $\bar{x}$ sea un minimizador local del problema (6.8). Si vale una de las condiciones de regularidad de las restricciones ((6.9) o (6.10)), entonces existe $\bar{\lambda} \in \mathbb{R}^l$ tal que

$$L'_x(\bar{x}, \bar{\lambda}) = 0. \quad (6.11)$$

Bajo la condición (6.9), el multiplicador $\bar{\lambda} \in \mathbb{R}^l$ que satisface (6.11) es único. Si f y h son dos veces diferenciables en el punto $\bar{x}$, entonces para cualquier $\bar{\lambda} \in \mathbb{R}^l$ que satisfaga (6.11) tenemos lo siguiente:

$$\langle L''_{xx}(\bar{x}, \bar{\lambda})d, d \rangle \geq 0 \quad \forall d \in \ker h'(\bar{x}). \quad (6.12)$$

(b) Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ sean dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x} \in D$ y existen $\bar{\lambda} \in \mathbb{R}^l$ satisfaciendo (6.11) y un número $\gamma > 0$ tales que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda})d, d \rangle \geq \gamma \|d\|^2 \quad \forall d \in \ker h'(\bar{x}), \quad (6.13)$$

entonces $\bar{x}$ es un minimizador local estricto del problema (6.8).

Prueba. Véanse los Teoremas sobre restricciones de igualdad en [Izm20] (o equivalentemente, Teoremas 2.4 a 2.6). ■

Finalmente, consideramos el caso más general, i.e., problemas con restricciones mixtas de igualdad y de desigualdad:

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0 \end{array} \right\}, \quad (6.14)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones dadas. La Lagrangiana del problema (6.14) está dada por

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle.$$

Definición 6.5. Sea $\bar{x} \in D$. Decimos que la restricción de desigualdad que corresponde al índice $i \in \{1, \dots, m\}$ es **activa** en el punto $\bar{x}$ cuando $g_i(\bar{x}) = 0$.

El conjunto de los índices de las restricciones activas en el punto $\bar{x} \in D$ será denotado por $I(\bar{x}) = \{i = 1, \dots, m \mid g_i(\bar{x}) = 0\}$.

Para representar las condiciones de optimalidad en forma primal-dual, precisaremos las hipótesis de regularidad de las restricciones (tales como Linealidad, Independencia Lineal LICQ, Condición de Mangasarian-Fromovitz MFCQ o Condición de Slater).

Para formular resultados de segunda orden precisaremos del llamado **cono crítico** del problema (6.14) en el punto $x \in D$:

$$K(x) = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} \langle f'(x), d \rangle \leq 0, \\ \langle g'_i(x), d \rangle \leq 0 \quad \forall i \in I(x), \\ \langle h'_i(x), d \rangle = 0, \quad i = 1, \dots, l \end{array} \right\}. \quad (6.15)$$

Teorema 6.4 (Condiciones de optimalidad en el caso de restricciones mixtas).

(a) Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferenciables en el punto $\bar{x} \in \mathbb{R}^n$, y sea $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ diferenciable en una vecindad de $\bar{x}$, con derivada continua en este punto. Supongamos que $\bar{x}$ sea un minimizador local del problema (6.14). Entonces, bajo alguna condición de regularidad, existen $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$ tales que

$$L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0, \quad (6.16)$$

$$\bar{\mu}_i g_i(\bar{x}) = 0, \quad i = 1, \dots, m. \quad (6.17)$$

Si f , h y g son dos veces diferenciables en $\bar{x}$ y satisface la condición de regularidad, entonces para los multiplicadores tenemos que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle \geq 0 \quad \forall d \in K(\bar{x}). \quad (6.18)$$

(b) Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x} \in D$ y existen $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$ satisfaciendo las condiciones (6.16) y (6.17), tales que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle \geq \gamma \|d\|^2 \quad \forall d \in K(\bar{x}), \quad (6.19)$$

donde $\gamma > 0$, entonces $\bar{x}$ es un minimizador local estricto del problema (6.14).

Prueba. Véanse los Teoremas sobre KKT y condiciones de segundo orden en [Izm20] (o Teoremas 4.5, 4.8 y 4.9). ■

La condición (6.17) se llama **condición de complementariedad**. El sistema de ecuaciones e inecuaciones que componen estas condiciones se llama **sistema de Karush-Kuhn-Tucker (KKT)**.

Cuando

$$\bar{\mu}_i > 0 \quad \forall i \in I(\bar{x}), \quad (6.20)$$

decimos que el punto estacionario $\bar{x}$ satisface la **condición de complementariedad estricta**.

Concluimos con la siguiente caracterización de compacidad del conjunto de multiplicadores de Lagrange.

Proposición 6.1. Sea $\bar{x}$ un punto estacionario del problema (6.14). El conjunto de multiplicadores es compacto si, y solamente si, la condición de regularidad de Mangasarian-Fromovitz (MFCQ) es satisfecha.

Prueba. Véase el Teorema en [Izm20] (o Proposición 4.3). ■

6.3. Convexidad

Definición 6.6. Un conjunto $D \subset \mathbb{R}^n$ es llamado **conjunto convexo** si para cualesquiera $x \in D$, $y \in D$ y $\alpha \in [0, 1]$, se tiene que $\alpha x + (1 - \alpha)y \in D$.

Una **proyección** (ortogonal) del punto $x \in \mathbb{R}^n$ sobre un conjunto $D \subset \mathbb{R}^n$ es un punto de D que está más próximo a x . En otras palabras, una proyección de x sobre D es una solución (global) del problema

$$\min \|y - x\| \quad \text{sujeto a } y \in D. \quad (6.21)$$

Teorema 6.5 (Teorema de la proyección). Si el conjunto D es cerrado y convexo, entonces para todo $x \in \mathbb{R}^n$ la proyección de x sobre D , denotada por $P_D(x)$, existe y es única. Además de eso, $\bar{x} = P_D(x)$ si, y solamente si,

$$\bar{x} \in D, \quad \langle x - \bar{x}, y - \bar{x} \rangle \leq 0 \quad \forall y \in D. \quad (6.22)$$

Prueba. Véase [Izm20] (o Corolario 1.4 sobre proyección). ■

Definición 6.7. Sea $D \subset \mathbb{R}^n$ un conjunto convexo, se dice que la función $f : D \rightarrow \mathbb{R}$ es **convexa en D** cuando para cualesquiera $x \in D$, $y \in D$ y $\alpha \in [0, 1]$, se tiene

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y).$$

Teorema 6.6 (Teorema de minimización convexa). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y $f : D \rightarrow \mathbb{R}$ una función convexa en D . Entonces todo minimizador local del problema es global. Además de eso, el conjunto de minimizadores es convexo.

Una función convexa es continua en cualquier subconjunto abierto de su dominio. Más aún, es localmente Lipschitz-continua en el interior de su dominio.

Teorema 6.7 (Continuidad de funciones convexas). Sean $\Omega \subset \mathbb{R}^n$ un conjunto convexo y abierto y $f : \Omega \rightarrow \mathbb{R}$ una función convexa en Ω . Entonces f es localmente Lipschitz-continua en Ω .

Prueba. Véase [Izm20] (o Teorema 3.16). ■

Teorema 6.8 (Compacidad de conjuntos de nivel). Supongamos que la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea fuertemente convexa en $\mathbb{R}^n$. Entonces el conjunto de nivel es compacto para todo $c \in \mathbb{R}$.

Prueba. Véase [Izm20] (o Teorema 3.17). ■

Corolario 6.3. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función fuertemente convexa y $\emptyset \neq D \subset \mathbb{R}^n$ un conjunto cerrado cualquiera. Entonces f tiene un minimizador en D y él es único.

Prueba. Véase [Izm20] (o Corolario 3.6). ■

Cuando una función es diferenciable, la convexidad admite varias caracterizaciones algebraicas.

Teorema 6.9 (Caracterizaciones de funciones convexas diferenciables). Sean $\Omega \subset \mathbb{R}^n$ un conjunto convexo y abierto y $f : \Omega \rightarrow \mathbb{R}$ una función diferenciable en Ω . Entre otras cosas, f es convexa si y solo si

$$f(y) \geq f(x) + \langle f'(x), y - x \rangle.$$

| **Prueba.** Véase [Izm20] (o Teorema 3.19). ■

Teorema 6.10 (Condiciones de optimalidad en caso convexo). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado, y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $\bar{x} \in D$. Si f es una función convexa y $\bar{x} = P_D(\bar{x} - \alpha f'(\bar{x}))$ para $\alpha > 0$, entonces $\bar{x}$ es un minimizador de f en D .

| **Prueba.** Véase [Izm20] (o Teorema 3.20). ■

Teorema 6.11. Sea $\bar{x} \in D$ un punto estacionario del problema (6.14), en el sentido de que valen las condiciones KKT. Sean f y g funciones convexas y sea h una función afín. Entonces $\bar{x}$ es un minimizador del problema (6.14).

| **Prueba.** Véase [Izm20] (o Teorema 4.6). ■

Recordamos ahora la noción de subdiferencial de una función convexa (no necesariamente diferenciable).

Definición 6.8. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Decimos que $y \in \mathbb{R}^n$ es un subgradiente de f en el punto $x \in \mathbb{R}^n$ si

$$f(z) \geq f(x) + \langle y, z - x \rangle \quad \forall z \in \mathbb{R}^n.$$

El conjunto de todos los subgradientes de f en x se llama subdiferencial de f en x ; lo denotamos por $\partial f(x)$.

Teorema 6.12 (El subdiferencial de una función convexa). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Entonces para todo $x \in \mathbb{R}^n$, el conjunto $\partial f(x)$ es convexo, compacto y no vacío. Además, $f'(x; d) = \max\{\langle y, d \rangle \mid y \in \partial f(x)\}$. El punto $\bar{x}$ es un minimizador de f en $\mathbb{R}^n$ si, y solamente si, $0 \in \partial f(\bar{x})$.

| **Prueba.** Véanse [Izm20] (o Teoremas 3.22 y 3.23). ■

Definición 6.9. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa y $\varepsilon \in \mathbb{R}_+$. Decimos que $y \in \mathbb{R}^n$ es un ε -subgradiente de f en el punto $x \in \mathbb{R}^n$ cuando

$$f(z) \geq f(x) + \langle y, z - x \rangle - \varepsilon \quad \forall z \in \mathbb{R}^n.$$

El conjunto de todos los ε -subgradientes de f en x , denotado por $\partial_\varepsilon f(x)$, se llama ε -subdiferencial de f en x .

Teorema 6.13 (El ε -subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Entonces para todo $x \in \mathbb{R}^n$ y todo $\varepsilon \in \mathbb{R}_+$, el conjunto $\partial_\varepsilon f(x)$ es convexo, compacto y no vacío.

| **Prueba.** Véase [Izm20] (o Definición 3.15). ■

6.4. Dualidad

Recordamos ahora algunos hechos de la teoría de dualidad. Consideramos un problema en formato general

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \left\{ x \in \Omega \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0 \end{array} \right\}, \quad (6.23)$$

Llamamos a (6.23) el **problema primal**. La Lagrangiana de este problema está dada por $L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle$.

El **problema dual** se obtiene intercambiando el orden de la minimización y de la maximización, lo que resulta en:

$$\max \varphi(\lambda, \mu) \quad \text{sujeto a} \quad (\lambda, \mu) \in \Delta, \quad (6.24)$$

donde $\varphi(\lambda, \mu) = \inf_{x \in \Omega} L(x, \lambda, \mu)$ es la función dual y Δ es su dominio de valores finitos.

Teorema 6.14. Para cualquier problema primal del tipo (6.23), el conjunto factible Δ del problema dual (6.24) es convexo y la función dual $\varphi : \Delta \rightarrow \mathbb{R}$ es cóncava.

| **Prueba.** Véase [Izm20] (o Teorema 5.3). ■

Teorema 6.15 (El Teorema de la dualidad débil). Para cualquier par de problemas primal y dual, se tiene que $\varphi(\lambda, \mu) \leq f(x)$ para todo $x \in D$ y todo $(\lambda, \mu) \in \Delta$.

| **Prueba.** Véase [Izm20] (o Teorema 5.4). ■

Teorema 6.16 (Teorema de la dualidad fuerte). Sean $\Omega = \mathbb{R}^n$, $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones convexas y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ una función afín. Supongamos que el problema primal satisface la condición de Slater. Si el valor óptimo de (6.23) es finito, entonces el problema dual posee una solución y no hay brecha de dualidad ($\bar{v} = \bar{w}$).

Prueba. Véase [Izm20] (o Teorema 5.7). ■

Teorema 6.17 (Teorema de Kuhn-Tucker). Bajo las hipótesis del Teorema 6.16, $\bar{x} \in D$ es una solución del problema primal (6.23) si, y solamente si, existe $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}_+^m$ tal que

$$L(\bar{x}, \bar{\lambda}, \bar{\mu}) = \min_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu}), \quad (6.25)$$

$$\bar{\mu}_i g_i(\bar{x}) = 0, \quad i = 1, \dots, m. \quad (6.26)$$

El conjunto de los pares $(\bar{\lambda}, \bar{\mu})$ satisfaciendo estas condiciones coincide con las soluciones del problema dual.

Prueba. Véase [Izm20] (o Teorema 5.6). ■

Proposición 6.2 (Subgradiente de la función dual). Sean $(\lambda, \mu) \in \Delta$ y $x(\lambda, \mu) \in \Omega$ tales que

$$L(x(\lambda, \mu), \lambda, \mu) = \varphi(\lambda, \mu) = \min_{x \in \Omega} L(x, \lambda, \mu).$$

Entonces

$$-(h(x(\lambda, \mu)), g(x(\lambda, \mu))) \in \partial(-\varphi)(\lambda, \mu).$$

Prueba. Véase [Izm20] (o Proposición 5.3). ■

6.5. Algunos resultados del Análisis y del Álgebra Lineal

En esta sección juntamos algunos resultados bien conocidos que serán utilizados a lo largo del libro y que no encuadran en las secciones anteriores.

Recordamos que en el espacio $\mathbb{R}^n$, para una norma $\|\cdot\|_p$ cualquiera, la norma dual $\|\cdot\|_D$ viene dada por

$$\|x\|_D = \sup\{\langle x, y \rangle \mid \|y\|_p = 1\}.$$

Lema 6.1 (Desigualdad de Cauchy-Schwarz generalizada). Se tiene que

$$|\langle x, y \rangle| \leq \|x\|_p \|y\|_D \quad \forall x \in \mathbb{R}^n, \forall y \in \mathbb{R}^n. \quad (6.27)$$

Prueba. Si $x = 0$ o $y = 0$, (6.27) vale trivialmente. Para todo $x \neq 0$ e $y \neq 0$ obtenemos

$$\begin{aligned} |\langle x, y \rangle| &= \|x\|_p \left| \left\langle \frac{x}{\|x\|_p}, y \right\rangle \right| \\ &\leq \|x\|_p \sup\{|\langle z, y \rangle| \mid \|z\|_p = 1\} \\ &= \|x\|_p \sup\{\langle z, y \rangle \mid \|z\|_p = 1\} \\ &= \|x\|_p \|y\|_D. \end{aligned}$$

En particular, las normas $\|\cdot\|_1$ y $\|\cdot\|_\infty$ son duales y se tiene que

$$\langle x, y \rangle \leq \|x\|_1 \|y\|_\infty \quad \forall x \in \mathbb{R}^n, \forall y \in \mathbb{R}^n.$$

El hecho siguiente, sobre perturbaciones pequeñas de una matriz no singular, también es bien conocido.

Teorema 6.18 (Teorema sobre perturbaciones pequeñas de una matriz no singular). Sea $\bar{A} \in \mathbb{R}^{n \times n}$ una matriz no singular. Entonces para toda matriz $A \in \mathbb{R}^{n \times n}$ satisfaciendo

$$\|A - \bar{A}\| < 1/\|\bar{A}^{-1}\|,$$

se tiene que la matriz A es no singular y además

$$\|A^{-1} - \bar{A}^{-1}\| \leq \frac{\|\bar{A}^{-1}\|^2 \|A - \bar{A}\|}{1 - \|\bar{A}^{-1}\| \|A - \bar{A}\|}.$$

El lema siguiente será utilizado para establecer propiedades de la Lagrangiana aumentada en § 4.4.3.

Lema 6.2 (Lema de Debreu). Sean $A \in \mathbb{R}^{l \times n}$ y $B \in \mathbb{R}^{n \times n}$ cualesquiera matrices tales que

$$\langle Bd, d \rangle > 0 \quad \forall d \in \ker A \setminus \{0\}.$$

Entonces existe $\bar{c} > 0$ tal que la matriz $B + cA^T A$ es definida positiva para todo $c \geq \bar{c}$.

Prueba. Supongamos que la afirmación no sea verdadera, i.e., que para todo $k \in \mathbb{N}$ exista $d^k \in \mathbb{R}^n \setminus \{0\}$ tal que

$$\langle (B + kA^\top A)d^k, d^k \rangle \leq 0.$$

Por lo tanto,

$$\langle Bd^k, d^k \rangle \leq \langle Bd^k, d^k \rangle + k\|Ad^k\|^2 \leq 0. \quad (6.28)$$

Sea $d \in \mathbb{R}^n$ un punto de acumulación de la secuencia $\{d^k/\|d^k\|\}$ (que es acotada). Dividiendo los dos lados en (6.28) por $k\|d^k\|^2$ y pasando al límite a lo largo de la subsecuencia correspondiente, obtenemos que $\|Ad\|^2 \leq 0$, i.e., $Ad = 0$, donde $d \neq 0$. Por otro lado, como $\langle Bd^k, d^k \rangle \leq 0$ para todo k , tenemos que $\langle Bd, d \rangle \leq 0$. Como esto contradice la hipótesis, concluimos que vale el resultado anunciado. ■

Lema 6.3 (Lema de Gronwall). Supongamos que los números $\theta_0, \theta_1, \dots, \theta_N$, a y b satisfagan

$$0 \leq \theta_0 \leq a, \quad 0 \leq \theta_{i+1} \leq a + b \sum_{j=0}^i \theta_j \quad \forall i = 0, 1, \dots, N-1.$$

Entonces

$$\theta_i \leq a(1+b)^i \quad \forall i = 0, 1, \dots, N.$$

El resultado siguiente es bien conocido.

Teorema 6.19 (Fórmula de Newton-Leibnitz). Sea $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ una función continuamente diferenciable. Entonces para todo $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^n$ se tiene que

$$F(x+y) = F(x) + \int_0^1 F'(x+ty)y \, dt.$$

La propiedad siguiente de una función con derivada Lipschitz-continua será utilizada varias veces a lo largo del libro.

Lema 6.4. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$. Entonces

$$|f(x+d) - f(x) - \langle f'(x), d \rangle| \leq \frac{L}{2} \|d\|^2 \quad \forall x, d \in \mathbb{R}^n.$$

Prueba. Por la fórmula de Newton-Leibnitz,

$$\begin{aligned} |f(x+d) - f(x) - \langle f'(x), d \rangle| &= \left| \int_0^1 \langle f'(x+td) - f'(x), d \rangle \, dt \right| \\ &\leq \int_0^1 \|f'(x+td) - f'(x)\| \|d\| \, dt \\ &\leq \int_0^1 Lt \|d\|^2 \, dt = \frac{L}{2} \|d\|^2, \end{aligned}$$

donde también utilizamos la desigualdad de Cauchy-Schwarz. ■

El siguiente es el famoso Teorema de la Función Implícita.

Teorema 6.20 (Teorema de la Función Implícita). Supongamos que $F : \mathbb{R}^s \times \mathbb{R}^n \rightarrow \mathbb{R}^n$ sea diferenciable en una vecindad del punto $(\bar{u}, \bar{x}) \in \mathbb{R}^s \times \mathbb{R}^n$, y la derivada de F en relación a x sea continua en el punto $(\bar{u}, \bar{x})$. Supongamos además que $F(\bar{u}, \bar{x}) = 0$ y que la matriz $F'_x(\bar{u}, \bar{x}) \in \mathbb{R}^{n \times n}$ sea no singular.

Entonces existen una vecindad U de $\bar{u}$ y una vecindad V de $\bar{x}$, para las cuales existe una única función $\chi : U \rightarrow \mathbb{R}^n$ tal que $\chi(U) \subset V$ y

$$F(u, \chi(u)) = 0 \quad \forall u \in U. \quad (6.29)$$

Más aún, $\chi(\bar{u}) = \bar{x}$, y si la vecindad U es suficientemente pequeña, entonces χ es diferenciable en U y

$$\chi'(u) = -(F'_x(u, \chi(u)))^{-1} F'_u(u, \chi(u)), \quad u \in U.$$

En particular, la derivada de χ es continua en el punto $\bar{u}$.

Precisaremos también de la siguiente modificación del Teorema de la Función Implícita.

Teorema 6.21 (Existencia de la función implícita). Supongamos que $F : \mathbb{R}^s \times \mathbb{R}^n \rightarrow \mathbb{R}^l$ sea diferenciable en una vecindad del punto $(\bar{u}, \bar{x}) \in \mathbb{R}^s \times \mathbb{R}^n$, y que la derivada de F en relación a x sea continua en el punto $(\bar{u}, \bar{x})$. Supongamos también que $F(\bar{u}, \bar{x}) = 0$ y $\text{rk } F'_x(\bar{u}, \bar{x}) = l$.

Entonces existen una vecindad U de $\bar{u}$, una única función $\chi : U \rightarrow \mathbb{R}^n$ y un número $M > 0$ tales que vale (6.29) y

$$\|\chi(u) - \bar{x}\| \leq M\|F(u, \bar{x})\| \quad \forall u \in U. \quad (6.30)$$

Como consecuencia del Teorema 6.21, tenemos la siguiente estimativa local para la distancia entre un punto dado y el conjunto definido por ecuaciones de igualdad.

Teorema 6.22 (Estimativa de la violación de viabilidad). Supongamos que $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ sea diferenciable en una vecindad del punto $\bar{x} \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}$. Supongamos que la derivada de h sea continua en $\bar{x}$ y que $\text{rk } h'(\bar{x}) = l$.

Entonces existen una vecindad U de $\bar{x}$ y un número $M > 0$ tales que

$$\text{dist}(x, D) \leq M\|h(x)\| \quad \forall x \in U. \quad (6.31)$$

Una generalización del Teorema 6.22, que presentamos sin probar, es la siguiente.

Teorema 6.23 (Teorema de Robinson). Sean $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en una vecindad del punto $\bar{x} \in D$,

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\},$$

con derivadas continuas en este punto. Supongamos que $\bar{x}$ satisfaga la condición de regularidad de Mangasarian-Fromovitz (??).

Entonces existen una vecindad U del punto $\bar{x}$ y un número $M > 0$ tales que

$$\text{dist}(x, D) \leq M\|\Psi(x)\| \quad \forall x \in U, \quad (6.32)$$

donde

$$\Psi : \mathbb{R}^n \rightarrow \mathbb{R}^l \times \mathbb{R}^m, \quad \Psi(x) = (h(x), (\max\{0, g_1(x)\}, \dots, \max\{0, g_m(x)\})).$$

6.6. Elementos del Análisis no diferenciable

En este libro, nuestro interés en funciones no convexas y no diferenciables se debe principalmente al hecho de que las condiciones de complementariedad que aparecen en las condiciones de optimalidad en forma primal-dual para problemas con restricciones mixtas poseen una naturaleza esencialmente no diferenciable, incluso cuando las funciones involucradas en el problema son diferenciables.

Como ya fue mencionado en la apartado 6.2, la condición de complementariedad nos dice que todos los multiplicadores de Lagrange asociados a las restricciones inactivas en un punto estacionario $\bar{x}$ del problema (6.14) tienen que ser nulos:

$$\bar{\mu}_i = 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}),$$

donde $I(\bar{x}) = \{i = 1, \dots, m \mid g_i(\bar{x}) = 0\}$. Como los multiplicadores de Lagrange son también no negativos y el punto $\bar{x}$ es factible, equivalentemente esto puede ser escrito como

$$g_i(\bar{x}) \leq 0, \quad \bar{\mu}_i \geq 0, \quad \bar{\mu}_i g_i(\bar{x}) = 0, \quad i = 1, \dots, m. \quad (6.33)$$

O también, como

$$\min\{-g_i(\bar{x}), \bar{\mu}_i\} = 0, \quad i = 1, \dots, m.$$

Como es obvio, el sistema de ecuaciones

$$\min\{-g_i(\bar{x}), \bar{\mu}_i\} = 0, \quad i = 1, \dots, m, \quad (6.34)$$

con respecto a $(x, \mu) \in \mathbb{R}^n \times \mathbb{R}^m$ no es diferenciable en puntos (x, μ) para los cuales

$$J^0(x, \mu) = \{i = 1, \dots, m \mid g_i(x) = \mu_i\} \neq \emptyset.$$

En particular, este sistema no es diferenciable en la solución primal-dual $(\bar{x}, \bar{\mu})$ cuando la condición de complementariedad estricta no es satisfecha (i.e., $\bar{\mu}_i = 0$ para algún $i \in I(\bar{x})$).

Existen también otras maneras de reformular la condición de complementariedad (6.33), diferentes a (6.34). Para este fin, la siguiente noción es útil. Decimos que $\psi : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$ es una **función de complementariedad** si

$$\psi(a, b) = 0 \iff a \geq 0, b \geq 0, ab = 0.$$

Una función con esta propiedad ya fue utilizada arriba:

$$\psi(a, b) = \min\{a, b\}, \quad a, b \in \mathbb{R}.$$

Esta función se llama de *residuo natural*. Otra elección popular es la función de Fischer-Burmeister, dada por

$$\psi(a, b) = \sqrt{a^2 + b^2} - a - b, \quad a, b \in \mathbb{R}.$$

Algunas otras posibilidades serán mencionadas en la apartado 10.5.

Notemos que las funciones de complementariedad anteriores son no diferenciables. Es justamente por eso que estamos presentando algunos hechos (bien básicos) del Análisis no diferenciable. Como estos conocimientos serán necesarios solamente en la apartado 10.5, la presentación será breve. Los detalles pueden ser consultados en la bibliografía [6].

Teorema 6.24 (Teorema de Rademacher). Sea $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ una función Lipschitz-continua en un conjunto abierto $V \subset \mathbb{R}^n$. Sea D_F el conjunto de todos los puntos donde F es diferenciable. Entonces la medida de Lebesgue del conjunto $V \setminus D_F$ es nula.

La importancia del Teorema de Rademacher consiste en permitir generalizaciones bien útiles de la derivada clásica para funciones que no son diferenciables. Llamamos **B-diferencial** de la función $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ en el punto $x \in \mathbb{R}^n$ al conjunto

$$\partial_B F(x) = \left\{ H \in \mathbb{R}(l, n) \mid \begin{array}{l} \exists \{x^k\} \subset D_F : \{x^k\} \rightarrow x, \\ \{F'(x^k)\} \rightarrow H \ (k \rightarrow \infty) \end{array} \right\}.$$

El **diferencial de Clarke** de la función F en el punto x es el conjunto

$$\partial F(x) = \text{conv } \partial_B F(x),$$

i.e., la envoltura convexa del B-diferencial de F en x . Cabe mencionar que para una función convexa $f : \mathbb{R}^n \rightarrow \mathbb{R}$, el subdiferencial ∂f definido en la apartado 6.3 es el mismo conjunto que el diferencial de Clarke definido arriba para $F = f$.

Es importante resaltar que, para ser de utilidad práctica, una generalización de derivada debe permitir el cálculo explícito, por lo menos en algunas aplicaciones de interés. Esto no siempre es el caso para varias otras nociones de derivadas generalizadas en la literatura. Felizmente, en el caso del B-diferencial y del diferencial de Clarke, estos conjuntos (o, por lo menos, elementos de estos conjuntos) pueden ser calculados en varias aplicaciones de la Optimización (e.g., véase la apartado 10.5) y áreas afines.

Primero, notemos algunas propiedades que son fáciles de verificar. Para la función

$$F : \mathbb{R}^n \rightarrow \mathbb{R}^{l_1} \times \mathbb{R}^{l_2}, \quad F(x) = (F_1(x), F_2(x)),$$

vale la inclusión

$$\partial_B F(x) \subset \partial_B F_1(x) \times \partial_B F_2(x), \quad \forall x \in \mathbb{R}^n.$$

Además de eso, si F_1 es diferenciable en una vecindad del punto x , se tiene que $\{F'_1(x)\} \times \partial_B F_2(x) \subset \partial_B F(x)$, y si la derivada de F_1 es continua en x , entonces la última inclusión vale como igualdad. Teniendo en vista la reformulación de complementariedad (6.34), el resultado siguiente es importante para nuestros desarrollos futuros.

Teorema 6.25. Sean $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ funciones diferenciables en $\mathbb{R}^n$, $i = 1, \dots, s$, y para todo $x \in \mathbb{R}^n$,

$$f(x) = \min_{i=1, \dots, s} f_i(x).$$

Sea

$$I(x) = \{i = 1, \dots, s \mid f_i(x) = f(x)\}.$$

Entonces para todo $x \in \mathbb{R}^n$ tal que la derivada de f_i es continua en x para cada $i \in I(x)$, se tiene que

$$\partial_B f(x) \subset \{f'_i(x) \mid i \in I(x)\}.$$

Más aún, esta inclusión vale como igualdad si para cada índice $i \in I(x)$ existe una secuencia $\{x^{i,k}\}$ que converge a x y satisface $I(x^{i,k}) = \{i\}$ para todo k .

El diferencial de Clarke es utilizado para definir la propiedad siguiente, que es fundamental en el contexto del método de Newton generalizado, adecuado para resolver sistemas de ecuaciones no diferenciables. Decimos que la función $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ satisface en el punto $x \in \mathbb{R}^n$ la **condición de Kummer**, si

$$\sup_{H \in \partial F(x+d)} \|F(x+d) - F(x) - Hd\| = o(\|d\|), \quad (6.35)$$

y la **condición de Kummer fuerte**, si

$$\sup_{H \in \partial F(x+d)} \|F(x+d) - F(x) - Hd\| = O(\|d\|^2). \quad (6.36)$$

Otras nociones importantes de diferenciabilidad generalizada están basadas en la diferenciabilidad direccional clásica. Recordamos que una función $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es diferenciable en $x \in \mathbb{R}^n$ en la dirección $d \in \mathbb{R}^n$, si el límite $\lim_{t \rightarrow 0+} (F(x+td) - F(x))/t$ existe y es finito. En este caso, el límite arriba es denotado por $F'(x; d)$ y es llamado **derivada direccional de la función F en el punto x en la dirección d** . Naturalmente, si la función F es diferenciable en el punto x , ella es diferenciable en este punto en cada dirección, y se tiene que $F'(x; d) = F'(x)d$ para todo $d \in \mathbb{R}^n$.

Teorema 6.26. Sea $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ una función Lipschitz-continua en una vecindad del punto $x \in \mathbb{R}^n$, diferenciable en este punto en cada dirección. Entonces

(a) La función positivamente homogénea

$$d \mapsto F'(x; d) : \mathbb{R}^n \rightarrow \mathbb{R}^l$$

es Lipschitz-continua en $\mathbb{R}^n$.

(b) Para todo $d \in \mathbb{R}^n$ existe una matriz $H \in \partial_B F(x)$ tal que $F'(x; d) = Hd$.

(c) F es B-diferenciable en el punto x , i.e.,

$$F(x+d) - F(x) - F'(x; d) = o(\|d\|).$$

La noción que unifica la Lipschitz-continuidad en una vecindad de un punto dado, la condición de Kummer (fuerte) y la diferenciabilidad en cada dirección es la propiedad de **semi-diferenciabilidad**. Decimos que una función $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$, que posee en el punto $x \in \mathbb{R}^n$ las tres propiedades arriba mencionadas, es **(fuertemente) semi-diferenciable** en este punto. La utilidad de esta noción se debe al hecho de que, con frecuencia, las tres propiedades valen al mismo tiempo. A propósito, existen varias definiciones de semi-diferenciabilidad.

Teorema 6.27. Sea $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ una función Lipschitz-continua en una vecindad del punto $x \in \mathbb{R}^n$. Entonces ella es semi-diferenciable en x si, y solamente si, para todo $d \in \mathbb{R}^n$ existe el límite finito $\lim_{\xi \rightarrow d, t \rightarrow 0+} H\xi$ que no depende de la elección de $H \in \partial F(x+t\xi)$. En este caso, el límite arriba es la derivada direccional $F'(x; d)$.

Teorema 6.28. Sea $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ una función Lipschitz-continua en una vecindad del punto $x \in \mathbb{R}^n$, diferenciable en este punto en cada dirección. Entonces F satisface en x la condición de Kummer si, y solamente si,

$$\sup_{H \in \partial F(x+d)} \|Hd - F'(x; d)\| = o(\|d\|),$$

y F satisface en x la condición de Kummer fuerte si, y solamente si,

$$\sup_{H \in \partial F(x+d)} \|Hd - F'(x; d)\| = O(\|d\|^2).$$

A partir del Teorema del Valor Medio, es fácil probar que una función diferenciable con derivada continua en un punto dado es semi-diferenciable en este punto. Si, además de eso, la derivada de la función en cuestión es Lipschitz-continua en una vecindad del punto, entonces la función es fuertemente semi-diferenciable.

Para finalizar, presentamos una estimativa para la distancia a la solución de la ecuación

$$\Phi(x) = 0,$$

que será utilizada en la ???. Suponiendo que $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ sea diferenciable en el punto $\bar{x} \in \mathbb{R}^n$ en cada dirección, decimos que Φ satisface la R_0 -condición si

$$\{d \in \mathbb{R}^n \mid \Phi'(\bar{x}; d) = 0\} = \{0\}.$$

Notemos que, por la afirmación (b) del Ejercicio 6.4, si Φ además de ser diferenciable en cada dirección también es Lipschitz-continua en una vecindad de $\bar{x}$, entonces una BD -regularidad de Φ en $\bar{x}$ (i.e., la no singularidad de todo elemento de $\partial_B \Phi(\bar{x})$) implica la R_0 -condición en este punto.

Teorema 6.29. Sea $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ una función Lipschitz-continua con módulo $L > 0$ en una vecindad del punto $\bar{x} \in \mathbb{R}^n$ tal que $\Phi(\bar{x}) = 0$. Sea Φ diferenciable en este punto en cada dirección. Entonces Φ satisface en $\bar{x}$ la R_0 -condición si, y solamente si, existen una vecindad U del punto $\bar{x}$ en $\mathbb{R}^n$ y un número $M > 0$ tales que

$$\|x - \bar{x}\| \leq M\|\Phi(x)\| \quad \forall x \in U.$$

Prueba. Supongamos que Φ satisface en $\bar{x}$ la R_0 -condición, pero que exista una secuencia $\{x^k\} \subset \mathbb{R}^n$ tal que $\{x^k\} \rightarrow \bar{x}$ ($k \rightarrow \infty$), $x^k \neq \bar{x} \forall k$, y

$$\frac{\|\Phi(x^k)\|}{\|x^k - \bar{x}\|} \rightarrow 0 \quad (k \rightarrow \infty).$$

Para todo k , definimos $d^k = (x^k - \bar{x})/\|x^k - \bar{x}\|$, $t_k = \|x^k - \bar{x}\|$. Podemos admitir, sin pérdida de generalidad, que la secuencia $\{d^k\}$ converge a un cierto $d \in \mathbb{R}^n$, $\|d\| = 1$. Entonces, para todo k ,

$$\begin{aligned} \frac{\|\Phi(\bar{x} + t_k d)\|}{t_k} &\leq \frac{\|\Phi(\bar{x} + t_k d) - \Phi(\bar{x} + t_k d^k)\|}{t_k} + \frac{\|\Phi(\bar{x} + t_k d^k)\|}{t_k} \\ &\leq L\|d^k - d\| + \frac{\|\Phi(x^k)\|}{\|x^k - \bar{x}\|} \rightarrow 0 \quad (k \rightarrow \infty), \end{aligned}$$

de donde se sigue $\Phi'(\bar{x}; d) = 0$, en contradicción con la R_0 -condición.

Para probar la afirmación recíproca, consideremos cualquier $d \in \mathbb{R}^n$ tal que $\Phi'(\bar{x}; d) = 0$. Si existen una vecindad U del punto $\bar{x}$ y un número $M > 0$ con las propiedades de arriba, entonces para todo $t > 0$ suficientemente pequeño tenemos

$$\begin{aligned} t\|d\| &= \|\bar{x} + td - \bar{x}\| \\ &\leq M\|\Phi(\bar{x} + td)\| \\ &= M\|\Phi(\bar{x} + td) - \Phi(\bar{x})\| \\ &= M\|t\Phi'(\bar{x}; d)\| + o(t) = o(t), \end{aligned}$$

lo que solo puede valer para $d = 0$. ■

Ejercicios del Capítulo

Ejercicio 6.1. Probar el Lema 6.3 utilizando la técnica de inducción.

Ejercicio 6.2. Probar que si $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es Lipschitz-continua con módulo $L > 0$ en una vecindad del punto $x \in \mathbb{R}^n$, entonces $\partial F(x)$ es un conjunto compacto no vacío y $\|H\| \leq L \forall H \in \partial F(x)$.

Ejercicio 6.3. Probar que si la función $F : \mathbb{R}^n \rightarrow \mathbb{R}$ es convexa en una vecindad (convexa) del punto $x \in \mathbb{R}^n$, entonces F es semi-diferenciable en el punto x .

Ejercicio 6.4. Probar que si las funciones $F_1, F_2 : \mathbb{R}^n \rightarrow \mathbb{R}^l$ son semi-diferenciables en el punto $x \in \mathbb{R}^n$, entonces las funciones definidas a continuación también son semi-diferenciables en x :

- (a) $F : \mathbb{R}^n \rightarrow \mathbb{R}, F(x) = \langle F_1(x), F_2(x) \rangle$.
- (b) $F : \mathbb{R}^n \rightarrow \mathbb{R}^l, F(x) = F_1(x) + F_2(x)$.
- (c) $F : \mathbb{R}^n \rightarrow \mathbb{R}^l, F_i(x) = \max\{(F_1(x))_i, (F_2(x))_i\}, i = 1, \dots, l$.
- (d) $F : \mathbb{R}^n \rightarrow \mathbb{R}^l, F_i(x) = \min\{(F_1(x))_i, (F_2(x))_i\}, i = 1, \dots, l$.

Ejercicio 6.5. Probar que si las funciones $F_1 : \mathbb{R}^n \rightarrow \mathbb{R}^{l_1}$ y $F_2 : \mathbb{R}^n \rightarrow \mathbb{R}^{l_2}$ son semi-diferenciables en el punto $x \in \mathbb{R}^n$, entonces la función $F : \mathbb{R}^n \rightarrow \mathbb{R}^{l_1} \times \mathbb{R}^{l_2}, F(x) = (F_1(x), F_2(x))$, es semi-diferenciable en x .

Ejercicio 6.6. Probar que si la función $F_1 : \mathbb{R}^n \rightarrow \mathbb{R}^{l_1}$ es semi-diferenciable en el punto $x \in \mathbb{R}^n$, y la función $F_2 : \mathbb{R}^{l_1} \rightarrow \mathbb{R}^{l_2}$ es semi-diferenciable en el punto $F_1(x)$, entonces la función $F : \mathbb{R}^n \rightarrow \mathbb{R}^{l_2}$, $F(x) = F_2(F_1(x))$ es semi-diferenciable en x .

7. Introducción a los Métodos de Optimización

El objetivo de este capítulo es presentar algunas nociones básicas sobre métodos (algoritmos) de Optimización en general. Serán mencionadas las diferentes clases de métodos y los principales problemas relacionados con la utilización y el análisis teórico de los mismos. También hablaremos sobre métodos para la resolución de problemas unidimensionales. Con frecuencia, los métodos de esta clase sirven como base para el desarrollo de algoritmos para problemas más complejos.

7.1. Clasificación de los métodos. Nociones de convergencia

Sea el problema dado en formato general

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \left\{ x \in \Omega \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0 \end{array} \right\}, \quad (7.1)$$

donde $\Omega \subset \mathbb{R}^n$, $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$.

Todo método para la resolución numérica del problema (7.1) hace uso del cálculo de valores de la función objetivo y de las restricciones, así como (típicamente) de las derivadas de estas funciones. Hablamos de un **método pasivo**, cuando los puntos de evaluación de estos valores son elegidos de acuerdo con una estrategia definida a priori, sin tener en cuenta la información obtenida a lo largo del proceso iterativo. Hablamos de un **método secuencial**, cuando cada punto se define de acuerdo con la información obtenida en los puntos anteriores. Naturalmente, los métodos de esta segunda clase, generalmente, son mucho más eficientes. La gran mayoría de los métodos computacionales son de este tipo.

Un método secuencial genera una secuencia de puntos en $\mathbb{R}^n$, $x^1, \dots, x^k, \dots$, que serán llamados **aproximaciones** a la solución del problema o, también, **iterados** del método. Esta secuencia $\{x^k\}$ (también llamada *trayectoria*) puede no contener todos los puntos en los que se calculan valores de funciones y derivadas, i.e., puede contener solo puntos especialmente seleccionados. La generación de una nueva aproximación x^{k+1} a partir de x^k se llama **iteración** del método. Los detalles concretos de este proceso constituyen la esencia (naturaleza) del método. Con frecuencia, los algoritmos son descritos en formato de un esquema iterativo, como

$$x^{k+1} = \Psi_k(x^k), \quad k = 0, 1, \dots, \quad (7.2)$$

donde Ψ_k es un operador con valores en $\mathbb{R}^n$, definido en un conjunto $U_k \subset \mathbb{R}^n$. Naturalmente, suponemos que en la iteración $k + 1$ este operador es conocido. Si el esquema iterativo está fijado, la elección del punto inicial $x^0 \in U_0$ define sin ambigüedad una única trayectoria del método si, y solamente si,

$$\Psi_{k-1}(\Psi_{k-2}(\dots \Psi_0(x^0) \dots)) \in U_k \quad \forall k = 1, 2, \dots$$

El esquema (7.2) considerado arriba es del tipo *sin memoria*. Existen también esquemas *con memoria*, donde Ψ_k depende no solamente de x^k , sino también de otros puntos anteriores (no necesariamente todos).

El **orden del método** es el máximo orden de derivadas de la función objetivo y de las restricciones que están siendo utilizadas en la realización de una iteración. Por ejemplo, cuando un método está basado apenas en los valores de las funciones (sin hacer uso de derivadas), hablamos de método de *orden cero*. Si están siendo utilizadas las derivadas primeras (segundas, etc.), el método es de *primer (segundo, etc.) orden*.

Cuando cualquier punto inicial $x^0 \in U_0$ define una trayectoria tal que x^k es una solución del problema para algún k finito, hablamos de un método con **convergencia finita**. Algoritmos con esta propiedad existen para problemas

relativamente simples, tales como la programación lineal y programación cuadrática (Capítulo 6). Para problemas de optimización con estructura más general, tenemos que apelar a métodos con **convergencia asintótica**. En estos casos, no hay cómo garantizar que un elemento x^k de la trayectoria sea una solución exacta del problema. La tarea, por lo tanto, es probar que para k suficientemente grande, x^k es una buena aproximación de la solución (en algún sentido). Dependiendo de la naturaleza de esta aproximación, hablamos de diferentes tipos de convergencia. Por ejemplo, si

$$\{x^k\} \rightarrow \bar{x} \quad (k \rightarrow \infty),$$

donde $\bar{x}$ es una solución del problema, hablamos de convergencia en relación a las variables del problema (o, simplemente, de **convergencia**) del método a partir del punto inicial x^0 . Con frecuencia, no es posible probar convergencia a una solución específica, sino apenas a una propiedad más débil:

$$\text{dist}(x^k, S) \rightarrow 0 \quad (k \rightarrow \infty),$$

donde S es el conjunto de soluciones del problema. En estos casos, hablamos de convergencia al conjunto de soluciones. Cuando el conjunto S es compacto, esta propiedad es equivalente a la existencia de puntos de acumulación de $\{x^k\}$, siendo que todo punto de acumulación de esta secuencia es solución del problema (cuando S es ilimitado, en principio es posible que $\{x^k\}$ con la propiedad de arriba no posea puntos de acumulación). Cuando

$$\text{dist}(x^k, D) \rightarrow 0, \quad f(x^k) \rightarrow \bar{v} \quad (k \rightarrow \infty),$$

donde $\bar{v}$ es el valor óptimo del problema, hablamos de **convergencia en relación a la función objetivo**. Es claro que esto no significa que la trayectoria $\{x^k\}$ del método converja.

Con gran frecuencia, probar convergencia al conjunto de soluciones del problema no es posible y lo mejor que puede hacerse es probar convergencia al conjunto de puntos estacionarios (o también, convergencia a cero de alguna medida de violación de condiciones necesarias de optimalidad). Por ejemplo, para el problema irrestricto, cuando vale

$$\{f'(x^k)\} \rightarrow 0 \quad (k \rightarrow \infty),$$

hablamos de **convergencia en relación al gradiente**. Un resultado típico para métodos de optimización irrestricta afirma que todo punto de acumulación de $\{x^k\}$ es estacionario.

Finalmente, cuando $U_0 = \mathbb{R}^n$ y tenemos convergencia a partir de cualquier $x^0 \in \mathbb{R}^n$, hablamos de **convergencia global**. Cuando algún tipo de convergencia puede ser garantizado solamente a partir de puntos suficientemente próximos a una solución (o un punto estacionario), hablamos de **convergencia local** del método. En principio, todo método con convergencia local debe ser pensado en combinación con algún otro método capaz de proveer un punto inicial x^0 que sea adecuado para una aplicación exitosa del método local (*globalización de la convergencia*).

Con frecuencia, una estrategia de resolución de un problema relativamente difícil está basada en la reducción de este problema a una secuencia (finita o infinita) de problemas más simples. Es claro que esto solo tiene sentido cuando existen métodos eficientes para la resolución de cada problema simple (es decir, la medida de simplicidad debe ser computacional). Por ejemplo, el método clásico de Newton reduce la solución de un sistema de ecuaciones no lineales a la resolución de una secuencia de ecuaciones lineales (que se resuelven con herramientas bien desarrolladas del Álgebra Lineal Computacional). De manera análoga, muchos métodos de Optimización utilizan resolución (aproximada) de problemas unidimensionales, de problemas irrestrictos, de problemas lineales o cuadráticos. Más aún, métodos para problemas irrestrictos utilizan, con frecuencia, métodos para problemas unidimensionales, así como métodos para programación cuadrática utilizan aquellos para programación lineal. Por lo tanto, el desarrollo de métodos para problemas más complejos requiere un estudio previo de métodos para problemas más básicos. Por otro lado, dada la existencia de herramientas para estos problemas básicos, es natural no especificar cómo los subproblemas serán resueltos dentro de un algoritmo general y tratar esto como la parte exterior al algoritmo.

7.2. Tasas de convergencia. Reglas de parada

Para el análisis y evaluación de métodos con convergencia asintótica, la cuestión de la **tasa de convergencia** es una de las más importantes. La tasa de convergencia es uno de los principales indicadores de eficiencia de un método iterativo. En esta sección, hablaremos sobre la convergencia en relación a las variables del problema. Para cualquier otro tipo de convergencia, la definición de tasa es completamente análoga.

Supongamos que un método dado sea convergente (tal vez localmente) a una solución $\bar{x}$, i.e., $\{x^k\} \rightarrow \bar{x}$ ($k \rightarrow \infty$). Resultados sobre la tasa de convergencia proporcionan una garantía de velocidad en la reducción de la distancia $\|x^{k+1} - \bar{x}\|$ en relación a $\|x^k - \bar{x}\|$, cuando k es suficientemente grande. En esta exposición suponemos que $x^0 \in \mathbb{R}^n$ es suficientemente próximo a $\bar{x}$, que $x^k \neq \bar{x}$ para todo k , y que todos los números constantes a continuación no dependen de x^0 . Si existe $q \in (0, 1)$ tal que

$$\limsup_{k \rightarrow \infty} \frac{\|x^{k+1} - \bar{x}\|}{\|x^k - \bar{x}\|} = q,$$

decimos que el método posee **convergencia lineal**. Cuando en la relación anterior $q = 0$, hablamos de **convergencia superlineal**. La convergencia más lenta que la lineal es llamada **sublineal**. Un caso especial de convergencia superlineal es la **convergencia cuadrática**:

$$\limsup_{k \rightarrow \infty} \frac{\|x^{k+1} - \bar{x}\|}{\|x^k - \bar{x}\|^2} \leq C,$$

donde $C > 0$ es una constante fija.

Cabe mencionar que la convergencia cuadrática de la secuencia $\{x^k\} \subset \mathbb{R}^n$ a un punto $\bar{x}$, en principio no implica la convergencia cuadrática (ni superlineal) de las secuencias $\{x_i^k\}$ a $\bar{x}_i$, $i = 1, \dots, n$.

Ejemplo 7.1. Consideremos la secuencia $\{x^k\} \subset \mathbb{R}^2$ generada de la siguiente manera. Sea $x_1^1 \in (0, 1)$. Para todo k , tomamos $x_2^{k+1} = (x_2^k)^2$. Para k impar tomamos $x_1^{k+1} = x_1^k$, y para k par tomamos $x_1^{k+1} = (x_1^{k+1})^2$.

Como puede ser verificado, la secuencia $\{x^k\}$ converge a $(0, 0)$ con tasa cuadrática, pero la convergencia de $\{x_1^k\}$ a 0 no posee ni tasa lineal.

Un ejemplo de propiedad que garantiza apenas tasa sublineal es la siguiente desigualdad:

$$\limsup_{k \rightarrow \infty} k \|x^k - \bar{x}\| \leq C.$$

En este caso, hablamos de **convergencia aritmética**. Cuando

$$\limsup_{k \rightarrow \infty} \frac{\|x^k - \bar{x}\|}{q^k} \leq C,$$

donde $q \in (0, 1)$, hablamos de **convergencia geométrica**. Es obvio que la tasa lineal implica convergencia geométrica, pero no recíprocamente. Más informaciones sobre diferentes estimativas y tasas de convergencia pueden ser encontradas en la literatura.

Las estimativas de tasa de convergencia proporcionan información útil para la comparación cualitativa de métodos diferentes. Sin embargo, es importante resaltar que la tasa de convergencia no es la única característica relevante en este sentido. Por ejemplo, es indispensable tener en cuenta el costo computacional de una iteración. Un método con tasa más rápida puede ser más lento en la práctica (i.e., llevar más tiempo computacional para resolver un problema dado), si el costo de iteración del mismo es más alto. Otra propiedad importante de un método es la *estabilidad*, i.e., la capacidad de lidiar con una situación cuando los datos de un problema son proporcionados con errores (son inexactos, perturbados). A veces, también puede ser importante que la secuencia generada sea factible (i.e., que $x^k \in D$ para todo k). Por ejemplo, en varias aplicaciones prácticas la función f y/o las restricciones h y g pueden estar bien definidas solamente para puntos factibles. Naturalmente, en estos casos la elección para resolver el problema debe ser algún método que, en cada iteración, produzca puntos factibles.

Aunque un método sea de convergencia asintótica, en la práctica ningún proceso computacional puede ser infinito. Por eso, cualquier método razonable precisa de una **regla de parada**. Las reglas de parada más confiables están basadas justamente en estimativas de tasa de convergencia y en otras propiedades relacionadas (por ejemplo, estimativas de la distancia al conjunto de soluciones). Cuando la tasa de convergencia es conocida, esta puede ser usada para estimar el número de iteraciones necesarias para aproximar una solución con la precisión dada. Sin embargo, la cuestión no es simple. Primero, en la mayoría de los casos, las tasas de convergencia tienen una naturaleza local, y la cuantificación del número de iteraciones para conseguir un punto a partir del cual comienza a valer esta tasa no es posible. Segundo, las estimativas de tasa de convergencia casi siempre contienen algunas constantes con valores no conocidos (tales como q y C arriba). En este sentido, la aplicación práctica de tasas de convergencia para la definición de reglas de parada en términos del número de iteraciones es bastante limitada.

En la práctica computacional, típicamente se utilizan reglas de parada menos confiables desde el punto de vista teórico, pero que pueden ser fácilmente implementadas. Estas reglas están basadas en la información obtenida en el

punto x^k y, tal vez, algunos puntos anteriores. Se examina el comportamiento de la parte más reciente de la secuencia $\{x^k\}$ y/o de la secuencia $\{f(x^k)\}$ y/o de alguna medida de violación de condiciones de optimalidad. Por ejemplo, fijando un número pequeño $\varepsilon > 0$, el método es parado después de la iteración indexada por $(k + 1)$ si

$$\|x^{k+1} - x^k\| \leq \varepsilon.$$

O sea, cuando el paso del método se vuelve corto y creemos que ya no es posible mejorar la calidad de aproximación a una solución de manera significativa. Otra regla de parada, que es de cierto modo análoga, es

$$|f(x^{k+1}) - f(x^k)| \leq \varepsilon.$$

En el caso de un problema irrestricto con una función objetivo f diferenciable, una regla de parada utilizada con frecuencia está dada por

$$\|f'(x^{k+1})\| \leq \varepsilon.$$

No obstante, es muy claro que reglas de parada de este tipo no pueden ser completamente confiables — en general, ellas no garantizan la proximidad del iterado x^{k+1} a una solución del problema en ningún sentido. Por ejemplo, el hecho de que la secuencia generada satisfaga $\lim_{k \rightarrow \infty} \|x^{k+1} - x^k\| = 0$ no implica la convergencia de $\{x^k\}$ (basta considerar $\{x^k\} \subset \mathbb{R}$, $x^k = \sqrt{k}$, o $x^k = \sin \sqrt{k}$, $k = 0, 1, \dots$). Aun así, las reglas de parada mencionadas arriba son típicas en métodos computacionales, simplemente porque alternativas mejores no existen.

Además de lo que fue mencionado, el número de iteraciones puede (y debe) depender de las posibilidades computacionales disponibles. En la práctica, para problemas difíciles de gran porte, incluso cuando ninguna regla de parada deseada está satisfecha, el método tiene que ser parado de todas formas, por agotamiento del tiempo disponible. O sea, una de las reglas de parada implícita es el número máximo de iteraciones que pueden ser realizadas, o el número máximo de evaluaciones de las funciones, etc. Naturalmente, en esos casos la aproximación obtenida puede no tener nada que ver con la solución del problema, pero es lo mejor que se podría hacer con las herramientas disponibles.

En general, se debe utilizar alguna combinación de varias reglas de parada, ordenadas en una jerarquía. La definición de esta jerarquía y de varios parámetros involucrados es una cuestión de arte y de la experiencia computacional, más que de la ciencia exacta. Es por eso que nos limitamos a los comentarios genéricos.

Haremos el siguiente comentario sobre convergencia global y convergencia local de métodos. Típicamente, los métodos con convergencia global son más lentos que los métodos locales. Esto es natural, porque los métodos locales hacen un mejor uso de la estructura (local) del problema en torno a la solución. Por eso, una estrategia razonable sería la de utilizar un método local en combinación con un método que posea convergencia global. El papel de este último es justamente el de proporcionar un punto inicial adecuado para el primero que, a partir de este punto, debe converger a la solución con una tasa rápida. En este método “combinado” es muy deseable que el paso del método global al local sea automático. Así se construye un método completo para la resolución de problemas. Un típico resultado de convergencia para un método “combinado” es el siguiente: el método tiene convergencia global en algún sentido (digamos, convergencia en relación a las variables del problema al conjunto de puntos estacionarios), y si la trayectoria del método entra en una vecindad de un punto estacionario con ciertas propiedades deseadas, la secuencia converge a este punto con tasa rápida (digamos, superlineal). Algunas estrategias de globalización de métodos locales serán presentadas en secciones posteriores (§3.3, 4.6.3).

En relación al problema de hallar una solución global (en el caso no convexo), cabe subrayar que este problema es mucho más complejo que el de hallar un punto estacionario o una solución local. Los métodos para optimización global están mucho menos desarrollados, principalmente en su parte teórica (i.e., en general ellos no admiten un análisis matemático riguroso). No hay duda de que la optimización global es un asunto importante para varias aplicaciones, pero ella no forma parte de este libro. El método más obvio de optimización global consiste en definir una red suficientemente fina en el conjunto factible D , y comparar los valores de f en todos los puntos de la red. Así puede ser obtenida una aproximación a la solución global, cuya calidad depende de la densidad de la red. Es claro que un procedimiento así solo puede ser práctico cuando D tiene una estructura bien simple y cuando la dimensión del espacio n es bastante pequeña (a continuación presentamos este método para problemas unidimensionales). Métodos de optimización global más eficientes utilizan optimización local, lo que permite reducir el costo de verificación pasiva de todos los puntos de la red. Un ejemplo de esto es el método de “multi-arranque” (*multi-start*), donde un método local es iniciado a partir de cada punto de una red gruesa. El resultado es obtenido comparando los valores de f en todas las soluciones locales y todos los puntos estacionarios encontrados. Por tanto, los métodos locales desarrollados

en este libro son componentes importantes también para métodos de optimización global. Más informaciones sobre optimización global deben ser buscadas en la literatura especializada.

Para finalizar, resaltamos que en este libro, hablando de un método global, nosotros pensamos en un método con convergencia global, i.e., capaz de encontrar un punto estacionario o una solución local a partir de un punto inicial cualquiera, y no en un método capaz de encontrar una solución global (que, en general, es una tarea imposible).

7.3. Métodos de optimización unidimensional

A continuación, presentamos algunos métodos básicos para resolver el problema

$$\min f(x) \quad \text{sujeto a} \quad x \in [a, b], \quad (7.3)$$

donde $a, b \in \mathbb{R}$, $a < b$, $f: [a, b] \rightarrow \mathbb{R}$. Todos estos métodos son de orden cero (i.e., no utilizan derivadas de f). El primer método es pasivo y no es muy eficiente. Los otros tres métodos son secuenciales y relativamente eficientes. Ellos permiten aproximar una solución global del problema (y, como consecuencia, también el valor óptimo), pero se aplican a una clase de funciones de estructura más específica. Notemos que existen varios otros algoritmos de optimización unidimensional. La exposición a seguir sirve apenas para mencionar algunas posibilidades. El desarrollo de métodos para este tipo de problema no es nuestro objetivo. Cabe resaltar que buenos algoritmos unidimensionales están implementados en todos los sistemas computacionales de uso general, tales como Matlab, Maple, Scilab. Naturalmente, lo mismo se aplica a sistemas computacionales de optimización. Esta es una de las razones para no presentar muchos detalles sobre algoritmos unidimensionales. Esencialmente, cuando un algoritmo hace uso de optimización unidimensional, trataremos la implementación de esta parte como exterior al método en cuestión.

7.3.1. Método de comparación de puntos de red

Sea la tarea de encontrar el valor óptimo

$$\bar{v} = \min\{f(x) \mid x \in [a, b]\}$$

del problema (7.3), donde f es una función continua en $[a, b]$. Supongamos que para una resolución aproximada de este problema, sea permitido calcular valores de f en N puntos del intervalo $[a, b]$, donde N es fijo. Sin informaciones adicionales, la estrategia razonable consiste en cortar $[a, b]$ en N intervalos iguales, y elegir el punto medio de cada intervalo.

Algoritmo 2.3.1. (Método de comparación de puntos de red)

Definimos $\delta_N = (b - a)/N$ y computamos $x_i^N = (a + i\delta_N) - \delta_N/2$, $i = 1, \dots, N$, $v_N = \min_{i=1, \dots, N} f(x_i^N)$.

Aceptamos v_N como una aproximación al valor óptimo $\bar{v}$. Es natural pensar que el número $v_N - \bar{v} \geq 0$ es el error de la aproximación obtenida. Obviamente, sin hipótesis adicionales sobre f , para un N fijo cualquiera este error puede ser arbitrariamente grande. Conseguir una estimativa del error solo puede ser posible para algunas clases de funciones. Sea f Lipschitz-continua en $[a, b]$ con módulo $L > 0$, i.e.,

$$|f(x^1) - f(x^2)| \leq L|x^1 - x^2| \quad \forall x^1, x^2 \in [a, b].$$

Sea $\bar{x} \in [a, b]$ una solución global del problema (7.3). Observamos que la distancia máxima entre los puntos elegidos de la red y $\bar{x}$ no puede ser mayor que $\delta_N/2$. Por lo tanto,

$$v_N - \bar{v} = \min_{i=1, \dots, N} f(x_i^N) - f(\bar{x}) \leq L\delta_N/2 = \frac{L(b-a)}{2N}.$$

La dificultad práctica para la definición del número N que garantiza una aproximación deseada consiste en estimar bien el valor de la constante de Lipschitz L . En la gran mayoría de casos, esta tarea no es trivial; es posiblemente tan difícil como resolver el problema de optimización en cuestión. Por lo tanto, el método tiene utilidad computacional apenas cuando el valor de L es conocido con alguna precisión, o puede ser estimado sin gran costo computacional (i.e., para algunos problemas bien específicos).

No es difícil verificar que, dentro de la clase de métodos pasivos para funciones Lipschitz-continuas, el método presentado arriba es el mejor posible, en el sentido siguiente: para cualquier otra elección de N puntos en $[a, b]$ existe una función, que es Lipschitz-continua, tal que el error de aproximación sería mayor del que se obtiene con el Algoritmo 2.3.1.

Observamos que el Algoritmo 2.3.1 no proporciona una aproximación a la solución $\bar{x}$ con alguna precisión dada, incluso cuando la constante L es conocida. Por cierto, para todo número entero N existe una función f , Lipschitz-continua en $[a, b]$ con módulo L , tal que si aceptamos como aproximación de $\bar{x}$ al punto $\bar{x}^N$ de la red donde fue alcanzado el valor v_N de la función f , se tiene que $|\bar{x}^N - \bar{x}| = (b - a) - \delta_N/2$.

7.3.2. Método de bisección. Método de la sección áurea

Definición 7.1. Decimos que una función $f : [a, b] \rightarrow \mathbb{R}$ es **unimodal** (en $[a, b]$), cuando ella tiene un único minimizador global $\bar{x}$ en $[a, b]$, y es estrictamente decreciente en $[a, \bar{x}]$ y estrictamente creciente en $[\bar{x}, b]$, i.e.,

$$\begin{aligned} f(y) &> f(z) \quad \forall y, z \in [a, \bar{x}], y < z, \\ f(y) &< f(z) \quad \forall y, z \in [\bar{x}, b], y < z. \end{aligned}$$

Una función continua en $[a, b]$ es unimodal si, y solamente si, ella tiene un único minimizador local en $[a, b]$ (que en este caso también es global). Se puede verificar que cualquier función continua fuertemente convexa en $[a, b]$ es unimodal. Naturalmente, existen también funciones unimodales no convexas.

La propiedad siguiente de las funciones unimodales es importante para el desarrollo de los métodos a ser presentados.

Lema 7.1. Sea $f : [a, b] \rightarrow \mathbb{R}$ una función unimodal y $\bar{x}$ el minimizador global de f en $[a, b]$. Sigue que para cualesquiera puntos $y, z \in [a, b]$ tales que $y < z$, vale lo siguiente:

- (a) Si $f(y) \leq f(z)$, entonces $\bar{x} \in [a, z]$.
- (b) Si $f(y) \geq f(z)$, entonces $\bar{x} \in [y, b]$.

Prueba. Probaremos el ítem (a). Supongamos que $f(y) \leq f(z)$, pero $\bar{x} > z$. En este caso $y < z < \bar{x}$ y, por lo tanto, $f(y) > f(z)$ por el hecho de que f es unimodal. Obtenemos una contradicción con la hipótesis. La demostración del ítem (b) es análoga. ■

Como consecuencia, comparando los valores de una función unimodal f en dos puntos de $[a, b]$, podemos “localizar” la solución global del problema (7.3) en un intervalo menor. Repitiendo este procedimiento, podemos disminuir cada vez más el intervalo que contiene la solución. Los métodos basados en esta estrategia pueden ser diferentes en la manera de elegir puntos para la comparación. Resaltamos que estamos aproximando al mismo tiempo el valor óptimo del problema (7.3) y la solución correspondiente.

Suponiendo que f sea unimodal, presentamos a continuación el *método de bisección*.

Algoritmo 2.3.2. (Método de la bisección)

Elegir $a_1 = a$, $b_1 = b$ y $c_1 = (a + b)/2$. Calcular $f(c_1)$. Tomar $k := 1$.

1. Definir $y_k = (a_k + c_k)/2$ y calcular $f(y_k)$.
Si $f(y_k) \leq f(c_k)$, definir $a_{k+1} = a_k$, $b_{k+1} = c_k$, $c_{k+1} = y_k$ y pasar al Paso 3.
Si $f(y_k) > f(c_k)$, definir $z_k = (c_k + b_k)/2$ y calcular $f(z_k)$.
2. Si $f(c_k) \leq f(z_k)$, definir $a_{k+1} = y_k$, $b_{k+1} = z_k$, $c_{k+1} = c_k$.
Si $f(c_k) > f(z_k)$, definir $a_{k+1} = c_k$, $b_{k+1} = b_k$, $c_{k+1} = z_k$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

El Lema 7.1 garantiza que, después de la iteración con índice k , se tiene que $\bar{x} \in [a_{k+1}, b_{k+1}]$. Además de eso, $c_{k+1} = (a_{k+1} + b_{k+1})/2$ y

$$b_{k+1} - a_{k+1} = (b_k - a_k)/2 = \dots = \frac{1}{2^k}(b - a).$$

Como aproximación siguiente a la solución $\bar{x}$, podemos tomar cualquier punto $x_{k+1} \in [a_{k+1}, b_{k+1}]$. La realización de una iteración del método requiere, como máximo, el cálculo de valores de f en dos puntos. Supongamos que el número permitido de evaluaciones sea N . Por razones de conveniencia, sea N un número impar. En este caso, podemos hacer por lo menos $k = (N - 1)/2$ iteraciones del método, lo que resulta en la siguiente estimativa del error de aproximación:

$$|x_{k+1} - \bar{x}| \leq b_{k+1} - a_{k+1} \leq \frac{1}{2^{(N-1)/2}}(b - a) \approx 0.707^{N-1}(b - a).$$

En particular, aumentando N , el error disminuye con tasa geométrica (asociada a $q \approx 0.707$).

A continuación, presentamos un método más eficiente, con una estimativa similar pero asociada a $q \approx 0.618$ (para N grande, la diferencia se vuelve bastante significativa). *Sección áurea* se refiere a la partición del intervalo en dos

partes tales que la relación de la longitud del intervalo original con la longitud de la parte mayor es igual a la relación de la longitud de la parte mayor con la longitud de la parte menor. En particular, si y es un punto de tal partición de $[a, b]$, y si él está más próximo de a que de b , entonces

$$(b - a)/(b - y) = (b - y)/(y - a).$$

De donde obtenemos que

$$y = y(a, b) = a + \frac{3 - \sqrt{5}}{2}(b - a) \approx a + 0.382(b - a).$$

El segundo punto que realiza la sección áurea de $[a, b]$ viene dado por

$$z = z(a, b) = a + \frac{\sqrt{5} - 1}{2}(b - a) \approx a + 0.618(b - a).$$

Llamamos a y y z el menor y el mayor punto de la sección áurea, respectivamente. La partición descrita arriba tiene una cierta relación con la secuencia de Fibonacci.

El resultado siguiente puede ser verificado haciendo un cálculo directo.

Lema 7.2. Sean y y z el menor y el mayor punto de la partición de $[a, b]$, respectivamente. Entonces

$$(a) \quad z - a = b - y = \frac{\sqrt{5} - 1}{2}(b - a);$$

(b) y es el mayor punto de la partición de $[a, z]$, y z es el menor punto de la partición de $[y, b]$.

Presentamos el *método de la sección áurea*, suponiendo que f sea unimodal.

Algoritmo 2.3.3. (Método de la sección áurea)

Definir $a_1 = a$, $b_1 = b$, $y_1 = y(a, b)$, $z_1 = z(a, b)$. Calcular $f(y_1)$. Tomar $k := 1$.

1. Calcular aquel valor entre $f(y_k)$ y $f(z_k)$, que aún no fue calculado.

Si $f(y_k) \leq f(z_k)$, definir $a_{k+1} = a_k$, $b_{k+1} = z_k$, $y_{k+1} = y(a_{k+1}, b_{k+1})$, $z_{k+1} = y_k$.

Si $f(y_k) > f(z_k)$, definir $a_{k+1} = y_k$, $b_{k+1} = b_k$, $y_{k+1} = z_k$, $z_{k+1} = z(a_{k+1}, b_{k+1})$.

2. Tomar $k := k + 1$ y retornar al Paso 1.

Observamos que, por el Lema 7.2 (ítem (b)), tenemos que $y_{k+1} = y(a_{k+1}, b_{k+1})$, $z_{k+1} = z(a_{k+1}, b_{k+1})$. Además de eso, por el Lema 7.1, se tiene que $\bar{x} \in [a_{k+1}, b_{k+1}]$ y, por el Lema 7.2 (ítem (a)),

$$b_{k+1} - a_{k+1} = \frac{\sqrt{5} - 1}{2}(b_k - a_k) = \dots = \left(\frac{\sqrt{5} - 1}{2}\right)^k (b - a).$$

Como aproximación siguiente a la solución $\bar{x}$, podemos tomar cualquier punto $x_{k+1} \in [a_{k+1}, b_{k+1}]$.

Cabe notar que la realización de cada iteración del método requiere la evaluación de f en un solo punto (esto está asegurado por la propiedad descrita en el Lema 7.2 (ítem (b))). Por lo tanto, N evaluaciones de la función f permiten hacer $k = N - 1$ iteraciones del método, lo que resulta en la siguiente estimativa de error:

$$|x_{k+1} - \bar{x}| \leq b_{k+1} - a_{k+1} = \left(\frac{\sqrt{5} - 1}{2}\right)^{N-1} (b - a) \approx 0.618^{N-1}(b - a).$$

Con el aumento de N , el error disminuye con tasa, por lo menos, geométrica (asociada a $q \approx 0.618$).

En la práctica, en vez de definir el número N de iteraciones o evaluaciones de f a priori, lo más típico es continuar el método hasta que la longitud del intervalo que contiene la solución no se vuelva menor que una tolerancia/precisión dada.

Con frecuencia, los algoritmos de optimización para problemas generales necesitan minimizar una función unidimensional en una semirrecta $[a, +\infty)$, en vez de en un intervalo limitado. La definición de una función unimodal y el resultado del Lema 7.1 pueden ser extendidos para este caso sin dificultad. Más aún, bajo la hipótesis de que f sea unimodal, el problema de minimización en $[a, +\infty)$ puede ser reducido al problema de minimización en un intervalo limitado. En efecto, fijemos $\delta > 0$ arbitrario y elijamos el menor $k = 0, 1, \dots$, tal que $f(a + k\delta) \leq f(a + (k + 1)\delta)$. Por el Lema 7.1, el minimizador global de f en $[a, +\infty)$ pertenece a $[a, a + (k + 1)\delta]$. Si $f(a + k\delta) > f(a + (k + 1)\delta)$ para todo $k = 0, 1, \dots$, obtenemos una contradicción con el hecho de que f es unimodal.

En el caso de que f sea continua pero no unimodal, es posible probar la convergencia del método de la bisección y del método de la sección áurea a una solución local del problema (7.3). En muchas situaciones prácticas, la función a

ser minimizada o no es unimodal, o no hay cómo saber si lo es o no. Pero aun así, los métodos de la bisección y de la sección áurea son utilizados con mucha frecuencia.

7.3.3. Interpolación polinomial

En la práctica, los métodos presentados arriba son utilizados, con frecuencia, en combinación con técnicas de aproximación polinomial. Estas últimas son más eficientes en términos de número de iteraciones, pero también son más caras y necesitan de salvaguardias basadas en los métodos anteriores.

La idea consiste en aproximar la función f por un polinomio, utilizando los valores de f (y, tal vez, de sus derivadas) en un cierto número de puntos. El minimizador de este polinomio sirve como siguiente aproximación al minimizador de f . Esta idea puede ser implementada de varias maneras. A continuación, presentaremos lo que se llama *interpolación cuadrática*.

De nuevo, consideremos el problema (7.3). En cada iteración, el método trabaja con tres puntos a_k, b_k y c_k en $[a, b]$, tales que

$$a_k < b_k < c_k, \quad f(a_k) > f(b_k), \quad f(b_k) < f(c_k). \quad (7.4)$$

Como es fácil ver, el minimizador de f pertenece al intervalo $[a_k, c_k]$. El método aproxima la función f por un polinomio cuadrático (haciendo interpolación a partir de los valores de f en los tres puntos), y sustituye uno de estos puntos por el minimizador del polinomio.

Algoritmo 2.3.4. (Método de la interpolación cuadrática)

Elegir a_1, b_1 y c_1 satisfaciendo las condiciones (7.4) escritas con $k = 1$. Tomar $k := 1$.

1. Calcular

$$x_k = \frac{1}{2} \frac{f(a_k)(c_k^2 - b_k^2) + f(b_k)(a_k^2 - c_k^2) + f(c_k)(b_k^2 - a_k^2)}{f(a_k)(c_k - b_k) + f(b_k)(a_k - c_k) + f(c_k)(b_k - a_k)}.$$

2. Si $x_k > b_k$ y $f(x_k) < f(b_k)$, definir $a_{k+1} = b_k, b_{k+1} = x_k, c_{k+1} = c_k$.

Si $x_k > b_k$ y $f(x_k) > f(b_k)$, definir $a_{k+1} = a_k, b_{k+1} = b_k, c_{k+1} = x_k$.

Si $x_k < b_k$ y $f(x_k) < f(b_k)$, definir $a_{k+1} = a_k, b_{k+1} = x_k, c_{k+1} = b_k$.

Si $x_k < b_k$ y $f(x_k) > f(b_k)$, definir $a_{k+1} = x_k, b_{k+1} = b_k, c_{k+1} = c_k$.

3. Tomar $k := k + 1$ y retornar al Paso 1.

El método descrito arriba es apenas una de las posibilidades. En la práctica, son comunes también las interpolaciones cúbicas, así como las interpolaciones que utilizan los valores de la derivada de f .

Ejercicios del Capítulo

Ejercicio 7.1. Sea $c \in [a, b]$. Sea $f : [a, b] \rightarrow \mathbb{R}$ una función Lipschitz-continua en $[a, c]$ y en $[c, b]$, con módulo $L_1 > 0$ y módulo $L_2 > 0$, respectivamente. Probar que f es Lipschitz-continua en $[a, b]$ con módulo $\max\{L_1, L_2\}$.

Ejercicio 7.2. Sea $f : [a, b] \rightarrow \mathbb{R}$ una función continua en $[a, b]$, diferenciable en $[a, b]$ excepto, posiblemente, en un número finito de puntos $c_i \in [a, b], i = 1, \dots, s$. Sea

$$L = \sup\{|f'(x)| \mid x \in [a, b] \setminus \{c_1, \dots, c_s\}\} < \infty.$$

Probar que f es Lipschitz-continua en $[a, b]$ con módulo L .

Ejercicio 7.3. Sean $f_1, f_2 : [a, b] \rightarrow \mathbb{R}$ Lipschitz-continuas en $[a, b]$ con módulo $L_1 > 0$ y con módulo $L_2 > 0$, respectivamente. Probar que las funciones $f_1(\cdot) + f_2(\cdot)$ y $\max\{f_1(\cdot), f_2(\cdot)\}$ son Lipschitz-continuas en $[a, b]$, con módulo $L_1 + L_2$ y con módulo $\max\{L_1, L_2\}$, respectivamente.

Ejercicio 7.4. Encontrar una función continua en $[a, b]$ que no sea Lipschitz-continua en $[a, b]$.

Ejercicio 7.5. Sea $X \subset \mathbb{R}^n$ un conjunto convexo. Una función $f : X \rightarrow \mathbb{R}$ se llama *estrictamente cuasi-convexa* (en X), cuando $\forall x^1, x^2 \in X, x^1 \neq x^2, \forall t \in (0, 1)$ se tiene que

$$f(tx^1 + (1-t)x^2) < \max\{f(x^1), f(x^2)\}.$$

Probar que, cuando $X = [a, b]$, una función continua en X es unimodal si, y solamente si, ella es estrictamente cuasi-convexa.

Ejercicio 7.6. Sean $f_1, f_2 : [a, b] \rightarrow \mathbb{R}$ funciones continuas unimodales en $[a, b]$. Determinar si esto implica o no que las funciones $f_1(\cdot) + f_2(\cdot)$ y $\max\{f_1(\cdot), f_2(\cdot)\}$ son unimodales en $[a, b]$.

Ejercicio 7.7. Realizar dos iteraciones del método de la bisección para el problema

$$\min f(x) = 2x^2 - 7x + 1 \quad \text{sujeto a } x \in [1, 5].$$

Ejercicio 7.8. Mostrar que el punto x_k definido en el **Algoritmo 2.3.4** es el minimizador del polinomio cuadrático que interpola la función f en los puntos a_k, b_k y c_k .

8. Optimización Irrestricla

En este capítulo, presentamos algoritmos para minimizar, sin restricciones, funciones una o dos veces diferenciables. Nuestra intención es, como siempre, explicar las ideas principales y los fundamentos matemáticos del desarrollo y del análisis de los algoritmos. Aspectos esencialmente de implementación, aunque siendo un asunto de extrema importancia, serán presentados solamente cuando sean interesantes o reveladores también desde el punto de vista matemático. Serán tratados métodos de descenso y técnicas de búsqueda lineal, que representan ideas muy importantes en optimización computacional, inclusive para problemas con restricciones (como veremos en capítulos subsiguientes). Presentaremos también el método de Newton, que representa ideas fundamentales para el desarrollo de algoritmos con convergencia rápida. Sin embargo, los métodos cuasi-Newton, que son incluso más importantes en la práctica, serán tratados como una realización inexacta y económica del esquema básico del método de Newton, sin todos los detalles de implementación y de análisis. El mismo comentario es válido para los métodos de los gradientes conjugados en el caso de funciones no lineales generales (i.e., funciones que no sean cuadráticas).

8.1. Métodos de descenso

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dada. Una de las estrategias más naturales para resolver el problema irrestricto

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (8.1)$$

es la siguiente. Dada una aproximación $x^k \in \mathbb{R}^n$ de la solución del problema, encontramos un punto $x^{k+1} \in \mathbb{R}^n$ tal que

$$f(x^{k+1}) < f(x^k).$$

Obviamente, esto puede ser hecho de varias maneras. Una realización de esta estrategia básica es tomar una dirección $d^k \in \mathbb{R}^n$ tal que f es decreciente (por lo menos para pasos cortos) a partir del punto x^k en esa dirección, y computar una longitud de paso $\alpha_k > 0$ que proporcione un valor de f menor que en el punto x^k ,

$$f(x^k + \alpha_k d^k) < f(x^k).$$

Así obtenemos el iterando siguiente $x^{k+1} = x^k + \alpha_k d^k$. Repetimos el proceso para el nuevo punto x^{k+1} , etc. Métodos de este tipo se llaman *métodos de descenso*, y los presentamos a continuación.

8.1.1. Esquema general de los métodos de descenso. Búsqueda lineal

Sea $x \in \mathbb{R}^n$ un punto cualquiera, tal que $f'(x) \neq 0$. Consideremos los puntos de la forma $x + td$, donde $d = -f'(x)$. Por la Fórmula de Taylor de primer orden, para todo $t \geq 0$ tenemos que

$$\begin{aligned} f(x + td) &= f(x) - t\|f'(x)\|^2 + o(t\|f'(x)\|) \\ &= f(x) - t(\|f'(x)\|^2 + o(t)/t). \end{aligned}$$

Como para valores de $t > 0$ suficientemente pequeños se tiene que $\|f'(x)\|^2 > o(t)/t$, para esos valores vale que $f(x + td) < f(x)$. De hecho, como es fácil ver, el mismo razonamiento puede ser usado para cualquier dirección $d \in \mathbb{R}^n$ que satisfaga

$$\langle f'(x), d \rangle < 0.$$

A continuación, formalizaremos estas observaciones.

Definición 8.1. Decimos que $d \in \mathbb{R}^n$ es una *dirección de descenso* de la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ en el punto $x \in \mathbb{R}^n$, si existe $\varepsilon > 0$ tal que

$$f(x + td) < f(x) \quad \forall t \in (0, \varepsilon].$$

Denotamos por $\mathcal{D}_f(x)$ el conjunto de todas las direcciones de descenso de la función f en el punto x .

En otras palabras, $d \in \mathcal{D}_f(x)$ si, y solamente si, todo paso suficientemente corto a partir del punto x en la dirección d resulta en algún decrecimiento de la función f . Es claro que $\mathcal{D}_f(x)$ puede ser vacío, y que el conjunto $\mathcal{D}_f(x) \cup \{0\}$ es un cono no vacío.

Lema 8.1 (Direcciones de descenso). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $x \in \mathbb{R}^n$. Entonces:

- (a) Para todo $d \in \mathcal{D}_f(x)$, se tiene $\langle f'(x), d \rangle \leq 0$.
- (b) Si $d \in \mathbb{R}^n$ satisface $\langle f'(x), d \rangle < 0$, entonces $d \in \mathcal{D}_f(x)$.

Prueba. Sea $d \in \mathcal{D}_f(x)$. Para todo $t > 0$ suficientemente pequeño, por la diferenciabilidad de f en x ,

$$0 > f(x + td) - f(x) = t(\langle f'(x), d \rangle + o(t)/t).$$

Dividiendo los dos lados de la desigualdad anterior por $t > 0$ y pasando al límite cuando $t \rightarrow 0^+$, obtenemos $0 \geq \langle f'(x), d \rangle$, lo que prueba el ítem (a).

Supongamos ahora que $\langle f'(x), d \rangle < 0$. Tenemos que

$$f(x + td) - f(x) = t(\langle f'(x), d \rangle + o(t)/t).$$

En particular, para todo $t > 0$ suficientemente pequeño, tenemos

$$\langle f'(x), d \rangle + o(t)/t \leq \frac{1}{2} \langle f'(x), d \rangle < 0,$$

lo que implica que $f(x + td) - f(x) < 0$, i.e., $d \in \mathcal{D}_f(x)$. ■

Por lo expuesto arriba, tenemos que $-f'(x) \in \mathcal{D}_f(x)$ desde que $f'(x) \neq 0$. De modo más general, si $f'(x) \neq 0$ entonces se tiene que $-Qf'(x) \in \mathcal{D}_f(x)$ para cualquier matriz $Q \in \mathbb{R}^{n \times n}$ definida positiva.

El esquema iterativo general de los métodos de descenso consiste en lo siguiente:

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k \in \mathcal{D}_f(x^k), \quad k = 0, 1, \dots, \quad (8.2)$$

donde los valores de la longitud de paso $\alpha_k > 0$ son elegidos para satisfacer, por lo menos, la condición de que

$$f(x^{k+1}) < f(x^k), \quad (8.3)$$

i.e., la secuencia $\{f(x^k)\}$ de valores de la función objetivo tiene que ser decreciente.

Naturalmente, estamos suponiendo que $\mathcal{D}_f(x^k) \neq \emptyset$ para todo k . En particular, el método se detiene si $\mathcal{D}_f(x^k) = \emptyset$ en alguna iteración. Observamos que, por el hecho de que $d^k \in \mathcal{D}_f(x^k)$, un número $\alpha_k > 0$ satisfaciendo (8.3) siempre existe (por la propia definición de dirección de descenso). Por lo tanto, obtenemos una “descendida” de miembros de la secuencia $\{x^k\}$ por curvas de nivel de la función f asociadas a valores cada vez menores. Esto justifica la “esperanza” de que la secuencia así generada pueda convergir a una solución del problema (en general, solo podemos garantizar convergencia a puntos estacionarios, como veremos más adelante).

Un método concreto, dentro de la clase descrita arriba, es dado por la elección específica de la dirección de descenso y por la regla que define la longitud del paso en esta dirección. La longitud del paso es calculada observando el comportamiento de la función f a lo largo de la semirrecta a partir de x^k en la dirección d^k , o a lo largo de un intervalo limitado en la misma dirección. Por eso, los procedimientos para este cálculo se llaman *búsqueda lineal*¹.

Por el Lema 8.1, como ya fue observado, la elección más obvia de una dirección de descenso viene dada por $d^k = -f'(x^k)$ (suponiendo que $f'(x^k) \neq 0$). Los métodos de descenso correspondientes son, en cierto sentido, más naturales y son también importantes como punto de partida en el desarrollo y estudio de métodos de optimización en general. El análisis de convergencia y de la tasa de convergencia de estos métodos serán presentados en § 3.1.2. Sin embargo, la elección $d^k = -f'(x^k)$ está lejos de ser eficiente en la práctica. Con gran frecuencia, los métodos correspondientes a esta elección poseen convergencia bastante lenta, principalmente cuando las curvas de nivel de la función objetivo son “alargadas”, como en la Figura 3.1.1. El problema es que en los casos así, la dirección del

¹En inglés: *linesearch*.

anti-gradiente $-f'(x^k)$ es casi ortogonal a la dirección $x^k - \bar{x}$ que lleva a la solución $\bar{x}$. Por eso, la secuencia $\{x^k\}$ generada por el método se aproxima a la solución siguiendo una trayectoria en “zig-zag”.

Figura 8.1.: Cuando las curvas de nivel de f son “alargadas”, el método del gradiente anda en “zig-zag”.

Desde el punto de vista práctico, mucho más importantes son los métodos con $d^k = -Q_k f'(x^k)$, donde $Q_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, elegida “de manera inteligente” (en vez de la elección simplista $Q_k = E^n$ correspondiente a $d^k = -f'(x^k)$). Métodos de este tipo serán considerados en § 3.2.3. Por el Lema 8.1, si $f'(x^k) \neq 0$, $d^k = -Q_k f'(x^k)$ también es una dirección de descenso de f en x^k y el análisis teórico de convergencia global no es muy diferente del análisis para el caso de $d^k = -f'(x^k)$ presentado en § 3.1.2. Sin embargo, el comportamiento práctico y la tasa de convergencia local pueden ser bien diferentes. Para ver posibles ventajas de elecciones de Q_k diferentes de la matriz identidad, supongamos que la matriz Hessiana de la función objetivo sea definida positiva en x^k , y tomemos

$$Q_k = (f''(x^k))^{-1},$$

lo que corresponde al método de Newton en § 3.2. Observemos que, en este caso, $d^k = -Q_k f'(x^k)$ es la solución del sistema de ecuaciones lineales

$$f'(x^k) + f''(x^k)d = 0$$

con respecto a $d \in \mathbb{R}^n$, y por la condición de optimalidad de primera orden, d^k es la solución del problema

$$\min f(x^k) + \langle f'(x^k), d \rangle + \frac{1}{2} \langle f''(x^k)d, d \rangle, \quad d \in \mathbb{R}^n,$$

donde minimizamos la aproximación cuadrática de la función objetivo. Por intuición, queda claro que este método puede ser mucho más eficiente, principalmente cuando la aproximación cuadrática de la función objetivo es suficientemente buena, por lo menos localmente (entorno de x^k). Como veremos, esto es verdadero cuando la matriz Hessiana de la función objetivo es definida positiva en la solución.

Finalmente, mencionamos que, con frecuencia, la dirección $d^k = -f'(x^k)$ tiene el papel de “último recurso” cuando en un determinado iterando x^k elecciones más sofisticadas no funcionaron (por una razón u otra).

A continuación, presentamos las principales reglas de búsqueda lineal, suponiendo que para un punto x^k dado, una dirección $d^k \in \mathcal{D}_f(x^k)$ ya fue elegida.

Regla de la minimización unidimensional. Una estrategia natural es minimizar la función objetivo en la semirrecta $x^k + \alpha d^k$, $\alpha \geq 0$. La longitud de paso α_k viene dada por la condición

$$f(x^k + \alpha_k d^k) = \min_{\alpha \geq 0} f(x^k + \alpha d^k),$$

i.e., α_k es una solución del problema

$$\min \varphi_k(\alpha), \quad \alpha \in \mathbb{R}_+, \quad (8.4)$$

donde

$$\varphi_k : \mathbb{R}_+ \rightarrow \mathbb{R}, \quad \varphi_k(\alpha) = f(x^k + \alpha d^k).$$

Observamos que el hecho de que $d^k \in \mathcal{D}_f(x^k)$ garantiza que las soluciones del problema (8.4) están en el interior del conjunto factible, i.e., que $\alpha_k > 0$. Por lo tanto, para una función f diferenciable en el punto x^{k+1} , por el Teorema 1.2.1 se sigue que

$$0 = \varphi'_k(\alpha_k) = \langle f'(x^k + \alpha_k d^k), d^k \rangle = \langle f'(x^{k+1}), d^k \rangle. \quad (8.5)$$

En particular, si $f'(x^{k+1}) \neq 0$, el punto de vista geométrico es que x^{k+1} es el punto de intersección de la semirrecta a partir de x^k en la dirección d^k con la curva de nivel de la función f que pasa por el punto x^{k+1} , véase la Figura 3.1.2.

Este valor de α_k es el mejor posible, en el sentido de que en el punto correspondiente obtenemos el menor valor de f entre todos los puntos de la forma $x^k + \alpha d^k$, $\alpha \geq 0$. Cuando f es una función cuadrática, i.e.,

$$f(x) = \frac{1}{2} \langle Qx, x \rangle + \langle q, x \rangle, \quad x \in \mathbb{R}^n,$$

Figura 8.2.: En el caso de minimización unidimensional, la dirección de búsqueda lineal es ortogonal a la dirección del gradiente en el iterando siguiente.

donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, $q \in \mathbb{R}^n$, puede ser visto que la solución α_k del problema (8.4) es dada por la fórmula explícita:

$$\alpha_k = -\frac{\langle 2Qx^k + q, d^k \rangle}{2\langle Qd^k, d^k \rangle}.$$

Sin embargo, en el caso general, la resolución de un problema unidimensional (véase § 2.3) en cada iteración de un método, mismo que sea inexacta, es relativamente cara. En la práctica, otras reglas de búsqueda lineal (desarrolladas a continuación) son más útiles y más usadas.

Cabe notar también que a veces (en la práctica, casi siempre con excepción de algunos casos bien especiales, como el de una función cuadrática), el problema (8.4) es sustituido por

$$\min \varphi_k(\alpha), \quad \alpha \in [0, \hat{\alpha}],$$

donde $\hat{\alpha} > 0$ es un parámetro (que puede variar con k). De aquí en adelante, cuando hablemos sobre la regla de la optimización unidimensional, siempre pensaremos en este último problema (formalmente, el problema (8.4) puede ser obtenido tomando $\hat{\alpha} = +\infty$).

La regla de Armijo. Otra estrategia natural es computar una longitud de paso que resulte en un decrecimiento suficiente de la función f en relación al valor $f(x^k)$. La idea es que esto puede ser bien más económico desde el punto de vista computacional que la minimización unidimensional, garantizando de la misma forma la convergencia.

Supongamos que f sea diferenciable en el punto x^k . Fijamos los parámetros $\hat{\alpha} > 0$, $\sigma, \theta \in (0, 1)$. Tomamos $\alpha := \hat{\alpha}$.

1. Verificamos si la desigualdad

$$f(x^k + \alpha d^k) \leq f(x^k) + \sigma \alpha \langle f'(x^k), d^k \rangle \quad (8.6)$$

se satisface o no.

2. Si (8.6) no se satisface, tomamos $\alpha := \theta \alpha$ y retornamos al Paso 1.

3. Caso contrario, aceptamos $\alpha_k = \alpha$ como el valor de la longitud de paso.

En otras palabras, α_k es el mayor número entre todos los números de la forma $\alpha = \hat{\alpha} \theta^i$, $i = 0, 1, 2, \dots$, que satisface la desigualdad (8.6). La regla de Armijo es ilustrada en la Figura 3.1.3.

Figura 8.3.: Los valores de α que satisfacen la desigualdad de Armijo $f(x^k + \alpha d^k) - f(x^k) \leq \sigma \alpha \langle f'(x^k), d^k \rangle$.

El valor $\alpha \langle f'(x^k), d^k \rangle$ en el lado derecho en (8.6) representa el valor de reducción de f , previsto por su aproximación lineal para el paso de longitud α en la dirección d^k . Por lo tanto, la desigualdad (8.6) significa que el decrecimiento real de f debe ser por lo menos la fracción (determinada por $\sigma \in (0, 1)$) del previsto.

La implementación computacional de la regla de Armijo es fácil: reducimos el valor inicial $\hat{\alpha}$, multiplicándolo cada vez por el parámetro $\theta \in (0, 1)$, hasta que la desigualdad (8.6) sea satisfecha. El resultado siguiente muestra que cuando d^k satisface la condición suficiente de descenso dada en el Lema 8.1, i.e.,

$$\langle f'(x^k), d^k \rangle < 0, \quad (8.7)$$

entonces la regla de Armijo está bien definida (ella produce un valor $\alpha_k > 0$ aceptable, después de un número finito de reducciones del valor inicial $\hat{\alpha}$).

Lema 8.2 (La regla de Armijo está bien definida). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $x^k \in \mathbb{R}^n$. Supongamos que $d^k \in \mathbb{R}^n$ satisface (8.7). Entonces la desigualdad (8.6) es satisfecha para todo $\alpha > 0$ suficientemente pequeño. En particular, la regla de Armijo está bien definida y termina con un $\alpha_k > 0$.

Prueba. Para todo $\alpha > 0$ suficientemente pequeño,

$$\begin{aligned} f(x^k + \alpha d^k) - f(x^k) &= \langle f'(x^k), \alpha d^k \rangle + o(\alpha) \\ &= \sigma \alpha \langle f'(x^k), d^k \rangle + (1 - \sigma) \alpha \langle f'(x^k), d^k \rangle + o(\alpha) \\ &= \sigma \alpha \langle f'(x^k), d^k \rangle + \alpha((1 - \sigma) \langle f'(x^k), d^k \rangle + o(\alpha)/\alpha) \\ &\leq \sigma \alpha \langle f'(x^k), d^k \rangle, \end{aligned}$$

donde la desigualdad se sigue de

$$(1 - \sigma) \langle f'(x^k), d^k \rangle + \frac{o(\alpha)}{\alpha} \leq \frac{1 - \sigma}{2} \langle f'(x^k), d^k \rangle < 0,$$

que vale para todo $\alpha > 0$ suficientemente pequeño, por la condición (8.7). ■

Por lo tanto, bajo la condición (8.7), el cálculo de α_k por la regla de Armijo garantiza la propiedad (8.3) de descenso para los valores de la función objetivo. Más aún, la desigualdad (8.6), con $\alpha = \alpha_k$, proporciona una estimativa de cuánto el valor $f(x^{k+1})$ es menor que $f(x^k)$. Esta estimativa es crucial para la prueba de convergencia del método (a puntos estacionarios del problema). Como es fácil ver, la condición más débil (8.3) no es suficiente para este fin. La prueba de convergencia se vuelve más fácil cuando los valores de la longitud del paso α_k están uniformemente (en k) acotados inferiormente por algún $\bar{\alpha} > 0$. En este sentido, el siguiente resultado es importante.

Lema 8.3 (Cota inferior para el valor del paso dada por la regla de Armijo). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$. Si $x^k, d^k \in \mathbb{R}^n$ satisfacen la condición (8.7), entonces la desigualdad (8.6) es válida para todo $\alpha \in (0, \bar{\alpha}_k]$, donde

$$\bar{\alpha}_k = -\frac{2(1-\sigma)\langle f'(x^k), d^k \rangle}{L\|d^k\|^2} > 0. \quad (8.8)$$

Prueba. Por el Teorema 1.5.4 y por la desigualdad (8.8), para todo $\alpha \in (0, \bar{\alpha}_k]$ tenemos que

$$\begin{aligned} f(x^k + \alpha d^k) - f(x^k) &\leq \langle f'(x^k), \alpha d^k \rangle + \frac{L}{2} \alpha^2 \|d^k\|^2 \\ &= \alpha \left(\langle f'(x^k), d^k \rangle + \frac{L}{2} \alpha \|d^k\|^2 \right) \\ &\leq \sigma \alpha \langle f'(x^k), d^k \rangle. \end{aligned}$$

El razonamiento del Lema 8.3 es ilustrado en la Figura 3.1.4.

Bajo las hipótesis del Lema 8.3, si

$$\frac{\langle f'(x^k), d^k \rangle}{\|d^k\|^2} \leq \delta < 0, \quad (8.9)$$

Figura 8.4.: En el caso en que el gradiente de f es Lipschitz-continuo, el valor de $f(x^k + \alpha d^k) - f(x^k)$ es menor o igual al valor de la función cuadrática $\alpha \langle f'(x^k), d^k \rangle + \frac{L}{2} \alpha^2 \|d^k\|^2$, cuyo minimizador es el punto $-\frac{\langle f'(x^k), d^k \rangle}{L\|d^k\|^2}$.

donde δ es una constante que no depende de k , y si los parámetros $\hat{\alpha}$, σ y θ son los mismos para cada iteración, se sigue que la desigualdad (8.6) se satisface para todo $\alpha \in (0, \bar{\alpha}]$, donde

$$\bar{\alpha} = -\frac{2\delta(1-\sigma)}{L} > 0.$$

Como el valor de la longitud del paso mayor al que α_k no fue aceptado, tenemos que, o bien

$$\alpha_k = \hat{\alpha},$$

i.e., α_k es el mayor valor permitido en principio, o bien

$$\alpha_k/\theta > \bar{\alpha}$$

(pues en caso contrario, $\alpha = \alpha_k/\theta$ sería aceptado). Concluimos entonces que

$$\alpha_k \geq \min\{\hat{\alpha}, \theta\bar{\alpha}\} = \check{\alpha} > 0.$$

En la práctica, con frecuencia esto significa que, para todo k suficientemente grande, el valor de α_k siempre es el mismo. Esto justifica la consideración de la regla siguiente (aunque para fines esencialmente teóricos).

Regla de la longitud de paso fijo. Fijamos un número $\bar{\alpha} > 0$ que no depende de k y tomamos $\alpha_k = \bar{\alpha}$ para todas las iteraciones.

Esta regla es la más simple y, como consecuencia natural, es de las menos eficientes. Es obvio que una elección de $\bar{\alpha}$ grande muy probablemente llevaría a la no convergencia del método, en cuanto que una elección de $\bar{\alpha}$ pequeño resulta en convergencia lenta. La utilización de longitud de paso fijo solo puede presentar alguna ventaja en situaciones en que el cálculo de los valores de f es muy caro. Por lo expuesto arriba, cuando bajo las hipótesis del Lema 8.3 vale (8.9), la desigualdad (8.6) se satisface para $\alpha = \alpha_k = \bar{\alpha}$, dado que $\bar{\alpha}$ sea suficientemente pequeño. Como consecuencia, la convergencia de métodos con longitud de paso fijo suficientemente pequeño se sigue de la convergencia de métodos que utilizan la regla de Armijo.

Cuando la constante de Lipschitz L es conocida o puede ser estimada, la fórmula (8.8) puede servir para el cálculo de la longitud del paso. Sin embargo, como ya fue mencionado varias veces, las situaciones en las que L es conocida son atípicas. Además de eso, cuanto mayor es el valor de L menor es el valor $\tilde{\alpha}_k$ en el Lema 8.3, i.e., el paso es más corto. Resaltamos también que la estimativa dada en el Lema 8.3 es bastante conservadora. Es perfectamente posible que un paso más largo también satisfaga la condición de descenso (8.6). Intuitivamente, queda claro que con pasos más cortos de lo necesario, la convergencia se vuelve más lenta.

Entre las reglas de longitud de paso consideradas hasta ahora, la de Armijo es de mayor importancia y es ella la que aparecerá en la gran mayoría de los resultados de convergencia a continuación.

Presentamos dos opciones más que también son a veces utilizadas en la práctica.

La regla de Goldstein. La longitud de paso $\alpha_k > 0$ se calcula para satisfacer las siguientes dos desigualdades (en relación a α):

Figura 8.5.: Los valores de α que satisfacen la desigualdad de Goldstein $\sigma_2 \alpha \langle f'(x^k), d^k \rangle \leq f(x^k + \alpha d^k) - f(x^k) \leq \sigma_1 \alpha \langle f'(x^k), d^k \rangle$.

$$\sigma_1 \leq \frac{f(x^k + \alpha d^k) - f(x^k)}{\alpha \langle f'(x^k), d^k \rangle} \leq \sigma_2, \quad (8.10)$$

donde $0 < \sigma_1 < \sigma_2 < 1$. La primera desigualdad es la de Armijo, i.e., (8.6) con $\sigma = \sigma_1$; ella garantiza un decrecimiento suficiente de la función objetivo. Por el Lema 8.2, esta desigualdad vale para todo $\alpha > 0$ suficientemente pequeño. Como es fácil observar, la segunda desigualdad en (8.10) es violada para todo α pequeño demás. La idea de la regla de Goldstein es exactamente esta: en cuanto garantiza una reducción suficiente de la función objetivo, i.e., la desigualdad de Armijo (8.6), no permite pasos cortos de más (lo que, en general, tornaría el método más lento). La regla de Goldstein es ilustrada en la Figura 3.1.5.

Otra realización de la misma idea es la siguiente.

La regla de Wolfe. La longitud de paso $\alpha_k > 0$ se calcula para satisfacer las siguientes dos desigualdades (en relación a α):

$$f(x^k + \alpha d^k) \leq f(x^k) + \sigma_1 \alpha \langle f'(x^k), d^k \rangle, \quad (8.11)$$

$$\langle f'(x^k + \alpha d^k), d^k \rangle \geq \sigma_2 \langle f'(x^k), d^k \rangle, \quad (8.12)$$

donde $0 < \sigma_1 < \sigma_2 < 1$. La primera condición arriba es, de nuevo, la de la regla de Armijo. La segunda condición controla, de cierto modo, la precisión de la minimización de f en la semirrecta $x^k + \alpha d^k$, $\alpha \geq 0$. Como ya vimos arriba, si $\alpha > 0$ minimiza esa función exactamente, se tiene que $\langle f'(x^k + \alpha d^k), d^k \rangle = 0$ (véase la Figura 3.1.2). Por lo tanto, la desigualdad (8.12) es un test de calidad de un $\alpha > 0$ dado como aproximación de minimizadores de f en la semirrecta a lo largo de la dirección d^k . La regla de Wolfe es ilustrada en la Figura 3.1.6.

Figura 8.6.: Los valores de α que satisfacen las desigualdades de Wolfe (8.11) y (8.12).

Cuando el cálculo de la derivada de f no es muy caro, la regla de Wolfe es considerada la regla de búsqueda lineal más eficiente. Además de eso, el paso dado por la regla de Wolfe posee una propiedad que es importante para los métodos cuasi-Newton en § 3.2.

A continuación presentamos un procedimiento de implementación de la regla de Wolfe (cabe notar que la regla de Goldstein puede ser implementada de manera análoga).

Algoritmo 8.1 (Regla de Wolfe). Fijamos los parámetros $0 < \sigma_1 < \sigma_2 < 1$. Tomar $\hat{\alpha} := 0$. Tomar un valor inicial $\alpha > 0$.

1. Si (8.11) y (8.12) se satisfacen, pasar al Ítem 6.
2. Si (8.11) es violada, tomar $\check{\alpha} := \alpha$ y pasar al Ítem 4.
3. Si (8.12) es violada, tomar $\hat{\alpha} := \alpha$.
4. Si $\hat{\alpha} = 0$, escoger un nuevo valor $\alpha > \check{\alpha}$ (extrapolación) y pasar al Ítem 1.
5. Escoger un nuevo valor $\alpha \in (\check{\alpha}, \hat{\alpha})$ (interpolación) y pasar al Ítem 1.
6. Tomar $\alpha_k := \alpha$.

La violación de la condición (8.11) significa que el valor de α es grande de más, en cuanto a la violación de la condición (8.12) significa que este valor es pequeño de más. El procedimiento arriba funciona de la siguiente manera. Primero, se hacen pasos de extrapolación hasta que $\hat{\alpha}$ se vuelva positivo. Después de eso, se hacen pasos de interpolación. Mientras eso, $\hat{\alpha}$ solo puede disminuir, mas quedando positivo, y $\check{\alpha}$ solo puede aumentar, mas siempre quedando menor del que $\hat{\alpha}$. En este esquema, extrapolación e interpolación pueden ser implementadas de varias maneras diferentes. Por ejemplo, podemos fijar números $\theta_1 > 1, \theta_2 \in (0, 1)$ y, durante la extrapolación, tomar cada vez

$$\alpha := \theta_1 \alpha,$$

y durante la interpolación, tomar a cada vez

$$\alpha := (1 - \theta_2)\check{\alpha} + \theta_2\hat{\alpha}.$$

Existen también implementaciones más sofisticadas. Lo que es importante es que un número infinito de extrapolaciones llevaría el valor de $\check{\alpha}$ a $+\infty$, y un número infinito de interpolaciones llevaría el valor de $(\hat{\alpha} - \check{\alpha})$ a cero.

Lema 8.4 (La regla de Wolfe está bien definida). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función acotada inferiormente en $\mathbb{R}^n$, diferenciable con derivada continua. Supongamos que $x^k \in \mathbb{R}^n$ y $d^k \in \mathbb{R}^n$ satisfagan (8.7). Entonces cualquier implementación de la regla de Wolfe, para la cual se tiene que $\check{\alpha} \rightarrow +\infty$ en el caso de número infinito de extrapolaciones y $(\hat{\alpha} - \check{\alpha}) \rightarrow 0$ en el caso de número infinito de interpolaciones, está bien definida, en el sentido de que ella termina con un valor de longitud de paso $\alpha_k > 0$.

Prueba. Supongamos primero que el número de extrapolaciones sea infinito. En este caso, tenemos una secuencia de valores $\check{\alpha} \rightarrow +\infty$, para los cuales

$$f(x^k + \check{\alpha}d^k) \leq f(x^k) + \sigma_1 \check{\alpha} \langle f'(x^k), d^k \rangle. \quad (8.13)$$

Teniendo en cuenta (8.7), esto contradice el hecho de que f está limitada inferiormente. Por lo tanto, el número de extrapolaciones es finito.

Supongamos ahora que el número de interpolaciones sea infinito. En este caso, las secuencias monótonas de valores de $\check{\alpha}$ y de $\hat{\alpha}$ convergen al límite común $\tilde{\alpha}$. Además de eso, los elementos de la primera secuencia satisfacen (8.13) e

$$\langle f'(x^k + \check{\alpha}d^k), d^k \rangle < \sigma_2 \langle f'(x^k), d^k \rangle, \quad (8.14)$$

y los elementos de la segunda secuencia satisfacen

$$f(x^k + \hat{\alpha}d^k) > f(x^k) + \sigma_1 \hat{\alpha} \langle f'(x^k), d^k \rangle. \quad (8.15)$$

Pasando al límite en (8.13) y (8.15), obtenemos la igualdad

$$f(x^k + \tilde{\alpha}d^k) = f(x^k) + \sigma_1 \tilde{\alpha} \langle f'(x^k), d^k \rangle. \quad (8.16)$$

Teniendo en cuenta (8.15) y el hecho de que los valores de $\hat{\alpha}$ son decrecientes, concluimos que estos valores quedan estrictamente mayores a $\tilde{\alpha}$. Usando (8.16), escribimos (8.15) como

$$\begin{aligned} f(x^k + \hat{\alpha}d^k) &> f(x^k) + \sigma_1 (\tilde{\alpha} + \hat{\alpha} - \tilde{\alpha}) \langle f'(x^k), d^k \rangle \\ &= f(x^k + \tilde{\alpha}d^k) + \sigma_1 (\hat{\alpha} - \tilde{\alpha}) \langle f'(x^k), d^k \rangle. \end{aligned}$$

Y como $\hat{\alpha} - \tilde{\alpha} > 0$, tenemos que

$$\frac{f(x^k + \hat{\alpha}d^k) - f(x^k + \tilde{\alpha}d^k)}{\hat{\alpha} - \tilde{\alpha}} > \sigma_1 \langle f'(x^k), d^k \rangle.$$

Pasando al límite (cuando $(\hat{\alpha} - \tilde{\alpha}) \rightarrow 0$) y usando que $\sigma_1 < \sigma_2$ y (8.7), obtenemos

$$\langle f'(x^k + \tilde{\alpha}d^k), d^k \rangle \geq \sigma_1 \langle f'(x^k), d^k \rangle > \sigma_2 \langle f'(x^k), d^k \rangle. \quad (8.17)$$

Por otro lado, pasando al límite en (8.14), obtenemos la desigualdad

$$\langle f'(x^k + \tilde{\alpha}d^k), d^k \rangle \leq \sigma_2 \langle f'(x^k), d^k \rangle,$$

en contradicción con (8.17). ■

Como es fácil observar, en el resultado arriba, en vez de las hipótesis sobre la función f en $\mathbb{R}^n$, podemos colocar hipótesis análogas sobre la función $f(x^k + \alpha d^k)$ en la semirrecta $\mathbb{R}_+ \setminus \{0\}$.

Finalmente, comentaremos que existen también reglas de búsqueda lineal no monótonas. Las estrategias no monótonas permiten pasos más largos y pueden ser bien eficientes en la práctica. La idea es permitir un posible aumento de la función objetivo en comparación con el valor obtenido en la iteración anterior, desde que obtengamos una reducción en comparación con el valor medio de f , o el valor máximo de f , en las p iteraciones anteriores. O sea, para decidir si un valor de longitud de paso $\alpha > 0$ debe ser aceptado o no, $f(x^k + \alpha d^k)$ es comparado con $p^{-1} \sum_{i=k-p+1}^k f(x^i)$, o con $\max\{f(x^i) \mid i = k - p + 1, \dots, k\}$, en vez de $f(x^k)$.

8.1.2. El método del gradiente

Supongamos que la función f sea diferenciable en $\mathbb{R}^n$. En el caso de los métodos de descenso (8.2), hablamos del método del gradiente cuando la dirección de descenso d^k se elige como el anti-gradiente de la función f en el punto x^k , i.e., $d^k = -f'(x^k)$. Si $f'(x^k) = 0$ para algún k , x^k es un punto estacionario del problema (8.1) y el método se detiene (sin embargo, para fines de análisis de convergencia puede ser conveniente considerar que $x^j = \dots = x^{k+1} = x^k$ para todo $j \geq k$, lo cual es válido, ya que $x^{k+1} = x^k - \alpha_k f'(x^k)$). En particular, el esquema (8.2) se reduce al siguiente:

$$x^{k+1} = x^k - \alpha_k f'(x^k), \quad k = 0, 1, \dots \quad (8.18)$$

El método del gradiente es de primer orden y, en general, es poco eficiente para resolver problemas prácticos. Aun así, el estudio de este método es un paso importante para entender los fundamentos de la optimización computacional.

Algoritmo 8.2 (Método del gradiente). Tomar $x^0 \in \mathbb{R}^n$ y $k := 0$.

1. Si $f'(x^k) = 0$, parar.
2. Si $k \geq 1$, calcular β_{k-1} por la fórmula (8.144).
3. Calcular d^k por la fórmula (8.143), y α_k por la fórmula (8.139).
4. Calcular x^{k+1} por la fórmula (8.137).
5. Si $k < n - 1$, tomar $k := k + 1$ y retornar al Paso 1.

El método del gradiente con minimización unidimensional se llama *método de máximo descenso* (cabe destacar que este nombre no debe ser entendido como caracterización de las cualidades de este método en la práctica). Una propiedad importante del método de máximo descenso (por lo menos en el caso $\hat{\alpha} = +\infty$) es la igualdad

$$\langle f'(x^{k+1}), f'(x^k) \rangle = 0,$$

que se sigue de (8.5). O sea, las direcciones utilizadas en las iteraciones subsiguientes, i.e., $d^k = -f'(x^k)$ y $d^{k+1} = -f'(x^{k+1})$, son ortogonales. Es por eso que la trayectoria del método es del tipo “zig-zag” (véase la Figura 8.1).

La desigualdad de Armijo (8.6) en este caso tiene la forma siguiente:

$$f(x^k - \alpha f'(x^k)) \leq f(x^k) - \sigma \alpha \|f'(x^k)\|^2.$$

Observamos que cuando $f'(x^k) \neq 0$, la condición (8.9) es satisfecha automáticamente (con $\delta = -1$), y la estimativa (8.8) del paso más largo viene dada por

$$\tilde{\alpha}_k = 2(1 - \sigma)/L. \quad (8.19)$$

Como esta estimativa no depende de k , cuando el gradiente de la función f es Lipschitz-continuo en $\mathbb{R}^n$ y está siendo utilizada la regla de Armijo, por el Lema 8.3 y los comentarios subsiguientes,

$$\alpha_k \geq \tilde{\alpha} > 0, \quad (8.20)$$

donde $\tilde{\alpha}$ no depende de k .

Las propiedades de convergencia global del método del gradiente son las siguientes.

Teorema 8.1 (Convergencia global del método del gradiente I). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$ con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$. En el caso en que el Algoritmo 3.1.1 utilice longitud de paso fijo, supongamos que $\tilde{\alpha} > 0$ satisfaga

$$\tilde{\alpha} < 2/L. \quad (8.21)$$

Entonces cada punto de acumulación de cualquier secuencia $\{x^k\}$ generada por el Algoritmo 3.1.1 es un punto estacionario del problema (8.1). Si un punto de acumulación existe, o si la función f está acotada inferiormente en $\mathbb{R}^n$, entonces

$$f'(x^k) \rightarrow 0 \quad (k \rightarrow \infty). \quad (8.22)$$

Prueba. Consideramos primero el caso de la regla de Armijo. Si $f'(x^k) \neq 0$ para todo k , la secuencia $\{f(x^k)\}$ es decreciente. Supongamos que la secuencia $\{x^k\}$ tenga un punto de acumulación. En este caso, por la continuidad de f , la secuencia $\{f(x^k)\}$ también tiene un punto de acumulación. Como $\{f(x^k)\}$ es monótona, se sigue que en este caso ella está acotada inferiormente y, por lo tanto, converge (si la función f está acotada inferiormente en $\mathbb{R}^n$, la conclusión es válida incluso cuando $\{x^k\}$ no tiene puntos de acumulación). Por la desigualdad de Armijo y (8.20), para todo k tenemos que

$$f(x^k) - f(x^{k+1}) \geq \sigma \alpha_k \|f'(x^k)\|^2 \geq \sigma \tilde{\alpha} \|f'(x^k)\|^2.$$

Como

$$f(x^k) - f(x^{k+1}) \rightarrow 0 \quad (k \rightarrow \infty),$$

obtenemos (8.22) de la desigualdad anterior.

Consideramos ahora el caso de minimización unidimensional. Para todo k , denotamos por $\tilde{x}^{k+1}$ el punto que sería obtenido si la regla de Armijo fuese utilizada para computar el paso (a partir de x^k en la dirección $d^k = -f'(x^k)$), con $\tilde{\alpha}_k$ siendo la longitud de paso asociada. Por la propia definición de $\tilde{x}^{k+1}$, tenemos que

$$f(x^k) - f(x^{k+1}) \geq f(x^k) - f(\tilde{x}^{k+1}) \geq \sigma \tilde{\alpha}_k \|f'(x^k)\|^2.$$

El resultado se sigue del análisis anterior, con sustitución de α_k por $\tilde{\alpha}_k$.

Finalmente, consideramos el caso de longitud de paso fijo. Por el Lema 8.3, por (8.19) y (8.21) esto es equivalente a la utilización de la regla de Armijo con $\hat{\alpha} = \tilde{\alpha}$ y un $\sigma > 0$ suficientemente pequeño. ■

En los casos de la minimización unidimensional y de la regla de Armijo, un análisis más fino permite sustituir la hipótesis de que la derivada de f sea Lipschitz-continua por la hipótesis más débil de que ella sea continua. La dificultad en este caso tiene que ver con la posible inexistencia de $\tilde{\alpha} > 0$ que satisfaga (8.20), i.e., con la posibilidad de que α_k se aproxime a cero (tal vez a lo largo de una subsecuencia).

Teorema 8.2 (Convergencia global del método del gradiente II). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada continua. Supongamos que el Algoritmo 3.1.1 utiliza la minimización unidimensional o la regla de Armijo. Entonces cada punto de acumulación de cualquier secuencia $\{x^k\}$ generada por el Algoritmo 3.1.1 es un punto estacionario del problema (8.1). Si la secuencia $\{x^k\}$ es acotada, entonces vale (8.22).

Prueba. El caso de minimización unidimensional se reduce al caso de la regla de Armijo de la misma manera que en la demostración del Teorema 8.1. Por lo tanto, consideremos solamente la regla de Armijo.

Supongamos que la secuencia $\{x^k\}$ tenga un punto de acumulación $\bar{x} \in \mathbb{R}^n$, y que $f'(x^k) \neq 0$ para todo k . Supongamos que $x^{k_j} \rightarrow \bar{x}$ ($j \rightarrow \infty$). El caso en que existe $\tilde{\alpha} > 0$ tal que $\alpha_{k_j} \geq \tilde{\alpha}$ para todo j , puede ser analizado de manera completamente análoga a la del Teorema 8.1 (sustituyendo $\{x^k\}$ por $\{x^{k_j}\}$). Por lo tanto, tomando una subsecuencia si fuera necesario, consideremos el caso

$$\alpha_{k_j} \rightarrow 0 \quad (j \rightarrow \infty).$$

En este caso, para todo j suficientemente grande, el valor inicial de la longitud de paso $\hat{\alpha}$ fue reducido por lo menos una vez, i.e., el valor $\alpha = \theta^{-1} \alpha_{k_j} > \alpha_{k_j}$ no satisface la desigualdad de Armijo (8.6). O sea,

$$f(x^{k_j} - \theta^{-1} \alpha_{k_j} f'(x^{k_j})) > f(x^{k_j}) - \sigma \theta^{-1} \alpha_{k_j} \|f'(x^{k_j})\|^2.$$

Denotando $\tilde{\alpha}_{k_j} = \theta^{-1} \alpha_{k_j} \|f'(x^{k_j})\|$ y dividiendo la última desigualdad por $\tilde{\alpha}_{k_j}$, obtenemos

$$\frac{f(x^{k_j} - \tilde{\alpha}_{k_j} f'(x^{k_j}) / \|f'(x^{k_j})\|) - f(x^{k_j})}{\tilde{\alpha}_{k_j}} > -\sigma \|f'(x^{k_j})\|.$$

Observamos que $\tilde{\alpha}_{k_j} \rightarrow 0$ ($j \rightarrow \infty$), porque $\{\|f'(x^{k_j})\|\}$ es acotada y $\alpha_{k_j} \rightarrow 0$. Pasando al límite cuando $j \rightarrow \infty$ y utilizando el Teorema del Valor Medio, obtenemos que

$$-\|f'(\bar{x})\| = \langle f'(\bar{x}), -f'(\bar{x}) / \|f'(\bar{x})\| \rangle \geq -\sigma \|f'(\bar{x})\|.$$

Como $\sigma \in (0, 1)$, esto solo es posible cuando $f'(\bar{x}) = 0$.

La última afirmación del teorema es una consecuencia obvia de la primera. ■

Cabe mencionar que la existencia de puntos de acumulación de la secuencia $\{x^k\}$ no forma parte de la afirmación en los Teorema 8.1 y Teorema 8.2. Una hipótesis natural que garantiza tal existencia consiste en suponer que el conjunto de nivel $L(f(x^0)) = L_{f, \mathbb{R}^n}(f(x^0))$ sea acotado. Como el método es de descenso, es claro que $f(x^k) \leq f(x^0)$ para todo k , i.e., $\{x^k\} \subset L(f(x^0))$. Por lo tanto, bajo esta hipótesis $\{x^k\}$ será acotada y tendrá algún punto de acumulación.

Aunque los resultados anteriores se refieren al método de máximo descenso, afirmaciones análogas son verdaderas para varias otras elecciones de direcciones de descenso.

En el caso de una función convexa, las propiedades de convergencia global del método del gradiente son mucho más fuertes. Mostraremos a continuación que en este caso, si el conjunto de minimizadores es no vacío, entonces toda la secuencia converge a una solución del problema, i.e., la secuencia está acotada y posee un único punto de acumulación. Resaltamos que la afirmación es válida incluso si el conjunto de minimizadores fuese no acotado.

Teorema 8.3 (Convergencia global del método del gradiente en el caso convexo). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa, diferenciable en $\mathbb{R}^n$, con derivada continua. Supongamos que el Algoritmo 3.1.1 utiliza la regla de Armijo con $\hat{\alpha} \leq 1$.*

Si el conjunto de minimizadores irrestrictos de f es no vacío, entonces cualquier secuencia $\{x^k\}$ generada por el Algoritmo 3.1.1 converge a una solución del problema (8.1).

Prueba. Sea $\bar{x} \in \mathbb{R}^n$ una solución del problema. Como para todo k

$$f(x^k) - f(x^{k+1}) \geq \sigma \alpha_k \|f'(x^k)\|^2,$$

tenemos que

$$\begin{aligned} f(x^0) - f(\bar{x}) &\geq f(x^0) - f(x^k) \\ &= \sum_{i=0}^{k-1} (f(x^i) - f(x^{i+1})) \\ &\geq \sigma \sum_{i=0}^{k-1} \alpha_i \|f'(x^i)\|^2. \end{aligned}$$

Pasando al límite cuando $k \rightarrow \infty$, obtenemos que

$$\sum_{i=0}^{\infty} \alpha_i \|f'(x^i)\|^2 \leq \frac{f(x^0) - f(\bar{x})}{\sigma} < +\infty. \quad (8.23)$$

Por la convexidad de f y por la optimalidad de $\bar{x}$,

$$\langle f'(x^k), \bar{x} - x^k \rangle \leq f(\bar{x}) - f(x^k) \leq 0.$$

De donde, usando también (8.18) y el hecho de que $\alpha_k^2 \leq \alpha_k$ (porque $\alpha_k \leq \hat{\alpha} \leq 1$, por la elección del parámetro $\hat{\alpha}$), obtenemos

$$\begin{aligned} \|x^{k+1} - \bar{x}\|^2 &= \|x^k - \bar{x}\|^2 + 2\langle x^{k+1} - x^k, x^k - \bar{x} \rangle + \|x^{k+1} - x^k\|^2 \\ &= \|x^k - \bar{x}\|^2 - 2\alpha_k \langle f'(x^k), x^k - \bar{x} \rangle + \alpha_k^2 \|f'(x^k)\|^2 \\ &\leq \|x^k - \bar{x}\|^2 + \alpha_k \|f'(x^k)\|^2. \end{aligned}$$

Sea k arbitrario pero fijo. Utilizando la última desigualdad en secuencia, para cualquier $j \geq k + 1$, obtenemos

$$\|x^j - \bar{x}\|^2 \leq \|x^k - \bar{x}\|^2 + \sum_{i=k}^{j-1} \alpha_i \|f'(x^i)\|^2 \leq \|x^k - \bar{x}\|^2 + \sum_{i=k}^{\infty} \alpha_i \|f'(x^i)\|^2 < +\infty, \quad (8.24)$$

por (8.23). Concluimos que la secuencia $\{x^k\}$ es acotada. Por lo tanto, $\{x^k\}$ tiene un punto de acumulación $\hat{x}$. Por el Teorema 8.2, $f'(\hat{x}) = 0$ lo que, en el caso convexo, significa que $\hat{x}$ es una solución del problema (véase, por ejemplo, el Teorema 1.3.7). Podemos entonces tomar $\bar{x} = \hat{x}$ en el análisis anterior, para concluir de (8.24), que para todo $j \geq k + 1$

$$\|x^j - \hat{x}\|^2 \leq \|x^k - \hat{x}\|^2 + \sum_{i=k}^{\infty} \alpha_i \|f'(x^i)\|^2, \quad (8.25)$$

donde, de (8.23),

$$\lim_{k \rightarrow \infty} \left(\sum_{i=k}^{\infty} \alpha_i \|f'(x^i)\|^2 \right) = 0.$$

En particular, para todo $\delta > 0$ arbitrariamente pequeño, podemos elegir k suficientemente grande, tal que

$$\delta/2 > \sum_{i=k}^{\infty} \alpha_i \|f'(x^i)\|^2.$$

Como $\hat{x}$ es un punto de acumulación de la secuencia $\{x^k\}$, podemos también elegir un k tal que

$$\delta/2 > \|x^k - \hat{x}\|^2.$$

De (8.25), concluimos que para todo $\delta > 0$, existe k tal que

$$\delta > \|x^j - \hat{x}\|^2 \quad \forall j \geq k+1.$$

Esto significa que $\{x^k\}$ converge a $\hat{x}$. ■

A continuación, analizaremos el comportamiento local del método del gradiente, i.e., el comportamiento en una vecindad de un punto estacionario $\bar{x} \in \mathbb{R}^n$ del problema (8.1). Supongamos que la función f sea dos veces diferenciable en $\bar{x}$, y que $\bar{x}$ satisfaga la condición suficiente de segundo orden (véase el Teorema 1.2.1).

En particular, $\bar{x}$ es un minimizador local estricto. Más aún, en este caso f crece con orden por lo menos cuadrático en una vecindad de $\bar{x}$. En efecto, existen una vecindad U de $\bar{x}$ y un número $\beta > 0$ tales que

$$\begin{aligned} f(x) - f(\bar{x}) &= \langle f'(\bar{x}), x - \bar{x} \rangle + \frac{1}{2} \langle f''(\bar{x})(x - \bar{x}), x - \bar{x} \rangle + o(\|x - \bar{x}\|^2) \\ &= \frac{1}{2} \langle f''(\bar{x})(x - \bar{x}), x - \bar{x} \rangle + o(\|x - \bar{x}\|^2) \\ &\geq \beta \|x - \bar{x}\|^2 \quad \forall x \in U, \end{aligned} \tag{8.26}$$

donde utilizamos el Teorema 1.2.1, en particular (1.5) y (1.7). Esta propiedad (8.26) tendrá un papel importante en nuestro análisis local.

Lema 8.5. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en una vecindad del punto $\bar{x} \in \mathbb{R}^n$ y dos veces diferenciable en $\bar{x}$. Supongamos que $\bar{x}$ es un punto estacionario del problema (8.1) que satisface la condición suficiente de segundo orden dada en el Teorema 1.2.1 (i.e., $\bar{x}$ satisface (1.5) y (1.7)).

Entonces para cualquier número $\nu \in (0, 4)$ existe una vecindad U de $\bar{x}$ tal que, además de (8.26), vale

$$\|f'(x)\|^2 \geq \nu \beta (f(x) - f(\bar{x})) \quad \forall x \in U. \tag{8.27}$$

Prueba. Para $x \in \mathbb{R}^n$ suficientemente próximo a $\bar{x}$, tenemos que

$$f'(x) = f'(x) - f'(\bar{x}) = f''(\bar{x})(x - \bar{x}) + o(\|x - \bar{x}\|),$$

donde usamos que $f'(\bar{x}) = 0$. Por lo tanto,

$$\begin{aligned} f(x) - f(\bar{x}) &= \frac{1}{2} \langle f''(\bar{x})(x - \bar{x}), x - \bar{x} \rangle + o(\|x - \bar{x}\|^2) \\ &= \frac{1}{2} \langle f'(x), x - \bar{x} \rangle + o(\|x - \bar{x}\|^2), \end{aligned}$$

i.e.,

$$\langle f'(x), x - \bar{x} \rangle = 2(f(x) - f(\bar{x})) + o(\|x - \bar{x}\|^2).$$

Usando (8.26), obtenemos

$$\begin{aligned} \langle f'(x), x - \bar{x} \rangle - \sqrt{\nu} (f(x) - f(\bar{x})) &= (2 - \sqrt{\nu})(f(x) - f(\bar{x})) + o(\|x - \bar{x}\|^2) \\ &\geq (2 - \sqrt{\nu})\beta \|x - \bar{x}\|^2 + o(\|x - \bar{x}\|^2) > 0, \end{aligned}$$

donde la desigualdad vale para todo x suficientemente próximo a $\bar{x}$. Por lo tanto,

$$\langle f'(x), x - \bar{x} \rangle \geq \sqrt{\nu} (f(x) - f(\bar{x})). \tag{8.28}$$

De donde, usando también (8.26), se sigue que

$$\begin{aligned} \|f'(x)\| \|x - \bar{x}\| &\geq \langle f'(x), x - \bar{x} \rangle \\ &\geq \sqrt{\nu} (f(x) - f(\bar{x})) \\ &\geq \sqrt{\nu \beta} \|x - \bar{x}\|^2, \end{aligned}$$

i.e.,

$$\|f'(x)\| \geq \sqrt{\nu\beta}\|x - \bar{x}\|.$$

Por lo tanto, usando (8.28),

$$\begin{aligned} \|f'(x)\|^2 &\geq \sqrt{\nu\beta}\|x - \bar{x}\|\|f'(x)\| \\ &\geq \sqrt{\nu\beta}\langle f'(x), x - \bar{x} \rangle \\ &\geq \nu\beta(f(x) - f(\bar{x})), \end{aligned}$$

lo que es el resultado deseado. ■

Presentamos ahora el resultado principal sobre la convergencia local del método del gradiente.

Teorema 8.4 (Convergencia local del método del gradiente I). *Además de las hipótesis del Teorema 8.1, supongamos que la función f sea dos veces diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Supongamos que $\bar{x}$ es un punto estacionario del problema (8.1) que satisface la condición suficiente de segundo orden dada en el Teorema 1.2.1 (i.e., $\bar{x}$ satisface (1.5) y (1.7)). Finalmente, en el caso de utilización de minimización unidimensional en el Algoritmo 3.1.1, sea $\hat{\alpha}$ un valor finito. Entonces:*

- (a) *Para cualquier $x^0 \in \mathbb{R}^n$ suficientemente próximo a $\bar{x}$, la secuencia generada por el Algoritmo 3.1.1 converge a $\bar{x}$; la tasa de convergencia en relación a la función objetivo es lineal, y en relación a las variables es geométrica: $\forall k = 0, 1, \dots$, se tiene que*

$$f(x^{k+1}) - f(\bar{x}) \leq q(f(x^k) - f(\bar{x})), \quad (8.29)$$

$$\|x^k - \bar{x}\| \leq \Gamma \sqrt{f(x^k) - f(\bar{x})} \leq (\sqrt{q})^k \Gamma \sqrt{f(x^0) - f(\bar{x})}, \quad (8.30)$$

donde los números $q \in [0, 1)$ y $\Gamma > 0$ no dependen ni de k , ni de x^0 .

- (b) *En el caso de minimización unidimensional, si $\hat{\alpha}$ satisface*

$$\hat{\alpha} \geq 1/L, \quad (8.31)$$

se tiene que

$$\limsup_{k \rightarrow \infty} \frac{f(x^{k+1}) - f(\bar{x})}{f(x^k) - f(\bar{x})} \leq 1 - \rho_1/\rho_n, \quad (8.32)$$

donde $\rho_1 > 0$ y $\rho_n > 0$ son el menor y el mayor autovalor de la matriz $f''(\bar{x})$, respectivamente.

- (c) *En el caso de la regla de Armijo, si $\hat{\alpha}$ satisface (8.31) y θ satisface la condición*

$$\theta \leq 1/2, \quad (8.33)$$

se tiene que

$$\limsup_{k \rightarrow \infty} \frac{f(x^{k+1}) - f(\bar{x})}{f(x^k) - f(\bar{x})} \leq 1 - 2\sigma(1 - \sigma)\rho_1/\rho_n. \quad (8.34)$$

Si en lugar de la condición (8.33) sobre θ , se supone que vale $\sigma \geq 1/2$, se tiene que

$$\limsup_{k \rightarrow \infty} \frac{f(x^{k+1}) - f(\bar{x})}{f(x^k) - f(\bar{x})} \leq 1 - \theta\rho_1/\rho_n. \quad (8.35)$$

- (d) *En el caso de longitud de paso fijo, se tiene que*

$$\limsup_{k \rightarrow \infty} \frac{f(x^{k+1}) - f(\bar{x})}{f(x^k) - f(\bar{x})} \leq 1 - 2\rho_1\bar{\alpha} + \rho_1\rho_n\bar{\alpha}^2. \quad (8.36)$$

Prueba. Fijemos una vecindad U de $\bar{x}$ tal que las propiedades (8.26) y (8.27) valgan con algunas constantes $\beta > 0$ y $\nu \in (0, 4)$ (la condición suficiente de segundo orden y el Lema 8.5 garantizan la existencia de esta vecindad). Sea $x^k \in U$. En el caso de la minimización unidimensional, para todo $\alpha \in [0, \hat{\alpha}]$, tenemos que

$$\begin{aligned} f(x^{k+1}) - f(\bar{x}) &\leq f(x^k - \alpha f'(x^k)) - f(\bar{x}) \\ &\leq f(x^k) - f(\bar{x}) - \alpha\|f'(x^k)\|^2 + \frac{L\alpha^2}{2}\|f'(x^k)\|^2, \end{aligned}$$

donde la última desigualdad se sigue del Lema 1.5.4. Analizando el término cuadrático (en relación a α) del lado derecho de esta desigualdad, puede verse que él alcanza su mínimo sobre el intervalo $[0, \hat{\alpha}]$ en el punto $\alpha = \min\{\hat{\alpha}, 1/L\}$.

Por lo tanto, teniendo en cuenta (8.27),

$$\begin{aligned} f(x^{k+1}) - f(\bar{x}) &\leq f(x^k) - f(\bar{x}) - \alpha(1 - \alpha L/2) \|f'(x^k)\|^2 \\ &\leq (1 - \min\{\hat{\alpha}, 1/L\} \max\{1 - \hat{\alpha}L/2, 1/2\} \nu\beta) (f(x^k) - f(\bar{x})). \end{aligned} \quad (8.37)$$

En el caso de la regla de Armijo, por (8.20) y (8.27), tenemos que

$$\begin{aligned} f(x^{k+1}) - f(\bar{x}) &\leq f(x^k) - f(\bar{x}) - \sigma\hat{\alpha} \|f'(x^k)\|^2 \\ &\leq (1 - \sigma\hat{\alpha}\nu\beta) (f(x^k) - f(\bar{x})). \end{aligned} \quad (8.38)$$

El caso de la longitud de paso fijo se reduce al caso de la regla de Armijo (véase la demostración del Teorema 8.1, con $\hat{\alpha} = \hat{\alpha} = \bar{\alpha}$). Concluimos que en todos los casos vale la desigualdad (8.29).

La tarea siguiente consiste en probar que si x^0 está suficientemente próximo a $\bar{x}$, entonces la secuencia $\{x^k\}$ no sale de la vecindad U . Para ello, precisaremos de la siguiente desigualdad, que se sigue de (8.26):

$$\|f'(x)\| \leq L\|x - \bar{x}\| \leq L\sqrt{\frac{f(x) - f(\bar{x})}{\beta}} \quad \forall x \in U. \quad (8.39)$$

Fijemos $r > 0$ tal que $B(\bar{x}, r) \subset U$, y definamos $\delta > 0$ satisfaciendo la condición

$$\delta + \frac{\hat{\alpha}L\sqrt{(f(x^0) - f(\bar{x}))/\beta}}{1 - \sqrt{q}} \leq r \quad \forall x \in B(\bar{x}, \delta) \quad (8.40)$$

(notamos que $\delta \leq r$). Sea $x^0 \in B(\bar{x}, \delta)$. En este caso, por (8.39) y (8.40),

$$\begin{aligned} \|x^1 - \bar{x}\| &\leq \|x^0 - \bar{x}\| + \|x^1 - x^0\| \\ &\leq \delta + \hat{\alpha}\|f'(x^0)\| \\ &\leq \delta + \hat{\alpha}L\sqrt{(f(x^0) - f(\bar{x}))/\beta} \leq r, \end{aligned}$$

i.e., $x^1 \in B(\bar{x}, r)$. De donde, y por (8.26), se sigue que $q \geq 0$, pues caso contrario (8.29) sería válida para $k = 0$.

Supongamos que $x^k \in B(\bar{x}, r)$ para $k = 1, \dots, s$. En este caso, por (8.29), obtenemos

$$\begin{aligned} f(x^k) - f(\bar{x}) &\leq q(f(x^{k-1}) - f(\bar{x})) \leq \dots \\ &\leq q^k(f(x^0) - f(\bar{x})) \quad \forall k = 0, \dots, s. \end{aligned}$$

Por lo tanto, usando también (8.39),

$$\begin{aligned} \|x^{k+1} - x^k\| &\leq \hat{\alpha}\|f'(x^k)\| \\ &\leq \hat{\alpha}L\sqrt{(f(x^k) - f(\bar{x}))/\beta} \\ &\leq (\sqrt{q})^k \hat{\alpha}L\sqrt{(f(x^0) - f(\bar{x}))/\beta} \quad \forall k = 0, \dots, s. \end{aligned}$$

De donde, y por (8.40), se sigue que

$$\begin{aligned} \|x^{s+1} - \bar{x}\| &\leq \|x^s - \bar{x}\| + \|x^{s+1} - x^s\| \leq \dots \\ &\leq \|x^0 - \bar{x}\| + \sum_{k=0}^s \|x^{k+1} - x^k\| \\ &\leq \delta + \hat{\alpha}L\sqrt{\frac{f(x^0) - f(\bar{x})}{\beta}} \sum_{k=0}^s (\sqrt{q})^k \\ &\leq \delta + \frac{\hat{\alpha}L\sqrt{(f(x^0) - f(\bar{x}))/\beta}}{1 - \sqrt{q}} \leq r, \end{aligned}$$

i.e., $x^{s+1} \in B(\bar{x}, r)$.

Acabamos de mostrar que $\{x^k\} \subset U$. En particular, para todo k vale la estimativa (8.29). De donde, usando también (8.26), obtenemos (8.30) con $\Gamma = 1/\sqrt{\beta}$. La convergencia de $\{x^k\}$ a $\bar{x}$ ahora es obvia, lo que concluye la prueba del ítem (a).

Dejamos como ejercicio para el lector las afirmaciones (b)-(d). Ellas pueden ser verificadas sin mayores dificultades, utilizando el ítem (a) y las propiedades (8.37) y (8.38), estimativas asintóticas del número β y de la constante de

Lipschitz de la derivada de f en U en términos de ρ_1 y ρ_n , respectivamente, reduciendo la vecindad U de $\bar{x}$. Además de eso, debe ser utilizado el hecho de que en el Lema 8.5 el número ν puede ser elegido arbitrariamente próximo a 4. En la demostración del ítem (c), será necesario elegir el mayor número $\check{\alpha}$, que garantice que (8.20) se satisfaga. En la demostración del ítem (d), como σ debe ser elegido un número para el cual valga (8.19) con $\check{\alpha}_k = \check{\alpha}$, i.e., $\sigma = 1 - \check{\alpha}L/2$. ■

Por la estimativa (8.34), en la regla de Armijo es preferible elegir el parámetro σ próximo a $1/2$. Pero incluso para $\sigma = 1/2$, la estimativa (8.34) es un poco peor de que (8.32) en el caso del método de máximo descenso, así como la estimativa (8.35). En relación a esta última, es preferible elegir θ próximo a 1 (sin embargo, cuanto más próximo está θ a 1, más cara es la implementación computacional de la regla de Armijo, por lo menos en principio). Finalmente, la elección óptima de longitud de paso fijo, por la estimativa (8.36), está dada por $\tilde{\alpha} = 1/L$ (en este caso, la estimativa (8.36) coincide con (8.32)).

Otros resultados sobre convergencia local del método del gradiente están basados en la sustitución de la condición suficiente de segundo orden por una condición de crecimiento cuadrático de la función objetivo, en el sentido más débil que (8.26) (recordamos que (8.26) es una consecuencia de la condición suficiente de segundo orden). Esto tiene sentido, porque la condición de segundo orden es violada cuando $\bar{x}$ es una solución del problema (8.1), que no es aislada (i.e., en toda vecindad de $\bar{x}$ existen otros puntos del conjunto S de minimizadores globales de f). Este es un caso perfectamente posible, por ejemplo, en el problema de minimizar la violación de viabilidad en un sistema de ecuaciones donde el número de ecuaciones es menor que el número de variables, i.e.,

$$f(x) = \|F(x)\|^2/2, \quad x \in \mathbb{R}^n, \quad (8.41)$$

donde $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es diferenciable y $n > l$. Esta es una de las situaciones en que es natural sustituir la condición de crecimiento cuadrático (8.26) por la siguiente estimativa a la distancia al conjunto S :

$$f(x) - \bar{v} \geq \gamma(\text{dist}(x, S))^2 \quad \forall x \in U, \quad (8.42)$$

donde U es una vecindad del punto $\bar{x}$, $\gamma > 0$ es una constante, y $\bar{v} = f(\bar{x})$ es el valor óptimo del problema (8.1). Por ejemplo, si F satisface en el punto $\bar{x}$ las hipótesis del Teorema 1.5.5 (en particular, $\text{rk } F'(\bar{x}) = l$), entonces para la función f definida por (8.41) tenemos la estimativa (8.42). Observamos que, a diferencia del caso de (8.26), el caso de (8.42) no presupone la convexidad de f ni siquiera localmente, en torno de $\bar{x}$.

En un análisis de este tipo, es común pasar de consideraciones puramente locales (en torno de un punto dado) a consideraciones en una vecindad de todo el conjunto S . En otras palabras, vamos a suponer que U en (8.42) es una vecindad de S (i.e., $S \subset U$) y no apenas de $\bar{x}$. La propiedad (8.42) también se llama *crecimiento cuadrático local* (de la función f en torno del conjunto de soluciones S). Con frecuencia, se considera una vecindad U específica, por ejemplo: $U = U(S, \delta) = \{x \in \mathbb{R}^n \mid \text{dist}(x, S) \leq \delta\}$, o $U = L_{f, \mathbb{R}^n}(\bar{v} + \delta)$, o $U = L_{\|f'(\cdot)\|, \mathbb{R}^n}(\delta)$, para algún $\delta > 0$.

Las principales afirmaciones de resultados asociados consisten en la convergencia al conjunto S , con alguna tasa de convergencia. Por ejemplo, bajo ciertas condiciones de diferenciabilidad, la propiedad (8.42) con $U = U(S, \delta)$ y algunos $\delta > 0$ y $\gamma > 0$, garantiza lo siguiente: si el punto inicial x^0 está suficientemente próximo de S , entonces la secuencia del método del gradiente con regla de Armijo converge a un punto de S , con tasa lineal en relación a la función y con tasa geométrica en relación a las variables. Un resultado parecido pero, en cierto modo más general, será probado a continuación.

A veces, puede ser considerada una propiedad más débil que la de (8.42), que consiste en

$$f(x) - \bar{v} \geq \gamma(\text{dist}(x, S))^p \quad \forall x \in U,$$

donde $p > 2$. Para este caso, puede ser probada la convergencia del método del gradiente con tasa aritmética.

En el análisis de convergencia y de tasa de convergencia de métodos del gradiente al conjunto S_0 de puntos estacionarios del problema (8.1), es natural que la condición de crecimiento cuadrático sea sustituida por una estimativa a la distancia al conjunto S_0 de la siguiente forma:

$$\|f'(x)\| \geq \gamma \text{dist}(x, S_0) \quad \forall x \in U, \quad (8.43)$$

donde U es una vecindad de S_0 , y $\gamma > 0$ es una constante.

Supongamos que existan números $\delta > 0$ y $\gamma > 0$ tales que la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea tres veces diferenciable en $U = U(S, \delta)$, con la derivada tercera acotada en U . Supongamos que (8.42) sea satisfecha. Entonces para todo $\nu \in (0, 4)$, existe $r > 0$ tal que

$$\|f'(x)\|^2 \geq \nu\gamma(f(x) - \bar{v}) \quad \forall x \in U(S, r).$$

Cabe mencionar que la condición de crecimiento cuadrático implica, en un cierto sentido, la estimativa (8.43). Más precisamente, el resultado del Ejercicio 3.1.9 implica lo siguiente: si $S = S_0$, la función f es suficientemente suave y vale (8.42) con $U = U(S, \delta)$ y algunos $\delta > 0$ y $\gamma > 0$, entonces vale también (8.43) con cierta (tal vez diferente) vecindad U del conjunto S_0 y número $\gamma > 0$.

A continuación, suponemos que la vecindad U en (8.43) sea dada por $U = L_{\|f'(\cdot)\|, \mathbb{R}^n}(\delta)$ con algún $\delta > 0$ (notamos que la propiedad (8.43) con $U = U(S_0, \delta)$ y algún $\delta > 0$, implica la misma propiedad con $U = L_{\|f'(\cdot)\|, \mathbb{R}^n}(\delta)$, tal vez con otro $\delta > 0$). Además de eso, supongamos que se satisfacen las hipótesis del Teorema 8.1 y que $\bar{v} > -\infty$, lo que garantiza que vale (8.22) para toda secuencia $\{x^k\}$ del Algoritmo 3.1.1. Luego, tenemos que $x^k \in U$ para todo k suficientemente grande. Es exactamente esto lo que hace que el resultado de convergencia a ser presentado tenga un carácter verdaderamente global.

Una condición adicional que será necesaria se llama *condición de separación de superficies de nivel críticas*. Esta condición consiste en lo siguiente: existe un número $\varepsilon > 0$ tal que para cualesquiera $\bar{x}^1, \bar{x}^2 \in S_0$ satisfaciendo $f(\bar{x}^1) \neq f(\bar{x}^2)$, se tiene que $\|\bar{x}^1 - \bar{x}^2\| \geq \varepsilon$.

Es fácil verificar que, si el conjunto S_0 es suavemente conexo (i.e., cualesquiera dos puntos de S_0 pueden ser conectados por una curva diferenciable), entonces f asume el mismo valor en todos los puntos de S_0 y, por lo tanto, la condición de separación de superficies de nivel críticas es satisfecha trivialmente.

Teorema 8.5 (Convergencia local del método del gradiente II). *Además de las hipótesis del Teorema 8.1, suponemos que el valor óptimo del problema (8.1) sea finito, y que (8.43) sea satisfecha para $U = L_{\|f'(\cdot)\|, \mathbb{R}^n}(\delta)$ y algunos $\delta > 0$ y $\gamma > 0$. Sea satisfecha también la condición de separación de superficies de nivel críticas de f . Supongamos que el Algoritmo 3.1.1 usa o la regla de Armijo, o la regla de longitud de paso fijo.*

Entonces cualquier secuencia $\{x^k\}$ del Algoritmo 3.1.1 converge a un punto estacionario del problema (8.1). La tasa de convergencia es lineal en relación a la función y es geométrica en relación a las variables.

Prueba. De nuevo, consideremos solamente la regla de Armijo, porque el caso de uso de longitud de paso fijo puede ser reducido al caso de regla de Armijo, como ya fue mostrado arriba.

Para todo k , se tiene que

$$f(x^k) - f(x^{k+1}) \geq \sigma \|x^{k+1} - x^k\|^2 / \check{\alpha}. \quad (8.44)$$

Luego, si $f'(x^k) \neq 0$ para todo k , la secuencia $\{f(x^k)\}$ es decreciente. Como el valor óptimo del problema (8.1) es finito, se sigue que $\{f(x^k)\}$ también está acotada inferiormente y, por lo tanto, ella converge. De (8.44) obtenemos entonces que $\|x^{k+1} - x^k\| \rightarrow 0$ ($k \rightarrow \infty$). De donde, usando también (8.18) y (8.20), concluimos que

$$\check{\alpha} \|f'(x^k)\| \leq \alpha_k \|f'(x^k)\| = \|x^{k+1} - x^k\| \rightarrow 0 \quad (k \rightarrow \infty).$$

Por lo tanto, $x^k \in U$ para todo k suficientemente grande. Sin pérdida de generalidad, podemos admitir que $\{x^k\} \subset U$. La última propiedad y (8.43) resultan en

$$\|x^k - \bar{x}^k\| \leq \frac{1}{\gamma} \|f'(x^k)\| \leq \frac{1}{\check{\alpha}\gamma} \|x^{k+1} - x^k\| \rightarrow 0 \quad (k \rightarrow \infty), \quad (8.45)$$

donde $\bar{x}^k$ es una proyección del punto x^k en el conjunto S_0 de puntos estacionarios del problema (8.1) (como S_0 es cerrado, la proyección existe, pero ella puede no ser única en el caso en que S_0 no sea convexo; véase el Teorema 1.3.1). De (8.45) obtenemos que

$$\|\bar{x}^{k+1} - \bar{x}^k\| \leq \|\bar{x}^{k+1} - x^{k+1}\| + \|x^{k+1} - x^k\| + \|x^k - \bar{x}^k\| \rightarrow 0 \quad (k \rightarrow \infty).$$

Ahora, por la condición de separación de superficies de nivel críticas de f , existe un número $v \in \{s \in \mathbb{R} \mid s = f(\bar{x}), \bar{x} \in S_0\}$ tal que, para todo k suficientemente grande,

$$f(\bar{x}^k) = v. \quad (8.46)$$

En consecuencia, por el hecho de que $f'(\bar{x}^{k+1}) = 0$ (porque $\bar{x}^{k+1} \in S_0$), por el Lema 1.5.4, por la definición de proyección y por (8.45), obtenemos que

$$\begin{aligned} |f(x^{k+1}) - v| &= |f(x^{k+1}) - f(\bar{x}^{k+1}) - \langle f'(\bar{x}^{k+1}), x^{k+1} - \bar{x}^{k+1} \rangle| \\ &\leq \frac{L}{2} \|x^{k+1} - \bar{x}^{k+1}\|^2 \\ &\leq \frac{L}{2} \|x^{k+1} - \bar{x}^k\|^2 \\ &\leq \frac{L}{2} (\|x^{k+1} - x^k\| + \|x^k - \bar{x}^k\|)^2 \\ &\leq \frac{L}{2} \left(1 + \frac{1}{\alpha\gamma}\right)^2 \|x^{k+1} - x^k\|^2 \rightarrow 0 \quad (k \rightarrow \infty). \end{aligned}$$

Teniendo en cuenta que $\{f(x^k)\}$ es decreciente y por (8.44), obtenemos de la última relación que

$$0 \leq f(x^{k+1}) - v \leq M(f(x^k) - f(x^{k+1})), \quad (8.47)$$

donde

$$M = \frac{L\alpha}{2\sigma} \left(1 + \frac{1}{\alpha\gamma}\right)^2 > 0.$$

Redistribuyendo los términos en (8.47), obtenemos

$$0 \leq f(x^{k+1}) - v \leq q(f(x^k) - v), \quad (8.48)$$

donde $q = M/(1 + M) \in (0, 1)$. Esto significa que $\{f(x^k)\}$ converge a v con tasa lineal.

Ahora, usando (8.44) y (8.48), para todo k suficientemente grande obtenemos

$$\begin{aligned} \|x^{k+1} - x^k\| &\leq \sqrt{\frac{\alpha}{\sigma}} \sqrt{f(x^k) - f(x^{k+1})} \\ &\leq \sqrt{\frac{\alpha}{\sigma}} \sqrt{f(x^k) - v} \\ &\leq \sqrt{\frac{\alpha q}{\sigma}} \sqrt{f(x^{k-1}) - v} \\ &\dots \\ &\leq (\sqrt{q})^k \sqrt{\frac{\alpha}{\sigma}} \sqrt{f(x^0) - v}. \end{aligned}$$

Definiendo $\Gamma = \sqrt{\frac{\alpha}{\sigma}} \sqrt{f(x^0) - v}$, tenemos

$$\begin{aligned} \|x^{k+i} - x^k\| &\leq \sum_{j=0}^{i-1} \|x^{k+j+1} - x^{k+j}\| \\ &\leq \sum_{j=0}^{i-1} (\sqrt{q})^{k+j} \Gamma \\ &\leq (\sqrt{q})^k \frac{\Gamma}{1 - \sqrt{q}}. \end{aligned}$$

Esto muestra la propiedad de Cauchy de la secuencia $\{x^k\}$ y, por lo tanto, la convergencia de esta secuencia a un punto $\bar{x} \in \mathbb{R}^n$. Pasando al límite cuando $i \rightarrow \infty$ en la última desigualdad, obtenemos que

$$\|x^k - \bar{x}\| \leq (\sqrt{q})^k \frac{\Gamma}{1 - \sqrt{q}},$$

lo que significa que la tasa de convergencia de la secuencia $\{x^k\}$ es geométrica. Finalmente, de (8.45) obtenemos $\text{dist}(x^k, S_0) \rightarrow 0$ ($k \rightarrow \infty$). Por lo tanto, $\bar{x} \in S_0$. ■

8.2. El método de Newton. Métodos cuasi-Newton

La idea principal del método de Newton, presentado a continuación, es fundamental en varias áreas de la matemática computacional. En su forma básica, el método de Newton es una herramienta para resolver sistemas de ecuaciones no lineales. En principio, él no es un método de minimización. Por ejemplo, a diferencia de los métodos de descenso

considerados arriba, cuando es aplicado a un problema de optimización (i.e., a la ecuación $f'(x) = 0$), el método de Newton tiene la misma “preferencia” tanto por los minimizadores de f como por los maximizadores (o, de hecho, cualquier otro punto estacionario). Por otro lado, el método admite también una interpretación ligada a la optimización, lo que puede ser usado para una mejor adaptación a problemas de optimización y, en particular, para el desarrollo de estrategias de globalización.

La convergencia rápida del método de Newton se debe al uso de información de segunda orden. Como consecuencia, una iteración del método es significativamente más cara en comparación con el método del gradiente. Felizmente, el método de Newton sirve también como base de desarrollo de los métodos cuasi-Newton. Estos últimos son ligeramente más lentos que el método de Newton, pero tienen iteraciones mucho más baratas (en particular, ni tan más caras de lo que las del método del gradiente). Esto los hace bastante atractivos para uso práctico. Se puede decir que los métodos cuasi-Newton son, en general, los más eficientes y más usados entre todos los algoritmos de la optimización irrestricta (en el caso de funciones dos veces diferenciables).

8.2.1. El método de Newton para ecuaciones

El método de Newton clásico es introducido para el problema de encontrar un $x \in \mathbb{R}^n$ tal que

$$\Phi(x) = 0, \quad (8.49)$$

donde $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ es diferenciable. Sea $x^k \in \mathbb{R}^n$ una aproximación a alguna solución $\bar{x}$ de la ecuación (8.49). En torno a x^k , podemos aproximar (8.49) por su linealización

$$\Phi(x^k) + \Phi'(x^k)(x - x^k) = 0. \quad (8.50)$$

La relación (8.50) se llama la ecuación de iteración del método de Newton.

Algoritmo 8.3 (El método de Newton). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular $x^{k+1} \in \mathbb{R}^n$ como una solución de la ecuación lineal (8.50).
2. Tomar $k := k + 1$ y retornar al ítem 1.

Las iteraciones del método de Newton son ilustradas en la Figura 8.7.

Figura 8.7.: Iteraciones del método de Newton en el caso unidimensional.

Suponiendo que $\Phi'(x^k)$ sea no singular (en este caso, naturalmente, la solución de la ecuación de Newton es única), el método de Newton puede ser escrito en forma del esquema iterativo

$$x^{k+1} = x^k - (\Phi'(x^k))^{-1}\Phi(x^k), \quad k = 0, 1, \dots \quad (8.51)$$

Observamos que aunque $\Phi'(x^k)$ sea no singular, el cálculo de x^{k+1} no requiere necesariamente el cálculo de la inversa de esta matriz. Existen varios métodos de resolución de sistemas de ecuaciones lineales que no invierten la matriz asociada (lo que es caro desde el punto de vista computacional).

Las consideraciones siguientes, aunque un poco informales, muestran que cuando el método de Newton converge, podemos esperar convergencia rápida. Supongamos que una secuencia $\{x^k\}$ generada de acuerdo con el esquema (8.51) sea convergente a un punto $\bar{x} \in \mathbb{R}^n$, donde $\Phi(\bar{x}) = 0$ con $\Phi'(\bar{x})$ no singular. Por la Fórmula de Taylor de primer orden, se tiene que

$$0 = \Phi(\bar{x}) = \Phi(x^k) + \Phi'(x^k)(\bar{x} - x^k) + o(\|x^k - \bar{x}\|),$$

de donde

$$\begin{aligned} 0 &= (\Phi'(x^k))^{-1}(\Phi(x^k) + \Phi'(x^k)(\bar{x} - x^k) + o(\|x^k - \bar{x}\|)) \\ &= \bar{x} - (x^k - (\Phi'(x^k))^{-1}\Phi(x^k)) + o(\|x^k - \bar{x}\|) \\ &= \bar{x} - x^{k+1} + o(\|x^k - \bar{x}\|), \end{aligned}$$

lo que muestra convergencia superlineal:

$$x^{k+1} - \bar{x} = o(\|x^k - \bar{x}\|).$$

El razonamiento anterior, aunque válido, es incompleto. Para obtener un resultado verdaderamente satisfactorio, tenemos que probar la propia convergencia de la secuencia $\{x^k\}$ (arriba, la convergencia fue asumida). Esto es hecho en el teorema siguiente.

Teorema 8.6 (Convergencia local del método de Newton). Sea $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ diferenciable en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivada continua en este punto. Sea $\bar{x}$ una solución de la ecuación (8.49), tal que $\det \Phi'(\bar{x}) \neq 0$ (i.e., la matriz $\Phi'(\bar{x})$ es no singular).

Entonces para cualquier punto inicial $x^0 \in \mathbb{R}^n$ suficientemente próximo a $\bar{x}$, el Algoritmo 3.2.1 genera una secuencia $\{x^k\}$ bien definida que converge a $\bar{x}$. La tasa de convergencia es superlineal, y si la derivada de Φ es Lipschitz-continua en una vecindad de $\bar{x}$, entonces la tasa de convergencia es cuadrática.

Prueba. Por el teorema sobre pequeñas perturbaciones de una matriz no singular (véase el Teorema 6.18), existen una vecindad U del punto $\bar{x}$ y un número $M > 0$ tales que

$$\det \Phi'(x) \neq 0, \quad \|(\Phi'(x))^{-1}\| \leq M \quad \forall x \in U. \quad (8.52)$$

En particular, para $x^k \in U$ la ecuación (8.50) tiene una única solución x^{k+1} , i.e., la iteración del Algoritmo 3.2.1, a partir de tal x^k , está bien definida.

Además de eso, por (8.51), (8.52) y por el Teorema del Valor Medio, podemos tomar la vecindad U tal que, si $x^k \in U$, entonces

$$\begin{aligned} \|x^{k+1} - \bar{x}\| &= \|x^k - \bar{x} - (\Phi'(x^k))^{-1}\Phi(x^k)\| \\ &\leq \|(\Phi'(x^k))^{-1}\| \|\Phi(x^k) - \Phi(\bar{x}) - \Phi'(x^k)(x^k - \bar{x})\| \\ &\leq M \sup_{t \in [0,1]} \|\Phi'(tx^k + (1-t)\bar{x}) - \Phi'(x^k)\| \|x^k - \bar{x}\|. \end{aligned} \quad (8.53)$$

Notamos que

$$\sup_{t \in [0,1]} \|\Phi'(tx^k + (1-t)\bar{x}) - \Phi'(x^k)\| \rightarrow 0 \quad (x^k \rightarrow \bar{x}).$$

Por lo tanto, de (8.53), tenemos que para todo $q \in (0, 1)$ existe $\delta > 0$ tal que $B(\bar{x}, \delta) \subset U$ y, si $x^k \in B(\bar{x}, \delta)$,

$$\|x^{k+1} - \bar{x}\| \leq q \|x^k - \bar{x}\|.$$

En particular, $x^{k+1} \in B(\bar{x}, \delta)$. Concluimos que para todo x^0 suficientemente próximo a $\bar{x}$, el Algoritmo 3.2.1 genera una secuencia $\{x^k\}$ bien definida, y que esta secuencia converge a $\bar{x}$. Además de eso, la tasa de convergencia es superlineal (podemos tomar q arbitrariamente pequeño, i.e., $q \rightarrow 0$, a medida que $x^k \rightarrow \bar{x}$).

Cuando la derivada de Φ es Lipschitz-continua en U con módulo $L > 0$, de (8.53) obtenemos: si $x^k \in U$, entonces

$$\|x^{k+1} - \bar{x}\| \leq ML \|x^k - \bar{x}\|^2, \quad (8.54)$$

i.e., la convergencia es cuadrática. ■

Bajo las hipótesis del Teorema 8.6, la convergencia local del método de Newton es bien rápida. Sin embargo, es fácil ver que, en general, la convergencia es local mismo. O sea, para un punto inicial que no está suficientemente próximo a la solución, el método puede no funcionar, incluso cuando la solución satisface todas las hipótesis necesarias. La Figura 8.8 ilustra este hecho. Otros ejemplos serán dados en § 3.2.2.

Figura 8.8.: El método de Newton no posee convergencia global: en el dibujo, el método siempre genera los dos mismos puntos que no son soluciones de la ecuación $\Phi(x) = 0$.

Observamos que en el Teorema 8.6, así como en otros resultados sobre convergencia cuadrática de métodos Newtonianos, en lugar de la hipótesis de que la derivada de Φ sea Lipschitz-continua, podemos utilizar una condición un poco más débil:

$$\|\Phi'(x) - \Phi'(\bar{x})\| \leq L \|x - \bar{x}\| \quad \forall x \in V,$$

donde V es una vecindad de la solución $\bar{x}$ y $L > 0$ es una constante. Sin embargo, diferencias de este tipo no son muy significativas. Siguiendo la tradición, casi siempre formularemos resultados de esta naturaleza usando la continuidad de Lipschitz en una vecindad de la solución.

A veces, en la representación de $\Phi'(\cdot)$ es posible identificar algún término que se anula en el punto $\bar{x}$. En casos así, para simplificar los cálculos, es razonable descartar este término desde el inicio, i.e., sustituir $\Phi'(\cdot)$ por su aproximación

$\Psi : \mathbb{R}^n \rightarrow \mathbb{R}^{n \times n}$ correspondiente (el término que se anula en $\bar{x}$ viene dado por la diferencia $\Phi'(\cdot) - \Psi(\cdot)$). Esta estrategia es un ejemplo de métodos de Newton inexactos, que pueden ser representados por el siguiente esquema iterativo:

$$x^{k+1} = x^k - (\Psi(x^k))^{-1} \Phi(x^k), \quad k = 0, 1, \dots \quad (8.55)$$

Corolario 8.1. Supongamos que valen las hipótesis del Teorema 8.6. Se tiene que para todo $\Psi : \mathbb{R}^n \rightarrow \mathbb{R}^{n \times n}$ tal que

$$\|\Psi(x) - \Phi'(x)\| \rightarrow 0 \quad (x \rightarrow \bar{x}),$$

para cualquier punto inicial $x^0 \in \mathbb{R}^n$ suficientemente próximo a $\bar{x}$, el método dado por (8.55) genera una secuencia $\{x^k\}$ bien definida, que converge a $\bar{x}$. La tasa de convergencia es superlineal, y si la derivada de Φ es Lipschitz-continua en una vecindad V del punto $\bar{x}$ y existe un número $N > 0$ tal que

$$\|\Psi(x) - \Phi'(x)\| \leq N\|x - \bar{x}\| \quad \forall x \in V,$$

entonces la convergencia es cuadrática.

En implementaciones computacionales, principalmente cuando el problema es de gran tamaño, los sistemas de ecuaciones lineales asociados a las iteraciones del método de Newton se resuelven por algún método iterativo hasta que una cierta tolerancia sea alcanzada. Estrategias de este tipo se llaman de *métodos de Newton truncados*. Uno de los criterios típicos para la aceptación de una aproximación a la solución de la ecuación de Newton (8.50) como el iterando siguiente x^{k+1} viene dado por

$$\|\Phi(x^k) + \Phi'(x^k)(x^{k+1} - x^k)\| \leq \sigma_k \|\Phi(x^k)\|, \quad (8.56)$$

donde $\sigma_k \in [0, 1)$ es un parámetro.

Otra modificación del método de Newton que puede ser útil es la siguiente:

$$x^{k+1} = x^k - (\Phi'(x^0))^{-1} \Phi(x^k), \quad k = 0, 1, \dots \quad (8.57)$$

La ventaja de este método es que tenemos que calcular la derivada de Φ en un único punto, en vez de hacerlo en cada iteración. Además de eso, todos los sistemas lineales a ser resueltos tienen la misma matriz, lo que facilita el trabajo computacional drásticamente. Por otro lado, como es de esperar, la convergencia es más lenta en comparación con la del método de Newton.

Otra modificación, más práctica, consiste en un cierto compromiso entre el método de Newton puro y (8.57). Más precisamente, podemos calcular $\Phi'(x^k)$ no apenas para $k = 0$, y también no para cada iteración k , sino para alguna secuencia creciente de índices de iteraciones (por ejemplo, en las iteraciones con índices $0, s, 2s, \dots$, donde $s \geq 2$ es un número entero). Así obtenemos una reducción del costo del método puro (8.51), al mismo tiempo elevando la tasa de convergencia de (8.57).

8.2.2. El método de Newton para optimización irrestricta

Ahora consideremos el problema de optimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (8.58)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función dos veces diferenciable en $\mathbb{R}^n$. Los puntos estacionarios de este problema se caracterizan por la ecuación (8.49), donde

$$\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n, \quad \Phi(x) = f'(x).$$

Por lo tanto, podemos intentar calcular puntos estacionarios de (8.58) aplicando el método de Newton a la ecuación $f'(x) = 0$.

Sea $x^k \in \mathbb{R}^n$ una aproximación a un punto estacionario $\bar{x}$ del problema (8.58). La aproximación siguiente x^{k+1} es calculada como solución del sistema de ecuaciones lineales

$$f'(x^k) + f''(x^k)(x - x^k) = 0, \quad (8.59)$$

en relación a $x \in \mathbb{R}^n$. Suponiendo que $f''(x^k)$ sea no singular para todo k , obtenemos el esquema iterativo siguiente:

$$x^{k+1} = x^k - (f''(x^k))^{-1} f'(x^k), \quad k = 0, 1, \dots \quad (8.60)$$

Observamos que esta iteración admite una interpretación en términos de problemas de optimización. En particular, en torno del punto x^k , el problema de optimización irrestricta (8.58) puede ser aproximado por el siguiente problema de una función cuadrática:

$$\min f(x^k) + \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle f''(x^k)(x - x^k), x - x^k \rangle, \quad x \in \mathbb{R}^n. \quad (8.61)$$

Como es fácil ver, la ecuación de Newton (8.59) caracteriza los puntos estacionarios del problema cuadrático (8.61). Por lo tanto, el método de Newton para un problema de optimización irrestricto es lo siguiente.

Algoritmo 8.4 (El método de Newton para optimización irrestricta). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular $x^{k+1} \in \mathbb{R}^n$ como punto estacionario del problema (8.61).
2. Tomar $k := k + 1$ y retornar al Paso 1.

Del Teorema 8.6, inmediatamente obtenemos las siguientes propiedades del Algoritmo 3.2.2.

Corolario 8.2. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces diferenciable en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con segunda derivada continua en este punto. Sea $\bar{x}$ un punto estacionario del problema (8.58), que satisface la condición suficiente de segunda orden (dada en el Teorema 6.2).

Entonces para cualquier punto inicial $x^0 \in \mathbb{R}^n$ suficientemente próximo a $\bar{x}$, el Algoritmo 3.2.2 genera una secuencia $\{x^k\}$ bien definida, que converge a $\bar{x}$. La tasa de convergencia es superlineal, y si la derivada segunda de f es Lipschitz-continua en una vecindad de $\bar{x}$, la convergencia es cuadrática.

Bajo las condiciones del Corolario 8.2, uno de los métodos más eficientes para resolver la ecuación lineal (8.59) es el método de Cholesky. Este método permite obtener la descomposición LL^T de una matriz simétrica definida positiva en el orden de $n^3/6$ multiplicaciones y el mismo número de sumas (donde L es una matriz triangular con elementos positivos en la diagonal). Este esquema puede ser modificado para sustituir a la matriz $f''(x^k)$, cuando ella no es definida positiva, por una matriz definida positiva (por ejemplo, de la forma $f''(x^k) + \gamma E^n$ con $\gamma > 0$ suficientemente grande). Esto es importante para el desarrollo de estrategias de globalización de los métodos Newtonianos (véase § 3.3). Observamos que, sin la modificación mencionada arriba, el Corolario 8.2 continúa siendo válido si sustituimos la condición suficiente de segunda orden en el punto estacionario $\bar{x}$ por la condición más débil de que $f''(\bar{x})$ sea no singular. En este sentido, el método de Newton no tiene preferencia por minimizadores en relación a otros puntos estacionarios del problema (8.58).

La principal ventaja del método de Newton es la convergencia superlineal. Recordamos que en el caso de los métodos del gradiente considerados en § 3.1, la tasa de convergencia es, en la mejor de las hipótesis, lineal. Sin embargo, el método de Newton posee también algunas desventajas que mencionamos a continuación.

Primero, como ya fue visto en § 3.2.1, el método tiene apenas convergencia local. De nuevo, esto tiene que ser comparado, por ejemplo, con los mismos métodos del gradiente. Estos últimos tienen convergencia global en el sentido de que, dado un punto inicial cualquiera, los puntos de acumulación de la secuencia generada son puntos estacionarios del problema (8.58), suponiendo, es claro, que ciertas hipótesis razonables sean satisfechas. Cuando f es una función cuadrática, i.e.,

$$f(x) = \frac{1}{2} \langle Qx, x \rangle + \langle q, x \rangle, \quad x \in \mathbb{R}^n, \quad (8.62)$$

donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica no singular y $b \in \mathbb{R}^n$, el método de Newton encontrará el único punto estacionario de f en una iteración. Mas en el caso no cuadrático, la situación es bien más complicada. Primero, para algunos puntos iniciales, el método puede ni estar bien definido. Incluso cuando el método genera correctamente una secuencia de iteraciones, la secuencia puede no poseer puntos de acumulación o los puntos de acumulación de ella pueden no ser puntos estacionarios del problema, como veremos a continuación.

Ejemplo 8.1. Consideremos la función

$$f : \mathbb{R} \rightarrow \mathbb{R}, \quad f(x) = \begin{cases} -x^4/(4\tau^3) + (1 + 3/\tau)x^2/2, & \text{si } |x| \leq \tau, \\ x^2/2 + 2|x| - 3\tau/4, & \text{si } |x| > \tau, \end{cases}$$

donde $\tau > 0$ es un parámetro. Como es fácil de verificar, para cualquier $\tau > 0$ la función f es dos veces diferenciable en $\mathbb{R}$, con segunda derivada continua. Además, el problema (8.58) definido por esta f tiene un único punto estacionario $\bar{x} = 0$, y se tiene que $f''(\bar{x}) = 1 + 3/\tau > 0$. En particular, todas las hipótesis del Corolario 8.2 son satisfechas.

Tomaremos $x^0 = \tau$. La secuencia $\{x^k\}$ generada por el Algoritmo 3.2.2 tiene la siguiente forma: $x^k = 2(-1)^k$, $k = 1, 2, \dots$. En particular, $\bar{x}$ no es punto de acumulación de $\{x^k\}$, independientemente de cuán pequeño sea τ (i.e., cuán próximo x^0 sea a $\bar{x}$).

La globalización de métodos newtonianos será considerada en § 3.3. Por ahora, mencionaremos que para este fin puede ser útil la interpretación (8.61) de la iteración del método en términos de problemas de optimización, así como la introducción de la longitud de paso, i.e., sustitución del esquema (8.60) por

$$x^{k+1} = x^k - \alpha_k (f''(x^k))^{-1} f'(x^k), \quad k = 0, 1, \dots$$

donde $\alpha_k > 0$ puede ser diferente de 1. Lejos de una solución del problema, el paso unitario $\alpha_k = 1$, que caracteriza el método de Newton puro, puede no resultar en decrecimiento de la función objetivo. En este caso, el método de Newton puro no es un método de descenso, en cuanto que un paso más corto en la misma dirección puede garantizar esta propiedad.

Como ya notamos, en cada iteración del método de Newton es necesario calcular la derivada segunda de la función objetivo y resolver el sistema de ecuaciones lineales correspondiente. Las modificaciones de los métodos que permiten reducir el costo computacional de cada iteración manteniendo convergencia rápida serán consideradas en § 3.2.3.

8.2.3. Métodos cuasi-Newton

Una clase importante de métodos de optimización irrestricta viene dada por el esquema iterativo

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k = -Q_k f'(x^k), \quad k = 0, 1, \dots, \quad (8.63)$$

donde, para todo k , $Q_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, y $\alpha_k > 0$ es la longitud de paso calculada utilizando una de las reglas de búsqueda lineal presentadas en § 3.1.1. Notemos que el método (8.63) es un método de descenso. En efecto, si x^k no es un punto estacionario del problema (8.58), como Q_k es definida positiva, se tiene que

$$\langle f'(x^k), d^k \rangle = -\langle Q_k f'(x^k), f'(x^k) \rangle < 0, \quad (8.64)$$

y por lo tanto, por el Lema 8.1, d^k es una dirección de descenso de f en x^k , i.e., $d^k \in \mathcal{D}_f(x^k)$. En el caso de $Q_k = E^n$, (8.63) se reduce a un de los métodos de gradiente, y en el caso de $Q_k = (f''(x^k))^{-1}$ con $\alpha_k = 1$, obtenemos el método de Newton puro. Existen, sin embargo, otras posibilidades que son más atractivas computacionalmente que las dos obvias mencionadas arriba.

Algoritmo 8.5 (Método de descenso con métrica variable). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$. Elegir una de las reglas de búsqueda lineal presentadas en § 3.1.1 y los parámetros asociados: $\hat{\alpha} > 0$ (o $\hat{\alpha} = +\infty$) en el caso de la minimización unidimensional; $\hat{\alpha} > 0, \sigma, \theta \in (0, 1)$ en el caso de la regla de Armijo; y $\bar{\alpha} > 0$ en el caso de longitud de paso fijo.

1. Elegir una matriz $n \times n$ simétrica definida positiva Q_k y tomar $d^k = -Q_k f'(x^k)$. Calcular la longitud de paso α_k en la dirección d^k , por la regla de búsqueda lineal elegida (si $f'(x^k) = 0$, formalmente definimos $\alpha_k = 1$).
2. Tomar $x^{k+1} = x^k + \alpha_k d^k$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

Los métodos cuasi-Newton son métodos de la forma (8.63), donde las matrices Q_k son elegidas para aproximar, en un cierto sentido, a la matriz $(f''(\bar{x}))^{-1}$ para alguna solución $\bar{x}$. Más precisamente, la secuencia $\{Q_k\}$ tiene que satisfacer la condición de Dennis-Moré (8.66), dada en el teorema siguiente.

Teorema 8.7 (Teorema de Dennis-Moré). Supongamos que se satisfacen las hipótesis del Corolario 8.2. Además de eso, supongamos que la secuencia $\{x^k\}$, generada por el Algoritmo 3.2.3 utilizando la regla de búsqueda lineal de Armijo con $\hat{\alpha} = 1$ y $\sigma \in (0, 1/2)$, converge a $\bar{x}$.

Entonces, las siguientes afirmaciones son equivalentes:

- (a) La tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal, $\alpha_k = 1$ para todo k suficientemente grande, y

$$\|Q_k f'(x^k)\| \leq M \|f'(x^k)\| \quad \forall k = 0, 1, \dots, \quad (8.65)$$

donde $M > 0$ es una constante que no depende de k .

(b) Se tiene que

$$(Q_k - (f''(\bar{x}))^{-1})f'(x^k) = o(\|f'(x^k)\|). \quad (8.66)$$

Prueba. Primero, supongamos que la afirmación (a) se satisface. De (8.63), teniendo en cuenta que $\alpha_k = 1$ para todo k suficientemente grande, tenemos que

$$\begin{aligned} & ((f''(\bar{x}))^{-1} - Q_k)f'(x^k) \\ &= (f''(\bar{x}))^{-1}f'(x^k) + x^{k+1} - x^k \\ &= (f''(\bar{x}))^{-1}(f'(x^k) - f'(\bar{x}) - f''(\bar{x})(x^k - \bar{x})) \\ &\quad + x^{k+1} - \bar{x} \\ &= o(\|x^k - \bar{x}\|), \end{aligned} \quad (8.67)$$

donde la última igualdad sigue de la Fórmula de Taylor y de la convergencia superlineal de $\{x^k\}$ a $\bar{x}$. De (8.65), obtenemos que

$$\begin{aligned} M\|f'(x^k)\| &\geq \|Q_k f'(x^k)\| \\ &\geq \|x^k - \bar{x}\| - \|x^{k+1} - \bar{x}\| \\ &= \|x^k - \bar{x}\| + o(\|x^k - \bar{x}\|). \end{aligned}$$

Por lo tanto,

$$\begin{aligned} \frac{o(\|x^k - \bar{x}\|)}{\|f'(x^k)\|} &\leq \frac{o(\|x^k - \bar{x}\|)}{\|x^k - \bar{x}\|/M + o(\|x^k - \bar{x}\|)} \\ &= \frac{o(\|x^k - \bar{x}\|)/\|x^k - \bar{x}\|}{1/M + o(\|x^k - \bar{x}\|)/\|x^k - \bar{x}\|} \rightarrow 0 \quad (k \rightarrow \infty). \end{aligned}$$

Combinando esta última relación con (8.67), obtenemos (8.66).

Ahora supongamos que la afirmación (b) se satisface. La condición (8.65) sigue trivialmente (si no, obtenemos una contradicción obvia con (8.66)). Probaremos que $\alpha_k = 1$ para todo k suficientemente grande. Por el Teorema del Valor Medio, existe $\tilde{t}_k \in [0, 1]$ tal que

$$\begin{aligned} f(x^k - Q_k f'(x^k)) &= f(x^k) - \langle f'(x^k), Q_k f'(x^k) \rangle \\ &\quad + \frac{1}{2} \langle f''(\bar{x}^k) Q_k f'(x^k), Q_k f'(x^k) \rangle, \end{aligned}$$

donde $\bar{x}^k = x^k - \tilde{t}_k Q_k f'(x^k)$. Para verificar que $\alpha_k = 1$ satisface la regla de Armijo, basta mostrar que

$$\langle f'(x^k), Q_k f'(x^k) \rangle - \frac{1}{2} \langle f''(\bar{x}^k) Q_k f'(x^k), Q_k f'(x^k) \rangle \geq \sigma \langle f'(x^k), Q_k f'(x^k) \rangle. \quad (8.68)$$

Observamos que $\{\bar{x}^k\} \rightarrow \bar{x}$ ($k \rightarrow \infty$), porque $\{x^k\} \rightarrow \bar{x}$ y $\{Q_k f'(x^k)\} \rightarrow 0$ (la última propiedad se sigue de (8.65)). Por lo tanto, por (8.66), la desigualdad (8.68) puede ser escrita como

$$(1 - \sigma) \langle f'(x^k), (f''(\bar{x}))^{-1} f'(x^k) \rangle \geq \frac{1}{2} \langle f'(x^k), (f''(\bar{x}))^{-1} f'(x^k) \rangle + o(\|f'(x^k)\|^2),$$

o

$$(1/2 - \sigma) \langle (f''(\bar{x}))^{-1} f'(x^k), f'(x^k) \rangle \geq o(\|f'(x^k)\|^2).$$

Esta última desigualdad se satisface para todo k suficientemente grande, porque $\sigma \in (0, 1/2)$, y el hecho de que $f''(\bar{x})$ es definida positiva implica que $(f''(\bar{x}))^{-1}$ es definida positiva, y por lo tanto, existe $\gamma > 0$ tal que

$$(1/2 - \sigma) \langle (f''(\bar{x}))^{-1} f'(x^k), f'(x^k) \rangle \geq \gamma(1/2 - \sigma) \|f'(x^k)\|^2.$$

Finalmente, probaremos que la tasa de convergencia de $\{x^k\}$ es superlineal. Para k suficientemente grande, de (8.63), (8.66) y $\alpha_k = 1$, obtenemos

$$\begin{aligned}\|x^{k+1} - \bar{x}\| &= \|x^k - \bar{x} - Q_k f'(x^k)\| \\ &= \|x^k - \bar{x} - (f''(\bar{x}))^{-1} f'(x^k)\| + o(\|f'(x^k)\|) \\ &\leq \|(f''(\bar{x}))^{-1}\| \|f'(x^k) - f'(\bar{x}) - f''(\bar{x})(x^k - \bar{x})\| \\ &\quad + o(\|f'(x^k)\| - f'(\bar{x})) \\ &= o(\|x^k - \bar{x}\|),\end{aligned}$$

lo que concluye la demostración. ■

Una de las conclusiones importantes del Teorema de Dennis-Moré es la siguiente: en la optimización de funciones dos veces diferenciables, para ser eficiente, un método debe hacer uso de aproximación de segunda orden de la función objetivo, de alguna manera. En particular, métodos que utilizan apenas aproximación de primer orden no pueden poseer convergencia superlineal en general. Cabe observar que para el método de Newton, así como para métodos de Newton inexactos, en el caso en que la convergencia de la secuencia $\{x^k\}$ a $\bar{x}$, la condición (8.66) de Dennis-Moré se satisface automáticamente. Sin embargo, la información de segunda orden también puede ser construida implícitamente, sin cálculo directo de la derivada segunda de f . Esta es la idea principal de los métodos cuasi-Newton: la sustitución del cálculo de $f''(x^k)$ y de la resolución del sistema de ecuaciones lineales correspondiente, por aproximación directa del paso ideal $(f''(\bar{x}))^{-1} f'(x^k)$. Resaltamos que esta aproximación, en principio, no es en el sentido de la relación $Q_k \rightarrow (f''(\bar{x}))^{-1}$ ($k \rightarrow \infty$), sino en el sentido mucho más relajado de (8.66). Estas aproximaciones deben ser calculadas en cada iteración sin hacer uso de la derivada segunda de f . Esto puede ser hecho de varias maneras diferentes. Algunas serán presentadas a continuación.

Para todo k , definimos

$$r^k = x^{k+1} - x^k, \quad s^k = f'(x^{k+1}) - f'(x^k). \quad (8.69)$$

Notamos que esta información ya está disponible en el momento de la elección de Q_{k+1} . Como queremos que esta matriz aproxime, en cierto sentido, a la inversa de la Hessiana de f , es natural imponer la condición

$$Q_{k+1} s^k = r^k, \quad (8.70)$$

que es llamada de ecuación cuasi-Newton. Esta ecuación puede ser explicada por las consideraciones a seguir. Si $\alpha_k = 1$, por (8.63) y (8.69), tenemos que

$$r^k = -Q_k f'(x^k).$$

Teniendo en cuenta la fórmula (8.152) (N. del T.: en referencia a los ejercicios), Q_{k+1} tiene que ser elegida para que el vector $Q_{k+1} r^k$ aproxime a $f''(\bar{x}) r^k$. Observamos que

$$s^k = \int_0^1 f''(tx^{k+1} + (1-t)x^k) r^k dt.$$

Implícitamente admitiendo que la matriz $f''(tx^{k+1} + (1-t)x^k)$ aproxima a $f''(\bar{x})$ (lo que es automático si $\{x^k\} \rightarrow \bar{x}$), es natural pedir la condición

$$s^k = Q_{k+1}^{-1} r^k,$$

que resulta en (8.70).

Resumiendo, dados una matriz simétrica definida positiva Q_k y vectores r^k y s^k , la propuesta es elegir una matriz simétrica definida positiva Q_{k+1} que satisfaga (8.70). No es difícil ver que el número de elecciones admisibles es, de hecho, infinito. Sin embargo, es natural (por ejemplo, por razones de estabilidad numérica) pedir que la mudanza entre Q_k y Q_{k+1} , i.e., la diferencia $Q_{k+1} - Q_k$, sea “mínima” en algún sentido. Dependiendo de la noción de “minimalidad” adoptada, obtenemos métodos cuasi-Newton diferentes.

Históricamente, el primer método cuasi-Newton es el método de Davidon-Fletcher-Powell (DFP), que toma Q_0 como una matriz simétrica definida positiva arbitraria (digamos, $Q_0 = E^n$), y para todo k define

$$Q_{k+1} = Q_k + \frac{r^k (r^k)^\top}{\langle r^k, s^k \rangle} - \frac{(Q_k s^k)(Q_k s^k)^\top}{\langle Q_k s^k, s^k \rangle}. \quad (8.71)$$

Notemos que todas las matrices así generadas serán simétricas. Además de eso, la ecuación cuasi-Newton (8.70) también será satisfecha:

$$\begin{aligned} Q_{k+1}s^k &= Q_k s^k + r^k \frac{\langle r^k, s^k \rangle}{\langle r^k, s^k \rangle} - Q_k s^k \frac{\langle Q_k s^k, s^k \rangle}{\langle Q_k s^k, s^k \rangle} \\ &= Q_k s^k + r^k - Q_k s^k \\ &= r^k. \end{aligned}$$

Finalmente, la diferencia $Q_{k+1} - Q_k$ es una matriz de rango 2, en lo máximo (porque el $\ker(Q_{k+1} - Q_k)$ contiene todos los vectores ortogonales a r^k y a $Q_k s^k$). En este sentido, la diferencia entre Q_{k+1} y Q_k es pequeña.

Recordamos que necesitamos aún que Q_{k+1} sea definida positiva. Esta propiedad depende no solamente de la fórmula que define Q_{k+1} , mas también de la regla de longitud de paso en (8.63). En particular, tenemos el siguiente resultado.

Proposición 8.1. Sea $Q_k \in \mathbb{R}^{n \times n}$ una matriz simétrica definida positiva. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en los puntos $x^k, x^{k+1} \in \mathbb{R}^n$, que satisfacen la relación (8.63) con algún valor de longitud de paso $\alpha_k > 0$.

Entonces las fórmulas (8.71) y (8.69) definen sin ambigüedad una matriz Q_{k+1} definida positiva si, y solamente si, la desigualdad

$$\langle f'(x^{k+1}), d^k \rangle > \langle f'(x^k), d^k \rangle \quad (8.72)$$

es satisfecha.

Prueba. Supongamos que Q_{k+1} sea definida positiva. Usando (8.63), (8.69) y (8.70), obtenemos

$$\begin{aligned} \langle d^k, f'(x^{k+1}) - f'(x^k) \rangle &= \frac{1}{\alpha_k} \langle r^k, s^k \rangle \\ &= \frac{1}{\alpha_k} \langle Q_{k+1}s^k, s^k \rangle > 0, \end{aligned}$$

donde la desigualdad vale suponiendo que $s^k \neq 0$ (caso contrario, Q_{k+1} en (8.71) no estaría bien definida). Obtenemos entonces (8.72).

Supongamos ahora que (8.72) se satisfaga. Utilizando también (8.63) y (8.69), obtenemos

$$\langle r^k, s^k \rangle = \alpha_k \langle d^k, f'(x^{k+1}) - f'(x^k) \rangle > 0. \quad (8.73)$$

En particular, $s^k \neq 0$ y, por el hecho de que Q_k es definida positiva, $\langle Q_k s^k, s^k \rangle > 0$. Esto muestra que Q_{k+1} en (8.71) está bien definida.

Para todo $\xi \in \mathbb{R}^n$, utilizando (8.71), obtenemos

$$\begin{aligned} \langle Q_{k+1}\xi, \xi \rangle &= \langle Q_k \xi, \xi \rangle + \frac{\langle r^k, \xi \rangle^2}{\langle r^k, s^k \rangle} - \frac{\langle Q_k s^k, \xi \rangle^2}{\langle Q_k s^k, s^k \rangle} \\ &= \frac{\|(Q_k)^{1/2}\xi\|^2 \|(Q_k)^{1/2}s^k\|^2 - \langle (Q_k)^{1/2}\xi, (Q_k)^{1/2}s^k \rangle^2}{\|(Q_k)^{1/2}s^k\|^2} \\ &\quad + \frac{\langle r^k, \xi \rangle^2}{\langle r^k, s^k \rangle} \geq 0, \end{aligned}$$

donde la desigualdad se sigue del hecho de que ambos términos son no negativos (por (8.73) y por la desigualdad de Cauchy-Schwarz). Además de eso, la igualdad $\langle Q_{k+1}\xi, \xi \rangle = 0$ solamente puede valer cuando ambos estos términos se anulan, i.e., cuando

$$\langle r^k, \xi \rangle = 0 \quad (8.74)$$

e $\|(Q_k)^{1/2}\xi\| \|(Q_k)^{1/2}s^k\| = |\langle (Q_k)^{1/2}\xi, (Q_k)^{1/2}s^k \rangle|$. La última igualdad significa que $(Q_k)^{1/2}\xi = t(Q_k)^{1/2}s^k$ para algún número t . Como la matriz $(Q_k)^{1/2}$ es no singular, concluimos que $\xi = ts^k$. Pero en este caso, por (8.74), obtenemos que $0 = \langle r^k, \xi \rangle = t \langle r^k, s^k \rangle$. Teniendo en cuenta (8.73), esto solo es posible cuando $t = 0$, i.e., $\xi = 0$. Por lo tanto, Q_{k+1} es definida positiva. ■

Las consecuencias del resultado arriba son las siguientes. Si la longitud de paso en (8.63) se calcula por la regla de minimización unidimensional, tenemos que $\langle f'(x^{k+1}), d^k \rangle = 0$ (véase (8.5)). Por lo tanto, teniendo también en cuenta (8.64), tenemos que (8.72) vale automáticamente. En relación a las reglas de cumplimiento de paso más prácticas, observamos que (8.72) siempre se satisface en el caso de la regla de Wolfe (véase (8.12)). Las reglas de Armijo y de Goldstein, sin embargo, no poseen esta propiedad. Esta es la razón por la cual la regla de Wolfe es aquella utilizada con mayor frecuencia en las implementaciones de los métodos cuasi-Newton.

Entre todos los métodos cuasi-Newton, el método de Broyden-Fletcher-Goldfarb-Shanno (BFGS) es considerado actualmente el más eficiente. En este método, para todo k , definimos

$$Q_{k+1} = Q_k + \frac{(r^k - Q_k s^k)(r^k)^\top + r^k(r^k - Q_k s^k)^\top}{\langle r^k, s^k \rangle} - \frac{\langle r^k - Q_k s^k, s^k \rangle r^k (r^k)^\top}{\langle r^k, s^k \rangle^2}. \quad (8.75)$$

Es fácil ver que, como en el método DFP, las matrices generadas por (8.75) son simétricas, satisfacen la ecuación cuasi-Newton (8.70), y la diferencia $Q_{k+1} - Q_k$ tiene rango 2, en lo máximo.

Cuando f es una función cuadrática dada por (8.62), donde Q es definida positiva, y la longitud de paso α_k se calcula por la regla de minimización unidimensional, los métodos DFP y BFGS poseen convergencia finita al único punto estacionario de f (que en este caso es la única solución global del problema). En particular, el número de iteraciones j necesario para encontrar la solución es menor o igual a la dimensión del espacio ($j \leq n$) y se tiene que $Q_j = (f''(x^j))^{-1} = Q^{-1}$. Vale recordar que en el caso cuadrático, el cálculo de longitud de paso por la minimización unidimensional se reduce a una fórmula explícita (véase § 3.1.1). Para funciones cuadráticas, los métodos cuasi-Newton poseen una cierta equivalencia con métodos de direcciones conjugadas que serán presentados en § 3.4.

Resultados de convergencia y de tasa de convergencia para métodos cuasi-Newton en el caso no cuadrático pueden ser consultados en [9, 20]. Naturalmente, en este caso, la convergencia finita no puede ser esperada en general. Mas, con frecuencia, la tasa de convergencia es superlineal. La clase de métodos cuasi-Newton es considerada la más importante y más eficiente en el área de optimización irrestricta de funciones diferenciables. Como ya colocamos, esto se debe al hecho de que los métodos cuasi-Newton combinan convergencia rápida con un costo relativamente bajo de cada iteración. Desde el punto de vista teórico, cualquier método cuasi-Newton es apenas una realización aproximada del método de Newton, en el sentido de la condición de Dennis-Moré (8.66). Sin embargo, este es el caso cuando los detalles de implementación (que no presentamos en este libro) son tan importantes como la idea principal. Estos detalles pueden ser consultados en [9, 20].

8.2.4. Métodos cuasi-Newton

Una clase importante de métodos de optimización irrestricta es dada por el esquema iterativo

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k = -Q_k f'(x^k), \quad k = 0, 1, \dots, \quad (8.76)$$

donde, para todo k , $Q_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, y $\alpha_k > 0$ es la longitud de paso calculada utilizando una de las reglas de búsqueda lineal. Notamos que el método es un método de descenso. Con efecto, si x^k no es un punto estacionario del problema, como Q_k es definida positiva, se tiene que

$$\langle f'(x^k), d^k \rangle = -\langle Q_k f'(x^k), f'(x^k) \rangle < 0, \quad (8.77)$$

y por lo tanto d^k es una dirección de descenso de f en x^k . En el caso de $Q_k = E^n$, el esquema se reduce a uno de los métodos del gradiente, y en el caso de $Q_k = (f''(x^k))^{-1}$ con $\alpha_k = 1$, obtenemos el método de Newton puro. Existen, sin embargo, otras posibilidades que son más atractivas computacionalmente.

Algoritmo 8.6 (Método de descenso con métrica variable). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$. Elegir una de las reglas de búsqueda lineal y los parámetros asociados.

1. Elegir una matriz $n \times n$ simétrica definida positiva Q_k y tomar $d^k = -Q_k f'(x^k)$. Calcular la longitud de paso α_k en la dirección d^k , por la regla de búsqueda lineal elegida (se $f'(x^k) = 0$, formalmente definimos $\alpha_k = 1$).
2. Tomar $x^{k+1} = x^k + \alpha_k d^k$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

Los métodos cuasi-Newton son métodos de esta forma, donde las matrices Q_k son elegidas para aproximar, en un cierto sentido, la matriz $(f''(\bar{x}))^{-1}$ para alguna solución $\bar{x}$. Más precisamente, la secuencia $\{Q_k\}$ tiene que satisfacer la condición de Dennis-Moré, dada en el teorema siguiente.

Teorema 8.8 (Teorema de Dennis-Moré). Supongamos que se satisfacen las hipótesis del Corolario 3.2.2. Además de eso, supongamos que la secuencia $\{x^k\}$, generada por el Algoritmo utilizando la regla de búsqueda lineal de Armijo con $\hat{\alpha} = 1$ e $\sigma \in (0, 1/2)$, converge a $\bar{x}$.

Entonces, las siguientes dos afirmaciones son equivalentes:

(a) La tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal, $\alpha_k = 1$ para todo k suficientemente grande, y

$$\|Q_k f'(x^k)\| \leq M \|f'(x^k)\| \quad \forall k = 0, 1, \dots, \quad (8.78)$$

donde $M > 0$ es una constante que no depende de k .

(b) Se tiene que

$$(Q_k - (f''(\bar{x}))^{-1})f'(x^k) = o(\|f'(x^k)\|). \quad (8.79)$$

Prueba. Primero, supongamos que la afirmación (a) se satisface. Llevando en cuenta que $\alpha_k = 1$ para todo k suficientemente grande, tenemos que

$$\begin{aligned} ((f''(\bar{x}))^{-1} - Q_k)f'(x^k) &= (f''(\bar{x}))^{-1}f'(x^k) + x^{k+1} - x^k \\ &= (f''(\bar{x}))^{-1}(f'(x^k) - f'(\bar{x}) - f''(\bar{x})(x^k - \bar{x})) + x^{k+1} - \bar{x} \\ &= o(\|x^k - \bar{x}\|), \end{aligned} \quad (8.80)$$

donde la última igualdad se sigue de la Fórmula de Taylor y de la convergencia superlineal de $\{x^k\}$ a $\bar{x}$. De (8.78), obtenemos que

$$\begin{aligned} M\|f'(x^k)\| &\geq \|Q_k f'(x^k)\| \\ &\geq \|x^k - \bar{x}\| - \|x^{k+1} - \bar{x}\| = \|x^k - \bar{x}\| + o(\|x^k - \bar{x}\|). \end{aligned}$$

Por lo tanto,

$$\frac{o(\|x^k - \bar{x}\|)}{\|f'(x^k)\|} \leq \frac{o(\|x^k - \bar{x}\|)}{\|x^k - \bar{x}\|/M + o(\|x^k - \bar{x}\|)} \rightarrow 0 \quad (k \rightarrow \infty).$$

Combinando esta última relación con (8.80), obtenemos (8.79).

Ahora supongamos que la afirmación (b) se satisface. La condición (8.78) se sigue trivialmente (sino, obtenemos una contradicción obvia con (8.79)). Probaremos que $\alpha_k = 1$ para todo k suficientemente grande. Por el Teorema del Valor Medio, existe $\tilde{t}_k \in [0, 1]$ tal que

$$f(x^k - Q_k f'(x^k)) = f(x^k) - \langle f'(x^k), Q_k f'(x^k) \rangle + \frac{1}{2} \langle f''(\bar{x}^k) Q_k f'(x^k), Q_k f'(x^k) \rangle,$$

donde $\bar{x}^k = x^k - \tilde{t}_k Q_k f'(x^k)$. Para verificar que $\alpha_k = 1$ satisface la regla de Armijo, basta mostrar que

$$\langle f'(x^k), Q_k f'(x^k) \rangle - \frac{1}{2} \langle f''(\bar{x}^k) Q_k f'(x^k), Q_k f'(x^k) \rangle \geq \sigma \langle f'(x^k), Q_k f'(x^k) \rangle. \quad (8.81)$$

Observamos que $\{\bar{x}^k\} \rightarrow \bar{x}$ ($k \rightarrow \infty$), porque $\{x^k\} \rightarrow \bar{x}$ y $\{Q_k f'(x^k)\} \rightarrow 0$ (la última propiedad se sigue de (8.78)). Por tanto, por (8.79), la desigualdad (8.81) puede ser escrita como

$$(1 - \sigma) \langle f'(x^k), (f''(\bar{x}))^{-1} f'(x^k) \rangle \geq \frac{1}{2} \langle f'(x^k), (f''(\bar{x}))^{-1} f'(x^k) \rangle + o(\|f'(x^k)\|^2),$$

o bien

$$(1/2 - \sigma) \langle f'(x^k), (f''(\bar{x}))^{-1} f'(x^k) \rangle \geq o(\|f'(x^k)\|^2).$$

Esta última desigualdad se satisface para todo k suficientemente grande, porque $\sigma \in (0, 1/2)$, y el hecho de que $f''(\bar{x})$ es definida positiva implica que $(f''(\bar{x}))^{-1}$ es definida positiva, y por lo tanto, existe $\gamma > 0$ tal que

$$(1/2 - \sigma) \langle f'(x^k), (f''(\bar{x}))^{-1} f'(x^k) \rangle \geq \gamma (1/2 - \sigma) \|f'(x^k)\|^2.$$

Finalmente, probaremos que la tasa de convergencia de $\{x^k\}$ es superlineal. Para k suficientemente grande, $\alpha_k = 1$, obtenemos

$$\begin{aligned} \|x^{k+1} - \bar{x}\| &= \|x^k - \bar{x} - Q_k f'(x^k)\| \\ &= \|x^k - \bar{x} - (f''(\bar{x}))^{-1} f'(x^k) + ((f''(\bar{x}))^{-1} - Q_k) f'(x^k)\| \\ &\leq \|(f''(\bar{x}))^{-1} (f''(\bar{x})(x^k - \bar{x}) - f'(x^k))\| + o(\|f'(x^k)\|) \\ &= o(\|x^k - \bar{x}\|), \end{aligned}$$

lo que concluye la demostración. ■

Una de las conclusiones importantes del Teorema de Dennis-Moré es la siguiente: en la optimización de funciones dos veces diferenciables, para ser eficiente, un método debe hacer uso de aproximación de segunda orden de la

función objetivo, de alguna manera. En particular, métodos que utilizan apenas aproximación de primer orden no pueden poseer convergencia superlineal en general. Cabe observar que para el método de Newton, la condición de Dennis-Moré se satisface automáticamente.

No entanto, la información de segunda orden también puede ser construida implícitamente, sin cálculo directo de la derivada segunda de f . Esta es la idea principal de los métodos cuasi-Newton: la sustitución del cálculo de $f''(x^k)$ y de la resolución del sistema de ecuaciones lineales correspondiente, por una aproximación directa del paso calculada en cada iteración. Esto puede ser hecho de varias maneras diferentes.

Para todo k , definimos

$$r^k = x^{k+1} - x^k, \quad s^k = f'(x^{k+1}) - f'(x^k). \quad (8.82)$$

Notamos que esta información ya está disponible en el momento de la escogencia de Q_{k+1} . Como queremos que esta matriz aproxime, en un cierto sentido, la inversa de la Hessiana de f , es natural imponer la condición

$$Q_{k+1}s^k = r^k, \quad (8.83)$$

que es llamada de ecuación cuasi-Newton. Implícitamente admitiendo que la matriz $f''(\bar{x})$ es natural pedir la condición $s^k = Q_{k+1}^{-1}r^k$, que resulta en (8.83).

Resumiendo, dada una matriz simétrica definida positiva Q_k y vectores r^k e s^k , la propuesta es escoger una matriz simétrica definida positiva Q_{k+1} que satisfaga (8.83). Históricamente, el primer método cuasi-Newton es el método de Davidon-Fletcher-Powell (DFP), que toma Q_0 como una matriz simétrica definida positiva arbitraria (digamos, $Q_0 = E^n$), y para todo k define

$$Q_{k+1} = Q_k + \frac{r^k(r^k)^\top}{\langle r^k, s^k \rangle} - \frac{(Q_k s^k)(Q_k s^k)^\top}{\langle Q_k s^k, s^k \rangle}. \quad (8.84)$$

Notamos que todas las matrices así generadas serán simétricas. Además, la ecuación cuasi-Newton también será satisfecha.

Proposición 8.2. Sea $Q_k \in \mathbb{R}^{n \times n}$ una matriz simétrica definida positiva. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en los puntos $x^k, x^{k+1} \in \mathbb{R}^n$, que satisfacen la relación del paso con algún valor de longitud de paso $\alpha_k > 0$. Entonces las fórmulas definen sin ambigüedad una matriz Q_{k+1} definida positiva si, y solamente si, la desigualdad

$$\langle f'(x^{k+1}), d^k \rangle > \langle f'(x^k), d^k \rangle \quad (8.85)$$

es satisfecha.

Prueba. Supongamos que Q_{k+1} sea definida positiva. Usando la ecuación cuasi-Newton, obtenemos

$$\begin{aligned} \langle d^k, f'(x^{k+1}) - f'(x^k) \rangle &= \frac{1}{\alpha_k} \langle r^k, s^k \rangle \\ &= \frac{1}{\alpha_k} \langle Q_{k+1}s^k, s^k \rangle > 0, \end{aligned}$$

donde la desigualdad vale suponiendo que $s^k \neq 0$ (caso contrario, Q_{k+1} no estaría bien definida). Obtenemos entonces (8.85).

Supongamos ahora que (8.85) se satisfaga. Utilizando también el esquema obtenemos

$$\langle r^k, s^k \rangle = \alpha_k (\langle d^k, f'(x^{k+1}) - f'(x^k) \rangle) > 0.$$

En particular, $s^k \neq 0$ y, por el hecho de que Q_k es definida positiva, $\langle Q_k s^k, s^k \rangle > 0$. Esto muestra que Q_{k+1} está bien definida. Para todo $\xi \in \mathbb{R}^n$, obtenemos

$$\begin{aligned} \langle Q_{k+1}\xi, \xi \rangle &= \langle Q_k\xi, \xi \rangle + \frac{\langle r^k, \xi \rangle^2}{\langle r^k, s^k \rangle} - \frac{\langle Q_k s^k, \xi \rangle^2}{\langle Q_k s^k, s^k \rangle} \\ &= \frac{\|Q_k^{1/2}\xi\|^2 \|Q_k^{1/2}s^k\|^2 - \langle Q_k^{1/2}\xi, Q_k^{1/2}s^k \rangle^2}{\|Q_k^{1/2}s^k\|^2} + \frac{\langle r^k, \xi \rangle^2}{\langle r^k, s^k \rangle} \geq 0, \end{aligned}$$

donde la desigualdad sigue del hecho de que ambos términos son no negativos por la desigualdad de Cauchy-Schwarz. Además, la igualdad a 0 solamente puede valer cuando ambos términos se anulan, i.e., cuando $\langle r^k, \xi \rangle = 0$ y $\|Q_k^{1/2}\xi\| \|Q_k^{1/2}s^k\| = |\langle Q_k^{1/2}\xi, Q_k^{1/2}s^k \rangle|$. La última igualdad significa que $Q_k^{1/2}\xi = t(Q_k^{1/2}s^k)$ para algún t . Como $Q_k^{1/2}$ es no-singular, esto es posible cuando $t = 0$, i.e., $\xi = 0$. Por lo tanto, Q_{k+1} es definida positiva. ■

Como consecuencias del resultado arriba son las siguientes. Si el longitud de paso es calculado por la regla de minimización unidimensional, tenemos que $\langle f'(x^{k+1}), d^k \rangle = 0$. Por tanto, valiendo automáticamente la condición, la relación de curvatura (8.85) siempre es satisfecha. Las reglas de Armijo y de Goldstein, no obstante, no poseen esta propiedad. Esta es la razón por la cual la regla de Wolfe es aquella utilizada con mayor frecuencia en implementaciones de métodos cuasi-Newton.

Entre todos los métodos cuasi-Newton, el método de Broyden-Fletcher-Goldfarb-Shanno (BFGS) es considerado actualmente el más eficiente. En este método, para todo k , definimos

$$Q_{k+1} = Q_k + \frac{(r^k - Q_k s^k)(r^k)^\top + r^k(r^k - Q_k s^k)^\top}{\langle r^k, s^k \rangle} - \frac{\langle r^k - Q_k s^k, s^k \rangle r^k (r^k)^\top}{\langle r^k, s^k \rangle^2}. \quad (8.86)$$

Es fácil ver que, como en el método DFP, las matrices generadas por (8.86) son simétricas, satisfacen a la ecuación cuasi-Newton, y la diferencia $Q_{k+1} - Q_k$ tiene puesto 2, como máximo.

Cuando f es una función cuadrática dada y Q es definida positiva, si el longitud de paso α_k es calculado por la regla de minimización unidimensional, los métodos DFP y BFGS poseen convergencia finita al único punto estacionario de f (que en este caso es la única solución global del problema). En particular, el número de iteraciones j necesario para encontrar la solución es menor o igual a la dimensión del espacio ($j \leq n$) y se tiene que $Q_j = (f''(x^j))^{-1} = Q^{-1}$.

8.3. Estrategias de globalización

Por lo expuesto arriba, los métodos Newtonianos poseen (bajo ciertas hipótesis, claro) convergencia local con tasa rápida pero, en general, no poseen la propiedad de convergencia global (a partir de un punto inicial arbitrario). Por lo tanto, es natural intentar modificar métodos de este tipo para garantizar convergencia global, al mismo tiempo preservando eficiencia local. A propósito, los métodos locales pasan a ser verdaderamente útiles solamente cuando son incrementados por alguna estrategia global, capaz de proveer un punto inicial adecuado para el buen funcionamiento del esquema local. A continuación, presentamos algunas ideas con el objetivo de alcanzar este fin. Detalles de implementación pueden ser consultados, por ejemplo, en [1, 7].

8.3.1. Métodos con búsqueda lineal

Una clase importante de métodos de optimización son los métodos de descenso, considerados en § 3.1. Recordamos que métodos de este tipo poseen convergencia global (a los puntos estacionarios del problema) bajo hipótesis bien naturales. Sin embargo, no podemos esperar convergencia local con tasa mejor que la lineal, incluso bajo la mejor de las hipótesis. Esto lleva a la idea de combinar, de alguna manera y dentro de un único algoritmo, las buenas propiedades globales de métodos de descenso con la convergencia rápida de métodos Newtonianos. Para este fin, una estrategia natural es introducir búsqueda lineal en la dirección Newtoniana, para garantizar el decrecimiento de la función objetivo, en caso de que el paso completo (i.e., con longitud igual a uno) haga que el valor de la función aumente. En principio, podemos esperar que tal modificación (cuando se implementa adecuadamente) heredará las propiedades globales de los métodos de descenso. Por otro lado, si conseguimos probar que, bajo las hipótesis suficientes para la convergencia local del método Newtoniano asociado, el método modificado acepta la longitud de paso igual a uno para todo k suficientemente grande, obtendremos entonces la convergencia local deseada.

Consideremos de nuevo un problema de minimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (8.87)$$

donde la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es dos veces diferenciable. Consideremos el esquema general del Algoritmo 3.2.3, i.e.,

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k = -Q_k f'(x^k), \quad k = 0, 1, \dots, \quad (8.88)$$

donde para todo k la matriz $Q_k \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva, y $\alpha_k > 0$ es el valor de la longitud del paso. Para simplificar, supongamos que α_k sea calculado por la regla de Armijo.

Por el Teorema 3.2.2, para este método la tasa superlineal de convergencia a un punto estacionario $\bar{x} \in \mathbb{R}^n$ del problema (8.87) (cuando hay convergencia) puede ser esperada si Q_k aproxima a $(f''(\bar{x}))^{-1}$ cuando $k \rightarrow \infty$, en el sentido de la relación (8.66) de Dennis-Moré. Además de esto, en este caso $\alpha_k = 1$ para todo k suficientemente grande. Cabe resaltar que simplemente tomando $\alpha_k = 1$ para todo k , la convergencia global no puede ser garantizada: lejos de puntos estacionarios, un paso así puede ser largo de más para obtener una secuencia $\{f(x^k)\}$ no creciente.

Por otro lado, como fue mencionado en § 3.2.3, si en el Algoritmo 3.2.3 en vez de tomar $\alpha_k = 1$ el valor de α_k es calculado por la regla de Armijo, obtenemos un método de descenso para el problema (8.87). Más aún, suponiendo que

$$\|Q_k\| \leq \Gamma, \quad \langle Q_k d, d \rangle \geq \gamma \|d\|^2 \quad \forall d \in \mathbb{R}^n, \forall k, \quad (8.89)$$

para ciertos $\Gamma > 0$ y $\gamma > 0$, utilizando (8.88), obtenemos que para todo k ,

$$\begin{aligned} \langle f'(x^k), d^k \rangle \|d^k\|^{-2} &= -\langle f'(x^k), Q_k f'(x^k) \rangle \|Q_k f'(x^k)\|^{-2} \\ &\leq -\gamma/\Gamma^2 < 0. \end{aligned} \quad (8.90)$$

En particular, la relación (8.9) vale con $\delta = -\gamma/\Gamma^2$. De donde concluimos que existe una constante $\check{\alpha}$ que no depende de k , tal que

$$\alpha_k \geq \check{\alpha} > 0; \quad (8.91)$$

vea el razonamiento en § 3.1.1.

El teorema siguiente es una generalización del Teorema 3.1.1. El caso de la minimización unidimensional y de la longitud de paso fijo pueden ser reducidos a la consideración de la regla de Armijo de la misma manera que en la demostración del Teorema 3.1.1.

Teorema 8.9. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$. Supongamos que el Algoritmo 3.2.3 utiliza la regla de Armijo. Supongamos, finalmente, que la secuencia de matrices $\{Q_k\}$ elegidas en este método satisface (8.89) para ciertos $\Gamma > 0$ y $\gamma > 0$.

Entonces, todo punto de acumulación de la secuencia $\{x^k\}$ generada por el Algoritmo 3.2.3 es un punto estacionario del problema (8.87). Si un punto de acumulación existe, o si la función f está acotada inferiormente en $\mathbb{R}^n$, entonces

$$f'(x^k) \rightarrow 0 \quad (k \rightarrow \infty).$$

Prueba. Supongamos que $f'(x^k) \neq 0$ para todo k (ya que, caso contrario, la afirmación es obvia). Por la desigualdad de Armijo (8.6), se tiene que

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) + \sigma \alpha_k \langle f'(x^k), d^k \rangle \\ &\leq f(x^k) + \sigma \check{\alpha} \delta \|d^k\|^2, \end{aligned}$$

donde utilizamos (8.90), (8.91), y definimos $\delta = -\gamma/\Gamma^2 < 0$.

En particular, la secuencia $\{f(x^k)\}$ es no creciente. Si f está acotada inferiormente en $\mathbb{R}^n$, o si $\{x^k\}$ tiene un punto de acumulación, sigue que $\{f(x^k)\}$ converge. Por lo tanto, tenemos que $f(x^{k+1}) - f(x^k) \rightarrow 0$ ($k \rightarrow \infty$) y, luego, $d^k \rightarrow 0$ ($k \rightarrow \infty$). Como $f'(x^k) = -Q_k^{-1} d^k$ y las matrices $\{Q_k\}$ son uniformemente definidas positivas (véase (8.89)), obtenemos el resultado. ■

Las relaciones (8.89) pueden ser esperadas si la secuencia de matrices $\{Q_k\}$ es generada utilizando fórmulas de métodos cuasi-Newton y los parámetros de longitud de paso α_k son calculados por la regla de Wolfe (el papel importante de esta regla en el contexto de métodos cuasi-Newton ya fue mencionado en § 3.2.3). Cabe mencionar, sin embargo, que no existen pruebas completas de las condiciones (8.89) para métodos DFP y BFGS, por lo menos en el caso no convexo y sin modificaciones de los métodos en cuestión.

Como Q_k también puede ser elegida como la inversa de una modificación definida positiva (regularización) de la matriz $f''(x^k)$; véase § 3.2.2. Es claro que la modificación de $f''(x^k)$ solo es necesaria cuando esta matriz no es definida positiva. Cuando ella es definida positiva, podemos tomar $Q_k = (f''(x^k))^{-1}$, ya que esta elección es atractiva desde el punto de vista de la convergencia local. Sin embargo, el requerimiento de que $f''(x^k)$ sea uniformemente definida positiva para todo k (la segunda condición en (8.89)) es ligeramente más débil que la convexidad fuerte de f en $\mathbb{R}^n$. En el caso en que no hay convexidad fuerte, la regularización se vuelve necesaria.

Existen también otras posibilidades de globalización con búsqueda lineal (véase el Ejercicio 3.3.1).

Las estrategias de globalización pueden ser extendidas tanto a problemas de optimización con restricciones (véase § 4.6.3), como a sistemas de ecuaciones no lineales y otros problemas variacionales (incluso cuando ellos no tienen relaciones directas con optimización). Para este fin, es necesario encontrar una *función de mérito*, i.e., una función que puede medir, en algún sentido, la calidad de un punto dado como aproximación a la solución del problema en cuestión.

Por ejemplo, consideremos el sistema de ecuaciones

$$\Phi(x) = 0, \quad (8.92)$$

donde $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ es diferenciable. En este contexto, necesitamos una función de mérito tal que, bajo hipótesis naturales, los puntos estacionarios de ella sean soluciones del sistema de ecuaciones original. Una elección popular viene dada por

$$\varphi : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \varphi(x) = \frac{1}{2} \|\Phi(x)\|^2.$$

En este caso, tenemos que

$$\varphi'(x) = (\Phi'(x))^T \Phi(x), \quad x \in \mathbb{R}^n.$$

Si $\bar{x} \in \mathbb{R}^n$ es un punto estacionario de la función φ tal que la matriz $\Phi'(\bar{x})$ es no singular, entonces $\varphi'(\bar{x}) = 0$ implica $\Phi(\bar{x}) = 0$, i.e., $\bar{x}$ es una solución del problema original (8.92). Además de eso, en todo punto $x \in \mathbb{R}^n$ donde la matriz $\Phi'(x)$ es no singular, la dirección de Newton $d = -(\Phi'(x))^{-1}\Phi(x)$ es una dirección de descenso de la función φ (si x no es una solución de (8.92)). En efecto,

$$\begin{aligned} \langle \varphi'(x), d \rangle &= -\langle (\Phi'(x))^T \Phi(x), (\Phi'(x))^{-1} \Phi(x) \rangle \\ &= -\|\Phi(x)\|^2 < 0, \end{aligned}$$

y la afirmación se sigue del Lema 8.1.

Sin embargo, es fácil observar que el método de Newton correspondiente, incluso con búsqueda lineal, puede fallar en puntos donde la derivada de Φ es degenerada (singular), y estos puntos pueden no ser ni soluciones del sistema de ecuaciones (8.92), ni puntos estacionarios de la función φ .

8.3.2. Métodos de regiones de confianza

Otra estrategia natural de globalización de métodos Newtonianos es la siguiente. Como ya vimos, cada iteración de un método Newtoniano consiste en la resolución de un subproblema obtenido a través de la aproximación local (en torno de x^k dado) del problema original. Naturalmente, tal aproximación solo puede ser “confiada” en una vecindad suficientemente pequeña del punto x^k . Parece entonces razonable intentar minimizar la aproximación de la función objetivo exactamente en esta vecindad, llamada *región de confianza*², y no en todo el espacio.

De nuevo, consideremos un problema de optimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (8.93)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Sea $x^k \in \mathbb{R}^n$ una aproximación a la solución del problema. El subproblema de un método Newtoniano viene dado por

$$\min \psi_k(x), \quad x \in \mathbb{R}^n, \quad (8.94)$$

donde

$$\begin{aligned} \psi_k : \mathbb{R}^n &\rightarrow \mathbb{R}, \\ \psi_k(x) &= f(x^k) + \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle H_k(x - x^k), x - x^k \rangle, \end{aligned} \quad (8.95)$$

y $H_k \in \mathbb{R}(n, n)$ es una matriz simétrica (comparar con (8.61)). Una iteración del método de regiones de confianza correspondiente consiste en la resolución del siguiente subproblema:

$$\min \psi_k(x) \quad \text{sujeto a } x \in B(x^k, \delta_k), \quad (8.96)$$

donde $\delta_k > 0$ es el radio de la región de confianza. La elección inteligente del parámetro δ_k es el asunto principal en este contexto.

La comparación de eficiencia de métodos con búsqueda lineal y con regiones de confianza es una cuestión complicada. Tanto una estrategia como la otra tienen sus defensores. Nosotros no vamos a entrar en esta discusión y nos limitaremos a algunos comentarios conceptuales.

En principio, un subproblema de regiones de confianza presupone el cálculo de una solución global, lo que es ciertamente mucho más caro que el cálculo de la longitud del paso por una búsqueda lineal. El mismo comentario se aplica mismo si sustituimos la resolución global de (8.96) por el cálculo de un punto estacionario de este problema, lo que es posible en métodos de regiones de confianza avanzados. Más aún, una iteración en métodos de regiones de confianza puede requerir la resolución de más de un subproblema de la forma (8.96), hasta que un valor adecuado (suficientemente pequeño) del radio δ_k sea encontrado. Sin embargo, el subproblema (8.96) posee una estructura

²En inglés: *trust-region*.

bien específica, que puede (y debe) ser aprovechada. Existen varios métodos bien eficientes para la minimización de una función cuadrática en una bola [20] (i.e., no hay necesidad de apelar a métodos de optimización de uso general). Además de eso, un control inteligente del parámetro δ_k evita en la práctica la necesidad de resolución de muchos subproblemas en la misma iteración. Resumiendo, buenas implementaciones de métodos de regiones de confianza tienen un costo de iteración bien aceptable.

Por otro lado, intuitivamente, parece claro que el subproblema (8.96) es una aproximación bien mejor del problema original que el subproblema que consiste en minimizar f en alguna dirección fija (como en métodos de búsqueda lineal). Por lo tanto, puede ser esperado que a pesar del costo más alto, una iteración en métodos de regiones de confianza puede significar más progreso en relación a la minimización de f de lo que una iteración en métodos de búsqueda lineal. Otra ventaja, que parece ser aún más clara, es la siguiente: los métodos de regiones de confianza son más robustos, en el sentido de que son capaces de resolver algunos problemas donde los métodos de búsqueda lineal no funcionan bien. Para ver esto, basta considerar un punto x^k tal que $f'(x^k) = 0$ pero existe una dirección de descenso d de f a partir de x^k que satisface $\langle f''(x^k)d, d \rangle < 0$ (véase el Ejercicio 3.1.1). Obviamente, un método de búsqueda lineal en la dirección $d^k = Q_k f'(x^k)$ no va a hacer progreso ninguno ya que $d^k = 0$ cualquiera que sea la matriz Q_k . Sin embargo, es claro que si $H_k = f''(x^k)$, resolviendo el subproblema (8.96) obtendremos un punto diferente de x^k . Y, como puede ser visto (Proposición 3.3.1 más adelante), este punto proporciona un valor de f menor del que $f(x^k)$. A propósito, los métodos de regiones de confianza realmente poseen propiedades de convergencia global más fuertes. Como veremos más adelante (Teorema 3.3.2), es posible probar convergencia a los puntos estacionarios que satisfacen la condición necesaria de segunda orden, y no apenas a la condición necesaria de primera orden (como en el caso de métodos de descenso con búsqueda lineal).

Resaltamos, una vez más, que la eficiencia del método utilizado para resolver los subproblemas (8.96) es determinante para la eficiencia de cualquier método de regiones de confianza. Detalles de desarrollo y de implementación de métodos para (8.96) pueden ser consultados en [9, 7, 18]. A continuación presentaremos algunas consideraciones básicas, relevantes en este contexto.

Sea ahora $\tilde{x}^k \in \mathbb{R}^n$ la solución del subproblema (8.96), donde la matriz H_k es definida positiva. Definimos

$$d(\mu) = -(H_k + \mu E^n)^{-1} f'(x^k), \quad \mu \in \mathbb{R}_+. \quad (8.97)$$

Por el Ejercicio 3.3.2,

$$\tilde{x}^k = x^k + d^k, \quad d^k = d(\mu_k).$$

Notamos que $\mu_k = 0$ cuando $\|H_k^{-1} f'(x^k)\| \leq \delta_k$ (en este caso $\tilde{x}^k$ coincide con el paso de Newton puro, i.e., $\tilde{x}^k$ es la solución del problema (8.94)). Caso contrario, el número $\mu_k \geq 0$ es unívocamente definido por la ecuación escalar

$$\|d(\mu)\| = \delta_k, \quad (8.98)$$

en relación a $\mu \in \mathbb{R}_+$. Una ilustración es dada en la Figura 8.9.

Figura 8.9.: Solución de subproblemas de regiones de confianza (son mostradas curvas de nivel de un minimizador irrestricto de ψ_k , y la posición de la solución $\tilde{x}^k$ de (8.94), dependiendo del valor de δ_k).

Una manera de resolver el subproblema (8.96) es calcular el valor de μ_k de acuerdo con (8.98), y obtener d^k como solución del sistema lineal

$$(H_k + \mu_k E^n) d = -f'(x^k),$$

en relación a $d \in \mathbb{R}^n$. En la práctica, la ecuación (8.98) es resuelta (de manera aproximada) por ciertas implementaciones especiales del método de Newton (de nuevo, aprovechando la estructura bien especial de la ecuación). De hecho, debido a ciertos detalles numéricos, es preferible resolver la ecuación siguiente, que es equivalente:

$$\frac{1}{\|d(\mu)\|} = \frac{1}{\delta_k}.$$

Figura 8.10.: La curva de soluciones $d(\mu)$ de subproblemas de regiones de confianza para $\mu \in [0, +\infty)$: el paso de Newton corresponde a $d(0)$; para μ grande, el paso se vuelve casi en la dirección del anti-gradiente (la variación de μ en $[0, +\infty)$ corresponde a la variación inversa del radio δ).

Otra aproximación para la resolución del subproblema (8.96) es la siguiente. Variando $\mu \in \mathbb{R}_+$, $d(\mu)$ muda de manera continua en $\mathbb{R}^n$, entre el paso de Newton $d(0) = -H_k^{-1}f'(x^k)$ hasta un paso de “cuasi-gradiente” $d(\mu) \approx -f'(x^k)/\mu$ para valores de μ grandes. Además de eso, como puede ser observado en (8.97) y (8.98), las variaciones de μ tienen correspondencia inversa con las variaciones de δ_k . Por eso, en vez de la resolución de subproblemas (8.96) para varias elecciones de δ_k , podemos intentar aproximar directamente la curva de soluciones $d(\cdot)$. Algunas maneras para implementar esta estrategia pueden ser consultadas en [9, 20] (véase también § 3.3.3).

A continuación, presentamos un método de regiones de confianza básico. Para simplificar, consideremos el caso de $H_k = f''(x^k)$ para todo k .

Algoritmo 8.7 (Método de regiones de confianza). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$. Elegir los parámetros $\bar{\delta} > 0$, $\sigma, \theta_1, \theta_2 \in (0, 1)$, $\theta_1 < \theta_2$.

1. Elegir $\delta \geq \bar{\delta}$.
2. Tomar $\delta_k := \delta$. Encontrar $\tilde{x}^k \in \mathbb{R}^n$, una solución global del problema (8.96), donde la función objetivo ψ_k es dada por (8.95) con $H_k = f''(x^k)$.
3. Si $\tilde{x}^k = x^k$, pasar al ítem 4. Caso contrario, verificar la desigualdad

$$f(\tilde{x}^k) - f(x^k) \leq \sigma(\psi_k(\tilde{x}^k) - f(x^k)). \quad (8.99)$$

Si ella se satisface, pasar al ítem 4. Caso contrario, escoger $\delta \in [\theta_1 \|\tilde{x}^k - x^k\|, \theta_2 \delta_k]$ y pasar al ítem 2.

4. Tomar $x^{k+1} := \tilde{x}^k$, $k := k + 1$, y retornar al Paso 1.

Como es fácil ver, si para algún k en el Paso 3 del algoritmo tenemos la igualdad $\tilde{x}^k = x^k$, entonces el punto x^k es estacionario para el problema (8.93) y satisface la condición necesaria de segunda orden para este problema. Más precisamente, como se tiene que $\tilde{x}^k = x^k \in \text{int } B(x^k, \delta_k)$, por las condiciones necesarias de primera y de segunda orden para el problema (8.96), vea el Teorema 1.2.1, obtenemos que

$$0 = \psi'_k(x^k) = f'(x^k) + f''(x^k)(\tilde{x}^k - x^k) = f'(x^k),$$

y la matriz

$$\psi''_k(x^k) = f''(x^k)$$

es semidefinida positiva.

La desigualdad (8.99) significa que el decrecimiento de la función objetivo f es por lo menos una fracción dada del decrecimiento previsto por la aproximación ψ_k de la función f . El Algoritmo 3.3.1 es bien básico. Nosotros no entraremos en detalles de implementación, que admiten varias posibilidades. Por ejemplo, como ya fue mencionado, aproximación de una solución del subproblema (8.96) para un nuevo valor de δ_k no significa necesariamente resolución directa del subproblema. También no estamos tratando la elección del valor inicial δ en el Paso 1 del algoritmo. En la práctica, es razonable tomar δ grande cuando la iteración anterior fue “muy bien sucedida”, i.e., llevó a un decrecimiento relativamente grande de la función objetivo. Caso contrario, tiene sentido tomar δ inicial con un valor más conservador, i.e., menor.

Primero mostraremos que el Algoritmo 3.3.1 está bien definido.

Proposición 8.3 (El método de regiones de confianza está bien definido). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces diferenciable en $\mathbb{R}^n$. Supongamos que $x^k \in \mathbb{R}^n$ no es un punto estacionario del problema (8.93) (i.e., $f'(x^k) \neq 0$), o que él no satisface la condición necesaria de segunda orden para el mismo problema (i.e., $f''(x^k)$ no es semidefinida positiva).

Entonces el Algoritmo 3.3.1 genera un iterando siguiente x^{k+1} tal que $f(x^{k+1}) < f(x^k)$.

Prueba. Para cada número $\delta > 0$, sea $\bar{x}(\delta)$ alguna (cualquier) solución global del subproblema (8.96) con $\delta_k = \delta$ (recordamos que estamos considerando el caso en que la función objetivo en (8.96) está dada por (8.95) con $H_k = f''(x^k)$). Definimos

$$\rho(\delta) = \frac{f(\bar{x}(\delta)) - f(x^k)}{\psi_k(\bar{x}(\delta)) - f(x^k)}. \quad (8.100)$$

Por lo expuesto arriba, $f'(x^k) \neq 0$, o $f'(x^k) = 0$ con la matriz $f''(x^k)$ no semidefinida positiva, implican que $\bar{x}(\delta) \neq x^k$. Por eso, en particular, tenemos que

$$\psi_k(\bar{x}(\delta)) < \psi_k(x^k) = f(x^k).$$

Observamos que es suficiente probar que

$$\lim_{\delta \rightarrow 0^+} \rho(\delta) = 1. \quad (8.101)$$

(Claramente, (8.101) implica que (8.99) vale para todo δ suficientemente pequeño. Logo, el valor de δ será adecuado después de un número finito de modificaciones en el Paso 3 del algoritmo).

Supongamos primero que $f'(x^k) \neq 0$. Tomamos $d \in \mathbb{R}^n$ tal que $\langle f'(x^k), d \rangle < 0$, $\|d\| = 1$. Como $x^k + \delta d \in B(x^k, \delta_k)$, tenemos que

$$\begin{aligned} \psi_k(\bar{x}(\delta)) &\leq \psi_k(x^k + \delta d) \\ &= f(x^k) + \delta \langle f'(x^k), d \rangle + \frac{\delta^2}{2} \langle f''(x^k) d, d \rangle, \end{aligned}$$

donde

$$\begin{aligned} \psi_k(\bar{x}(\delta)) - f(x^k) &\leq \delta \left(\langle f'(x^k), d \rangle + \frac{\delta}{2} \|f''(x^k)\| \right) \\ &\leq \frac{\delta}{2} \langle f'(x^k), d \rangle, \end{aligned} \quad (8.102)$$

donde la última desigualdad vale para todo $\delta > 0$ suficientemente pequeño.

Por la Fórmula de Taylor de segunda orden, tenemos que

$$\begin{aligned} f(\bar{x}(\delta)) - \psi_k(\bar{x}(\delta)) &= f(\bar{x}(\delta)) - f(x^k) - \langle f'(x^k), \bar{x}(\delta) - x^k \rangle \\ &\quad - \frac{1}{2} \langle f''(x^k)(\bar{x}(\delta) - x^k), \bar{x}(\delta) - x^k \rangle \\ &= o(\delta^2). \end{aligned} \quad (8.103)$$

Combinando (8.103) y (8.102), obtenemos que

$$|\rho(\delta) - 1| = \left| \frac{f(\bar{x}(\delta)) - \psi_k(\bar{x}(\delta))}{\psi_k(\bar{x}(\delta)) - f(x^k)} \right| = o(\delta),$$

lo que implica (8.101).

Sea ahora $f'(x^k) = 0$, y existe $d \in \mathbb{R}^n$, $\|d\| = 1$, tal que $\langle f''(x^k) d, d \rangle < 0$. Obtenemos que

$$\psi_k(\bar{x}(\delta)) \leq \psi_k(x^k + \delta d) = f(x^k) + \frac{\delta^2}{2} \langle f''(x^k) d, d \rangle.$$

Luego,

$$\psi_k(\bar{x}(\delta)) - f(x^k) \leq \frac{\delta^2}{2} \langle f''(x^k) d, d \rangle.$$

Combinando esta relación con (8.103), obtenemos

$$|\rho(\delta) - 1| = \frac{o(\delta^2)}{\delta^2},$$

lo que implica en (8.101). ■

Probaremos ahora la convergencia de métodos de regiones de confianza a puntos estacionarios satisfaciendo la condición necesaria de segunda orden.

Teorema 8.10 (Convergencia de métodos de regiones de confianza). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces continuamente diferenciable en $\mathbb{R}^n$. Entonces, todo punto de acumulación de cualquier secuencia $\{x^k\}$ generada por el Algoritmo 3.3.1 es un punto estacionario del problema (8.93). Más aún, este punto satisface la condición necesaria de segunda orden para este problema.*

Prueba. Por la Proposición 8.3, la secuencia $\{f(x^k)\}$ es decreciente. Supongamos que la secuencia $\{x^k\}$ posea un punto de acumulación $\bar{x} \in \mathbb{R}^n$. En este caso, por el hecho de que $\{f(x^k)\}$ es decreciente, ella está acotada inferiormente (por $f(\bar{x})$) y, por lo tanto, ella converge. En particular, tenemos que $f(x^{k+1}) - f(x^k) \rightarrow 0$ ($k \rightarrow \infty$). De (8.99) tenemos que

$$0 \leq \sigma(f(x^k) - \psi_k(x^{k+1})) \leq f(x^k) - f(x^{k+1}),$$

de donde

$$\psi_k(x^{k+1}) - f(x^k) \rightarrow 0 \quad (k \rightarrow \infty). \quad (8.104)$$

Sea $\{x^{k_j}\}$ una subsecuencia de $\{x^k\}$ que converge a $\bar{x}$. Hay dos posibilidades:

$$\liminf_{j \rightarrow \infty} \delta_{k_j} > 0, \quad (8.105)$$

o

$$\liminf_{j \rightarrow \infty} \delta_{k_j} = 0. \quad (8.106)$$

Consideremos el primer caso. Definimos

$$\bar{\delta} = \liminf_{j \rightarrow \infty} \delta_{k_j} > 0.$$

Sea $\bar{y} \in \mathbb{R}^n$ una solución global del problema

$$\min \langle f'(\bar{x}), x - \bar{x} \rangle + \frac{1}{2} \langle f''(\bar{x})(x - \bar{x}), x - \bar{x} \rangle \quad \text{sujeto a } x \in \bar{D}, \quad (8.107)$$

$$\bar{D} = \{x \in \mathbb{R}^n \mid \|x - \bar{x}\| \leq \bar{\delta}/4\}. \quad (8.108)$$

Para todo j suficientemente grande,

$$\|\bar{y} - x^{k_j}\| \leq \|\bar{y} - \bar{x}\| + \|x^{k_j} - \bar{x}\| \leq \bar{\delta}/2 \leq \delta_{k_j}.$$

En particular, el punto $\bar{y}$ es factible para el problema (8.96) para $k = k_j$. Por lo tanto,

$$\begin{aligned} \psi_{k_j}(x^{k_j+1}) &\leq \psi_{k_j}(\bar{y}) \\ &= f(x^{k_j}) + \langle f'(x^{k_j}), \bar{y} - x^{k_j} \rangle + \frac{1}{2} \langle f''(x^{k_j})(\bar{y} - x^{k_j}), \bar{y} - x^{k_j} \rangle. \end{aligned}$$

Pasando al límite cuando $j \rightarrow \infty$ y teniendo en cuenta (8.104), obtenemos que

$$0 \leq \langle f'(\bar{x}), \bar{y} - \bar{x} \rangle + \frac{1}{2} \langle f''(\bar{x})(\bar{y} - \bar{x}), \bar{y} - \bar{x} \rangle.$$

Concluimos que $\bar{x}$ también es una solución global del problema (8.107), (8.108) (y el valor óptimo de este problema es cero). Como se tiene que $\bar{x} \in \text{int } \bar{D}$, las condiciones de optimalidad del Teorema 1.2.1 implican en el resultado anunciado, en el caso de (8.105).

Supongamos ahora (8.106). Sin pérdida de generalidad podemos admitir que toda la secuencia $\{\delta_{k_j}\}$ converge a cero. Luego, para todo j suficientemente grande tenemos $\delta_{k_j} < \bar{\delta}$, i.e., en la iteración con índice k_j en el Paso 3 del algoritmo el radio de la región de confianza fue reducido por lo menos una vez. Por lo tanto, existe un número $\hat{\delta}_{k_j}$ para el cual existe una solución global $\bar{x}(\hat{\delta})$ del problema (8.96) con $x^k = x^{k_j}$, $\delta_k = \hat{\delta}_{k_j}$, tal que

$$f(\bar{x}(\hat{\delta}_{k_j})) > f(x^{k_j}) + \sigma(\psi_{k_j}(\bar{x}(\hat{\delta}_{k_j})) - f(x^{k_j})), \quad (8.109)$$

$$\delta_{k_j} \geq \theta_1 \|\bar{x}(\hat{\delta}_{k_j}) - x^{k_j}\|.$$

Por la elección de la subsecuencia $\{\delta_{k_j}\}$, la última relación significa, en particular, que $\|\bar{x}(\hat{\delta}_{k_j}) - x^{k_j}\| \rightarrow 0$ ($j \rightarrow \infty$). El resto de la demostración es similar a la de la Proposición 3.3.1. Supongamos que exista $d \in \mathbb{R}^n$ tal que $\|d\| = 1$ y o bien

$$\langle f'(\bar{x}), d \rangle < 0, \quad (8.110)$$

es satisfecha, o bien

$$f'(\bar{x}) = 0, \quad \langle f''(\bar{x})d, d \rangle < 0. \quad (8.111)$$

Obtenemos que

$$\begin{aligned} \psi_{k_j}(\bar{x}(\hat{\delta}_{k_j})) &\leq \psi_{k_j}(x^{k_j} + \hat{\delta}_{k_j}d) \\ &= f(x^{k_j}) + \hat{\delta}_{k_j} \langle f'(x^{k_j}), d \rangle + \frac{\hat{\delta}_{k_j}^2}{2} \langle f''(x^{k_j})d, d \rangle. \end{aligned}$$

De aquí, en el caso de (8.110), se sigue que para todo j suficientemente grande

$$\begin{aligned} \psi_{k_j}(\bar{x}(\hat{\delta}_{k_j})) - f(x^{k_j}) &\leq \hat{\delta}_{k_j} (\langle f'(x^{k_j}), d \rangle + \hat{\delta}_{k_j} \|f''(x^{k_j})\|/2) \\ &\leq \frac{\hat{\delta}_{k_j}}{2} \langle f'(\bar{x}), d \rangle. \end{aligned}$$

Ahora, definiendo

$$\rho_{k_j} = \frac{f(\tilde{x}(\hat{\delta}_{k_j})) - f(x^{k_j})}{\psi_{k_j}(\tilde{x}(\hat{\delta}_{k_j})) - f(x^{k_j})},$$

obtenemos que

$$|\rho_{k_j} - 1| = o(\hat{\delta}_{k_j}^2)/\hat{\delta}_{k_j}.$$

De donde,

$$\rho_{k_j} \rightarrow 1 \quad (j \rightarrow \infty), \quad (8.112)$$

en contradicción con (8.109). En el caso de (8.111), obtenemos (8.112) de manera análoga (véase la demostración de la Proposición 3.3.1), lo que de nuevo entra en contradicción con (8.109).

La última cuestión a ser resuelta es la siguiente. Nos gustaría verificar si, bajo hipótesis naturales, cerca de una solución del problema la iteración del Algoritmo 3.3.1 se reduce a la iteración del método de Newton puro. La respuesta es afirmativa y puede ser obtenida, sin problemas mayores, utilizando el resultado del Ejercicio 3.3.2. ■

8.3.3. Métodos de continuación paramétricos

Otra idea para la obtención de una buena aproximación a la solución, que puede ser posteriormente utilizada por métodos locales, es la presentada a continuación. El problema de optimización original, o el sistema de condiciones de optimalidad asociado al problema, puede ser incluido en una familia de problemas, parametrizados (tanto de manera “natural” como “artificial”) por un parámetro escalar. Supongamos que para un cierto valor del parámetro, la solución (o una buena aproximación de la solución) sea conocida (o pueda ser encontrada fácilmente). Podemos entonces intentar “seguir” esta solución (o su aproximación) hasta el valor del parámetro que corresponde al problema original. Naturalmente, este proceso, cuando es viable en principio, debe ser realizado de manera computacionalmente razonable (en particular, de manera inexacta, aproximada). Con una coordinación inteligente de parámetros involucrados, podemos esperar que un punto generado así sea una aproximación de la solución del problema original, aceptable para la aplicación de un método local rápido.

De nuevo, nos limitaremos a un problema de optimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (8.113)$$

donde la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es suficientemente diferenciable. Sea $\Phi : [0, 1] \times \mathbb{R}^n \rightarrow \mathbb{R}^n$ una función suficientemente diferenciable que posee la propiedad de que

$$\Phi(1, x) = f'(x), \quad x \in \mathbb{R}^n.$$

Supongamos finalmente que una solución $x^0 \in \mathbb{R}^n$ de la ecuación

$$\Phi(0, x) = 0 \quad (8.114)$$

puede ser aproximada con una precisión arbitrariamente fina. Por ejemplo, para alguna función $\Phi_0 : \mathbb{R}^n \rightarrow \mathbb{R}^n$ la ecuación

$$\Phi_0(x) = 0$$

posee una solución que es conocida, podemos tomar

$$\Phi(t, x) = tf'(x) + (1 - t)\Phi_0(x), \quad t \in [0, 1], \quad x \in \mathbb{R}^n.$$

En particular, podemos fijar $x^0 \in \mathbb{R}^n$ y definir

$$\Phi_0(x) = f'(x) - f'(x^0), \quad x \in \mathbb{R}^n,$$

lo que resulta en

$$\Phi(t, x) = f'(x) - (1 - t)f'(x^0), \quad t \in [0, 1], \quad x \in \mathbb{R}^n.$$

Sin embargo, cabe resaltar que en la mayoría de los casos (en particular, en optimización con restricciones), la función Φ es definida utilizando técnicas y consideraciones bien más sofisticadas.

Supongamos que exista una función $\chi : [0, 1] \rightarrow \mathbb{R}^n$ continua en $[0, 1]$, tal que

$$\chi(0) = x^0, \quad \Phi(t, \chi(t)) = 0 \quad \forall t \in [0, 1]. \quad (8.115)$$

Bajo estas hipótesis $\bar{x} = \chi(1)$ es un punto estacionario del problema (8.113), y podemos intentar aproximar este punto siguiendo la curva en $\mathbb{R}^n$ definida por χ , de $\chi(0)$ hasta $\chi(1)$.

Las condiciones suficientes que garantizan que esto puede ser hecho (localmente) son dadas por el Teorema de la Función Implícita (Teorema 1.5.3). Más precisamente, si la matriz $\Phi'_x(0, x^0)$ no es singular, entonces existen una vecindad $\mathcal{U}$ de 0 en $\mathbb{R}$ y una función $\chi : \mathcal{U} \rightarrow \mathbb{R}^n$, continua (de hecho, diferenciable) en $\mathcal{U}$, tales que

$$\chi(0) = x^0, \quad \Phi(t, \chi(t)) = 0 \quad \forall t \in \mathcal{U}.$$

Sin embargo, para garantizar las mismas propiedades globalmente (en otras palabras, garantizar que $\mathcal{U} \supset [0, 1]$), son necesarias hipótesis bien fuertes (véase, por ejemplo, el Ejercicio 3.3.5 más adelante). Por eso, puede ser bastante útil sustituir la parametrización “natural” introducida arriba por una parametrización “artificial”. En particular, bajo hipótesis mucho más débiles sobre Φ , existe una curva de soluciones en el espacio $\mathbb{R} \times \mathbb{R}^n$, definida por una función continua de la forma

$$(\tau(\cdot), \chi(\cdot)) : [0, \bar{s}] \rightarrow \mathbb{R} \times \mathbb{R}^n,$$

$$(\tau(0), \chi(0)) = (0, x^0), \quad \tau(\bar{s}) = 1, \text{ donde } \bar{s} > 0.$$

Como parámetro nuevo es razonable considerar la longitud de esta curva (véase [1, 20]). En este caso, la curva en cuestión es caracterizada por el problema diferencial

$$\frac{\partial \Phi}{\partial t}(t, x)\dot{t} + \frac{\partial \Phi}{\partial x}(t, x)\dot{x} = 0, \quad |(\dot{t}, \dot{x})| = 1, \quad (t(0), x(0)) = (0, x^0).$$

Para simplificar, de aquí en adelante consideraremos solo la continuación global en relación al parámetro natural.

Comenzamos con algoritmos de continuación finitos. Para un número entero N arbitrario, definimos en el intervalo $[0, 1]$ una red $\{t_0^N, t_1^N, \dots, t_N^N\}$ ($0 = t_0^N < t_1^N < \dots < t_N^N = 1$). Definimos aún

$$\Delta_N = \max_{i=0, \dots, N-1} (t_{i+1}^N - t_i^N). \quad (8.116)$$

Sea $x^{0,0} \in \mathbb{R}^n$ una aproximación a la solución x^0 de la ecuación (8.114) que tenemos a disposición. A partir de $x^{0,0}$ hacemos k_0 pasos del método de Newton para la ecuación

$$\Phi(t_1^N, x) = 0, \quad (8.117)$$

con $i = 0$ (o sea para la ecuación (8.114)). A partir del punto obtenido de esta manera, hacemos k_1 pasos del método de Newton para la ecuación (8.117) con $i = 1$. Repitiendo este proceso para todo $i = 0, 1, \dots, N-1$, obtenemos las fórmulas

$$x^{i,k+1} = x^{i,k} - (\Phi'_x(t_i^N, x^{i,k}))^{-1} \Phi(t_i^N, x^{i,k}), \quad (8.118)$$

$$k = 0, 1, \dots, k_i - 1, \quad i = 0, 1, \dots, N-1,$$

donde

$$x^{i,0} = x^{i-1,k_{i-1}}, \quad i = 1, \dots, N-1. \quad (8.119)$$

La sugerencia es utilizar el punto final $\tilde{x}^N = x^{N-1,k_{N-1}}$ obtenido de esta manera como un punto inicial para algún método local rápido para encontrar el punto estacionario $\bar{x} = \chi(1)$ del problema (8.113).

En el análisis a seguir, consideraremos el caso cuando $k_i = 1$ para todo $i = 0, 1, \dots, N-1$, i.e., para toda ecuación (8.117) el parámetro es actualizado después de cada paso del método de Newton.

Algoritmo 8.8 (Método de continuación finito). En el intervalo $[0, 1]$, escoger una red $\{t_0^N, t_1^N, \dots, t_N^N\}$ (donde $0 = t_0^N < t_1^N < \dots < t_N^N = 1$). Escoger $x^{0,0} \in \mathbb{R}^n$. Tomar $\tilde{x}^0 = x^{0,0}$ y calcular el punto $\tilde{x}^N \in \mathbb{R}^n$ de acuerdo con

$$\tilde{x}^{i+1} = \tilde{x}^i - (\Phi'_x(t_i^N, \tilde{x}^i))^{-1} \Phi(t_{i+1}^N, \tilde{x}^i), \quad i = 0, 1, \dots, N-1. \quad (8.120)$$

Como veremos, bajo hipótesis naturales, es posible garantizar que el punto $\tilde{x}^N$ así generado quede tan próximo a $\bar{x}$ como deseemos, siempre que la red escogida sea suficientemente fina y el punto $x^{0,0}$ sea suficientemente próximo a x^0 .

Denotamos el grafo de la función $\chi : [0, 1] \rightarrow \mathbb{R}^n$ por

$$G(\chi) = \{(t, x) \in [0, 1] \times \mathbb{R}^n \mid \chi(t) = x\}.$$

Teorema 8.11 (Propiedades del método de continuación finito). Sean una función $\Phi : [0, 1] \times \mathbb{R}^n \rightarrow \mathbb{R}^n$ y el punto $x^0 \in \mathbb{R}^n$ tales que existe una función $\chi : [0, 1] \rightarrow \mathbb{R}^n$ continua en $[0, 1]$ que satisface (8.115). Sea Φ diferenciable en

relación a x en una vecindad del conjunto $G(\chi)$, con la derivada parcial Φ'_x continua en $G(\chi)$. Supongamos, finalmente, que

$$\det \Phi'_x(t, \chi(t)) \neq 0 \quad \forall t \in [0, 1]. \quad (8.121)$$

Entonces, para todo número $\delta > 0$ suficientemente pequeño existe un número $\Delta > 0$ tal que, si la red $\{t_0^N, t_1^N, \dots, t_N^N\}$ en $[0, 1]$ y el punto inicial $x^{0,0} \in \mathbb{R}^n$ satisfacen las condiciones

$$\Delta_N < \Delta, \quad \|x^{0,0} - x^0\| < \delta, \quad (8.122)$$

donde Δ_N es definido en (8.116), entonces el Algoritmo 3.3.2 está bien definido y genera el punto $\bar{x}^N \in \mathbb{R}^n$ tal que

$$\|\bar{x}^N - \chi(1)\| < \delta. \quad (8.123)$$

Prueba. Utilizando (8.121), la continuidad de Φ'_x en $G(\chi)$, el teorema sobre perturbaciones pequeñas de una matriz no singular (véase el Teorema 1.5.1), y la compacidad del intervalo $[0, 1]$, es fácil verificar que existen una vecindad $\mathcal{U}$ del conjunto $G(\chi)$ y un número $M > 0$, tales que

$$\det \Phi'_x(t, x) \neq 0, \quad \|(\Phi'_x(t, x))^{-1}\| \leq M \quad \forall (t, x) \in \mathcal{U}. \quad (8.124)$$

Por consideraciones análogas a aquellas de la demostración del Teorema 3.2.1, esto implica en que para todo $q \in (0, 1)$ existe un número $\delta > 0$ tal que (independientemente de la elección de la red), si para algún $i \in \{0, 1, \dots, N-1\}$ tenemos que $\bar{x}^i \in B(\chi(t_i^N), \delta)$, entonces la fórmula (8.120) unívocamente define $\bar{x}^{i+1}$. Más aún,

$$\|\bar{x}^{i+1} - \chi(t_i^N)\| \leq q \|\bar{x}^i - \chi(t_i^N)\|. \quad (8.125)$$

Definimos

$$\tilde{\Delta}_N = \max_{i=0, \dots, N-1} \|\chi(t_{i+1}^N) - \chi(t_i^N)\|. \quad (8.126)$$

De (8.116), teniendo en cuenta que una función continua en un conjunto compacto es uniformemente continua en este conjunto, obtenemos que para todo $\delta \in (0, \delta)$ existe $\Delta > 0$ tal que, cuando vale la primera desigualdad en (8.122), se tiene que

$$\tilde{\Delta}_N / (1 - q) < \delta. \quad (8.127)$$

Supongamos que el algoritmo haya generado los puntos $\bar{x}^0, \dots, \bar{x}^i, i \in \{0, 1, \dots, N-1\}$, y $\|\bar{x}^j - \chi(t_j^N)\| < \delta \quad \forall j = 0, 1, \dots, i$. El algoritmo entonces unívocamente define $\bar{x}^{i+1}$ y, por la segunda desigualdad en (8.122) y (8.125)–(8.127), se tiene que

$$\begin{aligned} \|\bar{x}^{i+1} - \chi(t_{i+1}^N)\| &\leq \|\bar{x}^{i+1} - \chi(t_i^N)\| + \|\chi(t_{i+1}^N) - \chi(t_i^N)\| \\ &\leq q \|\bar{x}^i - \chi(t_i^N)\| + \tilde{\Delta}_N \\ &\leq q(q \|\bar{x}^{i-1} - \chi(t_{i-1}^N)\| + \tilde{\Delta}_N) + \tilde{\Delta}_N \\ &\dots \\ &\leq q^{i+1} \|x^{0,0} - \chi(t_0^N)\| + \tilde{\Delta}_N \sum_{j=0}^i q^j \\ &\leq q^{i+1} \delta + \tilde{\Delta}_N (1 - q^{i+1}) / (1 - q) \\ &= q^{i+1} (\delta - \tilde{\Delta}_N / (1 - q)) + \tilde{\Delta}_N / (1 - q) \\ &\leq q(\delta - \tilde{\Delta}_N / (1 - q)) + \tilde{\Delta}_N / (1 - q) \\ &= q\delta + \tilde{\Delta}_N < \delta. \end{aligned}$$

De donde, sigue el resultado anunciado. ■

Naturalmente, métodos de continuación finitos pueden ser construidos utilizando otras técnicas, i.e., no necesariamente sobre la base de métodos Newtonianos. De la demostración anterior, puede ser observado que la propiedad necesaria para tal desenvolvimiento es la convergencia local (del método que queremos utilizar) a la solución $\chi(t)$ de la ecuación

$$\Phi(t, x) = 0,$$

para todo $t \in [0, 1]$. En este sentido, la condición (8.121) es importante: sin esta condición, la tarea de “seguir” a la curva definida por χ es muy difícil (en el sentido computacional). En algunos casos, esta dificultad puede ser superada cambiando la parametrización, como ya fue mencionado (los detalles pueden ser consultados en [1]).

A veces, puede ser útil parametrizar directamente el problema de optimización (8.113) y no las condiciones de optimalidad asociadas, introduciendo la función $\varphi : [0, 1] \times \mathbb{R}^n \rightarrow \mathbb{R}$ tal que

$$\varphi(1, x) = f(x), \quad x \in \mathbb{R}^n,$$

donde alguna solución x^0 (local o global) del problema

$$\min \varphi(0, x), \quad x \in \mathbb{R}^n,$$

es conocida o puede ser encontrada con cualquier precisión deseada. Si existe una función $\chi : [0, 1] \rightarrow \mathbb{R}^n$ continua en $[0, 1]$ tal que $\chi(0) = x^0$ y $\chi(t)$ es una solución del problema

$$\min \varphi(t, x), \quad x \in \mathbb{R}^n,$$

para todo $t \in [0, 1]$, podemos construir técnicas de continuación sobre la base de métodos de descenso para problemas de minimización.

Consideremos ahora métodos de continuación basados en la resolución de un problema diferencial.

Si Φ es suficientemente diferenciable y para todo $t \in [0, 1]$ la matriz $\Phi'_x(t, \chi(t))$ es no singular, el Teorema 1.5.3 garantiza que la función χ es diferenciable. Tomando la derivada en relación a t en la segunda igualdad de (8.115) como composición de funciones diferenciables (o simplemente recordando la fórmula correspondiente del Teorema 1.5.3), obtenemos que $\chi(\cdot)$ es una solución del problema diferencial

$$\dot{x} = -\left(\frac{\partial \Phi}{\partial x}(t, x)\right)^{-1} \frac{\partial \Phi}{\partial t}(t, x), \quad x(0) = x^0. \quad (8.128)$$

Una idea natural consiste en aproximar $\bar{x} = \chi(1)$ resolviendo el problema (8.128) utilizando, por ejemplo, el método de Euler, o el método de Runge-Kutta, etc. En el caso del método de Euler, obtenemos lo siguiente (comparar con el Algoritmo 3.3.2).

Algoritmo 8.9 (Método de continuación basado en la resolución de un problema diferencial). En el intervalo $[0, 1]$ escoger una red $\{t_0^N, t_1^N, \dots, t_N^N\}$ (donde $0 = t_0^N < t_1^N < \dots < t_N^N = 1$). Escoger $x^{0,0} \in \mathbb{R}^n$. Tomar $\bar{x}^0 = x^{0,0}$ y calcular el punto $\bar{x}^N \in \mathbb{R}^n$ de acuerdo con

$$\begin{aligned} \bar{x}^{i+1} &= \bar{x}^i - (t_{i+1}^N - t_i^N)(\Phi'_x(t_i^N, \bar{x}^i))^{-1} \Phi'_t(t_i^N, \bar{x}^i), \\ i &= 0, 1, \dots, N-1. \end{aligned} \quad (8.129)$$

Teorema 8.12 (Propiedades del método de continuación basado en la resolución de un problema diferencial). Sean la función $\Phi : [0, 1] \times \mathbb{R}^n \rightarrow \mathbb{R}$ y el punto $x^0 \in \mathbb{R}^n$ tales que existe una función $\chi : [0, 1] \rightarrow \mathbb{R}^n$ continua en $[0, 1]$ que satisface (8.115). Sea Φ diferenciable en una vecindad V del conjunto $G(\chi)$, con derivada continua en $G(\chi)$. Supongamos que exista un número $L > 0$ tal que

$$\|\Phi'_t(t, x) - \Phi'_t(t, \chi(t))\| \leq L\|x - \chi(t)\| \quad \forall (t, x) \in \mathcal{V}. \quad (8.130)$$

Supongamos, finalmente, que (8.121) se satisfaga.

Entonces, para cualesquiera números $\varepsilon > 0$ y $C > 0$ existen un número entero $\bar{N}$ y un número $\delta > 0$ tales que, si el punto inicial $x^{0,0} \in \mathbb{R}^n$ y la red $\{t_0^N, t_1^N, \dots, t_N^N\}$ en $[0, 1]$ satisfacen las condiciones

$$\Delta_N \leq C/N, \quad N \geq \bar{N}, \quad \|x^{0,0} - x^0\| < \delta, \quad (8.131)$$

donde Δ_N está definido en (8.116), el Algoritmo 3.3.3 está bien definido y genera el punto $\bar{x}^N \in \mathbb{R}^n$ tal que

$$\|\bar{x}^N - \chi(1)\| < \varepsilon.$$

Prueba. Utilizando (8.121), la continuidad de $\chi(\cdot)$ en $[0, 1]$, la continuidad de la derivada de Φ en $G(\chi)$, (8.130), el teorema sobre perturbaciones pequeñas de una matriz no singular (véase el Teorema 1.5.1), y la compacidad del intervalo $[0, 1]$, es fácil verificar que existen una vecindad $\mathcal{U} \subset \mathcal{V}$ del conjunto $G(\chi)$ y un número $\tilde{L} > 0$ tales que la función

$$\Psi : \mathcal{U} \rightarrow \mathbb{R}^n, \quad \Psi(t, x) = -(\Phi'_x(t, x))^{-1} \Phi'_t(t, x),$$

está bien definida, la función $\Psi(\cdot, \chi(\cdot)) : [0, 1] \rightarrow \mathbb{R}^n$ es continua en $[0, 1]$, e

$$\|\Psi(t, x) - \Psi(t, \chi(t))\| \leq \tilde{L}\|x - \chi(t)\| \quad \forall (t, x) \in \mathcal{U}. \quad (8.132)$$

Elegiremos un número $\delta > 0$ para satisfacer

$$\{t\} \times B(\chi(t), \delta) \subset \mathcal{U} \quad \forall t \in [0, 1]$$

(la posibilidad de hacer esto se sigue de la compacidad de $[0, 1]$). Definimos

$$\bar{\Delta}_N = \max_{i=0, \dots, N-1} \max_{t \in [t_i^N, t_{i+1}^N]} \|\Psi(t_i^N, x(t_i^N)) - \Psi(t, x(t))\|. \quad (8.133)$$

De (8.116), (8.131), de la continuidad de la función $\Psi(\cdot, \chi(\cdot))$ en $[0, 1]$, del hecho de que una función continua en un conjunto compacto es uniformemente continua en este conjunto, se sigue que existe un número $\delta > 0$ tal que, cuando la primera desigualdad en (8.122) es satisfecha, se tiene que

$$\begin{aligned} (\delta + \bar{\Delta}_N)(1 + \bar{L}\Delta_N)^N &\leq (\delta + \bar{\Delta}_N)(1 + \bar{L}C/N)^N \\ &\leq (\delta + \bar{\Delta}_N)e^{\bar{L}C} \\ &< \min\{\varepsilon, \delta\}, \end{aligned} \quad (8.134)$$

para todo N suficientemente grande.

Supongamos que el algoritmo generó los puntos $\bar{x}^0, \bar{x}^1, \dots, \bar{x}^i, i \in \{0, 1, \dots, N-1\}$, e $\|\bar{x}^j - \chi(t_j^N)\| < \delta \quad \forall j = 0, 1, \dots, i$. El algoritmo entonces define unívocamente $\bar{x}^{i+1}$ y, por (8.145), tenemos que

$$\begin{aligned} \bar{x}^{i+1} &= \bar{x}^i + (t_{i+1}^N - t_i^N)\Psi(t_i^N, \bar{x}^i) \\ &= \bar{x}^{i-1} + (t_i^N - t_{i-1}^N)\Psi(t_{i-1}^N, \bar{x}^{i-1}) + (t_{i+1}^N - t_i^N)\Psi(t_i^N, \bar{x}^i) \\ &\dots \\ &= \bar{x}^0 + \sum_{j=0}^i (t_{j+1}^N - t_j^N)\Psi(t_j^N, \bar{x}^j) \\ &= \bar{x}^0 + \sum_{j=0}^i \int_{t_j^N}^{t_{j+1}^N} \Psi(t_j^N, \bar{x}^j) dt. \end{aligned}$$

Además de eso, utilizando (8.128) y la Fórmula de Newton-Leibnitz (véase el Teorema 1.5.2), tenemos que

$$\chi(t_{i+1}^N) = x^0 + \int_0^{t_{i+1}^N} \Psi(t, \chi(t)) dt = x^0 + \sum_{j=0}^i \int_{t_j^N}^{t_{j+1}^N} \Psi(t, \chi(t)) dt.$$

Utilizando las dos últimas relaciones, (8.116), la última desigualdad en (8.131), así como las relaciones (8.132) y (8.133), obtenemos que

$$\begin{aligned} \|\bar{x}^{i+1} - \chi(t_{i+1}^N)\| &\leq \|\bar{x}^0 - x^0\| + \sum_{j=0}^i \int_{t_j^N}^{t_{j+1}^N} \|\Psi(t_j^N, \bar{x}^j) - \Psi(t, \chi(t))\| dt \\ &\leq \|x^{0,0} - x^0\| \\ &\quad + \sum_{j=0}^i \int_{t_j^N}^{t_{j+1}^N} (\|\Psi(t_j^N, \bar{x}^j) - \Psi(t_j^N, \chi(t_j^N))\| \\ &\quad + \|\Psi(t_j^N, \chi(t_j^N)) - \Psi(t, \chi(t))\|) dt \\ &\leq \delta + \bar{\Delta}_N + \bar{L}\Delta_N \sum_{j=0}^i \|\bar{x}^j - \chi(t_j^N)\|. \end{aligned}$$

Ahora, utilizando también el Lema 1.5.3 e (8.134), obtenemos

$$\|\bar{x}^{i+1} - \chi(t_{i+1}^N)\| \leq (\delta + \bar{\Delta}_N)(1 + \bar{L}\Delta_N)^{i+1} < \min\{\varepsilon, \delta\},$$

donde se sigue el resultado deseado. ■

Por lo observado en los Teoremas 3.3.3 y 3.3.4, el Algoritmo 3.3.2 posee claras ventajas en comparación con el Algoritmo 3.3.3, tanto en relación a las propiedades establecidas cuanto en relación a las hipótesis utilizadas para probar estas propiedades. Por otro lado, el Algoritmo 3.3.3 en general es bien menos sensible en relación a la elección de la red. Por eso, ambos métodos poseen cierta utilidad práctica. De hecho, con frecuencia estos métodos se utilizan en combinación: por ejemplo, la aproximación obtenida a partir de un punto dado de la red por el esquema de Euler

es posteriormente mejorada por uno o más pasos del método de Newton. Típicamente, la red no es fijada a priori y se va adaptando a lo largo del proceso computacional.

Varios otros métodos de continuación, así como detalles de implementación, pueden ser consultados en [1].

8.4. Métodos de direcciones conjugadas

Presentamos a continuación otra importante clase de métodos que apuntan a alcanzar convergencia más rápida que la de los métodos del gradiente, al mismo tiempo reduciendo el costo computacional del método de Newton. En particular, son métodos de primera orden (que no usan derivadas segundas), sin embargo están basados en ideas diferentes de los métodos cuasi-Newton.

8.4.1. Métodos de direcciones conjugadas para funciones cuadráticas

Los métodos de direcciones conjugadas serán introducidos primero para un problema de minimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (8.135)$$

con función objetivo $f : \mathbb{R}^n \rightarrow \mathbb{R}$ cuadrática fuertemente convexa:

$$f(x) = \langle Qx, x \rangle + \langle q, x \rangle, \quad x \in \mathbb{R}^n, \quad (8.136)$$

donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, $q \in \mathbb{R}^n$.

Para motivar el desarrollo, consideremos un iterando x^k , una dirección d^k , y el iterando siguiente x^{k+1} calculado por la regla de minimización unidimensional. Recordamos que en el caso cuadrático x^{k+1} puede ser calculado por la fórmula explícita (véase § 3.1.1) y que vale (véase (8.5)) la relación

$$0 = \langle f'(x^{k+1}), d^k \rangle = \langle 2Qx^{k+1} + q, d^k \rangle.$$

Sea $\bar{x}$ el minimizador de f . En particular, $f'(\bar{x}) = 2Q\bar{x} + q = 0$. Por lo tanto,

$$0 = \langle 2Q\bar{x} + q, d^k \rangle.$$

Restando las dos ecuaciones anteriores, obtenemos

$$0 = 2\langle Q(x^{k+1} - \bar{x}), d^k \rangle.$$

La idea es hacer que la dirección siguiente d^{k+1} satisfaga la misma condición que la dirección “ideal” $x^{k+1} - \bar{x}$ (que lleva a la solución). O sea,

$$\langle Qd^{k+1}, d^k \rangle = 0.$$

Definición 8.2. Un conjunto de vectores $d^0, \dots, d^k \in \mathbb{R}^n \setminus \{0\}$ se llama Q -conjugado, si

$$\langle Qd^i, d^j \rangle = 0 \quad \forall i, j = 0, 1, \dots, k, \quad i \neq j.$$

Observamos que esta noción generaliza la noción de un conjunto de vectores ortogonales (que corresponde a $Q = E^n$).

Lema 8.6 (Direcciones conjugadas son linealmente independientes). Para cualquier matriz $Q \in \mathbb{R}^{n \times n}$ simétrica definida positiva, cualquier conjunto de direcciones Q -conjugadas es linealmente independiente.

Prueba. Supongamos que uno de los vectores $d^0, \dots, d^k$ del conjunto Q -conjugado pueda ser expresado por una combinación lineal de los otros, por ejemplo, el primero:

$$d^0 = \sum_{i=1}^k \beta_i d^i,$$

donde $\beta_i \in \mathbb{R}$, $i = 1, \dots, k$. Multiplicando los dos lados de esta ecuación por Qd^0 , y utilizando el hecho de que Q es definida positiva y $d^0 \neq 0$, obtenemos

$$0 < \langle Qd^0, d^0 \rangle = \sum_{i=1}^k \beta_i \langle Qd^0, d^i \rangle = 0,$$

lo que es una contradicción. ■

En particular, un conjunto de vectores Q -conjugados en $\mathbb{R}^n$ no puede contener más de n elementos.

El esquema general de los métodos de direcciones conjugadas para funciones de la forma (8.136) es el siguiente:

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, 1, \dots, n-1, \quad (8.137)$$

donde $d^0, d^1, \dots, d^{n-1}$ es un conjunto (generado de una manera u otra) de direcciones Q -conjugadas, y los valores de la longitud de paso α_k son calculados para satisfacer

$$f(x^k + \alpha_k d^k) = \min_{\alpha \in \mathbb{R}} f(x^k + \alpha d^k), \quad (8.138)$$

i.e.,

$$\alpha_k = -\frac{\langle 2Qx^k + q, d^k \rangle}{2\langle Qd^k, d^k \rangle}. \quad (8.139)$$

El mínimo en (8.138) es calculado sobre todos los $\alpha \in \mathbb{R}$, y no apenas sobre $\alpha \geq 0$. Esto se debe al hecho de que no va a ser una dirección de descenso para f en el punto x^k . Más aún, es posible que ni d^k ni $-d^k$ sean una dirección de descenso.

Métodos de direcciones conjugadas, en principio, no son métodos de descenso. La idea es diferente.

Naturalmente, la naturaleza de cada método de direcciones conjugadas específico es definida por la manera concreta de construir el conjunto de vectores Q -conjugados asociado. Sin embargo, cualquiera que sea esta construcción, vale el siguiente resultado fundamental: todo método de direcciones conjugadas encuentra la solución del problema de minimización irrestricta de una función cuadrática, de la forma (8.136) con matriz Q definida positiva, en n iteraciones, a lo sumo.

Teorema 8.13 (Convergencia finita de métodos de direcciones conjugadas para funciones cuadráticas). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función definida por (8.136), donde se tiene que $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, $q \in \mathbb{R}^n$.

Entonces, para cualquier punto inicial $x^0 \in \mathbb{R}^n$, el punto x^n obtenido de acuerdo con el esquema (8.137), (8.138), con cualquier elección de conjunto Q -conjugado de vectores $d^0, d^1, \dots, d^{n-1}$, es la solución global del problema (8.135).

Prueba. Por el hecho de que Q es definida positiva, el problema (8.135) tiene un único punto estacionario $\bar{x} \in \mathbb{R}^n$, caracterizado por la ecuación

$$f'(\bar{x}) = 2Q\bar{x} + q = 0. \quad (8.140)$$

Por la convexidad de f , este punto es la solución global del problema.

Por el Lema 8.6, el conjunto de vectores $d^0, d^1, \dots, d^{n-1}$ forma una base de $\mathbb{R}^n$. Por lo tanto, podemos representar el vector $\bar{x} - x^0$ como

$$\bar{x} - x^0 = \sum_{k=0}^{n-1} \beta_k d^k, \quad (8.141)$$

para algunos $\beta_k \in \mathbb{R}$, $k = 0, 1, \dots, n-1$. Por otro lado, por (8.137), tenemos que

$$x^n = x^0 + \sum_{k=0}^{n-1} \alpha_k d^k,$$

donde los números α_k son definidos en (8.139). Ahora resta mostrar que $\beta_k = \alpha_k \forall k = 0, 1, \dots, n-1$.

Usando (8.141) y el hecho de que $d^0, d^1, \dots, d^{n-1}$ es un conjunto de direcciones Q -conjugadas, para todo $k = 0, 1, \dots, n-1$, obtenemos que

$$\begin{aligned} \langle Q\bar{x}, d^k \rangle &= \langle Qx^0, d^k \rangle + \sum_{i=0}^{n-1} \beta_i \langle Qd^i, d^k \rangle \\ &= \langle Qx^0, d^k \rangle + \beta_k \langle Qd^k, d^k \rangle, \end{aligned}$$

de donde se sigue que

$$\beta_k = \frac{\langle Q\bar{x} - Qx^0, d^k \rangle}{\langle Qd^k, d^k \rangle} = -\frac{\langle 2Qx^0 + q, d^k \rangle}{2\langle Qd^k, d^k \rangle}, \quad (8.142)$$

donde (8.140) fue tomada en cuenta. Usando de nuevo (8.137) y el hecho de que $d^0, d^1, \dots, d^{n-1}$ son Q -conjugadas, obtenemos

$$\begin{aligned}\langle Qx^k, d^k \rangle &= \langle Q(x^{k-1} + \alpha_{k-1}d^{k-1}), d^k \rangle \\ &= \langle Qx^{k-1}, d^k \rangle \\ &= \langle Q(x^{k-2} + \alpha_{k-2}d^{k-2}), d^k \rangle \\ &= \langle Qx^{k-2}, d^k \rangle \\ &\dots \\ &= \langle Qx^0, d^k \rangle.\end{aligned}$$

Combinando esta relación con (8.139) y (8.142), obtenemos el resultado anunciado. ■

La propiedad siguiente es muy reveladora. Acontece que cada iterando x^k , $k \geq 1$, generado de acuerdo con (8.137), (8.138), minimiza la función f en un conjunto afín de dimensión k . Es por eso que, para $k = n$, el punto x^n así generado minimiza f en $\mathbb{R}^n$. Observamos que, sorprendentemente, el cálculo de estos minimizadores es explícito, i.e., no hay necesidad de utilización de algún método iterativo para minimizar f en un conjunto de dimensión cada vez mayor.

Teorema 8.14. *Bajo las hipótesis del Teorema 8.13, para cualquier punto inicial $x^0 \in \mathbb{R}^n$, para todo $k = 0, \dots, n-1$, el punto x^{k+1} definido por el esquema (8.137), (8.138), donde $d^0, \dots, d^k$ es cualquier conjunto de direcciones Q -conjugadas, es una solución (global) del problema*

$$\min f(x) \quad \text{sujeto a } x \in D_k = x^0 + \text{span} \{d^0, \dots, d^k\}.$$

Prueba. Para todo $i = 0, \dots, k-1$, tenemos que

$$\begin{aligned}\langle f'(x^{k+1}), d^i \rangle &= \langle 2Qx^{k+1} + q, d^i \rangle \\ &= 2\langle x^{k+1}, Qd^i \rangle + \langle q, d^i \rangle \\ &= 2\langle x^{i+1} + \sum_{j=i+1}^k \alpha_j d^j, Qd^i \rangle + \langle q, d^i \rangle \\ &= 2\langle x^{i+1}, Qd^i \rangle + \langle q, d^i \rangle \\ &= \langle 2Qx^{i+1} + q, d^i \rangle \\ &= \langle f'(x^{i+1}), d^i \rangle,\end{aligned}$$

donde la cuarta igualdad se sigue del hecho de que las direcciones en cuestión son Q -conjugadas.

De (8.138), para todo i , tenemos que

$$0 = f'_\alpha(x^i + \alpha_i d^i) = \langle f'(x^{i+1}), d^i \rangle.$$

Combinando las dos últimas relaciones, concluimos que

$$\langle f'(x^{k+1}), d^i \rangle = 0 \quad \forall i = 0, 1, \dots, k.$$

Para verificar la afirmación, tenemos que mostrar que el minimizador irrestricto de la función

$$\varphi : \mathbb{R}^{k+1} \rightarrow \mathbb{R}, \quad \varphi(\beta) = f(x^0 + \beta_0 d^0 + \dots + \beta_k d^k)$$

es el punto $(\alpha_1, \dots, \alpha_k) \in \mathbb{R}^{k+1}$. Mas esto sigue del hecho de que

$$\varphi'(\alpha_1, \dots, \alpha_k) = 0,$$

ya que, como fue probado arriba,

$$\begin{aligned}\varphi'_{\beta_i}(\alpha_1, \dots, \alpha_k) &= \langle f'(x^0 + \alpha_0 d^0 + \dots + \alpha_k d^k), d^i \rangle \\ &= \langle f'(x^{k+1}), d^i \rangle = 0,\end{aligned}$$

para todo $i = 0, 1, \dots, k$. ■

A propósito, una manera de construir un conjunto de direcciones Q -conjugadas ya fue presentada arriba. Puede ser probado que los vectores $d^k = -Q_k f'(x^k)$, $k = 0, \dots, n-1$, donde las matrices Q_k son generadas por el método DFP o por el método BFGS (véase § 3.2.3), forman un conjunto Q -conjugado; véase [3, 4]. Una propiedad interesante

del método DFP es la siguiente. Al mismo tiempo, él resuelve el problema de minimización y calcula la matriz Q^{-1} (lo que puede ser importante en algunas aplicaciones). Por otro lado, la implementación del método DFP requiere guardar en la memoria y actualizar, en cada iteración, la matriz $Q_k \in \mathbb{R}^{n \times n}$, lo que puede ser caro cuando n es grande. Una realización más económica del método de direcciones conjugadas será presentada a continuación.

8.4.2. El método de los gradientes conjugados

Tal vez el más importante entre los métodos de direcciones conjugadas es el método de los gradientes conjugados. En este método,

$$d^0 = -f'(x^0), \quad d^k = -f'(x^k) + \beta_{k-1}d^{k-1}, \quad k = 1, \dots, n-1, \quad (8.143)$$

donde los números β_{k-1} son elegidos para hacer que las dos direcciones seguidas d^{k-1} y d^k sean Q -conjugadas, i.e.,

$$0 = \langle Qd^{k-1}, d^k \rangle = -\langle Qd^{k-1}, f'(x^k) \rangle + \beta_{k-1} \langle Qd^{k-1}, d^{k-1} \rangle,$$

de donde

$$\beta_{k-1} = \frac{\langle Qd^{k-1}, f'(x^k) \rangle}{\langle Qd^{k-1}, d^{k-1} \rangle}. \quad (8.144)$$

Algoritmo 8.10 (El método de los gradientes conjugados). En el intervalo $[0, 1]$ escoger una red $\{t_0^N, t_1^N, \dots, t_N^N\}$ (donde $0 = t_0^N < t_1^N < \dots < t_N^N = 1$). Escoger $x^{0,0} \in \mathbb{R}^n$. Tomar $\tilde{x}^0 = x^{0,0}$ y calcular el punto $\tilde{x}^N \in \mathbb{R}^n$ de acuerdo con

$$\begin{aligned} \tilde{x}^{i+1} &= \tilde{x}^i - (t_{i+1}^N - t_i^N)(\Phi'_x(t_i^N, \tilde{x}^i))^{-1} \Phi'_t(t_i^N, \tilde{x}^i), \\ i &= 0, 1, \dots, N-1. \end{aligned} \quad (8.145)$$

En la fórmula (8.139), que define α_k , entendemos que $d^k \neq 0$ (en la fórmula (8.144), que define β_{k-1} , entendemos que $d^{k-1} \neq 0$). Si $d^0 = -f'(x^0) = 0$, el método pararía antes del cálculo de d^0 y α_0 (y, obviamente, de β_0). Supongamos que para algún $k \geq 1$, por primera vez aconteció que $d^k = 0$ (en particular, $d^{k-1} \neq 0$). En este caso, por (8.143), obtenemos que

$$\begin{aligned} 0 &= \langle f'(x^k), d^k \rangle \\ &= -\|f'(x^k)\|^2 + \beta_{k-1} \langle f'(x^k), d^{k-1} \rangle \\ &= -\|f'(x^k)\|^2, \end{aligned}$$

donde la última igualdad sigue del hecho de que, por la definición de α_{k-1} ,

$$\langle f'(x^k), d^{k-1} \rangle = 0 \quad (8.146)$$

(véase (8.5)). Por lo tanto, $f'(x^k) = 0$, y el método pararía antes del cálculo de d^k y α_k (y, obviamente, de β_k).

El resultado siguiente muestra que el método que acabamos de presentar es realmente un método de direcciones conjugadas.

Teorema 8.15. Sean satisfechas las hipótesis del Teorema 8.13.

Para cualquier punto inicial $x^0 \in \mathbb{R}^n$, y todo $k = 1, \dots, n$, si el Algoritmo 3.4.1 generó los vectores $d^0, d^1, \dots, d^{k-1}$, entonces ellos forman un conjunto Q -conjugado. Además de eso, los gradientes $f'(x^0), f'(x^1), \dots, f'(x^{k-1})$ forman un conjunto de vectores ortogonales en $\mathbb{R}^n$.

Prueba. Primero notemos que, por lo expuesto arriba, si el método generó los vectores $d^0, d^1, \dots, d^{k-1}$, entonces todos ellos son no nulos, así como los gradientes $f'(x^0), f'(x^1), \dots, f'(x^{k-1})$.

La prueba se hará por inducción en relación a k . Para $k = 1$, la afirmación del teorema es obvia, porque el conjunto d^0, d^1 es Q -conjugado por construcción, y los vectores $f'(x^0) = -d^0$ y $f'(x^1)$ son ortogonales por (8.146).

Supongamos que la afirmación del teorema sea verdadera para $k = s \geq 2$. Precisamos mostrar que

$$\langle Qd^s, d^i \rangle = 0, \quad \langle f'(x^s), f'(x^i) \rangle = 0 \quad \forall i = 0, 1, \dots, s-1. \quad (8.147)$$

Por (8.143), por la hipótesis de inducción, y por el Teorema 8.14, tenemos que

$$\begin{aligned}\langle f'(x^s), f'(x^i) \rangle &= \langle f'(x^s), -d^i + \beta_{i-1}d^{i-1} \rangle \\ &= 0 \quad \forall i = 0, 1, \dots, s-1.\end{aligned}$$

Esto verifica la segunda igualdad en (8.147).

Para $i = s-1$, la primera igualdad en (8.147) vale por construcción. Para todo $i = 0, 1, \dots, s-2$, por (8.143) y por la hipótesis de inducción, obtenemos

$$\begin{aligned}\langle Qd^s, d^i \rangle &= -\langle Qf'(x^s), d^i \rangle + \beta_{s-1}\langle Qd^{s-1}, d^i \rangle \\ &= -\langle Qf'(x^s), d^i \rangle.\end{aligned}\tag{8.148}$$

Como, por (8.137),

$$f'(x^{i+1}) - f'(x^i) = 2Q(x^{i+1} - x^i) = 2\alpha_i Qd^i,$$

obtenemos que

$$\langle Qf'(x^s), d^i \rangle = \frac{1}{2\alpha_i} (\langle f'(x^s), f'(x^{i+1}) \rangle - \langle f'(x^s), f'(x^i) \rangle) = 0,$$

donde utilizamos la segunda igualdad en (8.147), ya probada. En combinación con (8.148), esto concluye la prueba de la primera igualdad en (8.147). ■

Por los Teoremas 8.15 y 8.13, el método de gradientes conjugados encuentra la solución del problema de minimización irrestricta de una función cuadrática de la forma (8.136), con una matriz Q definida positiva, en n iteraciones, a lo sumo, a partir de cualquier punto inicial. De hecho, con frecuencia, una aproximación suficientemente buena es encontrada bien más rápido, principalmente para problemas de gran tamaño (cuando n es grande). Por eso, los métodos de direcciones conjugadas son muy usados para minimización iterativa de funciones cuadráticas, inclusive para resolución iterativa de sistemas de ecuaciones lineales

$$Ax = a,$$

donde $A \in \mathbb{R}^{l \times n}$ es una matriz de rango l y $a \in \mathbb{R}^n$. Este último problema puede ser escrito como minimización de una función cuadrática, por ejemplo, de la manera siguiente:

$$\min \|Ax - a\|^2, \quad x \in \mathbb{R}^n,$$

donde la matriz asociada $Q = A^T A \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva (cuando A tiene rango l).

Si intentamos aplicar el método de los gradientes conjugados a una función que no sea cuadrática, la primera dificultad estaría en la fórmula (8.144) para el cálculo de β_{k-1} , que contiene la matriz Q . Felizmente, esta dificultad es puramente formal. Sin embargo, por las mismas razones mencionadas en relación a los métodos de Newton y cuasi-Newton, es altamente deseable evitar el cálculo de la matriz $f''(x^k)$. Se puede mostrar (véase el Ejercicio 3.4.1) que la fórmula (8.144) puede ser escrita de la siguiente manera:

$$\beta_{k-1} = \frac{\langle f'(x^k), f'(x^k) - f'(x^{k-1}) \rangle}{\|f'(x^{k-1})\|^2},$$

o aún,

$$\beta_{k-1} = \frac{\|f'(x^k)\|^2}{\|f'(x^{k-1})\|^2}.$$

En el caso de una función no cuadrática, las fórmulas para el cálculo de β_{k-1} dadas arriba resultan, en general, en valores diferentes. Más aún, los vectores d^k así generados no forman un conjunto Q -conjugado para ninguna matriz Q . Naturalmente, convergencia finita no puede ser esperada. Mas aún así, hay razones para esperar convergencia rápida, debido al hecho de que, localmente, una función dos veces diferenciable es aproximada bien por una función cuadrática (dada por la parte cuadrática de su expansión de Taylor).

La experiencia computacional sugiere que la primera fórmula es mejor que la segunda. Las explicaciones pueden ser consultadas en [3, 4, 20]. Resultados sobre convergencia y tasa de convergencia de varios métodos de gradientes conjugados pueden ser consultados en [20]. Curiosamente, estos resultados se refieren a la segunda fórmula, y no a la primera, aunque la primera sea aquella utilizada en la práctica. De cierto modo, tal situación no es rara en el área de optimización computacional: a veces un método es justificado teóricamente para una elección de parámetros, mas la experiencia computacional indica ventajas de alguna elección diferente que, sin embargo, no posee justificación

teórica completa. El papel del análisis matemático de métodos computacionales es importante, mas no debe ser ni exagerado ni menospreciado.

Resaltamos que, por (8.143) y (8.146),

$$\langle f'(x^k), d^k \rangle = -\|f'(x^k)\|^2 < 0,$$

si $f'(x^k) \neq 0$. Por lo tanto, por el Lema 8.1, $d^k \in \mathcal{D}_f(x^k)$. Por eso, podemos minimizar en (8.138) sobre el conjunto $\alpha \geq 0$, admitir que $\alpha_k > 0$, y considerar el método de los gradientes conjugados como un método de descenso. En el caso no cuadrático, la minimización unidimensional exacta ya no es posible y tenemos que apelar a otras reglas de búsqueda lineal, por ejemplo a la de Wolfe [20]. Para mejorar la convergencia global del método de los gradientes conjugados, es recomendable utilizar, de vez en cuando, pasos del método del gradiente (véase también comentarios en § 3.2.3).

Por razones ya mencionadas, los métodos cuasi-Newton y los gradientes conjugados son los más adecuados para minimización irrestricta de funciones diferenciables. Una comparación detallada de estos métodos puede ser consultada en [3, 4]. Actualmente, una cierta preferencia en el caso no cuadrático es dada a los métodos cuasi-Newton. Los métodos de los gradientes conjugados, bastante populares hasta hace algún tiempo atrás, ahora son considerados un tanto sobrepasados. De cierto modo, el método de los gradientes conjugados puede ser pensado como una especie “pobre” de métodos cuasi-Newton. En particular, como se sigue del Ejercicio 3.4.2 a continuación, en el caso de utilización de la primera fórmula y de la regla de minimización unidimensional, el paso del método de gradientes conjugados puede ser interpretado como paso del método BFGS, donde en la fórmula (8.75) en vez de la matriz Q_k calculada en la iteración anterior, se utiliza la matriz identidad E^n . En otras palabras, tal método de gradientes conjugados es una modificación del método BFGS, que comienza cada iteración con la elección primitiva de $Q_k (= E^n)$.

8.5. Métodos que no utilizan derivadas

Esta sección bien corta no contiene resultados de convergencia, porque los métodos que serán mencionados están fuera de los asuntos principales abordados en este libro y el análisis teórico de ellos es muy complicado. Por otro lado, la importancia práctica de métodos de orden cero no permite omitirlos completamente. Fue elegido entonces presentar un resumen breve, sin estudio teórico. Más informaciones pueden ser obtenidas en [14].

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dada. La implementación de métodos para el problema

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (8.149)$$

que fueron presentados hasta ahora, requiere el cálculo de (primeras o, incluso, segundas) derivadas de f . En la práctica, a veces, este cálculo tiene costo computacional muy grande. En algunas aplicaciones, este cálculo puede hasta ser imposible en principio (por ejemplo, cuando no hay fórmulas explícitas para las derivadas de f). A veces, lo mejor que puede ser hecho es calcular apenas valores de f . Este es el caso, por ejemplo, cuando para un punto dado x , el valor $f(x)$ es obtenido por resolución de otro problema que tiene a x como parámetro. En las situaciones de este tipo, precisamos o bien hacer una aproximación de derivadas utilizando valores de la función, o bien desarrollar métodos completamente diferentes, que no utilizan derivadas (tales métodos son llamados de métodos de búsqueda directa).

Dificultades de otra naturaleza (incluso con consecuencias parecidas) surgen en los casos en que la función objetivo ni siquiera es diferenciable. En estos casos, los métodos presentados hasta ahora no pueden ser utilizados o, cuando pueden, la convergencia de ellos no puede ser garantizada. Algunos métodos para minimización de funciones no diferenciables serán presentados más adelante. Cabe resaltar que la resolución de problemas no diferenciables presenta desafíos serios y necesita herramientas diferentes de aquellas del caso diferenciable. La situación se complica todavía más cuando el problema en consideración no posee alguna estructura especial y/o cuando él no es un problema de programación convexa. En el caso convexo, existen, sí, algunos métodos bien eficaces, que serán desarrollados en el Capítulo 5.

En principio, todos los métodos de primera y segunda orden considerados arriba pueden ser implementados (de manera inexacta) sin utilización de derivadas, aproximándolas por esquemas de diferencias finitas. Por ejemplo, el gradiente de la función f en el punto $x^k \in \mathbb{R}^n$ puede ser aproximado por el esquema de diferencias hacia adelante

separadas:

$$f'_{x_j}(x^k) \approx g_j^k = \frac{f(x^k + t_k e^j) - f(x^k)}{t_k}, \quad j = 1, \dots, n,$$

o además, por el esquema de diferencias centradas:

$$f'_{x_j}(x^k) \approx g_j^k = \frac{f(x^k + t_k e^j) - f(x^k - t_k e^j)}{2t_k}, \quad j = 1, \dots, n,$$

donde $t_k > 0$ es un número pequeño y $\{e^1, \dots, e^n\}$ es la base canónica de $\mathbb{R}^n$. La aproximación por diferencias centradas es más precisa, mas ella requiere casi el doble de computaciones de valores de la función f .

El análogo del método del gradiente, con diferencias finitas, viene dado por

$$x^{k+1} = x^k - \alpha_k g^k, \quad k = 0, 1, \dots, \quad (8.150)$$

donde los vectores $g^k \in \mathbb{R}^n$ son calculados utilizando uno de los esquemas de arriba, y los valores de la longitud de paso α_k son calculados por una de las reglas de búsqueda lineal en la dirección $-g^k$ (véase § 3.1.1). Sin embargo, es importante mencionar que la prueba de convergencia de un método de este tipo difícilmente puede ser hecha sin la hipótesis de diferenciabilidad de la función f , aunque el método no utilice las derivadas.

Ejemplo 8.2. Para la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = \max\{|x_1|, |x_2|\},$$

el vector g^k , calculado por el esquema de diferencias hacia adelante separadas en el punto $x^k = (-1, -1)$, sería el cero. Luego, el análogo del método del gradiente correspondiente no conseguiría salir del punto x^k , en cuanto que el único minimizador local irrestricto de f es el cero (que también es el minimizador global).

Esto, sin embargo, no es ninguna sorpresa: el método está basado en la aproximación del método del gradiente; por lo tanto, la convergencia de él solo puede ser esperada cuando el método “exacto” converge.

El método más natural que no utiliza el cálculo (exacto o aproximado) de derivadas es el método de descenso por coordenadas, dado por el esquema siguiente:

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, 1, \dots, \quad (8.151)$$

donde

$$d^0 = e^1, \dots, d^{n-1} = e^n, \quad d^n = e^1, \dots, d^{2n-1} = e^n, \dots$$

Los valores de la longitud del paso α_k pueden ser calculados por la minimización unidimensional, i.e.,

$$f(x^k + \alpha_k d^k) = \min_{\alpha \in \mathbb{R}} f(x^k + \alpha d^k),$$

donde la minimización es sobre todos los $\alpha \in \mathbb{R}$, ya que d^k puede no ser una dirección de descenso de la función f en el punto x^k . Una iteración del método consiste entonces en la minimización unidimensional de la función f en relación a una coordenada, con otras coordenadas fijas. Las variables de minimización son cambiadas de manera cíclica. El método es ilustrado en la Figura 8.11.

Figura 8.11.: Iteraciones del método de descenso por coordenadas.

En el método de descenso por coordenadas, pueden ser utilizadas también otras ideas para el cálculo de longitudes de paso. Por ejemplo, la siguiente. Fijamos parámetros $\hat{\alpha} > 0$ y $\theta \in (0, 1)$. Dados x^k y d^k , tomamos primero $\alpha = \hat{\alpha}$. Si

$$f(x^k + \alpha d^k) < f(x^k),$$

aceptamos $\alpha_k = \alpha$. Caso contrario, si

$$f(x^k - \alpha d^k) < f(x^k),$$

aceptamos $\alpha_k = -\alpha$. Si ninguna de las dos desigualdades se satisface, o bien definimos $\alpha_k = 0$ (es claro que esto solo puede tener algún sentido en un número de iteraciones seguidas menor que n), o bien cambiamos α por $\theta\alpha$ e intentamos de nuevo.

Es interesante notar que, de nuevo, aunque el método no tenga ninguna relación aparente con derivadas, garantizar su comportamiento razonable solo es posible para funciones diferenciables (véase el Ejemplo 8.2 arriba). Además de

eso, sin convexidad, no es posible probar convergencia global del método de descenso por coordenadas: puntos de acumulación de la secuencia generada pueden no ser puntos estacionarios del problema (8.149), véase [20].

El método de descenso por coordenadas puede ser extendido fácilmente al problema de optimización con restricciones de caja.

En el método de descenso por coordenadas aleatorio, la dirección d^k en (8.151) es definida por un vector de la base canónica e^j , donde el índice j viene dado por la realización de algún proceso estocástico, con probabilidades iguales para los valores $1, \dots, n$. En el método de búsqueda aleatoria, la dirección d^k viene dada por la realización de algún proceso estocástico, con probabilidades iguales para los vectores en la esfera unitaria del espacio $\mathbb{R}^n$. Los valores de la longitud del paso son calculados utilizando alguna regla de búsqueda lineal para garantizar, por lo menos, que la secuencia $\{f(x^k)\}$ sea no creciente (en particular, cuando d^k no es una dirección de descenso, la longitud de paso es cero). Resultados teóricos para métodos de este tipo afirman, típicamente, la convergencia de la secuencia $\{f'(x^k)\}$ a cero con probabilidad 1.

Finalmente, comentaremos sobre el caso en que la función f es no diferenciable. En esta situación el hecho siguiente es crucial: si una función es Lipschitz-continua en una vecindad de cada punto de $\mathbb{R}^n$, entonces ella es diferenciable en casi todo punto de $\mathbb{R}^n$ (en el sentido de que el conjunto de puntos de no diferenciableidad tiene medida nula, véase § 1.6). Por eso, podemos esperar que f sea diferenciable en un punto $\tilde{x}^k$ elegido de manera aleatoria (por ejemplo, en una caja de tamaño $\delta_k > 0$ en torno a un punto dado x^k). Este razonamiento sugiere el método de diferencias finitas estocásticas, dado por el esquema (8.150) con

$$g_j^k = \frac{f(\tilde{x}^k + t_k e^j) - f(\tilde{x}^k)}{t_k}, \quad j = 1, \dots, n,$$

donde $t_k > 0$. Haciendo una coordinación inteligente de los parámetros α_k , δ_k y t_k , es posible probar la convergencia de este método al conjunto de puntos estacionarios del problema (8.149) con probabilidad 1 (mas es claro que la propia noción de un punto estacionario tiene que ser repensada, debido a la no diferenciableidad de la función objetivo).

Ejercicios del Capítulo 3

Ejercicio 8.1. Probar los siguientes hechos, que pueden ser pensados como caracterizaciones adicionales de direcciones de descenso. Si la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es dos veces diferenciable en el punto $x \in \mathbb{R}^n$, entonces

- (a) Para todo $d \in \mathcal{D}_f(x)$ tal que $\langle f'(x), d \rangle = 0$, se tiene que $\langle f''(x)d, d \rangle \leq 0$.
- (b) Si $d \in \mathbb{R}^n$ satisface $\langle f'(x), d \rangle = 0$ e $\langle f''(x)d, d \rangle < 0$, se tiene que $d \in \mathcal{D}_f(x)$.

Ejercicio 8.2. Suponiendo que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea continuamente diferenciable en el punto x^k y que $d^k \in \mathcal{D}_f(x^k)$, probar que la modificación de la regla de Armijo donde la desigualdad (8.6) es sustituida por

$$f(x^k + \alpha d^k) \leq f(x^k) + \sigma \alpha^2 \langle f'(x^k), d^k \rangle,$$

con $\sigma > 0$, está bien definida (i.e., que existe $\bar{\alpha}_k > 0$ tal que la condición de arriba vale para todo $\alpha \in (0, \bar{\alpha}_k]$).

Ejercicio 8.3. Bajo las mismas hipótesis probar que la implementación de la regla de Goldstein (8.10), análoga a aquella presentada para la regla de Wolfe, está bien definida.

Ejercicio 8.4. Probar afirmaciones análogas a aquellas del Teorema 8.2 para el método del gradiente con búsqueda lineal de Goldstein y con búsqueda lineal de Wolfe.

Ejercicio 8.5. Suponiendo las hipótesis del Teorema 8.2 y que el conjunto de nivel $L(f(x^0))$ sea acotado, probar que

$$\text{dist}(x^k, S_0) \rightarrow 0 \quad (k \rightarrow \infty),$$

donde $S_0 = S_0(x^0) = \{x \in L(f(x^0)) \mid f'(x) = 0\}$.

Ejercicio 8.6. Considerar el esquema iterativo dado por

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, 1, \dots,$$

donde

$$c_1 \|f'(x^k)\|^{p_1} \leq -\langle f'(x^k), d^k \rangle, \quad \|d^k\| \leq c_2 \|f'(x^k)\|^{p_2},$$

con $c_1, c_2 > 0$, $p_1, p_2 \geq 0$, y la longitud de paso α_k es calculada por la regla de minimización unidimensional o por la regla de Armijo.

Suponiendo que la función f sea continuamente diferenciable, probar que todo punto de acumulación de la secuencia $\{x^k\}$ es un punto estacionario del problema (8.1).

Ejercicio 8.7. Probar los ítems (b)-(d) del Teorema 8.4.

Ejercicio 8.8. Probar que en el Teorema 8.4, la hipótesis de diferenciabilidad de la función f en todo $\mathbb{R}^n$, así como la hipótesis de la continuidad de Lipschitz de la derivada de f en $\mathbb{R}^n$, pueden ser relajadas, suponiendo estas propiedades en una vecindad del punto $\bar{x}$.

Ejercicio 8.9. Probar el siguiente resultado, siguiendo el razonamiento de demostración del Lema 8.5.

Supongamos que existan números $\delta > 0$ y $\gamma > 0$ tales que la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea tres veces diferenciable en $U = U(S, \delta)$, con la derivada tercera acotada en U . Supongamos que (8.42) sea satisfecha. Entonces para todo $\nu \in (0, 4)$, existe $r > 0$ tal que

$$\|f'(x)\|^2 \geq \nu\gamma(f(x) - \bar{v}) \quad \forall x \in U(S, r).$$

Ejercicio 8.10. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$. Suponiendo que f asuma en el conjunto de sus puntos estacionarios un número finito de valores diferentes, mostrar que la condición de separación de superficies de nivel críticas es satisfecha.

Ejercicio 8.11. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función cuadrática que posee un punto estacionario. Mostrar que la propiedad (8.43) es satisfecha (con $U = \mathbb{R}^n$ y algún $\gamma > 0$). Mostrar que la condición de separación de superficies de nivel críticas también es satisfecha (trivialmente).

Ejercicio 8.12. Tomando $x^0 = (-2, 1)$, hacer dos iteraciones del método de máximo descenso para la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + x_1x_2 + 2x_2^2 + x_1.$$

Ejercicio 8.13. Tomando $x^0 = (1, -1)$, hacer una iteración del método del gradiente para la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = 2x_1^2 + x_1x_2 + 3x_2^2,$$

utilizando la regla de Armijo, con parámetros siendo $\hat{\alpha} = 1$ y $\sigma = \theta = 1/2$.

Ejercicio 8.14. Sea $\{x^k\}$ una secuencia generada por

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, 1, \dots,$$

donde

$$c_1 \|f'(x^k)\|^2 \leq -\langle f'(x^k), d^k \rangle, \quad \|d^k\| \leq c_2 \|f'(x^k)\|,$$

$c_1, c_2 > 0$, y la secuencia $\{\alpha_k\} \subset \mathbb{R}_+$ satisface

$$\lim_{k \rightarrow \infty} \alpha_k = 0, \quad \sum_{k=0}^{\infty} \alpha_k = +\infty.$$

Sea f acotada inferiormente y sea la derivada de f Lipschitz-continua en $\mathbb{R}^n$. Probar que la secuencia $\{f(x^k)\}$ converge y que

$$\lim_{k \rightarrow \infty} \inf \|f'(x^k)\| = 0.$$

Más aún, si conjuntos de nivel $\{x \in \mathbb{R}^n \mid f(x) \leq c\}$ son acotados para todo $c \in \mathbb{R}$, entonces la secuencia $\{x^k\}$ es acotada y todo punto de acumulación de $\{x^k\}$ es punto estacionario del problema (8.1).

Ejercicio 8.15. Sea $\{x^k\}$ una secuencia generada por

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, 1, \dots,$$

donde α_k es calculado por la regla de Armijo,

$$d^k = -(0, \dots, 0, f'_{x_i}(x^k), 0, \dots, 0),$$

y el índice $i \in \{1, \dots, n\}$ satisface

$$|f'_{x_i}(x^k)| = \max_{j=1, \dots, n} |f'_{x_j}(x^k)|.$$

Suponiendo que la función f es continuamente diferenciable, probar que todo punto de acumulación de $\{x^k\}$ es punto estacionario del problema (8.1).

Ejercicio 8.16. Sea f una función continuamente diferenciable. Supongamos que, dado un punto $x^k \in \mathbb{R}^n$, la dirección $d^k \in \mathbb{R}^n$ sea elegida de manera que garantice que cuando una subsecuencia $\{x^{k_i}\}$ converge a un punto no estacionario del problema (8.1), entonces

$$\liminf_{i \rightarrow \infty} \langle f'(x^{k_i}), d^{k_i} \rangle < 0.$$

Sea $\{x^k\}$ una secuencia generada por

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, 1, \dots,$$

donde α_k es calculado por la regla de Armijo. Probar que todo punto de acumulación de $\{x^k\}$ es punto estacionario del problema (8.1).

Ejercicio 8.17. Sea $\{x^k\}$ una secuencia generada por

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, 1, \dots,$$

donde

$$d^k = -f'(x^k) + \varepsilon^k, \quad \|\varepsilon^k\| \leq \delta \quad \forall k.$$

Supongamos que la secuencia $\{x^k\}$ sea acotada. Probar que para todo $c > \delta$, existen $c_1, c_2 > 0$ tales que si $\alpha_k \in [c_1, c_2]$, entonces la secuencia $\{x^k\}$ posee un punto de acumulación que pertenece al conjunto $\{x \in \mathbb{R}^n \mid \|f'(x)\| \leq c\}$.

Ejercicio 8.18. Probar el Corolario 8.1.

Ejercicio 8.19. Bajo las hipótesis del Teorema 8.6, probar que una secuencia $\{x^k\}$ que satisface la condición (8.56), donde $\sigma_k \rightarrow 0$ ($k \rightarrow \infty$), converge a $\bar{x}$ con tasa superlineal.

Ejercicio 8.20. Probar que bajo las condiciones del Teorema 8.6, el método dado por (8.57) converge localmente a $\bar{x}$ con tasa lineal. Además de eso, la tasa de convergencia lineal se vuelve más rápida a medida que x^0 es tomado más próximo a $\bar{x}$.

Ejercicio 8.21. A partir del punto $x^0 = 1$, hacer dos iteraciones del método de Newton para la ecuación

$$x^p = 0,$$

donde $p \geq 2$ es un parámetro entero. Analizar la tasa de convergencia y explicar el fenómeno observado. Modificar el método de Newton introduciendo la longitud de paso igual a p y analizar la tasa de convergencia de nuevo.

Ejercicio 8.22. Probar la siguiente afirmación.

Sea la función $\Phi : \mathbb{R} \rightarrow \mathbb{R}$ diferenciable p veces en el punto $\bar{x} \in \mathbb{R}$, $p \geq 2$, donde $\bar{x}$ es una raíz de orden p de la ecuación (8.49), i.e.,

$$\Phi(\bar{x}) = \Phi'(\bar{x}) = \dots = \Phi^{(p-1)}(\bar{x}) = 0, \quad \Phi^{(p)}(\bar{x}) \neq 0.$$

Entonces el método de Newton converge localmente a $\bar{x}$ con tasa lineal, y si introducimos una longitud de paso igual a p , la tasa de convergencia se vuelve superlineal.

Ejercicio 8.23. Probar que el método de Newton es invariante en relación a transformaciones lineales de variables, en el sentido siguiente.

Sea $x = Ay$ una transformación de variables, dada por una matriz no singular $A \in \mathbb{R}^{n \times n}$. Entonces si el método de Newton en variables y genera una secuencia $\{y^k\}$ y en variables x genera una secuencia $\{x^k\}$, se tiene que $y^k = A^{-1}x^k$.

Ejercicio 8.24. Hacer dos iteraciones del método de Newton a partir del punto $x^0 = (1, 1)$ para el problema de minimización irrestricta de la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + e^{x_2^2}.$$

Analizar la tasa de convergencia. Mostrar que, en este caso, el método de Newton posee convergencia global.

Ejercicio 8.25. Considerar el método de Newton para minimizar la función

$$f : \mathbb{R} \rightarrow \mathbb{R}, \quad f(x) = x^2 + \cos x.$$

Mostrar que la solución $\bar{x} = 0$ satisface todas las hipótesis del Corolario 8.2 y que, si $x^0 = 2\pi i$ donde $i \in \{1, 2, \dots\}$ (notemos que tal x^0 no es próximo a $\bar{x}$), la secuencia generada por el método de Newton no converge.

Ejercicio 8.26. Aplicar el método de Newton para minimizar la función

$$f : \mathbb{R}^n \rightarrow \mathbb{R}, \quad f(x) = \|x\|^3.$$

Analizar la tasa de convergencia y explicar lo observado.

Ejercicio 8.27. Mostrar que si valen las hipótesis del Teorema 8.7, la condición (8.66) es equivalente a

$$(Q_k^{-1} - f''(\bar{x}))Q_k f'(x^k) = o(\|Q_k f'(x^k)\|). \quad (8.152)$$

Ejercicio 8.28. Para el caso de utilización de la regla de búsqueda lineal de Goldstein con el valor inicial de la longitud del paso $\alpha = 1$, probar afirmaciones análogas a las del Teorema 8.7.

Ejercicio 8.29. Mostrar que los métodos DFP y BFGS tienen una relación de “dualidad” en el sentido siguiente.

Para una matriz simétrica definida positiva $Q_k \in \mathbb{R}^{n \times n}$, definimos $H_k = Q_k^{-1}$. Sea la matriz Q_{k+1} generada por (8.75), y la matriz H_{k+1} generada por

$$H_{k+1} = H_k + \frac{s^k (s^k)^\top}{\langle r^k, s^k \rangle} - \frac{(H_k r^k)(H_k r^k)^\top}{\langle H_k r^k, r^k \rangle}$$

(comparar con (8.71)), suponiendo que H_{k+1} sea no singular. Entonces la matriz Q_{k+1} es no singular y se tiene que $H_{k+1} = Q_{k+1}^{-1}$.

Utilizar este hecho para probar, para BFGS, el resultado análogo a aquel de la Proposición 8.1.

Ejercicio 8.30. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces continuamente diferenciable. Considerar el siguiente algoritmo.

Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$. Elegir los parámetros $\sigma \in (0, 1/2)$, $\theta \in (0, 1)$. Si $f''(x^k)$ es no singular, tomar $d^k = -(f''(x^k))^{-1} f'(x^k)$. Caso contrario, tomar $d^k = 0$. Tomar $h^k = -f'(x^k)$. Computar

$$x^{k+1} = x^k + \alpha_k((1 - \alpha_k)h^k + \alpha_k d^k),$$

donde α_k es el mayor entre todos los números de la forma θ^s , $s \in \mathbb{N}$, satisfaciendo

$$f(x^k + \theta^s((1 - \theta^s)h^k + \theta^s d^k)) \leq f(x^k) - \sigma \theta^s \langle f'(x^k), (1 - \theta^s)h^k + \theta^s d^k \rangle.$$

Probar que el método está bien definido (en particular, la regla del cálculo de la longitud del paso está bien definida). Probar que todo punto de acumulación de una secuencia $\{x^k\}$ así generada, es un punto estacionario del problema (8.87). Probar que si $\{x^k\}$ converge a un punto estacionario $\bar{x}$ donde $f''(\bar{x})$ es definida positiva, entonces la tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal.

Ejercicio 8.31. Sean dados un vector $q \in \mathbb{R}^n$, una matriz simétrica $Q \in \mathbb{R}^{n \times n}$, y un número $\delta > 0$. Probar que si $\bar{x} \in \mathbb{R}^n$ es una solución global del problema

$$\min \langle Qx, x \rangle + \langle q, x \rangle \quad \text{sujeto a } x \in B(0, \delta), \quad (8.153)$$

entonces existe un único número $\mu \geq 0$ tal que

$$2(Q + \mu E^n)\bar{x} + q = 0, \quad \mu(\|\bar{x}\| - \delta) = 0,$$

donde la matriz $Q + \mu E^n$ es semidefinida positiva.

Si la matriz Q es definida positiva, entonces

$$\bar{x} = \begin{cases} -Q^{-1}q/2, & \text{si } \|Q^{-1}q\|/2 \leq \delta, \\ -(Q + \mu E^n)^{-1}q/2, & \text{si no,} \end{cases}$$

donde $\mu \geq 0$ está unívocamente definido por la ecuación

$$\|(Q + \mu E^n)^{-1}q\|/2 = \delta.$$

Ejercicio 8.32. En la notación del Ejercicio 8.31, sean $\bar{x} \in \mathbb{R}^n$ y $\mu \in \mathbb{R}$ tales que $2(Q + \mu E^n)\bar{x} + q = 0$ y la matriz $Q + \mu E^n$ es semidefinida positiva. Probar las siguientes afirmaciones:

(a) Si $\|\bar{x}\| \leq \delta$ y $\mu = 0$, entonces $\bar{x}$ es una solución global del problema (8.153).

(b) Si $\|\tilde{x}\| = \delta$, entonces $\tilde{x}$ es una solución global del problema

$$\min \langle Qx, x \rangle + \langle q, x \rangle \quad \text{sueto a } x \in \{x \in \mathbb{R}^n \mid \|x\| = \delta\}.$$

(c) Si $\|\tilde{x}\| = \delta$ y $\mu \geq 0$, entonces $\tilde{x}$ es una solución global del problema (8.153).

Además de esto, si la matriz $Q + \mu E^n$ es definida positiva, en todas las afirmaciones (a)-(c) el punto $\tilde{x}$ es la única solución global del problema correspondiente.

Ejercicio 8.33. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces diferenciable en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con la segunda derivada continua en este punto. Sea $\bar{x}$ un punto estacionario del problema (8.93) que satisface la condición suficiente de segunda orden.

Probar que si $x^k \in \mathbb{R}^n \setminus \{\bar{x}\}$ está suficientemente próximo a $\bar{x}$, entonces para el iterando siguiente generado por el Algoritmo 3.3.1 vale $x^{k+1} = x^k - (f''(\bar{x}))^{-1} f'(x^k)$.

Ejercicio 8.34. Sea $\varphi : [0, 1] \times \mathbb{R}^n \rightarrow \mathbb{R}$ una función con las siguientes propiedades: existe un conjunto compacto $D \subset \mathbb{R}^n$ tal que φ es continua en $[0, 1] \times D$ y para todo $t \in [0, 1]$ el problema

$$\min \varphi(t, x) \quad \text{sueto a } x \in D,$$

posee una única solución global $\chi(t)$.

Probar que la función $\chi : [0, 1] \rightarrow \mathbb{R}^n$ es continua en $[0, 1]$.

Ejercicio 8.35. Mostrar que la fórmula (8.144) puede ser escrita de la siguiente manera:

$$\beta_{k-1} = \frac{\langle f'(x^k), f'(x^k) - f'(x^{k-1}) \rangle}{\|f'(x^{k-1})\|^2}$$

o aún,

$$\beta_{k-1} = \frac{\|f'(x^k)\|^2}{\|f'(x^{k-1})\|^2}.$$

Ejercicio 8.36. Supongamos que para los puntos $x^k \in \mathbb{R}^n$ y $x^{k+1} \in \mathbb{R}^n$ y los vectores $d^{k-1} \in \mathbb{R}^n$ y $d^k \in \mathbb{R}^n$, generados por el método de gradientes conjugados para algún $k \geq 1$, se tiene que $\langle f'(x^k), d^{k-1} \rangle = 0$ e $\langle f'(x^{k+1}), d^k \rangle = 0$. Mostrar que la dirección d^{k+1} , calculada de acuerdo con (8.143) y la segunda fórmula del Ejercicio 8.35, puede ser representada por $d^{k+1} = -Q_{k+1} f'(x^{k+1})$, donde Q_{k+1} está dada por (8.75) con $Q_k = E^n$.

Ejercicio 8.37. Utilizando el método de los gradientes conjugados, con punto inicial $x^0 = (1, 1)$, encontrar el minimizador irrestricto de la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + 2x_2^2.$$

Ejercicio 8.38. Sea $Q \in \mathbb{R}^{n \times n}$ dada por

$$Q = A + \sum_{i=1}^m y^i (y^i)^\top,$$

donde $A \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva e $y^i \in \mathbb{R}^n$, $i = 1, \dots, m$, son vectores arbitrarios.

Mostrar que el iterando x^{k+1} generado por el método de gradientes conjugados satisface la relación

$$f(x^{k+1}) \leq \left(\frac{c_n - c_1}{c_n + c_1} \right)^2 f(x^0),$$

donde c_n y c_1 son el mayor y el menor autovalor de la matriz A , respectivamente.

Ejercicio 8.39. Para el método de gradientes conjugados aplicado a la función $f(x) = \langle Qx, x \rangle + \langle q, x \rangle$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, probar que el iterando x^k minimiza f en el conjunto $x^0 + \text{span} \langle f'(x^0), Qf'(x^0), \dots, Q^{k-1} f'(x^0) \rangle$.

Ejercicio 8.40. A partir del punto inicial $x^0 = 0$, hacer dos pasos del método de descenso por coordenadas para minimizar la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + 2x_1x_2 + 3x_2^2 + 4x_1,$$

calculando la longitud del paso por la regla de minimización unidimensional.

Ejercicio 8.41. Hacer lo mismo para la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = 2x_1^2 - x_1x_2 + x_2^2,$$

a partir del punto $x^0 = (2, 0)$.

9. Métodos para Optimización con Restricción

10. Métodos para Optimización con Restricciones

Este capítulo constituye la parte principal del libro. De cierto modo, el material de los otros capítulos es preparatorio, auxiliar o adicional en relación a métodos para resolución de problemas de optimización con restricciones.

10.1. Métodos para conjuntos factibles de estructura simple

Comenzaremos el desarrollo de métodos para problemas de optimización con restricciones en el caso en que el conjunto factible tenga descripción abstracta:

$$\min f(x) \quad \text{sujeto a } x \in D, \quad (10.1)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función diferenciable y $D \subset \mathbb{R}^n$. Por razones de aplicación práctica, entendemos que el conjunto D posee una estructura simple (por lo menos, D es convexo y cerrado).

Con frecuencia, problemas con restricciones simples aparecen como subproblemas en métodos para resolución de problemas con restricciones más complejas. Notamos que cuando el conjunto D es convexo y cerrado, para todo punto $x \in \mathbb{R}^n$ existe una proyección $P_D(x)$ de x sobre D que es única (véase el Teorema 1.3.1). Recordamos también que el punto $\bar{x} \in D$ es un punto estacionario del problema (10.1) cuando

$$\langle f'(\bar{x}), x - \bar{x} \rangle \geq 0 \quad \forall x \in D, \quad (10.2)$$

o, equivalentemente,

$$P_D(\bar{x} - \alpha f'(\bar{x})) = \bar{x} \quad (10.3)$$

para algún $\alpha > 0$ (véase el Teorema 1.3.7). Más aún, la validez de (10.3) para algún $\alpha > 0$ implica la validez de esta relación para todo $\alpha > 0$.

10.1.1. Métodos del gradiente proyectado

Los métodos del gradiente proyectado pueden ser pensados como una combinación natural de métodos del gradiente para optimización irrestricta con proyección de iteraciones así obtenidas en el conjunto factible del problema. Esto resulta en el esquema siguiente:

$$x^{k+1} = P_D(x^k - \alpha_k f'(x^k)), \quad k = 0, 1, \dots, \quad (10.4)$$

donde $x^0 \in D$, y los parámetros de longitud de paso $\alpha_k > 0$ son calculados utilizando extensiones de técnicas de búsqueda lineal de § 3.1.1 con restricciones. En particular, el valor de longitud de paso es calculado para obtener un decrecimiento de la función

$$\varphi_k : \mathbb{R}_+ \rightarrow \mathbb{R}, \quad \varphi_k(\alpha) = f(x^k(\alpha)),$$

donde

$$x^k(\alpha) = P_D(x^k - \alpha f'(x^k)) \quad (10.5)$$

es el arco de proyección (véase la Figura 10.1).

Figura 10.1.: El arco de proyección $x^k(\alpha)$, $\alpha \in [0, \hat{\alpha}]$.

Por ejemplo, en el caso de la minimización unidimensional, α_k es una solución del problema

$$\min \varphi_k(\alpha) \quad \text{sujeto a } \alpha \in \mathbb{R}_+,$$

o del problema

$$\min \varphi_k(\alpha) \quad \text{sujeto a } \alpha \in [0, \hat{\alpha}],$$

donde $\hat{\alpha} > 0$ es un parámetro. Sin embargo, como en el caso irrestricto, las reglas de minimización unidimensional no son muy atractivas desde el punto de vista práctico.

Más interesantes son las extensiones de la regla de Armijo. Esto puede ser hecho, por ejemplo, por el mismo esquema que fue considerado en § 3.1.1, sustituyendo la condición (8.6) por

$$f(x^k(\alpha)) \leq f(x^k) + \sigma \langle f'(x^k), x^k(\alpha) - x^k \rangle. \quad (10.6)$$

Recordamos que, para comenzar el proceso, deben ser elegidos un parámetro $\sigma \in (0, 1)$, el valor inicial de la longitud del paso $\hat{\alpha} > 0$ y el parámetro de reducción del paso $\theta \in (0, 1)$. En particular, α_k es calculado como el mayor entre todos los números de la forma $\alpha = \hat{\alpha}\theta^s$, $s \in \mathbb{N}$, satisfaciendo la desigualdad (10.6). Como es fácil ver, en el caso cuando $D = \mathbb{R}^n$, la desigualdad (10.6) se reduce a la condición de Armijo (8.6) en el caso irrestricto.

Existen también varias modificaciones de la regla de Armijo (por ejemplo, similares a la regla de Goldstein). Podríamos considerar también la regla de longitud de paso fijo, donde $\alpha_k = \bar{\alpha}$ para todo k , con $\bar{\alpha} > 0$ fijo.

Algoritmo 4.1.1. (Método del gradiente proyectado)

Elegir $x^0 \in D$ y tomar $k := 0$. Elegir una de las tres reglas de cálculo de longitud de paso a ser utilizada, y los parámetros asociados: $\hat{\alpha} > 0$ (o $\hat{\alpha} = +\infty$) en el caso de minimización unidimensional, $\hat{\alpha} > 0, \sigma, \theta \in (0, 1)$ en el caso de la regla de Armijo, $\bar{\alpha} > 0$ en el caso de longitud de paso fijo.

1. Calcular α_k de acuerdo con la regla elegida.
2. Calcular x^{k+1} utilizando la fórmula (10.4).
3. Tomar $k := k + 1$ y retornar al Paso 1.

El Algoritmo 4.1.1 está ilustrado en la Figura 10.1.

Observamos que si para algún k el punto x^k es estacionario para el problema (10.1), entonces el método genera $x^k = x^{k+1} = \dots$, cualquiera que sea la longitud del paso α_k . Notamos también que para $D = \mathbb{R}^n$, un método del gradiente proyectado se reduce al método del gradiente (irrestricto) correspondiente. Las propiedades de convergencia de métodos del gradiente proyectado son muy parecidas a las propiedades de métodos del gradiente. A continuación, presentaremos dos resultados que son generalizaciones de los Teoremas 8.1 y 8.5, respectivamente.

En el análisis a seguir, la siguiente desigualdad tiene un papel importante:

$$\langle f'(x^k), x^k(\alpha) - x^k \rangle \leq -\frac{1}{\alpha} \|x^k(\alpha) - x^k\|^2 \quad \forall \alpha > 0. \quad (10.7)$$

Para probar esta desigualdad, notamos que para todo $\alpha > 0$,

$$\begin{aligned} & \langle f'(x^k), x^k(\alpha) - x^k \rangle \\ &= \frac{1}{\alpha} \langle x^k + \alpha f'(x^k) - x^k, x^k(\alpha) - x^k \rangle \\ &= \frac{1}{\alpha} \langle x^k - x^k(\alpha), x^k(\alpha) - x^k \rangle + \frac{1}{\alpha} \langle x^k(\alpha) - (x^k - \alpha f'(x^k)), x^k(\alpha) - x^k \rangle \\ &\leq -\frac{1}{\alpha} \|x^k(\alpha) - x^k\|^2, \end{aligned}$$

donde el Teorema 1.3.1 fue utilizado.

Lema 10.1. Sean $D \subset \mathbb{R}^n$ un conjunto cerrado y convexo, y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$. Entonces para cualquier $x^k \in \mathbb{R}^n$ la desigualdad (10.6) es satisfecha para todo $\alpha \in (0, \bar{\alpha}]$, donde

$$\bar{\alpha} = 2(1 - \sigma)/L > 0. \quad (10.8)$$

Prueba. Utilizando el Lema 1.5.4 y las desigualdades (10.7) y (10.8), para todo $\alpha \in (0, \bar{\alpha}]$ obtenemos que

$$\begin{aligned} f(x^k(\alpha)) - f(x^k) &\leq \langle f'(x^k), x^k(\alpha) - x^k \rangle + \frac{L}{2} \|x^k(\alpha) - x^k\|^2 \\ &\leq \sigma \langle f'(x^k), x^k(\alpha) - x^k \rangle + \left(\frac{L}{2} - \frac{1-\sigma}{\alpha} \right) \|x^k(\alpha) - x^k\|^2 \\ &\leq \sigma \langle f'(x^k), x^k(\alpha) - x^k \rangle, \end{aligned}$$

lo que es justamente el resultado anunciado. $\blacksquare$

El resultado del Lema 10.1 implica que, bajo las hipótesis correspondientes, los valores de longitud del paso calculados por la regla de Armijo están limitados inferiormente por un número que no depende de k , i.e.,

$$\alpha_k \geq \check{\alpha} > 0 \quad \forall k. \quad (10.9)$$

Observamos también que la utilización de longitud de paso fijo, suponiendo que

$$\bar{\alpha} < 2/L, \quad (10.10)$$

es equivalente a la regla de Armijo con $\hat{\alpha} = \bar{\alpha}$ y $\sigma > 0$ suficientemente pequeño. Por lo tanto, este caso no requiere análisis separado.

Teorema 10.1 (Convergencia del método del gradiente proyectado). Sean $D \subset \mathbb{R}^n$ un conjunto cerrado y convexo, $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$. Entonces cada punto de acumulación de cualquier secuencia $\{x^k\}$ generada por el Algoritmo 4.1.1 es un punto estacionario del problema (10.1). Si un punto de acumulación existe, o si la función f está limitada inferiormente en D , entonces para cualquier secuencia acotada $\{t_k\} \subset \mathbb{R}_+$ se tiene que

$$\|x^k - P_D(x^k - t_k f'(x^k))\| \rightarrow 0 \quad (k \rightarrow \infty). \quad (10.11)$$

Prueba. Consideremos el caso de la regla de Armijo. Por (10.7), para todo k tenemos que

$$\begin{aligned} f(x^k) - f(x^{k+1}) &\geq -\sigma \langle f'(x^k), x^{k+1} - x^k \rangle \\ &\geq \frac{\sigma}{\alpha_k} \|x^{k+1} - x^k\|^2 \\ &\geq \frac{\sigma}{\bar{\alpha}} \|x^{k+1} - x^k\|^2. \end{aligned} \quad (10.12)$$

Si x^k no es un punto estacionario del problema (10.1), se tiene que

$$\|x^{k+1} - x^k\| = \|P_D(x^k - \alpha_k f'(x^k)) - x^k\| > 0,$$

porque $\alpha_k > 0$. Por eso, de (10.12) obtenemos que la secuencia $\{f(x^k)\}$ es decreciente. Supongamos que la secuencia $\{x^k\}$ posea un punto de acumulación $\bar{x} \in \mathbb{R}^n$. En este caso, por el hecho de que la secuencia $\{f(x^k)\}$ es decreciente, obtenemos que ella está limitada inferiormente (por $f(\bar{x})$), y por lo tanto converge (cuando la función f es limitada inferiormente en $\mathbb{R}^n$, esto vale incluso cuando $\{x^k\}$ no tiene puntos de acumulación). Concluimos que

$$f(x^k) - f(x^{k+1}) \rightarrow 0 \quad (k \rightarrow \infty),$$

y, de (10.12), obtenemos que

$$\|x^{k+1} - x^k\| \rightarrow 0 \quad (k \rightarrow \infty). \quad (10.13)$$

Sea la secuencia $\{t_k\} \subset \mathbb{R}_+$ limitada superiormente por un número $\hat{t}$. Por el Teorema 1.3.1, utilizando también (10.9) y (10.13), obtenemos que

$$\begin{aligned} \|x^k(t_k) - x^k\| &\leq \max\{1, t_k/\alpha_k\} \|x^k(\alpha_k) - x^k\| \\ &\leq \max\{1, \hat{t}/\check{\alpha}\} \|x^{k+1} - x^k\| \rightarrow 0 \quad (k \rightarrow \infty), \end{aligned}$$

lo que prueba (10.11).

Sea $\{x^{k_j}\}$ una subsecuencia de la secuencia $\{x^k\}$ que converge a $\bar{x}$. Pasando al límite cuando $j \rightarrow \infty$ en (10.11), donde tomamos $t_k = t \forall k$, siendo $t > 0$ un número arbitrario, llevando en cuenta la continuidad del operador de proyección (vea el Teorema 1.3.1), obtenemos (10.3), mostrando que $\bar{x}$ es un punto estacionario.

La consideración del caso de utilización de la minimización unidimensional se reduce a la regla de Armijo de la misma manera que en el Teorema 8.1. $\blacksquare$

Sea S_0 el conjunto de puntos estacionarios del problema (10.1). Supongamos que valga la condición de separación de superficies de nivel críticas, que tiene la misma forma que en § 3.1.2 (mas con la nueva definición de S_0 , es claro). Supongamos que vale la estimativa

$$\|x - P_D(x - f'(x))\| \geq \gamma \text{dist}(x, S_0) \quad \forall x \in U, \quad (10.14)$$

donde

$$U = \{x \in \mathbb{R}^n \mid \|x - P_D(x - f'(x))\| < \delta\}, \quad (10.15)$$

con constantes $\delta > 0$ y $\gamma > 0$. En el caso de $D = \mathbb{R}^n$, estas condiciones ya fueron consideradas en § 3.1.2. Sin entrar en detalles, mencionamos que ambas son satisfechas si, por ejemplo, f es una función cuadrática, D es un conjunto poliedral, y $S_0 \neq \emptyset$.

Teorema 10.2 (Convergencia lineal del método del gradiente proyectado). *Además de las hipótesis del Teorema 10.1, supongamos que el valor óptimo del problema (10.1) sea finito y valga la condición (10.14), con U definido en (10.15) y algunos $\delta > 0$ y $\gamma > 0$. Supongamos también que valga la condición de separación de superficies de nivel críticas.*

Entonces cualquier secuencia $\{x^k\}$ generada por el Algoritmo 4.1.1 converge a un punto estacionario del problema (10.1). La tasa de convergencia en relación a la función es lineal, y en relación a las variables la tasa es geométrica.

La demostración de este teorema puede ser hecha por la modificación relativamente obvia de la demostración del Teorema 8.5. Mencionemos apenas que aquí deben ser también utilizados los resultados de los Teoremas 6.5 y 6.10.

Existen modificaciones de métodos del gradiente proyectado que requieren, en cada iteración, una proyección apenas. Por ejemplo, en vez del esquema (10.4) basado en el arco de proyección (10.5), podemos utilizar el intervalo

$$x^k(\alpha) = (1 - \alpha)x^k + \alpha P_D(x^k - \beta_k f'(x^k)).$$

Esto resulta en el esquema

$$x^{k+1} = (1 - \alpha_k)x^k + \alpha_k P_D(x^k - \beta_k f'(x^k)), \quad k = 0, 1, \dots, \quad (10.16)$$

donde $x^0 \in D$, los parámetros $\beta_k > 0$ pueden ser elegidos más o menos arbitrariamente (desde que $0 < c_1 \leq \beta_k \leq c_2$), y el parámetro de longitud de paso α_k es calculado por la regla de Armijo (10.6) con $\hat{\alpha} = 1$. Las reglas de la minimización unidimensional pueden ser adaptadas análogamente.

Observamos que si $x^k \in D$ entonces, por la convexidad de D ,

$$d^k = P_D(x^k - \beta_k f'(x^k)) - x^k$$

es una dirección factible en el punto x^k en relación al conjunto D y, en particular, $x^k(\alpha) = x^k + \alpha d^k \in D$ para todo $\alpha \in [0, 1]$. Este intervalo es ilustrado en la Figura 10.2.

Figura 10.2.: El intervalo factible $x^k(\alpha) = (1 - \alpha)x^k + \alpha P_D(x^k - \beta_k f'(x^k))$, $\alpha \in [0, 1]$.

Además de esto, por (10.7), d^k es una dirección de descenso de la función f en el punto x^k . Tenemos entonces una dirección de descenso que es factible. A partir de esto, es fácil probar que, si la secuencia $\{\beta_k\}$ es acotada inferiormente por un número positivo, este esquema posee convergencia global en el sentido del Teorema 10.1. Sin embargo, probar la tasa de convergencia lineal para este esquema ya no es posible, por lo menos bajo las hipótesis usuales.

10.1.2. Direcciones factibles y métodos de descenso

Dada una aproximación x^k a la solución del problema, una idea natural consiste en definir una dirección que, al mismo tiempo, es factible en x^k en relación al conjunto D y es de descenso para la función objetivo f . A propósito, un método de este tipo ya fue presentado arriba, como modificación (10.16) del método del gradiente proyectado. A seguir, consideremos algunas otras posibilidades.

Primero, recordamos la noción de direcciones factibles (véase [12]).

Definición 10.1. Un vector $d \in \mathbb{R}^n$ se llama una *dirección factible* en el punto $x \in D$ en relación a D , si para todo $t > 0$ suficientemente pequeño se tiene que $x + td \in D$.

Recordamos también que el conjunto de todas las direcciones factibles en $x \in D$ en relación a D es un cono que denotamos por $V_D(x)$. Entonces, $d \in V_D(x)$ si, y solamente si, un paso suficientemente corto a partir de x en

la dirección d resulta en un punto que pertenece a D . Tenemos que $0 \in V_D(x)$ trivialmente. Los dos resultados siguientes proporcionan condiciones suficientes para una dirección dada ser factible. Las demostraciones de estos resultados están contenidas en las demostraciones de resultados más generales (sobre la caracterización de direcciones tangentes) en [12, Teorema 4.1.2].

Lema 10.2. Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Entonces

$$y - x \in V_D(x) \quad \forall x, y \in D.$$

Lema 10.3. Sea

$$D = \{x \in \mathbb{R}^n \mid g(x) \leq 0\},$$

donde la función $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es diferenciable en el punto $y \in D$. Entonces:

- (a) Para todo $d \in V_D(y)$ se tiene que $\langle g'_i(y), d \rangle \leq 0 \quad \forall i \in I(y)$, donde $I(y) = \{i = 1, \dots, m \mid g_i(y) = 0\}$ es el conjunto de índices de las restricciones activas en y .
- (b) Si $d \in \mathbb{R}^n$ satisface $\langle g'_i(y), d \rangle < 0 \quad \forall i \in I(y)$, se tiene que $d \in V_D(y)$.

Métodos de descenso pueden ser definidos para un problema general

$$\min f(x) \quad \text{sujeto a } x \in D, \quad (10.17)$$

donde, en principio, el conjunto factible $D \subset \mathbb{R}^n$ no precisa ser ni convexo ni cerrado, y la función objetivo no precisa ser diferenciable. El esquema general es el siguiente:

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k \in \mathcal{D}_f(x^k) \cap V_D(x^k), \quad k = 0, 1, \dots, \quad (10.18)$$

donde $x^0 \in D$, y los parámetros de longitud de paso $\alpha_k > 0$ tienen que satisfacer, por lo menos, las condiciones

$$f(x^{k+1}) < f(x^k), \quad x^{k+1} \in D. \quad (10.19)$$

Como $d^k \in \mathcal{D}_f(x^k) \cap V_D(x^k)$ por la definición, las condiciones (10.19) serán satisfechas para todo $\alpha_k > 0$ suficientemente pequeño. Entendemos que cuando $\mathcal{D}_f(x^k) \cap V_D(x^k) = \emptyset$, el método se detiene. Así, está siendo realizado descenso para superficies de nivel de la función objetivo con valores cada vez más bajos, manteniendo también la viabilidad. Cada método específico es caracterizado por la manera concreta de la elección de la dirección d^k y del cálculo de longitud del paso α_k en esta dirección. Para $D = \mathbb{R}^n$, el esquema (10.18), (10.19) coincide con el esquema general de los métodos de descenso para optimización irrestricta presentado en § 3.1.1.

Si D es un conjunto convexo y cerrado, la segunda condición en (10.19) es satisfecha para todo $\alpha_k \in [0, \hat{\alpha}_k]$, donde

$$0 < \hat{\alpha}_k = \sup\{\alpha \in \mathbb{R}_+ \mid x^k + \alpha d^k \in D\} \quad (10.20)$$

(si $\hat{\alpha}_k = +\infty$, la segunda condición en (10.19) es satisfecha para todo $\alpha_k \geq 0$). Para determinar α_k que garantice la disminución de la función objetivo f , pueden ser utilizadas las mismas técnicas de minimización unidimensional consideradas en § 3.1.1, llevando en cuenta la restricción adicional $\alpha_k \leq \hat{\alpha}_k$. Los cálculos son bien más simples cuando $\hat{\alpha}_k$ puede ser determinado explícitamente, o cuando una cota inferior para $\hat{\alpha}_k$ puede ser obtenida fácilmente.

A seguir, presentaremos dos ejemplos de métodos de descenso para problemas con restricciones simples.

10.1.3. Método del gradiente restringido. Método de Newton restringido

Supongamos que el conjunto factible D del problema (10.1), además de cerrado y convexo, sea también acotado (esta última hipótesis sirve para garantizar la existencia de soluciones en el subproblema (10.21) del método descrito a seguir). Métodos del gradiente restringido son dados de la siguiente manera de elegir una dirección de descenso factible en el esquema (10.18): para $x^k \in D$, resolvemos el problema

$$\min \langle f'(x^k), x - x^k \rangle \quad \text{sujeto a } x \in D, \quad (10.21)$$

obtenido por la linealización de la función objetivo del problema (10.1) en el punto x^k (la constante $f(x^k)$ es desconsiderada en (10.21)). Sea $\bar{x}^k \in D$ una solución del problema (10.21) y $v_k = \langle f'(x^k), \bar{x}^k - x^k \rangle$ el valor óptimo (una solución existe, por el Teorema de Weierstrass 1.1.1). Observamos que $v_k \leq \langle f'(x^k), x^k - x^k \rangle = 0$, porque $x^k \in D$. Si $v_k = 0$, tenemos que

$$\langle f'(x^k), x - x^k \rangle \geq v_k = 0 \quad \forall x \in D,$$

i.e., x^k es un punto estacionario del problema (10.1) (véase (10.2)). En este caso, el método se detiene. Si $v_k < 0$, por los Lemas 8.1 y 10.2, para la dirección $d^k = \bar{x}^k - x^k$ tenemos que $d^k \in \mathcal{D}_f(x^k) \cap V_D(x^k)$. Tal dirección d^k es llamada de *anti-gradiente restringido* de la función f en el punto x^k en relación al conjunto D , vea la Figura 10.3.

Es fácil ver que para esta elección de d^k , el valor de $\hat{\alpha}_k$ definido en (10.20) es igual a 1. Así el cálculo de la longitud del paso α_k queda facilitado.

Para métodos del gradiente restringido pueden ser obtenidos resultados análogos a aquellos del Teorema 10.1 (véase [4]). Además de esto, bajo la hipótesis adicional de que f sea convexa en D , puede ser probada convergencia aritmética (véase [22]), que garantiza una tasa apenas sublineal. Siendo una extensión obvia del método del gradiente para el caso irrestricto, este algoritmo no es rápido.

Figura 10.3.: La solución $\bar{x}^k$ del problema del gradiente restringido es el punto factible que está más lejos de x^k en la dirección $-f'(x^k)$.

A pesar de la relativamente pequeña área de aplicación y de la lenta convergencia, los métodos del gradiente restringido tienen un cierto interés teórico por consistir en una implementación (sin embargo, bastante simple) de la importante idea de linealización de las funciones que definen un problema de optimización. Una implementación más adecuada de esta idea será presentada en § 4.2 para problemas con restricciones de desigualdad, donde tanto la función objetivo cuanto las restricciones serán linealizadas en cada iteración.

Otra idea natural es utilizar, en vez de la aproximación lineal, la aproximación cuadrática de la función objetivo. Esquemas de este tipo se llaman *métodos de Newton restringido*, donde en (10.18) tenemos $d^k = \bar{x}^k - x^k$ y $\bar{x}^k$ es una solución del problema

$$\min \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle f''(x^k)(x - x^k), x - x^k \rangle \quad \text{sujeto a } x \in D. \quad (10.22)$$

Cuando D es un conjunto poliedral, (10.22) es un problema de programación cuadrática (véase § 6.2). En otros casos (i.e., de restricciones no lineales), la resolución de (10.22) puede ser no mucho más fácil de lo que la resolución del problema original (10.1), lo que torna el método poco atractivo. Para simplificar los subproblemas, parece natural combinar la aproximación de segunda orden de la función objetivo con linealización de las restricciones. Sin embargo, como veremos más adelante, en este caso es recomendable utilizar otro término cuadrático en la función objetivo de los subproblemas. Para garantizar convergencia global, en principio podemos utilizar (en vez de $f''(x^k)$) hasta una matriz definida positiva cualquiera. Mas para conseguir convergencia local rápida, la matriz en cuestión tiene que incorporar la información de segunda orden tanto sobre la función objetivo como sobre las restricciones del problema. Métodos de este tipo son bien eficientes. Ellos se llaman de *programación cuadrática secuencial* y serán presentados en § 4.6.

10.2. Métodos de direcciones factibles

En cada iteración de los métodos considerados en § 4.1, el conjunto factible del problema no es aproximado/simplificado de manera alguna. En los métodos del gradiente proyectado, el conjunto aparece en la operación de proyección. En los métodos del gradiente y de Newton restringidos, el conjunto factible original es pasado directamente para los subproblemas. Es claro que esto solo puede tener sentido computacional cuando el conjunto en cuestión es bien simple.

Para problemas más complejos, es razonable intentar utilizar aproximaciones locales de todos los datos del problema. Esta es la idea básica de los *métodos de direcciones factibles*, que son métodos de descenso para problemas con restricciones de desigualdad. Consideremos entonces el problema

$$\min f(x) \quad \text{sujeto a } x \in D = \{x \in \mathbb{R}^n \mid g(x) \leq 0\}, \quad (10.23)$$

donde las funciones $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son diferenciables. De § 4.1.2, recordamos el esquema general de los métodos de descenso para problemas con restricciones:

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k \in \mathcal{D}_f(x^k) \cap V_D(x^k), \quad k = 0, 1, \dots, \quad (10.24)$$

donde $x^0 \in D$, y los parámetros de longitud de paso $\alpha_k > 0$ son calculados para satisfacer, por lo menos, la condición

$$f(x^{k+1}) < f(x^k), \quad x^{k+1} \in D. \quad (10.25)$$

Como ya fue visto en [12], esta abordaje no siempre es recomendable. Resaltamos que, en el caso de restricciones de igualdad no lineales, en situaciones típicas el cono de direcciones factibles en relación al conjunto en cuestión es vacío ([12, § 1.4]). Es por eso que el desarrollo a seguir es hecho para restricciones de desigualdad. El método puede ser extendido fácilmente al caso en que hay restricciones de igualdad, desde que ellas sean lineales.

La realización básica de los métodos de direcciones factibles consiste en la elección siguiente de la dirección en (10.24). Para un $x^k \in D$ dado, resolvemos el problema

$$\min \max \left\{ \langle f'(x^k), d \rangle; \max_{i \in I_k} \langle g'_i(x^k), d \rangle \right\} \quad \text{sueto a } \|d\|_\infty \leq 1,$$

donde $I_k = I(x^k) = \{i = 1, \dots, m \mid g_i(x^k) = 0\}$ es el conjunto de los índices de las restricciones del problema (10.23) que son activas en el punto x^k . Este problema puede ser resuelto como el problema de programación lineal

$$\min t \quad \text{sueto a } (t, d) \in U_k, \quad (10.26)$$

$$U_k = \left\{ u = (t, d) \in \mathbb{R} \times \mathbb{R}^n \mid \begin{array}{l} \langle f'(x^k), d \rangle \leq t, \\ \langle g'_i(x^k), d \rangle \leq t, \quad i \in I_k, \\ -1 \leq d_j \leq 1, \quad j = 1, \dots, n. \end{array} \right\}. \quad (10.27)$$

En la definición del conjunto U_k , las restricciones $-1 \leq d_j \leq 1$ sirven para garantizar que el subproblema (10.26), (10.27), tenga una solución. Con efecto, $(0, 0) \in U_k$, i.e., $U_k \neq \emptyset$, y el hecho de que (10.26), (10.27), posee una solución se sigue del Corolario 1.1.1.

Sea $u^k = (t_k, d^k)$ una solución de (10.26), (10.27). Claramente, $t_k \leq 0$, porque en el punto factible $(0, 0)$ la función objetivo del problema (10.26), (10.27), tiene valor nulo. Si $t_k = 0$, el método se detiene.

Proposición 10.1. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en el punto $x^k \in D$, donde el conjunto D es definido en (10.23). Supongamos que el punto x^k satisfaga la condición de regularidad de Mangasarian-Fromovitz (??).

Si $(0, d^k)$ es una solución del problema (10.26), (10.27), con $I_k = I(x^k)$, entonces x^k es un punto estacionario del problema (10.23).

Prueba. Recordamos que la condición de Mangasarian-Fromovitz, en el caso en consideración, consiste en la existencia de $\bar{d} \in \mathbb{R}^n$ tal que

$$\langle g'_i(x^k), \bar{d} \rangle < 0 \quad \forall i \in I(x^k) = I_k. \quad (10.28)$$

Si el punto $(0, d^k)$ es una solución del problema (10.26), (10.27), el punto $(0, 0)$ también es solución de este problema (porque él es factible y proporciona el mismo valor de la función objetivo). Como las restricciones de este problema son lineales, podemos aplicar el Teorema 1.2.3 en el punto $(0, 0)$. Así obtenemos que existen $\mu_0 \geq 0$ y $\mu_i \geq 0$, $i \in I_k$, tales que

$$1 - \mu_0 - \sum_{i \in I_k} \mu_i = 0, \quad (10.29)$$

$$\mu_0 f'(x^k) + \sum_{i \in I_k} \mu_i g'_i(x^k) = 0. \quad (10.30)$$

Supongamos que $\mu_0 = 0$. En este caso, (10.29) implica que entre los números $\mu_i \geq 0$, $i \in I_k$, hay algunos estrictamente positivos. Multiplicando los dos lados de la ecuación (10.30) por $\bar{d}$ y utilizando (10.28), obtenemos una contradicción

$$0 = \sum_{i \in I_k} \mu_i \langle g'_i(x^k), \bar{d} \rangle < 0.$$

Concluimos que $\mu_0 > 0$. Dividiendo ahora los dos lados de (10.30) por μ_0 , obtenemos

$$f'(x^k) + \sum_{i \in I_k} \bar{\mu}_i g'_i(x^k) = 0,$$

donde $\bar{\mu}_i = \mu_i / \mu_0 \geq 0$, $i \in I_k$. Por lo tanto, x^k es un punto estacionario del problema (10.23). ■

Ahora, si $t_k < 0$, utilizando los Lemas 8.1 y 10.3 concluimos que $d^k \in \mathcal{D}_f(x^k) \cap V_D(x^k)$. De hecho, la naturaleza del subproblema (10.26), (10.27), es la siguiente: a medida que t disminuye, la componente d del punto factible (t, d) de este subproblema obtiene cada vez características más claras de una dirección factible de descenso. En particular, cuando $I(x^k) = \emptyset$, d^k queda en la dirección del anti-gradiente de la función f en el punto x^k .

El cálculo de los parámetros de longitud de paso α_k puede ser hecho por las técnicas de § 3.1.1, llevando también en cuenta la restricción adicional $\alpha_k \leq \hat{\alpha}_k$, donde $\hat{\alpha}_k > 0$ es el mayor número satisfaciendo $x^k + \alpha d^k \in D \quad \forall \alpha \in [0, \hat{\alpha}_k]$.

Esta restricción garantiza la validez de la segunda condición en (10.25). Si el conjunto D es convexo (por ejemplo, si las funciones g_i , $i = 1, \dots, m$, son convexas), el número $\hat{\alpha}_k$ viene dado por la fórmula

$$\hat{\alpha}_k = \sup\{\alpha \in \mathbb{R}_+ \mid x^k + \alpha d^k \in D\}.$$

Más incluso en el caso convexo, $\hat{\alpha}_k$ puede ser calculado o estimado solamente en casos bien especiales; véase § 4.1.2. Cuando el conjunto D no es convexo, difícilmente puede existir una estrategia razonable de cálculo de longitud de paso para esquemas de este tipo.

Más aún, mismo suponiendo que $\hat{\alpha}_k$ sea conocido para todo k , e incluso bajo hipótesis muy fuertes, los métodos de direcciones factibles presentados arriba pueden no poseer convergencia garantizada. La principal dificultad, tanto en el sentido práctico como teórico, es la siguiente. Para $I_k = I(x^k)$, el subproblema (10.26), (10.27), no tiene en cuenta las restricciones del problema original (10.23) que no son activas en x^k , mas son “casi-activas” en este punto. Esto puede hacer que, para la dirección d^k escogida, el valor de $\hat{\alpha}_k$ sea muy pequeño, mismo que existan otras direcciones factibles y de descenso que permitan pasos bien más largos. La disminución indebida de los valores de $\hat{\alpha}_k$ puede resultar en la convergencia del método a puntos no estacionarios del problema (véase [2]).

La idea de llevar en cuenta restricciones casi-activas puede ser implementada de la manera siguiente. Fijamos $\delta_0 > 0$ e $\theta \in (0, 1)$. Para todo k , definimos

$$I_k = \{i = 1, \dots, m \mid g_i(x^k) \geq -\delta_k\}.$$

Si para la solución $u^k = (t_k, d^k)$ del subproblema correspondiente (10.26), (10.27), tenemos que $t_k \leq -\delta_k$, aceptamos d^k como la dirección factible de descenso. Caso contrario, cambiamos δ_k por $\theta\delta_k$ y repetimos el cálculo de d^k , con nuevo I_k . Esta modificación, con el adecuado de los parámetros involucrados, ya permite probar convergencia al conjunto de puntos estacionarios del problema.

Notemos que, como los métodos del gradiente proyectado, los métodos de descenso con direcciones factibles necesitan un punto inicial factible. En el caso de un conjunto factible de estructura simple, como en § 4.1, el cálculo de un punto $x^0 \in D$ no presenta dificultades. En casos más generales, pueden ser utilizados algunos métodos especiales, desarrollados para este fin [4]. Sin embargo, en general, la tarea de computar un punto factible puede ser casi tan difícil como la resolución del problema original (10.23).

Nosotros no vamos a presentar más detalles sobre los algoritmos de direcciones factibles, porque mismo siendo naturales y de cierto interés teórico, estos métodos no pueden ser considerados como un abordaje correcto al caso de restricciones no-lineales. Además de eso, ellos ni pueden ser aplicados cuando hay restricciones no lineales de igualdad. A continuación, nos vamos a concentrar en la descripción de algunos métodos que son más eficientes y más utilizados en la práctica computacional.

10.3. Métodos de penalización

La penalización tiene por objetivo aproximar un problema con restricciones mediante una secuencia de problemas irrestrictos, teniendo en vista la aplicación de técnicas computacionales ya desarrolladas. La idea de convertir un problema de optimización con restricciones en un problema (o una secuencia de problemas) sin restricciones es natural y es usada en la construcción de varios algoritmos.

En la *penalización externa*, a la función objetivo se le añade un término cuyo valor es nulo en todos los puntos factibles y es positivo para los no factibles. En general, la solución de un problema así penalizado está fuera del conjunto factible, lo que explica el nombre de penalización “externa”. Para obtener convergencia a la solución del problema original (que, obviamente, tiene que ser factible), el parámetro escalar que multiplica el término penalizador tiene que crecer a más infinito. Una excepción importante a esta regla es la *penalización exacta*, donde un valor del parámetro penalizador suficientemente grande (sin embargo, fijo) permite la recuperación exacta de una solución del problema original. Típicamente, esto solo es posible al costo de la utilización de términos penalizadores no diferenciables. La penalización exacta será presentada un poco más adelante, en § 4.3.2.

En la *penalización interna*, a la función objetivo se le añade un término cuyo valor tiende a más infinito cuando puntos factibles se aproximan a la frontera del conjunto factible del problema. Tenemos entonces una “barrera” que no permite a las soluciones de problemas así penalizados dejar el interior del conjunto factible. Esto explica el nombre de penalización “interna” o, también, de *métodos de barreras*. Para obtener convergencia a la solución del problema

original (que, típicamente, está justamente en la frontera del conjunto factible), el parámetro escalar que multiplica el término penalizador tiene que decrecer a cero.

Las técnicas de penalización son bien simples y universales. Sin embargo, ellas no son muy usadas en forma pura, debido a la necesidad de la utilización de valores del parámetro penalizador muy grandes (en el caso de la penalización externa) o muy pequeños (en el caso de la penalización interna), lo que tiende a provocar inestabilidad numérica. De todos modos, esta idea tiene una cierta importancia histórica, y es útil para el entendimiento de estrategias más sofisticadas. Además de esto, la penalización exacta proporciona una de las técnicas más eficientes para la globalización de métodos de programación cuadrática secuencial, que será desarrollada en § 4.6.

10.3.1. Penalización externa

Consideremos un problema en formato general

$$\min f(x) \quad \text{sujeto a } x \in D, \quad (10.31)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $D \subset \mathbb{R}^n$ es un conjunto cualquiera. Como ya fue anunciado, introduciremos un término que tiene por objetivo penalizar la violación de las restricciones, i.e., una función $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$ continua en $\mathbb{R}^n$, tal que

$$\psi(x) \begin{cases} = 0 & \forall x \in D, \\ > 0 & \forall x \in \mathbb{R}^n \setminus D. \end{cases} \quad (10.32)$$

Por ejemplo, si

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\}, \quad (10.33)$$

es conveniente definir

$$\Psi : \mathbb{R}^n \rightarrow \mathbb{R}^l \times \mathbb{R}^m,$$

$$\Psi(x) = (h(x), (\max\{0, g_1(x)\}, \dots, \max\{0, g_m(x)\})), \quad (10.34)$$

$$\psi(x) = \|\Psi(x)\|^p, \quad x \in \mathbb{R}^n, \quad (10.35)$$

donde $p > 0$. En (10.35), además de la norma Euclidiana $\|\cdot\| = \|\cdot\|_2$, pueden ser utilizadas también $\|\cdot\|_p$, o $\|\cdot\|_\infty$ (para $p \in (0, 1)$, $\|\cdot\|_p$ no define una norma, mas en este contexto es conveniente utilizar la misma notación). Estas elecciones resultan en

$$\psi(x) = \|\Psi(x)\|_p^p = \|h(x)\|_p^p + \sum_{i=1}^m (\max\{g_i(x), 0\})^p, \quad (10.36)$$

o

$$\psi(x) = \|\Psi(x)\|_\infty^p = (\max\{\|h(x)\|_\infty, 0, g_1(x), \dots, g_m(x)\})^p. \quad (10.37)$$

Notemos que para h y g diferenciables, la función ψ definida por (10.36) es diferenciable cuando $p > 1$, y no es diferenciable en el caso contrario. La función ψ dada por (10.37) no es diferenciable, mismo cuando h y g son infinitamente diferenciables. Como veremos más adelante, existen algunas diferencias importantes entre propiedades de penalizadores diferenciables y no diferenciables.

Consideremos una familia de problemas irrestrictos

$$\min \varphi(x; c), \quad x \in \mathbb{R}^n, \quad (10.38)$$

donde

$$\varphi(\cdot; c) : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \varphi(x; c) = f(x) + c\psi(x), \quad (10.39)$$

y $c > 0$ es el parámetro penalizador.

La idea es que a medida en que el valor de c aumenta, la violación de las restricciones se torna cada vez más cara. Podemos esperar, entonces, que soluciones de los problemas irrestrictos (10.38) se aproximen al conjunto factible cuando $c \rightarrow +\infty$ y sus puntos de acumulación resuelvan el problema original (10.31).

Algoritmo 4.3.1. (Método de penalización externa)

Elegir una función $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$, penalizador externo para el conjunto D . Elegir $c_0 > 0$. Tomar $k := 0$.

1. Calcular $x^k = x(c_k)$, una solución del problema (10.38), donde la función objetivo es dada por la fórmula (10.39) con $c = c_k$.

2. Elegir $c_{k+1} > c_k$, tomar $k := k + 1$. Retornar al Paso 1.

Mencionamos que, por razones obvias, es natural utilizar el punto x^{k-1} como punto inicial del método aplicado para minimizar la función $\varphi(\cdot; c_k)$ en la iteración k .

Notemos que la mayoría de los resultados de convergencia de métodos de este tipo se refiere a la secuencia de soluciones globales de los problemas (10.38), suponiendo que ellas existan. Por lo tanto, fuera del caso convexo, la aplicación de métodos de penalización puros no tiene convergencia garantizada, ya que en el caso no convexo no hay como calcular soluciones globales. El asunto de la utilización de soluciones locales será considerado también, más adelante.

A seguir, veremos algunos ejemplos de aplicación del Algoritmo 4.3.1.

Ejemplo 10.1. Consideremos el problema

$$\min x_1^2 - x_2 \quad \text{sueto a } x_1 + x_2 - 1 = 0, \quad x_1 \geq 0.$$

Este es un problema de programación convexa, y la única solución es $\bar{x} = (0, 1)$. Eligiendo el término penalizador (10.36) con $p = 2$, obtenemos

$$\varphi(x; c) = x_1^2 - x_2 + c(x_1 + x_2 - 1)^2 + c(\max\{-x_1, 0\})^2.$$

Como es fácil ver, esta función es convexa, diferenciable, y su (único) minimizador (global) irrestricto es caracterizado por el sistema de ecuaciones

$$0 = \varphi'(x; c) = \begin{pmatrix} 2x_1 + 2c(x_1 + x_2 - 1) - 2c \max\{-x_1, 0\} \\ -1 + 2c(x_1 + x_2 - 1) \end{pmatrix},$$

donde $\varphi'(x; c)$ es el gradiente de $\varphi(\cdot; c)$ en x (acreditamos que no debe haber confusión con la notación de la derivada direccional). De donde obtenemos que

$$2x_1 + 1 - 2c \max\{-x_1, 0\} = 0.$$

La última ecuación no posee solución si $x_1 \geq 0$. Resolviendo el sistema para $x_1 < 0$, obtenemos

$$x_1(c) = -1/(2(1+c)), \quad x_2(c) = 1 + 1/(2c) + 1/(2(1+c)).$$

En particular, tenemos que

$$x(c) = (x_1(c), x_2(c)) \rightarrow (0, 1) = \bar{x} \quad (c \rightarrow +\infty).$$

Observemos que para todo $c > 0$, el punto $x(c)$ no es factible. La Figura 10.4 ilustra la trayectoria $x(c)$ de las soluciones de los problemas penalizados.

El ejemplo arriba muestra que, en general, las soluciones de problemas penalizados no son puntos factibles del problema original y, por lo tanto, para métodos de este tipo solo podemos esperar convergencia asintótica.

Figura 10.4.: La trayectoria de soluciones de los problemas penalizados: se tiene que $x(c) \notin D$ e $x(c) \rightarrow \bar{x}$ cuando $c \rightarrow +\infty$.

El ejemplo siguiente muestra que, en principio, es posible que alguna solución del problema penalizado sea factible y, en este caso, ella es la solución del problema original. Resaltamos, no obstante, que tal situación es bastante atípica en el caso de utilización de penalizadores diferenciables.

Ejemplo 10.2. Consideremos el problema

$$\min x^2 \quad \text{sueto a } x \geq -1.$$

La solución de este problema es $\bar{x} = 0$. Eligiendo el término penalizador (10.36) con $p = 2$, obtenemos

$$\varphi(x; c) = x^2 + c(\max\{-x - 1, 0\})^2.$$

Como es fácil ver, esta función es convexa, diferenciable, y su (único) minimizador (global) irrestricto es caracterizado por

$$0 = \varphi'(x; c) = 2x - 2c \max\{-x - 1, 0\}.$$

La única solución de esta ecuación es $x(c) = 0$. Observemos que $x(c)$ es un punto factible y que $x(c) = \bar{x}$.

A seguir, probaremos las propiedades de convergencia del Algoritmo 4.3.1, ya observadas en los Ejemplos 10.1 y 10.2.

Proposición 10.2. Sea $\{x^k\}$ una secuencia generada por el Algoritmo 4.3.1, donde x^k es una solución global de (10.38) con $c = c_k$. Entonces, para todo k , se tiene que

$$\varphi(x^{k+1}; c_{k+1}) \geq \varphi(x^k; c_k), \quad (10.40)$$

$$\psi(x^{k+1}) \leq \psi(x^k), \quad (10.41)$$

$$f(x^{k+1}) \geq f(x^k). \quad (10.42)$$

Prueba. Por la optimalidad de x^k en (10.38) con $c = c_k$, tenemos que

$$\begin{aligned} \varphi(x^k; c_k) &\leq \varphi(x^{k+1}; c_k) \\ &= f(x^{k+1}) + c_k \psi(x^{k+1}) \\ &\leq f(x^{k+1}) + c_{k+1} \psi(x^{k+1}) \\ &= \varphi(x^{k+1}; c_{k+1}) \\ &\leq \varphi(x^k; c_{k+1}), \end{aligned} \quad (10.43)$$

donde también utilizamos que $c_{k+1} > c_k$ y $\psi(x^{k+1}) \geq 0$. Acabamos de mostrar (10.40). De (10.43), tenemos

$$\begin{aligned} f(x^k) + c_k \psi(x^k) &\leq f(x^{k+1}) + c_k \psi(x^{k+1}), \\ f(x^{k+1}) + c_{k+1} \psi(x^{k+1}) &\leq f(x^k) + c_{k+1} \psi(x^k). \end{aligned}$$

Sumando las dos últimas desigualdades, obtenemos

$$(c_k - c_{k+1})\psi(x^k) \leq (c_k - c_{k+1})\psi(x^{k+1}),$$

de donde, teniendo en cuenta que $c_{k+1} > c_k$, sigue (10.41).

Ahora, utilizando (10.41) y (10.43), de

$$\begin{aligned} f(x^k) + c_k \psi(x^k) &\leq f(x^{k+1}) + c_k \psi(x^{k+1}) \\ &\leq f(x^{k+1}) + c_k \psi(x^k), \end{aligned}$$

obtenemos (10.42). ■

El resultado siguiente prueba la convergencia asintótica del Algoritmo 4.3.1, además de mostrar que, en general, los puntos x^k por él generados no son factibles. Con efecto, si el método genera un punto factible, él ya es una solución del problema original. Por lo tanto, es claro que tal situación no puede ser esperada en general.

Teorema 10.3 (Convergencia global del método de penalización externa). Sea $\{x^k\}$ una secuencia generada por el Algoritmo 4.3.1, donde x^k es una solución global de (10.38) con $c = c_k$. Entonces $x^k \in D$ si, y solamente si, x^k es una solución global del problema (10.31). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$ funciones continuas en $\mathbb{R}^n$ y sea $\bar{v} > -\infty$ el valor óptimo del problema (10.31). Se $c_k \rightarrow +\infty$ ($k \rightarrow \infty$), entonces todo punto de acumulación de la secuencia $\{x^k\}$ es una solución global del problema (10.31).

Prueba. Primero, es fácil ver que para todo punto $x \in D$,

$$\begin{aligned} f(x^k) &\leq f(x^k) + c_k \psi(x^k) \\ &= \varphi(x^k; c_k) \\ &\leq \varphi(x; c_k) \\ &= f(x), \end{aligned}$$

donde utilizamos que $c_k > 0$, $\psi(x^k) \geq 0$, que x^k es una solución global de (10.38) con $c = c_k$, y que $\psi(x) = 0$ para todo $x \in D$. Concluimos que, para todo k ,

$$f(x^k) \leq \varphi(x^k; c_k) \leq \bar{v} = \inf_{x \in D} f(x). \quad (10.44)$$

Si $x^k \in D$, obtenemos entonces que x^k es una solución del problema (10.31).

Por la Proposición 10.2, la secuencia $\{\varphi(x^k; c_k)\}$ es no decreciente. Por (10.44), ella está limitada superiormente por $\bar{v}$. Luego, ella converge y se tiene que

$$\lim_{k \rightarrow \infty} \varphi(x^k; c_k) = \lim_{k \rightarrow \infty} (f(x^k) + c_k \psi(x^k)) \leq \bar{v}. \quad (10.45)$$

Sea $\bar{x}$ un punto de acumulación de la secuencia $\{x^k\}$, $\{x^{k_j}\} \rightarrow \bar{x}$ ($j \rightarrow \infty$). Por la continuidad de f , tenemos que $f(x^{k_j}) \rightarrow f(\bar{x})$ ($j \rightarrow \infty$). De (10.45), obtenemos entonces que

$$\lim_{j \rightarrow \infty} c_{k_j} \psi(x^{k_j}) \leq \bar{v} - f(\bar{x}).$$

De donde, como $c_k \rightarrow +\infty$ y $\psi(x^{k_j}) \geq 0$, se sigue que

$$\lim_{j \rightarrow \infty} \psi(x^{k_j}) = 0.$$

Por la continuidad de ψ , concluimos que $\psi(\bar{x}) = 0$, i.e., $\bar{x} \in D$. Ahora, pasando al límite en (10.44), obtenemos

$$\lim_{j \rightarrow \infty} f(x^{k_j}) \leq \bar{v},$$

lo que (teniendo en cuenta que $\bar{x} \in D$), muestra que $\bar{x}$ es una solución de (10.31). ■

El Teorema 10.3 puede ser ligeramente generalizado en relación a las hipótesis de continuidad de las funciones f y ψ .

Observemos que podemos considerar un método más general que el Algoritmo 4.3.1, donde (tal vez) no todas las restricciones son penalizadas. Sea el problema

$$\min f(x) \quad \text{sujeto a } x \in \Omega \cap D,$$

donde Ω y D son conjuntos en $\mathbb{R}^n$ arbitrarios. Un método con penalización parcial de restricciones es dado por resolución de problemas

$$\min \varphi(x; c) \quad \text{sujeto a } x \in \Omega,$$

donde $\varphi(\cdot; c)$ es dada por (10.39) y ψ es dada por (10.32). O sea, ψ penaliza la violación de la restricción $x \in D$ (y no penaliza la restricción $x \in \Omega$). Cuando un subconjunto de restricciones tiene estructura simple (el subconjunto Ω), la no penalización de esas restricciones puede ser ventajosa. O sea, puede tener sentido computacional tratar esas restricciones explícitamente (como restricciones del problema) en vez de implícitamente (vía penalización). Evidentemente, el Algoritmo 4.3.1 es un caso especial de la construcción arriba, correspondiente a la elección $\Omega = \mathbb{R}^n$.

En general, el problema (10.38) puede no poseer soluciones o poseer varias. El resultado siguiente contiene, entre otras cosas, condiciones suficientes para garantizar la existencia de soluciones (locales) de (10.38) y la convergencia de estas soluciones a una solución local del problema original. Así obtenemos una versión más práctica del Algoritmo 4.3.1, que trabaja con soluciones locales de problemas penalizados.

Teorema 10.4 (Convergencia de soluciones locales de problemas penalizados). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$ funciones continuas en $\mathbb{R}^n$, donde ψ satisface (10.32). Sea $\bar{x} \in \mathbb{R}^n$ un minimizador local estricto del problema (10.31). Entonces existe un número $\delta > 0$ tal que para cualquier solución (global) $x(c)$ del problema

$$\min \varphi(x; c) \quad \text{sujeto a } x \in B(\bar{x}, \delta), \quad (10.46)$$

donde la función objetivo está dada por (10.39) con $c \geq 0$, se tiene que

$$x(c) \rightarrow \bar{x} \quad (c \rightarrow +\infty). \quad (10.47)$$

En particular, para todo número $c > 0$ suficientemente grande, el problema (10.38) posee una solución local $x(c)$ tal que vale (10.47).

Prueba. Primero notemos que, por el Teorema de Weierstrass (Teorema 1.1.1), para todo $c \geq 0$ el punto $x(c)$ en cuestión existe. Fijemos $\delta > 0$ tal que el punto $\bar{x}$ sea la única solución global del problema

$$\min f(x) \quad \text{sujeto a } x \in D \cap B(\bar{x}, \delta). \quad (10.48)$$

(La existencia de tal $\delta > 0$ se sigue del hecho de que $\bar{x}$ es minimizador local estricto). Los valores de la función $x(\cdot) : \mathbb{R} \rightarrow \mathbb{R}^n$ pertenecen al conjunto $B(\bar{x}, \delta)$, que es compacto. Por lo tanto, estos valores tienen un punto de acumulación $\bar{x} \in B(\bar{x}, \delta)$ cuando $c \rightarrow +\infty$. Probaremos que $\bar{x}$ es una solución global del problema (10.48). Por la

definición de $x(c)$, para todo c se tiene que

$$\varphi(x(c); c) \leq \varphi(x; c) \quad \forall x \in B(\bar{x}, \delta).$$

Por lo tanto, utilizando el hecho de que $f(x) = \varphi(x; c)$ para todo $x \in D$, tenemos que

$$\begin{aligned} f(x(c)) + c\psi(x(c)) &= \varphi(x(c); c) \\ &\leq \inf_{x \in D \cap B(\bar{x}, \delta)} \varphi(x; c) \\ &= \inf_{x \in D \cap B(\bar{x}, \delta)} f(x) = v, \end{aligned} \quad (10.49)$$

donde $v = v(\bar{x}, \delta)$ es el valor óptimo del problema (10.48). Fijemos ahora una secuencia $\{c_k\} \subset \mathbb{R}$ tal que $c_k \rightarrow +\infty$, $\{x(c_k)\} \rightarrow \bar{x}$ ($k \rightarrow \infty$). De (10.49), obtenemos que

$$\limsup_{k \rightarrow \infty} c_k \psi(x(c_k)) \leq v - f(\bar{x}). \quad (10.50)$$

De donde, como $c_k \rightarrow +\infty$ ($k \rightarrow \infty$), obtenemos

$$\psi(\bar{x}) = \lim_{k \rightarrow \infty} \psi(x(c_k)) = 0,$$

i.e., $\bar{x} \in D \cap B(\bar{x}, \delta)$. Por lo tanto,

$$v \leq f(\bar{x}). \quad (10.51)$$

Ahora, de (10.50), obtenemos que

$$\limsup_{k \rightarrow \infty} c_k \psi(x(c_k)) \leq 0,$$

lo que solo puede valer si

$$\lim_{k \rightarrow \infty} c_k \psi(x(c_k)) = 0.$$

De (10.49), tenemos entonces que

$$f(\bar{x}) \leq v,$$

lo que resulta, en combinación con (10.51), en

$$f(\bar{x}) = v.$$

Como $\bar{x}$ es un punto factible para el problema (10.48), esto significa que $\bar{x}$ es una solución global de este problema. Como por la elección de δ , el punto $\bar{x}$ es la única solución global de (10.48), concluimos que $\bar{x} = \bar{x}$. Acabamos de mostrar, entonces, que $\bar{x}$ es el único punto de acumulación de los valores de $x(\cdot)$. O sea, vale (10.47). En particular, $x(c) \in \text{int } B(\bar{x}, \delta)$ para todo c suficientemente grande. Obviamente, si $x(c)$ minimiza la función $\varphi(\cdot; c)$ en un conjunto, y está en el interior de este conjunto, entonces sus valores locales de c , $x(c)$ es una solución local del problema (10.38). ■

Evidentemente, esta matriz es mal condicionada (para valores de $c > 0$ grandes). En particular, el método de Newton aplicado para minimizar $\varphi(\cdot; c)$ va a requerir resolver sistemas de ecuaciones lineales cada vez peor condicionados, a medida que c crece.

De cierto modo, la necesidad de resolver muchos problemas penalizados puede ser evitada. A seguir, mostraremos cómo, para una precisión dada cualquier, una solución aproximada del problema original puede ser obtenida a través de la resolución de dos problemas penalizados apenas.

Sea $\varepsilon > 0$ la tolerancia deseada. Nos gustaría calcular un punto $y \in \mathbb{R}^n$ tal que

$$f(y) \leq \inf_{x \in D} f(x), \quad \psi(y) \leq \varepsilon. \quad (10.52)$$

Para ε suficientemente pequeño, es natural considerar tal punto y como buena aproximación de la solución del problema (la segunda relación en (10.52) significa que y es un punto “casi factible”).

Supongamos que $\inf_{x \in D} f(x) > -\infty$ y que un punto factible $\hat{x} \in D$ sea dado (en caso contrario, calculamos un punto factible primero). Elegimos un $c_1 > 0$ arbitrario, y calculamos $x(c_1)$, una solución global del problema (10.38) con $c = c_1$.

Si $f(\hat{x}) \leq f(x(c_1))$, de (10.45) obtenemos que

$$f(x(c_1)) \leq \inf_{x \in D} f(x) \leq f(\hat{x}) \leq f(x(c_1)).$$

Esto muestra que $\hat{x}$ es una solución (exacta) del problema original (10.31).

Consideremos el caso de $f(\hat{x}) > f(x(c_1))$. Elegimos

$$c_2 > \max\left\{c_1, \frac{f(\hat{x}) - f(x(c_1))}{\varepsilon}\right\}, \quad (10.53)$$

y calculamos $x(c_2)$, una solución global del problema (10.38) con $c = c_2$.

Caso $f(\hat{x}) \leq f(x(c_2))$, tenemos que $\hat{x}$ es una solución del problema original (10.31), por el raciocinio presentado arriba.

Caso contrario, el punto $x(c_2)$ satisface

$$f(x(c_2)) \leq \inf_{x \in D} f(x),$$

por (10.45). Por la optimalidad de $x(c_2)$ en (10.38), tenemos que

$$f(x(c_2)) + c_2\psi(x(c_2)) \leq f(\hat{x}) + c_2\psi(\hat{x}) = f(\hat{x}),$$

donde la igualdad sigue del hecho de que $\hat{x} \in D$. Luego,

$$\begin{aligned} \psi(x(c_2)) &\leq (f(\hat{x}) - f(x(c_2)))/c_2 \\ &\leq (f(\hat{x}) - f(x(c_1)))/c_2 \\ &< \varepsilon, \end{aligned}$$

donde la segunda desigualdad sigue de la Proposición 10.2 y del hecho de que $c_2 > c_1$, y la tercera desigualdad sigue de (10.53). Acabamos de mostrar que el punto $x(c_2)$ satisface las condiciones (10.52).

Sin embargo, la construcción arriba resuelve la dificultad asociada al mal condicionamiento de los subproblemas apenas parcialmente. En particular, es posible que el valor de c_2 dado por (10.53) sea muy grande, e incluso que para satisfacer (10.52) tengamos que resolver solo un subproblema, esto puede ser difícil del punto de vista computacional.

Consideremos ahora la cuestión de la tasa de convergencia de los métodos de penalización externa en relación a los valores de la función objetivo, suponiendo la convergencia en relación a las variables. Para este fin, suponemos que el término penalizador $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$, definido en (10.32), proporciona una estimativa local de la violación de factibilidad, en el sentido siguiente: existen una vecindad U de la solución dada $\bar{x}$ del problema (10.31) y números $M > 0$ y $\nu > 0$, tales que

$$\text{dist}(x, D) \leq M(\psi(x))^\nu \quad \forall x \in U. \quad (10.54)$$

Ya vimos algunas situaciones de validez de estimativas de este tipo: por ejemplo, en los Teoremas 1.5.5, 1.6.6, 1.5.6. En particular, bajo las hipótesis del Teorema 1.5.6, la función ψ dada por (10.36) con algún $p > 0$, satisface (10.54) con $\nu = 1/p$.

Observemos que el resultado a seguir, además de estimativas de tasa de convergencia, establece algunas situaciones en que métodos de penalización externa poseen convergencia finita. I.e., situaciones en las cuales x^k sea una solución exacta del problema para algún k suficientemente grande. Notemos que como fue probado en el Teorema 10.3 (vea (10.45)), la condición (10.55) a seguir siempre es satisfecha si x^k es una solución global del problema penalizado. Puede ser visto que (10.55) también vale si x^k es una solución global del problema penalizado en un conjunto que contiene a $\bar{x}$ (en vez de todo el espacio). De cualquier manera, la condición (10.55) es natural en el contexto de métodos de penalización. La segunda condición en (10.56) significa la convergencia del método en consideración en relación a las variables del problema. Las dos condiciones (10.55) y (10.56) serán satisfechas, por ejemplo, si $\bar{x}$ es una solución local estricta del problema original (10.31), y $x^k = x(c_k)$ es elegido como fue hecho en la demostración del Teorema 10.4.

Teorema 10.5 (Tasa de convergencia de métodos de penalización externa). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función Lipschitz-continua con módulo $N > 0$ en una vecindad U del punto $\bar{x} \in \mathbb{R}^n$, y $D \subset \mathbb{R}^n$ un conjunto cerrado. Sea $\bar{x}$ una solución local del problema (10.31). Supongamos, finalmente, que la función $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$, definida por (10.32), satisfaga la condición (10.54) para algunos $M > 0$ y $\nu > 0$.

Si las secuencias $\{c_k\} \subset \mathbb{R}_+$ y $\{x^k\} \subset \mathbb{R}^n$ son tales que

$$\varphi(x^k; c_k) \leq \varphi(\bar{x}; c_k) = f(\bar{x}) \quad \forall k, \quad (10.55)$$

donde la función $\varphi(\cdot; c_k)$ es definida por (10.39), y

$$\{c_k\} \rightarrow \infty, \quad \{x^k\} \rightarrow \bar{x} \quad (k \rightarrow \infty), \quad (10.56)$$

entonces para todo k suficientemente grande, se tiene que

(a) si $\nu < 1$, entonces

$$0 \leq f(\bar{x}) - f(x^k) \leq \left(\frac{(MN)^{1/\nu}}{c_k} \right)^{\nu/(1-\nu)}, \quad (10.57)$$

$$\text{dist}(x^k, D) \leq M \left(\frac{MN}{c_k} \right)^{\nu/(1-\nu)}; \quad (10.58)$$

(b) si $\nu \geq 1$, entonces

$$f(x^k) = f(\bar{x}), \quad x^k \in D;$$

en particular, si $\bar{x}$ es una solución local estricta del problema (10.31), se tiene que $x^k = \bar{x}$.

Prueba. Utilizando (10.32), (10.54), (10.55), y la segunda relación en (10.56), para todo k suficientemente grande, tenemos que

$$\begin{aligned} f(\bar{x}) &= f(\bar{x}) + c_k \psi(\bar{x}) \\ &= \varphi(\bar{x}; c_k) \\ &\geq \varphi(x^k; c_k) \\ &= f(x^k) + c_k \psi(x^k) \\ &\geq f(x^k) + c_k \left(\frac{\text{dist}(x^k, D)}{M} \right)^{1/\nu}. \end{aligned} \quad (4.59)$$

Para todo k suficientemente grande, sea $\tilde{x}^k$ una proyección del punto x^k sobre el conjunto D (cuya existencia sigue del hecho de que D es cerrado; vea el Teorema 1.3.1). Por la segunda relación en (10.56), como $\bar{x} \in D$, obtenemos que

$$\{\tilde{x}^k\} \rightarrow \bar{x} \quad (k \rightarrow \infty).$$

Siendo que $\bar{x}$ es una solución local del problema (10.31), para todo k suficientemente grande, se tiene que

$$f(\bar{x}) - f(x^k) \leq f(\tilde{x}^k) - f(x^k) \leq N \text{dist}(x^k, D). \quad (10.59)$$

Combinando (4.59) y (10.59), obtenemos que

$$f(\bar{x}) - f(x^k) \geq c_k \left(\frac{f(\bar{x}) - f(x^k)}{MN} \right)^{1/\nu}. \quad (10.60)$$

Definimos el conjunto

$$J = \{k = 0, 1, \dots \mid f(x^k) \neq f(\bar{x})\}.$$

Las relaciones (4.59) y (10.60) implican que

$$0 \leq (f(\bar{x}) - f(x^k))^{(1-\nu)/\nu} \leq \frac{(MN)^{1/\nu}}{c_k}, \quad (10.61)$$

para todo $k \in J$ suficientemente grande. La afirmación (a) vale trivialmente para $k \notin J$, y se sigue de (10.61) para $k \in J$ ((4.58) sigue de (10.57) y (4.59)).

Si $\nu \geq 1$, por la relación (10.56), el lado izquierdo de (10.61) no tiende a cero cuando $k \rightarrow \infty$, en cuanto el lado derecho tiende a cero. Esto implica que el conjunto J no puede ser infinito (pues, en caso contrario, (10.61) resulta en una contradicción). Que el conjunto J sea finito significa exactamente que $f(\bar{x}) = f(x^k)$ para todo k suficientemente grande. Además de eso, para tales k , $x^k \in D$ vale por (4.59). Esto concluye la prueba del ítem (b). ■

Corolario 10.1. Bajo las hipótesis del Teorema 10.5, sea $\bar{x}$ una solución local estricta del problema (10.31), y sea $\nu \geq 1$. Entonces existe un número $\bar{c} \geq 0$, tal que para todo $c > \bar{c}$ el punto $\bar{x}$ es una solución local estricta del problema (10.38), donde la función objetivo es dada por (10.39).

Prueba. Supongamos lo contrario, i.e., que existan secuencias $\{c_i\} \subset \mathbb{R}_+$ y $\{x^i\} \subset \mathbb{R}^n$ tales que

$$\varphi(x^i; c_i) \leq \varphi(\bar{x}; c_i), \quad x^i \neq \bar{x} \quad \forall i, \quad (10.62)$$

$$\{c_i\} \rightarrow \infty, \quad \{x^i\} \rightarrow \bar{x} \quad (i \rightarrow \infty). \quad (10.63)$$

Mas la validez simultánea de (10.62) y (10.63) contradice el ítem (b) del Teorema 10.5. Luego, vale el resultado anunciado. ■

Notemos que en el caso de la penalización cuadrática para el conjunto factible (10.33) ($p = 2$ en la definición de ψ en (10.36)), las estimativas (10.57) y (10.58) se transforman en

$$0 \leq f(\bar{x}) - f(x^k) \leq \frac{(NM)^2}{c_k},$$

$$\text{dist}(x^k, D) \leq \frac{M^2 N}{c_k}.$$

Por el Teorema 10.5, la disminución de valores de grado p lleva a convergencia más rápida de métodos de penalización asociados (recordamos que, bajo las hipótesis del Teorema 1.5.6, tenemos $\nu = 1/p$). Más aún, por el Corolario 10.1, para p suficientemente pequeño (más precisamente, para $p \leq 1$), la convergencia es finita en el sentido de que la solución local (estricta) $\bar{x}$ del problema (10.31), (10.33), también es una solución local del problema penalizado (10.38) para todo c suficientemente grande. En otras palabras, si en la aplicación de un método de penalización externa conseguimos el cálculo de soluciones locales adecuadas del problema penalizado (10.38), no habrá necesidad de crecimiento ilimitado del parámetro penalizador. Una penalización con esta propiedad se llama de *penalización exacta*. Ella será considerada con más detalles en § 4.3.2 a seguir.

No obstante, notemos que la disminución del valor de grado p empeora la diferenciabilidad de la función $\varphi(\cdot; c)$, lo que torna el problema penalizado más difícil en el sentido computacional. En particular, para $p \leq 1$ el término penalizador (10.35) ya no es diferenciable, incluso para las funciones h y g infinitamente diferenciables. Entre otras cosas, la propia noción de punto estacionario del problema (10.38) tiene que ser repensada. Otra dificultad obvia es que no podemos saber a priori cuál es el valor del parámetro penalizador que torna la penalización exacta. Algunas técnicas para la elección de parámetros de penalización pueden ser consultadas en [3].

Finalmente, comentamos que métodos de minimización de funciones convexas no-diferenciables serán presentados en el Capítulo 5. Además de eso, cabe resaltar que en la práctica computacional moderna, funciones de penalización exacta típicamente son utilizadas como funciones de mérito para la globalización de métodos locales, y no para la resolución directa de problemas penalizados. Exactamente así vamos a desenvolver la globalización de métodos de programación cuadrática secuencial en § 4.6.

10.3.2. Penalización externa exacta

Consideramos ahora el problema con restricciones mixtas

$$\min f(x) \quad \text{sujeto a } x \in D = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0. \end{array} \right\}, \quad (10.64)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones dadas. Elegimos el término penalizador

$$\psi(x) = \sum_{i=1}^l |h_i(x)| + \sum_{i=1}^m \max\{g_i(x), 0\}. \quad (10.65)$$

Observamos que la función ψ así definida no es diferenciable, incluso cuando h y g sean diferenciables. Consideremos la familia de problemas penalizados

$$\min \varphi(x; c), \quad x \in \mathbb{R}^n, \quad (10.66)$$

donde

$$\varphi(\cdot; c) : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \varphi(x; c) = f(x) + c\psi(x), \quad (10.67)$$

y $c > 0$ es el parámetro penalizador. Mencionamos que los resultados a ser presentados también son válidos para varias otras formas de penalización no diferenciable. Por ejemplo (vea el Ejercicio 4.3.6),

$$\psi(x) = \max\{|h_1(x)|, \dots, |h_l(x)|, 0, g_1(x), \dots, g_m(x)\}. \quad (10.68)$$

Precisaremos de la siguiente caracterización de la derivada direccional de la función ψ definida por (10.65).

Teorema 10.6 (Condiciones necesarias para penalización exacta). *Sea $\bar{x} \in \mathbb{R}^n$ una solución local (estricta) del problema penalizado (10.66). Si $\bar{x} \in D$, entonces $\bar{x}$ es una solución local (estricta) del problema original (10.64). Si, además de la hipótesis de que $\bar{x} \in D$, las funciones f, h y g son diferenciables en $\bar{x}$, entonces existe un par de multiplicadores de Lagrange $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}^m$ tal que las condiciones de optimalidad de Karush-Kuhn-Tucker (del*

Teorema 1.2.3(a)) son satisfechas en el punto $\bar{x}$. Si, además de las hipótesis anteriores, $\bar{x}$ satisface la condición de regularidad de independencia lineal de los gradientes de las restricciones activas (??), entonces $c \geq \|(\bar{\lambda}, \bar{\mu})\|_\infty$.

Prueba. Como $\bar{x}$ es un minimizador local del problema (10.66), existe una vecindad U de $\bar{x}$ tal que

$$\varphi(\bar{x}; c) \leq \varphi(x; c) \quad \forall x \in U.$$

Como $\bar{x} \in D$ y tenemos que $\varphi(x; c) = f(x)$ para todo $x \in D$, obtenemos entonces

$$f(\bar{x}) \leq f(x) \quad \forall x \in U \cap D,$$

i.e., $\bar{x}$ es una solución local del problema (10.64). Si $\bar{x}$ es una solución local estricta de (10.66), todas las desigualdades arriba son estrictas. Por lo tanto, en este caso $\bar{x}$ es una solución local estricta de (10.64).

Supongamos ahora que f, h y g sean diferenciables en $\bar{x}$. Por el Ejercicio 4.3.5, la función $\varphi(\cdot; c)$ es diferenciable en $\bar{x}$ en cada dirección $d \in \mathbb{R}^n$. Tenemos que para todo $t > 0$ suficientemente pequeño,

$$\begin{aligned} 0 &\leq \varphi(\bar{x} + td; c) - \varphi(\bar{x}; c) \\ &= t\varphi'(\bar{x}; d; c) + o(t), \end{aligned}$$

donde $\varphi'(\bar{x}; d; c)$ es la derivada de la función $\varphi(\cdot; c)$ en $\bar{x}$ en la dirección d . Dividiendo los dos lados de la relación arriba por $t > 0$ y pasando al límite cuando $t \rightarrow 0+$, obtenemos que

$$\varphi'(\bar{x}; d; c) \geq 0 \quad \forall d \in \mathbb{R}^n.$$

Como $\bar{x} \in D$ por la hipótesis, de (??) obtenemos que

$$\begin{aligned} 0 &\leq \langle f'(\bar{x}), d \rangle + c \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| \\ &\quad + c \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\}. \end{aligned} \quad (10.69)$$

En particular, como los dos últimos términos son no negativos, esto implica que

$$0 \geq \langle f'(\bar{x}), d \rangle. \quad (10.70)$$

Por otro lado, por la condición suficiente de segunda orden (que incluye las condiciones de optimalidad KKT),

$$f'(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i h'_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i g'_i(\bar{x}) = 0.$$

Multiplicando esta relación por d , de (10.76) obtenemos que

$$\begin{aligned} 0 &\geq - \sum_{i=1}^l \bar{\lambda}_i \langle h'_i(\bar{x}), d \rangle - \sum_{i \in I(\bar{x})} \bar{\mu}_i \langle g'_i(\bar{x}), d \rangle \\ &\geq (c - \|(\bar{\lambda}, \bar{\mu})\|_\infty) \left(\sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| + \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\} \right), \end{aligned}$$

donde $\bar{\mu} \geq 0$ fue llevado en cuenta. Como $c > \|(\bar{\lambda}, \bar{\mu})\|_\infty$ y todos los términos en el lado derecho de la relación arriba son no negativos, concluimos que todos ellos tienen que ser nulos. Por lo tanto,

$$\langle h'_i(\bar{x}), d \rangle = 0, \quad i = 1, \dots, l, \quad \langle g'_i(\bar{x}), d \rangle \leq 0 \quad i \in I(\bar{x}).$$

para todo $d \in \mathbb{R}^n$. En particular, para todo $d \in \mathbb{R}^n$ tal que

$$\langle h'_i(\bar{x}), d \rangle = 0, \quad i = 1, \dots, l, \quad \langle g'_i(\bar{x}), d \rangle \leq 0, \quad i \in I(\bar{x}),$$

se tiene que

$$\langle f'(\bar{x}), d \rangle \geq 0.$$

Por lo tanto, $d = 0$ es una solución del problema de programación lineal

$$\min \langle f'(\bar{x}), d \rangle \quad \text{sujeto a } \langle h'_i(\bar{x}), d \rangle = 0, \quad i = 1, \dots, l, \quad \langle g'_i(\bar{x}), d \rangle \leq 0, \quad i \in I(\bar{x}). \quad (10.71)$$

Como este problema satisface la condición de regularidad de las restricciones (ya que ellas son lineales), por las condiciones de optimalidad KKT (del Teorema 1.2.3(a)) existen $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^{|I(\bar{x})|}$ tales que, entre otras cosas, vale

$$f'(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i h'_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i g'_i(\bar{x}) = 0. \quad (10.72)$$

Teniendo en cuenta que $\bar{x} \in D$, y definiendo $\bar{\mu}_i = 0$ para todo índice $i \in \{1, \dots, m\} \setminus I(\bar{x})$, de (10.72) obtenemos que $\bar{x}$ satisface las condiciones KKT para el problema (10.64), con multiplicadores $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}^m$.

Supongamos, finalmente, que $\bar{x}$ satisfaga la condición de independencia lineal de los gradientes de las restricciones activas (??). De (10.69) y (10.72), obtenemos que para todo $d \in \mathbb{R}^n$ vale

$$\begin{aligned} & \sum_{i=1}^l \bar{\lambda}_i \langle h'_i(\bar{x}), d \rangle + \sum_{i \in I(\bar{x})} \bar{\mu}_i \langle g'_i(\bar{x}), d \rangle \\ & \leq c \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| + c \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\}. \end{aligned} \quad (10.73)$$

Por la condición de regularidad (??), $\forall (u, v_I) \in \mathbb{R}^l \times \mathbb{R}^{|I|}$ existe $d \in \mathbb{R}^n$ tal que

$$\begin{pmatrix} h'(\bar{x}) \\ g'_I(\bar{x}) \end{pmatrix} d = \begin{pmatrix} u \\ v_I \end{pmatrix},$$

donde denotamos $I = I(\bar{x})$. O sea,

$$\langle h'_i(\bar{x}), d \rangle = u_i, \quad i = 1, \dots, m, \quad \langle g'_i(\bar{x}), d \rangle = v_i, \quad i \in I.$$

Ahora, tomando $(u, v_I) \in \mathbb{R}^l \times \mathbb{R}^{|I|}$ arbitrario, de (10.73) obtenemos que

$$\begin{aligned} \langle (\bar{\lambda}, \bar{\mu}_I), (u, v_I) \rangle &= \sum_{i=1}^l \bar{\lambda}_i u_i + \sum_{i \in I} \bar{\mu}_i v_i \\ &= \sum_{i=1}^l \bar{\lambda}_i \langle h'_i(\bar{x}), d \rangle + \sum_{i \in I} \bar{\mu}_i \langle g'_i(\bar{x}), d \rangle \\ &\leq c \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| + c \sum_{i \in I} \max\{0, \langle g'_i(\bar{x}), d \rangle\} \\ &= c \sum_{i=1}^l |u_i| + c \sum_{i \in I} \max\{0, v_i\} \\ &\leq c \|u\|_1 + c \sum_{i \in I} |v_i| \\ &= c \|(u, v_I)\|_1, \end{aligned}$$

donde utilizamos el hecho de que $\max\{0, t\} \leq |t|$ para todo $t \in \mathbb{R}$. Por la definición de la norma dual, tenemos que

$$\begin{aligned} \|(\bar{\lambda}, \bar{\mu}_I)\|_\infty &= \sup\{\langle (\bar{\lambda}, \bar{\mu}_I), (u, v_I) \rangle \mid \|(u, v_I)\|_1 = 1\} \\ &= \sup\left\{ \left\langle (\bar{\lambda}, \bar{\mu}_I), \frac{(u, v_I)}{\|(u, v_I)\|_1} \right\rangle \mid (u, v_I) \in \mathbb{R}^l \times \mathbb{R}^{|I|} \right\} \\ &\leq c. \end{aligned}$$

Teniendo en cuenta que $\|(\bar{\lambda}, \bar{\mu})\|_\infty = \|(\bar{\lambda}, \bar{\mu}_I)\|_\infty$, ya que $\bar{\mu}_i = 0 \forall i \in \{1, \dots, m\} \setminus I$, obtenemos la última afirmación del teorema. ■

Ahora estudiaremos condiciones que son suficientes para que una penalización sea exacta, i.e., condiciones que garanticen que una solución del problema penalizado (10.66) también sea una solución del problema original (10.64). Es conveniente separar el caso de programación convexa (que es más fácil) del caso no convexo. Notemos que en el caso convexo, la función $\varphi(\cdot; c)$ es convexa. Recordamos que la Lagrangiana del problema (10.64) es dada por

$$L : \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R},$$

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle.$$

Primero mostraremos que, bajo ciertas condiciones, el valor de la Lagrangiana proporciona una cota inferior para el valor de la función penalizada.

Teorema 10.7 (Penalización exacta en el caso convexo). Sean f y g funciones convexas, diferenciables en el punto $\bar{x} \in \mathbb{R}^n$ y sea h una función afín. Supongamos que existan multiplicadores de Lagrange $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}^m$ tales que las condiciones de optimalidad de Karush-Kuhn-Tucker (del Teorema 1.2.3(a)) son satisfechas (luego, $\bar{x}$ es una solución global del problema (10.64)). Entonces para todo $c \geq \|(\bar{\lambda}, \bar{\mu})\|_\infty$, el punto $\bar{x}$ es una solución (global) del problema (10.66).

Prueba. Como $L(\cdot, \bar{\lambda}, \bar{\mu})$ es una función convexa y $L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$, el punto $\bar{x}$ es un minimizador global de $L(\cdot, \bar{\lambda}, \bar{\mu})$ en $\mathbb{R}^n$, i.e.,

$$L(\bar{x}, \bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu}) \quad \forall x \in \mathbb{R}^n.$$

Teniendo también en cuenta que $\psi(\bar{x}) = 0$, $h(\bar{x}) = 0$ y que $\langle \bar{\mu}, g(\bar{x}) \rangle = 0$, obtenemos que para $c \geq 0$ cualquier

$$\begin{aligned} \varphi(\bar{x}; c) &= f(\bar{x}) + c\psi(\bar{x}) \\ &= f(\bar{x}) \\ &= f(\bar{x}) + \langle \bar{\lambda}, h(\bar{x}) \rangle + \langle \bar{\mu}, g(\bar{x}) \rangle \\ &= L(\bar{x}, \bar{\lambda}, \bar{\mu}) \\ &\leq L(x, \bar{\lambda}, \bar{\mu}) \quad \forall x \in \mathbb{R}^n. \end{aligned} \tag{10.74}$$

Por otro lado, como $\bar{\mu} \geq 0$ y $c \geq \|(\bar{\lambda}, \bar{\mu})\|_\infty$, tenemos que

$$\begin{aligned} L(x, \bar{\lambda}, \bar{\mu}) &= f(x) + \langle \bar{\lambda}, h(x) \rangle + \langle \bar{\mu}, g(x) \rangle \\ &\leq f(x) + \|\bar{\lambda}\|_\infty \|h(x)\|_1 + \sum_{i=1}^m \bar{\mu}_i \max\{0, g_i(x)\} \\ &\leq f(x) + \|\bar{\lambda}\|_\infty \|h(x)\|_1 + \|\bar{\mu}\|_\infty \sum_{i=1}^m \max\{0, g_i(x)\} \\ &\leq f(x) + \|(\bar{\lambda}, \bar{\mu})\|_\infty \psi(x) \\ &\leq \varphi(x; c). \end{aligned}$$

Combinando esta desigualdad con (10.74), tenemos

$$\varphi(\bar{x}; c) \leq \varphi(x; c) \quad \forall x \in \mathbb{R}^n,$$

lo que nos dice que $\bar{x}$ es minimizador global de $\varphi(\cdot; c)$ en $\mathbb{R}^n$. ■

Consideremos, finalmente, el caso no-convexo, mas en que una solución satisface la condición suficiente de segunda orden (por tanto, ella es estricta).

Teorema 10.8 (Penalización exacta en el caso de la condición suficiente de segunda orden). Sean f, h y g funciones dos veces diferenciables en $\bar{x} \in \mathbb{R}^n$. Supongamos también que existan los multiplicadores de Lagrange $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}^m$ tales que la condición suficiente de segunda orden (del Teorema 1.2.3(b)) sea satisfecha (luego, $\bar{x}$ es una solución local estricta del problema (10.64)). Entonces para todo $c > \|(\bar{\lambda}, \bar{\mu})\|_\infty$, el punto $\bar{x}$ es una solución local estricta del problema (10.66).

Prueba. Supongamos que $\bar{x}$ no sea un minimizador local estricto del problema (10.66), i.e., que exista una secuencia $\{x^k\} \subset \mathbb{R}^n \setminus \{\bar{x}\}$ tal que $\{x^k\} \rightarrow \bar{x}$ ($k \rightarrow \infty$) e, para todo k ,

$$\varphi(x^k; c) \leq \varphi(\bar{x}; c). \tag{10.75}$$

Podemos admitir, sin pérdida de generalidad, que la secuencia limitada $\{(x^k - \bar{x})/\|x^k - \bar{x}\|\}$ converge a $d \in \mathbb{R}^n$, $\|d\| = 1$. Definiendo, para todo k , $d^k = (x^k - \bar{x})/\|x^k - \bar{x}\|$ y $t_k = \|x^k - \bar{x}\|$, tenemos que

$$x^k = \bar{x} + t_k d^k = \bar{x} + t_k d + t_k(d^k - d) = \bar{x} + t_k d + o(t_k).$$

Como es fácil ver, la función $\varphi(\cdot; c)$ es Lipschitz-continua (digamos, con módulo $L > 0$) en una vecindad de $\bar{x}$. Por lo tanto,

$$|\varphi(x^k; c) - \varphi(\bar{x} + t_k d; c)| \leq L \|x^k - \bar{x} - t_k d\| = o(t_k).$$

Obtenemos que

$$\begin{aligned}\varphi'((\bar{x}; d); c) &= \lim_{k \rightarrow \infty} \frac{\varphi(\bar{x} + t_k d; c) - \varphi(\bar{x}; c)}{t_k} \\ &= \lim_{k \rightarrow \infty} \frac{\varphi(x^k; c) - \varphi(\bar{x}; c) + o(t_k)}{t_k} \\ &\leq 0,\end{aligned}$$

donde la desigualdad se sigue de (10.75). Como $\bar{x} \in D$, de (10.69) se sigue que

$$\begin{aligned}0 &\geq \langle f'(\bar{x}), d \rangle + c \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| \\ &\quad + c \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\}.\end{aligned}\tag{10.76}$$

En particular, como los dos últimos términos son no-negativos, esto implica que

$$0 \geq \langle f'(\bar{x}), d \rangle.\tag{10.77}$$

Por otro lado, por la condición suficiente de segunda orden (que incluye las condiciones de optimalidad KKT),

$$f'(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i h'_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i g'_i(\bar{x}) = 0.$$

Multiplicando esta relación por d , de (10.76) obtenemos que

$$\begin{aligned}0 &\geq - \sum_{i=1}^l \bar{\lambda}_i \langle h'_i(\bar{x}), d \rangle - \sum_{i \in I(\bar{x})} \bar{\mu}_i \langle g'_i(\bar{x}), d \rangle \\ &\quad + c \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| + c \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\} \\ &\geq (c - \|\bar{\lambda}, \bar{\mu}\|_\infty) \left(\sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| + \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\} \right) \\ &\quad + \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle|.\end{aligned}$$

donde $\bar{\mu} \geq 0$ fue llevado en cuenta. Como $c > \|\bar{\lambda}, \bar{\mu}\|_\infty$ y todos los términos del lado derecho de la relación arriba son no-negativos, concluimos que todos ellos tienen que ser nulos. Por lo tanto,

$$\langle h'_i(\bar{x}), d \rangle = 0, \quad i = 1, \dots, l, \quad \langle g'_i(\bar{x}), d \rangle \leq 0 \quad i \in I(\bar{x}).$$

Combinando esto con (10.77), obtenemos que $d \in \mathcal{H}(\bar{x})$, i.e., d pertenece al cono crítico del problema (10.64) en el punto $\bar{x}$ (vea (??)). Ahora, recordando que $\|d\| = 1$, por la condición suficiente de segunda orden tenemos que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle \geq \gamma \|d\|^2 = \gamma,$$

donde $\gamma > 0$. Llevando en cuenta que $L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$, obtenemos

$$\begin{aligned}L(x^k, \bar{\lambda}, \bar{\mu}) &= L(\bar{x}, \bar{\lambda}, \bar{\mu}) + \langle L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}), x^k - \bar{x} \rangle \\ &\quad + \frac{1}{2} \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^k - \bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|^2) \\ &= L(\bar{x}, \bar{\lambda}, \bar{\mu}) + \frac{t_k^2}{2} \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle + o(t_k^2) \\ &\geq L(\bar{x}, \bar{\lambda}, \bar{\mu}) + \frac{t_k^2}{2} \gamma + o(t_k^2) \\ &\geq L(\bar{x}, \bar{\lambda}, \bar{\mu}) + \frac{t_k^2}{4} \gamma \\ &> L(\bar{x}, \bar{\lambda}, \bar{\mu}),\end{aligned}\tag{10.78}$$

donde la primera desigualdad vale para todo k suficientemente grande (tal que $o(t_k^2) \geq -\gamma t_k^2/4$). De (10.75) y (10.78), para todo k suficientemente grande obtenemos

$$\begin{aligned}\varphi(x^k; c) &\leq \varphi(\bar{x}; c) \\ &= f(\bar{x}) \\ &= L(\bar{x}, \bar{\lambda}, \bar{\mu}) \\ &< L(x^k, \bar{\lambda}, \bar{\mu}) \\ &\leq \varphi(x^k; c),\end{aligned}$$

donde la última desigualdad se sigue de (??). Esta contradicción concluye la demostración. ■

10.3.3. Penalización interna. Métodos de barreras

Los métodos de penalización interna lidian con problemas de la forma

$$\min f(x) \quad \text{sujeto a } x \in D = \{x \in \mathbb{R}^n \mid g(x) \leq 0\}, \quad (10.79)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$, y el “interior” del conjunto factible no es vacío:

$$D^0 = \{x \in \mathbb{R}^n \mid g(x) < 0\} \neq \emptyset. \quad (10.80)$$

Supongamos, aún, que

$$\inf_{x \in D^0} f(x) = \inf_{x \in D} f(x) = \bar{v} > -\infty, \quad (10.81)$$

i.e., el ínfimo de f en el conjunto D^0 es igual al valor óptimo del problema (10.79). Esta hipótesis tiene por objetivo eliminar ciertos casos patológicos, como aquel en la Figura 10.5, donde, evidentemente, la solución $\bar{x}$ no puede ser aproximada por puntos del interior del conjunto factible.

Figura 10.5.: La solución $\bar{x}$ no puede ser aproximada por puntos del interior del conjunto factible D .

La idea de métodos de penalización interna es la misma que la de penalización externa, en el sentido de que el problema original es aproximado por una secuencia de problemas que pueden ser considerados irrestrictos. Solo que este objetivo es llevado a cabo de otra manera. En particular, a la función objetivo se le añade un término penalizador que tiende a más infinito para cualquier secuencia que se aproxime a la frontera $D \setminus D^0$ del conjunto factible.

Definición 10.2. Una función $\psi : D^0 \rightarrow \mathbb{R}_+$ se llama *barrera* para el conjunto D definido en (10.79), si ella es continua en D^0 , y para toda secuencia $\{x^k\} \in D^0$ tal que $g_i(x^k) \rightarrow 0$ para algún $i \in \{1, \dots, m\}$, se tiene que $\psi(x^k) \rightarrow +\infty$ ($k \rightarrow \infty$).

Las elecciones más comunes son la *barrera logarítmica*

$$\psi(x) = -\sum_{i=1}^m \log(-g_i(x)), \quad x \in D^0, \quad (10.82)$$

y la *barrera inversa*

$$\psi(x) = -\sum_{i=1}^m 1/g_i(x), \quad x \in D^0. \quad (10.83)$$

Consideremos una familia de funciones

$$\varphi(\cdot; t) : D^0 \rightarrow \mathbb{R}, \quad \varphi(x; t) = f(x) + t\psi(x), \quad (10.84)$$

donde $t > 0$ es el parámetro penalizador, y los problemas

$$\min \varphi(x; t) \quad \text{sujeto a } x \in D^0. \quad (10.85)$$

Podemos pensar en el problema (10.85) como de optimización irrestricta en el sentido siguiente. Es bien claro que si simplemente ignoramos por completo las restricciones del problema (10.85) (que son desigualdades estrictas) y resolvemos el problema

$$\min \varphi(x; t), \quad x \in \mathbb{R}^n,$$

aplicando cualquier método iterativo razonable a partir de un punto inicial en D^0 , toda la secuencia generada por este método (así como sus puntos de acumulación) va a quedar dentro de D^0 , ya que los puntos cerca de la frontera $D \setminus D^0$ tienen valores de $\varphi(\cdot; t)$ explosivos y, por lo tanto, no son nada atractivos para algoritmos de minimización.

Algoritmo 4.3.2. (Método de barreras)

Elegir una función barrera $\psi : D^0 \rightarrow \mathbb{R}$ para el conjunto D definido en (10.79). Elegir $t_0 > 0$ y tomar $k := 0$.

1. Calcular $x^k \in D^0$ como una solución del problema (10.85), donde la función objetivo es dada por la fórmula (10.84) con $t = t_k$.
2. Elegir $t_{k+1} < t_k$ y tomar $k := k + 1$. Retornar al Paso 1.

Observemos que como las soluciones del problema original típicamente están en la frontera $D \setminus D^0$, queda claro que para la convergencia de métodos de este tipo es necesario que los valores del parámetro t tiendan a cero (para amenizar la influencia explosiva de la barrera ψ y permitir la aproximación a soluciones en la frontera del conjunto factible).

Ejemplo 10.3. Consideremos el problema

$$\min x \quad \text{sujeto a } x \geq 0.$$

Este es un problema de programación convexa y su única solución es $\bar{x} = 0$. Eligiendo la barrera inversa (10.83), tenemos

$$\varphi(x; t) = x + t/x, \quad t > 0.$$

Los puntos estacionarios de esta función en el conjunto abierto

$$D^0 = \{x \in \mathbb{R} \mid x > 0\} \neq \emptyset$$

están caracterizados por la ecuación

$$0 = \varphi'(x; t) = 1 - t/x^2,$$

de donde obtenemos

$$x(t) = \sqrt{t} \in D^0.$$

En particular, $x(t) \rightarrow 0 = \bar{x}$ cuando $t \rightarrow 0$.

Figura 10.6.: Para las soluciones de los problemas penalizados, se tiene que $x(t) \in D^0$ para todo $t > 0$ y $x(t) \rightarrow \bar{x}$ cuando $t \rightarrow 0+$.

Ejemplo 10.4. Consideremos el problema

$$\min x_1 + x_2 \quad \text{sujeto a } -x_1^2 + x_2 \geq 0, \quad x_1 \geq 0.$$

Este es un problema de programación convexa y su única solución es $\bar{x} = 0$. Eligiendo la barrera logarítmica (10.82), tenemos

$$\varphi(x; t) = x_1 + x_2 - t \log(-x_1^2 + x_2) - t \log(x_1).$$

Los puntos estacionarios del problema de minimizar esta función en el conjunto abierto

$$D^0 = \{x \in \mathbb{R}^2 \mid -x_1^2 + x_2 > 0, \quad x_1 > 0\} \neq \emptyset$$

están caracterizados por el sistema de ecuaciones

$$0 = \varphi'(x; t) = \begin{pmatrix} 1 + 2tx_1/(-x_1^2 + x_2) - t/x_1 \\ 1 - t/(-x_1^2 + x_2) \end{pmatrix}.$$

De donde obtenemos

$$x_1(t) = (-1 + \sqrt{1 + 8t})/4, \quad x_2(t) = t + ((-1 + \sqrt{1 + 8t})/4)^2.$$

En particular, $x(t) \rightarrow 0 = \bar{x}$ cuando $t \rightarrow 0$. La trayectoria de soluciones de los problemas penalizados es ilustrada en la Figura 10.6.

Ahora estudiaremos propiedades de convergencia del Algoritmo 4.3.2. Como en el caso de la penalización externa, los resultados de convergencia para métodos de barreras se refieren a la secuencia generada por minimizadores globales de problemas penalizados.

Proposición 10.3. *Supongamos que el conjunto D definido en (10.79) satisface (10.80) y (10.81). Sea $\{x^k\}$ una secuencia generada por el Algoritmo 4.3.2, donde x^k es una solución global del problema (10.85) con $t = t_k$. Entonces, para todo k , se tiene que*

$$\varphi(x^{k+1}; t_{k+1}) \leq \varphi(x^k; t_k), \quad (10.86)$$

$$\psi(x^{k+1}) \geq \psi(x^k), \quad (10.87)$$

$$f(x^{k+1}) \leq f(x^k). \quad (10.88)$$

Prueba. Por la optimalidad de x^{k+1} en (10.85), $t = t_{k+1}$, tenemos que

$$\begin{aligned} f(x^{k+1}) + t_{k+1}\psi(x^{k+1}) &= \varphi(x^{k+1}; t_{k+1}) \\ &\leq \varphi(x^k; t_{k+1}) \\ &= f(x^k) + t_{k+1}\psi(x^k). \end{aligned}$$

Sumando esta última desigualdad a la desigualdad (??) (que obtuve del paso análogo en el texto original, vea a seguir), obtenemos que

$$(t_k - t_{k+1})\psi(x^k) \leq (t_k - t_{k+1})\psi(x^{k+1}).$$

De donde, como $t_{k+1} < t_k$, sigue (10.87). Ahora, utilizando de nuevo la relación que probamos, obtenemos

$$f(x^{k+1}) - f(x^k) \leq t_{k+1}(\psi(x^k) - \psi(x^{k+1})) \leq 0,$$

donde la segunda desigualdad sigue de $t_{k+1} > 0$ y de (10.87). Finalmente, obtenemos el siguiente resultado. ■

Teorema 10.9 (Convergencia de los métodos de penalización interna). *Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones continuas en $\mathbb{R}^n$. Supongamos que el conjunto D definido en (10.79) satisface (10.80) y (10.81). Entonces todo punto de acumulación de la secuencia $\{x^k\}$ generada por el Algoritmo 4.3.2, donde x^k es una solución global del problema (10.85) con $t = t_k$ y $t_k \rightarrow 0$ ($k \rightarrow \infty$), es una solución global del problema (10.79).*

Prueba. Sea $\bar{x}$ un punto de acumulación de la secuencia $\{x^k\}$. Sea $\{x^{k_j}\} \rightarrow \bar{x}$ ($j \rightarrow \infty$). Como $\{x^k\} \subset D^0$, i.e., tenemos que $g(x^k) < 0$ para todo k , y g es continua, concluimos que $g(\bar{x}) \leq 0$. O sea, $\bar{x} \in D$. Si $f(\bar{x}) = \bar{v}$, no hay nada más que probar. Sea $f(\bar{x}) > \bar{v}$. Definimos

$$\delta = (f(\bar{x}) - \bar{v})/2 > 0. \quad (10.89)$$

Por la relación (10.81),

$$\exists \tilde{x} \in D^0 \text{ tal que } f(\tilde{x}) < \bar{v} + \delta. \quad (10.90)$$

La secuencia $\{f(x^k)\}$ es no-creciente (vea (10.88)). Por lo tanto, $\{f(x^{k_j})\}$ también es no-creciente y tenemos que

$$f(x^{k_j}) \geq \lim_{j \rightarrow \infty} f(x^{k_j}) = f(\bar{x}) = \bar{v} + 2\delta,$$

donde llevamos en cuenta la continuidad de f y (10.89). Ahora, utilizando (10.90), obtenemos que

$$f(x^{k_j}) - f(\tilde{x}) \geq \bar{v} + 2\delta - f(\tilde{x}) > \delta. \quad (10.91)$$

Tenemos entonces que, para j suficientemente grande,

$$\begin{aligned} 0 &\geq \varphi(x^{k_j}; t_{k_j}) - \varphi(\tilde{x}; t_{k_j}) \\ &= f(x^{k_j}) + t_{k_j}\psi(x^{k_j}) - f(\tilde{x}) - t_{k_j}\psi(\tilde{x}) \\ &> \delta + t_{k_j}(\psi(x^{k_j}) - \psi(\tilde{x})) \\ &\geq \delta + t_{k_j}(\psi(x^{k_0}) - \psi(\tilde{x})) \\ &\geq \delta/2 > 0, \end{aligned}$$

donde la primera desigualdad sigue del hecho de que x^{k_j} es una solución global del problema (10.85) con $t = t_{k_j}$, la segunda desigualdad sigue de (10.92), la tercera de la desigualdad (10.87), y la última del hecho de que $t_k \rightarrow 0$ ($k \rightarrow \infty$). La contradicción encima implica que $f(\bar{x}) = \bar{v}$, lo que concluye la demostración. ■

10.4. Métodos para problemas con restricciones de igualdad

A seguir, consideramos problemas con restricciones de igualdad

$$\min f(x) \quad \text{sujeto a } x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}, \quad (10.92)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ son funciones diferenciables. Recordamos que, en principio, un problema que posee también restricciones de desigualdad puede ser convertido en un problema de la forma (10.92), vía la introducción de variables auxiliares (“de holgura”); vea [12]. Por lo tanto, todos los métodos presentados a seguir pueden ser empleados también para resolver problemas con restricciones mixtas de igualdad y de desigualdad. Como ya fue visto en [12], este abordaje no siempre es recomendable.

Mas, a veces, este abordaje puede ser útil. Principalmente en casos en que, utilizando la estructura del método, es posible determinar explícitamente las variables auxiliares vía las originales (en particular, evitando así el aumento artificial de la dimensión del problema). Esta técnica será usada, por ejemplo, en § 4.5.3 y § 4.5.4 para extender el material de § 4.4.2 y de § 4.4.3 a problemas con restricciones mixtas. Métodos desarrollados específicamente para el caso de restricciones mixtas serán presentados en § 4.5–4.7.

10.4.1. Métodos de Newton para el sistema de Lagrange

Los puntos estacionarios del problema (10.92) son caracterizados por el sistema de Lagrange

$$L'_x(x, \lambda) = 0, \quad h(x) = 0, \quad (10.93)$$

donde

$$L : \mathbb{R}^n \times \mathbb{R}^l \rightarrow \mathbb{R}, \quad L(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle,$$

es la función de Lagrange del problema en consideración. El sistema (10.93) consiste en $n + l$ ecuaciones en relación a $n + l$ variables $(x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l$. Por lo tanto, puntos estacionarios y multiplicadores de Lagrange asociados pueden ser encontrados aplicando a (10.93) el método de Newton, considerado en § 3.2.1, lo que resulta en el esquema iterativo

$$(x^{k+1}, \lambda^{k+1}) = (x^k, \lambda^k) - (L''(x^k, \lambda^k))^{-1} L'(x^k, \lambda^k), \quad k = 0, 1, \dots$$

Reescribimos la iteración de Newton, calculando las derivadas involucradas. Sean x^k una aproximación dada a la solución $\bar{x}$ del problema (10.92) y $\lambda^k \in \mathbb{R}^l$ una aproximación al multiplicador de Lagrange asociado a $\bar{x}$. Como

$$L''(x^k, \lambda^k) = \begin{pmatrix} L''_{xx}(x^k, \lambda^k) & (h'(x^k))^T \\ h'(x^k) & 0 \end{pmatrix},$$

las aproximaciones siguientes (x^{k+1}, λ^{k+1}) son soluciones del sistema lineal

$$L''_{xx}(x^k, \lambda^k)(x - x^k) + (h'(x^k))^T(\lambda - \lambda^k) = -f'(x^k) - (h'(x^k))^T \lambda^k, \quad (10.94)$$

$$h'(x^k)(x - x^k) = -h(x^k), \quad (10.95)$$

en relación a $(x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l$. El método de Newton para el sistema de Lagrange, por lo tanto, consiste en el siguiente procedimiento.

Algoritmo 4.4.1. (El método de Newton-Lagrange)

Elegir $(x^0, \lambda^0) \in \mathbb{R}^n \times \mathbb{R}^l$ y tomar $k := 0$.

1. Calcular $(x^{k+1}, \lambda^{k+1}) \in \mathbb{R}^n \times \mathbb{R}^l$, una solución del sistema (10.94), (10.95).
2. Tomar $k := k + 1$ y volver al Paso 1.

Observamos que la matriz del sistema lineal (10.94), (10.95), es simétrica. No obstante, como es fácil ver, ella no puede ser definida positiva (o definida negativa) cuando $l > 0$. En efecto, tomando $\tilde{u} = (\tilde{x}, \tilde{\lambda}) \in \mathbb{R}^n \times \mathbb{R}^l$, con $\tilde{x} = 0, \tilde{\lambda} \neq 0$, obtenemos

$$\begin{aligned} \langle L''(x^k, \lambda^k) \tilde{u}, \tilde{u} \rangle &= \langle L''_{xx}(x^k, \lambda^k) \tilde{x}, \tilde{x} \rangle + \langle (h'(x^k))^T \tilde{\lambda}, \tilde{x} \rangle + \langle \tilde{\lambda}, h'(x^k) \tilde{x} \rangle \\ &= 0, \end{aligned}$$

lo que muestra que $L''(x^k, \lambda^k)$ no es ni definida positiva, ni definida negativa, por la propia estructura de esta matriz, independientemente del problema en consideración.

El resultado siguiente proporciona condiciones naturales para que la matriz en cuestión sea no-singular. Para la resolución de este sistema pueden ser utilizados tanto métodos de Álgebra Lineal computacional de uso general, como métodos que tienen en cuenta la estructura especial de la matriz que define el sistema.

Teorema 10.10 (Convergencia superlineal del método de Lagrange-Newton). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones dos veces diferenciables en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivadas segundas continuas en $\bar{x}$. Supongamos que $\bar{x}$ satisfaga la condición de regularidad de las restricciones (6.9), y que este punto sea un punto estacionario del problema (10.92), siendo $\bar{\lambda} \in \mathbb{R}^l$ el (único) multiplicador de Lagrange asociado. Supongamos, finalmente, que la condición suficiente de segunda orden del Teorema 1.2.2 se satisfaga.

Entonces todo punto inicial $(x^0, \lambda^0) \in \mathbb{R}^n \times \mathbb{R}^l$, suficientemente próximo al punto $(\bar{x}, \bar{\lambda})$, define unívocamente una secuencia del Algoritmo 4.4.1, que converge a $(\bar{x}, \bar{\lambda})$. La tasa de convergencia es superlineal, y si las derivadas segundas de f y h son Lipschitz-continuas en una vecindad de $\bar{x}$, entonces la convergencia es cuadrática.

Prueba. El resultado es una consecuencia directa del Teorema 3.2.1. Basta probar que, bajo las hipótesis especificadas, la matriz

$$L''(\bar{x}, \bar{\lambda}) = \begin{pmatrix} L''_{xx}(\bar{x}, \bar{\lambda}) & (h'(\bar{x}))^\top \\ h'(\bar{x}) & 0 \end{pmatrix}$$

es no-singular. Tomamos $\tilde{u} = (\tilde{x}, \tilde{\lambda}) \in \ker L''(\bar{x}, \bar{\lambda})$ arbitrario. Tenemos que

$$L''_{xx}(\bar{x}, \bar{\lambda})\tilde{x} + (h'(\bar{x}))^\top \tilde{\lambda} = 0, \quad (10.96)$$

$$h'(\bar{x})\tilde{x} = 0. \quad (10.97)$$

Multiplicando los dos lados de (10.96) por $\tilde{x}$ y utilizando (10.97), obtenemos

$$\begin{aligned} 0 &= \langle L''_{xx}(\bar{x}, \bar{\lambda})\tilde{x}, \tilde{x} \rangle + \langle (h'(\bar{x}))^\top \tilde{\lambda}, \tilde{x} \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda})\tilde{x}, \tilde{x} \rangle + \langle \tilde{\lambda}, h'(\bar{x})\tilde{x} \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda})\tilde{x}, \tilde{x} \rangle. \end{aligned}$$

Esto significa que $\tilde{x} = 0$, porque en caso contrario la condición suficiente de segunda orden sería violada. Ahora, de (10.96), obtenemos que

$$(h'(\bar{x}))^\top \tilde{\lambda} = 0. \quad (10.98)$$

La condición de regularidad de las restricciones (6.9) es equivalente a $\ker(h'(\bar{x}))^\top = \{0\}$. Luego, (10.98) solo puede ser satisfecha cuando $\tilde{\lambda} = 0$. Acabamos de mostrar que $\tilde{u} = (\tilde{x}, \tilde{\lambda}) = 0$, i.e., la matriz $L''(\bar{x}, \bar{\lambda})$ es no-singular. ■

Notemos que, en general, la convergencia cuadrática de la secuencia primal-dual no implica ni siquiera la convergencia superlineal de la secuencia primal (vea el Ejemplo 2.2.1). La cuestión de la convergencia superlineal primal, así como la globalización del método de Newton-Lagrange, serán tratadas más adelante, en el contexto de métodos de programación cuadrática secuencial; vea § 4.6.

Observemos que cuando un punto estacionario satisface la condición de regularidad de las restricciones (6.9) y tenemos una aproximación x^0 suficientemente buena en las variables primales, una buena aproximación λ^0 en las variables duales puede ser obtenida de la siguiente manera. La condición de regularidad implica que $h'(\bar{x})(h'(\bar{x}))^\top$ es una matriz no-singular. Por lo tanto, de la condición

$$-f'(\bar{x}) = (h'(\bar{x}))^\top \bar{\lambda},$$

obtenemos

$$-h'(\bar{x})f'(\bar{x}) = h'(\bar{x})(h'(\bar{x}))^\top \bar{\lambda},$$

y luego,

$$\bar{\lambda} = -(h'(\bar{x})(h'(\bar{x}))^\top)^{-1} h'(\bar{x})f'(\bar{x}).$$

Tomando

$$\lambda^0 = -(h'(x^0)(h'(x^0))^\top)^{-1} h'(x^0)f'(x^0),$$

por el teorema de perturbaciones pequeñas de una matriz no-singular (vea el Teorema 1.5.1), obtenemos que $\lambda^0 \rightarrow \bar{\lambda}$ cuando $x^0 \rightarrow \bar{x}$. O sea, si x^0 es próximo a $\bar{x}$, entonces el λ^0 especificado arriba queda próximo a $\bar{\lambda}$.

Existen métodos, de gran importancia práctica, que en cada iteración k , en vez de la matriz $L''_{xx}(x^k, \lambda^k)$ utilizan la matriz $M_k^\top L''_{xx}(x^k, \lambda^k) M_k$, donde las columnas de $M_k \in \mathbb{R}(n, \dim \ker h'(x^k))$ forman una base del subespacio

ker $h'(x^k)$, que depende de manera continua de x^k . Técnicas de este tipo se llaman *métodos de Hessiana reducida*. Los detalles pueden ser consultados en [5].

Para resolver el sistema de Lagrange (10.93), podemos utilizar no solamente el método de Newton puro, sino también varias modificaciones (vea § 3.2.1 y [3]), además de otras técnicas para la resolución de ecuaciones no-lineales [13].

Podemos también intentar resolver el sistema (10.93) aplicando métodos de optimización irrestricta al problema

$$\min \|L'(x, \lambda)\|^2, \quad (x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l. \quad (10.99)$$

Obviamente, las soluciones globales de este problema coinciden con las soluciones del sistema (10.93) (cuando este último posee soluciones). La deficiencia principal de este abordaje, así como la de otros métodos de resolución directa del sistema de Lagrange, es que estamos ignorando, de cierto modo, la naturaleza del problema original (10.92), que es la de minimización. Con efecto, es bien claro que el sistema de Lagrange caracteriza tanto minimizadores como maximizadores del problema original, sin preferencia. A seguir, consideramos algunos métodos que son menos afectados por este tipo de deficiencias.

10.4.2. El método de penalización cuadrática

Los métodos de penalización en el contexto general ya fueron considerados en § 4.3. Presentaremos ahora un método específico para el problema con restricciones de igualdad (10.92).

Consideremos una familia de funciones penalizadas, obtenidas sumando f con la función de penalización cuadrática $\|h(\cdot)\|^2/2$, multiplicada por el parámetro de penalización $c \geq 0$:

$$\varphi(\cdot; c) : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \varphi(x; c) = f(x) + \frac{c}{2} \|h(x)\|^2. \quad (10.100)$$

Notemos que $\varphi(\cdot; c) \equiv f(\cdot)$ en el conjunto factible D ; y que en cualquier punto fuera de D , el valor del término penalizador crece (sin límite) con el crecimiento de c . Por lo tanto, podemos pensar que, en algún sentido, el problema de optimización irrestricta

$$\min \varphi(x; c), \quad x \in \mathbb{R}^n, \quad (10.101)$$

aproxima el problema original (10.92), cuando $c \rightarrow +\infty$. El método de penalización cuadrática para el problema (10.92) consiste en el siguiente procedimiento.

Algoritmo 4.4.2. (El método de penalización cuadrática)

Elegir $c_0 > 0$ y tomar $k := 0$.

1. Calcular $x^k \in \mathbb{R}^n$, un punto estacionario del problema (10.101), donde la función objetivo es definida en (10.100) con $c = c_k$.
2. Elegir $c_{k+1} \geq c_k$, tomar $k := k + 1$ y retornar al Paso 1.

Para encontrar puntos estacionarios del problema (10.101), pueden ser utilizados métodos de optimización irrestricta considerados en el Capítulo 3. Notemos que la función objetivo de (10.101) es tantas veces diferenciable como lo sean f y h . En el Algoritmo 4.4.2, en la iteración k es natural tomar x^{k-1} (punto estacionario de $\varphi(\cdot; c_{k-1})$) como punto inicial en el método utilizado para minimizar $\varphi(\cdot; c_k)$. Sin embargo, para que tal punto x^{k-1} sea una buena aproximación del punto estacionario de $\varphi(\cdot; c_k)$, el valor de c_k no puede ser muy diferente de c_{k-1} . En otras palabras, el cambio del parámetro de penalización debe ser relativamente lento.

Tenemos el siguiente resultado sobre la convergencia del método de penalización cuadrática.

Teorema 10.11 (Convergencia del método de penalización cuadrática). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones diferenciables en $\mathbb{R}^n$, con derivadas continuas. Sea $\bar{x} \in \mathbb{R}^n$ un punto de acumulación de una secuencia $\{x^k\}$ generada por el Algoritmo 4.4.2, donde $\{c_k\} \rightarrow +\infty$ ($k \rightarrow \infty$), que satisfaga la condición de regularidad de las restricciones (6.9).

Entonces $\bar{x}$ es un punto estacionario del problema (10.92). Además de eso, para cualquier subsecuencia $\{x^{k_j}\}$ que converge a $\bar{x}$, se tiene que

$$\{c_{k_j} h(x^{k_j})\} \rightarrow \bar{\lambda} \quad (j \rightarrow \infty), \quad (10.102)$$

donde $\bar{\lambda} \in \mathbb{R}^l$ es el (único) multiplicador de Lagrange asociado al punto estacionario $\bar{x}$.

Prueba. Como x^k es un punto estacionario de (10.101),

$$\begin{aligned} 0 &= \varphi'(x^k; c_k) = f'(x^k) + c_k(h'(x^k))^\top h(x^k) \\ &= f'(x^k) + (h'(x^k))^\top \lambda^k, \end{aligned} \quad (10.103)$$

donde definimos $\lambda^k = c_k h(x^k)$, para todo k . Luego,

$$h'(x^k)f'(x^k) + h'(x^k)(h'(x^k))^\top \lambda^k = 0.$$

Por la condición (6.9) de regularidad de las restricciones en $\bar{x}$, y por el teorema de perturbaciones pequeñas de una matriz no-singular (Teorema 1.5.1), tenemos que la matriz $h'(x^{k_j})(h'(x^{k_j}))^\top$ es no-singular para todo j suficientemente grande. Por lo tanto, podemos escribir que

$$\lambda^{k_j} = -(h'(x^{k_j})(h'(x^{k_j}))^\top)^{-1} h'(x^{k_j})f'(x^{k_j}).$$

De donde, teniendo en cuenta que f y h son diferenciables con derivadas continuas, obtenemos que

$$\{\lambda^{k_j}\} \rightarrow \bar{\lambda} \quad (j \rightarrow \infty), \quad (10.104)$$

donde

$$\bar{\lambda} = -(h'(\bar{x})(h'(\bar{x}))^\top)^{-1} h'(\bar{x})f'(\bar{x}).$$

Pasando al límite cuando $j \rightarrow \infty$ en (10.103), obtenemos que

$$0 = f'(\bar{x}) + (h'(\bar{x}))^\top \bar{\lambda} = L'_x(\bar{x}, \bar{\lambda}).$$

Además de eso, en vista de que $c_k \rightarrow \infty$ y de que $\{\lambda^{k_j}\}$ es acotada (vea (10.104)), tenemos que

$$h(\bar{x}) = \lim_{j \rightarrow \infty} h(x^{k_j}) = \lim_{j \rightarrow \infty} \lambda^{k_j}/c_{k_j} = 0.$$

Acabamos de mostrar que $\bar{x}$ es un punto estacionario del problema (10.92), y $\bar{\lambda} = \bar{\lambda}$ es el multiplicador de Lagrange asociado (que debe ser único en el caso de (6.9)). Finalmente, la relación (10.102) se sigue de (10.104). ■

En general, el problema (10.101) puede no poseer ningún punto estacionario, o poseer varios. El resultado siguiente (que es una consecuencia directa del Teorema 4.3.2) contiene, entre otras cosas, condiciones suficientes para garantizar la existencia de puntos estacionarios en (10.101).

Teorema 10.12. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones continuas en $\mathbb{R}^n$. Sea $\bar{x} \in \mathbb{R}^n$ un minimizador local estricto del problema (10.92). Entonces existe un número $\delta > 0$ tal que para cualquier solución (global) $x(c)$ del problema

$$\min \varphi(x; c) \quad \text{sujeto a } x \in B(\bar{x}, \delta),$$

donde la función objetivo es dada por (10.100) con $c \geq 0$, se tiene que

$$\|x(c) - \bar{x}\| \rightarrow 0 \quad (c \rightarrow +\infty), \quad (10.105)$$

y en particular, para todo número $c > 0$ suficientemente grande, el punto $x(c)$ es una solución local del problema (10.101).

De acuerdo con el Teorema 10.12, cualquier solución local estricta $\bar{x}$ del problema (10.92) puede ser encontrada como el límite de la secuencia generada por el Algoritmo 4.4.2, si en este algoritmo los puntos estacionarios del problema (10.101) son elegidos de manera adecuada (cuando hay más de un punto estacionario). Bajo ciertas hipótesis adicionales, puede ser probado que para k suficientemente grande, el problema (10.101), donde la función objetivo es dada por (10.100) con $c = c_k$, posee en una vecindad de $\bar{x}$ un único punto estacionario $x(c_k)$. Más aún, puede ser obtenida una estimativa de la tasa de convergencia de la secuencia $\{x(c_k)\}$ a $\bar{x}$. Si para todo k elegimos como punto inicial en el método de optimización irrestricta un punto suficientemente próximo a $\bar{x}$, podemos esperar que como aproximación siguiente será obtenido justamente $x^k = x(c_k)$. Esto sugiere que la elección de x^{k-1} , como punto inicial en la iteración siguiente, es bien razonable: cuando lleguemos cerca del punto $\bar{x}$ (lo que puede ser esperado, por el Teorema 10.11), esta elección probablemente va a garantizar que los iterandos x^j , $j \geq k$, van a permanecer cerca de $\bar{x}$; o sea, van a coincidir con los $x(c_j)$ (que convergen a $\bar{x}$).

Teorema 10.13 (Estimativa de la tasa de convergencia del método de penalización cuadrática). Supongamos que valen las hipótesis del Teorema 10.10. Entonces existen una vecindad U del punto $\bar{x}$ y números $\bar{c} \geq 0$ y $M > 0$ tales que, para todo $c > \bar{c}$, el problema (10.101) con la función objetivo dada por (10.100) tiene en U un único punto

estacionario $x(c)$. Además de eso, se tiene que

$$\|x(c) - \bar{x}\| \leq M\|\bar{\lambda}\|/c, \quad \|ch(x(c)) - \bar{\lambda}\| \leq M\|\bar{\lambda}\|/c. \quad (10.106)$$

Prueba. Definimos la función

$$\begin{aligned} \Phi : \mathbb{R} \times (\mathbb{R}^n \times \mathbb{R}^l) &\rightarrow \mathbb{R}^n \times \mathbb{R}^l, \\ \Phi(t, \chi) &= \begin{pmatrix} L'_x(\xi, \eta) \\ h(\xi) - t\eta \end{pmatrix}, \quad \chi = (\xi, \eta). \end{aligned} \quad (10.107)$$

Sea $\bar{\lambda} \in \mathbb{R}^l$ el (único) multiplicador de Lagrange asociado al punto estacionario $\bar{x}$. Definimos $\bar{\chi} = (\bar{x}, \bar{\lambda})$. Entonces $\Phi(0, \bar{\chi}) = 0$ y $\Phi'_\chi(0, \bar{\chi}) = L''(\bar{x}, \bar{\lambda})$, donde la última matriz es no-singular (lo que fue verificado, bajo las hipótesis actuales, en la demostración del Teorema 10.10). Aplicando a la función Φ en el punto $(0, \bar{\chi})$ el Teorema de la Función Implícita (Teorema 1.5.3), concluimos que existen un número $\bar{t} > 0$ y una vecindad U del punto $\bar{\chi}$ en $\mathbb{R}^n \times \mathbb{R}^l$ tales que para todo $t \in (-\bar{t}, \bar{t})$, la ecuación

$$\Phi(t, \chi) = 0 \quad (10.108)$$

en relación a $\chi \in \mathbb{R}^n \times \mathbb{R}^l$ posee en U una única solución $\chi(t) = (\xi(t), \eta(t))$, siendo la función $\chi(\cdot)$ diferenciable en $(-\bar{t}, \bar{t})$ con derivada continua en 0. Además de eso, por el Teorema 1.5.4, tenemos que para alguna constante $M > 0$,

$$\|\chi(t) - \bar{\chi}\| \leq M\|\Phi(t, \bar{\chi})\| = M\|\bar{\lambda}\|t \quad \forall t \in (-\bar{t}, \bar{t}), \quad (10.109)$$

si $\bar{t}$ es suficientemente pequeño.

Definimos $\bar{c} = 1/\bar{t}$ y $x(c) = \xi(1/c)$, $c > \bar{c}$. Para todo tal c , de (10.107) obtenemos

$$\begin{aligned} \varphi'(x(c); c) &= f'(x(c)) + c(h'(x(c)))^\top h(x(c)) \\ &= L'_x(\xi(1/c), \eta(1/c)) = 0, \end{aligned}$$

i.e., $x(c)$ es un punto estacionario del problema (10.101). Además de eso, de (10.109) siguen las estimativas (10.106), ya que por la construcción, $h(\xi(t)) = t\eta(t) \forall t \in (-\bar{t}, \bar{t})$.

Finalmente, consideremos secuencias $\{c_i\} \subset \mathbb{R}^n$ y $\{x^i\} \subset \mathbb{R}^n$ tales que $\{c_i\} \rightarrow \infty$, $\{x^i\} \rightarrow \bar{x}$ ($i \rightarrow \infty$), donde para todo i , el punto x^i es estacionario para el problema (10.101). De (10.107), es fácil ver que, para todo i , $\chi^i = (x^i, c_i h(x^i))$ es una solución de la ecuación (10.108) con $t = 1/c_i$. Además de eso, por el Teorema 10.11,

$$\{c_i h(x^i)\} \rightarrow \bar{\lambda} \quad (i \rightarrow \infty).$$

Por lo tanto, $\chi^i \in U$ para todo i suficientemente grande. Luego, $\chi^i = \chi(1/c_i)$ y, en particular, $x^i = x(c_i)$. Esto prueba que $x(c)$ es el único punto estacionario del problema (10.101) en una vecindad U de $\bar{x}$, para c suficientemente grande. ■

Como fue mostrado en la demostración anterior, las funciones $\xi(\cdot)$ y $\eta(\cdot)$, en ella definidas, son diferenciables en $(-\bar{t}, \bar{t})$. En particular, la función $x(\cdot)$ es diferenciable en $(\bar{c}, +\infty)$. Además de eso, como se sigue de (10.107), para todo $t \in (-\bar{t}, \bar{t})$ el punto $\xi(t)$ satisface la ecuación

$$tf'(\xi) + (h'(\xi))^\top h(\xi) = 0 \quad (10.110)$$

en relación a $\xi \in \mathbb{R}^n$. Derivando ambos lados de esta ecuación a lo largo de la curva $\xi(\cdot)$, obtenemos que esta trayectoria satisface, en $(-\bar{t}, \bar{t})$, el siguiente sistema de ecuaciones diferenciales:

$$((t-1)f''(\xi) + L''_{xx}(\xi, h(\xi)) + (h'(\xi))^\top h'(\xi))\dot{\xi} + f'(\xi) = 0, \quad (10.111)$$

donde $\dot{\xi}$ denota la derivada de ξ en relación a t . El mismo resultado puede ser obtenido apelando a la fórmula de la derivada de la función implícita del Teorema 1.5.3.

Lo expuesto arriba motiva una interpretación continua del método de penalización cuadrática. Fijamos un número $t_0 \neq 0$ y encontramos un punto $\xi^0 \in \mathbb{R}^n$ como una solución de la ecuación (10.110) con $t = t_0$. Después, esta solución puede ser continuada (extrapolada) por una técnica u otra, en relación a t hasta el valor $t = 0$. Por ejemplo, aquí pueden ser utilizados esquemas inexatos para la resolución de ecuaciones diferenciales, añadiendo a (10.111) la condición inicial

$$\xi(t_0) = \xi^0.$$

Naturalmente, si el par inicial (t_0, ξ^0) está lejos del par $(0, \bar{x})$, donde $\bar{x}$ satisface las hipótesis del Teorema 10.13, una continuación de este tipo no siempre será posible o, cuando sea posible, puede no ser única. Algunos asuntos de técnicas de continuación ya fueron tratados en § 3.3.3.

Como puede ser visto de la estimativa (10.106), para $\bar{\lambda} = 0$ (lo que en el contexto del Teorema 10.13 es equivalente a $f'(\bar{x}) = 0$), se tiene que $x(c) = \xi(1/c) = \bar{x}$ para todo c suficientemente grande. O sea, la penalización cuadrática queda *exacta* en el sentido siguiente: para un valor c suficientemente grande un punto estacionario $x(c)$ del problema de optimización irrestricta (10.101) queda suficientemente próximo a la solución $\bar{x}$ del problema original (10.92), entonces $x(c)$ es exactamente la solución $\bar{x}$. En estas situaciones, hablamos de *penalización exacta*. Sin embargo, subrayamos que en el caso de penalización cuadrática, esta propiedad no es común.

Si $\bar{\lambda} \neq 0$, por (10.111), por la condición de regularidad de las restricciones (6.9), y por la definición del multiplicador de Lagrange, tenemos que

$$\|h'(\bar{x})\xi(0)\| = \|\bar{\lambda}\| > 0,$$

i.e., cuando $t \rightarrow 0$ la trayectoria $\xi(\cdot)$ se aproxima a la solución $\bar{x}$ de manera “transversal” al conjunto factible D (en el sentido de que el vector $\xi(0)$, que es tangente a la trayectoria, no pertenece al subespacio $\ker h'(\bar{x})$ que es tangente a D en el punto $\bar{x}$). En este caso, la estimativa (10.106) no puede ser mejorada.

En el sentido teórico, el Algoritmo 4.4.2 posee propiedades satisfactorias. Observamos que la convergencia se hace más rápida en la medida en que la secuencia $\{c_k\}$ crece más rápidamente (esto puede ser visto a partir de la estimativa (10.106)). No obstante, es bien claro que todas las dificultades fueron traspasadas para la fase de resolución de los subproblemas irrestrictos. Arriba ya mencionamos una razón por la cual los parámetros de penalización no deben ser cambiados bruscamente, lo que significa que más subproblemas tienen que ser resueltos, haciendo el método más lento. Pero ni eso es la deficiencia principal de métodos de este tipo. El gran problema es el siguiente. Generalmente, para llegar a un punto $x(c)$ que sea aceptable como una buena aproximación de la solución $\bar{x}$, el parámetro de penalización c tiene que ser bastante grande. Como ya comentamos arriba, en la medida en que c crece, los subproblemas (10.101) se tornan cada vez peores (la función objetivo en (10.101) pasa a tener curvas de nivel cada vez más alargadas, vea § 3.1.2). Un análisis detallado de este fenómeno puede ser consultado en [3]. Esto hace que la resolución de cada subproblema sea cada vez más difícil desde el punto de vista computacional. Por eso, los métodos de penalización en su forma básica tienen poca utilidad práctica. Algunos métodos más sofisticados, que utilizan ideas de penalización pero trabajan con parámetros de penalización limitados, serán considerados en § 4.4.3.

10.4.3. Lagrangianas aumentadas y funciones de penalización exacta diferenciables

Una manera de evitar el crecimiento ilimitado del parámetro de penalización es añadir un término de penalización diferenciable (por ejemplo, cuadrático) a la Lagrangiana del problema (10.92), en vez de solo a la función objetivo. Así introducimos una familia de *Lagrangianas aumentadas* del problema (10.92):

$$\begin{aligned} L(\cdot; c) : \mathbb{R}^n \times \mathbb{R}^l &\rightarrow \mathbb{R}, \\ L(x, \lambda; c) &= L(x, \lambda) + \frac{c}{2} \|h(x)\|^2 \\ &= f(x) + \langle \lambda, h(x) \rangle + \frac{c}{2} \|h(x)\|^2, \end{aligned} \quad (10.112)$$

donde $c \geq 0$ es un parámetro. En particular, entendemos que la Lagrangiana clásica viene dada por $L(x, \lambda) := L(x, \lambda; 0)$.

Observamos que el problema original (10.92) es equivalente al problema

$$\min f(x) + \frac{c}{2} \|h(x)\|^2 \quad \text{sujeto a } x \in D, \quad (10.113)$$

para $c > 0$ cualquiera (basta notar que las funciones objetivo de este problema y del problema original coinciden en el conjunto factible D). Ahora, la Lagrangiana aumentada, dada por (10.112), puede ser considerada como la Lagrangiana clásica del problema modificado (10.113) (que es equivalente al problema original (10.92)).

Otra interpretación es la siguiente. Un punto estacionario $\bar{x}$ del problema (10.92) también es punto estacionario del problema irrestricto

$$\min L(x, \bar{\lambda}), \quad x \in \mathbb{R}^n, \quad (10.114)$$

donde $\bar{\lambda}$ es un multiplicador de Lagrange asociado a $\bar{x}$. En principio, en vez de la resolución del sistema de Lagrange del problema (10.92), podemos intentar encontrar un punto estacionario de (10.114). Es claro que el multiplicador $\bar{\lambda}$ no es conocido a priori. Él puede ser aproximado utilizando información disponible en la aproximación x^k de $\bar{x}$. Sin embargo, esta estrategia tiene un defecto bastante serio. En particular, la satisfacción de las hipótesis (naturales) del Teorema 10.10 no garantiza que la matriz $L''_{xx}(\bar{x}, \bar{\lambda})$ (que es la matriz Hessiana de la función objetivo en (10.114) en la

solución) sea definida positiva. De hecho, incluso bajo hipótesis de regularidad de las restricciones y de la condición suficiente de segunda orden para el problema original, $\bar{x}$ puede no ser una solución del problema (10.114).

Ejemplo 10.5. Consideremos el problema

$$\min x^3 \quad \text{sujeto a } x + 1 = 0.$$

La solución de este problema es $\bar{x} = -1$, que satisface la condición de regularidad de las restricciones (6.9). La Lagrangiana viene dada por $L(x, \lambda) = x^3 + \lambda(x + 1)$. Como es fácil ver, el (único) multiplicador de Lagrange es $\bar{\lambda} = -3$. Sin embargo, el punto $\bar{x}$ no es una solución del problema (10.114), porque $L''_{xx}(\bar{x}, \bar{\lambda}) = -6 < 0$ (en particular, la condición necesaria de segunda orden del Teorema 1.2.1(a) está violada).

Observemos que la condición suficiente de segunda orden del Teorema 1.2.2(b) para el problema original está satisfecha (trivialmente), porque $\ker h'(\bar{x}) = \{0\}$.

Por eso, la aplicación (con éxito garantizado) de métodos de optimización irrestricta al problema (10.114) solo puede ser justificada bajo hipótesis muy fuertes (y que no son nada naturales en relación al problema original (10.92)).

En el desarrollo y análisis de algoritmos, la Lagrangiana aumentada puede ser utilizada al lado de la clásica, porque, como puede verse con facilidad, para todo c se tiene que

$$\begin{aligned} L'_x(x, \lambda; c) &= L'_x(x, \lambda) \quad \forall x \in D, \forall \lambda \in \mathbb{R}^l, \\ L'_\lambda(x, \lambda; c) &= L'_\lambda(x, \lambda) = h(x) \quad \forall x \in \mathbb{R}^n, \forall \lambda \in \mathbb{R}^l. \end{aligned}$$

En particular, el conjunto de soluciones de la ecuación

$$L'(x, \lambda; c) = 0,$$

donde la derivada es en relación a (x, λ) , coincide con el conjunto de soluciones del sistema de Lagrange del problema (10.92). Desde el punto de vista algorítmico, la Lagrangiana aumentada posee ciertas ventajas. Una de ellas puede ser vista en el hecho siguiente.

Teorema 10.14. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Sea $\bar{x}$ un punto estacionario del problema (10.92), que satisfaga la condición suficiente de segunda orden del Teorema 1.2.2(b), con algún multiplicador de Lagrange $\bar{\lambda} \in \mathbb{R}^l$.

Entonces para todo número c suficientemente grande, la matriz

$$L''_{xx}(\bar{x}, \bar{\lambda}; c) = L''_{xx}(\bar{x}, \bar{\lambda}) + c(h'(\bar{x}))^\top h'(\bar{x})$$

es definida positiva. En particular, el punto estacionario $\bar{x}$ del problema

$$\min L(x, \bar{\lambda}; c), \quad x \in \mathbb{R}^n, \quad (10.115)$$

satisface la condición suficiente de segunda orden dada en el Teorema 1.2.1(b) (y, por lo tanto, es una solución local estricta de (10.115)).

Prueba. El hecho de que un punto estacionario $\bar{x}$ del problema (10.92) también es un punto estacionario del problema (10.115) ya fue verificado arriba. Bajo la condición suficiente de segunda orden del Teorema 1.2.2(b), la aplicación directa del Lema 1.5.2 implica que la matriz $L''_{xx}(\bar{x}, \bar{\lambda}; c)$ es definida positiva. ■

Volviendo al Ejemplo 10.5, observemos que

$$L(x, \bar{\lambda}; c) = x^3 - 3(x + 1) + \frac{c}{2}(x + 1)^2,$$

$\bar{x} = -1$ es un punto estacionario del problema (10.115), ya que

$$L'_x(\bar{x}, \bar{\lambda}; c) = 3\bar{x}^2 - 3 = 0,$$

y este punto realmente es una solución de este problema, ya que $L''_{xx}(\bar{x}, \bar{\lambda}; c) = 6\bar{x} + c > 0$ para todo $c > 6$.

Esto motiva el siguiente esquema iterativo, llamado *método de la Lagrangiana aumentada*. Cada iteración de este método consiste en la resolución, para un parámetro $c > 0$ y una aproximación λ al multiplicador de Lagrange, del problema de optimización irrestricta

$$\min L(x, \lambda; c), \quad x \in \mathbb{R}^n, \quad (10.116)$$

con subsecuente actualización de λ y de c . El origen de la regla de actualización de λ puede ser explicada, por lo menos parcialmente, por la fórmula (10.102) (recordando, no obstante, que esta fórmula fue obtenida para el método

de penalización cuadrática pura y no para la Lagrangiana aumentada). El valor del parámetro c , en principio, puede hasta ser fijo para todas las iteraciones. Es obvio que esta difícilmente puede ser la mejor estrategia. Existen varias reglas de actualización de c bien más eficientes en la práctica. Notemos que, en cualquier caso, para garantizar convergencia, este parámetro no precisa ser ilimitado (diferentemente del caso de la penalización cuadrática).

Algoritmo 4.4.3. (Método de la Lagrangiana aumentada)

Elegir $\lambda^0 \in \mathbb{R}^l$ y $c_0 > 0$. Tomar $k := 0$.

1. Calcular $x^k \in \mathbb{R}^n$, un punto estacionario del problema (10.116), donde la función objetivo es dada por la fórmula (10.112) con $c = c_k$ y $\lambda = \lambda^k$.

2. Tomar

$$\lambda^{k+1} = \lambda^k + c_k h(x^k)$$

y elegir $c_{k+1} \geq c_k$.

3. Tomar $k := k + 1$ y retornar al Paso 1.

Varias reglas específicas para la elección de los parámetros c_k pueden ser consultadas, por ejemplo, en [3, 4].

A seguir, comentaremos las propiedades de convergencia del Algoritmo 4.4.3.

Teorema 10.15 (Convergencia del método de la Lagrangiana aumentada). *Supongamos que valen las hipótesis del Teorema 10.10.*

Entonces existen una vecindad U de $\bar{x}$ y números $\bar{c} \geq 0$, $\delta > 0$ y $M > 0$, tales que:

- (a) Para todo par $(\lambda, c) \in \Delta(\bar{c}, \delta)$, donde

$$\Delta(\bar{c}, \delta) = \{(\lambda, c) \in \mathbb{R}^l \times \mathbb{R} \mid \|\lambda - \bar{\lambda}\| < \delta c, c > \bar{c}\},$$

el problema (10.116) con la función objetivo dada por la fórmula (10.112), tiene en U un único punto estacionario $x(\lambda, c)$ y este punto satisface

$$\begin{aligned} \|x(\lambda, c) - \bar{x}\| &\leq M\|\lambda - \bar{\lambda}\|/c, \\ \|\lambda + ch(x(\lambda, c)) - \bar{\lambda}\| &\leq M\|\lambda - \bar{\lambda}\|/c. \end{aligned} \quad (10.117)$$

- (b) Existe un número $\bar{\delta} \in (0, \delta]$ tal que para cualquier secuencia $\{c_k\} \subset \mathbb{R}_+$ no decreciente y cualquier punto $\lambda^0 \in \mathbb{R}^l$ satisfaciendo

$$(\lambda^0, c_0) \in \Delta(\bar{c}, \bar{\delta}), \quad (10.118)$$

la fórmula

$$\lambda^{k+1} = \lambda^k + c_k h(x(\lambda^k, c_k)), \quad k = 0, 1, \dots,$$

define unívocamente una secuencia $\{\lambda^k\}$ (en el sentido de que $\{(\lambda^k, c_k)\} \subset \Delta(\bar{c}, \delta)$, i.e., para todo k el punto $x(\lambda^k, c_k)$ está bien definido).

Además de eso, $\{\lambda^k\} \rightarrow \bar{\lambda}$, $\{x(\lambda^k, c_k)\} \rightarrow \bar{x}$ ($k \rightarrow \infty$). La tasa de convergencia de la secuencia $\{\lambda^k\}$ es lineal, y si $c_k \rightarrow \infty$ ($k \rightarrow \infty$), ella es superlineal.

La demostración de este resultado necesita de algunas herramientas que están fuera del alcance de este libro. Nosotros vamos a limitarnos a comentarios generales. Primero, notamos que para $\lambda = 0$, la afirmación (a) coincide con aquella del Teorema 10.13. La demostración del ítem (a) puede seguir la misma línea que el Teorema 10.13, mas introduciendo algunas consideraciones más sofisticadas que la aplicación directa del Teorema de la Función Implícita. Para probar el ítem (b), la dificultad principal es establecer la existencia de un número $\bar{\delta} \in (0, \delta]$ tal que para todo par (λ^0, c_0) satisfaciendo (10.118), la secuencia $\{(\lambda^k, c_k)\}$ permanece dentro del conjunto $\Delta(\bar{c}, \delta)$. Cuando esto es probado, por (10.117), tenemos que para todo k ,

$$\begin{aligned} \|x(\lambda^k, c_k) - \bar{x}\| &\leq (M/c_k)\|\lambda^k - \bar{\lambda}\| \leq (M/\bar{c})\|\lambda^k - \bar{\lambda}\|, \\ \|\lambda^{k+1} - \bar{\lambda}\| &\leq (M/c_k)\|\lambda^k - \bar{\lambda}\| \leq (M/\bar{c})\|\lambda^k - \bar{\lambda}\|. \end{aligned}$$

Y si $\bar{c}$ es suficientemente grande, la secuencia $\{\lambda^k\}$ converge a $\bar{\lambda}$ con tasa lineal. Cuando $\{c_k\} \rightarrow \infty$ ($k \rightarrow \infty$), la tasa se torna superlineal. Además de eso, la secuencia $\{x(\lambda^k, c_k)\}$ converge a $\bar{x}$, con tasa por lo menos tan rápida como la tasa de convergencia de $\{\lambda^k\}$, i.e., por lo menos con tasa geométrica. La demostración completa puede ser consultada en [3].

Por el Teorema 10.15, si en el Algoritmo 4.4.3 los valores iniciales c_0 y λ^0 satisfacen la inclusión (10.118), y si x^k es escogido como punto estacionario del problema (10.116) que está más próximo a la solución $\bar{x}$ del problema (10.92), entonces la secuencia $\{(x^k, \lambda^k)\}$ generada por el Algoritmo 4.4.3 está bien definida y converge a $(\bar{x}, \bar{\lambda})$ (la tasa de convergencia ya fue comentada arriba). En relación al cálculo de un punto estacionario adecuado (i.e., próximo a $\bar{x}$), notamos que en la práctica esto está siendo utilizado de la manera ya mencionada en el caso del método de penalización cuadrática: para todo $k = 1, 2, \dots$, como punto inicial en el método de optimización irrestricta utilizado para resolver los subproblemas, tomamos el punto x^{k-1} . Con frecuencia, la secuencia $\{x^k\}$ así generada se mantiene dentro de la vecindad de alguna solución del problema (10.92) y, por lo tanto, el método converge a esta solución.

Es importante comentar que, independientemente de cuanto $\lambda^0 \in \mathbb{R}^l$ esté lejos de $\bar{\lambda}$, la condición (10.118) será satisfecha si el número c_0 es suficientemente grande. En otras palabras

10.5. Métodos para problemas con restricciones mixtas

A seguir, consideraremos el problema con restricciones mixtas de igualdad y desigualdad. Como fue mencionado en § 1.6, el sistema de optimalidad de Karush-Kuhn-Tucker (KKT) para este problema puede ser escrito en la forma de un sistema de ecuaciones no-lineales, pero en general no-diferenciables. Primero, serán presentados métodos de Newton generalizados para sistemas de ecuaciones no-diferenciables generales (no necesariamente ligados a optimización). Después de esto, consideraremos métodos específicos para resolver reformulaciones no-diferenciables de sistemas KKT.

10.5.1. Métodos de Newton generalizados

Consideremos una función $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$, no necesariamente diferenciable, y la ecuación

$$\Phi(x) = 0 \quad (10.119)$$

asociada. Una extensión natural del método de Newton viene dada por el esquema iterativo

$$x^{k+1} = x^k - H_k^{-1}\Phi(x^k), \quad k = 0, 1, \dots, \quad (10.120)$$

donde $H_k \in \partial\Phi(x^k)$ o $H_k \in \partial_B\Phi(x^k)$, i.e., en vez de la derivada clásica está siendo utilizado el subdiferencial de Clarke o el subdiferencial de Bouligand (vea § 1.6). Así, obtenemos el método de Newton generalizado.

Algoritmo 4.5.1. (El método de Newton generalizado)

Elegir la versión B o C del método. Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular una matriz $H_k \in \partial_B\Phi(x^k)$ en el caso de la versión B, o $H_k \in \partial\Phi(x^k)$ en el caso de la versión C. Calcular $x^{k+1} \in \mathbb{R}^n$, una solución del sistema de ecuaciones lineales

$$H_k(x - x^k) = -\Phi(x^k),$$

en relación a $x \in \mathbb{R}^n$.

2. Tomar $k := k + 1$ y retornar al Paso 1.

Las condiciones de regularidad que utilizaremos para probar la convergencia del método de Newton generalizado son las siguientes. La función $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ se llama BD-regular (CD-regular) en el punto $\bar{x} \in \mathbb{R}^n$, si todas las matrices $H \in \partial_B\Phi(\bar{x})$ ($H \in \partial\Phi(\bar{x})$) son no-singulares.

Teorema 10.16 (Convergencia del método de Newton generalizado). Sea $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ una función Lipschitz-continua en una vecindad del punto $\bar{x} \in \mathbb{R}^n$ que satisface en este punto la condición de Kummer (6.35). Sea $\bar{x}$ una solución de (10.119), tal que Φ es BD-regular en $\bar{x}$ en el caso de la versión B del Algoritmo 4.5.1, y CD-regular en el caso de la versión C.

Entonces para cualquier punto inicial $x^0 \in \mathbb{R}^n$ suficientemente próximo a $\bar{x}$, el Algoritmo 4.5.1 genera una secuencia bien definida que converge a $\bar{x}$. La tasa de convergencia es superlineal, y si Φ satisface en $\bar{x}$ la condición de Kummer fuerte (6.36), la tasa es cuadrática.

Prueba. La demostración es bastante similar a aquella para el método de Newton clásico (Teorema 3.2.1). Por eso, vamos a presentar apenas los pasos principales. Consideremos la versión B del algoritmo (la prueba para la versión C es análoga).

Por el resultado del Ejercicio 1.6.1, por las definiciones de B -diferencial y de diferencial de Clarke, utilizando el Teorema 1.5.1 (de perturbaciones pequeñas de una matriz no-singular) y un raciocinio por absurdo, obtenemos que existen una vecindad U del punto $\bar{x}$ y un número $M > 0$ tales que

$$\det H \neq 0, \quad \|H^{-1}\| \leq M \quad \forall H \in \partial_B \Phi(x), \quad \forall x \in U. \quad (10.121)$$

En particular, la iteración del Algoritmo 4.5.1 está bien definida para $x^k \in U$ cualquiera. Ahora, por (10.120), (10.121), y la condición de Kummer (6.35) en $\bar{x}$, podemos tomar una vecindad U tal que, si $x^k \in U$ e $H_k \in \partial_B \Phi(x^k)$, entonces

$$\begin{aligned} \|x^{k+1} - \bar{x}\| &= \|x^k - \bar{x} - H_k^{-1} \Phi(x^k)\| \\ &\leq \|H_k^{-1}\| \|\Phi(x^k) - \Phi(\bar{x}) - H_k(x^k - \bar{x})\| \\ &= o(\|x^k - \bar{x}\|). \end{aligned} \quad (10.122)$$

De aquí se sigue que, primero, para cualquier punto inicial x^0 suficientemente próximo a $\bar{x}$, el Algoritmo 4.5.1 genera una secuencia bien definida y, segundo, que esta secuencia converge a $\bar{x}$ con tasa superlineal. Finalmente, si en $\bar{x}$ vale la condición de Kummer fuerte (6.36), la estimativa (10.122) se transforma en

$$\|x^{k+1} - \bar{x}\| = O(\|x^k - \bar{x}\|^2),$$

i.e., la convergencia es cuadrática. ■

10.5.2. Métodos de Newton generalizados para el sistema de Karush-Kuhn-Tucker

Consideremos el problema

$$\min f(x) \quad \text{sujeto a } x \in D = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0. \end{array} \right\}, \quad (10.123)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones diferenciables. Puntos estacionarios de este problema son caracterizados por el sistema KKT

$$L'_x(x, \lambda, \mu) = 0, \quad h(x) = 0, \quad (10.124)$$

$$g_i(x) \leq 0, \quad \mu_i \geq 0, \quad \mu_i g_i(x) = 0, \quad i = 1, \dots, m, \quad (10.125)$$

donde

$$L : \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R},$$

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle,$$

es la Lagrangiana del problema. Sea $(\bar{x}, \bar{\lambda}, \bar{\mu})$ una solución del sistema (10.124)–(10.125). Sea como siempre, $I(\bar{x}) = \{i = 1, \dots, m \mid g_i(\bar{x}) = 0\}$ el conjunto de las restricciones activas en el punto $\bar{x}$. Bajo la condición de *complementaridad estricta*, i.e.,

$$\bar{\mu}_i > 0 \quad \forall i \in I(\bar{x}),$$

es bien fácil ver que, en torno del punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$, las relaciones (10.125) son equivalentes al sistema de ecuaciones

$$\mu_i = 0, \quad i \in \{1, \dots, m\} \setminus I(\bar{x}), \quad g_i(x) = 0, \quad i \in I(\bar{x}). \quad (10.126)$$

Por lo tanto, en este caso, el sistema KKT (10.124)–(10.125), es localmente equivalente al sistema (10.124), (10.126), de $n + l + m$ ecuaciones en relación a las variables $(x, \lambda, \mu) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$. Si f , h y g son dos veces diferenciables, este último sistema puede ser resuelto por el método de Newton clásico, como fue hecho en § 4.4.1 en el caso de problemas con restricciones de igualdad (cuando no hay restricciones de desigualdad). Naturalmente, la aplicación práctica del método de Newton clásico es limitada por el hecho de que el conjunto $I(\bar{x})$ no es conocido a priori. Sin embargo, existen varias técnicas de identificación de restricciones activas (inclusive cuando no hay complementaridad estricta, vea § 4.7). En el caso de complementaridad estricta, esta identificación es, en cierto sentido, hasta trivial. Por lo menos, en principio. El asunto de identificación de restricciones activas será tratado con más cuidado en § 4.7.

Aquí, presentaremos métodos de solución del sistema KKT que no necesitan de la condición de complementaridad estricta, ni de la identificación del conjunto $I(\bar{x})$. Cabe mencionar que cuando hay complementaridad estricta, las

iteraciones de estos métodos son localmente equivalentes a las iteraciones del método de Newton clásico para el sistema (10.124), (10.126). De hecho, esto es completamente natural y hasta deseable: en un cierto sentido puede ser afirmado que cualquier método Newtoniano debe ser equivalente al método de Newton clásico para el sistema (10.124), (10.126), cuando este sistema es equivalente al sistema KKT del problema original.

La idea es reformular las relaciones en (10.125) en un sistema de ecuaciones que no contengan elementos o parámetros a priori desconocidos. Mas es claro que la ventaja de lidiar con ecuaciones (en vez de ecuaciones e inecuaciones, lo que siempre es más complicado) tiene un precio a ser pagado. En este contexto, el precio consiste en la pérdida de diferenciabilidad, o en la inevitable singularidad de una solución, como veremos a seguir. En un cierto sentido, la primera dificultad no es tan grave así, y actualmente es considerada preferible a la segunda.

Recordamos que una función $\psi : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$ se llama *función de complementaridad*, si el conjunto de soluciones de la ecuación

$$\psi(a, b) = 0$$

coincide con el conjunto de soluciones del sistema

$$a \geq 0, \quad b \geq 0, \quad ab = 0.$$

Como ya mencionamos en § 1.6, entre las funciones de complementaridad más populares están el *residuo natural*

$$\psi(a, b) = \min\{a, b\}, \quad a, b \in \mathbb{R}, \quad (10.127)$$

y la función de Fischer-Burmeister

$$\psi(a, b) = \sqrt{a^2 + b^2} - a - b, \quad a, b \in \mathbb{R}. \quad (10.128)$$

Proposición 10.4 (Semi-diferenciabilidad de las reformulaciones del sistema KKT). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en $\mathbb{R}^n$, con derivadas semi-diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Entonces para todo $\lambda \in \mathbb{R}^l$ y $\mu \in \mathbb{R}^m$, la función Φ dada por (??), donde la función ψ es dada por (10.127), o por (10.128), es semi-diferenciable en el punto $(\bar{x}, \lambda, \mu)$.

Si f, h y g son dos veces diferenciables en una vecindad de $\bar{x}$, con derivadas segundas Lipschitz-continuas en esta vecindad, entonces Φ es fuertemente semi-diferenciable en $(\bar{x}, \lambda, \mu)$.

Ahora probaremos un resultado que garantiza la regularidad de las soluciones de la reformulación no-diferenciable del sistema KKT en el caso de la función de complementaridad del residuo natural (10.127).

Proposición 10.5 (Regularidad de la reformulación del sistema KKT en el caso del residuo natural). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en $\mathbb{R}^n$, dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$, con derivadas primeras Lipschitz-continuas en una vecindad de $\bar{x}$. Supongamos que $\bar{x}$ satisfaga la condición de independencia lineal de los gradientes de las restricciones activas (??), y que $\bar{x}$ sea un punto estacionario del problema (10.123), con (únicos) multiplicadores de Lagrange asociados $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$. Finalmente, supongamos que valga la condición suficiente de segunda orden fuerte, i.e., que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle > 0 \quad \forall d \in \mathcal{H}_+(\bar{x}) \setminus \{0\}, \quad (10.129)$$

donde

$$\mathcal{H}_+(\bar{x}) = \{d \in \ker h'(\bar{x}) \mid \langle g'_i(\bar{x}), d \rangle = 0 \forall i \in I_+(\bar{x})\},$$

$$I_+(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i > 0\}.$$

Entonces la función Φ definida en (??), con ψ dada por (10.127), es CD-regular (luego, también BD-regular) en el punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$.

Prueba. Para cualquier matriz $H \in \partial\Phi(\bar{x}, \bar{\lambda}, \bar{\mu})$, por las reglas del diferencial de Clarke, es posible que los últimos m componentes de la función Φ tengan que ser reindexados para obtener esta representación, lo que puede ser hecho en este contexto sin cambiar las propiedades del problema): existe un conjunto de índices $J_0 \subset I_0(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i = 0\}$

tal que, definiendo $J_+ = I(\bar{x}) \setminus J_0$ y $J_- = \{1, \dots, m\} \setminus I(\bar{x})$, se tiene que

$$H = \begin{pmatrix} L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) & (h'(\bar{x}))^T & (g'_{J_+}(\bar{x}))^T & (g'_{J_0}(\bar{x}))^T & (g'_{J_-}(\bar{x}))^T \\ h'(\bar{x}) & 0 & 0 & 0 & 0 \\ -g'_{J_+}(\bar{x}) & 0 & 0 & 0 & 0 \\ -Ag'_{J_0}(\bar{x}) & 0 & 0 & E_{J_0} - A & 0 \\ 0 & 0 & 0 & 0 & E_{J_-} \end{pmatrix},$$

donde $A(\bar{x}, \bar{\mu})$ y $B(\bar{x}, \bar{\mu})$ son las matrices diagonales $m \times m$ con elementos $a_i = a_i(\bar{x}, \bar{\mu})$ y $b_i = b_i(\bar{x}, \bar{\mu})$, $i = 1, \dots, m$, definidos en (??) y (??), respectivamente.

Para $\bar{u} = (\bar{x}, \bar{\lambda}, \bar{\mu}) \in \ker H$ cualquiera, tenemos que

$$L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{x} + (h'(\bar{x}))^T \bar{\lambda} + (g'(\bar{x}))^T \bar{\mu} = 0, \quad (10.130)$$

donde A es la matriz diagonal $|J_0| \times |J_0|$ con elementos $a_i \in [0, 1]$, $i = 1, \dots, |J_0|$; para el conjunto de índices $J \subset \{1, \dots, m\}$, E_J es la matriz identidad $|J| \times |J|$; $g'_J(\bar{x})$ es la matriz compuesta por las líneas de la matriz $g'(\bar{x})$ con índices en J .

Tomamos cualquier

$$\bar{u} = (\bar{x}, \bar{\lambda}, \bar{\mu}^+, \bar{\mu}^0, \bar{\mu}^-) \in \ker H,$$

donde $\bar{x} \in \mathbb{R}^n$, $\bar{\lambda} \in \mathbb{R}^l$, $\bar{\mu}^+ \in \mathbb{R}^{|J_+|}$, $\bar{\mu}^0 \in \mathbb{R}^{|J_0|}$, $\bar{\mu}^- \in \mathbb{R}^{|J_-|}$. Tenemos entonces que

$$L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{x} + (h'(\bar{x}))^T \bar{\lambda} + (g'_{J_+}(\bar{x}))^T \bar{\mu}^+ + (g'_{J_0}(\bar{x}))^T \bar{\mu}^0 + (g'_{J_-}(\bar{x}))^T \bar{\mu}^- = 0, \quad (10.131)$$

$$h'(\bar{x})\bar{x} = 0, \quad (10.132)$$

$$\langle g'_i(\bar{x}), \bar{x} \rangle = 0, \quad i \in J_+, \quad (10.133)$$

$$-a_i \langle g'_i(\bar{x}), \bar{x} \rangle + (1 - a_i) \bar{\mu}_i^0 = 0, \quad i \in J_0, \quad (10.134)$$

$$\bar{\mu}_i^- = 0. \quad (10.135)$$

Como

$$I_+(\bar{x}) = I(\bar{x}) \setminus I_0(\bar{x}) \subset I(\bar{x}) \setminus J_0 = J_+,$$

de (10.132) y (10.133) obtenemos que

$$\bar{x} \in \mathcal{K}_+(\bar{x}).$$

Multiplicando los dos lados en (10.131) por $\bar{x}$ y utilizando (10.132)-(10.135), obtenemos que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{x}, \bar{x} \rangle + \sum_{i \in J_0} \bar{\mu}_i^0 \langle g'_i(\bar{x}), \bar{x} \rangle = 0. \quad (10.136)$$

Ahora, multiplicando (10.134) por $\bar{\mu}_i^0$, para todo $i \in J_0$ tenemos que

$$a_i \bar{\mu}_i^0 \langle g'_i(\bar{x}), \bar{x} \rangle = (1 - a_i) (\bar{\mu}_i^0)^2.$$

Como $a_i \in [0, 1]$, se sigue que

$$\bar{\mu}_i^0 \langle g'_i(\bar{x}), \bar{x} \rangle \geq 0 \quad \forall i \in J_0.$$

Ahora, de (10.136), tenemos

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{x}, \bar{x} \rangle \leq 0,$$

donde $\bar{x} \in \mathcal{K}_+(\bar{x})$. De (10.129) concluimos que $\bar{x} = 0$. Además de esto, utilizando (10.135), de (10.131) obtenemos que

$$(h'(\bar{x}))^T \bar{\lambda} + (g'_{J_+}(\bar{x}))^T \bar{\mu}^+ + (g'_{J_0}(\bar{x}))^T \bar{\mu}^0 = 0,$$

donde $J_+ \cup J_0 = I(\bar{x})$. Esta relación y la condición (??) de independencia lineal de los gradientes de las restricciones activas en $\bar{x}$, se sigue que $\bar{\lambda} = 0$, $\bar{\mu}^+ = 0$, $\bar{\mu}^0 = 0$, i.e., $\bar{u} = 0$. Acabamos de mostrar que para todo $H \in \partial \Phi(\bar{x}, \bar{\lambda}, \bar{\mu})$, se tiene que $\ker H = \{0\}$. ■

Consideremos ahora el caso de la función de complementaridad de Fischer-Burmeister (10.128).

Proposición 10.6 (Regularidad de la reformulación del sistema KKT en el caso de la función de Fischer-Burmeister). *Bajo las hipótesis de la Proposición 10.5, la función Φ definida por (??), con la función ψ dada en (10.128), es CD-regular (luego, también BD-regular) en el punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$.*

Prueba. Para una matriz $H \in \partial\Phi(\bar{x}, \bar{\lambda}, \bar{\mu})$ cualquiera,

$$H = \begin{pmatrix} L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) & (h'(\bar{x}))^\top & (g'(\bar{x}))^\top \\ h'(\bar{x}) & 0 & 0 \\ A(\bar{x}, \bar{\mu})g'(\bar{x}) & 0 & B(\bar{x}, \bar{\mu}) \end{pmatrix},$$

donde $A(\bar{x}, \bar{\mu})$ y $B(\bar{x}, \bar{\mu})$ son las matrices diagonales $m \times m$ con elementos $a_i = a_i(\bar{x}, \bar{\mu})$ y $b_i = b_i(\bar{x}, \bar{\mu})$, $i = 1, \dots, m$, definidos en (??) y (??), respectivamente.

Para $\tilde{u} = (\tilde{x}, \tilde{\lambda}, \tilde{\mu}) \in \ker H$ cualquiera, tenemos que

$$L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\tilde{x} + (h'(\bar{x}))^\top \tilde{\lambda} + (g'(\bar{x}))^\top \tilde{\mu} = 0, \quad (10.137)$$

$$h'(\bar{x})\tilde{x} = 0, \quad (10.138)$$

$$a_i \langle g'_i(\bar{x}), \tilde{x} \rangle + b_i \tilde{\mu}_i = 0, \quad i = 1, \dots, m. \quad (10.139)$$

Notemos que, de acuerdo con (??) y (??), para $i \in I_+(\bar{x})$ tenemos que $a_i = 1$, $b_i = 0$. Por lo tanto, de (10.139) se sigue que

$$\langle g'_i(\bar{x}), \tilde{x} \rangle = 0 \quad \forall i \in I_+(\bar{x}). \quad (10.140)$$

En particular, de (10.138) y (10.140) obtenemos que

$$\tilde{x} \in \mathcal{K}_+(\bar{x}).$$

Por las relaciones (??) y (??), para $i \in \{1, \dots, m\} \setminus I(\bar{x})$ se tiene $a_i = 0$, $b_i = -1$, y para $i \in I_0(\bar{x}) = \{i \in I(\bar{x}) \mid \tilde{\mu}_i = 0\}$ se tiene que $a_i \geq 1$, $b_i \leq 0$. Por lo tanto, de (10.139) obtenemos

$$\tilde{\mu}_i = 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}), \quad (10.141)$$

$$\tilde{\mu}_i \langle g'_i(\bar{x}), \tilde{x} \rangle \geq 0 \quad \forall i \in I_0(\bar{x}). \quad (10.142)$$

Multiplicando los dos lados en (10.137) por $\tilde{x}$ y utilizando (10.138), (10.140), (10.141), obtenemos que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\tilde{x}, \tilde{x} \rangle + \sum_{i \in I_0(\bar{x})} \tilde{\mu}_i \langle g'_i(\bar{x}), \tilde{x} \rangle = 0.$$

Teniendo en cuenta (10.142), tenemos que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\tilde{x}, \tilde{x} \rangle \leq 0,$$

y como $\tilde{x} \in \mathcal{K}_+(\bar{x})$, de (10.129) se sigue que $\tilde{x} = 0$. A continuación, utilizando (10.141), de (10.137) obtenemos que

$$(h'(\bar{x}))^\top \tilde{\lambda} + \sum_{i \in I(\bar{x})} \tilde{\mu}_i g'_i(\bar{x}) = 0.$$

La condición de independencia lineal de los gradientes de las restricciones activas (??) ahora implica que $\tilde{\lambda} = 0$, $\tilde{\mu}_i = 0 \forall i \in I(\bar{x})$. Por lo tanto, $\tilde{u} = 0$. Acabamos de mostrar que para todo $H \in \partial\Phi(\bar{x}, \bar{\lambda}, \bar{\mu})$, se tiene que $\ker H = \{0\}$. ■

Los resultados anteriores justifican la resolución del sistema KKT del problema (10.123) por los métodos de Newton generalizados.

Algoritmo 4.5.2. (Método de Newton generalizado para el sistema KKT)

Elegir $\psi : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$, de acuerdo con (10.127) o (10.128). Elegir $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ y tomar $k := 0$.

1. Calcular una matriz $H_k \in \mathbb{R}(n+l+m, n+l+m)$. Calcular $(x^{k+1}, \lambda^{k+1}, \mu^{k+1}) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$, una solución del sistema de ecuaciones lineales

$$H_k((x, \lambda, \mu) - (x^k, \lambda^k, \mu^k)) = -\Phi(x^k, \lambda^k, \mu^k),$$

en relación a $(x, \lambda, \mu) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$, donde Φ es dada por (??).

2. Tomar $k := k + 1$ y retornar al Paso 1.

Si para cada iteración k en el método presentado arriba tomamos $H_k \in \partial_B \Phi(x^k, \lambda^k, \mu^k)$ o $H_k \in \partial \Phi(x^k, \lambda^k, \mu^k)$, obtenemos el método de Newton generalizado puro para el sistema KKT. Para cualquiera de estas matrices pueden ser utilizadas fórmulas dadas arriba (vea los Ejercicios 4.5.3 y 4.5.4). Esto torna los métodos en cuestión completamente

explícitos e implementables (hablaremos sobre las elecciones de H_k también más adelante). Resultados de convergencia local y de tasa de convergencia para métodos de Newton generalizados puros para el sistema KKT siguen directamente del Teorema 4.5.1 y de las Proposiciones 10.4–10.6.

Teorema 10.17 (Convergencia local del método de Newton generalizado para el sistema KKT). *Además de las hipótesis de la Proposición 10.5, supongamos que las funciones $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ sean dos veces diferenciables en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivadas segundas Lipschitz-continuas en esta vecindad. Entonces cualquier punto inicial $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$, suficientemente próximo a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, define unívocamente una secuencia del Algoritmo 4.5.2, donde $H_k \in \partial\Phi(x^k, \lambda^k, \mu^k)$ para todo $k = 0, 1, \dots$, y esta secuencia converge a $(\bar{x}, \bar{\lambda}, \bar{\mu})$. La tasa de convergencia es cuadrática.*

Notemos que, de acuerdo con el Ejercicio 4.5.3, la función Φ definida por (??) con ψ dada en (10.127), es BD -regular en el punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$ se, y solamente si, este punto satisface la condición de cuasi-regularidad que consiste en lo siguiente: la matriz

$$\begin{pmatrix} L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) & (h'(\bar{x}))^\top & (g'_{I_+(\bar{x})}(\bar{x}))^\top & (g'_J(\bar{x}))^\top \\ h'(\bar{x}) & 0 & 0 & 0 \\ g'_{I_+(\bar{x})}(\bar{x}) & 0 & 0 & 0 \\ g'_J(\bar{x}) & 0 & 0 & 0 \end{pmatrix}$$

es no-singular para todo conjunto de índices $J \subset I_0(\bar{x})$. La condición de cuasi-regularidad contiene la condición de independencia lineal de los gradientes de las restricciones activas (??). Mas en el caso en que (??) es satisfecha, la cuasi-regularidad es una condición más débil de lo que la condición suficiente de segunda orden fuerte. Como se sigue del Teorema 4.5.1, la condición de cuasi-regularidad es suficiente para probar la convergencia cuadrática del método de Newton generalizado asociado a la función ψ dada en (10.127).

Notemos también que las hipótesis de diferenciabilidad del Teorema 10.17 pueden ser relajadas de acuerdo con la Proposición 4.5.1. En este caso, podemos probar convergencia superlineal en vez de cuadrática.

10.6. Programación cuadrática secuencial

Como sugiere el nombre, los métodos de programación cuadrática secuencial (SQP)¹ consisten en la resolución de una secuencia de problemas de programación cuadrática (i.e., de minimización de una función cuadrática sujeta a restricciones lineales o afines), aproximando, en cada iteración, un problema original dado. Un problema de programación cuadrática adecuadamente construido puede ser una buena aproximación del problema original, al mismo tiempo que su resolución es relativamente fácil. En particular, los problemas de programación cuadrática admiten varios métodos bien eficientes, inclusive algunos con convergencia finita (vea la ??). Por eso, esta estrategia tiene sentido práctico, a diferencia de la utilización de aproximaciones de tercera orden, cuarta, etc.

Por otro lado, los métodos SQP pueden ser pensados como una generalización natural de la idea fundamental del método de Newton clásico. A propósito, como veremos más adelante, en el caso de restricciones de igualdad, los métodos SQP pueden ser considerados como una implementación específica del método de Newton aplicado al sistema de Lagrange asociado al problema. En el caso en que hay restricciones de desigualdad, esta equivalencia deja de existir, pero la relación con el método de Newton es clara en este caso también.

Los métodos SQP son considerados entre los más eficientes métodos de optimización de uso general. Para resolver un problema dado, sin estructura especial, con frecuencia se eligen métodos de esta clase.

10.6.1. Restricciones de igualdad

Consideremos el problema

$$\min f(x) \quad \text{sueto a } x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}, \quad (10.143)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ son funciones dos veces diferenciables en $\mathbb{R}^n$.

Sea $x^k \in \mathbb{R}^n$ una aproximación del punto estacionario $\bar{x}$ del problema (10.143). Vamos a aproximar el problema original, en torno a x^k , por un problema de programación cuadrática de la forma

$$\min f(x^k) + \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle H_k(x - x^k), x - x^k \rangle \quad \text{sueto a } x \in D_k, \quad (10.144)$$

¹En inglés: SQP - sequential quadratic programming

donde $D_k = \{x \in \mathbb{R}^n \mid h(x^k) + h'(x^k)(x - x^k) = 0\}$, y $H_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica.

La primera tentativa, que parece natural, sería utilizar la matriz $H_k = f''(x^k)$, i.e., tomar como función objetivo del subproblema la aproximación pura de segunda orden de la función objetivo f del problema original (comparar con el método de Newton restringido en la ??). Sin embargo, consideraciones más finas muestran que esta elección, aparentemente natural, no es de las mejores. Esto tiene que ver con la siguiente observación. La aproximación lineal de las restricciones no puede proveer información sobre la curvatura de las mismas. Sin embargo, intuitivamente, es claro que esta información de segunda orden sobre las restricciones es tan importante como la información de segunda orden sobre la función objetivo (son dos partes del problema distintas, una tan importante como la otra). Agregar términos cuadráticos a las restricciones de los subproblemas los tornaría mucho más difíciles de resolver. Actualmente existen algunas propuestas de métodos de este tipo, que hasta tienen ciertas ventajas teóricas. Pero por ahora no se puede decir que los subproblemas con restricciones cuadráticas se establecieron como una alternativa práctica a los subproblemas con restricciones lineales de SQP. Felizmente, la información de segunda orden sobre las restricciones puede ser pasada al subproblema de otra manera, bastante natural desde el punto de vista Newtoniano, como veremos a continuación. En particular, la propuesta es elegir

$$H_k = L''_{xx}(x^k, \lambda^k), \quad (10.145)$$

donde $\lambda^k \in \mathbb{R}^l$ es una aproximación al multiplicador de Lagrange $\tilde{\lambda}$ asociado al punto estacionario $\bar{x}$, y

$$L : \mathbb{R}^n \times \mathbb{R}^l \rightarrow \mathbb{R}, \quad L(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle,$$

es la Lagrangiana del problema (10.143). O sea, la información de segunda orden sobre las restricciones es pasada al subproblema vía la función objetivo del mismo. Notamos que el subproblema así obtenido continúa siendo de programación cuadrática (con función objetivo dada por la aproximación cuadrática de la función $L(\cdot, \lambda^k)$ en torno a x^k , y con conjunto factible dado por la aproximación lineal de las restricciones en torno a x^k).

Otra motivación para esta elección viene dada por la interpretación del problema (10.144) como una implementación de la iteración de Newton para el sistema de Lagrange del problema original (10.143), que fue considerada en la ??. Recordamos que el sistema de Lagrange para el problema en cuestión es

$$L'(x, \lambda) = 0, \quad (10.146)$$

y una iteración de Newton para este sistema consiste en la resolución del sistema lineal

$$L''_{xx}(x^k, \lambda^k)(x - x^k) + (h'(x^k))^T(\lambda - \lambda^k) = -f'(x^k) - (h'(x^k))^T \lambda^k, \quad (10.147)$$

$$h'(x^k)(x - x^k) = -h(x^k) \quad (10.148)$$

con respecto a $(x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l$, donde $(x^k, \lambda^k) \in \mathbb{R}^n \times \mathbb{R}^l$ es una aproximación dada de la solución de (10.146).

Sea $x^{k+1} \in \mathbb{R}^n$ un punto estacionario del problema (10.144) y $\lambda^{k+1} \in \mathbb{R}^l$ un multiplicador de Lagrange asociado. Esto significa que (x^{k+1}, λ^{k+1}) es una solución del sistema

$$\begin{aligned} f'(x^k) + H_k(x - x^k) + (h'(x^k))^T y &= 0, \\ h(x^k) + h'(x^k)(x - x^k) &= 0 \end{aligned}$$

con respecto a $(x, y) \in \mathbb{R}^n \times \mathbb{R}^l$. Comparando este último sistema con (10.147)-(10.148), vemos que ellos coinciden, si la matriz H_k es elegida de acuerdo con (10.145). Por lo tanto, esta es la elección que corresponde a la idea de métodos Newtonianos. Podemos, entonces, esperar convergencia local rápida bajo hipótesis naturales. Formulamos ahora el método de programación cuadrática secuencial (SQP) para problemas con restricciones de igualdad.

Algoritmo 10.1 (El método de programación cuadrática secuencial). Elegir $(x^0, \lambda^0) \in \mathbb{R}^n \times \mathbb{R}^l$ y tomar $k := 0$.

1. Calcular $x^{k+1} \in \mathbb{R}^n$, un punto estacionario del problema (10.144), donde H_k es dada por (10.145), y calcular $y^{k+1} \in \mathbb{R}^l$, un multiplicador de Lagrange asociado a x^{k+1} .
2. Tomar $\lambda^{k+1} = y^{k+1}$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

Por lo expuesto arriba, para un punto inicial (x^0, λ^0) cualquiera, el Algoritmo 10.1 genera la misma secuencia $\{(x^k, \lambda^k)\}$ que el método de Newton puro aplicado al sistema de Lagrange (10.146), ya considerado en la ??. Por eso, no

hay necesidad de un nuevo análisis (local) del método SQP en este caso. En particular, si las derivadas segundas de las funciones f e h son continuas en el punto $\bar{x}$, y satisfacen la condición de regularidad de las restricciones (??) y la condición suficiente de segunda orden del ??(b), entonces por el ??, inmediatamente tenemos que el método SQP converge localmente a $(\bar{x}, \bar{\lambda})$ con tasa superlineal. Más aún, si las derivadas segundas de f e h son Lipschitz-continuas en una vecindad de $\bar{x}$, entonces la tasa de convergencia es cuadrática.

Como implementación del método de Newton para el sistema de Lagrange, el método SQP tal vez no sea muy útil (por lo menos en el contexto de un estudio local). Esta interpretación es análoga a la de la ?? en el caso del método de Newton para optimización irrestricta y su interpretación vía minimización de funciones cuadráticas. Sin embargo, estas consideraciones son importantes para sugerir estrategias de globalización del esquema local. Además de esto, el método SQP para problemas con restricciones de igualdad sugiere una generalización muy natural para el caso general, cuando hay también restricciones de desigualdad. Esta generalización será presentada a continuación.

10.6.2. Restricciones mixtas

Consideremos ahora un problema de optimización con restricciones de igualdad y desigualdad

$$\min f(x) \quad \text{sueto a } x \in D = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0 \end{array} \right\}, \quad (10.149)$$

donde $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ son dos veces diferenciables en $\mathbb{R}^n$.

Sea $x^k \in \mathbb{R}^n$ una aproximación del punto estacionario $\bar{x}$ del problema (10.149). Una generalización natural del subproblema (10.144) para el caso de restricciones mixtas está dada por

$$\min \langle f'(x^k), d \rangle + \frac{1}{2} \langle H_k d, d \rangle \quad \text{sueto a } d \in D_k, \quad (10.150)$$

$$D_k = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} h(x^k) + h'(x^k)d = 0, \\ g(x^k) + g'(x^k)d \leq 0 \end{array} \right\}. \quad (10.151)$$

El método SQP, por lo tanto, consiste en lo siguiente.

Algoritmo 10.2 (El método de programación cuadrática secuencial). Elegir $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}_+^m$ y tomar $k := 0$.

1. Calcular un punto estacionario $d^k \in \mathbb{R}^n$ del problema (10.150)-(10.151), donde $H_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica, y multiplicadores de Lagrange $y^k \in \mathbb{R}^l, z^k \in \mathbb{R}_+^m$ asociados a d^k .
2. Tomar $x^{k+1} = x^k + d^k, \lambda^{k+1} = y^k, \mu^{k+1} = z^k$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

Por lo observado arriba en el caso de restricciones de igualdad, podemos esperar convergencia rápida del método si elegimos

$$H_k = L''_{xx}(x^k, \lambda^k, \mu^k), \quad (10.152)$$

donde

$$L: \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R}, \quad L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle$$

es la Lagrangiana del problema (10.149). Notemos que si $D_k \neq \emptyset$ y la matriz H_k es definida positiva, el subproblema (10.150)-(10.151) posee una única solución y esta solución también es el único punto estacionario del problema (por el hecho de que la función objetivo es fuertemente convexa y el conjunto factible es convexo). No obstante, cabe mencionar que bajo hipótesis naturales (tales como la condición suficiente de segunda orden para el problema (10.149)) no es posible garantizar que la matriz H_k dada por (10.152) sea definida positiva, aun para x^k próximo a $\bar{x}$, y λ^k, μ^k próximos a $\bar{\lambda}$ y $\bar{\mu}$, respectivamente (comparar con la motivación para la introducción de Lagrangianas aumentadas en la ??, y con el Ejercicio 10.49). Por eso, la existencia de puntos estacionarios del subproblema (10.150)-(10.151) no es automática y tiene que ser probada como parte del análisis local del método. Además, incluso cuando un punto estacionario existe, él puede no ser único. Por eso, en el análisis local suponemos que d^k sea el punto estacionario del subproblema (10.150)-(10.151) de menor norma. En la práctica, este requerimiento es simplemente ignorado.

Teorema 10.18 (Convergencia local del método SQP). Sean funciones $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ dos veces diferenciables en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivadas segundas continuas en este punto. Sea $\bar{x}$ un punto estacionario del problema (10.149) que satisface la condición de independencia lineal de los gradientes de las restricciones activas (??). Supongamos que $\bar{x}$, con los (únicos) multiplicadores de Lagrange asociados $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$, satisface la condición suficiente de segunda orden del ??(b). Supongamos, finalmente, la condición de complementariedad estricta

$$\bar{\mu}_i > 0 \quad \forall i \in I(\bar{x}) = \{i = 1, \dots, m \mid g_i(\bar{x}) = 0\}. \quad (10.153)$$

Entonces para cualquier punto inicial $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ suficientemente próximo a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, el Algoritmo 10.2, donde H_k es dada por (10.152) y d^k es el punto estacionario de (10.150)-(10.151) con menor norma, está bien definido. La secuencia generada por el método converge a $(\bar{x}, \bar{\lambda}, \bar{\mu})$. La tasa de convergencia es superlineal. Más aún, si las derivadas segundas de f , h y g son Lipschitz-continuas en una vecindad del punto $\bar{x}$, entonces la tasa de convergencia es cuadrática.

Prueba. Denotamos $U = \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$. Primero, tenemos que probar que para $(x^k, \lambda^k, \mu^k) \in U$ suficientemente próximo a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, el subproblema (10.150)-(10.151) posee un único punto estacionario d^k de menor norma y que este punto tiene un único par de multiplicadores de Lagrange (y^k, z^k) asociado. Consideremos el sistema KKT del subproblema (10.150)-(10.151):

$$f'(x^k) + L''_{xx}(x^k, \lambda^k, \mu^k)d + (h'(x^k))^T y + (g'(x^k))^T z = 0, \quad (10.154)$$

$$h(x^k) + h'(x^k)d = 0, \quad (10.155)$$

$$g(x^k) + g'(x^k)d \leq 0, \quad z \geq 0, \quad (10.156)$$

$$z_i(g_i(x^k) + \langle g'_i(x^k), d \rangle) = 0, \quad i = 1, \dots, m, \quad (10.157)$$

con respecto a $(d, y, z) \in U$. Notemos primero que si x^k es suficientemente próximo a $\bar{x}$ y $d \in \mathbb{R}^n$ tiene norma suficientemente pequeña, no puede existir más de un par de multiplicadores $(y, z) \in \mathbb{R}^l \times \mathbb{R}^m$ tales que el punto (d, y, z) satisfaga (10.154)-(10.157). En efecto, para tales x^k y d , se tiene que

$$g_i(x^k) + \langle g'_i(x^k), d \rangle < 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}),$$

por la continuidad de las funciones involucradas, y de (10.157),

$$z_i = 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}).$$

En particular, para el conjunto de los índices J^k de las restricciones activas en la solución del subproblema (10.150)-(10.151), se tiene que $J^k \subset I(\bar{x})$. Los gradientes de estas restricciones forman, entonces, un subconjunto de

$$\{h'_i(x^k), i = 1, \dots, l\} \cup \{g'_i(x^k), i \in I(\bar{x})\}$$

que es linealmente independiente para x^k próximo a $\bar{x}$ (por la continuidad y por la hipótesis de independencia lineal de los gradientes en el punto $\bar{x}$). Concluimos entonces que los gradientes de las restricciones activas son linealmente independientes en el subproblema (10.150)-(10.151). Esto implica que no puede haber más de un par de multiplicadores de Lagrange en el sistema (10.154)-(10.157).

Definimos la función $\Phi: U \times U \rightarrow U$,

$$\Phi(w, u) = \begin{pmatrix} f'(x) + L''_{xx}(x, \lambda, \mu)d + (h'(x))^T y + (g'(x))^T z \\ h(x) + h'(x)d \\ z_1(g_1(x) + \langle g'_1(x), d \rangle) \\ \vdots \\ z_m(g_m(x) + \langle g'_m(x), d \rangle) \end{pmatrix},$$

$$w = (x, \lambda, \mu), \quad u = (d, y, z).$$

El sistema

$$\Phi(w, u) = 0,$$

donde $w \in U$ hace el papel de parámetro, corresponde a las ecuaciones (10.154), (10.155), (10.157).

Por las definiciones de punto estacionario del problema (10.149) y de multiplicadores de Lagrange asociados, tenemos $\Phi(\bar{w}, \bar{u}) = 0$, donde $\bar{w} = (\bar{x}, \bar{\lambda}, \bar{\mu})$, $\bar{u} = (0, \bar{\lambda}, \bar{\mu})$. Además de eso,

$$\Phi'_u(\bar{w}, \bar{u}) = \begin{pmatrix} L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) & (h'(\bar{x}))^\top & (g'(\bar{x}))^\top \\ h'(\bar{x}) & 0 & 0 \\ \bar{\mu}_1(g'_1(\bar{x}))^\top & 0 & 0 \\ \vdots & \vdots & \vdots \\ \bar{\mu}_m(g'_m(\bar{x}))^\top & 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & \text{diag}(g_i(\bar{x})) \end{pmatrix},$$

donde $\text{diag}(g_i(\bar{x}))$ es la matriz diagonal con entradas $g_i(\bar{x})$ para $i = 1, \dots, m$.

Tomamos $\bar{u} = (\bar{d}, \bar{y}, \bar{z}) \in \ker \Phi'_u(\bar{w}, \bar{u})$, arbitrario, i.e.,

$$L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{d} + (h'(\bar{x}))^\top \bar{y} + (g'(\bar{x}))^\top \bar{z} = 0, \quad (10.158)$$

$$h'(\bar{x})\bar{d} = 0, \quad (10.159)$$

$$\bar{\mu}_i \langle g'_i(\bar{x}), \bar{d} \rangle + g_i(\bar{x})\bar{z}_i = 0, \quad i = 1, \dots, m. \quad (10.160)$$

De (10.160) y de la condición de complementariedad estricta (10.153), tenemos que

$$\bar{z}_i = 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}), \quad \langle g'_i(\bar{x}), \bar{d} \rangle = 0 \quad \forall i \in I(\bar{x}). \quad (10.161)$$

Además de eso, bajo la condición de complementariedad estricta (10.153) tenemos que el cono crítico del problema (10.149) en el punto $\bar{x}$ tiene la siguiente forma:

$$\mathcal{K}(\bar{x}) = \{v \in \ker h'(\bar{x}) \mid \langle g'_i(\bar{x}), v \rangle = 0 \quad \forall i \in I(\bar{x})\}. \quad (10.162)$$

Por tanto, de (10.159) y (10.161), tenemos que $\bar{d} \in \mathcal{K}(\bar{x})$. Multiplicando ambos lados de (10.158) por $\bar{d}$, obtenemos que

$$\begin{aligned} 0 &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{d}, \bar{d} \rangle + \langle \bar{y}, h'(\bar{x})\bar{d} \rangle + \langle \bar{z}, g'(\bar{x})\bar{d} \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{d}, \bar{d} \rangle + \sum_{i=1}^m \bar{z}_i \langle g'_i(\bar{x}), \bar{d} \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{d}, \bar{d} \rangle, \end{aligned}$$

donde utilizamos (10.159) y (10.161). Esto significa que $\bar{d} = 0$ (pues en caso contrario, la condición suficiente de segunda orden en el punto $\bar{x}$ sería violada). De (10.158) y (10.161), ahora se sigue que

$$(h'(\bar{x}))^\top \bar{y} + \sum_{i \in I(\bar{x})} \bar{z}_i g'_i(\bar{x}) = 0.$$

Por la condición (??) de independencia lineal de los gradientes de las restricciones activas en $\bar{x}$, obtenemos que $\bar{y} = 0$ y $\bar{z}_i = 0 \quad \forall i \in I(\bar{x})$. Acabamos de probar que $\bar{u} = (\bar{d}, \bar{y}, \bar{z}) = 0$, i.e., la matriz $\Phi'_u(\bar{w}, \bar{u})$ es no-singular.

Aplicando a la función Φ en el punto $(\bar{w}, \bar{u})$ el Teorema de la Función Implícita (??), concluimos que existen vecindades W del punto $\bar{w}$ y V del punto $\bar{u}$ en U , para las cuales existe una única función $\chi(\cdot) = (d(\cdot), y(\cdot), z(\cdot)) : W \rightarrow U$ continua en el punto $\bar{w}$ tal que $\chi(W) \subset V$ y

$$\Phi(w, \chi(w)) = 0 \quad \forall w \in W. \quad (10.163)$$

En particular, $d(\bar{w}) = 0$, $y(\bar{w}) = \bar{\lambda}$, $z(\bar{w}) = \bar{\mu}$. De aquí, de la continuidad de $\chi(\cdot)$ en $\bar{w}$, y de la condición de complementariedad estricta (10.153), obtenemos que para una vecindad W suficientemente pequeña, $\forall w = (x, \lambda, \mu) \in W$ se tiene que

$$g_i(x) + \langle g'_i(x), d(w) \rangle < 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}), \quad (10.164)$$

$$z_i(w) > 0 \quad \forall i \in I(\bar{x}). \quad (10.165)$$

Teniendo en cuenta la definición de la función Φ , las relaciones (10.163)-(10.165) significan que, para $w^k = (x^k, \lambda^k, \mu^k) \in W$, el sistema (10.154)-(10.157) posee en V una única solución, que es $(d(w^k), y(w^k), z(w^k))$. Por el hecho de que los multiplicadores tienen que ser únicos (ya justificado arriba), podemos afirmar que si la vecindad W es suficientemente pequeña, esta solución es única no solamente en V sino también en el conjunto $\tilde{V} \times \mathbb{R}^l \times \mathbb{R}^m$, donde $\tilde{V}$ es una vecindad de 0 en $\mathbb{R}^n$. De aquí se sigue que $d^k = d(w^k)$ es el único punto estacionario del problema (10.150)-(10.151) de menor norma, y $(y^k, z^k) = (y(w^k), z(w^k))$ es el único par de multiplicadores de Lagrange asociado a d^k .

Observamos que, por (10.164) y (10.165), para $(x^k, \lambda^k, \mu^k) \in W$ las condiciones (10.156) y (10.157) en el sistema (10.154)-(10.157), que define (d^k, y^k, z^k) , pueden ser sustituidas por

$$g_i(x^k) + \langle g'_i(x^k), d \rangle = 0 \quad i \in I(\bar{x}), \quad (10.166)$$

$$z_i = 0 \quad i \in \{1, \dots, m\} \setminus I(\bar{x}). \quad (10.167)$$

En particular, una iteración del método es equivalente al cálculo de la solución (d^k, y^k, z^k) del sistema de ecuaciones lineales (10.154), (10.155), (10.166), (10.167).

Consideremos el problema con restricciones de igualdad

$$\min f(x) \quad \text{sujeto a } x \in \tilde{D},$$

$$\tilde{D} = \{x \in \mathbb{R}^n \mid h(x) = 0, g_i(x) = 0, i \in I(\bar{x})\}.$$

Como es fácil ver, bajo nuestras hipótesis el punto $\bar{x}$ es una solución local de este problema que satisface la condición de regularidad de las restricciones y la condición suficiente de segunda orden (problemas con restricciones de igualdad; vea la ??). Por lo tanto, si agregamos al sistema de Lagrange correspondiente las ecuaciones

$$\mu_i = 0, \quad i \in \{1, \dots, m\} \setminus I(\bar{x}),$$

el sistema de ecuaciones con respecto a $(x, \lambda, \mu) \in U$ así obtenido tendrá una solución $(\bar{x}, \bar{\lambda}, \bar{\mu})$ que es regular (en el sentido de que la derivada de este sistema en esta solución es no-singular). De acuerdo con el ??, el método de Newton para este sistema converge (localmente) a la solución con tasa superlineal, y si las derivadas segundas de f, h y g son Lipschitz-continuas en una vecindad del punto $\bar{x}$, la tasa de convergencia es cuadrática.

Como es fácil ver, para una aproximación (x^k, λ^k, μ^k) dada, una iteración del método de Newton consiste en un paso d^k al punto $(x^k + d^k, y^k, z^k)$, donde (d^k, y^k, z^k) es la solución del sistema que consiste en las ecuaciones (10.155), (10.166), (10.167) y en la ecuación

$$\begin{aligned} L''_{xx}(x^k, \lambda^k, \mu^k)d - \sum_{i=1}^m \mu_i^k g_i''(x^k)d \\ + (h'(x^k))^T y + \sum_{i \in I(\bar{x})} z_i g_i'(x^k) = -f'(x^k). \end{aligned} \quad (10.168)$$

Notemos que la única diferencia entre (10.168) y (10.154) es el segundo término en el lado izquierdo de (10.168) (aquí tomamos en cuenta (10.167)). Pero como $\bar{\mu}_i = 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x})$, existe un número $M > 0$ tal que para todo $x \in \mathbb{R}^n$ suficientemente próximo a $\bar{x}$ y todo $\mu \in \mathbb{R}^m$ suficientemente próximo a $\bar{\mu}$, se tiene que

$$\left\| \sum_{i=1}^m \mu_i g_i''(x) \right\| \leq \sum_{i \notin I(\bar{x})} |\mu_i - \bar{\mu}_i| \|g_i''(x)\| \leq M \|\mu - \bar{\mu}\|.$$

Esto significa que el algoritmo cuya iteración está dada por las ecuaciones (10.154), (10.155), (10.166) y (10.167), puede ser pensado como un método de Newton inexacto con iteraciones determinadas por las ecuaciones (10.155), (10.166), (10.167) y (10.168). Por el ??, las propiedades locales y la tasa de convergencia de este método son completamente análogas a aquellas del método de Newton^a. ■

^aDe hecho, teniendo en cuenta (10.167), puede verse que para la secuencia $\{(x^k, \lambda^k, \mu^k)\}$ generada por el método, se tiene que $\mu_i^k = 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}), \forall k \geq 2$, i.e., ya a partir de la segunda iteración el método funciona como un método de Newton exacto.

Cabe mencionar que la convergencia cuadrática de la secuencia $\{(x^k, \lambda^k, \mu^k)\}$ a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, en principio no implica la convergencia cuadrática (ni siquiera superlineal) de la secuencia $\{x^k\}$ a $\bar{x}$ (vea el ??). Sin embargo, con frecuencia la convergencia rápida en las variables primales es lo que interesa más en las aplicaciones. Este asunto será investigado a continuación. Al mismo tiempo, consideremos la posibilidad de elegir las matrices H_k para satisfacer (10.152) de manera inexacta, siguiendo los principios de la condición de Dennis-Moré (vea el ??). Algunas maneras concretas para construir H_k con tales propiedades pueden ser consultadas en [20].

Teorema 10.19 (Convergencia superlineal primal del método SQP). *Supongamos que valen las hipótesis del Teorema 10.18 con excepción, tal vez, de la condición de complementariedad estricta. Supongamos que la secuencia $\{(x^k, \lambda^k, \mu^k)\}$ del Algoritmo 10.2 converge a $(\bar{x}, \bar{\lambda}, \bar{\mu})$.*

Entonces la tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal si, y solamente si,

$$P_{\mathcal{H}(\bar{x})}((H_k - L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}))(x^{k+1} - x^k)) = o(\|x^{k+1} - x^k\|), \quad (10.169)$$

donde

$$\mathcal{H}(\bar{x}) = \{h \in \ker h'(\bar{x}) \mid \langle g_i(\bar{x}), h \rangle \leq 0 \quad \forall i \in I(\bar{x}), \langle f'(\bar{x}), h \rangle \leq 0\}$$

es el cono crítico del problema (10.149).

Prueba. Recordamos que por la construcción del Algoritmo 10.2, el punto $(d^k, \lambda^{k+1}, \mu^{k+1})$ (donde $d^k = x^{k+1} - x^k$) satisface las condiciones KKT para el problema (10.150)-(10.151), i.e.,

$$f'(x^k) + H_k d^k + (h'(x^k))^T \lambda^{k+1} + (g'(x^k))^T \mu^{k+1} = 0, \quad (10.170)$$

$$h(x^k) + h'(x^k) d^k = 0, \quad (10.171)$$

$$g(x^k) + g'(x^k) d^k \leq 0, \quad \mu^{k+1} \geq 0, \quad (10.172)$$

$$\mu_i^{k+1} (g_i(x^k) + \langle g'_i(x^k), d^k \rangle) = 0, \quad i = 1, \dots, m. \quad (10.173)$$

De (10.170) obtenemos que

$$\begin{aligned} -H_k d^k &= f'(x^k) + (h'(x^k))^T \lambda^{k+1} + (g'(x^k))^T \mu^{k+1} \\ &= L'_x(x^k, \lambda^{k+1}, \mu^{k+1}) \\ &= L'_x(\bar{x}, \lambda^{k+1}, \mu^{k+1}) + L''_{xx}(\bar{x}, \lambda^{k+1}, \mu^{k+1})(x^k - \bar{x}) \\ &\quad + o(\|x^k - \bar{x}\|) \\ &= (h'(\bar{x}))^T (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^T (\mu^{k+1} - \bar{\mu}) \\ &\quad + L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^k - \bar{x}) + o(\|x^k - \bar{x}\|), \end{aligned} \quad (10.174)$$

donde utilizamos las definiciones de punto estacionario del problema (10.149) y de multiplicadores de Lagrange asociados, así como la convergencia de $\{(\lambda^k, \mu^k)\}$ a $(\bar{\lambda}, \bar{\mu})$. De (10.174), obtenemos que

$$\begin{aligned} &(L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k) d^k \\ &= (h'(\bar{x}))^T (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^T (\mu^{k+1} - \bar{\mu}) \\ &\quad + L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^{k+1} - \bar{x}) + o(\|x^k - \bar{x}\|). \end{aligned} \quad (10.175)$$

Supongamos primero que la tasa de convergencia de $\{x^k\}$ a $\bar{x}$ sea superlineal, i.e., $\|x^{k+1} - \bar{x}\| = o(\|x^k - \bar{x}\|)$. En este caso, (10.175) se escribe como

$$\begin{aligned} &(L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k) d^k \\ &= (h'(\bar{x}))^T (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^T (\mu^{k+1} - \bar{\mu}) \\ &\quad + o(\|x^k - \bar{x}\|). \end{aligned} \quad (10.176)$$

Como $\{d^k\} \rightarrow 0, \{\mu^k\} \rightarrow \bar{\mu}$ ($k \rightarrow \infty$), de (10.173) obtenemos que $\mu_i^{k+1} = 0 \forall i \in \{1, \dots, m\} \setminus I(\bar{x})$, para todo k suficientemente grande. Utilizando la definición de $\mathcal{H}(\bar{x})$ y la segunda desigualdad en (10.172), obtenemos que $\forall v \in \mathcal{H}(\bar{x})$, se tiene que

$$\begin{aligned} &\langle (h'(\bar{x}))^T (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^T (\mu^{k+1} - \bar{\mu}), v \rangle \\ &= \langle \mu^{k+1}, g'(\bar{x}) v \rangle \\ &= \sum_{i \in I(\bar{x})} \mu_i^{k+1} \langle g'_i(\bar{x}), v \rangle \leq 0. \end{aligned} \quad (10.177)$$

Por el ??(c), la última relación implica que

$$P_{\mathcal{H}(\bar{x})}((h'(\bar{x}))^T (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^T (\mu^{k+1} - \bar{\mu})) = 0.$$

De (10.176) obtenemos ahora que

$$P_{\mathcal{H}(\bar{x})}((L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k) d^k) = o(\|x^k - \bar{x}\|). \quad (10.178)$$

Teniendo en cuenta que

$$\|d^k\| \geq \|x^k - \bar{x}\| - \|x^{k+1} - \bar{x}\| = \|x^k - \bar{x}\| + o(\|x^k - \bar{x}\|),$$

la relación (10.178) implica (10.169), porque

$$\frac{o(\|x^k - \bar{x}\|)}{\|d^k\|} \leq \frac{o(\|x^k - \bar{x}\|)}{\|x^k - \bar{x}\| + o(\|x^k - \bar{x}\|)} = \frac{o(\|x^k - \bar{x}\|)/\|x^k - \bar{x}\|}{1 + o(\|x^k - \bar{x}\|)/\|x^k - \bar{x}\|} \rightarrow 0 \quad (k \rightarrow \infty).$$

Supongamos ahora que valga (10.169). Observamos que, por (10.171), se tiene que

$$\begin{aligned} 0 &= h(x^k) + h'(x^k)d^k \\ &= h'(\bar{x})(x^k - \bar{x}) + h'(\bar{x})d^k + o(\|x^k - \bar{x}\|) \\ &= h'(\bar{x})(x^{k+1} - \bar{x}) + \eta^k, \end{aligned} \quad (10.179)$$

donde, tomando en cuenta que $\{x^k\} \rightarrow \bar{x}$,

$$\begin{aligned} \eta^k &= (h'(x^k) - h'(\bar{x}))d^k + o(\|x^k - \bar{x}\|) \\ &= o(\|d^k\|) + o(\|x^k - \bar{x}\|). \end{aligned} \quad (10.180)$$

De modo análogo, de la primera desigualdad en (10.172), de la relación (10.173) y del hecho de que $\{\mu^k\} \rightarrow \bar{\mu}$, obtenemos que

$$0 = g_i(\bar{x}) + \langle g'_i(\bar{x}), x^{k+1} - \bar{x} \rangle + \zeta_i^k \quad \forall i \in I_+(\bar{x}), \quad (10.181)$$

$$0 \geq g_i(\bar{x}) + \langle g'_i(\bar{x}), x^{k+1} - \bar{x} \rangle + \zeta_i^k \quad \forall i \in I_0(\bar{x}), \quad (10.182)$$

$$0 = \mu_i^{k+1}(g_i(\bar{x}) + \langle g'_i(\bar{x}), x^{k+1} - \bar{x} \rangle + \zeta_i^k) \quad \forall i \in I_0(\bar{x}), \quad (10.183)$$

donde $I_+(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i > 0\}$, $I_0(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i = 0\}$, y

$$\zeta_i^k = o(\|d^k\|) + o(\|x^k - \bar{x}\|), \quad i \in I(\bar{x}). \quad (10.184)$$

Por la condición de independencia lineal de los gradientes de las restricciones activas (??) y por las relaciones (10.180) y (10.184), existe un elemento $\xi^k \in \mathbb{R}^n$ tal que

$$h'(\bar{x})\xi^k = \eta^k, \quad \langle g'_i(\bar{x}), \xi^k \rangle = \zeta_i^k \quad \forall i \in I(\bar{x}), \quad (10.185)$$

$$\|\xi^k\| = o(\|d^k\|) + o(\|x^k - \bar{x}\|). \quad (10.186)$$

Definimos $v^k = x^{k+1} - \bar{x} + \xi^k$. De (10.179)-(10.182) y (10.185), tenemos que $v^k \in \mathcal{H}(\bar{x})$. En particular, de modo análogo a (10.177), obtenemos que

$$\begin{aligned} &\langle (h'(\bar{x}))^\top(\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^\top(\mu^{k+1} - \bar{\mu}), v^k \rangle \\ &= \sum_{i \in I(\bar{x})} \mu_i^{k+1} \langle g'_i(\bar{x}), v^k \rangle = 0, \end{aligned}$$

donde la última igualdad se sigue de (10.181) y (10.183). Multiplicando escalarmente ambos lados de (10.175) por v^k y utilizando la relación arriba, obtenemos

$$\langle (L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k)d^k, v^k \rangle = \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^{k+1} - \bar{x}), v^k \rangle + o(\|x^k - \bar{x}\| \|v^k\|). \quad (10.187)$$

Por la condición suficiente de segunda orden existe un número $\gamma > 0$ tal que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})v, v \rangle \geq \gamma \|v\|^2 \quad \forall v \in \mathcal{H}(\bar{x}).$$

Utilizando también (10.187), obtenemos

$$\begin{aligned} \gamma \|v^k\|^2 &\leq \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})v^k, v^k \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^{k+1} - \bar{x} + \xi^k), v^k \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^{k+1} - \bar{x}), v^k \rangle + \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\xi^k, v^k \rangle \\ &= \langle (L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k)d^k, v^k \rangle + o(\|x^k - \bar{x}\| \|v^k\|) \\ &\leq \langle P_{\mathcal{H}(\bar{x})}(L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k)d^k, v^k \rangle \\ &\quad + o(\|d^k\| \|v^k\|) + o(\|x^k - \bar{x}\| \|v^k\|) \\ &= o(\|d^k\| \|v^k\|) + o(\|x^k - \bar{x}\| \|v^k\|), \end{aligned}$$

donde la segunda igualdad se sigue de (10.186), la segunda desigualdad se sigue del ??(c), y la última igualdad se sigue de (10.169). Concluimos que $\|v^k\| = o(\|d^k\|) + o(\|x^k - \bar{x}\|)$. Mas en este caso, por (10.186), obtenemos que

$$\|x^{k+1} - \bar{x}\| = \|v^k - \xi^k\| = o(\|d^k\|) + o(\|x^k - \bar{x}\|).$$

Esto significa que existen secuencias $\{t_k\} \subset \mathbb{R}_+$ y $\{s_k\} \subset \mathbb{R}_+$ tales que $t_k \rightarrow 0$, $s_k \rightarrow 0$ ($k \rightarrow \infty$) y, para todo k ,

$$\begin{aligned} \|x^{k+1} - \bar{x}\| &\leq t_k \|x^{k+1} - x^k\| + s_k \|x^k - \bar{x}\| \\ &\leq \max\{t_k, s_k\} (\|x^{k+1} - \bar{x}\| + 2\|x^k - \bar{x}\|). \end{aligned}$$

De aquí, para todo k suficientemente grande,

$$\|x^{k+1} - \bar{x}\| \leq \frac{2 \max\{t_k, s_k\}}{1 - \max\{t_k, s_k\}} \|x^k - \bar{x}\|,$$

y como $\max\{t_k, s_k\} \rightarrow 0$ ($k \rightarrow \infty$), tenemos que

$$x^{k+1} - \bar{x} = o(\|x^k - \bar{x}\|),$$

i.e., la convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal. ■

Observamos que en el caso de la elección de la matriz H_k de acuerdo con (10.152), la convergencia en las variables primales ciertamente es superlineal, ya que $H_k \rightarrow L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})$ trivialmente cuando $(x^k, \lambda^k, \mu^k) \rightarrow (\bar{x}, \bar{\lambda}, \bar{\mu})$ ($k \rightarrow \infty$) y, por lo tanto, la validez de la condición (10.169) es obvia.

Las hipótesis del Teorema 10.18 que garantizan convergencia local superlineal (en variables primales-duales) del método SQP pueden ser relajadas. Por ejemplo, es posible eliminar la condición de complementariedad estricta, pero a costa de la introducción de una condición de segunda orden más fuerte. Esta condición, llamada condición suficiente de segunda orden fuerte, consiste en lo siguiente:

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})v, v \rangle > 0 \quad \forall v \in \mathcal{H}_+(\bar{x}) \setminus \{0\},$$

donde

$$\mathcal{H}_+(\bar{x}) = \{v \in \ker h'(\bar{x}) \mid \langle g'_i(\bar{x}), v \rangle = 0 \quad \forall i \in I_+(\bar{x})\},$$

$$I_+(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i > 0\}.$$

En el caso de complementariedad estricta, se tiene que $I_+(\bar{x}) = I(\bar{x})$ y, por lo tanto, $\mathcal{H}_+(\bar{x}) = \mathcal{H}(\bar{x})$ y la condición suficiente de segunda orden fuerte coincide con la condición suficiente de segunda orden común.

Investigaciones contemporáneas del método SQP y de diversas modificaciones del mismo tienen por objetivo el relajamiento de las hipótesis utilizadas para garantizar convergencia local superlineal. Desarrollos en esta dirección hacen uso de técnicas mucho más sofisticadas, que están fuera del alcance de este libro. El resultado más fuerte sobre convergencia local superlineal del método SQP (conocido actualmente) está basado en la condición suficiente de segunda orden (común) y en la hipótesis de que el multiplicador de Lagrange asociado a la solución sea único (esta última condición también se llama condición de Mangasarian-Fromovitz estricta; vea [12]).

Finalmente, comentaremos sobre la comparación de los métodos de Newton generalizados para el sistema KKT en la ?? con el método SQP. La convergencia local cuadrática de los métodos de Newton generalizados fue establecida bajo las hipótesis de independencia lineal de los gradientes de las restricciones activas y la condición suficiente de segunda orden fuerte (vea el ??), en cuanto el método SQP precisa de la unicidad del multiplicador de Lagrange y de la condición suficiente de segunda orden común, que son hipótesis mucho más débiles. En compensación, una iteración del método de Newton generalizado consiste en la resolución de un sistema de ecuaciones lineales, lo que tiene un coste computacional mucho menor de lo que la resolución de un problema de programación cuadrática en SQP. Notamos también que la condición (??) en el ??, que es necesaria para la convergencia superlineal en variables primales del método de Newton generalizado, es un poco más débil que la condición correspondiente en el caso de SQP (vea el Teorema 10.19). La estructura de SQP permite varias estrategias de globalización bastante naturales (que serán presentadas a continuación). La globalización del método de Newton generalizado también es posible, pero ella es más difícil y generalmente es menos eficiente desde el punto de vista computacional.

10.6.3. Globalización de convergencia de SQP

Para la globalización del método SQP pueden ser utilizadas tanto la estrategia de búsqueda lineal para una función de mérito adecuada, como la estrategia de regiones de confianza. Nosotros vamos a considerar a la primera opción, cuya implementación en el contexto de SQP es un poco más simple. La segunda opción puede ser consultada, por ejemplo, en [20].

De nuevo, consideremos el problema

$$\min f(x) \quad \text{sujeto a } x \in D = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0 \end{array} \right\}, \quad (10.188)$$

donde $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones suficientemente suaves. Sea

$$L: \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R},$$

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle,$$

la Lagrangiana del problema (10.188).

Como función de mérito en la búsqueda lineal en los métodos SQP, típicamente es utilizada alguna función de penalización exacta (vea la ??) para el problema (10.188). Por ejemplo, una elección común viene dada por

$$\varphi(\cdot; c): \mathbb{R}^n \rightarrow \mathbb{R}, \quad \varphi(x; c) = f(x) + c\psi(x), \quad (10.189)$$

donde

$$\psi(x) = \|h(x)\|_1 + \sum_{i=1}^m \max\{0, g_i(x)\}, \quad x \in \mathbb{R}^n, \quad (10.190)$$

y $c > 0$ es el parámetro de penalización.

Cabe resaltar que en esta sección, la cuestión de la tasa de convergencia de métodos SQP globalizados no será abordada. El objetivo consiste en garantizar convergencia global, en algún sentido, a puntos estacionarios del problema. El asunto de la interferencia de métodos globalizados con la tasa de convergencia local, así como las posibles modificaciones propuestas para evitar esto, serán considerados en la apartado 10.6.4.

Algoritmo 10.3 (El método SQP globalizado). Elegir los parámetros $\bar{c} > 0$, $\theta \in (0, 1)$ y $\sigma \in (0, 1)$. Elegir $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ y una matriz simétrica $H_0 \in \mathbb{R}^{n \times n}$. Tomar $k := 0$.

1. Calcular $d^k \in \mathbb{R}^n$, un punto estacionario del subproblema de programación cuadrática

$$\min \langle f'(x^k), d \rangle + \frac{1}{2} \langle H_k d, d \rangle \quad \text{sujeto a } d \in D_k, \quad (10.191)$$

$$D_k = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} h(x^k) + h'(x^k)d = 0, \\ g(x^k) + g'(x^k)d \leq 0 \end{array} \right\}, \quad (10.192)$$

y multiplicadores de Lagrange $y^k \in \mathbb{R}^l$ y $z^k \in \mathbb{R}_+^m$ asociados a d^k .

2. Si $d^k = 0$, parar. Caso contrario, elegir

$$c_k \geq \bar{c} + \|(y^k, z^k)\|_\infty \quad (10.193)$$

y calcular

$$\Delta_k = \langle f'(x^k), d^k \rangle - c_k \psi(x^k). \quad (10.194)$$

Tomar $\alpha = 1$.

3. Si la desigualdad

$$\varphi(x^k + \alpha d^k; c_k) \leq \varphi(x^k; c_k) + \sigma \alpha \Delta_k, \quad (10.195)$$

se satisface, tomar $\alpha_k = \alpha$. Caso contrario, tomar $\alpha := \theta \alpha$, verificar la validez de (10.195) de nuevo, etc., hasta que (10.195) se satisfaga.

4. Tomar $x^{k+1} = x^k + \alpha_k d^k$, $\lambda^{k+1} = y^k$, $\mu^{k+1} = z^k$.

5. Tomar $k := k + 1$, elegir una nueva matriz $H_k \in \mathbb{R}^{n \times n}$ simétrica, y retornar al Paso 1.

Observemos que la existencia de multiplicadores de Lagrange asociados a un punto estacionario en subproblemas de SQP es automática, ya que las restricciones de los subproblemas son lineales. Es importante que las normas que aparecen en las definiciones del término penalizador (10.190) y del valor del parámetro de penalización (10.193), estén en relación de dualidad, vea la ?. Si utilizamos alguna otra norma en (10.190), la elección (10.193) tiene que ser modificada para mantener la dualidad.

El Algoritmo 10.3 presupone que los subproblemas (10.191)-(10.192) poseen puntos estacionarios para todo k . En principio, esto no es siempre verdad. Primero, en general, hasta el conjunto factible del subproblema (10.191)-(10.192) puede ser vacío. No obstante, es fácil verificar lo siguiente.

Otra condición que evidentemente garantiza que $D_k \neq \emptyset$ es la independencia lineal de los gradientes $h'_i(x^k)$, $i = 1, \dots, l$, $g'_i(x^k)$, $i = 1, \dots, m$. Pero la validez de esta condición en cada punto de la secuencia $\{x^k\}$ generada por el método es una hipótesis bastante fuerte. Notemos, no obstante, que la viabilidad de los subproblemas puede ser asegurada introduciendo en las restricciones variables de holgura; vea el Ejercicio 10.52 más adelante.

Otra posible dificultad es que la función objetivo del problema (10.191)-(10.192) puede ser ilimitada inferiormente en el conjunto D_k (no vacío). En este caso, la existencia de puntos estacionarios también puede no estar garantizada. Es claro que esta situación no es posible si H_k es una matriz definida positiva. Por eso, realmente es deseable elegir H_k definida positiva, por lo menos mientras estemos lejos de la solución. De acuerdo con el Teorema 10.20 más adelante, para garantizar convergencia global del Algoritmo 10.3, la secuencia $\{H_k\}$ debe ser esencialmente cualquiera, siempre que las matrices sean uniformemente definidas positivas y uniformemente limitadas. En particular, podemos utilizar hasta una matriz fija para todo k , digamos $H_k = E^n$. Por otro lado, desde el punto de vista de convergencia local rápida, la elección deseable es $H_k = L''_{xx}(x^k, \lambda^k, \mu^k)$, vea la ???. Infelizmente, bajo hipótesis naturales sobre la solución del problema, no podemos garantizar que esta matriz sea definida positiva. En este sentido, puede ser útil sustituir la Lagrangiana por la Lagrangiana aumentada, con un valor del parámetro penalizador suficientemente grande (vea el ??? y el Ejercicio 10.49). Otra opción consiste en la modificación directa de las matrices $L''_{xx}(x^k, \lambda^k, \mu^k)$, como en la ???. Además de esto, hay estrategias de actualización de H_k cuasi-Newtonianas. En este caso, la regla de cálculo de la longitud de paso también tiene que ser modificada (vea los comentarios sobre la regla de Wolfe en la ???), para garantizar que H_k sea definida positiva para todo k . Las estrategias cuasi-Newtonianas tienen la ventaja de que ellas evitan el cálculo de las derivadas segundas de f , h y g .

Recordamos que $\psi'(x; d)$, la derivada direccional de la función ψ (dada por (10.190)) en el punto $x \in \mathbb{R}^n$ en la dirección $d \in \mathbb{R}^n$, tiene la siguiente forma (vea el Ejercicio 10.17):

$$\begin{aligned} \psi'(x; d) = & \sum_{j \in J^+(x)} \langle h'_j(x), d \rangle + \sum_{j \in J^0(x)} |\langle h'_j(x), d \rangle| \\ & - \sum_{j \in J^-(x)} \langle h'_j(x), d \rangle + \sum_{i \in I^+(x)} \langle g'_i(x), d \rangle \\ & + \sum_{i \in I(x)} \max\{0, \langle g'_i(x), d \rangle\}, \end{aligned}$$

donde

$$\begin{aligned} J^+(x) &= \{j = 1, \dots, l \mid h_j(x) > 0\}, \\ J^0(x) &= \{j = 1, \dots, l \mid h_j(x) = 0\}, \\ J^-(x) &= \{j = 1, \dots, l \mid h_j(x) < 0\}, \\ I^+(x) &= \{i = 1, \dots, m \mid g_i(x) > 0\}, \\ I(x) &= \{i = 1, \dots, m \mid g_i(x) = 0\}. \end{aligned}$$

A continuación, mostramos que cuando H_k es definida positiva, la solución del subproblema del método SQP provee una dirección de descenso para la función de mérito elegida.

Lema 10.4 (Derivada de la función de mérito en la dirección de SQP). Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en el punto $x^k \in \mathbb{R}^n$. Sean $H_k \in \mathbb{R}^{n \times n}$ una matriz simétrica, $d^k \in \mathbb{R}^n$ un punto estacionario del problema (10.191)-(10.192), y $y^k \in \mathbb{R}^l$ y $z^k \in \mathbb{R}_+^m$ multiplicadores de Lagrange asociados, y c_k un número que satisface (10.193). Sean φ y ψ las funciones definidas por (10.189) y (10.190), respectivamente.

Entonces la función $\varphi(\cdot; c_k)$ es diferenciable en el punto x^k en cada dirección, y se tiene que

$$\varphi'((x^k; d^k); c_k) \leq \Delta_k \leq -\langle H_k d^k, d^k \rangle - \bar{c} \psi(x^k), \quad (10.196)$$

donde el número Δ_k está definido en (10.194).

Prueba. Por las condiciones KKT para el problema (10.191)-(10.192), el punto (d^k, y^k, z^k) satisface el sistema

$$f'(x^k) + H_k d^k + (h'(x^k))^T y^k + (g'(x^k))^T z^k = 0, \quad (10.197)$$

$$h(x^k) + h'(x^k) d^k = 0, \quad (10.198)$$

$$g(x^k) + g'(x^k) d^k \leq 0, \quad z^k \geq 0, \quad (10.199)$$

$$z_i^k (g_i(x^k) + \langle g'_i(x^k), d^k \rangle) = 0, \quad i = 1, \dots, m \quad (10.200)$$

(la relación (10.200) no será utilizada en esta demostración, pero será necesaria más adelante). De (10.198) se sigue que

$$\langle h'_j(x^k), d^k \rangle = -h_j(x^k) \quad \forall j = 1, \dots, l,$$

y, por lo tanto,

$$-|h_j(x^k)| = \begin{cases} \langle h'_j(x^k), d^k \rangle, & \text{si } j \in J^+(x^k), \\ |\langle h'_j(x^k), d^k \rangle|, & \text{si } j \in J^0(x^k), \\ -\langle h'_j(x^k), d^k \rangle, & \text{si } j \in J^-(x^k). \end{cases}$$

Además de eso, por la primera desigualdad en (10.199), tenemos que

$$-\max\{0, g_i(x^k)\} = \begin{cases} -g_i(x^k) \geq \langle g'_i(x^k), d^k \rangle, & \text{si } i \in I^+(x^k), \\ 0 = \max\{0, \langle g'_i(x^k), d^k \rangle\}, & \text{si } i \in I(x^k). \end{cases}$$

Utilizando la fórmula de la derivada direccional de la función $\psi(\cdot)$, dada arriba, obtenemos entonces

$$\begin{aligned} \varphi'((x^k; d^k); c_k) &= \langle f'(x^k), d^k \rangle + c_k \psi'(x^k; d^k) \\ &\leq \langle f'(x^k), d^k \rangle - c_k \sum_{j=1}^l |h_j(x^k)| \\ &\quad - c_k \sum_{i \in I^+(x^k) \cup I(x^k)} \max\{0, g_i(x^k)\} \\ &= \langle f'(x^k), d^k \rangle - c_k \sum_{j=1}^l |h_j(x^k)| \\ &\quad - c_k \sum_{i=1}^m \max\{0, g_i(x^k)\} \\ &= \langle f'(x^k), d^k \rangle - c_k \psi(x^k) \\ &= \Delta_k, \end{aligned}$$

donde la segunda igualdad se sigue del hecho de que para todo índice $i \notin \{1, \dots, m\} \setminus (I^+(x^k) \cup I(x^k))$, se tiene que $\max\{0, g_i(x^k)\} = 0$. Acabamos de probar la primera desigualdad en (10.196).

Multiplicando ambos lados de (10.197) por d^k y haciendo uso de (10.198) y (10.199), obtenemos que

$$\begin{aligned} \langle f'(x^k), d^k \rangle &= -\langle H_k d^k, d^k \rangle - \langle y^k, h'(x^k) d^k \rangle - \langle z^k, g'(x^k) d^k \rangle \\ &= -\langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle + \langle z^k, g(x^k) \rangle \\ &\leq -\langle H_k d^k, d^k \rangle + \sum_{j=1}^l |y_j^k| |h_j(x^k)| \\ &\quad + \sum_{i=1}^m z_i^k \max\{0, g_i(x^k)\} \\ &\leq -\langle H_k d^k, d^k \rangle + \|y^k\|_\infty \|h(x^k)\|_1 \\ &\quad + \|z^k\|_\infty \sum_{i=1}^m \max\{0, g_i(x^k)\}. \end{aligned}$$

De aquí, utilizando (10.190), (10.193) y (10.194), obtenemos

$$\begin{aligned}
 \Delta_k &= \langle f'(x^k), d^k \rangle - c_k \psi(x^k) \\
 &\leq \langle f'(x^k), d^k \rangle - (\bar{c} + \|y^k\|_\infty) \|h(x^k)\|_1 \\
 &\quad - (\bar{c} + \|z^k\|_\infty) \sum_{i=1}^m \max\{0, g_i(x^k)\} \\
 &\leq -\langle H_k d^k, d^k \rangle - \bar{c} \|h(x^k)\|_1 \\
 &\quad - \bar{c} \sum_{i=1}^m \max\{0, g_i(x^k)\} \\
 &= -\langle H_k d^k, d^k \rangle - \bar{c} \psi(x^k),
 \end{aligned}$$

lo que es la segunda desigualdad en (10.196). ■

De la segunda desigualdad en (10.196), concluimos que para todo k , si la matriz H_k es definida positiva y el Algoritmo 10.3 genera $d^k \neq 0$, se tiene que

$$\Delta_k < 0. \quad (10.201)$$

De aquí y de la primera desigualdad en (10.196), es fácil ver que d^k es una dirección de descenso para la función $\varphi(\cdot; c_k)$ en el punto x^k (comparar con el ??). Por lo tanto, la regla de búsqueda lineal en el Paso 2 del método está bien definida, en el sentido de que ella acepta un valor de longitud de paso $\alpha_k > 0$, después de un número finito de disminuciones del valor inicial (comparar con el ??). A propósito, la regla de (10.195) sería una extensión obvia de la desigualdad de Armijo para el caso de una función no-diferenciable (que posee, sin embargo, derivadas direccionales). No obstante, la fórmula para el cálculo de Δ_k es más simple que la fórmula $\varphi'((x^k; d^k); c_k)$. En particular, (10.194) no contiene derivadas de las funciones h y g .

En principio, iteraciones del Algoritmo 10.3 utilizan valores diferentes del parámetro penalizador c_k . En el análisis de convergencia es conveniente admitir que este valor es fijo, por lo menos para todo k suficientemente grande:

$$c_k = c, \quad (10.202)$$

donde c es una constante. Notemos que en este caso, a partir de cierto paso k , el Algoritmo 10.3 puede ser pensado como un método de descenso para el problema irrestricto

$$\min \varphi(x; c), \quad x \in \mathbb{R}^n.$$

Recordamos que, bajo ciertas hipótesis, la penalización es exacta (vea la ??), ya que la validez de (10.193), para un $c_k = c$ fijo y todo k suficientemente grande, indica que el valor de este parámetro es adecuado.

Como es fácil observar de (10.193), la posibilidad de utilizar c_k fijo para todo k suficientemente grande presupone que la secuencia de multiplicadores $\{(y^k, z^k)\}$ generada por el método es limitada. Desde el punto de vista práctico, esto es completamente natural (por lo menos, cuando el conjunto de multiplicadores asociados al punto estacionario del problema original es limitado). De hecho, bajo ciertas hipótesis razonables, podemos garantizar que la secuencia $\{(y^k, z^k)\}$ sea limitada. Sin embargo, para simplificar el análisis, nosotros vamos simplemente a colocar esto como una hipótesis. Así, la validez de (10.202) para algún c y todo k suficientemente grande puede ser garantizada, por ejemplo, por la siguiente regla de elección de valores de c_k . En la primera iteración, tomamos $c_0 = \bar{c} + 1 + \|(y^0, z^0)\|_\infty$. Para cada iteración $k = 1, 2, \dots$, subsecuente, verificamos la validez de (10.193) para $c_k = c_{k-1}$. Si (10.193) se satisface, aceptamos este c_k ; caso contrario tomamos $c_k = \bar{c} + 1 + \|(y^k, z^k)\|_\infty$. Puede verse que si $\{(y^k, z^k)\}$ es limitada, los parámetros c_k así elegidos satisfacen (10.202) para algún c y todo k suficientemente grande.

Teorema 10.20 (Convergencia global del método SQP). Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en $\mathbb{R}^n$, con derivadas Lipschitz-continuas en $\mathbb{R}^n$. Supongamos que en el Algoritmo 10.3 las matrices H_k sean elegidas de tal manera que la secuencia $\{H_k\}$ sea limitada y las matrices sean uniformemente definidas positivas, i.e.,

$$\langle H_k v, v \rangle \geq \gamma \|v\|^2 \quad \forall v \in \mathbb{R}^n, \forall k, \quad (10.203)$$

donde $\gamma > 0$. Sea $\{(x^k, \lambda^k, \mu^k)\}$ una secuencia generada por este algoritmo y supongamos, para todo k suficientemente grande, que se satisfaga la condición (10.202), donde c es una constante.

Cuando $k \rightarrow \infty$, se tiene que o

$$\varphi(x^k; c_k) \rightarrow -\infty, \quad (10.204)$$

0

$$\begin{aligned}
\{d^k\} &\rightarrow 0, \\
L'_x(x^k, \lambda^{k+1}, \mu^{k+1}) &\rightarrow 0, \\
h(x^k) &\rightarrow 0, \quad \max\{0, g_i(x^k)\} \rightarrow 0, \quad i = 1, \dots, m, \\
\langle \mu^{k+1}, g(x^k) \rangle &\rightarrow 0.
\end{aligned}$$

En particular, si $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ es un punto de acumulación de la secuencia $\{(x^k, \lambda^k, \mu^k)\}$, entonces $\bar{x}$ es un punto estacionario del problema (10.188), en cuanto $\bar{\lambda}$ y $\bar{\mu}$ son multiplicadores de Lagrange asociados.

Prueba. Recordamos que (d^k, y^k, z^k) satisface las condiciones de optimalidad (10.197)-(10.200), para todo k . La segunda o tercera conclusión significan que el punto (x^k, y^k, z^k) resuelve el sistema KKT del problema (10.188), o que $d^k = 0$ da el resultado deseado. De aquí en adelante, suponemos que $d^k \neq 0 \forall k$. Notemos que, por (10.202) y (10.193), las secuencias $\{\lambda^k\}$ y $\{\mu^k\}$ son limitadas.

Primero probaremos que la secuencia de valores de las longitudes de pasos $\{\alpha_k\}$ está limitada inferiormente por un número fijo estrictamente positivo. Sea $\alpha \in (0, 1]$ arbitrario. Sea $M > 0$ el máximo entre los módulos de Lipschitz-continuidad de las derivadas de f, h y g en $\mathbb{R}^n$. Por el ??, para todo k y todo $i = 1, \dots, m$, obtenemos que

$$\begin{aligned}
&\max\{0, g_i(x^k + \alpha d^k)\} - \max\{0, g_i(x^k) + \alpha \langle g'_i(x^k), d^k \rangle\} \\
&\leq \max\{0, g_i(x^k + \alpha d^k) - g_i(x^k) - \alpha \langle g'_i(x^k), d^k \rangle\} \\
&\leq |g_i(x^k + \alpha d^k) - g_i(x^k) - \alpha \langle g'_i(x^k), d^k \rangle| \\
&\leq \frac{M\alpha^2}{2} \|d^k\|^2,
\end{aligned} \tag{10.205}$$

donde utilizamos los hechos de que, para todo $a, b \in \mathbb{R}$, se tiene que $\max\{0, a\} - \max\{0, b\} \leq \max\{0, a - b\}$ y $\max\{0, a\} \leq |a|$. Además de eso,

$$\begin{aligned}
&\max\{0, g_i(x^k) + \alpha \langle g'_i(x^k), d^k \rangle\} \\
&= \max\{0, \alpha(g_i(x^k) + \langle g'_i(x^k), d^k \rangle) + (1 - \alpha)g_i(x^k)\} \\
&\leq \alpha \max\{0, g_i(x^k) + \langle g'_i(x^k), d^k \rangle\} + (1 - \alpha) \max\{0, g_i(x^k)\} \\
&= (1 - \alpha) \max\{0, g_i(x^k)\},
\end{aligned}$$

donde la desigualdad se sigue de la convexidad de la función $\max\{0, \cdot\}$, y la última igualdad se sigue de (10.199). De (10.205) obtenemos entonces que

$$\begin{aligned}
\max\{0, g_i(x^k + \alpha d^k)\} &\leq \max\{0, g_i(x^k) + \alpha \langle g'_i(x^k), d^k \rangle\} + \frac{M\alpha^2}{2} \|d^k\|^2 \\
&\leq (1 - \alpha) \max\{0, g_i(x^k)\} + \frac{M\alpha^2}{2} \|d^k\|^2.
\end{aligned} \tag{10.206}$$

Por el ??,

$$f(x^k + \alpha d^k) \leq f(x^k) + \alpha \langle f'(x^k), d^k \rangle + \frac{M\alpha^2}{2} \|d^k\|^2. \tag{10.207}$$

De modo similar, de (10.198) y del ??, tenemos que para todo $j = 1, \dots, l$,

$$\begin{aligned}
|h_j(x^k + \alpha d^k)| &= |h_j(x^k + \alpha d^k) - \alpha h_j(x^k) - \alpha \langle h'_j(x^k), d^k \rangle| \\
&\leq (1 - \alpha) |h_j(x^k)| + \frac{M\alpha^2}{2} \|d^k\|^2.
\end{aligned} \tag{10.208}$$

Utilizando (10.189), (10.190), y combinando las relaciones (10.206)-(10.208), obtenemos

$$\begin{aligned}
 \varphi(x^k + \alpha d^k; c_k) &= f(x^k + \alpha d^k) + c_k \|h(x^k + \alpha d^k)\|_1 \\
 &\quad + c_k \sum_{i=1}^m \max\{0, g_i(x^k + \alpha d^k)\} \\
 &\leq f(x^k) + \alpha \langle f'(x^k), d^k \rangle + c_k(1 - \alpha) \|h(x^k)\|_1 \\
 &\quad + c_k(1 - \alpha) \sum_{i=1}^m \max\{0, g_i(x^k)\} + C_k \alpha^2 \|d^k\|^2 \\
 &= \varphi(x^k; c_k) + \alpha \langle f'(x^k), d^k \rangle - c_k \|h(x^k)\|_1 \\
 &\quad - c_k \sum_{i=1}^m \max\{0, g_i(x^k)\} + C_k \alpha^2 \|d^k\|^2 \\
 &= \varphi(x^k; c_k) + \alpha \Delta_k + C_k \alpha^2 \|d^k\|^2,
 \end{aligned} \tag{10.209}$$

donde

$$C_k = M(1 + (l + m)c_k)/2 > 0.$$

Comparando la relación de arriba con (10.195), vemos que la desigualdad de (10.195) será satisfecha si

$$\Delta_k + C_k \alpha \|d^k\|^2 \leq \sigma \Delta_k,$$

o sea, para todo $\alpha \in (0, \bar{\alpha}_k]$, donde

$$\bar{\alpha}_k = \frac{(\sigma - 1)\Delta_k}{C_k \|d^k\|^2}.$$

Por la segunda desigualdad en (10.196) y por (10.203), se tiene que

$$\bar{\alpha}_k \geq (1 - \sigma)\gamma/C_k,$$

donde la secuencia $\{C_k\}$ está limitada, por (10.209) y por la igualdad de (10.202), que vale para todo k suficientemente grande. Concluimos que existe un número $\check{\alpha} > 0$, que no depende de k , tal que

$$\alpha_k \geq \check{\alpha} > 0. \tag{10.210}$$

De las relaciones (10.195), (10.202) y (10.210), obtenemos ahora que, para todo k suficientemente grande,

$$\varphi(x^{k+1}; c_{k+1}) \leq \varphi(x^k; c_k) + \sigma \check{\alpha} \Delta_k. \tag{10.211}$$

Recordamos que vale (10.201). Por lo tanto, la secuencia $\{\varphi(x^k; c_k)\}$ es decreciente. Entonces, o ella es ilimitada inferiormente (vale (10.204)) o ella converge. En este segundo caso, de (10.211) obtenemos que

$$\Delta_k \rightarrow 0 \quad (k \rightarrow \infty). \tag{10.212}$$

De donde, utilizando la segunda desigualdad en (10.196) y (10.203), así como el hecho de que $\{H_k\}$ es limitada, obtenemos

$$\psi(x^k) \rightarrow 0, \quad \{d^k\} \rightarrow 0, \quad \{H_k d^k\} \rightarrow 0 \quad (k \rightarrow \infty). \tag{10.213}$$

En particular, por la definición de $\psi(\cdot)$,

$$\{h(x^k)\} \rightarrow 0, \quad \max\{0, g_i(x^k)\} \rightarrow 0, \quad i = 1, \dots, m, \quad (k \rightarrow \infty). \tag{10.214}$$

Pasando al límite en la relación (10.197) cuando $k \rightarrow \infty$, y utilizando (10.213), obtenemos también que

$$L'_x(x^k, \lambda^{k+1}, \mu^{k+1}) \rightarrow 0 \quad (k \rightarrow \infty).$$

Para concluir la prueba, falta verificar que se satisfaga, asintóticamente, la condición de complementariedad. De (10.194), (10.212) y (10.213), obtenemos que

$$\langle f'(x^k), d^k \rangle = \Delta_k + c_k \psi(x^k) \rightarrow 0 \quad (k \rightarrow \infty).$$

Multiplicando (10.197) por d^k y utilizando la última relación y (10.213), obtenemos

$$\begin{aligned} & \langle \lambda^{k+1}, h'(x^k)d^k \rangle + \langle \mu^{k+1}, g'(x^k)d^k \rangle \\ & = -\langle f'(x^k), d^k \rangle - \langle H_k d^k, d^k \rangle \rightarrow 0 \quad (k \rightarrow \infty). \end{aligned}$$

Como de (10.198) y (10.214) se sigue que

$$h'(x^k)d^k = -h(x^k) \rightarrow 0 \quad (k \rightarrow \infty),$$

recordando que $\{\lambda^k\}$ es limitada, concluimos que

$$\langle \lambda^{k+1}, h'(x^k)d^k \rangle \rightarrow 0 \quad (k \rightarrow \infty).$$

Finalmente, de (10.200), obtenemos que

$$\langle \mu^{k+1}, g'(x^k)d^k \rangle = -\langle \mu^{k+1}, g(x^k) \rangle \rightarrow 0 \quad (k \rightarrow \infty).$$

■

La construcción siguiente es importante en la práctica, para lidiar con situaciones en que los subproblemas de SQP pueden ser inviables (i.e., pueden poseer conjunto factible vacío en algunas iteraciones).

El subproblema (??)-(??) (ver el Ejercicio 10.52), que también es un problema de programación cuadrática, puede servir para el desarrollo de un método SQP globalmente convergente, donde la viabilidad de los subproblemas es automática (vea, por ejemplo, [3; 4]). No obstante, esta ventaja viene con un cierto precio a pagar. Para garantizar convergencia de un método de este tipo, de nuevo precisamos que el valor del parámetro penalizador c_k sea suficientemente grande (en particular, mayor de lo que $\|(\bar{\lambda}, \bar{\mu})\|_1$, para todo k grande). Observamos que en el subproblema (??)-(??), c_k tiene que ser definido antes de la resolución de este subproblema, i.e., cuando las nuevas aproximaciones a los multiplicadores de Lagrange aún no están disponibles. Esto presenta un cierto nivel de dificultad tanto computacional como teórica. Mas existen algunas estrategias satisfactorias para la elección de c_k , por lo menos del punto de vista práctico.

10.6.4. Restauración de la convergencia local superlineal

De acuerdo con el Teorema 10.20, la convergencia global de métodos SQP puede ser garantizada bajo hipótesis bien razonables. Resta, no obstante, investigar la siguiente cuestión natural: ¿estos métodos globalizados preservan (o no) la convergencia local rápida del método SQP original? Cuando hay convergencia, en principio, por el Teorema 10.19 podemos esperar convergencia superlineal a una solución $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ del sistema KKT del problema si las matrices H_k aproximan a la matriz $L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})$ en el sentido de la relación (10.169). Resaltamos que esta aproximación no significa que necesariamente vale $\{H_k\} \rightarrow L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})$ ($k \rightarrow \infty$). Más aún, la validez de la última condición puede no ser lograda, ya que la matriz $L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})$ puede no ser definida positiva. En cualquier caso, una aproximación adecuada de esta matriz no es suficiente para afirmar la convergencia superlineal del método globalizado: tenemos que garantizar que el valor de la longitud de paso $\alpha_k = 1$ (que corresponde a la iteración del método SQP puro) sea aceptado por la regla de búsqueda lineal, para todo k suficientemente grande. Será que esto es válido si el punto $(x^k, \lambda^k, \mu^k) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ está próximo a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, y si el punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$ satisface todas las hipótesis para convergencia superlineal del Teorema 10.19? Infelizmente, la respuesta es negativa, como puede ser visto del ejemplo siguiente. Este fenómeno se llama *efecto de Maratos*. Resaltamos que este ejemplo no es patológico o raro.

Ejemplo 10.6 (Efecto de Maratos). Sean $n = 2, l = 1, m = 0$,

$$f(x) = x_1, \quad h(x) = x_1^2 + x_2^2 - 1, \quad x \in \mathbb{R}^2.$$

La solución global del problema (10.188) es el punto $\bar{x} = (-1, 0)$. Este punto satisface la condición de regularidad de las restricciones (??), y el único multiplicador de Lagrange asociado es $\bar{\lambda} = 1/2$. Más aún, se satisface la condición suficiente de segunda orden (??).

Para $x^k \in \mathbb{R}^2$ cualquiera, sea $(d^k, y^k) \in \mathbb{R}^2 \times \mathbb{R}$ la solución del sistema de Lagrange del subproblema (10.191)-(10.192), donde utilizamos la elección $H_k = L''_{xx}(\bar{x}, \bar{\lambda}) = E^2$, i.e.,

$$1 + d_1^k + 2y^k x_1^k = 0, \quad d_2^k + 2y^k x_2^k = 0, \quad (10.215)$$

$$(x_1^k)^2 + (x_2^k)^2 - 1 + 2x_1^k d_1^k + 2x_2^k d_2^k = 0 \quad (10.216)$$

(vea (10.197), (10.198)). Notemos que la matriz H_k es definida positiva y para $x^k \neq 0$, las relaciones (10.215), (10.216), definen (d^k, y^k) unívocamente. Podríamos encontrar los valores de d^k y y^k explícitamente, pero no vamos a hacer esto aquí porque precisaremos solamente de las propiedades siguientes.

Multiplicando ambos lados de la primera igualdad en (10.215) por d_1^k , y de la segunda igualdad por d_2^k , y sumando las relaciones obtenidas, utilizando (10.216) obtenemos que

$$d_1^k = y^k((x_1^k)^2 + (x_2^k)^2 - 1) - (d_1^k)^2 - (d_2^k)^2.$$

Por lo tanto,

$$f(x^k + d^k) - f(x^k) = d_1^k = y^k h(x^k) - \|d^k\|^2.$$

De (10.216), obtenemos que

$$h(x^k + d^k) = (x_1^k + d_1^k)^2 + (x_2^k + d_2^k)^2 - 1 = \|d^k\|^2.$$

Por lo tanto,

$$\begin{aligned} \varphi(x^k + d^k; c) - \varphi(x^k; c) \\ = y^k h(x^k) - c|h(x^k)| + (c - 1)\|d^k\|^2 > 0, \end{aligned}$$

para todo $c > 1$, si, por ejemplo, $h(x^k) = 0$ y el punto x^k no es estacionario para el problema (10.188) (lo que garantiza que $d^k \neq 0$; vea la demostración del Teorema 10.20). Esto muestra que $\alpha = 1$ no puede satisfacer la desigualdad de Armijo (10.195), ya que vale (10.201).

Notemos que toda vecindad del punto $\bar{x}$ contiene un número infinito de puntos factibles que no son estacionarios para el problema (10.188). De acuerdo con lo expuesto arriba, en todos estos puntos el valor de la longitud de paso $\alpha_k = 1$ no sería aceptado por la regla de búsqueda lineal (10.195).

Notemos que en el ejemplo anterior, para $c \in (1/2, 1)$ el valor de $\alpha_k = 1$ provee, sin embargo, un decrecimiento de la función $\varphi(\cdot; c)$ con respecto a su valor en el punto x^k . Para estos valores del parámetro penalizador, tal vez no haya contradicción entre los requerimientos para convergencia global y para convergencia local superlineal. Pero no es difícil modificar el ejemplo de modo que realmente no haya intervalo de valores del parámetro penalizador que puedan servir tanto para convergencia global como para convergencia local superlineal.

Ejemplo 10.7. En el Ejercicio 10.49, redefinimos

$$f(x) = x_1 + x_1^2 + x_2^2, \quad x \in \mathbb{R}^2.$$

La solución global del problema (10.188) es $\bar{x} = (-1, 0)$, con multiplicador de Lagrange $\bar{\lambda} = -1/2$. Como antes, el punto $\bar{x}$ satisface la condición de regularidad de las restricciones (??) y la condición suficiente de segunda orden (??).

Sea $x^k \in \mathbb{R}^2$ un punto cualquiera que no es un punto estacionario del problema (10.188) y que satisface $h(x^k) = 0$. Sea $(d^k, y^k) \in \mathbb{R}^2 \times \mathbb{R}$ la solución del sistema de Lagrange del subproblema (10.191)-(10.192), con $H_k = L''_{xx}(\bar{x}, \bar{\lambda}) = E^2$, i.e.,

$$1 + 2x_1^k + d_1^k + 2y^k x_1^k = 0, \quad 2x_2^k + d_2^k + 2y^k x_2^k = 0, \quad (10.217)$$

$$x_1^k d_1^k + x_2^k d_2^k = 0 \quad (10.218)$$

(vea (10.197), (10.198)). Multiplicando la primera igualdad en (10.217) por d_1^k , y la segunda por d_2^k , y sumando las relaciones así obtenidas, utilizando también (10.218), obtenemos que

$$d_1^k + (d_1^k)^2 + (d_2^k)^2 = 0.$$

Por lo tanto,

$$\begin{aligned} f(x^k + d^k) - f(x^k) &= d_1^k + (x_1^k + d_1^k)^2 + (x_2^k + d_2^k)^2 - (x_1^k)^2 - (x_2^k)^2 \\ &= h(x^k + d^k) = (x_1^k + d_1^k)^2 + (x_2^k + d_2^k)^2 - 1 = \|d^k\|^2, \end{aligned}$$

donde de nuevo tomamos en cuenta (10.218). De estas relaciones, obtenemos que

$$\varphi(x^k + d^k; c) - \varphi(x^k; c) = c\|d^k\|^2 > 0 \quad \forall c > 0.$$

El efecto de Maratos puede ser explicado de la manera siguiente. Si un punto x^k está próximo al conjunto factible D , el paso de x^k a $x^k + d^k$ puede hacer aumentar el término penalizador por un valor de la misma magnitud de orden que la disminución de la función objetivo f . Como consecuencia, para c suficientemente grande, el valor de la función

penalizada $\varphi(\cdot; c)$ puede aumentar, lo que hace que el valor de la longitud de paso $\alpha = 1$ no sea aceptado. Por eso, la cuestión de la convergencia local rápida de un método SQP globalizado es mucho más compleja que, por ejemplo, la misma cuestión para el método de Newton globalizado en el caso de optimización irrestricta (vea los ???). Para evitar el posible efecto de Maratos, el Algoritmo 10.3 tiene que ser modificado. Hay varias maneras de hacer esto. Una estrategia consiste en el cálculo de la longitud de paso por una búsqueda no lineal. Más precisamente, la búsqueda se hace a lo largo de la frontera del conjunto factible (vea [3; 20]). Vamos a presentar otra estrategia, que consiste en la modificación de la función de mérito. Más precisamente, utilizaremos la Lagrangiana aumentada no-diferenciable.

De aquí en adelante, consideremos el problema con restricciones de igualdad, en vez de (10.188), sea el problema dado por

$$\min f(x) \quad \text{sueto a } x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}. \quad (10.219)$$

Introducimos la familia de funciones

$$\begin{aligned} \varphi(\cdot; c, \eta) &: \mathbb{R}^n \rightarrow \mathbb{R}, \\ \varphi(x; c, \eta) &= f(x) + \langle \eta, h(x) \rangle + c\|h(x)\|_1, \end{aligned} \quad (10.220)$$

donde $c \geq 0$ y $\eta \in \mathbb{R}^l$ son parámetros. La función anterior puede ser pensada como una Lagrangiana clásica del problema (10.219), aumentada por un término penalizador no-diferenciable. Tenemos la propiedad siguiente (comparar con el ??).

Proposición 10.7. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Supongamos que $\bar{x}$ sea un punto estacionario del problema (10.219), que satisface la condición suficiente de segunda orden del ??(b), con multiplicador de Lagrange $\bar{\lambda} \in \mathbb{R}^l$.

Entonces existe un número $\bar{c} \geq 0$ tal que, para todo $c > \bar{c}$ y todo $\eta \in \mathbb{R}^l$ satisfaciendo la desigualdad

$$c > \|\eta - \bar{\lambda}\|_\infty, \quad (10.221)$$

el punto $\bar{x}$ es una solución local estricta del problema

$$\min \varphi(x; c, \eta), \quad x \in \mathbb{R}^n,$$

donde la función objetivo es definida por la fórmula (10.220).

Prueba. Recordando la Lagrangiana aumentada (clásica) para el problema (10.219), y utilizando el ??, para todo $c > 0$ suficientemente grande tenemos que

$$\begin{aligned} \varphi(\bar{x}; c, \eta) &= f(\bar{x}) \\ &= L(\bar{x}, \bar{\lambda}) + \frac{c}{2} \|h(\bar{x})\|^2 \\ &< L(x, \bar{\lambda}) + \frac{c}{2} \|h(x)\|^2, \end{aligned} \quad (10.222)$$

para todo $x \in \mathbb{R}^n \setminus \{\bar{x}\}$ suficientemente próximo a $\bar{x}$. Por otro lado, para todo x suficientemente próximo a $\bar{x}$ (tal que $h(x)$ está suficientemente próximo a cero), se tiene que

$$\|h(x)\|^2 = o(\|h(x)\|_1).$$

Por lo tanto,

$$\begin{aligned} \varphi(x; c, \eta) &= L(x, \lambda) + \langle \eta - \lambda, h(x) \rangle + c\|h(x)\|_1 \\ &\geq L(x, \lambda) + (c - \|\eta - \lambda\|_\infty)\|h(x)\|_1 \\ &\geq L(x, \lambda) + \frac{c}{2} \|h(x)\|^2, \end{aligned} \quad (10.223)$$

donde utilizamos la desigualdad de Cauchy-Schwarz generalizada (??) y (10.221). Finalmente, combinando (10.222) y (10.223), obtenemos el resultado anunciado. ■

Para un iterando $x^k \in \mathbb{R}^n$, definimos

$$D_k = \{d \in \mathbb{R}^n \mid h(x^k) + h'(x^k)d = 0\}. \quad (10.224)$$

Sea $d^k \in \mathbb{R}^n$ un punto estacionario del subproblema de programación cuadrática (10.191), (10.224), y $y^k \in \mathbb{R}^l$ un multiplicador de Lagrange asociado. En particular,

$$f'(x^k) + H_k d^k + (h'(x^k))^T y^k = 0, \quad h(x^k) + h'(x^k) d^k = 0. \quad (10.225)$$

Utilizando el Ejercicio 10.17 y la relación (10.225), y siguiendo el razonamiento de la demostración del Lema 10.4, para toda dirección d^k se tiene la siguiente forma:

$$\varphi'((x^k; d^k); c, \eta) = -\langle H_k d^k, d^k \rangle + \langle y^k - \eta, h(x^k) \rangle - c \|h(x^k)\|_1. \quad (10.226)$$

De donde, si $c \geq \|y^k - \eta\|_\infty$, se tiene que

$$\varphi'((x^k; d^k); c, \eta) \leq -\langle H_k d^k, d^k \rangle. \quad (10.227)$$

Por lo tanto, si la matriz H_k es definida positiva y $d^k \neq 0$, entonces d^k es una dirección de descenso para la función $\varphi(\cdot; c, \eta)$ en el punto x^k .

Podemos entonces construir un método análogo al Algoritmo 10.3, utilizando la función de mérito $\varphi(\cdot; c, \eta)$. La condición (10.193) tiene que ser sustituida por

$$c_k \geq \bar{c} + \|y^k - \eta^k\|_\infty, \quad (10.228)$$

y la desigualdad (10.195) por

$$\varphi(x^k + \alpha d^k; c_k, \eta_k) \leq \varphi(x^k; c_k, \eta_k) + \sigma \alpha \varphi'((x^k; d^k); c_k, \eta_k). \quad (10.229)$$

El teorema siguiente, en combinación con el Teorema 10.19, muestra que para elecciones adecuadas de las matrices H_k , el método modificado posee tanto convergencia global como convergencia local superlineal. En relación a la condición (10.230), recordamos que bajo la condición suficiente de segunda orden en $\bar{x}$, la matriz $L''_{xx}(\bar{x}, \bar{\lambda}) + c(h'(\bar{x}))^T h'(\bar{x})$ es definida positiva para todo c suficientemente grande (vea el ??). La condición (10.230) para la elección de H_k significa que H_k debe ser una aproximación “superior” de la matriz introducida en el Teorema 10.18 para c suficientemente grande.

Teorema 10.21 (Convergencia local superlineal del método SQP globalizado). Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$ y $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones dos veces diferenciables en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivadas segundas continuas en este punto. Supongamos que $\bar{x}$ satisface la condición de regularidad de las restricciones (??), y que sea un punto estacionario del problema (10.219), con (único) multiplicador de Lagrange $\bar{\lambda} \in \mathbb{R}^l$ asociado. Supongamos que vale la condición suficiente de segunda orden del ??(b).

Supongamos también que $\{x^k\} \subset \mathbb{R}^n$ sea convergente a $\bar{x}$, que $\{d^k, y^k\} \in \mathbb{R}^n \times \mathbb{R}^l$, que $\{d^k\} \rightarrow 0$ (y que 0 es el vector nulo), y que el vector $\eta^k \in \mathbb{R}^l$ satisface (10.225), (10.228). Para todo k suficientemente grande, suponemos que la matriz simétrica $H_k \in \mathbb{R}^{n \times n}$ satisface la condición

$$\langle (H_k - L''_{xx}(\bar{x}, \bar{\lambda}) - c(h'(\bar{x}))^T h'(\bar{x})) d^k, d^k \rangle \geq o(\|d^k\|^2), \quad (10.230)$$

donde el número $c \geq 0$ es tal que la matriz $L''_{xx}(\bar{x}, \bar{\lambda}) + c(h'(\bar{x}))^T h'(\bar{x})$ es definida positiva.

Entonces para todo $\sigma \in (0, 1/2)$ existe $\delta > 0$ tal que para todo k suficientemente grande, la validez de las desigualdades

$$c_k \leq \delta, \quad \|\eta^k - \bar{\lambda}\| \leq \delta \quad (10.231)$$

implica la validez de la desigualdad (10.229) para $\alpha = 1$, donde la función $\varphi(\cdot; c, \eta)$ es dada por (10.220).

Prueba. De la relación (10.230) y de la elección del número c , se sigue que existe un número $\gamma > 0$ tal que, para todo k suficientemente grande,

$$\langle H_k d^k, d^k \rangle \geq \gamma \|d^k\|^2. \quad (10.232)$$

Además de eso, para todo k , de (10.230) y del hecho de que la matriz $(h'(\bar{x}))^T h'(\bar{x})$ es semidefinida positiva, tenemos que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}) d^k, d^k \rangle \leq \langle H_k d^k, d^k \rangle + o(\|d^k\|^2). \quad (10.233)$$

De (10.225), obtenemos que

$$\begin{aligned} \langle f'(x^k), d^k \rangle &= -\langle H_k d^k, d^k \rangle - \langle y^k, h'(x^k) d^k \rangle \\ &= -\langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle. \end{aligned}$$

Utilizando el Teorema del Valor Medio y la última igualdad, obtenemos

$$\begin{aligned} f(x^k + d^k) &= f(x^k) + \langle f'(x^k), d^k \rangle + \frac{1}{2} \langle f''(x^k + \tilde{t}_k d^k) d^k, d^k \rangle \\ &= f(x^k) - \langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle \\ &\quad + \frac{1}{2} \langle f''(x^k), d^k \rangle + o(\|d^k\|^2), \end{aligned} \quad (10.234)$$

donde $\tilde{t}_k \in [0, 1]$, y usamos la convergencia de $\{x^k\}$ a $\bar{x}$, y de $\{d^k\}$ a cero. De manera análoga, utilizando la segunda igualdad en (10.225) y el Teorema del Valor Medio, tenemos que

$$\begin{aligned} h_i(x^k + d^k) &= h_i(x^k) + \langle h'_i(x^k), d^k \rangle + \frac{1}{2} \langle h''_i(x^k + \tilde{t}_k d^k) d^k, d^k \rangle \\ &= \frac{1}{2} \langle h''_i(x^k + \tilde{t}_k d^k) d^k, d^k \rangle \\ &= \frac{1}{2} \langle h''_i(\bar{x}) d^k, d^k \rangle + o(\|d^k\|^2). \end{aligned} \quad (10.235)$$

Ahora, combinando la relación (10.234) con la relación (10.235), obtenemos que

$$\begin{aligned} \varphi(x^k + d^k; c_k, \eta^k) &= f(x^k) - \langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle \\ &\quad + \frac{1}{2} \langle f''(\bar{x}) d^k, d^k \rangle + \frac{1}{2} \sum_{i=1}^l \eta_i^k \langle h''_i(\bar{x}) d^k, d^k \rangle \\ &\quad + \frac{c_k}{2} \sum_{i=1}^l |\langle h''_i(\bar{x}) d^k, d^k \rangle| + o(\|d^k\|^2) \\ &= f(x^k) - \langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle \\ &\quad + \frac{1}{2} \langle L''_{xx}(\bar{x}, \eta^k) d^k, d^k \rangle + O(c_k \|d^k\|^2) + o(\|d^k\|^2) \\ &= f(x^k) - \langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle \\ &\quad + \frac{1}{2} \langle L''_{xx}(\bar{x}, \bar{\lambda}) d^k, d^k \rangle \\ &\quad + O(c_k \|d^k\|^2) + O(\|\eta^k - \bar{\lambda}\| \|d^k\|^2) + o(\|d^k\|^2). \end{aligned}$$

Por lo tanto, haciendo uso también de las relaciones (10.220), (10.226) y (10.233), concluimos que

$$\begin{aligned} \varphi(x^k + d^k; c_k, \eta^k) - \varphi(x^k; c_k, \eta^k) &= -\langle H_k d^k, d^k \rangle + \frac{1}{2} \langle L''_{xx}(\bar{x}, \bar{\lambda}) d^k, d^k \rangle + \langle y^k - \eta^k, h(x^k) \rangle \\ &\quad - c_k \|h(x^k)\|_1 + o(\|d^k\|^2) \\ &= \varphi'((x^k; d^k); c_k, \eta^k) + \frac{1}{2} \langle L''_{xx}(\bar{x}, \bar{\lambda}) d^k, d^k \rangle \\ &\quad + o(\|d^k\|^2) \\ &\leq \varphi'((x^k; d^k); c_k, \eta^k) + \frac{1}{2} \langle H_k d^k, d^k \rangle + o(\|d^k\|^2). \end{aligned}$$

Ahora, bajo la condición (10.231), podemos escribir

$$\begin{aligned} \varphi(x^k + d^k; c_k, \eta^k) - \varphi(x^k; c_k, \eta^k) &\leq \varphi'((x^k; d^k); c_k, \eta^k) + \frac{1}{2} \langle H_k d^k, d^k \rangle + O(\delta \|d^k\|^2) \\ &\leq \sigma \varphi'((x^k; d^k); c_k, \eta^k) - \frac{1-2\sigma}{2} \langle H_k d^k, d^k \rangle + O(\delta \|d^k\|^2) \\ &\leq \sigma \varphi'((x^k; d^k); c_k, \eta^k) - \frac{\gamma(1-2\sigma)}{2} \|d^k\|^2 + O(\delta \|d^k\|^2) \\ &\leq \sigma \varphi'((x^k; d^k); c_k, \eta^k), \end{aligned}$$

donde la segunda desigualdad se sigue de (10.227), la tercera de (10.232), y la última vale para todo k suficientemente grande, si el número $\delta > 0$ es suficientemente pequeño. ■

Procedimientos concretos de elección de los parámetros c_k y η^k , que garanticen tanto convergencia global del método SQP como convergencia local superlineal, existen y pueden ser consultadas en la literatura especial. Como estos procedimientos son bastante complejos, ellos no serán presentados en este libro.

10.6.5. Otras técnicas de globalización

Para finalizar, mencionaremos algunas otras técnicas de globalización de métodos SQP. Sea $x^k \in \mathbb{R}^n$ una aproximación actual a un punto estacionario del problema. Como en el caso irrestricto, podemos considerar una aproximación del problema original en una vecindad específica (“región de confianza”) de x^k . Así obtenemos el subproblema (10.191), donde el conjunto factible D_k es dado por

$$D_k = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} h(x^k) + h'(x^k)d = 0, g(x^k) + g'(x^k)d \leq 0, \\ \|d\|_\infty \leq \delta_k \end{array} \right\} \quad (10.236)$$

(comparar con (10.192)), y $\delta_k > 0$ define la región de confianza. Sea d^k una solución global de este subproblema. El punto $x^k + d^k$ será aceptado como aproximación siguiente x^{k+1} si el paso de x^k a x^{k+1} provee un decrecimiento suficiente de la función de mérito elegida (típicamente, una función de penalización exacta). Si un decrecimiento suficiente no es alcanzado, el subproblema (10.191), (10.236), es resuelto con un valor del parámetro δ_k menor. La globalización por las técnicas de regiones de confianza presenta esencialmente las mismas dificultades potenciales que la globalización con búsqueda lineal presentada arriba (posible inviabilidad de subproblemas, elección inadecuada del parámetro penalizador, el efecto de Maratos). Hay aún la cuestión adicional del control del parámetro δ_k . Es claro que para un valor de δ_k pequeño, el conjunto D_k en (10.236) puede ser vacío incluso cuando el sistema dado por la linealización de las restricciones (sin la restricción de la región de confianza $\|d\|_\infty \leq \delta_k$) posee soluciones (que se encuentran fuera de esta región de confianza).

Recientemente, fue propuesta una nueva estrategia de globalización, llamada de *estrategia de filtros*. Pensamos en el residuo de las restricciones (por ejemplo, dado por el término penalizador ψ en (10.190)) como un criterio a ser minimizado, adicional a aquel dado por la función objetivo f . De este modo, la minimización de este criterio adicional puede ser considerada hasta más importante que la de f (en muchas aplicaciones, una aproximación a la solución del problema, antes de nada, tiene que ser factible para tener sentido práctico). Notemos que una función penalizada representa el criterio agregado, donde a la parte ψ se le da un peso importante cuando el valor del parámetro penalizador es grande. Por otro lado, podemos pensar en el problema original (10.188) como un problema de optimización multicriterial en $\mathbb{R}^n$ (más precisamente, bicriterial, los criterios siendo f y ψ). En vez de utilizar el valor de una función de mérito escalar (función penalizada) para decidir sobre la aceptación o no de un punto $\tilde{x}$ como aproximación siguiente x^{k+1} a la solución del problema, podemos mirar separadamente los valores de las funciones f y ψ , y aceptar el punto $\tilde{x}$ si él mejora por lo menos uno de los dos criterios, con respecto a cada punto obtenido anteriormente. El método del filtro, por lo tanto, es un método con memoria. Después de la iteración k , tenemos en la memoria el filtro $\mathcal{F}_k$, i.e., un subconjunto de $\mathbb{R} \times \mathbb{R}$ finito, formado por pares $(f(x^j), \psi(x^j))$ calculados en las (algunas de las) iteraciones anteriores $j \leq k$. Son guardados en la memoria aquellos que no sean dominados por ningún otro par $(a_1, b_1) \in \mathcal{F}_k$ en el sentido de que las desigualdades $a_1 \geq a_2$ y $b_1 \geq b_2$ no pueden ser satisfechas simultáneamente. En particular, un punto $\tilde{x}$ será aceptado como el siguiente iterando x^{k+1} si el par $(f(\tilde{x}), \psi(\tilde{x}))$ no es dominado por ningún par en $\mathcal{F}_k$. Después de la aceptación de x^{k+1} , el nuevo filtro $\mathcal{F}_{k+1}$ es generado de la manera siguiente: el par $(f(\tilde{x}), \psi(\tilde{x}))$ entra en el filtro, mientras que todos los pares dominados por él son excluidos. Si $\tilde{x}$ no fue aceptado por la regla de arriba, disminuimos el valor de la longitud del paso α_k , o el valor del parámetro de la región de confianza δ_k , y probamos la nueva aproximación a la solución así obtenida. Esta descripción bien breve transmite apenas una idea general de la estrategia de filtros. Varios detalles tienen que ser cuidadosamente considerados e implementados para construir un método convergente.

Ejercicios del Capítulo

Sección 4.1: Métodos para conjuntos factibles de estructura simple

Ejercicio 10.1. Probar el ??.

Ejercicio 10.2. Probar las fórmulas siguientes.

(a) Si $D = B(\hat{x}, \delta)$, donde $\hat{x} \in \mathbb{R}^n$, $\delta > 0$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = \begin{cases} y, & \text{si } y \in D, \\ \hat{x} + \delta(y - \hat{x})/\|y - \hat{x}\|, & \text{si } y \in \mathbb{R}^n \setminus D. \end{cases}$$

(b) Si $D = \mathbb{R}_+^n$, entonces para todo $y \in \mathbb{R}^n$,

$$(P_D(y))_j = \max\{0, y_j\}, \quad j = 1, \dots, n.$$

(c) Si $D = \{x \in \mathbb{R}^n \mid x_j \in [a_j, b_j], j = 1, \dots, n\}$, donde $a_j \leq b_j, j = 1, \dots, n$, son números dados, entonces para todo $y \in \mathbb{R}^n$,

$$(P_D(y))_j = \begin{cases} a_j, & \text{si } y_j < a_j, \\ y_j, & \text{si } a_j \leq y_j \leq b_j, \\ b_j, & \text{si } y_j > b_j, \end{cases} \quad j = 1, \dots, n.$$

(d) Si $D = \{x \in \mathbb{R}^n \mid \langle a, x \rangle = b\}$, donde $a \in \mathbb{R}^n \setminus \{0\}, b \in \mathbb{R}$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = y + \frac{b - \langle a, y \rangle}{\|a\|^2} a.$$

(e) Si $D = \{x \in \mathbb{R}^n \mid \langle a, x \rangle \leq b\}$, donde $a \in \mathbb{R}^n \setminus \{0\}, b \in \mathbb{R}$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = y + \frac{\min\{0, b - \langle a, y \rangle\}}{\|a\|^2} a.$$

(f) Si $D = \{x \in \mathbb{R}^n \mid Ax = b\}$, donde $A \in \mathbb{R}^{l \times n}$ tiene rango $l, b \in \mathbb{R}^l$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = y - A^\top(AA^\top)^{-1}(Ay - b).$$

Ejercicio 10.3. Analizar las propiedades de convergencia del método del gradiente proyectado modificado, descrito en (??), suponiendo que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea una función continuamente diferenciable en $\mathbb{R}^n$ y D sea un conjunto convexo y cerrado.

Ejercicio 10.4. A partir del punto inicial $x^0 = (3, 1)$, hacer dos pasos del método del gradiente proyectado, con longitud de paso fijo, para el problema

$$\min x_1 - x_2 \quad \text{sujeto a } 1 \leq x_1 \leq 3, \quad 1 \leq x_2 \leq 2.$$

Ejercicio 10.5. Sea S_0 el conjunto de puntos estacionarios del problema original (??). Supongamos que, además de las hipótesis del ??, el conjunto de nivel $L_{f,D}(f(x^0))$ sea acotado. Probar que

$$\text{dist}(x^k, S_0 \cap L_{f,D}(f(x^0))) \rightarrow 0 \quad (k \rightarrow \infty).$$

(comparar con el ??).

Ejercicio 10.6. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función continuamente diferenciable y $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado. Considerar el método del gradiente proyectado con métrica variable, i.e., el esquema

$$x^{k+1} = x^k + \alpha_k(y^k - x^k),$$

donde $y^k \in \mathbb{R}^n$ es la solución del problema

$$\min \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle Q_k(x - x^k), x - x^k \rangle \quad \text{sujeto a } x \in D,$$

$Q_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, y el valor de la longitud de paso α_k es calculado por la regla de Armijo o por la regla de minimización unidimensional (si $Q_k = f''(x^k)$, obtenemos el método de Newton restringido a ser considerado en la ??). Mostrar que y^k también resuelve el problema

$$\min \|x - (x^k - Q_k^{-1} f'(x^k))\|_{Q_k}^2 \quad \text{sujeto a } x \in D,$$

donde la norma $\|\cdot\|_{Q_k}$ es dada por $\|x\|_{Q_k} = \sqrt{\langle Q_k x, x \rangle}$. Probar que si existen $c_2 \geq c_1 > 0$ tales que

$$c_1 \|x\|^2 \leq \langle Q_k x, x \rangle \leq c_2 \|x\|^2 \quad \forall x \in \mathbb{R}^n, \quad \forall k,$$

entonces todo punto de acumulación de una secuencia $\{x^k\}$ así generada, es un punto estacionario del problema original (??).

Ejercicio 10.7. Probar el ?? (sobre caracterización de direcciones factibles). Probar también que, en el caso de restricciones lineales (i.e., cuando g es una función afín), las desigualdades estrictas en la afirmación (b) del ?? pueden ser sustituidas por desigualdades no estrictas.

Ejercicio 10.8. Sea

$$D = \{x \in \mathbb{R}^n \mid Ax \leq a\},$$

donde $A \in \mathbb{R}^{m \times n}$ es una matriz con filas $A_i, i = 1, \dots, m, a \in \mathbb{R}^m$. Mostrar que para todo $x^k \in D$ y todo $d^k \in \mathcal{V}_D(x^k)$, para $\hat{\alpha}_k$ definido en (??) tenemos lo siguiente:

(a) Si $\langle A_i, d^k \rangle > 0$ para por lo menos un $i \in \{1, \dots, m\}$, entonces

$$\hat{\alpha}_k = \min \left\{ \frac{a_i - \langle A_i, x^k \rangle}{\langle A_i, d^k \rangle} \mid i = 1, \dots, m : \langle A_i, d^k \rangle > 0 \right\}.$$

(b) Si $\langle A_i, d^k \rangle \leq 0 \forall i = 1, \dots, m$, entonces $\hat{\alpha}_k = +\infty$.

Ejercicio 10.9. A partir del punto inicial $x^0 = 0$, hacer dos iteraciones del método del gradiente restringido, con longitud de paso calculado por la minimización unidimensional, para el problema

$$\min x_1^2 + 2x_2^2 - 3x_1 + 4x_2 \quad \text{sujeto a } x \in B(0, 2).$$

Ejercicio 10.10. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable con derivada Lipschitz-continua (con módulo $L > 0$) en el conjunto D que es convexo y compacto. Sea

$$+\infty > R = \max_{x, y \in D} \|x - y\|.$$

Dado un $x^k \in D$, sea $d^k = \bar{x}^k - x^k$, donde $\bar{x}^k$ es una solución del problema (??) de linealización de f .

(a) Probar que

$$\min_{\alpha \in [0, 1]} f(x^k + \alpha d^k) \leq f(x^k) + \Delta_k,$$

donde

$$0 \leq \Delta_k = \begin{cases} \frac{1}{2} \langle f'(x^k), d^k \rangle, & \text{si } \langle f'(x^k), d^k \rangle + L \|d^k\|^2 < 0, \\ -\frac{|\langle f'(x^k), d^k \rangle|^2}{2LR^2}, & \text{caso contrario.} \end{cases}$$

(b) Para el método del gradiente restringido con regla de longitud de paso de minimización unidimensional restringida, mostrar que todo punto de acumulación de la secuencia generada es un punto estacionario del problema de minimizar f en D .

Ejercicio 10.11. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $x^k \in D \subset \mathbb{R}^n, f'(x^k) \neq 0$. Probar los siguientes resultados sobre soluciones $\bar{x}^k$ del problema (??):

(a) Si $D = B(\hat{x}, \delta)$, donde $\hat{x} \in \mathbb{R}^n, \delta > 0$, entonces

$$\bar{x}^k = \hat{x} - \delta f'(x^k) / \|f'(x^k)\|.$$

(b) Si $D = \{x \in \mathbb{R}^n \mid x_j \in [a_j, b_j], j = 1, \dots, n\}$, donde se tiene que $a_j \leq b_j, j = 1, \dots, n$, entonces todo $\bar{x}^k$ satisfaciendo

$$\bar{x}_j^k = \begin{cases} a_j, & \text{si } f'_{x_j}(x^k) > 0, \\ b_j, & \text{si } f'_{x_j}(x^k) < 0, \\ \in [a_j, b_j], & \text{si } f'_{x_j}(x^k) = 0, \end{cases}$$

$j = 1, \dots, n$, es una solución.

(c) Si $D = \{x \in \mathbb{R}^n \mid x \geq 0, \sum_{i=1}^n x_i = c\}, c > 0$, entonces todo $\bar{x}^k$ satisfaciendo $\bar{x}_j^k = c$ para algún índice $j \in \{1, \dots, n\}$ tal que

$$f'_{x_j}(x^k) = \min\{f'_{x_i}(x^k) \mid i = 1, \dots, n\},$$

y $\bar{x}_i^k = 0$ para todo $i \in \{1, \dots, n\} \setminus \{j\}$, es una solución.

Ejercicio 10.12. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces continuamente diferenciable, con matriz Hessiana $f''(x)$ definida positiva en todo punto $x \in D$. Sea $\bar{x}$ un minimizador local de f en D . Probar que existe $\delta > 0$ tal que, si $\|x^0 - \bar{x}\| < \delta$, entonces el método de Newton restringido está bien definido y genera una secuencia $\{x^k\}$ satisfaciendo $\|x^k - \bar{x}\| < \delta \forall k; \{x^k\} \rightarrow \bar{x} (k \rightarrow \infty)$ y la tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal.

Sección 4.3: Métodos de penalización

Ejercicio 10.13. Probar las afirmaciones del ??, suponiendo que f y ψ son inferiormente semi-continuas en $\mathbb{R}^n$, ψ satisface (??), $D \neq \emptyset$ e $\inf_{x \in D} f(x) > -\infty$.

Ejercicio 10.14. Probar resultados análogos a aquellos de la ?? y del ??, para el método de penalización externa parcial.

Ejercicio 10.15. Suponiendo en vez de la existencia de una solución local estricta del problema (??), la existencia de un conjunto de soluciones locales compacto y aislado, probar un resultado análogo a aquel del ??. (Entendemos que un conjunto $S \subset \mathbb{R}^n$ de soluciones locales es aislado cuando existe un número $\delta > 0$ tal que la vecindad $U(S, \delta) = \{x \in \mathbb{R}^n \mid \text{dist}(x, S) < \delta\}$ de S no contiene soluciones locales que no pertenezcan a S).

Ejercicio 10.16. Considerar el problema (??), donde el conjunto factible D está dado por (??). Sean las funciones $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferenciables en una vecindad de una solución local $\bar{x} \in \mathbb{R}^n$ del problema, con derivadas continuas en este punto. Considerando el problema auxiliar

$$\min f(x) + \|x - \bar{x}\|^2 \quad \text{sujeto a } x \in D,$$

y utilizando los resultados del ?? y del ??, probar las condiciones de optimalidad de Fritz John (vea [12]).

Ejercicio 10.17. Sean $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en el punto $x \in \mathbb{R}^n$. Mostrar que la función ψ definida por (??) es diferenciable en x en cada dirección $d \in \mathbb{R}^n$, y se tiene que

$$\begin{aligned} \psi'(x; d) = & \sum_{i \in J^+(x)} \langle h'_i(x), d \rangle + \sum_{i \in J^0(x)} |\langle h'_i(x), d \rangle| \\ & - \sum_{i \in J^-(x)} \langle h'_i(x), d \rangle + \sum_{i \in I^+(x)} \langle g'_i(x), d \rangle \\ & + \sum_{i \in I^0(x)} \max\{0, \langle g'_i(x), d \rangle\}, \end{aligned}$$

donde $J^+(x) = \{i \mid h_i(x) > 0\}$, $J^0(x) = \{i \mid h_i(x) = 0\}$, etc.

Ejercicio 10.18. Probar resultados análogos a aquellos de los ??????, para la penalización exacta no-diferenciable dada por (??).

Ejercicio 10.19. Probar el mismo resultado del ?? suponiendo que la función f sea semi-continua inferiormente en $\mathbb{R}^n$, siendo las otras hipótesis las mismas del teorema.

Ejercicio 10.20. Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones convexas y diferenciables en $\mathbb{R}^n$. Sea $x(t)$ una solución del problema (??). Si la función barrera ψ es dada por (??), probar que

$$\bar{v} \leq f(x(t)) \leq \bar{v} + mt.$$

Si la función ψ es dada por (??), probar que

$$\bar{v} \leq f(x(t)) \leq \bar{v} - t \sum_{i=1}^m 1/g_i(x(t)).$$

Ejercicio 10.21. Probar análogos de la ?? y del ?? para el caso de la penalización interna parcial.

Sección 4.4: Métodos para problemas con restricciones de igualdad

Ejercicio 10.22. Resolver el problema

$$\min -x_1 x_2 \quad \text{sujeto a } x_1 + x_2 = 2,$$

utilizando el método de Newton para el sistema de Lagrange (el punto inicial puede ser arbitrario).

Ejercicio 10.23. Sean

$$R = \{x \in \mathbb{R}^n \mid \text{rank } h'(x) = l\},$$

$$\lambda_\tau: R \rightarrow \mathbb{R}^l, \quad \lambda_\tau(x) = (h'(x)(h'(x))^T)^{-1}(\tau h(x) - h'(x)f'(x)),$$

donde $\tau \in \mathbb{R}$ es un parámetro. Suponiendo que $\bar{x}$ sea un punto estacionario del problema (??), que satisface la condición de regularidad de las restricciones (??), calcular la derivada de $\lambda_\tau(\cdot)$ en $\bar{x}$. Utilizando el resultado obtenido, construir un método de Newton inexacto para la ecuación

$$L'_x(x, \lambda_\tau(x)) = 0$$

con respecto a $x \in \mathbb{R}^n$. Eligiendo τ de manera adecuada, analizar las propiedades de convergencia de este método.

Ejercicio 10.24. Probar los siguientes hechos que complementan las afirmaciones del ??:

(a) Para todo número $\varepsilon > 0$ existe un número $c(\varepsilon) \geq \bar{c}$ tal que, para todo $c > c(\varepsilon)$, se tiene que

$$\frac{\|(L''_{xx}(\bar{x}, \bar{\lambda}))^{-1}\|\|\bar{\lambda} - \varepsilon\|}{c} \leq \|x(c) - \bar{x}\| \leq \frac{\|(L''_{xx}(\bar{x}, \bar{\lambda}))^{-1}\|\|\bar{\lambda} + \varepsilon\|}{c}.$$

(b) Para todo $c > \bar{c}$ suficientemente grande, se tiene que la matriz $\varphi''(x(c); c)$ es definida positiva, i.e., el punto estacionario $x(c)$ del problema (??) satisface la condición suficiente de segunda orden del ??(b).

Ejercicio 10.25. Utilizando el método de penalización cuadrática, resolver el problema

$$\min x \quad \text{sueto a } x^p = 0,$$

donde $p \geq 2$ es un parámetro entero. Analizar la tasa de convergencia y explicar el fenómeno observado.

Ejercicio 10.26. Utilizando el método de penalización cuadrática, resolver los problemas:

$$\min 2x_1^2 + (x_2 - 1)^2 \quad \text{sueto a } x \in D = \{x \in \mathbb{R}^2 \mid 2x_1 + x_2 = 0\},$$

$$\min x_1^2 + 2x_2^2 \quad \text{sueto a } x \in D = \{x \in \mathbb{R}^2 \mid 3x_1 + x_2 = 3\}.$$

Ejercicio 10.27. Probar que, si para algunos $c > 0$ y $\lambda \in \mathbb{R}^l$, $x \in \mathbb{R}^n$ es un punto estacionario para el problema (??), y se tiene $\text{rank } h'(x) = l$, entonces

$$\lambda + ch(x) = -(h'(x)(h'(x))^T)^{-1}h'(x)f'(x)$$

(comparar con el Ejercicio 10.23).

Ejercicio 10.28. Probar el siguiente complemento de la afirmación (a) del ??: para cualquier par $(\lambda, c) \in \Delta(\bar{c}, \delta)$, si c es suficientemente grande, entonces la matriz $L''_{xx}(x(\lambda, c), \lambda; c)$ es definida positiva, i.e., el punto estacionario $x(\lambda, c)$ del problema (??) satisface la condición suficiente de segunda orden del ??(b) (comparar con el ítem (b) del Ejercicio 10.24 y con el ??).

Ejercicio 10.29. Probar el ítem (a) del ??.

Ejercicio 10.30. Sea $R \subset \mathbb{R}^n$ el conjunto definido en el Ejercicio 10.23. Definimos

$$C(x) = (h'(x)(h'(x))^T)^{-1}h'(x), \quad \lambda(x) = -C(x)f'(x), \quad x \in R.$$

Mostrar que para la familia de funciones definida en (??), vale lo siguiente: para todo c y todo $x \in R$,

$$\min_{\lambda \in \mathbb{R}^l} \varphi(x, \lambda; c+1) = \varphi(x, \lambda(x); c+1) = L(x, \lambda(x); c).$$

Ejercicio 10.31. Construir y analizar métodos de Newton inexactos para los problemas de optimización irrestricta (??) y (??) con funciones objetivo dadas por las fórmulas (??) y (??), respectivamente, así como para el problema

$$\min L(x, \lambda(x); c) \quad \text{sueto a } x \in R$$

(en notación del Ejercicio 10.30).

Sección 4.5: Métodos para problemas con restricciones mixtas

Ejercicio 10.32. Mostrar que la función del residuo natural definida en (??) y la función de Fischer-Burmeister en (??) son efectivamente funciones de complementariedad.

Ejercicio 10.33. Sea $\omega : \mathbb{R} \rightarrow \mathbb{R}$ una función creciente cualquiera, $\omega(0) = 0$. Mostrar que

$$\psi : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}, \quad \psi(a, b) = \omega(|a - b|) - \omega(a) - \omega(b),$$

es una función de complementariedad.

Ejercicio 10.34. Sea $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ una función diferenciable en $\mathbb{R}^n$. Definamos una función $\Phi : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^m$ con componentes

$$\Phi_i(x, \mu) = \psi(-g_i(x), \mu_i), \quad x \in \mathbb{R}^n, \mu \in \mathbb{R}^m, i = 1, \dots, m,$$

donde ψ es la función de complementariedad del residuo natural (??). Mostrar que para todo $x \in \mathbb{R}^n$ tal que la derivada de g sea continua en x , y todo $\mu \in \mathbb{R}^m$, el B-diferencial $\partial_B \Phi(x, \mu)$ es el conjunto de matrices de la forma $(-A(x, \mu)g'(x), E^m - A(x, \mu))$, donde $A(x, \mu)$ es la matriz diagonal $m \times m$ con elementos

$$a_i(x, \mu) = \begin{cases} 1, & \text{si } \mu_i > -g_i(x), \\ 0 \text{ o } 1, & \text{si } \mu_i = -g_i(x), \\ 0, & \text{si } \mu_i < -g_i(x), \end{cases} \quad i = 1, \dots, m.$$

Ejercicio 10.35. En las condiciones del Ejercicio 10.34, considerar el caso en que ψ es la función de complementariedad de Fischer-Burmeister. Mostrar que para todo $x \in \mathbb{R}^n$ tal que la derivada de g sea continua en x , y todo $\mu \in \mathbb{R}^m$, $\partial_B \Phi(x, \mu)$ es el conjunto de matrices de la forma $(A(x, \mu)g'(x), B(x, \mu))$, donde $A(x, \mu)$ y $B(x, \mu)$ son las matrices diagonales $m \times m$ con elementos

$$a_i(x, \mu) = \begin{cases} 1 + \frac{g_i(x)}{\sqrt{\mu_i^2 + g_i^2(x)}}, & \text{si } |\mu_i| + |g_i(x)| \neq 0, \\ 1 + \alpha_i, & \text{si } |\mu_i| + |g_i(x)| = 0, \end{cases}$$

$$b_i(x, \mu) = \begin{cases} \frac{\mu_i}{\sqrt{\mu_i^2 + g_i^2(x)}} - 1, & \text{si } |\mu_i| + |g_i(x)| \neq 0, \\ \beta_i - 1, & \text{si } |\mu_i| + |g_i(x)| = 0, \end{cases}$$

con $\alpha_i, \beta_i \in \mathbb{R}, \alpha_i^2 + \beta_i^2 = 1, i = 1, \dots, m$.

Ejercicio 10.36. Mostrar que la función diferenciable $\psi(a, b) = 2ab - (\min\{0, a + b\})^2$ definida en (??) es una función de complementariedad.

Ejercicio 10.37. Utilizando los resultados del (B-diferencial y subdiferencial de Clarke), probar la ??.

Ejercicio 10.38. Probar que para $f : \mathbb{R}^n \rightarrow \mathbb{R}, h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ cualesquiera, el punto $\bar{x} \in \mathbb{R}^n$ es una solución local (estricta) del problema (??) si, y solamente si, el punto $(\bar{x}, \bar{t})$, donde $\bar{t} \in \mathbb{R}^m$ es dado por (??), está bien definido y es una solución local (estricta) del problema (??)-(??).

Ejercicio 10.39. Probar que para cualesquiera $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferenciables en el punto $x \in \mathbb{R}^n$, la validez de la condición de independencia lineal de los gradientes extendida (??) en x implica la condición de regularidad de las restricciones del problema (??)-(??) en el punto (x, t) para todo $t \in \mathbb{R}^m$ tal que $t_i \neq 0 \forall i \in \{1, \dots, m\} \setminus (I(x) \cup I^+(x))$.

Ejercicio 10.40. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}, h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones continuas en el punto $\bar{x} \in \mathbb{R}^n$. Mostrar que para todo $c \geq 0$, un punto $\bar{x}$ es solución local (estricta) del problema (??) con función objetivo dada por (??), (??), si, y solamente si, el punto $(\bar{x}, t(\bar{x}))$, donde la parte $t(\bar{x}) \in \mathbb{R}^m$ evalúa la holgura óptima definida por (??), es solución local (estricta) del problema (??) con función objetivo definida por (??), (??).

Ejercicio 10.41. Utilizando los (??), así como el ?? y el ítem (b) del Ejercicio 10.24, probar el ??.

Ejercicio 10.42. Utilizando el método de penalización cuadrática, resolver el problema

$$\min x^2 - 4x \quad \text{sueto a } x \in D = \{x \in \mathbb{R} \mid x \leq 1\}.$$

Ejercicio 10.43. Probar el ??.

Ejercicio 10.44. Probar el ??.

Ejercicio 10.45. Utilizando los (??), el ?? y el Ejercicio 10.28, probar el ??.

Ejercicio 10.46. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}, h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Mostrar que si $\bar{x}$ es un punto estacionario del problema (??), con multiplicadores de Lagrange $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$

asociados, entonces para todo $c_1 > 0$ y $c_2 \geq 0$, el punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$ es estacionario para el problema (??) con función objetivo dada por la fórmula (??).

Ejercicio 10.47. Probar el ??.

Ejercicio 10.48. Utilizando los ????, el ?? y el Ejercicio 10.46, probar el ??.

Sección 4.6: Programación cuadrática secuencial (SQP)

Ejercicio 10.49. Establecer relaciones entre el subproblema definido para (10.144) con la matriz $H_k = L''_{xx}(x^k, \lambda^k)$ dada en (10.145), y el subproblema análogo, donde

$$H_k = L''_{xx}(x^k, \lambda^k) + c_k(h'(x^k))^T h'(x^k),$$

$c_k > 0$. ¿Cuáles son las posibles ventajas de esta segunda elección en el contexto de SQP?

Ejercicio 10.50. Para el problema (10.143), considerar el siguiente método del gradiente proyectado modificado:

$$x^{k+1} = P_{D_k}(x^k - \alpha_k f'(x^k)), \quad k = 0, 1, \dots,$$

donde $\alpha_k > 0$ es el parámetro de longitud de paso, y el conjunto D_k es el mismo de (10.144). Establecer relaciones con el método SQP (con elección de H_k correspondiente). Estudiar convergencia local de este método.

Ejercicio 10.51. Mostrar que si $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es una función afín, g es una función convexa diferenciable en el punto $x^k \in \mathbb{R}^n$, y el conjunto factible D del problema original (10.188) es no-vacío, entonces el conjunto factible D_k del subproblema (10.191)-(10.192) también es no-vacío, para todo k .

Ejercicio 10.52. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones dos veces diferenciables. Considerar el problema (??)-(??),

$$\min c_k t + \langle f'(x^k), d \rangle + \frac{1}{2} \langle H_k d, d \rangle \quad \text{sujeto a } (t, d) \in U_k,$$

donde $c_k > 0$. Sea la función φ dada por (10.189), donde la función ψ es dada por (10.190). Mostrar que si $d^k \neq 0$, entonces d^k es una dirección de descenso para la función $\varphi(\cdot; c_k)$ en el punto x^k .

11. Métodos para optimización no diferenciable

Este capítulo está dedicado al área de la optimización convexa no diferenciable. Resaltamos que las técnicas que se presentarán son relevantes incluso para la resolución de algunas clases de problemas que son, en principio, diferenciables y/o no convexos. Más precisamente, estamos hablando de aplicaciones prácticas de gran escala cuya resolución emplea estrategias de relajación Lagrangiana¹, así como algunas otras técnicas de descomposición. Como vimos en [SolodovVol1] (véase también la ??), el dual de un problema de optimización cualquiera puede ser considerado como un problema de programación convexa, pero no diferenciable. Con frecuencia, la resolución del problema dual proporciona información muy útil sobre el problema primal y, bajo ciertas condiciones, puede incluso resultar en la resolución exacta del primal. Como veremos a continuación, los problemas no diferenciables necesitan el desarrollo de técnicas computacionales propias, diferentes de aquellas para el caso diferenciable.

Consideremos entonces el problema

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (11.1)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa en $\mathbb{R}^n$. Estamos pensando en situaciones en las que es cierto que f no es diferenciable, o cuando la diferenciabilidad de f difícilmente puede ser esperada.

Por el Teorema 6.12(a), la derivada direccional de la función f en el punto $x \in \mathbb{R}^n$ en la dirección $d \in \mathbb{R}^n$ satisface la condición

$$f'(x; d) = \max\{\langle y, d \rangle \mid y \in \partial f(x)\}, \quad (11.2)$$

donde $\partial f(x)$ es el subdiferencial de f en el punto x , i.e.,

$$\partial f(x) = \{y \in \mathbb{R}^n \mid f(z) \geq f(x) + \langle y, z - x \rangle \quad \forall z \in \mathbb{R}^n\}.$$

De la relación (11.2), obtenemos la siguiente condición que es necesaria y suficiente para que $d \in \mathbb{R}^n$ sea una dirección de descenso de f en el punto x :

$$d \in \mathcal{D}_f(x) \iff \langle y, d \rangle < 0 \quad \forall y \in \partial f(x).$$

Una consecuencia inmediata de esto es el siguiente hecho, claramente desafortunado: para obtener una dirección de descenso de la función f en un punto dado x , necesitamos conocer todo el conjunto subdiferencial $\partial f(x)$ (recordamos que este conjunto siempre es no vacío; véase el Teorema 6.12). En particular, tomando un subgradiente cualquiera, la dirección de anti-subgradiente puede no ser de descenso, como veremos en el siguiente ejemplo.

Ejemplo 11.1. Sea $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, $f(x) = |x_1| + 2|x_2|$. Consideremos un punto $x = (x_1, 0)$, donde $x_1 > 0$ es arbitrario. Como es muy fácil de verificar,

$$y = (1, 2) \in \partial f(x).$$

Sin embargo, para todo $t > 0$ suficientemente pequeño,

$$f(x - ty) = |x_1 - t| + 2|0 - 2t| = x_1 - t + 4t = x_1 + 3t > x_1 = f(x),$$

lo que muestra que

$$-y \notin \mathcal{D}_f(x).$$

Este hecho se ilustra en la figura 11.1.

Es importante resaltar que, en la gran mayoría de las aplicaciones prácticas, conocer todo el conjunto $\partial f(x)$ para cada x , es decir, todos los subgradientes, no puede ser esperado. Un buen ejemplo de esta situación es la

¹En inglés: *Lagrangian relaxation*.




Figura 11.1.: Las curvas de nivel de la función $f(x) = |x_1| + 2|x_2|$, las direcciones de descenso en el punto $x = (x_1, 0)$, donde $x_1 > 0$, y la dirección $-y = -(1, 2)$ que es un anti-subgradiente de f en x pero no es una dirección de descenso de f en x .

relajación Lagrangiana, donde la evaluación de la función dual en un punto dado proporciona, en general, apenas un subgradiente (véase la Proposición 6.2). Es válido afirmar, sin lugar a dudas, que un método para optimización no diferenciable solo puede ser considerado práctico si funciona utilizando información *incompleta*. O sea, para cada punto dado, la información disponible consiste en valores de la función objetivo y de *un* subgradiente en este punto (y de construcciones que pueden ser obtenidas a través de información de este tipo, acumulada a lo largo de iteraciones anteriores).

Lo expuesto arriba ya muestra que la utilización de ideas de descenso, comunes y naturales en el caso diferenciable, va a ser problemática en el caso en consideración. Al menos sin modificaciones bastante profundas.

Otra dificultad importante consiste en la elección de reglas de parada confiables. En el caso de optimización diferenciable, una regla de parada razonable está dada por la condición $\|\nabla f(x^k)\| \leq \varepsilon$, donde $\varepsilon > 0$ es suficientemente pequeño. Es fácil ver que esta regla no puede ser extendida de manera directa al caso no diferenciable (esto tiene que ver con la falta de “continuidad” del operador punto-conjunto $x \mapsto \partial f(x)$). Para ver esto, consideremos el siguiente ejemplo, bien simple.

Ejemplo 11.2. Sean $n = 1$, $f(x) = |x|$, $x \in \mathbb{R}$. Para cualquier punto $x^k \neq 0$, no importa cuán próximo a la solución $\bar{x} = 0$ del problema (11.1), se tiene que $|y| = 1$ para todo $y \in \partial f(x^k)$. O sea, no importa cuán próximo está $x^k \neq 0$ a la solución, en x^k no hay ningún subgradiente con norma pequeña. Más aún, incluso si tuviéramos la suerte de encontrar la solución exacta después de un número finito de iteraciones, i.e., $x^k = 0$ para algún k , este hecho puede no ser reconocido (y el método no va a parar) si conocemos apenas un subgradiente en cada punto. Esto porque la “caja negra”, que calcula subgradientes, puede proporcionar cualquier $y \in \partial f(0) = [-1, 1]$ y, por lo tanto, $|y|$ puede ser grande.

No entrando en detalles, afirmamos que otros tipos de reglas de parada, comunes en el caso diferenciable, también son completamente inadecuadas en el caso no diferenciable.

En este capítulo, primero consideraremos **métodos de subgradiente**, bien básicos. Entre otras cosas, esto se debe a razones históricas. Sin embargo, es importante dejar claro que los métodos de subgradiente son rústicos y generalmente ineficientes. Aún son utilizados, en gran parte debido a su extrema simplicidad, por personas de otras áreas que con frecuencia no conocen opciones más sofisticadas. Profesionales en optimización emplean métodos de subgradiente solamente en aplicaciones donde una aproximación a la solución bien grosera puede ser aceptable. Notemos también que los métodos de subgradiente no permiten ninguna regla de parada razonable. Este último problema es resuelto con el **método de planos cortantes**, que consideraremos a continuación. Cada iteración de este método consiste en la minimización del máximo de funciones afines, acumuladas en las iteraciones anteriores, que aproximan la función objetivo inferiormente. Notemos que esto puede ser hecho resolviendo un problema de programación lineal. Sin embargo, el método de planos cortantes también tiene algunas deficiencias serias. Por ejemplo, inestabilidad numérica. Los métodos verdaderamente satisfactorios son las versiones estabilizadas del método de planos cortantes, llamados **métodos de haces** (*bundle methods*). Cada iteración de estos métodos consiste en la minimización del máximo de *algunas* de las funciones afines acumuladas en las iteraciones anteriores, más

un término cuadrático estabilizador. Notemos que esto puede ser hecho resolviendo un problema de programación cuadrática. Los métodos de haces ya vienen con reglas de parada confiables, control efectivo del tamaño de los subproblemas a ser resueltos en cada iteración (lo que no es posible en el método de planos cortantes), y eficiencia computacional comprobada. Puede decirse que fue el desarrollo de los métodos de haces lo que posibilitó la resolución de problemas no diferenciables en aplicaciones prácticas, especialmente cuando la precisión es importante.

11.1. Métodos de subgradiente

En los métodos de subgradiente, la dificultad para garantizar el descenso de la función objetivo en cada iteración (véase el Ejemplo 11.1 y los comentarios asociados) es “resuelta” simplemente fijando a priori una sucesión de valores de las longitudes de paso, sin preocuparse por el descenso de la función objetivo (al menos de una iteración para otra). Es bien claro que la fijación de la longitud de paso para una iteración k antes de que el punto x^k sea calculado (así como los valores $f(x^k)$ y $y^k \in \partial f(x^k)$), difícilmente puede dar una buena elección. Por lo tanto, esta manera de sortear la dificultad asociada al descenso de la función objetivo es puramente formal y, aun cuando resuelva la situación en el análisis de convergencia teórica, no es satisfactoria en la realidad.

A continuación introducimos el método de subgradiente básico, donde utilizaremos subgradientes aproximados. Esto torna el esquema un poco más práctico, por lo menos en este aspecto (obviamente, la posibilidad de utilizar subgradientes aproximados no resuelve las dificultades principales, comentadas anteriormente). Recordemos que para $\varepsilon \geq 0$, el ε -subdiferencial de la función f en el punto $x \in \mathbb{R}^n$ (véase apartado 6.3) viene dado por

$$\partial_\varepsilon f(x) = \{y \in \mathbb{R}^n \mid f(z) \geq f(x) + \langle y, z - x \rangle - \varepsilon \quad \forall z \in \mathbb{R}^n\}. \quad (11.3)$$

El subdiferencial $\partial f(x)$ es obtenido tomando $\varepsilon = 0$.

Algoritmo 5.1.1. (El método de subgradiente)

Elegir sucesiones $\{\varepsilon_k\}, \{\alpha_k\} \subset \mathbb{R}_+$. Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular $d^k \in \partial_{\varepsilon_k} f(x^k)$.
2. Calcular

$$x^{k+1} = x^k - \alpha_k d^k. \quad (11.4)$$

3. Tomar $k := k + 1$ y retornar al Paso 1.

Estudiaremos propiedades de convergencia del Algoritmo 5.1.1.

Teorema 11.1 (Convergencia del método de subgradiente I). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa en $\mathbb{R}^n$. Supongamos que en el Algoritmo 5.1.1 las sucesiones $\{\varepsilon_k\}, \{\alpha_k\}$ y $\{d^k\}$ satisfacen las condiciones

$$\sum_{k=0}^{\infty} \alpha_k = +\infty, \quad (11.5)$$

$$\lim_{k \rightarrow \infty} \varepsilon_k = 0, \quad (11.6)$$

$$\lim_{k \rightarrow \infty} \alpha_k \|d^k\|^2 = 0. \quad (11.7)$$

Entonces, para la sucesión $\{x^k\}$ generada por el Algoritmo 5.1.1, se tiene que

$$\liminf_{k \rightarrow \infty} f(x^k) = \bar{v},$$

donde $\bar{v} = \inf_{x \in \mathbb{R}^n} f(x)$.

Prueba. Por las relaciones (11.3) y (11.4), para cualquier $x \in \mathbb{R}^n$ tenemos que

$$\begin{aligned} \|x^{k+1} - x\|^2 &= \|x^k - x\|^2 + 2\langle x^{k+1} - x^k, x^k - x \rangle + \|x^{k+1} - x^k\|^2 \\ &= \|x^k - x\|^2 + 2\alpha_k \langle d^k, x - x^k \rangle + \alpha_k^2 \|d^k\|^2 \\ &\leq \|x^k - x\|^2 + 2\alpha_k (f(x) - f(x^k) + \varepsilon_k) + \alpha_k^2 \|d^k\|^2. \end{aligned} \quad (11.8)$$

Supongamos que la afirmación no sea verdadera, i.e., que $\liminf_{k \rightarrow \infty} f(x^k) > \bar{v}$. En este caso, existen $x \in \mathbb{R}^n$, un número $\delta > 0$ y un índice $\bar{k}$, tales que

$$f(x) < f(x^k) - \delta \quad \forall k \geq \bar{k}. \quad (11.9)$$

De (11.6) y (11.7), se sigue que podemos tomar $\bar{k}$ suficientemente grande para satisfacer

$$\alpha_k \|d^k\|^2 + 2\varepsilon_k \leq \delta \quad \forall k \geq \bar{k}.$$

Combinando esta última relación con (11.8) y (11.9), obtenemos que

$$\begin{aligned} \|x^{k+1} - x\|^2 &\leq \|x^k - x\|^2 + \alpha_k(2\varepsilon_k + \alpha_k \|d^k\|^2 - 2\delta) \\ &\leq \|x^k - x\|^2 - \delta\alpha_k \quad \forall k \geq \bar{k}. \end{aligned}$$

Por lo tanto,

$$\delta \sum_{i=\bar{k}}^k \alpha_i \leq \sum_{i=\bar{k}}^k (\|x^i - x\|^2 - \|x^{i+1} - x\|^2) = \|x^{\bar{k}} - x\|^2 - \|x^{k+1} - x\|^2 \leq \|x^{\bar{k}} - x\|^2,$$

de donde obtenemos una contradicción con (11.5) cuando $k \rightarrow \infty$. ■

Si hiciéramos una normalización de las direcciones empleadas en el Algoritmo 5.1.1, las afirmaciones sobre convergencia del método pueden ser fortalecidas (para una elección de longitudes de paso más específica, véase (11.10) y (11.12) a continuación). Para simplificar, consideremos el caso de subgradientes exactos. Obtenemos entonces el esquema siguiente:

$$x^{k+1} = x^k - \beta_k \frac{d^k}{\|d^k\|}, \quad d^k \in \partial f(x^k), \quad k = 0, 1, \dots, \quad (11.10)$$

donde $\beta_k > 0$ es el parámetro de longitud de paso (naturalmente, si en x^k calculamos el subgradiente $d^k = 0$, el método se detiene).

Teorema 11.2 (Convergencia del método de subgradiente II). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa en $\mathbb{R}^n$. Supongamos que el problema (11.1) tenga una solución. Supongamos que en el Algoritmo 5.1.1,

$$\varepsilon_k = 0, \quad \alpha_k = \frac{\beta_k}{\|d^k\|} \quad \forall k, \quad (11.11)$$

lo que corresponde a (11.10), y que la sucesión $\{\beta_k\}$ satisfaga las condiciones

$$\sum_{k=0}^{\infty} \beta_k = +\infty, \quad \sum_{k=0}^{\infty} \beta_k^2 < +\infty. \quad (11.12)$$

Entonces toda sucesión $\{x^k\}$ generada por el Algoritmo 5.1.1 converge a una solución del problema (11.1).

Prueba. Sea $\bar{x} \in \mathbb{R}^n$ una solución del problema (11.1). Obviamente, $f(\bar{x}) \leq f(x^k)$ para todo k . Tomando en (11.8) $x = \bar{x}$, y teniendo en cuenta también (11.11), obtenemos que

$$\|x^{k+1} - \bar{x}\|^2 \leq \|x^k - \bar{x}\|^2 + \beta_k^2.$$

El resto de la demostración es similar a la parte correspondiente del Teorema 3.3. Sea k arbitrario pero fijo. Utilizando la última desigualdad en cadena, para cualquier $j \geq k + 1$, obtenemos

$$\begin{aligned} \|x^j - \bar{x}\|^2 &\leq \|x^k - \bar{x}\|^2 + \sum_{i=k}^{j-1} \beta_i^2 \\ &\leq \|x^k - \bar{x}\|^2 + \sum_{i=0}^{\infty} \beta_i^2 < +\infty, \end{aligned} \quad (11.13)$$

por la segunda relación en (11.12). Concluimos que la sucesión $\{x^k\}$ es acotada. Por lo tanto, por el Teorema 6.12, la sucesión $\{d^k\}$ también es acotada (ya que $d^k \in \partial f(x^k)$ para todo k). Por eso, de (11.11) y (11.12), obtenemos que las relaciones (11.5)-(11.7) se satisfacen. Ahora, por el Teorema 11.1, tenemos que $\liminf_{k \rightarrow \infty} f(x^k) = f(\bar{x})$. Teniendo en cuenta la continuidad de la función f en $\mathbb{R}^n$ (véase el Teorema 6.7) y el hecho de que la sucesión $\{x^k\}$ es acotada, concluimos que $\{x^k\}$ posee un punto de acumulación $\hat{x} \in \mathbb{R}^n$ tal que $f(\hat{x}) = f(\bar{x})$, i.e., $\hat{x}$ es una solución del problema (11.1).

Podemos entonces tomar $\bar{x} = \hat{x}$ en el análisis previo, para concluir, de (11.13), que para todo $j \geq k + 1$

$$\|x^j - \hat{x}\|^2 \leq \|x^k - \hat{x}\|^2 + \sum_{i=k}^{\infty} \beta_i^2, \quad (11.14)$$

donde, de (11.12),

$$\lim_{k \rightarrow \infty} \left(\sum_{i=k}^{\infty} \beta_i^2 \right) = 0.$$

En particular, para todo $\delta > 0$ arbitrariamente pequeño, podemos escoger k suficientemente grande, tal que

$$\delta/2 > \sum_{i=k}^{\infty} \beta_i^2.$$

Como $\hat{x}$ es un punto de acumulación de la sucesión $\{x^k\}$, podemos también escoger un k tal que

$$\delta/2 > \|x^k - \hat{x}\|^2.$$

De (11.14), concluimos que para todo $\delta > 0$, existe k tal que

$$\delta > \|x^j - \hat{x}\|^2 \quad \forall j \geq k+1.$$

Esto significa que $\{x^k\}$ converge a $\hat{x}$, que es una solución del problema. ■

La propiedad que hace a los métodos de subgradiente funcionar es la siguiente. Si $\bar{x}$ es un minimizador de f , de (11.8) tenemos que

$$\|x^{k+1} - \bar{x}\|^2 \leq \|x^k - \bar{x}\|^2 - 2\alpha_k(f(x^k) - f(\bar{x})) + \alpha_k^2 \|d^k\|^2,$$

donde $d^k \in \partial f(x^k)$. De donde obtenemos que

$$\|x^{k+1} - \bar{x}\|^2 < \|x^k - \bar{x}\|^2$$

si

$$0 < \alpha_k < \frac{2(f(x^k) - f(\bar{x}))}{\|d^k\|^2}.$$

O sea, para pasos suficientemente cortos, la distancia al conjunto de soluciones disminuye. Sin embargo, cuando no conocemos el valor óptimo del problema, no hay cómo escoger una longitud de paso que garantice esta propiedad. Es por eso que tenemos que emplear reglas del tipo (11.12), para que los valores de las longitudes de paso sean suficientemente cortos asintóticamente.

Introduciendo el operador de proyección, los métodos de subgradiente pueden ser fácilmente extendidos al caso de optimización con restricciones. Naturalmente, estamos hablando de conjuntos viables convexos y, por razones prácticas, de estructura simple (que permita fórmulas de proyección explícitas).

Ejercicio 11.1. Consideremos el problema

$$\min f(x) \quad \text{sujeto a } x \in D,$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa en $\mathbb{R}^n$ y $D \subset \mathbb{R}^n$ es un conjunto convexo y cerrado. Consideremos la modificación del Algoritmo 5.1.1, donde cambiamos la fórmula (11.4) por la fórmula

$$x^{k+1} = P_D(x^k - \alpha_k d^k).$$

Para esta modificación del Algoritmo 5.1.1 y el problema arriba, probar resultados análogos a aquellos de los Teoremas 11.1 y 11.2.

La única atracción de los métodos de subgradiente es su extrema simplicidad (cuando el cálculo de subgradientes es fácil). Infelizmente, como ya comentamos arriba, estos métodos son poco eficientes y, a veces, completamente inútiles. La fijación a priori de valores de longitud de paso es una estrategia pésima. Es verdad que, en principio, podemos intentar definir β_k en la iteración k misma (y no fijar toda la sucesión $\{\beta_k\}$ justo al inicio). Existen algunas sugerencias en este sentido, que hasta pueden funcionar bien en la práctica para algunos tipos de problemas. Sin embargo, no hay nada claro sobre cómo hacer eso de manera matemáticamente sólida (en particular, para satisfacer las condiciones de convergencia del método). En este sentido, podemos afirmar también que las dos condiciones en (11.12) que la sucesión $\{\alpha_k\}$ debe satisfacer son, desde el punto de vista numérico, contradictorias: la segunda condición precisa que $\beta_k \rightarrow 0$ ($k \rightarrow \infty$), lo que torna β_k nulo para k grande en cualquier implementación computacional. Y esto imposibilita la validez de la primera condición en (11.12). Por otro lado, el número de varias sucesiones $\{\beta_k\}$ que satisfacen (11.12) es claramente infinito, y el método no suministra ninguna estrategia para preferir una elección a otra (ni a priori, ni en una iteración k dada). Esto indica que un método así difícilmente puede ser eficiente.

Notemos también que un método con longitudes de paso dados por una regla del tipo (11.12), necesariamente tiene una tasa de convergencia muy lenta; en particular, *sublineal*. Y este es el caso incluso para problemas muy bien

comportados. O sea, no importan las hipótesis y propiedades de un problema dado. La tasa de convergencia siempre es peor que lineal. Es claro que esto no es satisfactorio.

Otra deficiencia, ya mencionada anteriormente, es que los métodos de subgradiente no poseen ninguna regla de parada confiable. La situación en que $\|d^k\| \leq \varepsilon$ puede nunca ocurrir (véase el Ejemplo 11.2). Por otro lado, la situación en que $\|x^{k+1} - x^k\| \leq \varepsilon$ (que es otra regla de parada popular en el caso diferenciable) no significa absolutamente nada en este contexto, ya que $\{\beta_k\} \rightarrow 0$ ($k \rightarrow \infty$) y, por lo tanto, $\|x^{k+1} - x^k\| \rightarrow 0$, independientemente de cualquier cosa.

Existen, sin embargo, unos pocos casos en los que los métodos de subgradiente pueden ser ligeramente mejorados. Una situación de este tipo es cuando el valor óptimo $\bar{v}$ del problema (11.1) es conocido.

Ejercicio 11.2. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa en $\mathbb{R}^n$. Supongamos que el problema (11.1) posee una solución y $\bar{v} = \min_{x \in \mathbb{R}^n} f(x)$. Probar que cualquier sucesión $\{x^k\}$ generada por el esquema (11.10), donde $\beta_k = f(x^k) - \bar{v}$, converge a una solución de (11.1), y se tiene que

$$\liminf_{k \rightarrow \infty} \sqrt{k}(f(x^k) - \bar{v}) = 0.$$

Si, además, la condición de crecimiento lineal de f se satisface, i.e., si existen una vecindad U del conjunto de soluciones S de (11.1) y un número $\gamma > 0$ tales que

$$f(x) - \bar{v} \geq \gamma \text{dist}(x, S) \quad \forall x \in U,$$

entonces la tasa de convergencia (en relación a las variables) es geométrica.

Cuando el valor de $\bar{v}$ no es conocido, podemos intentar modificar el método del Ejercicio 11.2, haciendo actualización dinámica de aproximaciones inferiores para el valor de $\bar{v}$.

11.2. El método de planos cortantes

Consideremos el problema

$$\min f(x) \quad \text{sujeto a} \quad x \in D, \quad (11.15)$$

donde $D \subset \mathbb{R}^n$ es un conjunto convexo y cerrado, y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa en $\mathbb{R}^n$. Supongamos también que D sea acotado, lo que es necesario para garantizar la existencia de soluciones en los subproblemas del método a ser estudiado, principalmente en las iteraciones iniciales (la primera iteración consiste en la minimización de una función afín sobre el conjunto D , que claramente no tiene solución si $D = \mathbb{R}^n$).

La idea principal del método de planos cortantes consiste en la utilización de la información acumulada a lo largo de las iteraciones anteriores para construir una aproximación (inferior) de la función f , lineal por partes, cada vez más precisa. En particular, este método pertenece a la clase de *métodos con memoria* (véase ??). Consideramos que al inicio de la iteración con índice $k + 1$, tenemos la siguiente información en la memoria: $x^i \in \mathbb{R}^n$, $y^i \in \partial f(x^i)$, $i = 0, 1, \dots, k$. La iteración (indexada por $k + 1$) del método de planos cortantes consiste en la resolución del problema

$$\min \psi_k(x) \quad \text{sujeto a} \quad x \in D, \quad (11.16)$$

donde

$$\psi_k : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \psi_k(x) = \max_{i=0,1,\dots,k} \{f(x^i) + \langle y^i, x - x^i \rangle\}. \quad (11.17)$$

Notemos que si D es un conjunto poliedral, (11.16) puede ser escrito en forma del siguiente problema de programación lineal:

$$\min t \quad \text{sujeto a} \quad (t, x) \in U_k, \quad (11.18)$$

$$U_k = \left\{ (t, x) \in \mathbb{R} \times D \mid \begin{array}{l} f(x^i) + \langle y^i, x - x^i \rangle \leq t, \\ i = 0, 1, \dots, k. \end{array} \right\}. \quad (11.19)$$

De la definición del subdiferencial y de (11.17), inmediatamente obtenemos que

$$f(x) \geq \psi_{k+1}(x) \geq \psi_k(x) \quad \forall x \in \mathbb{R}^n. \quad (11.20)$$

A medida que más información es acumulada (o sea, cuando k crece), la aproximación (inferior) (11.17) de la función f se hace cada vez más precisa. Podemos esperar, entonces, que las soluciones de los subproblemas (11.16) aproximen cada vez mejor a las soluciones del problema original (11.15).

Algoritmo 5.2.1. (El método de planos cortantes)

Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular $f(x^k)$ y $y^k \in \partial f(x^k)$.
2. Calcular x^{k+1} , una solución del problema (11.16), donde la función objetivo está dada por (11.17).
3. Tomar $k := k + 1$ y retornar al Paso 1.

Tres iteraciones del método de planos cortantes se ilustran en la figura 11.2.




Figura 11.2.: Tres iteraciones del método de planos cortantes para la función f en el conjunto $D = [0, a]$. Se tiene que x^{k+1} es el minimizador de la aproximación ψ_k en D . Después de cada iteración, un plano cortante más es introducido en la aproximación: $\psi_{k+1}(x) = \max\{\psi_k(x), f(x^{k+1}) + \langle y^{k+1}, x - x^{k+1} \rangle\}$, $y^{k+1} \in \partial f(x^{k+1})$.

La ventaja más importante de este método en comparación con los métodos de subgradiente es la posibilidad de construir una regla de parada informativa. Para todo k , definimos

$$\Delta_k = f(x^{k+1}) - \psi_k(x^{k+1}).$$

De la relación (11.20), se sigue que $\Delta_k \geq 0$ y

$$f(x) \geq \psi_k(x) \geq \psi_k(x^{k+1}) = f(x^{k+1}) - \Delta_k \quad \forall x \in D.$$

Por lo tanto,

$$f(x^{k+1}) \geq \bar{v} \geq f(x^{k+1}) - \Delta_k,$$

donde $\bar{v}$ es el valor óptimo del problema (11.15). Esta última relación significa que es razonable parar el método después de la iteración indexada por $k + 1$, si Δ_k es pequeño (menor que la tolerancia escogida). Como mostraremos más adelante, para un cierto k esto siempre va a ocurrir (véase el Teorema 11.3).

¿Cuáles son las deficiencias del método de planos cortantes? En la práctica, la hipótesis de compacidad de D en general no es muy restrictiva. Por ejemplo, en vez de comenzar por resolver subproblemas (11.16) con $k = 0$, lo que ciertamente puede dar un problema ilimitado inferiormente cuando D es ilimitado, podemos primero tomar unos $k > 0$ puntos (digamos, aleatorios) y solo después de eso comenzar efectivamente el proceso iterativo. Si la aproximación (11.17) contiene un número de puntos significativo, es muy probable que el subproblema asociado ya no sea ilimitado inferiormente, incluso para un conjunto viable D ilimitado.

La primera deficiencia más profunda es que la resolución de los subproblemas se hace más difícil a medida que más puntos se introducen en (11.17). Esto es bien claro, ya que el número de restricciones escalares en el problema de programación lineal (11.18), (11.19), es exactamente el número de puntos anteriores $k + 1$. Notemos que existen algunas estrategias de eliminación de algunos de los puntos anteriores en la aproximación (11.17). Sin embargo, en el caso del método de planos cortantes estas estrategias no son completamente satisfactorias (comparar con los métodos de haces en la apartado 11.3).

Otra deficiencia sería del método de planos cortantes es su inestabilidad numérica. Más precisamente, las sucesiones $\{x^k\}$ y $\{f(x^k)\}$ con frecuencia muestran un comportamiento caótico. Para visualizar esto, basta observar el Algoritmo 5.2.1 cuando es aplicado al problema (11.15), con $n = 1$, $D = [-1, 1]$ y la función objetivo $f(x) = x^2$, $x \in \mathbb{R}$. Véase también la figura 11.3.




Figura 11.3.: La iteración del método de planos cortantes puede generar x^{k+1} para el cual la distancia a la solución y el valor de la función objetivo aumentan en comparación con el iterado anterior x^k .

Aun siendo estos ejemplos muy especiales (en particular, f es diferenciable y no está claro por qué emplear un método de optimización no diferenciable), lo que puede ser observado es relevante para entender las posibles dificultades de la aplicación del método en general. A propósito, el método de planos cortantes es realmente eficiente solamente cuando el problema posee una *única* solución, que satisface la condición de crecimiento lineal (véase el Ejercicio 11.2).

Teorema 11.3 (Convergencia del método de planos cortantes). Sean $D \subset \mathbb{R}^n$ un conjunto convexo compacto y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa en $\mathbb{R}^n$. Entonces, para toda sucesión $\{x^k\}$ generada por el Algoritmo 5.2.1, se tiene que

$$\lim_{k \rightarrow \infty} \psi_k(x^{k+1}) = \bar{v} = \liminf_{k \rightarrow \infty} f(x^k), \quad (11.21)$$

donde $\bar{v} = \min_{x \in D} f(x)$, y las funciones ψ_k están definidas por la fórmula (11.17).

Prueba. De la relación (11.20) se sigue que la sucesión $\{\psi_k(x^{k+1})\}$ es no decreciente y limitada superiormente por $\bar{v}$. Luego, esta sucesión converge. Supongamos que el límite de ella no sea $\bar{v}$, i.e., que exista un número $\delta > 0$ tal que

$$\psi_k(x^{k+1}) \leq \bar{v} - \delta \quad \forall k. \quad (11.22)$$

La sucesión $\{x^k\}$ es acotada (ya que D es compacto). Tomando una subsucesión (si fuera necesario), podemos admitir que $\{x^k\}$ converge. Existe, entonces, un número $M > 0$ tal que, para todo k suficientemente grande, tenemos

$$\|x^{k+1} - x^k\| \leq \frac{\delta}{2M}, \quad \|y^k\| \leq M,$$

donde la segunda desigualdad se sigue del Teorema 6.12 (y del hecho de que $\{x^k\}$ es acotada). Combinando estas desigualdades con (11.17) y (11.22), obtenemos que

$$\begin{aligned} \bar{v} - \delta &\geq \psi_k(x^{k+1}) \\ &\geq f(x^k) + \langle y^k, x^{k+1} - x^k \rangle \\ &\geq \bar{v} - \|y^k\| \|x^{k+1} - x^k\| \\ &\geq \bar{v} - \delta/2, \end{aligned}$$

lo que es una contradicción. Acabamos de mostrar la primera igualdad en (11.21).

Supongamos ahora que la segunda igualdad en (11.21) no sea verdadera, i.e., que exista un número $\delta > 0$ tal que para todo k suficientemente grande se tiene que

$$f(x^k) \geq \bar{v} + \delta.$$

Observamos que, por la definición (11.17),

$$\begin{aligned}\psi_{k+1}(x^{k+1}) &= \max\{\psi_k(x^{k+1}), f(x^{k+1})\} \\ &\geq f(x^{k+1}) \\ &\geq \bar{v} + \delta,\end{aligned}\tag{11.23}$$

para todo k suficientemente grande. Pasando de nuevo a una subsucesión (si es necesario) podemos admitir que

$$\|x^{k+1} - x^k\| \leq \frac{\delta}{2L},$$

donde

$$L = \sup\{\|y\| \mid y \in \cup_{x \in D} \partial f(x)\}.$$

Recordamos que, por el Teorema 6.12, el número L es finito y sirve como módulo de Lipschitz-continuidad de la función f en el conjunto D . Como es fácil ver, L también sirve como módulo de Lipschitz-continuidad de la función ψ_{k+1} en D (véase el Ejercicio 7.3). Ahora, utilizando también (11.23) y (11.20), obtenemos

$$\begin{aligned}\bar{v} + \delta &\leq \psi_{k+1}(x^{k+1}) \\ &= \psi_{k+1}(x^k) + \psi_{k+1}(x^{k+1}) - \psi_{k+1}(x^k) \\ &\leq \bar{v} + L\|x^{k+1} - x^k\| \\ &\leq \bar{v} + \delta/2,\end{aligned}$$

lo que de nuevo es una contradicción. Esto prueba la segunda igualdad en (11.21). ■

11.3. Métodos de haces

De nuevo consideramos el problema de minimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n,\tag{11.24}$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa en $\mathbb{R}^n$, en general no diferenciable.

Los métodos presentados a continuación se basan en la idea de aproximación lineal por partes (véase apartado 11.2), complementada con un mecanismo de estabilización, una regla de parada altamente confiable, y una técnica que permite control total del tamaño de los subproblemas a ser resueltos. Así llegamos a una clase de métodos verdaderamente eficientes y prácticos.

Primero, vamos a presentar una versión simplificada, para explicar mejor las ideas principales. Sea $x^k \in \mathbb{R}^n$ una aproximación actual de la solución del problema (11.24), en el sentido de que x^k es el “mejor” punto calculado hasta ahora. De nuevo, tenemos en la memoria la información acumulada hasta el inicio de la iteración con índice $k + 1$, que consiste en los puntos $z^i \in \mathbb{R}^n$ y subgradiientes $y^i \in \partial f(z^i)$, $i = 0, 1, \dots, k$. Llamamos a este conjunto de datos el *haz*². Resaltamos que aquí, el último punto calculado z^k no necesariamente coincide con el punto x^k (la diferencia quedará clara a continuación). El iterado siguiente $z^{k+1} \in \mathbb{R}^n$ es calculado resolviendo el problema

$$\min \psi_k(x) + \frac{\gamma_k}{2} \|x - x^k\|^2, \quad x \in \mathbb{R}^n,\tag{11.25}$$

donde

$$\psi_k : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \psi_k(x) = \max_{i=0,1,\dots,k} \{f(z^i) + \langle y^i, x - z^i \rangle\},\tag{11.26}$$

es la aproximación de planos cortantes de la función objetivo f (véase apartado 11.2) y $\gamma_k > 0$ es un parámetro estabilizador (comparar con el subproblema (11.16)). El punto x^k puede ser pensado como centro de estabilización, y el papel del término cuadrático (estabilizador) consiste en no permitir un desplazamiento muy grande del punto z^{k+1} en relación al centro x^k , lo que puede ocurrir en el caso de minimización de la aproximación por planos cortantes.

La idea es cambiar el centro de estabilización solamente cuando eso esté realmente justificado, i.e., cuando el paso de x^k a z^{k+1} resulte en un decrecimiento suficiente de la función objetivo f . Si esto ocurre, tomamos entonces $x^{k+1} = z^{k+1}$. Este tipo de iteración se llama *paso serio*³ (o aun, paso de descenso). Caso contrario, el centro de estabilización (la aproximación actual x^k) no cambia, i.e., tomamos $x^{k+1} = x^k$. Este tipo de iteración se llama *paso*

²En inglés: *bundle*; métodos de haces – *bundle methods*.

³En inglés: *serious step*.

nulo⁴. Subrayamos que la información obtenida a través de la resolución del subproblema (11.25) en un paso nulo no es descartada: ella sirve para mejorar la aproximación de la función f en la siguiente iteración.

Para construir un método verdaderamente práctico, basado en las ideas presentadas, algunos detalles importantes tienen que ser incorporados. Notemos primero que la función ψ_k , definida en (11.26), puede ser escrita de la siguiente manera equivalente:

$$\psi_k(x) = f(x^k) + \max_{i=0,1,\dots,k} \{-e_i^k + \langle y^i, x - x^k \rangle\}, \quad (11.27)$$

donde la expresión está “centrada” en el punto x^k y utiliza los *errores de linealización* en los puntos z^i en relación a x^k :

$$e_i^k := f(x^k) - f(z^i) - \langle y^i, x^k - z^i \rangle \geq 0, \quad i = 0, 1, \dots, k. \quad (11.28)$$

La desigualdad en (11.28) sigue directamente de la definición de subgradiente. Esta representación de la función ψ_k está mejor adaptada a la implementación computacional (entre otras cosas, necesita menos memoria, ya que en vez de vectores $z^i \in \mathbb{R}^n$ utiliza números escalares $e_i^k \in \mathbb{R}$). Como puede ser visto directamente de (11.28) y de la definición del ε -subdiferencial (véase apartado 6.3), se tiene que

$$y^i \in \partial_{e_i^k} f(x^k), \quad i = 0, 1, \dots, k. \quad (11.29)$$

Notemos que los errores de linealización en (11.28) tienen que ser modificados cada vez que cambia el centro x^k .

Recordamos que la complejidad del subproblema (11.25) está directamente relacionada con el número de planos cortantes que definen ψ_k en (11.26), que es $k + 1$. Como veremos más adelante, este también será el número de restricciones en la reformulación de (11.25) como un problema de programación cuadrática. Por razones prácticas, es altamente deseable mantener el número de restricciones computacionalmente realista. O sea, necesitamos alguna herramienta que permita descartar parte de la información acumulada de manera que, aun así, garantice convergencia del proceso iterativo. La eliminación de alguna información anterior significa la sustitución de la función dada por (11.26) por otra función, definida por un número menor de planos cortantes. Formalmente definimos

$$\psi_k(x) = f(x^k) + \max_{i \in B_k} \{-e_i^k + \langle y^i, x - x^k \rangle\}, \quad (11.30)$$

donde B_k es el conjunto de índices que define el haz actual, y se tiene que

$$y^i \in \partial_{e_i^k} f(x^k), \quad i \in B_k. \quad (11.31)$$

De la Definición 6.9 del ε -subdiferencial, se tiene que

$$\forall x \in \mathbb{R}^n, \quad f(x) \geq f(x^k) + \langle y^i, x - x^k \rangle - e_i^k, \quad \forall i \in B_k.$$

Por lo tanto, de (11.30) obtenemos que

$$f(x) \geq \psi_k(x) \quad \forall x \in \mathbb{R}^n, \quad k = 0, 1, \dots \quad (11.32)$$

Subrayamos que en la definición arriba, B_k no necesita contener a todos los índices $i = 0, 1, \dots, k$. Además, suponiendo que necesariamente $y^i \in \partial f(z^i)$ para algún índice anterior $i \in \{0, 1, \dots, k\}$, es claro que si no estamos empleando todos los planos cortantes obtenidos en los $k + 1$ puntos anteriores, los ε -subgradiientes en (11.31) tienen que ser contruidos de manera inteligente para no perder aquella información que es esencial. Para este fin, la llamada *función agregada* es fundamental. Esta función es definida a través de la solución del subproblema (11.25), que estudiaremos a continuación.

Evidentemente, la función objetivo del subproblema (11.25) es fuertemente convexa. Por lo tanto, (11.25) posee una solución que es única. Además, como es fácil verificar, el problema (11.25), con ψ_k dada por (11.30), es equivalente al problema de programación cuadrática siguiente:

$$\min t + \frac{\gamma_k}{2} \|x - x^k\|^2 \quad \text{sujeto a} \quad (t, x) \in U_k, \quad (11.33)$$

$$U_k = \{(t, x) \in \mathbb{R} \times \mathbb{R}^n \mid f(x^k) - e_i^k + \langle y^i, x - x^k \rangle \leq t, \quad i \in B_k\}. \quad (11.34)$$

Mencionaremos también que, en vez del problema (11.33)-(11.34), podemos resolver su dual (véase ??), que puede ser escrito como

$$\min \frac{1}{2} \left\| \sum_{i \in B_k} v_i y^i \right\|^2 + \gamma_k \sum_{i \in B_k} v_i e_i^k \quad \text{sujeto a} \quad v \in \mathcal{U}_k, \quad (11.35)$$

⁴En inglés: *null step*.

$$\mathcal{U}_k = \left\{ v \in \mathbb{R}_+^{|B_k|} \mid \sum_{i \in B_k} v_i = 1 \right\}, \quad (11.36)$$

véase el Lema 11.1 a continuación. Por el Teorema de Weierstrass, el problema dual siempre posee solución, ya que su conjunto viable es compacto y la función objetivo es continua. A ventaja del problema dual es que su conjunto viable posee una estructura que permite el uso de métodos computacionales especializados muy eficientes (el simplex estándar).

Lema 11.1 (Dualidad del subproblema). Para el problema (11.33)-(11.34), el dual viene dado por

$$\max f(x^k) - \frac{1}{2\gamma_k} \left\| \sum_{i \in B_k} v_i y^i \right\|^2 - \sum_{i \in B_k} v_i e_i^k \quad \text{sujeto a } v \in \mathcal{U}_k, \quad (11.37)$$

donde el conjunto $\mathcal{U}_k$ está definido en (11.36). Los dos problemas poseen soluciones y no hay brecha de dualidad.

Prueba. El problema primal (11.33)-(11.34) es equivalente a (11.25), que posee una única solución (como ya fue justificado). Ahora, por el Teorema 6.16, el dual no tiene brecha de dualidad (es evidente que el problema primal satisface la condición de regularidad de Slater). Resta mostrar que el dual tiene el formato (11.37). La Lagrangiana viene dada por:

$$\begin{aligned} L(t, x, v) &= t + \frac{\gamma_k}{2} \|x - x^k\|^2 + \sum_{i \in B_k} v_i (f(x^k) - e_i^k + \langle y^i, x - x^k \rangle - t) \\ &= \left(1 - \sum_{i \in B_k} v_i\right) t + \frac{\gamma_k}{2} \|x - x^k\|^2 + \sum_{i \in B_k} v_i \langle y^i, x - x^k \rangle + \sum_{i \in B_k} v_i (f(x^k) - e_i^k). \end{aligned} \quad (11.38)$$

Evidentemente, el ínfimo sobre t es $-\infty$ a menos que $\sum v_i = 1$. Maximizando la función dual sobre x se obtiene la formulación (11.37) luego de completar cuadrados. ■

Lema 11.2 (Propiedades del subproblema de programación cuadrática del método de haces). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Para cualesquiera $x^k \in \mathbb{R}^n$, $y^i \in \partial_{e_i^k} f(x^k)$, $i \in B_k$, y $\gamma_k > 0$, sea

$$d^k = \sum_{i \in B_k} v_i^k y^i, \quad (11.39)$$

donde $v^k \in \mathbb{R}^{|B_k|}$ es una solución del problema dual (11.35)-(11.36). Entonces, la única solución z^{k+1} del problema (11.25) viene dada por

$$z^{k+1} = x^k - \frac{1}{\gamma_k} d^k. \quad (11.40)$$

Además, se tiene que

$$d^k \in \partial_{\varepsilon_k} f(x^k), \quad (11.41)$$

donde

$$\varepsilon_k = \sum_{i \in B_k} v_i^k e_i^k \geq 0. \quad (11.42)$$

Por la definición del subgradiente, a partir del Lema se tiene la relación crítica:

$$d^k \in \partial \psi_k(z^{k+1}). \quad (11.43)$$

Ahora, por la definición del subgradiente, tenemos que

$$f(x) \geq \psi_k(x) \geq \psi_k(z^{k+1}) + \langle d^k, x - z^{k+1} \rangle \quad \forall x \in \mathbb{R}^n, \quad (11.44)$$

donde la primera desigualdad ya fue probada (véase (11.32)). Como no hay brecha de dualidad, el valor óptimo primal y dual coinciden, obteniendo:

$$\psi_k(z^{k+1}) = f(x^k) - \frac{1}{\gamma_k} \|d^k\|^2 - \varepsilon_k. \quad (11.45)$$

Ahora estamos listos para introducir la **función agregada**, mencionada anteriormente:

$$\psi_k^a : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \psi_k^a(x) := f(x^k) - \varepsilon_k + \langle d^k, x - x^k \rangle, \quad (11.46)$$

donde $d^k \in \mathbb{R}^n$ y $\varepsilon_k \geq 0$ son exactamente los definidos en el Lema 11.2. Observamos que esta función está definida a través de la solución del subproblema de programación cuadrática. Notemos también que el Lema 11.2 implica en que

$$f(x) \geq \psi_k^a(x) \quad \forall x \in \mathbb{R}^n, \quad (11.47)$$

i.e., ψ_k^a es una aproximación inferior de la función objetivo f .

Para construir un método bien definido y convergente, precisamos garantizar que si un punto x^k dado no es solución, entonces tras un número finito de pasos nulos obtenemos un paso serio de descenso. Necesitamos entonces remover planos anteriores de manera inteligente, conteniendo toda la información relevante en la *función agregada* de forma tal que se satisfaga la condición:

$$\psi_{k+1}(x) \geq \max\{\psi_k^a(x), f(z^{k+1}) + \langle y^{k+1}, x - z^{k+1} \rangle\} \quad \forall x \in \mathbb{R}^n. \quad (11.48)$$

La condición (11.48) significa que a la hora de definir el nuevo haz, tras un paso nulo, es suficiente incluir el par (y^{k+1}, e_{k+1}^{k+1}) , donde

$$e_{k+1}^{k+1} = f(x^k) - f(z^{k+1}) - \langle y^{k+1}, x^k - z^{k+1} \rangle \geq 0, \quad (11.49)$$

y el par agregado (d^k, ε_k) . Como estrategia extrema, podemos remover todos los pares anteriores y calcular el punto z^{k+2} como solución del problema

$$\min \psi_{k+1}(x) + \frac{\gamma_{k+1}}{2} \|x - x^{k+1}\|^2,$$

donde

$$\psi_{k+1}(x) = \max\{\psi_k^a(x), f(z^{k+1}) + \langle y^{k+1}, x - z^{k+1} \rangle\}. \quad (11.50)$$

Para poder actualizar los errores de linealización cada vez que el centro de estabilización cambia, garantizando la validez de la inclusión, la fórmula siguiente garantiza esto:

$$e_i^{k+1} = e_i^k + f(x^{k+1}) - f(x^k) + \langle y^i, x^k - x^{k+1} \rangle, \quad i \in B_{k+1} \setminus \{k+1\}. \quad (11.51)$$

Ahora ya podemos describir el método formalmente.

Algoritmo 5.3.1. (El método de haces)

Fijar un número entero $M \geq 2$ (el tamaño máximo permitido del haz). Escoger $x^0 \in \mathbb{R}^n$ y tomar $k := 0, K := \emptyset$. Escoger $\sigma \in (0, 1)$. Calcular $f(x^0)$ y $y^0 \in \partial f(x^0)$. Tomar $z^0 := x^0, e_0^0 := 0$. Tomar $B_0 := \{0\}$ y definir el haz inicial, que contiene el único par (y^0, e_0^0) .

1. Escoger $\gamma_k > 0$ y calcular z^{k+1} , la solución del problema (11.25), con función objetivo dada por (11.30).
2. Calcular $f(z^{k+1}), y^{k+1} \in \partial f(z^{k+1})$ y

$$\Delta_k = f(x^k) - \psi_k(z^{k+1}) - \frac{\gamma_k}{2} \|z^{k+1} - x^k\|^2. \quad (11.52)$$

3. Si

$$f(x^k) - f(z^{k+1}) \geq \sigma \Delta_k, \quad (11.53)$$

tomar $x^{k+1} := z^{k+1}$ e incluir el índice k en el conjunto K (**paso serio**).

Caso contrario, tomar $x^{k+1} := x^k$ (**paso nulo**).

4. Si $|B_k| < M$, tomar $B_{k+1} := B_k \cup \{k+1\}$.
Si $|B_k| = M$, escoger dos índices $i_1, i_2 \in B_k$ y tomar $B_{k+1} := (B_k \setminus \{i_2\}) \cup \{k+1\}$, $y^{i_1} := d^k, e_{i_1}^k := \varepsilon_k$, donde $d^k \in \mathbb{R}^n$ y $\varepsilon_k \geq 0$ están definidos en el Lema 11.2.
5. Si $k \in K$, calcular $e_i^{k+1}, i \in B_{k+1} \setminus \{k+1\}$, por la fórmula (11.51). Caso contrario, tomar $e_i^{k+1} := e_i^k, i \in B_{k+1} \setminus \{k+1\}$.
Calcular e_{k+1}^{k+1} por la fórmula (11.49). Definir el nuevo haz como el conjunto de pares $(y^i, e_i^{k+1}), i \in B_{k+1}$.
6. Tomar $k := k+1$ y retornar al Paso 1.

Haremos algunos comentarios sobre la regla de parada. De (11.41), obtenemos que Δ_k se simplifica a

$$\Delta_k = \varepsilon_k + \frac{\|d^k\|^2}{2\gamma_k}. \quad (11.54)$$

Tenemos entonces que $\Delta_k \geq 0$ y, si este número es pequeño, entonces son pequeños $\|d^k\|$ y ε_k . Por lo tanto, la regla de parada basada en la condición de que Δ_k sea suficientemente pequeño, será satisfecha tras un número finito de iteraciones.

Teorema 11.4 (Convergencia de los pasos serios del método de haces). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa en $\mathbb{R}^n$. Supongamos que el Algoritmo 5.3.1 genera una sucesión de iteraciones para las cuales el conjunto K de pasos serios

es infinito. Supongamos que la sucesión $\{\gamma_k\}$ satisfaga la condición

$$\sum_{k \in K} \frac{1}{\gamma_k} = +\infty. \quad (11.55)$$

Entonces, para la sucesión $\{x^k\}$ del Algoritmo 5.3.1 se tiene que

$$\lim_{k \rightarrow \infty} f(x^k) = \bar{v}, \quad (11.56)$$

donde $\bar{v} = \inf_{x \in \mathbb{R}^n} f(x)$, y para $k \in K$ se verifica

$$\Delta_k \rightarrow 0 \quad (k \rightarrow \infty). \quad (11.57)$$

Si el problema (11.24) tiene una solución y

$$\gamma_k \geq \bar{\gamma} > 0 \quad \forall k \in K, \quad (11.58)$$

entonces la sucesión $\{x^k\}$ converge a una solución del problema.

Prueba. Por el Lema 11.2, para todo $k \in K$ se tiene que

$$x^{k+1} = x^k - \frac{1}{\gamma_k} d^k, \quad d^k \in \partial_{\varepsilon_k} f(x^k), \quad (11.59)$$

donde las cantidades $\gamma_k > 0$, $\|d^k\|$, $\Delta_k \geq 0$ y $\varepsilon_k \geq 0$ están relacionadas por (11.54). Si $\bar{v} > -\infty$, tenemos que

$$\sum_{k \in K} \Delta_k \leq \sum_{k \in K} \frac{f(x^k) - f(x^{k+1})}{\sigma} \leq \frac{f(x^0) - \bar{v}}{\sigma} < +\infty. \quad (11.60)$$

De aquí y de (11.54), se sigue que

$$\sum_{k \in K} \varepsilon_k < +\infty, \quad \sum_{k \in K} \frac{\|d^k\|^2}{\gamma_k} < +\infty. \quad (11.61)$$

Ahora, las relaciones (11.55), (11.59) y (11.61), implican la convergencia:

$$\liminf_{k \rightarrow \infty} f(x^k) = \bar{v}.$$

Para todo $k \in K$, siendo que vale (11.59), por el mismo razonamiento usado en la prueba del método de subgradiente, se tiene que

$$\|x^{k+1} - \bar{x}\|^2 \leq \|x^k - \bar{x}\|^2 + \frac{\|d^k\|^2}{\gamma_k^2} + \frac{2\varepsilon_k}{\gamma_k}. \quad (11.62)$$

De (11.58) y (11.61), se sigue que esta condición implica que $\{x^k\}$ converge al minimizador. ■

Teorema 11.5 (Convergencia de pasos nulos del método de haces). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Supongamos que el Algoritmo 5.3.1 genera una sucesión para la cual el conjunto de pasos serios K es finito, i.e., $x^k = x^{\bar{k}}$ para algún índice $\bar{k}$. Supongamos que la sucesión $\{\gamma_k\}$ sea limitada y satisfaga la condición

$$\gamma_{k+1} \geq \gamma_k \quad \forall k \geq \bar{k}. \quad (11.63)$$

Entonces, $x^{\bar{k}}$ es una solución del problema (11.24), y la sucesión $\{z^k\}$ converge a $x^{\bar{k}}$.

Prueba. El análisis (que involucra las ecuaciones (11.64) a (??)) muestra que, gracias a la agregación del haz, la sucesión de subgradiantes aproximados fuerza al algoritmo a encontrar que $0 \in \partial f(x^{\bar{k}})$. En particular, la función agregada satisface para todo $x \in \mathbb{R}^n$:

$$\psi_k^a(x) + \frac{\gamma_k}{2} \|x - x^{\bar{k}}\|^2 = \psi_k(z^{k+1}) + \frac{\gamma_k}{2} \|z^{k+1} - x^{\bar{k}}\|^2 + \frac{\gamma_k}{2} \|x - z^{k+1}\|^2. \quad (11.64)$$

Utilizando (11.32), la definición de z^{k+2} , (11.48) y (11.63), obtenemos que la secuencia $\{\psi_k(z^{k+1}) + \gamma_k \|z^{k+1} - x^{\bar{k}}\|^2/2\}$ es monótona no decreciente y acotada superiormente. Evaluando el límite de paso nulo (11.53), se concluye que:

$$0 \in \partial f(x^{\bar{k}}), \quad (11.65)$$

lo cual significa que $x^{\bar{k}}$ es solución del problema. ■

Ejercicio 11.3. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones convexas en $\mathbb{R}^n$. Supongamos que la condición de Slater sea satisfecha. Probar que para la familia de funciones parametrizadas

$$\varphi(y; x) = \max \left\{ f(y) - f(x), \max_{i=1, \dots, m} \{0, g_i(y)\} \right\}, \quad (11.66)$$

las afirmaciones siguientes son equivalentes:

- (a) $\bar{x}$ es una solución del problema $\min\{f(x) \mid g(x) \leq 0\}$ (eq. (??));
- (b) $\min\{\varphi(y; \bar{x}) \mid y \in \mathbb{R}^n\} = \varphi(\bar{x}; \bar{x}) = 0$;
- (c) $0 \in \partial\varphi(\bar{x}; \bar{x})$, i.e., $0 \in \partial\psi(\bar{x})$, donde $\psi(\cdot) := \varphi(\cdot; \bar{x})$.

12. Programación lineal y cuadrática

En este último capítulo presentaremos algunos métodos especiales para resolver problemas de programación lineal y de programación cuadrática. La importancia de problemas de este tipo se debe al hecho de que aparecen como subproblemas en varios algoritmos de uso general, como ya hemos visto anteriormente. Sin embargo, nuestra presentación se limitará solo a algunas consideraciones básicas, ya que el tratamiento detallado podría merecer incluso un libro separado.

12.1. Programación lineal

Recordamos que llamamos problema de programación lineal a un problema de optimización donde la función objetivo es lineal y el conjunto viable es un poliedro (o sea, conjunto de soluciones de un sistema de ecuaciones e inecuaciones lineales). En particular, tal problema es convexo. Por lo tanto, toda solución local es global. Más aún, todo punto estacionario es una solución. A continuación, presentaremos un resumen de propiedades de problemas lineales.

12.1.1. Elementos de teoría de la programación lineal

El problema de programación lineal en formato general viene dado por

$$\min \langle c_1, x_1 \rangle + \langle c_2, x_2 \rangle \quad \text{sujeto a} \quad (x_1, x_2) \in D, \quad (12.1)$$

$$D = \left\{ (x_1, x_2) \in \Omega \mid \begin{array}{l} A_{11}x_1 + A_{12}x_2 = b_1, \\ A_{21}x_1 + A_{22}x_2 \geq b_2 \end{array} \right\}, \quad (12.2)$$

donde $c_1 \in \mathbb{R}^{n_1}$, $c_2 \in \mathbb{R}^{n_2}$, $A_{11} \in \mathbb{R}^{l \times n_1}$, $A_{12} \in \mathbb{R}^{l \times n_2}$, $A_{21} \in \mathbb{R}^{m \times n_1}$, $A_{22} \in \mathbb{R}^{m \times n_2}$, $b_1 \in \mathbb{R}^l$, $b_2 \in \mathbb{R}^m$, $\Omega = \mathbb{R}^{n_1} \times \mathbb{R}_+^{n_2}$. El tratamiento de $x_2 \geq 0$ como restricción abstracta es conveniente en este contexto.

Ejercicio 12.1. Sea $X = \{x \in \mathbb{R}^n \mid Ax \geq b\}$ un conjunto acotado con interior no vacío, donde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Formular el problema de incluir en X una bola de radio máximo como un problema de programación lineal.

En la teoría de programación lineal, el problema en formato canónico, donde tomamos en (12.1), (12.2), $n_1 = m = 0$, tiene un papel especial. Simplificando la notación tomando $n = n_2$, el problema canónico puede ser escrito como

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad x \in D = \{x \in \Omega \mid Ax = b\}, \quad (12.3)$$

donde $c = c_2 \in \mathbb{R}^n$, $A = A_{12} \in \mathbb{R}^{l \times n}$, $b = b_1 \in \mathbb{R}^l$, $\Omega = \mathbb{R}_+^n$. Observamos que el problema general (12.1), (12.2), siempre puede ser transformado al formato canónico, introduciendo variables adicionales:

$$\begin{aligned} \min \langle c_1, u^1 - u^2 \rangle + \langle c_2, x_2 \rangle \quad \text{sujeto a} \quad (u^1, u^2, x_2, y) \in \tilde{D}, \\ \tilde{D} = \left\{ (u^1, u^2, x_2, y) \in \tilde{\Omega} \mid \begin{array}{l} A_{11}(u^1 - u^2) + A_{12}x_2 = b_1, \\ A_{21}(u^1 - u^2) + A_{22}x_2 - y = b_2 \end{array} \right\}, \end{aligned}$$

donde $\tilde{\Omega} = \mathbb{R}_+^{n_1} \times \mathbb{R}_+^{n_1} \times \mathbb{R}_+^{n_2} \times \mathbb{R}_+^m$. Los conjuntos viables y de las soluciones del problema anterior y de (12.1), (12.2), están en una correspondencia obvia.

Teorema 12.1 (Existencia de soluciones en un problema de programación lineal). Si el conjunto viable de un problema de programación lineal es no vacío y el valor óptimo es finito, entonces este problema posee una solución.

Prueba. La afirmación es una consecuencia del Teorema 5.1.2 del Volumen 1 (véase [SolodovVol1]), pero reproduciremos la prueba.

Por lo dicho anteriormente sobre la transformación del problema general (12.1), (12.2), en problema canónico, podemos considerar este último. Sea el conjunto viable D del problema (12.3) no vacío y sea

$$\bar{v} = \inf_{x \in D} \langle c, x \rangle < +\infty.$$

Supongamos que la afirmación del teorema no sea verdadera, i.e., que el sistema

$$Ax = b, \quad \langle c, x \rangle = \bar{v}, \quad x \geq 0$$

con respecto a $x \in \mathbb{R}^n$ no tenga solución. Como es fácil ver, este sistema no tiene solución si, y solamente si, el sistema

$$Ax - tb = 0, \quad \langle c, x \rangle - t\bar{v} = 0, \quad x \geq 0, \quad t > 0$$

con respecto a $(x, t) \in \mathbb{R}^n \times \mathbb{R}$ no tiene solución. Aplicando al último sistema el Teorema de la Alternativa de Motzkin (véase el Teorema 3.14 del Volumen 1), concluimos que existe $(y, \tau) \in \mathbb{R}^l \times \mathbb{R}$ tal que

$$A^T y + \tau c \geq 0, \quad \langle b, y \rangle + \tau \bar{v} < 0.$$

Para todo $x \in D$, de la primera relación obtenemos que

$$\langle A^T y, x \rangle + \tau \langle c, x \rangle \geq 0,$$

ya que $x \geq 0$. De donde, utilizando también la segunda relación, tenemos que

$$\tau \langle c, x \rangle \geq -\langle y, Ax \rangle = -\langle y, b \rangle > \tau \bar{v}.$$

Por lo tanto,

$$\inf_{x \in D} \tau \langle c, x \rangle > \tau \bar{v} = \tau \inf_{x \in D} \langle c, x \rangle,$$

lo que es una contradicción, cualquiera que sea el valor de τ . ■

En programación lineal, una solución solo puede no existir cuando el conjunto viable del problema es vacío, o cuando la función objetivo es ilimitada inferiormente en este conjunto. Como sabemos, en el caso no lineal, un problema puede no poseer soluciones incluso cuando la función objetivo es limitada inferiormente en el conjunto viable no vacío.

Por los Teoremas 1.2.3 y 1.3.8, tenemos las siguientes condiciones de optimalidad.

Teorema 12.2 (Condiciones de optimalidad en programación lineal). Sean $c_1 \in \mathbb{R}^{n_1}$, $c_2 \in \mathbb{R}^{n_2}$, $A_{11} \in \mathbb{R}^{l \times n_1}$, $A_{12} \in \mathbb{R}^{l \times n_2}$, $A_{21} \in \mathbb{R}^{m \times n_1}$, $A_{22} \in \mathbb{R}^{m \times n_2}$, $b_1 \in \mathbb{R}^l$, $b_2 \in \mathbb{R}^m$, $\Omega = \mathbb{R}^{n_1} \times \mathbb{R}_+^{n_2}$. El punto $(\bar{x}_1, \bar{x}_2) \in D$ es una solución del problema (12.1), (12.2), si, y solamente si, existen $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$ tales que

$$A_{11}^T \bar{\lambda} + A_{21}^T \bar{\mu} = c_1, \quad A_{12}^T \bar{\lambda} + A_{22}^T \bar{\mu} \leq c_2, \quad (12.4)$$

$$\langle \bar{\mu}, A_{21} \bar{x}_1 + A_{22} \bar{x}_2 - b_2 \rangle = 0, \quad \langle A_{12}^T \bar{\lambda} + A_{22}^T \bar{\mu} - c_2, \bar{x}_2 \rangle = 0. \quad (12.5)$$

A continuación recordamos la noción de vértice del poliedro D . Aquí es conveniente tomar $n_2 = 0$, i.e., considerar el caso donde no hay restricciones abstractas (ellas pueden ser incluidas en las restricciones de desigualdad). Tomando también $n = n_1$, podemos escribir (12.2) en la forma

$$D = \{x \in \mathbb{R}^n \mid A_1 x = b_1, A_2 x \geq b_2\}, \quad (12.6)$$

donde $A_1 = A_{11} \in \mathbb{R}^{l \times n}$, $A_2 = A_{21} \in \mathbb{R}^{m \times n}$. Como siempre, para un punto $x \in \mathbb{R}^n$ cualquiera,

$$I(x) = \{i = 1, \dots, m \mid \langle (A_2)_i, x \rangle = (b_2)_i\}$$

es el conjunto de índices de las restricciones activas en x , donde $(A_2)_1, \dots, (A_2)_m$ son las filas de la matriz A_2 .

Definición 12.1 (Vértice). Un punto $\hat{x} \in D$ se llama **vértice** del poliedro D definido por (12.6), si las filas de la matriz A_1 y las filas de la matriz A_2 indexadas por $i \in I(\hat{x})$, forman en $\mathbb{R}^n$ un sistema de rango n . Si el número de elementos en este sistema es igual a n , entonces el vértice $\hat{x}$ se llama **no degenerado**, y si el número es mayor que n , entonces el vértice es **degenerado**.

La figura 12.1 ilustra esta definición.




Figura 12.1.: Los puntos x^1 , x^2 y x^3 son vértices del conjunto poliedral $D \subset \mathbb{R}^n$, $n = 2$, definido por las desigualdades $\langle B_i, x \rangle \geq b_i$, $i = 1, \dots, 4$. Por ejemplo, se tiene que $I(x^1) = \{1, 2\}$ y los vectores B_1 y B_2 forman una matriz de rango $2 = n$; x^1 es un vértice no degenerado. Se tiene que $I(x^2) = \{2, 3, 4\}$ y los vectores B_2 , B_3 y B_4 forman una matriz de rango $2 = n$; x^2 es un vértice degenerado. El punto $y \in D$ no es un vértice: $I(y) = \{2\}$ y el vector B_2 forma una matriz de rango $1 < n = 2$.

En otras palabras, $\hat{x} \in D$ es un vértice del poliedro D dado por (12.6), si $\hat{x}$ es la única solución del sistema lineal

$$A_1 x = b_1, \quad \langle (A_2)_i, x \rangle = (b_2)_i, \quad i \in I(\hat{x}).$$

De aquí, inmediatamente obtenemos el siguiente hecho.

Proposición 12.1. *El número de vértices de un conjunto poliedral cualquiera es finito.*

A continuación presentamos un criterio de existencia de vértices.

Teorema 12.3 (Existencia de vértices de un conjunto poliedral). *Para cualesquiera $A_1 \in \mathbb{R}^{l \times n}$, $A_2 \in \mathbb{R}^{m \times n}$, $b_1 \in \mathbb{R}^l$ y $b_2 \in \mathbb{R}^m$, el poliedro D definido en (12.6) posee al menos un vértice si, y solamente si, $D \neq \emptyset$ y la matriz*

$$A = \begin{pmatrix} A_1 \\ A_2 \end{pmatrix}$$

tiene rango n . Más aún, si $\text{rk } A = n$, entonces para todo punto $x \in D$ existe un vértice $\hat{x}$ tal que $I(x) \subset I(\hat{x})$.

Prueba. El hecho de que las condiciones arriba son necesarias para la existencia de un vértice es obvio. Probaremos que esas condiciones también son suficientes.

Sea $x \in D$ arbitrario. Definimos los conjuntos $I = I(x)$, $J = \{1, \dots, m\} \setminus I$. Si las filas de la matriz A_1 y las filas $(A_2)_i$, $i \in I$, forman en $\mathbb{R}^n$ un sistema de rango n , entonces x es un vértice, por definición. Supongamos que el rango de este sistema sea $r < n$. En este caso, existe un vector $d \in \mathbb{R}^n \setminus \{0\}$ tal que

$$A_1 d = 0, \quad \langle (A_2)_i, d \rangle = 0 \quad \forall i \in I. \quad (12.7)$$

Si $\langle (A_2)_i, d \rangle = 0 \quad \forall i \in J$, obtendremos que $Ad = 0$, en contradicción con la hipótesis de que $\text{rk } A = n$. Por lo tanto, existe un índice $i \in J$ tal que $\langle (A_2)_i, d \rangle \neq 0$. Sin pérdida de generalidad, podemos admitir que $\langle (A_2)_i, d \rangle < 0$.

Para todo $t \geq 0$, consideremos puntos de la forma $x(t) = x + td$. Utilizando (12.7), tenemos que

$$\begin{aligned} A_1 x(t) &= A_1 x + t A_1 d = b_1, \\ \langle (A_2)_i, x(t) \rangle &= \langle (A_2)_i, x \rangle + t \langle (A_2)_i, d \rangle = (b_2)_i \quad \forall i \in I. \end{aligned} \quad (12.8)$$

Por lo tanto, $x(t) \in D$ si, y solamente si,

$$\langle (A_2)_i, x(t) \rangle = \langle (A_2)_i, x \rangle + t \langle (A_2)_i, d \rangle \geq (b_2)_i \quad \forall i \in J.$$

Definimos

$$t_1 = \max\{t \in \mathbb{R}_+ \mid x(t) \in D\}.$$

Como es fácil ver, existe un índice $i_1 \in J$ tal que $\langle (A_2)_{i_1}, d \rangle < 0$ y

$$0 < t_1 = \frac{(b_2)_{i_1} - \langle (A_2)_{i_1}, x \rangle}{\langle (A_2)_{i_1}, d \rangle} \quad (12.9)$$

(comparar con el Ejercicio 4.1.8; notemos que para todo $i \in J$, se tiene que $(b_2)_i - \langle (A_2)_i, x \rangle < 0$). Definimos $x^1 = x(t_1)$, $I_1 = I(x^1)$. De (12.8) se sigue la inclusión

$$I \subset I_1. \quad (12.10)$$

De (12.9) obtenemos

$$\langle (A_2)_{i_1}, x^1 \rangle = \langle (A_2)_{i_1}, x \rangle + \frac{(b_2)_{i_1} - \langle (A_2)_{i_1}, x \rangle}{\langle (A_2)_{i_1}, d \rangle} \langle (A_2)_{i_1}, d \rangle = (b_2)_{i_1},$$

i.e., $i_1 \in I_1$. Si vale

$$(A_2)_{i_1} = A_1^T y + \sum_{i \in I} \beta_i (A_2)_i$$

para algunos $y \in \mathbb{R}^l$ y $\beta_i, i \in I$, de (12.7) se sigue la contradicción

$$0 > \langle (A_2)_{i_1}, d \rangle = \langle y, A_1 d \rangle + \sum_{i \in I} \beta_i \langle (A_2)_i, d \rangle = 0.$$

Concluimos entonces que las filas de la matriz A_1 y $(A_2)_i, i \in I_1$, forman en $\mathbb{R}^n$ un sistema de rango $r_1 > r$.

Si $r_1 = n$, entonces x^1 es un vértice y, teniendo en cuenta (12.10), esto concluye la demostración. Si $r_1 < n$, podemos repetir la construcción anterior, cambiando el punto x por x^1 . Repitiendo la construcción s veces, obtenemos puntos $x, x^1, x^2, \dots, x^s \in D$, satisfaciendo

$$I(x) \subset I(x^1) \subset I(x^2) \subset \dots \subset I(x^s),$$

$$r < r_1 < r_2 < \dots < r_s,$$

donde r_k es el rango de filas de la matriz A_1 , complementadas por $(A_2)_i, i \in I(x^k), k = 1, \dots, s$. Es claro que para algún número s obtendremos $r_s = n$, lo que significa que $\hat{x} = x^s$ es un vértice e $I(x) \subset I(x^s)$. ■

Si queremos encontrar todos los vértices de un poliedro D de la forma (12.6), podemos seguir el esquema siguiente. Para todo conjunto $I \subset \{1, \dots, m\}$ con $(n-l)$ -elementos, resolvemos el sistema lineal

$$A_1 x = b_1, \quad \langle (A_2)_i, x \rangle = (b_2)_i, \quad i \in I.$$

Si la solución existe, es única, y pertenece a D , entonces ella es un vértice de D . Caso contrario, consideramos otro conjunto I .

El conjunto viable del problema canónico (12.3) se llama poliedro canónico (recordamos que en (12.3) $\Omega = \mathbb{R}_+^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$). Para todo $x \in \mathbb{R}^n$, denotamos

$$J(x) = \{j = 1, \dots, n \mid x_j > 0\}.$$

Denotamos por $A^1, \dots, A^n$ las columnas de la matriz A .

Teorema 12.4 (Vértices del poliedro canónico). Para $A \in \mathbb{R}^{l \times n}$ y $b \in \mathbb{R}^l$ cualesquiera, el punto $\hat{x} \in D$ es un vértice del poliedro canónico definido en (12.3) (con $\Omega = \mathbb{R}_+^n$) si, y solamente si, las columnas $A^j, j \in J(\hat{x})$, de la matriz A son linealmente independientes. Si el conjunto $J(\hat{x})$ tiene l elementos, entonces el vértice $\hat{x}$ es no degenerado, y si el número de elementos en $J(\hat{x})$ es menor que l , el vértice es degenerado.

Ejercicio 12.2. Probar el Teorema 12.4.

Una propiedad importante de los poliedros canónicos es la siguiente.

Teorema 12.5 (Existencia de vértices de los poliedros canónicos). Para $A \in \mathbb{R}^{l \times n}$ y $b \in \mathbb{R}^l$ cualesquiera, el poliedro canónico D definido en (12.3) (con $\Omega = \mathbb{R}_+^n$) tiene al menos un vértice. Más aún, para todo punto $x \in D$ existe un vértice $\hat{x}$ del poliedro D tal que $J(x) \supset J(\hat{x})$.

Ejercicio 12.3. Utilizando el Teorema 12.3, probar el Teorema 12.5.

Para encontrar vértices de un poliedro canónico, puede ser empleado el siguiente esquema especial. Para cada conjunto $J \subset \{1, \dots, n\}$ tal que las columnas $A^j, j \in J$, de la matriz A son linealmente independientes, resolvemos el sistema lineal

$$\sum_{j \in J} A^j x_j = b.$$

Si este sistema posee una solución con coordenadas $\hat{x}_j \geq 0 \forall j \in J$, tomando $\hat{x}_j = 0, j \in \{1, \dots, n\} \setminus J$, obtenemos un vértice $\hat{x} = (\hat{x}_1, \dots, \hat{x}_n)$. Caso contrario, consideramos otro conjunto J .

El resultado siguiente, que es un corolario inmediato de los Teorema 12.2 y Teorema 12.3, es importante para el cálculo de soluciones de un problema de programación lineal. La intuición geométrica sugiere que si un problema lineal posee soluciones, una de las soluciones es vértice del conjunto viable del problema (si existen vértices), véase la figura 12.2.




Figura 12.2.: Cuando un problema de programación lineal posee soluciones y el conjunto viable tiene vértices, uno de los vértices es solución del problema (en el dibujo, las rectas paralelas son curvas de nivel de la función objetivo $\langle c, x \rangle$).

Como el número de vértices es finito (Proposición 12.1), la estrategia más obvia es simplemente calcular todos los vértices (por ejemplo, utilizando los esquemas presentados arriba) y escoger uno con el valor mínimo de la función objetivo. Naturalmente, tal estrategia no puede ser eficiente, pero el resultado no deja de ser importante.

Teorema 12.6. Si un problema de programación lineal posee soluciones y si el conjunto viable del problema tiene al menos un vértice, entonces uno de los vértices es solución del problema.

Como es fácil verificar, el problema dual (véase ?? y [SolodovVol1]) del problema (12.1), (12.2) (donde $\Omega = \mathbb{R}^{n_1} \times \mathbb{R}_+^{n_2}$) viene dado por

$$\max \langle b_1, \lambda \rangle + \langle b_2, \mu \rangle \quad \text{sueto a} \quad (\lambda, \mu) \in \Delta, \quad (12.11)$$

$$\Delta = \left\{ (\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m \mid \begin{array}{l} A_{11}^T \lambda + A_{21}^T \mu = c_1, \\ A_{12}^T \lambda + A_{22}^T \mu \leq c_2. \end{array} \right\}. \quad (12.12)$$

Recordamos que el dual del dual de un problema de programación lineal también es un problema de programación lineal. El dual del problema canónico (12.3) (donde $\Omega = \mathbb{R}_+^n$) es

$$\max \langle b, \lambda \rangle \quad \text{sueto a} \quad \lambda \in \Delta = \{ \lambda \in \mathbb{R}^l \mid A^T \lambda \leq c \}.$$

Si colocamos este último problema en la forma (12.1), (12.2), y escribimos su dual de acuerdo con (12.11), (12.12), obtendremos de nuevo el problema en el formato (12.3) (para obtener exactamente (12.3), es necesario transformar maximización en minimización cambiando el signo de la función objetivo). Lo mismo vale también para el problema general (12.1), (12.2). O sea, dualizando el problema dos veces resulta en el problema de la estructura original.

Recordamos que por la relación de dualidad débil (véase el Teorema 6.15), se tiene que

$$\begin{aligned} \langle c_1, x_1 \rangle + \langle c_2, x_2 \rangle &\geq \langle b_1, \lambda \rangle + \langle b_2, \mu \rangle \\ \forall (x_1, x_2) \in D, \quad \forall (\lambda, \mu) \in \Delta, \end{aligned} \quad (12.13)$$

y en particular,

$$\bar{v} \geq \bar{\omega},$$

donde

$$\bar{v} = \inf \{ \langle c_1, x_1 \rangle + \langle c_2, x_2 \rangle \mid (x_1, x_2) \in D \}$$

es el valor óptimo del problema primal y

$$\bar{\omega} = \sup \{ \langle b_1, \lambda \rangle + \langle b_2, \mu \rangle \mid (\lambda, \mu) \in \Delta \}$$

es el valor óptimo del problema dual.

El caso importante es cuando para algunos $(\bar{x}_1, \bar{x}_2) \in D$ y $(\bar{\lambda}, \bar{\mu}) \in \Delta$ se realiza igualdad en la relación (12.13), i.e.,

$$\langle c_1, \bar{x}_1 \rangle + \langle c_2, \bar{x}_2 \rangle = \langle b_1, \bar{\lambda} \rangle + \langle b_2, \bar{\mu} \rangle. \quad (12.14)$$

De (12.13) se sigue que, en este caso, $(\bar{x}_1, \bar{x}_2)$ es una solución del problema primal (12.1), (12.2), e $(\bar{\lambda}, \bar{\mu})$ es una solución del problema dual (12.11), (12.12), y que no hay brecha de dualidad:

$$\bar{v} = \bar{\omega}. \quad (12.15)$$

Lema 12.1. *Bajo las hipótesis del Teorema 12.2, sean D y Δ los conjuntos definidos en (12.2) y (12.12), respectivamente. Para $(\bar{x}_1, \bar{x}_2) \in D$ e $(\bar{\lambda}, \bar{\mu}) \in \Delta$ cualesquiera, la relación (12.14) vale como igualdad si, y solamente si, las condiciones (12.5) se satisfacen.*

Prueba. De $(\bar{x}_1, \bar{x}_2) \in D$ e $(\bar{\lambda}, \bar{\mu}) \in \Delta$ obtenemos que

$$\begin{aligned} \langle c_1, \bar{x}_1 \rangle + \langle c_2, \bar{x}_2 \rangle &\geq \langle A_{11}^T \bar{\lambda} + A_{21}^T \bar{\mu}, \bar{x}_1 \rangle + \langle A_{12}^T \bar{\lambda} + A_{22}^T \bar{\mu}, \bar{x}_2 \rangle \\ &= \langle \bar{\lambda}, A_{11} \bar{x}_1 + A_{12} \bar{x}_2 \rangle + \langle \bar{\mu}, A_{21} \bar{x}_1 + A_{22} \bar{x}_2 \rangle \\ &\geq \langle \bar{\lambda}, b_1 \rangle + \langle \bar{\mu}, b_2 \rangle. \end{aligned}$$

Si vale (12.14), el lado izquierdo es igual al lado derecho en la relación de arriba, y todas las desigualdades valen como igualdades. Es fácil ver que esto solo es posible si valen las condiciones (12.5). Recíprocamente, si vale (12.5), las desigualdades en la relación arriba se vuelven igualdades, lo que resulta en (12.14). ■

Recordamos que (12.5) son *condiciones de complementariedad* para el problema primal. Tenemos entonces que (12.14), o equivalentemente, las condiciones de complementariedad (12.5), son suficientes para optimalidad de puntos viables $(\bar{x}_1, \bar{x}_2)$ en el problema primal y puntos viables $(\bar{\lambda}, \bar{\mu})$ en el problema dual. Para ver que estas condiciones son también necesarias, notemos que la inclusión $(\bar{\lambda}, \bar{\mu}) \in \Delta$ coincide con (12.4), complementada por $\bar{\mu} \geq 0$. De aquí, del Lema 12.1 y del Teorema 12.2, obtenemos condiciones de optimalidad siguientes.

Teorema 12.7. *Bajo las hipótesis del Teorema 12.2, sean D y Δ los conjuntos definidos en (12.2) y (12.12), respectivamente. El punto $(\bar{x}_1, \bar{x}_2) \in D$ es una solución del problema primal (12.1), (12.2), si, y solamente si, existe $(\bar{\lambda}, \bar{\mu}) \in \Delta$ satisfaciendo (12.14) o, equivalentemente, (12.5). En este caso, $(\bar{\lambda}, \bar{\mu})$ es una solución del problema dual (12.11), (12.12).*

El Teorema 12.7 contiene las siguientes dos afirmaciones clásicas.

Teorema 12.8 (Dualidad fuerte). *Un problema de programación lineal posee una solución si, y solamente si, su dual posee una solución. En este caso, los valores óptimos de los dos problemas son iguales.*

Teorema 12.9. *Bajo las hipótesis del Teorema 12.7, los puntos $(\bar{x}_1, \bar{x}_2) \in D$ e $(\bar{\lambda}, \bar{\mu}) \in \Delta$ son soluciones de los problemas (12.1), (12.2), y (12.11), (12.12), si, y solamente si, valen las condiciones de complementariedad (12.5).*

Finalmente, de los Teoremas 12.1 y 12.8 se sigue el siguiente resultado de existencia de soluciones en programación lineal.

Teorema 12.10. *Si los conjuntos viables de un problema de programación lineal y de su dual son no vacíos, entonces ambos problemas tienen solución. Si solo uno de los problemas posee conjunto viable no vacío, entonces el valor óptimo de este problema es infinito.*

Como comentamos en [SolodovVol1], resolver el problema dual de un problema dado (no necesariamente de programación lineal) puede ser bien útil, principalmente cuando él es más simple que el problema original y no hay brecha de dualidad. Esta afirmación queda aún más clara en el caso de programación lineal. Habiendo resuelto el problema dual, esta solución puede ser usada para obtener una solución del problema primal, por ejemplo con ayuda del Teorema 12.9.

Ejercicio 12.4. Haciendo dibujos geométricos, formular hipótesis sobre soluciones de los problemas duales para

$$\min -7x_1 - x_3 + 4x_4 \quad \text{sueto a} \quad x \in D,$$

$$D = \{x \in \mathbb{R}_+^4 \mid -x_1 + x_2 - 2x_3 + x_4 \geq -6, -2x_1 - x_2 + x_3 \geq 1\};$$

$$\min 2x_1 + 3x_2 + 2x_3 + 3x_4 \quad \text{sueto a} \quad x \in D,$$

$$D = \{x \in \mathbb{R}_+^4 \mid 2x_1 - x_2 - x_3 + x_4 \geq 2, -x_1 - 3x_2 + x_3 + x_4 \geq 1\}.$$

Verificar las hipótesis y encontrar soluciones de los problemas primales, utilizando el resultado del Teorema 12.9.

Ejercicio 12.5. Encontrar todas las soluciones del problema

$$\min x_1 + x_2 + x_3 + x_4 \quad \text{sujeto a } x \in D,$$

$$D = \{x \in \mathbb{R}_+^4 \mid x_1 - x_2 \geq 0, x_1 + x_2 - x_3 + x_4 \geq 1\}.$$

Ejercicio 12.6. Formular el dual para el problema

$$\min \sum_{j=1}^s \langle c_j, x_j \rangle \quad \text{sujeto a } (x_1, \dots, x_s) \in D,$$

$$D = \left\{ (x_1, \dots, x_s) \in \Omega \mid A_j x_j \geq b_j, j = 1, \dots, s, \sum_{j=1}^s B_j x_j \geq d \right\},$$

donde $c_j \in \mathbb{R}^{n_j}$, $A \in \mathbb{R}^{m_j \times n_j}$, $b_j \in \mathbb{R}^{m_j}$ y $B \in \mathbb{R}^{m \times n_j}$, $j = 1, \dots, s$, $d \in \mathbb{R}^m$, $\Omega = \prod_{j=1}^s \mathbb{R}_+^{n_j}$.

Ejercicio 12.7. Formular el dual para el problema

$$\min \sum_{j=1}^s \langle c_j, x_j \rangle \quad \text{sujeto a } (x_1, \dots, x_s) \in D,$$

$$D = \{(x_1, \dots, x_s) \in \Omega \mid Ax_j \geq x_{j-1}, j = 1, \dots, s\},$$

donde $c_j \in \mathbb{R}^n$, $j = 1, \dots, s$, $A \in \mathbb{R}^{n \times n}$, $x_0 \in \mathbb{R}^n$ es dado, $\Omega = \prod_{j=1}^s \mathbb{R}_+^n$.

Ejercicio 12.8. Resolver el problema

$$\min \langle c, x \rangle \quad \text{sujeto a } x \in D = \{x \in \Omega \mid \langle a, x \rangle = b\},$$

donde $c, a \in \mathbb{R}^n$, $b \in \mathbb{R}$, $a > 0$, $b > 0$, $\Omega = \mathbb{R}_+^n$.

Ejercicio 12.9. Resolver el problema

$$\min \sum_{j=1}^n jx_j \quad \text{sujeto a } x \in D,$$

$$D = \left\{ x \in \Omega \mid \sum_{j=1}^i x_j \geq i, i = 1, \dots, n \right\},$$

donde $\Omega = \mathbb{R}_+^n$.

Ejercicio 12.10. El conjunto de soluciones de un problema de programación lineal puede

- (a) contener un solo punto;
- (b) contener más de un punto y ser acotado;
- (c) ser ilimitado.

Construir ejemplos mostrando que para un par de problemas primal y dual, todas las combinaciones de los escenarios de arriba son posibles.

12.1.2. El método del simplex

El método del simplex es históricamente el primer método computacional para optimización con restricciones. Fue él el que permitió la resolución de los primeros problemas de optimización de la “vida real”, dando inicio al desarrollo de métodos computacionales de optimización. Aun siendo el método más “viejo”, implementaciones sofisticadas de la idea básica son bien eficientes y son utilizadas hasta ahora.

El método será presentado para el problema canónico

$$\min \langle c, x \rangle \quad \text{sujeto a } x \in D = \{x \in \Omega \mid Ax = b\}, \quad (12.16)$$

donde $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$, $\Omega = \mathbb{R}_+^n$. Esto no reduce la generalidad, ya que todo problema de programación lineal puede ser escrito en este formato; véase la apartado 12.1.1.

De aquí en adelante,

$$J(x) = \{j = 1, \dots, n \mid x_j > 0\}$$

es el conjunto de las coordenadas positivas del punto $x \in \mathbb{R}^n$, y A^j , $j = 1, \dots, n$, son las columnas de la matriz A .

Basada en la Proposición 12.1 y en los Teoremas 12.5 y 12.6, la estrategia más simple para resolver un problema de programación lineal sería calcular todos los vértices del conjunto viable y escoger aquel con menor valor de la función objetivo. Algunas maneras de hacer esto fueron comentadas en la apartado 12.1.1. Si el problema (12.16) posee soluciones, por lo menos una será encontrada después de un número finito de pasos. Teóricamente, esta estrategia puede ser aplicada a cualquier problema de programación lineal. Sin embargo, ya para dimensiones n y l del orden de algunas docenas (lo que es un problema pequeño), el número de cálculos necesarios torna a este método poco práctico. Por eso, este método no tiene valor práctico. Él, naturalmente, lleva a la idea principal del método del simplex: en vez del cálculo indiscriminado de todos los vértices del conjunto viable, el proceso tiene que ser ordenado de manera inteligente, evitando el cálculo de vértices claramente no óptimos (por ejemplo, con valor de la función objetivo mayor que el ya visto).

Recordamos que, por el Teorema 12.4, el punto $\hat{x} \in D$ es un vértice del poliedro canónico D definido en (12.16) si, y solamente si, las columnas A^j , $j \in J(\hat{x})$, de la matriz A son linealmente independientes. Si el conjunto $J(\hat{x})$ contiene l índices, el vértice es no degenerado; si el número de índices es menor que l , el vértice es degenerado.

Notemos que para todo $x \in D$,

$$b = Ax = \sum_{j=1}^n A^j x_j = \sum_{j \in J(x)} A^j x_j,$$

i.e., el vector b en las restricciones es una combinación lineal de las columnas de la matriz A que corresponden a las coordenadas positivas del punto viable x . Más aún, los multiplicadores en esta combinación son precisamente las coordenadas de x positivas.

Definición 12.2. Dado un vértice $\hat{x}$ del poliedro canónico D definido en (12.16), llamamos **base** del vértice $\hat{x}$ a cualquier conjunto de l columnas linealmente independientes de la matriz A que contiene a todas las columnas A^j , $j \in J(\hat{x})$.

En otras palabras, $\mathcal{B} = \{A^j, j \in J\}$, donde $J \subset \{1, \dots, n\}$, es una base del vértice $\hat{x}$ si, primero, $\mathcal{B}$ es una base de $\mathbb{R}^l$ (en particular, J tiene que contener l elementos) y, segundo, $J \supset J(\hat{x})$. Notemos que para un vértice no degenerado, la única base es $\mathcal{B} = \{A^j, j \in J(\hat{x})\}$. Un vértice degenerado puede poseer tanto más de una base como ninguna.

La existencia de vértices degenerados en el caso de un poliedro canónico no es muy típica, en el sentido siguiente. Si hay un vértice degenerado, el vector b está en un subespacio de $\mathbb{R}^l$ generado por menos de l columnas de la matriz A . Por lo tanto, casi cualquier pequeña perturbación de b eliminaría todos los vértices degenerados.

Recordamos que por el Teorema 12.5, un poliedro canónico no vacío siempre posee al menos un vértice. Como es obvio, un vértice tiene una base si, y solamente si, $\text{rk } A = l$. De aquí en adelante, supongamos que $\text{rk } A = l$, lo que siempre puede ser garantizado eliminando aquellas restricciones de igualdad que son combinaciones lineales de las otras.

El método del simplex es una estrategia especial de generar vértices x^k del conjunto viable D y las bases $\mathcal{B}_k$ asociadas. Para todo k , dependiendo de los signos de ciertos parámetros generados, se hace una de las siguientes tres conclusiones:

1. El punto x^k es una solución del problema (12.16);
2. El problema (12.16) no tiene solución;
3. Existe (y puede ser calculado explícitamente) un vértice x^{k+1} del conjunto D , con base $\mathcal{B}_{k+1}$, tal que

$$x^{k+1} \neq x^k, \quad \langle c, x^{k+1} \rangle < \langle c, x^k \rangle, \quad (12.17)$$

o

$$x^{k+1} = x^k, \quad \mathcal{B}_{k+1} \neq \mathcal{B}_k. \quad (12.18)$$

El método del simplex puede ser interpretado como un método basado en la identificación de las restricciones activas (véase ??). Más precisamente, él determina el conjunto $I(\bar{x}) = \{1, \dots, n\} \setminus J(\bar{x})$ de las coordenadas nulas de un vértice óptimo $\bar{x}$, i.e., el conjunto de las restricciones de desigualdad del problema (12.16), activas en $\bar{x}$. Después de

eso, las coordenadas no nulas de $\bar{x}$ pueden ser calculadas resolviendo el sistema lineal

$$\sum_{j \in J(\bar{x})} A^j x_j = b.$$

En los primeros dos casos listados arriba, el algoritmo, naturalmente, para. Si el vértice x^k es no degenerado y estamos en el Caso 3, siempre se realiza (12.17). Si el vértice x^k es degenerado, puede ocurrir también (12.18). Sin embargo, el método posee mecanismos para evitar la elección cíclica de las bases; en algún momento siempre ocurrirá el caso (12.17), lo que significa que encontramos un nuevo vértice, mejor que el anterior.

Como el número de vértices es finito y, cuando la solución del problema (12.16) existe, una de ellas es vértice, después de un número finito de pasos obtenemos una de las conclusiones 1 o 2. En otras palabras, si el problema (12.16) posee soluciones, una de ellas será encontrada después de un número finito de pasos. Si el problema (12.16) no tiene solución, esto también será descubierto después de un número finito de pasos.

Cabe resaltar que, teóricamente, el método del simplex puede pasar por *todos* los vértices del conjunto viable hasta terminar con la conclusión 1 o 2. O sea, existen ejemplos (¡artificiales!) donde el método no presenta ninguna ventaja con relación a la estrategia del cálculo indiscriminado de todos los vértices del conjunto viable. Sin embargo, en la práctica, el desempeño del método del simplex es mucho mejor que eso. Típicamente, el número de iteraciones queda entre l y $2l$, y el método es muy adecuado para resolver problemas con n y l del orden de algunos miles.

A continuación, presentaremos los detalles del método del simplex. Sean $x^0, x^1, \dots, x^k$ los vértices del poliedro D ya calculados (un método para encontrar el primer vértice x^0 será comentado más adelante). Sea $\mathcal{B}_k = \{A^j, j \in J_k\}$ una base del vértice x^k , donde $J_k \subset \{1, \dots, n\}$. Como tratamos de explicar una iteración del método (la iteración que genera el iterado siguiente x^{k+1}), para simplificar la notación omitimos el índice k , definiendo $x = x^k$, $\mathcal{B} = \mathcal{B}_k$, $J = J_k$.

Como $\mathcal{B}$ es una base de $\mathbb{R}^l$, las columnas de la matriz A son unívocamente representadas en la forma siguiente:

$$A^i = \sum_{j \in J} \gamma_{ji} A^j, \quad i = 1, \dots, n, \quad (12.19)$$

donde los números $\gamma_{ji} \in \mathbb{R}$, $j \in J$, $i = 1, \dots, n$, se llaman **coeficientes de sustitución**. Definimos de qué se llaman **estimaciones de sustitución**:

$$\delta_i = c_i - \sum_{j \in J} c_j \gamma_{ji}, \quad i = 1, \dots, n. \quad (12.20)$$

Notemos que

$$\gamma_{ji} = \begin{cases} 1, & \text{si } j = i, \\ 0, & \text{si } j \in J \setminus \{i\}, \end{cases} \quad \delta_i = 0 \quad \forall i \in J,$$

y para $i \in J$ los coeficientes y las estimaciones de sustitución no contienen información ninguna. Es el análisis de los signos de δ_i y de γ_{ji} con $j \in J$, $i \notin J$, que permite hacer una de las tres conclusiones listadas anteriormente (de aquí en adelante, $i \notin J$ significa que $i \in \{1, \dots, n\} \setminus J$).

A continuación, presentamos el criterio de optimalidad en el método del simplex.

Teorema 12.11 (Criterio de optimalidad en el método del simplex). Para $A \in \mathbb{R}^{l \times n}$ y $b \in \mathbb{R}^l$, sea $x \in D$ un vértice del poliedro D definido en (12.16) con $\Omega = \mathbb{R}_+^n$, y sea $\mathcal{B} = \{A^j, j \in J\}$ una base de este vértice, $J \subset \{1, \dots, n\}$. Si para las estimaciones de sustitución, definidas en (12.19) y (12.20), se tiene que

$$\delta_i \geq 0 \quad \forall i \notin J, \quad (12.21)$$

entonces x es una solución del problema (12.16).

Prueba. Consideremos el dual del problema (12.16), i.e.,

$$\max \langle b, \lambda \rangle \quad \text{sueto a} \quad \lambda \in \Delta = \{\lambda \in \mathbb{R}^l \mid A^T \lambda \leq c\}. \quad (12.22)$$

Por el Teorema 12.7, para probar la afirmación basta construir un punto $\lambda \in \Delta$ tal que

$$\langle c, x \rangle = \langle b, \lambda \rangle. \quad (12.23)$$

Como $\mathcal{B}$ es una base de $\mathbb{R}^l$, existe un único $\lambda \in \mathbb{R}^l$ que satisface el sistema lineal

$$\langle A^j, \lambda \rangle = c_j, \quad j \in J. \quad (12.24)$$

Para este λ , teniendo en cuenta (12.19)-(12.21), obtenemos que para todo $i \notin J$ se tiene que

$$\langle A^i, \lambda \rangle = \sum_{j \in J} \langle A^j, \lambda \rangle \gamma_{ji} = \sum_{j \in J} c_j \gamma_{ji} = c_i - \delta_i \leq c_i.$$

En combinación con (12.24), esto muestra la inclusión $\lambda \in \Delta$. Ahora, como $\mathcal{B}$ es una base del vértice x , se tiene que $J(x) \subset J$, i.e., $x_j = 0 \forall j \notin J$. De aquí, de (12.24) y de la inclusión $x \in D$, obtenemos que

$$\langle c, x \rangle = \sum_{j=1}^n \langle A^j, \lambda \rangle x_j = \left\langle \sum_{j=1}^n A^j x_j, \lambda \right\rangle = \langle Ax, \lambda \rangle = \langle b, \lambda \rangle,$$

o sea, vale (12.23). De la demostración anterior se sigue que, si vale (12.21), entonces una solución del problema dual (12.22) puede ser encontrada resolviendo el sistema lineal (12.24). ■

Lema 12.2. Sean satisfechas las hipótesis del Teorema 12.11. Para todo índice $s \notin J$ y todo $t \geq 0$, el punto $x(t) \in \mathbb{R}^n$ con coordenadas

$$x_j(t) = \begin{cases} x_j - t\gamma_{js}, & \text{si } j \in J, \\ t, & \text{si } j = s, \\ 0, & \text{si } j \notin J, j \neq s, \end{cases} \quad (12.25)$$

satisface las siguientes relaciones:

$$Ax(t) = b, \quad (12.26)$$

$$\langle c, x(t) \rangle = \langle c, x \rangle + t\delta_s. \quad (12.27)$$

Prueba. Utilizando (12.19), (12.20) y (12.25), obtenemos que

$$\begin{aligned} Ax(t) &= \sum_{j=1}^n A^j x_j(t) \\ &= \sum_{j \in J} A^j (x_j - t\gamma_{js}) + tA^s \\ &= \sum_{j \in J} A^j x_j + t \left(A^s - \sum_{j \in J} A^j \gamma_{js} \right) \\ &= \sum_{j=1}^n A^j x_j = Ax = b, \end{aligned}$$

y

$$\begin{aligned} \langle c, x(t) \rangle &= \sum_{j=1}^n c_j x_j(t) \\ &= \sum_{j \in J} c_j (x_j - t\gamma_{js}) + tc_s \\ &= \sum_{j \in J} c_j x_j + t \left(c_s - \sum_{j \in J} c_j \gamma_{js} \right) \\ &= \sum_{j=1}^n c_j x_j + t\delta_s = \langle c, x \rangle + t\delta_s, \end{aligned}$$

lo que verifica (12.26) y (12.27). ■

Presentamos ahora el criterio de insolubilidad en el método del simplex.

Teorema 12.12 (Criterio de insolubilidad en el método del simplex). Supongamos que valen las hipótesis del Teorema 12.11. Si para los coeficientes y las estimaciones de sustitución, definidas en (12.19) y (12.20), existe un índice $s \notin J$ tal que

$$\delta_s < 0, \quad \gamma_{js} \leq 0 \quad \forall j \in J, \quad (12.28)$$

entonces el problema (12.16) no posee solución.

Prueba. De (12.27) y (12.28), para el punto $x(t)$, con coordenadas definidas en (12.25), tenemos que

$$x(t) \geq 0 \quad \forall t \geq 0,$$

$$\langle c, x(t) \rangle = \langle c, x \rangle + t\delta_s \rightarrow -\infty \quad (t \rightarrow +\infty).$$

En combinación con (12.26), estas dos relaciones muestran que $\inf_{x \in D} \langle c, x \rangle = -\infty$. ■

Ejercicio 12.11. Probar el resultado del Teorema 12.12 empleando la teoría de dualidad, sin hacer uso del Lema 12.2.

Supongamos ahora que existan índices $s \notin J$ y $j \in J$ tales que

$$\delta_s < 0, \quad \gamma_{js} > 0. \quad (12.29)$$

La idea de la iteración del método del simplex es la siguiente: procuramos cambiar la base del vértice actual de manera que se garantice que en el vértice nuevo (que corresponde a la nueva base) el valor de la función objetivo sea menor que en el vértice actual. Definimos

$$\tilde{t} = \max\{t \in \mathbb{R}_+ \mid x(t) \geq 0\}. \quad (12.30)$$

De (12.25) queda claro que

$$\tilde{t} = \min \left\{ \frac{x_j}{\gamma_{js}} \mid \gamma_{js} > 0, j \in J \right\}. \quad (12.31)$$

Sea r un índice donde se realiza el mínimo en la definición anterior, i.e.,

$$r \in J, \quad \gamma_{rs} > 0, \quad \frac{x_r}{\gamma_{rs}} = \tilde{t}. \quad (12.32)$$

Definimos también el conjunto

$$\tilde{J} = (J \setminus \{r\}) \cup \{s\}. \quad (12.33)$$

Teorema 12.13 (Iteración del método del simplex). Supongamos que valen las hipótesis del Teorema 12.11. Si para los coeficientes y las estimaciones de sustitución, definidas en (12.19) y (12.20), existen índices $s \notin J$ y $j \in J$ tales que vale (12.29), entonces el punto $\tilde{x} = x(\tilde{t})$, definido por las fórmulas (12.25), (12.31), es un vértice del poliedro D y el sistema $\tilde{\mathcal{B}} = \{A^j, j \in \tilde{J}\}$, donde el conjunto $\tilde{J}$ viene dado por (12.33), es una base de él. Además, si $\tilde{t} > 0$ entonces $\langle c, \tilde{x} \rangle < \langle c, x \rangle$; y si $\tilde{t} = 0$ entonces $\tilde{x} = x$, pero $\tilde{\mathcal{B}} \neq \mathcal{B}$.

Prueba. De (12.25), (12.30) y de la igualdad en (12.32), se sigue que $\tilde{x} \geq 0$ y $\tilde{x}_r = x_r - \tilde{t}\gamma_{rs} = 0$. Por lo tanto, utilizando el Lema 12.2 y (12.33), obtenemos que $\tilde{x} \in D$ y

$$J(\tilde{x}) \subset \tilde{J}. \quad (12.34)$$

Además, de (12.19) tenemos

$$A^s = \sum_{j \in J} \gamma_{js} A^j = \sum_{j \in J \setminus \{r\}} \gamma_{js} A^j + \gamma_{rs} A^r.$$

Como de (12.32) tenemos que $\gamma_{rs} > 0$, concluimos que

$$A^r = \frac{1}{\gamma_{rs}} A^s - \sum_{j \in J \setminus \{r\}} \frac{\gamma_{js}}{\gamma_{rs}} A^j. \quad (12.35)$$

De aquí, de (12.33) y del hecho de que $\mathcal{B}$ es una base de $\mathbb{R}^l$, se sigue que $\tilde{\mathcal{B}}$ también es una base de $\mathbb{R}^l$. Por lo tanto, por (12.34) y por el Teorema 12.4, el punto $\tilde{x}$ es un vértice de D y $\tilde{\mathcal{B}}$ es una base de él. La última afirmación del teorema se sigue de (12.25), (12.27) y (12.29). ■

Observamos que la nueva base $\tilde{\mathcal{B}}$ se obtiene de la base anterior $\mathcal{B}$ sustituyendo la columna A^r por la columna A^s . En otras palabras, la columna A^r está eliminada de la base y la columna A^s está incluida. A veces, el coeficiente de sustitución γ_{rs} se llama elemento principal.

Si x es un vértice no degenerado, se tiene que $J(x) = J$, i.e., $x_j > 0 \forall j \in J$. En este caso, de (12.31) se sigue que $\tilde{t} > 0$. Por lo tanto, en la iteración de este tipo necesariamente se realiza (12.17), i.e., el método genera un nuevo vértice, mejor que el anterior. Iteraciones de este tipo se ilustran en la figura 12.3.

Si x es un vértice degenerado, posiblemente existe un índice $j \in J$ tal que $x_j = 0$ y $\gamma_{js} > 0$. En este caso, de (12.25) y (12.31) se sigue que $\tilde{t} = 0$, $\tilde{x} = x$, i.e., el método no genera un vértice nuevo y la iteración consiste solamente en el cambio de la base $\mathcal{B}$ del vértice x por la base $\tilde{\mathcal{B}}$. Resaltamos que esto también es una operación no trivial, ya que para la nueva base tenemos que recalcular los coeficientes y las estimaciones de sustitución (y, posiblemente, el propio vértice será cambiado en la iteración siguiente). Sin embargo, también puede ocurrir que las iteraciones del método del simplex se reduzcan a la generación de bases para un mismo vértice. Como el número de bases es finito, a partir de un cierto momento ellas serán repetidas. O sea, el método entra en un *ciclo*. Existen ejemplos (¡artificiales!) donde esto realmente ocurre, pero situaciones así no son típicas en la práctica computacional. Recordamos que la propia existencia de vértices degenerados ya es una situación rara, e incluso para un vértice degenerado, típicamente alguna base resulta en la generación de un vértice nuevo.




Figura 12.3.: Dos iteraciones del método del simplex que generan vértices no degenerados (y resultan en un decrecimiento de la función objetivo). El último iterado es la solución del problema.

Además de eso, la iteración del método del simplex puede ser organizada de manera que elimine la posibilidad de ciclo. La idea consiste en la utilización de ciertas estrategias especiales para la elección de columnas que dejan la base y que entran (en los casos cuando hay más de un candidato). Una estrategia más simple es la **regla de Bland**: en el caso cuando (12.29) se satisface, tomamos los menores números s y r entre los posibles, i.e.,

$$s = \min\{i \mid i \notin J, \delta_i < 0\},$$

$$r = \min\{j \mid j \in J, \gamma_{js} > 0, x_j/\gamma_{js} = \tilde{t}\}.$$

Estos últimos comentarios concluyen la descripción de una iteración del método del simplex. En la iteración siguiente, las mismas construcciones se repiten para el vértice $\bar{x}$ y la base de él $\tilde{\mathcal{B}}$. Para eso, primero calculamos los coeficientes $\tilde{\gamma}_{ji}$ y las estimaciones $\tilde{\delta}_i$ de sustitución correspondientes, $j \in \tilde{J}, i = 1, \dots, n$. En principio, para esto necesitamos resolver el sistema lineal correspondiente (véase (12.19)). Sin embargo, no hay necesidad de resolver el sistema, ya que los coeficientes y las estimaciones de sustitución en las dos iteraciones siguientes tienen relaciones explícitas. En particular, utilizando (12.19), (12.20) y (12.35), es fácil verificar que para todo $i = 1, \dots, n$, se tiene que

$$\tilde{\gamma}_{ji} = \begin{cases} \gamma_{ji} - \gamma_{js}\gamma_{ri}/\gamma_{rs}, & \text{si } j \in J \setminus \{r\}, \\ \gamma_{ri}/\gamma_{rs}, & \text{si } j = s, \end{cases}$$

$$\tilde{\delta}_i = \delta_i - \delta_s \frac{\gamma_{ri}}{\gamma_{rs}}.$$

Ejercicio 12.12. Probar las fórmulas de arriba relacionando los coeficientes y las estimaciones de sustitución en las dos iteraciones siguientes del método del simplex.

Ejercicio 12.13. Encontrando todos los vértices del conjunto viable, resolver el problema

$$\min x_1 + 2x_2 + 4x_3 \quad \text{sujeto a } x \in D,$$

$$D = \{x \in \mathbb{R}_+^3 \mid 2x_1 + 3x_2 + 4x_3 = 10, x_1 + x_2 - x_3 = 4\}.$$

Ejercicio 12.14. A partir del vértice $x = (0, 1, 3)$, hacer una iteración del método del simplex para el problema

$$\min -x_1 - x_2 - x_3 \quad \text{sujeto a } x \in D,$$

$$D = \{x \in \mathbb{R}_+^3 \mid -2x_1 + x_2 + x_3 = 4, x_1 - 2x_2 + x_3 = 1\}.$$

Ejercicio 12.15. A partir del vértice $x = (1, 1, 0)$, hacer una iteración del método del simplex para el problema

$$\min -x_1 + 2x_2 - x_3 \quad \text{sujeto a } x \in D,$$

$$D = \{x \in \mathbb{R}_+^3 \mid x_1 - x_2 + 2x_3 = 0, x_1 + x_2 + 5x_3 = 2\}.$$

Ejercicio 12.16. Aplicando el método del simplex a partir del vértice $x = (1, 0, 1, 0)$, resolver el problema

$$\min -x_1 + 3x_2 + 5x_3 + x_4 \quad \text{sujeto a} \quad x \in D,$$

$$D = \{x \in \mathbb{R}_+^4 \mid x_1 + 4x_2 + 4x_3 + x_4 = 5, x_1 + 7x_2 + 8x_3 + 2x_4 = 9\}.$$

Ejercicio 12.17. Aplicando el método del simplex a partir del vértice $x = (0, 0, 1, 3)$, resolver el problema

$$\min -3x_1 - x_2 - x_3 + x_4 \quad \text{sujeto a} \quad x \in D,$$

$$D = \{x \in \mathbb{R}_+^4 \mid x_1 - x_2 + x_3 = 1, 2x_1 + x_2 + x_4 = 3\}.$$

Para finalizar, comentamos el asunto del cálculo de un vértice inicial (que es necesario para comenzar el proceso descrito arriba). A veces, esta tarea no es difícil. Consideremos, por ejemplo, el siguiente problema de programación lineal:

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad x \in D = \{x \in \Omega \mid Ax \geq b\},$$

donde $c \in \mathbb{R}^n, A \in \mathbb{R}^{l \times n}, b \in \mathbb{R}^l, \Omega = \mathbb{R}_+^n$. Consideremos el caso cuando $b \geq 0$. Este problema puede ser transformado al formato canónico:

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad (x, y) \in \tilde{D} = \{z = (x, y) \in \tilde{\Omega} \mid Ax - y = b\}, \quad (12.36)$$

donde $\tilde{\Omega} = \mathbb{R}_+^n \times \mathbb{R}_+^m$. Es fácil ver que el punto $z = (0, b)$ es un vértice del poliedro canónico $\tilde{D}$, y que la base canónica del espacio $\mathbb{R}^m$ es una base de este vértice.

En el caso general, el cálculo de un vértice inicial es comparable en costos computacionales con el método del simplex propiamente dicho. El esquema siguiente para el cálculo de un vértice inicial es llamado **método de base artificial**. De hecho, él es el método del simplex aplicado a un problema auxiliar.

Sin pérdida de generalidad, admitimos que en el problema (12.16) tenemos $b \geq 0$ (esto siempre puede ser garantizado cambiando los signos de las restricciones, donde sea necesario). Consideremos el siguiente problema auxiliar:

$$\min \sum_{i=1}^l y_i \quad \text{sujeto a} \quad (x, y) \in \tilde{D}, \quad (12.37)$$

donde el conjunto $\tilde{D}$ está definido en (12.36). Por lo visto arriba, en este caso sabemos un vértice $z = (0, b)$ del poliedro $\tilde{D}$ y una base de él. A partir de este vértice, aplicamos el método del simplex para resolver el problema (12.36). Como la función objetivo de este problema está limitada inferiormente (por cero) y el conjunto viable $\tilde{D}$ es no vacío, por el Teorema 12.1, el problema (12.37) tiene soluciones. Luego, el método del simplex encontraría una solución $z^0 = (x^0, y^0)$, que es un vértice del poliedro $\tilde{D}$.

Existen dos posibilidades. Si $y^0 \neq 0$, el valor óptimo del problema (12.37) es positivo y el conjunto viable D del problema (12.16) es vacío. En efecto, si un punto $x \in D$ existiera, tendríamos $z = (x, 0) \in \tilde{D}$ con valor de la función objetivo del problema (12.37) nulo en el punto z . Pero esto contradice el hecho de que z^0 es una solución del problema (12.37). Por otro lado, si $y^0 = 0$, se tiene que x^0 es un vértice de D , ya que esto es equivalente a que $(x^0, 0)$ sea un vértice de $\tilde{D}$.

El método de base artificial también puede ser equipado con el cálculo de una base del vértice inicial x^0 .

Ejercicio 12.18. Probar que, bajo las condiciones del Teorema 12.11, si el vértice x es no degenerado, entonces vale la afirmación inversa a aquella del teorema: si x es una solución del problema (12.16), entonces la condición (12.21) se satisface; y si x es una única solución, entonces $\delta_i > 0 \forall i \notin J$.

Construir un ejemplo mostrando que para un vértice degenerado, tal afirmación puede ser falsa.

12.1.3. Métodos de puntos interiores

Los métodos de puntos interiores se volvieron bastante populares a partir de los años 80 del siglo pasado. El interés inicial se debió a la complejidad polinomial de estos métodos, lo que los diferencia del método del simplex que tiene complejidad exponencial (véase comentarios más adelante). Un poco más tarde, fueron desarrolladas versiones de los métodos de puntos interiores bien competitivas también desde el punto de vista computacional. A propósito, actualmente los métodos de puntos interiores son los más indicados para problemas de gran escala. A continuación presentaremos algunas ideas básicas, sin entrar en todos los detalles.

Comenzamos con algunos comentarios sobre la complejidad de algoritmos. Informalmente hablando, por *complejidad* de un método entendemos la dependencia de la cantidad máxima de cálculos (iteraciones, operaciones aritméticas, etc.) necesarias para encontrar una solución exacta del problema en función de las dimensiones del problema de la clase en consideración. Si esta dependencia puede ser acotada superiormente por un polinomio (con respecto a las dimensiones del problema), hablamos de complejidad polinomial. Si la cota superior tiene forma exponencial, hablamos entonces de complejidad exponencial. Resaltamos que en cuestión están estimaciones para “el peor caso posible”, i.e., para los problemas más difíciles de resolver (por el método en consideración).

Los métodos de puntos interiores poseen complejidad polinomial. El método del simplex, por otro lado, tiene complejidad exponencial, ya que la naturaleza de este último tiene aspectos claramente combinatorios (recordamos que para encontrar una solución, el método del simplex puede precisar calcular todos los vértices del conjunto viable).

Consideremos un problema de programación lineal, por ejemplo, en forma canónica:

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}_+^n \mid Ax = b\}, \quad (12.38)$$

donde $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$ son dados. La cantidad de cálculos típicamente es medida en términos de la dimensión del problema (12.38), como se llama al número

$$s = q + n + l,$$

donde q es el número total de bits (en inglés) necesarios para representar elementos de c , A y b , suponiendo que ellos sean números enteros (números reales pueden ser representados por enteros). El significado del número s es el siguiente: 2^s es un número “muy grande”, en el sentido de que es mayor que el resultado de cualquier operación aritmética utilizando los datos del problema. Luego, 2^{-s} es un número “muy pequeño”, que posee las propiedades siguientes. Si $\hat{x}$ es un vértice del poliedro D entonces, primero, $\hat{x}_j \notin (0, 2^{-s}) \forall j = 1, \dots, n$, y segundo, $\langle c, \hat{x} \rangle - \bar{v} \notin (0, 2^{-s})$, donde $\bar{v} = \inf_{x \in D} \langle c, x \rangle$ es el valor óptimo del problema (12.38).

Recordamos que el método del simplex es finito: él encuentra una solución exacta después de un número finito de iteraciones. Como veremos más adelante, los métodos de puntos interiores no tienen convergencia finita, apenas asintótica (ya que ellos siempre generan puntos en el interior del conjunto viable, y la solución de un problema de programación lineal está siempre en la frontera). Sin embargo, teniendo una aproximación a la solución suficientemente buena, la solución exacta puede ser obtenida utilizando la llamada *técnica de purificación*¹, que para un punto $x \in D$ cualquiera encuentra un vértice $\hat{x}$ del poliedro D tal que $\langle c, \hat{x} \rangle \leq \langle c, x \rangle$, en un número de operaciones aritméticas de orden $O(n^3)$. Naturalmente, la técnica de purificación tiene un papel puramente teórico (el de viabilizar una comparación entre el método del simplex, que es finito, y los métodos de puntos interiores, que no son finitos). Ella no es utilizada en la práctica computacional.

Teniendo en cuenta lo dicho arriba, en el análisis de la complejidad de los métodos de puntos interiores se considera que ellos paran cuando un iterado x satisface la desigualdad

$$\langle c, x \rangle - \bar{v} < 2^{-s}. \quad (12.39)$$

Cuando hablamos de la complejidad polinomial de métodos de puntos interiores, entendemos lo siguiente. La cantidad de cálculos necesarios para que el método alcance la propiedad (12.39) puede ser acotada por un polinomio en relación a n . Habiendo calculado un punto x que satisface (12.39), puede ser utilizada la técnica de purificación para encontrar un vértice que es una solución exacta del problema. Como la complejidad de la purificación es polinomial, ella no interfiere en la complejidad polinomial del método como un todo. Naturalmente, versiones diferentes de los métodos de puntos interiores poseen diferentes estimaciones de complejidad. En términos de número de iteraciones, hay estimaciones de orden $O(\sqrt{ns})$, y en términos de operaciones aritméticas, de orden $O(n^{3.5}s)$.

Por otro lado, es claro que el número de vértices del poliedro D puede depender de n de manera exponencial (por ejemplo, una caja en $\mathbb{R}^n$ tiene 2^n vértices). Y como comentamos en la apartado 12.1.2, el método del simplex puede calcular todos los vértices hasta encontrar una solución del problema. Tales ejemplos existen y muestran que la complejidad del método del simplex es exponencial (¡en el sentido del peor caso posible!).

Sin embargo, es importante resaltar lo siguiente. Aunque la complejidad atractiva de un método dado sea ciertamente deseable, ella puede reflejarse muy poco en el desempeño del método cuando es aplicado a problemas típicos o de interés práctico. No es raro que métodos con mejores estimaciones de complejidad sean menos eficientes en la práctica que métodos con propiedades, en principio, peores. Por ejemplo, existen métodos de puntos interiores que poseen complejidad polinomial, pero no tienen ningún valor computacional (en particular, son mucho peores

¹En inglés: *purification procedure*.

que el método del simplex). Por otro lado, hay métodos de puntos interiores muy buenos (en particular, versiones primal-dual) que son computacionalmente eficientes, y actualmente son la elección para problemas muy grandes.

Los métodos de puntos interiores (principalmente, versiones primales) pueden ser pensados como implementaciones aproximadas de los métodos de barreras (véase apartado 10.3.3).

A continuación, consideraremos un método de puntos interiores para el problema canónico (12.38). Recordamos que esto no reduce la generalidad. En este contexto, es conveniente tomar

$$\Omega = \{x \in \mathbb{R}^n \mid Ax = b\},$$

tratando las restricciones de igualdad como abstractas, y penalizar las restricciones $x \geq 0$. Supongamos que el conjunto viable D en (12.38) sea acotado y que $D^0 \neq \emptyset$, donde

$$D^0 = \{x \in \Omega \mid x > 0\}. \quad (12.40)$$

Supongamos también que $\text{rk } A = l$, lo que siempre puede ser garantizado eliminando restricciones que son consecuencias de las otras, si fuera necesario.

Definimos la **trayectoria central** (primal) del problema (12.38) como la función $x : (\mathbb{R}_+ \setminus \{0\}) \rightarrow D^0$, donde para todo valor del parámetro $t > 0$ de la penalización, $x(t)$ es la solución del problema

$$\min \varphi(x; t) \quad \text{sujeto a} \quad x \in D^0, \quad (12.41)$$

donde

$$\varphi(\cdot; t) : \{x \in \mathbb{R}^n \mid x > 0\} \rightarrow \mathbb{R}, \quad \varphi(x; t) = \langle c, x \rangle - t \sum_{j=1}^n \log x_j. \quad (12.42)$$

Como la función objetivo en (12.41) es coerciva en el conjunto viable, el problema en cuestión posee solución. Más aún, como el problema es de programación convexa y la función objetivo es estrictamente convexa, la solución es única. Por lo tanto, la trayectoria central está bien definida.

Intuitivamente, parece natural seguir la trayectoria central “comenzando” con $t = +\infty$ hasta $t = 0$. Por eso, es común definir el valor de x para $t = +\infty$ de la manera siguiente. Observemos que para todo $t > 0$, el problema (12.41), con la función objetivo definida en (12.42), tiene la misma solución que

$$\max \sum_{j=1}^n \log x_j - \frac{1}{t} \langle c, x \rangle \quad \text{sujeto a} \quad x \in D^0.$$

Tomando el límite cuando $t \rightarrow +\infty$, obtenemos el problema

$$\max \sum_{j=1}^n \log x_j \quad \text{sujeto a} \quad x \in D^0.$$

Definimos $x(+\infty)$ como la solución de este problema. Este punto inicial de la trayectoria central se llama **centro analítico** del conjunto D definido en (12.38). Notemos que él depende de A y b (i.e., del conjunto viable) y no depende de c (i.e., de la función objetivo). El centro analítico de un conjunto y algunas trayectorias centrales están ilustradas en la figura 12.4.




Figura 12.4.: El centro analítico de D y las trayectorias centrales para dos funciones objetivo diferentes.

Observemos también que para $t > 0$, el punto $x(t)$ es el centro analítico de la intersección del conjunto D con el hiperplano donde la función objetivo del problema (12.38) tiene el valor $\langle c, x(t) \rangle$, i.e., $x(t)$ es la solución del problema

$$\max \sum_{j=1}^n \log x_j \quad \text{sueto a} \quad x \in D_t^0 = \{x \in D^0 \mid \langle c, x \rangle = \langle c, x(t) \rangle\}.$$

Este hecho se ilustra en la figura 12.5.




Figura 12.5.: El punto $x(t)$ de la trayectoria central es el centro analítico de la intersección de D con el hiperplano donde el valor de la función objetivo es $\langle c, x(t) \rangle$.

Puede ser probado que el límite $\lim_{t \rightarrow 0^+} x(t)$ existe y es el centro analítico del conjunto de las soluciones del problema (12.38). No vamos a probar este resultado, porque la justificación del apartado 10.3.3 ya sirve como motivación suficiente para intentar encontrar alguna estrategia de seguir la trayectoria central, principalmente si pudimos hacer esto de manera computacionalmente barata, sin precisar calcular valores exactos (o casi exactos) de la función x (o sea, sin resolver los subproblemas penalizados).

El esquema básico de los métodos de puntos interiores (primales) es el siguiente.

Algoritmo 6.1.1. (El método de puntos interiores primal)

Escoger parámetro inicial $t_0 > 0$. Para el conjunto D^0 definido en (12.40), escoger $x^{-1} \in D^0$ y tomar $k := 0$.

1. A partir del punto x^{k-1} , calcular $x^k \in D^0$ dando algunos pasos de un método (típicamente, Newtoniano) para el problema (12.41), donde la función objetivo está dada en (12.42) con $t = t_k$.
2. Escoger $t_{k+1} \in (0, t_k)$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

En este esquema, el punto x^{-1} debe ser suficientemente próximo a $x(t_0)$, y el número de pasos del método interno debe garantizar que, para todo x^{k-1} , el punto siguiente x^k quede suficientemente próximo a $x(t_k)$. Existen métodos con complejidad polinomial que permiten para $t_0 > 0$ arbitrario aproximar $x(t_0)$ con cualquier precisión deseada.

Es claro que el Algoritmo 6.1.1 es solo un esquema básico. Para obtener un método completo, será necesario especificar varios detalles. Por ejemplo, la regla de decrecimiento del parámetro t_k a lo largo de las iteraciones es muy importante. Si la sucesión de parámetros disminuye despacio, entonces para todo k el punto $x(t_k)$ estará próximo a $x(t_{k-1})$, y podemos esperar que unos pocos pasos (tal vez apenas un) del método interno a partir del punto x^{k-1} producirán x^k lo suficientemente próximo a $x(t_k)$ para garantizar convergencia del algoritmo. Un poco más adelante mostraremos que esto realmente ocurre. Sin embargo, esta estrategia puede requerir un número grande de iteraciones (del método externo) para generar un punto $x(t_k)$ próximo al conjunto de soluciones del problema (12.38), ya que muchas actualizaciones serán necesarias para que t_k llegue próximo a cero. La alternativa es disminuir el parámetro más rápidamente, a costa de aumentar el número de iteraciones del método interno. En el primer caso, hablamos de *métodos de pasos cortos*², y en el segundo – de *métodos de pasos largos*³. Consideremos los métodos de pasos cortos, que tienen estimaciones de complejidad mejores. Resaltamos, sin embargo, que las buenas implementaciones de los métodos de pasos largos son, usualmente, más eficientes en la práctica.

²En inglés: *short-step methods*.

³En inglés: *long-step methods*.

Sea $x \in D^0$ la aproximación actual a la solución del problema (12.41). Definimos el paso Newtoniano para este problema: la aproximación siguiente $\tilde{x} \in \mathbb{R}^n$ se calcula como solución del problema

$$\min \langle \varphi'(x; t), \xi - x \rangle + \frac{1}{2} \langle \varphi''(x; t)(\xi - x), \xi - x \rangle \quad \text{sueto a } \xi \in \Omega. \quad (12.43)$$

Si ignoramos en el problema (12.41) las restricciones funcionales $x > 0$ (lo que puede ser hecho, en cierto sentido; véase los comentarios en apartado 10.3.3), el problema (12.43) puede ser interpretado como una iteración del método de Newton irrestricto con longitud de paso unitario (véase apartado 10.1.3) o, ya que las restricciones que definen Ω son lineales, como una iteración del método de programación cuadrática secuencial (véase ??).

De aquí en adelante, denotamos $e = (1, \dots, 1) \in \mathbb{R}^n$. Para todo $x \in \mathbb{R}^n$, denotamos por $X \in \mathbb{R}^{n \times n}$ la matriz diagonal con coeficientes $(x_1, \dots, x_n)$. Definimos también las siguientes funciones:

$$\lambda : (\mathbb{R}_+ \setminus \{0\}) \times D^0 \rightarrow \mathbb{R}^l, \quad \lambda(t, x) = (AX^2A^T)^{-1}AX(Xc - te), \quad (12.44)$$

$$d : (\mathbb{R}_+ \setminus \{0\}) \times D^0 \rightarrow \mathbb{R}^n, \quad d(t, x) = \frac{1}{t}X(c - A^T\lambda(t, x)) - e. \quad (12.45)$$

Ejercicio 12.19. Para $t > 0$ y $x \in D^0$ dados, sea $\tilde{x} \in \mathbb{R}^n$ la solución del problema (12.43), donde la función $\varphi(\cdot; t)$ está definida en (12.42), $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$, $\Omega = \{x \in \mathbb{R}^n \mid Ax = b\}$, y el conjunto D^0 es dado por (12.40). Sean los vectores $d(t, x) \in \mathbb{R}^n$ y $\lambda(t, x) \in \mathbb{R}^l$ definidos por (12.44), (12.45). Probar que

$$\tilde{x} = x - Xd(t, x),$$

y que $\lambda(t, x)$ es la solución del problema

$$\min \left\| \frac{1}{t}X(c - A^T y) - e \right\|, \quad y \in \mathbb{R}^l.$$

Mostrar que $d(t, x) = 0$ si, y solamente si, x es una solución del problema (12.41).

Por lo tanto, el vector $-d(t, x) = X^{-1}(\tilde{x} - x)$ puede ser considerado como un paso del método de Newton para el problema (12.41) a partir del punto x , preconditionado por la matriz X^{-1} . Como veremos a continuación, $\|d(t, x)\|$ sirve como medida de proximidad de x a $x(t)$. El resultado a ser presentado puede ser pensado también como una caracterización de convergencia del método general de barreras (véase apartado 10.3.3) cuando es aplicado al problema de programación lineal (12.38). Para el método de puntos interiores, el resultado es importante porque establece la precisión con la que los subproblemas tienen que ser resueltos para garantizar convergencia del método.

Proposición 12.2. Sean $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$. Sean $\Omega = \{x \in \mathbb{R}^n \mid Ax = b\}$ y D^0 el conjunto definido en (12.40). Sean λ y d las funciones definidas por las fórmulas (12.44), (12.45). Entonces, si para el número $t > 0$ y el punto $x \in D^0$ dados vale que $\|d(t, x)\| < 1$, se tiene que

$$\begin{aligned} \langle c, x \rangle - \bar{v} &\leq \langle c, x \rangle - \langle b, \lambda(t, x) \rangle \\ &\leq t(n + \sqrt{n}\|d(t, x)\|) \\ &< t(n + \sqrt{n}), \end{aligned} \quad (12.46)$$

donde $\bar{v} = \inf_{x \in D} \langle c, x \rangle$.

Prueba. Por (12.45), tenemos que

$$\left\| \frac{1}{t}X(c - A^T\lambda(t, x)) - e \right\| < 1,$$

de donde se sigue que $X(c - A^T\lambda(t, x)) > 0$. De aquí y de la condición $x \in D^0$, obtenemos que

$$c - A^T\lambda(t, x) > 0. \quad (12.47)$$

Por eso, para cualquier solución $\bar{x}$ del problema (12.38), tenemos que

$$\bar{v} = \langle c, \bar{x} \rangle \geq \langle A^T\lambda(t, x), \bar{x} \rangle = \langle \lambda(t, x), A\bar{x} \rangle = \langle \lambda(t, x), b \rangle,$$

donde tuvimos en cuenta que $\bar{x} \in D$. Esto verifica la primera desigualdad en (12.46). Ahora, por la desigualdad de Cauchy-Schwarz, tenemos lo siguiente:

$$\begin{aligned} \langle e, \frac{1}{t}X(c - A^T\lambda(t, x)) - e \rangle &\leq \|e\| \left\| \frac{1}{t}X(c - A^T\lambda(t, x)) - e \right\| \\ &= \sqrt{n} \|d(t, x)\| \\ &< \sqrt{n}. \end{aligned}$$

Por otro lado,

$$\begin{aligned} \langle e, \frac{1}{t}X(c - A^T\lambda(t, x)) - e \rangle &= \frac{1}{t} \langle x, c - A^T\lambda(t, x) \rangle - \|e\|^2 \\ &= \frac{1}{t} (\langle c, x \rangle - \langle b, \lambda(t, x) \rangle) - n, \end{aligned}$$

donde tuvimos en cuenta que $x \in \Omega$. Combinando las dos últimas relaciones, obtenemos las últimas dos desigualdades en (12.46). ■

Recordamos que el punto x en consideración es viable en el problema (12.38). Además de eso, en las condiciones de la Proposición 12.2, vale (12.47). Por eso, el punto $\lambda(t, x)$ es viable en el problema dual de (12.38), i.e., en el problema

$$\max \langle b, \lambda \rangle \quad \text{sujeto a} \quad \lambda \in \Delta = \{\lambda \in \mathbb{R}^l \mid A^T\lambda \leq c\}. \quad (12.48)$$

Más aún, la relación (12.46) proporciona una estimación de proximidad entre los valores $\langle c, x \rangle$ y $\langle b, \lambda(t, x) \rangle$, y la diferencia entre ellos tiende a cero cuando $t \rightarrow 0$ (comparar con el Teorema 12.7).

A continuación, probaremos que el conjunto

$$\{x \in D^0 \mid \|d(t, x)\| < 1\}$$

está contenido en la región de convergencia cuadrática del método Newtoniano para el problema auxiliar (12.41) descrito arriba. Después de eso, mostraremos cómo debe ser actualizado el parámetro de barrera t para garantizar que el iterado siguiente valga lo mismo, i.e., que él también quede en la región de convergencia rápida del método Newtoniano, para el nuevo subproblema (con nuevo valor de t).

Proposición 12.3. *En las condiciones de la Proposición 12.2, si para el número $t > 0$ y el punto $x \in D^0$ dados vale que $\|d(t, x)\| < 1$, entonces el punto $\bar{x} = x - Xd(t, x)$ satisface*

$$\bar{x} \in D^0, \quad \|d(t, \bar{x})\| \leq \|d(t, x)\|^2. \quad (12.49)$$

Prueba. Definimos $z = X(c - A^T\lambda(t, x))/t$. Por (12.45), tenemos que $d(t, x) = z - e$. De la condición $\|d(t, x)\| < 1$ se sigue que $0 < z_j < 2 \forall j = 1, \dots, n$. Además de eso,

$$\bar{x} = x - X(z - e) = 2x - Xz.$$

Por lo tanto, $\bar{x}_j = (2 - z_j)x_j > 0 \forall j = 1, \dots, n$. Por la primera afirmación del Ejercicio 6.1.19, tenemos que $\bar{x} \in \Omega$. Luego, vale la inclusión en (12.49). El punto $\lambda(t, \bar{x})$ es la solución del problema

$$\min \left\| \frac{1}{t} \tilde{X}(c - A^T y) - e \right\|, \quad y \in \mathbb{R}^l$$

(véase el Ejercicio 12.19). Por lo tanto,

$$\begin{aligned} \|d(t, \bar{x})\| &= \left\| \frac{1}{t} \tilde{X}(c - A^T\lambda(t, \bar{x})) - e \right\| \\ &\leq \left\| \frac{1}{t} \tilde{X}(c - A^T\lambda(t, x)) - e \right\| \\ &= \|\tilde{X}X^{-1}z - e\|. \end{aligned}$$

Recordando que $\bar{x} = 2x - Xz$, obtenemos

$$\tilde{X}X^{-1}z = (2X - ZX)X^{-1}z = 2z - Zz.$$

De las dos últimas relaciones se sigue que

$$\begin{aligned}
 \|d(t, \tilde{x})\|^2 &\leq \|2z - Zz - e\|^2 \\
 &= \sum_{j=1}^n (2z_j - z_j^2 - 1)^2 = \sum_{j=1}^n (z_j - 1)^4 \\
 &\leq \left(\sum_{j=1}^n (z_j - 1)^2 \right)^2 \\
 &= \|z - e\|^4 = \|d(t, x)\|^4,
 \end{aligned}$$

lo que verifica (12.49). ■

El resultado que acabamos de probar muestra que si $\|d(t, x)\|$ es suficientemente pequeño, después de un paso Newtoniano $\|d(t, \tilde{x})\|$ queda aún menor. Por eso, si el valor $\tilde{t}$ del nuevo parámetro de barrera no es muy diferente de t , podemos esperar que el valor de $\|d(\tilde{t}, \tilde{x})\|$ también sea suficientemente pequeño. Más precisamente, tenemos lo siguiente.

Proposición 12.4. *En las condiciones de la Proposición 12.2, si para el número $t > 0$ y el punto $x \in D^0$ dados vale que $\|d(t, x)\| = \delta < 1$, entonces para cualquier $\theta \in (0, \sqrt{n})$, el número*

$$\tilde{t} = (1 - \theta/\sqrt{n})t \in (0, t) \quad (12.50)$$

y el punto $\tilde{x} = x - Xd(t, x)$ satisfacen

$$\|d(\tilde{t}, \tilde{x})\| \leq \frac{\delta^2 + \theta}{1 - \theta/\sqrt{n}}.$$

En particular, si $\theta \leq \delta(1 - \delta)/(1 + \delta)$, entonces

$$\|d(\tilde{t}, \tilde{x})\| \leq \delta.$$

Prueba. De (12.45), de la desigualdad en (12.49), de (12.50), y del hecho de que $\lambda(\tilde{t}, \tilde{x})$ es la solución del problema

$$\min \left\| \frac{1}{\tilde{t}} \tilde{X}(c - A^T y) - e \right\|, \quad y \in \mathbb{R}^l$$

(véase el Ejercicio 12.19), obtenemos que

$$\begin{aligned}
 \|d(\tilde{t}, \tilde{x})\| &= \left\| \frac{1}{\tilde{t}} \tilde{X}(c - A^T \lambda(\tilde{t}, \tilde{x})) - e \right\| \\
 &\leq \left\| \frac{1}{\tilde{t}} \tilde{X}(c - A^T \lambda(t, \tilde{x})) - e \right\| \\
 &= \left\| \frac{\tilde{X}(c - A^T \lambda(t, \tilde{x}))}{(1 - \theta/\sqrt{n})t} - e \right\| \\
 &= \left\| \frac{d(t, \tilde{x}) + e}{1 - \theta/\sqrt{n}} - e \right\| \\
 &= \frac{\|d(t, \tilde{x}) + \theta e/\sqrt{n}\|}{1 - \theta/\sqrt{n}} \\
 &\leq \frac{\|d(t, \tilde{x})\| + \theta \|e\|/\sqrt{n}}{1 - \theta/\sqrt{n}} \\
 &\leq \frac{\|d(t, x)\|^2 + \theta}{1 - \theta/\sqrt{n}} \\
 &= \frac{\delta^2 + \theta}{1 - \theta/\sqrt{n}},
 \end{aligned}$$

como fue enunciado. ■

Resumiendo, si tomar x^{-1} suficientemente próximo a $x(t_0)$ y controlar los parámetros de barrera t_k de manera adecuada, para todo k un paso Newtoniano será suficiente para aproximar $x(t_k)$ con precisión satisfactoria. En particular, siempre podemos forzar a que los puntos x^k queden tan próximos a la trayectoria central como deseemos. Como ya fue comentado arriba, esto viene con cierto costo – los parámetros t_k tienen que ser disminuidos lentamente (véase la fórmula (12.50) en la Proposición 12.4). Aun así, los resultados presentados son importantes y sirven como base para el desarrollo de métodos más sofisticados y más prácticos.

Un aspecto importante que está ausente en el Algoritmo 6.1.1 es el preconditionamiento. Notemos que si el punto $x^{k-1} \in D^0$ está próximo a la frontera del ortante no negativo, esto puede llevar a hacer pasos muy cortos, así como a inestabilidad numérica (ya que la matriz X^{k-1} será casi degenerada; véase las fórmulas (12.44), (12.45)). Esta dificultad puede ser aliviada haciendo preconditionamiento del subproblema, por ejemplo de la siguiente manera. En el espacio $\mathbb{R}^n$, aplicamos la transformación lineal de las variables, dada por $(X^{k-1})^{-1}$. El elemento x^{k-1} será transformado en $\xi^{k-1} = e$. Calculamos $-d(t_k, \xi^{k-1})$ como el paso Newtoniano para el problema preconditionado (12.41) con $t = t_k$ (notemos que $X^{k-1} = E^n$). Tomamos $\xi^k = \xi^{k-1} - d(t_k, \xi^{k-1})$, e invertimos la transformación de las variables: $x^k = X^{k-1} \xi^k$. La idea consiste en alejar el punto actual de la frontera de $\mathbb{R}_+^n$, aumentando así el “espacio para maniobra”. Además de eso, varias fórmulas relacionadas a la barrera (y a las derivadas de ella) se simplifican después de esta transformación de las variables.

A continuación, presentamos métodos de puntos interiores *primal-duales*. Por el Teorema 12.2, las condiciones necesarias y suficientes de optimalidad para el problema (12.38) están dadas por el sistema

$$A^T \lambda + z = c, \quad Ax = b, \quad (12.51)$$

$$x \geq 0, \quad z \geq 0, \quad \langle z, x \rangle = 0, \quad (12.52)$$

con respecto a $(x, \lambda, z) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$, donde la variable dual z corresponde a la restricción $x \geq 0$ del problema primal. La idea de los métodos de puntos interiores primal-duales consiste en la modificación del sistema anterior para eliminar el aspecto no diferenciable (o, también, combinatorio) de la condición de complementariedad en (12.52). Para este fin, cambiamos (12.52) por las condiciones siguientes:

$$x_j > 0, \quad z_j > 0, \quad x_j z_j = t, \quad j = 1, \dots, n, \quad (12.53)$$

donde $t > 0$ es un parámetro (que se aproxima a cero a lo largo de las iteraciones). Así, ignorando las desigualdades estrictas, en vez de (12.51), (12.52), obtenemos el sistema

$$A^T \lambda + z = c, \quad Ax = b, \quad XZe = te. \quad (12.54)$$

El problema dual (12.48) puede ser escrito como

$$\max \langle b, \lambda \rangle \quad \text{sujeto a} \quad (\lambda, z) \in \tilde{\Delta}, \quad (6.54)$$

donde

$$\tilde{\Delta} = \{(\lambda, z) \in \mathbb{R}^l \times \mathbb{R}_+^n \mid A^T \lambda + z = c\}. \quad (12.55)$$

Para $t > 0$ fijo, consideremos el siguiente problema auxiliar:

$$\min \varphi(x, z; t), \quad (x, (\lambda, z)) \in D^0 \times \tilde{\Delta}^0, \quad (12.56)$$

donde D^0 está definido en (12.40) con $\Omega = \{x \in \mathbb{R}^n \mid Ax = b\}$,

$$\tilde{\Delta}^0 = \{(\lambda, z) \in \tilde{\Omega} \mid z > 0\}, \quad (12.57)$$

$$\tilde{\Omega} = \{(\lambda, z) \in \mathbb{R}^l \times \mathbb{R}^n \mid A^T \lambda + z = c\}, \quad (12.58)$$

$$\varphi(\cdot; t) : \{x \in \mathbb{R}^n \mid x > 0\} \times \{z \in \mathbb{R}^n \mid z > 0\} \rightarrow \mathbb{R},$$

$$\varphi(x, z; t) = \langle x, z \rangle - t \sum_{j=1}^n \log(z_j x_j). \quad (12.59)$$

La **trayectoria central primal-dual** está definida como la función

$$(x(\cdot), (\nu(\cdot), \zeta(\cdot))) : (\mathbb{R}_+ \setminus \{0\}) \rightarrow D^0 \times \tilde{\Delta}^0,$$

donde para todo $t > 0$ el valor de la función es la solución del problema (12.56).

Ejercicio 12.20. Sean $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$. Sean $\Omega = \{x \in \mathbb{R}^n \mid Ax = b\}$, D^0 el conjunto definido en (12.40) y $\tilde{\Delta}^0$ el conjunto definido por (12.57), (12.58). Mostrar que para todo número $t > 0$ dado, la solución del problema (12.56), con la función objetivo dada por (12.59), está caracterizada por el sistema de ecuaciones (12.53).

Una iteración del método de puntos interiores primal-dual consiste en lo siguiente. Para un parámetro $t_k > 0$ dado, en el punto actual $(x^k, \lambda^k, z^k) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$ tal que $x^k > 0$ y $(\lambda^k, z^k) \in \tilde{\Delta}^0$, definimos la dirección Newtoniana para

el sistema (12.53). Habiendo calculado esta dirección, hacemos una búsqueda lineal para la función de mérito

$$\tilde{\varphi} : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}, \quad \tilde{\varphi}(x, z) = \langle x, z \rangle + \|Ax - b\|, \quad (12.60)$$

disminuyendo el valor de ella, y al mismo tiempo garantizando que la aproximación siguiente $(x^{k+1}, \lambda^{k+1}, z^{k+1})$ satisfaga las desigualdades $x^{k+1} > 0$ y $z^{k+1} > 0$. Notemos que

$$0 < \langle x^k, z^k \rangle = \langle c, x^k \rangle - \langle b, \lambda^k \rangle + \langle b - Ax^k, \lambda^k \rangle.$$

En particular, si $x^k \in \Omega$ (y, por lo tanto, $x^k \in D^0$), se tiene que

$$\tilde{\varphi}(x^k, z^k) = \langle c, x^k \rangle - \langle b, \lambda^k \rangle.$$

En general, la convergencia de $\tilde{\varphi}(x^k, z^k)$ a cero significa que

$$\langle c, x^k \rangle - \langle b, \lambda^k \rangle \rightarrow 0, \quad \{Ax^k\} \rightarrow b \quad (k \rightarrow \infty).$$

Si esto ocurre, del Teorema 12.7 se sigue que todo punto de acumulación de la sucesión $\{(x^k, \lambda^k)\}$ es una solución primal-dual del problema (12.38). Notemos que, como veremos más adelante, la viabilidad primal de puntos de acumulación de la sucesión $\{x^k\}$ no es automática en métodos de este tipo (a diferencia de los métodos de puntos interiores primales). La inclusión del segundo término en la definición de la función de mérito $\tilde{\varphi}$ tiene por objetivo resolver esta dificultad, al menos en el límite.

Algoritmo 6.1.2. (El método de puntos interiores primal-dual)

Escoger un número $t_0 > 0$. Para el conjunto $\tilde{\Delta}^0$ definido por (12.57), (12.58), escoger $(x^0, \lambda^0, z^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$, $x^0 > 0$, $(\lambda^0, z^0) \in \tilde{\Delta}^0$. Tomar $k := 0$.

1. Calcular $(d_x^k, d_\lambda^k, d_z^k) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$, el paso Newtoniano para el sistema (12.53) a partir del punto (x^k, λ^k, z^k) , con $t = t_k$.

2. Tomar

$$(x^{k+1}, \lambda^{k+1}, z^{k+1}) = (x^k, \lambda^k, z^k) + \alpha_k (d_x^k, d_\lambda^k, d_z^k),$$

donde el parámetro de la longitud de paso $\alpha_k \in (0, 1]$ es calculado para satisfacer

$$x^{k+1} > 0, \quad z^{k+1} > 0, \quad \tilde{\varphi}(x^{k+1}, z^{k+1}) < \tilde{\varphi}(x^k, z^k).$$

3. Escoger $t_{k+1} \in (0, t_k)$.
4. Tomar $k := k + 1$ y retornar al Paso 1.

Como fue el caso de los métodos de puntos interiores primales, en la práctica tenemos que agregar al Algoritmo 6.1.2 alguna técnica de preconditionamiento. La descripción y el análisis completo de los métodos de puntos interiores primal-duales requieren muchos detalles técnicos que están fuera del alcance de este libro. Presentaremos apenas algunos pasos, para ayudar a la intuición del lector.

Ejercicio 12.21. Sean $x \in \mathbb{R}^n$, $x > 0$, $(\lambda, z) \in \tilde{\Delta}^0$, donde el conjunto $\tilde{\Delta}^0$ está dado por (12.57), (12.58), $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$. Mostrar que para un número $t > 0$ dado, la dirección Newtoniana $(d_x, d_\lambda, d_z) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$ para el sistema (12.53) a partir del punto (x, λ, z) , viene dada por las ecuaciones

$$\begin{aligned} d_\lambda &= (AZ^{-1}XA^T)^{-1}(AZ^{-1}(XZe - te) + b - Ax), \\ d_z &= -A^T d_\lambda, \\ d_x &= Z^{-1}(te - XZe) - Z^{-1}X d_z. \end{aligned} \quad (12.61)$$

Mostrar que el punto $x + d_x$ es viable en el problema primal (12.38), y que el punto $(\lambda + d_\lambda, z + d_z)$ es viable en el problema dual (6.54), (12.55).

Si en las condiciones del Ejercicio 12.21 el parámetro de la longitud de paso satisface $\alpha \in (0, 1)$, el punto $x + \alpha d_x$ ya puede ser inviable en el problema primal. Pero, como puede ser visto fácilmente, el punto $(\lambda + \alpha d_\lambda, z + \alpha d_z)$ permanece viable en el problema dual. A continuación, mostraremos que un control adecuado de los valores de t y α garantiza el decrecimiento de la función de mérito $\tilde{\varphi}$.

Proposición 12.5. Sean $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$. Sean $x \in \mathbb{R}^n$, $x > 0$, $(\lambda, z) \in \tilde{\Delta}^0$, donde el conjunto $\tilde{\Delta}^0$ está dado por (12.57), (12.58). Para $t > 0$ dado, sea $(d_x, d_\lambda, d_z) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$ la dirección Newtoniana para el sistema (12.53) a

partir del punto (x, λ, z) . Entonces para todo $\alpha \in (0, 1]$, se tiene que

$$A(x + \alpha d_x) - b = (1 - \alpha)(Ax - b), \quad (12.62)$$

$$\begin{aligned} \tilde{\varphi}(x + \alpha d_x, z + \alpha d_z) &= \tilde{\varphi}(x, z) + \alpha^2 \langle Ax - b, d_\lambda \rangle \\ &\quad - \alpha(\langle x, z \rangle - nt + \|Ax - b\|), \end{aligned} \quad (12.63)$$

donde la función $\tilde{\varphi}$ está dada por (12.60).

Prueba. La dirección Newtoniana para el sistema (12.53) a partir del punto (x, λ, z) viene dada por las ecuaciones

$$A^T d_\lambda + d_z = 0, \quad Ad_x = b - Ax, \quad Zd_x + Xd_z = te - XZe. \quad (12.64)$$

De la segunda ecuación obtenemos que

$$A(x + \alpha d_x) - b = Ax + \alpha(b - Ax) - b = (1 - \alpha)(Ax - b),$$

lo que prueba (12.62). Además de eso,

$$\langle x + \alpha d_x, z + \alpha d_z \rangle = \langle x, z \rangle + \alpha^2 \langle d_x, d_z \rangle + \alpha(\langle x, d_z \rangle + \langle z, d_x \rangle). \quad (12.65)$$

Multiplicando los lados izquierdo y derecho de la última igualdad en (12.64) por e , obtenemos que

$$\langle x, d_z \rangle + \langle z, d_x \rangle = \langle e, te - XZe \rangle = nt - \langle x, z \rangle.$$

Ahora, utilizando (12.61) y la segunda igualdad en (12.64), tenemos que

$$\langle d_x, d_z \rangle = -\langle d_x, A^T d_\lambda \rangle = \langle Ax - b, d_\lambda \rangle.$$

Las dos últimas relaciones permiten reescribir (12.65) como

$$\langle x + \alpha d_x, z + \alpha d_z \rangle = \langle x, z \rangle - \alpha(\langle x, z \rangle - nt) + \alpha^2 \langle Ax - b, d_\lambda \rangle.$$

De aquí, teniendo también en cuenta (12.60) y (12.62), concluimos que

$$\begin{aligned} \tilde{\varphi}(x + \alpha d_x, z + \alpha d_z) &= \langle x + \alpha d_x, z + \alpha d_z \rangle + \|A(x + \alpha d_x) - b\| \\ &= \langle x, z \rangle - \alpha(\langle x, z \rangle - nt) \\ &\quad + \alpha^2 \langle Ax - b, d_\lambda \rangle + (1 - \alpha)\|Ax - b\|, \end{aligned}$$

lo que verifica (12.63). ■

Como se sigue de (12.62), la medida de inviabilidad en el problema primal está decreciendo para cualquier valor de la longitud de paso $\alpha \in (0, 1]$, si el punto x no es viable en (12.38) (y si x es viable, el punto nuevo $x + \alpha d_x$ también es viable). Además de eso, como se sigue de (12.63), si $t < \langle x, z \rangle / n$, existe un número $\bar{\alpha} > 0$ tal que todo $\alpha \in (0, \bar{\alpha})$ resulta en un decrecimiento de la función $\tilde{\varphi}$.

Una construcción inteligente de las sucesiones $\{t_k\}$ y $\{\alpha_k\}$, además del preconditionamiento, permiten el desarrollo de métodos de puntos interiores primal-duales muy eficientes (véase [20]).

Finalmente, comentaremos que métodos de puntos interiores pueden ser extendidos también a algunas clases de problemas no lineales convexos (véase [10]).

Ejercicio 12.22. Considerar el problema

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid Ax = b, g(x) \leq 0\}, \quad (12.66)$$

donde las funciones $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son convexas y dos veces continuamente diferenciables en $\mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$. Sean $\text{rk } A = l$, $\text{rk } g'(x) = m \forall x \in D$. Supongamos que exista un punto $\tilde{x} \in D$ tal que $g(\tilde{x}) < 0$. Definimos la trayectoria central primal-dual como la función

$$(x(\cdot), \nu(\cdot), \zeta(\cdot)) : (\mathbb{R}_+ \setminus \{0\}) \rightarrow \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m,$$

donde para todo $t > 0$ el valor de la función es la solución del sistema

$$f'(x) + A^T \lambda + (g'(x))^T \mu = 0, \quad Ax = b, \quad (12.67)$$

$$g_i(x) < 0, \quad \mu_i > 0, \quad \mu_i g_i(x) = t, \quad i = 1, \dots, m, \quad (12.68)$$

con respecto a $(x, \lambda, \mu) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$. Probar que las afirmaciones siguientes son equivalentes:

- (a) El conjunto de soluciones del problema (12.66) es no vacío y acotado.
- (b) Para todo $t > 0$, el sistema (12.67), (12.68), posee una única solución (en particular, la trayectoria central primal-dual está bien definida).
- (c) El sistema (12.67), (12.68), tiene una única solución para algún valor de $t > 0$.
- (d) El sistema

$$f'(x) + A^T \lambda + (g'(x))^T \mu = 0, \quad g(x) < 0, \quad \mu > 0$$

tiene una solución.

- (e) El sistema

$$f'(x) + A^T \lambda + (g'(x))^T \mu = 0, \quad \mu > 0$$

tiene una solución.

12.2. Programación cuadrática

Nuestro interés en problemas de programación cuadrática se debe a la misma razón que en el caso de la programación lineal: ellos aparecen como subproblemas en varios métodos para problemas de optimización más generales. Un ejemplo importante es el método de programación cuadrática secuencial, considerado en la ???. Naturalmente, la eficiencia de los métodos de este tipo depende de la eficiencia de resolución de los subproblemas cuadráticos.

Como fue en el caso lineal, en el caso convexo de la programación cuadrática también existen algoritmos con convergencia finita. A continuación presentaremos un método de este tipo, llamado método de puntos especiales. Otros métodos pueden ser consultados en [8]. Problemas de programación cuadrática convexos también pueden ser resueltos por varios algoritmos con convergencia asintótica, bien eficientes. Un ejemplo es el de los métodos de puntos interiores (generalizaciones de aquellos de la apartado 12.1.3 para el caso cuadrático), véase [20].

Consideramos el problema de programación cuadrática

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid Ax \leq b\}, \quad (12.69)$$

donde

$$f : \mathbb{R}^n \rightarrow \mathbb{R}, \quad f(x) = \frac{1}{2} \langle Cx, x \rangle + \langle c, x \rangle,$$

$C \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. El formato de las restricciones no reduce la generalidad, ya que cualesquiera restricciones lineales pueden ser transformadas a esta forma. Notemos también que el método a ser presentado puede ser modificado para resolver un problema donde la matriz C es semidefinida positiva (en vez de definida positiva).

Suponiendo que $D \neq \emptyset$, el problema (12.69) tiene una única solución, ya que la función objetivo del problema es fuertemente convexa en el conjunto viable D que es convexo (véase el Corolario 6.3).

12.2.1. Puntos especiales

Sean A_i , $i = 1, \dots, m$, las filas de la matriz A . El método a ser presentado se basa en la noción siguiente.

Definición 12.3. Un punto $\hat{x} \in D$ se llama **punto especial** del problema (12.69), si existe un conjunto $I \subset \{1, \dots, m\}$ tal que $\hat{x}$ es una solución del problema

$$\min f(x) \quad \text{sujeto a} \quad x \in D_I = \{x \in \mathbb{R}^n \mid \langle A_i, x \rangle = b_i, \quad i \in I\} \quad (12.70)$$

(los casos de $I = \emptyset$ e $I = \{1, \dots, m\}$ no están excluidos).

La solución de un problema de programación cuadrática fuertemente convexo es un punto especial.

Teorema 12.14. Para cualquier matriz $C \in \mathbb{R}^{n \times n}$ simétrica definida positiva, y cualesquiera $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$, el número de puntos especiales en el problema (12.69) es finito. Más aún, la solución de este problema es un punto especial.

Prueba. Es claro que el número de problemas de la forma (12.70) es finito. Como la función objetivo es fuertemente convexa, cada problema no puede poseer más de una solución (para I tales que $D_I = \emptyset$, no hay solución). Por eso, el número de puntos especiales es finito.

Sea $\bar{x} \in \mathbb{R}^n$ la solución del problema (12.69). Como es fácil ver, $\bar{x}$ es una solución local del problema

$$\min f(x) \quad \text{sujeto a} \quad x \in \bar{D} = \{x \in \mathbb{R}^n \mid \langle A_i, x \rangle \leq b_i, i \in I(\bar{x})\},$$

donde $I(\bar{x}) = \{i = 1, \dots, m \mid \langle A_i, \bar{x} \rangle = b_i\}$ es el conjunto de índices de las restricciones activas en $\bar{x}$. Como este problema es convexo, $\bar{x}$ es una solución global de él. Luego, $\bar{x}$ es una solución del problema (12.70) con $I = I(\bar{x})$, ya que el conjunto viable de él es menor. ■

Este resultado muestra que una manera de resolver el problema (12.69) es calcular todos los puntos especiales y escoger aquel con menor valor de la función objetivo. Para encontrar todos los puntos especiales del problema (12.69), es suficiente resolver los problemas (12.70) para todos los conjuntos $I \subset \{1, \dots, m\}$ tales que $D_I \neq \emptyset$, y verificar la viabilidad de las soluciones obtenidas para el problema (12.69).

Con relación a la resolución de un problema de la forma (12.70) (con restricciones de igualdad), notemos que él puede ser reducido a la minimización irrestricta de una función cuadrática fuertemente convexa. Para eso, podemos utilizar la proyección al conjunto D_I , o la representación de puntos del conjunto D_I en la base del subespacio lineal $\{x \in \mathbb{R}^n \mid \langle A_i, x \rangle = 0, i \in I\}$, o la relajación Lagrangiana (véase [20]). El problema de minimización irrestricta de una función cuadrática fuertemente convexa puede ser resuelto en un número de pasos finito, por ejemplo utilizando el método de los gradientes conjugados (apartado 8.4) o métodos del Álgebra Lineal.

El cálculo de todos los puntos especiales es un procedimiento finito. Pero, como también fue en el caso del cálculo de todos los vértices del conjunto viable para encontrar una solución en problemas de programación lineal, él no tiene valor práctico. El número de soluciones de problemas (12.70) es 2^m , y esta estrategia requiere un número de cálculos muy grande ya para n y m modestos. Por eso, como en la construcción del método del simplex, es natural intentar evitar el cálculo indiscriminado de puntos especiales, sustituyéndolo por un proceso más ordenado.

Ejercicio 12.23. Encontrando todos los puntos especiales, resolver los problemas

$$\begin{aligned} \min x_1^2 + x_2^2 \quad \text{sujeto a} \quad x \in D, \\ D = \{x \in \mathbb{R}^2 \mid -x_1 - x_2 \leq -4, x_1 \leq 5, x_2 \leq 3\}; \\ \min (x_1 - 1)^2 + (x_2 + 1)^2 \quad \text{sujeto a} \quad x \in D, \\ D = \{x \in \mathbb{R}^2 \mid -x_1 + x_2 \leq 1, x_1 + x_2 \leq 1, x_2 \geq 0\}. \end{aligned}$$

12.2.2. El método de puntos especiales

El método de puntos especiales calcula puntos especiales del problema (12.69) de manera que el valor de la función objetivo f en cada punto quede menor que en el anterior. Por el Teorema 12.14, este proceso es finito y termina en la solución del problema (12.69).

Sean $x^0, x^1, \dots, x^k$ los puntos especiales ya encontrados. La tarea es verificar si el punto x^k es la solución o no y, en el segundo caso, encontrar otro punto especial x^{k+1} del problema (12.69) tal que

$$f(x^{k+1}) < f(x^k). \quad (12.71)$$

Esto se hace en dos pasos.

El papel del primer paso es encontrar un punto (no necesariamente especial) $\tilde{x}^k \in \mathbb{R}^n$ tal que

$$f(\tilde{x}^k) < f(x^k), \quad \tilde{x}^k \in D, \quad (12.72)$$

o determinar que tal punto no existe (lo que significa que x^k es la solución del problema (12.69)). Esto puede ser hecho de varias maneras. Por ejemplo, podemos hacer una iteración del método de direcciones viables (véase apartado 10.2) para el problema (12.69) a partir del punto x^k .

Teniendo en cuenta la linealidad de las restricciones en (12.69), en vez de (10.26), (10.27), consideremos el subproblema (de programación lineal) simplificado:

$$\min \langle f'(x^k), d \rangle = \langle Cx^k + c, d \rangle \quad \text{sujeto a} \quad d \in D_k, \quad (12.73)$$

$$D_k = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} \langle A_i, d \rangle \leq 0, \quad i \in I(x^k), \\ -1 \leq d_j \leq 1, \quad j = 1, \dots, n \end{array} \right\}. \quad (12.74)$$

Sean d^k una solución de este subproblema y $v_k = \langle f'(x^k), d^k \rangle$ el valor óptimo del mismo. Si $v_k = 0$, el método se detiene.

Ejercicio 12.24. Sean $C \in \mathbb{R}^{n \times n}$ una matriz simétrica semidefinida positiva, $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Mostrar que si en el punto $x^k \in D$, donde el conjunto D está definido en (12.69), el valor óptimo del problema (12.73), (12.74), es cero, entonces x^k es la solución del problema (12.69).

En el caso de $v_k < 0$, de acuerdo con los Lemas 8.1, 10.3 y el Ejercicio 4.1.7, se tiene que $d^k \in \mathcal{D}_f(x^k) \cap \mathcal{V}_D(x^k)$, i.e., tenemos una dirección viable de descenso. Por lo tanto, las condiciones (12.72) serán satisfechas para $\tilde{x}^k = x^k + \alpha d^k$ y todo $\alpha > 0$ suficientemente pequeño. El valor concreto $\alpha = \alpha_k$ puede ser escogido de varias maneras. Por ejemplo, haciendo una búsqueda lineal a partir del valor inicial $\hat{\alpha} > 0$, hasta que (12.72) se satisfaga. Podemos también tomar α_k como solución del problema unidimensional

$$\min f(x^k + \alpha d^k) \quad \text{sujeto a} \quad \alpha \in [0, \hat{\alpha}_k], \quad (12.75)$$

donde

$$\begin{aligned} \hat{\alpha}_k &= \max\{\alpha \in \mathbb{R}_+ \mid x^k + \alpha d^k \in D\} \\ &= \min\left\{ \frac{b_i - \langle A_i, x^k \rangle}{\langle A_i, d^k \rangle} \mid \langle A_i, d^k \rangle > 0, \quad i = 1, \dots, m \right\} \end{aligned} \quad (12.76)$$

(la última igualdad es fácil de verificar; comparar con (12.76)). Así, de (12.79)-(12.81) y de la convexidad de la función f , tenemos que

$$f(\xi^{s+1}) \leq t_s f(\tilde{\xi}^s) + (1 - t_s) f(\xi^s) \leq f(\xi^s).$$

*(Nota de traducción: Para resolver (12.75), utilizando los hechos de que f es una función cuadrática y C es una matriz definida positiva, obtenemos la siguiente fórmula explícita para la solución del problema (12.75)):

$$\alpha_k = \min\left\{ -\frac{\langle Cx^k + c, d^k \rangle}{\langle Cd^k, d^k \rangle}, \hat{\alpha}_k \right\}.$$

En el segundo paso (si no paramos en el primero), calculamos un punto especial x^{k+1} del problema (12.69) que satisfaga la desigualdad

$$f(x^{k+1}) \leq f(\tilde{x}^k). \quad (12.77)$$

Para esto, generamos una sucesión auxiliar

$$\xi^0, \tilde{\xi}^0, \xi^1, \tilde{\xi}^1, \dots, \xi^s, \tilde{\xi}^s, \dots \quad (12.78)$$

de puntos en $\mathbb{R}^n$ de la manera especificada a continuación. Tomamos $\xi^0 = \tilde{x}^k$. Sea $\xi^s \in D$ un punto ya construido. Como ξ^s tomamos la solución del problema (12.70) con $I = I(\xi^s)$. Como el punto ξ^s es viable en este problema, se tiene que

$$f(\tilde{\xi}^s) \leq f(\xi^s). \quad (12.79)$$

Hay dos posibilidades. Si $\tilde{\xi}^s \in D$, entonces $\tilde{\xi}^s$ es un punto especial del problema (12.69), por la definición. En este caso, el proceso de construcción de la sucesión (12.78) se detiene: tomamos $x^{k+1} = \tilde{\xi}^s$. Si $\tilde{\xi}^s \notin D$, tomamos como ξ^{s+1} el punto del intervalo con extremos ξ^s y $\tilde{\xi}^s$ que está más próximo a $\tilde{\xi}^s$ entre todos los puntos del intervalo que son viables en el problema (12.69), i.e.,

$$\xi^{s+1} = \xi^s + t_s(\tilde{\xi}^s - \xi^s), \quad (12.80)$$

$$\begin{aligned} t_s &= \max\{t \in [0, 1] \mid \xi^s + t(\tilde{\xi}^s - \xi^s) \in D\} \\ &= \min\left\{ \frac{b_i - \langle A_i, \xi^s \rangle}{\langle A_i, \tilde{\xi}^s - \xi^s \rangle} \mid \langle A_i, \tilde{\xi}^s - \xi^s \rangle > 0, \quad i = 1, \dots, m \right\} \end{aligned} \quad (12.81)$$

(la última igualdad es fácil de verificar; comparar con (12.76)). Así, de (12.79)-(12.81) y de la convexidad de la función f , tenemos que

$$f(\xi^{s+1}) \leq t_s f(\tilde{\xi}^s) + (1 - t_s) f(\xi^s) \leq f(\xi^s). \quad (12.82)$$

Obviamente, $I(\xi^{s+1}) \subset I(\xi^s)$. Sea $i = i_s$ un índice para el cual se realiza el mínimo en (12.81). Se tiene que $i_s \notin I(\xi^s)$ y

$$\langle A_{i_s}, \xi^{s+1} \rangle = \langle A_{i_s}, \xi^s \rangle + \frac{b_{i_s} - \langle A_{i_s}, \xi^s \rangle}{\langle A_{i_s}, \tilde{\xi}^s - \xi^s \rangle} \langle A_{i_s}, \tilde{\xi}^s - \xi^s \rangle = b_{i_s},$$

i.e., $i_s \in I(\xi^{s+1})$ y, en particular, el conjunto $I(\xi^{s+1})$ contiene al menos un elemento más del que $I(\xi^s)$. Pero todos estos conjuntos están contenidos en $\{1, \dots, m\}$. Por lo tanto, para algún s , acontecerá que $\tilde{\xi}^s \in D$, i.e., el proceso de construcción de la sucesión (12.78) es finito. Para el punto especial $x^{k+1} = \tilde{\xi}^s$ así generado, por (12.79) y (12.82), tenemos que

$$f(x^{k+1}) = f(\tilde{\xi}^s) \leq f(\xi^s) \leq f(\xi^{s-1}) \leq \dots \leq f(\xi^0) = f(\tilde{x}^k),$$

i.e., vale (12.77). De la desigualdad en (12.72) y (12.77), obtenemos (12.71). Esto concluye la descripción de una iteración del método.

Como fue en el caso del método del simplex, necesitamos especificar cómo calcular el primer punto especial x^0 . Para eso, podemos primero encontrar un punto $\tilde{x}^{-1} \in D$ viable cualquiera (por ejemplo, empleando el método de base artificial presentado en el apartado 12.1.2), y después utilizar el segundo paso del algoritmo anterior.

En algunos casos, es conveniente aplicar el método de puntos especiales al dual del problema a ser resuelto. Notemos que el dual del problema (12.69) viene dado por

$$\max -\frac{1}{2} \langle AC^{-1}A^T \mu, \mu \rangle - \langle AC^{-1}c + b, \mu \rangle - \frac{1}{2} \langle C^{-1}c, c \rangle, \quad \mu \in \mathbb{R}_+^m. \quad (12.83)$$

Si $\bar{\mu}$ es una solución del problema dual, la única solución del problema primal puede ser calculada por la fórmula explícita:

$$\bar{x} = -C^{-1}(c + A^T \bar{\mu}).$$

En particular, resolviendo el problema dual (12.83), fácilmente obtenemos la solución del problema primal (12.69). Notemos que las restricciones del problema (12.83) son muy simples y varias partes del método de puntos especiales se simplifican. En principio, la matriz $AC^{-1}A^T$ es semidefinida positiva, pero no es definida positiva cuando $\text{rk } A < m$. Sin embargo, como ya fue comentado, el método de puntos especiales puede ser extendido al caso en el que la función objetivo cuadrática es convexa, pero no fuertemente.

Ejercicio 12.25. Para el punto viable $\tilde{x} = (0, 3)$ del problema

$$\min (x_1 - 6)^2 + x_2^2 \quad \text{sueto a } x \in D,$$

$$D = \{x \in \mathbb{R}^2 \mid x_1 + x_2 \leq 4, 3x_1 + 2x_2 \leq 8, -4x_1 + x_2 \leq 4\},$$

aplicar el método de construcción de un punto especial, sin aumentar el valor de la función objetivo (i.e., el segundo paso de una iteración del método de puntos especiales).

Bibliografía

- [Izm20] Mikhail Izmailov Alexey y Solodov. *Otimização: Condições de Otimalidade, Elementos de Análise Convexa e de Dualidade (Volume 1)*. Rio de Janeiro, Brasil: IMPA, 2020 (vid. págs. 1-3, 71-76).
- [Roc09] Roger J.-B. Rockafellar R. Tyrrell y Wets. *Variational Analysis*. Vol. 317. Grundlehren der mathematical Sciences. Springer Science & Business Media, 2009 (vid. pág. 1).