




Universidad Nacional de Ingeniería

Facultad de Ciencias

Programación No Lineal – CM4E2

2026-I

Apuntes de Optimalidad y Algoritmos de Optimización

Análisis Convexo, Dualidad y Optimización

Campos Mendoza, D. Daniel

danicampsmen@gmail.pe

Profesor: La Vida

Jefe de Prácticas: El Gato

Referencias Principales

- Mikhail Izmailov Alexey y Solodov. *Otimização: Condições de Otimidade, Elementos de Análise Convexa e de Dualidade (Volume 1)*. Rio de Janeiro, Brasil: IMPA, 2020
- Roger J.-B. Rockafellar R. Tyrrell y Wets. *Variational Analysis*. Vol. 317. Grundlehren der mathematical Sciences. Springer Science & Business Media, 2009
- [bazaraa2013nonlinearprogrammingtheory](#)

Lima, Perú

Última Edición

Fecha: 2026-07-12

Hora: 11:25:24

Versión 2.0 (Refactorizada)

Índice general

I. Condiciones de Optimalidad	1
1. Introducción a la optimización	2
1.1. Definiciones y algunos hechos básicos	2
1.2. Existencia de soluciones globales	4
1.3. Condiciones de optimalidad para problemas sin restricciones	6
1.4. Condiciones de optimalidad en forma primal para problemas con restricciones. El cono tangente	8
Ejercicios del Capítulo	10
Parte I: Conceptos Básicos y Existencia de Soluciones	10
Parte II: Condiciones de Optimalidad Irrestricida	11
Parte III: Cono Tangente y Condiciones Primitives	11
2. Restricciones de igualdad	13
2.1. El problema de optimización y el subespacio tangente	13
2.2. Condiciones de Primer Orden y Estructura Afin	16
2.3. Condiciones diferenciales de segundo orden	18
Ejercicios del Capítulo	20
Parte I: Mecánica Primal-Dual y Fallas Topológicas	20
Parte II: Condiciones Diferenciales de Segundo Orden y Matriz KKT	21
Parte III: Aplicaciones Físicas, Análisis de Sensibilidad y Variedades Matriciales	22
3. Análisis convexo	24
3.1. Definiciones de convexidad. El problema de minimización convexo	24
3.2. Conjuntos convexos y Teoremas de Separación	27
3.2.1. Propiedades básicas de conjuntos convexos	27
3.2.2. Cono de Recesión y Generadores Finitos	29
3.2.3. El operador de proyección	29
3.2.4. Teoremas de Separación	30
3.2.5. Puntos Extremos	30
3.3. Teoremas de alternativa	31
3.4. Funciones convexas	33
3.4.1. Propiedades básicas de las funciones convexas	33
3.4.2. Funciones convexas diferenciables	34
3.4.3. Funciones convexas no diferenciables	34
Ejercicios del Capítulo	35
Parte I: Mecánica Primal-Dual y Fallas Topológicas	35
Parte II: Condiciones Diferenciales de Segundo Orden y Matriz KKT	36
Parte III: Aplicaciones Físicas, Análisis de Sensibilidad y Variedades Matriciales	37
Parte IV: Teoremas de Alternativa y Análisis Convexo	38
4. capítulo 4	40
4.1. Cono tangente en el caso de restricciones de igualdad y desigualdad	40
4.2. Condiciones de optimalidad de Karush-Kuhn-Tucker	46
4.3. Condiciones de optimalidad de segundo orden	51
Ejercicios del Capítulo 4	57
Parte I: Mecánica Primal-Dual y Condición de Mangasarian-Fromovitz	57

Parte II: Condiciones de Segundo Orden	58
Parte III: Tópicos Avanzados - Dualidad, Conos Convexos y KKT Singular	58
4.4. Dualidad en programación lineal	59
4.5. Dualidad para un problema general	62
4.5.1. Formulación Minimax del Problema Primal	62
4.5.2. El Problema Dual General	63
4.5.3. Teorema de Dualidad Débil	63
4.5.4. Patologías y Casos Límite en la Teoría de Dualidad	64
4.5.5. Teoría de Multiplicadores de Lagrange Globales	65
4.5.6. Dualidad Fuerte y la Condición de Slater	66
4.5.7. El Problema Dual de Wolfe	67
4.5.8. Caracterización mediante Puntos de Silla	67
4.5.9. Subgradiente de la Función Dual	68
Ejercicios del Capítulo 5	68
Parte I: Dualidad en Programación Lineal	68
Parte II: Dualidad en Problemas Generales y Puntos de Silla	69

II. Métodos Computacionales 72

5. Resumen Teórico y Preliminares Matemáticos 73

5.1. Existencia de soluciones	73
5.2. Condiciones de optimalidad	74
5.3. Convexidad	75
5.4. Dualidad	75
5.5. Herramientas del Análisis y del Álgebra Lineal	76
5.6. Elementos del Análisis no Diferenciable	77
Ejercicios de Preliminares Teóricos	78

6. Introducción a los Métodos de Optimización 79

6.1. Clasificación de los métodos y nociones de convergencia	79
6.1.1. Estrategia de muestreo: Métodos pasivos vs. secuenciales	79
6.1.2. Estructura del esquema iterativo: Métodos sin memoria vs. con memoria	79
6.1.3. Orden del método	80
6.1.4. Tipos de convergencia	80
6.2. Tasas de convergencia y reglas de parada	81
6.3. Métodos de optimización unidimensional	83
6.3.1. Búsqueda en rejilla (Grid Search)	83
6.3.2. Métodos de exclusión de intervalos	84
6.3.3. Búsquedas en Dominios Semi-infinitos e Intervalos No Unimodales	86
6.3.4. Interpolación polinómica cuadrática y salvaguardas	87
Ejercicios del Capítulo	88

7. Optimización No Restringida 90

7.1. Métodos de descenso	90
7.1.1. Esquema general de los métodos de descenso. Búsqueda lineal.	90
7.2. El método del gradiente	93
7.3. El método de Newton. Métodos cuasi-Newton.	96
7.3.1. El método de Newton para ecuaciones	96
7.3.2. Método de Newton para optimización irrestricta	97
7.3.3. Métodos cuasi-Newton	98
7.4. Estrategias de globalización	101
7.4.1. Métodos con búsqueda lineal	101
7.4.2. Métodos de regiones de confianza	103

7.4.3. Métodos de continuación paramétricos	107
7.5. Métodos de direcciones conjugadas	111
7.5.1. Métodos de direcciones conjugadas para funciones cuadráticas	111
7.5.2. El método de los gradientes conjugados	114
7.6. Métodos que no utilizan derivadas	116
Ejercicios del Capítulo	117
Sección I: Métodos de Descenso y Gradiente	117
Sección II: Método de Newton y Cuasi-Newton	119
Sección III: Estrategias de Globalización	120
Sección IV: Direcciones Conjugadas	121
Sección V: Métodos sin Derivadas	121
8. Métodos para Optimización con Restricción	123
8.1. Métodos para conjuntos factibles de estructura simple	123
8.1.1. Métodos del gradiente proyectado	123
8.1.2. Direcciones factibles y métodos de descenso	126
8.1.3. Método del gradiente restringido. Método de Newton restringido	127
8.2. Métodos de penalización	128
8.2.1. Penalización externa	129
8.2.2. Penalización externa exacta	136
8.2.3. Penalización interna. Métodos de barreras	141
8.3. Métodos para problemas con restricciones de igualdad	144
8.3.1. Métodos de Newton para el sistema de Lagrange	145
8.3.2. El método de penalización cuadrática	147
8.3.3. Lagrangianas aumentadas y funciones de penalización exacta diferenciables	150
8.4. Métodos para problemas con restricciones mixtas	154
8.4.1. Métodos de Newton generalizados	155
8.4.2. Métodos de Newton generalizados para el sistema de Karush-Kuhn-Tucker	156
8.4.3. Métodos de penalización cuadrática	163
8.4.4. Lagrangianas aumentadas	168
8.4.5. Penalización exacta diferenciable	171
8.5. Programación cuadrática secuencial	172
8.5.1. Restricciones de igualdad	172
8.5.2. Restricciones mixtas	173
8.5.3. Globalización de convergencia de SQP	180
8.5.4. Restauración de la convergencia local superlineal	186
8.5.5. Otras técnicas de globalización	191
9. Métodos para optimización no diferenciable	199
9.1. Métodos de subgradiente	201
9.2. El método de planos cortantes	204
9.3. Métodos de haces	207
10. Programación lineal y cuadrática	213
10.1. Programación lineal	213
10.1.1. Elementos de teoría de la programación lineal	213
10.1.2. El método del simplex	219
10.1.3. Métodos de puntos interiores	225
10.2. Programación cuadrática	235
10.2.1. Puntos especiales	235
10.2.2. El método de puntos especiales	236
Bibliografía	239

Parte I.

Condiciones de Optimalidad

1. Introducción a la optimización

Objetivo. Este capítulo establece los fundamentos teóricos de los problemas de optimización. Se presentan los resultados de existencia de soluciones y las condiciones de optimalidad (necesarias y suficientes) para problemas irrestrictos y con restricciones. El análisis de restricciones se desarrollará en su forma primal mediante el uso riguroso de conos y direcciones tangentes, evitando la introducción prematura de hipótesis restrictivas.

Notación. A lo largo de este texto, para una función escalar diferenciable $f : \mathbb{R}^n \rightarrow \mathbb{R}$, denotaremos su vector gradiente (entendido como vector columna) mediante el operador nabla $\nabla f(x)$. Análogamente, su matriz Hessiana de segundas derivadas se denotará por $\nabla^2 f(x)$.

1.1. Definiciones y algunos hechos básicos

Sean dados conjuntos $D \subset \mathbb{R}^n$ y $\Omega \subset \mathbb{R}^n$ tales que $D \subset \Omega$, y una función $f : \Omega \rightarrow \mathbb{R}$. El problema principal a ser considerado en este libro es el de hallar un minimizador de f en el conjunto D . Este problema se escribirá como:

$$\min f(x) \quad \text{sujeto a} \quad x \in D. \quad (1.1)$$

El conjunto D será llamado **conjunto factible** del problema, los puntos de D serán llamados **puntos factibles**, y f será llamada **función objetivo**.

Definición 1.1 (Minimizadores). Dado el problema (1.1), un punto $\bar{x} \in D$ se denomina:


1. **Minimizador global** de (1.1), si

$$f(\bar{x}) \leq f(x) \quad \forall x \in D;$$

2. **Minimizador local** de (1.1), si existe una vecindad U de $\bar{x}$ tal que

$$f(\bar{x}) \leq f(x) \quad \forall x \in D \cap U.$$

De forma equivalente, $\bar{x} \in D$ es minimizador local si existe $\varepsilon > 0$ tal que $f(\bar{x}) \leq f(x)$ para todo $x \in \{x \in D \mid \|x - \bar{x}\| \leq \varepsilon\}$.



Observación. Por la definición, es claro que todo minimizador global también es minimizador local, pero no reciprocamente. Si para todo $x \neq \bar{x}$ la desigualdad correspondiente es estricta, $\bar{x}$ será llamado **minimizador estricto** (global o local, respectivamente).

Definición 1.2 (Valor óptimo). El **valor óptimo** del problema (1.1) es el valor $\bar{v} \in [-\infty, +\infty)$ definido por

$$\bar{v} = \inf_{x \in D} f(x).$$

Observación. Una función puede admitir varios minimizadores globales, pero el valor óptimo (global) del problema, naturalmente, siempre es el mismo.

Cuando existen una vecindad U de $\bar{x} \in D$ y un número $\beta > 0$ tales que

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\| \quad \forall x \in D \cap U,$$

decimos que f satisface la **condición de crecimiento lineal** en el conjunto D en torno a $\bar{x}$. Decimos que f satisface la **condición de crecimiento cuadrático** cuando

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\|^2 \quad \forall x \in D \cap U.$$

Observamos que cualquiera de estas dos condiciones implica que $\bar{x}$ es un minimizador local estricto.

Proposición 1.1. Si la función f satisface la condición de crecimiento lineal o cuadrático en D en torno a $\bar{x}$, entonces $\bar{x}$ es un minimizador local estricto de f .


Prueba. Supongamos que se cumple la condición de crecimiento cuadrático (el análisis para el lineal es análogo). Existe una vecindad U de $\bar{x}$ y $\beta > 0$ tal que $f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\|^2$ para todo $x \in D \cap U$. Sea $x \in D \cap U$ tal que $x \neq \bar{x}$. Dado que la norma es definida positiva, $\|x - \bar{x}\| > 0$, lo que implica que $\beta \|x - \bar{x}\|^2 > 0$. Por lo tanto $f(x) - f(\bar{x}) > 0$, es decir, $f(\bar{x}) < f(x)$. Esto satisface la definición de minimizador local estricto. ■

También es fácil ver que cualquier problema de maximización

$$\max f(x) \quad \text{sujeto a } x \in D \tag{1.2}$$

puede ser transformado en un problema de minimización equivalente:

$$\min -f(x) \quad \text{sujeto a } x \in D.$$



Proposición 1.2 (Equivalencia entre maximización y minimización). Sea el problema de maximización (1.2). Un punto $\bar{x} \in D$ es maximizador de (1.2) si y solo si $\bar{x}$ es minimizador del problema equivalente $\min_{x \in D} -f(x)$. Además, se satisface que $\max_{x \in D} f(x) = -\min_{x \in D} (-f(x))$.

Prueba. Sea $\bar{x}$ un maximizador de f en D . Por definición, $f(\bar{x}) \geq f(x)$ para todo $x \in D$. Multiplicando por -1 , se invierte el orden: $-f(\bar{x}) \leq -f(x)$ para todo $x \in D$. Esto es exactamente la definición de $\bar{x}$ como minimizador de $-f$ en D . La igualdad de los valores óptimos es consecuencia de las propiedades del supremo y el ínfimo: $\sup_{x \in D} f(x) = -\inf_{x \in D} (-f(x))$. ■

En particular, las soluciones locales y globales de ambos problemas son las mismas, con signos opuestos para los valores óptimos. Por eso, desde el punto de vista matemático, no existe ninguna diferencia relevante entre los problemas de minimización y de maximización: todos los resultados obtenidos para una clase de problemas pueden ser extendidos a la otra clase sin dificultad. Por razones de tradición, en este libro consideramos sistemáticamente los problemas de minimización.

Típicamente, el conjunto factible de un problema está definido por un sistema de igualdades y/o desigualdades y/o una inclusión, como, por ejemplo,

$$D = \{x \in \Omega \mid h(x) = 0, g(x) \leq 0\}, \quad (1.3)$$

donde $\Omega \subset \mathbb{R}^n$, $h : \Omega \rightarrow \mathbb{R}^l$ y $g : \Omega \rightarrow \mathbb{R}^m$ (suponemos que la función objetivo f también está definida en el conjunto Ω). El conjunto Ω representa lo que se llama **restricciones directas** y las restricciones de igualdad y desigualdad se llaman **restricciones funcionales**. Cabe resaltar que la separación de las restricciones en directas y funcionales en la mayoría de los casos es solo una cuestión de simple conveniencia. Por ejemplo, la restricción directa $x \in \Omega = \mathbb{R}_+^n$ puede escribirse en el formato funcional $x \in \{x \in \mathbb{R}^n \mid x_i \geq 0, i = 1, \dots, n\}$.

En este libro, casi siempre supondremos que todas las restricciones de un problema dado son de un solo tipo: o directas o funcionales. En principio, las restricciones de igualdad siempre pueden escribirse en forma de desigualdades duplicando el número de restricciones:

$$h_i(x) = 0 \iff h_i(x) \leq 0 \quad \text{y} \quad -h_i(x) \leq 0.$$

Las restricciones de desigualdad también pueden transformarse en igualdades mediante la introducción de variables artificiales, llamadas “de holgura”:

$$g_i(x) \leq 0 \iff g_i(x) + z_i^2 = 0, \quad z_i \in \mathbb{R}.$$

Sin embargo, las transformaciones de este tipo son indeseables, tanto desde el punto de vista teórico como desde el punto de vista computacional. En primer lugar, en muchos casos estas transformaciones llevan a condiciones de optimalidad más débiles que las obtenidas en un análisis directo de las restricciones originales. En segundo lugar, el número de restricciones y/o variables aumenta, lo que hace el problema más difícil de resolver en la práctica. Por estas razones, en capítulos posteriores estudiaremos el formato general de restricciones mixtas (1.3) de forma directa.

Cuando $D = \mathbb{R}^n$, decimos que el problema (1.1) es **irrestringido**, y cuando $D \neq \mathbb{R}^n$ hablamos de **optimización con restricciones**.

Definición 1.3 (Tipos de problemas especiales).

1. Decimos que un conjunto es **poliedral** cuando puede ser representado como el conjunto de las soluciones de un sistema finito de ecuaciones e inecuaciones lineales: $D = \{x \in \mathbb{R}^n \mid Ax = a, Bx \leq b\}$.
2. Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ definida por $f(x) = \frac{1}{2} \langle Qx, x \rangle + \langle q, x \rangle + c$, donde Q es una matriz simétrica, se llama **función cuadrática**.
3. Si D es un conjunto poliedral y f es cuadrática, el problema se llama de **programación cuadrática**. Si f es lineal ($Q = 0$), es de **programación lineal**.
4. Cuando D es un conjunto convexo y f es una función convexa, decimos que el problema es de **programación convexa**.

1.2. Existencia de soluciones globales

Cuando en la Definición 1.2 tenemos $\bar{v} = -\infty$, el problema (1.1) no posee solución global (en este caso f es no acotada inferiormente en el conjunto factible). Pero incluso cuando $\bar{v}$ es finito, el minimizador global puede no existir. Este es el caso en que $\bar{v}$ no es alcanzado en ningún punto factible, es decir, cuando no existe $x \in D$ tal que $f(x) = \bar{v}$.

Por ejemplo, sean $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = e^x$, $D = \mathbb{R}$. Evidentemente, $\bar{v} = \inf_{x \in \mathbb{R}} e^x = 0$. Sin embargo, no existe $x \in \mathbb{R}$ tal que $e^x = 0$. Sean ahora $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = e^x$, $D = (0, 1]$. Se tiene que $\bar{v} = \inf_{x \in (0, 1]} e^x = 1$, pero de nuevo no existe $x \in (0, 1]$ tal que $e^x = 1$. Observamos que la función f es continua en D , pero en el primer ejemplo D no es acotado y en el segundo D no es cerrado.

A continuación estudiaremos algunos criterios que garantizan la existencia de solución global.

Teorema 1.1 (Weierstrass). Sean $D \subset \mathbb{R}^n$ un conjunto compacto no vacío y $f : D \rightarrow \mathbb{R}$ una función continua. Entonces los problemas de minimizar y de maximizar f en D tienen soluciones globales.

Prueba. Por lo observado en la sección anterior, es suficiente probar la existencia de un minimizador. Como la imagen de un conjunto compacto por una función continua es compacta, el conjunto $\{v \in \mathbb{R} \mid v = f(x) \text{ para algún } x \in D\}$ es

compacto. En particular, este conjunto es acotado inferiormente, es decir,

$$-\infty < \bar{v} = \inf_{x \in D} f(x).$$

Por la definición de ínfimo, para todo $k \in \mathbb{N}$ existe un $x^k \in D$ tal que

$$\bar{v} \leq f(x^k) \leq \bar{v} + \frac{1}{k}.$$

Pasando al límite cuando $k \rightarrow \infty$, concluimos que

$$\lim_{k \rightarrow \infty} f(x^k) = \bar{v}. \quad (1.4)$$

Como $\{x^k\} \subset D$ y D es compacto, se sigue que $\{x^k\}$ es una sucesión acotada. Luego, posee una subsucesión $\{x^{k_j}\}$ que converge a un punto de D :

$$\lim_{j \rightarrow \infty} x^{k_j} = \bar{x} \in D.$$

Por la continuidad de f , tenemos $\lim_{j \rightarrow \infty} f(x^{k_j}) = f(\bar{x})$. Usando (1.4), concluimos que $f(\bar{x}) = \bar{v}$, es decir, f asume el valor mínimo en D en el punto $\bar{x} \in D$. En otras palabras, $\bar{x}$ es un minimizador global. ■

La hipótesis de que el conjunto factible sea compacto solo puede ser eliminada en los resultados de existencia de solución al costo de fortalecer las hipótesis sobre la función objetivo. En este sentido, la noción de conjunto de nivel es fundamental.

Definición 1.4 (Conjunto de nivel). El **conjunto de nivel** de la función $f : D \rightarrow \mathbb{R}$ asociado a $c \in \mathbb{R}$ es el conjunto dado por

$$L_{f,D}(c) = \{x \in D \mid f(x) \leq c\}.$$

Corolario 1.1 (Existencia vía compacidad del conjunto de nivel). Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ continua en D . Supongamos que existe $c \in \mathbb{R}$ tal que el conjunto de nivel $L_{f,D}(c)$ sea no vacío y compacto. Entonces el problema de minimizar f en D posee una solución global.

Prueba. Por el Teorema de Weierstrass (Teorema 1.1), el problema $\min f(x)$ sujeto a $x \in L_{f,D}(c)$ tiene una solución global, digamos $\bar{x}$. Para todo $x \in D \setminus L_{f,D}(c)$, tenemos que $f(x) > c \geq f(\bar{x})$, lo que muestra que $\bar{x}$ es un minimizador global de f no solo en $L_{f,D}(c)$, sino también en D . ■

A continuación mostraremos un importante ejemplo de aplicación del Corolario 1.1.

Definición 1.5 (Proyección ortogonal). Dados un conjunto $D \subset \mathbb{R}^n$ y un punto $y \in \mathbb{R}^n$, una **proyección** (ortogonal) de y sobre D es una solución global del problema

$$\min \|x - y\| \quad \text{sujeto a } x \in D.$$

En otras palabras, la proyección de y sobre D es uno de los puntos de D que está más cerca de y .

Corolario 1.2 (Existencia de la proyección). Sea $D \subset \mathbb{R}^n$ un conjunto cerrado no vacío. Entonces la proyección de y sobre D existe para todo punto $y \in \mathbb{R}^n$.

Prueba. Fijemos $y \in \mathbb{R}^n$ arbitrario. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}_+$, $f(x) = \|x - y\|$. Evidentemente, f es continua en $\mathbb{R}^n$ y

$$L_{f,D}(c) = D \cap B(y, c),$$

donde $B(y, c) = \{x \in \mathbb{R}^n \mid \|x - y\| \leq c\}$ es la bola cerrada de centro y y radio c . El conjunto de nivel $L_{f,D}(c)$ es la intersección del conjunto cerrado D con el conjunto compacto $B(y, c)$. Por lo tanto, $L_{f,D}(c)$ es compacto. Además, para $c > 0$ suficientemente grande, es obvio que la bola $B(y, c)$ contiene puntos de D . Luego, $L_{f,D}(c) \neq \emptyset$. La afirmación ahora sigue por el Corolario 1.1. ■

En el problema de minimización del Corolario 1.2, el conjunto factible del problema podría ser ilimitado, pero es cerrado. A continuación consideremos un ejemplo donde el conjunto factible no es ni limitado ni cerrado.

Ejemplo 1.1. Mostraremos que el problema (1.1), donde

$$D = \{x \in \mathbb{R}^2 \mid x_1 + x_2 > 0\}, \quad f : D \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + x_2 + \frac{1}{x_1 + x_2},$$

posee una solución global.

Observamos que D es ilimitado y abierto. Por lo tanto, el Teorema 1.1 no se aplica en este caso. Fijemos $c \in \mathbb{R}$ tal que $L(c) = L_{f,D}(c) \neq \emptyset$ (por ejemplo, tomando $c = f(x)$ para un $x \in D$ cualquiera). Verificaremos que $L(c)$ es compacto (es decir, acotado y cerrado), y aplicaremos el Corolario 1.1.

Supongamos primero que $L(c)$ sea ilimitado, es decir, que exista $\{x^k\} \subset L(c)$ tal que $\|x^k\| \rightarrow \infty$ cuando $k \rightarrow \infty$. Tenemos que $x_1^k + x_2^k > 0$ (porque $x^k \in D$) y $f(x^k) \leq c$ para todo k . Si $|x_1^k| \rightarrow \infty$ cuando $k \rightarrow \infty$, entonces $c \geq f(x^k) > (x_1^k)^2 + x_2^k > (x_1^k)^2 - x_1^k \rightarrow +\infty$, lo que es imposible. Si $\{x_1^k\}$ es acotada, entonces $x_2^k \rightarrow +\infty$ cuando $k \rightarrow \infty$, y para todo k suficientemente grande, tenemos que $c \geq f(x^k) > x_2^k \rightarrow +\infty$, lo que también es imposible. Acabamos de mostrar que $L(c)$ es acotado.

Supongamos ahora que $L(c)$ no sea cerrado, es decir, que exista $\{x^k\} \subset L(c)$ tal que $\{x^k\} \rightarrow x$ cuando $k \rightarrow \infty$, con $x \in \mathbb{R}^2 \setminus L(c)$. La función f es continua en D . Por lo tanto, $f(x^k) \leq c$ implica que $f(x) \leq c$. Entonces, como $x \notin L(c)$, debe ser $x \in \text{cl } D \setminus D$, es decir, $x_1 + x_2 = 0$, pero en este caso $c \geq f(x^k) \rightarrow +\infty$ cuando $k \rightarrow \infty$, lo que es imposible. Acabamos de mostrar entonces que $L(c)$ también es cerrado. Luego $L(c)$ es compacto y la existencia de minimizador global sigue.

A continuación formalizaremos los fenómenos observados en el análisis del Ejemplo 1.1.

Definición 1.6 (Sucesión crítica y coercitividad). Decimos que una sucesión $\{x^k\} \subset \mathbb{R}^n$ es **crítica** en relación al conjunto D , si $\{x^k\} \subset D$ y o bien $\|x^k\| \rightarrow \infty$ o bien $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$ cuando $k \rightarrow \infty$.

Decimos que la función $f : D \rightarrow \mathbb{R}$ es **coercitiva** en el conjunto D , cuando para toda sucesión $\{x^k\}$ crítica en relación a D , se tiene

$$\limsup_{k \rightarrow \infty} f(x^k) = +\infty.$$

En el Ejemplo 1.1, f es coercitiva en el conjunto D . Observamos que cuando D es cerrado, coercitividad de f en D significa que si $x^k \in D$ y $\|x^k\| \rightarrow \infty$ entonces $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$. Cuando D es acotado, coercitividad significa que cuando $x^k \in D$ y $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$, se tiene $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$. Finalmente, cuando D es compacto, no hay sucesiones críticas, por lo que cualquier función $f : D \rightarrow \mathbb{R}$ es coercitiva en D trivialmente.

Corolario 1.3 (Existencia vía coercitividad). Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ una función continua y coercitiva en $D \neq \emptyset$. Entonces el problema de minimizar f en D posee una solución global.

El Teorema de Weierstrass puede ser generalizado ligeramente en relación a las propiedades de continuidad de la función objetivo.

Definición 1.7 (Semicontinuidad). Decimos que la función $f : D \rightarrow \mathbb{R}$ es **semicontinua inferiormente** en el punto $x \in D \subset \mathbb{R}^n$, cuando para cualquier sucesión $\{x^k\} \subset D$ tal que $\{x^k\} \rightarrow x$ cuando $k \rightarrow \infty$, se tiene

$$\liminf_{k \rightarrow \infty} f(x^k) \geq f(x). \quad (1.5)$$

Decimos que f es **semicontinua superiormente** cuando, en las mismas condiciones,

$$\limsup_{k \rightarrow \infty} f(x^k) \leq f(x).$$

Ejemplo 1.2. Sean $D = [1/2, 2] \subset \mathbb{R}$ y $f : D \rightarrow \mathbb{R}$ dada por

$$f(x) = \begin{cases} 1/x, & x \in [1/2, 1), \\ 2, & x \in [1, 2], \end{cases}$$

El conjunto D es compacto. La función f no es semicontinua inferiormente en D , pues no lo es en el punto $x = 1$. Se tiene que $\bar{v} = 1$, pero no existe $x \in D$ tal que $f(x) = 1$. Sin embargo, es fácil ver que f es semicontinua superiormente y que posee maximizadores globales en D .

1.3. Condiciones de optimalidad para problemas sin restricciones

Consideremos el problema de minimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (1.6)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$. A continuación estudiaremos las condiciones que deben ser satisfechas cuando un $\bar{x} \in \mathbb{R}^n$ dado es minimizador (local) del problema (1.6). Condiciones de este tipo se llaman **condiciones necesarias de**

optimalidad. También estudiaremos las condiciones que garantizan que un punto dado es minimizador local del problema (**condiciones suficientes de optimalidad**). Cabe notar que todos los resultados presentados a continuación son también verdaderos para un problema con restricciones $\min_{x \in D} f(x)$ siempre que el punto de interés $\bar{x}$ esté en el interior del conjunto factible D .

Teorema 1.2 (Condición necesaria de primer orden - Fermat). Supongamos que la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un minimizador local irrestricto de f , entonces

$$\nabla f(\bar{x}) = 0. \quad (1.7)$$

Prueba. Sea $d \in \mathbb{R}^n$ arbitrario. Por la definición de minimizador local, existe $\varepsilon > 0$ tal que

$$f(\bar{x}) \leq f(\bar{x} + td) \quad \forall t \in [0, \varepsilon].$$

Por la diferenciabilidad de f en $\bar{x}$,

$$f(\bar{x} + td) = f(\bar{x}) + t\langle \nabla f(\bar{x}), d \rangle + o(t).$$

Luego, $0 \leq t\langle \nabla f(\bar{x}), d \rangle + o(t)$. Dividiendo por $t > 0$ y tomando el límite cuando $t \rightarrow 0^+$, obtenemos

$$0 \leq \langle \nabla f(\bar{x}), d \rangle.$$

Como $d \in \mathbb{R}^n$ es arbitrario, podemos elegir $d = -\nabla f(\bar{x})$, lo que resulta en la condición $0 \leq \langle \nabla f(\bar{x}), -\nabla f(\bar{x}) \rangle = -\|\nabla f(\bar{x})\|^2$. De donde sigue que $\nabla f(\bar{x}) = 0$. ■

Definición 1.8 (Punto estacionario). Decimos que un punto $\bar{x} \in \mathbb{R}^n$ es **estacionario** (o **crítico**) para el problema (1.6), si vale la condición (1.7).

Por lo tanto, si f es diferenciable, las soluciones locales del problema (1.6) deben ser puntos estacionarios. Claramente, lo mismo vale para los problemas de maximización. A continuación, presentamos las condiciones de segundo orden.

Teorema 1.3 (Condición necesaria de segunda orden). Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea dos veces diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un minimizador local irrestricto de f , entonces vale (1.7) y la matriz Hessiana de f en el punto $\bar{x}$ es **semidefinida positiva**, es decir,

$$\langle \nabla^2 f(\bar{x})d, d \rangle \geq 0 \quad \forall d \in \mathbb{R}^n. \quad (1.8)$$

Prueba. La condición (1.7) ya fue obtenida por el Teorema 1.2. Sea $d \in \mathbb{R}^n$ arbitrario. Si $\bar{x}$ es minimizador local del problema (1.6), entonces para todo $t > 0$ suficientemente pequeño

$$0 \leq f(\bar{x} + td) - f(\bar{x}) = \langle \nabla f(\bar{x}), td \rangle + \frac{1}{2} \langle \nabla^2 f(\bar{x})(td), td \rangle + o(t^2) = \frac{t^2}{2} \langle \nabla^2 f(\bar{x})d, d \rangle + o(t^2).$$

Dividiendo ambos lados por $t^2 > 0$ y pasando al límite cuando $t \rightarrow 0^+$, obtenemos (1.8). ■

Si en un punto estacionario $\bar{x}$ en vez de (1.8) vale una condición más fuerte (la matriz Hessiana es definida positiva), podemos afirmar que de hecho $\bar{x}$ es un minimizador local estricto con crecimiento cuadrático.

Teorema 1.4 (Condición suficiente de segunda orden). Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea dos veces diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un punto estacionario (es decir, si vale (1.7)) y si la matriz Hessiana de f en $\bar{x}$ es definida positiva, es decir,

$$\langle \nabla^2 f(\bar{x})d, d \rangle > 0 \quad \forall d \in \mathbb{R}^n \setminus \{0\}, \quad (1.9)$$

entonces f satisface en torno a $\bar{x}$ la condición de crecimiento cuadrático: existen una vecindad U de $\bar{x}$ y un número $\beta > 0$ tales que

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\|^2 \quad \forall x \in U. \quad (1.10)$$

En particular, $\bar{x}$ es minimizador local estricto del problema (1.6). Recíprocamente, si vale (1.10), entonces $\bar{x}$ satisface las condiciones (1.7) y (1.9).

Prueba. Supongamos que valgan las condiciones (1.7) y (1.9), pero no (1.10). Entonces existe $\{x^k\} \subset \mathbb{R}^n \setminus \{\bar{x}\}$ tal que $\{x^k\} \rightarrow \bar{x}$ cuando $k \rightarrow \infty$ y

$$f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|^2 \quad \forall k.$$

Como la sucesión $\{(x^k - \bar{x})/\|x^k - \bar{x}\|\}$ es acotada, posee puntos de acumulación. Escogiendo una subsucesión, podemos admitir que

$$\frac{x^k - \bar{x}}{\|x^k - \bar{x}\|} \rightarrow d \in \mathbb{R}^n \setminus \{0\} \quad (\|d\| = 1).$$

Obtenemos que

$$\frac{1}{k}\|x^k - \bar{x}\|^2 > f(x^k) - f(\bar{x}) = \frac{1}{2}\langle \nabla^2 f(\bar{x})(x^k - \bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|^2),$$

donde usamos (1.7). Dividiendo por $\|x^k - \bar{x}\|^2 > 0$ y tomando el límite cuando $k \rightarrow \infty$, obtenemos

$$0 \geq \frac{1}{2}\langle \nabla^2 f(\bar{x})d, d \rangle,$$

en contradicción con (1.9).

Supongamos ahora que valga la condición de crecimiento cuadrático (1.10). Como ella implica que $\bar{x}$ es un minimizador local, obtenemos (1.7) por el Teorema 1.2. Para cualquier $d \in \mathbb{R}^n$ y $t \in \mathbb{R}$ suficientemente pequeño, $\bar{x} + td \in U$. Utilizando (1.10) y (1.7), obtenemos que

$$\beta t^2 \|d\|^2 \leq f(\bar{x} + td) - f(\bar{x}) = \frac{t^2}{2}\langle \nabla^2 f(\bar{x})d, d \rangle + o(t^2).$$

Dividiendo por $t^2 > 0$ y tomando el límite cuando $t \rightarrow 0$, obtenemos $\beta \|d\|^2 \leq \frac{1}{2}\langle \nabla^2 f(\bar{x})d, d \rangle$, lo que significa que $\nabla^2 f(\bar{x})$ es definida positiva. ■

Cabe resaltar que las condiciones (1.7) y (1.8) no son suficientes para que un punto sea minimizador (ej: $f(x) = x^3$ en $x = 0$). Por otro lado, (1.7) y (1.9) no son necesarias para que un punto sea minimizador (ej: $f(x) = x^4$ en $x = 0$).

Ejemplo 1.3. Encontremos los minimizadores y maximizadores locales irrestrictos de la función $f(x) = x_1^3 + x_2^3 - 3x_1x_2$. Es fácil ver que f no es acotada ni inferior ni superiormente, por lo que no hay óptimos globales. Los puntos estacionarios son $x^1 = (0, 0)$ y $x^2 = (1, 1)$. Las matrices Hessianas son:

$$\nabla^2 f(x^1) = \begin{pmatrix} 0 & -3 \\ -3 & 0 \end{pmatrix}, \quad \nabla^2 f(x^2) = \begin{pmatrix} 6 & -3 \\ -3 & 6 \end{pmatrix}.$$

La matriz $\nabla^2 f(x^1)$ no es ni semidefinida positiva ni semidefinida negativa. Por el Teorema 1.3, x^1 no es ni minimizador ni maximizador. Como la matriz $\nabla^2 f(x^2)$ es definida positiva, por los Teoremas 1.2 y 1.4, x^2 es el único minimizador local estricto.

Ejemplo 1.4. Encontremos las soluciones globales del problema

$$\min f(x) = x_1 + \frac{x_2^2}{4x_1} + \frac{x_3^2}{x_2} + \frac{2}{x_3} \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^3 \mid x_i > 0\}.$$

El conjunto D es abierto, así que todo punto factible pertenece al interior. Resolviendo (1.7), encontramos que el único punto estacionario es $\bar{x} = (1/2, 1, 1)$. Se puede verificar que él es minimizador global comprobando que f es coercitiva en D (véase la Definición 1.6).

1.4. Condiciones de optimalidad en forma primal para problemas con restricciones. El cono tangente

Consideramos ahora un problema en formato general


$$\min f(x) \quad \text{sujeto a} \quad x \in D, \tag{1.11}$$

donde $D \subset \mathbb{R}^n$ es un conjunto dado (no vacío) y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es la función objetivo. Para desarrollar las condiciones de optimalidad necesitamos estudiar la estructura del conjunto factible mediante **direcciones viables** y **direcciones tangentes**.

Definición 1.9 (Dirección viable). Decimos que $d \in \mathbb{R}^n$ es una **dirección viable** en relación al conjunto D en el punto $\bar{x} \in D$, cuando existe $\varepsilon > 0$ tal que

$$\bar{x} + td \in D \quad \forall t \in [0, \varepsilon].$$

Denotamos por $\mathcal{V}_D(\bar{x})$ el conjunto de todas las direcciones viables en relación al conjunto D en el punto $\bar{x} \in D$.



Definición 1.10 (Cono). Un conjunto $K \subset \mathbb{R}^n$ se llama **cono** cuando

$$d \in K \implies td \in K \quad \forall t \in \mathbb{R}_+.$$

Es fácil ver que para $D \subset \mathbb{R}^n$ y $\bar{x} \in D$ cualesquiera, el conjunto $\mathcal{V}_D(\bar{x})$ siempre es un cono no vacío (al menos, $0 \in \mathcal{V}_D(\bar{x})$).

Definición 1.11 (Dirección de descenso). Decimos que $d \in \mathbb{R}^n$ es una **dirección de descenso** de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ en el punto $\bar{x} \in \mathbb{R}^n$, si existe $\varepsilon > 0$ tal que

$$f(\bar{x} + td) < f(\bar{x}) \quad \forall t \in (0, \varepsilon].$$

Denotamos por $\mathcal{D}_f(\bar{x})$ el conjunto de todas las direcciones de descenso de la función f en el punto $\bar{x}$.

El conjunto $\mathcal{D}_f(\bar{x})$ puede ser vacío, pero el conjunto $\mathcal{D}_f(\bar{x}) \cup \{0\}$ es siempre un cono.

Lema 1.1 (Direcciones de descenso). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Entonces:

1. Para todo $d \in \mathcal{D}_f(\bar{x})$, se tiene que $\langle \nabla f(\bar{x}), d \rangle \leq 0$.
2. Si $d \in \mathbb{R}^n$ satisface $\langle \nabla f(\bar{x}), d \rangle < 0$, entonces $d \in \mathcal{D}_f(\bar{x})$.

Prueba. Sea $d \in \mathcal{D}_f(\bar{x})$. Para todo $t > 0$ suficientemente pequeño, $0 > f(\bar{x} + td) - f(\bar{x}) = t(\langle \nabla f(\bar{x}), d \rangle + o(t)/t)$.

Pasando al límite cuando $t \rightarrow 0^+$, obtenemos $0 \geq \langle \nabla f(\bar{x}), d \rangle$, lo que prueba el ítem (a).

Si $\langle \nabla f(\bar{x}), d \rangle < 0$, tenemos que $f(\bar{x} + td) - f(\bar{x}) = t(\langle \nabla f(\bar{x}), d \rangle + o(t)/t) \leq \frac{t}{2} \langle \nabla f(\bar{x}), d \rangle < 0$ para todo $t > 0$ suficientemente pequeño, implicando que $d \in \mathcal{D}_f(\bar{x})$. ■

Si $\bar{x} \in D$ es un minimizador local de (1.11), obviamente $\mathcal{D}_f(\bar{x}) \cap \mathcal{V}_D(\bar{x}) = \emptyset$. Por el Lema 1.1, tenemos entonces que $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{V}_D(\bar{x})$. Sin embargo, esta condición no siempre proporciona información útil, porque $\mathcal{V}_D(\bar{x})$ puede contener solo al vector nulo. Necesitamos considerar las **direcciones tangentes**.

Definición 1.12 (Dirección tangente y cono tangente). Decimos que $d \in \mathbb{R}^n$ es una **dirección tangente** en relación al conjunto D en el punto $\bar{x} \in D$ cuando

$$\text{dist}(\bar{x} + td, D) = o(t), \quad t \in \mathbb{R}_+.$$

Denotamos por $\mathcal{T}_D(\bar{x})$ el conjunto de todas las direcciones tangentes, el cual forma un cono.

Claramente, $\mathcal{V}_D(\bar{x}) \subset \mathcal{T}_D(\bar{x})$. Otra noción útil es la del **cono de Bouligand**:

$$\mathcal{B}_D(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} \exists \{t_k\} \subset \mathbb{R}_+, \{t_k\} \rightarrow 0^+, \\ \text{dist}(\bar{x} + t_k d, D) = o(t_k) \end{array} \right\}. \quad (1.12)$$

De forma equivalente, $d \in \mathcal{B}_D(\bar{x})$ si existen sucesiones $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$ para todo k . En general, $\mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$.

Ejemplo 1.5. Sean $q \in (0, 1)$ y $D = \{0\} \cup \{q^0, q^1, q^2, \dots\} \subset \mathbb{R}$. En $\bar{x} = 0 \in D$, para todo $d > 0$, eligiendo $t_k = q^k/d$ y $d^k = d$, tenemos $\bar{x} + t_k d^k = q^k \in D$. Así que $d \in \mathcal{B}_D(\bar{x})$ y $\mathcal{B}_D(\bar{x}) = \mathbb{R}_+$. Sin embargo, se puede demostrar analíticamente que $\mathcal{T}_D(\bar{x}) = \{0\}$, probando que $\mathcal{T}_D(\bar{x}) \neq \mathcal{B}_D(\bar{x})$.

Teorema 1.5 (Condición necesaria en forma primal). Sean $D \subset \mathbb{R}^n$ y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en el punto $\bar{x} \in D$. Si $\bar{x}$ es una solución local del problema de minimizar f en D , entonces

$$\langle \nabla f(\bar{x}), d \rangle \geq 0 \quad \forall d \in \mathcal{B}_D(\bar{x}). \quad (1.13)$$

Prueba. Fijemos $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$ y las sucesiones asociadas $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$. Como $\bar{x}$ es un minimizador local, para todo k suficientemente grande:

$$0 \leq f(\bar{x} + t_k d^k) - f(\bar{x}) = t_k \langle \nabla f(\bar{x}), d^k \rangle + o(t_k).$$

Dividiendo por $t_k > 0$ y pasando al límite, obtenemos (1.13). ■

Decimos que $\bar{x} \in \mathbb{R}^n$ es un **punto estacionario** del problema (1.11) si $\bar{x} \in D$ y vale (1.13).

Corolario 1.4. Sea $\bar{x} \in \text{int } D$ una solución local del problema (1.11) tal que f es diferenciable en $\bar{x}$. Entonces $\nabla f(\bar{x}) = 0$.


La condición de optimalidad puede transformarse a la forma primal-dual usando el cono dual.

Definición 1.13 (Cono dual). El **cono dual** de un cono $K \subset \mathbb{R}^n$ se define por

$$K^* = \{y \in \mathbb{R}^n \mid \langle y, d \rangle \leq 0 \quad \forall d \in K\}.$$

Usando esta noción, la condición de optimalidad (1.13) es equivalente a

$$-\nabla f(\bar{x}) \in (\mathcal{B}_D(\bar{x}))^*. \quad (1.14)$$



Teorema 1.6 (Condición suficiente en forma primal). Sean $D \subset \mathbb{R}^n$ y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en $\bar{x} \in D$. Entonces

$$\langle \nabla f(\bar{x}), d \rangle > 0 \quad \forall d \in \mathcal{B}_D(\bar{x}) \setminus \{0\} \quad (1.15)$$

si, y solamente si, f satisface en D en torno a $\bar{x}$ la condición de crecimiento lineal:

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\| \quad \forall x \in D \cap U. \quad (1.16)$$

En particular, (1.16) implica que $\bar{x}$ es minimizador local estricto.

Prueba. Supongamos que (1.15) valga, pero no (1.16). Existe $\{x^k\} \subset D \setminus \{\bar{x}\}$ convergiendo a $\bar{x}$ tal que $f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|$. Definiendo $t_k = \|x^k - \bar{x}\|$ y $d^k = (x^k - \bar{x})/t_k$, podemos extraer una subsucesión convergente $d^k \rightarrow d$ ($\|d\| = 1$). Así $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. Evaluando el gradiente, obtenemos $0 \geq \langle \nabla f(\bar{x}), d \rangle$, en contradicción con (1.15).

El recíproco es directo evaluando (1.16) a lo largo de las trayectorias que definen el cono de Bouligand y tomando el límite para el gradiente. ■

Proposición 1.3 (Relaciones entre conos). Sean $D \subset \mathbb{R}^n$ y $\bar{x} \in D$. Los conos $\mathcal{T}_D(\bar{x})$ y $\mathcal{B}_D(\bar{x})$ son cerrados y se tiene que

$$\{0\} \subset \text{cl } \mathcal{V}_D(\bar{x}) \subset \mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x}).$$

Ejercicios del Capítulo

Parte I: Conceptos Básicos y Existencia de Soluciones

Ejercicio 1.1. Mediante un dibujo geométrico, formular una hipótesis sobre la solución global del problema (1.1), donde:

1. $f(x) = -x_1 + x_2$, $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 \leq 1, x_1 \geq x_2^2, x_1 + x_2 \geq 0\}$;
2. $f(x) = \max\{|x_1 - 2|, |x_2|\}$, $D = \{x \in \mathbb{R}^2 \mid 2|x_1| - |x_2| \leq 2\}$;
3. $f(x) = (x_1 - 1)^2 + x_2^2$, $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 = 2\sigma x_1 x_2\}$ y $\sigma \in \mathbb{R}$ es un parámetro.

Ejercicio 1.2. Mediante un dibujo geométrico, responder a la siguiente pregunta: para qué valores del parámetro $\sigma \in \mathbb{R}$ el problema (1.1) con $f(x) = x_1 + \sigma x_2$ y $D = \{x \in \mathbb{R}^2 \mid x_1^3 + x_2^3 = 3x_1 x_2\}$, tiene una solución global y para cuáles solo una solución local.

Ejercicio 1.3. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función continua. Probar que $\bar{x} \in \mathbb{R}^n$ es un minimizador global de f en $\mathbb{R}^n$ si, y solo si, todo x tal que $f(x) = f(\bar{x})$ es un minimizador local de f .

Ejercicio 1.4. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función cualquiera y $D \subset \mathbb{R}^n$ un conjunto cualquiera. Probar que para cualesquiera $\alpha \in \mathbb{R}_+$ y $c \in \mathbb{R}$, el conjunto de soluciones (locales y globales) del problema $\min \alpha f(x) + c$ sujeto a $x \in D$ es el mismo que el del problema original.

Ejercicio 1.5. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función cualquiera y $D_1, D_2 \subset \mathbb{R}^n$ conjuntos tales que $D_2 \subset D_1$.

1. Mostrar que $\inf_{x \in D_1} f(x) \leq \inf_{x \in D_2} f(x)$.
2. Probar que si $\bar{x}$ es un minimizador de f en D_1 tal que $\bar{x} \in D_2$, entonces $\bar{x}$ también es minimizador de f en D_2 .

Ejercicio 1.6. Probar el Corolario 1.3. (Ayuda: Usar el razonamiento analítico del Ejemplo 1.1).

Ejercicio 1.7. Sea D un conjunto compacto no vacío. Suponiendo que f sea semicontinua inferiormente en D (ver Definición 1.7), probar que existe un minimizador global para el problema (1.1). Suponiendo que f sea semicontinua superiormente en D , probar que existe un maximizador global.

Ejercicio 1.8. Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ una función semicontinua inferiormente y coercitiva en $D \neq \emptyset$. Probar que el problema (1.1) posee una solución global.

Ejercicio 1.9. Sea f una función cuadrática $f(x) = \langle Qx, x \rangle + \langle q, x \rangle + c$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica. Probar:

1. Si el problema de minimización irrestricta de f tiene un minimizador local, entonces la matriz Q es semidefinida positiva y todo minimizador local es global.
2. Si Q es definida positiva, entonces f es coercitiva en $\mathbb{R}^n$. Mostrar que el problema de minimización de f sobre cualquier conjunto D no vacío y cerrado tiene un minimizador global, pero que en general, esto no es verdadero cuando D no es cerrado.

Ejercicio 1.10. Supóngase que el problema de minimización irrestricta de una función continua en $\mathbb{R}^n$ tenga una solución global. Determinar si esto implica o no que f tiene un minimizador global en cualquier conjunto cerrado en $\mathbb{R}^n$.

Ejercicio 1.11. Supóngase que las funciones $f_1, f_2 : \mathbb{R}^n \rightarrow \mathbb{R}$ sean continuas y tengan minimizadores globales. Determinar si esto implica que la suma $f_1(\cdot) + f_2(\cdot)$ también tiene un minimizador global.

Ejercicio 1.12. Probar que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es semicontinua inferiormente en el conjunto cerrado D si, y solo si, sus conjuntos de nivel $L_{f,D}(c)$ son cerrados para todo $c \in \mathbb{R}$.

Parte II: Condiciones de Optimalidad Irrestricta

Ejercicio 1.13. Encontrar todos los valores del parámetro $\sigma \in \mathbb{R}$ para los cuales el problema de minimización irrestricta de la función $f(x) = \sigma x_1^2 + 4x_1x_2 + 4x_2^2 + x_1 + x_2$ tiene una solución.

Ejercicio 1.14. Mostrar que la función $f(x) = (x_2 - x_1^2)^2 + x_1^5$ tiene un único punto estacionario que no es un maximizador ni un minimizador en $\mathbb{R}^2$.

Ejercicio 1.15. Sean $n \geq 2$ y $f(x) = (1 + x_n)^3 \sum_{i=1}^{n-1} x_i^2 + x_n^2$. Mostrar que $\bar{x} = 0$ es el único punto estacionario de f en $\mathbb{R}^n$ y que es un minimizador local estricto, pero no es minimizador global en $\mathbb{R}^n$.

Ejercicio 1.16. Determinar si puede o no existir una función $f : \mathbb{R} \rightarrow \mathbb{R}$ que tiene un único punto estacionario y este punto es minimizador local, pero no minimizador global.

Ejercicio 1.17. Probar que, para cualquier $\sigma > 1$, el sistema de ecuaciones:

$$\sigma \cos x_1 \sin x_2 + x_1 e^{x_1^2 + x_2^2} = 0, \quad \sigma \sin x_1 \cos x_2 + x_2 e^{x_1^2 + x_2^2} = 0$$

posee una solución $x \in \mathbb{R}^2 \setminus \{0\}$.

Parte III: Cono Tangente y Condiciones Primitives

Ejercicio 1.18. Sean $K_1 \subset K_2$ dos conos en $\mathbb{R}^n$. Mostrar que su cono dual verifica $K_2^* \subset K_1^*$.

Ejercicio 1.19. Sean K_1 y K_2 conos no vacíos en $\mathbb{R}^n$. Mostrar las siguientes propiedades:

1. $K_1 \times K_2$ es un cono, y $(K_1 \times K_2)^* = K_1^* \times K_2^*$.
2. $K_1 \cup K_2$ es un cono, y $(K_1 \cup K_2)^* = K_1^* \cap K_2^*$.
3. $K_1 + K_2$ es un cono, y $(K_1 + K_2)^* = K_1^* \cap K_2^*$.

Ejercicio 1.20. Mostrar que el cono de Bouligand $\mathcal{B}_D(\bar{x})$ admite la siguiente definición equivalente:

$$\mathcal{B}_D(\bar{x}) = \{0\} \cup \left\{ d \in \mathbb{R}^n \left| \begin{array}{l} \exists \{x^k\} \subset D \text{ tal que } \{x^k\} \rightarrow \bar{x}, \\ \left\{ \frac{x^k - \bar{x}}{\|x^k - \bar{x}\|} \right\} \rightarrow \frac{d}{\|d\|} \end{array} \right. \right\}.$$

Ejercicio 1.21. Mostrar que en $\mathbb{R}^n$ la condición de optimalidad primal (1.13) es equivalente a:

$$\forall \varepsilon > 0, \quad \langle \nabla f(\bar{x}), d \rangle > -\varepsilon \|d\| \quad \forall d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}.$$

Ejercicio 1.22. Sean $C \subset \mathbb{R}^n, D \subset \mathbb{R}^n$ conjuntos cualesquiera. Probar que:

$$\mathcal{B}_{C \cup D}(\bar{x}) = \mathcal{B}_C(\bar{x}) \cup \mathcal{B}_D(\bar{x}), \quad \mathcal{B}_{C \cap D}(\bar{x}) \subset \mathcal{B}_C(\bar{x}) \cap \mathcal{B}_D(\bar{x}).$$

Ejercicio 1.23. Sean $\emptyset \neq D \subset \mathbb{R}^n, C = \mathbb{R}^n \setminus D$. Denotamos por $\text{fr } D$ la frontera de D . Mostrar que si $\bar{x} \in \text{fr } D$, entonces:

$$\mathcal{B}_C(\bar{x}) \cup \mathcal{B}_D(\bar{x}) = \mathbb{R}^n, \quad \mathcal{B}_{\text{fr } D}(\bar{x}) = \mathcal{B}_C(\bar{x}) \cap \mathcal{B}_D(\bar{x}).$$

Ejercicio 1.24. Sean $D \subset \mathbb{R}^n$ un conjunto no vacío y cerrado, y $x \notin D$. Sea $P_D(x)$ el conjunto de proyecciones ortogonales de x sobre D . Mostrar que:

$$x - \bar{x} \in (\mathcal{B}_D(\bar{x}))^* \quad \forall \bar{x} \in P_D(x).$$

2. Restricciones de igualdad

Este capítulo presenta las condiciones teóricas de optimalidad para problemas con restricciones de igualdad, definidos sobre variedades diferenciables. A partir del Teorema de Lyusternik, se establece la relación entre la topología del cono tangente y el núcleo de la matriz Jacobiana, para luego deducir las condiciones de primer y segundo orden mediante multiplicadores de Lagrange.

Notación. Dada una función vectorial diferenciable $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$, denotaremos por $J_h(x) \in \mathbb{R}^{l \times n}$ a su matriz Jacobiana evaluada en el punto x . Consecuentemente, las filas de esta matriz corresponden a los gradientes transpuestos $\nabla h_i(x)^\top$, para $i = 1, \dots, l$.

2.1. El problema de optimización y el subespacio tangente

Definición 2.1 (Problema con restricciones de igualdad). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones de clase $\mathcal{C}^1$ (y de clase $\mathcal{C}^2$ cuando el análisis lo requiera). Se define el **conjunto factible** D como la variedad algebraica descrita por el sistema de igualdades:

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0\}.$$

El **problema de optimización con restricciones de igualdad** consiste en hallar un elemento en D que minimice a la función objetivo f . Este problema se denota formalmente mediante la expresión:

$$\min f(x) \quad \text{sujeto a} \quad x \in D. \quad (2.1)$$

Proposición 2.1. Supóngase que $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es diferenciable en $\bar{x} \in D$. Entonces, el cono de Bouligand está contenido en el núcleo del Jacobiano:

$$\mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x}).$$

Prueba. El vector nulo pertenece a ambos conjuntos. Sea $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. Por definición secuencial, existen sucesiones $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$, tales que $\bar{x} + t_k d^k \in D$ para todo $k \in \mathbb{N}$. Consecuentemente, $h(\bar{x} + t_k d^k) = 0$. Aplicando el desarrollo de Taylor de primer orden a la función vectorial h :

$$0 = h(\bar{x} + t_k d^k) - h(\bar{x}) = t_k J_h(\bar{x}) d^k + o(t_k \|d^k\|).$$

Dividiendo por el escalar $t_k > 0$ y tomando el límite cuando $k \rightarrow \infty$, la convergencia $d^k \rightarrow d$ implica que $J_h(\bar{x})d = 0$. Por consiguiente, $d \in \ker J_h(\bar{x})$. ■

Nota: Interpretación Geométrica del Núcleo

El álgebra lineal indica que $d \in \ker J_h(\bar{x})$ equivale a $\langle \nabla h_i(\bar{x}), d \rangle = 0$ para cada restricción i . Geométricamente, esto significa que cualquier movimiento en la dirección de d debe ser ortogonal a los gradientes de las superficies que definen a D . De este modo, d es tangente a la superficie en primer orden.

Definición 2.2 (Condiciones de regularidad). Decimos que el punto $\bar{x} \in D$ es **regular** (o satisface una calificación de restricciones) si cumple una de las siguientes propiedades:

- Independencia Lineal de los Gradientes (LICQ):** El operador lineal $J_h(\bar{x})$ es sobreyectivo; esto es, $\text{rk } J_h(\bar{x}) = l$. Algebraicamente, esto equivale a afirmar que la transformación transpuesta es inyectiva: $\ker(J_h(\bar{x})^\top) = \{0\}$. (Nótese que esto exige la condición topológica $l \leq n$).
- Linealidad afín:** La función h es afín, i.e., $h(x) = Ax - a$, con $A \in \mathbb{R}^{l \times n}$ y $a \in \mathbb{R}^l$.

Para establecer la topología local de la variedad, se requiere un resultado analítico preparatorio basado en el Teorema de la Función Implícita clásico.

Lema 2.1 (Existencia de Función Implícita Acotada). Sean $F : \mathbb{R}^s \times \mathbb{R}^n \rightarrow \mathbb{R}^l$ diferenciable en una vecindad de $(\bar{p}, \bar{y})$ y $\nabla_y F$ continua en dicho punto. Supóngase que $F(\bar{p}, \bar{y}) = 0$ y que el rango de la matriz Jacobiana parcial es máximo: $\text{rk } J_y F(\bar{p}, \bar{y}) = l$.

Entonces, existen una vecindad U de $\bar{p}$ y una constante $M > 0$ tales que, para todo $p \in U$, existe un único $y(p) \in \mathbb{R}^n$ que satisface $F(p, y(p)) = 0$ y la acotación:

$$\|y(p) - \bar{y}\| \leq M \|F(p, \bar{y})\|.$$

Prueba. Como $J_y F(\bar{p}, \bar{y}) \in \mathbb{R}^{l \times n}$ tiene rango l , sus filas son linealmente independientes. Sea $A \in \mathbb{R}^{(n-l) \times n}$ una matriz cuyas filas completan una base de $\mathbb{R}^n$. Construimos el operador extendido $\Phi : \mathbb{R}^s \times \mathbb{R}^n \rightarrow \mathbb{R}^l \times \mathbb{R}^{n-l}$ mediante:

$$\Phi(p, y) = \begin{pmatrix} F(p, y) \\ A(y - \bar{y}) \end{pmatrix}.$$

Evaluable en el punto base, $\Phi(\bar{p}, \bar{y}) = 0$. El Jacobiano parcial respecto a y es la matriz cuadrada $J_y \Phi(\bar{p}, \bar{y}) = \begin{pmatrix} J_y F(\bar{p}, \bar{y}) \\ A \end{pmatrix} \in \mathbb{R}^{n \times n}$, la cual es no singular por construcción.

Por el Teorema de la Función Implícita, existe una función diferenciable $y : U \rightarrow \mathbb{R}^n$ definida en una vecindad de $\bar{p}$ tal que $y(\bar{p}) = \bar{y}$ y $\Phi(p, y(p)) = 0$. Esto último implica que $F(p, y(p)) = 0$ y $A(y(p) - \bar{y}) = 0$.

Aplicando el Teorema del Valor Medio sobre el operador inverso local $\Phi(p, \cdot)$ y utilizando la desigualdad triangular para el difeomorfismo continuo, se deduce la existencia de una constante M dependiente de $\|J_y \Phi^{-1}\|$ que satisface la acotación requerida. ■

Nota: Justificación Geométrica de la Corrección Ortogonal

Si un punto x no cumple las restricciones ($h(x) \neq 0$), se busca una corrección Δx tal que $h(x + \Delta x) = 0$. Geométricamente, la trayectoria más corta para retornar a la variedad es ortogonal a ella. Dado que el espacio ortogonal al plano tangente ($\ker J_h$) coincide con la imagen de la matriz transpuesta ($\mathfrak{S}(J_h)^T$), la corrección óptima tiene la forma $\Delta x = J_h(\bar{x})^T \xi$, donde $\xi \in \mathbb{R}^l$ es un vector de ponderación. Este concepto fundamenta el desarrollo del Teorema de Lyusternik.

Ejemplo 2.1. Para ilustrar el Lema de la Función Implícita Acotada, consideremos la intersección de una circunferencia de radio paramétrico p con la recta vertical $y_1 = 1$. Modelamos esto mediante el campo vectorial $F : \mathbb{R} \times \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dado por:

$$F(p, y) = \begin{pmatrix} y_1^2 + y_2^2 - p^2 \\ y_1 - 1 \end{pmatrix}.$$

Fijemos el parámetro nominal $\bar{p} = \sqrt{2}$ y el punto de solución nominal $\bar{y} = (1, 1)^T$. Se verifica de manera directa que $F(\sqrt{2}, (1, 1)) = 0$.

Evaluamos el Jacobiano parcial respecto a las variables espaciales y :

$$J_y F(p, y) = \begin{pmatrix} 2y_1 & 2y_2 \\ 1 & 0 \end{pmatrix} \implies J_y F(\bar{p}, \bar{y}) = \begin{pmatrix} 2 & 2 \\ 1 & 0 \end{pmatrix}.$$

El determinante de esta matriz es $-2 \neq 0$. Por lo tanto, $\text{rk } J_y F(\bar{p}, \bar{y}) = 2 = l$, por lo que las hipótesis del Lema 2.1 se cumplen.

Si se perturba el radio de la circunferencia ligeramente, pasando a un nuevo parámetro $p \approx \sqrt{2}$ y manteniendo el punto en $\bar{y} = (1, 1)$, el error algebraico inducido es:

$$F(p, \bar{y}) = \begin{pmatrix} 1^2 + 1^2 - p^2 \\ 1 - 1 \end{pmatrix} = \begin{pmatrix} 2 - p^2 \\ 0 \end{pmatrix}.$$

El lema asegura que existe una raíz exacta $y(p)$ para el sistema perturbado, y que la distancia desde el punto antiguo $\bar{y}$ a la nueva raíz $y(p)$ está acotada por este error: $\|y(p) - \bar{y}\| \leq M \|F(p, \bar{y})\| = M |2 - p^2|$. En este caso, la nueva raíz analítica es $y(p) = (1, \sqrt{p^2 - 1})^T$, y mediante el desarrollo de Taylor se verifica que la distancia $|\sqrt{p^2 - 1} - 1|$ decae a la misma velocidad que la perturbación $|p^2 - 2|$.

Teorema 2.1 (Lyusternik: Estimación de Viabilidad). Supóngase que $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es continuamente diferenciable en una vecindad de $\bar{x} \in D$ y que satisface la condición LICQ. Entonces, existen una vecindad U de $\bar{x}$ y una constante

$M > 0$ tales que:

$$\text{dist}(x, D) \leq M\|h(x)\| \quad \forall x \in U.$$

Prueba. Definimos el campo paramétrico $F : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}^l$ mediante la traslación $F(x, \xi) = h(x + \xi)$. Tratando a x como el parámetro y a ξ como la variable, evaluamos en el punto base $(\bar{x}, 0)$. Se tiene $F(\bar{x}, 0) = h(\bar{x}) = 0$. El Jacobiano respecto a la variable ξ es $J_\xi F(\bar{x}, 0) = J_h(\bar{x})$, el cual, por la hipótesis LICQ, tiene rango máximo l . Las hipótesis del Lema 2.1 se verifican.

Por consiguiente, existen una vecindad U de $\bar{x}$ y un número $M > 0$ tales que, para cada $x \in U$, existe una perturbación $\xi(x) \in \mathbb{R}^n$ que cumple $0 = F(x, \xi(x)) = h(x + \xi(x))$. Esto asegura que el punto trasladado $x + \xi(x) \in D$. Además, el Lema 2.1 establece la cota $\|\xi(x)\| \leq M\|F(x, 0)\| = M\|h(x)\|$. Por la definición métrica de distancia a un conjunto:

$$\text{dist}(x, D) \leq \|x + \xi(x) - x\| = \|\xi(x)\| \leq M\|h(x)\|.$$

■

Ejemplo 2.2 (Acotación de Lyusternik en la Esfera). Considérese la variedad esférica unitaria en $\mathbb{R}^2$, definida por $h(x) = x_1^2 + x_2^2 - 1 = 0 \implies D = \{x \in \mathbb{R}^2 \mid \|x\|^2 = 1\}$. Tomemos un punto nominal en el polo norte, $\bar{x} = (0, 1) \in D$. El Jacobiano evaluado en este punto es $J_h(\bar{x}) = (0, 2)$. Dado que $\text{rk } J_h(\bar{x}) = 1$, la condición LICQ se cumple en $\bar{x}$. El Teorema 2.1 asegura la existencia de una constante $M > 0$ y una vecindad U de $\bar{x}$ tal que $\text{dist}(x, D) \leq M|h(x)|$ para todo $x \in U$.

Analíticamente, para $x \in \mathbb{R}^2 \setminus \{0\}$, la distancia es $\text{dist}(x, D) = |\|x\| - 1|$. La violación algebraica es $|h(x)| = |\|x\|^2 - 1| = \text{dist}(x, D) \cdot (\|x\| + 1)$. Despejando, obtenemos $\text{dist}(x, D) = \frac{1}{\|x\| + 1}|h(x)|$. En una vecindad U alrededor de $\bar{x} = (0, 1)$, la norma satisface $\|x\| \approx 1$. Si restringimos U a la bola de radio $1/2$ centrada en $\bar{x}$, para todo $x \in U$ se cumple que $\|x\| \geq 1/2$, lo que implica $\frac{1}{\|x\| + 1} \leq \frac{2}{3}$. Así, se obtiene la constante de Lyusternik $M = 2/3$. En este caso, el error algebraico $|h(x)|$ acota la distancia geométrica al conjunto.

Atención: Colapso de la Geometría por falta de Regularidad

La condición LICQ es un requisito fundamental para asegurar la regularidad del punto. Consideremos la restricción escalar $h(x) = x^2 = 0$, con el conjunto $D = \{0\}$. En $\bar{x} = 0$, el gradiente se anula ($h'(0) = 0$), por lo que no se cumple LICQ. Para cualquier $x \notin D$, se tiene:

$$\frac{\text{dist}(x, D)}{\|h(x)\|} = \frac{|x|}{x^2} = \frac{1}{|x|} \rightarrow +\infty \quad \text{cuando } x \rightarrow 0.$$

No existe ninguna constante M finita que acote esta relación, por lo que la equivalencia entre la caracterización algebraica y la topológica deja de cumplirse.

Teorema 2.2 (Teorema del Subespacio Tangente). Sea $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ de clase $\mathcal{C}^1$ en $\bar{x} \in D$.

1. Si se satisface la condición LICQ en $\bar{x}$, entonces los conos topológicos y el subespacio algebraico coinciden:

$$\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \ker J_h(\bar{x}).$$

2. Si las restricciones son afines, se tiene adicionalmente que $\mathcal{V}_D(\bar{x}) = \ker J_h(\bar{x})$.

Prueba. Parte (1): Por la Proposición 2.1, $\mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x})$. Inversamente, sea $d \in \ker J_h(\bar{x})$. Por el Teorema de Lyusternik (Teorema 2.1), para $t > 0$ suficientemente pequeño se tiene $\text{dist}(\bar{x} + td, D) \leq M\|h(\bar{x} + td)\|$. Expandiendo h por Taylor y utilizando que $h(\bar{x}) = 0$ y $J_h(\bar{x})d = 0$:

$$h(\bar{x} + td) = h(\bar{x}) + tJ_h(\bar{x})d + o(t) = o(t).$$

Consecuentemente, $\text{dist}(\bar{x} + td, D) \leq M\|o(t)\| = o(t)$. Esto corresponde a la definición de dirección tangente, por lo que $d \in \mathcal{T}_D(\bar{x})$. De la cadena de inclusiones $\ker J_h(\bar{x}) \subset \mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x})$, se deduce la igualdad de los conjuntos.

Parte (2): Para $h(x) = Ax - a$, se tiene $J_h(\bar{x}) = A$. Si $d \in \ker A$, para cualquier escalar $t \in \mathbb{R}$: $h(\bar{x} + td) = A(\bar{x} + td) - a = (A\bar{x} - a) + tAd = h(\bar{x}) = 0$. Luego $\bar{x} + td \in D$ para todo t , lo que demuestra que $d \in \mathcal{V}_D(\bar{x})$. ■

Ejemplo 2.3 (Colapso Analítico del Cono Tangente en $\mathbb{R}^3$). Considérese la curva en $\mathbb{R}^3$ formada por la intersección de un cilindro parabólico y un plano, definida por el sistema algebraico $h(x) = (x_1^2 - x_2, x_1 + x_3 - 1)^\top = 0$. Elegimos el punto $\bar{x} = (1, 1, 0)^\top \in D$. El subespacio nulo del Jacobiano evaluado en $\bar{x}$ está generado por el vector director $d = (1, 2, -1)^\top$. Es decir: $\ker J_h(\bar{x}) = \text{span} \langle (1, 2, -1)^\top \rangle$.

Verificamos que este vector pertenece a $\mathcal{T}_D(\bar{x})$. Construimos una curva $x(t) \in D$ parametrizada que pase por $\bar{x}$. Tomando $x_1 = 1 + t$, el sistema exige $x_2(t) = 1 + 2t + t^2$ y $x_3(t) = -t$. La curva factible es $x(t) = (1 + t, 1 + 2t + t^2, -t)^\top$. Desarrollando: $x(t) = \bar{x} + td + r(t)$, donde el residuo es $r(t) = (0, t^2, 0)^\top$. La norma del residuo satisface $\|r(t)\| = o(t)$. Por definición, se tiene que $d \in \mathcal{T}_D(\bar{x})$.

Teorema 2.3 (Condición necesaria en forma primal). Sea $\bar{x} \in D$ un minimizador local del problema (2.1). Si $\bar{x}$ es regular (cumple LICQ o linealidad), entonces el gradiente de la función objetivo se anula a lo largo de todo el subespacio tangente:

$$\langle \nabla f(\bar{x}), d \rangle = 0 \quad \forall d \in \ker J_h(\bar{x}). \quad (2.2)$$

Prueba. De acuerdo con la caracterización general del Capítulo 1, si $\bar{x}$ es un mínimo local, se cumple que $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{B}_D(\bar{x})$. Por la regularidad y el Teorema 2.2, se tiene $\mathcal{B}_D(\bar{x}) = \ker J_h(\bar{x})$. Esta desigualdad se aplica sobre el subespacio nulo. Dado que $\ker J_h(\bar{x})$ es un subespacio vectorial, si $d \in \ker J_h(\bar{x})$, su opuesto simétrico $-d$ también pertenece a $\ker J_h(\bar{x})$. Evaluando la desigualdad en dicho vector: $\langle \nabla f(\bar{x}), -d \rangle \geq 0 \implies \langle \nabla f(\bar{x}), d \rangle \leq 0$. De ambas desigualdades se deduce la igualdad a cero. ■

Ejemplo 2.4 (Ortogonalidad Primal en el Cilindro). Considérese el problema de minimizar la distancia al origen de un punto restringido a yacer sobre un cilindro desplazado en $\mathbb{R}^3$: $\min \frac{1}{2}(x_1^2 + x_2^2 + x_3^2)$ sujeto a $h(x) = (x_1 - 2)^2 + x_2^2 - 1 = 0$. Geométricamente, el punto del cilindro más cercano al origen es $\bar{x} = (1, 0, 0)^\top$. El Jacobiano de la restricción evaluado en $\bar{x}$ es $\nabla h(\bar{x}) = (-2, 0, 0)^\top$, por lo que se cumple LICQ. El subespacio tangente en $\bar{x}$ es el plano vertical $x_1 = 1$ generado por $d = (0, d_2, d_3)^\top$. El gradiente de la función objetivo en $\bar{x}$ es $\nabla f(\bar{x}) = (1, 0, 0)^\top$. El producto interno $\langle \nabla f(\bar{x}), d \rangle = 0$. De este modo se verifica la condición necesaria: el gradiente es ortogonal al subespacio de direcciones tangentes.

Corolario 2.1 (Singularidad Topológica por Exceso de Restricciones). Supóngase que el punto $\bar{x} \in D$ satisface la condición LICQ y que la dimensión de las restricciones es mayor o igual que la dimensión del espacio primal ($l \geq n$). Entonces, $\bar{x}$ es un **punto aislado** del conjunto factible D , y es un minimizador local estricto para cualquier función continua f .

Prueba. Por el Teorema del Rango de Álgebra Lineal, $\dim(\ker J_h(\bar{x})) = n - \text{rk } J_h(\bar{x})$. Bajo LICQ, el rango es máximo: $\text{rk } J_h(\bar{x}) = \min(l, n) = n$. Sustituyendo, se tiene que $\dim(\ker J_h(\bar{x})) = 0$, lo que implica $\ker J_h(\bar{x}) = \{0\}$. Aplicando el Teorema del Subespacio Tangente (Teorema 2.2), los conos topológicos se reducen a $\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \{0\}$. Al no existir direcciones tangentes no nulas, no es posible definir una sucesión en $D \setminus \{\bar{x}\}$ que converja a $\bar{x}$. Por lo tanto, existe una vecindad U de $\bar{x}$ tal que $D \cap U = \{\bar{x}\}$. Al ser el único punto factible en dicha vecindad, la condición $f(\bar{x}) \leq f(x)$ se cumple trivialmente para todo $x \in D \cap U$. ■

2.2. Condiciones de Primer Orden y Estructura Afín

Lema 2.2 (Dualidad del Núcleo). Para cualquier matriz $A \in \mathbb{R}^{l \times n}$, el cono dual de su subespacio nulo coincide con la imagen de su matriz transpuesta:

$$(\ker A)^* = \mathfrak{S}(A)^\top.$$

Prueba. Sea $y \in \mathfrak{S}(A)^\top$, esto es, $y = A^\top \lambda$ para algún $\lambda \in \mathbb{R}^l$. Para todo $x \in \ker A$:

$$\langle y, x \rangle = \langle A^\top \lambda, x \rangle = \langle \lambda, Ax \rangle = \langle \lambda, 0 \rangle = 0 \leq 0.$$

Por lo tanto, $\mathfrak{S}(A)^\top \subset (\ker A)^*$. Supóngase, por reducción al absurdo, que exista $z \in (\ker A)^* \setminus \mathfrak{S}(A)^\top$. Por el Teorema de Proyección Ortogonal en espacios de Hilbert, $\mathbb{R}^n = \ker A \oplus \mathfrak{S}(A)^\top$. Existen vectores únicos $u \in \ker A$ y $w \in \mathfrak{S}(A)^\top$ tales que $z = u + w$. Como $z \notin \mathfrak{S}(A)^\top$, la proyección $u \neq 0$.

Dado que $z \in (\ker A)^*$, se tiene $\langle z, x \rangle \leq 0$ para todo $x \in \ker A$. Evaluando en $x = u$:

$$0 \geq \langle z, u \rangle = \langle u + w, u \rangle = \|u\|^2 + \langle w, u \rangle.$$

Como los subespacios son ortogonales, $\langle w, u \rangle = 0$, lo que implica que $0 \geq \|u\|^2$. Esto fuerza a $u = 0$, lo cual contradice la hipótesis. Luego, $(\ker A)^* \subset \mathfrak{S}(A)^\top$. ■

Ejemplo 2.5 (Cálculo Explícito de la Dualidad). Considérese la transformación lineal definida por la matriz fila ($l = 1, n = 3$): $A = (1 \quad -1 \quad 0)$. El subespacio nulo $\ker A$ es el plano generado por $(1, 1, 0)^\top$ y $(0, 0, 1)^\top$. La imagen de la matriz transpuesta $\mathfrak{S}(A)^\top$ es la recta paramétrica $\lambda(1, -1, 0)^\top$.

Construimos el cono dual del núcleo $(\ker A)^*$ a partir de la definición de cono dual. Sea $y \in (\ker A)^*$. Debe cumplirse que $\langle y, x \rangle \leq 0$ para todo $x \in \ker A$. Al ser $\ker A$ un subespacio, si $x \in \ker A$, entonces $-x \in \ker A$.

Evaluando la desigualdad: $\langle y, x \rangle \leq 0$ y $\langle y, -x \rangle \leq 0 \implies \langle y, x \rangle = 0$. Evaluando la condición de ortogonalidad sobre los vectores que generan el núcleo obtenemos $y_1 + y_2 = 0$ y $y_3 = 0$. Deducimos que todo elemento del cono dual debe tener la forma $y = y_1(1, -1, 0)^\top$. Este conjunto coincide con la parametrización de $\mathfrak{S}(A)^\top$. Este resultado ilustra el cono dual de un subespacio vectorial y explica por qué los multiplicadores de Lagrange asociados a restricciones de igualdad pertenecen a $\mathbb{R}^l$ sin restricciones de signo.

Definición 2.3 (Función Lagrangiana). Se define la aplicación **Lagrangiana** asociada al problema (2.1), $L : \mathbb{R}^n \times \mathbb{R}^l \rightarrow \mathbb{R}$, como:

$$L(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle.$$

El gradiente respecto al vector primal x se expresa matricialmente mediante:

$$\nabla_x L(x, \lambda) = \nabla f(x) + J_h(x)^\top \lambda.$$

Nota: Equilibrio de Fuerzas y Precio Sombra

La ecuación estacionaria $\nabla f(\bar{x}) + \sum \lambda_i \nabla h_i(\bar{x}) = 0$ admite una interpretación física directa. Si se interpreta $-\nabla f$ como una fuerza que actúa sobre una partícula, y cada gradiente ∇h_i como la fuerza normal ejercida por la superficie de la restricción, el multiplicador λ_i representa la magnitud de la fuerza de reacción necesaria para mantener el equilibrio estático de la partícula.

Proposición 2.2 (Estructura Algebraica de los Multiplicadores). Para un punto $\bar{x} \in \mathbb{R}^n$ fijo, definase el conjunto de multiplicadores de Lagrange asociados como:

$$\mathcal{M}(\bar{x}) = \{\lambda \in \mathbb{R}^l \mid \nabla_x L(\bar{x}, \lambda) = 0\}.$$

Si $\mathcal{M}(\bar{x}) \neq \emptyset$ y $\bar{\lambda} \in \mathcal{M}(\bar{x})$ es un elemento particular, entonces $\mathcal{M}(\bar{x})$ constituye una variedad afin parametrizada por:

$$\mathcal{M}(\bar{x}) = \bar{\lambda} + \ker(J_h(\bar{x})^\top).$$

Prueba. De acuerdo con la Definición 2.3, la condición de estacionariedad respecto al vector primal x equivale a resolver el sistema lineal $J_h(\bar{x})^\top \lambda = -\nabla f(\bar{x})$. Procederemos por doble inclusión:

($\subset$): Sea $\lambda \in \mathcal{M}(\bar{x})$ un multiplicador arbitrario. Entonces, $J_h(\bar{x})^\top \lambda = -\nabla f(\bar{x})$. Por hipótesis, disponemos de un elemento $\bar{\lambda} \in \mathcal{M}(\bar{x})$, el cual satisface $J_h(\bar{x})^\top \bar{\lambda} = -\nabla f(\bar{x})$. Restando ambas ecuaciones se obtiene $J_h(\bar{x})^\top (\lambda - \bar{\lambda}) = 0$. Esto significa que $(\lambda - \bar{\lambda}) \in \ker(J_h(\bar{x})^\top)$. Despejando se obtiene $\lambda = \bar{\lambda} + v$ para algún $v \in \ker(J_h(\bar{x})^\top)$, lo que demuestra que $\mathcal{M}(\bar{x}) \subset \bar{\lambda} + \ker(J_h(\bar{x})^\top)$.

($\supset$): Recíprocamente, sea $\lambda \in \bar{\lambda} + \ker(J_h(\bar{x})^\top)$. Esto implica la existencia de un vector $v \in \ker(J_h(\bar{x})^\top)$ tal que $\lambda = \bar{\lambda} + v$. Evaluando la transformación lineal: $J_h(\bar{x})^\top \lambda = J_h(\bar{x})^\top \bar{\lambda} + J_h(\bar{x})^\top v = -\nabla f(\bar{x}) + 0 = -\nabla f(\bar{x})$. Esto equivale a $\nabla_x L(\bar{x}, \lambda) = 0$. Por consiguiente, $\lambda \in \mathcal{M}(\bar{x})$, lo que demuestra que $\bar{\lambda} + \ker(J_h(\bar{x})^\top) \subset \mathcal{M}(\bar{x})$. ■

Ejemplo 2.6 (Multiplicadores en Ausencia de Regularidad). Considérese el problema de minimizar $f(x) = x_1^2 + x_2^2$ sujeto a un sistema de dos restricciones afines linealmente dependientes en $\mathbb{R}^2$: $h_1(x) = x_1 + x_2 - 1 = 0$ y $h_2(x) = 2x_1 + 2x_2 - 2 = 0$. El minimizador global es $\bar{x} = (1/2, 1/2)^\top$. El Jacobiano evaluado en $\bar{x}$ es una matriz cuyas dos filas son $(1, 1)$ y $(2, 2)$. El rango de la matriz es 1. Como $l = 2$, no se cumple la condición LICQ y la matriz transpuesta tiene un núcleo no trivial generado por $(-2, 1)^\top$. Determinamos el conjunto de multiplicadores $\mathcal{M}(\bar{x})$ resolviendo $J_h(\bar{x})^\top \lambda = -\nabla f(\bar{x})$, resultando $\lambda_1 + 2\lambda_2 = -1$. Un multiplicador particular es $\bar{\lambda} = (-1, 0)^\top \in \mathcal{M}(\bar{x})$. La Proposición 2.2 asegura que el conjunto de multiplicadores es la variedad afin:

$$\mathcal{M}(\bar{x}) = \left\{ \begin{pmatrix} -1 - 2t \\ t \end{pmatrix} \mid t \in \mathbb{R} \right\}.$$

La falta de regularidad conduce a la pérdida de la unicidad del multiplicador.

Teorema 2.4 (Condiciones de Optimalidad de Lagrange). Sea $\bar{x} \in D$ un minimizador local del problema de optimización. Si el punto $\bar{x}$ es regular (Definición 2.2), entonces $\mathcal{M}(\bar{x}) \neq \emptyset$. Adicionalmente, si la regularidad proviene de la condición LICQ, el multiplicador es único ($\mathcal{M}(\bar{x}) = \{\bar{\lambda}\}$).

Prueba. Por el Teorema 2.3, el opuesto del gradiente de la función objetivo pertenece al cono dual del núcleo: $-\nabla f(\bar{x}) \in (\ker J_h(\bar{x}))^*$. Invocando el Lema 2.2, obtenemos $-\nabla f(\bar{x}) \in \mathfrak{S}(J_h(\bar{x}))^\top$. Por definición, existe un vector $\bar{\lambda} \in \mathbb{R}^l$ tal que $J_h(\bar{x})^\top \bar{\lambda} = -\nabla f(\bar{x})$, lo cual equivale a $\nabla_x L(\bar{x}, \bar{\lambda}) = 0$. Bajo la hipótesis LICQ, la matriz transpuesta es inyectiva ($\ker(J_h(\bar{x})^\top) = \{0\}$). Aplicando la Proposición 2.2, el subespacio afin $\mathcal{M}(\bar{x})$ se reduce a un único vector. ■

Pregunta de Control

Pregunta: Si se resuelve el sistema de Lagrange y se halla un punto $\bar{x}$ con su respectivo multiplicador $\bar{\lambda}$, ¿es posible asegurar que se trata de un mínimo local?

Respuesta: No. El Teorema de Lagrange establece únicamente una condición necesaria de primer orden. El punto obtenido podría corresponder a un máximo local o a un punto de silla sobre la variedad factible. Para determinar la naturaleza del punto, es indispensable realizar un análisis de segundo orden.

Ejemplo 2.7. Considérese el problema geométrico de proyectar un vector $y \in \mathbb{R}^n$ sobre el hiperplano afín $H = \{x \in \mathbb{R}^n \mid \langle a, x \rangle = c\}$, con $a \neq 0$. Esto se formula como $\min \frac{1}{2} \|x - y\|^2$ sujeto a $\langle a, x \rangle - c = 0$. Al ser la restricción afín, se verifica la condición de regularidad (Definición 2.2). El sistema de Lagrange impone $\nabla_x L(\bar{x}, \bar{\lambda}) = (\bar{x} - y) + \bar{\lambda}a = 0 \implies \bar{x} = y - \bar{\lambda}a$. Utilizando la condición de factibilidad ($\langle a, \bar{x} \rangle = c$) y la linealidad del producto interno, obtenemos $\bar{\lambda} = (\langle y, a \rangle - c)/\|a\|^2$. Sustituyendo este escalar, obtenemos la proyección ortogonal clásica:

$$\bar{x} = y + \left(\frac{c - \langle y, a \rangle}{\|a\|^2} \right) a.$$

Ejemplo 2.8. Determinéense los minimizadores y maximizadores globales de la función $f(x) = \frac{x_1^3}{3} + x_2$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 = 1\}$. El gradiente de la restricción, $\nabla h(x) = 2(x_1, x_2)^\top$, no se anula en D , lo que verifica la condición LICQ. El sistema de Lagrange requiere $x_1^2 + 2\lambda x_1 = 0$ y $1 + 2\lambda x_2 = 0$. La primera ecuación se puede factorizar como $x_1(x_1 + 2\lambda) = 0$, lo que permite dividir el análisis en dos casos:

1. Si $x_1 = 0$, la condición de factibilidad implica $x_2 = \pm 1$. La segunda ecuación determina $\lambda = \mp 1/2$. Esto genera los puntos estacionarios $(0, 1)$ y $(0, -1)$.
2. Si $x_1 \neq 0$, entonces $x_1 = -2\lambda$. La segunda ecuación exige $x_2 = -1/(2\lambda)$. Sustituyendo en la ecuación de la esfera se obtiene $16\lambda^4 - 4\lambda^2 + 1 = 0$. El discriminante de esta ecuación bicuadrática es negativo, por lo que no existen raíces reales en este caso.

Evaluando la función objetivo en los puntos obtenidos, $f(0, 1) = 1$ y $f(0, -1) = -1$, identificamos el máximo y el mínimo global sobre el conjunto factible.

2.3. Condiciones diferenciales de segundo orden

Teorema 2.5 (Condición necesaria de segundo orden). Supóngase que f, h son de clase $\mathcal{C}^2$ en una vecindad de $\bar{x} \in D$, siendo $\bar{x}$ un minimizador local regular. Entonces, para todo $\lambda \in \mathcal{M}(\bar{x})$, el operador Hessiano de la Lagrangiana es semidefinido positivo al restringirse sobre el subespacio tangente:

$$\langle \nabla_{xx}^2 L(\bar{x}, \lambda) d, d \rangle \geq 0 \quad \forall d \in \ker J_h(\bar{x}). \quad (2.3)$$

Prueba. Sea $d \in \ker J_h(\bar{x})$. Por el Teorema del Subespacio Tangente (Teorema 2.2), $d \in \mathcal{T}_D(\bar{x})$. Por definición secuencial, para todo $t \in \mathbb{R}$ suficientemente pequeño, existe un punto $x(t) \in D$ parametrizado por $x(t) = \bar{x} + td + r(t)$, donde $\|r(t)\| = o(t)$. Como la trayectoria yace en la variedad factible, $h(x(t)) = 0$ y $h(\bar{x}) = 0$. Por consiguiente, para cualquier $\lambda \in \mathcal{M}(\bar{x})$, la variación de la función objetivo coincide con la variación de la Lagrangiana: $f(x(t)) - f(\bar{x}) = L(x(t), \lambda) - L(\bar{x}, \lambda)$.

Aplicando el desarrollo de Fréchet de segundo orden a la Lagrangiana en torno a $\bar{x}$ (y denotando $\Delta x = td + r(t)$):

$$L(x(t), \lambda) - L(\bar{x}, \lambda) = \langle \nabla_x L(\bar{x}, \lambda), \Delta x \rangle + \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda) \Delta x, \Delta x \rangle + o(\|\Delta x\|^2).$$

Como $\lambda \in \mathcal{M}(\bar{x})$, el término lineal se anula. Al expandir la forma cuadrática, y dado que $\|r(t)\| = o(t)$, los términos cruzados y dependientes de $r(t)$ se incorporan al término residual $o(t^2)$, obteniéndose $f(x(t)) - f(\bar{x}) = \frac{t^2}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda) d, d \rangle + o(t^2)$. Dado que $\bar{x}$ es un mínimo local, se requiere que $f(x(t)) - f(\bar{x}) \geq 0$. Sustituyendo esta condición, dividiendo por $t^2 > 0$ y tomando el límite cuando $t \rightarrow 0$, se concluye que $\langle \nabla_{xx}^2 L(\bar{x}, \lambda) d, d \rangle \geq 0$. ■

Nota: Propiedad cancelativa de la Lagrangiana

En la demostración anterior ocurre una simplificación relevante. Si se aplicara el desarrollo de Taylor directamente a la función objetivo $f(x(t))$ usando el vector tangente $\Delta x = td + r(t)$, el término lineal $\langle \nabla f(\bar{x}), r(t) \rangle$ introduciría un error de orden $o(t)/t^2$ que no se anula al dividir por t^2 . Al emplear la función Lagrangiana, la

condición de primer orden garantiza que $\nabla_x L(\bar{x}, \lambda) = 0$. Este hecho **anula el efecto del término residual** $r(t)$ en primer orden, permitiendo que el término de segundo orden ($\nabla_{xx}^2 L$) determine el comportamiento asintótico de la función.

Ejemplo 2.9 (La curvatura de la restricción domina). Considérese el problema de maximizar la altura sobre una parábola invertida, equivalente a $\min f(x) = -x_2$ sujeto a $h(x) = x_2 - x_1^2 = 0$. El único punto estacionario geométrico es el vértice de la parábola, $\bar{x} = (0, 0)^\top$. El gradiente de la restricción es $\nabla h(x) = (-2x_1, 1)^\top$. Evaluado en el origen resulta en $(0, 1)^\top \neq 0$, lo que cumple la condición LICQ. Planteamos el sistema de Lagrange de primer orden: $\nabla f(\bar{x}) + \lambda \nabla h(\bar{x}) = (0, -1)^\top + \lambda(0, 1)^\top = (0, 0)^\top$, lo que implica $\bar{\lambda} = 1$.

Evaluamos ahora la Condición Necesaria de Segundo Orden. Las matrices Hessianas de las funciones individuales son nulas o constantes. La matriz Hessiana global de la Lagrangiana evaluada en $(\bar{x}, \bar{\lambda})$ es $\nabla_{xx}^2 L(\bar{x}, \bar{\lambda}) = \begin{pmatrix} -2 & 0 \\ 0 & 0 \end{pmatrix}$. Esta matriz es semidefinida negativa. Calculamos el núcleo de la matriz Jacobiana, obteniendo $\ker J_h(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \in \mathbb{R}\}$. Para una dirección tangente genérica $d = (d_1, 0)^\top$, proyectamos la Hessiana de la Lagrangiana: $\langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda})d, d \rangle = -2d_1^2$. Para todo $d_1 \neq 0$, esta forma cuadrática proyectada resulta en un valor estrictamente negativo. Por lo tanto, la condición necesaria de segundo orden (2.3) **no se cumple**. Se concluye entonces que $\bar{x} = (0, 0)^\top$ no es un mínimo local.

Teorema 2.6 (Condición suficiente de segundo orden). Sea $\bar{x} \in D$, con f, h de clase $\mathcal{C}^2$. Si la estructura diferencial en el punto satisface la condición estrictamente definida positiva sobre el núcleo:

$$\forall d \in \ker J_h(\bar{x}) \setminus \{0\}, \quad \exists \lambda \in \mathcal{M}(\bar{x}) \quad \text{t.q.} \quad \langle \nabla_{xx}^2 L(\bar{x}, \lambda)d, d \rangle > 0, \quad (2.4)$$

entonces $\bar{x}$ es un minimizador local estricto, y satisface la condición de crecimiento cuadrático local sobre D . Recíprocamente, si se verifica una de las condiciones de regularidad y el crecimiento cuadrático local rige, entonces la condición (2.4) se cumple necesariamente.

Prueba. Para demostrar la suficiencia, supóngase por reducción al absurdo que la condición (2.4) se verifica, pero el crecimiento cuadrático no se cumple. En tal caso, existe una sucesión factible $\{x^k\} \subset D \setminus \{\bar{x}\}$ que converge a $\bar{x}$ y que satisface $f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|^2$ para todo $k \in \mathbb{N}$. Por compacidad, se extrae una subsucesión de direcciones normalizadas d^k convergente a un vector unitario $d \in \mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x})$.

Sea $\lambda \in \mathcal{M}(\bar{x})$ el multiplicador cuya existencia asegura la hipótesis (2.4) para esta dirección particular. Sustituyendo el desarrollo de Fréchet de la Lagrangiana: $\frac{1}{k} \|x^k - \bar{x}\|^2 > \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda)(x^k - \bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|^2)$. Dividiendo la desigualdad por $\|x^k - \bar{x}\|^2 > 0$ y tomando el límite cuando $k \rightarrow \infty$, se obtiene $0 \geq \langle \nabla_{xx}^2 L(\bar{x}, \lambda)d, d \rangle$, lo cual contradice la hipótesis de positividad estricta.

Para probar el recíproco, supóngase que el crecimiento cuadrático se cumple con una constante $\beta > 0$, se sostiene la condición de regularidad, pero la condición (2.4) no se verifica. Esto implica la existencia de una dirección $d \in \ker J_h(\bar{x}) \setminus \{0\}$ tal que para todo $\lambda \in \mathcal{M}(\bar{x})$, la forma cuadrática es ≤ 0 . Dado que $d \in \mathcal{T}_D(\bar{x})$, existe una trayectoria factible $x(t) = \bar{x} + td + r(t) \in D$. Evaluando la condición de crecimiento cuadrático: $\beta \|td + r(t)\|^2 \leq f(x(t)) - f(\bar{x}) = \frac{t^2}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda)d, d \rangle + o(t^2) \leq o(t^2)$. Dividiendo la ecuación por t^2 y tomando el límite cuando $t \rightarrow 0^+$, el residuo se anula obteniéndose $\beta \|d\|^2 \leq 0$. Como $\beta > 0$, esto implica que $d = 0$, lo cual contradice la elección de un vector $d \neq 0$. ■

Ejemplo 2.10 (La silla de montar restringida). Considérese la minimización de una función de silla clásica sujeta a una restricción lineal: $\min f(x) = x_1^2 - x_2^2$ sujeto a $h(x) = x_1 - x_2 = 0$. El origen $\bar{x} = (0, 0)^\top$ es el único punto de intersección y candidato a análisis. El sistema de Lagrange se cumple para el multiplicador $\bar{\lambda} = 0$. A nivel irrestricto, la matriz Hessiana de la función objetivo es indefinida (con autovalores 2 y -2). Dado que la restricción es afín, $\nabla_{xx}^2 L(\bar{x}, \bar{\lambda}) = \nabla^2 f(\bar{x})$.

Aplicamos el Teorema 2.6 analizando el subespacio tangente (núcleo del Jacobiano), que está generado por $d = (d_1, d_1)^\top$. Evaluando la forma cuadrática proyectada de la Lagrangiana, se obtiene $2d_1^2 - 2d_1^2 = 0$. La forma cuadrática proyectada resulta ser idénticamente cero, por lo que la condición de positividad estricta no se cumple y el análisis diferencial de segundo orden no es concluyente. No obstante, si se sustituye la restricción $x_1 = x_2$ directamente en la función objetivo, se observa que $f(x(t)) = 0$. La función es constante a lo largo del subespacio tangente y el punto es un mínimo global no estricto.

Ejemplo 2.11 (La Hessiana proyectada positiva). Considérese el problema: $\min f(x) = x_1^2 - x_2^2$ sujeto a $h(x) = x_2 = 0$. El punto estacionario en el origen es $\bar{x} = (0, 0)^\top$. El sistema de Lagrange evaluado en el origen resulta en

$\bar{\lambda} = 0$. La matriz Hessiana de la Lagrangiana es indefinida en el espacio total. Aplicamos el Teorema 2.6 calculando el subespacio tangente: $\ker J_h(\bar{x}) = \{(d_1, 0)^T \mid d_1 \in \mathbb{R}\}$. Para una dirección tangente no nula, evaluamos la forma cuadrática proyectada obteniendo $2d_1^2 > 0$. Este resultado ilustra la aplicación del teorema: aunque la matriz Hessiana global presenta un autovalor negativo en la dirección de x_2 , la restricción descarta este eje de descenso. En el subespacio tangente permitido, la curvatura es estrictamente positiva. En consecuencia, se concluye que $\bar{x} = (0, 0)^T$ es un mínimo local estricto.

Atención: Ventaja sobre criterios clásicos

La literatura clásica frecuentemente exige una condición suficiente basada en un multiplicador único. Dicha formulación exige utilizar un único multiplicador común para todas las direcciones. El Teorema 2.6 resulta más general, ya que al ser $\mathcal{M}(\bar{x})$ un conjunto afín, permite asociar diferentes multiplicadores a distintas direcciones tangentes para verificar la condición de positividad.

Contraejemplo 2.1 (Colapso del multiplicador uniforme). Sean $f(x) = -x_1^2 - x_2^2$ y $h(x) = (x_1 x_2, x_1^2 - x_2^2)^T = 0$. El origen $\bar{x} = 0$ es el único punto factible. Los gradientes se anulan en dicho punto, lo que da lugar a $\ker J_h(0) = \mathbb{R}^2$ y $\mathcal{M}(0) = \mathbb{R}^2$. El operador Hessiano de la Lagrangiana tiene traza -4 para cualquier valor de λ . Dado que la traza es negativa, esta matriz no puede ser definida positiva. En consecuencia, no existe un multiplicador único $\bar{\lambda}$ que garantice la positividad de la forma cuadrática para toda dirección d . Sin embargo, para cada dirección específica $d \neq 0$, es posible elegir un vector $\lambda(d)$ adecuado que asegure la positividad de la forma cuadrática.

Ejercicios del Capítulo

Parte I: Mecánica Primal-Dual y Fallas Topológicas

Ejercicio 2.1. Determinéense los minimizadores y maximizadores globales del funcional lineal $f(x) = \sum_{i=1}^n x_i$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^n \mid \|x\|^2 = 1\}$.

Ejercicio 2.2. Hállense los minimizadores de la función $f(x) = \|x\|^2$ sujetos a las siguientes restricciones:

- (a) El hiperplano afín $h(x) = 1 - \sum_{i=1}^n x_i = 0$.
- (b) La superficie cuádrica $h(x) = 1 - \langle Qx, x \rangle = 0$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica.

Ejercicio 2.3. Verifíquese analíticamente que el punto $\bar{x} = (0, 0) \in \mathbb{R}^2$ es la solución global del problema $\min x_2$ sujeto a la intersección de las circunferencias $(x_1 - 1)^2 + x_2^2 = 1$ y $(x_1 + 1)^2 + x_2^2 = 1$. Demuestre que $\bar{x}$ no cumple con las condiciones de regularidad y que el sistema de Lagrange no admite solución en dicho punto.

Ejercicio 2.4. Demuestre que $\bar{x} = (0, 0) \in \mathbb{R}^2$ es la solución global del problema $\min x_1^2 + x_2^2$ sujeto a la restricción $(x_1 - 1)^3 = x_2^2$, y explique por qué las condiciones de optimalidad de Lagrange no se cumplen en este punto debido a la falta de regularidad (falta de LICQ).

Ejercicio 2.5 (Pérdida de la condición LICQ por reformulación no lineal). Sea el conjunto factible $D = \{x \in \mathbb{R}^n \mid h(x) = 0\}$, donde $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ cumple la condición LICQ en todo punto de D . Considérese el problema de minimización de $f(x)$ sobre D . Supóngase que se reformula el problema utilizando la restricción escalar equivalente: $\tilde{h}(x) = \frac{1}{2} \|h(x)\|^2 = 0$.

1. Demuestre que el nuevo conjunto factible $\tilde{D} = \{x \in \mathbb{R}^n \mid \tilde{h}(x) = 0\}$ coincide con D .
2. Pruebe analíticamente que ningún punto de $\tilde{D}$ cumple la condición de regularidad LICQ para la restricción $\tilde{h}$.
3. Explique por qué el sistema de Lagrange asociado a $\tilde{h}$ no permite identificar los puntos óptimos del problema original, analizando la diferencia entre la representación algebraica y el conjunto geométrico.

Ejercicio 2.6 (El Cilindro y el Plano Tangente). Considérese la superficie descrita por $h(x) = x_1^2 + x_2^2 - x_3 = 0$ (un paraboloide).

1. Evalúe el punto $\bar{x} = (1, 1, 2)^T$. Demuestre que se cumple LICQ y halle una base ortonormal para el subespacio tangente $\ker J_h(\bar{x})$.

2. Considere la curva parametrizada $x(t) = (\cos t, \sin t, 1)^T$. Verifique que la curva pertenece a la variedad para todo t , y demuestre que el vector velocidad $x'(0)$ es una combinación lineal de los vectores de la base obtenida en el inciso anterior.

Ejercicio 2.7 (Dependencia Funcional y Conjuntos de Nivel). Sea $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ una función escalar de clase $\mathcal{C}^1$. Considérese el problema de minimizar $f(x)$ sujeto a que el punto pertenezca a una curva de nivel de otra función suave: $h(x) = g(x) - c = 0$. Demuestre que, si el punto $\bar{x}$ es un óptimo regular, entonces las curvas de nivel de f y de g que pasan por $\bar{x}$ son tangentes entre sí en dicho punto. Interprete este resultado geoméricamente usando los gradientes.

Ejercicio 2.8 (Intersección de dimensión mixta y puntos aislados). Sea el conjunto factible en $\mathbb{R}^3$ definido por $h_1(x) = x_1^2 + x_2^2 - x_3 = 0$ y $h_2(x) = x_3 = 0$.

1. Describa geoméricamente el conjunto resultante D .
2. Demuestre que el único punto en D es el origen $(0, 0, 0)^T$.
3. Calcule la matriz Jacobiana $J_h(0)$. Determine si el origen es un punto regular y analice, desde una perspectiva geométrica y topológica, por qué la intersección de estas restricciones produce un punto aislado en lugar de una curva.

Parte II: Condiciones Diferenciales de Segundo Orden y Matriz KKT

Ejercicio 2.9. Determine los extremos locales y globales de la función $f(x) = x_1^3/3 + x_2$ restringida a la esfera $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 = 2\}$.

Ejercicio 2.10 (El Sistema Lineal de Karush-Kuhn-Tucker). Sea el funcional cuadrático generalizado $f(x) = \frac{1}{2}\langle Qx, x \rangle + \langle q, x \rangle$ sujeto a la restricción afín sobreyectiva $Ax = a$. Asumiendo que Q es simétrica y definida positiva, pruébese la unicidad de la solución primal-dual y determínese analíticamente el sistema matricial de bloques (Matriz KKT) que resuelven los vectores x y λ simultáneamente.

Ejercicio 2.11 (No-singularidad Numérica de la Matriz KKT). Generalizando el ejercicio anterior, sea $\bar{x} \in D$ un punto estacionario regular (LICQ) para un problema no lineal de optimización, con multiplicador único $\bar{\lambda}$. Definase el Hessiano $H = \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}) \in \mathbb{R}^{n \times n}$ y el Jacobiano $A = J_h(\bar{x}) \in \mathbb{R}^{l \times n}$. Supóngase que se cumple la condición suficiente de segundo orden estricta: $\langle Hd, d \rangle > 0$ para todo $d \in \ker A \setminus \{0\}$. Demuéstrese que la matriz de bloques KKT:

$$K = \begin{pmatrix} H & A^T \\ A & 0 \end{pmatrix} \in \mathbb{R}^{(n+l) \times (n+l)}$$

es invertible. (Ayuda: Suponga que $K \begin{pmatrix} d \\ y \end{pmatrix} = 0$, multiplique la primera fila de bloques por d^T y utilice la condición de positividad sobre el núcleo para deducir que $d = 0$).

Ejercicio 2.12 (Valores Propios como Extremos de Rayleigh). Sea $Q \in \mathbb{R}^{n \times n}$ una matriz simétrica. Utilícese el sistema de optimalidad para encontrar todos los minimizadores y maximizadores de la forma cuadrática $f(x) = \langle Qx, x \rangle$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^n \mid \|x\|^2 = 1\}$. Caracterícese el conjunto de multiplicadores de Lagrange en términos de los autovalores de la matriz Q .

Ejercicio 2.13 (Degeneración de la Condición Necesaria). Considérese el problema $\min f(x) = x_1^4 + x_2^4$ sujeto a $h(x) = x_1 + x_2 = 0$. Verifique analíticamente que $\bar{x} = (0, 0)$ es el minimizador global estricto del problema. Sin embargo, al calcular la matriz Hessiana de la Lagrangiana evaluada sobre el núcleo de la restricción, demuestre que el resultado es la matriz nula. Muestre que cuando las de menor orden se anulan, las aproximaciones cuadráticas no bastan para asegurar la suficiencia analítica de segundo orden.

Ejercicio 2.14 (Descomposición Espectral en Lagrange). Minimice la función $f(x) = x_1^2 + x_2^2 + x_3^2$ sujeta a la restricción no lineal $h(x) = x_1 x_2 x_3 - 1 = 0$.

1. Encuentre todos los puntos estacionarios y sus respectivos multiplicadores de Lagrange.
2. Calcule la matriz Hessiana de la Lagrangiana en dichos puntos.
3. Proyecte la matriz Hessiana sobre el subespacio tangente y utilice el criterio de los autovalores para determinar cuáles puntos son mínimos locales. (Ayuda: Analice la simetría de las coordenadas).

Ejercicio 2.15 (Puntos de Enselladura Restringidos). Considere el problema $\min x_1 x_2$ sujeto a $x_1 + x_2 = 2$. Demuestre que el único punto estacionario del sistema de Lagrange es $\bar{x} = (1, 1)^T$. Evaluando las condiciones necesarias y suficientes de segundo orden, pruebe que este punto no es un minimizador local, sino que corresponde a un máximo global restringido.

Ejercicio 2.16 (La Matriz Fronteada (Bordered Hessian)). Sea un problema con restricciones afines $Ax = a$. La matriz KKT $K = \begin{pmatrix} H & A^T \\ A & 0 \end{pmatrix}$ es simétrica. Demuestre que, incluso si H es estrictamente definida positiva, la matriz de bloques completa K es siempre indefinida (posee tanto autovalores estrictamente positivos como estrictamente negativos). Este resultado explica por qué los algoritmos de optimización numérica suelen utilizar factorizaciones como LDL^T en lugar de la factorización de Cholesky.

Parte III: Aplicaciones Físicas, Análisis de Sensibilidad y Variedades Matriciales

Ejercicio 2.17 (Precio Sombra y Análisis de Sensibilidad). Considérese el problema parametrizado $\min f(x)$ sujeto a $h(x) = p$, donde $p \in \mathbb{R}^l$ es un vector de perturbaciones de frontera. Sea $\bar{x}$ un mínimo local estricto para el problema nominal ($p = 0$), regular (LICQ) y que satisface las condiciones suficientes de segundo orden con multiplicador único $\bar{\lambda}$. Invocando el Teorema de la Función Implícita sobre el sistema KKT, existe una trayectoria suave de minimizadores locales $x(p)$ con $x(0) = \bar{x}$. Defínase la función valor óptimo $v(p) = f(x(p))$. Aplicando la regla de la cadena multivariable y la ecuación estacionaria de Lagrange, demuéstrese rigurosamente que: $\nabla_p v(0) = -\bar{\lambda}$. Interprete este resultado desde una perspectiva geométrica y económica, relacionando el multiplicador de Lagrange con la sensibilidad del valor óptimo frente a variaciones en el término independiente de la restricción.

Ejercicio 2.18 (Problema Isoperimétrico de Herón). Entre todos los triángulos de perímetro fijo $2p > 0$, utilícense las condiciones de optimalidad de Lagrange de primero y segundo orden para demostrar que el triángulo que maximiza el área es el triángulo equilátero. (Ayuda: Modele el problema maximizando el cuadrado del área mediante la fórmula de Herón $f(x, y, z) = p(p-x)(p-y)(p-z)$ sujeto a la restricción afín $x + y + z = 2p$).

Ejercicio 2.19 (Principio de Fermat y la Ley de Snell). Un rayo de luz viaja desde el punto $A = (0, y_A)$ en un medio isótropo con velocidad v_1 , hasta un punto $B = (x_B, y_B)$ en un medio con velocidad v_2 . La interfaz de refracción entre ambos medios es la recta horizontal $y = 0$. Modele el problema buscando el punto de cruce $P = (x, y) \in \mathbb{R}^2$ que minimiza el tiempo total de viaje $T(x, y) = \frac{\|P-A\|}{v_1} + \frac{\|B-P\|}{v_2}$ sujeto a la restricción de frontera $h(x, y) = y = 0$. Resolviendo el sistema de Lagrange, obténgase analíticamente la Ley de Snell.

Ejercicio 2.20 (Distribución Uniforme y Entropía de Shannon). En Teoría de la Información, la entropía de una distribución de probabilidad discreta $x \in \mathbb{R}^n$ (con $x_i > 0$) se define como el funcional $\mathcal{H}(x) = -\sum_{i=1}^n x_i \ln(x_i)$. Demuestre analíticamente que el problema de maximización de entropía $\max \mathcal{H}(x)$ sujeto a $\sum_{i=1}^n x_i = 1$ es resuelto unívocamente por la distribución uniforme $\bar{x}_i = 1/n$ para todo i . Verifique el carácter de máximo global analizando los autovalores de la matriz Hessiana.

Ejercicio 2.21 (Proyección sobre el Grupo Ortogonal: El Problema de Procrustes). Sea el espacio de matrices cuadradas $M_n(\mathbb{R})$ equipado con el producto de Frobenius $\langle X, Y \rangle_F = \text{Tr}(X^T Y)$. Considérese el problema de encontrar la matriz ortogonal más cercana a una matriz dada $A \in M_n(\mathbb{R})$:

$$\min \frac{1}{2} \|X - A\|_F^2 \quad \text{sujeto a} \quad X^T X - I = 0.$$

Haciendo uso de las derivadas de Fréchet para funciones matriciales, defina la Lagrangiana (donde el multiplicador de Lagrange es una matriz simétrica $\Lambda \in M_n(\mathbb{R})$) y derive la ecuación matricial estacionaria.

Ejercicio 2.22 (Mecánica Clásica: El Péndulo Simple). Un péndulo consiste en una masa m sujeta al extremo de una varilla rígida de longitud L sin masa, cuyo otro extremo está fijo en el origen $(0, 0)$. La posición de la masa se denota por (x, y) . La energía potencial es $V(x, y) = mgy$. Modele las posiciones de equilibrio del péndulo determinando los extremos de $V(x, y)$ sujetos a la restricción de longitud $x^2 + y^2 = L^2$. Interprete el multiplicador de Lagrange como la fuerza de tensión en la varilla.

Ejercicio 2.23 (Microeconomía: Maximización de Utilidad). Un consumidor desea maximizar su función de utilidad Cobb-Douglas $U(x_1, x_2) = x_1^\alpha x_2^\beta$ (con $\alpha, \beta > 0$), sujeto a su restricción presupuestaria $p_1 x_1 + p_2 x_2 = I$, donde p_i son los precios e I el ingreso disponible.

1. Encuentre las funciones de demanda marshallianas $x_1(p_1, p_2, I)$ y $x_2(p_1, p_2, I)$ resolviendo el sistema de Lagrange.
2. Calcule el multiplicador de Lagrange óptimo λ^* .
3. Demuestre analíticamente que $\lambda^* = \frac{\partial U^*}{\partial I}$, verificando que el multiplicador representa la “utilidad marginal del ingreso”.

Ejercicio 2.24 (Problema de Optimización de Carteras de Markowitz). Un inversor desea construir un portafolio con n activos financieros. Sea $x \in \mathbb{R}^n$ el vector de ponderación de cada activo (fracción del capital invertido), tal que $\sum x_i = 1$. Sea $\Sigma \in \mathbb{R}^{n \times n}$ la matriz de covarianza de los retornos (simétrica y definida positiva) y $\mu \in \mathbb{R}^n$ el vector de retornos esperados. El inversor desea minimizar la varianza de la cartera $\frac{1}{2}x^T \Sigma x$, sujeto a obtener un retorno esperado objetivo $\mu^T x = R$, y a que la suma de las ponderaciones sea igual a 1 ($e^T x = 1$, donde e es el vector de unos). Escriba el sistema KKT, halle la solución analítica para las ponderaciones óptimas x^* y demuestre que dicha solución es única.

Ejercicio 2.25 (Mínimos Cuadrados Restringidos). En estimación estadística, a menudo se requiere estimar parámetros sujetos a un conjunto de restricciones lineales exactas. Considere el problema de regresión $\min \frac{1}{2} \|Y - X\beta\|^2$ sujeto a $C\beta = d$, donde $Y \in \mathbb{R}^m$, $X \in \mathbb{R}^{m \times n}$ (con rango de columnas completo), $C \in \mathbb{R}^{l \times n}$ (rango de filas completo) y $d \in \mathbb{R}^l$. Encuentre la expresión analítica cerrada del estimador restringido β^* resolviendo el sistema de ecuaciones de Lagrange y compárelo con el estimador de mínimos cuadrados ordinarios irrestricto $\hat{\beta} = (X^T X)^{-1} X^T Y$.

3. Análisis convexo

En este capítulo estudiamos conjuntos convexos y funciones convexas. La convexidad es una noción muy importante en la teoría de optimización. Con hipótesis de convexidad, las condiciones necesarias de optimalidad pasan a ser suficientes. En otras palabras, todo punto estacionario se convierte en una solución del problema. En particular, cualquier minimizador local es global. Además, en el caso convexo podemos desarrollar la teoría de dualidad en su forma más completa, es decir, asociar al problema original (primal) otro problema, llamado dual, que bajo ciertas hipótesis es equivalente al original y a veces es más fácil de resolver.

Finalmente, las herramientas del Análisis Convexo serán necesarias para la caracterización del cono dual al cono tangente en el caso de restricciones mixtas (de igualdad y desigualdad), lo que resulta en las condiciones de optimalidad primal-duales de Karush-Kuhn-Tucker. Cabe resaltar que este capítulo no constituye un curso de Análisis Convexo completo; además de resultados básicos, presentamos solo el material que será necesario a lo largo de este libro.

3.1. Definiciones de convexidad. El problema de minimización convexo

Un conjunto convexo se caracteriza por contener todos los segmentos cuyos extremos pertenecen al conjunto.

Definición 3.1 (Conjunto convexo). Un conjunto $D \subset \mathbb{R}^n$ se llama **conjunto convexo** si para cualesquiera $x \in D$, $y \in D$ y $\alpha \in [0, 1]$, se tiene que

$$\alpha x + (1 - \alpha)y \in D.$$

El punto $\alpha x + (1 - \alpha)y$, donde $\alpha \in [0, 1]$, se llama **combinación convexa** de x e y (con parámetro α).

El conjunto vacío, el espacio $\mathbb{R}^n$ y un conjunto que contiene un solo punto son trivialmente convexos. Cualquier conjunto no convexo es trivialmente no convexo.

A continuación mostramos que la dualización de un cono cualquiera (incluso no convexo) siempre produce un cono convexo.

Proposición 3.1. Para todo cono $\emptyset \neq K \subset \mathbb{R}^n$, el cono dual K^* siempre es convexo y cerrado.

Prueba. Sean $x \in K^*$ e $y \in K^*$, es decir, $\langle x, d \rangle \leq 0$ e $\langle y, d \rangle \leq 0$ para todo $d \in K$. Sea $\alpha \in [0, 1]$. Para cualquier $d \in K$, tenemos que:

$$\langle \alpha x + (1 - \alpha)y, d \rangle = \alpha \langle x, d \rangle + (1 - \alpha) \langle y, d \rangle \leq 0,$$

es decir, $\alpha x + (1 - \alpha)y \in K^*$. Por lo tanto, K^* es convexo.

Sea $\{y^k\} \subset K^*$, $\{y^k\} \rightarrow y$ ($k \rightarrow \infty$). Fijando $d \in K$ arbitrario, y pasando al límite cuando $k \rightarrow \infty$ en la relación $\langle y^k, d \rangle \leq 0$, obtenemos que $\langle y, d \rangle \leq 0$. Por lo tanto, como $d \in K$ era arbitrario, $y \in K^*$. Esto muestra que K^* es cerrado. ■

Otros criterios de convexidad de conjuntos se presentarán en la siguiente sección. Mostramos a continuación que, para un conjunto convexo, el cono tangente (usual o de Bouligand) está dado por la clausura de todas las direcciones viables. Pero primero introducimos la siguiente noción.

Definición 3.2 (Cápsula cónica o envoltura cónica). Dado un conjunto $D \subset \mathbb{R}^n$ cualquiera, la **cápsula cónica** de D , denotado por $\text{cone } D$, es el menor cono convexo en $\mathbb{R}^n$ que contiene a D (o, equivalentemente, la intersección de todos los conos convexos en $\mathbb{R}^n$ que contienen a D).

Para un conjunto convexo, la cápsula cónica está compuesto por todos los múltiplos no negativos de elementos del conjunto.

Proposición 3.2 (Cápsula cónica de un conjunto convexo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Se tiene que:

$$\text{cone } D = \{d \in \mathbb{R}^n \mid d = \alpha x, x \in D, \alpha \in \mathbb{R}_+\}.$$

Prueba. Denotamos $C = \{d \in \mathbb{R}^n \mid d = \alpha x, x \in D, \alpha \in \mathbb{R}_+\}$. Como el conjunto cone D es un cono, para todo $x \in D \subset \text{cone } D$, tenemos que $\alpha x \in \text{cone } D$ para todo $\alpha \in \mathbb{R}_+$. Luego, $C \subset \text{cone } D$.

Observamos que C es un cono que contiene a D (basta tomar $\alpha = 1$). Por lo tanto, si demostramos que C es convexo, C será un cono convexo que contiene a D , de donde la inclusión $\text{cone } D \subset C$ será obvia por la Definición 3.2.

Sean $d^1 \in C, d^2 \in C$, es decir, $d^i = \alpha_i x^i, \alpha_i \in \mathbb{R}_+ \text{ e } x^i \in D, i = 1, 2$. Sea $d = td^1 + (1-t)d^2 = t\alpha_1 x^1 + (1-t)\alpha_2 x^2$, con $t \in [0, 1]$. Cuando $t \in \{0, 1\}$ o $\alpha_i = 0$ para algún $i \in \{1, 2\}$, la inclusión $d \in C$ es obvia. Supongamos entonces que $t \in (0, 1), \alpha_i > 0, i = 1, 2$. Definimos:

$$\beta = \left(1 + \frac{\alpha_2(1-t)}{\alpha_1 t}\right)^{-1} \in (0, 1).$$

Por la convexidad de D , tenemos que $x = \beta x^1 + (1-\beta)x^2 \in D$. Además,

$$\frac{\alpha_1 t}{\beta} x = \alpha_1 t(x^1 + (1/\beta - 1)x^2) = t\alpha_1 x^1 + (1-t)\alpha_2 x^2 = d,$$

mostrando que $d \in C$. Esto prueba que C es convexo. ■

A continuación probaremos un resultado importante sobre el cono tangente de un conjunto convexo.

Teorema 3.1 (Direcciones viables y cono tangente de un conjunto convexo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo, $\bar{x} \in D$. Entonces:

$$\mathcal{V}_D(\bar{x}) = \text{cone}(D - \{\bar{x}\}),$$

$$\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \text{cl } \mathcal{V}_D(\bar{x}) = \text{cl } \text{cone}(D - \{\bar{x}\}).$$

En particular, $\mathcal{T}_D(\bar{x})$ es convexo y cerrado.

Prueba. Es fácil ver que el conjunto $D - \{\bar{x}\}$ es convexo. Por lo tanto, por la Proposición 3.2:

$$\text{cone}(D - \{\bar{x}\}) = \{d \in \mathbb{R}^n \mid d = \alpha(x - \bar{x}), x \in D, \alpha \in \mathbb{R}_+\}. \quad (3.1)$$

Sea $d \in \text{cone}(D - \{\bar{x}\}), d \neq 0$ (luego, $\alpha > 0$). Esto significa que $\bar{x} + d/\alpha = x \in D$. Por la convexidad de D , se sigue que $\bar{x} + td \in D$ para todo $t \in [0, 1/\alpha]$, es decir, $d \in \mathcal{V}_D(\bar{x})$. Recíprocamente, para $d \in \mathcal{V}_D(\bar{x})$ se tiene que $\bar{x} + td \in D$ para todo $t \in [0, \epsilon]$. Por lo tanto, existe $x \in D$ tal que $x = \bar{x} + td, t > 0$. Luego, $d = (x - \bar{x})/t$, es decir, $d \in \text{cone}(D - \{\bar{x}\})$. Así, $\mathcal{V}_D(\bar{x}) = \text{cone}(D - \{\bar{x}\})$.

Como se estableció en el Capítulo 1, siempre se tiene que $\text{cl } \mathcal{V}_D(\bar{x}) \subset \mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$. Probamos la afirmación mostrando que $\mathcal{B}_D(\bar{x}) \subset \text{cl } \mathcal{V}_D(\bar{x})$.

Sea $d \in \mathcal{B}_D(\bar{x})$, es decir, existen $\{t_k\} \rightarrow 0+$ e $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$ para todo k . Como ya mostramos, esto significa que $d^k \in \mathcal{V}_D(\bar{x})$. En particular, concluimos que $d = \lim_{k \rightarrow \infty} d^k \in \text{cl } \mathcal{V}_D(\bar{x})$. ■

A continuación mostramos que un cono y su clausura tienen el mismo cono dual.

Proposición 3.3. Sea $K \subset \mathbb{R}^n$ un cono cualquiera. Entonces $\text{cl } K$ es un cono y se tiene que:

$$K^* = (\text{cl } K)^*.$$

En particular, si $D \subset \mathbb{R}^n$ es un conjunto convexo y $\bar{x} \in D$, se tiene que:

$$(\mathcal{T}_D(\bar{x}))^* = (\mathcal{V}_D(\bar{x}))^* = (\text{cone}(D - \{\bar{x}\}))^*.$$

Prueba. El hecho de que $\text{cl } K$ sea un cono es fácil de verificar. Por la definición de cono dual, la inclusión $K \subset \text{cl } K$ implica que $(\text{cl } K)^* \subset K^*$.

Sean $y \in K^*$ y $d \in \text{cl } K$ cualesquiera. Existe $\{d^k\} \subset K$ tal que $\{d^k\} \rightarrow d$. Tenemos que $\langle y, d^k \rangle \leq 0$ para todo k . Pasando al límite cuando $k \rightarrow \infty$, obtenemos que $\langle y, d \rangle \leq 0$. Por lo tanto, $y \in (\text{cl } K)^*$, es decir, $K^* \subset (\text{cl } K)^*$. Ahora, la última afirmación se sigue del Teorema 3.1. ■

Otra noción útil en Análisis Convexo es la de cono normal.

Definición 3.3 (Cono normal). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y $\bar{x} \in D$. El **cono normal** (o cono de direcciones normales) en el punto $\bar{x}$ con respecto al conjunto D está dado por:

$$\mathcal{N}_D(\bar{x}) = \{d \in \mathbb{R}^n \mid \langle d, x - \bar{x} \rangle \leq 0 \forall x \in D\}.$$

A continuación, mostramos que, en el caso convexo, el dual del cono tangente es exactamente el cono normal.

Teorema 3.2 (El cono normal es el dual del cono tangente). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y $\bar{x} \in D$. Entonces:

$$(\mathcal{T}_D(\bar{x}))^* = (\mathcal{V}_D(\bar{x}))^* = (\text{cone}(D - \{\bar{x}\}))^* = \mathcal{N}_D(\bar{x}).$$

Prueba. Las primeras dos igualdades ya fueron probadas en la Proposición 3.3. Supongamos que $y \in (\text{cone}(D - \{\bar{x}\}))^*$, es decir, $\langle y, d \rangle \leq 0$ para todo $d \in \text{cone}(D - \{\bar{x}\})$. En particular, $\langle y, x - \bar{x} \rangle \leq 0$ para todo $x \in D$, es decir, $y \in \mathcal{N}_D(\bar{x})$. Supongamos que $y \in \mathcal{N}_D(\bar{x})$. Tenemos que $\langle y, x - \bar{x} \rangle \leq 0$ para todo $x \in D$, es decir, $\langle y, d \rangle \leq 0$ para todo $d \in (D - \{\bar{x}\})$. Luego, $\langle y, d \rangle \leq 0$ para todo $d \in \text{cone}(D - \{\bar{x}\})$. Concluimos que $y \in (\text{cone}(D - \{\bar{x}\}))^*$. ■

Como consecuencia de la caracterización del cono tangente y de su dual, obtenemos las siguientes condiciones de optimalidad para un problema con conjunto factible convexo.

Teorema 3.3 (Condición necesaria de primer orden). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $\bar{x} \in D$. Si $\bar{x}$ es un minimizador local de f en el conjunto D , entonces:

$$\langle \nabla f(\bar{x}), x - \bar{x} \rangle \geq 0 \quad \forall x \in D, \quad (3.2)$$

o, equivalentemente,

$$-\nabla f(\bar{x}) \in \mathcal{N}_D(\bar{x}). \quad (3.3)$$

Prueba. Por las condiciones primales de primer orden del Capítulo 1, $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{B}_D(\bar{x})$. Por el Teorema 3.1, tenemos que:

$$\{d \in \mathbb{R}^n \mid d = x - \bar{x}, x \in D\} \subset \text{cone}(D - \{\bar{x}\}) \subset \mathcal{B}_D(\bar{x}),$$

lo que implica (3.2). Por la Definición 3.3, (3.2) y (3.3) son equivalentes. ■

Si la función f es convexa, la condición necesaria de optimalidad dada en el Teorema 3.3 también es suficiente.

Definición 3.4 (Funciones convexas, estrictas y fuertes). Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Se dice que una función $f : D \rightarrow \mathbb{R}$ es **convexa** en D si para cualesquiera $x \in D$, $y \in D$ y $\alpha \in [0, 1]$, se tiene:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y).$$

La función f se dice **estrictamente convexa** cuando la desigualdad anterior es estricta para todos los $x \neq y$ y $\alpha \in (0, 1)$.

La función f se dice **fuertemente convexa** con módulo $\gamma > 0$, cuando para cualesquiera $x, y \in D$ y $\alpha \in [0, 1]$, se tiene:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) - \gamma \alpha(1 - \alpha)\|x - y\|^2.$$

Es obvio que una función fuertemente convexa es estrictamente convexa, y una función estrictamente convexa es convexa. La función $f(x) = x^2$ es fuertemente convexa. La función $f(x) = e^x$ es estrictamente (pero no fuertemente) convexa. Una función afín $f(x) = x$ es convexa (pero no estricta).

Definición 3.5 (Epígrafe). El **epígrafe** de la función $f : D \rightarrow \mathbb{R}$ es el conjunto:

$$E_f = \{(x, c) \in D \times \mathbb{R} \mid f(x) \leq c\}.$$

La relación entre convexidad de conjuntos y de funciones está dada por el siguiente teorema.

Teorema 3.4 (El epígrafe caracteriza la convexidad). Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Una función $f : D \rightarrow \mathbb{R}$ es convexa en D si, y solo si, el epígrafe de f es un conjunto convexo en $\mathbb{R}^n \times \mathbb{R}$.

Prueba. Supongamos primero que E_f es convexo. Sean $x \in D$ y $y \in D$ cualesquiera. Obviamente, $(x, f(x)) \in E_f$ y $(y, f(y)) \in E_f$. Por la convexidad de E_f , para todo $\alpha \in [0, 1]$ tenemos que:

$$\alpha(x, f(x)) + (1 - \alpha)(y, f(y)) \in E_f.$$

Por la definición de epígrafe, esto es equivalente a decir que $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$, es decir, f es convexa.

Supongamos ahora que f es convexa. Sean $(x, c_1) \in E_f$ y $(y, c_2) \in E_f$. Como $f(x) \leq c_1$ y $f(y) \leq c_2$, por la convexidad de f , para todo $\alpha \in [0, 1]$ se tiene $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) \leq \alpha c_1 + (1 - \alpha)c_2$, lo que significa que $(\alpha x + (1 - \alpha)y, \alpha c_1 + (1 - \alpha)c_2) \in E_f$, es decir, E_f es convexo. ■

Decimos que $\min_{x \in D} f(x)$ es un **problema de minimización convexo** cuando $D \subset \mathbb{R}^n$ es un conjunto convexo y $f : D \rightarrow \mathbb{R}$ es una función convexa. La importancia de la convexidad se puede ver en el siguiente resultado.

Teorema 3.5 (Teorema de minimización convexo). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y $f : D \rightarrow \mathbb{R}$ una función convexa en D . Entonces todo minimizador local del problema es global. Además, el conjunto de minimizadores es convexo. Si f es estrictamente convexa, no puede haber más de un minimizador.

Prueba. Supongamos que $\bar{x} \in D$ sea un minimizador local que no es global. Entonces existe $y \in D$ tal que $f(y) < f(\bar{x})$. Definimos $x(\alpha) = \alpha y + (1 - \alpha)\bar{x}$. Por la convexidad de D , $x(\alpha) \in D$ para todo $\alpha \in (0, 1)$. Por la convexidad de f , para todo $\alpha \in (0, 1)$, se tiene:

$$f(x(\alpha)) \leq \alpha f(y) + (1 - \alpha)f(\bar{x}) = f(\bar{x}) + \alpha(f(y) - f(\bar{x})) < f(\bar{x}).$$

Tomando $\alpha > 0$ suficientemente pequeño, $x(\alpha)$ está arbitrariamente próximo al punto $\bar{x}$, y aun así $f(x(\alpha)) < f(\bar{x})$. Esto contradice el hecho de que $\bar{x}$ es un minimizador local.

Sea $S \subset D$ el conjunto de los minimizadores (globales) e $\bar{v} \in \mathbb{R}$ el valor óptimo. Para cualesquiera $x, \bar{x} \in S$ y $\alpha \in [0, 1]$, por la convexidad de f obtenemos $f(\alpha x + (1 - \alpha)\bar{x}) \leq \alpha \bar{v} + (1 - \alpha)\bar{v} = \bar{v}$, lo que implica que de hecho $f(\alpha x + (1 - \alpha)\bar{x}) = \bar{v}$, por lo tanto, la combinación convexa pertenece a S . Luego S es convexo.

Si f es estrictamente convexa y existieran $x, \bar{x} \in S$ distintos, entonces para $\alpha \in (0, 1)$:

$$f(\alpha x + (1 - \alpha)\bar{x}) < \alpha f(x) + (1 - \alpha)f(\bar{x}) = \bar{v},$$

lo que resulta en una contradicción. Concluimos que en este caso el minimizador es único. ■

Definición 3.6 (Función cóncava). Si $D \subset \mathbb{R}^n$ es un conjunto convexo, decimos que una función $f : D \rightarrow \mathbb{R}$ es una **función cóncava** en D , cuando la función $(-f)$ es convexa en D .

Es fácil ver que las afirmaciones del Teorema 3.5 son verdaderas si sustituimos la minimización de una función convexa por la maximización de una función cóncava.

3.2. Conjuntos convexos y Teoremas de Separación

Estudiaremos los conjuntos convexos con más profundidad, abarcando la estructura de conjuntos, la proyección ortogonal y la separación mediante hiperplanos.

3.2.1. Propiedades básicas de conjuntos convexos

Proposición 3.4. Sean $D_i \subset \mathbb{R}^n$, $i \in I$, conjuntos convexos, donde I es un conjunto cualquiera (posiblemente infinito). Entonces la intersección $D = \bigcap_{i \in I} D_i$ también es un conjunto convexo.

Prueba. Sean $x \in D$ e $y \in D$. Por la definición de intersección, $x \in D_i$ e $y \in D_i$ para todo $i \in I$. Como los conjuntos D_i son convexos, $\alpha x + (1 - \alpha)y \in D_i$ para todo $i \in I$. Por la definición de la intersección, se sigue que la combinación convexa pertenece a D , es decir, D es convexo. ■

Corolario 3.1. Un conjunto poliédrico en $\mathbb{R}^n$ es convexo.

Prueba. Un conjunto poliédrico es el conjunto de soluciones de un sistema finito de ecuaciones e inecuaciones lineales, es decir, una intersección de semiespacios e hiperplanos que son conjuntos convexos. Por lo tanto, un conjunto poliédrico es convexo por la Proposición 3.4. ■

A continuación mostramos que la clausura y el interior de un conjunto convexo son conjuntos convexos.

Proposición 3.5. Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Entonces $\text{cl } D$ e $\text{int } D$ son conjuntos convexos.

Prueba. Sean $x, y \in \text{cl } D$, $\alpha \in [0, 1]$. Elegimos secuencias $\{x^k\}, \{y^k\} \subset D$ tales que $\{x^k\} \rightarrow x$ e $\{y^k\} \rightarrow y$. Por la convexidad de D , $\alpha x^k + (1 - \alpha)y^k \in D$. Pasando al límite obtenemos que $\alpha x + (1 - \alpha)y \in \text{cl } D$.

Sean $x, y \in \text{int } D$. Fijamos $\epsilon > 0$ tal que $B(x, \epsilon) \subset D$ y $B(y, \epsilon) \subset D$. Para mostrar que $z = \alpha x + (1 - \alpha)y \in \text{int } D$, tomamos un vector q con $\|q\| \leq \epsilon$. Observamos que $z + q = \alpha(x + q) + (1 - \alpha)(y + q)$. Obviamente, $x + q \in B(x, \epsilon) \subset D$ e $y + q \in B(y, \epsilon) \subset D$. Por la convexidad, concluimos que $z + q \in D$. Por lo tanto, $B(z, \epsilon) \subset D$, lo que significa que $z \in \text{int } D$. ■

Proposición 3.6. Sean $D_i \subset \mathbb{R}^n$, $i = 1, 2$, conjuntos convexos cerrados. Si uno de ellos también es acotado (luego, compacto), entonces la suma de Minkowski $D_1 + D_2$ es convexa y cerrada.

Prueba. Es fácil ver que el conjunto $D = D_1 + D_2$ es convexo. Mostraremos que D es cerrado, suponiendo que D_2 sea acotado.

Sea $\{x^k\} \rightarrow x$, con $x^k \in D$. Para todo k existen $x^{k,1} \in D_1$ e $x^{k,2} \in D_2$ tales que $x^k = x^{k,1} + x^{k,2}$. Es claro que la secuencia $\{x^{k,2}\}$ es acotada. Como la secuencia de la suma converge, se sigue que $\{x^{k,1}\}$ también es acotada. Luego, tiene un punto de acumulación, digamos $\bar{x}^1$. Sea $\{x^{k_j,1}\} \rightarrow \bar{x}^1$. Podemos admitir que $\{x^{k_j,2}\} \rightarrow \bar{x}^2$, eligiendo una subsecuencia si es necesario. Como D_1 y D_2 son cerrados, $\bar{x}^1 \in D_1$ y $\bar{x}^2 \in D_2$. Por lo tanto, $x = \bar{x}^1 + \bar{x}^2 \in D_1 + D_2 = D$, lo que muestra que D es cerrado. ■

Observamos que para D_1 y D_2 convexos y cerrados es posible que $D_1 + D_2$ no sea cerrado si ambos son no acotados (por ejemplo, si D_1 es el eje x_1 y D_2 es el epígrafe de $1/x_1$).

Definición 3.7 (Combinación convexa). Dados $x^i \in \mathbb{R}^n$, $\alpha_i \in [0, 1]$, $i = 1, \dots, p$, tales que $\sum_{i=1}^p \alpha_i = 1$, el punto $\sum_{i=1}^p \alpha_i x^i$ se llama **combinación convexa** de los puntos $x^i \in \mathbb{R}^n$ con parámetros α_i .

Teorema 3.6 (Caracterización por combinaciones convexas). Un conjunto $D \subset \mathbb{R}^n$ es convexo si, y solo si, para cualesquiera $p \in \mathbb{N}$, $x^i \in D$ y $\alpha_i \in [0, 1]$ tales que $\sum_{i=1}^p \alpha_i = 1$, la combinación convexa $\sum_{i=1}^p \alpha_i x^i$ pertenece a D .

Prueba. Si D contiene todas las combinaciones convexas de sus puntos, en particular contiene las combinaciones de dos puntos, luego D es convexo. Supongamos que D sea convexo. La prueba se realiza por inducción en p . Para $p = 1$ es trivial. Supongamos que vale para $j \geq 1$ puntos y consideremos $p = j + 1$. Sea $x = \sum_{i=1}^{j+1} \alpha_i x^i$. Si $\alpha_{j+1} = 1$, entonces $x = x^{j+1} \in D$. Si $\alpha_{j+1} \in [0, 1)$, escribimos

$$x = (1 - \alpha_{j+1})y + \alpha_{j+1}x^{j+1}, \quad (3.4)$$

donde $y = \sum_{i=1}^j \frac{\alpha_i}{1 - \alpha_{j+1}} x^i$. Como los coeficientes de y suman 1, $y \in D$ por hipótesis de inducción. Luego, (3.4) muestra que x es una combinación convexa de dos puntos de D , por lo que $x \in D$. ■

Corolario 3.2 (Desigualdad de Jensen). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y $f : D \rightarrow \mathbb{R}$ una función convexa en D . Entonces para cualesquiera $p \in \mathbb{N}$, $x^i \in D$ y $\alpha_i \in \mathbb{R}_+$ tales que $\sum_{i=1}^p \alpha_i = 1$, se tiene que:

$$f\left(\sum_{i=1}^p \alpha_i x^i\right) \leq \sum_{i=1}^p \alpha_i f(x^i). \quad (3.5)$$

Prueba. Por la definición de epígrafe, $(x^i, f(x^i)) \in E_f$. Por la convexidad de f , E_f es un conjunto convexo en $\mathbb{R}^n \times \mathbb{R}$ (Teorema 3.4). Por el Teorema 3.6, la combinación convexa pertenece a E_f :

$$\left(\sum_{i=1}^p \alpha_i x^i, \sum_{i=1}^p \alpha_i f(x^i)\right) = \sum_{i=1}^p \alpha_i (x^i, f(x^i)) \in E_f.$$

Usando la definición de epígrafe, obtenemos la (3.5). ■

Teorema 3.7 (Teorema de Carathéodory). Sea $x \in \mathbb{R}^n$ una combinación convexa de puntos del conjunto $D \subset \mathbb{R}^n$. Entonces existen $x^i \in D$ y $\alpha_i \in \mathbb{R}_+$, $i = 1, \dots, n + 1$, tales que $x = \sum_{i=1}^{n+1} \alpha_i x^i$ y $\sum_{i=1}^{n+1} \alpha_i = 1$.

Prueba. Supongamos que x es una combinación convexa de $p > n + 1$ puntos: $x = \sum_{i=1}^p \beta_i x^i$, con $\sum \beta_i = 1$ y $\beta_i > 0$. Como $p > n + 1$, los $p - 1$ vectores $\{x^i - x^p\}$ son linealmente dependientes, es decir, existen γ_i (no todos nulos) tales que $0 = \sum_{i=1}^{p-1} \gamma_i (x^i - x^p)$. Definiendo $\gamma_p = -\sum_{i=1}^{p-1} \gamma_i$, obtenemos $\sum_{i=1}^p \gamma_i = 0$ y $\sum_{i=1}^p \gamma_i x^i = 0$. Podemos admitir que algún $\gamma_j > 0$. Sea j el índice que maximiza la relación γ_i/β_i . Definimos $q_i = \beta_i - (\beta_j/\gamma_j)\gamma_i$. Por construcción, $q_j = 0$, $q_i \geq 0$, $\sum q_i = 1$ y $\sum q_i x^i = x$. Hemos expresado x como una combinación convexa de $p - 1$ puntos. Repitiendo este proceso, llegamos a $n + 1$ puntos. ■

Definición 3.8 (Cierre convexo o envoltura convexa). Sea $D \subset \mathbb{R}^n$ un conjunto cualquiera. El **cierre convexo** de D , denotado por $\text{conv } D$, es el menor conjunto convexo en $\mathbb{R}^n$ que contiene a D (o la intersección de todos los conjuntos convexos que contienen a D).

Proposición 3.7. El cierre convexo $\text{conv } D$ es el conjunto de todas las combinaciones convexas de puntos de D .

Prueba. Sea C el conjunto de todas las combinaciones convexas. Como $\text{conv } D$ es convexo y contiene a D , por el Teorema 3.6 debe contener a C , luego $C \subset \text{conv } D$. Por otro lado, es fácil demostrar que C es convexo (la combinación convexa de dos combinaciones convexas sigue siendo una combinación convexa cuyos coeficientes suman 1). Como $D \subset C$ y C es convexo, $\text{conv } D \subset C$. ■

Proposición 3.8. Sea $D \subset \mathbb{R}^n$ un conjunto compacto. Entonces $\text{conv } D$ es compacto.

Prueba. Primero mostraremos que $\text{conv } D$ es acotado. Todo $x \in \text{conv } D$ es una combinación convexa $\sum \alpha_i x^i$. Por la desigualdad triangular, $\|x\| \leq \sum \alpha_i \|x^i\| \leq \sup_{y \in D} \|y\| < +\infty$.

Para ver que es cerrado, sea $\{y^k\} \rightarrow y$ con $y^k \in \text{conv } D$. Por el Teorema 3.7, $y^k = \sum_{i=1}^{n+1} \alpha_{k,i} x^{k,i}$. Por compacidad, las secuencias $\{x^{k,i}\}$ y $\{\alpha_{k,i}\}$ son acotadas. Pasando a una subsecuencia convergente, los límites $x^i \in D$ y $\alpha_i \geq 0$ satisfacen $\sum \alpha_i = 1$ y $y = \sum \alpha_i x^i \in \text{conv } D$. ■

Proposición 3.9. Sea $K \subset \mathbb{R}^n$ un cono cualquiera. Se tiene:

$$K^* = (\text{cl } K)^* = (\text{conv } K)^*.$$

Prueba. La primera igualdad ya fue establecida en la Proposición 3.3. $\text{conv } K$ es un cono. De la inclusión $K \subset \text{conv } K$ obtenemos $(\text{conv } K)^* \subset K^*$. Si $y \in K^*$, para cualquier $d = \sum \alpha_i d^i \in \text{conv } K$ con $d^i \in K$, se tiene $\langle y, d \rangle = \sum \alpha_i \langle y, d^i \rangle \leq 0$. Luego $K^* \subset (\text{conv } K)^*$. ■

3.2.2. Cono de Recesión y Generadores Finitos

Definición 3.9 (Dirección de recesión). Decimos que $d \in \mathbb{R}^n$ es una **dirección de recesión** del conjunto convexo $D \subset \mathbb{R}^n$ cuando:

$$x + td \in D \quad \forall x \in D, \forall t \in \mathbb{R}_+.$$

Denotamos por $\mathcal{R}_D$ el **cono de recesión**.

Proposición 3.10 (Cono de recesión de un conjunto convexo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo, cerrado y no vacío. Entonces:

- (a) $\mathcal{R}_D$ es un cono convexo, cerrado y no vacío.
- (b) $d \in \mathcal{R}_D$ si, y solo si, existe $x \in D$ tal que $x + td \in D$ para todo $t \in \mathbb{R}_+$.
- (c) $\mathcal{R}_D \neq \{0\}$ si, y solo si, D es ilimitado.

Prueba. (a) Es obvio que $0 \in \mathcal{R}_D$. Si $d^1, d^2 \in \mathcal{R}_D$ y $\alpha \in [0, 1]$, para $x \in D$ y $t \geq 0$, $x + t(\alpha d^1 + (1 - \alpha)d^2) = \alpha(x + td^1) + (1 - \alpha)(x + td^2) \in D$, por lo que es convexo. La cerradura sigue por la cerradura de D .

(b) Si existe $\bar{x}$ tal que $\bar{x} + td \in D$ para todo t , para cualquier otro $x \in D$ definimos $d^k = \frac{\|d\|}{\|x^k - \bar{x}\|}(x^k - \bar{x})$ donde $x^k = x + ktd \in D$. Se puede demostrar (tomando convexidad con $\bar{x} + td^k$) que en el límite $x + td \in D$.

(c) Si D contiene una semirrecta, es ilimitado. Si D es ilimitado, tomamos una secuencia $\|x^k - x\| \rightarrow \infty$. Los vectores normalizados $d^k = (x^k - x)/\|x^k - x\|$ tienen un punto de acumulación $d \neq 0$. Por convexidad, $x + td^k \in D$ para k grande. En el límite $x + td \in D$, luego $d \in \mathcal{R}_D$. ■

Definición 3.10 (Cono con número finito de generadores). Un cono $K \subset \mathbb{R}^n$ tiene un **número finito de generadores** cuando existen $a^1, \dots, a^p \in \mathbb{R}^n$ tales que $K = \text{cone}\{a^i, i = 1, \dots, p\}$.

Proposición 3.11. Sean $a^i \in \mathbb{R}^n, i = 1, \dots, p$. Se tiene que:

$$\text{cone}\{a^i, i = 1, \dots, p\} = \left\{ x \in \mathbb{R}^n \mid x = \sum_{i=1}^p \mu_i a^i, \mu_i \geq 0, i = 1, \dots, p \right\}. \quad (3.6)$$

Prueba. Sea C el lado derecho de (3.6). C es un cono convexo y contiene los a^i , por lo que $\text{cone}\{a^i\} \subset C$. Por otro lado, cualquier $x \in C$ con $\sum \mu_i > 0$ se puede escribir como $(\sum \mu_i) \sum \beta_i a^i$, donde $\beta_i = \mu_i / \sum \mu_i$ suman 1. Así, x es un múltiplo positivo de una combinación convexa de los a^i , por lo que $x \in \text{cone}\{a^i\} = \text{cone}\{a^i\}$. Luego $C \subset \text{cone}\{a^i\}$. ■

Lema 3.1. Cualquier cono que tiene un número finito de generadores es convexo y cerrado.

Prueba. Se prueba por inducción en p . Para $p = 1$ es una semirrecta cerrada (o $\{0\}$). Para $p + 1$, o bien el cono es un subespacio (que es cerrado), o existe un generador que no puede ser negado dentro del cono. En ese caso, se descompone como $K_{p+1} = K_p + \text{cone}\{a^{p+1}\}$. Resolviendo un problema de minimización sobre la intersección compacta, se acotan los coeficientes y se asegura que el límite de secuencias convergentes pertenece al cono. ■

Definición 3.11 (Cono poliédrico). Decimos que un cono $K \subset \mathbb{R}^n$ es **poliédrico** si es el conjunto de soluciones de un sistema lineal homogéneo: $K = \{x \in \mathbb{R}^n \mid Q_1 x \leq 0, Q_2 x = 0\}$.

Teorema 3.8 (Teorema de Minkowski-Weyl). Un cono $K \subset \mathbb{R}^n$ tiene un número finito de generadores si, y solamente si, K es un cono poliédrico.

3.2.3. El operador de proyección

Teorema 3.9 (Teorema de la Proyección). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado. Para todo $x \in \mathbb{R}^n$, la proyección $P_D(x)$ existe y es única. Además, $\bar{x} = P_D(x)$ si, y solamente si,

$$\bar{x} \in D, \quad \langle x - \bar{x}, y - \bar{x} \rangle \leq 0 \quad \forall y \in D, \quad (3.7)$$

o, equivalentemente, $x - \bar{x} \in \mathcal{N}_D(\bar{x})$.

Prueba. Si $\bar{x}$ resuelve la proyección, para cualquier $y \in D$, el punto $x(\alpha) = (1 - \alpha)\bar{x} + \alpha y \in D$ para $\alpha \in [0, 1]$. Desarrollando $\|x - \bar{x}\|^2 \leq \|x - x(\alpha)\|^2$, dividiendo por α y tomando el límite, se obtiene $\langle x - \bar{x}, y - \bar{x} \rangle \leq 0$.

Si se cumple (3.7), entonces $\|x - y\|^2 = \|x - \bar{x}\|^2 + \|y - \bar{x}\|^2 - 2\langle x - \bar{x}, y - \bar{x} \rangle \geq \|x - \bar{x}\|^2$. Luego $\bar{x}$ minimiza la distancia.

Si existiera $\hat{x}$ otra proyección, $\langle x - \bar{x}, \hat{x} - \bar{x} \rangle \leq 0$ y $\langle x - \hat{x}, \bar{x} - \hat{x} \rangle \leq 0$. Sumando obtenemos $-\|\hat{x} - \bar{x}\|^2 \geq 0$, de donde $\hat{x} = \bar{x}$. ■

Corolario 3.3 (Operador de proyección no expansivo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado. Entonces $\forall x, y \in \mathbb{R}^n$:

$$\|P_D(x) - P_D(y)\| \leq \|x - y\|. \quad (3.8)$$

Prueba. Evaluando (3.7) dos veces y sumando, se obtiene $\|P_D(x) - P_D(y)\|^2 \leq \langle x - y, P_D(x) - P_D(y) \rangle$. Aplicando Cauchy-Schwarz, se deduce (3.8). ■

3.2.4. Teoremas de Separación

Definición 3.12 (Hiperplano de separación). El hiperplano $H(a, c) = \{x \in \mathbb{R}^n \mid \langle a, x \rangle = c\}$ **separa** los conjuntos D_1 y D_2 si:

$$\langle a, x^1 \rangle \leq c \leq \langle a, x^2 \rangle \quad \forall x^1 \in D_1, \forall x^2 \in D_2.$$

La separación es **estricta** cuando las desigualdades son estrictas.

Lema 3.2 (Lema de Minkowski). Sea $D \subset \mathbb{R}^n$ un conjunto convexo no vacío. Si $x \notin \text{cl } D$, entonces existen $a \in \mathbb{R}^n \setminus \{0\}$ y $c \in \mathbb{R}$ tales que:

$$\langle a, x \rangle = c, \quad \langle a, y \rangle > c \quad \forall y \in D.$$

Prueba. Sea $\bar{x} = P_{\text{cl } D}(x)$. Definimos $a = \bar{x} - x \neq 0$ y $c = \langle \bar{x} - x, x \rangle$. Para $y \in D$, por el Teorema 3.9, $\langle a, y \rangle = \langle \bar{x} - x, y \rangle \geq \langle \bar{x} - x, \bar{x} \rangle = c + \|\bar{x} - x\|^2 > c$. ■

Lema 3.3 (Separación en la frontera). Si $x \in \text{fr } D$, entonces existe un **hiperplano de soporte**: $a \in \mathbb{R}^n \setminus \{0\}$ tal que $\langle a, x \rangle = c$ y $\langle a, y \rangle \geq c$ para todo $y \in D$.

Prueba. Tomamos $\{x^k\} \rightarrow x$ con $x^k \notin \text{cl } D$. Por el Lema 3.2, existen a^k (normalizados) y c_k . Extraemos una subsucesión convergente $\{a^k\} \rightarrow a \neq 0$. En el límite, se cumple la separación. ■

Teorema 3.10 (Teorema de Separación). Sean $D_1, D_2 \subset \mathbb{R}^n$ conjuntos convexos disjuntos. Existen $a \in \mathbb{R}^n \setminus \{0\}$ y $c \in \mathbb{R}$ tales que $\langle a, x^1 \rangle \leq c \leq \langle a, x^2 \rangle$ para todo $x^1 \in D_1, x^2 \in D_2$.

Prueba. El conjunto $D = D_2 - D_1$ es convexo y $0 \notin D$. Si $0 \notin \text{cl } D$, aplicamos el Lema 3.2; si $0 \in \text{fr } D$, aplicamos el Lema 3.3. En ambos casos, existe $a \neq 0$ tal que $\langle a, x^2 - x^1 \rangle \geq 0$. Elegimos $c = (\sup_{D_1} \langle a, x^1 \rangle + \inf_{D_2} \langle a, x^2 \rangle)/2$. ■

Teorema 3.11 (Teorema de Separación Estricta). Sean $D_1, D_2 \subset \mathbb{R}^n$ convexos, cerrados y no vacíos, con uno de ellos compacto. Entonces $D_1 \cap D_2 = \emptyset$ si, y solamente si, pueden ser separados estrictamente.

Prueba. Sea D_2 compacto. La función distancia $\text{dist}(x, D_1)$ alcanza su mínimo en D_2 en un punto a^2 . Sea $a^1 = P_{D_1}(a^2)$. Como son disjuntos, $a = a^2 - a^1 \neq 0$. Usando propiedades de proyección para a^1 y a^2 , se demuestra que $\langle a, x^1 \rangle \leq \langle a, a^1 \rangle < \langle a, a^2 \rangle \leq \langle a, x^2 \rangle$, permitiendo una separación estricta con c en el punto medio. ■

Proposición 3.12. Sea $K \subset \mathbb{R}^n$ un cono cualquiera. Se tiene:

$$(K^*)^* = \text{cl conv } K.$$

Si D es convexo y $\bar{x} \in D$, $(\mathcal{N}_D(\bar{x}))^* = \mathcal{T}_D(\bar{x})$.

Prueba. Por definición, $\text{cl conv } K \subset (K^*)^*$. Si $x \notin \text{cl conv } K$, por separación estricta (Teorema 3.11), existe $a \neq 0$ tal que $\langle a, x \rangle > c > \langle a, d \rangle$ para todo $d \in \text{cl conv } K$. Tomando $d = 0$ resulta $c > 0$, por lo que $\langle a, x \rangle > 0$. Para $d \in K$, se deduce que $\langle a, d \rangle \leq 0$ (de lo contrario la semirrecta rompería la cota c). Así, $a \in K^*$, lo que muestra que $x \notin (K^*)^*$. La última afirmación sigue de identificar $\mathcal{N}_D(\bar{x}) = \mathcal{T}_D(\bar{x})^*$. ■

3.2.5. Puntos Extremos

Definición 3.13 (Punto extremo). Decimos que $x \in D$ es un **punto extremo** del conjunto convexo D cuando no puede ser representado por una combinación convexa de dos puntos diferentes de D (es decir, $x = \alpha x^1 + (1 - \alpha)x^2 \implies x = x^1 = x^2$). Denotamos el conjunto por $E(D)$.

Lema 3.4. Sea $D \subset \mathbb{R}^n$ un conjunto convexo no vacío y C un semiespacio cerrado tal que $D \subset C$. Entonces $E(D \cap \text{fr } C) \subset E(D)$.

Prueba. Sea $\bar{x} \in E(D \cap \text{fr } C)$. Si $\bar{x} = \alpha x^1 + (1 - \alpha)x^2$ para $x^i \in D$, evaluando el producto interno que define el hiperplano $\text{fr } C$ se deduce que ambos x^i deben yacer exactamente en la frontera, forzando a que $x^i \in D \cap \text{fr } C$, y por la extremidad relativa, $x^1 = x^2$. ■

Proposición 3.13. Sea $D \subset \mathbb{R}^n$ convexo, cerrado y no vacío. D tiene puntos extremos ($E(D) \neq \emptyset$) si, y solamente si, D no contiene ninguna recta.

Prueba. Si D contiene una recta que pasa por x , x se puede escribir como el punto medio de $x + d$ y $x - d$, por lo que no es extremo. El recíproco se demuestra por inducción en la dimensión n , interceptando el conjunto con hiperplanos de soporte y utilizando el Lema 3.4. ■

Teorema 3.12 (Teorema de Krein-Milman). Sea $D \subset \mathbb{R}^n$ un conjunto convexo compacto. Entonces:

$$D = \text{conv } E(D).$$

Prueba. Por inducción en n . Para $n = 1$ es obvio. Supongamos válido en $\mathbb{R}^n$. Para $D \subset \mathbb{R}^{n+1}$, si $\bar{x} \in \text{fr } D$, el hiperplano de soporte reduce la dimensión del problema, y por hipótesis inductiva y el Lema 3.4, $\bar{x}$ se forma por extremos de D . Si $\bar{x} \in \text{int } D$, cualquier recta que pase por $\bar{x}$ corta a la frontera en dos puntos (por compacidad); como $\bar{x}$ es combinación convexa de ellos, queda probado. ■

Proposición 3.14. Sea $x \in D$, donde $D = \{x \in \mathbb{R}^n \mid B_i x \leq b_i\}$ es un conjunto poliédrico. Entonces x es un vértice (punto extremo) de D si, y solamente si, las filas correspondientes a las restricciones activas ($I(x)$) tienen rango n .

Prueba. Si el rango es n , una perturbación $x \pm d$ viola las restricciones activas salvo que $d = 0$. Si el rango es menor que n , existe $d \in \ker B_I \setminus \{0\}$. Un desplazamiento $x \pm td$ se mantiene en la cara activa, demostrando que x no es extremo. ■

Corolario 3.4. El número de vértices de un conjunto poliédrico cualquiera es finito.

Teorema 3.13 (Representación de conjuntos poliédricos sin rectas). Sea D un conjunto poliédrico que no contiene ninguna recta. Entonces:

$$D = \text{conv } E(D) + \mathcal{R}_D.$$

3.3. Teoremas de alternativa

A continuación, consideramos sistemas de ecuaciones e inecuaciones lineales, relacionados en el sentido de que existen dos alternativas: si un sistema no posee soluciones, entonces el otro posee soluciones, y ambos sistemas no pueden poseer soluciones simultáneamente. Un resultado de este tipo será usado para caracterizar el cono dual del cono tangente en el caso de restricciones mixtas de igualdad y desigualdad y para formular las condiciones de optimalidad en forma primal-dual para problemas con este tipo de restricciones.

Teorema 3.14 (Teorema de la Alternativa de Motzkin). Para cualesquiera matrices $A_i \in \mathbb{R}^{m_i \times n}$, $i = 0, 1, 2$, con $A_0 \neq 0$, uno, y solamente uno, de los dos sistemas siguientes posee solución:

$$A_0 x > 0, \quad A_1 x = 0, \quad A_2 x \geq 0, \quad x \in \mathbb{R}^n, \quad (3.9)$$

o

$$\begin{aligned} A_0^T y^0 + A_1^T y^1 + A_2^T y^2 &= 0, \\ (y^0, y^1, y^2) &\in (\mathbb{R}_+^{m_0} \setminus \{0\}) \times \mathbb{R}^{m_1} \times \mathbb{R}_+^{m_2}. \end{aligned} \quad (3.10)$$

Prueba. Primero supongamos que (3.10) tenga una solución (y^0, y^1, y^2) . Si x fuese solución de (3.9), entonces:

$$0 = \langle A_0^T y^0 + A_1^T y^1 + A_2^T y^2, x \rangle = \langle y^0, A_0 x \rangle + \langle y^1, A_1 x \rangle + \langle y^2, A_2 x \rangle \geq \langle y^0, A_0 x \rangle > 0,$$

donde para obtener la primera desigualdad usamos el hecho de que todas las coordenadas de los vectores involucrados son no negativas, y para obtener la segunda usamos además los hechos de que $y_i^0 \geq 0$, $(A_0 x)_i > 0 \forall i$, y para algún índice la coordenada de y^0 es estrictamente positiva. La contradicción muestra que cuando (3.10) tiene solución, (3.9) no puede tenerla.

Supongamos ahora que (3.10) no tenga solución. Es decir,

$$0 \notin \left\{ z \in \mathbb{R}^n \mid \begin{array}{l} z = A_0^T y^0 + A_1^T y^1 + A_2^T y^2, \\ y^0 \in \mathbb{R}_+^{m_0} \setminus \{0\}, y^1 \in \mathbb{R}^{m_1}, y^2 \in \mathbb{R}_+^{m_2} \end{array} \right\}.$$

Como $y^0 \in \mathbb{R}_+^{m_0} \setminus \{0\}$, dividiendo z por $\sum y_i^0 > 0$, vemos que esta propiedad es equivalente a $0 \notin D$, donde $D = D_1 + D_2$, con:

$$D_1 = \left\{ z \in \mathbb{R}^n \mid z = A_0^T y^0, y^0 \in \mathbb{R}_+^{m_0}, \sum_{i=1}^{m_0} y_i^0 = 1 \right\},$$

$$D_2 = \{ z \in \mathbb{R}^n \mid z = A_1^T y^1 + A_2^T y^2, y^1 \in \mathbb{R}^{m_1}, y^2 \in \mathbb{R}_+^{m_2} \}.$$

El conjunto D_1 es la clausura convexa de las columnas de A_0^T (que son finitas), por lo tanto, es compacto. El conjunto D_2 es un cono con un número finito de generadores; por lo tanto, es convexo y cerrado. La suma $D = D_1 + D_2$ es un conjunto convexo y cerrado (al sumar un compacto y un cerrado).

Como $0 \notin D$, por el Teorema de Separación Estricta, existe un hiperplano que separa 0 de D estrictamente; es decir, existe $x \in \mathbb{R}^n \setminus \{0\}$ y $c \in \mathbb{R}$ tales que:

$$\langle x, z \rangle > c > 0 \quad \forall z \in D.$$

Como D_2 es un cono, si existiera $y \in D_2$ tal que $\langle x, y \rangle < 0$, tomando múltiplos grandes contradeciríamos la separación. Así, $\langle x, y \rangle \geq 0$ para todo $y \in D_2$, lo que implica:

$$A_1 x = 0, \quad A_2 x \geq 0.$$

Finalmente, tomando $y^0 = e^i$ (vectores de la base canónica), deducimos que $\langle e^i, A_0 x \rangle > c > 0$, lo que implica $A_0 x > 0$. Hemos hallado una solución para (3.9). ■

El famoso Lema de Farkas se obtiene como una consecuencia del Teorema de Motzkin.

Lema 3.5 (Lema de Farkas). Para cualquier matriz $A \in \mathbb{R}^{m \times n}$ y cualquier $b \in \mathbb{R}^n$, uno, y solamente uno, de los siguientes sistemas posee solución:

$$Ax \leq 0, \quad \langle b, x \rangle > 0, \quad x \in \mathbb{R}^n, \quad (3.11)$$

o

$$A^T y = b, \quad y \in \mathbb{R}_+^m. \quad (3.12)$$

Prueba. Aplicando el Teorema de Motzkin (Teorema 3.14) con las elecciones $A_0 = b^T \in \mathbb{R}^{1 \times n}$ y $A_2 = -A \in \mathbb{R}^{m \times n}$ (y sin matriz A_1), la alternativa a (3.11) es:

$$y^0 b - A^T y^2 = 0, \quad (y^0, y^2) \in (\mathbb{R}_+ \setminus \{0\}) \times \mathbb{R}_+^m.$$

Como $y^0 > 0$, dividiendo por y^0 y llamando $y = y^2/y^0$, obtenemos exactamente el sistema (3.12). ■

El Lema de Farkas ya permite probar las condiciones de optimalidad en forma primal-dual en el caso especial de restricciones de desigualdad lineales.

Corolario 3.5. Sea $\bar{x} \in \mathbb{R}^n$ una solución local del problema $\min f(x)$ sujeto a $Bx \leq b$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es diferenciable en $\bar{x}$, $B \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Entonces existe $\bar{\mu} \in \mathbb{R}_+^m$ tal que

$$\nabla f(\bar{x}) + B^T \bar{\mu} = 0, \quad \bar{\mu}_i = 0 \text{ para } i \notin I(\bar{x}),$$

donde $I(\bar{x}) = \{i \mid \langle B_i, \bar{x} \rangle = b_i\}$.

Prueba. Sea $C = \{d \in \mathbb{R}^n \mid \langle B_i, d \rangle \leq 0, i \in I(\bar{x})\}$. Para todo $d \in C$, se tiene que $B(\bar{x} + td) \leq b$ para todo $t > 0$ suficientemente pequeño, por lo tanto $d \in \mathcal{V}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$. Por el Teorema de la condición necesaria primal (Teorema 1.5), $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in C$.

Es decir, el sistema $\langle \nabla f(\bar{x}), d \rangle < 0, \langle B_i, d \rangle \leq 0$ para $i \in I(\bar{x})$ no tiene solución. Por el Lema de Farkas (Lema 3.5), el sistema alternativo $(B_{I(\bar{x})})^T \mu = -\nabla f(\bar{x})$ con $\mu \in \mathbb{R}_+^{|I(\bar{x})|}$ tiene solución. Definiendo $\bar{\mu}_i = 0$ para $i \notin I(\bar{x})$, obtenemos el resultado. ■

Nota: Otros Teoremas de Alternativa

Existen otros teoremas clásicos de alternativa que surgen como variantes lógicas del Lema de Farkas y el Teorema de Motzkin, muy útiles en teoría de juegos y economía matemática:

- **Teorema de Tucker:** Los sistemas $Ax \geq 0, Ax \neq 0$ y $A^T y = 0, y > 0$ son mutuamente excluyentes.
- **Teoremas de Gale:** Alternativas puras sobre igualdades/desigualdades (ej. $Ax = b, x \geq 0$ vs $A^T y \geq 0, \langle b, y \rangle < 0$).
- **Teorema de Gordan:** $Ax < 0$ vs $A^T y = 0, y \in \mathbb{R}_+^m \setminus \{0\}$.

(Las demostraciones de estos teoremas se proponen como ejercicios en la sección final de este capítulo).

3.4. Funciones convexas

Ahora estudiaremos funciones convexas con más profundidad. Trataremos la estructura de estas funciones, caracterizaciones para funciones diferenciables, continuidad, y el concepto de subdiferencial para funciones no diferenciables.

3.4.1. Propiedades básicas de las funciones convexas

Mostramos primero que una suma de múltiplos no negativos de un número finito de funciones convexas es convexa, así como el supremo.

Proposición 3.15 (Convexidad de la suma y el supremo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y sean $f_i : D \rightarrow \mathbb{R}$ funciones convexas en D .

1. Para cualesquiera $\mu_i \in \mathbb{R}_+$, la función $f(x) = \sum_{i=1}^p \mu_i f_i(x)$ es convexa en D .
2. Si I es un conjunto de índices arbitrario (posiblemente infinito) y existe $\beta \in \mathbb{R}$ tal que $f_i(x) \leq \beta$ para todo $x \in D$ e $i \in I$, entonces la función $f(x) = \sup_{i \in I} f_i(x)$ es convexa en D .

Prueba. (1) Para $x, y \in D$ y $\alpha \in [0, 1]$, se tiene $f(\alpha x + (1-\alpha)y) = \sum \mu_i f_i(\alpha x + (1-\alpha)y) \leq \sum \mu_i (\alpha f_i(x) + (1-\alpha)f_i(y)) = \alpha f(x) + (1-\alpha)f(y)$, ya que $\mu_i \geq 0$.

(2) El epígrafe de un supremo de funciones es la intersección de los epígrafes individuales: $E_f = \{(x, c) \mid \sup f_i(x) \leq c\} = \bigcap_{i \in I} \{(x, c) \mid f_i(x) \leq c\} = \bigcap_{i \in I} E_{f_i}$. Al ser f_i convexas, los E_{f_i} son convexos, y la intersección de conjuntos convexos es convexa. Luego, el epígrafe E_f es convexo, lo que implica que f es convexa. ■

Proposición 3.16 (Composición convexa). Sean $g : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa, y $\psi : \mathbb{R} \rightarrow \mathbb{R}$ una función convexa y no decreciente. Entonces la composición $f(x) = \psi(g(x))$ es convexa en $\mathbb{R}^n$.

Prueba. Por convexidad de g y monotonía de ψ , se tiene $\psi(g(\alpha x + (1-\alpha)y)) \leq \psi(\alpha g(x) + (1-\alpha)g(y))$. Luego, por la convexidad de ψ , esto es $\leq \alpha \psi(g(x)) + (1-\alpha)\psi(g(y))$, demostrando la afirmación. ■

A continuación, mostraremos que los conjuntos de nivel de una función convexa son conjuntos convexos.

Teorema 3.15 (Convexidad de conjuntos de nivel). Supongamos que el conjunto $D \subset \mathbb{R}^n$ sea convexo y la función $f : D \rightarrow \mathbb{R}$ sea convexa en D . Entonces el conjunto de nivel

$$L_{f,D}(c) = \{x \in D \mid f(x) \leq c\}$$

es convexo para todo $c \in \mathbb{R}$.

Prueba. Sean $x, y \in L_{f,D}(c)$. Por definición, $f(x) \leq c$ y $f(y) \leq c$. Por convexidad de D y f , para todo $\alpha \in [0, 1]$ se tiene que $f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha)f(y) \leq \alpha c + (1-\alpha)c = c$. Luego $\alpha x + (1-\alpha)y \in L_{f,D}(c)$. ■

Observación. La convexidad de todos los conjuntos de nivel no es suficiente para afirmar que la función es convexa. Las funciones que cumplen la propiedad de tener todos sus conjuntos de nivel convexos se denominan **funciones cuasiconvexas**. Un ejemplo clásico es $f(x) = x^3$ en $\mathbb{R}$, cuyos conjuntos de nivel son intervalos (luego, convexos), pero la función no es convexa.

Teorema 3.16 (Continuidad de funciones convexas). Sean $D \subset \mathbb{R}^n$ un conjunto convexo abierto y $f : D \rightarrow \mathbb{R}$ convexa. Entonces f es localmente Lipschitz-continua en D . En particular, es continua en D .

Nota de Demostración. La prueba formal construye un simplex cerrado (caja) contenido en D en torno a un punto de interés y utiliza la convexidad para acotar superior e inferiormente las variaciones de f , limitando la constante de Lipschitz mediante el valor máximo de la función en los vértices del simplex. (Ver referencias estándar de Análisis Convexo). ■

El siguiente resultado es crucial computacionalmente, ya que garantiza que si un problema fuertemente convexo tiene solución, el conjunto de nivel se mantiene acotado.

Teorema 3.17 (Compacidad del nivel de funciones fuertemente convexas). Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es fuertemente convexa, entonces para todo $c \in \mathbb{R}$, el conjunto de nivel $L_{f,\mathbb{R}^n}(c)$ es compacto.

Corolario 3.6. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ fuertemente convexa y $\emptyset \neq D \subset \mathbb{R}^n$ un conjunto cerrado. Entonces f tiene un minimizador en D . Si D es convexo, el minimizador es único.

Finalizamos esta subsección con resultados de maximización. El problema de maximizar una función convexa sobre un conjunto convexo tiene una naturaleza diferente al de minimización: la solución tiende a ubicarse en la frontera o vértices.

Teorema 3.18 (Maximización de función convexa). Sea $D \subset \mathbb{R}^n$ convexo compacto y $f : D \rightarrow \mathbb{R}$ convexa. Entonces el problema $\max_{x \in D} f(x)$ tiene solución y se alcanza en un **punto extremo** de D (es decir, en $E(D)$).

Además, si D es polédrico y no contiene rectas, el máximo (si existe) se alcanza en un vértice de D .

3.4.2. Funciones convexas diferenciables

Cuando una función es diferenciable, la convexidad admite varias caracterizaciones algebraicas muy útiles.

Teorema 3.19 (Caracterizaciones de convexidad diferenciable). Sean $D \subset \mathbb{R}^n$ abierto y convexo, y $f : D \rightarrow \mathbb{R}$ diferenciable. Las siguientes propiedades son equivalentes:

1. f es convexa en D .
2. (Desigualdad del subgradiente): Para todo $x, y \in D$, $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$.
3. (Monotonía del gradiente): Para todo $x, y \in D$, $\langle \nabla f(y) - \nabla f(x), y - x \rangle \geq 0$.

Si f es dos veces diferenciable en D , las anteriores son equivalentes a:

4. La matriz Hessiana $\nabla^2 f(x)$ es semidefinida positiva en todo punto de D .

Prueba. (1) $\implies$ (2): Por convexidad, $f(x + \alpha(y - x)) \leq (1 - \alpha)f(x) + \alpha f(y)$. Reorganizando: $f(y) - f(x) \geq \frac{f(x + \alpha(y - x)) - f(x)}{\alpha}$. Tomando límite $\alpha \rightarrow 0^+$, el lado derecho es la derivada direccional $\langle \nabla f(x), y - x \rangle$.
 (2) $\implies$ (3): Evaluando (2) intercambiando x e y : $f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle$. Sumando ambas desigualdades se obtiene $0 \geq \langle \nabla f(x), y - x \rangle + \langle \nabla f(y), x - y \rangle$, de donde se deduce (3).
 (3) $\implies$ (1): Por el Teorema del Valor Medio, integrando la monotonía del gradiente en un segmento se deduce que la función yace por encima de cualquier secante. (La equivalencia con la Hessiana sigue de las propiedades clásicas de formas cuadráticas). ■

Observación (Condiciones para fuerte convexidad). Para funciones fuertemente convexas con módulo $\gamma > 0$, las caracterizaciones se adaptan:

- $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \gamma \|y - x\|^2$.
- $\langle \nabla f(y) - \nabla f(x), y - x \rangle \geq 2\gamma \|y - x\|^2$.
- $\langle \nabla^2 f(x)d, d \rangle \geq 2\gamma \|d\|^2$ (es decir, los autovalores de la Hessiana están acotados por 2γ).

Como ya sabemos, en un problema de minimización convexo, todo minimizador local es global. El siguiente teorema muestra que la condición necesaria de primer orden (Teorema 3.3) pasa a ser suficiente.

Teorema 3.20 (Condiciones KKT para problema convexo). Sean $D \subset \mathbb{R}^n$ convexo y f convexa y diferenciable en un abierto que contiene a D . Un punto $\bar{x} \in D$ es minimizador global si, y solo si:

$$\langle \nabla f(\bar{x}), x - \bar{x} \rangle \geq 0 \quad \forall x \in D \iff -\nabla f(\bar{x}) \in \mathcal{N}_D(\bar{x}).$$

Prueba. La necesidad ya fue demostrada en el Capítulo 1 (Teorema 1.2). Para la suficiencia, usamos la caracterización (2) del Teorema 3.19: $f(x) \geq f(\bar{x}) + \langle \nabla f(\bar{x}), x - \bar{x} \rangle$. Si la condición se cumple, el segundo término es ≥ 0 para todo $x \in D$, luego $f(x) \geq f(\bar{x})$, lo que prueba que $\bar{x}$ es mínimo global. ■

3.4.3. Funciones convexas no diferenciables

Cuando una función convexa pierde la diferenciable (por ejemplo, al tomar el supremo de varias funciones), las derivadas clásicas se reemplazan por derivadas direccionales y subdiferenciales.

Teorema 3.21 (Derivada direccional). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. Entonces para todo $x, d \in \mathbb{R}^n$, el límite

$$f'(x; d) = \lim_{\alpha \rightarrow 0^+} \frac{f(x + \alpha d) - f(x)}{\alpha}$$

siempre existe en $\mathbb{R} \cup \{-\infty, +\infty\}$. (Si f es finita, el límite es finito).

Definición 3.14 (Subgradiente y Subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. Decimos que un vector $y \in \mathbb{R}^n$ es un **subgradiente** de f en el punto x si:

$$f(z) \geq f(x) + \langle y, z - x \rangle \quad \forall z \in \mathbb{R}^n. \quad (3.13)$$

Al conjunto de todos los subgradiientes de f en x se le llama **subdiferencial** y se denota por $\partial f(x)$.

Geoméricamente, un subgradiente define un hiperplano afín que soporta al epígrafe de f en el punto $(x, f(x))$ y queda por debajo de la gráfica de la función globalmente.

Teorema 3.22 (Propiedades del Subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa finita en todo el espacio.

1. El conjunto $\partial f(x)$ es convexo, compacto y no vacío para todo $x \in \mathbb{R}^n$.
2. $\bar{x}$ es un minimizador global de f en $\mathbb{R}^n$ si, y solo si, $0 \in \partial f(\bar{x})$.
3. Para un conjunto D convexo cerrado, $\bar{x}$ es solución de $\min_{x \in D} f(x)$ si y solo si $0 \in \partial f(\bar{x}) + \mathcal{N}_D(\bar{x})$.
4. (Regla de la suma): Si f_1, f_2 son convexas en $\mathbb{R}^n$, entonces $\partial(f_1 + f_2)(x) = \partial f_1(x) + \partial f_2(x)$.

Prueba. El ítem (2) es inmediato de la definición (3.13): si $0 \in \partial f(\bar{x})$, entonces $f(z) \geq f(\bar{x}) + \langle 0, z - \bar{x} \rangle = f(\bar{x})$, por lo que $\bar{x}$ es óptimo global. Las demás pruebas requieren teoremas de separación que se omiten aquí por brevedad, pero que siguen estándares del análisis convexo de Rockafellar. ■

Teorema 3.23 (Relación entre derivada direccional y subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. La derivada direccional en x a lo largo de d equivale al máximo del producto interno sobre el subdiferencial:

$$f'(x; d) = \max_{y \in \partial f(x)} \langle y, d \rangle.$$

Finalmente, para el desarrollo de algoritmos de optimización no diferenciable, es útil relajar la noción de subgradiente.

Definición 3.15 (ϵ -subdiferencial). Para $\epsilon \geq 0$, el vector y es un ϵ -subgradiente de f en x si:

$$f(z) \geq f(x) + \langle y, z - x \rangle - \epsilon \quad \forall z \in \mathbb{R}^n.$$

El conjunto de todos los ϵ -subgradiientes se denota $\partial_\epsilon f(x)$. $\bar{x}$ es un ϵ -minimizador del problema si y solo si $0 \in \partial_\epsilon f(\bar{x})$.

Ejercicios del Capítulo

Parte I: Teoremas de Alternativa

Ejercicio 3.1 (Teorema de Tucker). Pruebe el Teorema de la Alternativa de Tucker: Para cualesquiera matrices A_i , $i = 0, 1, 2$, con $A_0 \neq 0$, uno y solo uno de los sistemas posee solución:

$$A_0 x \geq 0 \text{ (con } A_0 x \neq 0), \quad A_1 x = 0, \quad A_2 x \geq 0, \quad x \in \mathbb{R}^n;$$

o

$$A_0^\top y^0 + A_1^\top y^1 + A_2^\top y^2 = 0, \quad y^0 > 0, \quad y^2 \geq 0.$$

Ejercicio 3.2 (Teoremas de Gale I y II). Demuestre los Teoremas de Alternativa de Gale:

1. $Ax = a$ ($x \geq 0$) vs $A^\top y \geq 0$ ($\langle a, y \rangle < 0$).
2. $Ax \leq a$ ($x \geq 0$) vs $A^\top y \geq 0$ ($\langle a, y \rangle < 0, y \geq 0$).

Ejercicio 3.3 (Teoremas de Gordan y Stiemke). Demuestre los Teoremas de Alternativa:

1. **Gordan:** $Ax < 0$ vs $A^\top y = 0$ ($y \geq 0, y \neq 0$).
2. **Stiemke:** $Ax \leq 0$ ($Ax \neq 0$) vs $A^\top y = 0$ ($y > 0$).

Parte II: Análisis Convexo

Ejercicio 3.4 (Desigualdad de la media y Cobb-Douglas). Sean $\alpha_i > 0$, $i = 1, \dots, p$. Probar utilizando propiedades de funciones convexas:

$$\frac{1}{p} \sum_{i=1}^p \alpha_i \geq \left(\prod_{i=1}^p \alpha_i \right)^{1/p}.$$

Ejercicio 3.5 (Módulo de convexidad fuerte). Probar que la función $f(x) = \|x\|^2$ es fuertemente convexa con módulo $\gamma = 1$.

Ejercicio 3.6 (Linealidad afín). Sea f una función convexa y al mismo tiempo cóncava en $\mathbb{R}^n$. Mostrar que esto implica que f es una función afín (es decir, $f(x) = \langle a, x \rangle + c$).

Ejercicio 3.7 (Condiciones paramétricas de convexidad). ¿Para qué valores del parámetro $\sigma \in \mathbb{R}$ la función $f(x) = (\sigma + 6)x_1^2 + 2\sigma x_1 x_2 + x_2^2$ es convexa en $\mathbb{R}^2$?

Ejercicio 3.8 (Funciones generadoras convexas). Probar que las siguientes funciones son convexas en $\mathbb{R}^n$:

1. $f(x) = \ln\left(\sum_{i=1}^n e^{x_i}\right)$.
2. $f(x) = e^{\langle Qx, x \rangle}$, donde Q es una matriz simétrica y semidefinida positiva.

Ejercicio 3.9 (Minimización analítica en cajas). Resolver de forma analítica el problema $\min f(x)$ sujeto a $x \in D$:

1. $f(x) = 2x_1^2 + 4x_2^2 - 5x_1 x_2$, $D = \{x \in \mathbb{R}^2 \mid 0 \leq x_1 \leq 1, 0 \leq x_2 \leq 1\}$.
2. $f(x) = 4x_1^2 - x_1 x_2 + 2x_2^2$, $D = \{x \in \mathbb{R}^2 \mid 4 \leq x_1 \leq 8, -1 \leq x_2 \leq 2\}$.

Ejercicio 3.10 (Operaciones que preservan convexidad). Probar que la función $f(x) = \max\{e^x, x^2\} + 1/x$ es convexa en el dominio $\mathbb{R}_+ \setminus \{0\}$.

4. capítulo 4

En este capítulo contamos con las herramientas necesarias para abordar el problema de optimización general con restricciones mixtas de igualdad y desigualdad. Estudiaremos la caracterización del cono tangente para los conjuntos definidos por este tipo de restricciones, lo que nos permitirá derivar las condiciones de optimalidad primal-dual de Karush-Kuhn-Tucker (KKT). Asimismo, desarrollaremos las condiciones necesarias y suficientes de segundo orden.

Consideramos el problema de optimización con restricciones mixtas de igualdad y desigualdad:

$$\min f(x) \quad \text{sujeto a} \quad x \in D, \quad (4.1)$$

donde el conjunto factible está dado por:

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\}, \quad (4.2)$$

y $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones dadas.

Nota: Transformación a restricciones de igualdad

Como se mencionó en el Capítulo 1, es posible convertir el problema (4.1)-(4.2) en uno con restricciones exclusivas de igualdad, introduciendo variables de holgura $\sigma \in \mathbb{R}^m$ mediante la siguiente transformación:

$$\tilde{D} = \left\{ (x, \sigma) \in \mathbb{R}^n \times \mathbb{R}^m \mid \begin{array}{l} h(x) = 0, \\ g_i(x) + \sigma_i^2 = 0, \quad i = 1, \dots, m. \end{array} \right\}.$$

Sin embargo, esta aproximación exige hipótesis de regularidad más restrictivas y produce condiciones de optimalidad de segundo orden más débiles que las obtenidas al estudiar las desigualdades de forma directa.

Para el estudio local del problema, es necesario identificar cuáles restricciones de desigualdad determinan la frontera del conjunto factible en un punto dado.

Definición 4.1 (Restricciones activas). Sea $\bar{x} \in D$. Diremos que la restricción de desigualdad correspondiente al índice $i \in \{1, \dots, m\}$ es **activa** en el punto $\bar{x}$ cuando $g_i(\bar{x}) = 0$.

El conjunto de índices de las restricciones activas en el punto $\bar{x} \in D$ se denota por:

$$I(\bar{x}) = \{i \in \{1, \dots, m\} \mid g_i(\bar{x}) = 0\}.$$

Notación. Las restricciones de igualdad no se incluyen en esta definición puesto que, por la propia definición del conjunto D , siempre se satisfacen como igualdades en cualquier punto factible.

4.1. Cono tangente en el caso de restricciones de igualdad y desigualdad

Por continuidad, un minimizador local $\bar{x}$ del problema (4.1)-(4.2) también es minimizador local del problema relajado que omite las restricciones inactivas en $\bar{x}$. Geométricamente, las restricciones activas determinan el comportamiento local del conjunto factible en torno a $\bar{x}$ y, por ende, son las únicas relevantes para el análisis diferencial.

Definición 4.2 (Cono de linealización). Supongamos que h y g son diferenciables en $\bar{x} \in D$. Se define el **cono de linealización** en $\bar{x}$ para las restricciones de igualdad y las desigualdades activas, denotado por $\mathcal{H}(\bar{x})$, como:

$$\mathcal{H}(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} \langle \nabla h_i(\bar{x}), d \rangle = 0, \quad i = 1, \dots, l \\ \langle \nabla g_i(\bar{x}), d \rangle \leq 0, \quad \forall i \in I(\bar{x}) \end{array} \right\}. \quad (4.3)$$

De manera equivalente, utilizando la matriz Jacobiana J_h :

$$\mathcal{H}(\bar{x}) = \{d \in \ker J_h(\bar{x}) \mid \langle \nabla g_i(\bar{x}), d \rangle \leq 0 \quad \forall i \in I(\bar{x})\}.$$

Ejemplo 4.1 (Cálculo del cono de linealización). Considérese el conjunto factible en $\mathbb{R}^2$ delimitado por una parábola y el eje horizontal:

$$D = \left\{ x \in \mathbb{R}^2 \mid \begin{array}{l} g_1(x) = x_2 - x_1^2 \leq 0 \\ g_2(x) = -x_2 \leq 0 \end{array} \right\}.$$

El conjunto D consta de un único punto factible, $\bar{x} = (0, 0)^\top$.

Para determinar el cono de linealización $\mathcal{H}(\bar{x})$, evaluamos las restricciones en el origen: $g_1(0, 0) = 0$ y $g_2(0, 0) = 0$, por lo que $I(\bar{x}) = \{1, 2\}$. Los gradientes son:

$$\nabla g_1(\bar{x}) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \nabla g_2(\bar{x}) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}.$$

Por la Definición 4.2, un vector $d = (d_1, d_2)^\top$ pertenece a $\mathcal{H}(\bar{x})$ si satisface:

$$\langle \nabla g_1(\bar{x}), d \rangle = d_2 \leq 0 \quad \text{y} \quad \langle \nabla g_2(\bar{x}), d \rangle = -d_2 \leq 0 \implies d_2 \geq 0.$$

El sistema implica que $d_2 = 0$. La coordenada d_1 no está acotada por las restricciones linealizadas. En consecuencia:

$$\mathcal{H}(\bar{x}) = \left\{ \begin{pmatrix} d_1 \\ 0 \end{pmatrix} \mid d_1 \in \mathbb{R} \right\}.$$

Este caso ilustra una discrepancia entre la topología y el álgebra: el cono tangente geométrico es $\mathcal{T}_D(\bar{x}) = \{0\}$, mientras que el cono de linealización $\mathcal{H}(\bar{x})$ es una recta completa.

Proposición 4.1 (Inclusión de conos). Sea $D \subset \mathbb{R}^n$ el conjunto definido en (4.2). Si las funciones $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son diferenciables en $\bar{x} \in D$, entonces los conos tangentes están contenidos en el cono de linealización:

$$\mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x}) \subset \mathcal{H}(\bar{x}).$$

Prueba. La inclusión $\mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$ es una propiedad topológica general. Para la segunda inclusión, es inmediato que $0 \in \mathcal{B}_D(\bar{x}) \cap \mathcal{H}(\bar{x})$.

Sea $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. Existen sucesiones $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$ para todo $k \in \mathbb{N}$. La condición de factibilidad exige que para todo k :

$$h(\bar{x} + t_k d^k) = 0 \quad \text{y} \quad g_i(\bar{x} + t_k d^k) \leq 0 \quad \forall i \in I(\bar{x}).$$

Utilizando el desarrollo de Taylor de primer orden en $\bar{x}$:

$$\begin{aligned} 0 &= h(\bar{x} + t_k d^k) - h(\bar{x}) = t_k J_h(\bar{x}) d^k + o(t_k \|d^k\|), \\ 0 &\geq g_i(\bar{x} + t_k d^k) - g_i(\bar{x}) = t_k \langle \nabla g_i(\bar{x}), d^k \rangle + o(t_k \|d^k\|). \end{aligned}$$

Dividiendo por $t_k > 0$ y tomando el límite cuando $k \rightarrow \infty$, se sigue que $d^k \rightarrow d$ y el término residual $\frac{o(t_k \|d^k\|)}{t_k} \rightarrow 0$. Se obtiene:

$$J_h(\bar{x})d = 0 \quad \text{y} \quad \langle \nabla g_i(\bar{x}), d \rangle \leq 0 \quad \forall i \in I(\bar{x}),$$

lo cual demuestra que $d \in \mathcal{H}(\bar{x})$. ■

Contraejemplo 4.1 (Falta de regularidad e inclusión estricta). El siguiente ejemplo muestra que la igualdad $\mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$ requiere hipótesis adicionales. Sea $D \subset \mathbb{R}^2$ definido por:

$$g(x) = -x_1^3 + x_2^2 \leq 0.$$

En el origen $\bar{x} = (0, 0)^\top \in D$, la restricción es activa y su gradiente es $\nabla g(\bar{x}) = (0, 0)^\top$. El cono de linealización es todo el espacio:

$$\mathcal{H}(\bar{x}) = \{d \in \mathbb{R}^2 \mid \langle (0, 0)^\top, d \rangle \leq 0\} = \mathbb{R}^2.$$

Sin embargo, el conjunto D presenta una cúspide orientada hacia la dirección positiva del eje x_1 . La dirección $d = (-1, 0)^\top \in \mathcal{H}(\bar{x})$ no es tangente, ya que para cualquier $t > 0$, evaluando en la restricción se tiene $-(-t)^3 + 0^2 = t^3 > 0$, por lo que $\bar{x} + td \notin D$. Por tanto, $d \notin \mathcal{B}_D(\bar{x})$, verificándose la inclusión estricta $\mathcal{B}_D(\bar{x}) \subsetneq \mathcal{H}(\bar{x})$.

Ejemplo 4.2 (Igualdad de conos bajo regularidad). Considérese el conjunto en $\mathbb{R}^2$ definido por:

$$D = \left\{ x \in \mathbb{R}^2 \mid \begin{array}{l} h(x) = x_2 - x_1^2 = 0 \\ g(x) = x_1 \leq 0 \end{array} \right\}.$$

Tomemos el punto $\bar{x} = (0, 0)^\top$. La restricción de desigualdad es activa ($I(\bar{x}) = \{1\}$). Los gradientes en $\bar{x}$ son $\nabla h(\bar{x}) = (0, 1)^\top$ y $\nabla g(\bar{x}) = (1, 0)^\top$. El cono de linealización $\mathcal{H}(\bar{x})$ requiere $d_2 = 0$ y $d_1 \leq 0$, de donde $\mathcal{H}(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \leq 0\}$.

Para el cono de Bouligand $\mathcal{B}_D(\bar{x})$, dada una sucesión $t_k \rightarrow 0^+$, los puntos de D admiten la forma $(-t_k, t_k^2)^\top$. La dirección secante es:

$$d^k = \frac{1}{t_k} \begin{pmatrix} -t_k \\ t_k^2 \end{pmatrix} = \begin{pmatrix} -1 \\ t_k \end{pmatrix}.$$

En el límite $k \rightarrow \infty$, se obtiene $d = (-1, 0)^\top$. Por homotecia de conos, $\mathcal{B}_D(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \leq 0\}$. Para el cono tangente estricto $\mathcal{T}_D(\bar{x})$, la curva $x(t) = (-t, t^2)^\top$ contenida en D para $t \geq 0$ tiene por vector director $d = (-1, 0)^\top$. Por lo tanto, en este punto se verifica $\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$.

Lema 4.1 (Lema de Farkas Generalizado). Sea $K \subset \mathbb{R}^n$ un cono poliédrico definido por el sistema:

$$K = \{x \in \mathbb{R}^n \mid A_1 x = 0, A_2 x \leq 0\},$$

con matrices $A_1 \in \mathbb{R}^{m_1 \times n}$ y $A_2 \in \mathbb{R}^{m_2 \times n}$.

El cono dual K^* equivale al conjunto de combinaciones lineales de las filas de A_1 y A_2 , donde los coeficientes correspondientes a A_2 son no negativos:

$$K^* = \left\{ z \in \mathbb{R}^n \mid \begin{array}{l} z = A_1^\top \lambda + A_2^\top \mu, \\ \lambda \in \mathbb{R}^{m_1}, \mu \in \mathbb{R}_+^{m_2} \end{array} \right\}. \quad (4.4)$$

Prueba. Sea Q el conjunto de la ecuación (4.4). Para todo $z \in Q$ y todo $x \in K$, existen $\lambda \in \mathbb{R}^{m_1}$ y $\mu \in \mathbb{R}_+^{m_2}$ tales que $\langle z, x \rangle = \langle A_1^\top \lambda + A_2^\top \mu, x \rangle = \langle \lambda, A_1 x \rangle + \langle \mu, A_2 x \rangle$. Dado que $x \in K$, se satisface $A_1 x = 0$ y $A_2 x \leq 0$. Como $\mu \geq 0$, se concluye que $\langle \mu, A_2 x \rangle \leq 0$. Luego, $\langle z, x \rangle \leq 0$, lo que implica la inclusión $Q \subset K^*$.

Para demostrar la inclusión $K^* \subset Q$, supongamos que existe $\xi \in K^*$ tal que $\xi \notin Q$. Al ser Q un cono convexo cerrado, por el Teorema de Separación Estricta (o Lema de Motzkin), existe $x \in \mathbb{R}^n$ que separa ξ de Q : $\langle \xi, x \rangle > 0$ y $\langle z, x \rangle \leq 0$ para todo $z \in Q$. Evaluando la segunda condición: $\langle \lambda, A_1 x \rangle + \langle \mu, A_2 x \rangle \leq 0$ para todo $\lambda \in \mathbb{R}^{m_1}, \mu \in \mathbb{R}_+^{m_2}$. La pertenencia de λ a todo el espacio requiere que $A_1 x = 0$. La condición $\mu \geq 0$ exige que $A_2 x \leq 0$. En consecuencia, $x \in K$. Sin embargo, la desigualdad $\langle \xi, x \rangle > 0$ contradice la hipótesis $\xi \in K^*$, que exige $\langle \xi, x \rangle \leq 0$ para todo $x \in K$. Esta contradicción demuestra que $K^* \subset Q$. ■

Ejemplo 4.3 (Lema de Farkas en $\mathbb{R}^2$). Sea el cono poliédrico $K \subset \mathbb{R}^2$ definido por:

$$A_2 x \leq 0 \implies \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \leq \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies x_1 \geq 0, x_2 \geq 0.$$

El cono primal es $K = \mathbb{R}_+^2$. Por definición, $z \in K^*$ si $z_1 x_1 + z_2 x_2 \leq 0$ para todo $x \in \mathbb{R}_+^2$. Evaluando en la base canónica, se concluye $z_1 \leq 0$ y $z_2 \leq 0$, es decir, $K^* = \mathbb{R}_-^2$.

Aplicando el Lema 4.1, K^* se expresa mediante combinaciones cónicas de las filas de A_2 :

$$K^* = \left\{ \mu_1 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} \mid \mu_1, \mu_2 \geq 0 \right\} = \left\{ \begin{pmatrix} -\mu_1 \\ -\mu_2 \end{pmatrix} \mid \mu_1, \mu_2 \geq 0 \right\} = \mathbb{R}_-^2.$$

Lema 4.2 (Estructura Dual del Cono de Linealización). Sea $\mathcal{H}(\bar{x})$ el cono poliédrico definido en (4.3). El cono dual $\mathcal{H}(\bar{x})^*$ está dado por:

$$\mathcal{H}(\bar{x})^* = \left\{ y \in \mathbb{R}^n \mid \begin{array}{l} y = J_h(\bar{x})^\top \lambda + \sum_{i \in I(\bar{x})} \mu_i \nabla g_i(\bar{x}), \\ \lambda \in \mathbb{R}^l, \mu_i \geq 0 \quad \forall i \in I(\bar{x}) \end{array} \right\}. \quad (4.5)$$

Prueba. El resultado se sigue directamente de la aplicación del Lema de Farkas (Lema 4.1). Definiendo la matriz $A_1 = J_h(\bar{x}) \in \mathbb{R}^{l \times n}$ y construyendo A_2 a partir de los gradientes transpuestos $\nabla g_i(\bar{x})^\top$ para $i \in I(\bar{x})$, un vector $y \in \mathcal{H}(\bar{x})^*$ se descompone como $A_1^\top \lambda + A_2^\top \mu$, con $\mu \geq 0$. ■

Ejemplo 4.4 (Construcción del cono dual). Considérese el origen $\bar{x} = (0, 0, 0)^\top$ en el sistema:

$$D = \left\{ x \in \mathbb{R}^3 \mid \begin{array}{l} h(x) = x_1 - x_2 = 0 \\ g(x) = x_1 + x_2 + x_3 \leq 0 \end{array} \right\}.$$

La desigualdad es activa ($g(0) = 0$). Los gradientes en $\bar{x}$ son $\nabla h(\bar{x}) = (1, -1, 0)^\top$ y $\nabla g(\bar{x}) = (1, 1, 1)^\top$. El cono de linealización $\mathcal{H}(\bar{x})$ requiere $d_1 = d_2$ y $2d_1 + d_3 \leq 0$.

Por el Lema 4.2, su cono dual $\mathcal{H}(\bar{x})^*$ toma la forma:

$$y = \lambda \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} + \mu \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} \lambda + \mu \\ -\lambda + \mu \\ \mu \end{pmatrix}, \quad \lambda \in \mathbb{R}, \mu \geq 0.$$

El parámetro λ , asociado a la igualdad, no tiene restricción de signo y genera un subespacio. La variable μ , asociada a la desigualdad, está restringida a $\mu \geq 0$, lo que define la estructura cónica del conjunto dual.

Teorema 4.1 (Condición suficiente de primer orden). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferenciables en $\bar{x} \in D$. Sea $\mathcal{H}(\bar{x})$ el cono definido en (4.3).

Si se cumple la condición:

$$\langle \nabla f(\bar{x}), d \rangle > 0 \quad \forall d \in \mathcal{H}(\bar{x}) \setminus \{0\}, \quad (4.6)$$

entonces f satisface la **condición de crecimiento lineal** en $\bar{x}$: existen un entorno U de $\bar{x}$ y un escalar $\beta > 0$ tales que

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\| \quad \forall x \in D \cap U.$$

Por lo tanto, $\bar{x}$ es un minimizador local estricto de (4.1).

Prueba. Supongamos, por reducción al absurdo, que se cumple (4.6) pero la condición de crecimiento lineal es falsa. Esto implica la existencia de una sucesión $x^k \in D \setminus \{\bar{x}\}$ convergiendo a $\bar{x}$ tal que

$$f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|.$$

Sea $t_k = \|x^k - \bar{x}\| > 0$ y considérese la dirección normalizada $d^k = (x^k - \bar{x})/t_k$. Por la compacidad de la esfera unitaria, existe una subsucesión convergente $d^k \rightarrow d$, con $\|d\| = 1$ (es decir, $d \neq 0$). Por la definición de direcciones tangentes secuenciales, $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. La inclusión del Proposición 4.1 establece que $d \in \mathcal{H}(\bar{x}) \setminus \{0\}$.

Utilizando el desarrollo de Taylor de primer orden para f :

$$\frac{t_k}{k} > \langle \nabla f(\bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|) = t_k \langle \nabla f(\bar{x}), d^k \rangle + o(t_k).$$

Dividiendo entre t_k y tomando el límite $k \rightarrow \infty$, dado que $o(t_k)/t_k \rightarrow 0$ y $d^k \rightarrow d$, se sigue que $0 \geq \langle \nabla f(\bar{x}), d \rangle$. Este resultado contradice la hipótesis (4.6). Se concluye la existencia de crecimiento lineal, garantizando que $\bar{x}$ es un mínimo estricto. ■

Ejemplo 4.5 (Aplicación de la condición suficiente). Sea el problema:

$$\min f(x) = x_2 \quad \text{sujeto a} \quad D = \left\{ x \in \mathbb{R}^2 \mid \begin{array}{l} g_1(x) = x_1 - x_2 \leq 0 \\ g_2(x) = -x_1 - x_2 \leq 0 \end{array} \right\}.$$

En el origen $\bar{x} = (0, 0)^\top$, ambas restricciones son activas ($I(\bar{x}) = \{1, 2\}$). Los gradientes son $\nabla g_1(\bar{x}) = (1, -1)^\top$ y $\nabla g_2(\bar{x}) = (-1, -1)^\top$. El cono de linealización $\mathcal{H}(\bar{x})$ requiere $d_1 - d_2 \leq 0$ y $-d_1 - d_2 \leq 0$, lo que implica $d_2 \geq |d_1|$.

El gradiente objetivo es $\nabla f(\bar{x}) = (0, 1)^\top$. El producto interno para $d \in \mathcal{H}(\bar{x}) \setminus \{0\}$ es $\langle \nabla f(\bar{x}), d \rangle = d_2$. Al ser $d \neq 0$ y $d_2 \geq |d_1|$, se tiene que $d_2 > 0$. Por tanto, $\langle \nabla f(\bar{x}), d \rangle > 0$ para todo $d \in \mathcal{H}(\bar{x}) \setminus \{0\}$. La condición del Teorema 4.1 se verifica, garantizando que $\bar{x}$ es un mínimo local estricto.

Para caracterizar adecuadamente el cono tangente y establecer $\mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$, se requiere la introducción de condiciones de regularidad.

Definición 4.3 (Condiciones de regularidad). Se dice que el punto $\bar{x} \in D$ es **regular** (o cumple una cualificación de restricciones) si satisface alguna de las siguientes condiciones:

1. **Linealidad:** Las funciones h y g son afines:

$$h(x) = Ax - a, \quad A \in \mathbb{R}^{l \times n}, a \in \mathbb{R}^l; \quad g(x) = Bx - b, \quad B \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m. \quad (4.7)$$

2. **Condición de Mangasarian-Fromovitz (MFCQ):** Los gradientes de igualdad $\{\nabla h_i(\bar{x})\}_{i=1}^l$ son linealmente independientes, y existe una dirección en el espacio nulo de las igualdades que es estrictamente interior para

las restricciones de desigualdad activas:

$$\exists \bar{d} \in \ker J_h(\bar{x}) \quad \text{tal que} \quad \langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0 \quad \forall i \in I(\bar{x}). \quad (4.8)$$

3. Condición de Slater (para problemas convexos): h es afín, g es convexa, y existe un punto que satisface estrictamente las desigualdades:

$$\exists \hat{x} \in \mathbb{R}^n \quad \text{tal que} \quad h(\hat{x}) = 0, \quad g_i(\hat{x}) < 0 \quad \forall i = 1, \dots, m. \quad (4.9)$$

Ejemplo 4.6 (Evaluación de MFCQ). Sea el sistema:

$$D = \left\{ x \in \mathbb{R}^2 \mid g_1(x) = -x_1 \leq 0, \quad g_2(x) = -x_2 \leq 0, \quad g_3(x) = x_1 + x_2 - 1 \leq 0 \right\}.$$

En $\bar{x} = (0, 0)^\top$, los índices activos son $I(\bar{x}) = \{1, 2\}$. Los gradientes activos correspondientes son $\nabla g_1(\bar{x}) = (-1, 0)^\top$ y $\nabla g_2(\bar{x}) = (0, -1)^\top$. El vector $\bar{d} = (1, 1)^\top$ cumple $\langle \nabla g_1, \bar{d} \rangle = -1 < 0$ y $\langle \nabla g_2, \bar{d} \rangle = -1 < 0$, lo que satisface la existencia del vector $\bar{d}$ requerido por la condición MFCQ.

Observación. La condición MFCQ es menos restrictiva que exigir la independencia lineal de todos los gradientes activos (LICQ). Mientras que LICQ garantiza la existencia del vector $\bar{d}$ por resolución de sistemas lineales, MFCQ permite que los gradientes de las desigualdades activas sean linealmente dependientes, lo cual abarca una clase más amplia de problemas.

Proposición 4.2 (Condición dual de MFCQ). El punto $\bar{x} \in D$ cumple la condición MFCQ (4.8) si y solo si el sistema lineal:

$$\sum_{i=1}^l \lambda_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \mu_i \nabla g_i(\bar{x}) = 0, \quad \mu_i \geq 0, \quad i \in I(\bar{x}), \quad (4.10)$$

tiene como única solución $(\lambda, \mu) = (0, 0)$.

Prueba. Supongamos que se cumple MFCQ. Si el sistema (4.10) admitiera una solución con $\mu \in \mathbb{R}_+^{|I(\bar{x})|} \setminus \{0\}$, al realizar el producto escalar de (4.10) con el vector $\bar{d}$ garantizado por (4.8), se obtendría:

$$0 = \sum_{i=1}^l \lambda_i \langle \nabla h_i(\bar{x}), \bar{d} \rangle + \sum_{i \in I(\bar{x})} \mu_i \langle \nabla g_i(\bar{x}), \bar{d} \rangle.$$

Dado que $\langle \nabla h_i(\bar{x}), \bar{d} \rangle = 0$, $\langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0$, y al menos un $\mu_i > 0$, el término derecho es estrictamente negativo, lo que es una contradicción. Si $\mu = 0$, la ecuación requiere que $\sum \lambda_i \nabla h_i = 0$ con $\lambda \neq 0$, lo cual contradice la independencia lineal de $\nabla h_i(\bar{x})$.

Recíprocamente, si la única solución de (4.10) es la nula, el sistema carece de soluciones para $\mu \neq 0$ o $\lambda \neq 0$. Por el Teorema de la Alternativa (Motzkin), esto garantiza la existencia de $\bar{d}$ tal que $\langle \nabla h_i(\bar{x}), \bar{d} \rangle = 0$ y $\langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0$. Además, los gradientes ∇h_i deben ser independientes. Por lo tanto, se satisface MFCQ. ■

Ejemplo 4.7 (Falla de MFCQ). Considérese el sistema:

$$D = \left\{ x \in \mathbb{R}^2 \mid g_1(x) = -x_1^2 + x_2 \leq 0, \quad g_2(x) = -x_2 \leq 0 \right\}.$$

En $\bar{x} = (0, 0)^\top$, los gradientes activos son $\nabla g_1(\bar{x}) = (0, 1)^\top$ y $\nabla g_2(\bar{x}) = (0, -1)^\top$. Resolviendo el sistema dual (4.10) con $\mu \geq 0$:

$$\mu_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \mu_1 = \mu_2.$$

Existen soluciones no nulas (e.g., $\mu_1 = 1, \mu_2 = 1$). Por la Proposición 4.2, el punto no satisface MFCQ. Geométricamente, los gradientes opuestos impiden la existencia de una dirección estrictamente interior.

Teorema 4.2 (Cono tangente para restricciones mixtas). Sea D definido por (4.2). Supongamos que h y g son continuamente diferenciables en $\bar{x} \in D$. Se verifica lo siguiente:

1. $\mathcal{B}_D(\bar{x}) \subset \mathcal{H}(\bar{x})$.
2. Si se cumple MFCQ (4.8):

$$\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x}).$$

3. Si se cumple la condición de **Slater** (4.9):

$$\text{cl } \mathcal{V}_D(\bar{x}) = \mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x}).$$

4. Si las restricciones son **lineales** (4.7):

$$\mathcal{V}_D(\bar{x}) = \mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x}).$$

Prueba. (a) Ya demostrado en la Proposición 4.1.

(b) **[MFCQ]:** Sea $\bar{d}$ el vector de (4.8) y $d \in \mathcal{H}(\bar{x})$. Definimos $d(\alpha) = \alpha\bar{d} + (1 - \alpha)d$ para $\alpha \in (0, 1]$. Es claro que $d(\alpha) \in \ker J_h(\bar{x})$. Por el Teorema del Subespacio Tangente en variedades, $d(\alpha)$ es tangente a $h(x) = 0$, lo que implica la existencia de $r(t) = o(t)$ tal que $h(\bar{x} + td(\alpha) + r(t)) = 0$. Para las desigualdades activas $i \in I(\bar{x})$:

$$\langle \nabla g_i(\bar{x}), d(\alpha) \rangle \leq \alpha \langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0.$$

Sustituyendo en la aproximación de primer orden: $g_i(\bar{x} + td(\alpha) + r(t)) = t \langle \nabla g_i(\bar{x}), d(\alpha) \rangle + o(t)$. Para $t > 0$ suficientemente pequeño, $g_i(\bar{x} + td(\alpha) + r(t)) < 0$ debido a que el término de primer orden es estrictamente negativo. Las restricciones inactivas se mantienen en un entorno por continuidad. En conclusión, la curva pertenece a D , lo que muestra $d(\alpha) \in \mathcal{T}_D(\bar{x})$. Tomando el límite $\alpha \rightarrow 0^+$, como el cono tangente es cerrado, se sigue $d \in \mathcal{T}_D(\bar{x})$, demostrando la igualdad de los conos.

(c) **[Slater]:** Considerando $d(\alpha) = \alpha(\hat{x} - \bar{x}) + (1 - \alpha)d$. Por la linealidad de h , la dirección verifica $h(\bar{x} + td(\alpha)) = 0$. Por la desigualdad del subgradiente para funciones convexas, $\langle \nabla g_i(\bar{x}), \hat{x} - \bar{x} \rangle \leq g_i(\hat{x}) < 0$. Evaluando $g_i(\bar{x} + td(\alpha))$ se obtiene que $d(\alpha)$ es una dirección factible. Por lo tanto, $d(\alpha) \in \mathcal{V}_D(\bar{x})$. En el límite, se verifica la densidad y la igualdad de las estructuras.

(d) **[Linealidad]:** Si $h(x) = Ax - a$ y $g(x) = Bx - b$, sea $d \in \mathcal{H}(\bar{x})$. Para todo $t > 0$, la semirrecta $\bar{x} + td$ satisface el sistema algebraico directamente, lo que garantiza $\mathcal{H}(\bar{x}) \subset \mathcal{V}_D(\bar{x})$ y concluye la demostración. ■

Teorema 4.3 (Condición necesaria en forma primal). Supongamos que f y g son diferenciables en $\bar{x}$ y h es continuamente diferenciable en un entorno de $\bar{x}$. Si $\bar{x}$ es un minimizador local del problema (4.1) y se satisface alguna de las condiciones de regularidad de la Definición 4.3, entonces:

$$\langle \nabla f(\bar{x}), d \rangle \geq 0 \quad \forall d \in \mathcal{H}(\bar{x}). \quad (4.11)$$

Prueba. Por las propiedades generales vistas en el Capítulo 1, para todo minimizador local se verifica $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{B}_D(\bar{x})$. Si el punto es regular, el Teorema 4.2 establece $\mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$, concluyendo la prueba. ■

Ejemplo 4.8. Para minimizar $f(x) = \frac{1}{2}(x_1^2 + x_2^2 + x_3^2)$ sobre el conjunto:

$$h(x) = x_1 + x_2 + x_3 - 1 = 0, \quad g_i(x) = -x_i \leq 0, \quad i = 1, 2, 3.$$

El minimizador global por simetría es $\bar{x} = (1/3, 1/3, 1/3)^\top$. Las desigualdades no son activas ($I(\bar{x}) = \emptyset$). El gradiente de la restricción activa es $\nabla h(\bar{x}) = (1, 1, 1)^\top \neq 0$, cumpliendo la condición de regularidad. El cono de linealización se define exclusivamente por la igualdad:

$$\mathcal{H}(\bar{x}) = \left\{ d \in \mathbb{R}^3 \mid d_1 + d_2 + d_3 = 0 \right\}.$$

Para el gradiente de la función objetivo $\nabla f(\bar{x}) = (1/3, 1/3, 1/3)^\top$, al proyectar sobre $d \in \mathcal{H}(\bar{x})$:

$$\langle \nabla f(\bar{x}), d \rangle = \frac{1}{3}(d_1 + d_2 + d_3) = 0 \geq 0.$$

Se verifica la condición necesaria. Este resultado muestra que la formulación generalizada con desigualdades abarca el caso de restricciones de igualdad como un caso particular.

Teorema 4.4 (Cota de viabilidad de Robinson). Bajo la condición de regularidad MFCQ en $\bar{x} \in D$, existen un entorno U de $\bar{x}$ y una constante $M > 0$ tales que la distancia al conjunto factible satisface:

$$\text{dist}(x, D) \leq M \|\Psi(x)\| \quad \forall x \in U, \quad (4.12)$$

donde la función residual se define como $\Psi(x) = (h(x), \max\{0, g_1(x)\}, \dots, \max\{0, g_m(x)\})$.

Nota. La demostración se omite por requerir resultados de regularidad métrica y multifunciones en espacios de Banach (Teorema de Robinson-Graves). ■

Ejemplo 4.9 (Cota de Robinson). Considérese $D = \mathbb{R}_+^2$ definido por $g_1(x) = -x_1 \leq 0$ y $g_2(x) = -x_2 \leq 0$. El operador residual es $\Psi(x) = (\max\{0, -x_1\}, \max\{0, -x_2\})$. El operador $\max\{0, \cdot\}$ anula los términos correspondientes a las desigualdades que se satisfacen, cuantificando únicamente el error o violación de las restricciones. Por ejemplo, si

$x = (-3, -4)^\top$, $\|\Psi(x)\| = 5$, lo cual coincide exactamente con la distancia del punto a su proyección en el cuadrante $(0, 0)^\top$. En este caso se verifica la cota con $M = 1$.

4.2. Condiciones de optimalidad de Karush-Kuhn-Tucker

En esta sección deducimos las condiciones analíticas de optimalidad de primer orden para problemas con restricciones mixtas a partir de la caracterización del cono tangente desarrollada en la sección anterior. Como se demostró, la condición necesaria primal establece que el opuesto del gradiente pertenece al cono dual del cono de linealización: $-\nabla f(\bar{x}) \in \mathcal{H}(\bar{x})^*$. Utilizando la parametrización de este cono dual obtenida en el Lema 4.2, expresaremos esta relación geométrica como un sistema algebraico de multiplicadores de Lagrange, conocido como condiciones de Karush-Kuhn-Tucker (KKT).

Teorema 4.5 (Condiciones de Karush-Kuhn-Tucker). *Supongamos que $\bar{x} \in D$ es una solución local del problema (4.1)-(4.2), donde f, h, g son funciones continuamente diferenciables en $\bar{x}$.*

Si el punto $\bar{x}$ satisface alguna de las condiciones de regularidad de las restricciones detalladas en la Definición 4.3 (independencia lineal, linealidad afín, Slater o MFCQ), entonces existen multiplicadores $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}^m$ con $\bar{\mu} \geq 0$, tales que:

$$\nabla f(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i=1}^m \bar{\mu}_i \nabla g_i(\bar{x}) = 0, \quad (4.13)$$

$$\bar{\mu}_i g_i(\bar{x}) = 0 \quad \forall i \in \{1, \dots, m\}. \quad (4.14)$$

Prueba. Bajo cualquiera de las condiciones de regularidad supuestas, el Teorema de la Condición Necesaria Primal (Teorema 4.3) establece que la derivada direccional es no negativa sobre todo el cono de linealización, es decir, $\langle \nabla f(\bar{x}), d \rangle \geq 0 \quad \forall d \in \mathcal{H}(\bar{x})$. En términos de conos duales, esto equivale a la afirmación geométrica:

$$-\nabla f(\bar{x}) \in \mathcal{H}(\bar{x})^*.$$

Por el Lema 4.2, conocemos la parametrización de los elementos de $\mathcal{H}(\bar{x})^*$. Por lo tanto, se garantiza la existencia de multiplicadores $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu}_i \geq 0$ para $i \in I(\bar{x})$ tales que:

$$-\nabla f(\bar{x}) = \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i \nabla g_i(\bar{x}).$$

Definimos el vector $\bar{\mu} \in \mathbb{R}^m$ haciendo $\bar{\mu}_i = \bar{\mu}_i$ si $i \in I(\bar{x})$, y $\bar{\mu}_i = 0$ si $i \notin I(\bar{x})$. Al agrupar los términos se obtiene la condición de estacionariedad (4.13).

Por otra parte, si la restricción i es activa ($i \in I(\bar{x})$), se tiene $g_i(\bar{x}) = 0$, lo que anula el producto $\bar{\mu}_i g_i(\bar{x})$. Si es inactiva ($i \notin I(\bar{x})$), por construcción se tiene $\bar{\mu}_i = 0$, lo que también anula el producto. Esto demuestra la condición de complementariedad (4.14). ■

Nota: La condición de holgura complementaria

La condición $\bar{\mu}_i g_i(\bar{x}) = 0$ establece que para cada restricción de desigualdad se debe cumplir al menos una de las dos condiciones siguientes:

- Si la restricción no es activa ($g_i(\bar{x}) < 0$), el multiplicador asociado es nulo ($\bar{\mu}_i = 0$).
- Si el multiplicador es estrictamente positivo ($\bar{\mu}_i > 0$), la restricción debe satisfacerse con igualdad ($g_i(\bar{x}) = 0$).

Esta relación introduce un componente combinatorio en el cálculo de los puntos estacionarios, al requerir el análisis de los distintos casos de restricciones activas e inactivas.

Definición 4.4 (Complementariedad Estricta). Sea $\bar{x}$ un punto estacionario KKT con multiplicadores $(\bar{\lambda}, \bar{\mu})$. Se dice que se satisface la **condición de complementariedad estricta** si:

$$\bar{\mu}_i - g_i(\bar{x}) > 0 \quad \forall i = 1, \dots, m.$$

Esta condición excluye el caso degenerado en el que coinciden $g_i(\bar{x}) = 0$ y $\bar{\mu}_i = 0$. Esto equivale a exigir que toda restricción activa en el punto tenga un multiplicador estrictamente positivo.

Ejemplo 4.10 (Análisis por casos del sistema KKT). Considérese el problema de minimizar la suma de las coordenadas sobre el hemisferio superior de la circunferencia unitaria:

$$\min f(x) = x_1 + x_2 \quad \text{sujeto a} \quad \begin{aligned} h(x) &= x_1^2 + x_2^2 - 1 = 0 \\ g(x) &= -x_2 \leq 0 \end{aligned}$$

El conjunto factible D es el arco semicircular definido por $x_2 \geq 0$. El gradiente de la igualdad es $\nabla h(x) = (2x_1, 2x_2)^\top \neq 0$ en todo punto factible, lo que garantiza la condición LICQ.

Cualquier mínimo local debe cumplir el sistema KKT. Con $\nabla f = (1, 1)^\top$ y $\nabla g = (0, -1)^\top$, el sistema se formula como:

$$\begin{cases} 1. \ 1 + 2\lambda x_1 = 0 \\ 2. \ 1 + 2\lambda x_2 - \mu = 0 \\ 3. \ \mu(-x_2) = 0 \\ 4. \ x_1^2 + x_2^2 = 1, \quad x_2 \geq 0, \quad \mu \geq 0 \end{cases}$$

Analizamos las soluciones mediante los dos casos que define la condición de complementariedad:

Caso 1: Restricción inactiva ($\mu = 0$). Suponiendo $x_2 > 0$, la condición de complementariedad exige $\mu = 0$. Las ecuaciones de estacionariedad se reducen a:

$$1 + 2\lambda x_1 = 0 \implies x_1 = -\frac{1}{2\lambda}, \quad 1 + 2\lambda x_2 = 0 \implies x_2 = -\frac{1}{2\lambda}.$$

Sustituyendo en la ecuación de la circunferencia: $\frac{2}{4\lambda^2} = 1 \implies \lambda = \pm \frac{1}{\sqrt{2}}$. Dado que asumimos $x_2 > 0$, la única raíz compatible es $\lambda = -1/\sqrt{2}$. Obtenemos el primer punto KKT: $\bar{x}^{(1)} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)^\top$, con $\lambda = -\frac{1}{\sqrt{2}}$, $\mu = 0$.

Caso 2: Restricción activa ($\mu > 0$). Esto implica que la restricción se cumple con igualdad, es decir, $x_2 = 0$. Por la ecuación de la circunferencia, se tiene $x_1^2 = 1 \implies x_1 = \pm 1$. Evaluamos ambos casos:

- Si $x_1 = 1, x_2 = 0$: $1 + 2\lambda = 0 \implies \lambda = -1/2$. Sustituyendo se obtiene $1 - \mu = 0 \implies \mu = 1 \geq 0$. Obtenemos: $\bar{x}^{(2)} = (1, 0)^\top$, con $\lambda = -\frac{1}{2}$, $\mu = 1$.
- Si $x_1 = -1, x_2 = 0$: $1 - 2\lambda = 0 \implies \lambda = 1/2$. Sustituyendo resulta $1 - \mu = 0 \implies \mu = 1 \geq 0$. Obtenemos: $\bar{x}^{(3)} = (-1, 0)^\top$, con $\lambda = \frac{1}{2}$, $\mu = 1$.

Evaluando la función objetivo $f(x) = x_1 + x_2$ en los tres puntos obtenidos: $f(\bar{x}^{(1)}) = \sqrt{2} \approx 1.41$, $f(\bar{x}^{(2)}) = 1$, y $f(\bar{x}^{(3)}) = -1$. Por el Teorema de Weierstrass, se concluye que el punto $\bar{x}^{(3)} = (-1, 0)^\top$ es el minimizador global del problema.

Definición 4.5 (Sistema KKT y Lagrangiana). La **función Lagrangiana** $L : \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R}$ para el problema con restricciones mixtas se define como:

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle.$$

El sistema de ecuaciones e inecuaciones:

$$\nabla_x L(x, \lambda, \mu) = 0, \quad h(x) = 0, \quad g(x) \leq 0, \quad \mu \geq 0, \quad \mu_i g_i(x) = 0 \quad \forall i = 1, \dots, m,$$

se denomina **Sistema de Karush-Kuhn-Tucker (KKT)**. El conjunto de todos los multiplicadores asociados a un punto estacionario $\bar{x} \in D$ se denota por:

$$\mathcal{M}(\bar{x}) = \left\{ (\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}^m \mid \begin{aligned} &\nabla_x L(\bar{x}, \lambda, \mu) = 0, \\ &\mu \geq 0, \mu_i g_i(\bar{x}) = 0 \quad \forall i \end{aligned} \right\}.$$

Bajo condiciones de convexidad, las condiciones necesarias de primer orden pasan a ser también suficientes para garantizar la optimalidad global.

Teorema 4.6 (Suficiencia de KKT bajo Convexidad). Sea $\bar{x} \in \mathbb{R}^n$ un punto estacionario del problema (4.1)-(4.2) (es decir, $\mathcal{M}(\bar{x}) \neq \emptyset$).

Si las funciones f y g_i son funciones convexas en $\mathbb{R}^n$, y la función de igualdad h es afín, entonces $\bar{x}$ es un minimizador global del problema.

Prueba. Sea $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$ el vector de multiplicadores asociado. Dado que $\bar{\mu}_i \geq 0$ y las funciones g_i son convexas, la combinación cónica $\sum \bar{\mu}_i g_i(x)$ es convexa. Como h es afín, el término $\sum \bar{\lambda}_i h_i(x)$ también lo es. Por tanto, la función $x \mapsto L(x, \bar{\lambda}, \bar{\mu})$ es convexa en $\mathbb{R}^n$.

Al ser $\bar{x}$ un punto estacionario, se cumple $\nabla_x L(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$. Utilizando la propiedad de primer orden para funciones convexas diferenciables, se tiene:

$$L(x, \bar{\lambda}, \bar{\mu}) \geq L(\bar{x}, \bar{\lambda}, \bar{\mu}) \quad \forall x \in \mathbb{R}^n.$$

Para cualquier punto factible $x \in D$, evaluando las restricciones se cumple $h(x) = 0$ y $g(x) \leq 0$. Puesto que $\bar{\mu} \geq 0$, se verifica:

$$f(x) \geq f(x) + \sum_{i=1}^l \bar{\lambda}_i h_i(x) + \sum_{i=1}^m \bar{\mu}_i g_i(x) = L(x, \bar{\lambda}, \bar{\mu}).$$

Usando la minimalidad de la Lagrangiana en $\bar{x}$ y la condición de complementariedad $\bar{\mu}_i g_i(\bar{x}) = 0$:

$$L(x, \bar{\lambda}, \bar{\mu}) \geq L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x}).$$

Por transitividad, se concluye que $f(x) \geq f(\bar{x})$ para todo punto factible $x \in D$, lo que demuestra que $\bar{x}$ es un minimizador global. ■

Nota: Dualidad y condiciones de punto de silla

La demostración del Teorema 4.6 utiliza la propiedad de punto de silla de la función Lagrangiana:

$$L(\bar{x}, \lambda, \mu) \leq L(\bar{x}, \bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu}) \quad \forall x \in \mathbb{R}^n, \forall \lambda \in \mathbb{R}^l, \forall \mu \in \mathbb{R}_+^m.$$

Esta relación de min-max es fundamental en la teoría de dualidad y en el diseño de algoritmos primal-duales.

Ejemplo 4.11 (Falta de convexidad en las restricciones). Considérese el problema:

$$\min f(x) = x_2 \quad \text{sujeto a} \quad g(x) = -x_1^2 - x_2^2 \leq 0.$$

El conjunto factible es $\mathbb{R}^2$, el cual es convexo. Sin embargo, la función objetivo no está acotada inferiormente en $\mathbb{R}^2$, por lo que no existe un mínimo global.

El origen $\bar{x} = (0, 0)^\top$ es un punto estacionario, puesto que $\nabla g(\bar{x}) = (0, 0)^\top$, y el sistema de primer orden no admite solución con multiplicador estrictamente positivo para la restricción modificada $g(x) = -x_1^2 + x_2 \leq 0$.

No es posible aplicar el Teorema 4.6 en este caso debido a que la función $g(x) = -x_1^2 + x_2$ no es convexa en $\mathbb{R}^2$ (su Hessiano es indefinido). El teorema exige la convexidad de las funciones que definen las restricciones, no únicamente la del conjunto factible resultante.

Ejemplo 4.12 (Resolución de un problema convexo). Minimicemos la función $f(x) = x_1^2 + 3x_2^2$ sujeta a:

$$g_1(x) = 1 - x_1 - 2x_2 \leq 0, \quad g_2(x) = 1 - 2x_1 - x_2 \leq 0.$$

La función objetivo es estrictamente convexa y las restricciones son afines, lo que asegura que se satisfacen las condiciones de regularidad. El sistema KKT está dado por:

$$\begin{cases} 1. \ 2x_1 - \mu_1 - 2\mu_2 = 0 \\ 2. \ 6x_2 - 2\mu_1 - \mu_2 = 0 \\ 3. \ \mu_1(1 - x_1 - 2x_2) = 0 \\ 4. \ \mu_2(1 - 2x_1 - x_2) = 0 \\ 5. \ \mu_1 \geq 0, \ \mu_2 \geq 0 \\ 6. \ g_1(x) \leq 0, \ g_2(x) \leq 0 \end{cases}$$

Analizamos los posibles casos según la complementariedad:

- **Caso 1** ($\mu_1 = 0, \mu_2 = 0$): De las ecuaciones de estacionariedad se obtiene $x_1 = 0, x_2 = 0$. Evaluando las restricciones: $g_1(0, 0) = 1 > 0$, lo que es infactible.
- **Caso 2** ($\mu_1 = 0, \mu_2 > 0$): La complementariedad exige $2x_1 + x_2 = 1$. Con $\mu_1 = 0$, se tiene $2x_1 = 2\mu_2$ y $6x_2 = \mu_2$, de donde $x_1 = 6x_2$. Sustituyendo en la restricción activa se obtiene $x_2 = 1/13$ y $x_1 = 6/13$. Evaluando la restricción inactiva: $g_1(6/13, 1/13) = 5/13 > 0$, lo que es infactible.
- **Caso 3** ($\mu_1 > 0, \mu_2 = 0$): Se requiere $x_1 + 2x_2 = 1$. Las ecuaciones de estacionariedad implican $2x_1 = \mu_1$ y $6x_2 = 2\mu_1$, lo que da $x_1 = 1.5x_2$. Sustituyendo en la restricción se obtiene $x_2 = 2/7$ y $x_1 = 3/7$. Evaluando las condiciones restantes: $g_2(3/7, 2/7) = -1/7 \leq 0$ y el multiplicador es $\mu_1 = 6/7 \geq 0$.

Se verifican todas las condiciones. El punto estacionario único es $\bar{x} = (3/7, 2/7)^\top$ con multiplicadores $\bar{\mu} = (6/7, 0)^\top$, el cual corresponde al minimizador global.

Las propiedades algebraicas del conjunto de multiplicadores $\mathcal{M}(\bar{x})$ dependen del cumplimiento de las condiciones de regularidad en el punto estacionario.

Definición 4.6 (Condición Estricta de Mangasarian-Fromovitz - SMFCQ). Sea $\bar{x} \in D$ un punto estacionario y sea $\bar{\mu}$ un vector de multiplicadores en $\mathcal{M}(\bar{x})$. Definimos los conjuntos de índices activos según el signo del multiplicador:

$$I_+(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i > 0\}, \quad I_0(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i = 0\}.$$

El punto cumple **SMFCQ** si los gradientes $\{\nabla h_i(\bar{x})\}_{i=1}^l \cup \{\nabla g_i(\bar{x})\}_{i \in I_+(\bar{x})}$ son linealmente independientes y existe un vector $\bar{d} \in \mathbb{R}^n$ tal que $\langle \nabla h_i(\bar{x}), \bar{d} \rangle = 0$, $\langle \nabla g_i(\bar{x}), \bar{d} \rangle = 0$ para $i \in I_+(\bar{x})$, y $\langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0$ para $i \in I_0(\bar{x})$.

Proposición 4.3 (Propiedades del Conjunto de Multiplicadores). Sea $\bar{x} \in \mathbb{R}^n$ un punto estacionario del problema ($\mathcal{M}(\bar{x}) \neq \emptyset$).

1. El conjunto $\mathcal{M}(\bar{x})$ es compacto si y solo si se cumple la condición MFCQ.
2. El conjunto $\mathcal{M}(\bar{x})$ consta de un único punto si y solo si se cumple la condición SMFCQ.

Prueba. Demostramos (a). La propiedad de ser cerrado se deduce directamente de que $\mathcal{M}(\bar{x})$ está definido mediante igualdades e inecuaciones continuas. Supongamos, por reducción al absurdo, que el conjunto no está acotado, por lo que existe una sucesión $\{(\lambda^k, \mu^k)\} \subset \mathcal{M}(\bar{x})$ tal que $\|(\lambda^k, \mu^k)\| \rightarrow \infty$.

Dividiendo las ecuaciones del sistema KKT correspondientes a cada k por el escalar $\|(\lambda^k, \mu^k)\| > 0$, se obtiene una sucesión en la esfera unitaria. Por el Teorema de Bolzano-Weierstrass, existe una subsucesión convergente hacia un vector límite $(\tilde{\lambda}, \tilde{\mu}) \in (\mathbb{R}^l \times \mathbb{R}_+^m)$ con $\|(\tilde{\lambda}, \tilde{\mu})\| = 1$. Pasando al límite en la ecuación normalizada, se obtiene:

$$0 = \sum_{i=1}^l \tilde{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \tilde{\mu}_i \nabla g_i(\bar{x}), \quad \text{con } \tilde{\mu}_i \geq 0.$$

Por la caracterización dual de Mangasarian-Fromovitz (Proposición 4.2), si se cumple MFCQ este sistema homogéneo admite únicamente la solución trivial $(\tilde{\lambda}, \tilde{\mu}) = 0$. Esto contradice que el vector límite tiene norma unitaria, concluyendo que el conjunto de multiplicadores es compacto. ■

Ejemplo 4.13 (Geometría del conjunto de multiplicadores). Considérese el problema en $\mathbb{R}^2$ con dos restricciones de desigualdad:

$$\begin{aligned} &\text{minimizar} && f(x) = x_1 \\ &\text{subject to} && g_1(x) = -x_1 + x_2 \leq 0, \\ &&& g_2(x) = -x_1 - x_2 \leq 0 \end{aligned}$$

El mínimo global se alcanza en $\bar{x} = (0, 0)^\top$, donde ambas restricciones son activas. Los gradientes son $\nabla g_1 = (-1, 1)^\top$ y $\nabla g_2 = (-1, -1)^\top$. Dado que son linealmente independientes, se verifican MFCQ y SMFCQ.

Planteando el sistema KKT: $(1, 0)^\top + \mu_1(-1, 1)^\top + \mu_2(-1, -1)^\top = 0$, cuya única solución es $\bar{\mu} = (1/2, 1/2)^\top$. En este caso, el conjunto de multiplicadores es un único punto.

1. Incumplimiento de SMFCQ con MFCQ (Compactibilidad):

Añadiendo la restricción redundante $g_3(x) = -x_1 \leq 0$, en el origen se tiene $\nabla g_3 = (-1, 0)^\top$. El conjunto de gradientes ya no es linealmente independiente, pero el vector $\bar{d} = (1, 0)^\top$ sigue cumpliendo $\langle \nabla g_i, \bar{d} \rangle < 0$ para todo i , por lo que se mantiene MFCQ.

El sistema KKT resulta en:

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} -1 \\ -1 \end{pmatrix} + \mu_3 \begin{pmatrix} -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

De la segunda coordenada se deduce $\mu_1 = \mu_2$. Sustituyendo en la primera se obtiene $\mu_3 = 1 - 2\mu_1$. Dado que los multiplicadores deben ser no negativos, se requiere $0 \leq \mu_1 \leq 1/2$. El conjunto de multiplicadores es:

$$\mathcal{M}(\bar{x}) = \left\{ \begin{pmatrix} \mu_1 \\ \mu_1 \\ 1 - 2\mu_1 \end{pmatrix} \mid \mu_1 \in \left[0, \frac{1}{2}\right] \right\}.$$

Al no cumplirse SMFCQ no se cumple la unicidad, pero bajo MFCQ el conjunto $\mathcal{M}(\bar{x})$ es un segmento de recta compacto en $\mathbb{R}^3$.

2. Falta de acotamiento por incumplimiento de MFCQ:

Sustituyendo la tercera restricción por $g_4(x) = x_1 \leq 0$, se tiene $\nabla g_4 = (1, 0)^\top$. En este caso, cualquier dirección factible con $d_1 > 0$ contradice la restricción g_4 , por lo que no se satisface MFCQ. El sistema KKT es:

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} -1 \\ -1 \end{pmatrix} + \mu_4 \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Esto implica $\mu_1 = \mu_2$ y $\mu_4 = 2\mu_1 - 1$. Como se requiere $\mu_4 \geq 0$, se tiene $\mu_1 \geq 1/2$. El conjunto de multiplicadores es:

$$\mathcal{M}(\bar{x}) = \left\{ \begin{pmatrix} \mu_1 \\ \mu_1 \\ 2\mu_1 - 1 \end{pmatrix} \mid \mu_1 \in \left[\frac{1}{2}, +\infty \right) \right\}.$$

Al no cumplirse MFCQ, el conjunto de multiplicadores es un rayo no acotado.

Si en un mínimo local no se cumple ninguna condición de regularidad, el sistema KKT clásico puede no tener solución. Para tratar estos casos se introducen las condiciones de Fritz John.

Teorema 4.7 (Condiciones de Fritz John). Sea $\bar{x} \in D$ un minimizador local de (4.1)-(4.2). Independientemente de las condiciones de regularidad, existe un vector no nulo $(\lambda_0, \bar{\lambda}, \bar{\mu}) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m$ tal que:

$$\begin{aligned} \lambda_0 \nabla f(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i=1}^m \bar{\mu}_i \nabla g_i(\bar{x}) &= 0, \\ \bar{\mu}_i g_i(\bar{x}) &= 0 \quad \forall i = 1, \dots, m, \\ \lambda_0 \geq 0, \quad \bar{\mu} \geq 0, \quad (\lambda_0, \bar{\lambda}, \bar{\mu}) &\neq 0. \end{aligned} \tag{4.15}$$

Prueba. Consideramos dos casos.

Caso 1: Si se cumple la condición de regularidad MFCQ, por el Teorema 4.5 se garantiza la existencia de multiplicadores KKT $(\bar{\lambda}, \bar{\mu})$. En este caso basta definir $\lambda_0 = 1$ para obtener la solución $(1, \bar{\lambda}, \bar{\mu}) \neq 0$.

Caso 2: Si no se cumple MFCQ, por la Proposición 4.2 existe una solución no nula del sistema dual homogéneo:

$$\sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i \nabla g_i(\bar{x}) = 0, \quad \text{con } \bar{\mu}_i \geq 0 \text{ y } (\bar{\lambda}, \bar{\mu}) \neq 0.$$

Definiendo el escalar $\lambda_0 = 0$ y completando $\bar{\mu}_i = 0$ para $i \notin I(\bar{x})$, se obtiene el vector no nulo $(\lambda_0, \bar{\lambda}, \bar{\mu})$ que satisface el sistema de Fritz John. ■

Ejemplo 4.14 (Puntos estacionarios con $\lambda_0 = 0$). Considérese el problema:

$$\begin{aligned} \text{minimizar} \quad & f(x) = -x_1 \\ \text{subject to} \quad & g_1(x) = -x_1^1 + x_2 \leq 0, \\ & g_2(x) = -x_1 - x_2 \leq 0 \end{aligned}$$

El único punto factible es el origen $\bar{x} = (0, 0)^\top$, que corresponde al mínimo global. Los gradientes activos en este punto son $\nabla g_1(\bar{x}) = (0, 1)^\top$ y $\nabla g_2(\bar{x}) = (0, -1)^\top$. Como se tiene $\nabla g_1 + \nabla g_2 = 0$, los gradientes son linealmente dependientes y no se cumple la condición MFCQ.

Intentando plantear el sistema KKT tradicional ($\lambda_0 = 1$):

$$\nabla f(\bar{x}) + \mu_1 \nabla g_1(\bar{x}) + \mu_2 \nabla g_2(\bar{x}) = \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

La primera ecuación requiere $-1 = 0$, lo que es una contradicción. Por lo tanto, no existen multiplicadores de KKT.

Sin embargo, planteando el sistema de Fritz John con $\lambda_0 = 0$:

$$0 \cdot \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ \mu_1 - \mu_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Cualquier elección con $\mu_1 = \mu_2 > 0$ proporciona una solución válida. El hecho de que $\lambda_0 = 0$ indica que el punto es geoméricamente singular, y el gradiente de la función objetivo no interviene en la estacionariedad.

Atención: Dificultades numéricas en presencia de multiplicadores singulares

Aunque el Teorema de Fritz John garantiza la existencia de multiplicadores en presencia de puntos singulares, este resultado suele ser indeseable desde el punto de vista algorítmico.

Si un método numérico converge a un punto donde $\lambda_0 = 0$, el algoritmo ignora la función objetivo $f(x)$ y realiza iteraciones destinadas únicamente a satisfacer la factibilidad de las restricciones. Por ello, en optimización no lineal es de gran importancia asegurar que se cumplan condiciones de regularidad como MFCQ para garantizar que $\lambda_0 = 1$ y mantener la convergencia hacia el óptimo de la función objetivo.

4.3. Condiciones de optimalidad de segundo orden

En esta sección se presentan las condiciones analíticas necesarias y suficientes de segundo orden para el problema de optimización con restricciones mixtas. Estas condiciones se evalúan sobre un subconjunto de direcciones factibles, denominado *cono crítico*, en el cual la información de primer orden no permite determinar la optimalidad debido a la anulación de las derivadas direccionales.

Definición 4.7 (Cono Crítico). Sea $\bar{x} \in D$ un punto estacionario del problema (4.1)-(4.2). Se define el **cono crítico** (o cono de direcciones críticas) asociado a $\bar{x}$, denotado por $K(\bar{x})$, como el conjunto de direcciones del cono de linealización $\mathcal{H}(\bar{x})$ que satisfacen la condición:

$$K(\bar{x}) = \{d \in \mathcal{H}(\bar{x}) \mid \langle \nabla f(\bar{x}), d \rangle \leq 0\}. \quad (4.16)$$

Utilizando la definición del cono de linealización, este conjunto equivale al sistema poliédrico:

$$K(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{cases} \langle \nabla f(\bar{x}), d \rangle \leq 0, \\ \langle \nabla g_i(\bar{x}), d \rangle \leq 0 \quad \forall i \in I(\bar{x}), \\ \langle \nabla h_i(\bar{x}), d \rangle = 0 \quad \forall i = 1, \dots, l \end{cases} \right\}.$$

Observación. Por la linealidad de las ecuaciones e inecuaciones que lo definen, $K(\bar{x})$ es un cono poliédrico cerrado. En adelante, supondremos que las funciones f, h y g son dos veces diferenciables en el punto $\bar{x}$.

El siguiente lema proporciona caracterizaciones algebraicas alternativas del cono crítico cuando se dispone de un vector de multiplicadores de Lagrange.

Lema 4.3 (Caracterización alternativa del cono crítico). Supongamos que $\bar{x}$ es un punto estacionario de Karush-Kuhn-Tucker y sea $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$ un vector de multiplicadores asociado.

El cono crítico $K(\bar{x})$ admite las siguientes representaciones equivalentes:

$$K(\bar{x}) = \{d \in \mathcal{H}(\bar{x}) \mid \langle \nabla f(\bar{x}), d \rangle = 0\} = \{d \in \mathcal{H}(\bar{x}) \mid \bar{\mu}_i \langle \nabla g_i(\bar{x}), d \rangle = 0 \quad \forall i \in I(\bar{x})\}. \quad (4.17)$$

Prueba. Sea $d \in \mathcal{H}(\bar{x})$. Multiplicando la condición de estacionariedad de KKT por el vector d , se obtiene:

$$\langle \nabla f(\bar{x}), d \rangle = - \left\langle \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i \nabla g_i(\bar{x}), d \right\rangle.$$

Dado que $\langle \nabla h_i(\bar{x}), d \rangle = 0$ para todo $d \in \mathcal{H}(\bar{x})$, el primer término es nulo:

$$\langle \nabla f(\bar{x}), d \rangle = - \sum_{i \in I(\bar{x})} \bar{\mu}_i \langle \nabla g_i(\bar{x}), d \rangle.$$

Puesto que $\bar{\mu}_i \geq 0$ por viabilidad dual y $\langle \nabla g_i(\bar{x}), d \rangle \leq 0$ para $d \in \mathcal{H}(\bar{x})$, la suma del miembro derecho es no positiva. Al antecederle el signo negativo, se deduce que $\langle \nabla f(\bar{x}), d \rangle \geq 0$. Por la definición de $K(\bar{x})$ se requiere $\langle \nabla f(\bar{x}), d \rangle \leq 0$, por lo que la única forma de satisfacer ambas condiciones es que $\langle \nabla f(\bar{x}), d \rangle = 0$. Asimismo, para que una suma de términos no negativos sea nula, cada término individual debe ser cero: $\bar{\mu}_i \langle \nabla g_i(\bar{x}), d \rangle = 0$ para todo $i \in I(\bar{x})$, lo que demuestra la caracterización (4.17). ■

Ejemplo 4.15 (Cálculo del cono crítico). Considérese el problema de minimizar una función lineal sobre el primer cuadrante:

$$\begin{aligned} \text{minimizar} \quad & f(x) = x_1 + x_2 \\ \text{subject to} \quad & g_1(x) = -x_1 \leq 0, \\ & g_2(x) = -x_2 \leq 0 \end{aligned}$$

El mínimo global se alcanza en el origen $\bar{x} = (0, 0)^\top$, donde ambas restricciones son activas ($I(\bar{x}) = \{1, 2\}$). Los gradientes de las restricciones son $\nabla g_1 = (-1, 0)^\top$ y $\nabla g_2 = (0, -1)^\top$. El gradiente de la función objetivo es $\nabla f = (1, 1)^\top$.

Primero, el cono de linealización $\mathcal{H}(\bar{x})$ se define por las condiciones:

$$\langle (-1, 0)^\top, d \rangle = -d_1 \leq 0 \implies d_1 \geq 0, \quad \text{y} \quad -d_2 \leq 0 \implies d_2 \geq 0.$$

Es decir, $\mathcal{H}(\bar{x}) = \mathbb{R}_+^2$. Cualquier dirección con componentes no negativas es una dirección de linealización.

Para construir el cono crítico $K(\bar{x})$ añadimos la condición de no descenso de la función objetivo $\langle \nabla f(\bar{x}), d \rangle \leq 0$:

$$\langle (1, 1)^\top, d \rangle = d_1 + d_2 \leq 0.$$

Dado que $d \in \mathbb{R}_+^2$, la única solución es que ambas componentes sean nulas. Por lo tanto, el cono crítico se reduce al origen: $K(\bar{x}) = \{(0, 0)^\top\}$.

Para verificar la caracterización alternativa del Lema 4.3, resolvemos el sistema de primer orden $\nabla f + \mu_1 \nabla g_1 + \mu_2 \nabla g_2 = 0$:

$$\begin{pmatrix} 1 \\ 1 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \mu_1 = 1, \quad \mu_2 = 1.$$

Al ser ambos multiplicadores estrictamente positivos, las restricciones activas impiden el descenso de la función objetivo en cualquier dirección factible no nula. Dado que el cono crítico se reduce a $\{0\}$, las condiciones de segundo orden se satisfacen de forma vacía.

Corolario 4.1 (Cono crítico bajo complementariedad estricta). Supongamos que el punto estacionario $\bar{x}$ con multiplicador $(\bar{\lambda}, \bar{\mu})$ satisface la condición de complementariedad estricta (Definición 4.4).

Al ser $\bar{\mu}_i > 0$ para todo $i \in I(\bar{x})$, la caracterización del Lema 4.3 implica que $\langle \nabla g_i(\bar{x}), d \rangle = 0$. Bajo esta hipótesis, las restricciones de desigualdad activas se comportan localmente como restricciones de igualdad, por lo que el cono crítico es un subespacio vectorial:

$$K(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{aligned} &\langle \nabla h_i(\bar{x}), d \rangle = 0 \quad \forall i = 1, \dots, l \\ &\langle \nabla g_i(\bar{x}), d \rangle = 0 \quad \forall i \in I(\bar{x}) \end{aligned} \right\}.$$

Consideramos en primer lugar el caso donde los gradientes de las restricciones activas son linealmente independientes (LICQ) o las restricciones son afines, lo que garantiza la unicidad del vector de multiplicadores.

Teorema 4.8 (Condición necesaria de segundo orden bajo LICQ o linealidad). Supongamos que $\bar{x} \in D$ es un minimizador local del problema y que f, h, g son dos veces diferenciables en $\bar{x}$.

Si el punto satisface la condición de independencia lineal (LICQ) de las restricciones activas, o si todas las restricciones son afines, entonces, para el multiplicador de Lagrange $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$ (el cual es único bajo LICQ), la Hessiana de la función Lagrangiana es semidefinida positiva sobre el cono crítico:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}, \bar{\mu}) d, d \rangle \geq 0 \quad \forall d \in K(\bar{x}). \quad (4.18)$$

Prueba. Fijemos $d \in K(\bar{x})$. Bajo LICQ o linealidad, el cono de Bouligand coincide con el cono de linealización (Teorema 4.2), por lo que $d \in \mathcal{B}_D(\bar{x})$. Esto implica la existencia de una trayectoria factible $x(t) = \bar{x} + td + r(t) \in D$ para $t > 0$ suficientemente pequeño, donde $\|r(t)\| = o(t)$.

Al ser $\bar{x}$ un minimizador local, se tiene $f(x(t)) - f(\bar{x}) \geq 0$. Para el multiplicador $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$, se cumple $\bar{\mu}_i g_i(\bar{x}) = 0$.

Dado que $x(t) \in D$, se verifica $h_i(x(t)) = 0$ y $g_i(x(t)) \leq 0$. Por lo tanto:

$$\begin{aligned} 0 &\leq f(x(t)) - f(\bar{x}) \\ &\leq f(x(t)) - f(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i h_i(x(t)) + \sum_{i=1}^m \bar{\mu}_i g_i(x(t)) \\ &= L(x(t), \bar{\lambda}, \bar{\mu}) - L(\bar{x}, \bar{\lambda}, \bar{\mu}). \end{aligned}$$

Utilizando el desarrollo de Taylor de la función Lagrangiana en torno a $\bar{x}$:

$$0 \leq \langle \nabla_x L(\bar{x}, \bar{\lambda}, \bar{\mu}), td + r(t) \rangle + \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}, \bar{\mu})(td + r(t)), td + r(t) \rangle + o(t^2).$$

Por la condición de estacionariedad $\nabla_x L(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$, el término de primer orden es nulo. Dividiendo por $t^2 > 0$ y tomando el límite cuando $t \rightarrow 0^+$, los términos dependientes de $r(t)$ se anulan, concluyendo que $\langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle \geq 0$. ■

Ejemplo 4.16 (Hessiana de la Lagrangiana en el cono crítico). Considérese el problema de maximizar la altura sobre una región acotada por una parábola, formulado

$$\begin{aligned} &\text{minimizar} && f(x) = -x_2 \\ &\text{subject to} && g(x) = x_1^2 - x_2 \leq 0 \end{aligned}$$

El conjunto factible D es el área superior a la parábola $x_2 = x_1^2$. Evaluamos las condiciones en el origen $\bar{x} = (0, 0)^\top$. La restricción es activa ($g(0) = 0$).

El gradiente de la restricción es $\nabla g(x) = (2x_1, -1)^\top$, que en el origen resulta en $\nabla g(\bar{x}) = (0, -1)^\top \neq 0$, por lo que se cumple LICQ. El sistema de primer orden $\nabla f(\bar{x}) + \mu \nabla g(\bar{x}) = 0$ exige $\mu = -1$. Dado que las condiciones KKT requieren $\mu \geq 0$, el punto no satisface las condiciones de primer orden.

Para ilustrar el análisis de segundo orden, modifiquemos el problema a:

$$\begin{aligned} &\text{minimizar} && f(x) = x_2 \\ &\text{subject to} && g(x) = x_1^2 - x_2 \leq 0. \end{aligned}$$

El sistema KKT es:

$$\begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \bar{\mu} = 1.$$

El multiplicador es admisible ($\bar{\mu} = 1 \geq 0$). Determinamos el cono crítico $K(\bar{x})$ mediante la caracterización alternativa. Al ser $\bar{\mu} = 1 > 0$, se requiere: $\langle \nabla g(\bar{x}), d \rangle = -d_2 = 0 \implies d_2 = 0$. Por lo tanto, el cono crítico es el eje horizontal: $K(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \in \mathbb{R}\}$.

La Hessiana de la Lagrangiana $L(x, \bar{\mu}) = x_2 + x_1^2 - x_2 = x_1^2$ en $\bar{x}$ está dada por:

$$\nabla_{xx}^2 L(\bar{x}, \bar{\mu}) = \nabla^2 f(\bar{x}) + \bar{\mu} \nabla^2 g(\bar{x}) = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} + (1) \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}.$$

Para cualquier dirección $d \in K(\bar{x})$, evaluamos la forma cuadrática:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\mu})d, d \rangle = \begin{pmatrix} d_1 & 0 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} d_1 \\ 0 \end{pmatrix} = 2d_1^2 \geq 0.$$

La condición necesaria de segundo orden se verifica. Este ejemplo muestra cómo la curvatura de la restricción, representada en el término de segundo orden de la Lagrangiana por el multiplicador positivo, compensa la falta de curvatura de la función objetivo.

Observación (Multiplicadores no únicos bajo MFCQ). La demostración del Teorema 4.8 no se aplica directamente bajo la condición de Mangasarian-Fromovitz (MFCQ), dado que el conjunto de multiplicadores $\mathcal{M}(\bar{x})$ es un poliedro compacto pero no necesariamente un único punto. En este caso, se requiere un análisis basado en desarrollos de segundo orden y teoremas de separación.

Proposición 4.4 (Aproximación de segundo orden de curvas factibles). Sean h y g funciones dos veces diferenciables en $\bar{x} \in D$. Para que exista una sucesión $\{t_k\} \rightarrow 0^+$ tal que un par de vectores $(d, w) \in \mathbb{R}^n \times \mathbb{R}^n$ cumpla:

$$\text{dist}(\bar{x} + t_k d + t_k^2 w, D) = o(t_k^2), \quad (4.19)$$

es necesario que $d \in \mathcal{B}_D(\bar{x})$ y que el vector de segundo orden w satisfaga el sistema:

$$\langle \nabla h_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 h_i(\bar{x})d, d \rangle = 0 \quad \forall i \in \{1, \dots, l\}, \quad (4.20)$$

$$\langle \nabla g_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 g_i(\bar{x})d, d \rangle \leq 0 \quad \forall i \in I(\bar{x}, d), \quad (4.21)$$

donde $I(\bar{x}, d) = \{i \in I(\bar{x}) \mid \langle \nabla g_i(\bar{x}), d \rangle = 0\}$ representa el conjunto de restricciones activas a lo largo de la dirección d .

Prueba. La demostración se omite por brevedad; se basa en la aplicación del desarrollo de Taylor de segundo orden y la condición de factibilidad de la trayectoria $x^k = \bar{x} + t_k d + t_k^2 w + o(t_k^2)$. ■

Nota: Interpretación cinemática

La caracterización de la Proposición 4.4 admite una interpretación física al modelar la trayectoria $x(t)$ como el movimiento de una partícula en el tiempo t :

- El vector $d \in \mathbb{R}^n$ representa la **velocidad** (dirección tangente de primer orden), la cual debe cumplir la condición de no apuntar hacia el exterior del conjunto factible ($\langle \nabla g, d \rangle \leq 0$).
- El vector $w \in \mathbb{R}^n$ representa la **aceleración**. Las condiciones de segundo orden (4.20) y (4.21) determinan la curvatura necesaria de la trayectoria para mantener la factibilidad.

Ejemplo 4.17 (Ejemplo de trayectoria de segundo orden). Analicemos las condiciones de segundo orden para un punto restringido a yacer dentro del disco unitario:

$$D = \left\{ x \in \mathbb{R}^2 \mid g(x) = \frac{1}{2}(x_1^2 + x_2^2 - 1) \leq 0 \right\}.$$

Consideremos el punto $\bar{x} = (0, 1)^\top$, en el cual la restricción es activa ($g(0, 1) = 0$). Evaluando las derivadas en $\bar{x}$:

$$\nabla g(\bar{x}) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \nabla^2 g(\bar{x}) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Buscamos construir una trayectoria $x(t) = \bar{x} + td + t^2 w + o(t^2)$ factible en D para $t > 0$.

1. Dirección de primer orden (Velocidad d):

Por la definición de $d \in \mathcal{H}(\bar{x})$, el vector velocidad debe cumplir $\langle \nabla g(\bar{x}), d \rangle \leq 0 \implies d_2 \leq 0$. Consideremos la dirección horizontal unitaria $d = (1, 0)^\top$, para la cual se tiene $\langle \nabla g(\bar{x}), d \rangle = 0$ (la restricción es activa a lo largo de d).

2. Dirección de segundo orden (Aceleración w):

Como la restricción es activa a lo largo de d , el índice pertenece a $I(\bar{x}, d)$. La Proposición 4.4 requiere que w satisfaga:

$$\langle \nabla g(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 g(\bar{x}) d, d \rangle \leq 0.$$

Sustituyendo los vectores correspondientes:

$$w_2 + \frac{1}{2}(1) \leq 0 \implies w_2 \leq -\frac{1}{2}.$$

Este resultado muestra que para una velocidad horizontal unitaria, la trayectoria requiere una aceleración con componente vertical negativa de al menos 1/2 (aceleración centrípeta) para mantener la factibilidad en D .

Nota: Dificultad del análisis bajo MFCQ

Bajo la condición LICQ, el multiplicador de Lagrange es único, por lo que el análisis de la curvatura se realiza con un único operador. Bajo MFCQ, al no haber unicidad, el conjunto de multiplicadores es un poliedro. El análisis requiere determinar si existe algún multiplicador que satisfaga la condición de semidefinición positiva para cada dirección crítica específica.

Teorema 4.9 (Condición necesaria de segundo orden bajo MFCQ). Sea $\bar{x}$ un minimizador local de (4.1) que satisface la condición de regularidad de Mangasarian-Fromovitz (MFCQ).

Para cada dirección crítica $d \in K(\bar{x})$, existe un vector de multiplicadores de Lagrange $(\lambda, \mu) \in \mathcal{M}(\bar{x})$ tal que:

$$\langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle \geq 0. \quad (4.22)$$

Prueba. Fijemos $d \in K(\bar{x})$. Definimos los conjuntos:

$$S_1(d) = \left\{ (\alpha, y, z) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m \mid \begin{array}{l} \alpha = \langle \nabla f(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 f(\bar{x}) d, d \rangle \\ y_i = \langle \nabla h_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 h_i(\bar{x}) d, d \rangle, \quad i = 1, \dots, l \\ z_i = \langle \nabla g_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 g_i(\bar{x}) d, d \rangle, \quad i = 1, \dots, m \\ w \in \mathbb{R}^n \end{array} \right\}$$

$$S_2(d) = \{ (\alpha, y, z) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m \mid \alpha < 0, y_i = 0 \forall i, z_i \leq 0 \forall i \in I(\bar{x}, d) \}.$$

El conjunto $S_1(d)$ es un espacio afín y $S_2(d)$ es un cono convexo abierto. Si la intersección de ambos fuera no vacía, existiría un vector $w \in \mathbb{R}^n$ tal que satisfaría las condiciones (4.20) y (4.21) con un decremento estricto de segundo orden en la función objetivo, lo que contradice la hipótesis de que $\bar{x}$ es un mínimo local. Por tanto, $S_1(d) \cap S_2(d) = \emptyset$. Por el Teorema de Separación de Conjuntos Convexos, existe un vector no nulo $(\lambda_0, \lambda, \mu) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m \setminus \{0\}$ tal que para todo $p_1 \in S_1(d)$ y $p_2 \in S_2(d)$:

$$\langle (\lambda_0, \lambda, \mu), p_2 \rangle \leq 0 \leq \langle (\lambda_0, \lambda, \mu), p_1 \rangle.$$

Analizando la geometría de los conjuntos, se deduce que $\lambda_0 \geq 0$ y $\mu_i \geq 0$ para $i \in I(\bar{x}, d)$, definiendo $\mu_i = 0$ para los índices restantes. Al ser la dirección w libre en el espacio afín, el término que la multiplica debe ser nulo para garantizar la acotación inferior, lo que da:

$$\lambda_0 \nabla f(\bar{x}) + \sum_{i=1}^l \lambda_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \mu_i \nabla g_i(\bar{x}) = 0.$$

Si $\lambda_0 = 0$, se tendría una combinación lineal nula de los gradientes de las restricciones con coeficientes no negativos, lo cual contradice la condición MFCQ (Proposición 4.2). Por lo tanto, $\lambda_0 > 0$. Dividiendo el sistema por λ_0 y redefiniendo las variables duales, se demuestra que (λ, μ) es un vector de multiplicadores en $\mathcal{M}(\bar{x})$.

Evaluando la desigualdad de separación para el término constante de $S_1(d)$ y normalizando por λ_0 , se obtiene:

$$\langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle \geq 0,$$

lo cual concluye la demostración. ■

Ejemplo 4.18 (Análisis de segundo orden bajo MFCQ). Considérese el problema de optimización en $\mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && f(x) = x_1^2 - x_2^2 \\ &\text{subject to} && g_1(x) = x_2 - x_1 \leq 0, \\ &&& g_2(x) = x_2 + x_1 \leq 0 \end{aligned}$$

La función objetivo tiene un punto de silla en el origen. Las restricciones exigen que $x_1^2 \leq x_2 \leq -x_1^2$, lo que restringe el conjunto factible al único punto $D = \{(0, 0)^T\}$, el cual es el mínimo global.

Evaluamos las restricciones en el origen $\bar{x} = (0, 0)^T$. Ambas son activas. Los gradientes son $\nabla g_1(\bar{x}) = (0, 1)^T$ y $\nabla g_2(\bar{x}) = (0, 1)^T$, por lo que no se satisface LICQ. Sin embargo, el sistema dual $\mu_1(0, 1)^T + \mu_2(0, 1)^T = 0$ con $\mu \geq 0$ tiene por solución única $\mu_1 = \mu_2 = 0$, de donde se verifica MFCQ.

Para el sistema de primer orden en $\bar{x}$, al ser $\nabla f(\bar{x}) = 0$, el único multiplicador de KKT es $\bar{\mu} = (0, 0)^T$. El cono crítico se define por las inecuaciones $\langle \nabla g_i, d \rangle \leq 0$:

$$d_2 \leq 0 \implies K(\bar{x}) = \{(d_1, d_2)^T \mid d_2 \leq 0\}.$$

El cono crítico corresponde al semiplano inferior. La Hessiana de la Lagrangiana en $\bar{x}$ con $\bar{\mu} = 0$ está dada por:

$$\nabla_{xx}^2 L(\bar{x}, \bar{\mu}) = \nabla^2 f(\bar{x}) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}.$$

Evaluando la forma cuadrática para $d = (d_1, d_2)^T \in K(\bar{x})$:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\mu}) d, d \rangle = 2d_1^2 - 2d_2^2.$$

En este caso, la condición necesaria del Teorema 4.9 no se cumple para todas las direcciones críticas (por ejemplo, para $d = (0, -1)^T \in K(\bar{x})$ la forma cuadrática es negativa). Esto ocurre debido a la geometría del conjunto factible, el cual está restringido a un único punto, impidiendo la existencia de curvas factibles no triviales en las direcciones críticas.

Ejemplo 4.19 (No existencia de un multiplicador universal). El siguiente ejemplo muestra por qué en el Teorema 4.9 los multiplicadores pueden depender de la dirección crítica considerada. Sea $n = m = 3$, $l = 0$. Consideremos el problema $\min f(x) = x_3$ sujeto a $g(x) \leq 0$, con:

$$g(x) = \begin{pmatrix} 2\sqrt{3}x_1x_2 - 2x_2^2 - x_3 \\ -2\sqrt{3}x_1x_2 - 2x_1^2 - x_3 \\ -3x_1^2 + x_2^2 - x_3 \end{pmatrix} \leq 0.$$

El origen $\bar{x} = (0, 0, 0)^\top$ es el mínimo global. Los gradientes en $\bar{x}$ son $\nabla f(0) = (0, 0, 1)^\top$ y $\nabla g_i(0) = (0, 0, -1)^\top$ para todo i . Se verifica la condición MFCQ (e.g., con $\bar{d} = (0, 0, 1)^\top$, $\langle \nabla g_i, \bar{d} \rangle = -1 < 0$). El conjunto de multiplicadores es:

$$\mathcal{M}(0) = \{\mu \in \mathbb{R}_+^3 \mid \mu_1 + \mu_2 + \mu_3 = 1\}.$$

El cono crítico es $K(0) = \{d \in \mathbb{R}^3 \mid d_3 = 0\}$. Evaluamos las direcciones críticas $d^1 = (1, 0, 0)^\top$ y $d^2 = (0, 1, 0)^\top$. Para un multiplicador $\mu \in \mathcal{M}(0)$, las formas cuadráticas correspondientes son:

$$\langle \nabla_{xx}^2 L(0, \mu) d^1, d^1 \rangle = -4\mu_2 - 6\mu_3,$$

$$\langle \nabla_{xx}^2 L(0, \mu) d^2, d^2 \rangle = -4\mu_1 + 2\mu_3.$$

Para satisfacer la condición necesaria en d^1 se requiere que $-4\mu_2 - 6\mu_3 \geq 0$, lo que implica $\mu_2 = \mu_3 = 0$, y por tanto, $\mu_1 = 1$. Sin embargo, con este multiplicador, la forma cuadrática en la dirección d^2 resulta negativa.

Por lo tanto, no existe un único multiplicador de Lagrange que satisfaga la condición de semidefinición positiva para todas las direcciones críticas simultáneamente, lo que demuestra que la dependencia del multiplicador respecto a la dirección crítica es estructuralmente necesaria bajo MFCQ.

Teorema 4.10 (Condición suficiente de segundo orden). *Supongamos que f, h, g son dos veces diferenciables en $\bar{x} \in D$. Sea $\bar{x}$ un punto estacionario ($\mathcal{M}(\bar{x}) \neq \emptyset$).*

*Si se cumple la **condición de curvatura estricta**:*

$$\forall d \in K(\bar{x}) \setminus \{0\} \quad \exists (\lambda, \mu) \in \mathcal{M}(\bar{x}) \text{ tal que } \langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle > 0, \quad (4.23)$$

*entonces f satisface la condición de **crecimiento cuadrático** en $\bar{x}$: existen una vecindad U de $\bar{x}$ y una constante $\beta > 0$ tales que*

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\|^2 \quad \forall x \in D \cap U.$$

En consecuencia, $\bar{x}$ es un minimizador local estricto de (4.1).

Prueba. Supongamos, por reducción al absurdo, que se cumple (4.23) pero no el crecimiento cuadrático. Esto implica la existencia de una sucesión $\{x^k\} \subset D \setminus \{\bar{x}\}$ convergiendo a $\bar{x}$ tal que:

$$f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|^2 \quad \forall k \in \mathbb{N}.$$

Sea $d^k = \frac{x^k - \bar{x}}{\|x^k - \bar{x}\|}$. Por compacidad, existe una subsucesión convergente $d^k \rightarrow d$, con $\|d\| = 1$. Dado que el conjunto factible es regular en el límite, se tiene $d \in \mathcal{H}(\bar{x})$. Tomando el límite se deduce que la derivada direccional satisface $\langle \nabla f(\bar{x}), d \rangle \leq 0$. Por lo tanto, la dirección límite pertenece al cono crítico: $d \in K(\bar{x}) \setminus \{0\}$.

Por la hipótesis (4.23), para esta dirección d existe un multiplicador $(\lambda, \mu) \in \mathcal{M}(\bar{x})$ tal que la Hessiana asociada es estrictamente positiva. Para los puntos de la sucesión se cumple:

$$\sum_{i=1}^l \lambda_i h_i(x^k) + \sum_{i=1}^m \mu_i g_i(x^k) \leq 0.$$

Puesto que en $\bar{x}$ la suma es nula por complementariedad, podemos acotar la diferencia de la función objetivo mediante la diferencia de la Lagrangiana:

$$\frac{1}{k} \|x^k - \bar{x}\|^2 > f(x^k) - f(\bar{x}) \geq L(x^k, \lambda, \mu) - L(\bar{x}, \lambda, \mu).$$

Utilizando el desarrollo de Taylor de segundo orden en $\bar{x}$ y la estacionariedad de la Lagrangiana:

$$\frac{1}{k} \|x^k - \bar{x}\|^2 > \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) (x^k - \bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|^2).$$

Dividiendo por la norma al cuadrado y calculando el límite para $k \rightarrow \infty$, obtenemos $0 \geq \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle$, lo cual contradice la hipótesis (4.23). ■

Ejemplo 4.20 (Suficiencia de segundo orden con multiplicadores dependientes). Considérese el problema de optimización en $\mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && f(x) = x_1^2 - x_2^2 \\ &\text{subject to} && g_1(x) = x_2 - x_1^2 \leq 0, \\ &&& g_2(x) = x_1 - x_2^2 \leq 0 \end{aligned}$$

El origen es un punto de silla de la función objetivo, y las restricciones definen una región que acota el conjunto factible en el primer cuadrante. En $\bar{x} = 0$, se satisface LICQ y el sistema KKT da por solución única $\bar{\mu} = (0, 0)^\top$.

El cono crítico se define por las condiciones de linealización: $d_2 \leq 0$ y $d_1 \leq 0 \implies K(\bar{x}) = \{d \in \mathbb{R}^2 \mid d_1 \leq 0, d_2 \leq 0\}$. Dado que $\bar{\mu} = 0$, la Hessiana de la Lagrangiana en $\bar{x}$ coincide con la de la función objetivo:

$$\nabla_{xx}^2 L(\bar{x}, \bar{\mu}) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}.$$

Para cualquier dirección no nula en $K(\bar{x})$ (por ejemplo, $d = (0, -1)^\top$), la forma cuadrática asociada es negativa:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\mu}) d, d \rangle = 2d_1^2 - 2d_2^2 < 0.$$

En este caso, la condición suficiente no se satisface, lo cual es consistente con el hecho de que el origen no es un mínimo local (por ejemplo, para la trayectoria $x(t) = (-t, -t)^\top$ se tiene factibilidad y decremento de la función objetivo). El análisis de segundo orden identifica de este modo la existencia de direcciones de descenso no lineales.

Atención: Casos no concluyentes en el análisis de segundo orden

Al igual que en el cálculo de una variable, existe una diferencia entre las condiciones necesarias y las suficientes de segundo orden. Si para una dirección crítica no nula se cumple que $\langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle = 0$, el término de segundo orden es nulo y el análisis de segundo orden no es concluyente. En este caso, para determinar si el punto es un mínimo, un máximo o un punto de silla, es necesario recurrir a desarrollos de Taylor de orden superior o a análisis topológicos directos.

Ejercicios del Capítulo 4

Parte I: Mecánica Primal-Dual y Condición de Mangasarian-Fromovitz

Ejercicio 4.1. Completar los detalles algebraicos (específicamente la implicación recíproca mediante el Teorema de la Alternativa de Motzkin) omitidos en el texto para la demostración de la Proposición 4.2 (Condición dual de Mangasarian-Fromovitz).

Ejercicio 4.2. Mediante una representación geométrica, formular una hipótesis sobre la solución del problema $\min(x_1 - 1)^2 + (x_2 + 1)^2$ sujeto a $x_1 - x_2 \leq 0$ y $(x_1 - 2)^2 + (x_2 - 1)^2 \leq 1$. Confirmar la hipótesis resolviendo el sistema mediante KKT.

Ejercicio 4.3. Encontrar todos los valores del parámetro $\sigma \in \mathbb{R}$ para los cuales el punto $\bar{x} = (\sqrt{3}/2 + 1, 1/2) \in \mathbb{R}^2$ es una solución del problema $\min x_1 + x_2$ sujeto a $(x_1 - 1)^2 + (x_2 - 1)^2 \leq 1$ y $(x_1 - 2)^2 + x_2^2 \leq 1$.

Ejercicio 4.4. Encontrar todos los valores del parámetro $\sigma \in \mathbb{R}$ para los cuales el punto $\bar{x} = (1, 1) \in \mathbb{R}^2$ es una solución local del problema $\min -x_1 + \sigma x_2$ sujeto a $x_1^2 + x_2^2 \leq 2$ y $x_1^2 - x_2 \leq 0$.

Ejercicio 4.5. Encontrar de manera analítica la solución global del problema $\max 2x_1 + 4x_2 - \frac{1}{2}x_3^2$ sujeto a $x_1^2 + x_2^2 - x_3 \leq 4$ y $x_1 - x_2 + x_3^2 \leq 1$.

Ejercicio 4.6. Demostrar que la solución del problema $\min x_2$ sujeto a $(x_1 - 1)^2 + x_2^2 \leq 1$ y $(x_1 + 1)^2 + x_2^2 \leq 1$ no satisface las condiciones de KKT e interpretar el resultado en relación con el comportamiento con restricciones de igualdad analizado en el Capítulo 2.

Ejercicio 4.7. Sea $\bar{x}$ un minimizador local del problema sobre el simplex escalado: $\min f(x)$ sujeto a $x \geq 0, \sum_{i=1}^n x_i = t$. Demostrar que, si $I_+(\bar{x}) = \{i \mid \bar{x}_i > 0\}$ denota el soporte estrictamente positivo, entonces $\nabla_{x_i} f(\bar{x}) = \min_j \nabla_{x_j} f(\bar{x})$ para todo $i \in I_+(\bar{x})$.

Ejercicio 4.8. Sean $Q \in \mathbb{R}^{n \times n}$, $q \in \mathbb{R}^n$, $B \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$. Demostrar que el conjunto de puntos de KKT de un problema de programación cuadrática constituye una unión finita de conjuntos poliédricos en el espacio extendido $\mathbb{R}^n \times \mathbb{R}^m$.

Ejercicio 4.9. Demostrar que $\bar{x} \in \mathbb{R}^n$ es un punto KKT de $\min f(x)$ sujeto a $h(x) = 0$ y $g(x) \leq 0$ si, y solamente si, existe $(\bar{\beta}, \bar{\gamma}) \in \mathbb{R}^l \times \mathbb{R}^m$ tal que el siguiente sistema no lineal de ecuaciones se anula:

$$F(x, \beta, \gamma) = \begin{pmatrix} \nabla_x L(x, \beta, \max\{0, \gamma\}) \\ h(x) \\ -g(x) + \min\{0, \gamma\} \end{pmatrix} = 0.$$

Ejercicio 4.10. Sea $\bar{x} \in \mathbb{R}^n$ un punto factible de $\min f(x)$ sujeto a $g(x) \leq 0$. Supongamos que $\bar{x}$ satisface MFCQ pero no es estacionario. Demostrar que existe una dirección de descenso para f que apunta hacia el interior del conjunto factible D .

Ejercicio 4.11. Sean $(\bar{x}, \bar{\mu})$ y $(\hat{x}, \hat{\mu})$ dos pares KKT para un problema convexo. Demostrar que los pares cruzados $(\bar{x}, \hat{\mu})$ y $(\hat{x}, \bar{\mu})$ también satisfacen las condiciones KKT.

Ejercicio 4.12. Supongamos que un problema de minimización convexo satisface Slater. Dada una solución $\bar{x}$, determinar un escalar $M > 0$ tal que $\|\bar{\mu}\| \leq M$ para todo multiplicador de Lagrange.

Ejercicio 4.13. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa dos veces diferenciable y $D = \{x \in \mathbb{R}^n \mid Ax = a, x \geq 0\}$ un conjunto poliédrico acotado y no vacío. Demostrar que el problema modificado $\min \|\nabla f(x) + A^T y - z\|^2 + \|Ax - a\|^2 + \langle x, z \rangle^2$ sujeto a $x \geq 0, z \geq 0$ admite por lo menos un punto KKT que resuelve el problema original.

Parte II: Condiciones de Segundo Orden

Ejercicio 4.14. A partir de las demostraciones, demostrar la afirmación recíproca del Teorema 4.10: si $\bar{x}$ satisface MFCQ y la condición de crecimiento cuadrático, entonces se satisface la condición necesaria de segundo orden.

Ejercicio 4.15. Resolver de forma sistemática los siguientes problemas $\min f(x)$ sujeto a $x \in D$:

1. $f(x) = x_1^2 + x_2^2$, con $D = \{x \in \mathbb{R}^2 \mid 2x_1 + x_2 \geq 2, x_1 + 2x_2 \leq \sigma\}$.
2. $f(x) = \log x_1 - x_2$, con $D = \{x \in \mathbb{R}^2 \mid 2x_1 + x_2 \geq 1, -x_1 + x_2 \leq 1, 2x_1 - x_2 \leq 3\}$.
3. $f(x) = 2x_1^2 + x_2^2 + 2x_3^2 - x_1x_3$, con $D = \{x \in \mathbb{R}^3 \mid x_1 - 3x_2 + 2x_3 \leq 1, 2x_1 + x_2 \leq 10\}$.
4. $f(x) = \sum_{j=1}^n (x_j - a_j)^2$, sujeto a $\sum x_j^2 \leq 1$ y $\sum x_j = 0$.

Ejercicio 4.16. Demostrar analíticamente que $\min(x_1 + 1)^3$ sujeto a $0 \leq x_1 + x_2 \leq x_1^3 + \sigma$ tiene soluciones para todo $\sigma \in \mathbb{R}$ y determinar dichas soluciones.

Ejercicio 4.17. Considere un problema de programación cuadrática sobre la bola euclidiana $\|x\| \leq \delta$. Demostrar que $\bar{x}$ es un minimizador global si y solamente si existe $\bar{\mu} \in \mathbb{R}_+$ tal que $(Q + \bar{\mu}I)\bar{x} = -q$, $\|\bar{x}\| \leq \delta$, $\bar{\mu}(\|\bar{x}\| - \delta) = 0$, y la matriz Hessiana $(Q + \bar{\mu}I)$ es semidefinida positiva.

Ejercicio 4.18. Demostrar la desigualdad clásica de las medias aritmética y geométrica utilizando KKT en $\max \prod x_i$ sujeto a $\sum x_i = 1, x \geq 0$.

Ejercicio 4.19. Verificar que $\bar{x}$ es una solución local del problema modificado $\min f(x)$ sujeto a $h(x) = 0$ y $g_j(x) + \sigma_j^2 = 0$. Plantee las condiciones de KKT e interprete la pérdida de fuerza en el análisis de segundo orden comparado con el directo.

Parte III: Tópicos Avanzados - Dualidad, Conos Convexos y KKT Singular

Ejercicio 4.20. Considérese $\min x_1x_2$ sujeto a $x_1^2 + x_2^2 \leq 2$. Formule el sistema KKT, demuestre que hay 4 puntos estacionarios, proyecte la Hessiana sobre el cono crítico e identifique mínimos y máximos locales.

Ejercicio 4.21. Demuestre rigurosamente, utilizando la separación de conos convexos cerrados, el Lema de Farkas (Lema 4.1) para el sistema dual homogéneo y explique cómo garantiza la existencia de MFCQ.

Ejercicio 4.22. Sea $\min(x_1 - 2)^2 + x_2^2$ sujeto a $-x_1^3 + x_2 \leq 0$ y $-x_1^3 - x_2 \leq 0$. Demuestre que se viola LICQ, que KKT no tiene solución, y plantee el sistema de Fritz John (Teorema 4.7) hallando $(\lambda_0, \mu_1, \mu_2) \neq 0$.

Ejercicio 4.23. Demuestre, utilizando la regla de la cadena multivariable, que si un problema es sometido a una transformación afín biyectiva $x = Ay + b$, los multiplicadores de Lagrange KKT son invariantes.

Ejercicio 4.24. Considere $\min -x_1$ sujeto a $x_1^2 + x_2^2 = 1$ y su relajación convexa $x_1^2 + x_2^2 \leq 1$. Resuelva ambos sistemas KKT y demuestre por qué la relajación descarta al maximizador del problema original.

La teoría de dualidad consiste en asociar a un problema de optimización original (primal) un problema alternativo (dual) cuyas propiedades aportan información cuantitativa y cualitativa sobre el primero. En el caso convexo, y muy especialmente en programación lineal, la relación entre ambos es simétrica y permite no solo resolver problemas complejos de forma indirecta, sino también fundamentar las técnicas computacionales. Incluso bajo ausencia de convexidad, el esquema dual proporciona cotas inferiores globales de gran utilidad en la resolución numérica de problemas combinatorios.

4.4. Dualidad en programación lineal

Sea el programa lineal en su forma de minimización, al cual nos referiremos como el **problema primal**:

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid Bx \geq b\}, \quad (4.24)$$

donde $B \in \mathbb{R}^{m \times n}$, $c \in \mathbb{R}^n$ y $b \in \mathbb{R}^m$. El **problema dual** asociado es el programa de maximización:

$$\max \langle b, \mu \rangle \quad \text{sujeto a} \quad \mu \in \Delta = \{\mu \in \mathbb{R}^m \mid B^T \mu = c, \mu \geq 0\}. \quad (4.25)$$

Si el problema primal tiene n variables y m restricciones, el dual se define sobre m variables (una por cada restricción primal) y cuenta con n restricciones de igualdad (una por cada variable primal).

Proposición 4.5 (Teorema de Dualidad Débil). Para cualesquiera puntos factibles $x \in D$ y $\mu \in \Delta$, se cumple:

$$\langle c, x \rangle \geq \langle b, \mu \rangle. \quad (4.26)$$

Prueba. Como $Bx \geq b$ y $\mu \geq 0$, es inmediato que $\langle \mu, Bx \rangle \geq \langle \mu, b \rangle$. Usando la definición de operador adjunto y la restricción dual $B^T \mu = c$:

$$\langle c, x \rangle = \langle B^T \mu, x \rangle = \langle \mu, Bx \rangle \geq \langle \mu, b \rangle = \langle b, \mu \rangle.$$

■

Cualquier punto factible dual proporciona una cota inferior del valor óptimo primal, y recíprocamente, cualquier punto factible primal acota superiormente al problema dual.

Nota: Interpretación de la Dualidad Débil

Si encontramos $\bar{x} \in D$ y $\bar{\mu} \in \Delta$ tales que $\langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle$, la desigualdad (4.26) fuerza a que $\bar{x}$ sea un mínimo global del primal y $\bar{\mu}$ un máximo global del dual.

Teorema 4.11 (Caracterización de Optimalidad). Un punto $\bar{x}$ es una solución del problema primal (4.24) si, y solo si, existe un punto $\bar{\mu}$ que es factible para el problema dual (4.25) y tal que:

$$\langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle, \quad (4.27)$$

es decir, los valores de las funciones objetivo de ambos problemas coinciden.

Más aún, la última afirmación es equivalente a decir que $\bar{\mu}$ es una solución óptima del problema dual (4.25), o que $\bar{\mu}$ es un multiplicador de Lagrange asociado a la solución $\bar{x}$ del problema primal.

Prueba. Por las condiciones necesarias y suficientes de optimalidad de primer orden para problemas afines, $\bar{x}$ es una solución de (4.24) si, y solo si, existe $\bar{\mu} \in \mathbb{R}_+^m$ tal que:

$$c - B^T \bar{\mu} = 0, \quad b - B\bar{x} \leq 0, \quad \langle \bar{\mu}, b - B\bar{x} \rangle = 0.$$

Observamos de forma inmediata que la primera condición asegura que $\bar{\mu} \in \Delta$. Notemos también que el producto interno de la condición de holgura complementaria se puede expandir mediante la definición del operador adjunto:

$$\langle \bar{\mu}, b - B\bar{x} \rangle = \langle \bar{\mu}, b \rangle - \langle B^T \bar{\mu}, \bar{x} \rangle = \langle b, \bar{\mu} \rangle - \langle c, \bar{x} \rangle.$$

Por lo tanto, concluimos que:

$$\langle \bar{\mu}, b - B\bar{x} \rangle = 0 \iff \langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle.$$

Por último, la relación de dualidad débil de la Proposición 4.5 implica que $\bar{\mu}$ es necesariamente una solución del problema dual (4.25), ya que la función objetivo dual alcanza en el punto $\bar{\mu}$ su cota superior global dentro del conjunto factible. ■

Ejemplo 4.21 (Demostración del Lema de Farkas vía Dualidad). El Lema de Farkas establece que el sistema de desigualdades lineales:

$$Ax \leq 0, \quad \langle b, x \rangle > 0 \quad (4.28)$$

carece de solución $x \in \mathbb{R}^n$ si y solo si el sistema alternativo:

$$A^T \mu = b, \quad \mu \geq 0 \quad (4.29)$$

tiene solución $\mu \in \mathbb{R}^m$.

Para probarlo mediante dualidad, planteamos el problema lineal de minimización:

$$\min \langle -b, x \rangle \quad \text{sujeto a} \quad -Ax \geq 0.$$

El origen $x = 0$ siempre es factible y su valor óptimo es nulo. El sistema (4.28) no tiene solución si y solo si no existe ningún punto factible con valor objetivo estrictamente menor que cero. Esto equivale a decir que $\bar{x} = 0$ es un mínimo global, con valor óptimo $\bar{v} = 0$.

Por el Teorema 4.11, esto ocurre si y solo si el dual:

$$\max \langle 0, \mu \rangle \quad \text{sujeto a} \quad -A^T \mu = -b, \quad \mu \geq 0$$

es factible. La restricción de igualdad es exactamente $A^T \mu = b$. Así, el sistema (4.28) es incompatible si y solo si el sistema dual (4.29) es compatible.

Ejemplo 4.22 (Verificación numérica). Tomemos el problema de minimización:

$$\begin{aligned} &\text{minimizar} && 3x_1 + 4x_2 \\ &\text{subject to} && x_1 + 2x_2 \geq 5, \\ &&& 2x_1 + x_2 \geq 6, \\ &&& x_1, x_2 \geq 0 \end{aligned}$$

En el formato estándar (4.24), definimos:

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad c = \begin{pmatrix} 3 \\ 4 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 5 \\ 6 \\ 0 \\ 0 \end{pmatrix}.$$

La intersección de las dos restricciones activas proporciona el mínimo global $\bar{x} = (7/3, 4/3)^T$, con valor óptimo primal $\langle c, \bar{x} \rangle = 37/3$.

Buscamos un punto dual factible $\bar{\mu} \in \mathbb{R}^4$ tal que coincidan los objetivos. Dado que las restricciones de no negatividad no están activas en $\bar{x}$, sus multiplicadores asociados deben ser nulos por holgura complementaria: $\bar{\mu}_3 = 0$ y $\bar{\mu}_4 = 0$. Resolvemos la factibilidad dual $B^T \bar{\mu} = c$ para los componentes restantes:

$$\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} \bar{\mu}_1 \\ \bar{\mu}_2 \end{pmatrix} = \begin{pmatrix} 3 \\ 4 \end{pmatrix} \implies \bar{\mu}_1 = \frac{5}{3}, \quad \bar{\mu}_2 = \frac{2}{3}.$$

El vector $\bar{\mu} = (5/3, 2/3, 0, 0)^T$ es no negativo, por lo que es factible para el dual. Evaluando el objetivo dual en este punto:

$$\langle b, \bar{\mu} \rangle = 5\left(\frac{5}{3}\right) + 6\left(\frac{2}{3}\right) = \frac{37}{3}.$$

Al cumplirse $\langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle = 37/3$, el Teorema 4.11 garantiza que $\bar{x}$ y $\bar{\mu}$ son soluciones óptimas globales de sus respectivos problemas.

Teorema 4.12 (Teorema de Dualidad en Programación Lineal). Para cualquier par de problemas primal (4.24) y dual (4.25), se cumple exactamente una de las siguientes afirmaciones:

1. Ambos problemas son infactibles ($D = \emptyset$ y $\Delta = \emptyset$).
2. Uno de los problemas es ilimitado y el otro es infactible.

3. Ambos problemas son factibles. En este caso, ambos poseen soluciones óptimas y sus valores óptimos coinciden:

$$\min_{x \in D} \langle c, x \rangle = \max_{\mu \in \Delta} \langle b, \mu \rangle. \quad (4.30)$$

Prueba. Para comprobar la existencia del caso (1), basta definir un problema con $n = m = 1$ mediante $B = 0$, $b = 1$, $c = 1$. Aquí $D = \{x \in \mathbb{R} \mid 0 \geq 1\} = \emptyset$ y $\Delta = \{\mu \in \mathbb{R} \mid 0 = 1, \mu \geq 0\} = \emptyset$.

En el caso (2), si el primal es ilimitado ($\bar{v} = \inf_{x \in D} \langle c, x \rangle = -\infty$), la existencia de un punto factible dual $\mu \in \Delta$ contradice el teorema de dualidad débil, pues exigiría que $-\infty \geq \langle b, \mu \rangle$. Por tanto, $\Delta = \emptyset$. El razonamiento es análogo si el dual es ilimitado.

Para el caso (3), supongamos que $D \neq \emptyset$ y $\Delta \neq \emptyset$. Por dualidad débil, el valor óptimo primal es finito: $\bar{v} = \inf_{x \in D} \langle c, x \rangle > -\infty$. El sistema de desigualdades:

$$Bx \geq b, \quad \langle -c, x \rangle > -\bar{v} \quad (4.31)$$

no tiene solución por la definición de ínfimo. Al aplicar el Teorema de la Alternativa de Motzkin, la incompatibilidad de (4.31) implica que el sistema dual homogéneo asociado:

$$B^T \mu - y c = 0, \quad -\langle b, \mu \rangle + y \bar{v} + \eta = 0, \quad \mu \geq 0, \quad y \geq 0, \quad \eta \geq 0 \quad (4.32)$$

admite una solución con $(\mu, y, \eta) \neq 0$ tal que $(y, \eta) \geq 0$ no son nulos de manera simultánea.

Analizamos las posibilidades para el escalar y :

- Si $y = 0$, se requiere que $\eta > 0$. De (4.32) se obtiene el sistema homogéneo $B^T \mu = 0$, $\langle b, \mu \rangle = \eta > 0$, $\mu \geq 0$. Aplicando de nuevo el Teorema de la Alternativa de Motzkin, el sistema $z^0 b + Bz^1 + z^2 = 0$ no posee solución. Sin embargo, al tomar un punto factible $x_0 \in D$ y definir $z^1 = -x_0$, $z^0 = 1 > 0$ y $z^2 = Bx_0 - b \geq 0$, evaluamos $b + B(-x_0) + (Bx_0 - b) = 0$, lo que resulta en una contradicción directa. Así, es obligatorio que $y > 0$.
- Si $y > 0$, dividimos por y y definimos $\bar{\mu} = \mu/y$ y $\bar{\eta} = \eta/y$. Obtenemos $B^T \bar{\mu} = c$, $\bar{\mu} \geq 0$ y $\langle b, \bar{\mu} \rangle = \bar{v} + \bar{\eta}$. Esto demuestra que $\bar{\mu}$ es factible para el dual. Como $\bar{\eta} \geq 0$, se tiene $\langle b, \bar{\mu} \rangle \geq \bar{v}$. Por dualidad débil, debe cumplirse simultáneamente que $\langle b, \bar{\mu} \rangle \leq \bar{v}$, lo que fuerza a que $\bar{\eta} = 0$ y, por ende, $\langle b, \bar{\mu} \rangle = \bar{v}$.

La igualdad de los valores objetivos demuestra la existencia de soluciones óptimas con salto de dualidad nulo. ■

Ejemplo 4.23 (Problemas ilimitados e infactibles). Para ilustrar el caso (2) del teorema de dualidad, consideremos el programa lineal primal:

$$\begin{aligned} &\text{minimizar} && -x_1 \\ &\text{subject to} && -x_1 + x_2 \geq -1, \\ &&& x_1, x_2 \geq 0 \end{aligned}$$

La trayectoria paramétrica $x(t) = (t, t)^T$ con $t \geq 0$ es factible para cualquier valor de t . Al evaluar el objetivo en dicha dirección, obtenemos $\lim_{t \rightarrow \infty} (-t) = -\infty$, de modo que el problema primal es **ilimitado**.

El problema dual asociado viene dado por:

$$\begin{aligned} &\text{maximizar} && -\mu_1 \\ &\text{subject to} && -\mu_1 + \mu_2 = -1, \\ &&& \mu_1 + \mu_3 = 0, \\ &&& \mu_1, \mu_2, \mu_3 \geq 0 \end{aligned}$$

La condición $\mu_1 + \mu_3 = 0$ junto con la no negatividad de las variables fuerza a que $\mu_1 = 0$ y $\mu_3 = 0$. Al sustituir $\mu_1 = 0$ en la primera restricción, se obtiene $\mu_2 = -1$, lo cual es incompatible con la condición $\mu_2 \geq 0$. El problema dual es, por tanto, **infactible**.

Pregunta de Control: Verificación de dualidad

¿Es posible que un problema primal lineal de minimización tenga un punto factible con valor objetivo 10 y su dual correspondiente tenga un punto factible con valor objetivo 15? Justifique su respuesta utilizando la relación de dualidad débil.

Nota: Precios sombra

En economía, los multiplicadores óptimos del dual, $\bar{\mu}_i$, se interpretan como los **precios sombra** de los recursos. Representan la tasa de cambio marginal del valor óptimo de la función objetivo ante variaciones infinitesimales en la disponibilidad de los recursos correspondientes (b_i).

4.5. Dualidad para un problema general

El análisis de dualidad se extiende a problemas con restricciones no lineales de igualdad y desigualdad mediante la función Lagrangiana. Dado el problema general de optimización, al cual llamaremos **problema primal**:

$$\begin{aligned} & \underset{x}{\text{minimizar}} && f(x) \\ & \text{subject to} && x \in D = \{x \in \Omega \mid h(x) = 0, g(x) \leq 0\} \end{aligned} \quad (4.33)$$

donde $\Omega \subset \mathbb{R}^n$, $f: \Omega \rightarrow \mathbb{R}$, $h: \Omega \rightarrow \mathbb{R}^l$ y $g: \Omega \rightarrow \mathbb{R}^m$.

Definición 4.8 (Función Lagrangiana). Asociada al problema primal (4.33), se define la **función Lagrangiana** con respecto a las restricciones funcionales como la aplicación $L: \Omega \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R}$ dada por:

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle, \quad (4.34)$$

donde los vectores $\lambda \in \mathbb{R}^l$ y $\mu \in \mathbb{R}^m$ reciben el nombre de **multiplicadores de Lagrange**.

4.5.1. Formulación Minimax del Problema Primal

La Lagrangiana penaliza implícitamente la violación de las restricciones funcionales al buscar el peor escenario respecto a las variables duales.

Lema 4.4 (Penalización implícita). Para cualquier $x \in \Omega$, se verifica:

$$\sup_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} L(x, \lambda, \mu) = \begin{cases} f(x) & \text{si } x \in D, \\ +\infty & \text{si } x \in \Omega \setminus D. \end{cases} \quad (4.35)$$

Prueba. Si $x \in D$, entonces $h(x) = 0$ y $g(x) \leq 0$. Como $\mu \geq 0$, el término $\langle \mu, g(x) \rangle \leq 0$. El valor máximo de la Lagrangiana se alcanza de forma única con $\mu = 0$ (o en cualquier multiplicador si $g_i(x) = 0$), resultando $\sup L = f(x)$. Si $x \notin D$, alguna restricción se infringe. Si $h_j(x) \neq 0$, basta con tomar $\lambda_j = t \cdot \text{sgn}(h_j(x))$ con $t \rightarrow \infty$. Si $g_i(x) > 0$, tomamos $\mu_i = t \rightarrow \infty$. En ambos casos, el supremo diverge a $+\infty$. ■

Observación. El Lema 4.4 permite reescribir de forma equivalente el problema primal (4.33) como un problema (tipo minimax) sin restricciones funcionales, sobre el conjunto base Ω :

$$\min \left\{ \sup_{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m} L(x, \lambda, \mu) \right\} \quad \text{sueto a } x \in \Omega. \quad (4.36)$$

Además, el **valor óptimo primal** $\bar{v}$ queda caracterizado por la ecuación:

$$\bar{v} = \inf_{x \in \Omega} \left\{ \sup_{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m} L(x, \lambda, \mu) \right\}, \quad (4.37)$$

donde es obligatorio el uso del operador ínfimo (inf), ya que, en ausencia de compacidad en Ω , el mínimo global podría no alcanzarse.

Ejemplo 4.24 (Evaluación del supremo de la Lagrangiana). Dado el problema en $\Omega = \mathbb{R}^2$:

$$\begin{aligned} & \text{minimizar} && x_1 + x_2 \\ & \text{subject to} && x_1^2 + x_2^2 - 1 = 0, \\ & && -x_1 \leq 0 \end{aligned}$$

la Lagrangiana asociada es $L(x, \lambda, \mu) = x_1 + x_2 + \lambda(x_1^2 + x_2^2 - 1) - \mu x_1$.

1. Para el punto factible $x^A = (1, 0)^T \in D$, se tiene $L(x^A, \lambda, \mu) = 1 - \mu$. Su supremo sobre $\mu \geq 0$ se alcanza en $\bar{\mu} = 0$, resultando $f(x^A) = 1$.

2. Para el punto infactible de igualdad $x^B = (2, 0)^T$, se tiene $L(x^B, \lambda, \mu) = 2 + 3\lambda - 2\mu$. El supremo respecto a $\lambda \in \mathbb{R}$ diverge trivialmente a $+\infty$.
3. Para el punto infactible de desigualdad $x^C = (-1, 0)^T$, se tiene $L(x^C, \lambda, \mu) = -1 + \mu$. Como la variable μ puede ser arbitrariamente grande, el supremo sobre $\mu \geq 0$ es $+\infty$.

4.5.2. El Problema Dual General

El **problema dual** se define alternando el orden de los operadores de optimización en la formulación minimax del primal (4.36):

$$\bar{w} = \max_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} \left\{ \inf_{x \in \Omega} L(x, \lambda, \mu) \right\}. \quad (4.38)$$

Para simplificar su análisis, introducimos la **función dual** $\varphi : \mathbb{R}^l \times \mathbb{R}^m \rightarrow [-\infty, +\infty)$ como el ínfimo parcial respecto a las variables primales:

$$\varphi(\lambda, \mu) = \inf_{x \in \Omega} L(x, \lambda, \mu). \quad (4.39)$$

El dominio de factibilidad dual es el conjunto $\Delta = \{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}^m \mid \mu \geq 0, \varphi(\lambda, \mu) > -\infty\}$, de modo que el problema dual se expresa como:

$$\max \varphi(\lambda, \mu) \quad \text{sujeto a} \quad (\lambda, \mu) \in \Delta. \quad (4.40)$$

Teorema 4.13 (Propiedades de la función dual). *El conjunto de factibilidad dual Δ es convexo y la función dual φ es cóncava sobre Δ .*

Prueba. Para cada punto fijo $x \in \Omega$, la función de multiplicadores $(\lambda, \mu) \mapsto L(x, \lambda, \mu)$ es afín y, por ende, cóncava. Como la función dual φ es el ínfimo puntual de una familia de funciones afines continuas, conserva la concavidad de estas. La convexidad del dominio Δ se deduce de forma inmediata al ser el dominio de definición de una función cóncava propia. ■

El problema dual siempre es un problema de optimización convexa (maximización de una función cóncava sobre un conjunto convexo), con independencia de las propiedades topológicas o de convexidad del problema primal original.

4.5.3. Teorema de Dualidad Débil

Teorema 4.14 (Teorema de Dualidad Débil). *Para cualquier punto factible primal $x \in D$ y cualquier punto factible dual $(\lambda, \mu) \in \Delta$, se cumple:*

$$\varphi(\lambda, \mu) \leq f(x). \quad (4.41)$$

Prueba. Evaluando el ínfimo parcial en el punto particular $x \in D$:

$$\varphi(\lambda, \mu) = \inf_{z \in \Omega} L(z, \lambda, \mu) \leq L(x, \lambda, \mu).$$

Como $h(x) = 0$ y $\langle \mu, g(x) \rangle \leq 0$ para todo $\mu \geq 0$, se deduce que $L(x, \lambda, \mu) \leq f(x)$. ■

Ejemplo 4.25 (Obtención analítica de la función dual). Sea el problema de optimización:

$$\min \quad x^2 \quad \text{sujeto a} \quad x - 2 \leq 0.$$

La Lagrangiana para $\mu \geq 0$ es $L(x, \mu) = x^2 + \mu x - 2\mu$. Resolvemos el ínfimo sobre $\Omega = \mathbb{R}$ igualando la derivada respecto a x a cero:

$$2x + \mu = 0 \implies x^*(\mu) = -\frac{\mu}{2}.$$

Sustituyendo x^* en la Lagrangiana, se obtiene la función dual:

$$\varphi(\mu) = -\frac{\mu^2}{4} - 2\mu.$$

Dado que el ínfimo es finito para todo μ , el dominio dual es $\Delta = [0, +\infty)$, el cual es convexo. Además, $\varphi''(\mu) = -1/2 < 0$, confirmando que la función dual es estrictamente cóncava sobre su dominio.

Definición 4.9. La diferencia entre el valor óptimo primal $\bar{v}$ y el dual $\bar{w}$ se llama **salto de dualidad** ($\bar{v} - \bar{w} \geq 0$).

Corolario 4.2 (Ausencia de salto de dualidad). *Si existen puntos factibles $\bar{x} \in D$ y $(\bar{\lambda}, \bar{\mu}) \in \Delta$ tales que $f(\bar{x}) = \varphi(\bar{\lambda}, \bar{\mu})$, entonces $\bar{x}$ y $(\bar{\lambda}, \bar{\mu})$ son soluciones óptimas globales de sus respectivos problemas, y el salto de dualidad es nulo.*

4.5.4. Patologías y Casos Límite en la Teoría de Dualidad

Los siguientes tres ejemplos ilustran cómo la falta de convexidad o la estructura de los dominios pueden impedir el alcance de los óptimos o dar lugar a saltos de dualidad estrictamente positivos.

Ejemplo 4.26 (Mínimo primal no alcanzado, sin salto de dualidad). Sea el problema de optimización definido sobre el conjunto base abierto $\Omega = (0, +\infty)$:

$$\begin{aligned} &\text{minimizar} && 1/x \\ &\text{subject to} && -x \leq 0 \end{aligned}$$

El dominio factible es $D = (0, +\infty)$. El valor del ínfimo primal es $\bar{v} = 0$, pero no se alcanza para ningún x finito. El problema primal no tiene solución.

Para cualquier $\mu \geq 0$, la Lagrangiana es $L(x, \mu) = 1/x - \mu x$. Evaluamos la función dual $\varphi(\mu) = \inf_{x>0} (1/x - \mu x)$:

- Si $\mu > 0$, tomando $x \rightarrow \infty$ el término $-\mu x$ decae sin límite inferior, resultando $\varphi(\mu) = -\infty$.
- Si $\mu = 0$, se tiene $\varphi(0) = \inf_{x>0} 1/x = 0$.

Así, el dominio dual es el conjunto unitario $\Delta = \{0\}$. El problema dual consiste en evaluar $\varphi(0) = 0$, con valor óptimo dual $\bar{w} = 0$. No existe salto de dualidad ($\bar{v} = \bar{w} = 0$) y el dual admite solución óptima en $\bar{\mu} = 0$, pero el primal no es soluble.

Ejemplo 4.27 (Óptimo primal existente, sin salto, pero dual no soluble). Sea el problema en $\Omega = \mathbb{R}$:

$$\begin{aligned} &\text{minimizar} && x \\ &\text{subject to} && x^2 \leq 0 \end{aligned}$$

El único punto factible es $\bar{x} = 0$, por lo que $\bar{v} = f(0) = 0$. La Lagrangiana es $L(x, \mu) = x + \mu x^2$. Calculamos la función dual $\varphi(\mu) = \inf_{x \in \mathbb{R}} (x + \mu x^2)$:

- Si $\mu > 0$, el mínimo de la parábola se alcanza en $x = -1/(2\mu)$, dando $\varphi(\mu) = -1/(4\mu)$.
- Si $\mu = 0$, el ínfimo de la función lineal en $\mathbb{R}$ es $\varphi(0) = -\infty$.

El conjunto de factibilidad dual es el intervalo abierto $\Delta = (0, +\infty)$. El problema dual es $\max_{\mu>0} (-1/(4\mu))$. Al aproximar $\mu \rightarrow \infty$, el supremo es $\bar{w} = 0$. Sin embargo, este valor no se alcanza para ningún multiplicador finito en el dominio abierto Δ . El salto de dualidad es nulo, pero el problema dual no posee solución.

Ejemplo 4.28 (Salto de dualidad estrictamente positivo). Tomemos el problema de optimización discreta sobre el conjunto no convexo $\Omega = \{0, 1\}$:

$$\begin{aligned} &\text{minimizar} && x_1 + x_2 \\ &\text{subject to} && x_1^2 + x_2^2 - 2 \leq 0. \end{aligned}$$

El único punto factible es $\bar{x} = 0$, lo que determina un valor óptimo primal $\bar{v} = f(0) = 0$.

Para $\mu \geq 0$, la Lagrangiana es $L(x, \mu) = -x + \mu(x - 1/2)$. Evaluamos la función dual $\varphi(\mu)$ seleccionando el mínimo en el conjunto discreto Ω :

$$\varphi(\mu) = \min_{x \in \{0,1\}} L(x, \mu) = \min \left\{ -\frac{1}{2}\mu, \frac{1}{2}\mu - 1 \right\}.$$

El máximo de esta función cóncava y continua por partes se localiza en la intersección de ambas rectas:

$$-\frac{1}{2}\mu = \frac{1}{2}\mu - 1 \implies \bar{\mu} = 1.$$

El valor óptimo dual es $\bar{w} = \varphi(1) = -1/2$. Obtenemos un salto de dualidad estrictamente positivo:

$$\bar{v} - \bar{w} = 0 - \left(-\frac{1}{2}\right) = \frac{1}{2} > 0.$$

4.5.5. Teoría de Multiplicadores de Lagrange Globales

Definición 4.10 (Multiplicador de Lagrange Global). Un vector $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}_+^m$ es un **multiplicador de Lagrange global** para el problema primal (4.33) si cumple:

$$\bar{v} = \inf_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu}). \quad (4.42)$$

Esta definición establece que las penalizaciones óptimas permiten hallar el valor óptimo del problema original mediante una minimización no restringida de la Lagrangiana sobre el conjunto base Ω .

Proposición 4.6 (Identidad entre Multiplicadores y Soluciones Duales). Supóngase que el valor óptimo primal $\bar{v}$ es finito y que el salto de dualidad es nulo. El conjunto de multiplicadores de Lagrange del problema primal coincide entonces con el conjunto de soluciones óptimas del problema dual.

Prueba. Si $(\bar{\lambda}, \bar{\mu})$ es un multiplicador de Lagrange, se tiene $\bar{\mu} \geq 0$ y $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{v}$. Como el salto de dualidad es nulo, se cumple $\bar{v} = \bar{w}$, lo que da $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{w}$. Esto demuestra que el par maximiza la función dual.

Recíprocamente, si $(\bar{\lambda}, \bar{\mu}) \in \Delta$ es óptimo dual, entonces $\bar{\mu} \geq 0$ y $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{w}$. Al cumplirse $\bar{w} = \bar{v}$, resulta inmediato que $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{v}$, satisfaciendo la definición de multiplicador. ■

Ejemplo 4.29 (Identidad en un problema cuadrático bidimensional). Consideremos la minimización de una función afín sobre un disco euclidiano compacto en $\Omega = \mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && x_1 - x_2 \\ &\text{subject to} && x_1 + x_2 \leq 0. \end{aligned}$$

El mínimo de esta función sobre el disco de radio $\sqrt{2}$ se alcanza en $\bar{x} = (-1, -1)^\top$. En consecuencia, el **valor óptimo primal** está dado por $\bar{v} = f(-1, -1) = -2$.

Para cualquier escalar $\mu \geq 0$, la Lagrangiana es $L(x, \mu) = x_1 + x_2 + \mu(x_1^2 + x_2^2 - 2)$. Si $\mu = 0$, $\varphi(0) = -\infty$. Para $\mu > 0$, la función es estrictamente convexa. Anulando el gradiente respecto a x :

$$\nabla_x L(x, \mu) = \begin{pmatrix} 1 + 2\mu x_1 \\ 1 + 2\mu x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies x_1^*(\mu) = x_2^*(\mu) = -\frac{1}{2\mu}.$$

Sustituyendo, obtenemos la función dual $\varphi(\mu) = -\frac{1}{2\mu} - 2\mu$.

El problema dual exige maximizar esta función cóncava sobre el dominio $\mu > 0$. Derivando e igualando a cero: $\varphi'(\mu) = \frac{1}{2\mu^2} - 2 = 0 \implies \mu^2 = 1/4$. El único candidato admisible es $\bar{\mu} = 1/2$. Al evaluar, confirmamos que el **valor óptimo dual** es: $\bar{w} = \varphi(1/2) = -2$.

Observamos empíricamente que $\bar{v} = \bar{w} = -2$ (brecha nula). El óptimo dual $\bar{\mu} = 1/2$ debe satisfacer la definición topológica de un multiplicador global (Definición 4.10). Comprobémoslo:

$$\inf_{x \in \mathbb{R}^2} L\left(x, \frac{1}{2}\right) = \inf_{x \in \mathbb{R}^2} \left[\frac{1}{2}(x_1 + 1)^2 + \frac{1}{2}(x_2 + 1)^2 - 2 \right].$$

Es evidente que el valor mínimo de esta suma de cuadrados es -2 , alcanzado en $x = (-1, -1)^\top$. Hemos demostrado que el conjunto de multiplicadores de Lagrange y el de soluciones duales son idénticos.

Teorema 4.15 (Garantía de Existencia de Solución Dual). Supóngase que el conjunto factible del problema primal es no vacío ($D \neq \emptyset$) y que el problema primal posee al menos un multiplicador de Lagrange global.

1. Si el conjunto de factibilidad dual es no vacío ($\Delta \neq \emptyset$), entonces el problema dual posee una solución óptima.
2. Si el conjunto de factibilidad dual es vacío ($\Delta = \emptyset$), entonces el valor óptimo del problema primal es infinito negativo ($\bar{v} = -\infty$).

Prueba. Sea $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}_+^m$ un multiplicador de Lagrange. Por definición (Definición 4.10), $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{v}$.

Si $\Delta \neq \emptyset$, por el Teorema de Dualidad Débil (Teorema 4.14), $\bar{v}$ acota superiormente a cualquier valor factible dual.

Puesto que el par $(\bar{\lambda}, \bar{\mu})$ alcanza este límite superior, pertenece a Δ y es un maximizador global de la función dual.

Si $\Delta = \emptyset$, implica que para todo par (λ, μ) se tiene $\varphi(\lambda, \mu) = -\infty$. Evaluando en el multiplicador garantizado por hipótesis, obtenemos $\varphi(\bar{\lambda}, \bar{\mu}) = -\infty$. Por ende, $\bar{v} = -\infty$. ■

Ejemplo 4.30 (Infactibilidad dual y divergencia primal). Consideremos el siguiente problema lineal sobre $\Omega = \mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && x_1 - x_2 \\ &\text{subject to} && x_1 + x_2 \leq 0. \end{aligned}$$

El dominio factible D contiene a $(0, 0)$. Tomando $x(t) = (-t, t)^\top$ para $t > 0$, la función objetivo evaluada en esta trayectoria es $-2t$. Al hacer $t \rightarrow \infty$, el problema es ilimitado: $\bar{v} = -\infty$.

Construyamos la función Lagrangiana para $\mu \geq 0$: $L(x, \mu) = x_1(1 + \mu) + x_2(\mu - 1)$. Para que el ínfimo sea finito, se requeriría $1 + \mu = 0$ y $\mu - 1 = 0$, lo cual es una contradicción. Concluimos que para cualquier $\mu \geq 0$, $\varphi(\mu) = -\infty$. Por tanto, $\Delta = \emptyset$, lo que corrobora el Teorema 4.15.

Teorema 4.16 (Condiciones de Kuhn-Tucker No Diferenciables). Un punto $\bar{x} \in D$ es solución óptima del problema primal y $(\bar{\lambda}, \bar{\mu})$ es un multiplicador de Lagrange si y solo si se cumplen las condiciones:

$$L(\bar{x}, \bar{\lambda}, \bar{\mu}) = \min_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu}), \quad (4.43)$$

$$\bar{\mu}_i g_i(\bar{x}) = 0, \quad \forall i = 1, \dots, m. \quad (4.44)$$

Prueba. ($\Rightarrow$) Como $\bar{x}$ es óptimo y $(\bar{\lambda}, \bar{\mu})$ es multiplicador, se tiene $f(\bar{x}) = \inf_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu})$. Como $\bar{x} \in D$, resulta $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x}) + \langle \bar{\mu}, g(\bar{x}) \rangle$. La condición $\bar{\mu} \geq 0, g(\bar{x}) \leq 0$ exige que $\langle \bar{\mu}, g(\bar{x}) \rangle \leq 0$. Al ser el ínfimo $f(\bar{x})$, se debe verificar de forma obligatoria que $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x})$, lo que prueba (4.43) y requiere $\bar{\mu}_i g_i(\bar{x}) = 0$.

($\Leftarrow$) Por holgura complementaria y factibilidad, se tiene $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x})$. Sustituyendo en la minimización global (4.43), resulta $f(\bar{x}) = \inf_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu})$, lo cual demuestra que $(\bar{\lambda}, \bar{\mu})$ es un multiplicador y $\bar{x}$ es óptimo global. ■

4.5.6. Dualidad Fuerte y la Condición de Slater

Definición 4.11 (Condición de Regularidad de Slater). Se dice que el problema primal (4.33) satisface la **condición de Slater** si las restricciones de igualdad son afines ($h(x) = Ax - a$), las restricciones de desigualdad g_i son funciones convexas en Ω , y existe un punto de regularidad $\hat{x} \in \text{int } \Omega$ tal que:

$$A\hat{x} - a = 0 \quad \text{y} \quad g_i(\hat{x}) < 0 \quad \forall i = 1, \dots, m. \quad (4.45)$$

Teorema 4.17 (Teorema de Dualidad Fuerte de Slater). Supóngase que en el problema primal (4.33) las funciones f y g_i son convexas, las restricciones de igualdad son afines dadas por $h(x) = Ax - a$ con $A \in \mathbb{R}^{l \times n}$, y el valor óptimo primal $\bar{v}$ es finito. Si se satisface la condición de regularidad de Slater (Definición 4.11), entonces el salto de dualidad es nulo ($\bar{v} = \bar{w}$), y el problema dual admite al menos una solución óptima $(\bar{\lambda}, \bar{\mu}) \in \Delta$.

Prueba. Supongamos, sin pérdida de generalidad, que las filas de la matriz A son linealmente independientes. Definamos el conjunto de valores admisibles para la función objetivo y las perturbaciones de las restricciones primales:

$$C = \left\{ (y, z, c) \in \mathbb{R} \times \mathbb{R}^m \times \mathbb{R}^l \mid \exists x \in \Omega \text{ t.q. } f(x) \leq y, g(x) \leq z, Ax - a = c \right\}.$$

La convexidad de f y g_i , sumada al carácter afín de h , garantizan que C es un conjunto convexo en $\mathbb{R} \times \mathbb{R}^m \times \mathbb{R}^l$. Dado que $\bar{v}$ es el valor óptimo primal, el punto $(\bar{v}, 0, 0)$ se encuentra en la frontera del conjunto convexo C .

Aplicamos el Teorema de Separación de Conjuntos Convexos (Lema de Minkowski). Existe un hiperplano de soporte en $(\bar{v}, 0, 0)$, caracterizado por un vector normal no nulo $(\beta, \bar{\mu}, \bar{\lambda}) \in \mathbb{R} \times \mathbb{R}^m \times \mathbb{R}^l$, tal que:

$$\beta \bar{v} \leq \beta y + \langle \bar{\mu}, z \rangle + \langle \bar{\lambda}, c \rangle \quad \forall (y, z, c) \in C. \quad (4.46)$$

Para que la desigualdad se cumpla asintóticamente es necesario que $\beta \geq 0$ y $\bar{\mu} \geq 0$.

Asumamos que $\beta = 0$. Evaluando (4.46) en el punto factible de Slater $\hat{x}$, se obtiene $0 \leq \langle \bar{\mu}, g(\hat{x}) \rangle$. Dado que $\bar{\mu} \geq 0$ y cada componente $g_i(\hat{x}) < 0$, la única posibilidad es que $\bar{\mu} = 0$. Sustituyendo $\beta = 0$ y $\bar{\mu} = 0$, nos queda $0 \leq \langle \bar{\lambda}, c \rangle$ para todo c factible. Como A tiene rango completo, esto es posible solo si $\bar{\lambda} = 0$. Esto implica que el vector normal es nulo, contradiciendo el Teorema de Separación. Por consiguiente, $\beta > 0$.

Dividiendo (4.46) por β y definiendo $\lambda^* = \bar{\lambda}/\beta \in \mathbb{R}^l$ y $\mu^* = \bar{\mu}/\beta \in \mathbb{R}_+^m$. Tomando $(y, z, c) = (f(x), g(x), Ax - a) \in C$, la inecuación se reduce a:

$$\bar{v} \leq f(x) + \langle \mu^*, g(x) \rangle + \langle \lambda^*, Ax - a \rangle = L(x, \lambda^*, \mu^*).$$

Tomando el ínfimo sobre todo $x \in \Omega$, concluimos que $\bar{v} \leq \varphi(\lambda^*, \mu^*)$. A su vez, por Dualidad Débil (Teorema 4.14), sabemos que $\varphi(\lambda^*, \mu^*) \leq \bar{v}$. Así, $\varphi(\lambda^*, \mu^*) = \bar{v}$, probando que no hay salto de dualidad y el óptimo dual se alcanza. ■

Ejemplo 4.31 (Verificación de la dualidad fuerte). Sea el problema de optimización en $\Omega = \mathbb{R}$:

$$\begin{aligned} & \text{minimizar} \quad (x - 3)^2 \\ & \text{subject to} \quad x - 2 \leq 0 \end{aligned}$$

El origen $\hat{x} = 0 \in \text{int } \mathbb{R}$ cumple $g(0) = -2 < 0$, satisfaciendo la condición de Slater. El mínimo restringido se alcanza en la frontera $\bar{x} = 2$, dando $\bar{v} = 1$.

Construimos la función dual para $\mu \geq 0$: $\varphi(\mu) = \inf_{x \in \mathbb{R}} \{(x - 3)^2 + \mu(x - 2)\} = -\frac{\mu^2}{4} + \mu$. Maximizando la función dual, calculamos el óptimo $\bar{\mu} = 2$. El valor óptimo dual es $\bar{w} = \varphi(2) = 1$. Verificamos que $\bar{v} = \bar{w} = 1$.

4.5.7. El Problema Dual de Wolfe

Definición 4.12 (Problema Dual de Wolfe). Asociado al problema primal (4.33), asumiendo que Ω es abierto en $\mathbb{R}^n$ y que f, g, h son continuamente diferenciables, el **problema dual de Wolfe** se define como:

$$\max_{\substack{x \in \Omega, \lambda \in \mathbb{R}^l \\ \mu \geq 0}} L(x, \lambda, \mu) \quad \text{sueto a} \quad \nabla_x L(x, \lambda, \mu) = 0. \quad (4.47)$$

Denotaremos al conjunto de factibilidad de este problema como W .

Teorema 4.18 (Dualidad Débil de Wolfe). Si el problema primal original es de minimización convexa (es decir, f y g_i son convexas, y h es afín), entonces para cualquier punto factible primal $\bar{x} \in D$ y cualquier punto factible del dual de Wolfe $(x, \lambda, \mu) \in W$, se verifica que:

$$L(x, \lambda, \mu) \leq f(\bar{x}). \quad (4.48)$$

Prueba. Dado que f y g_i son convexas y h es afín, la Lagrangiana $x \mapsto L(x, \lambda, \mu)$ preserva la convexidad. Por la definición de W , sabemos que $\nabla_x L(x, \lambda, \mu) = 0$. En funciones convexas, la anulación del gradiente garantiza que x es un minimizador global: $L(x, \lambda, \mu) = \inf_{z \in \Omega} L(z, \lambda, \mu) = \varphi(\lambda, \mu)$. Aplicando el Teorema de Dualidad Débil General (Teorema 4.14), sabemos que $\varphi(\lambda, \mu) \leq f(\bar{x})$. Sustituyendo la igualdad previa, se concluye: $L(x, \lambda, \mu) \leq f(\bar{x})$. ■

Ejemplo 4.32 (Coincidencia del Dual de Wolfe en Programación Lineal). Sea el programa primal lineal: $\min \langle c, x \rangle$ sujeto a $Bx \geq b$. Adaptando a $g(x) = b - Bx \leq 0$, la Lagrangiana es $L(x, \mu) = \langle c - B^T \mu, x \rangle + \langle b, \mu \rangle$. La restricción del dual de Wolfe es $\nabla_x L(x, \mu) = 0$, lo que equivale a $c - B^T \mu = 0$. Evaluando la función objetivo $L(x, \mu)$ bajo esta condición, el término con x se anula, resultando $L(x, \mu) = \langle b, \mu \rangle$. El dual de Wolfe se simplifica a maximizar $\langle b, \mu \rangle$ sujeto a $B^T \mu = c$ y $\mu \geq 0$, que es la formulación dual estándar planteada en (4.25).

4.5.8. Caracterización mediante Puntos de Silla

Definición 4.13 (Punto de Silla). Un punto $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in \Omega \times \mathbb{R}^l \times \mathbb{R}_+^m$ es un **punto de silla** de la Lagrangiana si verifica la doble desigualdad topológica:

$$L(\bar{x}, \lambda, \mu) \leq L(\bar{x}, \bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu}) \quad (4.49)$$

para todo $x \in \Omega$, todo $\lambda \in \mathbb{R}^l$ y todo $\mu \geq 0$.

Teorema 4.19 (Teorema del Punto de Silla). Un punto $\bar{x} \in \Omega$ es solución óptima del problema primal y $(\bar{\lambda}, \bar{\mu})$ es solución óptima del problema dual asociado con salto de dualidad nulo si y solo si $(\bar{x}, \bar{\lambda}, \bar{\mu})$ es un punto de silla de la Lagrangiana.

Prueba. ($\Rightarrow$) : Por el Lema 4.4 y la factibilidad de $\bar{x}$, se tiene $L(\bar{x}, \lambda, \mu) \leq f(\bar{x}) = L(\bar{x}, \bar{\lambda}, \bar{\mu})$, probando la primera desigualdad. Para la segunda, la dualidad fuerte implica $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = \varphi(\bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu})$. ($\Leftarrow$) : Si es un punto de silla, al tomar el supremo en las variables duales de la primera desigualdad: $\sup L(\bar{x}, \lambda, \mu) \leq L(\bar{x}, \bar{\lambda}, \bar{\mu}) < +\infty$. Por el Lema 4.4, esto fuerza a que $\bar{x} \in D$ y $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x})$. De la segunda desigualdad, $f(\bar{x}) \leq L(x, \bar{\lambda}, \bar{\mu})$. Tomando el ínfimo sobre $x \in \Omega$, resulta $f(\bar{x}) \leq \varphi(\bar{\lambda}, \bar{\mu})$. Por el Teorema de Dualidad Débil, esto obliga a que $f(\bar{x}) = \varphi(\bar{\lambda}, \bar{\mu})$, anulando el salto de dualidad. ■

Ejemplo 4.33 (Punto de silla de la Lagrangiana). Tomemos el problema: $\min x^2 - 4x$ sujeto a $x - 1 \leq 0$. El mínimo restringido en $D = (-\infty, 1]$ se alcanza en $\bar{x} = 1$, con $\bar{v} = -3$. La Lagrangiana es $L(x, \mu) = x^2 - 4x + \mu(x - 1)$. Igualando a cero la derivada en $\bar{x} = 1$, obtenemos $\bar{\mu} = 2$.

Verificamos las condiciones de punto de silla para $(\bar{x}, \bar{\mu}) = (1, 2)$:

1. **Izquierda:** Para cualquier $\mu \geq 0$, $L(1, \mu) = -3 \leq L(1, 2) = -3$, lo cual se cumple.

2. **Derecha:** Para cualquier $x \in \mathbb{R}$, $L(1, 2) \leq L(x, 2) \implies -3 \leq x^2 - 2x - 2 \implies (x - 1)^2 \geq 0$, la cual se verifica siempre.

Esto confirma que la terna constituye un punto de silla de la Lagrangiana.

4.5.9. Subgradiente de la Función Dual

Proposición 4.7 (Subgradiente de la Función Dual). Sean $(\lambda, \mu) \in \Delta$ y sea $x(\lambda, \mu) \in \Omega$ tal que se alcanza el ínfimo parcial, es decir, $\varphi(\lambda, \mu) = L(x(\lambda, \mu), \lambda, \mu)$. El vector de violaciones funcionales:

$$-\begin{pmatrix} h(x(\lambda, \mu)) \\ g(x(\lambda, \mu)) \end{pmatrix} \in \partial(-\varphi)(\lambda, \mu) \quad (4.50)$$

es un subgradiente de la función dual negativa $-\varphi$ en el punto (λ, μ) .

Prueba. Un vector s es un subgradiente si $\varphi(\eta, \nu) \leq \varphi(\lambda, \mu) - \langle s, (\eta - \lambda, \nu - \mu)^\top \rangle$. Partiendo de la definición de la función dual en un punto genérico $(\eta, \nu) \in \Delta$:

$$\varphi(\eta, \nu) = \inf_{z \in \Omega} L(z, \eta, \nu) \leq L(x(\lambda, \mu), \eta, \nu).$$

Desarrollando la expresión de la Lagrangiana evaluada en $x(\lambda, \mu)$:

$$L(x(\lambda, \mu), \eta, \nu) = \varphi(\lambda, \mu) + \langle \eta - \lambda, h(x(\lambda, \mu)) \rangle + \langle \nu - \mu, g(x(\lambda, \mu)) \rangle.$$

Esto verifica la desigualdad del subgradiente al tomar $s = -(h(x(\lambda, \mu)), g(x(\lambda, \mu)))^\top$. ■

Pregunta de Control: Interpretación de puntos de silla

Si se encuentra un punto de silla para la función Lagrangiana de un problema no convexo, ¿se puede asegurar que dicho punto define la solución global del problema primal? Justifique su respuesta basándose en las hipótesis del Teorema 4.19.

Nota: Relajación Lagrangiana

El Teorema de Dualidad Débil sustenta la técnica conocida como **relajación Lagrangiana**, utilizada en optimización entera y combinatoria. Al trasladar restricciones difíciles a la función objetivo mediante multiplicadores fijos $\mu \geq 0$, se obtiene un problema relajado fácil de resolver cuyo óptimo proporciona siempre una cota inferior rigurosa para el valor mínimo del problema original.

Ejercicios del Capítulo 5

Parte I: Dualidad en Programación Lineal

Ejercicio 4.25 (Dualidad en formato lineal general). Sea el problema de programación lineal en formato general:

$$\begin{aligned} &\text{minimizar} && \langle c_1, x_1 \rangle + \langle c_2, x_2 \rangle \\ &\text{subject to} && (x_1, x_2) \in D \end{aligned}$$

donde el conjunto factible D está definido por:

$$D = \left\{ (x_1, x_2) \in \mathbb{R}^{n_1} \times \mathbb{R}_+^{n_2} \mid \begin{array}{l} B_{11}x_1 + B_{12}x_2 = b_1, \\ B_{21}x_1 + B_{22}x_2 \geq b_2 \end{array} \right\},$$

con $c_1 \in \mathbb{R}^{n_1}$, $c_2 \in \mathbb{R}^{n_2}$, $B_{11} \in \mathbb{R}^{l \times n_1}$, $B_{12} \in \mathbb{R}^{l \times n_2}$, $B_{21} \in \mathbb{R}^{m \times n_1}$, $B_{22} \in \mathbb{R}^{m \times n_2}$, $b_1 \in \mathbb{R}^l$ y $b_2 \in \mathbb{R}^m$.

Demuestre que el problema dual asociado viene dado por:

$$\begin{aligned} &\text{maximizar} && \langle b_1, \lambda \rangle \\ &\text{subject to} && (\lambda, \mu) \in \Delta \end{aligned}$$

donde el conjunto factible dual es:

$$\Delta = \left\{ (\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m \mid \begin{array}{l} B_{11}^T \lambda + B_{21}^T \mu = c_1, \\ B_{12}^T \lambda + B_{22}^T \mu \leq c_2 \end{array} \right\},$$

y verifique que se cumplen todas las relaciones de dualidad débil y fuerte para este par de problemas.

Ejercicio 4.26 (Verificación numérica de dualidad). Dado el problema de programación lineal de maximización:

$$\begin{array}{ll} \text{maximizar} & \langle c, x \rangle \\ \text{subject to} & Bx \leq b, \\ & x \geq 0 \end{array}$$

donde:

$$B = \begin{pmatrix} 2 & 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 \end{pmatrix}, \quad c = \begin{pmatrix} 4 \\ 5 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \quad b = \begin{pmatrix} 8 \\ 7 \\ 3 \end{pmatrix}.$$

Formule el problema dual de minimización correspondiente y verifique que los puntos $\bar{x} = (3, 2, 0, 0, 1)^T$ y $\bar{\mu} = (1, 2, 0)^T$ son las soluciones óptimas de los problemas primal y dual, respectivamente.

Ejercicio 4.27 (Acotamiento y optimalidad en sistemas homogéneos). Demuestre que el problema de maximización lineal $\max \langle c, x \rangle$ sujeto a $Ax = 0, x \geq 0$ tiene un valor óptimo finito si y solo si $\bar{x} = 0$ es una solución óptima del problema.

Ejercicio 4.28 (Análisis de sensibilidad paramétrica). Para el problema lineal paramétrico:

$$\begin{array}{ll} \text{minimizar} & 3x_1 + 4x_2 + x_3 + x_4 \\ \text{subject to} & x_1 + x_2 + x_3 - x_4 \geq 2, \\ & -2x_1 + 2x_2 + x_3 + x_4 \geq \sigma, \\ & x_i \geq 0, \quad i = 1, \dots, 4 \end{array}$$

donde $\sigma \in \mathbb{R}$ es un parámetro real.

1. Formule el problema dual asociado.
2. Resuelva el problema dual analíticamente para cada valor posible de σ .
3. Utilizando la solución dual, determine el valor óptimo del problema primal en función de σ .

Parte II: Dualidad en Problemas Generales y Puntos de Silla

Ejercicio 4.29 (Dual de un problema de programación cuadrática). Dado el problema de programación cuadrática $\min \frac{1}{2} \langle Qx, x \rangle + \langle q, x \rangle$ sujeto a $Bx \leq b$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, $q \in \mathbb{R}^n$, $B \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$.

Demuestre que el problema dual asociado puede formularse como el siguiente problema de maximización cuadrática sobre el ortante no negativo:

$$\text{maximizar}_{\mu \geq 0} \left\{ -\frac{1}{2} \langle (BQ^{-1}B^T)\mu, \mu \rangle - \langle b + BQ^{-1}q, \mu \rangle - \frac{1}{2} \langle Q^{-1}q, q \rangle \right\}$$

Ejercicio 4.30 (Cálculo analítico de la función dual). Calcule analíticamente la función dual $\varphi(\mu)$ y resuelva de forma exacta el problema dual del problema general $\min f(x)$ sujeto a $x \in \Omega$ con $g(x) \leq 0$, para cada uno de los siguientes casos:

1. $f(x) = x_1 - x_2$, $g(x) = x_1 + x_2 - 1$, $\Omega = \mathbb{R}_+^2$.
2. $f(x) = \frac{1}{2}(x_1^2 + x_2^2)$, $g(x) = x_1 - 1$, $\Omega = \mathbb{R}^2$.
3. $f(x) = x$, $g(x) = x^2$, $\Omega = \mathbb{R}$.

En cada caso, determine si existe salto de dualidad.

Ejercicio 4.31 (Dualidad en problemas de proyección). Sean $A \in \mathbb{R}^{m \times n}$ una matriz de rango completo de filas y $z \in \mathbb{R}^n$ un punto de proyección fijo. Demuestre que el problema dual asociado al problema de proyección ortogonal $\min \frac{1}{2\|z-x\|^2}$ sujeto a $Ax = 0$ es equivalente a un problema de proyección de un vector transformado sobre la imagen de la matriz transpuesta A^T (un subespacio afín).

Ejercicio 4.32 (Invariancia y dependencia de la formación dual). Considere las dos formulaciones matemáticamente equivalentes del mismo problema geométrico:

$$(P1) \quad \min \langle a, x \rangle \quad \text{sujeto a} \quad \|x\| \leq 1,$$

$$(P2) \quad \min \langle a, x \rangle \quad \text{sujeto a} \quad \|x\|^2 \leq 1.$$

Demuestre que sus respectivos problemas duales de Lagrange son algebraicamente diferentes y analice cómo influye la elección de la función de restricción en la suavidad de la función dual.

Ejercicio 4.33 (Teorema de Everett). Sean $(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m$ y sea $x(\lambda, \mu) \in \Omega$ una solución óptima del problema de optimización no restringido de la Lagrangiana $\min_{x \in D} L(x, \lambda, \mu)$. Demuestre que el punto $x(\lambda, \mu)$ es una solución óptima del problema perturbado $\min f(x)$ sujeto a $h(x) = y$ y $g(x) \leq z$, donde los vectores de perturbación están definidos por $y = h(x(\lambda, \mu))$ y $z_j = g_j(x(\lambda, \mu))$ si $\mu_j > 0$, o $z_j \geq g_j(x(\lambda, \mu))$ si $\mu_j = 0$.

Ejercicio 4.34 (Puntos de Silla e Igualdad Minimax). Demuestre algebraicamente que $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in \Omega \times \mathbb{R}^l \times \mathbb{R}_+^m$ es un punto de silla de la Lagrangiana si y solo si se verifica la igualdad de los valores minimax:

$$\min_{x \in \Omega} \sup_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} L(x, \lambda, \mu) = \max_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} \inf_{x \in \Omega} L(x, \lambda, \mu) = L(\bar{x}, \bar{\lambda}, \bar{\mu}).$$

Ejercicio 4.35 (Proyección sobre un semiespacio). Sean $a \in \mathbb{R}^n \setminus \{0\}$ y $b \in \mathbb{R}^n$. Formule y resuelva de manera analítica el problema dual asociado al problema de minimización $\min \frac{1}{2}\|x\|^2 - \langle b, x \rangle$ sujeto a $\langle a, x \rangle \leq 0$. Utilice la solución del problema dual para obtener la solución óptima del problema primal.

Ejercicio 4.36 (Descomposición dual en optimización separable). Considere un problema con estructura separable donde las variables y las funciones pueden dividirse en p bloques independientes:

$$\begin{aligned} & \text{minimizar} \quad \sum_{j=1}^p f_j(x_j) \\ & \text{subject to} \quad \sum_{j=1}^p h_j(x_j) = 0, \\ & \quad \quad \quad \sum_{j=1}^p g_j(x_j) \leq 0, \\ & \quad \quad \quad x_j \in \Omega_j, \quad j = 1, \dots, p \end{aligned}$$

donde $\Omega_j \subset \mathbb{R}^{n_j}$, $f_j : \Omega_j \rightarrow \mathbb{R}$, $h_j : \Omega_j \rightarrow \mathbb{R}^l$ y $g_j : \Omega_j \rightarrow \mathbb{R}^m$.

Demuestre que la función dual $\varphi(\lambda, \mu)$ de este problema general puede descomponerse en la suma de p funciones duales independientes $\varphi(\lambda, \mu) = \sum_{j=1}^p \varphi_j(\lambda, \mu)$, donde cada componente se calcula resolviendo un subproblema local:

$$\varphi_j(\lambda, \mu) = \inf_{x_j \in \Omega_j} \{f_j(x_j) + \langle \lambda, h_j(x_j) \rangle + \langle \mu, g_j(x_j) \rangle\}.$$

Explique la importancia de esta propiedad en el desarrollo de algoritmos de optimización distribuida (descomposición dual).

Ejercicio 4.37 (Formulación de Consenso y Descomposición Dual). Considere el problema de optimización no separable con acoplamiento por la variable de decisión única x :

$$\begin{aligned} & \text{minimizar} \quad \sum_{i=0}^m f_i(x) \\ & \text{subject to} \quad x \in D_i, \quad i = 0, \dots, m \end{aligned}$$

donde $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ son funciones convexas y $D_i \subset \mathbb{R}^n$ son conjuntos poliedrales acotados tales que $\bigcap_{i=0}^m D_i \neq \emptyset$.

Para transformar este problema primal en uno con estructura separable, introducimos variables locales independientes $x_i \in \mathbb{R}^n$ para cada bloque ($i = 1, \dots, m$) junto con una variable de consenso global $x_0 \in \mathbb{R}^n$, imponiendo las

restricciones de acoplamiento $x_i = x_0$:

$$\begin{aligned} & \underset{x_0, x_1, \dots, x_m \in \mathbb{R}^n}{\text{minimizar}} && \sum_{i=0}^m f_i(x_i) \\ & \text{subject to} && x_i - x_0 = 0, \quad i = 1, \dots, m, \\ & && x_i \in D_i, \quad i = 0, \dots, m \end{aligned}$$

1. Demuestre que el problema dual de Lagrange asociado a esta formulación se puede escribir de la forma:

$$\max_{\lambda_1, \dots, \lambda_m \in \mathbb{R}^n} \left\{ \varphi_0 \left(\sum_{i=1}^m \lambda_i \right) + \sum_{i=1}^m \varphi_i(\lambda_i) \right\},$$

donde las funciones duales componentes vienen dadas por:

$$\varphi_0(u) = \min_{x_0 \in D_0} \{f_0(x_0) - \langle u, x_0 \rangle\}, \quad \varphi_i(\lambda_i) = \min_{x_i \in D_i} \{f_i(x_i) + \langle \lambda_i, x_i \rangle\}, \quad i = 1, \dots, m.$$

2. Demuestre que este par de problemas satisface la dualidad fuerte, justificando la nulidad del salto de dualidad.

Parte II.

Métodos Computacionales

5. Resumen Teórico y Preliminares Matemáticos

En este capítulo recordamos varios hechos fundamentales de la teoría de Optimización, tales como la existencia de soluciones, las condiciones de regularidad de las restricciones y de optimalidad, la convexidad de conjuntos y de funciones, y elementos de la teoría de dualidad. El objetivo es facilitar las referencias futuras a lo largo de este volumen.

Las demostraciones de estos resultados no serán presentadas aquí, ya que se espera que el lector haya asimilado el primer volumen de esta obra [Izm20]. Presentaremos también algunos hechos auxiliares del Análisis y del Álgebra Lineal, que serán utilizados intensivamente en el diseño de los métodos computacionales.

5.1. Existencia de soluciones

Sean dados un conjunto $D \subset \mathbb{R}^n$ y una función $f : \Omega \rightarrow \mathbb{R}$, donde $D \subset \Omega$. Los métodos computacionales que estudiaremos están dedicados al problema de hallar un minimizador de f en el conjunto D . Este problema se escribirá como:

$$\min f(x) \quad \text{sujeto a } x \in D. \quad (5.1)$$

El conjunto D será llamado **conjunto factible** del problema, los puntos de D serán llamados **puntos factibles**, y f será llamada **función objetivo**.

Definición 5.1 (Tipos de minimizadores). Decimos que un punto $\bar{x} \in D$ es:

1. **Minimizador global** de (5.1), si $f(\bar{x}) \leq f(x)$ para todo $x \in D$.
2. **Minimizador local** de (5.1), si existe una vecindad U de $\bar{x}$ tal que $f(\bar{x}) \leq f(x)$ para todo $x \in D \cap U$.

Si para todo $x \neq \bar{x}$ la desigualdad correspondiente es estricta, $\bar{x}$ será llamado **minimizador estricto**.

Definición 5.2 (Valor óptimo). Decimos que $\bar{v} \in [-\infty, +\infty]$ definido por $\bar{v} = \inf\{f(x) \mid x \in D\}$ es el **valor óptimo** del problema (5.1), donde entendemos que $\bar{v} = +\infty$ si $D = \emptyset$.

Una función puede admitir varios minimizadores globales, pero el valor óptimo (global) del problema siempre es único. Cuando $\bar{v} = +\infty$ o $\bar{v} = -\infty$, el problema no posee solución global. Pero incluso cuando $\bar{v}$ es finito, el minimizador global puede no existir (por ejemplo, minimizar $f(x) = e^x$ en $\mathbb{R}$).

Algunas de las condiciones que garantizan la existencia de solución global son las siguientes.

Teorema 5.1 (Teorema de Weierstrass). Sean $D \subset \mathbb{R}^n$ un conjunto compacto no vacío y $f : D \rightarrow \mathbb{R}$ una función continua. Entonces, el problema de minimizar f en D tiene una solución global.

Otro resultado importante se basa en la noción de conjunto de nivel de una función.

Definición 5.3 (Conjunto de nivel). El **conjunto de nivel** de la función $f : D \rightarrow \mathbb{R}$ asociado a un escalar $c \in \mathbb{R}$, es el conjunto dado por $L_{f,D}(c) = \{x \in D \mid f(x) \leq c\}$.

Corolario 5.1 (Compacidad del conjunto de nivel). Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ continua en D . Supongamos que existe $c \in \mathbb{R}$ tal que el conjunto de nivel $L_{f,D}(c)$ sea no vacío y compacto. Entonces, el problema de minimizar f en D posee una solución global.

Otro resultado de existencia utiliza la noción de función coercitiva.

Definición 5.4 (Coercitividad). Decimos que la función $f : D \rightarrow \mathbb{R}$ es **coercitiva** en el conjunto D , cuando para cada secuencia $\{x^k\} \subset D$ tal que $\|x^k\| \rightarrow \infty$ o $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$ ($k \rightarrow \infty$), se tiene que $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$.

Corolario 5.2 (Existencia por coercitividad). Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ una función continua y coercitiva en D . Entonces, el problema de minimizar f en D posee una solución global.

5.2. Condiciones de optimalidad

Cuando $D = \mathbb{R}^n$, decimos que el problema (5.1) es **irrestringido**, y cuando $D \neq \mathbb{R}^n$ hablamos de optimización con restricciones. Cabe notar que los resultados de problemas irrestringidos son verdaderos para problemas con restricciones siempre que el punto de interés $\bar{x}$ esté en el interior del conjunto factible ($\bar{x} \in \text{int } D$).

Teorema 5.2 (Condiciones en el caso irrestringido). (a) Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un minimizador local, entonces $f'(\bar{x}) = 0$. Si f es dos veces diferenciable en $\bar{x}$, entonces la matriz Hessiana de f en $\bar{x}$ es semidefinida positiva: $\langle f''(\bar{x})d, d \rangle \geq 0$ para todo $d \in \mathbb{R}^n$.

(b) Supongamos que f sea dos veces diferenciable en $\bar{x}$. Si $f'(\bar{x}) = 0$ y la matriz Hessiana es definida positiva (existe $\gamma > 0$ tal que $\langle f''(\bar{x})d, d \rangle \geq \gamma \|d\|^2$ para todo $d \in \mathbb{R}^n$), entonces $\bar{x}$ es minimizador local estricto.

A continuación recordamos las condiciones de optimalidad para el caso de **restricciones de igualdad**:

$$\min f(x) \quad \text{sueto a} \quad x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}, \quad (5.2)$$

donde la Lagrangiana está dada por $L(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle$. Las condiciones de regularidad clásicas son la independencia lineal de los gradientes (LICQ) o la linealidad afín de h .

Teorema 5.3 (Condiciones en el caso de restricciones de igualdad). (a) Si $\bar{x}$ es un minimizador local y vale LICQ o linealidad, entonces existe $\bar{\lambda} \in \mathbb{R}^l$ tal que $L'_x(\bar{x}, \bar{\lambda}) = 0$. Bajo LICQ, $\bar{\lambda}$ es único. Además, $\langle L''_{xx}(\bar{x}, \bar{\lambda})d, d \rangle \geq 0$ para todo $d \in \ker h'(\bar{x})$.

(b) Si $\bar{x} \in D$ y existen $\bar{\lambda} \in \mathbb{R}^l$ y $\gamma > 0$ tales que $L'_x(\bar{x}, \bar{\lambda}) = 0$ y $\langle L''_{xx}(\bar{x}, \bar{\lambda})d, d \rangle \geq \gamma \|d\|^2$ para todo $d \in \ker h'(\bar{x})$, entonces $\bar{x}$ es un minimizador local estricto.

Finalmente, consideramos el caso general con **restricciones mixtas**:

$$\min f(x) \quad \text{sueto a} \quad x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\}. \quad (5.3)$$

La Lagrangiana está dada por $L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle$. El conjunto de los índices de las restricciones activas de desigualdad en $\bar{x} \in D$ se denota por $I(\bar{x}) = \{i \mid g_i(\bar{x}) = 0\}$.

Las condiciones de regularidad para este problema son: linealidad afín, la condición de **Mangasarian-Fromovitz (MFCQ)** (independencia lineal de igualdades y existencia de dirección de descenso interior para desigualdades activas), LICQ, y la condición de Slater para convexidad. El **cono crítico** $K(\bar{x})$ es el conjunto de direcciones d tales que $\langle f'(\bar{x}), d \rangle \leq 0$, $\langle g'_i(\bar{x}), d \rangle \leq 0$ para activos y $\langle h'_i(\bar{x}), d \rangle = 0$.

Teorema 5.4 (Condiciones de optimalidad en el caso de restricciones mixtas). (a) Si $\bar{x}$ es minimizador local y cumple alguna regularidad (linealidad, MFCQ, o Slater), existen $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$ tales que $L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$ y $\bar{\mu}_i g_i(\bar{x}) = 0$ para todo i (**Condiciones KKT**). Bajo LICQ, los multiplicadores son únicos, y vale la condición de segundo orden: $\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle \geq 0$ para todo $d \in K(\bar{x})$.

(b) Si existen multiplicadores KKT y la Hessiana de la Lagrangiana es definida positiva en el cono crítico, entonces $\bar{x}$ es un minimizador local estricto.

Decimos que el punto estacionario $\bar{x}$ satisface la **condición de complementariedad estricta** si $\bar{\mu}_i > 0$ para todo $i \in I(\bar{x})$.

Proposición 5.1 (Compacidad de los multiplicadores). Sea $\bar{x}$ un punto estacionario del problema. El conjunto de multiplicadores de Lagrange asociados a $\bar{x}$ es compacto si, y solamente si, la condición de regularidad de Mangasarian-Fromovitz (MFCQ) es satisfecha.

5.3. Convexidad

Definición 5.5 (Conjunto Convexo). Un conjunto $D \subset \mathbb{R}^n$ es llamado **conjunto convexo** si para cualesquiera $x \in D$, $y \in D$ y $\alpha \in [0, 1]$, se tiene que $\alpha x + (1 - \alpha)y \in D$.

Una **proyección** (ortogonal) del punto $x \in \mathbb{R}^n$ sobre un conjunto $D \subset \mathbb{R}^n$ es una solución (global) del problema $\min \|y - x\|$ sujeto a $y \in D$.

Teorema 5.5 (Teorema de la proyección). Sea $D \subset \mathbb{R}^n$ un conjunto cerrado y convexo. Para todo $x \in \mathbb{R}^n$ la proyección de x sobre D , denotada por $P_D(x)$, existe y es única. Además, $\bar{x} = P_D(x)$ si, y solamente si,

$$\bar{x} \in D, \quad \langle x - \bar{x}, y - \bar{x} \rangle \leq 0 \quad \forall y \in D.$$

El operador es no expansivo: $\|P_D(x) - P_D(y)\| \leq \|x - y\|$ para todo x, y .

Definición 5.6 (Función Convexa). Una función $f : D \rightarrow \mathbb{R}$ (con D convexo) es **convexa** si para cualesquiera $x, y \in D$ y $\alpha \in [0, 1]$, $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$. Es **fuertemente convexa** con módulo $\gamma > 0$, si la cota mejora a $\alpha f(x) + (1 - \alpha)f(y) - \gamma\alpha(1 - \alpha)\|x - y\|^2$. Una función es **cóncava** si $(-f)$ es convexa.

Teorema 5.6 (Teorema de minimización convexa). Sean $D \subset \mathbb{R}^n$ convexo y $f : D \rightarrow \mathbb{R}$ convexa. Entonces todo minimizador local del problema es global y el conjunto de minimizadores es convexo. Si f es estrictamente convexa, el minimizador es único.

Teorema 5.7 (Continuidad y Compacidad). Una función convexa es localmente Lipschitz-continua en el interior de su dominio. Si f es fuertemente convexa en $\mathbb{R}^n$, sus conjuntos de nivel $L_{f, \mathbb{R}^n}(c)$ son compactos para todo $c \in \mathbb{R}$, lo que garantiza existencia y unicidad de soluciones en cualquier cerrado D .

Cuando una función es diferenciable, la convexidad admite varias caracterizaciones (desigualdad del subgradiente, monotonía del gradiente, y Hessiana semidefinida positiva o definida positiva para la fuerte convexidad).

Teorema 5.8 (Optimalidad primal convexa). Sea $D \subset \mathbb{R}^n$ convexo y cerrado, y f diferenciable. Si $\bar{x} \in D$ es un minimizador local, entonces $\langle f'(\bar{x}), x - \bar{x} \rangle \geq 0$ para todo $x \in D$. Equivalentemente, $\bar{x} = P_D(\bar{x} - \alpha f'(\bar{x}))$ para todo $\alpha \in \mathbb{R}_+$. Si f es convexa, esta condición es también suficiente.

Teorema 5.9 (Suficiencia de KKT). Si f y g son convexas y h es afín, entonces cualquier punto estacionario $\bar{x}$ que satisfaga las condiciones de KKT es un minimizador global del problema con restricciones mixtas.

En el análisis no diferenciable, la derivada se reemplaza por el subdiferencial.

Definición 5.7 (Subdiferencial). El **subdiferencial** de f convexa en x , denotado $\partial f(x)$, es el conjunto de vectores $y \in \mathbb{R}^n$ tales que $f(z) \geq f(x) + \langle y, z - x \rangle$ para todo $z \in \mathbb{R}^n$. Un punto $\bar{x}$ es minimizador global si y solo si $0 \in \partial f(\bar{x})$. Si se relaja la desigualdad restando una tolerancia $\varepsilon \geq 0$, se obtiene el **ε -subdiferencial** $\partial_\varepsilon f(x)$.

5.4. Dualidad

Consideramos un problema en formato general (Problema Primal):

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \Omega \mid h(x) = 0, g(x) \leq 0\}. \quad (5.4)$$

La Lagrangiana está dada por $L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle$. El problema primal puede ser escrito formalmente como una formulación minimax: $\min_{x \in \Omega} \sup_{(\lambda, \mu)} L(x, \lambda, \mu)$.

El **problema dual** se obtiene cambiando el orden de la optimización:

$$\max \varphi(\lambda, \mu) \quad \text{sujeto a} \quad (\lambda, \mu) \in \Delta, \quad (5.5)$$

donde la **función dual** es $\varphi(\lambda, \mu) = \inf_{x \in \Omega} L(x, \lambda, \mu)$ y el dominio dual es $\Delta = \{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m \mid \varphi(\lambda, \mu) > -\infty\}$.

Teorema 5.10 (Propiedades del problema Dual). El conjunto factible dual Δ es convexo y la función dual φ es siempre cóncava. Además, vale el **Teorema de Dualidad Débil**:

$$\bar{w} = \sup_{(\lambda, \mu) \in \Delta} \varphi(\lambda, \mu) \leq \inf_{x \in D} f(x) = \bar{v}.$$

Cualquier punto factible dual provee una cota inferior para el óptimo primal.

Cuando $\bar{v} > \bar{w}$ decimos que hay una brecha de dualidad (duality gap). Para garantizar la igualdad de estos valores, necesitamos hipótesis de convexidad.

Teorema 5.11 (Teorema de la Dualidad Fuerte). Sean $\Omega = \mathbb{R}^n$, f y g funciones convexas y h una función afín. Supongamos que el problema primal satisface la condición de Slater. Si el valor óptimo primal es finito ($\bar{v} > -\infty$), entonces el problema dual posee una solución y no hay brecha de dualidad ($\bar{v} = \bar{w}$).

Teorema 5.12 (Teorema del Punto de Silla de Kuhn-Tucker). Bajo las hipótesis de convexidad y Slater, $\bar{x} \in D$ es solución del problema primal si, y solamente si, existe $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}_+^m$ tal que $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = \min_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu})$ y $\bar{\mu}_i g_i(\bar{x}) = 0$. El conjunto de pares $(\bar{\lambda}, \bar{\mu})$ coincide con las soluciones del problema dual.

El siguiente resultado es fundamental para el diseño de algoritmos de optimización dual, ya que permite calcular un subgradiente de la función dual "gratis" al resolver el subproblema Lagrangiano.

Proposición 5.2 (Subgradiente de la función dual). Sean $(\lambda, \mu) \in \Delta$ y $x(\lambda, \mu) \in \Omega$ el punto donde se alcanza el ínfimo de la Lagrangiana. Entonces, el vector de violaciones de las restricciones es un subgradiente de la función dual (negativa):

$$-(h(x(\lambda, \mu)), g(x(\lambda, \mu))) \in \partial(-\varphi)(\lambda, \mu).$$

5.5. Herramientas del Análisis y del Álgebra Lineal

En esta sección agrupamos resultados analíticos y algebraicos cruciales para el desarrollo de los algoritmos computacionales.

Lema 5.1 (Desigualdad de Cauchy-Schwarz generalizada). Para una norma $\|\cdot\|_p$ y su dual $\|\cdot\|_D = \sup\{\langle \cdot, y \rangle \mid \|y\|_p = 1\}$, se tiene que

$$|\langle x, y \rangle| \leq \|x\|_p \|y\|_D \quad \forall x, y \in \mathbb{R}^n.$$

Teorema 5.13 (Perturbación de matrices no singulares). Sea $\bar{A}$ no singular. Para toda matriz A tal que $\|A - \bar{A}\| < 1/\|\bar{A}^{-1}\|$, la matriz A es no singular y su inversa está acotada por:

$$\|A^{-1} - \bar{A}^{-1}\| \leq \frac{\|\bar{A}^{-1}\|^2 \|A - \bar{A}\|}{1 - \|\bar{A}^{-1}\| \|A - \bar{A}\|}.$$

El siguiente lema será fundamental para establecer las propiedades de las Lagrangianas Aumentadas.

Lema 5.2 (Lema de Debreu). Sean $A \in \mathbb{R}^{l \times n}$ y $B \in \mathbb{R}^{n \times n}$ matrices tales que $\langle Bd, d \rangle > 0$ para todo $d \in \ker A \setminus \{0\}$. Entonces existe $\bar{c} > 0$ tal que la matriz $B + cA^T A$ es definida positiva para todo $c \geq \bar{c}$.

Lema 5.3 (Lema de Gronwall en versión discreta). Supongamos que los escalares θ_i cumplen $0 \leq \theta_0 \leq a$, y $0 \leq \theta_{i+1} \leq a + b \sum_{j=0}^i \theta_j$. Entonces $\theta_i \leq a(1 + b)^i$ para todo i .

Teorema 5.14 (Fórmula de Newton-Leibniz). Sea $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ continuamente diferenciable. Entonces $F(x + y) = F(x) + \int_0^1 F'(x + ty) y dt$.

Lema 5.4 (Acotación del error de linealización). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ con gradiente Lipschitz-continuo con módulo $L > 0$. Entonces el error de su aproximación de primer orden satisface $|f(x + d) - f(x) - \langle f'(x), d \rangle| \leq \frac{L}{2} \|d\|^2$.

Los métodos de programación cuadrática secuencial (SQP) y las regiones de confianza dependen del control de la factibilidad mediante la Función Implícita.

Teorema 5.15 (Teorema de la Función Implícita y Estimativa Local). Si $F(\bar{u}, \bar{x}) = 0$ y $F'_x(\bar{u}, \bar{x})$ es no singular, existe una trayectoria implícita $\chi(u)$ tal que $F(u, \chi(u)) = 0$. Si la matriz jacobiana parcial no es cuadrada pero tiene rango máximo por filas ($\text{rank } F'_x(\bar{u}, \bar{x}) = l$), entonces existe la función implícita χ y un escalar $M > 0$ tal que la corrección está acotada por el residuo: $\|\chi(u) - \bar{x}\| \leq M \|F(u, \bar{x})\|$.

Teorema 5.16 (Teorema de Robinson). Bajo la condición de regularidad de Mangasarian-Fromovitz (MFCQ), la distancia de un punto en una vecindad U al conjunto factible D está acotada métricamente por la norma de la violación de sus restricciones (residual natural): $\text{dist}(x, D) \leq M \|\Psi(x)\|$.

5.6. Elementos del Análisis no Diferenciable

En optimización, el interés en funciones no diferenciables proviene del hecho de que las condiciones KKT poseen naturaleza esencialmente no diferenciable. La condición de complementariedad $\bar{\mu}_i \geq 0$, $g_i(\bar{x}) \leq 0$, y $\bar{\mu}_i g_i(\bar{x}) = 0$ se puede reescribir mediante **funciones de complementariedad** $\psi(a, b)$ tales que $\psi(a, b) = 0 \iff a \geq 0$, $b \geq 0$, $ab = 0$.

Entre las elecciones más populares destacan el **residuo natural** $\psi(a, b) = \min\{a, b\}$ y la función de **Fischer-Burmeister** $\psi(a, b) = \sqrt{a^2 + b^2} - a - b$. Ambas son no diferenciables en el origen $(0, 0)$, lo que ocurre si el problema carece de complementariedad estricta (restricciones activas con multiplicador nulo).

Teorema 5.17 (Teorema de Rademacher). *Toda función Lipschitz-continua $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ en un conjunto abierto V es diferenciable en casi todo punto (la medida de Lebesgue del conjunto de puntos de no diferenciableidad es nula).*

Esto permite definir el **B-diferencial** (Bouligand-differential) como los límites de los jacobianos clásicos:

$$\partial_B F(x) = \{H \in \mathbb{R}^{l \times n} \mid \exists \{x^k\} \rightarrow x, \{F'(x^k)\} \rightarrow H\}.$$

El **diferencial de Clarke** es la envoltura convexa del B-diferencial: $\partial F(x) = \text{conv } \partial_B F(x)$.

Teorema 5.18 (Subdiferencial del Mínimo). *Si $f(x) = \min_i f_i(x)$ para funciones suaves, el B-diferencial de f está contenido en el conjunto de los gradientes de las funciones que empatan en el mínimo: $\partial_B f(x) \subset \{f'_i(x) \mid f_i(x) = f(x)\}$.*

Para la convergencia de métodos de Newton generalizados, necesitamos que la función no diferenciable aproxime bien a una función lineal. Decimos que F satisface la condición de Kummer si $\sup_{H \in \partial F(x+d)} \|F(x+d) - F(x) - Hd\| = o(\|d\|)$, y la **condición de Kummer fuerte** si el residuo es de orden $O(\|d\|^2)$.

La propiedad de **semi-diferenciabilidad** unifica la Lipschitz-continuidad, la existencia de derivadas direccionales y las condiciones de Kummer. Una función semi-diferenciable permite que el límite $\lim_{\xi \rightarrow d, t \rightarrow 0^+} H\xi$ (donde $H \in \partial F(x + t\xi)$) coincida con la derivada direccional clásica $F'(x; d)$.

Para finalizar, presentamos una estimativa para la distancia a la solución de la ecuación $\Phi(x) = 0$, que será utilizada posteriormente para probar convergencia superlineal. Suponiendo que $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ sea diferenciable en el punto $\bar{x} \in \mathbb{R}^n$ en cada dirección, decimos que Φ satisface la R_0 -condición si

$$\{d \in \mathbb{R}^n \mid \Phi'(\bar{x}; d) = 0\} = \{0\}.$$

Notemos que si Φ además de ser diferenciable en cada dirección también es Lipschitz-continua en una vecindad de $\bar{x}$, entonces la BD -regularidad de Φ en $\bar{x}$ (es decir, la no-singularidad de todo elemento de $\partial_B \Phi(\bar{x})$) implica la R_0 -condición en este punto.

Teorema 5.19 (Teorema de la R_0 -condición). *Sea $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ una función Lipschitz-continua con módulo $L > 0$ en una vecindad del punto $\bar{x} \in \mathbb{R}^n$ tal que $\Phi(\bar{x}) = 0$. Sea Φ diferenciable en este punto en cada dirección.*

Entonces Φ satisface en $\bar{x}$ la R_0 -condición si, y solamente si, existe una vecindad U del punto $\bar{x}$ en $\mathbb{R}^n$ y un número $M > 0$ tales que

$$\|x - \bar{x}\| \leq M\|\Phi(x)\| \quad \forall x \in U.$$

Prueba. Supongamos que Φ satisface en $\bar{x}$ la R_0 -condición, mas exista una secuencia $\{x^k\} \subset \mathbb{R}^n$ tal que $\{x^k\} \rightarrow \bar{x}$ ($k \rightarrow \infty$), $x^k \neq \bar{x} \quad \forall k$, y

$$\frac{\|\Phi(x^k)\|}{\|x^k - \bar{x}\|} \rightarrow 0 \quad (k \rightarrow \infty).$$

Para todo k , definimos $d^k = (x^k - \bar{x})/\|x^k - \bar{x}\|$, y $t_k = \|x^k - \bar{x}\|$. Podemos admitir, sin pérdida de generalidad, que la secuencia $\{d^k\}$ converge a un cierto $d \in \mathbb{R}^n$, $\|d\| = 1$. Entonces, para todo k ,

$$\begin{aligned} \frac{\|\Phi(\bar{x} + t_k d)\|}{t_k} &\leq \frac{\|\Phi(\bar{x} + t_k d) - \Phi(\bar{x} + t_k d^k)\|}{t_k} + \frac{\|\Phi(\bar{x} + t_k d^k)\|}{t_k} \\ &\leq L\|d^k - d\| + \frac{\|\Phi(x^k)\|}{\|x^k - \bar{x}\|} \rightarrow 0 \quad (k \rightarrow \infty), \end{aligned}$$

de donde se sigue que $\Phi'(\bar{x}; d) = 0$, en contradicción con la R_0 -condición.

Para probar la afirmación recíproca, consideremos cualquier $d \in \mathbb{R}^n$ tal que $\Phi'(\bar{x}; d) = 0$. Si existen una vecindad U del punto $\bar{x}$ y un número $M > 0$ con las propiedades de arriba, entonces para todo $t > 0$ suficientemente pequeño

tenemos:

$$\begin{aligned} t\|d\| &= \|\bar{x} + td - \bar{x}\| \leq M\|\Phi(\bar{x} + td)\| \\ &= M\|\Phi(\bar{x} + td) - \Phi(\bar{x})\| = M\|t\Phi'(\bar{x}; d)\| + o(t) = o(t), \end{aligned}$$

lo que solo puede valer para $d = 0$. ■

Ejercicios de Preliminares Teóricos

Parte I: Álgebra Lineal y Teoría Analítica

Ejercicio 5.1 (Lema de Gronwall). Supongamos que los números $\theta_0, \theta_1, \dots, \theta_N$, a y b satisfacen las siguientes cotas recursivas:

$$0 \leq \theta_0 \leq a, \quad 0 \leq \theta_{i+1} \leq a + b \sum_{j=0}^i \theta_j \quad \forall i = 0, 1, \dots, N-1.$$

Probar utilizando la técnica de inducción matemática que la sucesión está acotada geométricamente por $\theta_i \leq a(1+b)^i$ para todo $i = 0, 1, \dots, N$.

Parte II: Elementos de Análisis No Diferenciable

Ejercicio 5.2 (Compacidad del Diferencial de Clarke). Probar que si el operador no lineal $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es Lipschitz-continuo con módulo $L > 0$ en una vecindad del punto $x \in \mathbb{R}^n$, entonces su diferencial de Clarke $\partial F(x)$ es un conjunto compacto, no vacío y uniformemente acotado tal que $\|H\| \leq L$ para todo $H \in \partial F(x)$.

Ejercicio 5.3 (Semi-diferenciabilidad de funciones convexas). Probar que si la función escalar $F : \mathbb{R}^n \rightarrow \mathbb{R}$ es convexa en una vecindad (convexa) del punto $x \in \mathbb{R}^n$, entonces F es automáticamente semi-diferenciable en el punto x .

Ejercicio 5.4 (Álgebra de funciones semi-diferenciables). Probar que si las funciones vectoriales $F_1, F_2 : \mathbb{R}^n \rightarrow \mathbb{R}^l$ son semi-diferenciables en el punto $x \in \mathbb{R}^n$, entonces las operaciones algebraicas elementales preservan esta propiedad. Demostrar que las siguientes funciones son semi-diferenciables en x :

1. Producto interno: $F : \mathbb{R}^n \rightarrow \mathbb{R}$, $F(x) = \langle F_1(x), F_2(x) \rangle$.
2. Suma vectorial: $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$, $F(x) = F_1(x) + F_2(x)$.
3. Máximo componente a componente: $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$, $F_i(x) = \max\{(F_1(x))_i, (F_2(x))_i\}$.
4. Mínimo componente a componente: $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$, $F_i(x) = \min\{(F_1(x))_i, (F_2(x))_i\}$.

Ejercicio 5.5 (Semi-diferenciabilidad en el producto cartesiano). Probar que si las funciones de bloques $F_1 : \mathbb{R}^n \rightarrow \mathbb{R}^{l_1}$ y $F_2 : \mathbb{R}^n \rightarrow \mathbb{R}^{l_2}$ son semi-diferenciables en el punto $x \in \mathbb{R}^n$, entonces la función combinada $F : \mathbb{R}^n \rightarrow \mathbb{R}^{l_1} \times \mathbb{R}^{l_2}$, definida como $F(x) = (F_1(x), F_2(x))$, es semi-diferenciable en x .

Ejercicio 5.6 (Regla de la cadena para semi-diferenciabilidad). Probar la extensión del Teorema de Composición: si la función base $F_1 : \mathbb{R}^n \rightarrow \mathbb{R}^{l_1}$ es semi-diferenciable en el punto $x \in \mathbb{R}^n$, y el operador envolvente $F_2 : \mathbb{R}^{l_1} \rightarrow \mathbb{R}^{l_2}$ es semi-diferenciable en la imagen $F_1(x)$, entonces la composición iterada $F : \mathbb{R}^n \rightarrow \mathbb{R}^{l_2}$ dada por $F(x) = F_2(F_1(x))$ es semi-diferenciable en x .

6. Introducción a los Métodos de Optimización

La optimización matemática continua estudia el problema de minimizar una función sobre un dominio delimitado por restricciones. Representamos este modelo mediante la estructura general:

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\}, \quad (6.1)$$

donde $\mathbb{R}^n$ es el espacio base, la función objetivo es $f : \mathbb{R}^n \rightarrow \mathbb{R}$, y las restricciones de igualdad y desigualdad vienen dadas por los operadores $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$, respectivamente.

La resolución numérica de (6.1) requiere evaluar de forma sistemática los valores de la función objetivo, de las restricciones y, de forma habitual, de sus respectivas derivadas. Para estructurar el estudio teórico de estos algoritmos, presentaremos primero una clasificación sistemática de los métodos numéricos de optimización.

6.1. Clasificación de los métodos y nociones de convergencia

Los métodos de optimización se clasifican atendiendo a tres criterios fundamentales: la dependencia de la información obtenida en iteraciones previas (métodos pasivos o secuenciales), la cantidad de información histórica acumulada (esquemas con o sin memoria) y el orden máximo de las derivadas utilizadas.

6.1.1. Estrategia de muestreo: Métodos pasivos vs. secuenciales

Atendiendo al papel que desempeña la información obtenida durante el proceso de cálculo, distinguimos dos clases de métodos:

- **Método pasivo:** La secuencia de puntos de evaluación se elige y predetermina completamente a priori, de forma que la elección de cada candidato no se beneficia de la información obtenida en las iteraciones previas (por ejemplo, la búsqueda en rejilla o *grid search*).
- **Método secuencial:** Cada nuevo punto de la secuencia se determina utilizando los valores de la función objetivo, las restricciones o sus derivadas calculados en pasos anteriores. Esta clase resulta considerablemente más eficiente y abarca a la gran mayoría de los algoritmos computacionales prácticos.

6.1.2. Estructura del esquema iterativo: Métodos sin memoria vs. con memoria

Un método secuencial genera una secuencia de puntos en $\mathbb{R}^n$, denotada por $\{x^1, x^2, \dots, x^k, \dots\}$, a los que se denomina **aproximaciones** o **iterados** del método. Esta secuencia (llamada también **trayectoria**) se describe mediante un esquema iterativo.

Si denotamos por Ψ_k al operador de transición definido sobre conjuntos $U_k \subset \mathbb{R}^n$, la generación de un nuevo iterado se expresa como:

$$x^{k+1} = \Psi_k(x^k), \quad k = 0, 1, \dots \quad (6.2)$$

Para que el esquema esté bien definido a partir de un punto inicial $x^0 \in U_0$, los sucesivos iterados deben permanecer dentro de los dominios de definición de los operadores correspondientes. Esta condición de compatibilidad se expresa como:

$$\Psi_{k-1}(\Psi_{k-2}(\dots \Psi_0(x^0) \dots)) \in U_k \quad \forall k = 1, 2, \dots$$

Dependiendo de la cantidad de información histórica que requiera el operador Ψ_k , clasificamos los esquemas iterativos en:

- **Esquema sin memoria:** El operador Ψ_k depende únicamente de la aproximación actual x^k .
- **Esquema con memoria:** El operador utiliza información del iterado actual x^k y de puntos anteriores de la trayectoria $(x^{k-1}, x^{k-2}, \dots)$.

6.1.3. Orden del método

El tercer criterio clasifica los algoritmos según la información diferencial que emplean.

Definición 6.1 (Orden de un método). El **orden de un método** es el orden máximo de las derivadas de la función objetivo y de las restricciones utilizadas en cada iteración del algoritmo.

1. **Métodos de orden cero (o directos):** Aquellos que solo evalúan funcionalmente f , g o h , sin utilizar derivadas.
2. **Métodos de primer orden:** Aquellos que basan sus decisiones en la evaluación de las primeras derivadas (vectores gradientes, ∇f).
3. **Métodos de segundo orden:** Aquellos que requieren el cálculo de segundas derivadas (matrices Hessianas, $\nabla^2 f$).

6.1.4. Tipos de convergencia

El comportamiento asintótico de la trayectoria $\{x^k\}$ define las propiedades de convergencia del algoritmo. Distinguimos entre **convergencia finita** (cuando la trayectoria alcanza una solución exacta en un número finito de pasos, es decir, $x^k \in S$ para algún $k < \infty$) y **convergencia asintótica**.

En problemas no lineales generales, el análisis se centra rigurosamente en la convergencia asintótica. Dependiendo de la métrica y del espacio considerados, distinguimos cuatro tipos de convergencia:

1. **Convergencia en relación a las variables (o puntual):** La sucesión de iterados converge a una solución del problema:

$$x^k \rightarrow \bar{x} \quad (k \rightarrow \infty), \quad \text{con } \bar{x} \in S.$$

Esta propiedad suele requerir hipótesis restrictivas (como convexidad estricta o unicidad de solución) para poder ser demostrada de forma directa.

2. **Convergencia al conjunto de soluciones S :** La distancia de la trayectoria al conjunto de soluciones tiende a cero:

$$\text{dist}(x^k, S) \rightarrow 0 \quad (k \rightarrow \infty).$$

Si el conjunto S es compacto, esto asegura que el conjunto de puntos de acumulación de $\{x^k\}$ es no vacío y está contenido en S . Si S es ilimitado, es posible que la distancia tienda a cero sin que existan puntos de acumulación.

3. **Convergencia en relación a la función objetivo (o al valor óptimo):** La sucesión de valores de la función converge al valor mínimo $\bar{v}$, garantizando simultáneamente la aproximación al conjunto factible D :

$$\text{dist}(x^k, D) \rightarrow 0 \quad \text{y} \quad f(x^k) \rightarrow \bar{v} \quad (k \rightarrow \infty).$$

Este tipo de convergencia no implica necesariamente que la trayectoria de las variables $\{x^k\}$ sea convergente en el espacio $\mathbb{R}^n$.

4. **Convergencia en relación al gradiente:** En optimización irrestricta con funciones no convexas, es muy difícil garantizar la convergencia hacia un mínimo global. Por ello, el análisis se suele centrar en demostrar que la norma del gradiente converge a cero:

$$\|\nabla f(x^k)\| \rightarrow 0 \quad (k \rightarrow \infty).$$

Bajo esta condición, cualquier punto de acumulación $\bar{x}$ de la trayectoria es, por lo menos, un punto estacionario del problema ($\nabla f(\bar{x}) = 0$).

Distinguimos también entre **convergencia global** y **convergencia local**. Un método tiene *convergencia global* si la trayectoria converge a una solución para cualquier punto inicial x^0 . Por el contrario, un método *local* requiere que x^0 se sitúe suficientemente cerca de la solución para garantizar su convergencia.

Frecuentemente, la resolución de un problema complejo se basa en reducirlo a una secuencia de problemas más simples. Por ejemplo, el método de Newton aproxima un sistema no lineal mediante sistemas lineales. De igual modo, muchos algoritmos multidimensionales se apoyan internamente en la resolución iterativa de problemas unidimensionales a lo largo de direcciones específicas (búsqueda lineal).

Nota: El problema de la Optimización Global

Para problemas fuertemente no convexos, hallar el mínimo global es, en general, analíticamente imposible. El enfoque ingenuo de evaluar una red muy fina sobre el conjunto factible sufre la llamada *maldición de la dimensionalidad*.

Un enfoque heurístico más eficiente es la estrategia de **múltiple partida (multi-start)**. Esta estrategia superpone una red discreta gruesa sobre el conjunto factible y ejecuta un método de optimización local rápido desde cada nodo. La aproximación a la solución global se obtiene comparando los valores de los óptimos locales alcanzados por cada trayectoria.

6.2. Tasas de convergencia y reglas de parada

Para evaluar cuantitativamente la eficiencia de un método de optimización con convergencia asintótica, caracterizamos la velocidad con la que el error (la distancia al óptimo), definido por $e_k = \|x^k - \bar{x}\|$, se reduce iteración tras iteración.

Asumiendo que $x^k \neq \bar{x}$ para todo $k \geq 0$, la velocidad de convergencia se clasifica principalmente según el límite del cociente de errores sucesivos.

Definición 6.2 (Tasa de convergencia). Se dice que la sucesión $\{x^k\}$ converge a $\bar{x}$ con una tasa:

1. **Lineal:** Si existe una constante $q \in (0, 1)$ tal que el cociente asintótico está acotado por q :

$$\limsup_{k \rightarrow \infty} \frac{\|x^{k+1} - \bar{x}\|}{\|x^k - \bar{x}\|} = q. \quad (6.3)$$

Una tasa lineal implica que el error decae exponencialmente (existe $C > 0$ tal que $\|x^k - \bar{x}\| \leq Cq^k$), pero la implicación recíproca no siempre es cierta (la sucesión podría estar acotada por una envolvente exponencial sin que el límite del cociente exista o sea regular).

2. **Superlineal:** Si el límite del cociente de errores es estrictamente nulo:

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - \bar{x}\|}{\|x^k - \bar{x}\|} = 0. \quad (6.4)$$

Esto significa que la convergencia es eventualmente más rápida que cualquier progresión geométrica.

Un caso particular sumamente importante es la **convergencia cuadrática** (orden 2), que verifica la relación:

$$\limsup_{k \rightarrow \infty} \frac{\|x^{k+1} - \bar{x}\|}{\|x^k - \bar{x}\|^2} \leq C, \quad \text{con } C > 0. \quad (6.5)$$

En este escenario, el número de decimales correctos de la aproximación se duplica (aproximadamente) en cada iteración.

3. **Sublineal:** Si el límite de la relación de errores es igual a 1 (es decir, $q = 1$). Un ejemplo clásico es la **convergencia aritmética**, donde existe una constante $C > 0$ tal que:

$$\limsup_{k \rightarrow \infty} k\|x^k - \bar{x}\| \leq C. \quad (6.6)$$

Definición 6.3 (Convergencia geométrica). Se dice que $\{x^k\}$ converge geoméricamente a $\bar{x}$ si existen constantes $q \in (0, 1)$ y $C > 0$ tales que:

$$\limsup_{k \rightarrow \infty} \frac{\|x^k - \bar{x}\|}{q^k} \leq C. \quad (6.7)$$

Observación. Como se señaló en la Definición 6.2, la convergencia lineal implica convergencia geométrica, pero el recíproco en general no es cierto.

Es importante notar que el análisis de la tasa de convergencia de una sucesión vectorial se rige por su comportamiento global (su norma). El comportamiento aislado de las componentes individuales puede ser engañoso.

Contraejemplo 6.1 (Independencia de la tasa cuadrática en las componentes). La convergencia cuadrática de una sucesión vectorial hacia $\bar{x}$ no exige que cada componente individual converja con tasa superlineal o cuadrática.

Consideremos la trayectoria $\{x^k\} \subset \mathbb{R}^2$ que converge al origen $\bar{x} = (0, 0)^\top$. Fijamos el valor inicial de la segunda componente $x_2^1 \in (0, 1)$. Para todo $k \geq 1$, definimos recursivamente la segunda componente como $x_2^{k+1} = (x_2^k)^2$. Para la primera componente, el comportamiento se acopla según la paridad de la iteración:

$$x_1^{k+1} = \begin{cases} x_1^k & \text{si } k \text{ es impar,} \\ (x_2^{k+1})^2 & \text{si } k \text{ es par.} \end{cases}$$

Para un punto inicial $x^1 = (b^4, b)^\top$ con $b \in (0, 1)$, los primeros términos generados son:

$$\begin{aligned} x^2 &= (b^4, b^2)^\top & (\text{paso impar, por lo que } x_1^2 &= x_1^1) \\ x^3 &= (b^8, b^4)^\top & (\text{paso par, por lo que } x_1^3 &= (x_2^2)^2) \\ x^4 &= (b^8, b^8)^\top & (\text{paso impar, por lo que } x_1^4 &= x_1^3). \end{aligned}$$

La norma del error en cada iteración, $\|x^k\| = \sqrt{(x_1^k)^2 + (x_2^k)^2}$, decae asintóticamente a tasa cuadrática. Sin embargo, al aislar la primera componente en los pasos de paridad impar (por ejemplo, de $k = 3$ a $k = 4$), se observa que $x_1^4 = x_1^3$, por lo que la relación del error marginal es exactamente 1.

Esto demuestra que una componente unidimensional puede estancarse temporalmente (tasa de convergencia 1, ni siquiera lineal), a pesar de que el vector global converge rigurosamente con tasa cuadrática.

La tasa de convergencia asintótica no es el único criterio de eficiencia para seleccionar un algoritmo. Un método con convergencia cuadrática (como el método de Newton) puede requerir mucho más tiempo de cómputo total que un método de gradiente (lineal) si el costo computacional de evaluar y resolver el sistema de ecuaciones con la matriz Hessiana en cada iteración es exorbitantemente elevado. La estabilidad numérica y la viabilidad de los iterados dentro del conjunto factible también influyen dramáticamente en el éxito del algoritmo.

Para equilibrar las propiedades de convergencia global y local, se suelen utilizar **estrategias de globalización**. Se inicia el proceso con un método de convergencia global y robusto; una vez que el residuo del gradiente indica que el iterado está suficientemente cerca de la solución, el algoritmo cambia a un método de orden superior para aprovechar su aceleración local.

Dado que las implementaciones reales no pueden ejecutarse hasta el infinito, el proceso debe detenerse tras un tiempo finito. Para ello se utilizan **criterios de parada**, generalmente basados en el estancamiento de la trayectoria o en tolerancias estrictas de la función y del gradiente:

$$\|x^{k+1} - x^k\| \leq \epsilon, \quad (6.8)$$

$$|f(x^{k+1}) - f(x^k)| \leq \epsilon, \quad (6.9)$$

$$\|\nabla f(x^k)\| \leq \epsilon. \quad (6.10)$$

No obstante, estas condiciones de parada pueden resultar gravemente engañosas si se evalúan de forma aislada.

Contraejemplo 6.2 (Falsas convergencias en algoritmos de optimización). La condición de estancamiento del paso, $\lim_{k \rightarrow \infty} \|x^{k+1} - x^k\| = 0$, no garantiza en absoluto la convergencia hacia un punto límite estacionario. Consideremos dos trayectorias patológicas en $\mathbb{R}$:

1. **Divergencia monótona lenta:** Si $x^k = \sqrt{k}$, la distancia entre pasos decrece asintóticamente a cero, ya que $\sqrt{k+1} - \sqrt{k} \rightarrow 0$. Esto eventualmente satisfará cualquier tolerancia $\epsilon > 0$ en la condición (6.8), engañando al algoritmo para que se detenga. Sin embargo, la trayectoria diverge hacia $+\infty$.
2. **Oscilación acotada no convergente:** Si la secuencia es $x^k = \sin(\sqrt{k})$, la distancia entre pasos también decrece a cero. Activa el criterio de parada (6.8), pero la trayectoria no converge en absoluto; en su lugar, se mantiene orbitando densamente en el intervalo $[-1, 1]$.

Por estas razones, los programas y bibliotecas de optimización robustos siempre combinan varios criterios de parada de forma simultánea, junto con un límite estricto en el número máximo de iteraciones y de evaluaciones de la función objetivo.

Comentario. Como señala la literatura especializada [Izm20], la definición de la jerarquía de las reglas de parada y la calibración fina de sus parámetros numéricos (ϵ) es, en última instancia, “una cuestión de experiencia computacional y heurística más que de ciencia exacta”.

6.3. Métodos de optimización unidimensional

La optimización unidimensional (conocida comúnmente como *búsqueda de línea* o *line search*) es un componente estructural crítico en la gran mayoría de los métodos multivariables. Tras calcular una dirección de descenso $d^k \in \mathbb{R}^n$ desde el punto actual x^k , la determinación del tamaño de paso α requiere resolver (exacta o aproximadamente) el siguiente subproblema:

$$\min f(x) \quad \text{sujeto a } x \in [a, b], \quad (6.11)$$

donde $a < b$ y $f : [a, b] \rightarrow \mathbb{R}$ es una función continua.

Los algoritmos que presentaremos en esta sección son de **orden cero**, lo que significa que no exigen el cálculo de la derivada de f . Iniciaremos con el método de rejilla (un enfoque pasivo) y luego avanzaremos hacia los métodos secuenciales, que permiten aproximar la solución con un costo computacional mucho menor.

6.3.1. Búsqueda en rejilla (Grid Search)

El enfoque pasivo más intuitivo consiste en evaluar la función objetivo sobre una discretización uniforme del intervalo de búsqueda.

Algoritmo 6.1 (Búsqueda en rejilla). Fijamos un número entero $N \geq 1$ de puntos de evaluación permitidos.

1. Definimos el tamaño del incremento (resolución) de la rejilla como $\delta_N = (b - a)/N$.
2. Calculamos los puntos de muestreo distribuidos simétricamente en el intervalo:

$$x_i^N = a + i\delta_N - \frac{\delta_N}{2}, \quad i = 1, \dots, N. \quad (6.12)$$

3. Determinamos la aproximación devolviendo el valor mínimo obtenido tras evaluar los N puntos:

$$v_N = \min_{i=1, \dots, N} f(x_i^N). \quad (6.13)$$

Si la función f es Lipschitz continua en el intervalo con constante de Lipschitz $L > 0$ (es decir, $|f(y) - f(z)| \leq L|y - z|$ para todo $y, z \in [a, b]$), el error analítico de la aproximación está rigurosamente acotado.

Dado que cualquier minimizador global exacto $\bar{x} \in [a, b]$ dista a lo sumo la mitad de la resolución de la rejilla ($\delta_N/2$) del nodo de evaluación más cercano x_j^N , el error funcional del método satisface:

$$v_N - \bar{v} \leq f(x_j^N) - f(\bar{x}) \leq L|x_j^N - \bar{x}| \leq \frac{L(b - a)}{2N}. \quad (6.14)$$

Nota: Características de la Búsqueda en Rejilla

1. **Precisión óptima del error:** La cota de error obtenida en (6.14) es ajustada (*sharp*). Para todo número entero N existe una función f , Lipschitz continua con constante L , tal que el error real de aproximación es exactamente igual a la cota teórica. Esto demuestra que, dentro de la clase de métodos **pasivos** de orden cero, el algoritmo de rejilla es óptimo en el sentido minimax.
2. **Dificultad de estimación práctica:** La principal limitación práctica para definir a priori el número N que garantiza una precisión funcional ϵ consiste en estimar adecuadamente el valor de la constante de Lipschitz L . En la gran mayoría de los casos reales, esta tarea no es trivial y puede resultar analíticamente tan compleja como resolver el propio problema de optimización original. Por lo tanto, el Algoritmo 6.1

suele tener utilidad computacional principalmente cuando L es conocido por la física del problema o puede estimarse con un costo muy bajo.

6.3.2. Métodos de exclusión de intervalos

Los métodos secuenciales operan bajo un principio diferente: reducen la longitud del intervalo de incertidumbre de forma iterativa y adaptativa. Su análisis y garantía de convergencia requiere habitualmente que la función sea **unimodal**; es decir, que posea un único valle.

Definición 6.4 (Función unimodal). Se dice que una función continua $f : [a, b] \rightarrow \mathbb{R}$ es **unimodal** en $[a, b]$ si posee un único minimizador global $\bar{x} \in [a, b]$ y satisface dos condiciones de monotonía:

- Es estrictamente decreciente en el intervalo izquierdo $[a, \bar{x}]$.
- Es estrictamente creciente en el intervalo derecho $[\bar{x}, b]$.

Observación. De la Definición 6.4 se deducen propiedades fundamentales:

1. Una función continua en $[a, b]$ es unimodal si, y solamente si, posee un **único minimizador local** en todo el dominio (el cual forzosamente coincide con el mínimo global).
2. Toda función continua que sea **fuertemente convexa** en el intervalo $[a, b]$ es automáticamente unimodal.
3. La unimodalidad es un concepto topológico **más débil que la convexidad**. Existen múltiples funciones unimodales que son estrictamente no convexas. Por ello, los métodos de exclusión de intervalos que presentaremos tienen un campo de aplicación mucho más amplio que las técnicas basadas únicamente en Análisis Convexo.

El fundamento analítico subyacente de los métodos de exclusión (como Bisección o la Sección Áurea) radica en que la simple comparación ordinal de la función evaluada en dos puntos interiores permite acotar y garantizar la ubicación del mínimo global en un subintervalo estrictamente menor:

Lema 6.1 (Exclusión de intervalos). Sea $f : [a, b] \rightarrow \mathbb{R}$ una función unimodal con minimizador global en $\bar{x} \in [a, b]$. Para cualesquiera dos puntos de prueba interiores $y, z \in [a, b]$ tales que $y < z$, se verifica inexorablemente la siguiente alternativa lógica:

1. Si $f(y) \leq f(z)$, entonces el mínimo global se encuentra contenido en $\bar{x} \in [a, z]$.
2. Si $f(y) \geq f(z)$, entonces el mínimo global se encuentra contenido en $\bar{x} \in [y, b]$.

Prueba. Demostraremos el caso (1) procediendo por reducción al absurdo.

Supongamos que se cumple $f(y) \leq f(z)$, pero asumamos falsamente que el mínimo global $\bar{x}$ se encuentra estrictamente a la derecha del punto de corte z (es decir, $\bar{x} > z$). En este escenario geométrico, los puntos mantienen el orden estricto $y < z < \bar{x}$.

Invocando la definición de unimodalidad (Definición 6.4), sabemos que la función f debe ser **estrictamente decreciente** en todo el segmento anterior al mínimo $[a, \bar{x}]$. Como los puntos y y z pertenecen a este segmento de descenso, la relación espacial $y < z$ implica forzosamente que el valor funcional desciende: $f(y) > f(z)$.

Esto contradice frontalmente nuestra premisa inicial ($f(y) \leq f(z)$). Por consiguiente, la asunción inicial era falsa y el mínimo global $\bar{x}$ no puede estar a la derecha de z . Debe pertenecer al intervalo cerrado $[a, z]$.

La demostración del caso (2) es completamente análoga, apelando a la condición de crecimiento estricto en el segmento posterior al mínimo. ■

Método de Bisección

El método de bisección divide sistemáticamente el dominio de búsqueda a la mitad, requiriendo evaluar la función en nuevos puntos centrales.

Algoritmo 6.2 (Método de bisección). Fijamos los bordes $a_1 = a, b_1 = b$. Calculamos el centro inicial $c_1 = (a + b)/2$ y evaluamos funcionalmente $f(c_1)$. Para cada iteración $k \geq 1$:

1. Definimos el punto de prueba en el subintervalo izquierdo $y_k = (a_k + c_k)/2$ y evaluamos $f(y_k)$.

2. Si se cumple $f(y_k) \leq f(c_k)$, el Lema 6.1 garantiza que el mínimo está a la izquierda de c_k . El nuevo intervalo de incertidumbre es $[a_k, c_k]$. Actualizamos las variables:

$$a_{k+1} = a_k, \quad b_{k+1} = c_k, \quad c_{k+1} = y_k.$$

Saltamos directamente al paso de incremento (Paso 5).

3. Si $f(y_k) > f(c_k)$, el mínimo debe estar a la derecha de y_k . Para decidir entre el bloque central y el derecho, definimos un punto de prueba en el subintervalo derecho $z_k = (c_k + b_k)/2$ y evaluamos $f(z_k)$.
4. Si $f(c_k) \leq f(z_k)$, actualizamos con el bloque central:

$$a_{k+1} = y_k, \quad b_{k+1} = z_k, \quad c_{k+1} = c_k.$$

Si $f(c_k) > f(z_k)$, actualizamos con el bloque derecho:

$$a_{k+1} = c_k, \quad b_{k+1} = b_k, \quad c_{k+1} = z_k.$$

5. Incrementamos el contador de iteraciones $k \leftarrow k + 1$ y volvemos al Paso 1 hasta satisfacer una tolerancia ϵ .

La longitud del intervalo de incertidumbre se reduce a la mitad en cada paso ($b_{k+1} - a_{k+1} = (b_k - a_k)/2$). Sin embargo, la cantidad de evaluaciones de función requeridas es variable (a veces 1, a veces 2 por iteración).

Si suponemos, por conveniencia algorítmica, que el presupuesto total de evaluaciones permitidas N es un número impar, podemos realizar exactamente $k = (N - 1)/2$ iteraciones completas. La cota de reducción del intervalo final sigue una progresión geométrica dictada por el factor $(1/2)^{1/2} \approx 0.707$:

$$\text{Longitud Final} \leq \frac{1}{2^{(N-1)/2}}(b - a) \approx (0.707)^{N-1}(b - a). \quad (6.15)$$

Método de la Sección Áurea

Para maximizar la eficiencia computacional y garantizar que se requiera **exactamente una única evaluación de función** por cada iteración, se deben seleccionar los puntos de prueba interiores y y z manteniendo una proporción de invarianza geométrica constante τ .

Esta partición inteligente exige que la relación entre la longitud del intervalo original y el subintervalo mayor sea topológicamente idéntica a la relación entre el subintervalo mayor y el menor:

$$\frac{b - a}{b - y} = \frac{b - y}{y - a}. \quad (6.16)$$

Al resolver esta ecuación cuadrática de proporcionalidad, se obtiene que la constante de partición es el inverso de la proporción áurea (el límite de los cocientes de la sucesión de Fibonacci):

$$\tau = \frac{\sqrt{5} - 1}{2} \approx 0.618. \quad (6.17)$$

Para garantizar la validez del reciclaje de puntos internos sin necesidad de recalcularlos en cada paso, el Algoritmo 6.3 se apoya en el siguiente lema geométrico.

Lema 6.2 (Simetría e Invarianza de la Sección Áurea). Sean y y z el menor y el mayor punto interior de la partición áurea del intervalo $[a, b]$, respectivamente. Entonces se verifica:

1. La distancia a los bordes es simétrica: $z - a = b - y = \tau(b - a)$.
2. La propiedad de anidamiento fractal: el punto y es exactamente el mayor punto interno de la partición de la sección áurea del subintervalo izquierdo $[a, z]$. Del mismo modo, z es exactamente el menor punto interno de la partición áurea del subintervalo derecho $[y, b]$.

Prueba. La demostración exige una manipulación algebraica directa basada en las definiciones de y y z , y se propone como el Ejercicio 6.8 al final del capítulo. ■

Los puntos de prueba áureos para cualquier intervalo $[a, b]$ se calculan de forma exacta como:

$$y(a, b) = a + \frac{3 - \sqrt{5}}{2}(b - a) \approx a + 0.382(b - a), \quad (6.18)$$

$$z(a, b) = a + \frac{\sqrt{5} - 1}{2}(b - a) \approx a + 0.618(b - a). \quad (6.19)$$

Algoritmo 6.3 (Método de la sección áurea). Fijamos los bordes $a_1 = a$, $b_1 = b$. Calculamos los dos puntos internos iniciales $y_1 = y(a_1, b_1)$ y $z_1 = z(a_1, b_1)$ mediante (6.18)-(6.19) y realizamos la primera evaluación dual $f(y_1)$ y $f(z_1)$. Tomamos el contador $k := 1$.

1. Para las iteraciones subsecuentes, **evaluamos únicamente** aquel punto interno (entre y_k y z_k) cuyo valor de la función aún no haya sido calculado previamente.
2. Invocamos el Lema 6.1. Si $f(y_k) \leq f(z_k)$, el mínimo está en $[a_k, z_k]$. Actualizamos los límites y reciclamos el punto interno evaluado (invocando el Lema 6.2):

$$a_{k+1} = a_k, \quad b_{k+1} = z_k, \quad z_{k+1} = y_k.$$

Calculamos únicamente la coordenada del nuevo punto menor $y_{k+1} = y(a_{k+1}, b_{k+1})$.

3. Si $f(y_k) > f(z_k)$, el mínimo está en $[y_k, b_k]$. Actualizamos y reciclamos en sentido inverso:

$$a_{k+1} = y_k, \quad b_{k+1} = b_k, \quad y_{k+1} = z_k.$$

Calculamos únicamente la coordenada del nuevo punto mayor $z_{k+1} = z(a_{k+1}, b_{k+1})$.

4. Incrementamos $k \leftarrow k + 1$ y volvemos al Paso 1.

Al reciclar inteligentemente las evaluaciones funcionales, el factor de reducción del intervalo de incertidumbre por cada nueva función calculada es exactamente $\tau \approx 0.618$. El error final absoluto tras ejecutar un presupuesto de N evaluaciones decae de manera geométrica:

$$|x^N - \bar{x}| \leq b_{k+1} - a_{k+1} = \left(\frac{\sqrt{5} - 1}{2} \right)^{N-1} (b - a) \approx 0.618^{N-1}(b - a). \quad (6.20)$$

6.3.3. Búsquedas en Dominios Semi-infinitos e Intervalos No Unimodales

Fase de acotamiento en intervalos semi-infinitos

En las implementaciones reales de métodos de gradiente, rara vez se conoce a priori un límite superior para la búsqueda de línea a lo largo de una dirección de descenso. Se requiere minimizar la función f sobre una semirrecta unidimensional semi-infinita $[a, +\infty)$. Para poder instanciar el método de bisección o la sección áurea, la primera fase obliga a aislar topológicamente el mínimo en un intervalo acotado estricto $[a, a + T]$.

Esta **fase de acotamiento (bracketing)** funciona así: fijamos un tamaño de paso inicial exploratorio $\delta > 0$ y evaluamos la función en la secuencia de puntos equidistantes $z_k = a + k\delta$ para $k = 0, 1, 2, \dots$.

Determinamos el menor índice entero $k \geq 0$ en el cual se viole la condición de descenso funcional, es decir:

$$f(a + k\delta) \leq f(a + (k + 1)\delta). \quad (6.21)$$

Bajo la hipótesis analítica de que f mantiene su propiedad de unimodalidad a lo largo de toda la semirrecta, el mínimo global $\bar{x}$ pertenecerá invariablemente a la ventana acotada detectada:

$$\bar{x} \in \begin{cases} [a, a + \delta] & \text{si } k = 0, \\ [a + (k - 1)\delta, a + (k + 1)\delta] & \text{si } k \geq 1. \end{cases} \quad (6.22)$$

Si el algoritmo fuera incapaz de encontrar dicho índice k tras sucesivas evaluaciones (es decir, f decrece asintóticamente al infinito), se concluiría matemáticamente que el problema unidimensional original es ilimitado y carece de minimizador finito.

Robustez ante funciones no unimodales

Un teorema pragmático de gran relevancia computacional dicta que si la función objetivo f es continua en el intervalo cerrado $[a, b]$ pero **no es unimodal** (tiene múltiples valles locales y crestas), los algoritmos de Bisección (Algoritmo 6.2) y Sección Áurea (Algoritmo 6.3) no colapsan ni arrojan errores de división por cero.

En este escenario general caótico, los algoritmos operarán de forma ciega pero robusta, garantizando asintóticamente la convergencia hacia **al menos un minimizador local** (el cual depende estrictamente de los parámetros iniciales de partición) en el subespacio unidimensional.

6.3.4. Interpolación polinómica cuadrática y salvaguardas

Si la función objetivo f es suficientemente suave (dos veces continuamente diferenciable), se puede abandonar la reducción geométrica pasiva y aproximar la topología del valle localmente mediante un polinomio cuadrático $P(x)$, tomando el vértice exacto de dicha parábola como la siguiente aproximación del mínimo.

Este método requiere evaluar y mantener en memoria una terna de puntos $a_k < b_k < c_k$ que certifiquen el valle. A esta propiedad se le denomina **condición de sándwich**:

$$a_k < b_k < c_k, \quad f(a_k) > f(b_k), \quad f(b_k) < f(c_k). \quad (6.23)$$

Algoritmo 6.4 (Interpolación cuadrática sucesiva). Partiendo de una terna de puntos iniciales $a_1 < b_1 < c_1$ que garantice el cumplimiento de la condición de sándwich (6.23), definimos el iterador $k := 1$:

1. Calculamos algebraicamente la abscisa del vértice x_k de la parábola única que interpola los tres puntos:

$$x_k = \frac{1}{2} \frac{f(a_k)(c_k^2 - b_k^2) + f(b_k)(a_k^2 - c_k^2) + f(c_k)(b_k^2 - a_k^2)}{f(a_k)(c_k - b_k) + f(b_k)(a_k - c_k) + f(c_k)(b_k - a_k)}. \quad (6.24)$$

2. Evaluamos computacionalmente la función objetivo en la nueva abscisa del vértice, es decir, obtenemos $f(x_k)$.
3. Determinamos la topología del nuevo valle y actualizamos la terna analizando el árbol de decisiones lógicas:

- **Rama Derecha Inferior:** Si $x_k > b_k$ y $f(x_k) < f(b_k)$:

$$a_{k+1} = b_k, \quad b_{k+1} = x_k, \quad c_{k+1} = c_k.$$

- **Rama Derecha Superior:** Si $x_k > b_k$ y $f(x_k) \geq f(b_k)$:

$$a_{k+1} = a_k, \quad b_{k+1} = b_k, \quad c_{k+1} = x_k.$$

- **Rama Izquierda Inferior:** Si $x_k < b_k$ y $f(x_k) < f(b_k)$:

$$a_{k+1} = a_k, \quad b_{k+1} = x_k, \quad c_{k+1} = b_k.$$

- **Rama Izquierda Superior:** Si $x_k < b_k$ y $f(x_k) \geq f(b_k)$:

$$a_{k+1} = x_k, \quad b_{k+1} = b_k, \quad c_{k+1} = c_k.$$

4. Incrementamos $k \leftarrow k + 1$ y volvemos al Paso 1.

Bajo condiciones de regularidad local severas, el Algoritmo 6.4 alcanza asintóticamente una tasa de convergencia **superlineal** de orden ≈ 1.32 (mucho más rápida que la constante de la Sección Áurea).

Atención: El colapso de la interpolación cuadrática

A diferencia de los métodos pasivos de exclusión de intervalos (que están ciegamente garantizados), la evaluación iterativa del denominador en la ecuación (6.24) introduce una falla catastrófica potencial.

Si los puntos de evaluación se alinean casi colinealmente, la curvatura de la parábola tiende a cero y el denominador experimenta un desbordamiento numérico. El vértice x_k predicho puede ser arrojado violentamente fuera del intervalo de interés original.

Para evitar el colapso numérico, el conocido **Método de Brent** combina lo mejor de ambos mundos: intenta realizar un paso de interpolación cuadrática rápida, pero mantiene un estricto monitoreo. Si el paso cuadrático no resulta en una contracción suficiente o el vértice explota fuera de los límites, el algoritmo ejecuta una *salvaguarda* recurriendo a un paso ciego y seguro del método de la Sección Áurea.

Ejercicios del Capítulo

Parte I: Propiedades de Lipschitz e Intervalos

Ejercicio 6.1 (Constante de Lipschitz en funciones seccionadas). Sean $a, b, c \in \mathbb{R}$ tales que $a < c < b$. Supóngase que la función $f : [a, b] \rightarrow \mathbb{R}$ es Lipschitz continua en el intervalo $[a, c]$ con constante $L_1 > 0$, y es Lipschitz continua en $[c, b]$ con constante $L_2 > 0$. Demuestre rigurosamente que f es Lipschitz continua en todo el intervalo $[a, b]$ con constante global de Lipschitz:

$$L = \max\{L_1, L_2\}.$$

Ejercicio 6.2 (Acotación del gradiente y propiedad de Lipschitz). Sea $f : [a, b] \rightarrow \mathbb{R}$ una función continua en el intervalo compacto $[a, b]$ y diferenciable en el conjunto interior $[a, b] \setminus \{c_1, \dots, c_s\}$, donde $\{c_1, \dots, c_s\}$ es un conjunto finito de puntos de no diferenciabilidad (por ejemplo, puntos de cúspide). Si se cumple la acotación de la norma:

$$L = \sup\{|f'(x)| \mid x \in [a, b] \setminus \{c_1, \dots, c_s\}\} < \infty,$$

demuestre mediante el uso del Teorema del Valor Medio que f es Lipschitz continua en $[a, b]$ con constante L .

Ejercicio 6.3 (Álgebra de funciones de Lipschitz). Sean $f_1, f_2 : [a, b] \rightarrow \mathbb{R}$ dos funciones Lipschitz continuas en el intervalo $[a, b]$ con constantes garantizadas $L_1 > 0$ y $L_2 > 0$, respectivamente. Demuestre las siguientes propiedades algebraicas de la clase de funciones de Lipschitz:

1. La función suma $f_1 + f_2$ es Lipschitz continua en $[a, b]$ con constante acotada por $L_1 + L_2$.
2. La función envolvente máximo puntual $g(x) = \max\{f_1(x), f_2(x)\}$ es Lipschitz continua en $[a, b]$ con constante de Lipschitz acotada por $\max\{L_1, L_2\}$.

Ejercicio 6.4 (Existencia de funciones continuas no Lipschitz). El Teorema de Weierstrass garantiza mínimos para funciones continuas, pero no la tasa de variación. Proporcione un ejemplo analítico explícito de una función $f : [0, 1] \rightarrow \mathbb{R}$ que cumpla con ser continuamente diferenciable en el intervalo abierto $(0, 1)$ y absolutamente continua en los bordes cerrados $[0, 1]$, pero que **no** sea Lipschitz continua en $[0, 1]$. Justifique su demostración estudiando el límite del gradiente.

Parte II: Unimodalidad y Exclusión de Intervalos

Ejercicio 6.5 (Unimodalidad y Cuasiconvexidad Estricta). Sea el dominio $X \subset \mathbb{R}^n$ un conjunto topológico convexo. Se dice en Análisis Convexo que una función $f : X \rightarrow \mathbb{R}$ es **estrictamente cuasiconvexa** en X si, para cualquier par de puntos base $x^1, x^2 \in X$ con $x^1 \neq x^2$ y para cualquier interpolador $t \in (0, 1)$, se verifica la cota estricta:

$$f(tx^1 + (1-t)x^2) < \max\{f(x^1), f(x^2)\}. \quad (6.25)$$

Restrinja el estudio al caso donde el dominio es el intervalo unidimensional cerrado $X = [a, b]$. Demuestre analíticamente que una función continua $f : [a, b] \rightarrow \mathbb{R}$ cumple con ser topológicamente unimodal (Definición 6.4) si y solo si es estrictamente cuasiconvexa en dicho intervalo.

Ejercicio 6.6 (Preservación de la unimodalidad). Sean $f_1, f_2 : [a, b] \rightarrow \mathbb{R}$ dos funciones que garantizan la propiedad de unimodalidad en el intervalo $[a, b]$. Analice bajo qué escenarios analíticos restrictivos la función suma lineal $f_1 + f_2$ y la función máximo puntual $g(x) = \max\{f_1(x), f_2(x)\}$ preservan también la propiedad de unimodalidad.

Proporcione contraejemplos visuales o algebraicos detallados para demostrar por qué la suma y el máximo de funciones unimodales **no generan siempre** funciones unimodales en el caso general.

Ejercicio 6.7 (Simulación numérica del método de Bisección). Considere el siguiente problema de optimización polinómica unidimensional:

$$\underset{x \in [1,5]}{\text{minimizar}} \quad f(x) = 2x^2 - 7x + 1$$

Procediendo sin el uso de derivadas de primer orden:

1. Inicialice el Algoritmo 6.2. Realice de forma manual y documentada **dos iteraciones completas** para reducir y localizar el nuevo intervalo de incertidumbre del mínimo global.
2. Demuestre mediante la condición de primer orden del Capítulo 1 cuál es la solución analítica exacta $\bar{x}$, y compare el error residual de sus límites calculados.

Parte III: Demostraciones algebraicas de los Métodos

Ejercicio 6.8 (Verificación del Lema de la Sección Áurea). El Algoritmo 6.3 asume una propiedad de invarianza. Utilizando las definiciones exactas algebraicas de los puntos áureos fraccionarios $y(a, b)$ y $z(a, b)$ dados por las ecuaciones (6.18)-(6.19), demuestre por cálculo de reducción directa las propiedades declaradas en el Lema 6.2:

1. Pruebe rigurosamente que la longitud escalar de los subintervalos laterales es idéntica y satisface la simetría:

$$z - a = b - y = \tau(b - a),$$

donde $\tau = (\sqrt{5} - 1)/2$.

2. Pruebe que la proporción se anida. Es decir, al recortar el intervalo de incertidumbre original por la derecha, asignando el nuevo límite superior como $b_{new} = z$, el antiguo punto menor y original se convierte, sin error de truncamiento, exactamente en el punto de prueba mayor del nuevo intervalo acotado:

$$y = a + \tau(z - a).$$

Ejercicio 6.9 (Vértice del polinomio interpolador cuadrático). Demuestre de forma algebraica que el cálculo de la abscisa del vértice x_k provisto en la ecuación (6.24) del Algoritmo 6.4 no es heurístico.

Pruebe mediante la manipulación del determinante de Vandermonde o mediante sistemas lineales, que x_k es, en efecto, el único minimizador (si el denominador es positivo) del polinomio cuadrático exacto:

$$P(x) = \alpha x^2 + \beta x + \gamma$$

que interpola fielmente a la función objetivo f en los tres puntos de evaluación preexistentes $a_k < b_k < c_k$.

7. Optimización No Restringida

7.1. Métodos de descenso

Sea $f: \mathbb{R}^n \rightarrow \mathbb{R}$ una función dada. Una de las estrategias más naturales para resolver el problema irrestricto

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (7.1)$$

es la siguiente. Dada una aproximación $x^k \in \mathbb{R}^n$ de la solución del problema, encontramos un punto $x^{k+1} \in \mathbb{R}^n$ tal que

$$f(x^{k+1}) < f(x^k).$$

Obviamente, esto puede ser hecho de varias maneras. Una realización de esta estrategia básica es tomar una dirección $d^k \in \mathbb{R}^n$ tal que f es decreciente (por lo menos para pasos cortos) a partir del punto x^k en esa dirección, y computar una longitud de paso $\alpha_k > 0$ que proporcione un valor de f menor que en el punto x^k ,

$$f(x^k + \alpha_k d^k) < f(x^k).$$

Así obtenemos el iterando siguiente $x^{k+1} = x^k + \alpha_k d^k$. Repetimos el proceso para el nuevo punto x^{k+1} , etc. Métodos de este tipo se llaman métodos de descenso, y los presentamos a continuación.

7.1.1. Esquema general de los métodos de descenso. Búsqueda lineal.

Sea $x \in \mathbb{R}^n$ un punto cualquiera, tal que $f'(x) \neq 0$. Consideremos los puntos de la forma $x + td$, donde $d = -f'(x)$. Por la Fórmula de Taylor de primer orden, para todo $t \geq 0$ tenemos que

$$\begin{aligned} f(x + td) &= f(x) - t\|f'(x)\|^2 + o(t\|f'(x)\|) \\ &= f(x) - t(\|f'(x)\|^2 - o(t)/t). \end{aligned}$$

Como para valores de $t > 0$ suficientemente pequeños se tiene que $\|f'(x)\|^2 > o(t)/t$, para esos valores vale que $f(x + td) < f(x)$. De hecho, como es fácil ver, el mismo razonamiento puede ser usado para cualquier dirección $d \in \mathbb{R}^n$ satisfaciendo $\langle f'(x), d \rangle < 0$. A continuación, formalizaremos estas observaciones.

Definición 7.1 (Dirección de descenso). Decimos que $d \in \mathbb{R}^n$ es una dirección de descenso de la función $f: \mathbb{R}^n \rightarrow \mathbb{R}$ en el punto $x \in \mathbb{R}^n$, si existe $\varepsilon > 0$ tal que

$$f(x + td) < f(x) \quad \forall t \in (0, \varepsilon].$$

Denotamos por $\mathcal{D}_f(x)$ el conjunto de todas las direcciones de descenso de la función f en el punto x . En otras palabras, $d \in \mathcal{D}_f(x)$ si, y solamente si, todo paso suficientemente corto a partir del punto x en la dirección d resulta en algún decrecimiento de la función f . Es claro que $\mathcal{D}_f(x)$ puede ser vacío, y que el conjunto $\mathcal{D}_f(x) \cup \{0\}$ es un cono no vacío.

Lema 7.1 (Direcciones de descenso). Sea $f: \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $x \in \mathbb{R}^n$. Entonces:

- (a) Para todo $d \in \mathcal{D}_f(x)$, se tiene que $\langle f'(x), d \rangle \leq 0$.
- (b) Si $d \in \mathbb{R}^n$ satisface $\langle f'(x), d \rangle < 0$, se tiene que $d \in \mathcal{D}_f(x)$.

Prueba. Sea $d \in \mathcal{D}_f(x)$. Para todo $t > 0$ suficientemente pequeño, por la diferenciabilidad de f en x ,

$$0 > f(x + td) - f(x) = t(\langle f'(x), d \rangle + o(t)/t).$$

Dividiendo ambos lados de la desigualdad arriba por $t > 0$ y pasando al límite cuando $t \rightarrow 0^+$, obtenemos $0 \geq \langle f'(x), d \rangle$, lo que prueba el ítem (a).

Supongamos ahora que $\langle f'(x), d \rangle < 0$. Tenemos que

$$f(x + td) - f(x) = t(\langle f'(x), d \rangle + o(t)/t).$$

En particular, para todo $t > 0$ suficientemente pequeño, tenemos $\langle f'(x), d \rangle + o(t)/t \leq \frac{1}{2}\langle f'(x), d \rangle < 0$, lo que implica en que $f(x + td) - f(x) < 0$, i.e., $d \in \mathcal{D}_f(x)$. ■

El esquema iterativo general de métodos de descenso consiste en lo siguiente:

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k \in \mathcal{D}_f(x^k), \quad k = 0, 1, \dots, \quad (7.2)$$

donde los valores de la longitud del paso $\alpha_k > 0$ son elegidos para satisfacer, por lo menos, la condición de que

$$f(x^{k+1}) < f(x^k), \quad (7.3)$$

i.e., la secuencia $\{f(x^k)\}$ de valores de la función objetivo tiene que ser decreciente. Naturalmente, estamos suponiendo que $\mathcal{D}_f(x^k) \neq \emptyset$ para todo k . En particular, el método para si $\mathcal{D}_f(x^k) = \emptyset$ en alguna iteración. Observamos que, por el hecho de que $d^k \in \mathcal{D}_f(x^k)$, un número $\alpha_k > 0$ satisfaciendo (7.3) siempre existe (por la propia definición de dirección de descenso). Por lo tanto, obtenemos un “descenso” de miembros de la secuencia $\{x^k\}$ para curvas de nivel de la función f asociadas a valores cada vez menores.

Un método concreto, dentro de la clase descrita arriba, es dado por la elección específica de la dirección de descenso y por la regla que define la longitud del paso en esta dirección. La longitud del paso es calculada observando el comportamiento de la función f a lo largo de la semirrecta a partir de x^k en la dirección d^k , o a lo largo de un intervalo limitado en la misma dirección. Por eso, los procedimientos para este cálculo se llaman *búsqueda lineal*.

Por el Lema anterior, como ya fue observado, la elección más obvia de una dirección de descenso viene dada por $d^k = -f'(x^k)$ (suponiendo que $f'(x^k) \neq 0$). Sin embargo, la elección $d^k = -f'(x^k)$ está lejos de ser eficiente en la práctica. Con gran frecuencia, métodos correspondientes a esta elección poseen convergencia bastante lenta, principalmente cuando las curvas de nivel de la función objetivo son “alargadas”. El problema es que en los casos así, la dirección de anti-gradiente $-f'(x^k)$ es casi ortogonal a la dirección $x^k - \bar{x}$ que lleva a la solución $\bar{x}$. Por eso, la secuencia $\{x^k\}$ generada por el método se aproxima a la solución siguiendo una trayectoria en “zig-zag”.

Desde el punto de vista práctico, son mucho más importantes los métodos con $d^k = -Q_k f'(x^k)$, donde $Q_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, elegida “de manera inteligente”.

A seguir, presentamos las principales reglas de búsqueda lineal, suponiendo que para un punto x^k dado, una dirección $d^k \in \mathcal{D}_f(x^k)$ ya fue elegida.

Regla de la minimización unidimensional

Una estrategia natural es minimizar la función objetivo en la semirrecta $x^k + \alpha d^k$, $\alpha \geq 0$. La longitud de paso α_k viene dada por la condición

$$f(x^k + \alpha_k d^k) = \min_{\alpha \geq 0} f(x^k + \alpha d^k). \quad (7.4)$$

Observamos que el hecho de que $d^k \in \mathcal{D}_f(x^k)$ garantiza que soluciones de este problema están en el interior del conjunto factible, i.e., que $\alpha_k > 0$. Por lo tanto, para una función f diferenciable en el punto x^{k+1} , se sigue que

$$0 = \langle f'(x^k + \alpha_k d^k), d^k \rangle = \langle f'(x^{k+1}), d^k \rangle. \quad (7.5)$$

En particular, si $f'(x^{k+1}) \neq 0$, desde el punto de vista geométrico, x^{k+1} es el punto de intersección de la semirrecta a partir de x^k en la dirección d^k con la curva de nivel de la función f que pasa por el punto x^{k+1} . En la práctica, casi siempre (con excepción de algunos casos bien especiales, como el de una función cuadrática), la minimización exacta es sustituida por minimizar en un intervalo acotado $[0, \hat{\alpha}]$.

La regla de Armijo

Otra estrategia natural es computar una longitud de paso que resulta en un decrecimiento suficiente de la función f en relación al valor $f(x^k)$. La idea es que esto puede ser más económico desde el punto de vista computacional que la minimización unidimensional, y al mismo tiempo suficiente para garantizar convergencia.

Supongamos que f sea diferenciable en el punto x^k . Fijamos los parámetros $\hat{\alpha} > 0, \sigma, \theta \in (0, 1)$. Tomamos $\alpha := \hat{\alpha}$.

1. Verificamos si la desigualdad

$$f(x^k + \alpha d^k) \leq f(x^k) + \sigma \alpha \langle f'(x^k), d^k \rangle \quad (7.6)$$

se satisface o no.

2. Si no se satisface, tomamos $\alpha := \theta\alpha$ y retornamos al Paso 1. Caso contrario, aceptamos $\alpha_k = \alpha$ como el valor de la longitud de paso.

El valor $\alpha \langle f'(x^k), d^k \rangle$ en el lado derecho representa el valor de reducción de f , previsto por su aproximación lineal a un paso de longitud α en la dirección d^k . Por lo tanto, la desigualdad significa que el decrecimiento real de f debe ser por lo menos una fracción (determinada por σ) del previsto.

Lema 7.2 (La regla de Armijo está bien definida). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $x^k \in \mathbb{R}^n$. Supongamos que $d^k \in \mathbb{R}^n$ satisfaga $\langle f'(x^k), d^k \rangle < 0$. Entonces la desigualdad (7.6) es satisfecha para todo $\alpha > 0$ suficientemente pequeño. En particular, la regla de Armijo está bien definida y termina con un $\alpha_k > 0$.

Prueba. Para todo $\alpha > 0$ suficientemente pequeño,

$$\begin{aligned} f(x^k + \alpha d^k) - f(x^k) &= \alpha \langle f'(x^k), d^k \rangle + o(\alpha) \\ &= \sigma \alpha \langle f'(x^k), d^k \rangle + (1 - \sigma) \alpha \langle f'(x^k), d^k \rangle + o(\alpha) \\ &\leq \sigma \alpha \langle f'(x^k), d^k \rangle, \end{aligned}$$

donde la desigualdad se sigue de $(1 - \sigma) \langle f'(x^k), d^k \rangle + o(\alpha)/\alpha \leq \frac{1-\sigma}{2} \langle f'(x^k), d^k \rangle < 0$, que vale para todo $\alpha > 0$ suficientemente pequeño, por la condición supuesta. ■

Lema 7.3 (Cota inferior para el valor de la longitud de paso dado por la regla de Armijo). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$. Si $x^k, d^k \in \mathbb{R}^n$ satisfacen la condición $\langle f'(x^k), d^k \rangle < 0$, entonces la desigualdad (7.6) es válida para todo $\alpha \in (0, \bar{\alpha}_k]$, donde

$$\bar{\alpha}_k = -\frac{2(1 - \sigma) \langle f'(x^k), d^k \rangle}{L \|d^k\|^2} > 0. \quad (7.7)$$

Prueba. Por el Lema de descenso para funciones con gradiente Lipschitz y por la desigualdad (7.7), para todo $\alpha \in (0, \bar{\alpha}_k]$ tenemos que

$$\begin{aligned} f(x^k + \alpha d^k) - f(x^k) &\leq \alpha \langle f'(x^k), d^k \rangle + \frac{L}{2} \alpha^2 \|d^k\|^2 \\ &= \alpha \left(\langle f'(x^k), d^k \rangle + \frac{L}{2} \alpha \|d^k\|^2 \right) \\ &\leq \sigma \alpha \langle f'(x^k), d^k \rangle. \end{aligned}$$

Como el valor de longitud de paso mayor del que α_k no fue aceptado, tenemos que o bien $\alpha_k = \hat{\alpha}$, o bien $\alpha_k/\theta > \bar{\alpha}_k$. Concluimos entonces que

$$\alpha_k \geq \min\{\hat{\alpha}, \theta \bar{\alpha}_k\} = \check{\alpha} > 0.$$

Regla de la longitud de paso fijo

Fijamos un número $\bar{\alpha} > 0$ que no depende de k y tomamos $\alpha_k = \bar{\alpha}$ para todas las iteraciones. Esta regla es la más simple y, como consecuencia natural, es de las menos eficientes. La utilización de longitud de paso fijo solo puede presentar alguna ventaja en situaciones en las que el cálculo de los valores de f es muy caro. Cuando la constante de Lipschitz L es conocida o puede ser estimada, la fórmula (7.7) puede servir para calcular una longitud de paso fijo válida.

La regla de Goldstein

La longitud del paso $\alpha_k > 0$ se calcula para satisfacer las siguientes dos desigualdades:

$$\sigma_1 \leq \frac{f(x^k + \alpha d^k) - f(x^k)}{\alpha \langle f'(x^k), d^k \rangle} \leq \sigma_2, \quad (7.8)$$

donde $0 < \sigma_1 < \sigma_2 < 1$. La primera desigualdad es la de Armijo, ella garantiza un decrecimiento suficiente de la función. Como es fácil observar, la segunda desigualdad es violada para todo α pequeño. Así, la segunda desigualdad no permite pasos cortos de más (que, en general, tornaría el método más lento).

La regla de Wolfe

La longitud de paso $\alpha_k > 0$ se calcula para satisfacer las siguientes dos desigualdades:

$$f(x^k + \alpha d^k) \leq f(x^k) + \sigma_1 \alpha \langle f'(x^k), d^k \rangle, \quad (7.9)$$

$$\langle f'(x^k + \alpha d^k), d^k \rangle \geq \sigma_2 \langle f'(x^k), d^k \rangle, \quad (7.10)$$

donde $0 < \sigma_1 < \sigma_2 < 1$. La primera condición es, de nuevo, la de Armijo. La segunda controla la precisión de minimización de f en la semirrecta. Cuando el cálculo de la derivada de f no es muy caro, la regla de Wolfe es considerada la más eficiente regla de búsqueda lineal.

Lema 7.4 (La regla de Wolfe está bien definida). Sea $f: \mathbb{R}^n \rightarrow \mathbb{R}$ una función limitada inferiormente en $\mathbb{R}^n$, diferenciable con derivada continua. Supongamos que $\langle f'(x^k), d^k \rangle < 0$. Entonces cualquier implementación de la regla de Wolfe, para la cual se tiene que $\hat{\alpha} \rightarrow +\infty$ en el caso de número infinito de extrapolaciones y $(\hat{\alpha} - \bar{\alpha}) \rightarrow 0$ en el caso de número infinito de interpolaciones, está bien definida, en el sentido de que ella termina con un valor de longitud de paso $\alpha_k > 0$.

Prueba. Supongamos primero que el número de extrapolaciones sea infinito. En este caso, tenemos una secuencia de valores $\hat{\alpha} \rightarrow +\infty$, para los cuales

$$f(x^k + \hat{\alpha} d^k) \leq f(x^k) + \sigma_1 \hat{\alpha} \langle f'(x^k), d^k \rangle. \quad (7.11)$$

Llevando en cuenta que la derivada original es negativa, esto contradice el hecho de que f está limitada inferiormente. Por lo tanto, el número de extrapolaciones es finito.

Supongamos ahora que el número de interpolaciones sea infinito. En este caso, las secuencias monótonas de valores de $\bar{\alpha}$ y de $\hat{\alpha}$ convergen a un límite común $\bar{\alpha}$. Además, los elementos de la primera secuencia satisfacen

$$\langle f'(x^k + \bar{\alpha} d^k), d^k \rangle < \sigma_2 \langle f'(x^k), d^k \rangle, \quad (7.12)$$

y los de la segunda satisfacen

$$f(x^k + \hat{\alpha} d^k) > f(x^k) + \sigma_1 \hat{\alpha} \langle f'(x^k), d^k \rangle. \quad (7.13)$$

Pasando al límite en las desigualdades de Armijo asociadas a $\bar{\alpha}$ y (7.13), obtenemos la igualdad $f(x^k + \bar{\alpha} d^k) = f(x^k) + \sigma_1 \bar{\alpha} \langle f'(x^k), d^k \rangle$. Usando esto, escribimos

$$\begin{aligned} f(x^k + \hat{\alpha} d^k) &> f(x^k) + \sigma_1 (\bar{\alpha} + \hat{\alpha} - \bar{\alpha}) \langle f'(x^k), d^k \rangle \\ &= f(x^k + \bar{\alpha} d^k) + \sigma_1 (\hat{\alpha} - \bar{\alpha}) \langle f'(x^k), d^k \rangle. \end{aligned}$$

Y como $\hat{\alpha} - \bar{\alpha} > 0$, tenemos que

$$\frac{f(x^k + \hat{\alpha} d^k) - f(x^k + \bar{\alpha} d^k)}{\hat{\alpha} - \bar{\alpha}} > \sigma_1 \langle f'(x^k), d^k \rangle.$$

Pasando al límite (cuando $\hat{\alpha} - \bar{\alpha} \rightarrow 0$) obtenemos $\langle f'(x^k + \bar{\alpha} d^k), d^k \rangle \geq \sigma_1 \langle f'(x^k), d^k \rangle > \sigma_2 \langle f'(x^k), d^k \rangle$. Por otro lado, pasando al límite en (7.12), obtenemos la desigualdad opuesta, $\langle f'(x^k + \bar{\alpha} d^k), d^k \rangle \leq \sigma_2 \langle f'(x^k), d^k \rangle$, en contradicción. ■

Finalmente, comentaremos que existen también reglas de búsqueda lineal no monótonas. Estrategias no monótonas permiten pasos más largos y pueden ser eficientes en la práctica. La idea es permitir un posible aumento de la función objetivo en comparación con el valor obtenido en la iteración anterior, desde que obtengamos una reducción en comparación con el valor medio o máximo de iteraciones anteriores.

7.2. El método del gradiente

Supongamos que la función f sea diferenciable en $\mathbb{R}^n$. En el caso de métodos de descenso, hablamos del método del gradiente cuando la dirección de búsqueda se escoge como el anti-gradiente de la función f en el punto x^k , i.e., $d^k = -f'(x^k)$. Si $f'(x^k) = 0$ para algún k , x^k es un punto estacionario del problema y el método para. El esquema se reduce al siguiente:

$$x^{k+1} = x^k - \alpha_k f'(x^k), \quad k = 0, 1, \dots \quad (7.14)$$

El método del gradiente es de primer orden y, en general, es poco eficiente para resolver problemas prácticos. Aún así, el estudio de este método es un paso importante para entender los fundamentos de la optimización computacional.

Algoritmo 7.1 (Método del gradiente). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$. Elegir una regla de búsqueda lineal y los parámetros asociados.

1. Calcular la longitud de paso α_k en la dirección del anti-gradiente $d^k = -f'(x^k)$ de acuerdo con la regla elegida.
2. Calcular x^{k+1} por la fórmula (7.14).
3. Tomar $k := k + 1$ y retornar al Paso 1.

El método del gradiente con minimización unidimensional se llama método de máxima descida. Una propiedad importante del método de máxima descida es la igualdad

$$\langle f'(x^{k+1}), f'(x^k) \rangle = 0. \quad (7.15)$$

O sea, las direcciones utilizadas en las iteraciones subsecuentes, i.e., $d^k = -f'(x^k)$ y $d^{k+1} = -f'(x^{k+1})$, son ortogonales. Es por eso que la trayectoria del método es del tipo “zig-zag”.

La desigualdad de Armijo en este caso tiene la forma siguiente:

$$f(x^k - \alpha f'(x^k)) \leq f(x^k) - \sigma \alpha \|f'(x^k)\|^2. \quad (7.16)$$

Propiedades de convergencia global del método del gradiente son las siguientes.

Teorema 7.1 (Convergencia global del método del gradiente I). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$ con derivada Lipschitz-continua con módulo $L > 0$. En el caso en que el Algoritmo utiliza longitud de paso fijo, supongamos que $\bar{\alpha} > 0$ satisfaga $\bar{\alpha} < 2/L$. Entonces cada punto de acumulación de cualquier secuencia $\{x^k\}$ generada por el Algoritmo es un punto estacionario del problema. Si un punto de acumulación existe, o si la función f es limitada inferiormente, entonces

$$\|f'(x^k)\| \rightarrow 0 \quad (k \rightarrow \infty). \quad (7.17)$$

Prueba. Consideramos primero el caso de la regla de Armijo. Si $f'(x^k) \neq 0$ para todo k , la secuencia $\{f(x^k)\}$ es decreciente. Supongamos que la secuencia tenga un punto de acumulación. En este caso, por la continuidad de f , la secuencia también tiene un punto de acumulación, y como es monótona, es limitada inferiormente y converge. Por la desigualdad de Armijo y la cota inferior del paso $\bar{\alpha}$, para todo k tenemos que

$$f(x^k) - f(x^{k+1}) \geq \sigma \alpha_k \|f'(x^k)\|^2 \geq \sigma \bar{\alpha} \|f'(x^k)\|^2.$$

Como $f(x^k) - f(x^{k+1}) \rightarrow 0$ ($k \rightarrow \infty$), obtenemos $\|f'(x^k)\| \rightarrow 0$. El caso de minimización unidimensional se reduce al caso de Armijo. Para el paso fijo, por los Lemas anteriores, esto es equivalente a usar Armijo con un σ suficientemente pequeño. ■

Teorema 7.2 (Convergencia global del método del gradiente II). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada continua. Supongamos que el Algoritmo utiliza la minimización unidimensional o la regla de Armijo. Entonces cada punto de acumulación de cualquier secuencia generada es un punto estacionario. Si la secuencia es limitada, entonces $\|f'(x^k)\| \rightarrow 0$.

Prueba. El caso de minimización unidimensional se reduce al caso de Armijo de la misma manera que en la demostración del Teorema anterior. Supongamos que la secuencia tenga un punto de acumulación $\bar{x} \in \mathbb{R}^n$, y que $f'(x^k) \neq 0$ para todo k . Supongamos que $\{x^{k_j}\} \rightarrow \bar{x}$. El caso en que existe $\bar{\alpha} > 0$ tal que $\alpha_{k_j} \geq \bar{\alpha}$ para todo j puede ser analizado de manera completa y análoga al Teorema I. Por lo tanto, tomando una subsecuencia si es necesario, consideremos el caso $\alpha_{k_j} \rightarrow 0$. En este caso, para todo j suficientemente grande, el valor inicial $\bar{\alpha}$ fue reducido, es decir, el valor α_{k_j}/θ no satisface Armijo:

$$f(x^{k_j} - \theta^{-1} \alpha_{k_j} f'(x^{k_j})) > f(x^{k_j}) - \sigma \theta^{-1} \alpha_{k_j} \|f'(x^{k_j})\|^2.$$

Dividiendo la última desigualdad por $\theta^{-1} \alpha_{k_j}$ y usando el Teorema del Valor Medio, al pasar al límite obtenemos $-\|f'(\bar{x})\|^2 \geq -\sigma \|f'(\bar{x})\|^2$. Como $\sigma \in (0, 1)$, esto solo es posible si $f'(\bar{x}) = 0$. ■

Teorema 7.3 (Convergencia global del método del gradiente en el caso convexo). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa, diferenciable en $\mathbb{R}^n$, con derivada continua. Supongamos que el Algoritmo utiliza la regla de Armijo con $\hat{\alpha} \leq 1$. Si el conjunto de minimizadores irrestrictos de f no es vacío, entonces cualquier secuencia generada converge a una solución del problema.

Prueba. Sea $\bar{x}$ una solución del problema. Como para todo k tenemos $f(x^k) - f(x^{k+1}) \geq \sigma \alpha_k \|f'(x^k)\|^2$, al pasar al límite sumando, $\sum \alpha_i \|f'(x^i)\|^2 < +\infty$. Por la convexidad de f y la optimalidad de $\bar{x}$, $\langle f'(x^k), \bar{x} - x^k \rangle \leq f(\bar{x}) - f(x^k) \leq 0$. Donde obtenemos que

$$\begin{aligned} \|x^{k+1} - \bar{x}\|^2 &= \|x^k - \bar{x} - \alpha_k f'(x^k)\|^2 \\ &\leq \|x^k - \bar{x}\|^2 + \alpha_k^2 \|f'(x^k)\|^2. \end{aligned}$$

Utilizando esta desigualdad en secuencia, obtenemos $\|x^j - \bar{x}\|^2 \leq \|x^k - \bar{x}\|^2 + \sum_{i=k}^{\infty} \alpha_i \|f'(x^i)\|^2$. Concluimos que la secuencia es limitada y tiene un punto de acumulación que debe ser un minimizador, por lo que toda la secuencia converge a él. ■

A continuación, analizaremos el comportamiento local del método del gradiente, i.e., el comportamiento en una vecindad de un punto estacionario $\bar{x}$. Suponiendo que f sea dos veces diferenciable en $\bar{x}$, y que $\bar{x}$ satisfaga la condición suficiente de segundo orden, en particular, $\bar{x}$ es un minimizador local estricto. Más aún, en este caso f crece con orden cuadrático en una vecindad de $\bar{x}$.

Lema 7.5. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en una vecindad de $\bar{x}$ y dos veces diferenciable en $\bar{x}$. Supongamos que $\bar{x}$ satisface la condición suficiente de segundo orden. Entonces, para cualquier $\nu \in (0, 4)$ existe una vecindad U de $\bar{x}$ tal que, además de la condición de crecimiento, vale:

$$\|f'(x)\|^2 \geq \nu \beta (f(x) - f(\bar{x})) \quad \forall x \in U. \quad (7.18)$$

Prueba. Para x suficientemente próximo a $\bar{x}$, tenemos $f'(x) = f''(\bar{x})(x - \bar{x}) + o(\|x - \bar{x}\|)$ y $f(x) - f(\bar{x}) = \frac{1}{2} \langle f''(\bar{x}), x - \bar{x} \rangle + o(\|x - \bar{x}\|^2)$. Usando la constante $\beta > 0$ de la condición de segundo orden y las expansiones, manipulando algebraicamente se obtiene que $\|f'(x)\| \|x - \bar{x}\| \geq \sqrt{\nu \beta} \|x - \bar{x}\|^2$, de donde sigue el resultado deseado. ■

Presentamos ahora el resultado principal sobre convergencia local del método del gradiente.

Teorema 7.4 (Convergencia local del método del gradiente I). Además de las hipótesis del Teorema 3.1.1, supongamos que la función sea dos veces diferenciable en el punto $\bar{x}$, que satisfaga la condición suficiente de segundo orden. Entonces:

- (a) Para cualquier x^0 suficientemente próximo a $\bar{x}$, la secuencia converge a $\bar{x}$; la tasa de convergencia a la función objetivo es lineal, y geométrica en relación a las variables: $\forall k, f(x^{k+1}) - f(\bar{x}) \leq q(f(x^k) - f(\bar{x}))$.
- (b) En el caso de minimización unidimensional, $\limsup \frac{f(x^{k+1}) - f(\bar{x})}{f(x^k) - f(\bar{x})} \leq 1 - \rho_1 / \rho_n$, donde ρ_1 y ρ_n son los autovalores extremo de $f''(\bar{x})$.
- (c) En el caso de la regla de Armijo, $\limsup \frac{f(x^{k+1}) - f(\bar{x})}{f(x^k) - f(\bar{x})} \leq 1 - 2\sigma(1 - \sigma)\rho_1 / \rho_n$.
- (d) En el caso del paso fijo, $\limsup \frac{f(x^{k+1}) - f(\bar{x})}{f(x^k) - f(\bar{x})} \leq 1 - 2\rho_1 \bar{\alpha} + \rho_1 \rho_n \bar{\alpha}^2$.

Prueba. Fijamos una vecindad U de $\bar{x}$ tal que las propiedades de crecimiento y del Lema anterior valen. En el caso de optimización unidimensional, para todo $\alpha \in [0, \hat{\alpha}]$ tenemos

$$f(x^{k+1}) - f(\bar{x}) \leq f(x^k) - f(\bar{x}) - \alpha \|f'(x^k)\|^2 + \frac{L\alpha^2}{2} \|f'(x^k)\|^2.$$

Minimizando el término cuadrático en α , obtenemos un factor q estrictamente menor a 1. El análisis es análogo para la regla de Armijo usando el decrecimiento asegurado por σ , y para el paso fijo reemplazando α directamente, asegurando las cotas anunciadas para $q \in (0, 1)$. En consecuencia, la distancia de los iterados no sale de la vecindad U , y por la convergencia q^k de la función, la distancia decrece de manera geométrica acotada por $\sqrt{q^k}$. ■

Teorema 7.5 (Convergencia local del método del gradiente II). Además de las hipótesis de convergencia global, supongamos que el valor óptimo sea finito, y que la condición de separación de superficies de nivel críticas sea satisfecha. Supongamos que la función asume un crecimiento subcuadrático relajado general en la vecindad de S_0 : $\|f'(x)\| \geq \gamma \text{dist}(x, S_0)$. Entonces, cualquier secuencia $\{x^k\}$ generada por el Algoritmo converge a un punto estacionario del problema. La tasa de convergencia es lineal en relación a la función y geométrica en relación a las variables.

Prueba. Para todo k , por la desigualdad de descenso, $f(x^k) - f(x^{k+1}) \geq \sigma \|x^{k+1} - x^k\|^2 / \hat{\alpha}$. La sucesión de valores de la función es monótona decreciente y acotada, luego converge a un límite v . Utilizando la desigualdad que relaciona el gradiente a la distancia, obtenemos

$$0 \leq f(x^{k+1}) - v \leq M(f(x^k) - f(x^{k+1})),$$

lo que reescrito muestra que $f(x^{k+1}) - v \leq q(f(x^k) - v)$ con $q = M/(1 + M) \in (0, 1)$. De ahí, la diferencia sucesiva de las distancias se acota por una progresión geométrica, probando que la sucesión de variables satisface la condición de Cauchy y por ende converge geoméricamente a la proyección estacionaria en S_0 . ■

Para finalizar, resaltamos que los métodos del gradiente son, para gran mayoría de aplicaciones prácticas, poco eficientes. Ellos son particularmente lentos en el caso en que las superficies de nivel de la función sean “alargadas”. Podemos describir tal situación con un poco más de precisión de la manera siguiente: si el autovalor máximo ρ_n es bien mayor que el autovalor mínimo ρ_1 , se tiene que el número ρ_1/ρ_n es próximo a cero. En este caso, las constantes en el lado derecho de las estimativas del Teorema de convergencia local son próximas a 1. Esto muestra convergencia bastante lenta (aunque formalmente lineal). O sea, en cualquier caso, el método del gradiente no es competitivo en el sentido computacional. La importancia de él es sobre todo histórica, teórica y didáctica.

7.3. El método de Newton. Métodos cuasi-Newton.

La idea principal del método de Newton, presentado a continuación, es fundamental en varias áreas de la matemática computacional. En su forma básica, el método de Newton es una herramienta para resolver sistemas de ecuaciones no lineales. En principio, él no es un método de minimización. Por ejemplo, a diferencia de los métodos de descenso considerados arriba, cuando se aplica a un problema de optimización (i.e., a la ecuación $f'(x) = 0$), el método de Newton tiene la misma “preferencia” tanto para minimizadores de f cuanto para maximizadores (o, de hecho, cualesquier otros puntos estacionarios). Por otro lado, el método admite también una interpretación ligada a la optimización, lo que puede ser usado para una adaptación mejor a problemas de optimización y, en particular, para el desarrollo de estrategias de globalización.

La convergencia rápida del método de Newton se debe al uso de información de segundo orden. Como consecuencia, una iteración del método es significativamente más cara en comparación con el método del gradiente. Felizmente, el método de Newton sirve también como base de desarrollo de métodos cuasi-Newton. Estos últimos son ligeramente más lentos que el método de Newton, pero tienen iteraciones bien más baratas (en particular, no tanto más caras que las del método del gradiente). Esto los hace bastante atractivos para uso práctico. Puede ser dicho que los métodos cuasi-Newton son, en general, los más eficientes y más usados entre los algoritmos de la optimización irrestricta (en el caso de funciones dos veces diferenciables).

7.3.1. El método de Newton para ecuaciones

El método de Newton clásico es introducido para el problema de hallar un $x \in \mathbb{R}^n$ tal que

$$\Phi(x) = 0, \quad (7.19)$$

donde $\Phi: \mathbb{R}^n \rightarrow \mathbb{R}^n$ es diferenciable. Sea $x^k \in \mathbb{R}^n$ una aproximación a alguna solución $\bar{x}$ de la ecuación (7.19). En torno de x^k , podemos aproximar (7.19) por su linealización

$$\Phi(x^k) + \Phi'(x^k)(x - x^k) = 0. \quad (7.20)$$

La relación (7.20) se llama la ecuación de iteración del método de Newton.

Algoritmo 7.2 (El método de Newton). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular $x^{k+1} \in \mathbb{R}^n$ como una solución de la ecuación lineal (7.20).
2. Tomar $k := k + 1$ y retornar al ítem 1.

Suponiendo que $\Phi'(x^k)$ sea no-singular (en este caso, naturalmente, la solución de la ecuación de Newton es única), el método de Newton puede ser escrito en forma del esquema iterativo

$$x^{k+1} = x^k - (\Phi'(x^k))^{-1}\Phi(x^k), \quad k = 0, 1, \dots \quad (7.21)$$

Observamos que aunque $\Phi'(x^k)$ sea no-singular, el cálculo de x^{k+1} no requiere necesariamente el cálculo de la inversa de esta matriz. Existen varios métodos de resolución de sistemas de ecuaciones lineales que no invierten la matriz asociada (lo que es caro desde el punto de vista computacional).

Teorema 7.6 (Convergencia local del método de Newton). Sea $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ diferenciable en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivada continua en este punto. Sea $\bar{x}$ una solución de la ecuación (7.19), tal que $\det \Phi'(\bar{x}) \neq 0$ (i.e., la matriz $\Phi'(\bar{x})$ es no singular).

Entonces, para cualquier punto inicial $x^0 \in \mathbb{R}^n$ suficientemente próximo a $\bar{x}$, el Algoritmo genera una secuencia $\{x^k\}$ bien definida que converge a $\bar{x}$. La tasa de convergencia es superlineal, y si la derivada de Φ es Lipschitz-continua en una vecindad de $\bar{x}$, entonces la tasa de convergencia es cuadrática.

Prueba. Por el teorema sobre perturbaciones pequeñas de una matriz no singular, existen una vecindad U del punto $\bar{x}$ y un número $M > 0$ tales que

$$\det \Phi'(x) \neq 0, \quad \|(\Phi'(x))^{-1}\| \leq M \quad \forall x \in U. \quad (7.22)$$

En particular, para $x^k \in U$ la ecuación de iteración tiene una única solución x^{k+1} , i.e., la iteración del Algoritmo, a partir de tal x^k , está bien definida. Además de eso, por el Teorema del Valor Medio, podemos tomar la vecindad U tal que, si $x^k \in U$, entonces

$$\begin{aligned} \|x^{k+1} - \bar{x}\| &= \|x^k - \bar{x} - (\Phi'(x^k))^{-1}\Phi(x^k)\| \\ &\leq \|(\Phi'(x^k))^{-1}\| \|\Phi(x^k) - \Phi(\bar{x}) - \Phi'(x^k)(x^k - \bar{x})\| \\ &\leq M \sup_{t \in [0,1]} \|\Phi'(tx^k + (1-t)\bar{x}) - \Phi'(x^k)\| \|x^k - \bar{x}\|. \end{aligned} \quad (7.23)$$

Notamos que $\sup \|\Phi'(tx^k + (1-t)\bar{x}) - \Phi'(x^k)\| \rightarrow 0$ ($x^k \rightarrow \bar{x}$). Por lo tanto, para todo $q \in (0, 1)$ existe $\delta > 0$ tal que $B(\bar{x}, \delta) \subset U$ y, si $x^k \in B(\bar{x}, \delta)$,

$$\|x^{k+1} - \bar{x}\| \leq q \|x^k - \bar{x}\|.$$

En particular, $x^{k+1} \in B(\bar{x}, \delta)$. Concluimos que para todo x^0 suficientemente próximo a $\bar{x}$, se genera una secuencia $\{x^k\}$ bien definida, y que esta secuencia converge a $\bar{x}$. Además de eso, la tasa de convergencia es superlineal, ya que $q \rightarrow 0$ a medida que $x^k \rightarrow \bar{x}$. Cuando la derivada de Φ es Lipschitz-continua en U con módulo $L > 0$, obtenemos que

$$\|x^{k+1} - \bar{x}\| \leq ML \|x^k - \bar{x}\|^2,$$

i.e., la convergencia es cuadrática. ■

Corolario 7.1 (Método de Newton Inexacto). Supongamos que valen las hipótesis del Teorema de Newton local. Se tiene que para toda $\Psi : \mathbb{R}^n \rightarrow \mathbb{R}^{n \times n}$ tal que $\|\Psi(x) - \Phi'(x)\| \rightarrow 0$ ($x \rightarrow \bar{x}$), para cualquier punto inicial x^0 suficientemente próximo a $\bar{x}$, el método dado por $x^{k+1} = x^k - (\Psi(x^k))^{-1}\Phi(x^k)$ genera una secuencia bien definida que converge a $\bar{x}$ con tasa superlineal.

7.3.2. Método de Newton para optimización irrestricta

Ahora consideremos el problema de optimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (7.24)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función dos veces diferenciable en $\mathbb{R}^n$. Los puntos estacionarios de este problema se caracterizan por la ecuación

$$\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n, \quad \Phi(x) = f'(x). \quad (7.25)$$

Por lo tanto, podemos intentar computar puntos estacionarios aplicando el método de Newton a la ecuación $f'(x) = 0$. Sea $x^k \in \mathbb{R}^n$ una aproximación a un punto estacionario $\bar{x}$. La aproximación siguiente x^{k+1} es computada como solución del sistema de ecuaciones lineales

$$f'(x^k) + f''(x^k)(x - x^k) = 0, \quad (7.26)$$

en relación a $x \in \mathbb{R}^n$. Suponiendo que $f''(x^k)$ sea no-singular para todo k , obtenemos el esquema iterativo siguiente:

$$x^{k+1} = x^k - (f''(x^k))^{-1}f'(x^k), \quad k = 0, 1, \dots \quad (7.27)$$

Observamos que esta iteración admite una interpretación en términos de problemas de optimización. En particular, en torno del punto x^k , el problema puede ser aproximado por el siguiente problema de optimización irrestricta de una función cuadrática:

$$\min f(x^k) + \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle f''(x^k)(x - x^k), x - x^k \rangle, \quad x \in \mathbb{R}^n. \quad (7.28)$$

Como es fácil ver, la ecuación de Newton (7.26) caracteriza los puntos estacionarios del problema cuadrático. Por lo tanto, el método de Newton para un problema de optimización irrestricto es lo siguiente.

Algoritmo 7.3 (Método de Newton para optimización irrestricta). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular $x^{k+1} \in \mathbb{R}^n$ como punto estacionario del problema cuadrático asociado.
2. Tomar $k := k + 1$ y retornar al Paso 1.

Corolario 7.2. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces diferenciable en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con segunda derivada continua en este punto. Sea $\bar{x}$ un punto estacionario del problema que satisface la condición suficiente de segundo orden. Entonces para cualquier punto inicial $x^0 \in \mathbb{R}^n$ suficientemente próximo a $\bar{x}$, el Algoritmo genera una secuencia $\{x^k\}$ bien definida que converge a $\bar{x}$. La tasa de convergencia es superlineal, y si la derivada segunda es Lipschitz-continua en la vecindad de $\bar{x}$, la convergencia es cuadrática.

Bajo las condiciones del Corolario, uno de los métodos más eficientes para resolver la ecuación lineal del esquema es el método de Cholesky. Este método permite obtener la factorización LL^T de una matriz simétrica definida positiva en un orden de $n^3/6$ multiplicaciones más el mismo número de sumas (L es una matriz triangular con elementos positivos en la diagonal). Este esquema puede ser modificado para sustituir la matriz $f''(x^k)$, cuando ella no es definida positiva, por una matriz definida positiva (por ejemplo, de la forma $f''(x^k) + \gamma E^n$ con $\gamma > 0$ suficientemente grande). Esto es importante para el desarrollo de estrategias de globalización de métodos Newtonianos.

Observamos que, sin la modificación mencionada arriba, el Corolario continúa siendo válido si sustituimos la condición suficiente de segundo orden en el punto estacionario $\bar{x}$ por la condición más débil de que $f''(\bar{x})$ sea no singular. En este sentido, el método de Newton no tiene preferencia para minimizadores en relación a otros puntos estacionarios del problema.

La principal ventaja del método de Newton es la convergencia superlineal. No obstante, el método de Newton posee también algunas desventajas. Primero, como ya fue visto, el método tiene apenas convergencia local. De nuevo, esto tiene que ser comparado, por ejemplo, con los métodos del gradiente. Segundo, para algunos puntos iniciales, el método puede ni estar bien definido. Y mismo cuando el método genera correctamente una secuencia de iteraciones, la secuencia puede no poseer puntos de acumulación o los puntos de acumulación de ella pueden no ser puntos estacionarios del problema, como veremos a seguir.

Ejemplo 7.1. Consideremos la función

$$f : \mathbb{R} \rightarrow \mathbb{R}, \quad f(x) = \begin{cases} -x^4/(4\tau^3) + (1 + 3/\tau)x^2/2, & \text{si } |x| \leq \tau, \\ x^2/2 + 2|x| - 3\tau/4, & \text{si } |x| > \tau, \end{cases}$$

donde $\tau > 0$ es un parámetro. Como es fácil de verificar, para cualquier $\tau > 0$ la función f es dos veces diferenciable en $\mathbb{R}$, con segunda derivada continua. Más aún, el problema definido por esta f tiene un único punto estacionario $\bar{x} = 0$, y se tiene que $f''(\bar{x}) = 1 + 3/\tau > 0$. En particular, todas las hipótesis del Corolario son satisfechas.

Tomaremos $x^0 = \tau$. La secuencia $\{x^k\}$ generada por el Algoritmo tiene la siguiente forma: $x^k = 2(-1)^k$, $k = 1, 2, \dots$. En particular, $\bar{x}$ no es punto de acumulación de $\{x^k\}$, independientemente de cuánto τ sea pequeño (i.e., cuánto x^0 sea próximo a $\bar{x}$).

Lejos de una solución del problema, el paso unitario $\alpha_k = 1$, que caracteriza al método de Newton puro, puede no resultar en un decrecimiento de la función objetivo. En este caso, el método de Newton puro no es un método de descenso, en cuanto que un paso más corto en la misma dirección puede garantizar esta propiedad.

7.3.3. Métodos cuasi-Newton

Una clase importante de métodos de optimización irrestricta es dada por el esquema iterativo

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k = -Q_k f'(x^k), \quad k = 0, 1, \dots, \quad (7.29)$$

donde, para todo k , $Q_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, y $\alpha_k > 0$ es la longitud de paso calculada utilizando una de las reglas de búsqueda lineal. Notamos que el método es un método de descenso. Con efecto, si x^k no es un punto estacionario del problema, como Q_k es definida positiva, se tiene que

$$\langle f'(x^k), d^k \rangle = -\langle Q_k f'(x^k), f'(x^k) \rangle < 0, \quad (7.30)$$

y por lo tanto d^k es una dirección de descenso de f en x^k . En el caso de $Q_k = E^n$, el esquema se reduce a uno de los métodos del gradiente, y en el caso de $Q_k = (f''(x^k))^{-1}$ con $\alpha_k = 1$, obtenemos el método de Newton puro. Existen, sin embargo, otras posibilidades que son más atractivas computacionalmente.

Algoritmo 7.4 (Método de descenso con métrica variable). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$. Elegir una de las reglas de búsqueda lineal y los parámetros asociados.

1. Elegir una matriz $n \times n$ simétrica definida positiva Q_k y tomar $d^k = -Q_k f'(x^k)$. Calcular la longitud de paso α_k en la dirección d^k , por la regla de búsqueda lineal elegida (se $f'(x^k) = 0$, formalmente definimos $\alpha_k = 1$).
2. Tomar $x^{k+1} = x^k + \alpha_k d^k$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

Los métodos cuasi-Newton son métodos de esta forma, donde las matrices Q_k son elegidas para aproximar, en un cierto sentido, la matriz $(f''(\bar{x}))^{-1}$ para alguna solución $\bar{x}$. Más precisamente, la secuencia $\{Q_k\}$ tiene que satisfacer la condición de Dennis-Moré, dada en el teorema siguiente.

Teorema 7.7 (Teorema de Dennis-Moré). Supongamos que se satisfacen las hipótesis del Corolario 3.2.2. Además de eso, supongamos que la secuencia $\{x^k\}$, generada por el Algoritmo utilizando la regla de búsqueda lineal de Armijo con $\hat{\alpha} = 1$ e $\sigma \in (0, 1/2)$, converge a $\bar{x}$.

Entonces, las siguientes dos afirmaciones son equivalentes:

- (a) La tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal, $\alpha_k = 1$ para todo k suficientemente grande, y

$$\|Q_k f'(x^k)\| \leq M \|f'(x^k)\| \quad \forall k = 0, 1, \dots, \quad (7.31)$$

donde $M > 0$ es una constante que no depende de k .

- (b) Se tiene que

$$(Q_k - (f''(\bar{x}))^{-1})f'(x^k) = o(\|f'(x^k)\|). \quad (7.32)$$

Prueba. Primero, supongamos que la afirmación (a) se satisface. Llevando en cuenta que $\alpha_k = 1$ para todo k suficientemente grande, tenemos que

$$\begin{aligned} ((f''(\bar{x}))^{-1} - Q_k)f'(x^k) &= (f''(\bar{x}))^{-1}f'(x^k) + x^{k+1} - x^k \\ &= (f''(\bar{x}))^{-1}(f'(x^k) - f'(\bar{x}) - f''(\bar{x})(x^k - \bar{x})) + x^{k+1} - \bar{x} \\ &= o(\|x^k - \bar{x}\|), \end{aligned} \quad (7.33)$$

donde la última igualdad se sigue de la Fórmula de Taylor y de la convergencia superlineal de $\{x^k\}$ a $\bar{x}$. De (7.31), obtenemos que

$$\begin{aligned} M \|f'(x^k)\| &\geq \|Q_k f'(x^k)\| \\ &\geq \|x^k - \bar{x}\| - \|x^{k+1} - \bar{x}\| = \|x^k - \bar{x}\| + o(\|x^k - \bar{x}\|). \end{aligned}$$

Por lo tanto,

$$\frac{o(\|x^k - \bar{x}\|)}{\|f'(x^k)\|} \leq \frac{o(\|x^k - \bar{x}\|)}{\|x^k - \bar{x}\|/M + o(\|x^k - \bar{x}\|)} \rightarrow 0 \quad (k \rightarrow \infty).$$

Combinando esta última relación con (7.33), obtenemos (7.32).

Ahora supongamos que la afirmación (b) se satisface. La condición (7.31) se sigue trivialmente (sino, obtenemos una contradicción obvia con (7.32)). Probaremos que $\alpha_k = 1$ para todo k suficientemente grande. Por el Teorema del Valor Medio, existe $\tilde{t}_k \in [0, 1]$ tal que

$$f(x^k - Q_k f'(x^k)) = f(x^k) - \langle f'(x^k), Q_k f'(x^k) \rangle + \frac{1}{2} \langle f''(\bar{x}) Q_k f'(x^k), Q_k f'(x^k) \rangle,$$

donde $\bar{x} = x^k - \tilde{t}_k Q_k f'(x^k)$. Para verificar que $\alpha_k = 1$ satisface la regla de Armijo, basta mostrar que

$$\langle f'(x^k), Q_k f'(x^k) \rangle - \frac{1}{2} \langle f''(\bar{x}) Q_k f'(x^k), Q_k f'(x^k) \rangle \geq \sigma \langle f'(x^k), Q_k f'(x^k) \rangle. \quad (7.34)$$

Observamos que $\{\bar{x}^k\} \rightarrow \bar{x}$ ($k \rightarrow \infty$), porque $\{x^k\} \rightarrow \bar{x}$ y $\{Q_k f'(x^k)\} \rightarrow 0$ (la última propiedad se sigue de (7.31)). Por tanto, por (7.32), la desigualdad (7.34) puede ser escrita como

$$(1 - \sigma) \langle f'(x^k), (f''(\bar{x}))^{-1} f'(x^k) \rangle \geq \frac{1}{2} \langle f'(x^k), (f''(\bar{x}))^{-1} f'(x^k) \rangle + o(\|f'(x^k)\|^2),$$

o bien

$$(1/2 - \sigma) \langle f'(x^k), (f''(\bar{x}))^{-1} f'(x^k) \rangle \geq o(\|f'(x^k)\|^2).$$

Esta última desigualdad se satisface para todo k suficientemente grande, porque $\sigma \in (0, 1/2)$, y el hecho de que $f''(\bar{x})$ es definida positiva implica que $(f''(\bar{x}))^{-1}$ es definida positiva, y por lo tanto, existe $\gamma > 0$ tal que

$$(1/2 - \sigma) \langle f'(x^k), (f''(\bar{x}))^{-1} f'(x^k) \rangle \geq \gamma(1/2 - \sigma) \|f'(x^k)\|^2.$$

Finalmente, probaremos que la tasa de convergencia de $\{x^k\}$ es superlineal. Para k suficientemente grande, $\alpha_k = 1$, obtenemos

$$\begin{aligned} \|x^{k+1} - \bar{x}\| &= \|x^k - \bar{x} - Q_k f'(x^k)\| \\ &= \|x^k - \bar{x} - (f''(\bar{x}))^{-1} f'(x^k) + ((f''(\bar{x}))^{-1} - Q_k) f'(x^k)\| \\ &\leq \|(f''(\bar{x}))^{-1} (f''(\bar{x})(x^k - \bar{x}) - f'(x^k))\| + o(\|f'(x^k)\|) \\ &= o(\|x^k - \bar{x}\|), \end{aligned}$$

lo que concluye la demostración. ■

Una de las conclusiones importantes del Teorema de Dennis-Moré es la siguiente: en la optimización de funciones dos veces diferenciables, para ser eficiente, un método debe hacer uso de aproximación de segunda orden de la función objetivo, de alguna manera. En particular, métodos que utilizan apenas aproximación de primer orden no pueden poseer convergencia superlineal en general. Cabe observar que para el método de Newton, la condición de Dennis-Moré se satisface automáticamente.

No entanto, la información de segunda orden también puede ser construida implícitamente, sin cálculo directo de la derivada segunda de f . Esta es la idea principal de los métodos cuasi-Newton: la sustitución del cálculo de $f''(x^k)$ y de la resolución del sistema de ecuaciones lineales correspondiente, por una aproximación directa del paso calculada en cada iteración. Esto puede ser hecho de varias maneras diferentes.

Para todo k , definimos

$$r^k = x^{k+1} - x^k, \quad s^k = f'(x^{k+1}) - f'(x^k). \quad (7.35)$$

Notamos que esta información ya está disponible en el momento de la escogencia de Q_{k+1} . Como queremos que esta matriz aproxime, en un cierto sentido, la inversa de la Hessiana de f , es natural imponer la condición

$$Q_{k+1} s^k = r^k, \quad (7.36)$$

que es llamada de ecuación cuasi-Newton. Implícitamente admitiendo que la matriz $f''(\bar{x})$ es natural pedir la condición $s^k = Q_{k+1}^{-1} r^k$, que resulta en (7.36).

Resumiendo, dada una matriz simétrica definida positiva Q_k y vectores r^k e s^k , la propuesta es escoger una matriz simétrica definida positiva Q_{k+1} que satisfaga (7.36). Históricamente, el primer método cuasi-Newton es el método de Davidon-Fletcher-Powell (DFP), que toma Q_0 como una matriz simétrica definida positiva arbitraria (digamos, $Q_0 = E^n$), y para todo k define

$$Q_{k+1} = Q_k + \frac{r^k (r^k)^\top}{\langle r^k, s^k \rangle} - \frac{(Q_k s^k) (Q_k s^k)^\top}{\langle Q_k s^k, s^k \rangle}. \quad (7.37)$$

Notamos que todas las matrices así generadas serán simétricas. Además, la ecuación cuasi-Newton también será satisfecha.

Proposición 7.1. Sea $Q_k \in \mathbb{R}^{n \times n}$ una matriz simétrica definida positiva. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en los puntos $x^k, x^{k+1} \in \mathbb{R}^n$, que satisfacen la relación del paso con algún valor de longitud de paso $\alpha_k > 0$. Entonces las fórmulas definen sin ambigüedad una matriz Q_{k+1} definida positiva si, y solamente si, la desigualdad

$$\langle f'(x^{k+1}), d^k \rangle > \langle f'(x^k), d^k \rangle \quad (7.38)$$

es satisfecha.

Prueba. Supongamos que Q_{k+1} sea definida positiva. Usando la ecuación cuasi-Newton, obtenemos

$$\begin{aligned}\langle d^k, f'(x^{k+1}) - f'(x^k) \rangle &= \frac{1}{\alpha_k} \langle r^k, s^k \rangle \\ &= \frac{1}{\alpha_k} \langle Q_{k+1} s^k, s^k \rangle > 0,\end{aligned}$$

donde la desigualdad vale suponiendo que $s^k \neq 0$ (caso contrario, Q_{k+1} no estaría bien definida). Obtenemos entonces (7.38).

Supongamos ahora que (7.38) se satisfaga. Utilizando también el esquema obtenemos

$$\langle r^k, s^k \rangle = \alpha_k (\langle d^k, f'(x^{k+1}) - f'(x^k) \rangle) > 0.$$

En particular, $s^k \neq 0$ y, por el hecho de que Q_k es definida positiva, $\langle Q_k s^k, s^k \rangle > 0$. Esto muestra que Q_{k+1} está bien definida. Para todo $\xi \in \mathbb{R}^n$, obtenemos

$$\begin{aligned}\langle Q_{k+1} \xi, \xi \rangle &= \langle Q_k \xi, \xi \rangle + \frac{\langle r^k, \xi \rangle^2}{\langle r^k, s^k \rangle} - \frac{\langle Q_k s^k, \xi \rangle^2}{\langle Q_k s^k, s^k \rangle} \\ &= \frac{\|Q_k^{1/2} \xi\|^2 \|Q_k^{1/2} s^k\|^2 - \langle Q_k^{1/2} \xi, Q_k^{1/2} s^k \rangle^2}{\|Q_k^{1/2} s^k\|^2} + \frac{\langle r^k, \xi \rangle^2}{\langle r^k, s^k \rangle} \geq 0,\end{aligned}$$

donde la desigualdad sigue del hecho de que ambos términos son no negativos por la desigualdad de Cauchy-Schwarz. Además, la igualdad a 0 solamente puede valer cuando ambos términos se anulan, i.e., cuando $\langle r^k, \xi \rangle = 0$ y $\|Q_k^{1/2} \xi\| \|Q_k^{1/2} s^k\| = |\langle Q_k^{1/2} \xi, Q_k^{1/2} s^k \rangle|$. La última igualdad significa que $Q_k^{1/2} \xi = t(Q_k^{1/2} s^k)$ para algún t . Como $Q_k^{1/2}$ es no-singular, esto es posible cuando $t = 0$, i.e., $\xi = 0$. Por lo tanto, Q_{k+1} es definida positiva. ■

Como consecuencias del resultado arriba son las siguientes. Si el longitud de paso es calculado por la regla de minimización unidimensional, tenemos que $\langle f'(x^{k+1}), d^k \rangle = 0$. Por tanto, valiendo automáticamente la condición, la relación de curvatura (7.38) siempre es satisfecha. Las reglas de Armijo y de Goldstein, no obstante, no poseen esta propiedad. Esta es la razón por la cual la regla de Wolfe es aquella utilizada con mayor frecuencia en implementaciones de métodos cuasi-Newton.

Entre todos los métodos cuasi-Newton, el método de Broyden-Fletcher-Goldfarb-Shanno (BFGS) es considerado actualmente el más eficiente. En este método, para todo k , definimos

$$Q_{k+1} = Q_k + \frac{(r^k - Q_k s^k)(r^k)^\top + r^k(r^k - Q_k s^k)^\top}{\langle r^k, s^k \rangle} - \frac{\langle r^k - Q_k s^k, s^k \rangle r^k (r^k)^\top}{\langle r^k, s^k \rangle^2}. \quad (7.39)$$

Es fácil ver que, como en el método DFP, las matrices generadas por (7.39) son simétricas, satisfacen a la ecuación cuasi-Newton, y la diferencia $Q_{k+1} - Q_k$ tiene puesto 2, como máximo.

Cuando f es una función cuadrática dada y Q es definida positiva, si el longitud de paso α_k es calculado por la regla de minimización unidimensional, los métodos DFP y BFGS poseen convergencia finita al único punto estacionario de f (que en este caso es la única solución global del problema). En particular, el número de iteraciones j necesario para encontrar la solución es menor o igual a la dimensión del espacio ($j \leq n$) y se tiene que $Q_j = (f''(x^j))^{-1} = Q^{-1}$.

7.4. Estrategias de globalización

Por lo expuesto arriba, los métodos Newtonianos poseen (bajo ciertas hipótesis, es claro) convergencia local con tasa rápida, mas, en general, no poseen la propiedad de convergencia global (a partir de un punto inicial arbitrario). Por lo tanto, es natural intentar modificar métodos de este tipo para garantizar convergencia global, al mismo tiempo preservando la eficiencia local. A propósito, métodos locales pasan a ser verdaderamente útiles solamente cuando son acrecentados de alguna estrategia global, capaz de proveer un punto inicial adecuado para el buen funcionamiento del esquema local. A seguir, presentamos algunas ideas con el intuito de alcanzar este objetivo.

7.4.1. Métodos con búsqueda lineal

Una clase importante de métodos de optimización son los métodos de descenso, considerados en la sección 3.1. Recordamos que métodos de este tipo poseen convergencia global (a los puntos estacionarios del problema) bajo hipótesis bien naturales. Sin embargo, no podemos esperar convergencia local con tasa mejor que lineal, incluso bajo las mejores hipótesis. Esto lleva a la idea de combinar, de alguna manera y dentro de un único algoritmo, las buenas

propiedades globales de métodos de descenso con la convergencia rápida de métodos Newtonianos. Para este fin, una estrategia natural es introducir búsqueda lineal en la dirección Newtoniana, para garantizar decrecimiento de la función objetivo, en caso de que el paso completo (i.e., con longitud igual a uno) haga que el valor de la función aumente. En principio, podemos esperar que tal modificación (cuando es adecuadamente implementada) heredará las propiedades globales de los métodos de descenso. Por otro lado, si conseguimos probar que, bajo hipótesis suficientes para convergencia local del método Newtoniano asociado, el método modificado acepta la longitud de paso igual a uno para todo k suficientemente grande, obtendremos entonces la convergencia local deseada.

Consideremos de nuevo un problema de minimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (7.40)$$

donde la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es dos veces diferenciable. Consideremos el esquema iterativo general

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k = -Q_k f'(x^k), \quad k = 0, 1, \dots, \quad (7.41)$$

donde para todo k la matriz $Q_k \in \mathbb{R}^{n \times n}$ es simétrica y definida positiva, y $\alpha_k > 0$ es el valor de la longitud del paso. Para simplificar, suponemos que α_k sea calculado por la regla de Armijo.

Por el Teorema 3.2.2 (Dennis-Moré), para este método la tasa superlineal de convergencia a un punto estacionario $\bar{x} \in \mathbb{R}^n$ del problema (7.40) (cuando convergencia) puede ser esperada si Q_k aproxima $(f''(\bar{x}))^{-1}$ cuando $k \rightarrow \infty$, en el sentido de la relación (3.66) de Dennis-Moré. Además de eso, en este caso $\alpha_k = 1$ para todo k suficientemente grande. Cabe resaltar que simplemente tomando $\alpha_k = 1$ para todo k , la convergencia global no puede ser garantizada: lejos de puntos estacionarios, un paso así puede ser demasiado largo para obtener una secuencia $\{f(x^k)\}$ no-creciente.

Supongamos que

$$\|Q_k\| \leq \Gamma, \quad \langle Q_k d, d \rangle \geq \gamma \|d\|^2 \quad \forall d \in \mathbb{R}^n, \quad \forall k, \quad (7.42)$$

para ciertos $\Gamma > 0$ y $\gamma > 0$. Utilizando (7.42), obtenemos que para todo k ,

$$\begin{aligned} \langle f'(x^k), d^k \rangle \|d^k\|^{-2} &= -\langle f'(x^k), Q_k f'(x^k) \rangle \|Q_k f'(x^k)\|^{-2} \\ &\leq -\gamma/\Gamma^2 < 0. \end{aligned} \quad (7.43)$$

En particular, la relación de acotamiento inferior del ángulo se cumple con $\delta = -\gamma/\Gamma^2$. De donde concluimos que existe una constante $\check{\alpha}$ que no depende de k , tal que

$$\alpha_k \geq \check{\alpha} > 0. \quad (7.44)$$

El teorema siguiente es una generalización del Teorema de convergencia global del gradiente. El caso de la minimización unidimensional y del paso fijo pueden ser reducidos a consideración de la regla de Armijo de la misma manera.

Teorema 7.8 (Convergencia global de métodos Newtonianos con búsqueda lineal). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$. Supongamos que el algoritmo utiliza la regla de Armijo. Supongamos, finalmente, que la secuencia de matrices $\{Q_k\}$ escogidas en este método satisfaga (7.42) para ciertos $\Gamma > 0$ e $\gamma > 0$.

Entonces, todo punto de acumulación de la secuencia $\{x^k\}$ generada por el algoritmo es un punto estacionario del problema (7.40). Si un punto de acumulación existe, o si la función f es limitada inferiormente en $\mathbb{R}^n$, entonces

$$\|f'(x^k)\| \rightarrow 0 \quad (k \rightarrow \infty).$$

Prueba. Supongamos que $f'(x^k) \neq 0$ para todo k . Por la desigualdad de Armijo, se tiene que

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) + \sigma \alpha_k \langle f'(x^k), d^k \rangle \\ &\leq f(x^k) + \sigma \check{\alpha} \delta \|d^k\|^2, \end{aligned}$$

donde utilizamos (7.43) y definimos $\delta = -\gamma/\Gamma^2 < 0$. En particular, la secuencia $\{f(x^k)\}$ es no-creciente. Si f es limitada inferiormente en $\mathbb{R}^n$, o si $\{x^k\}$ tiene un punto de acumulación, se sigue que $\{f(x^k)\}$ converge. Por lo tanto, tenemos que $f(x^{k+1}) - f(x^k) \rightarrow 0$ ($k \rightarrow \infty$) y, luego, $\{d^k\} \rightarrow 0$. Como $f'(x^k) = -Q_k^{-1} d^k$ y las matrices $\{Q_k\}$ son uniformemente definidas positivas, obtenemos el resultado. ■

Las relaciones (7.42) pueden ser esperadas en métodos cuasi-Newton (y las longitudes de paso α_k son calculados por la regla de Wolfe). Como Q_k también puede ser escogida la inversa de una modificación definida positiva (regularización) de la matriz $f''(x^k)$; vea la sección del método de Newton. Es claro que la modificación de $f''(x^k)$

solo es necesaria cuando esta matriz no es definida positiva. Cuando ella es definida positiva, podemos tomar $Q_k = (f''(x^k))^{-1}$, ya que esta elección es atractiva desde el punto de vista de convergencia local. No obstante, el requerimiento de que $f''(x^k)$ sea uniformemente definida positiva para todo k es ligeramente más fuerte que la convexidad fuerte de f en $\mathbb{R}^n$. En el caso en que no hay convexidad fuerte, la regularización se torna necesaria.

Estrategias para sistemas de ecuaciones no lineales

Las estrategias de globalización pueden ser extendidas tanto a problemas de optimización con restricciones, como a sistemas de ecuaciones no-lineales y otros problemas variacionales (mismo cuando ellos no tienen relaciones directas con optimización). Para este fin, es necesario encontrar una función de mérito, i.e., una función que puede medir, en algún sentido, la calidad de un punto dado como aproximación a la solución del problema en cuestión.

Por ejemplo, consideremos el sistema de ecuaciones

$$\Phi(x) = 0, \quad (7.45)$$

donde $\Phi: \mathbb{R}^n \rightarrow \mathbb{R}^n$ es diferenciable. En este contexto, precisamos de una función de mérito tal que los puntos estacionarios de ella sean soluciones del sistema de ecuaciones original. Una elección popular viene dada por

$$\varphi: \mathbb{R}^n \rightarrow \mathbb{R}, \quad \varphi(x) = \frac{1}{2} \|\Phi(x)\|^2. \quad (7.46)$$

En este caso, tenemos que

$$\varphi'(x) = (\Phi'(x))^T \Phi(x), \quad x \in \mathbb{R}^n. \quad (7.47)$$

Si $\bar{x} \in \mathbb{R}^n$ es un punto estacionario de la función φ tal que la matriz $\Phi'(\bar{x})$ es no-singular, entonces $\varphi'(\bar{x}) = 0$ implica $\Phi(\bar{x}) = 0$, i.e., $\bar{x}$ es una solución del problema original (7.45). Además de eso, en todo punto $x \in \mathbb{R}^n$ donde la matriz $\Phi'(x)$ es no-singular, la dirección de Newton $d = -(\Phi'(x))^{-1}\Phi(x)$ es una dirección de descenso de la función φ . Con efecto,

$$\begin{aligned} \langle \varphi'(x), d \rangle &= -\langle (\Phi'(x))^T \Phi(x), (\Phi'(x))^{-1} \Phi(x) \rangle \\ &= -\|\Phi(x)\|^2 < 0, \end{aligned}$$

y la afirmación sigue del Lema sobre direcciones de descenso.

No obstante, es fácil observar que el método de Newton correspondiente, incluso con búsqueda lineal, puede fallar en puntos donde la derivada de Φ es degenerada (singular), y estos puntos pueden no ser ni soluciones del sistema de ecuaciones, ni puntos estacionarios de la función φ .

7.4.2. Métodos de regiones de confianza

Otra estrategia natural de globalización de métodos Newtonianos es la siguiente. Como ya vimos, cada iteración de un método Newtoniano consiste en la resolución de un subproblema obtenido a través de la aproximación local (en torno de x^k dado) del problema original. Naturalmente, tal aproximación solo puede ser “confiada” en una vecindad suficientemente pequeña del punto x^k . Parece entonces razonable intentar minimizar la aproximación de la función objetivo exactamente en esta vecindad, llamada de región de confianza, y no en todo el espacio.

De nuevo, consideremos un problema de optimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (7.48)$$

donde $f: \mathbb{R}^n \rightarrow \mathbb{R}$. Sea $x^k \in \mathbb{R}^n$ una aproximación a la solución del problema. El subproblema de un método Newtoniano viene dado por

$$\min \psi_k(x), \quad x \in \mathbb{R}^n, \quad (7.49)$$

donde

$$\psi_k(x) = f(x^k) + \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle H_k(x - x^k), x - x^k \rangle, \quad (7.50)$$

y $H_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica. Una iteración del método de regiones de confianza correspondiente consiste en la resolución del siguiente subproblema:

$$\min \psi_k(x) \quad \text{sujeto a } x \in B(x^k, \delta_k), \quad (7.51)$$

donde $\delta_k > 0$ es el radio de la región de confianza. La elección inteligente del parámetro δ_k es el asunto principal en este contexto.

En principio, un subproblema de regiones de confianza presupone el cálculo de una solución global, el cual es ciertamente bien más caro que el cálculo del longitud de paso por una búsqueda lineal. O mismo comentario se aplica mismo si sustituimos resolución global de (7.51) por el cálculo de un punto estacionario de este problema. Más aún, una iteración en métodos de regiones de confianza puede requerir la resolución de más de un subproblema de la forma (7.51), hasta que un valor adecuado del radio δ_k sea encontrado. No entanto, el subproblema (7.51) posee una estructura bien específica, que puede (y debe) ser aprovechada. Existen varios métodos bien eficientes para la minimización de una función cuadrática en una bola; no hay necesidad de apelar a métodos de optimización de uso general. Además de eso, un control inteligente del parámetro δ_k evita en la práctica la necesidad de resolución de muchos subproblemas en la misma iteración. Resumiendo, buenas implementaciones de métodos de regiones de confianza tienen un costo de iteración bien aceptable.

Por otro lado, intuitivamente, parece claro que el subproblema (7.51) es una aproximación bien mejor del problema original de lo que el subproblema que consiste en minimizar f en alguna dirección fija (como en métodos de búsqueda lineal). Por lo tanto, puede ser esperado que a pesar del costo más alto, una iteración en métodos de regiones de confianza puede significar más progreso en relación a la minimización de f . Otra ventaja, que parece ser aún más clara, es la siguiente: los métodos de regiones de confianza son más robustos, en el sentido de que son capaces de resolver algunos problemas donde los métodos de búsqueda lineal no funcionan bien. Para ver esto, basta considerar un punto x^k tal que $f'(x^k) = 0$ pero existe una dirección de descenso d de f a partir de x^k que satisface $\langle f''(x^k)d, d \rangle < 0$. Obviamente, un método de búsqueda lineal en la dirección $d^k = -Q_k f'(x^k)$ no va a hacer progreso, dado que $d^k = 0$ para cualquier matriz Q_k . No obstante, es claro que si $H_k = f''(x^k)$, resolviendo el subproblema (7.51) obtendremos un punto diferente de x^k . E, como puede ser visto, este punto fornece un valor de f menor del que $f(x^k)$. A propósito, los métodos de regiones de confianza realmente poseen propiedades de convergencia global más fuertes. Como veremos a seguir, es posible probar convergencia a los puntos estacionarios que satisfacen la condición necesaria de segunda orden, y no apenas la condición necesaria de primera orden.

Algoritmo 7.5 (Método de regiones de confianza). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$. Elegir los parámetros $\bar{\delta} > 0, \sigma, \theta_1, \theta_2 \in (0, 1), \theta_1 < \theta_2$.

1. Elegir $\delta \geq \bar{\delta}$.
2. Tomar $\delta_k := \delta$. Encontrar $\tilde{x}^k \in \mathbb{R}^n$, una solución global del problema (7.51), donde la función objetivo ψ_k es dada por (7.50) con $H_k = f''(x^k)$.
3. Si $\tilde{x}^k = x^k$, pasar al ítem 4. Caso contrario, verificar la desigualdad

$$f(\tilde{x}^k) - f(x^k) \leq \sigma(\psi_k(\tilde{x}^k) - f(x^k)). \quad (7.52)$$

Si ella es satisfecha, pasar al ítem 4. Caso contrario, elegir $\delta \in [\theta_1 \|\tilde{x}^k - x^k\|, \theta_2 \delta_k]$ y pasar al ítem 2.

4. Tomar $x^{k+1} := \tilde{x}^k, k := k + 1$, y retornar al Paso 1.

Como es fácil ver, si para algún k en el Paso 3 del algoritmo tenemos la igualdad $\tilde{x}^k = x^k$, entonces el punto x^k es estacionario para el problema (7.51) y satisface la condición necesaria de segunda orden para este problema. Más precisamente, como se tiene que $\tilde{x}^k = x^k \in \text{int } B(x^k, \delta_k)$, por las condiciones necesarias de primera y segunda orden para el problema (7.51), obtenemos que

$$0 = \psi'_k(\tilde{x}^k) = f'(x^k) + f''(x^k)(\tilde{x}^k - x^k) = f'(x^k), \quad (7.53)$$

y la matriz

$$\psi''_k(\tilde{x}^k) = f''(x^k) \quad (7.54)$$

es semidefinida positiva. La desigualdad (7.52) significa que el decrecimiento de la función objetivo f es por lo menos una fracción dada del decrecimiento previsto por la aproximación ψ_k de la función f .

Proposición 7.2 (El método de regiones de confianza está bien definido). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces diferenciable en $\mathbb{R}^n$. Supongamos que $x^k \in \mathbb{R}^n$ o no es un punto estacionario del problema (7.48) (i.e., $f'(x^k) \neq 0$), o él no satisface a la condición necesaria de segunda orden para el mismo problema (i.e., $f''(x^k)$ no es semidefinida positiva). Entonces el Algoritmo genera un iterando siguiente x^{k+1} tal que $f(x^{k+1}) < f(x^k)$.

Prueba. Para cada número $\delta > 0$, sea $\tilde{x}(\delta)$ alguna (cualquier) solución global del subproblema (7.51) con $\delta_k = \delta$. Definimos

$$\rho(\delta) = \frac{f(\tilde{x}(\delta)) - f(x^k)}{\psi_k(\tilde{x}(\delta)) - f(x^k)}. \quad (7.55)$$

Pelo expuesto arriba, $f'(x^k) \neq 0$, o $f'(x^k) = 0$ con la matriz $f''(x^k)$ no semidefinida positiva, implican en que $\tilde{x}(\delta) \neq x^k$. Por eso, en particular, tenemos que

$$\psi_k(\tilde{x}(\delta)) < \psi_k(x^k) = f(x^k). \quad (7.56)$$

Observamos que es suficiente probar que

$$\lim_{\delta \rightarrow 0^+} \rho(\delta) = 1. \quad (7.57)$$

Claramente, (7.57) implica que (7.52) vale para todo δ suficientemente pequeño. Luego, el valor de δ será adecuado después de un número finito de modificaciones en el Paso 3 del algoritmo.

Supongamos primero que $f'(x^k) \neq 0$. Tomamos $d \in \mathbb{R}^n$ tal que $\langle f'(x^k), d \rangle < 0$, $\|d\| = 1$. Como $x^k + \delta d \in B(x^k, \delta_k)$, tenemos que

$$\begin{aligned} \psi_k(\tilde{x}(\delta)) &\leq \psi_k(x^k + \delta d) \\ &= f(x^k) + \delta \langle f'(x^k), d \rangle + \frac{\delta^2}{2} \langle f''(x^k) d, d \rangle, \end{aligned} \quad (7.58)$$

donde

$$\begin{aligned} \psi_k(\tilde{x}(\delta)) - f(x^k) &\leq \delta \left(\langle f'(x^k), d \rangle + \frac{\delta}{2} \|f''(x^k)\| \right) \\ &\leq \frac{\delta}{2} \langle f'(x^k), d \rangle, \end{aligned} \quad (7.59)$$

donde la última desigualdad vale para todo $\delta > 0$ suficientemente pequeño. Por la Fórmula de Taylor de segunda orden, tenemos que

$$\begin{aligned} f(\tilde{x}(\delta)) - \psi_k(\tilde{x}(\delta)) &= f(\tilde{x}(\delta)) - f(x^k) - \langle f'(x^k), \tilde{x}(\delta) - x^k \rangle \\ &\quad - \frac{1}{2} \langle f''(x^k)(\tilde{x}(\delta) - x^k), \tilde{x}(\delta) - x^k \rangle \\ &= o(\delta^2). \end{aligned} \quad (7.60)$$

Combinando (7.60) e (7.59), obtenemos que

$$|\rho(\delta) - 1| = \left| \frac{f(\tilde{x}(\delta)) - \psi_k(\tilde{x}(\delta))}{\psi_k(\tilde{x}(\delta)) - f(x^k)} \right| = o(\delta),$$

lo que implica (7.57).

Sea ahora $f'(x^k) = 0$, y existe $d \in \mathbb{R}^n$, $\|d\| = 1$, tal que $\langle f''(x^k) d, d \rangle < 0$. Obtenemos que

$$\psi_k(\tilde{x}(\delta)) \leq \psi_k(x^k + \delta d) = f(x^k) + \frac{\delta^2}{2} \langle f''(x^k) d, d \rangle. \quad (7.61)$$

Luego,

$$\psi_k(\tilde{x}(\delta)) - f(x^k) \leq \frac{\delta^2}{2} \langle f''(x^k) d, d \rangle. \quad (7.62)$$

Combinando esta relación con (7.60), obtenemos

$$|\rho(\delta) - 1| = \frac{o(\delta^2)}{\delta^2},$$

lo que implica en (7.57). Probaremos ahora la convergencia de métodos de regiones de confianza a puntos estacionarios satisfaciendo a condición necesaria de segunda orden. ■

Teorema 7.9 (Convergencia de métodos de regiones de confianza). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces continuamente diferenciable en $\mathbb{R}^n$. Entonces, todo punto de acumulación de cualquier secuencia $\{x^k\}$ generada por el Algoritmo es un punto estacionario del problema (7.48). Más aún, este punto satisface la condición necesaria de segunda orden para este problema.

Prueba. Por la Proposición 3.3.1, la secuencia $\{f(x^k)\}$ es decreciente. Supongamos que la secuencia $\{x^k\}$ posea un punto de acumulación $\bar{x} \in \mathbb{R}^n$. En este caso, por el hecho de que $\{f(x^k)\}$ es decreciente, ella es limitada inferiormente (por $f(\bar{x})$), por lo tanto, ella converge. En particular, tenemos que $f(x^{k+1}) - f(x^k) \rightarrow 0$ ($k \rightarrow \infty$). De (7.52) tenemos

que

$$0 \leq \sigma(f(x^k) - \psi_k(x^{k+1})) \leq f(x^k) - f(x^{k+1}),$$

donde

$$\psi_k(x^{k+1}) - f(x^k) \rightarrow 0 \quad (k \rightarrow \infty). \quad (7.63)$$

Sea $\{x^{k_j}\}$ una subsecuencia de $\{x^k\}$ que converge a $\bar{x}$. Hay dos posibilidades:

$$\liminf_{j \rightarrow \infty} \delta_{k_j} > 0, \quad (7.64)$$

o

$$\liminf_{j \rightarrow \infty} \delta_{k_j} = 0. \quad (7.65)$$

Consideremos el primer caso. Definimos

$$\bar{\delta} = \liminf_{j \rightarrow \infty} \delta_{k_j} > 0. \quad (7.66)$$

Sea $\bar{y} \in \mathbb{R}^n$ una solución global del problema

$$\min \langle f'(\bar{x}), x - \bar{x} \rangle + \frac{1}{2} \langle f''(\bar{x})(x - \bar{x}), x - \bar{x} \rangle \quad \text{sueto a } x \in \bar{D}, \quad (7.67)$$

donde $\bar{D} = \{x \in \mathbb{R}^n \mid \|x - \bar{x}\| \leq \bar{\delta}/4\}$. Para todo j suficientemente grande,

$$\|\bar{y} - x^{k_j}\| \leq \|\bar{y} - \bar{x}\| + \|x^{k_j} - \bar{x}\| \leq \bar{\delta}/2 \leq \delta_{k_j}.$$

En particular, el punto $\bar{y}$ es factible para el problema (7.51) para $k = k_j$. Por lo tanto,

$$\begin{aligned} \psi_{k_j}(x^{k_j+1}) &\leq \psi_{k_j}(\bar{y}) \\ &= f(x^{k_j}) + \langle f'(x^{k_j}), \bar{y} - x^{k_j} \rangle + \frac{1}{2} \langle f''(x^{k_j})(\bar{y} - x^{k_j}), \bar{y} - x^{k_j} \rangle. \end{aligned}$$

Pasando al límite cuando $j \rightarrow \infty$ y llevando en cuenta (7.63), obtenemos que

$$0 \leq \langle f'(\bar{x}), \bar{y} - \bar{x} \rangle + \frac{1}{2} \langle f''(\bar{x})(\bar{y} - \bar{x}), \bar{y} - \bar{x} \rangle. \quad (7.68)$$

Concluimos que $\bar{x}$ también es una solución global del problema (7.67) (donde el valor óptimo de este problema es cero). Como se tiene que $\bar{x} \in \text{int } \bar{D}$, las condiciones de optimalidad del Teorema 1.2.1 implican el resultado anunciado, en el caso de (7.64).

Supongamos ahora (7.65). Sin pérdida de generalidad podemos admitir que toda la secuencia $\{\delta_{k_j}\}$ converge a cero. Luego, para todo j suficientemente grande tenemos $\delta_{k_j} < \bar{\delta}$, y en la iteración con índice k_j en el Paso 3 del algoritmo el radio de la región de confianza fue reducido por lo menos una vez. Por lo tanto, existe un número $\hat{\delta}_{k_j}$, para el cual existe una solución global $\bar{x}(\hat{\delta})$ del problema (7.51) con $x^k = x^{k_j}$, $\delta_k = \hat{\delta}_{k_j}$, tal que

$$f(\bar{x}(\hat{\delta}_{k_j})) > f(x^{k_j}) + \sigma(\psi_{k_j}(\bar{x}(\hat{\delta}_{k_j})) - f(x^{k_j})), \quad (7.69)$$

y

$$\delta_{k_j} \geq \theta_1 \|\bar{x}(\hat{\delta}_{k_j}) - x^{k_j}\|. \quad (7.70)$$

Por la elección de la subsecuencia $\{\delta_{k_j}\}$, la última relación significa, en particular, que $\|\bar{x}(\hat{\delta}_{k_j}) - x^{k_j}\| \rightarrow 0$ ($j \rightarrow \infty$). El resto de la demostración es similar a aquella de la Proposición 3.3.1. Supongamos que exista $d \in \mathbb{R}^n$ tal que $\|d\| = 1$ y o

$$\langle f'(\bar{x}), d \rangle < 0, \quad (7.71)$$

es satisfecha, o

$$f'(\bar{x}) = 0, \quad \langle f''(\bar{x})d, d \rangle < 0, \quad (7.72)$$

es satisfecha. Obtenemos que

$$\begin{aligned} \psi_{k_j}(\bar{x}(\hat{\delta}_{k_j})) &\leq \psi_{k_j}(x^{k_j} + \hat{\delta}_{k_j}d) \\ &= f(x^{k_j}) + \hat{\delta}_{k_j} \langle f'(x^{k_j}), d \rangle + \frac{\hat{\delta}_{k_j}^2}{2} \langle f''(x^{k_j})d, d \rangle. \end{aligned}$$

De aquí, en el caso de (7.71), sigue que para todo j suficientemente grande

$$\begin{aligned}\psi_{k_j}(\bar{x}(\delta_{k_j})) - f(x^{k_j}) &\leq \delta_{k_j} \langle f'(x^{k_j}), d \rangle + \delta_{k_j} \|f''(x^{k_j})\|/2 \\ &\leq \frac{\delta_{k_j}}{2} \langle f'(\bar{x}), d \rangle.\end{aligned}$$

Ahora, definiendo

$$\rho_{k_j} = \frac{f(\bar{x}(\delta_{k_j})) - f(x^{k_j})}{\psi_{k_j}(\bar{x}(\delta_{k_j})) - f(x^{k_j})}, \quad (7.73)$$

obtenemos que

$$|\rho_{k_j} - 1| = o(\delta_{k_j}^2)/\delta_{k_j} \rightarrow 0 \quad (j \rightarrow \infty), \quad (7.74)$$

en contradicción con (7.69). En el caso de (7.72), obtenemos que $\rho_{k_j} \rightarrow 1$ de manera análoga, lo que de nuevo entra en contradicción con (7.69). ■

Como en el caso de búsqueda lineal, las áreas de utilización de estrategias de regiones de confianza no se limitan a optimización irrestricta o a los métodos Newtonianos. En el caso de problemas con restricciones, el radio de la región de confianza es escogido para garantizar decrecimiento suficiente de una función de mérito asociada al problema.

7.4.3. Métodos de continuación paramétricos

Otra idea para la obtención de una buena aproximación a la solución, que puede ser posteriormente utilizada por métodos locales, es la presentada a seguir. El problema de optimización original, o el sistema de condiciones de optimalidad asociado al problema, puede ser incluido en una familia de problemas, parametrizados (tanto de manera “natural” como “artificial”) por un parámetro escalar. Supongamos que para un cierto valor del parámetro, la solución (o una buena aproximación de la solución) sea conocida (o pueda ser encontrada fácilmente). Podemos entonces intentar “seguir” esta solución (o su aproximación) hasta el valor del parámetro que corresponde al problema original. Naturalmente, este proceso, cuando es viable en principio, debe ser realizado de manera computacionalmente razonable (en particular, de manera inexacta, aproximada). Con una coordinación inteligente de parámetros involucrados, podemos esperar que un punto generado así sea una aproximación de la solución del problema original, aceptable para aplicación de un método local rápido.

De nuevo, nos limitaremos a un problema de optimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (7.75)$$

donde la función $f: \mathbb{R}^n \rightarrow \mathbb{R}$ es suficientemente diferenciable. Sea $\Phi: [0, 1] \times \mathbb{R}^n \rightarrow \mathbb{R}^n$ una función suficientemente diferenciable que posee la propiedad de que

$$\Phi(1, x) = f'(x), \quad x \in \mathbb{R}^n. \quad (7.76)$$

Supongamos finalmente que una solución $x^0 \in \mathbb{R}^n$ de la ecuación

$$\Phi(0, x) = 0 \quad (7.77)$$

puede ser aproximada con una precisión arbitrariamente fina. Por ejemplo, si para alguna función $\Phi_0: \mathbb{R}^n \rightarrow \mathbb{R}^n$ la ecuación $\Phi_0(x) = 0$ posee una solución que es conocida, podemos tomar

$$\Phi(t, x) = t f'(x) + (1 - t) \Phi_0(x), \quad t \in [0, 1], \quad x \in \mathbb{R}^n. \quad (7.78)$$

En particular, podemos fijar $x^0 \in \mathbb{R}^n$ y definir $\Phi_0(x) = f'(x) - f'(x^0)$, $x \in \mathbb{R}^n$, lo que resulta en

$$\Phi(t, x) = f'(x) - (1 - t) f'(x^0), \quad t \in [0, 1], \quad x \in \mathbb{R}^n. \quad (7.79)$$

Ne entanto, cabe resaltar que en la mayoría de los casos (en particular, en optimización con restricciones), la función Φ es definida utilizando técnicas y consideraciones bien más sofisticadas.

Supongamos que exista una función $\chi: [0, 1] \rightarrow \mathbb{R}^n$ continua en $[0, 1]$, tal que

$$\chi(0) = x^0, \quad \Phi(t, \chi(t)) = 0 \quad \forall t \in [0, 1]. \quad (7.80)$$

Bajo estas hipótesis $\bar{x} = \chi(1)$ es un punto estacionario del problema (7.75), y podemos intentar aproximar este punto siguiendo la curva en $\mathbb{R}^n$ definida por la función χ , de $\chi(0)$ hasta $\chi(1)$.

Las condiciones suficientes que garantizan que esto puede ser hecho (localmente) son dadas por el Teorema de la Función Implícita. Más precisamente, si la matriz $\Phi'_x(0, x^0)$ no es singular, entonces existen una vecindad U de 0 en $\mathbb{R}$ y una función $\chi: U \rightarrow \mathbb{R}^n$, continua (de hecho, diferenciable) en U , tales que $\chi(0) = x^0$, $\Phi(t, \chi(t)) = 0$ para todo $t \in U$. No obstante, para garantizar las mismas propiedades globalmente (en otras palabras, garantizar que $U \supset [0, 1]$), son necesarias hipótesis bien fuertes (vea, por ejemplo, el Ejercicio 3.3.5 más adelante). Por eso, puede ser bastante útil sustituir la parametrización “natural” introducida arriba por una parametrización “artificial”. En particular, bajo hipótesis mucho más débiles sobre Φ , existe una curva de soluciones en el espacio $\mathbb{R} \times \mathbb{R}^n$, definida por una función continua de forma $(\tau(\cdot), \chi(\cdot)): [0, \bar{s}] \rightarrow \mathbb{R} \times \mathbb{R}^n$, con $(\tau(0), \chi(0)) = (0, x^0)$, $\tau(\bar{s}) = 1$, donde $\bar{s} > 0$. Como parámetro nuevo es razonable considerar el longitud de esta curva (vea [1, 20]). En este caso, la curva en cuestión es caracterizada por el problema diferencial

$$\frac{\partial \Phi}{\partial t}(t, x)\dot{t} + \frac{\partial \Phi}{\partial x}(t, x)\dot{x} = 0, \quad |(\dot{t}, \dot{x})| = 1, \quad (t(0), x(0)) = (0, x^0). \quad (7.81)$$

Para simplificar, de aquí en adelante consideraremos apenas la continuación global en relación al parámetro natural.

Comenzamos con algoritmos de continuación finitos. Para un número entero N arbitrario, definimos en el intervalo $[0, 1]$ una red $\{t_0^N, t_1^N, \dots, t_N^N\}$ ($0 = t_0^N < t_1^N < \dots < t_N^N = 1$). Definimos aún el paso máximo de la red

$$\bar{\Delta}_N = \max_{i=0,1,\dots,N-1} (t_{i+1}^N - t_i^N). \quad (7.82)$$

Sea $x^{0,0} \in \mathbb{R}^n$ una aproximación de la solución x^0 de la ecuación (7.77) que tenemos a disposición. A partir de $x^{0,0}$ hacemos k_0 pasos del método de Newton para la ecuación

$$\Phi(t_i^N, x) = 0, \quad (7.83)$$

con $i = 0$ (o sea para la ecuación (7.77)). A partir del punto obtenido de esta manera, hacemos k_1 pasos del método de Newton para la ecuación (7.83) con $i = 1$. Repitiendo este proceso para todo $i = 0, 1, \dots, N-1$, obtenemos las fórmulas

$$x^{i,k+1} = x^{i,k} - (\Phi'_x(t_i^N, x^{i,k}))^{-1} \Phi(t_i^N, x^{i,k}), \quad (7.84)$$

para $k = 0, 1, \dots, k_i - 1$, $i = 0, 1, \dots, N-1$, donde

$$x^{i,0} = x^{i-1,k_{i-1}}, \quad i = 1, \dots, N-1. \quad (7.85)$$

La sugerencia es utilizar el punto final $\tilde{x}^N = x^{N-1,k_{N-1}}$ obtenido de esta manera como un punto inicial para algún método local rápido para encontrar el punto estacionario $\bar{x} = \chi(1)$ del problema (7.75).

En el análisis a seguir, consideraremos el caso cuando $k_i = 1$ para todo $i = 0, 1, \dots, N-1$, i.e., para toda ecuación (7.83) el parámetro es actualizado después de cada paso del método de Newton.

Algoritmo 7.6 (Método de continuación finito). En el intervalo $[0, 1]$, elegir una red $\{t_0^N, t_1^N, \dots, t_N^N\}$ (donde $0 = t_0^N < t_1^N < \dots < t_N^N = 1$). Elegir $x^{0,0} \in \mathbb{R}^n$. Tomar $\tilde{x}^0 = x^{0,0}$ y calcular el punto $\tilde{x}^N \in \mathbb{R}^n$ de acuerdo con

$$\tilde{x}^{i+1} = \tilde{x}^i - (\Phi'_x(t_i^N, \tilde{x}^i))^{-1} \Phi(t_{i+1}^N, \tilde{x}^i), \quad i = 0, 1, \dots, N-1. \quad (7.86)$$

Como veremos, bajo hipótesis naturales, es posible garantizar que el punto $\tilde{x}^N$ así generado quede tan próximo como deseamos, desde que la red escogida sea suficientemente fina y el punto $x^{0,0}$ sea suficientemente próximo a x^0 . Denotamos el grafo de la función $\chi: [0, 1] \rightarrow \mathbb{R}^n$ por

$$G(\chi) = \{(t, x) \in [0, 1] \times \mathbb{R}^n \mid \chi(t) = x\}. \quad (7.87)$$

Teorema 7.10 (Propiedades del método de continuación finito). Sean la función $\Phi: [0, 1] \times \mathbb{R}^n \rightarrow \mathbb{R}^n$ y el punto $x^0 \in \mathbb{R}^n$ tales que existe una función $\chi: [0, 1] \rightarrow \mathbb{R}^n$ continua en $[0, 1]$ que satisface (7.80). Sea Φ diferenciable en relación a x en una vecindad del conjunto $G(\chi)$, con la derivada parcial Φ'_x continua en $G(\chi)$. Supongamos, finalmente, que

$$\det \Phi'_x(t, \chi(t)) \neq 0 \quad \forall t \in [0, 1]. \quad (7.88)$$

Entonces, para todo número $\delta > 0$ suficientemente pequeño existe un número $\Delta > 0$ tal que, si la red $\{t_0^N, t_1^N, \dots, t_N^N\}$ en $[0, 1]$ y el punto inicial $x^{0,0} \in \mathbb{R}^n$ satisfacen a las condiciones

$$\bar{\Delta}_N < \Delta, \quad \|x^{0,0} - x^0\| < \delta, \quad (7.89)$$

donde $\tilde{\Delta}_N$ es definido en (7.82), entonces el Algoritmo 3.3.2 está bien definido y genera el punto $\tilde{x}^N \in \mathbb{R}^n$ tal que

$$\|\tilde{x}^N - \chi(1)\| < \delta. \quad (7.90)$$

Prueba. Utilizando (7.88), la continuidad de Φ'_x en $G(\chi)$, el teorema sobre perturbaciones pequeñas de una matriz no-singular (vea el Teorema 1.5.1), y la compacidad del intervalo $[0, 1]$, es fácil verificar que existen una vecindad U del conjunto $G(\chi)$ y un número $M > 0$, tales que

$$\det \Phi'_x(t, x) \neq 0, \quad \|(\Phi'_x(t, x))^{-1}\| \leq M \quad \forall (t, x) \in U. \quad (7.91)$$

Por consideraciones análogas a aquellas de la demostración del Teorema 3.2.1 (Newton local), esto implica que para todo $q \in (0, 1)$ existe un número $\hat{\delta} > 0$ tal que (independientemente de la elección de la red), si para algún $i \in \{0, 1, \dots, N-1\}$ tenemos que $\tilde{x}^i \in B(\chi(t_i^N), \hat{\delta})$, entonces la fórmula (7.86) unívocamente define $\tilde{x}^{i+1}$. Más aún,

$$\|\tilde{x}^{i+1} - \chi(t_i^N)\| \leq q \|\tilde{x}^i - \chi(t_i^N)\|. \quad (7.92)$$

Definimos

$$\tilde{\Delta}_N = \max_{i=0,1,\dots,N-1} \|\chi(t_{i+1}^N) - \chi(t_i^N)\|. \quad (7.93)$$

De (7.82), llevando en cuenta que una función continua en un conjunto compacto es uniformemente continua en este conjunto, obtenemos que para todo $\delta \in (0, \hat{\delta})$ existe $\Delta > 0$ tal que, cuando vale la primera desigualdad en (7.89), se tiene que

$$\tilde{\Delta}_N / (1 - q) < \delta. \quad (7.94)$$

Supongamos que el algoritmo tenga generado los puntos $\tilde{x}^0, \dots, \tilde{x}^i, i \in \{0, 1, \dots, N-1\}$, e $\|\tilde{x}^j - \chi(t_j^N)\| < \delta \quad \forall j = 0, 1, \dots, i$. El algoritmo entonces unívocamente define $\tilde{x}^{i+1}$ y, por la desigualdad de contracción (7.92), tenemos que

$$\begin{aligned} \|\tilde{x}^{i+1} - \chi(t_{i+1}^N)\| &\leq \|\tilde{x}^{i+1} - \chi(t_i^N)\| + \|\chi(t_{i+1}^N) - \chi(t_i^N)\| \\ &\leq q \|\tilde{x}^i - \chi(t_i^N)\| + \tilde{\Delta}_N \\ &\leq q(q \|\tilde{x}^{i-1} - \chi(t_{i-1}^N)\| + \tilde{\Delta}_N) + \tilde{\Delta}_N \\ &\vdots \\ &\leq q^{i+1} \|\tilde{x}^{0,0} - \chi(t_0^N)\| + \tilde{\Delta}_N \sum_{j=0}^i q^j \\ &\leq q^{i+1} \delta + \tilde{\Delta}_N (1 - q^{i+1}) / (1 - q) \\ &= q^{i+1} (\delta - \tilde{\Delta}_N / (1 - q)) + \tilde{\Delta}_N / (1 - q) \\ &\leq q \delta + \tilde{\Delta}_N < \delta. \end{aligned}$$

Donde sigue el resultado anunciado. ■

Naturalmente, métodos de continuación finitos pueden ser contruidos utilizando otras técnicas, no necesariamente en la base de métodos Newtonianos. De la demostración anterior, puede ser observado que la propiedad necesaria para tal desarrollo es la convergencia local (del método que queremos utilizar) a la solución $\chi(t)$ de la ecuación $\Phi(t, x) = 0$, para todo $t \in [0, 1]$. En este sentido, la condición (7.88) es importante: sin esta condición, la tarea de “seguir” a la curva definida por χ es mucho más difícil (en el sentido computacional). En algunos casos, esta dificultad puede ser superada mudando a parametrización, como ya fue mencionado.

Consideraremos ahora métodos de continuación basados en la resolución de un problema diferencial. Si Φ es suficientemente diferenciable y para todo $t \in [0, 1]$ a la matriz $\Phi'_x(t, \chi(t))$ es no-singular, por el Teorema de la Función Implícita la función χ es diferenciable. Tomando a la derivada en relación a t en la segunda igualdad de (7.80) (como composición de funciones diferenciables), obtenemos que $\chi(\cdot)$ es una solución del problema diferencial

$$\dot{x} = - \left(\frac{\partial \Phi}{\partial x}(t, x) \right)^{-1} \frac{\partial \Phi}{\partial t}(t, x), \quad x(0) = x^0. \quad (7.95)$$

Una idea natural consiste en aproximar $\tilde{x} = \chi(1)$ resolviendo el problema (7.95) utilizando, por ejemplo, el método de Euler, o el método de Runge-Kutta, etc. En el caso del método de Euler, obtenemos el siguiente (comparar con el Algoritmo 3.3.2).

Algoritmo 7.7 (Método de continuación basado en resolución de un problema diferencial). En el intervalo $[0, 1]$ elegir una red $\{t_0^N, t_1^N, \dots, t_N^N\}$ (donde $0 = t_0^N < t_1^N < \dots < t_N^N = 1$). Elegir $x^{0,0} \in \mathbb{R}^n$. Tomar $\tilde{x}^0 = x^{0,0}$ y calcular el punto $\tilde{x}^N \in \mathbb{R}^n$ de acuerdo con

$$\tilde{x}^{i+1} = \tilde{x}^i - (t_{i+1}^N - t_i^N)(\Phi'_x(t_i^N, \tilde{x}^i))^{-1}\Phi'_t(t_i^N, \tilde{x}^i), \quad i = 0, 1, \dots, N-1. \quad (7.96)$$

Teorema 7.11 (Propiedades del método de continuación basado en resolución de un problema diferencial). Sean la función $\Phi: [0, 1] \times \mathbb{R}^n \rightarrow \mathbb{R}^n$ y el punto $x^0 \in \mathbb{R}^n$ tales que existe una función $\chi: [0, 1] \rightarrow \mathbb{R}^n$ continua en $[0, 1]$ que satisface (7.80). Sea Φ diferenciable en una vecindad V del conjunto $G(\chi)$, con derivada continua en $G(\chi)$. Supongamos que exista un número $L > 0$ tal que

$$\|\Phi'_x(t, x) - \Phi'_x(t, \chi(t))\| \leq L\|x - \chi(t)\| \quad \forall (t, x) \in V. \quad (7.97)$$

Supongamos, finalmente, que (7.88) se satisfaga. Entonces para cualesquier números $\varepsilon > 0$ y $C > 0$ existen un número entero $\bar{N}$ y un número $\delta > 0$ tales que, si el punto inicial $x^{0,0} \in \mathbb{R}^n$ y a la red $\{t_0^N, t_1^N, \dots, t_N^N\}$ en $[0, 1]$ satisfacen a las condiciones

$$\bar{\Delta}_N \leq C/N, \quad N \geq \bar{N}, \quad \|x^{0,0} - x^0\| < \delta, \quad (7.98)$$

donde $\bar{\Delta}_N$ es definido en (7.82), el Algoritmo 3.3.3 está bien definido y genera el punto $\tilde{x}^N \in \mathbb{R}^n$ tal que

$$\|\tilde{x}^N - \chi(1)\| < \varepsilon. \quad (7.99)$$

Prueba. Utilizando (7.88), la continuidad de $\chi(\cdot)$ en $[0, 1]$, la continuidad de la derivada de Φ en $G(\chi)$, el teorema sobre perturbaciones pequeñas de una matriz no-singular, y la compacidad del intervalo $[0, 1]$, es fácil verificar que existen una vecindad $U \subset V$ del conjunto $G(\chi)$ y un número $\tilde{L} > 0$ tales que a la función

$$\Psi: U \rightarrow \mathbb{R}^n, \quad \Psi(t, x) = -(\Phi'_x(t, x))^{-1}\Phi'_t(t, x),$$

está bien definida, a la función $\Psi(\cdot, \chi(\cdot)): [0, 1] \rightarrow \mathbb{R}^n$ es continua en $[0, 1]$, e

$$\|\Psi(t, x) - \Psi(t, \chi(t))\| \leq \tilde{L}\|x - \chi(t)\| \quad \forall (t, x) \in U. \quad (7.100)$$

Escogeremos un número $\hat{\delta} > 0$ para satisfacer

$$\{t\} \times B(\chi(t), \hat{\delta}) \subset U \quad \forall t \in [0, 1] \quad (7.101)$$

(la posibilidad de hacer esto sigue de la compacidad de $[0, 1]$). Definimos

$$\bar{\Delta}_N = \max_{i=0,1,\dots,N-1} \max_{t \in [t_i^N, t_{i+1}^N]} \|\Psi(t_i^N, \chi(t_i^N)) - \Psi(t, \chi(t))\|. \quad (7.102)$$

De (7.82), de la continuidad de la función $\Psi(\cdot, \chi(\cdot))$ en $[0, 1]$, del hecho de que una función continua en un conjunto compacto es uniformemente continua en este conjunto, sigue que para todo número $\delta > 0$ tal que, cuando a la primera desigualdad en (7.98) es satisfecha, se tiene que

$$\begin{aligned} (\delta + \bar{\Delta}_N)(1 + \tilde{L}\bar{\Delta}_N)^N &\leq (\delta + \bar{\Delta}_N)(1 + \tilde{L}C/N)^N \\ &\leq (\delta + \bar{\Delta}_N)e^{\tilde{L}C} \\ &< \min\{\varepsilon, \hat{\delta}\}, \end{aligned} \quad (7.103)$$

para todo N suficientemente grande. Supongamos que el algoritmo generó los puntos $\tilde{x}^0, \tilde{x}^1, \dots, \tilde{x}^i, i \in \{0, 1, \dots, N-1\}$, e $\|\tilde{x}^j - \chi(t_j^N)\| < \hat{\delta}$ para todo $j = 0, 1, \dots, i$. El algoritmo entonces define unívocamente $\tilde{x}^{i+1}$ y tenemos que

$$\begin{aligned} \tilde{x}^{i+1} &= \tilde{x}^i + (t_{i+1}^N - t_i^N)\Psi(t_i^N, \tilde{x}^i) \\ &= \tilde{x}^{i-1} + (t_i^N - t_{i-1}^N)\Psi(t_{i-1}^N, \tilde{x}^{i-1}) + (t_{i+1}^N - t_i^N)\Psi(t_i^N, \tilde{x}^i) \\ &\vdots \\ &= \tilde{x}^0 + \sum_{j=0}^i (t_{j+1}^N - t_j^N)\Psi(t_j^N, \tilde{x}^j) \\ &= \tilde{x}^0 + \sum_{j=0}^i \int_{t_j^N}^{t_{j+1}^N} \Psi(t_j^N, \tilde{x}^j) dt. \end{aligned}$$

Además de eso, utilizando la Fórmula de Newton-Leibnitz para (7.95), tenemos que

$$\chi(t_{i+1}^N) = x^0 + \int_0^{t_{i+1}^N} \Psi(t, \chi(t)) dt = x^0 + \sum_{j=0}^i \int_{t_j^N}^{t_{j+1}^N} \Psi(t, \chi(t)) dt. \quad (7.104)$$

Utilizando las dos últimas relaciones, a la última desigualdad en (7.98), así como las relaciones (7.100) e (7.103), obtenemos que

$$\begin{aligned} \|\bar{x}^{i+1} - \chi(t_{i+1}^N)\| &\leq \|\bar{x}^0 - x^0\| + \sum_{j=0}^i \int_{t_j^N}^{t_{j+1}^N} \|\Psi(t_j^N, \bar{x}^j) - \Psi(t, \chi(t))\| dt \\ &\leq \|\bar{x}^0 - x^0\| \\ &\quad + \sum_{j=0}^i \int_{t_j^N}^{t_{j+1}^N} (\|\Psi(t_j^N, \bar{x}^j) - \Psi(t_j^N, \chi(t_j^N))\| \\ &\quad + \|\Psi(t_j^N, \chi(t_j^N)) - \Psi(t, \chi(t))\|) dt \\ &\leq \delta + \bar{\Delta}_N + \bar{L}\bar{\Delta}_N \sum_{j=0}^i \|\bar{x}^j - \chi(t_j^N)\|. \end{aligned}$$

Ahora, utilizando también una desigualdad discreta de Gronwall (Lema 1.5.3 original) y (7.103), obtenemos

$$\|\bar{x}^{i+1} - \chi(t_{i+1}^N)\| \leq (\delta + \bar{\Delta}_N)(1 + \bar{L}\bar{\Delta}_N)^{i+1} < \min\{\epsilon, \delta\},$$

donde se sigue el resultado deseado. ■

Por lo observado en los Teoremas 3.3.3 e 3.3.4, el Algoritmo 3.3.2 posee claras ventajas en comparación con el Algoritmo 3.3.3, tanto en relación a las propiedades establecidas como en relación a las hipótesis utilizadas para probar estas propiedades. Por otro lado, el Algoritmo 3.3.3 es en general bien menos sensible en relación a la elección de la red. Por eso, ambos métodos poseen cierta utilidad práctica. De hecho, con frecuencia estos métodos son utilizados en combinación: por ejemplo, la aproximación obtenida a partir de un punto dado de la red por el esquema de Euler es posteriormente mejorada por uno o más pasos del método de Newton. Típicamente, la red no es fijada a priori y se va adaptando a lo largo del proceso computacional. Varios otros métodos de continuación, así como detalles de implementación, pueden ser consultados en la literatura clásica.

7.5. Métodos de direcciones conjugadas

Presentamos a continuación una clase más importante de métodos que buscan alcanzar una convergencia más rápida que la de los métodos del gradiente, al mismo tiempo reduciendo el costo computacional del método de Newton. En particular, son métodos de primer orden (que no usan derivadas segundas), pero basados en ideas diferentes de los métodos cuasi-Newton.

7.5.1. Métodos de direcciones conjugadas para funciones cuadráticas

Los métodos de direcciones conjugadas serán introducidos primero para un problema de minimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (7.105)$$

con función objetivo $f: \mathbb{R}^n \rightarrow \mathbb{R}$ cuadrática fuertemente convexa:

$$f(x) = \langle Qx, x \rangle + \langle q, x \rangle, \quad x \in \mathbb{R}^n, \quad (7.106)$$

donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, $q \in \mathbb{R}^n$.

Para motivar el desarrollo, consideremos un iterando x^k , una dirección d^k , y el iterando siguiente x^{k+1} calculado por la regla de minimización unidimensional. Recordamos que en el caso cuadrático x^{k+1} puede ser calculado por fórmula explícita y que vale la relación

$$0 = \langle f'(x^{k+1}), d^k \rangle = \langle 2Qx^{k+1} + q, d^k \rangle. \quad (7.107)$$

Sea $\bar{x}$ el minimizador de f . En particular, $f'(\bar{x}) = 2Q\bar{x} + q = 0$. Por lo tanto,

$$0 = \langle 2Q\bar{x} + q, d^k \rangle. \quad (7.108)$$

Restando las dos ecuaciones arriba, obtenemos

$$0 = 2\langle Q(x^{k+1} - \bar{x}), d^k \rangle. \quad (7.109)$$

La idea es hacer que la dirección siguiente d^{k+1} satisfaga a la misma condición que la dirección “ideal” $x^{k+1} - \bar{x}$ (que lleva a la solución). O sea,

$$\langle Qd^{k+1}, d^k \rangle = 0. \quad (7.110)$$

Definición 7.2. Un conjunto de vectores $d^0, \dots, d^k \in \mathbb{R}^n \setminus \{0\}$ se llama Q -conjugado si

$$\langle Qd^i, d^j \rangle = 0 \quad \forall i, j = 0, 1, \dots, k, \quad i \neq j. \quad (7.111)$$

Observamos que esta noción generaliza la noción de un conjunto de vectores ortogonales (que corresponde a $Q = E^n$).

Lema 7.6 (Direcciones conjugadas son linealmente independientes). Para cualquier matriz $Q \in \mathbb{R}^{n \times n}$ simétrica definida positiva, cualquier conjunto de direcciones Q -conjugadas es linealmente independiente.

Prueba. Supongamos que uno de los vectores $d^0, \dots, d^k$ del conjunto Q -conjugado pueda ser expresado como una combinación lineal de los otros, por ejemplo, el primero:

$$d^0 = \sum_{i=1}^k \beta_i d^i,$$

donde $\beta_i \in \mathbb{R}, i = 1, \dots, k$. Multiplicando los dos lados de esta ecuación por Qd^0 , y utilizando el hecho de que Q es definida positiva y $d^0 \neq 0$, obtenemos

$$0 < \langle Qd^0, d^0 \rangle = \sum_{i=1}^k \beta_i \langle Qd^0, d^i \rangle = 0,$$

lo que es una contradicción. ■

En particular, un conjunto de vectores Q -conjugados en $\mathbb{R}^n$ no puede contener más de n elementos.

El esquema general de métodos de direcciones conjugadas para funciones de la forma (7.106) es el siguiente:

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, 1, \dots, n-1, \quad (7.112)$$

donde $d^0, d^1, \dots, d^{n-1}$ es un conjunto (generado de una manera o de otra) de direcciones Q -conjugadas, y los valores de la longitud del paso α_k son calculados para satisfacer

$$f(x^k + \alpha_k d^k) = \min_{\alpha \in \mathbb{R}} f(x^k + \alpha d^k), \quad (7.113)$$

i.e.,

$$\alpha_k = -\frac{\langle 2Qx^k + q, d^k \rangle}{2\langle Qd^k, d^k \rangle}. \quad (7.114)$$

El mínimo en (7.113) es calculado sobre todos los $\alpha \in \mathbb{R}$ y no apenas sobre $\alpha \geq 0$. Esto se debe al hecho de que no siempre una dirección de descenso para f en el punto x^k es tal que sea una dirección de descenso en el sentido estricto. Más aún, es posible que ni siquiera d^k sea una dirección de descenso.

Métodos de direcciones conjugadas, en principio, no son métodos de descenso. La idea es diferente. La naturaleza de cada método de direcciones conjugadas específico es definida por la manera concreta de construir el conjunto de vectores Q -conjugados asociado. No obstante, cualquiera que sea esta construcción, vale el siguiente resultado fundamental: todo método de direcciones conjugadas encuentra la solución del problema de minimización irrestricta de una función cuadrática de la forma (7.106) con matriz Q definida positiva, en n iteraciones, a lo sumo.

Teorema 7.12 (Convergencia finita de métodos de direcciones conjugadas para funciones cuadráticas). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función cuadrática definida por (7.106), donde se tiene que $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, $q \in \mathbb{R}^n$. Entonces, para cualquier punto inicial $x^0 \in \mathbb{R}^n$, el punto x^n obtenido de acuerdo con el esquema (7.112), (7.113), con cualquier elección de conjunto Q -conjugado de vectores $d^0, d^1, \dots, d^{n-1}$, es la solución global del problema (7.105).

Prueba. Por el hecho de que Q es definida positiva, el problema (7.105) tiene un único punto estacionario $\bar{x} \in \mathbb{R}^n$, caracterizado por la ecuación

$$f'(\bar{x}) = 2Q\bar{x} + q = 0. \quad (7.115)$$

Por la convexidad de f , este punto es la solución global del problema. Pelo Lema 3.4.1, el conjunto de vectores $d^0, d^1, \dots, d^{n-1}$ forma una base de $\mathbb{R}^n$. Por lo tanto, podemos representar el vector $\bar{x} - x^0$ como

$$\bar{x} - x^0 = \sum_{k=0}^{n-1} \beta_k d^k, \quad (7.116)$$

para algunos $\beta_k \in \mathbb{R}, k = 0, 1, \dots, n-1$. Por otro lado, por (7.112), tenemos que

$$x^n = x^0 + \sum_{k=0}^{n-1} \alpha_k d^k, \quad (7.117)$$

donde los números α_k son definidos en (7.114). Ahora resta mostrar que $\beta_k = \alpha_k \forall k = 0, 1, \dots, n-1$. Usando (7.116) y el hecho de que $d^0, d^1, \dots, d^{n-1}$ es un conjunto de direcciones Q -conjugadas, para todo $k = 0, 1, \dots, n-1$, obtenemos que

$$\begin{aligned} \langle Q(\bar{x} - x^0), d^k \rangle &= \langle Q \left(\sum_{i=0}^{n-1} \beta_i d^i \right), d^k \rangle \\ &= \beta_k \langle Q d^k, d^k \rangle, \end{aligned}$$

donde sigue que

$$\beta_k = \frac{\langle Q(\bar{x} - x^0), d^k \rangle}{\langle Q d^k, d^k \rangle} = - \frac{\langle 2Qx^0 + q, d^k \rangle}{2\langle Q d^k, d^k \rangle}, \quad (7.118)$$

donde (7.115) fue llevado en cuenta. Usando de nuevo (7.112) y el hecho de que $d^0, d^1, \dots, d^{n-1}$ son Q -conjugadas, obtenemos

$$\begin{aligned} \langle Qx^k, d^k \rangle &= \langle Q \left(x^0 + \sum_{i=0}^{k-1} \alpha_i d^i \right), d^k \rangle \\ &= \langle Qx^0, d^k \rangle + \sum_{i=0}^{k-1} \alpha_i \langle Q d^i, d^k \rangle \\ &= \langle Qx^0, d^k \rangle. \end{aligned}$$

Combinando esta relación con (7.114) y (7.118), obtenemos el resultado anunciado. ■

La propiedad siguiente es mucho más reveladora. Acontece que cada iterando $x^k, k \geq 1$, generado de acuerdo con (7.112), (7.113), minimiza la función f en un conjunto afín de dimensión k . Es por eso que, para $k = n$, el punto x^n así generado minimiza f en $\mathbb{R}^n$. Observamos que, sorprendentemente, el cálculo de estos minimizadores es explícito, i.e., no hay necesidad de utilización de algún método iterativo para minimizar f en un conjunto de dimensión cada vez mayor.

Teorema 7.13. *Bajo las hipótesis del Teorema 3.4.1, para cualquier punto inicial $x^0 \in \mathbb{R}^n$, para todo $k = 0, \dots, n-1$, el punto x^{k+1} definido por el esquema (7.112), (7.113), donde $d^0, \dots, d^k$ es cualquier conjunto de direcciones Q -conjugadas, es una solución (global) del problema*

$$\min f(x) \quad \text{sujeto a } x \in D_k = x^0 + \text{span}\{d^0, \dots, d^k\}. \quad (7.119)$$

Prueba. Para todo $i = 0, \dots, k-1$, tenemos que

$$\begin{aligned} \langle f'(x^{k+1}), d^i \rangle &= \langle 2Qx^{k+1} + q, d^i \rangle \\ &= 2\langle Q \left(x^{i+1} + \sum_{j=i+1}^k \alpha_j d^j \right), d^i \rangle + \langle q, d^i \rangle \\ &= 2\langle x^{i+1}, Qd^i \rangle + \sum_{j=i+1}^k \alpha_j \langle Qd^j, d^i \rangle + \langle q, d^i \rangle \\ &= 2\langle x^{i+1}, Qd^i \rangle + \langle q, d^i \rangle \\ &= \langle f'(x^{i+1}), d^i \rangle, \end{aligned}$$

donde la cuarta igualdad sigue del hecho de que las direcciones en cuestión son Q -conjugadas. De (7.113), para todo i , tenemos que

$$0 = \langle f'(x^i + \alpha_i d^i), d^i \rangle = \langle f'(x^{i+1}), d^i \rangle. \quad (7.120)$$

Combinando las dos últimas relaciones, concluimos que

$$\langle f'(x^{k+1}), d^i \rangle = 0 \quad \forall i = 0, 1, \dots, k. \quad (7.121)$$

Para verificar la afirmación, tenemos que mostrar que el minimizador irrestricto de la función

$$\varphi: \mathbb{R}^{k+1} \rightarrow \mathbb{R}, \quad \varphi(\beta) = f(x^0 + \beta_0 d^0 + \dots + \beta_k d^k)$$

es el punto $(\alpha_0, \dots, \alpha_k) \in \mathbb{R}^{k+1}$. Mas esto se sigue del hecho de que

$$\frac{\partial \varphi}{\partial \beta_i}(\alpha_0, \dots, \alpha_k) = \langle f'(x^0 + \alpha_0 d^0 + \dots + \alpha_k d^k), d^i \rangle = \langle f'(x^{k+1}), d^i \rangle = 0,$$

para todo $i = 0, 1, \dots, k$, ya que, como fue probado arriba, estas derivadas se anulan en el punto considerado. ■

7.5.2. El método de los gradientes conjugados

Tal vez el más importante entre los métodos de direcciones conjugadas es el método de los gradientes conjugados. En este método,

$$d^0 = -f'(x^0), \quad d^k = -f'(x^k) + \beta_{k-1} d^{k-1}, \quad k = 1, \dots, n-1, \quad (7.122)$$

donde los números β_{k-1} son escogidos para hacer con que las dos direcciones seguidas d^{k-1} y d^k sean Q -conjugadas, i.e.,

$$0 = \langle Qd^{k-1}, d^k \rangle = -\langle Qd^{k-1}, f'(x^k) \rangle + \beta_{k-1} \langle Qd^{k-1}, d^{k-1} \rangle, \quad (7.123)$$

donde

$$\beta_{k-1} = \frac{\langle Qd^{k-1}, f'(x^k) \rangle}{\langle Qd^{k-1}, d^{k-1} \rangle}. \quad (7.124)$$

Algoritmo 7.8 (El método de los gradientes conjugados). Tomar $x^0 \in \mathbb{R}^n$ y $k := 0$.

1. Si $f'(x^k) = 0$, parar.
2. Si $k \geq 1$, calcular β_{k-1} por la fórmula (7.124).
3. Calcular d^k por la fórmula (7.122), y α_k por la fórmula (7.114).
4. Calcular x^{k+1} por la fórmula (7.112).
5. Si $k < n-1$, tomar $k := k+1$ y retornar al Paso 1.

En la fórmula (7.114), que define α_k , entendemos que $d^k \neq 0$ (e en la fórmula (7.124), que define β_{k-1} , entendemos que $d^{k-1} \neq 0$). Si $d^0 = -f'(x^0) = 0$, el método pararía antes del cálculo de d^0 y α_0 (y, obviamente, de β_0). Supongamos que para algún $k \geq 1$, por primera vez aconteció que $d^k = 0$ (en particular, $d^{k-1} \neq 0$). En este caso, por (7.122), obtenemos que

$$\begin{aligned} 0 &= \langle f'(x^k), d^k \rangle \\ &= -\|f'(x^k)\|^2 + \beta_{k-1} \langle f'(x^k), d^{k-1} \rangle \\ &= -\|f'(x^k)\|^2, \end{aligned}$$

donde la última igualdad sigue del hecho de que, por la definición de α_{k-1} , $\langle f'(x^k), d^{k-1} \rangle = 0$. Por lo tanto, $f'(x^k) = 0$, y el método pararía antes del cálculo de d^k y α_k (y, obviamente, de β_k). El resultado siguiente muestra que el método que acabamos de presentar es realmente un método de direcciones conjugadas.

Teorema 7.14. Sean satisfechas las hipótesis del Teorema 3.4.1. Para cualquier punto inicial $x^0 \in \mathbb{R}^n$, y todo $k = 1, \dots, n$, si el Algoritmo 3.4.1 generó vectores $d^0, d^1, \dots, d^{k-1}$, entonces ellos forman un conjunto Q -conjugado. Además, los gradientes $f'(x^0), f'(x^1), \dots, f'(x^{k-1})$ forman un conjunto de vectores ortogonales en $\mathbb{R}^n$.

Prueba. Primero notemos que, por lo expuesto arriba, si el método generó vectores $d^0, d^1, \dots, d^{k-1}$, entonces todos ellos son no nulos, así como los gradientes $f'(x^0), f'(x^1), \dots, f'(x^{k-1})$. La prueba será hecha por inducción en relación

a k . Para $k = 1$, la afirmación del teorema es obvia, porque el conjunto d^0, d^1 es Q -conjugado por la construcción, y los vectores $f'(x^0) = d^0$ y $f'(x^1)$ son ortogonales por (7.120).

Supongamos que la afirmación del teorema sea verdadera para $k = s \geq 2$. Precisamos mostrar que

$$\langle Qd^s, d^i \rangle = 0, \quad \langle f'(x^s), f'(x^i) \rangle = 0 \quad \forall i = 0, 1, \dots, s-1. \quad (7.125)$$

Por (7.122), por la hipótesis de inducción, y por el Teorema 3.4.2, tenemos que

$$\begin{aligned} \langle f'(x^s), f'(x^i) \rangle &= \langle f'(x^s), -d^i + \beta_{i-1}d^{i-1} \rangle \\ &= 0 \quad \forall i = 0, 1, \dots, s-1. \end{aligned}$$

Esto verifica la segunda igualdad en (7.125). Para $i = s-1$, la primera igualdad en (7.125) vale por la construcción.

Para todo $i = 0, 1, \dots, s-2$, por (7.122) y por la hipótesis de inducción, obtenemos

$$\begin{aligned} \langle Qd^s, d^i \rangle &= -\langle Qf'(x^s), d^i \rangle + \beta_{s-1}\langle Qd^{s-1}, d^i \rangle \\ &= -\langle Qf'(x^s), d^i \rangle. \end{aligned} \quad (7.126)$$

Como, por (7.112),

$$f'(x^{i+1}) - f'(x^i) = 2Q(x^{i+1} - x^i) = 2\alpha_i Qd^i,$$

obtenemos que

$$\langle Qf'(x^s), d^i \rangle = \frac{1}{2\alpha_i} \langle f'(x^s), f'(x^{i+1}) - f'(x^i) \rangle = 0, \quad (7.127)$$

donde utilizamos la segunda igualdad en (7.125), ya probada. En combinación con (7.126), esto concluye la prueba de la primera igualdad en (7.125). ■

Por los Teoremas 3.4.3 e 3.4.1, el método de gradientes conjugados encuentra la solución del problema de minimización irrestricta de una función cuadrática con matriz Q definida positiva, en n iteraciones. De hecho, con frecuencia, una aproximación suficientemente buena es encontrada bien más rápido, principalmente para problemas de gran porte (cuando n es grande). Por eso, los métodos de direcciones conjugadas son muy usados para minimización iterativa de funciones cuadráticas, incluso para resolución iterativa de sistemas de ecuaciones lineales.

A propósito, una manera de construir un conjunto de direcciones Q -conjugadas ya fue presentada arriba. Puede ser probado que los vectores $d^k = -Q_k f'(x^k)$, donde las matrices Q_k son generadas por el método DFP o por el método BFGS, forman un conjunto Q -conjugado. Una propiedad interesante del método DFP es la siguiente. Al mismo tiempo, él resuelve el problema de minimización y calcula la matriz Q^{-1} (lo que puede ser importante en algunas aplicaciones). Por otro lado, a implementación del método DFP requiere guardar en la memoria y actualizar, cada iteración, una matriz $Q_k \in \mathbb{R}^{n \times n}$, lo que puede ser caro cuando n es grande.

En el caso de una función no cuadrática, las fórmulas para el cálculo de β_{k-1} dadas arriba resultan, en general, en valores diferentes. Más aún, los vectores d^k así generados no forman un conjunto Q -conjugado para ninguna matriz Q . Naturalmente, convergencia finita no puede ser esperada. Pero aun así, hay razones para esperar convergencia rápida, debido al hecho de que, localmente, una función dos veces diferenciable es aproximada bien por una función cuadrática (dada por la parte cuadrática de su expansión de Taylor).

La experiencia computacional sugiere que la primera fórmula (la que actualiza β_{k-1} usando el cociente de las normas cuadradas de los gradientes) es en general mejor que la segunda (la cual involucra el producto interno de la diferencia de los gradientes). Las explicaciones pueden ser consultadas en la literatura. Resultados sobre convergencia y tasa de convergencia de varios métodos de gradientes conjugados pueden ser consultados en detalle. Curiosamente, estos resultados se refieren a la segunda fórmula, y no a la primera, a pesar de que la primera sea aquella utilizada en la práctica. De cierto modo, tal situación no es rara en el área de optimización computacional: a veces un método es justificado teóricamente para una escogencia de parámetros, pero la experiencia computacional indica ventajas de alguna escogencia diferente que, sin embargo, no posee justificación teórica completa. O papel del análisis matemático de métodos computacionales es importante, pero no debe ser exagerado ni menospreciado.

Resaltamos que, por las ecuaciones del método, $\langle f'(x^k), d^k \rangle = -\|f'(x^k)\|^2 < 0$, si $f'(x^k) \neq 0$. Por lo tanto, por el Lema de direcciones de descenso, $d^k \in \mathcal{D}_f(x^k)$. Por eso, podemos minimizar de forma irrestricta sobre la semirrecta $\alpha \geq 0$, admitir que $\alpha_k > 0$, y considerar al método de los gradientes conjugados como un método de descenso. En el caso no cuadrático, la minimización unidimensional exacta ya no es posible y tenemos que apelar a otras reglas de búsqueda lineal, por ejemplo la de Wolfe.

Para mejorar la convergencia global del método de los gradientes conjugados, es recomendable utilizar, de vez en cuando, pasos del método del gradiente. Por razones ya mencionadas, los métodos cuasi-Newton y los gradientes conjugados son los más adecuados para minimización irrestricta de funciones diferenciables.

7.6. Métodos que no utilizan derivadas

Esta sesión bien corta no contiene resultados de convergencia, porque los métodos que serán mencionados están fuera de los asuntos principales abordados en este libro y el análisis teórico de ellos es muy complicado. Por otro lado, la importancia práctica de métodos de orden cero no permite omitirlos completamente. Fue escogido entonces presentar un resumen breve, sin estudio teórico.

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dada. La implementación de métodos para el problema

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (7.128)$$

que fueron presentados hasta ahora, requiere el cálculo de (primeras o, aún, segundas) derivadas de f . En la práctica, a veces, este cálculo tiene costo computacional muy grande. En algunas aplicaciones, el cálculo puede ser hasta imposible en principio (por ejemplo, cuando no hay fórmulas explícitas para las derivadas de f). A veces, lo mejor que puede ser hecho es calcular apenas valores de f . Este es el caso, por ejemplo, cuando para un punto dado x , el valor $f(x)$ es obtenido por resolución de un otro problema que tiene a x como parámetro. En situaciones de este tipo, precisamos o hacer una aproximación de derivadas utilizando valores de la función, o desarrollar métodos completamente diferentes, que no utilizan derivadas (tales métodos son llamados de métodos de búsqueda directa).

Dificultades de otra naturaleza (mismo que con consecuencias parecidas) surgen en los casos en que la función objetivo sequer es diferenciable. En estos casos, los métodos presentados hasta ahora no pueden ser utilizados o, cuando pueden, a convergencia de ellos no puede ser garantizada. Algunos métodos para minimización de funciones no-diferenciables serán presentados más adelante. Cabe resaltar que la resolución de problemas no-diferenciables presenta desafíos serios y necesita herramientas diferentes a aquellas del caso diferenciable. La situación se complica aún más cuando el problema en consideración no posee alguna estructura especial y/o cuando él no es un problema de programación convexa. En estos casos, que serán desarrollados en capítulos posteriores, los métodos son bien menos eficaces.

En principio, todos los métodos de primera y segunda orden considerados arriba pueden ser implementados (de manera inexacta) sin utilización de derivadas, aproximándolas por esquemas de diferencias finitas. Por ejemplo, el gradiente de la función f en el punto $x^k \in \mathbb{R}^n$ puede ser aproximado por el esquema de diferencias hacia adelante separadas:

$$f'_{x_j}(x^k) \approx g_j^k = \frac{f(x^k + t_k e^j) - f(x^k)}{t_k}, \quad j = 1, \dots, n, \quad (7.129)$$

o aún, por el esquema de diferencias centradas:

$$f'_{x_j}(x^k) \approx g_j^k = \frac{f(x^k + t_k e^j) - f(x^k - t_k e^j)}{2t_k}, \quad j = 1, \dots, n, \quad (7.130)$$

donde $t_k > 0$ es un número pequeño y $\{e^1, \dots, e^n\}$ es la base canónica de $\mathbb{R}^n$. La aproximación por diferencias centradas es más precisa, mas ella requiere casi el doble de computaciones de valores de la función f .

El análogo del método del gradiente, con diferencias finitas, es dado por

$$x^{k+1} = x^k - \alpha_k g^k, \quad k = 0, 1, \dots, \quad (7.131)$$

donde vectores $g^k \in \mathbb{R}^n$ son calculados utilizando uno de los esquemas arriba, y los valores de la longitud del paso α_k son calculados por una de las reglas de búsqueda lineal en la dirección $-g^k$. No obstante, es importante mencionar que la prueba de convergencia de un método de este tipo difícilmente puede ser hecha sin la hipótesis de diferenciableidad de la función f , mismo que el método no utilice las derivadas.

Ejemplo 7.2. Para la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = \max\{|x_1|, |x_2|\},$$

el vector g^k , calculado por el esquema de diferencias hacia adelante separadas en el punto $x^k = (-1, -1)$, sería cero. Luego, el análogo del método del gradiente correspondiente no conseguiría salir del punto x^k , en cuanto el único minimizador local irrestricto de f es el cero (que también es el minimizador global).

Eso, por su parte, no es ninguna sorpresa: el método es basado en aproximación del método del gradiente; por lo tanto, la convergencia de él sólo puede ser esperada cuando el método “exacto” converge.

El método más natural que no utiliza el cálculo (exacto o aproximado) de derivadas es el método de descenso por coordenadas, dado por el esquema cíclico siguiente:

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, 1, \dots, \quad (7.132)$$

donde

$$d^0 = e^1, \dots, d^{n-1} = e^n, \quad d^n = e^1, \dots, \quad d^{2n-1} = e^n, \dots$$

Los valores de la longitud del paso α_k pueden ser calculados por la minimización unidimensional, i.e.,

$$f(x^k + \alpha_k d^k) = \min_{\alpha \in \mathbb{R}} f(x^k + \alpha d^k), \quad (7.133)$$

donde a minimización es sobre todos los $\alpha \in \mathbb{R}$, ya que d^k puede no ser una dirección de descenso de la función f en el punto x^k . Una iteración del método consiste entonces en la minimización unidimensional de la función f en relación a una coordenada, con otras coordenadas fijadas. Las variables de minimización son mudadas de manera cíclica.

En el método de descenso por coordenadas, pueden ser utilizadas también otras ideas para el cálculo de longitudes de paso. Por ejemplo, la siguiente. Fijemos parámetros $\hat{\alpha} > 0$ e $\theta \in (0, 1)$. Dados x^k y d^k , tomamos $\alpha = \hat{\alpha}$. Si

$$f(x^k + \alpha d^k) < f(x^k),$$

aceptamos $\alpha_k = \alpha$. Caso contrario, si

$$f(x^k - \alpha d^k) < f(x^k),$$

aceptamos $\alpha_k = -\alpha$. Si ninguna de las dos desigualdades se satisface, o definimos $\alpha_k = 0$ (es claro que esto solo se puede hacer en algún sentido de número de iteraciones seguidas menor que n), o trocamos α por $\theta\alpha$ y tentamos de nuevo. Es interesante notar que, de nuevo, mismo que el método no tenga ninguna relación aparente con derivadas, garantizar su comportamiento razonable solo es posible para funciones diferenciables. Además de eso, sin convexidad, no es posible probar convergencia global del método de descenso por coordenadas: puntos de acumulación de la secuencia generada pueden no ser puntos estacionarios del problema. El método de descenso por coordenadas puede ser extendido fácilmente al problema de optimización con restricciones de caja.

En el método de descenso por coordenadas aleatorio, la dirección d^k es definida por un vector de la base canónica e^j , donde el índice j viene dado por la realización de algún proceso estocástico, con probabilidades iguales para los valores $1, \dots, n$. En el método de búsqueda aleatoria, la dirección d^k viene dada por la realización de algún proceso estocástico, con probabilidades iguales para los vectores en la esfera unitaria del espacio $\mathbb{R}^n$. Los valores de la longitud del paso son calculados utilizando una regla de búsqueda lineal para garantizar, por lo menos, que la secuencia $\{f(x^k)\}$ sea no-creciente (en particular, cuando d^k no es una dirección de descenso, el longitud de paso es cero). Resultados teóricos para métodos de este tipo afirman, típicamente, la convergencia de la secuencia $\{f'(x^k)\}$ a cero con probabilidad 1.

Finalmente, comentaremos sobre el caso en que la función f es no-diferenciable. En esta situación, el hecho siguiente es crucial: si una función es Lipschitz-continua en una vecindad de cada punto de $\mathbb{R}^n$, entonces ella es diferenciable en casi todo punto de $\mathbb{R}^n$ (en el sentido de que el conjunto de puntos de no-diferenciabilidad tiene medida nula). Por eso, podemos esperar que f sea diferenciable en un punto $\tilde{x}^k$ escogido de manera aleatoria (por ejemplo, en una caja de tamaño $\delta_k > 0$ en torno de un punto dado x^k). Este raciocinio sugiere el método de diferencias finitas estocásticas, dado por el esquema de diferencias, donde $t_k > 0$. Haciendo una coordinación inteligente de los parámetros α_k, δ_k y t_k , es posible probar la convergencia de este método al conjunto de puntos estacionarios del problema con probabilidad 1 (mas es claro que la propia noción de un punto estacionario tiene que ser repensada, debido a la no-diferenciabilidad de la función objetivo).

Ejercicios del Capítulo

Sección I: Métodos de Descenso y Gradiente

Ejercicio 7.1. Probar los siguientes hechos, que pueden ser pensados como caracterizaciones adicionales de direcciones de descenso. Si la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es dos veces diferenciable en el punto $x \in \mathbb{R}^n$, entonces:

- (a) Para todo $d \in \mathcal{D}_f(x)$ tal que $\langle f'(x), d \rangle = 0$, se tiene que $\langle f''(x)d, d \rangle \leq 0$.
- (b) Si $d \in \mathbb{R}^n$ satisface $\langle f'(x), d \rangle = 0$ y $\langle f''(x)d, d \rangle < 0$, se tiene que $d \in \mathcal{D}_f(x)$.

Ejercicio 7.2. Suponiendo que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea continuamente diferenciable en el punto x^k y que $d^k \in \mathcal{D}_f(x^k)$, probar que la modificación de la regla de Armijo donde la desigualdad clásica es sustituida por

$$f(x^k + \alpha d^k) \leq f(x^k) + \sigma \alpha^2 \langle f'(x^k), d^k \rangle, \quad \sigma > 0,$$

está bien definida (i.e., que existe $\bar{\alpha}_k > 0$ tal que la condición arriba vale para todo $\alpha \in [0, \bar{\alpha}_k]$). Hacer un dibujo geométrico para ilustrar esta regla de búsqueda lineal.

Ejercicio 7.3. Bajo las mismas hipótesis probar que la implementación de la regla de Goldstein, análoga a aquella presentada para la regla de Wolfe, está bien definida.

Ejercicio 7.4. Probar afirmaciones análogas a aquellas del Teorema de Convergencia Global II para el método del gradiente con búsqueda lineal de Goldstein y con búsqueda lineal de Wolfe.

Ejercicio 7.5. Suponiendo las hipótesis del Teorema de Convergencia Global II y que el conjunto de nivel $\mathcal{L}(f(x^0))$ sea acotado, probar que

$$\text{dist}(x^k, S_0) \rightarrow 0 \quad (k \rightarrow \infty),$$

donde $S_0 = S_0(x^0) = \{x \in \mathcal{L}(f(x^0)) \mid f'(x) = 0\}$.

Ejercicio 7.6. Considerar el esquema iterativo dado por $x^{k+1} = x^k + \alpha_k d^k$, $k = 0, 1, \dots$, donde

$$c_1 \|f'(x^k)\|^{p_1} \leq -\langle f'(x^k), d^k \rangle, \quad \|d^k\| \leq c_2 \|f'(x^k)\|^{p_2},$$

$c_1, c_2 > 0$, $p_1, p_2 \geq 0$, y la longitud de paso α_k es calculada por la regla de minimización unidimensional o por la regla de Armijo. Suponiendo que la función f sea continuamente diferenciable, probar que todo punto de acumulación de la secuencia $\{x^k\}$ es un punto estacionario del problema.

Ejercicio 7.7. Probar los ítems (b)-(d) del Teorema de Convergencia local del método del gradiente I.

Ejercicio 7.8. Probar que en el Teorema de Convergencia local del método del gradiente I, la hipótesis de diferenciabilidad de la función f en todo $\mathbb{R}^n$, así como la hipótesis de continuidad de Lipschitz de la derivada de f en $\mathbb{R}^n$, pueden ser relajadas, suponiendo estas propiedades en una vecindad del punto $\bar{x}$.

Ejercicio 7.9. Probar el siguiente resultado sobre crecimiento subcuadrático: Si $S = S_0$, la función f es suficientemente suave y vale $\|f'(x)\| \geq \gamma \text{dist}(x, S_0) \quad \forall x \in U$, entonces existe $\gamma > 0$ tal que

$$f(x) - \bar{v} \geq \gamma (\text{dist}(x, S_0))^2 \quad \forall x \in U.$$

Ejercicio 7.10. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$. Suponiendo que f asuma en el conjunto de sus puntos estacionarios un número finito de valores diferentes, mostrar que la condición de separación de superficies de nivel críticas es satisfecha.

Ejercicio 7.11. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función cuadrática que posee un punto estacionario. Mostrar que la propiedad de cota a la distancia estacionaria $\|f'(x)\| \geq \gamma \text{dist}(x, S_0)$ es satisfecha (con $U = \mathbb{R}^n$ y algún $\gamma > 0$). Mostrar que la condición de separación de superficies de nivel críticas también es satisfecha (trivialmente).

Ejercicio 7.12. Tomando $x^0 = (-2, 1)$, hacer dos iteraciones del método de máximo descenso (minimización unidimensional exacta) para la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + x_1 x_2 + 2x_2^2 + x_1.$$

Ejercicio 7.13. Tomando $x^0 = (1, -1)$, hacer una iteración del método de gradiente para la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = 2x_1^2 + x_1 x_2 + 3x_2^2,$$

utilizando la regla de Armijo, con parámetros siendo $\hat{\alpha} = 1$ y $\sigma = \theta = 1/2$.

Ejercicio 7.14. Sea $\{x^k\}$ una secuencia generada por $x^{k+1} = x^k + \alpha_k d^k$, $k = 0, 1, \dots$, donde

$$c_1 \|f'(x^k)\|^2 \leq -\langle f'(x^k), d^k \rangle, \quad \|d^k\| \leq c_2 \|f'(x^k)\|,$$

$c_1, c_2 > 0$, y la secuencia $\{\alpha_k\} \subset \mathbb{R}_+$ satisface $\lim_{k \rightarrow \infty} \alpha_k = 0$, $\sum_{k=0}^{\infty} \alpha_k = +\infty$. Sea f acotada inferiormente y sea la derivada de f Lipschitz-continua en $\mathbb{R}^n$. Probar que la secuencia $\{f(x^k)\}$ converge y que $\liminf_{k \rightarrow \infty} \|f'(x^k)\| = 0$. Más aún, si los conjuntos de nivel $\{x \in \mathbb{R}^n \mid f(x) \leq c\}$ son acotados para todo $c \in \mathbb{R}$, entonces la secuencia $\{x^k\}$ es acotada y todo punto de acumulación es un punto estacionario del problema.

Ejercicio 7.15. Sea $\{x^k\}$ una secuencia generada por $x^{k+1} = x^k + \alpha_k d^k$, donde α_k es calculado por la regla de Armijo,

$$d^k = -(0, \dots, 0, f'_{x_i}(x^k), 0, \dots, 0),$$

y el índice $i \in \{1, \dots, n\}$ satisface $|f'_{x_i}(x^k)| = \max_{j=1, \dots, n} |f'_{x_j}(x^k)|$. Suponiendo que la función f es continuamente diferenciable, probar que todo punto de acumulación de $\{x^k\}$ es punto estacionario del problema.

Ejercicio 7.16. Sea f una función continuamente diferenciable. Supongamos que, dado un punto $x^k \in \mathbb{R}^n$, la dirección $d^k \in \mathbb{R}^n$ sea escogida de manera que garantiza que cuando una subsecuencia $\{x^{k_i}\}$ converge a un punto no-estacionario del problema, entonces $\liminf_{i \rightarrow \infty} \langle f'(x^{k_i}), d^{k_i} \rangle < 0$. Sea $\{x^k\}$ una secuencia generada por el método iterativo general, donde α_k es calculado por la regla de Armijo. Probar que todo punto de acumulación de $\{x^k\}$ es punto estacionario.

Ejercicio 7.17. Sea $\{x^k\}$ una secuencia generada por $x^{k+1} = x^k + \alpha_k d^k$, donde

$$d^k = -f'(x^k) + \varepsilon^k, \quad \|\varepsilon^k\| \leq \delta \quad \forall k.$$

Supongamos que la secuencia $\{x^k\}$ sea acotada. Probar que para todo $c > \delta$, existen $c_1 \geq c_2 > 0$ tales que si $\alpha_k \in [c_1, c_2]$, entonces la secuencia $\{x^k\}$ posee un punto de acumulación que pertenece al conjunto $\{x \in \mathbb{R}^n \mid \|f'(x)\| \leq c\}$.

Sección II: Método de Newton y Cuasi-Newton

Ejercicio 7.18. Probar analíticamente el Corolario de Convergencia local de Newton Inexacto (Corolario 3.2.1 original).

Ejercicio 7.19. Bajo las hipótesis del Teorema de Newton local para ecuaciones, probar que una secuencia $\{x^k\}$ que satisface la condición de los métodos de Newton truncados:

$$\|\Phi(x^k) + \Phi'(x^k)(x^{k+1} - x^k)\| \leq \sigma_k \|\Phi(x^k)\|,$$

donde $\sigma_k \rightarrow 0$ ($k \rightarrow \infty$), converge a $\bar{x}$ con tasa superlineal.

Ejercicio 7.20. Probar que bajo las condiciones del Teorema de Newton local, el método de Newton que usa una única evaluación del Jacobiano en el punto de arranque:

$$x^{k+1} = x^k - (\Phi'(x^0))^{-1} \Phi(x^k), \quad k = 0, 1, \dots$$

converge localmente a $\bar{x}$ con tasa lineal. Además, la tasa de convergencia lineal se hace más rápida a medida que x^0 es tomado más próximo a $\bar{x}$.

Ejercicio 7.21. A partir del punto $x^0 = 1$, hacer dos iteraciones del método de Newton para la ecuación $x^p = 0$, donde $p \geq 2$ es un parámetro entero. Analizar la tasa de convergencia y explicar el fenómeno observado. Modificar el método de Newton introduciendo un longitud de paso igual a p y analizar la tasa de convergencia de nuevo.

Ejercicio 7.22. Probar la siguiente afirmación. Sea la función $\Phi: \mathbb{R} \rightarrow \mathbb{R}$ diferenciable p veces en el punto $\bar{x} \in \mathbb{R}$, $p \geq 2$, donde $\bar{x}$ es una raíz de orden p de la ecuación $\Phi(x) = 0$, i.e.,

$$\Phi(\bar{x}) = \Phi'(\bar{x}) = \dots = \Phi^{(p-1)}(\bar{x}) = 0, \quad \Phi^{(p)}(\bar{x}) \neq 0.$$

Entonces el método de Newton converge localmente a $\bar{x}$ con tasa lineal, y si introducimos un longitud de paso igual a p , la tasa de convergencia se torna superlineal.

Ejercicio 7.23. Probar que el método de Newton es invariante en relación a las transformaciones lineales de variables, en el sentido siguiente. Sea $x = Ay$ una transformación de variables, dada por una matriz no singular $A \in \mathbb{R}^{n \times n}$. Entonces, si el método de Newton en variables y genera una secuencia $\{y^k\}$ y en variables x genera una secuencia $\{x^k\}$, se tiene que $y^k = A^{-1}x^k$.

Ejercicio 7.24. Hacer dos iteraciones del método de Newton a partir del punto $x^0 = (1, 1)$ para el problema de minimización irrestricta de la función $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, $f(x) = x_1^2 + e^{x_2^2}$. Analizar la tasa de convergencia. Mostrar que, en este caso, el método de Newton posee convergencia global.

Ejercicio 7.25. Considerar el método de Newton para minimizar la función $f: \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = x^2 + \cos x$. Mostrar que la solución $\bar{x} = 0$ satisface todas las hipótesis del Corolario de convergencia local en optimización, y que, si $x^0 = 2\pi i$ donde $i \in \{1, 2, \dots\}$ (notemos que tal x^0 no es próximo de $\bar{x}$), la secuencia generada por el método de Newton no converge.

Ejercicio 7.26. Aplicar el método de Newton para minimizar la función $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $f(x) = \|x\|^3$. Analizar la tasa de convergencia y explicar lo observado.

Ejercicio 7.27. Mostrar que si valen las hipótesis del Teorema de Dennis-Moré, la condición asintótica sublineal de Dennis-Moré es equivalente a:

$$(Q_k^{-1} - f''(\bar{x}))Q_k f'(x^k) = o(\|Q_k f'(x^k)\|).$$

Ejercicio 7.28. Para el caso de utilización de la regla de búsqueda lineal de Goldstein con el valor inicial del longitud de paso $\alpha = 1$, probar afirmaciones análogas a las del Teorema de Dennis-Moré.

Ejercicio 7.29. Mostrar que los métodos DFP y BFGS tienen una relación de "dualidad" en el sentido siguiente. Para una matriz simétrica definida positiva $Q_k \in \mathbb{R}^{n \times n}$, definimos $H_k = Q_k^{-1}$. Sea la matriz Q_{k+1} generada por la fórmula BFGS. Mostrar que la correspondiente matriz inversa $H_{k+1} = Q_{k+1}^{-1}$ viene dada por

$$H_{k+1} = H_k + \frac{s^k (s^k)^\top}{\langle r^k, s^k \rangle} - \frac{(H_k r^k)(H_k r^k)^\top}{\langle H_k r^k, r^k \rangle}$$

(comparar con la actualización directa de DFP), suponiendo que H_{k+1} sea no-singular y $H_{k+1} = Q_{k+1}^{-1}$. Utilizar este hecho para probar, para BFGS, el resultado análogo al de la Proposición de Mantenimiento de la matriz definida positiva que se demostró para DFP.

Sección III: Estrategias de Globalización

Ejercicio 7.30. Sea $f: \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces continuamente diferenciable. Considerar el siguiente algoritmo. Sean $\sigma \in (0, 1/2)$, $\theta \in (0, 1)$ parámetros escogidos. Si $f''(x^k)$ es no singular, tomar $d^k = -(f''(x^k))^{-1} f'(x^k)$; sino, tomar $d^k = 0$. Tomar $h^k = -f'(x^k)$. Computar

$$x^{k+1} = x^k + \alpha_k((1 - \alpha_k)h^k + \alpha_k d^k),$$

donde α_k es el mayor entre todos los números de forma θ^s , $s \in \mathbb{N}$, satisfaciendo

$$f(x^k + \theta^s((1 - \theta^s)h^k + \theta^s d^k)) \leq f(x^k) - \sigma \theta^s \langle f'(x^k), (1 - \theta^s)h^k + \theta^s d^k \rangle.$$

Probar que el método está bien definido (en particular, la regla de cálculo del longitud de paso está bien definida). Probar que todo punto de acumulación de una secuencia $\{x^k\}$ así generada, es un punto estacionario del problema original. Probar que si $\{x^k\}$ converge a un punto estacionario $\bar{x}$ donde $f''(\bar{x})$ es definida positiva, entonces la tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal.

Ejercicio 7.31. Sean dados un vector $q \in \mathbb{R}^n$, una matriz simétrica $Q \in \mathbb{R}^{n \times n}$, y un número $\delta > 0$. Probar que si $\tilde{x} \in \mathbb{R}^n$ es una solución global del problema

$$\min \langle Qx, x \rangle + \langle q, x \rangle \quad \text{sujeto a } x \in B(0, \delta),$$

entonces existe un único número $\mu \geq 0$ tal que

$$2(Q + \mu E^n)\tilde{x} + q = 0, \quad \mu(\|\tilde{x}\| - \delta) = 0,$$

donde la matriz $Q + \mu E^n$ es semidefinida positiva. Si la matriz Q es definida positiva, entonces

$$\tilde{x} = \begin{cases} -Q^{-1}q/2, & \text{si } \|Q^{-1}q\|/2 \leq \delta, \\ -(Q + \mu E^n)^{-1}q/2, & \text{si no,} \end{cases}$$

donde $\mu \geq 0$ está unívocamente definido por la ecuación $\|(Q + \mu E^n)^{-1}q\|/2 = \delta$.

Ejercicio 7.32. En la notación del ejercicio anterior, sean $\tilde{x} \in \mathbb{R}^n$ y $\mu \in \mathbb{R}$ tales que $2(Q + \mu E^n)\tilde{x} + q = 0$ y la matriz $Q + \mu E^n$ es semidefinida positiva. Probar las siguientes afirmaciones:

- (a) Si $\|\tilde{x}\| \leq \delta$ y $\mu = 0$, entonces $\tilde{x}$ es una solución global del problema.
- (b) Si $\|\tilde{x}\| = \delta$, entonces $\tilde{x}$ es una solución global del problema límite sobre la esfera $x \in \{x \in \mathbb{R}^n \mid \|x\| = \delta\}$.
- (c) Si $\|\tilde{x}\| = \delta$ y $\mu \geq 0$, entonces $\tilde{x}$ es una solución global del problema de la región de confianza interior.

Ejercicio 7.33. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces diferenciable en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con la segunda derivada continua en este punto. Sea $\bar{x}$ un punto estacionario del problema que satisface la condición suficiente de segunda orden. Probar que si $x^k \in \mathbb{R}^n \setminus \{\bar{x}\}$ es suficientemente próximo de $\bar{x}$, entonces para el iterado siguiente generado por el Algoritmo de regiones de confianza vale $x^{k+1} = x^k - (f''(x^k))^{-1} f'(x^k)$.

Ejercicio 7.34. Sea $\varphi : [0, 1] \times \mathbb{R}^n \rightarrow \mathbb{R}$ una función con las siguientes propiedades: existe un conjunto compacto $D \subset \mathbb{R}^n$ tal que φ es continua en $[0, 1] \times D$ y para todo $t \in [0, 1]$ el problema $\min \varphi(t, x)$ sujeto a $x \in D$ posee una única solución global $\chi(t)$. Probar que la función de soluciones $\chi : [0, 1] \rightarrow \mathbb{R}^n$ es continua en $[0, 1]$.

Sección IV: Direcciones Conjugadas

Ejercicio 7.35. Mostrar que la fórmula analítica original de actualización $\beta_{k-1} = \frac{\langle Qd^{k-1}, f'(x^k) \rangle}{\langle Qd^{k-1}, d^{k-1} \rangle}$ puede ser escrita de la siguiente manera:

$$\beta_{k-1} = \frac{\langle f'(x^k), f'(x^k) - f'(x^{k-1}) \rangle}{\|f'(x^{k-1})\|^2}.$$

Ejercicio 7.36. Supongamos que para los puntos $x^k \in \mathbb{R}^n$ y $x^{k+1} \in \mathbb{R}^n$ y los vectores $d^{k-1} \in \mathbb{R}^n$ y $d^k \in \mathbb{R}^n$ generados por el método de los gradientes conjugados para algún $k \geq 1$, se tiene que $\langle f'(x^k), d^{k-1} \rangle = 0$ y $\langle f'(x^{k+1}), d^k \rangle = 0$. Mostrar que la dirección d^{k+1} , calculada de acuerdo con la segunda fórmula de gradientes conjugados, puede ser representada por $d^{k+1} = -Q_{k+1}f'(x^{k+1})$, donde Q_{k+1} viene dada por la actualización BFGS con $Q_k = E^n$.

Ejercicio 7.37. Utilizando el método de los gradientes conjugados, con punto inicial $x^0 = (1, 1)$, encontrar el minimizador irrestricto de la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + 2x_2^2.$$

Ejercicio 7.38. Sea $Q \in \mathbb{R}^{n \times n}$ dada por

$$Q = A + \sum_{i=1}^m y^i (y^i)^\top,$$

donde $A \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva y $y^i \in \mathbb{R}^n$, $i = 1, \dots, m$, son vectores arbitrarios. Mostrar que el iterando x^{k+1} generado por el método de gradientes conjugados satisface la relación

$$f(x^{k+1}) \leq \left(\frac{c_n - c_1}{c_n + c_1} \right)^2 f(x^0),$$

donde c_n y c_1 son el mayor y el menor autovalores de la matriz A , respectivamente.

Ejercicio 7.39. Para el método de gradientes conjugados aplicado a la función $f(x) = \langle Qx, x \rangle + \langle q, x \rangle$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, probar que el iterando x^k minimiza f en el subespacio de Krylov trasladado:

$$x^0 + \text{span}\{f'(x^0), Qf'(x^0), \dots, Q^{k-1}f'(x^0)\}.$$

Sección V: Métodos sin Derivadas

Ejercicio 7.40. A partir del punto inicial $x^0 = 0$, hacer dos pasos del método de descenso por coordenadas para minimizar la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + 2x_1x_2 + 3x_2^2 + 4x_1,$$

calculando la longitud de paso por la regla de minimización unidimensional exacta.

Ejercicio 7.41. Hacer lo mismo para la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = 2x_1^2 - x_1x_2 + x_2^2,$$

a partir del punto de arranque $x^0 = (2, 0)$.

8. Métodos para Optimización con Restricción

Este capítulo constituye la parte principal del libro. De cierto modo, el material de los otros capítulos es preparatorio, auxiliar o adicional en relación a métodos para la resolución de problemas de optimización con restricciones.

8.1. Métodos para conjuntos factibles de estructura simple

Comenzaremos el desarrollo de métodos para problemas de optimización con restricciones en el caso en que el conjunto factible tenga descripción abstracta:

$$\min f(x) \quad \text{sujeto a } x \in D, \quad (8.1)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función diferenciable y $D \subset \mathbb{R}^n$. Por razones de aplicación práctica, entendemos que el conjunto D posee una estructura simple (por lo menos, D es convexo y cerrado).

Con frecuencia, problemas con restricciones simples aparecen como subproblemas en métodos para la resolución de problemas con restricciones más complejas. Notamos que cuando el conjunto D es convexo y cerrado, para todo punto $x \in \mathbb{R}^n$ existe una proyección $P_D(x)$ de x sobre D que es única (vea el Teorema 1.3.1). Recordamos también que el punto $\bar{x} \in D$ es un punto estacionario del problema (8.1) cuando

$$\langle f'(\bar{x}), x - \bar{x} \rangle \geq 0 \quad \forall x \in D, \quad (8.2)$$

o, equivalentemente,

$$P_D(\bar{x} - \alpha f'(\bar{x})) = \bar{x} \quad (8.3)$$

para algún $\alpha > 0$ (vea el Teorema 1.3.7). Más aún, la validez de (8.3) para algún $\alpha > 0$ implica la validez de esta relación para todo $\alpha > 0$.

8.1.1. Métodos del gradiente proyectado

Los métodos del gradiente proyectado pueden ser pensados como una combinación natural de métodos del gradiente para optimización irrestricta con proyección de iteraciones así obtenidas en el conjunto factible del problema. Esto resulta en el esquema siguiente:

$$x^{k+1} = P_D(x^k - \alpha_k f'(x^k)), \quad k = 0, 1, \dots, \quad (8.4)$$

donde $x^0 \in D$, y los parámetros de longitud de paso $\alpha_k > 0$ son calculados utilizando extensiones de técnicas de búsqueda lineal de § 3.1.1 para el caso con restricciones. En particular, el valor de longitud de paso es calculado para obtener decrecimiento de la función

$$\varphi_k : \mathbb{R}_+ \rightarrow \mathbb{R}, \quad \varphi_k(\alpha) = f(x^k(\alpha)),$$

donde

$$x^k(\alpha) = P_D(x^k - \alpha f'(x^k)) \quad (8.5)$$

es el arco de proyección (vea Figura 4.1.1).

Por ejemplo, en el caso de la minimización unidimensional, α_k es una solución del problema

$$\min \varphi_k(\alpha) \quad \text{sujeto a } \alpha \in \mathbb{R}_+,$$

o del problema

$$\min \varphi_k(\alpha) \quad \text{sujeto a} \quad \alpha \in [0, \hat{\alpha}],$$

donde $\hat{\alpha} > 0$ es un parámetro. Sin embargo, como en el caso irrestricto, las reglas de minimización unidimensional no son muy atractivas desde el punto de vista práctico.

Más interesantes son las extensiones de la regla de Armijo. Esto puede ser hecho, por ejemplo, por el mismo esquema que fue considerado en § 3.1.1, sustituyendo la condición (3.6) por

$$f(x^k(\alpha)) \leq f(x^k) + \sigma \langle f'(x^k), x^k(\alpha) - x^k \rangle. \quad (8.6)$$

Recordamos que, para comenzar el proceso, deben ser elegidos un parámetro $\sigma \in (0, 1)$, el valor inicial de la longitud de paso $\hat{\alpha} > 0$ y el parámetro de reducción del paso $\theta \in (0, 1)$. En particular, α_k es calculado como el mayor entre todos los números de la forma $\alpha = \hat{\alpha}\theta^s$, $s \in \mathbb{N}$, satisfaciendo la desigualdad (8.6). Como es fácil ver, en el caso cuando $D = \mathbb{R}^n$, la desigualdad (8.6) se reduce a la condición de Armijo (3.6) en el caso irrestricto.

Existen también varias modificaciones de la regla de Armijo (por ejemplo, similares a la regla de Goldstein). Podríamos considerar también la regla de longitud de paso fijo, donde $\alpha_k = \bar{\alpha}$ para todo k , con $\bar{\alpha} > 0$ fijo.

Algoritmo 8.1 (Método del gradiente proyectado). Elegir $x^0 \in D$ y tomar $k := 0$. Elegir una de las tres reglas de cálculo de longitud de paso a ser utilizada, y los parámetros asociados: $\hat{\alpha} > 0$ (o $\hat{\alpha} = +\infty$) en el caso de minimización unidimensional, $\hat{\alpha} > 0$, $\sigma, \theta \in (0, 1)$ en el caso de la regla de Armijo, $\bar{\alpha} > 0$ en el caso de longitud de paso fijo.

1. Calcular α_k de acuerdo con la regla elegida.
2. Calcular x^{k+1} utilizando la fórmula (8.4).
3. Tomar $k := k + 1$ y retornar al Paso 1.

El Algoritmo 4.1.1 está ilustrado en la Figura 4.1.1.

Observamos que si para algún k el punto x^k es estacionario para el problema (8.1), entonces el método genera $x^k = x^{k+1} = \dots$, cualquiera que sea la longitud de paso α_k . Notamos también que para $D = \mathbb{R}^n$, un método del gradiente proyectado se reduce al método del gradiente (irrestricto) correspondiente. Las propiedades de convergencia de métodos del gradiente proyectado son muy parecidas a las propiedades de métodos del gradiente. A continuación, presentaremos dos resultados que son generalizaciones de los Teoremas 3.1.1 y 3.1.5, respectivamente.

En el análisis a seguir, la siguiente desigualdad tiene un papel importante:

$$\langle f'(x^k), x^k(\alpha) - x^k \rangle \leq -\frac{1}{\alpha} \|x^k(\alpha) - x^k\|^2 \quad \forall \alpha > 0. \quad (8.7)$$

Para probar esta desigualdad, notamos que para todo $\alpha > 0$,

$$\begin{aligned} \langle f'(x^k), x^k(\alpha) - x^k \rangle &= \frac{1}{\alpha} \langle x^k + \alpha f'(x^k) - x^k, x^k(\alpha) - x^k \rangle \\ &= \frac{1}{\alpha} \langle x^k - x^k(\alpha), x^k(\alpha) - x^k \rangle + \frac{1}{\alpha} \langle x^k(\alpha) - (x^k - \alpha f'(x^k)), x^k(\alpha) - x^k \rangle \\ &\leq -\frac{1}{\alpha} \|x^k(\alpha) - x^k\|^2, \end{aligned}$$

donde el Teorema 1.3.1 fue utilizado.

Lema 8.1. Sean $D \subset \mathbb{R}^n$ un conjunto cerrado y convexo, y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$.

Entonces para cualquier $x^k \in \mathbb{R}^n$ la desigualdad (8.6) es satisfecha para todo $\alpha \in (0, \bar{\alpha}]$, donde

$$\bar{\alpha} = 2(1 - \sigma)/L > 0. \quad (8.8)$$

Prueba. Utilizando el Lema 1.5.4 y las desigualdades (8.7) y (8.8), para todo $\alpha \in (0, \bar{\alpha}]$ obtenemos que

$$\begin{aligned} f(x^k(\alpha)) - f(x^k) &\leq \langle f'(x^k), x^k(\alpha) - x^k \rangle + \frac{L}{2} \|x^k(\alpha) - x^k\|^2 \\ &\leq \sigma \langle f'(x^k), x^k(\alpha) - x^k \rangle + \left(\frac{L}{2} - \frac{1 - \sigma}{\alpha} \right) \|x^k(\alpha) - x^k\|^2 \\ &\leq \sigma \langle f'(x^k), x^k(\alpha) - x^k \rangle, \end{aligned}$$

lo que es justamente el resultado anunciado. ■

El resultado del Lema 4.1.1 implica en que, bajo las hipótesis correspondientes, los valores de longitud de paso calculados por la regla de Armijo son limitados inferiormente por un número que no depende de k , i.e.,

$$\alpha_k \geq \check{\alpha} > 0 \quad \forall k. \quad (8.9)$$

Observamos también que la utilización de longitud de paso fijo, suponiendo que

$$\bar{\alpha} < 2/L, \quad (8.10)$$

es equivalente a la regla de Armijo con $\hat{\alpha} = \bar{\alpha}$ y $\sigma > 0$ suficientemente pequeño. Por lo tanto, este caso no requiere análisis separado.

Teorema 8.1 (Convergencia del método del gradiente proyectado). Sean $D \subset \mathbb{R}^n$ un conjunto cerrado y convexo, $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$.

Entonces cada punto de acumulación de cualquier secuencia $\{x^k\}$ generada por el Algoritmo 4.1.1 es un punto estacionario del problema (8.1). Si un punto de acumulación existe, o si la función f es limitada inferiormente en D , entonces para cualquier secuencia limitada $\{t_k\} \subset \mathbb{R}_+$ se tiene que

$$\|x^k - P_D(x^k - t_k f'(x^k))\| \rightarrow 0 \quad (k \rightarrow \infty). \quad (8.11)$$

Prueba. Consideremos el caso de la regla de Armijo. Por (8.7), para todo k tenemos que

$$\begin{aligned} f(x^k) - f(x^{k+1}) &\geq -\sigma \langle f'(x^k), x^{k+1} - x^k \rangle \\ &\geq \frac{\sigma}{\alpha_k} \|x^{k+1} - x^k\|^2 \\ &\geq \frac{\sigma}{\check{\alpha}} \|x^{k+1} - x^k\|^2. \end{aligned} \quad (8.12)$$

Si x^k no es un punto estacionario del problema (8.1), se tiene que

$$\|x^{k+1} - x^k\| = \|P_D(x^k - \alpha_k f'(x^k)) - x^k\| > 0,$$

porque $\alpha_k > 0$. Por eso, de (8.12) obtenemos que la secuencia $\{f(x^k)\}$ es decreciente. Supongamos que la secuencia $\{x^k\}$ posea un punto de acumulación $\bar{x} \in \mathbb{R}^n$. En este caso, por el hecho de que la secuencia $\{f(x^k)\}$ es decreciente, obtenemos que ella es limitada inferiormente (por $f(\bar{x})$), y por lo tanto converge (cuando la función f es limitada inferiormente en $\mathbb{R}^n$, esto vale aun cuando $\{x^k\}$ no tiene puntos de acumulación). Concluimos que

$$f(x^k) - f(x^{k+1}) \rightarrow 0 \quad (k \rightarrow \infty),$$

y, de (8.12), obtenemos que

$$\|x^{k+1} - x^k\| \rightarrow 0 \quad (k \rightarrow \infty). \quad (8.13)$$

Sea la secuencia $\{t_k\} \subset \mathbb{R}_+$ limitada superiormente por un número $\hat{t}$. Por el Teorema 1.3.1, utilizando también (8.9) y (8.13), obtenemos que

$$\begin{aligned} \|x^k(t_k) - x^k\| &\leq \max\{1, t_k/\alpha_k\} \|x^k(\alpha_k) - x^k\| \\ &\leq \max\{1, \hat{t}/\check{\alpha}\} \|x^{k+1} - x^k\| \rightarrow 0 \quad (k \rightarrow \infty), \end{aligned}$$

lo que prueba (8.11).

Sea $\{x^{k_j}\}$ una subsecuencia de la secuencia $\{x^k\}$ que converge a $\bar{x}$. Pasando al límite cuando $j \rightarrow \infty$ en (8.11), donde tomamos $t_k = t \forall k$, siendo $t > 0$ un número arbitrario, teniendo en cuenta la continuidad del operador de proyección (vea el Teorema 1.3.1), obtenemos (8.3), mostrando que $\bar{x}$ es un punto estacionario.

La consideración del caso de utilización de la minimización unidimensional se reduce a la regla de Armijo de la misma manera que en el Teorema 3.1.1. ■

Sea S_0 el conjunto de puntos estacionarios del problema (8.1). Supongamos que valga la condición de separación de superficies de nivel críticas, que tiene la misma forma que en § 3.1.2 (pero con la nueva definición de S_0 , claro). Supongamos que vale la estimativa

$$\|x - P_D(x - f'(x))\| \geq \gamma \text{dist}(x, S_0) \quad \forall x \in U, \quad (8.14)$$

donde

$$U = \{x \in \mathbb{R}^n \mid \|x - P_D(x - f'(x))\| < \delta\}, \quad (8.15)$$

con constantes $\delta > 0$ y $\gamma > 0$. En el caso de $D = \mathbb{R}^n$, estas condiciones ya fueron consideradas en § 3.1.2. Sin entrar en detalles, mencionamos que ambas son satisfechas si, por ejemplo, f es una función cuadrática, D es un conjunto poliédrico, y $S_0 \neq \emptyset$ (comparar con el Ejercicio 3.1.11).

Teorema 8.2 (Convergencia lineal del método del gradiente proyectado). *Además de las hipótesis del Teorema 4.1.1, supongamos que el valor óptimo del problema (8.1) sea finito y valga la condición (8.14), con U definido en (8.15) y algunos $\delta > 0$ y $\gamma > 0$. Supongamos también que valga la condición de separación de superficies de nivel críticas.*

Entonces cualquier secuencia $\{x^k\}$ generada por el Algoritmo 4.1.1 converge a un punto estacionario del problema (8.1). La tasa de convergencia con respecto a la función es lineal, y con respecto a las variables la tasa es geométrica.

La demostración de este teorema puede ser hecha por la modificación relativamente obvia de la demostración del Teorema 3.1.5. Mencionemos apenas que aquí deben ser también utilizados los resultados de los Teoremas 1.3.1 y 1.3.7.

Cada iteración de un método del gradiente proyectado requiere el cálculo de proyecciones sobre el conjunto D (una vez, o más, dependiendo de la regla para la longitud de paso). Esto indica que el método sólo puede ser práctico cuando el cálculo de proyecciones tiene un costo computacional relativamente bajo. Por ejemplo, cuando D es un conjunto poliédrico, el problema de encontrar una proyección es de programación cuadrática (vea § 6.2), lo que es considerado aceptable. Difícilmente puede tener sentido utilizar técnicas de proyección en el caso más general, i.e., de restricciones no lineales. A veces, el cálculo de proyecciones no requiere resolución numérica de problemas de optimización, porque existen fórmulas explícitas.

Existen modificaciones de métodos del gradiente proyectado que requieren, en cada iteración, una proyección apenas. Por ejemplo, en vez del esquema (8.4) basado en el arco de proyección (8.5), podemos utilizar el intervalo

$$x^k(\alpha) = (1 - \alpha)x^k + \alpha P_D(x^k - \beta_k f'(x^k)).$$

Esto resulta en el esquema

$$x^{k+1} = (1 - \alpha_k)x^k + \alpha_k P_D(x^k - \beta_k f'(x^k)), \quad k = 0, 1, \dots, \quad (8.16)$$

donde $x^0 \in D$, los parámetros $\beta_k > 0$ pueden ser elegidos más o menos arbitrariamente (desde que $0 < c_1 \leq \beta_k \leq c_2$), y el parámetro de longitud de paso α_k es calculado por la regla de Armijo (8.6) con $\hat{\alpha} = 1$. Las reglas de minimización unidimensional pueden ser adaptadas análogamente.

Observamos que si $x^k \in D$ entonces, por la convexidad de D ,

$$d^k = P_D(x^k - \beta_k f'(x^k)) - x^k$$

es una dirección factible en el punto x^k con respecto al conjunto D y, en particular, $x^k(\alpha) = x^k + \alpha d^k \in D$ para todo $\alpha \in [0, 1]$. Este intervalo está ilustrado en la Figura 4.1.2.

Además de eso, por (8.7), d^k es una dirección de descenso de la función f en el punto x^k . Tenemos entonces una dirección de descenso que es factible. A partir de eso, es fácil probar que, si la secuencia $\{\beta_k\}$ es limitada inferiormente por un número positivo, este esquema posee convergencia global en el sentido del Teorema 4.1.1. Sin embargo, probar la tasa de convergencia lineal para este esquema ya no es posible, por lo menos bajo las hipótesis usuales.

La importancia teórica de métodos del gradiente proyectado consiste principalmente en el hecho de que varios otros métodos que generan iteraciones factibles y son métodos de descenso, pueden ser interpretados como versiones inexactas o modificadas de algún método del gradiente proyectado.

8.1.2. Direcciones factibles y métodos de descenso

Dada una aproximación x^k a la solución del problema, una idea natural consiste en definir una dirección que, al mismo tiempo, es factible en x^k con respecto al conjunto D y es de descenso para la función objetivo f . A propósito, un método de este tipo ya fue presentado arriba, como modificación (8.16) del método del gradiente proyectado. A continuación, consideraremos algunas otras posibilidades.

Primero, recordamos la noción de direcciones factibles (vea [12]).

Definición 8.1. Un vector $d \in \mathbb{R}^n$ se llama *dirección factible* en el punto $x \in D$ con respecto a D , si para todo $t > 0$ suficientemente pequeño se tiene que $x + td \in D$.

Recordamos también que el conjunto de todas las direcciones factibles en $x \in D$ con respecto a D es un cono que denotamos $V_D(x)$. Entonces, $d \in V_D(x)$ si, y solamente si, todo paso suficientemente corto a partir de x en

la dirección d resulta en un punto que pertenece a D . Tenemos que $0 \in V_D(x)$ trivialmente. Los dos resultados siguientes proporcionan condiciones suficientes para que una dirección dada sea factible. Las demostraciones de estos resultados están contenidas en las demostraciones de resultados más generales (sobre la caracterización de direcciones tangentes) en [12, Teorema 4.1.2].

Lema 8.2. Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Entonces

$$y - x \in V_D(x) \quad \forall x, y \in D.$$

Lema 8.3. Sea

$$D = \{x \in \mathbb{R}^n \mid g(x) \leq 0\},$$

donde la función $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es diferenciable en el punto $y \in D$. Entonces:

- (a) Para todo $d \in V_D(y)$ se tiene que $\langle g'_i(y), d \rangle \leq 0 \quad \forall i \in I(y)$, donde $I(y) = \{i = 1, \dots, m \mid g_i(y) = 0\}$ es el conjunto de índices de las restricciones activas en y .
- (b) Si $d \in \mathbb{R}^n$ satisface $\langle g'_i(y), d \rangle < 0 \quad \forall i \in I(y)$, se tiene que $d \in V_D(y)$.

Métodos de descenso pueden ser definidos para un problema general

$$\min f(x) \quad \text{sujeto a} \quad x \in D, \quad (8.17)$$

donde, en principio, el conjunto factible $D \subset \mathbb{R}^n$ no necesita ser ni convexo ni cerrado, y la función objetivo no necesita ser diferenciable. El esquema general es el siguiente:

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k \in D_f(x^k) \cap V_D(x^k), \quad k = 0, 1, \dots, \quad (8.18)$$

donde $x^0 \in D$, y los parámetros de longitud de paso $\alpha_k > 0$ tienen que satisfacer, por lo menos, las condiciones

$$f(x^{k+1}) < f(x^k), \quad x^{k+1} \in D. \quad (8.19)$$

Como $d^k \in D_f(x^k) \cap V_D(x^k)$ por la definición, las condiciones (8.19) serán satisfechas para todo $\alpha_k > 0$ suficientemente pequeño. Entendemos que cuando $D_f(x^k) \cap V_D(x^k) = \emptyset$, el método para. Así, se está realizando un descenso para superficies de nivel de la función objetivo con valores cada vez más bajos, manteniendo también la viabilidad. Cada método específico es caracterizado por la manera concreta de la elección de la dirección d^k y del cálculo de la longitud de paso α_k en esta dirección. Para $D = \mathbb{R}^n$, el esquema (8.18), (8.19) coincide con el esquema general de los métodos de descenso para optimización irrestricta presentado en § 3.1.1.

Si D es un conjunto convexo y cerrado, la segunda condición en (8.19) es satisfecha para todo $\alpha \in [0, \hat{\alpha}_k]$, donde

$$0 < \hat{\alpha}_k = \sup\{\alpha \in \mathbb{R}_+ \mid x^k + \alpha d^k \in D\} \quad (8.20)$$

(si $\hat{\alpha}_k = +\infty$, la segunda condición en (8.19) es satisfecha para todo $\alpha_k \geq 0$). Para determinar α_k que garantice la disminución de la función objetivo f , pueden ser utilizadas las mismas técnicas de minimización unidimensional consideradas en § 3.1.1, llevando en cuenta la restricción adicional $\alpha_k \leq \hat{\alpha}_k$. Los cálculos son bien más simples cuando $\hat{\alpha}_k$ puede ser determinado explícitamente, o cuando una cota inferior para $\hat{\alpha}_k$ puede ser obtenida fácilmente.

A continuación, presentaremos dos ejemplos de métodos de descenso para problemas con restricciones simples.

8.1.3. Método del gradiente restringido. Método de Newton restringido

Supongamos que el conjunto factible D del problema (8.1), además de cerrado y convexo, sea también limitado (esta última hipótesis sirve para garantizar la existencia de soluciones en el subproblema (8.21) del método descrito a continuación). Los métodos del gradiente restringido son dados por la siguiente manera de elegir una dirección de descenso en el esquema (8.18): para $x^k \in D$, resolvemos el problema

$$\min \langle f'(x^k), x - x^k \rangle \quad \text{sujeto a} \quad x \in D, \quad (8.21)$$

obtenido por la linealización de la función objetivo del problema (8.1) en el punto x^k (la constante $f(x^k)$ es desconsiderada en (8.21)). Sea $\bar{x}^k \in D$ una solución del problema (8.21) y $v_k = \langle f'(x^k), \bar{x}^k - x^k \rangle$ el valor óptimo (una solución existe, por el Teorema de Weierstrass 1.1.1). Observamos que $v_k \leq \langle f'(x^k), x^k - x^k \rangle = 0$, porque $x^k \in D$. Si $v_k = 0$, tenemos que

$$\langle f'(x^k), x - x^k \rangle \geq v_k = 0 \quad \forall x \in D,$$

i.e., x^k es un punto estacionario del problema (8.1) (vea (8.2)). En este caso, el método para. Si $v_k < 0$, por los Lemas 3.1.1 y 4.1.2, para la dirección $d^k = \bar{x}^k - x^k$ tenemos que $d^k \in D_f(x^k) \cap V_D(x^k)$. Tal dirección d^k es llamada *anti-gradiente restringido* de la función f en el punto x^k con respecto al conjunto D .

Es fácil ver que para esta elección de d^k , el valor de $\hat{\alpha}_k$ definido en (8.20) es igual a 1. Así el cálculo de la longitud de paso α_k queda facilitado.

Para métodos del gradiente restringido pueden ser obtenidos resultados análogos a aquellos del Teorema 4.1.1 (vea [4]). Además de eso, bajo la hipótesis adicional de que f sea convexa en D , puede ser probada convergencia aritmética (vea [22]), que garantiza una tasa apenas sublineal. Siendo una extensión obvia del método del gradiente para el caso irrestricto, este algoritmo no es rápido.

Es claro también que métodos de este tipo sólo pueden tener alguna utilidad cuando la resolución de subproblemas de forma (8.21) con función objetivo lineal sea fácil. Si D es un conjunto poliédrico, (8.21) es un problema de programación lineal, vea § 6.1, lo que es un problema simple.

A pesar de la relativamente pequeña área de aplicación y de la lenta convergencia, los métodos del gradiente restringido tienen un cierto interés teórico por consistir en una implementación (sin embargo, bastante simple) de la importante idea de linealización de las funciones que definen un problema de optimización. Una implementación más adecuada de esta idea será presentada en § 4.2 para problemas con restricciones de desigualdad, donde tanto la función objetivo como las restricciones serán linealizadas en cada iteración.

Otra idea natural es utilizar, en vez de la aproximación lineal, la aproximación cuadrática de la función objetivo. Esquemas de este tipo se llaman *métodos de Newton restringido*, donde en (8.18) tenemos $d^k = \bar{x}^k - x^k$ y $\bar{x}^k$ es una solución del problema

$$\min \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle f''(x^k)(x - x^k), x - x^k \rangle \quad \text{sujeto a } x \in D. \quad (8.22)$$

Cuando D es un conjunto poliédrico, (8.22) es un problema de programación cuadrática (vea § 6.2). En otros casos (i.e., de restricciones no lineales), la resolución de (8.22) puede no ser mucho más fácil que la resolución del problema original (8.1), lo que torna el método poco atractivo. Para simplificar el subproblema, parece natural combinar la aproximación de segunda orden de la función objetivo con la linealización de las restricciones. Sin embargo, como veremos más adelante, en este caso es recomendable utilizar otro término cuadrático en la función objetivo de los subproblemas. Para garantizar convergencia global, en principio podemos utilizar (en vez de $f''(x^k)$) hasta una matriz definida positiva cualquiera. Pero para conseguir convergencia local rápida, la matriz en cuestión tiene que incorporar la información de segunda orden tanto sobre la función objetivo como sobre las restricciones del problema. Métodos de este tipo son bien eficientes. Ellos se llaman de *programación cuadrática secuencial* y serán presentados en § 4.6.

8.2. Métodos de penalización

La penalización tiene por objetivo aproximar un problema con restricciones por una secuencia de problemas irrestrictos, teniendo en vista la aplicación de técnicas computacionales ya desarrolladas. La idea de convertir un problema de optimización con restricciones en un problema (o una secuencia de problemas) sin restricciones es natural y es usada en la construcción de varios algoritmos.

En la penalización externa, a la función objetivo se le añade un término cuyo valor es nulo en todos los puntos factibles y es positivo para los no factibles. En general, la solución de un problema así penalizado está fuera del conjunto factible, lo que explica el nombre de penalización “externa”. Para obtener convergencia a la solución del problema original (que, obviamente, tiene que ser factible), el parámetro escalar que multiplica el término penalizador tiene que crecer a más infinito. Una excepción importante a esta regla es la *penalización exacta*, donde un valor del parámetro penalizador suficientemente grande (pero fijo) permite la recuperación exacta de una solución del problema original. Típicamente, esto solo es posible a costa de la utilización de términos penalizadores no diferenciables. La penalización exacta será presentada un poco más adelante, en § 4.3.2.

En la penalización interna, a la función objetivo se le añade un término cuyo valor tiende a más infinito cuando los puntos factibles se aproximan a la frontera del conjunto factible del problema. Tenemos entonces una “barrera” que no permite a las soluciones de problemas así penalizados dejar el interior del conjunto factible. Esto explica el nombre de penalización “interna” o, también, de métodos de “barreras”. Para obtener convergencia a la solución del problema original (que, típicamente, está justamente en la frontera del conjunto factible), el parámetro escalar que multiplica el término penalizador tiene que decrecer a cero.

Las técnicas de penalización son bien simples y universales. Sin embargo, ellas no son muy usadas en forma pura, debido a la necesidad de la utilización de valores del parámetro penalizador muy grandes (en el caso de la penalización externa) o muy pequeños (en el caso de la penalización interna), lo que tiende a provocar inestabilidad numérica. Mismo así, la penalización tiene una cierta importancia histórica, y es útil para el entendimiento de estrategias más sofisticadas. Además de eso, la penalización exacta proporciona una de las técnicas más eficientes para la globalización de métodos de programación cuadrática secuencial, que será desarrollada en § 4.6.

8.2.1. Penalización externa

Consideremos un problema en formato general

$$\min f(x) \quad \text{sujeto a } x \in D, \quad (8.23)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $D \subset \mathbb{R}^n$ es un conjunto cualquiera. Como ya fue anunciado, introduciremos un término que tiene por objetivo penalizar la violación de las restricciones, i.e., una función $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$, continua en $\mathbb{R}^n$, tal que

$$\psi(x) = \begin{cases} 0 & \forall x \in D, \\ > 0 & \forall x \in \mathbb{R}^n \setminus D. \end{cases} \quad (8.24)$$

Por ejemplo, si

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\}, \quad (8.25)$$

es conveniente definir

$$\Psi : \mathbb{R}^n \rightarrow \mathbb{R}^l \times \mathbb{R}^m,$$

$$\Psi(x) = (h(x), (\max\{0, g_1(x)\}, \dots, \max\{0, g_m(x)\})), \quad (8.26)$$

$$\psi(x) = \|\Psi(x)\|^p, \quad x \in \mathbb{R}^n, \quad (8.27)$$

donde $p > 0$. En (8.27), además de la norma Euclidiana $\|\cdot\| = \|\cdot\|_2$, pueden ser utilizadas también $\|\cdot\|_p$, o $\|\cdot\|_\infty$ (para $p \in (0, 1)$, $\|\cdot\|_p$ no define una norma, pero en este contexto es conveniente utilizar la misma notación). Estas elecciones resultan en

$$\psi(x) = \|\Psi(x)\|_p^p = \|h(x)\|_p^p + \sum_{i=1}^m (\max\{g_i(x), 0\})^p, \quad (8.28)$$

o

$$\psi(x) = \|\Psi(x)\|_\infty^p = (\max\{\|h(x)\|_\infty, 0, g_1(x), \dots, g_m(x)\})^p. \quad (8.29)$$

Notamos que para h y g diferenciables, la función ψ definida por (8.28) es diferenciable cuando $p > 1$, y no es diferenciable en caso contrario. La función ψ dada por (8.29) no es diferenciable, mismo cuando h y g son diferenciables. Como veremos más adelante, existen algunas diferencias importantes entre propiedades de penalizadores diferenciables y no diferenciables.

Consideremos una familia de problemas irrestrictos

$$\min \varphi(x; c), \quad x \in \mathbb{R}^n, \quad (8.30)$$

donde

$$\varphi(\cdot; c) : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \varphi(x; c) = f(x) + c\psi(x), \quad (8.31)$$

y $c > 0$ es el parámetro penalizador.

La idea es que en la medida en que el valor de c aumenta, la violación de las restricciones se vuelve cada vez más cara. Podemos esperar, entonces, que las soluciones de los problemas irrestrictos (8.30) se aproximen al conjunto factible cuando $c \rightarrow +\infty$ y sus puntos de acumulación resuelvan el problema original (8.23).

Algoritmo 8.2 (Método de penalización externa). Elegir una función $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$, penalizador externo para el conjunto D . Elegir $c_0 > 0$. Tomar $k := 0$.

1. Calcular $x^k = x(c_k)$, una solución del problema (8.30), donde la función objetivo es dada por la fórmula (8.31) con $c = c_k$.

2. Elegir $c_{k+1} > c_k$, tomar $k := k + 1$. Retornar al Paso 1.

Mencionamos que, por razones obvias, es natural utilizar el punto x^{k-1} como punto inicial del método aplicado para minimizar la función $\varphi(\cdot; c_k)$ en la iteración k .

Notemos que la mayoría de los resultados de convergencia de métodos de este tipo se refiere a la secuencia de soluciones globales de los problemas (8.30), suponiendo que ellas existan. Por lo tanto, fuera del caso convexo, la aplicación de métodos de penalización puros no viene con convergencia garantizada, ya que en el caso no convexo no hay cómo calcular soluciones globales. El asunto de la utilización de soluciones locales será considerado también, más adelante.

A continuación, veremos algunos ejemplos de aplicación del Algoritmo 4.3.1.

Ejemplo 8.1. Consideremos el problema

$$\min x_1^2 - x_2 \quad \text{sujeto a} \quad x_1 + x_2 - 1 = 0, \quad x_1 \geq 0.$$

Este es un problema de programación convexa, y la única solución es $\bar{x} = (0, 1)$.

Eligiendo el término penalizador (8.28) con $p = 2$, obtenemos

$$\varphi(x; c) = x_1^2 - x_2 + c(x_1 + x_2 - 1)^2 + c(\max\{-x_1, 0\})^2.$$

Como es fácil ver, esta función es convexa, diferenciable, y su (único) minimizador (global) irrestricto es caracterizado por el sistema de ecuaciones

$$0 = \varphi'(x; c) = \begin{pmatrix} 2x_1 + 2c(x_1 + x_2 - 1) - 2c \max\{-x_1, 0\} \\ -1 + 2c(x_1 + x_2 - 1) \end{pmatrix},$$

donde $\varphi'(x; c)$ es el gradiente de $\varphi(\cdot; c)$ en x (creemos que no debe haber confusión con la notación de la derivada direccional). De donde obtenemos que

$$2x_1 + 1 - 2c \max\{-x_1, 0\} = 0.$$

La última ecuación no posee solución si $x_1 \geq 0$. Resolviendo el sistema para $x_1 < 0$, obtenemos

$$x_1(c) = -1/(2(1 + c)), \quad x_2(c) = 1 + 1/(2c) + 1/(2(1 + c)).$$

En particular, tenemos que

$$x(c) = (x_1(c), x_2(c)) \rightarrow (0, 1) = \bar{x} \quad (c \rightarrow +\infty).$$

Observemos que para todo $c > 0$, el punto $x(c)$ no es factible. La Figura 4.3.4 ilustra la trayectoria $x(c)$ de las soluciones de los problemas penalizados.

El ejemplo de arriba muestra que, en general, las soluciones de problemas penalizados no son puntos factibles del problema original y, por lo tanto, para métodos de este tipo solo podemos esperar convergencia asintótica. El ejemplo siguiente muestra que, en principio, es posible que alguna solución del problema penalizado sea factible y que, en este caso, ella es la solución del problema original. Resaltamos, no obstante, que tal situación es bastante atípica en el caso de la utilización de penalizadores diferenciables.

Ejemplo 8.2. Consideremos el problema

$$\min x^2 \quad \text{sujeto a} \quad x \geq -1.$$

La solución de este problema es $\bar{x} = 0$.

Eligiendo el término penalizador (8.28) con $p = 2$, obtenemos

$$\varphi(x; c) = x^2 + c(\max\{-x - 1, 0\})^2.$$

Como es fácil ver, esta función es convexa, diferenciable, y su (único) minimizador (global) irrestricto es caracterizado por

$$0 = \varphi'(x; c) = 2x - 2c \max\{-x - 1, 0\}.$$

La única solución de esta ecuación es $x(c) = 0$. Observemos que $x(c)$ es un punto factible y que $x(c) = \bar{x}$.

A continuación, probaremos las propiedades de convergencia del Algoritmo 4.3.1, ya observadas en los Ejemplos 4.3.1 y 4.3.2.

Proposición 8.1. Sea $\{x^k\}$ una secuencia generada por el Algoritmo 4.3.1, donde x^k es una solución global de (8.30) con $c = c_k$. Entonces, para todo k , se tiene que

$$\varphi(x^{k+1}; c_{k+1}) \geq \varphi(x^k; c_k), \quad (8.32)$$

$$\psi(x^{k+1}) \leq \psi(x^k), \quad (8.33)$$

$$f(x^{k+1}) \geq f(x^k). \quad (8.34)$$

Prueba. Por la optimalidad de x^k en (8.30) con $c = c_k$, tenemos que

$$\begin{aligned} \varphi(x^k; c_k) &\leq \varphi(x^{k+1}; c_k) \\ &= f(x^{k+1}) + c_k \psi(x^{k+1}) \\ &\leq f(x^{k+1}) + c_{k+1} \psi(x^{k+1}) \\ &= \varphi(x^{k+1}; c_{k+1}) \\ &\leq \varphi(x^k; c_{k+1}), \end{aligned} \quad (8.35)$$

donde también utilizamos que $c_{k+1} > c_k$ y $\psi(x^{k+1}) \geq 0$. Acabamos de mostrar (8.32).

De (8.35), tenemos

$$\begin{aligned} f(x^k) + c_k \psi(x^k) &\leq f(x^{k+1}) + c_k \psi(x^{k+1}), \\ f(x^{k+1}) + c_{k+1} \psi(x^{k+1}) &\leq f(x^k) + c_{k+1} \psi(x^k). \end{aligned}$$

Sumando las dos últimas desigualdades, obtenemos

$$(c_k - c_{k+1})\psi(x^k) \leq (c_k - c_{k+1})\psi(x^{k+1}),$$

de donde, teniendo en cuenta que $c_{k+1} > c_k$, se sigue (8.33).

Ahora, utilizando (8.33) y (8.35), de

$$\begin{aligned} f(x^k) + c_k \psi(x^k) &\leq f(x^{k+1}) + c_k \psi(x^{k+1}) \\ &\leq f(x^{k+1}) + c_k \psi(x^k), \end{aligned}$$

obtenemos (8.34). ■

El resultado siguiente prueba la convergencia asintótica del Algoritmo 4.3.1, además de mostrar que, en general, los puntos x^k generados no son factibles. Con efecto, si el método genera un punto factible, él ya es una solución del problema original. No obstante, es claro que tal situación no puede ser esperada en general.

Teorema 8.3 (Convergencia global del método de penalización externa). Sea $\{x^k\}$ una secuencia generada por el Algoritmo 4.3.1, donde x^k es una solución global de (8.30) con $c = c_k$. Entonces $x^k \in D$ si, y solamente si, x^k es una solución global del problema (8.23).

Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$ funciones continuas en $\mathbb{R}^n$, y sea $\bar{v} > -\infty$ el valor óptimo del problema (8.23). Si $c_k \rightarrow +\infty$ ($k \rightarrow \infty$), entonces todo punto de acumulación de la secuencia $\{x^k\}$ es una solución global del problema (8.23).

Prueba. Primero, es fácil ver que para todo punto $x \in D$,

$$\begin{aligned} f(x^k) &\leq f(x^k) + c_k \psi(x^k) \\ &= \varphi(x^k; c_k) \\ &\leq \varphi(x; c_k) \\ &= f(x), \end{aligned}$$

donde utilizamos que $c_k > 0$, $\psi(x^k) \geq 0$, que x^k es una solución global de (8.30) con $c = c_k$, y que $\psi(x) = 0$ para todo $x \in D$. Concluimos que, para todo k ,

$$f(x^k) \leq \varphi(x^k; c_k) \leq \bar{v} = \inf_{x \in D} f(x). \quad (8.36)$$

Si $x^k \in D$, obtenemos entonces que x^k es una solución del problema (8.23).

Por la Proposición 4.3.1, la secuencia $\{\varphi(x^k; c_k)\}$ es no decreciente. Por (8.36), ella es limitada superiormente por $\bar{v}$. Luego, ella converge y se tiene que

$$\lim_{k \rightarrow \infty} \varphi(x^k; c_k) = \lim_{k \rightarrow \infty} (f(x^k) + c_k \psi(x^k)) \leq \bar{v}. \quad (8.37)$$

Sea $\bar{x}$ un punto de acumulación de la secuencia $\{x^k\}$, $\{x^{k_j}\} \rightarrow \bar{x}$ ($j \rightarrow \infty$). Por la continuidad de f , tenemos que $f(x^{k_j}) \rightarrow f(\bar{x})$ ($j \rightarrow \infty$). De (8.37), obtenemos entonces que

$$\lim_{j \rightarrow \infty} c_{k_j} \psi(x^{k_j}) \leq \bar{v} - f(\bar{x}).$$

De donde, como $c_k \rightarrow +\infty$ y $\psi(x^{k_j}) \geq 0$, se sigue que

$$\lim_{j \rightarrow \infty} \psi(x^{k_j}) = 0.$$

Por la continuidad de ψ , concluimos que $\psi(\bar{x}) = 0$, i.e., $\bar{x} \in D$.

Ahora, pasando al límite en (8.36), obtenemos

$$\lim_{j \rightarrow \infty} f(x^{k_j}) \leq \bar{v},$$

lo que (teniendo en cuenta que $\bar{x} \in D$), muestra que $\bar{x}$ es una solución de (8.23). ■

El Teorema 4.3.1 puede ser ligeramente generalizado en relación a las hipótesis de continuidad de las funciones f y ψ .

Observemos que podemos considerar un método más general que el Algoritmo 4.3.1, donde (tal vez) no todas las restricciones son penalizadas. Sea el problema

$$\min f(x) \quad \text{sujeto a} \quad x \in \Omega \cap D,$$

donde Ω y D son conjuntos en $\mathbb{R}^n$ arbitrarios. Un método con penalización parcial de restricciones es dado por la resolución de problemas

$$\min \varphi(x; c) \quad \text{sujeto a} \quad x \in \Omega,$$

donde $\varphi(\cdot; c)$ es dada por (8.31) y ψ es dada por (8.24). O sea, ψ penaliza la violación de la restricción $x \in D$ (y no penaliza la restricción $x \in \Omega$). Cuando un subconjunto de restricciones tiene estructura simple (el subconjunto Ω), la no penalización de esas restricciones puede ser ventajosa. O sea, puede tener sentido computacional tratar esas restricciones explícitamente (como restricciones del problema) en vez de implícitamente (vía penalización). Evidentemente, el Algoritmo 4.3.1 es un caso especial de la construcción de arriba, correspondiente a la elección $\Omega = \mathbb{R}^n$.

En general, el problema (8.30) puede no poseer soluciones o poseer varias. El resultado siguiente contiene, entre otras cosas, condiciones suficientes para garantizar la existencia de soluciones (locales) de (8.30) y la convergencia de estas soluciones a una solución local del problema original. Así obtenemos una versión más práctica del Algoritmo 4.3.1, que trabaja con soluciones locales de problemas penalizados.

Teorema 8.4 (Convergencia de soluciones locales de problemas penalizados). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$ funciones continuas en $\mathbb{R}^n$, donde ψ satisface (8.24). Sea $\bar{x} \in \mathbb{R}^n$ un minimizador local estricto del problema (8.23).

Entonces existe un número $\delta > 0$ tal que para cualquier solución (global) $x(c)$ del problema

$$\min \varphi(x; c) \quad \text{sujeto a} \quad x \in B(\bar{x}, \delta),$$

donde la función objetivo es dada por (8.31) con $c \geq 0$, se tiene que

$$x(c) \rightarrow \bar{x} \quad (c \rightarrow +\infty). \quad (8.38)$$

En particular, para todo número $c > 0$ suficientemente grande, el problema (8.30) posee una solución local $x(c)$ tal que vale (8.38).

Prueba. Primero notamos que, por el Teorema de Weierstrass (Teorema 1.1.1), para todo $c \geq 0$ el punto $x(c)$ en cuestión existe.

Fijamos $\delta > 0$ tal que el punto $\bar{x}$ sea la única solución global del problema

$$\min f(x) \quad \text{sujeto a} \quad x \in D \cap B(\bar{x}, \delta). \quad (8.39)$$

(La existencia de tal $\delta > 0$ se sigue del hecho de que $\bar{x}$ es minimizador local estricto).

Los valores de la función $x(\cdot) : \mathbb{R} \rightarrow \mathbb{R}^n$ pertenecen al conjunto $B(\bar{x}, \delta)$, que es compacto. Por lo tanto, estos valores tienen un punto de acumulación $\tilde{x} \in B(\bar{x}, \delta)$ cuando $c \rightarrow +\infty$. Probaremos que $\tilde{x}$ es una solución global del problema (8.39).

Por la definición de $x(c)$, para todo c tenemos que

$$\varphi(x(c); c) \leq \varphi(x; c) \quad \forall x \in B(\bar{x}, \delta).$$

Por lo tanto, utilizando el hecho de que $f(x) = \varphi(x; c)$ para todo $x \in D$, tenemos que

$$\begin{aligned} f(x(c)) + c\psi(x(c)) &= \varphi(x(c); c) \\ &\leq \inf_{x \in D \cap B(\bar{x}, \delta)} \varphi(x; c) \\ &= \inf_{x \in D \cap B(\bar{x}, \delta)} f(x) = v, \end{aligned} \tag{8.40}$$

donde $v = v(\bar{x}, \delta)$ es el valor óptimo del problema (8.39).

Fijemos ahora una secuencia $\{c_k\} \subset \mathbb{R}$ tal que $c_k \rightarrow +\infty$, $\{x(c_k)\} \rightarrow \tilde{x}$ ($k \rightarrow \infty$). De (8.40), obtenemos que

$$\limsup_{k \rightarrow \infty} c_k \psi(x(c_k)) \leq v - f(\tilde{x}). \tag{8.41}$$

De donde, como $c_k \rightarrow +\infty$ ($k \rightarrow \infty$), obtenemos

$$\psi(\tilde{x}) = \lim_{k \rightarrow \infty} \psi(x(c_k)) = 0,$$

i.e., $\tilde{x} \in D \cap B(\bar{x}, \delta)$. Por lo tanto,

$$v \leq f(\tilde{x}). \tag{8.42}$$

Ahora, de (8.41), obtenemos que

$$\limsup_{k \rightarrow \infty} c_k \psi(x(c_k)) \leq 0,$$

lo que solo puede valer si

$$\lim_{k \rightarrow \infty} c_k \psi(x(c_k)) = 0.$$

De (8.41), tenemos entonces que

$$f(\tilde{x}) \leq v,$$

lo que resulta, en combinación con (8.42), en

$$f(\tilde{x}) = v.$$

Como $\tilde{x}$ es un punto factible para el problema (8.39), esto significa que $\tilde{x}$ es una solución global de este problema.

Como por la elección de δ , el punto $\tilde{x}$ es la única solución global de (8.39), concluimos que $\tilde{x} = \bar{x}$. Acabamos de mostrar, entonces, que $\bar{x}$ es el único punto de acumulación de los valores de $x(\cdot)$. O sea, vale (8.38). En particular, $x(c) \in \text{int } B(\bar{x}, \delta)$ para todo c suficientemente grande. Obviamente, de aquí se sigue que para tales valores de c , $x(c)$ es una solución local del problema (8.30). ■

Como ya fue mencionado, una limitación práctica de la aplicación de métodos de penalización consiste en la necesidad de resolver problemas cada vez peor condicionados, debido al uso de valores extremos del parámetro penalizador. Vemos cómo esto acontece en el ejemplo siguiente.

Ejemplo 8.3. Consideremos el problema

$$\min \frac{1}{2}(x_1^2 + x_2^2) \quad \text{sujeto a} \quad x_1 = 1,$$

y la siguiente función penalizada:

$$\varphi(x; c) = \frac{1}{2}(x_1^2 + x_2^2) + c(x_1 - 1)^2.$$

Como es fácil ver, la matriz Hessiana de esta función viene dada por

$$\varphi''(x; c) = \begin{pmatrix} 1 + c & 0 \\ 0 & 1 \end{pmatrix}.$$

Evidentemente, esta matriz es mal-condicionada (para valores de $c > 0$ grandes). En particular, el método de Newton aplicado para minimizar $\varphi(\cdot; c)$ va a necesitar resolver sistemas de ecuaciones lineales cada vez peor condicionados, a medida que c crece.

De cierto modo, la necesidad de resolver muchos problemas penalizados puede ser evitada. A continuación, mostraremos cómo, para una precisión dada cualquiera, una solución aproximada del problema original puede ser obtenida a través de la resolución de dos problemas penalizados apenas.

Sea $\varepsilon > 0$ la tolerancia deseada. Nos gustaría calcular un punto $y \in \mathbb{R}^n$ tal que

$$f(y) \leq \inf_{x \in D} f(x), \quad \psi(y) \leq \varepsilon. \quad (8.43)$$

Para ε suficientemente pequeño, es natural considerar tal punto y como una buena aproximación de la solución del problema (la segunda relación en (8.43) significa que y es un punto “casi-factible”).

Supongamos que $\inf_{x \in D} f(x) > -\infty$ y que un punto factible $\hat{x} \in D$ sea dado (en caso contrario, calculamos un punto factible primero). Elegimos un $c_1 > 0$ arbitrario, y calculamos $x(c_1)$, una solución global del problema (8.30) con $c = c_1$.

Si $f(\hat{x}) \leq f(x(c_1))$, de (8.36) obtenemos que

$$f(x(c_1)) \leq \inf_{x \in D} f(x) \leq f(\hat{x}) \leq f(x(c_1)).$$

Esto muestra que $\hat{x}$ es una solución (exacta) del problema original (8.23).

Consideremos el caso de $f(\hat{x}) > f(x(c_1))$. Elegimos

$$c_2 > \max\left\{c_1, \frac{f(\hat{x}) - f(x(c_1))}{\varepsilon}\right\}, \quad (8.44)$$

y calculamos $x(c_2)$, una solución global del problema (8.30) con $c = c_2$.

Caso $f(\hat{x}) \leq f(x(c_2))$, tenemos que $\hat{x}$ es una solución (exacta) del problema original (8.23), por el raciocinio presentado arriba.

Caso contrario, el punto $x(c_2)$ satisface

$$f(x(c_2)) \leq \inf_{x \in D} f(x),$$

por (8.36). Por la optimalidad de $x(c_2)$ en (8.30), tenemos que

$$f(x(c_2)) + c_2 \psi(x(c_2)) \leq f(\hat{x}) + c_2 \psi(\hat{x}) = f(\hat{x}),$$

donde la igualdad se sigue del hecho de que $\hat{x} \in D$. Luego,

$$\begin{aligned} \psi(x(c_2)) &\leq (f(\hat{x}) - f(x(c_2)))/c_2 \\ &\leq (f(\hat{x}) - f(x(c_1)))/c_2 \\ &< \varepsilon, \end{aligned}$$

donde la segunda desigualdad se sigue de la Proposición 4.3.1 y del hecho de que $c_2 > c_1$, y la tercera desigualdad se sigue de (8.44). Acabamos de mostrar que el punto $x(c_2)$ satisface las condiciones (8.43).

Sin embargo, la construcción de arriba resuelve la dificultad asociada al mal-condicionamiento de los subproblemas apenas parcialmente. En particular, es posible que el valor de c_2 dado por (8.44) sea muy grande, y mismo que para satisfacer (8.43) tengamos que resolver un solo subproblema, esto puede ser difícil desde el punto de vista computacional.

Consideremos ahora la cuestión de la tasa de convergencia de los métodos de penalización externa en relación a valores de la función objetivo, suponiendo la convergencia en relación a las variables. Para este fin, suponhamos que el término penalizador $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$, definido en (8.24), proporcione una estimativa local de la violación de factibilidad, en el sentido siguiente: existen una vecindad U de la solución dada $\bar{x}$ del problema (8.23) y números $M > 0$ y $\nu > 0$, tales que

$$\text{dist}(x, D) \leq M(\psi(x))^\nu \quad \forall x \in U. \quad (8.45)$$

Ya vimos algunas situaciones de validez de estimativas de este tipo: por ejemplo, en los Teoremas 1.5.5, 1.6.6, 1.5.6. En particular, bajo las hipótesis del Teorema 1.5.6, la función ψ dada por (8.27) con algún $p > 0$, satisface (8.45) con $\nu = 1/p$.

Observemos que el resultado a seguir, además de estimativas de la tasa de convergencia, establece algunas situaciones en que métodos de penalización externa poseen convergencia finita. I.e., situaciones en las cuales x^k sea una solución exacta del problema para algún k suficientemente grande. Notemos que como fue probado en el Teorema 4.3.1 (vea (8.36)), la condición (8.46) a seguir siempre es satisfecha si x^k es una solución global del problema penalizado. Puede ser visto que (8.46) también vale si x^k es una solución global del problema penalizado en un conjunto que contiene

a $\bar{x}$ (en vez de todo el espacio). De cualquier manera, la condición (8.46) es natural en el contexto de métodos de penalización. La segunda condición en (8.47) significa la convergencia del método en consideración en relación a las variables del problema. A su vez, estas condiciones (8.46) y (8.47) serán satisfechas, por ejemplo, si $\bar{x}$ es una solución local estricta del problema original (8.23), y $x^k = x(c_k)$ es elegido como fue hecho en la demostración del Teorema 4.3.2.

Teorema 8.5 (Tasa de convergencia de métodos de penalización externa). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función Lipschitz-continua con módulo $N > 0$ en una vecindad U del punto $\bar{x} \in \mathbb{R}^n$, y $D \subset \mathbb{R}^n$ un conjunto cerrado. Sea $\bar{x}$ una solución local del problema (8.23). Supongamos, finalmente, que la función $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$, definida por (8.24), satisfaga la condición (8.45) para algunos $M > 0$ y $\nu > 0$.

Si las secuencias $\{c_k\} \subset \mathbb{R}_+$ y $\{x^k\} \subset \mathbb{R}^n$ son tales que

$$\varphi(x^k; c_k) \leq \varphi(\bar{x}; c_k) = f(\bar{x}) \quad \forall k, \quad (8.46)$$

donde la función $\varphi(\cdot; c_k)$ es definida por (8.31), y

$$\{c_k\} \rightarrow \infty, \quad \{x^k\} \rightarrow \bar{x} \quad (k \rightarrow \infty), \quad (8.47)$$

entonces para todo k suficientemente grande, se tiene que

(a) si $\nu < 1$, entonces

$$0 \leq f(\bar{x}) - f(x^k) \leq \left(\frac{(MN)^{1/\nu}}{c_k} \right)^{\nu/(1-\nu)}, \quad (8.48)$$

$$\text{dist}(x^k, D) \leq M \left(\frac{MN}{c_k} \right)^{\nu/(1-\nu)}; \quad (8.49)$$

(b) si $\nu \geq 1$, entonces

$$f(x^k) = f(\bar{x}), \quad x^k \in D;$$

en particular, si $\bar{x}$ es una solución local estricta del problema (8.23), se tiene que $x^k = \bar{x}$.

Prueba. Utilizando (8.24), (8.45), (8.46), y la segunda relación en (8.47), para todo k suficientemente grande, tenemos que

$$\begin{aligned} f(\bar{x}) &= f(\bar{x}) + c_k \psi(\bar{x}) \\ &= \varphi(\bar{x}; c_k) \\ &\geq \varphi(x^k; c_k) \\ &= f(x^k) + c_k \psi(x^k) \\ &\geq f(x^k) + c_k \left(\frac{\text{dist}(x^k, D)}{M} \right)^{1/\nu}. \end{aligned} \quad (8.50)$$

Para todo k suficientemente grande, sea $\bar{x}^k$ una proyección del punto x^k sobre el conjunto D (cuya existencia se sigue del hecho de que D es cerrado; vea el Teorema 1.3.1). Por la segunda relación en (8.47), como $\bar{x} \in D$, obtenemos que

$$\{\bar{x}^k\} \rightarrow \bar{x} \quad (k \rightarrow \infty).$$

Siendo que $\bar{x}$ es una solución local del problema (8.23), para todo k suficientemente grande, se tiene que

$$f(\bar{x}) - f(x^k) \leq f(\bar{x}^k) - f(x^k) \leq N \text{dist}(x^k, D). \quad (8.51)$$

Combinando (8.50) y (8.51), obtenemos que

$$f(\bar{x}) - f(x^k) \geq c_k \left(\frac{f(\bar{x}) - f(x^k)}{MN} \right)^{1/\nu}. \quad (8.52)$$

Definimos el conjunto

$$J = \{k = 0, 1, \dots \mid f(x^k) \neq f(\bar{x})\}.$$

Las relaciones (8.50) y (8.52) implican que

$$0 \leq (f(\bar{x}) - f(x^k))^{(1-\nu)/\nu} \leq \frac{(MN)^{1/\nu}}{c_k}, \quad (8.53)$$

para todo $k \in J$ suficientemente grande.

La afirmación (a) vale trivialmente para $k \notin J$, y se sigue de (8.53) para $k \in J$ ((8.49) se sigue de (8.48) y (8.50)).

Si $\nu \geq 1$, por la relación (8.47), el lado izquierdo de (8.53) no tiende a cero cuando $k \rightarrow \infty$, en cuanto el lado derecho tiende a cero. Esto implica que el conjunto J no puede ser infinito (pues, caso contrario, (8.53) resulta en una contradicción). Que el conjunto J sea finito significa exactamente que $f(x^k) = f(\bar{x})$ para todo k suficientemente grande. Además de eso, para tales k , $x^k \in D$ vale por (8.50). Esto concluye la prueba del ítem (b). ■

Corolario 8.1. *Bajo las hipótesis del Teorema 4.3.3, sea $\bar{x}$ una solución local estricta del problema (8.23), y sea $\nu \geq 1$. Entonces existe un número $\bar{c} \geq 0$, tal que para todo $c > \bar{c}$ el punto $\bar{x}$ es una solución local estricta del problema (8.30), donde la función objetivo es dada por (8.31).*

Prueba. Supongamos lo contrario, i.e., que existan secuencias $\{c_i\} \subset \mathbb{R}_+$ y $\{x^i\} \subset \mathbb{R}^n$ tales que

$$\varphi(x^i; c_i) \leq \varphi(\bar{x}; c_i), \quad x^i \neq \bar{x} \quad \forall i, \quad (8.54)$$

$$\{c_i\} \rightarrow \infty, \quad \{x^i\} \rightarrow \bar{x} \quad (i \rightarrow \infty). \quad (8.55)$$

Pero la validez simultánea de (8.54) y (8.55) contradice el ítem (b) del Teorema 4.3.3. Luego, vale el resultado anunciado. ■

Notemos que en el caso de la penalización cuadrática para el conjunto factible (8.25) ($p = 2$ en la definición de ψ en (8.28)), las estimativas (8.48) y (8.49) se transforman en

$$0 \leq f(\bar{x}) - f(x^k) \leq \frac{(NM)^2}{c_k},$$

$$\text{dist}(x^k, D) \leq \frac{M^2 N}{c_k}.$$

Por el Teorema 4.3.3, la disminución de valores de grado p lleva a convergencia más rápida de métodos de penalización asociados (recordamos que, bajo las hipótesis del Teorema 1.5.6, tenemos $\nu = 1/p$). Más aún, por el Corolario 4.3.1, para p suficientemente pequeño (más precisamente, para $p \leq 1$), la convergencia es finita en el sentido de que la solución local (estricta) $\bar{x}$ del problema (8.23), (8.25), también es una solución local del problema penalizado (8.30) para todo c suficientemente grande. En otras palabras, si en la aplicación de un método de penalización externa conseguimos el cálculo de soluciones locales adecuadas del problema penalizado (8.30), no habrá necesidad de crecimiento ilimitado del parámetro penalizador. Una penalización con esta propiedad se llama de *penalización exacta*. Ella será considerada con más detalles en § 4.3.2 a seguir.

Sin embargo, notemos que la disminución del valor de grado p empeora la diferenciabilidad de la función $\varphi(\cdot; c)$, lo que torna al problema penalizado más difícil en el sentido computacional. En particular, para $p \leq 1$ el término penalizador (8.27) ya no es diferenciable, mismo para las funciones h y g infinitamente diferenciables. Entre otras cosas, la propia noción de punto estacionario del problema (8.30) tiene que ser repensada. Otra dificultad obvia es que no podemos saber a priori cuál es el valor del parámetro penalizador que torna a la penalización exacta. Algunas técnicas para la elección de parámetros de penalización pueden ser consultadas en [3].

Finalmente, comentamos que métodos de minimización de funciones convexas no diferenciables serán presentados en el Capítulo 5. Además de eso, cabe resaltar que en la práctica computacional moderna, las funciones de penalización exacta típicamente son utilizadas como funciones de mérito para la globalización de métodos locales, y no para la resolución directa de problemas penalizados. Es exactamente así como desarrollaremos la globalización de métodos de programación cuadrática secuencial en § 4.6.

8.2.2. Penalización externa exacta

Consideremos ahora el problema con restricciones mixtas

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0 \end{array} \right\}, \quad (8.56)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones dadas. Elegimos el término penalizador

$$\psi(x) = \sum_{i=1}^l |h_i(x)| + \sum_{i=1}^m \max\{g_i(x), 0\}. \quad (8.57)$$

Observamos que la función ψ así definida no es diferenciable, mismo cuando h y g sean diferenciables. Consideremos la familia de problemas penalizados

$$\min \varphi(x; c), \quad x \in \mathbb{R}^n, \quad (8.58)$$

donde

$$\varphi(\cdot; c) : \mathbb{R}^n \longrightarrow \mathbb{R}, \quad \varphi(x; c) = f(x) + c\psi(x), \quad (8.59)$$

y $c > 0$ es el parámetro penalizador.

Mencionamos que los resultados a ser presentados también son válidos para varias otras formas de penalización no diferenciable. Por ejemplo (vea el Ejercicio 4.3.6),

$$\psi(x) = \max\{|h_1(x)|, \dots, |h_l(x)|, 0, g_1(x), \dots, g_m(x)\}. \quad (8.60)$$

Precisaremos de la siguiente caracterización de la derivada direccional de la función ψ definida por (8.57). (Ver Ejercicio 4.3.5).

Comenzamos con condiciones que son necesarias para que la penalización sea exacta.

Teorema 8.6 (Condiciones necesarias para penalización exacta). Sea $\bar{x} \in \mathbb{R}^n$ una solución local (estricta) del problema penalizado (8.58).

Si $\bar{x} \in D$, entonces $\bar{x}$ es una solución local (estricta) del problema original (8.56).

Si, además de la hipótesis de que $\bar{x} \in D$, las funciones f, h y g son diferenciables en $\bar{x}$, entonces existe un par de multiplicadores de Lagrange $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}^m$ tal que las condiciones de optimalidad de Karush-Kuhn-Tucker (del Teorema 1.2.3(a)) son satisfechas en el punto $\bar{x}$.

Si, además de las hipótesis de arriba, $\bar{x}$ satisface la condición de regularidad de independencia lineal de los gradientes de las restricciones activas (1.17), entonces $c \geq \|(\bar{\lambda}, \bar{\mu})\|_\infty$.

Prueba. Como $\bar{x}$ es un minimizador local del problema (8.58), existe una vecindad U de $\bar{x}$ tal que

$$\varphi(\bar{x}; c) \leq \varphi(x; c) \quad \forall x \in U.$$

Como $\bar{x} \in D$ y tenemos que $\varphi(x; c) = f(x)$ para todo $x \in D$, obtenemos entonces

$$f(\bar{x}) \leq f(x) \quad \forall x \in U \cap D,$$

i.e., $\bar{x}$ es una solución local del problema (8.56). Si $\bar{x}$ es una solución local estricta de (8.58), todas las desigualdades arriba son estrictas. Por lo tanto, en este caso $\bar{x}$ es una solución local estricta de (8.56).

Supongamos ahora que f, h y g sean diferenciables en $\bar{x}$. Por el Ejercicio 4.3.5, la función $\varphi(\cdot; c)$ es diferenciable en $\bar{x}$ en cada dirección $d \in \mathbb{R}^n$. Tenemos que para todo $t > 0$ suficientemente pequeño,

$$\begin{aligned} 0 &\leq \varphi(\bar{x} + td; c) - \varphi(\bar{x}; c) \\ &= t\varphi'((\bar{x}; d); c) + o(t), \end{aligned}$$

donde $\varphi'((\bar{x}; d); c)$ es la derivada direccional de la función $\varphi(\cdot; c)$ en $\bar{x}$ en la dirección d . Dividiendo ambos lados de la relación de arriba por $t > 0$ y pasando al límite cuando $t \rightarrow 0+$, obtenemos que

$$\varphi'((\bar{x}; d); c) \geq 0 \quad \forall d \in \mathbb{R}^n.$$

Como $\bar{x} \in D$ por la hipótesis, de (??) obtenemos que

$$0 \leq \langle f'(\bar{x}), d \rangle + c \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| + c \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\}, \quad (8.61)$$

para todo $d \in \mathbb{R}^n$. En particular, para todo $d \in \mathbb{R}^n$ tal que $\langle h'_i(\bar{x}), d \rangle = 0, i = 1, \dots, l, \langle g'_i(\bar{x}), d \rangle \leq 0, i \in I(\bar{x})$, se tiene que

$$\langle f'(\bar{x}), d \rangle \geq 0.$$

Por lo tanto, $d = 0$ es una solución del problema de programación lineal

$$\min \langle f'(\bar{x}), d \rangle \quad \text{sujeto a} \quad \begin{aligned} \langle h'_i(\bar{x}), d \rangle &= 0, \quad i = 1, \dots, l, \\ \langle g'_i(\bar{x}), d \rangle &\leq 0, \quad i \in I(\bar{x}). \end{aligned} \quad (8.62)$$

Como este problema satisface la condición de regularidad de las restricciones (ya que ellas son lineales), por las condiciones de optimalidad KKT (del Teorema 1.2.3(a)) existen $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^{|I(\bar{x})|}$ tales que, entre otras cosas, vale

$$f'(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i h'_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i g'_i(\bar{x}) = 0. \quad (8.63)$$

Teniendo en cuenta que $\bar{x} \in D$, y definiendo $\bar{\mu}_i = 0$ para todo índice $i \in \{1, \dots, m\} \setminus I(\bar{x})$, de (8.63) obtenemos que $\bar{x}$ satisface las condiciones KKT para el problema (8.56), con multiplicadores $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}^m$.

Supongamos, finalmente, que $\bar{x}$ satisface la condición de independencia lineal de los gradientes de las restricciones activas (1.17). De (8.61) y (8.63), obtenemos que para todo $d \in \mathbb{R}^n$ vale

$$\sum_{i=1}^l \bar{\lambda}_i \langle h'_i(\bar{x}), d \rangle + \sum_{i \in I(\bar{x})} \bar{\mu}_i \langle g'_i(\bar{x}), d \rangle \leq c \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| + c \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\}. \quad (8.64)$$

Por la condición de regularidad (1.17), $\forall (u, v_I) \in \mathbb{R}^l \times \mathbb{R}^{|I(\bar{x})|}$ existe $d \in \mathbb{R}^n$ tal que

$$\begin{pmatrix} h'(\bar{x}) \\ g'_{I(\bar{x})}(\bar{x}) \end{pmatrix} d = \begin{pmatrix} u \\ v_I \end{pmatrix},$$

donde denotamos $I = I(\bar{x})$. O sea,

$$\langle h'_i(\bar{x}), d \rangle = u_i, \quad i = 1, \dots, l, \quad \langle g'_i(\bar{x}), d \rangle = v_i, \quad i \in I.$$

Ahora, tomando $(u, v_I) \in \mathbb{R}^l \times \mathbb{R}^{|I|}$ arbitrario, de (8.64) obtenemos que

$$\begin{aligned} \langle (\bar{\lambda}, \bar{\mu}_I), (u, v_I) \rangle &= \sum_{i=1}^l \bar{\lambda}_i u_i + \sum_{i \in I} \bar{\mu}_i v_i \\ &= \sum_{i=1}^l \bar{\lambda}_i \langle h'_i(\bar{x}), d \rangle + \sum_{i \in I} \bar{\mu}_i \langle g'_i(\bar{x}), d \rangle \\ &\leq c \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| + c \sum_{i \in I} \max\{0, \langle g'_i(\bar{x}), d \rangle\} \\ &= c \sum_{i=1}^l |u_i| + c \sum_{i \in I} \max\{0, v_i\} \\ &\leq c \|u\|_1 + c \sum_{i \in I} |v_i| \\ &= c \|(u, v_I)\|_1, \end{aligned}$$

donde utilizamos el hecho de que $\max\{0, t\} \leq |t|$ para todo $t \in \mathbb{R}$. Por la definición de la norma dual, tenemos que

$$\begin{aligned} \|(\bar{\lambda}, \bar{\mu}_I)\|_\infty &= \sup\{\langle (\bar{\lambda}, \bar{\mu}_I), (u, v_I) \rangle \mid \|(u, v_I)\|_1 = 1\} \\ &= \sup\left\{\langle (\bar{\lambda}, \bar{\mu}_I), \frac{(u, v_I)}{\|(u, v_I)\|_1} \rangle \mid (u, v_I) \in \mathbb{R}^l \times \mathbb{R}^{|I|} \setminus \{0\}\right\} \\ &\leq c. \end{aligned}$$

Teniendo en cuenta que $\|(\bar{\lambda}, \bar{\mu})\|_\infty = \|(\bar{\lambda}, \bar{\mu}_I)\|_\infty$, ya que $\bar{\mu}_i = 0 \forall i \in \{1, \dots, m\} \setminus I$, obtenemos la última afirmación del teorema. ■

Ahora estudiaremos condiciones que son suficientes para que una penalización sea exacta, i.e., condiciones que garanticen que una solución del problema penalizado (8.58) también sea una solución del problema original (8.56). Es conveniente separar el caso de programación convexa (que es más fácil) del caso no convexo. Notemos que en el caso convexo, la función $\varphi(\cdot; c)$ es convexa.

Recordamos que la Lagrangiana del problema (8.56) es dada por

$$\begin{aligned} L : \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m &\longrightarrow \mathbb{R}, \\ L(x, \lambda, \mu) &= f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle. \end{aligned}$$

Primero mostraremos que, bajo ciertas condiciones, el valor de la Lagrangiana proporciona una cota inferior para el valor de la función penalizada.

Proposición 8.2. Para todo $x \in \mathbb{R}^n$ y todo $(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m$, se tiene que

$$L(x, \lambda, \mu) \leq f(x) + \|(\lambda, \mu)\|_\infty \psi(x), \quad (8.65)$$

donde ψ es dada por (8.57).

En particular, si $c \geq \|(\lambda, \mu)\|_\infty$, se tiene que

$$L(x, \lambda, \mu) \leq \varphi(x; c), \quad (8.66)$$

donde φ es dada por (8.59).

Prueba. Para todo $x \in \mathbb{R}^n$, se tiene que

$$\begin{aligned} \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle &\leq \|\lambda\|_\infty \|h(x)\|_1 + \sum_{i=1}^m \mu_i \max\{0, g_i(x)\} \\ &\leq \|\lambda\|_\infty \|h(x)\|_1 + \|\mu\|_\infty \sum_{i=1}^m \max\{0, g_i(x)\} \\ &\leq \|(\lambda, \mu)\|_\infty \psi(x), \end{aligned}$$

donde utilizamos la desigualdad de Cauchy-Schwarz generalizada (??), y el hecho de que $\mu \geq 0$. De aquí, inmediatamente se sigue (8.65). La relación (8.66) es una consecuencia de (8.65), si tenemos que $c \geq \|(\lambda, \mu)\|_\infty$. ■

Consideremos ahora el caso convexo.

Teorema 8.7 (Penalización exacta en el caso convexo). Sean f y g funciones convexas, diferenciables en el punto $\bar{x} \in \mathbb{R}^n$, y sea h una función afín. Supongamos que existan multiplicadores de Lagrange $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}^m$ tales que las condiciones de optimalidad de Karush-Kuhn-Tucker (del Teorema 1.2.3(a)) son satisfechas (luego, $\bar{x}$ es una solución global del problema (8.56)).

Entonces para todo $c \geq \|(\bar{\lambda}, \bar{\mu})\|_\infty$, el punto $\bar{x}$ es una solución (global) del problema (8.58).

Prueba. Como $L(\cdot, \bar{\lambda}, \bar{\mu})$ es una función convexa y $L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$, el punto $\bar{x}$ es un minimizador global de $L(\cdot, \bar{\lambda}, \bar{\mu})$ en $\mathbb{R}^n$, i.e.,

$$L(\bar{x}, \bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu}) \quad \forall x \in \mathbb{R}^n.$$

Teniendo también en cuenta que $\psi(\bar{x}) = 0$, $h(\bar{x}) = 0$ y que $\langle \bar{\mu}, g(\bar{x}) \rangle = 0$, obtenemos que para $c \geq 0$ cualquiera

$$\begin{aligned} \varphi(\bar{x}; c) &= f(\bar{x}) + c\psi(\bar{x}) \\ &= f(\bar{x}) \\ &= f(\bar{x}) + \langle \bar{\lambda}, h(\bar{x}) \rangle + \langle \bar{\mu}, g(\bar{x}) \rangle \\ &= L(\bar{x}, \bar{\lambda}, \bar{\mu}) \\ &\leq L(x, \bar{\lambda}, \bar{\mu}) \quad \forall x \in \mathbb{R}^n. \end{aligned} \quad (8.67)$$

Por otro lado, como $\bar{\mu} \geq 0$ y $c \geq \|(\bar{\lambda}, \bar{\mu})\|_\infty$, de (8.66) tenemos que

$$L(x, \bar{\lambda}, \bar{\mu}) \leq \varphi(x; c) \quad \forall x \in \mathbb{R}^n.$$

Combinando esta desigualdad con (8.67), tenemos

$$\varphi(\bar{x}; c) \leq \varphi(x; c) \quad \forall x \in \mathbb{R}^n,$$

lo que nos dice que $\bar{x}$ es minimizador global de $\varphi(\cdot; c)$ en $\mathbb{R}^n$. ■

Consideremos, finalmente, el caso no convexo, pero en el que una solución satisface la condición suficiente de segunda orden (por lo tanto, ella es estricta).

Teorema 8.8 (Penalización exacta en el caso de la condición suficiente de segunda orden). Sean f , h y g funciones dos veces diferenciables en $\bar{x} \in \mathbb{R}^n$. Supongamos también que existan multiplicadores de Lagrange $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}^m$ tales que la condición suficiente de segunda orden (del Teorema 1.2.3(b)) sea satisfecha (luego, $\bar{x}$ es una solución local estricta del problema (8.56)).

Entonces para todo $c > \|(\bar{\lambda}, \bar{\mu})\|_\infty$, el punto $\bar{x}$ es una solución local estricta del problema (8.58).

Prueba. Supongamos que $\bar{x}$ no sea un minimizador local estricto del problema (8.58), i.e., que exista una secuencia $\{x^k\} \subset \mathbb{R}^n \setminus \{\bar{x}\}$ tal que $\{x^k\} \rightarrow \bar{x}$ ($k \rightarrow \infty$), y, para todo k ,

$$\varphi(x^k; c) \leq \varphi(\bar{x}; c). \quad (8.68)$$

Podemos admitir, sin pérdida de generalidad, que la secuencia limitada $\{(x^k - \bar{x})/\|x^k - \bar{x}\|\}$ converge a $d \in \mathbb{R}^n$, $\|d\| = 1$. Definiendo, para todo k , $d^k = (x^k - \bar{x})/\|x^k - \bar{x}\|$ y $t_k = \|x^k - \bar{x}\|$, tenemos que

$$x^k = \bar{x} + t_k d^k = \bar{x} + t_k d + t_k (d^k - d) = \bar{x} + t_k d + o(t_k).$$

Como es fácil ver, la función $\varphi(\cdot; c)$ es Lipschitz-continua (digamos, con módulo $L > 0$) en una vecindad de $\bar{x}$. Por lo tanto,

$$|\varphi(x^k; c) - \varphi(\bar{x} + t_k d; c)| \leq L \|x^k - \bar{x} - t_k d\| = o(t_k).$$

Obtenemos que

$$\begin{aligned} \varphi'((\bar{x}; d); c) &= \lim_{k \rightarrow \infty} \frac{\varphi(\bar{x} + t_k d; c) - \varphi(\bar{x}; c)}{t_k} \\ &= \lim_{k \rightarrow \infty} \frac{\varphi(x^k; c) - \varphi(\bar{x}; c) + o(t_k)}{t_k} \\ &\leq 0, \end{aligned}$$

donde la desigualdad se sigue de (8.68). Como $\bar{x} \in D$, de (??) obtenemos que

$$\begin{aligned} 0 &\geq \langle f'(\bar{x}), d \rangle + c \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| \\ &\quad + c \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\}. \end{aligned} \quad (8.69)$$

En particular, como los dos últimos términos son no negativos, esto implica que

$$0 \geq \langle f'(\bar{x}), d \rangle. \quad (8.70)$$

Por otro lado, por la condición suficiente de segunda orden (que incluye las condiciones de optimalidad KKT),

$$f'(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i h'_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i g'_i(\bar{x}) = 0.$$

Multiplicando esta relación por d , de (8.69) obtenemos que

$$\begin{aligned} 0 &\geq - \sum_{i=1}^l \bar{\lambda}_i \langle h'_i(\bar{x}), d \rangle - \sum_{i \in I(\bar{x})} \bar{\mu}_i \langle g'_i(\bar{x}), d \rangle \\ &\quad + c \sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| + c \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\} \\ &\geq (c - \|(\bar{\lambda}, \bar{\mu})\|_\infty) \left(\sum_{i=1}^l |\langle h'_i(\bar{x}), d \rangle| + \sum_{i \in I(\bar{x})} \max\{0, \langle g'_i(\bar{x}), d \rangle\} \right), \end{aligned}$$

donde $\bar{\mu} \geq 0$ fue tenido en cuenta. Como $c > \|(\bar{\lambda}, \bar{\mu})\|_\infty$ y todos los términos en el lado derecho de la relación de arriba son no negativos, concluimos que todos ellos tienen que ser nulos. Por lo tanto,

$$\langle h'_i(\bar{x}), d \rangle = 0, \quad i = 1, \dots, l, \quad \langle g'_i(\bar{x}), d \rangle \leq 0, \quad i \in I(\bar{x}).$$

Combinando esto con (8.70), obtenemos que $d \in K(\bar{x})$, i.e., d pertenece al cono crítico del problema (8.56) en el punto $\bar{x}$ (vea ??). Ahora, recordando que $\|d\| = 1$, por la condición suficiente de segunda orden tenemos que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) d, d \rangle \geq \gamma \|d\|^2 = \gamma,$$

donde $\gamma > 0$.

Teniendo en cuenta que $L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$, obtenemos

$$\begin{aligned}
 L(x^k, \bar{\lambda}, \bar{\mu}) &= L(\bar{x}, \bar{\lambda}, \bar{\mu}) + \langle L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}), x^k - \bar{x} \rangle \\
 &\quad + \frac{1}{2} \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^k - \bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|^2) \\
 &= L(\bar{x}, \bar{\lambda}, \bar{\mu}) + \frac{t_k^2}{2} \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d^k, d^k \rangle + o(t_k^2) \\
 &\geq L(\bar{x}, \bar{\lambda}, \bar{\mu}) + \frac{t_k^2}{2} \gamma + o(t_k^2) \\
 &\geq L(\bar{x}, \bar{\lambda}, \bar{\mu}) + \frac{t_k^2}{4} \gamma \\
 &> L(\bar{x}, \bar{\lambda}, \bar{\mu}),
 \end{aligned} \tag{8.71}$$

donde la primera desigualdad vale para todo k suficientemente grande (tal que $o(t_k^2) \geq -\gamma t_k^2/4$).

De (8.68) y (8.71), para todo k suficientemente grande obtenemos

$$\begin{aligned}
 \varphi(x^k; c) &\leq \varphi(\bar{x}; c) \\
 &= f(\bar{x}) \\
 &= L(\bar{x}, \bar{\lambda}, \bar{\mu}) \\
 &< L(x^k, \bar{\lambda}, \bar{\mu}) \\
 &\leq \varphi(x^k; c),
 \end{aligned}$$

donde la última desigualdad se sigue de (8.66). Esta contradicción concluye la demostración. ■

8.2.3. Penalización interna. Métodos de barreras

Los métodos de penalización interna lidian con problemas de la forma

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid g(x) \leq 0\}, \tag{8.72}$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$, y el “interior” del conjunto factible no es vacío:

$$D^0 = \{x \in \mathbb{R}^n \mid g(x) < 0\} \neq \emptyset. \tag{8.73}$$

Supongamos, además, que

$$\inf_{x \in D^0} f(x) = \inf_{x \in D} f(x) = \bar{v} > -\infty, \tag{8.74}$$

i.e., el ínfimo de f en el conjunto D^0 es igual al valor óptimo del problema (8.72). Esta hipótesis tiene por objetivo eliminar ciertos casos patológicos, como aquel en la Figura 4.3.5, donde, evidentemente, la solución $\bar{x}$ no puede ser aproximada por puntos del interior del conjunto factible.

La idea de métodos de penalización interna es la misma que la de penalización externa, en el sentido de que el problema original es aproximado por una secuencia de problemas que pueden ser considerados irrestrictos. Sólo que este objetivo es llevado a cabo de otra manera. En particular, a la función objetivo es agregado un término penalizador que tiende a más infinito para cualquier secuencia que se aproxima a la frontera $D \setminus D^0$ del conjunto factible.

Definición 8.2. Una función $\psi : D^0 \rightarrow \mathbb{R}_+$ se llama *barrera* para el conjunto D definido en (8.72), si ella es continua en D^0 , y para toda secuencia $\{x^k\} \subset D^0$ tal que $g_i(x^k) \rightarrow 0$ para algún $i \in \{1, \dots, m\}$, se tiene que $\psi(x^k) \rightarrow +\infty$ ($k \rightarrow \infty$).

Las elecciones más comunes son la *barrera logarítmica*

$$\psi(x) = -\sum_{i=1}^m \log(-g_i(x)), \quad x \in D^0, \tag{8.75}$$

y la *barrera inversa*

$$\psi(x) = -\sum_{i=1}^m 1/g_i(x), \quad x \in D^0. \tag{8.76}$$

Consideremos una familia de funciones

$$\varphi(\cdot; t) : D^0 \rightarrow \mathbb{R}, \quad \varphi(x; t) = f(x) + t\psi(x), \tag{8.77}$$

donde $t > 0$ es el parámetro penalizador, y los problemas

$$\min \varphi(x; t) \quad \text{sujeto a} \quad x \in D^0. \quad (8.78)$$

Podemos pensar en el problema (8.78) como de optimización irrestricta en el sentido siguiente. Es bien claro que si simplemente ignoramos por completo las restricciones del problema (8.78) (que son desigualdades estrictas) y resolvemos el problema

$$\min \varphi(x; t), \quad x \in \mathbb{R}^n,$$

aplicando cualquier método iterativo razonable a partir de un punto inicial en D^0 , toda la secuencia generada por este método (así como sus puntos de acumulación) va a quedar dentro de D^0 , ya que los puntos cerca de la frontera $D \setminus D^0$ tienen valores de $\varphi(\cdot; t)$ explosivos y, por lo tanto, no son nada atractivos para algoritmos de minimización.

Algoritmo 8.3 (Método de barreras). Elegir una función barrera $\psi : D^0 \rightarrow \mathbb{R}$ para el conjunto D definido en (8.72). Elegir $t_0 > 0$ y tomar $k := 0$.

1. Calcular $x^k \in D^0$ como una solución del problema (8.78), donde la función objetivo es dada por la fórmula (8.77) con $t = t_k$.
2. Elegir $t_{k+1} < t_k$ y tomar $k := k + 1$. Retornar al Paso 1.

Observemos que como las soluciones del problema original típicamente están en la frontera $D \setminus D^0$, queda claro que para la convergencia de métodos de este tipo es necesario que los valores del parámetro t tiendan a cero (para amenizar la influencia explosiva de la barrera ψ y permitir aproximación a soluciones en la frontera del conjunto factible).

Ejemplo 8.4. Consideremos el problema

$$\min x \quad \text{sujeto a} \quad x \geq 0.$$

Este es un problema de programación convexa y su única solución es $\bar{x} = 0$.

Elegiendo la barrera inversa (8.76), tenemos

$$\varphi(x; t) = x + t/x, \quad t > 0.$$

Puntos estacionarios de esta función en el conjunto abierto

$$D^0 = \{x \in \mathbb{R} \mid x > 0\} \neq \emptyset$$

son caracterizados por la ecuación

$$0 = \varphi'(x; t) = 1 - t/x^2,$$

de donde obtenemos

$$x(t) = \sqrt{t} \in D^0.$$

En particular, $x(t) \rightarrow 0 = \bar{x}$ cuando $t \rightarrow 0$.

Ejemplo 8.5. Consideremos el problema

$$\min x_1 + x_2 \quad \text{sujeto a} \quad -x_1^2 + x_2 \geq 0, \quad x_1 \geq 0.$$

Este es un problema de programación convexa y su única solución es $\bar{x} = 0$.

Elegiendo la barrera logarítmica (8.75), tenemos

$$\varphi(x; t) = x_1 + x_2 - t \log(-x_1^2 + x_2) - t \log(x_1).$$

Puntos estacionarios del problema de minimizar esta función en el conjunto abierto

$$D^0 = \{x \in \mathbb{R}^2 \mid -x_1^2 + x_2 > 0, \quad x_1 > 0\} \neq \emptyset$$

son caracterizados por el sistema de ecuaciones

$$0 = \varphi'(x; t) = \begin{pmatrix} 1 + 2tx_1/(-x_1^2 + x_2) - t/x_1 \\ 1 - t/(-x_1^2 + x_2) \end{pmatrix}.$$

De donde obtenemos

$$x_1(t) = (-1 + \sqrt{1 + 8t})/4, \quad x_2(t) = t + ((-1 + \sqrt{1 + 8t})/4)^2.$$

En particular, $x(t) \rightarrow 0 = \bar{x}$ cuando $t \rightarrow 0$. La trayectoria de soluciones de los problemas penalizados es ilustrada en la Figura 4.3.6.

Ahora estudiaremos propiedades de convergencia del Algoritmo 4.3.2. Como en el caso de la penalización externa, los resultados de convergencia para métodos de barreras se refieren a la secuencia generada por minimizadores globales de problemas penalizados.

Proposición 8.3. *Supongamos que el conjunto D definido en (8.72) satisfaga (8.73) y (8.74). Sea $\{x^k\}$ una secuencia generada por el Algoritmo 4.3.2, donde x^k es una solución global del problema (8.78) con $t = t_k$.*

Entonces, para todo k , se tiene que

$$\varphi(x^{k+1}; t_{k+1}) \leq \varphi(x^k; t_k), \quad (8.79)$$

$$\psi(x^{k+1}) \geq \psi(x^k), \quad (8.80)$$

$$f(x^{k+1}) \leq f(x^k). \quad (8.81)$$

Prueba. Por la optimalidad de x^{k+1} en (8.78), $t = t_{k+1}$, tenemos que

$$\begin{aligned} f(x^{k+1}) + t_{k+1}\psi(x^{k+1}) &= \varphi(x^{k+1}; t_{k+1}) \\ &\leq \varphi(x^k; t_{k+1}) \\ &= f(x^k) + t_{k+1}\psi(x^k) \\ &\leq f(x^k) + t_k\psi(x^k) \\ &= \varphi(x^k; t_k), \end{aligned} \quad (8.82)$$

donde la segunda desigualdad se sigue de $t_{k+1} < t_k$ y $\psi(x^k) \geq 0$. Esto muestra, entre otras cosas, la relación (8.79). Por otro lado, de la optimalidad de x^k en (8.78) con $t = t_k$, obtenemos

$$f(x^k) + t_k\psi(x^k) = \varphi(x^k; t_k) \leq \varphi(x^{k+1}; t_k) = f(x^{k+1}) + t_k\psi(x^{k+1}).$$

Sumando esta última desigualdad a la desigualdad (8.82), obtenemos que

$$(t_k - t_{k+1})\psi(x^k) \leq (t_k - t_{k+1})\psi(x^{k+1}).$$

De donde, como $t_{k+1} < t_k$, se sigue (8.80).

Ahora, utilizando de nuevo (8.82), obtenemos

$$f(x^{k+1}) - f(x^k) \leq t_{k+1}(\psi(x^k) - \psi(x^{k+1})) \leq 0,$$

donde la segunda desigualdad se sigue de $t_{k+1} > 0$ y de (8.80). ■

Finalmente, obtenemos el siguiente resultado.

Teorema 8.9 (Convergencia de los métodos de penalización interna). *Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones continuas en $\mathbb{R}^n$. Supongamos que el conjunto D definido en (8.72) satisfaga (8.73) y (8.74).*

Entonces todo punto de acumulación de la secuencia $\{x^k\}$ generada por el Algoritmo 4.3.2, donde x^k es una solución global del problema (8.78) con $t = t_k$ y $t_k \rightarrow 0$ ($k \rightarrow \infty$), es una solución global del problema (8.72).

Prueba. Sea $\bar{x}$ un punto de acumulación de la secuencia $\{x^k\}$. Sea $\{x^{k_j}\} \rightarrow \bar{x}$ ($j \rightarrow \infty$). Como $\{x^k\} \subset D^0$, i.e., $g(x^k) < 0$ para todo k , y g es continua, concluimos que $g(\bar{x}) \leq 0$. O sea, $\bar{x} \in D$.

Si $f(\bar{x}) = \bar{v}$, no hay nada más para probar. Sea $f(\bar{x}) > \bar{v}$. Definimos

$$\delta = (f(\bar{x}) - \bar{v})/2 > 0. \quad (8.83)$$

Por la relación (8.74),

$$\exists \bar{x} \in D^0 \text{ tal que } f(\bar{x}) < \bar{v} + \delta. \quad (8.84)$$

La secuencia $\{f(x^k)\}$ es no creciente (vea (8.81)). Por lo tanto, $\{f(x^{k_j})\}$ también es no creciente y tenemos que

$$f(x^{k_j}) \geq \lim_{j \rightarrow \infty} f(x^{k_j}) = f(\bar{x}) = \bar{v} + 2\delta,$$

donde tuvimos en cuenta la continuidad de f y (8.83). Ahora, utilizando (8.84), obtenemos que

$$f(x^{k_j}) - f(\bar{x}) \geq \bar{v} + 2\delta - f(\bar{x}) > \delta. \quad (8.85)$$

Tenemos entonces que, para j suficientemente grande,

$$\begin{aligned} 0 &\geq \varphi(x^{k_j}; t_{k_j}) - \varphi(\bar{x}; t_{k_j}) \\ &= f(x^{k_j}) + t_{k_j}\psi(x^{k_j}) - f(\bar{x}) - t_{k_j}\psi(\bar{x}) \\ &> \delta + t_{k_j}(\psi(x^{k_j}) - \psi(\bar{x})) \\ &\geq \delta + t_{k_j}(0 - \psi(\bar{x})) \\ &\geq \delta/2 > 0, \end{aligned}$$

donde la primera desigualdad se sigue del hecho de que x^{k_j} es una solución global del problema (8.78) con $t = t_{k_j}$, la tercera de (8.85), la cuarta del hecho de que $\psi(x) \geq 0$, y la última de la suposición de que $t_k \rightarrow 0$ ($k \rightarrow \infty$).

La contradicción de arriba implica en que $f(\bar{x}) = \bar{v}$, lo que concluye la demostración. ■

Podemos considerar también una generalización del Algoritmo 4.3.2, donde no todas las restricciones son penalizadas. Sea el problema

$$\min f(x) \quad \text{sueto a} \quad x \in D = \{x \in \Omega \mid g(x) \leq 0\},$$

donde $\Omega \subset \mathbb{R}^n$ y el conjunto

$$D^0 = \{x \in \Omega \mid g(x) < 0\} \neq \emptyset$$

satisface (8.74). Eligiendo una función barrera ψ para las restricciones de desigualdad, los problemas penalizados (parcialmente, ya que la restricción $x \in \Omega$ no es penalizada) son de la misma forma que (8.78), pero con el conjunto D^0 definido arriba.

Así como fue el caso de penalización externa (diferenciable), los métodos de barreras también sufren del mal condicionamiento de sus subproblemas, en este caso para valores del parámetro penalizador pequeños. Vemos cómo esto acontece en el ejemplo siguiente.

Ejemplo 8.6. Consideremos el problema

$$\min(x_1 + 1)^2 + (x_2 - 1)^2 \quad \text{sueto a} \quad x_1 \geq 0,$$

cuya solución es $\bar{x} = (0, 1)$. Consideremos el caso de la barrera logarítmica, lo que resulta en la minimización de las funciones

$$\varphi(x; t) = (x_1 + 1)^2 + (x_2 - 1)^2 - t \log(x_1).$$

Como es fácil ver, el minimizador de $\varphi(\cdot; t)$ en $\{x \in \mathbb{R}^2 \mid x_1 > 0\}$ es el punto

$$x(t) = ((-1 + \sqrt{1 + 2t})/2, 1).$$

Puede ser visto también que la matriz Hessiana de esta función viene dada por

$$\varphi''(x; t) = \begin{pmatrix} 2 + tx_1^{-2} & 0 \\ 0 & 2 \end{pmatrix},$$

de donde

$$\varphi''(x(t); t) = \begin{pmatrix} 2 + \frac{2t}{1+t-\sqrt{1+2t}} & 0 \\ 0 & 2 \end{pmatrix}.$$

Como

$$\lim_{t \rightarrow 0} \frac{2t}{1+t-\sqrt{1+2t}} = +\infty,$$

vemos que esta matriz queda cada vez peor condicionada, cuando t tiende a cero.

8.3. Métodos para problemas con restricciones de igualdad

A continuación, consideremos problemas con restricciones de igualdad

$$\min f(x) \quad \text{sueto a} \quad x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}, \quad (8.86)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ son funciones diferenciables. Recordamos que, en principio, un problema que posee también restricciones de desigualdad puede ser convertido en un problema de la forma (8.86), vía la introducción de variables auxiliares (“de holgura”); vea [12]. Por lo tanto, todos los métodos presentados a continuación pueden ser empleados también para resolver problemas con restricciones mixtas de igualdad y de desigualdad. Como ya fue visto en [12], este abordaje no siempre es recomendable.

Pero, a veces, ella puede ser útil. Principalmente en los casos en que, utilizando la estructura del método, es posible explícitamente determinar las variables auxiliares vía las originales (en particular, así evitando el aumento artificial de la dimensión del problema). Esta técnica será usada, por ejemplo, en las Secciones 4.5.3 y 4.5.4 para extender el material de la apartado 8.3.2 y de la apartado 8.3.3 a problemas con restricciones mixtas. Métodos desarrollados específicamente para el caso de restricciones mixtas serán presentados en las Secciones 4.5–4.7.

8.3.1. Métodos de Newton para el sistema de Lagrange

Puntos estacionarios del problema (8.86) son caracterizados por el sistema de Lagrange

$$L'(x, \lambda) = 0, \quad (8.87)$$

donde

$$L : \mathbb{R}^n \times \mathbb{R}^l \rightarrow \mathbb{R}, \quad L(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle,$$

es la función de Lagrange del problema en consideración. El sistema (8.87) consiste en $n + l$ ecuaciones con respecto a $n + l$ variables $(x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l$. Por lo tanto, puntos estacionarios y multiplicadores de Lagrange asociados pueden ser encontrados aplicando el método de Newton, considerado en la Sección 3.2.1, lo que resulta en el esquema iterativo

$$(x^{k+1}, \lambda^{k+1}) = (x^k, \lambda^k) - (L''(x^k, \lambda^k))^{-1} L'(x^k, \lambda^k), \quad k = 0, 1, \dots$$

Reescribimos la iteración de Newton, calculando las derivadas involucradas. Sean x^k una aproximación dada a la solución $\bar{x}$ del problema (8.86) y $\lambda^k \in \mathbb{R}^l$ una aproximación al multiplicador de Lagrange asociado a $\bar{x}$. Como

$$L''(x^k, \lambda^k) = \begin{pmatrix} L''_{xx}(x^k, \lambda^k) & (h'(x^k))^T \\ h'(x^k) & 0 \end{pmatrix},$$

las aproximaciones siguientes (x^{k+1}, λ^{k+1}) son soluciones del sistema lineal

$$L''_{xx}(x^k, \lambda^k)(x - x^k) + (h'(x^k))^T(\lambda - \lambda^k) = -f'(x^k) - (h'(x^k))^T \lambda^k, \quad (8.88)$$

$$h'(x^k)(x - x^k) = -h(x^k), \quad (8.89)$$

con respecto a $(x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l$. El método de Newton para el sistema de Lagrange, por lo tanto, consiste en el siguiente procedimiento.

Algoritmo 8.4 (Método de Newton-Lagrange). Elegir $(x^0, \lambda^0) \in \mathbb{R}^n \times \mathbb{R}^l$ y tomar $k := 0$.

1. Calcular $(x^{k+1}, \lambda^{k+1}) \in \mathbb{R}^n \times \mathbb{R}^l$, una solución del sistema (8.88), (8.89).
2. Tomar $k := k + 1$ y volver al Paso 1.

Observemos que la matriz del sistema lineal (8.88), (8.89), es simétrica. Sin embargo, como es fácil ver, ella no puede ser definida positiva (o definida negativa) cuando $l > 0$. En efecto, tomando $\tilde{u} = (\tilde{x}, \tilde{\lambda}) \in \mathbb{R}^n \times \mathbb{R}^l$, con $\tilde{x} = 0$, $\tilde{\lambda} \neq 0$, obtenemos

$$\langle L''(x^k, \lambda^k) \tilde{u}, \tilde{u} \rangle = \langle L''_{xx}(x^k, \lambda^k) \tilde{x}, \tilde{x} \rangle + \langle (h'(x^k))^T \tilde{\lambda}, \tilde{x} \rangle + \langle \tilde{\lambda}, h'(x^k) \tilde{x} \rangle = 0,$$

lo que muestra que $L''(x^k, \lambda^k)$ no es ni definida positiva ni definida negativa, por la propia estructura de esta matriz, independientemente del problema en consideración.

El resultado siguiente proporciona condiciones naturales para que la matriz en cuestión sea no singular. Para la resolución de este sistema pueden ser utilizados tanto métodos del Álgebra Lineal computacional de uso general, como métodos que tienen en cuenta la estructura especial de la matriz que define el sistema.

Teorema 8.10 (Convergencia superlineal del método de Lagrange-Newton). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones dos veces diferenciables en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivadas segundas continuas

en $\bar{x}$. Supongamos que $\bar{x}$ satisfaga la condición de regularidad de las restricciones (1.9), y que este punto sea un punto estacionario del problema (8.86), siendo $\bar{\lambda} \in \mathbb{R}^l$ el (único) multiplicador de Lagrange asociado. Supongamos, finalmente, que la condición suficiente de segunda orden del Teorema 1.2.2 se satisfaga.

Entonces todo punto inicial $(x^0, \lambda^0) \in \mathbb{R}^n \times \mathbb{R}^l$, suficientemente próximo al punto $(\bar{x}, \bar{\lambda})$, define unívocamente una secuencia del Algoritmo 8.4, que converge a $(\bar{x}, \bar{\lambda})$. La tasa de convergencia es superlineal, y si las derivadas segundas de f y h son Lipschitz-continuas en una vecindad de $\bar{x}$, entonces la convergencia es cuadrática.

Prueba. El resultado es una consecuencia directa del Teorema 3.2.1. Basta probar que, bajo las hipótesis especificadas, la matriz

$$L''(\bar{x}, \bar{\lambda}) = \begin{pmatrix} L''_{xx}(\bar{x}, \bar{\lambda}) & (h'(\bar{x}))^\top \\ h'(\bar{x}) & 0 \end{pmatrix}$$

es no singular.

Tomamos $\tilde{u} = (\tilde{x}, \tilde{\lambda}) \in \ker L''(\bar{x}, \bar{\lambda})$ arbitrario. Tenemos que

$$L''_{xx}(\bar{x}, \bar{\lambda})\tilde{x} + (h'(\bar{x}))^\top \tilde{\lambda} = 0, \quad (8.90)$$

$$h'(\bar{x})\tilde{x} = 0. \quad (8.91)$$

Multiplicando ambos lados de (8.90) por $\tilde{x}$ y utilizando (8.91), obtenemos

$$\begin{aligned} 0 &= \langle L''_{xx}(\bar{x}, \bar{\lambda})\tilde{x}, \tilde{x} \rangle + \langle (h'(\bar{x}))^\top \tilde{\lambda}, \tilde{x} \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda})\tilde{x}, \tilde{x} \rangle + \langle \tilde{\lambda}, h'(\bar{x})\tilde{x} \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda})\tilde{x}, \tilde{x} \rangle. \end{aligned}$$

Esto significa que $\tilde{x} = 0$, porque caso contrario la condición suficiente de segunda orden sería violada. Ahora, de (8.90), obtenemos que

$$(h'(\bar{x}))^\top \tilde{\lambda} = 0. \quad (8.92)$$

La condición de regularidad de las restricciones (1.9) es equivalente a $\ker(h'(\bar{x}))^\top = \{0\}$. Luego, (8.92) sólo puede ser satisfecha cuando $\tilde{\lambda} = 0$. Acabamos de mostrar que $\tilde{u} = (\tilde{x}, \tilde{\lambda}) = 0$, i.e., la matriz $L''(\bar{x}, \bar{\lambda})$ es no singular. ■

Notemos que, en general, la convergencia cuadrática de la secuencia primal-dual no implica convergencia superlineal de la secuencia primal (vea el Ejemplo 2.2.1). La cuestión de la convergencia superlineal primal, así como la globalización del método de Newton-Lagrange, serán tratadas más adelante, en el contexto de métodos de programación cuadrática secuencial; vea la Sección 4.6.

Observemos que cuando un punto estacionario satisface la condición de regularidad de las restricciones (1.9) y tenemos una aproximación x^0 suficientemente buena en las variables primales, una buena aproximación λ^0 en las variables duales puede ser obtenida de la manera siguiente. La condición de regularidad implica que $h'(\bar{x})(h'(\bar{x}))^\top$ es una matriz no singular. Por lo tanto, de la condición

$$-f'(\bar{x}) = (h'(\bar{x}))^\top \bar{\lambda},$$

obtenemos

$$-h'(\bar{x})f'(\bar{x}) = h'(\bar{x})(h'(\bar{x}))^\top \bar{\lambda},$$

y luego,

$$\bar{\lambda} = -(h'(\bar{x})(h'(\bar{x}))^\top)^{-1}h'(\bar{x})f'(\bar{x}).$$

Tomando

$$\lambda^0 = -(h'(x^0)(h'(x^0))^\top)^{-1}h'(x^0)f'(x^0),$$

por el teorema de perturbaciones pequeñas de una matriz no singular (vea el Teorema 1.5.1), obtenemos que $\lambda^0 \rightarrow \bar{\lambda}$ cuando $x^0 \rightarrow \bar{x}$. O sea, si x^0 está próximo a $\bar{x}$, entonces el λ^0 especificado arriba está próximo a $\bar{\lambda}$.

Existen métodos, de gran importancia práctica, que en cada iteración k , en vez de la matriz $L''_{xx}(x^k, \lambda^k)$ utilizan la matriz $M_k^\top L''_{xx}(x^k, \lambda^k) M_k$, donde las columnas de $M_k \in \mathbb{R}(n, \dim \ker h'(x^k))$ forman una base del subespacio $\ker h'(x^k)$, que depende de manera continua de x^k . Técnicas de este tipo se llaman *métodos de Hessiana reducida*¹. Los detalles pueden ser consultados en [5].

¹En inglés: *reduced Hessian methods*

Para resolver el sistema de Lagrange (8.87), podemos utilizar no solamente el método de Newton puro, sino también varias modificaciones (vea la Sección 3.2.1 y [3]), además de otras técnicas para la resolución de ecuaciones no lineales [13].

Podemos también intentar resolver el sistema (8.87) aplicando métodos de optimización irrestricta al problema

$$\min \|L'(x, \lambda)\|^2, \quad (x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l. \quad (8.93)$$

Obviamente, soluciones globales de este problema coinciden con soluciones del sistema (8.87) (cuando este último posee soluciones). La deficiencia principal de este abordaje, así como la de otros métodos de resolución directa del sistema de Lagrange, es que estamos ignorando, de cierto modo, la naturaleza del problema original (8.86), que es de minimización. En efecto, es bien claro que el sistema de Lagrange caracteriza tanto minimizadores como maximizadores del problema original, sin preferencia. A continuación, consideramos algunos métodos que son menos afectados por este tipo de deficiencias.

8.3.2. El método de penalización cuadrática

Los métodos de penalización en el contexto general ya fueron considerados en la Sección 4.3. Presentaremos ahora un método específico para el problema con restricciones de igualdad (8.86).

Consideremos una familia de funciones penalizadas, obtenidas sumando f con la función de penalización cuadrática $\|h(\cdot)\|^2/2$, multiplicada por el parámetro de penalización $c \geq 0$:

$$\varphi(\cdot; c) : \mathbb{R}^n \longrightarrow \mathbb{R}, \quad \varphi(x; c) = f(x) + \frac{c}{2} \|h(x)\|^2. \quad (8.94)$$

Notemos que $\varphi(\cdot; c) \equiv f(\cdot)$ en el conjunto factible D ; y que en cualquier punto fuera de D , el valor del término penalizador crece (sin límite) con el crecimiento de c . Por lo tanto, podemos pensar que, en algún sentido, el problema de optimización irrestricta

$$\min \varphi(x; c), \quad x \in \mathbb{R}^n, \quad (8.95)$$

aproxima al problema original (8.86), cuando $c \rightarrow +\infty$. El método de penalización cuadrática para el problema (8.86) consiste en el siguiente procedimiento.

Algoritmo 8.5 (Método de penalización cuadrática). Elegir $c_0 > 0$ y tomar $k := 0$.

1. Calcular $x^k \in \mathbb{R}^n$, un punto estacionario del problema (8.95), donde la función objetivo es definida en (8.94) con $c = c_k$.
2. Elegir $c_{k+1} \geq c_k$, tomar $k := k + 1$ y retornar al Paso 1.

Para encontrar puntos estacionarios del problema (8.95), pueden ser utilizados métodos de optimización irrestricta considerados en el Capítulo 3. Notemos que la función objetivo de (8.95) es tantas veces diferenciable como lo son f y h . En el Algoritmo 8.5, en la iteración k es natural tomar x^{k-1} (punto estacionario de $\varphi(\cdot; c_{k-1})$) como punto inicial en el método utilizado para minimizar $\varphi(\cdot; c_k)$. No obstante, para que tal punto x^{k-1} sea una aproximación buena del punto estacionario de $\varphi(\cdot; c_k)$, el valor de c_k no puede ser muy diferente de c_{k-1} . En otras palabras, el cambio del parámetro de penalización debe ser relativamente lento.

Tenemos el siguiente resultado sobre convergencia del método de penalización cuadrática.

Teorema 8.11 (Convergencia del método de penalización cuadrática). Sean $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ y $h : \mathbb{R}^n \longrightarrow \mathbb{R}^l$ funciones diferenciables en $\mathbb{R}^n$, con derivadas continuas. Sea $\bar{x} \in \mathbb{R}^n$ un punto de acumulación de una secuencia $\{x^k\}$ generada por el Algoritmo 8.5, donde $\{c_k\} \rightarrow +\infty$ ($k \rightarrow \infty$), que satisfaga la condición de regularidad de las restricciones (1.9).

Entonces $\bar{x}$ es un punto estacionario del problema (8.86). Además de eso, para cualquier subsecuencia $\{x^{k_j}\}$ que converge a $\bar{x}$, se tiene que

$$\{c_{k_j} h(x^{k_j})\} \rightarrow \bar{\lambda} \quad (j \rightarrow \infty), \quad (8.96)$$

donde $\bar{\lambda} \in \mathbb{R}^l$ es el (único) multiplicador de Lagrange asociado al punto estacionario $\bar{x}$.

Prueba. Como x^k es un punto estacionario de (8.95),

$$\begin{aligned} 0 &= \varphi'(x^k; c_k) = f'(x^k) + c_k(h'(x^k))^T h(x^k) \\ &= f'(x^k) + (h'(x^k))^T \lambda^k, \end{aligned} \quad (8.97)$$

donde definimos $\lambda^k = c_k h(x^k)$, para todo k . Luego,

$$h'(x^k)f'(x^k) + h'(x^k)(h'(x^k))^T \lambda^k = 0.$$

Por la condición (1.9) de regularidad de las restricciones en $\bar{x}$, y por el teorema de perturbaciones pequeñas de una matriz no singular (Teorema 1.5.1), tenemos que la matriz $h'(x^{k_j})(h'(x^{k_j}))^T$ es no singular para todo j suficientemente grande. Por lo tanto, podemos escribir

$$\lambda^{k_j} = -(h'(x^{k_j})(h'(x^{k_j}))^T)^{-1} h'(x^{k_j})f'(x^{k_j}).$$

De donde, teniendo en cuenta que f y h son diferenciables con derivadas continuas, obtenemos que

$$\{\lambda^{k_j}\} \rightarrow \bar{\lambda} \quad (j \rightarrow \infty), \quad (8.98)$$

donde

$$\bar{\lambda} = -(h'(\bar{x})(h'(\bar{x}))^T)^{-1} h'(\bar{x})f'(\bar{x}).$$

Pasando al límite cuando $j \rightarrow \infty$ en (8.97), obtenemos que

$$0 = f'(\bar{x}) + (h'(\bar{x}))^T \bar{\lambda} = L'_x(\bar{x}, \bar{\lambda}).$$

Además de eso, en vista de que $c_k \rightarrow \infty$ y de que $\{\lambda^{k_j}\}$ es limitada (vea (8.98)), tenemos que

$$h(\bar{x}) = \lim_{j \rightarrow \infty} h(x^{k_j}) = \lim_{j \rightarrow \infty} \lambda^{k_j}/c_{k_j} = 0.$$

Acabamos de mostrar que $\bar{x}$ es un punto estacionario del problema (8.86), y $\bar{\lambda}$ es el multiplicador de Lagrange asociado (que debe ser único en el caso de (1.9)). Finalmente, la relación (8.96) se sigue de (8.98). ■

En general, el problema (8.95) puede no poseer ningún punto estacionario, o poseer varios. El resultado siguiente (que es una consecuencia directa del Teorema 4.3.2) contiene, entre otras cosas, condiciones suficientes para garantizar la existencia de puntos estacionarios en (8.95).

Teorema 8.12. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones continuas en $\mathbb{R}^n$. Sea $\bar{x} \in \mathbb{R}^n$ un minimizador local estricto del problema (8.86).

Entonces existe un número $\delta > 0$ tal que para cualquier solución (global) $x(c)$ del problema

$$\min \varphi(x; c) \quad \text{sujeto a} \quad x \in B(\bar{x}, \delta),$$

donde la función objetivo es dada por (8.94) con $c \geq 0$, se tiene que

$$\|x(c) - \bar{x}\| \rightarrow 0 \quad (c \rightarrow +\infty), \quad (8.99)$$

y en particular, para todo número $c > 0$ suficientemente grande, el punto $x(c)$ es una solución local del problema (8.95).

De acuerdo con el Teorema 8.12, cualquier solución local estricta $\bar{x}$ del problema (8.86) puede ser encontrada como el límite de la secuencia generada por el Algoritmo 8.5, si en este algoritmo los puntos estacionarios del problema (8.95) son elegidos de manera adecuada (cuando hay más de un punto estacionario). Bajo ciertas hipótesis adicionales, puede ser probado que para k suficientemente grande, el problema (8.95), donde la función objetivo es dada por (8.94) con $c = c_k$, posee en una vecindad de $\bar{x}$ un único punto estacionario $x(c_k)$. Más aún, puede ser obtenida una estimativa de la tasa de convergencia de la secuencia $\{x(c_k)\}$ a $\bar{x}$. Si para todo k elegimos como punto inicial en el método de optimización irrestricta un punto suficientemente próximo a $\bar{x}$, podemos esperar que como aproximación siguiente será obtenido justamente $x^k = x(c_k)$. Esto sugiere que la iteración siguiente es bien razonable: cuando llegamos cerca del punto $\bar{x}$ (lo que puede ser esperado, por el Teorema 8.11), esta elección probablemente va a garantizar que los iterandos x^j , $j \geq k$, van a permanecer cerca de $\bar{x}$; o sea, van a coincidir con los $x(c_j)$ (que convergen a $\bar{x}$).

Teorema 8.13 (Estimativa de la tasa de convergencia del método de penalización cuadrática). Supongamos que valen las hipótesis del Teorema 8.10. Entonces existen una vecindad U del punto $\bar{x}$ y números $\bar{c} \geq 0$ y $M > 0$ tales que, para todo $c > \bar{c}$, el problema (8.95) con la función objetivo dada por (8.94) tiene en U un único punto estacionario

$x(c)$. Además de eso, se tiene que

$$\|x(c) - \bar{x}\| \leq M\|\bar{\lambda}\|/c, \quad \|ch(x(c)) - \bar{\lambda}\| \leq M\|\bar{\lambda}\|/c. \quad (8.100)$$

Prueba. Definimos la función

$$\begin{aligned} \Phi : \mathbb{R} \times (\mathbb{R}^n \times \mathbb{R}^l) &\longrightarrow \mathbb{R}^n \times \mathbb{R}^l, \\ \Phi(t, \chi) &= \begin{pmatrix} L'_x(\xi, \eta) \\ h(\xi) - t\eta \end{pmatrix}, \quad \chi = (\xi, \eta). \end{aligned} \quad (8.101)$$

Sea $\bar{\lambda} \in \mathbb{R}^l$ el (único) multiplicador de Lagrange asociado al punto estacionario $\bar{x}$. Definimos $\bar{\chi} = (\bar{x}, \bar{\lambda})$. Entonces $\Phi(0, \bar{\chi}) = 0$ y $\Phi'_\chi(0, \bar{\chi}) = L''(\bar{x}, \bar{\lambda})$, donde la última matriz es no singular (lo que fue verificado, bajo las hipótesis actuales, en la demostración del Teorema 8.10). Aplicando a la función Φ en el punto $(0, \bar{\chi})$ el Teorema de la Función Implícita (Teorema 1.5.3), concluimos que existen un número $\bar{t} > 0$ y una vecindad U del punto $\bar{\chi}$ en $\mathbb{R}^n \times \mathbb{R}^l$ tales que para todo $t \in (-\bar{t}, \bar{t})$, la ecuación

$$\Phi(t, \chi) = 0 \quad (8.102)$$

con respecto a $\chi \in \mathbb{R}^n \times \mathbb{R}^l$ posee en U una única solución $\chi(t) = (\xi(t), \eta(t))$, siendo la función $\chi(\cdot)$ diferenciable en $(-\bar{t}, \bar{t})$ con derivada continua en 0. Además de eso, por el Teorema 1.5.4, tenemos que para alguna constante $M > 0$,

$$\|\chi(t) - \bar{\chi}\| \leq M\|\Phi(t, \bar{\chi})\| = M\|\bar{\lambda}\||t| \quad \forall t \in (-\bar{t}, \bar{t}), \quad (8.103)$$

si $\bar{t}$ es suficientemente pequeño.

Definimos $\bar{c} = 1/\bar{t}$ y $x(c) = \xi(1/c)$, $c > \bar{c}$. Para tal c , de (8.101) obtenemos

$$\begin{aligned} \varphi'(x(c); c) &= f'(x(c)) + c(h'(x(c)))^\top h(x(c)) \\ &= L'_x(\xi(1/c), \eta(1/c)) = 0, \end{aligned}$$

i.e., $x(c)$ es un punto estacionario del problema (8.95). Además de eso, de (8.103) se siguen las estimativas (8.100), ya que por la construcción, $h(\xi(t)) = t\eta(t) \quad \forall t \in (-\bar{t}, \bar{t})$. ■

Finalmente, consideremos secuencias $\{c_i\} \subset \mathbb{R}$ y $\{x^i\} \subset \mathbb{R}^n$ tales que $\{c_i\} \rightarrow \infty$, $\{x^i\} \rightarrow \bar{x}$ ($i \rightarrow \infty$), donde para todo i , el punto x^i es estacionario para el problema (8.95). De (8.101), es fácil ver que, para todo i , $\chi^i = (x^i, c_i h(x^i))$ es una solución de la ecuación (8.102) con $t = 1/c_i$. Además, por el Teorema 8.11,

$$\{c_i h(x^i)\} \rightarrow \bar{\lambda} \quad (i \rightarrow \infty).$$

Por lo tanto, $\chi^i \in U$ para todo i suficientemente grande. Luego, $\chi^i = \chi(1/c_i)$ y, en particular, $x^i = x(c_i)$. Esto prueba que $x(c)$ es el único punto estacionario del problema (8.95) en una vecindad U de $\bar{x}$, para c suficientemente grande.

Como fue mostrado en la demostración arriba, las funciones $\xi(\cdot)$ y $\eta(\cdot)$, definidas en ella, son diferenciables en $(-\bar{t}, \bar{t})$. En particular, la función $x(\cdot)$ es diferenciable en $(\bar{c}, +\infty)$. Además de eso, se sigue de (8.101), que para todo $t \in (-\bar{t}, \bar{t})$ el punto $\xi(t)$ satisface la ecuación

$$tf'(\xi) + (h'(\xi))^\top h(\xi) = 0 \quad (8.104)$$

en relación a $\xi \in \mathbb{R}^n$. Derivando ambos lados de esta ecuación a lo largo de la curva $\xi(\cdot)$, obtenemos que esta trayectoria satisface, en $(-\bar{t}, \bar{t})$, el siguiente sistema de ecuaciones diferenciales:

$$((t-1)f''(\xi) + L''_{xx}(\xi, h(\xi)) + (h'(\xi))^\top h'(\xi))\dot{\xi} + f'(\xi) = 0, \quad (8.105)$$

donde $\dot{\xi}$ denota la derivada de ξ con respecto a t . El mismo resultado puede ser obtenido apelando a la fórmula de la derivada de la función implícita del Teorema 1.5.3.

Lo expuesto arriba motiva una interpretación continua del método de penalización cuadrática. Fijamos un número $t_0 \neq 0$ y encontramos un punto $\xi^0 \in \mathbb{R}^n$ como una solución de la ecuación (8.104) con $t = t_0$. Después, esta solución puede ser continuada (extrapolada) por una técnica, u otra, en relación a t hasta el valor $t = 0$. Por ejemplo, aquí pueden ser utilizados esquemas inexactos para la resolución de ecuaciones diferenciales, agregando a (8.105) la condición inicial

$$\xi(t_0) = \xi^0.$$

Naturalmente, si el par inicial (t_0, ξ^0) está lejos del par $(0, \bar{x})$, donde $\bar{x}$ satisface las hipótesis del Teorema 8.13, una continuación de este tipo no siempre será posible o, cuando sea posible, puede no ser única. Algunos asuntos de técnicas de continuación ya fueron tratados en la Sección 3.3.3.

Como puede ser visto de la estimativa (8.100), para $\bar{\lambda} = 0$ (lo que en el contexto del Teorema 8.13 es equivalente a $f'(\bar{x}) = 0$), se tiene que $x(c) = \xi(1/c) = \bar{x}$ para todo c suficientemente grande. O sea, la penalización cuadrática se vuelve exacta en el sentido siguiente: para un valor c suficientemente grande un punto estacionario $x(c)$ del problema de optimización irrestricta (8.95) (suficientemente próximo a la solución $\bar{x}$ del problema original (8.86)) es exactamente la solución $\bar{x}$. En estas situaciones, hablamos de *penalización exacta*. No obstante, enfatizamos que en el caso de penalización cuadrática, esta propiedad no es común.

Si $\bar{\lambda} \neq 0$, por (8.105), por la condición de regularidad de las restricciones (1.9), y por la definición del multiplicador de Lagrange, tenemos que

$$\|h'(\bar{x})\xi(0)\| = \|\bar{\lambda}\| > 0,$$

i.e., cuando $t \rightarrow 0$ la trayectoria $\xi(\cdot)$ se aproxima a la solución $\bar{x}$ de manera “transversal” al conjunto factible D (en el sentido de que el vector $\xi(0)$, que es tangente a la trayectoria, no pertenece al subespacio $\ker h'(\bar{x})$ que es tangente a D en el punto $\bar{x}$). En este caso, la estimativa (8.100) no puede ser mejorada.

8.3.3. Lagrangianas aumentadas y funciones de penalización exacta diferenciables

Una manera de evitar el crecimiento ilimitado del parámetro de penalización es añadir el término de penalización diferenciable (por ejemplo, cuadrática) a la Lagrangiana del problema (8.86), en vez de a la función objetivo apenas. Así introducimos una familia de *Lagrangianas aumentadas*² del problema (8.86):

$$L(\cdot; c) : \mathbb{R}^n \times \mathbb{R}^l \longrightarrow \mathbb{R},$$

$$\begin{aligned} L(x, \lambda; c) &= L(x, \lambda) + \frac{c}{2} \|h(x)\|^2 \\ &= f(x) + \langle \lambda, h(x) \rangle + \frac{c}{2} \|h(x)\|^2, \end{aligned} \quad (8.106)$$

donde $c \geq 0$ es un parámetro. En particular, entendemos que la Lagrangiana clásica viene dada por $L(x, \lambda; 0) := L(x, \lambda)$.

Observemos que el problema original (8.86) es equivalente al problema

$$\min f(x) + \frac{c}{2} \|h(x)\|^2 \quad \text{sujeto a } x \in D, \quad (8.107)$$

para $c > 0$ cualquiera (basta notar que las funciones objetivo de este problema y del problema original coinciden en el conjunto factible D). Ahora, la Lagrangiana aumentada, dada por (8.106), puede ser considerada como la Lagrangiana clásica del problema modificado (8.107) (que es equivalente al problema original (8.86)).

Otra interpretación es la siguiente. Un punto estacionario $\bar{x}$ del problema (8.86) también es punto estacionario del problema irrestricto

$$\min L(x, \bar{\lambda}), \quad x \in \mathbb{R}^n, \quad (8.108)$$

donde $\bar{\lambda}$ es un multiplicador de Lagrange asociado a $\bar{x}$. En principio, en vez de la resolución del sistema de Lagrange del problema (8.86), podemos intentar encontrar un punto estacionario de (8.108). Es claro que el multiplicador $\bar{\lambda}$ no es conocido a priori. Él puede ser aproximado utilizando información disponible en la aproximación x^k de $\bar{x}$ (vea, por ejemplo, el Ejercicio 4.4.2). Sin embargo, esta estrategia tiene un defecto bastante serio. En particular, la satisfacción de las hipótesis (naturales) del Teorema 8.10 no garantiza que la matriz $L''_{xx}(\bar{x}, \bar{\lambda})$ (que es la matriz Hessiana de la función objetivo en (8.108) en la solución) sea definida positiva. De hecho, aun bajo las hipótesis de regularidad de las restricciones y de la condición suficiente de segunda orden para el problema original, $\bar{x}$ puede ni ser una solución del problema (8.108).

Ejemplo 8.7. Consideremos el problema

$$\min x^3 \quad \text{sujeto a } x + 1 = 0.$$

La solución de este problema es $\bar{x} = -1$, que satisface la condición de regularidad de las restricciones (1.9). La Lagrangiana viene dada por $L(x, \lambda) = x^3 + \lambda(x + 1)$. Como es fácil ver, el multiplicador de Lagrange es $\bar{\lambda} = -3$. No obstante, el punto $\bar{x}$ no es una solución del problema (8.108), porque $L''_{xx}(\bar{x}, \bar{\lambda}) = -6 < 0$ (en particular, la condición necesaria de segunda orden del Teorema 1.2.1(a) está violada).

²En inglés: *augmented Lagrangians*

Observemos que la condición suficiente de segunda orden del Teorema 1.2.2(b) para el problema original está satisfecha (trivialmente), porque $\ker h'(\bar{x}) = \{0\}$.

Por eso, la aplicación (con éxito garantizado) de métodos de optimización irrestricta al problema (8.108) sólo puede ser justificada bajo hipótesis mucho más fuertes (y que no son nada naturales en relación al problema original (8.86)).

En el desarrollo y análisis de algoritmos, la Lagrangiana aumentada puede ser utilizada al lado de la clásica, porque, como puede verse con facilidad, para todo c se tiene que

$$\begin{aligned} L'_x(x, \lambda; c) &= L'_x(x, \lambda) \quad \forall x \in D, \forall \lambda \in \mathbb{R}^l, \\ L'_\lambda(x, \lambda; c) &= L'_\lambda(x, \lambda) = h(x) \quad \forall x \in \mathbb{R}^n, \forall \lambda \in \mathbb{R}^l. \end{aligned}$$

En particular, el conjunto de soluciones de la ecuación

$$L'(x, \lambda; c) = 0,$$

donde la derivada es en relación a (x, λ) , coincide con el conjunto de soluciones del sistema de Lagrange del problema (8.86). Desde el punto de vista algorítmico, la Lagrangiana aumentada posee ciertas ventajas. Una de ellas puede ser vista en el hecho siguiente.

Teorema 8.14. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Sea $\bar{x}$ un punto estacionario del problema (8.86), que satisface la condición suficiente de segunda orden del Teorema 1.2.2(b), con algún multiplicador de Lagrange $\bar{\lambda} \in \mathbb{R}^l$.

Entonces para todo número c suficientemente grande, la matriz

$$L''_{xx}(\bar{x}, \bar{\lambda}; c) = L''_{xx}(\bar{x}, \bar{\lambda}) + c(h'(\bar{x}))^\top h'(\bar{x})$$

es definida positiva. En particular, el punto estacionario $\bar{x}$ del problema

$$\min L(x, \bar{\lambda}; c), \quad x \in \mathbb{R}^n, \quad (8.109)$$

satisface la condición suficiente de segunda orden dada en el Teorema 1.2.1(b) (y, por lo tanto, es una solución local estricta de (8.109)).

Prueba. El hecho de que un punto estacionario $\bar{x}$ del problema (8.86) también es un punto estacionario del problema (8.109) ya fue verificado arriba. Bajo la condición suficiente de segunda orden del Teorema 1.2.2(b), la aplicación directa del Lema 1.5.2 implica que la matriz $L''_{xx}(\bar{x}, \bar{\lambda}; c)$ es definida positiva. ■

Volviendo al Ejercicio 8.22, observemos que

$$L(x, \bar{\lambda}; c) = x^3 - 3(x + 1) + \frac{c}{2}(x + 1)^2,$$

$\bar{x} = -1$ es un punto estacionario del problema (8.109), ya que

$$L'_x(\bar{x}, \bar{\lambda}; c) = 3\bar{x}^2 - 3 = 0,$$

y este punto realmente es una solución de este problema, ya que $L''_{xx}(\bar{x}, \bar{\lambda}; c) = 6\bar{x} + c > 0$ para todo $c > 6$.

Esto motiva el siguiente esquema iterativo, llamado de *método de la Lagrangiana aumentada*³. Cada iteración de este método consiste en la resolución, para un parámetro $c > 0$ y una aproximación λ al multiplicador de Lagrange, del problema de optimización irrestricta

$$\min L(x, \lambda; c), \quad x \in \mathbb{R}^n, \quad (8.110)$$

con la consecuente actualización de λ y de c . El origen de la regla de actualización de λ puede ser explicada, por lo menos parcialmente, por la fórmula (8.96) (recordando, no obstante, que esta fórmula fue obtenida para el método de penalización cuadrática pura y no para la Lagrangiana aumentada), y por el Ejercicio 4.4.6 más adelante. El valor del parámetro c , en principio, puede hasta ser fijo para todas las iteraciones. Es obvio que esta difícilmente puede ser la mejor estrategia. Existen varias reglas de actualización de c bien más eficientes en la práctica. Notemos que, en cualquier caso, para garantizar convergencia, este parámetro no precisa ser ilimitado (diferentemente del caso de la penalización cuadrática).

³En inglés, métodos de este tipo también son llamados de “*methods of multipliers*”

Algoritmo 8.6 (Método de la Lagrangiana aumentada). Elegir $\lambda^0 \in \mathbb{R}^l$ y $c_0 > 0$. Tomar $k := 0$.

1. Calcular $x^k \in \mathbb{R}^n$, un punto estacionario del problema (8.110), donde la función objetivo es dada por la fórmula (8.106) con $c = c_k$ y $\lambda = \lambda^k$.
2. Tomar $\lambda^{k+1} = \lambda^k + c_k h(x^k)$ y elegir $c_{k+1} \geq c_k$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

Varias reglas específicas para la elección de los parámetros c_k pueden ser consultadas, por ejemplo, en [3; 4].

A continuación, comentaremos las propiedades de convergencia del Algoritmo 8.6.

Teorema 8.15 (Convergencia del método de la Lagrangiana aumentada). *Supongamos que valen las hipótesis del Teorema 8.10. Entonces existen una vecindad U de $\bar{x}$ y números $\bar{c} \geq 0$, $\delta > 0$ y $M > 0$, tales que:*

(a) *Para todo par $(\lambda, c) \in \Delta(\bar{c}, \delta)$, donde*

$$\Delta(\bar{c}, \delta) = \{(\lambda, c) \in \mathbb{R}^l \times \mathbb{R} \mid \|\lambda - \bar{\lambda}\| < \delta c, c > \bar{c}\},$$

el problema (8.110) con la función objetivo dada por la fórmula (8.106), tiene en U un único punto estacionario $x(\lambda, c)$ y este punto satisface

$$\begin{aligned} \|x(\lambda, c) - \bar{x}\| &\leq M\|\lambda - \bar{\lambda}\|/c \\ \|\lambda + ch(x(\lambda, c)) - \bar{\lambda}\| &\leq M\|\lambda - \bar{\lambda}\|/c. \end{aligned} \quad (8.111)$$

(b) *Existe un número $\bar{\delta} \in (0, \delta]$ tal que para cualquier secuencia $\{c_k\} \subset \mathbb{R}_+$ no decreciente y cualquier punto $\lambda^0 \in \mathbb{R}^l$ satisfaciendo*

$$(\lambda^0, c_0) \in \Delta(\bar{c}, \bar{\delta}), \quad (8.112)$$

la fórmula

$$\lambda^{k+1} = \lambda^k + c_k h(x(\lambda^k, c_k)), \quad k = 0, 1, \dots,$$

define unívocamente una secuencia $\{\lambda^k\}$ (en el sentido de que $\{(\lambda^k, c_k)\} \subset \Delta(\bar{c}, \delta)$, i.e., para todo k el punto $x(\lambda^k, c_k)$ está bien definido).

Además de eso, $\{\lambda^k\} \rightarrow \bar{\lambda}$, $\{x(\lambda^k, c_k)\} \rightarrow \bar{x}$ ($k \rightarrow \infty$). La tasa de convergencia de la secuencia $\{\lambda^k\}$ es lineal, y si $c_k \rightarrow \infty$ ($k \rightarrow \infty$), ella es superlineal.

La demostración de este resultado necesita de algunas herramientas que nos llevarían fuera del alcance de este libro. Nos vamos a limitar a comentarios generales. Primero, notemos que para $\lambda = 0$, la afirmación (a) coincide con aquella del Teorema 8.13. La demostración del ítem (a) puede seguir la misma línea que en el Teorema 8.13, pero introduciendo algunas consideraciones más sofisticadas en la aplicación directa del Teorema de la Función Implícita. Para probar el ítem (b), la dificultad principal es establecer la existencia de un número $\bar{\delta} \in (0, \delta]$ tal que para todo par (λ^0, c_0) satisfaciendo (8.112), la secuencia $\{(\lambda^k, c_k)\}$ permanece dentro del conjunto $\Delta(\bar{c}, \delta)$. Cuando esto es probado, por (8.111), tenemos que para todo k ,

$$\begin{aligned} \|x(\lambda^k, c_k) - \bar{x}\| &\leq (M/c_k)\|\lambda^k - \bar{\lambda}\| \leq (M/\bar{c})\|\lambda^k - \bar{\lambda}\|, \\ \|\lambda^{k+1} - \bar{\lambda}\| &\leq (M/c_k)\|\lambda^k - \bar{\lambda}\| \leq (M/\bar{c})\|\lambda^k - \bar{\lambda}\|. \end{aligned}$$

Y si $\bar{c}$ es suficientemente grande, la secuencia $\{\lambda^k\}$ converge a $\bar{\lambda}$ con tasa lineal. Cuando $\{c_k\} \rightarrow \infty$ ($k \rightarrow \infty$), la tasa se torna superlineal. Además de eso, la secuencia $\{x(\lambda^k, c_k)\}$ converge a $\bar{x}$, con tasa por lo menos tan rápida como la tasa de convergencia de $\{\lambda^k\}$, i.e., por lo menos con tasa geométrica. La demostración completa puede ser consultada en [3].

Por el Teorema 8.15, si en el Algoritmo 8.6 los valores iniciales c_0 y λ^0 satisfacen la inclusión (8.112), y si x^k se elige como punto estacionario del problema (8.110) que está más próximo a la solución $\bar{x}$ del problema (8.86), entonces la secuencia $\{(x^k, \lambda^k)\}$ generada por el Algoritmo 8.6 está bien definida y converge a $(\bar{x}, \bar{\lambda})$ (la tasa de convergencia ya fue comentada arriba). En relación al cálculo de un punto estacionario adecuado (i.e., próximo a $\bar{x}$), notamos que en la práctica está siendo utilizado el mismo caso del método de penalización cuadrática: para todo $k = 1, 2, \dots$, como punto inicial en el método de optimización irrestricta utilizado para resolver los subproblemas, tomamos el punto x^{k-1} . Con frecuencia, la secuencia $\{x^k\}$ así generada permanece dentro de la vecindad de alguna solución del problema (8.86), y por lo tanto, el método converge a esta solución.

Es importante comentar que, independientemente de qué tan lejos $\lambda^0 \in \mathbb{R}^l$ esté de $\bar{\lambda}$, la condición (8.112) será satisfecha si el número c_0 es suficientemente grande. En otras palabras, una aproximación buena del multiplicador no es importante, si tomamos un valor grande del parámetro de penalización. Sin embargo, grandes parámetros de penalización pueden llevar a problemas numéricos.

Las Lagrangianas aumentadas pueden servir para construir funciones de penalización exacta diferenciables. Estas últimas son obtenidas agregando a la Lagrangiana aumentada términos adicionales, que son diferenciables y que penalizan la violación de condiciones necesarias de optimalidad de primer orden. La función así obtenida es minimizada en el espacio primal-dual. Por ejemplo, consideramos una familia de funciones

$$\begin{aligned}\varphi(\cdot; c_1, c_2) : \mathbb{R}^n \times \mathbb{R}^l &\longrightarrow \mathbb{R}, \\ \varphi(x, \lambda; c_1, c_2) &= L(x, \lambda; c_1) + \frac{c_2}{2} \|L'_x(x, \lambda)\|^2 \\ &= L(x, \lambda) + \frac{c_1}{2} \|h(x)\|^2 + \frac{c_2}{2} \|L'_x(x, \lambda)\|^2.\end{aligned}\quad (8.113)$$

Para $c_1, c_2 > 0$ consideremos el problema

$$\min \varphi(x, \lambda; c_1, c_2), \quad (x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l \quad (8.114)$$

(comparar con (8.93)). Es fácil ver que toda solución del sistema de Lagrange del problema (8.86) es punto estacionario del problema (8.114). Más aún, con una combinación adecuada de los parámetros c_1 y c_2 , tenemos también la afirmación recíproca.

Lema 8.4. Sean $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ y $h : \mathbb{R}^n \longrightarrow \mathbb{R}^l$ funciones dos veces diferenciables en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivadas continuas en este punto. Sea $\text{rank } h'(\bar{x}) = l$.

Entonces para todo $\hat{\lambda} \in \mathbb{R}^l$ existe un número $\bar{c}_2 > 0$ tal que para todo $c_2 \in (0, \bar{c}_2]$, entonces podemos elegir una vecindad U del punto $(\bar{x}, \hat{\lambda})$ y un número $\bar{c}_1(c_2) \geq 0$ de tal manera que para todo $c_1 > \bar{c}_1(c_2)$ el par $(\bar{x}, \bar{\lambda}) \in U$ es un punto estacionario del problema (8.114), donde la función objetivo es dada por la fórmula (8.113), si y solamente si, $\bar{x}$ es un punto estacionario del problema (8.86) y $\bar{\lambda}$ es el multiplicador de Lagrange asociado.

Prueba. Elegimos $\bar{c}_2 > 0$ suficientemente pequeño para garantizar que la matriz $E^n + c_2 L''_{xx}(\hat{x}, \hat{\lambda})$ sea definida positiva $\forall c_2 \in (0, \bar{c}_2]$. Fijamos $c_2 \in (0, \bar{c}_2]$ y elegimos $\bar{c}_1(c_2) \geq 0$ suficientemente grande para garantizar que la matriz

$$\Lambda_{c_1, c_2}(x, \lambda) = \begin{pmatrix} E^n + c_2 L''_{xx}(x, \lambda) & c_1(h'(x))^T \\ c_2 h'(x) & E^l \end{pmatrix} \in \mathbb{R}(l, n)$$

sea definida positiva $\forall c_1 > \bar{c}_1(c_2)$. Si c_1 y c_2 satisfacen estas condiciones, como es fácil verificar, para todo par $(x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l$ suficientemente próximo a $(\hat{x}, \hat{\lambda})$, la matriz $\Lambda_{c_1, c_2}(x, \lambda)$ es no singular (basta mostrar que la matriz $\Lambda_{c_1, c_2}(\hat{x}, \hat{\lambda})$ es no singular y utilizar el teorema de perturbaciones pequeñas de una matriz no singular (??)). Por cálculo directo, obtenemos

$$\varphi'(x, \lambda; c_1, c_2) = \Lambda_{c_1, c_2}(x, \lambda) \begin{pmatrix} L'_x(x, \lambda) \\ h(x) \end{pmatrix}.$$

Por lo tanto, el punto $(\bar{x}, \bar{\lambda})$ suficientemente próximo a $(\hat{x}, \hat{\lambda})$ puede ser estacionario para el problema (8.114) solamente si $(\bar{x}, \bar{\lambda})$ es una solución del sistema de Lagrange del problema (8.86). ■

Teorema 8.16. Supongamos que valen las hipótesis del Teorema 8.10.

- (a) Si f y h son tres veces diferenciables en el punto $\bar{x}$, entonces para todo $c_2 > 0$ existe un número $\bar{c}_1(c_2) \geq 0$, tal que para todo $c_1 > \bar{c}_1(c_2)$ la matriz $\varphi''(\bar{x}, \bar{\lambda}; c_1, c_2)$ es definida positiva, donde la función $\varphi(\cdot; c_1, c_2)$ está dada por la fórmula (8.113). Por lo tanto, el punto estacionario $(\bar{x}, \bar{\lambda})$ del problema (8.114) satisface la condición suficiente de segunda orden del Teorema 1.2.1(b).
- (b) Existe un número $\bar{c}_2 > 0$ tal que, si $c_2 \in (0, \bar{c}_2]$, entonces podemos elegir una vecindad U del punto $(\bar{x}, \bar{\lambda})$ y un número $\bar{c}_1(c_2) \geq 0$ de tal manera que $\forall c_1 > \bar{c}_1(c_2)$ el problema (8.114) tiene en U un único punto estacionario que es $(\bar{x}, \bar{\lambda})$.

Prueba. Para probar el ítem (a), es necesario calcular la derivada segunda de la función $\varphi(\cdot; c_1, c_2)$ en el punto $(\bar{x}, \bar{\lambda})$ y verificar (haciendo cálculo directo) que ella es definida positiva para $c_2 > 0$ cualquiera y c_1 suficientemente grande. El ítem (b) se sigue del Lema 8.4 y del hecho de que la solución $(\bar{x}, \bar{\lambda})$ del sistema de Lagrange del problema (8.86) está aislada. Este último hecho es una consecuencia obvia del Teorema de la Función Implícita (Teorema 1.5.3), utilizando que la matriz $L''(\bar{x}, \bar{\lambda})$ es no singular (lo que ya fue mostrado, bajo las hipótesis actuales, en la demostración del Teorema 8.10). ■

Una desventaja de la función de penalización exacta diferenciable introducida arriba consiste en la necesidad de coordinación entre los parámetros c_1 y c_2 . Esta desventaja puede ser eliminada a costa de la utilización de funciones más complejas. Por ejemplo, fijemos una función $C : \mathbb{R}^n \rightarrow \mathbb{R}(l, n)$ diferenciable y consideremos la familia de funciones

$$\begin{aligned}\varphi(\cdot; c) : \mathbb{R}^n \times \mathbb{R}^l &\rightarrow \mathbb{R}, \\ \varphi(x, \lambda; c) &= L(x, \lambda; c) + \frac{1}{2} \|C(x)L'_x(x, \lambda)\|^2 \\ &= L(x, \lambda) + \frac{c}{2} \|h(x)\|^2 + \frac{1}{2} \|C(x)L'_x(x, \lambda)\|^2.\end{aligned}\quad (8.115)$$

Para $c > 0$, consideremos el problema

$$\min \varphi(x, \lambda; c), \quad (x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l. \quad (8.116)$$

Como fue el caso de la función $\varphi(\cdot; c_1, c_2)$ arriba, toda solución del sistema de Lagrange del problema (8.86) es un punto estacionario del problema (8.116).

Lema 8.5. *Además de las hipótesis del Lema 8.4, supongamos que $C : \mathbb{R}^n \rightarrow \mathbb{R}(l, n)$ sea diferenciable en una vecindad del punto $\hat{x} \in \mathbb{R}^n$, y que en este punto la matriz $C(\hat{x})(h'(\hat{x}))^\top$ sea no singular.*

Entonces para todo $\hat{\lambda} \in \mathbb{R}^l$ existen una vecindad U del punto $(\hat{x}, \hat{\lambda})$ y un número $\bar{c} \geq 0$ tales que $\forall c > \bar{c}$ el par $(\bar{x}, \bar{\lambda}) \in U$ es un punto estacionario del problema (8.116), donde la función objetivo es dada por la fórmula (8.115), si, y solamente si, $\bar{x}$ es un punto estacionario del problema (8.86) y $\bar{\lambda}$ es el multiplicador de Lagrange asociado.

Prueba. La demostración es similar a la del Lema 8.4. Basta mostrar que para todo c suficientemente grande la matriz

$$\Lambda_c(\hat{x}, \hat{\lambda}) = \begin{pmatrix} E^n + A(\hat{x}, \hat{\lambda})C(\hat{x}) & c(h'(\hat{x}))^\top \\ h'(\hat{x})(C(\hat{x}))^\top C(\hat{x}) & E^l \end{pmatrix} \in \mathbb{R}(l, n)$$

es no singular, donde

$$A(\hat{x}, \hat{\lambda}) = \left((C(x)L'_x(x, \hat{\lambda}))' \Big|_{x=\hat{x}} \right)^\top \in \mathbb{R}(n, l).$$

Consideremos $\tilde{u} = (\tilde{x}, \tilde{\lambda}) \in \ker \Lambda_c(\hat{x}, \hat{\lambda})$ arbitrario. Tenemos que

$$\begin{aligned}(E^n + A(\hat{x}, \hat{\lambda})C(\hat{x}))\tilde{x} + c(h'(\hat{x}))^\top \tilde{\lambda} &= 0, \\ h'(\hat{x})(C(\hat{x}))^\top C(\hat{x})\tilde{x} + \tilde{\lambda} &= 0.\end{aligned}\quad (8.117)$$

Por la última ecuación,

$$C(\hat{x})\tilde{x} = -(h'(\hat{x})(C(\hat{x}))^\top)^{-1} \tilde{\lambda}. \quad (8.118)$$

De (8.117), ahora obtenemos

$$\begin{aligned}& \left(-(E^l + C(\hat{x})A(\hat{x}, \hat{\lambda})C(\hat{x}))(h'(\hat{x})(C(\hat{x}))^\top)^{-1} \right. \\ & \quad \left. + cC(\hat{x})(h'(\hat{x}))^\top \right) \tilde{\lambda} \\ &= C(\hat{x})(\tilde{x} + A(\hat{x}, \hat{\lambda})C(\hat{x})\tilde{x} + c(h'(\hat{x}))^\top \tilde{\lambda}) = 0.\end{aligned}$$

Elegimos $\bar{c} \geq 0$ suficientemente grande para garantizar que la matriz en el lado izquierdo de la última ecuación sea no singular $\forall c > \bar{c}$. Para tales c tenemos que $\tilde{\lambda} = 0$. Entonces, por (8.118), tenemos que $C(\hat{x})\tilde{x} = 0$. De (8.117) ahora obtenemos que $\tilde{x} = 0$. Concluimos que $\tilde{u} = 0$, finalizando así la demostración. ■

Teorema 8.17. *Bajo las hipótesis del Teorema 8.10, supongamos que $C : \mathbb{R}^n \rightarrow \mathbb{R}(l, n)$ sea diferenciable en una vecindad del punto $\bar{x}$, con derivada continua en este punto. Supongamos que la matriz $C(\bar{x})(h'(\bar{x}))^\top$ sea no singular.*

Entonces existen una vecindad U del punto $(\bar{x}, \bar{\lambda})$ y un número $\bar{c} \geq 0$ tales que para todo $c > \bar{c}$, el problema (8.116), donde la función objetivo es dada por la fórmula (8.115), tiene en U un único punto estacionario que es $(\bar{x}, \bar{\lambda})$. Además de eso, si f y h son tres veces diferenciables en el punto $\bar{x}$, entonces la matriz $\varphi''(\bar{x}, \bar{\lambda}; c)$ es definida positiva. Por lo tanto, el punto estacionario $(\bar{x}, \bar{\lambda})$ satisface la condición suficiente de segunda orden del Teorema 1.2.1(b).

8.4. Métodos para problemas con restricciones mixtas

A continuación, consideremos el problema con restricciones mixtas de igualdad y desigualdad. Como fue mencionado en la ??, el sistema de optimalidad de Karush-Kuhn-Tucker (KKT) para este problema puede ser escrito en la forma

de un sistema de ecuaciones no-lineales, pero en general no-diferenciables. Primero, serán presentados métodos de Newton generalizados para sistemas de ecuaciones no-diferenciables generales (no necesariamente ligados a optimización). Después de eso, consideraremos métodos específicos para resolver reformulaciones no-diferenciables de sistemas KKT.

8.4.1. Métodos de Newton generalizados

Consideremos una función $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$, no necesariamente diferenciable, y la ecuación

$$\Phi(x) = 0 \quad (8.119)$$

asociada. Una extensión natural del método de Newton viene dada por el esquema iterativo

$$x^{k+1} = x^k - H_k^{-1}\Phi(x^k), \quad k = 0, 1, \dots, \quad (8.120)$$

donde $H_k \in \partial\Phi(x^k)$ o $H_k \in \partial_B\Phi(x^k)$, i.e., en vez de la derivada clásica está siendo utilizado el subdiferencial de Clarke o el subdiferencial de Bouligand (vea la ??). Así, obtenemos el método de Newton generalizado.

Algoritmo 8.7 (El método de Newton generalizado). Elegir la versión B o C del método. Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular una matriz $H_k \in \partial_B\Phi(x^k)$ en el caso de la versión B, o $H_k \in \partial\Phi(x^k)$ en el caso de la versión C. Calcular $x^{k+1} \in \mathbb{R}^n$, una solución del sistema de ecuaciones lineales

$$H_k(x - x^k) = -\Phi(x^k),$$

con respecto a $x \in \mathbb{R}^n$.

2. Tomar $k := k + 1$ y retornar al Paso 1.

Las condiciones de regularidad que utilizaremos para probar la convergencia del método de Newton generalizado son las siguientes. La función $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ se llama BD-regular (CD-regular) en el punto $\bar{x} \in \mathbb{R}^n$, si todas las matrices $H \in \partial_B\Phi(\bar{x})$ ($H \in \partial\Phi(\bar{x})$) son no-singulares.

Teorema 8.18 (Convergencia del método de Newton generalizado). Sea $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ una función Lipschitz-continua en una vecindad del punto $\bar{x} \in \mathbb{R}^n$ que satisface en este punto la condición de Kummer (?). Sea $\bar{x}$ una solución de (8.119), tal que Φ es BD-regular en $\bar{x}$ en el caso de la versión B del Algoritmo 8.7, y CD-regular en el caso de la versión C.

Entonces para cualquier punto inicial $x^0 \in \mathbb{R}^n$ suficientemente próximo a $\bar{x}$, el Algoritmo 8.7 genera una secuencia bien definida que converge a $\bar{x}$. La tasa de convergencia es superlineal y, si Φ satisface en $\bar{x}$ la condición de Kummer fuerte (?), la tasa es cuadrática.

Prueba. La demostración es bastante similar a aquella para el método de Newton clásico (?). Por eso, presentaremos solo los pasos principales. Consideremos la versión B del algoritmo (la prueba para la versión C es análoga).

Por el resultado del ??, por las definiciones de B-diferencial y diferencial de Clarke, utilizando el teorema de perturbaciones pequeñas de una matriz no singular y un razonamiento por absurdo, obtenemos que existen una vecindad U del punto $\bar{x}$ y un número $M > 0$ tales que

$$\det H \neq 0, \quad \|H^{-1}\| \leq M \quad \forall H \in \partial_B\Phi(x), \quad \forall x \in U. \quad (8.121)$$

En particular, la iteración del Algoritmo 8.7 está bien definida para cualquier $x^k \in U$. Ahora, por (8.120), (8.121), y la condición de Kummer en $\bar{x}$, podemos tomar la vecindad U tal que, si $x^k \in U$ y $H_k \in \partial_B\Phi(x^k)$, entonces

$$\begin{aligned} \|x^{k+1} - \bar{x}\| &= \|x^k - \bar{x} - H_k^{-1}\Phi(x^k)\| \\ &\leq \|H_k^{-1}\| \|\Phi(x^k) - \Phi(\bar{x}) - H_k(x^k - \bar{x})\| \\ &= o(\|x^k - \bar{x}\|). \end{aligned} \quad (8.122)$$

De aquí se sigue que, primero, para cualquier punto inicial x^0 suficientemente próximo a $\bar{x}$, el Algoritmo 8.7 genera una secuencia bien definida y, en segundo lugar, que esta secuencia converge a $\bar{x}$ con tasa superlineal. Finalmente, si en $\bar{x}$ vale la condición de Kummer fuerte, la estimativa (8.122) se transforma en

$$\|x^{k+1} - \bar{x}\| = O(\|x^k - \bar{x}\|^2),$$

i.e., la convergencia es cuadrática. ■

8.4.2. Métodos de Newton generalizados para el sistema de Karush-Kuhn-Tucker

Consideremos el problema

$$\min f(x) \quad \text{sujeto a } x \in D = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0 \end{array} \right\}, \quad (8.123)$$

donde $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones diferenciables. Puntos estacionarios de este problema se caracterizan por el sistema KKT

$$L'_x(x, \lambda, \mu) = 0, \quad h(x) = 0, \quad (8.124)$$

$$g_i(x) \leq 0, \quad \mu_i \geq 0, \quad \mu_i g_i(x) = 0, \quad i = 1, \dots, m, \quad (8.125)$$

donde

$$L: \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R},$$

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle,$$

es la función de Lagrange del problema.

Sea $(\bar{x}, \bar{\lambda}, \bar{\mu})$ una solución del sistema (8.124)-(8.125). Sea, como siempre, $I(\bar{x}) = \{i = 1, \dots, m \mid g_i(\bar{x}) = 0\}$ el conjunto de las restricciones activas en el punto $\bar{x}$. Bajo la condición de complementariedad estricta, i.e.,

$$\bar{\mu}_i > 0 \quad \forall i \in I(\bar{x}),$$

es muy fácil ver que, alrededor del punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$, las relaciones (8.125) son equivalentes al sistema de ecuaciones

$$\mu_i = 0, \quad i \in \{1, \dots, m\} \setminus I(\bar{x}), \quad g_i(x) = 0, \quad i \in I(\bar{x}). \quad (8.126)$$

Por lo tanto, en este caso, el sistema KKT (8.124)-(8.125) es localmente equivalente al sistema (8.124), (8.126) de $n+l+m$ ecuaciones con respecto a las variables $(x, \lambda, \mu) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$. Si f, h y g son dos veces diferenciables, este último sistema puede ser resuelto por el método de Newton clásico, como fue hecho en la ?? en el caso de problemas con restricciones de igualdad (cuando no hay restricciones de desigualdad). Naturalmente, la aplicación práctica del método de Newton clásico está limitada por el hecho de que el conjunto $I(\bar{x})$ no es conocido a priori.

Aquí, presentaremos métodos de solución del sistema KKT que no precisan ni de la condición de complementariedad estricta, ni de la identificación del conjunto $I(\bar{x})$. Cabe mencionar que cuando hay complementariedad estricta, las iteraciones de estos métodos son localmente equivalentes a las iteraciones del método de Newton clásico para el sistema (8.124), (8.126). De hecho, esto es completamente natural y hasta deseable: en cierto sentido se puede afirmar que cualquier método Newtoniano debe ser equivalente al método de Newton clásico para el sistema (8.124), (8.126), cuando este sistema es equivalente al sistema KKT del problema original.

La idea es reformular las relaciones en (8.125) en un sistema de ecuaciones que no contiene elementos o parámetros a priori desconocidos. Pero es claro que la ventaja de lidiar con ecuaciones (en vez de ecuaciones e inecuaciones, lo que siempre es más complicado) tiene un precio a pagar. En este contexto, el precio consiste o en la pérdida de diferenciabilidad, o en la inevitable singularidad de una solución, como veremos a continuación. En cierto sentido, la primera dificultad no es tan grave, y actualmente es considerada preferible a la segunda.

Recordamos que una función $\psi: \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$ se llama función de complementariedad, si el conjunto de soluciones de la ecuación

$$\psi(a, b) = 0$$

coincide con el conjunto de soluciones del sistema

$$a \geq 0, \quad b \geq 0, \quad ab = 0.$$

Como ya mencionamos en la ??, entre las funciones de complementariedad más populares están el residuo natural

$$\psi(a, b) = \min\{a, b\}, \quad a, b \in \mathbb{R}, \quad (8.127)$$

y la función de Fischer-Burmeister

$$\psi(a, b) = \sqrt{a^2 + b^2} - a - b, \quad a, b \in \mathbb{R}. \quad (8.128)$$

Por lo expuesto anteriormente, eligiendo una función de complementariedad ψ , el sistema KKT del problema (8.123) puede ser escrito como el sistema de ecuaciones

$$\Phi(x, \lambda, \mu) = 0, \quad (8.129)$$

donde

$$\Phi: \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m, \quad \Phi(x, \lambda, \mu) = \begin{pmatrix} L'_x(x, \lambda, \mu) \\ h(x) \\ \psi(\mu_1, -g_1(x)) \\ \vdots \\ \psi(\mu_m, -g_m(x)) \end{pmatrix}. \quad (8.130)$$

Por el Teorema 8.18, para justificar la aplicación del método de Newton generalizado a la ecuación (8.129), es suficiente encontrar condiciones que garanticen semi-diferenciabilidad (fuerte) de la función Φ y CD-regularidad (o BD-regularidad) de esta función en la solución de (8.129).

Proposición 8.4 (Semi-diferenciabilidad de las reformulaciones del sistema KKT). Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en $\mathbb{R}^n$, con derivadas semi-diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Entonces para todo $\lambda \in \mathbb{R}^l$ y $\mu \in \mathbb{R}^m$, la función Φ dada por (8.130), donde la función ψ es dada por (8.127) o por (8.128), es semi-diferenciable en el punto $(\bar{x}, \lambda, \mu)$. Si f, h y g son dos veces diferenciables en una vecindad de $\bar{x}$, con derivadas segundas Lipschitz-continuas en esta vecindad, entonces Φ es fuertemente semi-diferenciable en $(\bar{x}, \lambda, \mu)$.

Ahora probaremos un resultado que garantiza la regularidad de las soluciones de la reformulación no-diferenciable del sistema KKT en el caso de la función de complementariedad del residuo natural (8.127).

Proposición 8.5 (Regularidad de la reformulación del sistema KKT en el caso del residuo natural). Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en $\mathbb{R}^n$, dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$ con derivadas primeras Lipschitz-continuas en una vecindad de $\bar{x}$. Supongamos que $\bar{x}$ satisface la condición de independencia lineal de los gradientes de las restricciones activas (??), y que $\bar{x}$ sea un punto estacionario del problema (8.123), con (únicos) multiplicadores de Lagrange asociados $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$. Finalmente, supongamos que vale la condición suficiente de segunda orden fuerte, i.e., que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle > 0 \quad \forall d \in \mathcal{K}_+(\bar{x}) \setminus \{0\}, \quad (8.131)$$

donde

$$\mathcal{K}_+(\bar{x}) = \{d \in \ker h'(\bar{x}) \mid \langle g'_i(\bar{x}), d \rangle = 0 \quad \forall i \in I_+(\bar{x})\},$$

$$I_+(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i > 0\}.$$

Entonces la función Φ definida en (8.130), con ψ dada por (8.127), es CD-regular (luego, también BD-regular) en el punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$.

Prueba. Para cualquier matriz $H \in \partial\Phi(\bar{x}, \bar{\lambda}, \bar{\mu})$, vale la representación siguiente (es posible que las últimas m componentes de la función Φ tengan que ser reindexadas para obtener esta representación, lo que puede ser hecho en este contexto sin cambiar las propiedades del problema): existe un conjunto de índices $J_0 \subset I_0(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i = 0\}$ tal que, definiendo $J_+ = I(\bar{x}) \setminus J_0$ y $J_- = \{1, \dots, m\} \setminus I(\bar{x})$, se tiene que

$$H = \begin{pmatrix} L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) & (h'(\bar{x}))^\top & (g'_{J_+}(\bar{x}))^\top & (g'_{J_0}(\bar{x}))^\top & (g'_{J_-}(\bar{x}))^\top \\ h'(\bar{x}) & 0 & 0 & 0 & 0 \\ -g'_{J_+}(\bar{x}) & 0 & 0 & 0 & 0 \\ -Ag'_{J_0}(\bar{x}) & 0 & 0 & E_{J_0} - A & 0 \\ 0 & 0 & 0 & 0 & E_{J_-} \end{pmatrix},$$

donde A es la matriz diagonal $|J_0| \times |J_0|$ con elementos $a_i \in [0, 1]$, $i = 1, \dots, |J_0|$; para el conjunto de índices $J \subset \{1, \dots, m\}$, E_J es la matriz identidad $|J| \times |J|$; $g'_J(\bar{x})$ es la matriz compuesta por las filas de la matriz $g'(\bar{x})$ con índices en J .

Tomamos cualquier $\tilde{u} = (\tilde{x}, \tilde{\lambda}, \tilde{\mu}^+, \tilde{\mu}^0, \tilde{\mu}^-) \in \ker H$, donde $\tilde{x} \in \mathbb{R}^n$, $\tilde{\lambda} \in \mathbb{R}^l$, $\tilde{\mu}^+ \in \mathbb{R}^{|J_+|}$, $\tilde{\mu}^0 \in \mathbb{R}^{|J_0|}$, $\tilde{\mu}^- \in \mathbb{R}^{|J_-|}$. Tenemos entonces que

$$L''_{xx}(\tilde{x}, \tilde{\lambda}, \tilde{\mu})\tilde{x} + (h'(\tilde{x}))^\top \tilde{\lambda} + (g'_{J_+}(\tilde{x}))^\top \tilde{\mu}^+ + (g'_{J_0}(\tilde{x}))^\top \tilde{\mu}^0 + (g'_{J_-}(\tilde{x}))^\top \tilde{\mu}^- = 0, \quad (8.132)$$

$$h'(\tilde{x})\tilde{x} = 0, \quad (8.133)$$

$$\langle g'_i(\tilde{x}), \tilde{x} \rangle = 0, \quad i \in J_+, \quad (8.134)$$

$$-a_i \langle g'_i(\tilde{x}), \tilde{x} \rangle + (1 - a_i)\tilde{\mu}_i^0 = 0, \quad i \in J_0, \quad (8.135)$$

$$\tilde{\mu}^- = 0. \quad (8.136)$$

Como $I_+(\tilde{x}) = I(\tilde{x}) \setminus I_0(\tilde{x}) \subset I(\tilde{x}) \setminus J_0 = J_+$, de (8.133) y (8.134) obtenemos que $\tilde{x} \in \mathcal{K}_+(\tilde{x})$. Multiplicando ambos lados de (8.132) por $\tilde{x}$ y utilizando (8.133)-(8.136), obtenemos que

$$\langle L''_{xx}(\tilde{x}, \tilde{\lambda}, \tilde{\mu})\tilde{x}, \tilde{x} \rangle + \sum_{i \in J_0} \tilde{\mu}_i^0 \langle g'_i(\tilde{x}), \tilde{x} \rangle = 0. \quad (8.137)$$

Ahora, multiplicando (8.135) por $\tilde{\mu}_i^0$, para todo $i \in J_0$ tenemos que

$$a_i \tilde{\mu}_i^0 \langle g'_i(\tilde{x}), \tilde{x} \rangle = (1 - a_i)(\tilde{\mu}_i^0)^2.$$

Como $a_i \in [0, 1]$, se sigue que $\tilde{\mu}_i^0 \langle g'_i(\tilde{x}), \tilde{x} \rangle \geq 0 \forall i \in J_0$. Ahora, de (8.137), tenemos

$$\langle L''_{xx}(\tilde{x}, \tilde{\lambda}, \tilde{\mu})\tilde{x}, \tilde{x} \rangle \leq 0,$$

donde $\tilde{x} \in \mathcal{K}_+(\tilde{x})$. De (8.131) concluimos que $\tilde{x} = 0$. Además, utilizando (8.136), de (8.132) obtenemos que

$$(h'(\tilde{x}))^\top \tilde{\lambda} + (g'_{J_+}(\tilde{x}))^\top \tilde{\mu}^+ + (g'_{J_0}(\tilde{x}))^\top \tilde{\mu}^0 = 0,$$

donde $J_+ \cup J_0 = I(\tilde{x})$. De esta relación y de la condición de independencia lineal de los gradientes de las restricciones activas en $\tilde{x}$, se sigue que $\tilde{\lambda} = 0$, $\tilde{\mu}^+ = 0$, $\tilde{\mu}^0 = 0$, i.e., $\tilde{u} = 0$. Acabamos de mostrar que para todo $H \in \partial\Phi(\tilde{x}, \tilde{\lambda}, \tilde{\mu})$, se tiene que $\ker H = \{0\}$. ■

Consideremos ahora el caso de la función de complementariedad de Fischer-Burmeister (8.128).

Proposición 8.6 (Regularidad de la reformulación del sistema KKT en el caso de la función de Fischer-Burmeister). *Bajo las hipótesis de la Proposición 8.5, la función Φ definida por (8.130), con la función ψ dada en (8.128), es CD-regular (luego, también BD-regular) en el punto $(\tilde{x}, \tilde{\lambda}, \tilde{\mu})$.*

Prueba. Para una matriz $H \in \partial\Phi(\tilde{x}, \tilde{\lambda}, \tilde{\mu})$ cualquiera, por el Ejercicio 8.36 tenemos que

$$H = \begin{pmatrix} L''_{xx}(\tilde{x}, \tilde{\lambda}, \tilde{\mu}) & (h'(\tilde{x}))^\top & (g'(\tilde{x}))^\top \\ h'(\tilde{x}) & 0 & 0 \\ A(\tilde{x}, \tilde{\mu})g'(\tilde{x}) & 0 & B(\tilde{x}, \tilde{\mu}) \end{pmatrix}, \quad (8.138)$$

donde $A(\tilde{x}, \tilde{\mu})$ y $B(\tilde{x}, \tilde{\mu})$ son matrices diagonales $m \times m$ con elementos $a_i = a_i(\tilde{x}, \tilde{\mu})$ y $b_i = b_i(\tilde{x}, \tilde{\mu})$, $i = 1, \dots, m$.

Para $\tilde{u} = (\tilde{x}, \tilde{\lambda}, \tilde{\mu}) \in \ker H$ cualquiera, tenemos que

$$L''_{xx}(\tilde{x}, \tilde{\lambda}, \tilde{\mu})\tilde{x} + (h'(\tilde{x}))^\top \tilde{\lambda} + (g'(\tilde{x}))^\top \tilde{\mu} = 0, \quad (8.139)$$

$$h'(\tilde{x})\tilde{x} = 0, \quad (8.140)$$

$$a_i \langle g'_i(\tilde{x}), \tilde{x} \rangle + b_i \tilde{\mu}_i = 0, \quad i = 1, \dots, m. \quad (8.141)$$

Notemos que para $i \in I_+(\tilde{x})$ tenemos que $a_i = 1$, $b_i = 0$. Por lo tanto, de (8.141) se sigue que

$$\langle g'_i(\tilde{x}), \tilde{x} \rangle = 0 \quad \forall i \in I_+(\tilde{x}). \quad (8.142)$$

En particular, de (8.140) y (8.142) obtenemos que $\tilde{x} \in \mathcal{K}_+(\tilde{x})$.

Para $i \in \{1, \dots, m\} \setminus I(\tilde{x})$ se tiene $a_i = 0$, $b_i = -1$, y para $i \in I_0(\tilde{x})$ se tiene que $a_i \geq 1$, $b_i \leq 0$. Por tanto, de (8.141) obtenemos

$$\tilde{\mu}_i = 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\tilde{x}), \quad (8.143)$$

$$\tilde{\mu}_i \langle g'_i(\tilde{x}), \tilde{x} \rangle \geq 0 \quad \forall i \in I_0(\tilde{x}). \quad (8.144)$$

Multiplicando ambos lados de (8.139) por $\tilde{x}$ y utilizando (8.140), (8.142) y (8.143), obtenemos que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\tilde{x}, \tilde{x} \rangle + \sum_{i \in I_0(\bar{x})} \tilde{\mu}_i \langle g'_i(\bar{x}), \tilde{x} \rangle = 0.$$

Teniendo en cuenta (8.145), tenemos que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\tilde{x}, \tilde{x} \rangle \leq 0,$$

y como $\tilde{x} \in \mathcal{H}_+(\bar{x})$, de (8.131) se sigue que $\tilde{x} = 0$. A continuación, utilizando (8.143), de (8.139) obtenemos que

$$(h'(\bar{x}))^\top \tilde{\lambda} + \sum_{i \in I(\bar{x})} \tilde{\mu}_i g'_i(\bar{x}) = 0.$$

La condición de independencia lineal de los gradientes de las restricciones activas (??) ahora implica que $\tilde{\lambda} = 0, \tilde{\mu}_i = 0 \forall i \in I(\bar{x})$. Por lo tanto, $\tilde{u} = 0$. Acabamos de mostrar que para todo $H \in \partial\Phi(\bar{x}, \bar{\lambda}, \bar{\mu})$, se tiene que $\ker H = \{0\}$. ■

Los resultados anteriores justifican la resolución del sistema KKT del problema (8.123) por los métodos de Newton generalizados.

Algoritmo 8.8 (Método de Newton generalizado para el sistema KKT). Elegir $\psi: \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$, de acuerdo con (8.127) o (8.128). Elegir $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ y tomar $k := 0$.

1. Calcular una matriz $H_k \in \mathbb{R}^{(n+l+m) \times (n+l+m)}$. Calcular $(x^{k+1}, \lambda^{k+1}, \mu^{k+1}) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$, una solución del sistema de ecuaciones lineales

$$H_k((x, \lambda, \mu) - (x^k, \lambda^k, \mu^k)) = -\Phi(x^k, \lambda^k, \mu^k),$$

con respecto a $(x, \lambda, \mu) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$, donde Φ es dada por (8.130).

2. Tomar $k := k + 1$ y retornar al Paso 1.

Si para cada iteración k en el método presentado arriba tomamos $H_k \in \partial_B\Phi(x^k, \lambda^k, \mu^k)$ o $H_k \in \partial\Phi(x^k, \lambda^k, \mu^k)$, obtenemos el método de Newton generalizado puro para el sistema KKT. Para este método, las elecciones de las matrices pueden seguir las fórmulas dadas anteriormente (vea los Ejercicios 8.34 y 8.35). Esto hace que los métodos en cuestión sean completamente explícitos e implementables (hablaremos sobre las elecciones de H_k más adelante). Los resultados de convergencia local y de la tasa de convergencia siguen directamente del Teorema 8.18 y de las Proposiciones 8.4 a 8.6.

Teorema 8.19 (Convergencia local del método de Newton generalizado para el sistema KKT). Además de las hipótesis de la Proposición 8.5, supongamos que las funciones $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ sean dos veces diferenciables en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivadas segundas Lipschitz-continuas en esta vecindad.

Entonces cualquier punto inicial $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$, suficientemente próximo a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, define unívocamente una secuencia del Algoritmo 8.8 (donde $H_k \in \partial\Phi(x^k, \lambda^k, \mu^k)$ para todo k), y esta secuencia converge a $(\bar{x}, \bar{\lambda}, \bar{\mu})$. La tasa de convergencia es cuadrática.

Notemos también que las hipótesis de diferenciabilidad del Teorema 8.19 pueden ser relajadas. En este caso, podemos probar convergencia superlineal en vez de cuadrática. Como el Teorema 8.19 no implica (automáticamente, vea el ??) ni tasa de convergencia cuadrática ni superlineal para la secuencia primal $\{x^k\}$, estudiaremos la tasa de convergencia primal separadamente. Al mismo tiempo, consideraremos la extensión del método en el sentido de métodos cuasi-Newtonianos, a fin de evitar el cálculo de derivadas segundas.

Para simplificar, consideremos solamente el caso de la función de complementariedad (8.127). Las matrices H_k serán elegidas de acuerdo con la fórmula siguiente:

$$H_k = \begin{pmatrix} \Lambda_k & (h'(x^k))^\top & (g'_{J_+^k}(x^k))^\top & (g'_{J_-^k}(x^k))^\top \\ h'(x^k) & 0 & 0 & 0 \\ -g'_{J_+^k}(x^k) & 0 & 0 & 0 \\ 0 & 0 & 0 & E_{J_-^k} \end{pmatrix}, \quad (8.145)$$

donde $\Lambda_k \in \mathbb{R}^{n \times n}$ es cierta aproximación a la matriz $L''_{xx}(x^k, \lambda^k, \mu^k)$,

$$J_+^k = J_+(x^k, \mu^k) = \{i = 1, \dots, m \mid \mu_i^k > -g_i(x^k)\},$$

$$J_-^k = J_-(x^k, \mu^k) = \{i = 1, \dots, m \mid \mu_i^k \leq -g_i(x^k)\},$$

y $E_{J_-^k}$ es la matriz-identidad $|J_-^k| \times |J_-^k|$. Notemos que si $\Lambda_k = L''_{xx}(x^k, \lambda^k, \mu^k)$, tenemos que $H_k \in \partial\Phi(x^k, \lambda^k, \mu^k)$.

Teorema 8.20 (Convergencia primal superlineal del método de Newton generalizado para el sistema KKT). Supongamos que valen las hipótesis del Teorema 8.19. Además, supongamos que la secuencia $\{(x^k, \lambda^k, \mu^k)\}$ generada por el Algoritmo 8.8 sea convergente a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, donde la función Φ viene dada por (8.130) con la función ψ dada por (8.127), y para todo $k = 0, 1, \dots$, la matriz H_k es dada por (8.145).

Entonces, si la tasa de convergencia de la secuencia $\{x^k\}$ a $\bar{x}$ es superlineal, se tiene que

$$P_{\mathcal{N}(\bar{x})}((\Lambda_k - L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}))(x^{k+1} - x^k)) = o(\|x^{k+1} - x^k\|), \quad (8.146)$$

donde

$$\mathcal{N}(\bar{x}) = \{d \in \ker h'(\bar{x}) \mid \langle g'_i(\bar{x}), d \rangle = 0 \quad \forall i \in I(\bar{x})\}.$$

Recíprocamente, si

$$P_{\mathcal{H}_+(\bar{x})}((\Lambda_k - L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}))(x^{k+1} - x^k)) = o(\|x^{k+1} - x^k\|), \quad (8.147)$$

donde

$$\mathcal{H}_+(\bar{x}) = \{d \in \ker h'(\bar{x}) \mid \langle g'_i(\bar{x}), d \rangle = 0 \quad \forall i \in I_+(\bar{x})\},$$

$$I_+(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i > 0\},$$

entonces la tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal.

Prueba. Por la construcción del Algoritmo 8.8 y (8.145), para todo k ,

$$\begin{aligned} & \Lambda_k(x^{k+1} - x^k) + (h'(x^k))^T(\lambda^{k+1} - \lambda^k) \\ & + (g'(x^k))^T(\mu^{k+1} - \mu^k) \\ & = -L'_x(x^k, \lambda^k, \mu^k), \end{aligned} \quad (8.148)$$

$$h'(x^k)(x^{k+1} - x^k) = -h(x^k), \quad (8.149)$$

$$-\langle g'_i(x^k), x^{k+1} - x^k \rangle = -\min\{\mu_i^k, -g_i(x^k)\}, \quad i \in J_+^k, \quad (8.150)$$

$$\mu_i^{k+1} - \mu_i^k = -\min\{\mu_i^k, -g_i(x^k)\}, \quad i \in J_-^k. \quad (8.151)$$

Por las definiciones de J_+^k y de J_-^k , las relaciones (8.150) y (8.151) pueden ser escritas como

$$g_i(x^k) + \langle g'_i(x^k), x^{k+1} - x^k \rangle = 0, \quad i \in J_+^k, \quad (8.152)$$

$$\mu_i^{k+1} = 0, \quad i \in J_-^k. \quad (8.153)$$

Además de eso, la convergencia de $\{(x^k, \mu^k)\}$ a $(\bar{x}, \bar{\mu})$ implica que

$$I_+(\bar{x}) \subset J_+^k, \quad \{1, \dots, m\} \setminus I(\bar{x}) \subset J_-^k \quad (8.154)$$

para todo k suficientemente grande.

De (8.148), obtenemos que

$$\begin{aligned} -\Lambda_k(x^{k+1} - x^k) &= f'(x^k) + (h'(x^k))^T \lambda^{k+1} + (g'(x^k))^T \mu^{k+1} \\ &= L'_x(x^k, \lambda^{k+1}, \mu^{k+1}) \\ &= L'_x(\bar{x}, \lambda^{k+1}, \mu^{k+1}) \\ &\quad + L''_{xx}(\bar{x}, \lambda^{k+1}, \mu^{k+1})(x^k - \bar{x}) + o(\|x^k - \bar{x}\|) \\ &= L'_x(\bar{x}, \lambda^{k+1}, \mu^{k+1}) + L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^k - \bar{x}) \\ &\quad + o(\|x^k - \bar{x}\|) \\ &= L'_x(\bar{x}, \bar{\lambda}, \bar{\mu})(x^k - \bar{x}) + o(\|x^k - \bar{x}\|) \\ &\quad + (h'(\bar{x}))^T(\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^T(\mu^{k+1} - \bar{\mu}) \\ &\quad + L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^k - \bar{x}) \\ &\quad + o(\|x^k - \bar{x}\|), \end{aligned} \quad (8.155)$$

donde utilizamos la definición de punto estacionario del problema (8.123) y de multiplicadores de Lagrange asociados, así como la convergencia de $\{(\lambda^k, \mu^k)\}$ a $(\bar{\lambda}, \bar{\mu})$. De (8.155) obtenemos que

$$\begin{aligned} & (L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - \Lambda_k)(x^{k+1} - x^k) \\ &= (h'(\bar{x}))^\top (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^\top (\mu^{k+1} - \bar{\mu}) \\ &+ L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^{k+1} - \bar{x}) + o(\|x^k - \bar{x}\|). \end{aligned} \quad (8.156)$$

Supongamos, primero, que la convergencia de $\{x^k\}$ a $\bar{x}$ sea superlineal, i.e., $\|x^{k+1} - \bar{x}\| = o(\|x^k - \bar{x}\|)$. En este caso, la relación (8.156) se transforma en

$$\begin{aligned} & (L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - \Lambda_k)(x^{k+1} - x^k) \\ &= (h'(\bar{x}))^\top (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^\top (\mu^{k+1} - \bar{\mu}) \\ &+ o(\|x^k - \bar{x}\|). \end{aligned} \quad (8.157)$$

Por (8.153), (8.154), y por la condición de complementariedad, para todo $d \in \mathcal{N}(\bar{x})$ se tiene que

$$\begin{aligned} & \langle (h'(\bar{x}))^\top (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^\top (\mu^{k+1} - \bar{\mu}), d \rangle \\ &= \sum_{i \in I(\bar{x})} (\mu_i^{k+1} - \bar{\mu}_i) \langle g'_i(\bar{x}), d \rangle = 0, \end{aligned} \quad (8.158)$$

de donde,

$$P_{\mathcal{N}(\bar{x})}((h'(\bar{x}))^\top (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^\top (\mu^{k+1} - \bar{\mu})) = 0 \quad (8.159)$$

(aquí $\mathcal{N}(\bar{x})$ es un subespacio lineal de $\mathbb{R}^n$, y $P_{\mathcal{N}(\bar{x})}(\cdot)$ es el operador de proyección ortogonal en este subespacio). Ahora, de (8.157) obtenemos que

$$P_{\mathcal{N}(\bar{x})}((L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - \Lambda_k)(x^{k+1} - x^k)) = o(\|x^k - \bar{x}\|). \quad (8.160)$$

Observemos que

$$\|x^{k+1} - x^k\| \geq \|x^k - \bar{x}\| - \|x^{k+1} - \bar{x}\| = \|x^k - \bar{x}\| + o(\|x^k - \bar{x}\|),$$

donde

$$\frac{o(\|x^k - \bar{x}\|)}{\|x^{k+1} - x^k\|} \leq \frac{o(\|x^k - \bar{x}\|)}{\|x^k - \bar{x}\| + o(\|x^k - \bar{x}\|)} = \frac{o(\|x^k - \bar{x}\|)/\|x^k - \bar{x}\|}{1 + o(\|x^k - \bar{x}\|)/\|x^k - \bar{x}\|} \rightarrow 0 \quad (k \rightarrow \infty).$$

Teniendo en cuenta esta relación, (8.146) se sigue de (8.160).

Supongamos ahora que la relación (8.147) sea satisfecha. Primero, notemos que, por (8.149),

$$\begin{aligned} 0 &= h(x^k) + h'(x^k)(x^{k+1} - x^k) \\ &= h'(\bar{x})(x^k - \bar{x}) + h'(\bar{x})(x^{k+1} - x^k) + o(\|x^k - \bar{x}\|) \\ &= h'(\bar{x})(x^{k+1} - \bar{x}) + \eta^k, \end{aligned} \quad (8.161)$$

donde, por la convergencia de $\{x^k\}$ a $\bar{x}$,

$$\eta^k = (h'(x^k) - h'(\bar{x}))(x^{k+1} - x^k) + o(\|x^k - \bar{x}\|) = o(\|x^{k+1} - x^k\|) + o(\|x^k - \bar{x}\|). \quad (8.162)$$

De modo análogo, de (8.152) obtenemos que

$$0 = \langle g'_i(\bar{x}), x^{k+1} - \bar{x} \rangle + \zeta_i^k \quad \forall i \in J_+^k, \quad (8.163)$$

donde

$$\zeta_i^k = o(\|x^{k+1} - x^k\|) + o(\|x^k - \bar{x}\|) \quad \forall i \in J_+^k. \quad (8.164)$$

Por la condición de independencia lineal de los gradientes de las restricciones activas (??), y por las relaciones (8.161) y (8.163), concluimos que existe $\xi^k \in \mathbb{R}^n$ tal que

$$h'(\bar{x})\xi^k = \eta^k, \quad \langle g'_i(\bar{x}), \xi^k \rangle = \zeta_i^k \quad \forall i \in J_+^k, \quad (8.165)$$

$$\|\xi^k\| = o(\|x^{k+1} - x^k\|) + o(\|x^k - \bar{x}\|). \quad (8.166)$$

Definimos $d^k = x^{k+1} - \bar{x} + \xi^k$. De (8.154) y (8.161)-(8.166), tenemos que $d^k \in \mathcal{H}_+(\bar{x})$. De modo análogo a la relación (8.158), obtenemos que

$$\begin{aligned} & \langle (h'(\bar{x}))^\top (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^\top (\mu^{k+1} - \bar{\mu}), d^k \rangle \\ &= \sum_{i \in I_0(\bar{x}) \cap J_+^k} (\mu_i^{k+1} - \bar{\mu}_i) \langle g'_i(\bar{x}), d^k \rangle + \sum_{i \in I_0(\bar{x}) \cap J_-^k} \mu_i^{k+1} \langle g'_i(\bar{x}), d^k \rangle = 0, \end{aligned}$$

donde la última ecuación se sigue de (8.153), (8.163) y (8.165). Multiplicando ambos lados de (8.156) por d^k y utilizando la última ecuación, obtenemos que

$$\begin{aligned} & \langle (L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - \Lambda_k)(x^{k+1} - x^k), d^k \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^{k+1} - \bar{x}), d^k \rangle + o(\|x^k - \bar{x}\| \|d^k\|). \end{aligned} \quad (8.167)$$

Por la condición suficiente de segunda orden fuerte (8.131), existe $\gamma > 0$ tal que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle \geq \gamma \|d\|^2 \quad \forall d \in \mathcal{H}_+(\bar{x}).$$

De aquí y de (8.167), obtenemos que

$$\begin{aligned} \gamma \|d^k\|^2 &\leq \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d^k, d^k \rangle \\ &= \langle (L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - \Lambda_k)(x^{k+1} - x^k), d^k \rangle \\ &\quad + \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\xi^k, d^k \rangle + o(\|x^k - \bar{x}\| \|d^k\|) \\ &= \langle (L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - \Lambda_k)(x^{k+1} - x^k), d^k \rangle \\ &\quad + o(\|x^{k+1} - x^k\| \|d^k\|) + o(\|x^k - \bar{x}\| \|d^k\|) \\ &\leq \langle P_{\mathcal{H}_+(\bar{x})}((L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - \Lambda_k)(x^{k+1} - x^k)), d^k \rangle \\ &\quad + o(\|x^{k+1} - x^k\| \|d^k\|) + o(\|x^k - \bar{x}\| \|d^k\|) \\ &= o(\|x^{k+1} - x^k\| \|d^k\|) + o(\|x^k - \bar{x}\| \|d^k\|), \end{aligned}$$

donde la segunda igualdad se sigue de (8.166), la segunda desigualdad se sigue del ?? (de la parte sobre la proyección sobre un cono convexo y cerrado), y la última igualdad se sigue de (8.147). En particular, dividiendo ambos lados de la relación arriba por $\|d^k\|$, concluimos que

$$\|d^k\| = o(\|x^{k+1} - x^k\|) + o(\|x^k - \bar{x}\|).$$

Por (8.166), tenemos entonces que

$$\|x^{k+1} - \bar{x}\| = \|d^k - \xi^k\| = o(\|x^{k+1} - x^k\|) + o(\|x^k - \bar{x}\|).$$

Esto significa que existen secuencias $\{t_k\} \subset \mathbb{R}_+$ y $\{s_k\} \subset \mathbb{R}_+$ tales que $t_k \rightarrow 0$, $s_k \rightarrow 0$ ($k \rightarrow \infty$) y, para todo k ,

$$\begin{aligned} \|x^{k+1} - \bar{x}\| &\leq t_k \|x^{k+1} - x^k\| + s_k \|x^k - \bar{x}\| \\ &\leq \max\{t_k, s_k\} (\|x^{k+1} - \bar{x}\| + 2\|x^k - \bar{x}\|). \end{aligned}$$

Por lo tanto, para todo k suficientemente grande,

$$\|x^{k+1} - \bar{x}\| \leq \frac{2 \max\{t_k, s_k\}}{1 - \max\{t_k, s_k\}} \|x^k - \bar{x}\|,$$

y como $\max\{t_k, s_k\} \rightarrow 0$ ($k \rightarrow \infty$), tenemos que

$$x^{k+1} - \bar{x} = o(\|x^k - \bar{x}\|),$$

i.e., la convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal. ■

Observemos que en el caso de la elección $\Lambda_k = L''_{xx}(x^k, \lambda^k, \mu^k)$, la convergencia en las variables primales ciertamente es superlineal, ya que $\Lambda_k \rightarrow L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})$ cuando $(x^k, \lambda^k, \mu^k) \rightarrow (\bar{x}, \bar{\lambda}, \bar{\mu})$ y, por lo tanto, la condición (8.147) vale trivialmente.

8.4.3. Métodos de penalización cuadrática

De nuevo, consideramos el problema

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0 \end{array} \right\}, \quad (8.168)$$

donde $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones diferenciables.

A continuación, extenderemos los resultados sobre penalización cuadrática, obtenidos en la apartado 8.3.2 para restricciones de igualdad, al caso de restricciones mixtas del problema (8.168). Para esto, utilizaremos la técnica de introducción de variables de holgura. Ocurre que la penalización cuadrática, así como las Lagrangianas aumentadas (que serán consideradas más adelante), son unos de los pocos casos donde la introducción de variables de holgura es una técnica eficiente, y esta no lleva a resultados más débiles de los que pueden ser obtenidos considerando desigualdades directamente.

Como ya sabemos, un problema con restricciones de igualdad y de desigualdad, como (8.168), puede ser formalmente transformado en un problema con solamente restricciones de igualdad. Por ejemplo, de la siguiente manera:

$$\min f(x) \quad \text{sujeto a} \quad (x, t) \in \tilde{D}, \quad (8.169)$$

$$\tilde{D} = \left\{ (x, t) \in \mathbb{R}^n \times \mathbb{R}^m \mid \begin{array}{l} h(x) = 0, \\ g_i(x) + t_i^2 = 0, \quad i = 1, \dots, m \end{array} \right\}. \quad (8.170)$$

Notemos, primero, que para todo $x \in \mathbb{R}^n$, podemos considerar que la condición $(x, t) \in \tilde{D}$ define el vector t unívocamente, si no nos preocupamos por los signos de las coordenadas del vector t . Este punto de vista tiene sentido, porque la elección de estos signos no tiene ninguna influencia en el valor de la función objetivo del problema (8.169)-(8.170), en el punto (x, t) . Por eso, a lo largo del análisis a continuación, vamos a ignorar los signos de las coordenadas de t . O sea, cualesquiera dos vectores (x, t^1) y (x, t^2) , que sean diferentes solamente en signos de las coordenadas de t^1 y $t^2 \in \mathbb{R}^m$, serán pensados como “iguales” (o, aún, como un mismo punto). Adoptando este punto de vista, soluciones locales de los problemas (8.168) y (8.169)-(8.170), se corresponden unívocamente: el punto $\bar{x} \in \mathbb{R}^n$ es una solución local de (8.168) si, y solamente si, el punto $(\bar{x}, \bar{t})$, donde

$$\bar{t} = (\sqrt{-g_1(\bar{x})}, \dots, \sqrt{-g_m(\bar{x})}), \quad (8.171)$$

está bien definido, y es una solución local del problema (8.169)-(8.170) (vea el Ejercicio 8.38 más adelante). Más aún, el problema (8.169)-(8.170) no posee otras soluciones locales de la forma $(\bar{x}, t)$, $t \in \mathbb{R}^m$.

Consideremos el término de penalización cuadrática para el problema (8.168), i.e.,

$$\psi(x) = \frac{1}{2} \left(\|h(x)\|^2 + \sum_{i=1}^m (\max\{0, g_i(x)\})^2 \right), \quad x \in \mathbb{R}^n, \quad (8.172)$$

donde introducimos el multiplicador $1/2$ por conveniencia a la hora de tomar derivadas. La familia asociada de funciones penalizadas viene dada por

$$\varphi(\cdot; c): \mathbb{R}^n \rightarrow \mathbb{R}, \quad \varphi(x; c) = f(x) + c\psi(x), \quad (8.173)$$

y los problemas penalizados asociados son

$$\min \varphi(x; c), \quad x \in \mathbb{R}^n. \quad (8.174)$$

El método en cuestión, entonces, es el siguiente.

Algoritmo 8.9 (El método de penalización cuadrática). Elegir $c_0 > 0$ y tomar $k := 0$.

1. Calcular $x^k \in \mathbb{R}^n$, un punto estacionario del problema (8.174), donde la función objetivo es dada por (8.173) con $c = c_k$.
2. Elegir $c_{k+1} > c_k$. Tomar $k := k + 1$ y retornar al Paso 1.

Los comentarios sobre la aplicación de este método son, en gran parte, los mismos que en el caso de la penalización cuadrática de restricciones de igualdad en la apartado 8.3.2. Existe, sin embargo, una diferencia que merece ser mencionada. La función $\varphi(\cdot; c)$, definida por (8.173), (8.172), es diferenciable cuando f, h y g son diferenciables; por lo tanto, ella no es diferenciable dos veces en puntos $x \in \mathbb{R}^n$ para los cuales el conjunto de índices $I(x) = \{i = 1, \dots, m \mid$

$g_i(x) = 0$ no es vacío, y esto es independiente de la diferenciabilidad de f, h y g . Esto tiene que ser tomado en consideración a la hora de elegir el método de optimización irrestricta para la resolución de los problemas (8.174).

Los Teoremas 8.21 y 8.22, que serán presentados a continuación, generalizan para el caso de restricciones mixtas los Teoremas 8.11 y 8.13, respectivamente, que fueron probados para restricciones de igualdad. Es más fácil conseguir estas generalizaciones utilizando la técnica de introducción de variables de holgura. Para eso, necesitaremos establecer conexiones auxiliares sobre la relación entre el problema (8.168) y el problema (8.169)-(8.170).

Sea

$$L : \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R},$$

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle,$$

la Lagrangiana del problema original (8.168). Introducimos también la Lagrangiana para el problema modificado (8.169)-(8.170):

$$\tilde{L} : (\mathbb{R}^n \times \mathbb{R}^m) \times (\mathbb{R}^l \times \mathbb{R}^m) \rightarrow \mathbb{R},$$

$$\begin{aligned} \tilde{L}((x, t), (\lambda, \mu)) &= f(x) + \langle \lambda, h(x) \rangle + \sum_{i=1}^m \mu_i (g_i(x) + t_i^2) \\ &= L(x, \lambda, \mu) + \sum_{i=1}^m \mu_i t_i^2. \end{aligned}$$

Lema 8.6. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}, h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en el punto $\bar{x} \in \mathbb{R}^n$.

- (a) Si $\bar{x}$ es un punto estacionario del problema (8.168) con multiplicadores de Lagrange asociados $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$, entonces el punto $(\bar{x}, \bar{t})$, donde $\bar{t} \in \mathbb{R}^m$ es dado por (8.171), está bien definido y es estacionario para el problema (8.169)-(8.170), con multiplicadores de Lagrange asociados $(\bar{\lambda}, \bar{\mu})$, i.e., $(\bar{x}, \bar{t}) \in \tilde{D}$ y

$$\tilde{L}'_{(x,t)}((\bar{x}, \bar{t}), (\bar{\lambda}, \bar{\mu})) = 0.$$

- (b) Si para algún $\bar{t} \in \mathbb{R}^m$ el punto $(\bar{x}, \bar{t})$ es estacionario para el problema (8.169)-(8.170), con multiplicadores de Lagrange asociados $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}^m$, entonces $\bar{x} \in D$ y

$$L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0, \quad (8.175)$$

$$\bar{\mu}_i g_i(\bar{x}) = 0, \quad i = 1, \dots, m. \quad (8.176)$$

Prueba. El hecho de que $\bar{x}$ es un punto estacionario del problema (8.168), con multiplicadores de Lagrange $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$, significa la validez de las restricciones de igualdad (8.175), y de las condiciones de complementariedad (8.176). De (8.171) y (8.176) se sigue que el punto $(\bar{x}, \bar{t})$ es un punto factible del problema (8.169)-(8.170). Además de eso, de (8.175) y (8.176) obtenemos que

$$\begin{aligned} \tilde{L}'_x((\bar{x}, \bar{t}), (\bar{\lambda}, \bar{\mu})) &= L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0, \\ \tilde{L}'_{t_i}((\bar{x}, \bar{t}), (\bar{\lambda}, \bar{\mu})) &= 2\bar{\mu}_i \bar{t}_i = 0 \quad \forall i = 1, \dots, m. \end{aligned}$$

Esto concluye la prueba del ítem (a).

El ítem (b) se prueba repitiendo el mismo razonamiento, en orden inverso. ■

Cabe resaltar que, en el ítem (b) del Lema 8.6, no se afirma que $\bar{x}$ es un punto estacionario del problema (8.168) en el sentido completo: el multiplicador $\bar{\mu}$ puede poseer coordenadas negativas. Para un punto $x \in \mathbb{R}^n$ cualquiera, definimos el conjunto de índices de restricciones de desigualdad del problema (8.168) violadas en x , i.e.,

$$I^+(x) = \{i = 1, \dots, m \mid g_i(x) > 0\}.$$

Decimos que x satisface la condición de independencia lineal de los gradientes extendida, si

$$\{h'_i(x), i = 1, \dots, l\} \cup \{g'_i(x), i \in I(x) \cup I^+(x)\} \quad (8.177)$$

es un conjunto linealmente independiente.

Notemos que en esta definición el punto x puede no ser factible. Cuando x es factible, se tiene que $I^+(x) = \emptyset$, y la condición (8.177) introducida arriba coincide con la condición de regularidad clásica (??).

Continuamos con el estudio de conexiones entre los problemas (8.168) y (8.169)-(8.170).

Lema 8.7. Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Supongamos que $\bar{x}$ satisface la condición de independencia lineal de los gradientes extendida (8.177), y que $\bar{x}$ sea un punto estacionario del problema (8.168), con multiplicadores de Lagrange asociados $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$. Supongamos, finalmente, que $\bar{x}$ satisface la condición suficiente de segunda orden del ??(b) y la condición de complementariedad estricta (??).

Entonces el punto $(\bar{x}, \bar{t})$, donde $\bar{t} \in \mathbb{R}^m$ es dado por (8.171), está bien definido y satisface la condición de regularidad de las restricciones para el problema (8.169)-(8.170). Además, $(\bar{x}, \bar{t})$ es un punto estacionario de este problema, con el único par de multiplicadores de Lagrange asociados $(\bar{\lambda}, \bar{\mu})$. Más aún, este punto satisface la condición suficiente de segunda orden para el problema (8.169)-(8.170), i.e.,

$$\langle \bar{L}''_{(x,t)(x,t)}((\bar{x}, \bar{t}), (\bar{\lambda}, \bar{\mu}))(d, \tau), (d, \tau) \rangle > 0 \quad (8.178)$$

para todo $(d, \tau) \in (\mathbb{R}^n \times \mathbb{R}^m) \setminus \{0\}$ tal que

$$h'(\bar{x})d = 0, \quad \langle g'_i(\bar{x}), d \rangle + 2\bar{t}_i\tau_i = 0 \quad \forall i = 1, \dots, m. \quad (8.179)$$

Prueba. El hecho de que $(\bar{x}, \bar{t})$ es un punto estacionario con multiplicadores de Lagrange asociados $(\bar{\lambda}, \bar{\mu})$, fue establecido en el ítem (a) del Lema 8.6. La validez en este punto de la condición de regularidad de las restricciones se sigue del resultado del Ejercicio 8.39.

Tomamos $(d, \tau) \in (\mathbb{R}^n \times \mathbb{R}^m) \setminus \{0\}$ que satisfaga (8.179). Haciendo el cálculo directo, puede verse que

$$\begin{aligned} & \langle \bar{L}''_{(x,t)(x,t)}((\bar{x}, \bar{t}), (\bar{\lambda}, \bar{\mu}))(d, \tau), (d, \tau) \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle + 2 \sum_{i=1}^m \bar{\mu}_i \tau_i^2. \end{aligned} \quad (8.180)$$

De (8.171), (8.179), y de la condición de complementariedad estricta (??), tenemos que $d \in \mathcal{H}(\bar{x})$, donde, como siempre, $\mathcal{H}(\bar{x})$ es el cono crítico del problema (8.168) en el punto $\bar{x}$. Si $d \neq 0$, la desigualdad (8.178) se sigue inmediatamente de la condición suficiente de segunda orden para el problema (8.168) en el punto $\bar{x}$ y de la igualdad (8.180), donde el segundo término en el lado derecho es no negativo (ya que $\bar{\mu} \geq 0$).

Sea $d = 0$. En este caso, $\tau \neq 0$. De (8.171) y (8.179), se sigue que $\tau_i = 0 \forall i \in \{1, \dots, m\} \setminus I(\bar{x})$. Por lo tanto, entre los números τ_i , $i \in I(\bar{x})$, hay algunos estrictamente positivos. De aquí, de la condición de complementariedad estricta (??), y de (8.180), obtenemos la desigualdad (8.178). ■

Ahora, para el problema (8.169)-(8.170), introducimos la familia de funciones penalizadas

$$\tilde{\varphi}(\cdot; c): \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}, \quad \tilde{\varphi}(x, t; c) = f(x) + c\tilde{\psi}(x, t), \quad (8.181)$$

asociada a la penalización cuadrática

$$\tilde{\psi}: \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}, \quad \tilde{\psi}(x, t) = \frac{1}{2} \left(\|h(x)\|^2 + \sum_{i=1}^m (g_i(x) + t_i^2)^2 \right). \quad (8.182)$$

Consideraremos problemas penalizados correspondientes:

$$\min \tilde{\varphi}(x, t; c), \quad (x, t) \in \mathbb{R}^n \times \mathbb{R}^m. \quad (8.183)$$

Observemos que para todo $x \in \mathbb{R}^n$ fijo, la minimización con respecto a $t \in \mathbb{R}^m$ en (8.183) puede ser hecha explícitamente, eliminando así las variables auxiliares: el mínimo global es alcanzado en $t(x) \in \mathbb{R}^m$, donde

$$t_i(x) = \begin{cases} 0, & \text{si } g_i(x) > 0, \\ \sqrt{-g_i(x)}, & \text{caso contrario,} \end{cases} \quad i = 1, \dots, m. \quad (8.184)$$

Este minimizador es único, si ignoramos los signos de las coordenadas. Tenemos, por lo tanto, lo siguiente:

$$\begin{aligned} \min_{t \in \mathbb{R}^m} \tilde{\varphi}(x, t; c) &= \tilde{\varphi}(x, t(x); c) \\ &= f(x) + \frac{c}{2} \left(\|h(x)\|^2 + \sum_{i=1}^m (\max\{0, g_i(x)\})^2 \right) \\ &= \varphi(x; c) \quad \forall x \in \mathbb{R}^n, \end{aligned}$$

donde $\varphi(\cdot; c)$ es la función definida por (8.173), (8.172).

Lema 8.8. Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Entonces para todo $c \geq 0$, un punto $\bar{x}$ es estacionario para el problema (8.174) con función objetivo dada por (8.173), (8.172), si,

y solamente si, el punto $(\bar{x}, t(\bar{x}))$, donde $t(\bar{x}) \in \mathbb{R}^m$ es dado por (8.184), es estacionario para el problema (8.183) con función objetivo definida por (8.181), (8.182).

Prueba. Sea $\bar{x}$ un punto estacionario del problema (8.174). De (8.184) obtenemos que

$$\begin{aligned}\tilde{\phi}'_x(\bar{x}, t(\bar{x}); c) &= f'(\bar{x}) + c \left((h'(\bar{x}))^\top h(\bar{x}) + \sum_{i=1}^m (g_i(\bar{x}) + (t_i(\bar{x}))^2) g'_i(\bar{x}) \right) \\ &= f'(\bar{x}) + c \left((h'(\bar{x}))^\top h(\bar{x}) + \sum_{i=1}^m \max\{0, g_i(\bar{x})\} g'_i(\bar{x}) \right) \\ &= \varphi'(\bar{x}; c) = 0,\end{aligned}\tag{8.185}$$

$$\tilde{\phi}'_{t_i}(\bar{x}, t(\bar{x}); c) = 2c(g_i(\bar{x}) + (t_i(\bar{x}))^2)t_i(\bar{x}) = 0 \quad \forall i = 1, \dots, m.\tag{8.186}$$

Las igualdades (8.185) y (8.186) significan que $(\bar{x}, t(\bar{x}))$ es un punto estacionario del problema (8.183).

La afirmación recíproca se prueba invirtiendo el razonamiento utilizado para obtener (8.185). ■

Notemos que el problema (8.183) puede poseer puntos estacionarios $(\bar{x}, \bar{t})$ tales que no todos los valores absolutos de las coordenadas de $\bar{t} \in \mathbb{R}^m$ coincidan con las coordenadas correspondientes de $t(\bar{x})$, y en este caso $\bar{x} \in \mathbb{R}^n$ puede no ser un punto estacionario del problema (8.174).

Ejemplo 8.8. Sean $n = m = 1, l = 0$,

$$f(x) = x, \quad g(x) = x^2 - 1, \quad x \in \mathbb{R}.$$

Puntos estacionarios de la función $\tilde{\phi}(\cdot; c)$ se caracterizan por las ecuaciones

$$\begin{aligned}\tilde{\phi}'_x(x, t; c) &= 1 + 2c(x^2 + t^2 - 1)x = 0, \\ \tilde{\phi}'_t(x, t; c) &= 2c(x^2 + t^2 - 1)t = 0.\end{aligned}$$

Es fácil ver que, para todo c suficientemente grande, este sistema tiene una solución de la forma $(\bar{x}, 0)$, donde $\bar{x} \in [-1, 1]$. No obstante,

$$\varphi'(\bar{x}; c) = 1 + 2c \max\{0, \bar{x}^2 - 1\} \bar{x} = 1,$$

i.e., $\bar{x}$ no es un punto estacionario de la función $\varphi(\cdot; c)$.

Generalmente, el fenómeno expuesto arriba no presenta una dificultad grave, porque puntos estacionarios “inde-seados” del problema (8.183) no pueden ser soluciones locales (o sea, minimizadores locales) de este problema.

Lema 8.9. Para $f: \mathbb{R}^n \rightarrow \mathbb{R}, h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ cualesquiera, si para algún $c > 0$ el punto $(\bar{x}, \bar{t})$ es una solución local del problema (8.183) con función objetivo dada por (8.181), (8.182), entonces $\bar{t}$ coincide con el punto $t(\bar{x})$, definido de acuerdo con (8.184), ignorando los signos de las coordenadas.

Prueba. Definimos la función

$$\begin{aligned}\hat{\phi}(\cdot; c): \mathbb{R}^m &\rightarrow \mathbb{R}, \\ \hat{\phi}(t; c) &= \tilde{\phi}(\bar{x}, t; c) = f(\bar{x}) + \frac{c}{2} \left(\|h(\bar{x})\|^2 + \sum_{i=1}^m (g_i(\bar{x}) + t_i^2)^2 \right).\end{aligned}$$

Esta función es (infinitamente) diferenciable en $\mathbb{R}^m$ y el punto $\bar{t}$ es su minimizador irrestricto. Por el ??(a), tenemos que

$$\hat{\phi}'_{t_i}(\bar{t}; c) = 2c(g_i(\bar{x}) + \bar{t}_i^2)\bar{t}_i = 0 \quad \forall i = 1, \dots, m.\tag{8.187}$$

De aquí se sigue que para los índices $i = 1, \dots, m$, para los cuales $g_i(\bar{x}) \geq 0$, se tiene que $\bar{t}_i = 0 = t_i(\bar{x})$.

Ahora, por el ??(a), la matriz $\hat{\phi}''(\bar{t}; c)$ es semidefinida positiva. Si admitimos que para algún $i = 1, \dots, m$ tal que $g_i(\bar{x}) < 0$, tenemos que $\bar{t}_i^2 \neq (t_i(\bar{x}))^2 = -g_i(\bar{x})$, de (8.187) se sigue que $\bar{t}_i = 0$. Pero en este caso,

$$\hat{\phi}''_{t_i t_i}(\bar{t}; c) = 2c(g_i(\bar{x}) + 3\bar{t}_i^2) = 2cg_i(\bar{x}) < 0,$$

en contradicción con el hecho de que la matriz $\hat{\phi}''(\bar{t}; c)$ es semidefinida positiva (notemos que la matriz en cuestión es diagonal). ■

En particular, y diferentemente del caso de los puntos estacionarios, soluciones locales de los problemas (8.174) y (8.183) están en correspondencia única (en el mismo sentido que en el caso de soluciones locales de los problemas (8.168) y (8.169)-(8.170)).

Teorema 8.21. Sean funciones $f: \mathbb{R}^n \rightarrow \mathbb{R}, h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferenciables en $\mathbb{R}^n$, con derivadas continuas. Entonces, si la secuencia $\{x^k\}$ es generada por el Algoritmo 8.9, donde $\{c_k\} \rightarrow +\infty$ ($k \rightarrow \infty$) y si se utiliza la función $\psi: \mathbb{R}^n \rightarrow \mathbb{R}$ dada por (8.172), todo punto de acumulación $\bar{x} \in \mathbb{R}^n$ de la secuencia $\{x^k\}$ que satisfaga la condición de independencia lineal de los gradientes extendida (8.177), es un punto estacionario del problema (8.168). Además de esto, para toda subsecuencia $\{x^{k_j}\}$ que converge a $\bar{x}$ se tiene que

$$\{c_{k_j} h(x^{k_j})\} \rightarrow \bar{\lambda} \quad (j \rightarrow \infty), \quad (8.188)$$

$$c_{k_j} \max\{0, g_i(x^{k_j})\} \rightarrow \bar{\mu}_i \quad (j \rightarrow \infty) \quad \forall i = 1, \dots, m, \quad (8.189)$$

donde $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$ son los únicos multiplicadores de Lagrange asociados a $\bar{x}$.

Prueba. Consideremos una secuencia $\{x^k, t(x^k)\}$, donde para todo k el punto $t(x^k) \in \mathbb{R}^m$ está definido de acuerdo con (8.184). Por el Lema 8.8, la secuencia $\{x^k, t(x^k)\}$ puede ser pensada como generada por el método de penalización cuadrática aplicado al problema (8.169)-(8.170). Por la continuidad de la función $t(\cdot)$, se sigue que $(\bar{x}, t(\bar{x}))$ es un punto de acumulación de esta secuencia, y del Ejercicio 8.39 se sigue que las restricciones del problema (8.169)-(8.170) son regulares en este punto.

Utilizando el Teorema 8.11, obtenemos que $(\bar{x}, t(\bar{x}))$ es un punto estacionario del problema (8.169)-(8.170), y que para una subsecuencia $\{x^{k_j}\}$ convergente a $\bar{x}$ valen las relaciones (8.188) y

$$c_{k_j} (g_i(x^{k_j}) + (t_i(x^{k_j}))^2) \rightarrow \bar{\mu}_i \quad \forall i = 1, \dots, m \quad (j \rightarrow \infty), \quad (8.190)$$

donde $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}^m$ son los multiplicadores de Lagrange correspondientes. De (8.184), se sigue que (8.190) coincide con (8.189), y de (8.189) se sigue que $\bar{\mu} \geq 0$. La demostración se concluye teniendo en cuenta el ítem (b) del Lema 8.6. ■

Notemos que de (8.189) se sigue la siguiente propiedad interesante: para todo j suficientemente grande y todo $i \in I(\bar{x})$ tal que $\bar{\mu}_i > 0$, se tiene que $g_i(x^{k_j}) > 0$. Este hecho es consistente con propiedades generales de métodos de penalización externa (vea la ??), de acuerdo con las cuales las iteraciones no son factibles con respecto al problema original.

El Teorema 8.21 nos dice que todo punto de acumulación de una secuencia generada por el método de penalización cuadrática o es un punto estacionario del problema original (8.168), o viola la condición de independencia lineal de los gradientes. En este último caso, el punto en cuestión puede no ser factible para el problema (8.168).

Ejemplo 8.9. Sean $n = m = 1, l = 0$,

$$f(x) = x, \quad g(x) = x^2 + 1, \quad x \in \mathbb{R}.$$

Tenemos que

$$\varphi(x; c) = x + c(\max\{0, x^2 + 1\})^2/2 = x + c(x^2 + 1)^2/2, \quad x \in \mathbb{R},$$

y puntos estacionarios del problema (8.174) se caracterizan por la ecuación

$$\varphi'(x; c) = 1 + 2c(x^2 + 1)x = 0.$$

Para todo c , esta ecuación tiene una única solución, que tiende a cero cuando $c \rightarrow \infty$. Pero el punto 0 no es factible en el problema (8.168). Observemos que $g'(0) = 0$, i.e., la condición (8.177) es violada.

En el Ejercicio 8.33 el problema original tiene su conjunto factible vacío. Pero la violación de restricciones por un punto de acumulación de una secuencia generada por el método de penalización cuadrática también es posible en el caso en que el conjunto factible no es vacío (naturalmente, tal punto debe violar la condición (8.177) de independencia lineal de los gradientes).

Ejemplo 8.10. Sean $n = 2, l = m = 1$,

$$h(x) = x_1^2 - 1, \quad g(x) = -x_1 + x_2^2, \quad x \in \mathbb{R}^2,$$

y sea f una función constante en $\mathbb{R}^2$. Puede verse que el punto 0 es estacionario para el problema (8.174) para c cualquiera, y que 0 no es factible en el problema (8.168). La condición (8.177) es violada, ya que $h'(0) = 0$.

Finalmente, presentamos estimativas de tasa de convergencia de los métodos de penalización cuadrática.

Teorema 8.22 (Estimativas de tasa de convergencia de los métodos de penalización cuadrática). Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}, h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones dos veces diferenciables en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con

derivadas segundas continuas en este punto. Supongamos que $\bar{x}$ satisface la condición (8.177) de independencia de los gradientes, y que $\bar{x}$ sea un punto estacionario del problema (8.168), con (únicos) multiplicadores de Lagrange $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$ asociados. Supongamos, finalmente, que $\bar{x}$ satisface a la condición suficiente de segunda orden del Teorema 1.2.3(b) y a la condición de complementariedad estricta (??).

Entonces, existen una vecindad U del punto $\bar{x}$ y números $\bar{c} \geq 0$ y $M > 0$, tales que, para todo $c > \bar{c}$, el problema (8.174) con la función objetivo definida por las fórmulas (8.173), (8.172), posee en U un único punto estacionario $x(c)$, y se tiene que

$$\begin{aligned} \|x(c) - \bar{x}\| &\leq M \frac{\|\bar{\lambda}\| + \|\bar{\mu}\|}{c}, \quad \|cF(x(c)) - \bar{\lambda}\| \leq M \frac{\|\bar{\lambda}\| + \|\bar{\mu}\|}{c}, \\ |c \max\{0, g_i(x(c))\} - \bar{\mu}_i| &\leq M \frac{\|\bar{\lambda}\| + \|\bar{\mu}\|}{c} \quad \forall i = 1, \dots, m. \end{aligned} \quad (8.191)$$

De la condición de complementariedad estricta (??) y de la estimativa (8.191), puede verse que para todo valor del parámetro penalizador c suficientemente grande, todas las restricciones de desigualdad del problema (8.168), activas en el punto $\bar{x}$, son violadas en los puntos de la trayectoria $x(\cdot)$ definida en el Teorema 8.22. O sea, tenemos que $g_i(x(c)) > 0 \quad \forall i \in I(\bar{x})$ para todo c suficientemente grande (comparar con las observaciones hechas para el Teorema 8.21).

8.4.4. Lagrangianas aumentadas

A continuación, extenderemos los resultados sobre Lagrangianas aumentadas, obtenidos en la apartado 8.3.3 para restricciones de igualdad, al caso de restricciones mixtas del problema (8.168). Para esto, de nuevo utilizaremos la técnica de introducción de variables de holgura. Para todo $c > 0$, definimos la Lagrangiana aumentada para el problema (8.169)-(8.170) con restricciones transformadas en igualdades:

$$\begin{aligned} \tilde{L}(\cdot; c) : (\mathbb{R}^n \times \mathbb{R}^m) \times (\mathbb{R}^l \times \mathbb{R}^m) &\rightarrow \mathbb{R}, \\ \tilde{L}((x, t), (\lambda, \mu); c) &= \tilde{L}((x, t), (\lambda, \mu)) \\ &\quad + \frac{c}{2} \left(\|h(x)\|^2 + \sum_{i=1}^m (g_i(x) + t_i^2)^2 \right). \end{aligned} \quad (8.192)$$

Para $\lambda \in \mathbb{R}^l$ y $\mu \in \mathbb{R}^m$ dados, la minimización en

$$\min \tilde{L}((x, t), (\lambda, \mu); c), \quad (x, t) \in \mathbb{R}^n \times \mathbb{R}^m, \quad (8.193)$$

con respecto a $t \in \mathbb{R}^m$ puede ser hecha explícitamente. En particular, para todo $x \in \mathbb{R}^n$ fijo, el mínimo global es alcanzado en el punto $t(x, \mu, c)$, donde

$$t_i(x, \mu, c) = \begin{cases} 0, & \text{si } g_i(x) + \mu_i/c > 0, \\ \sqrt{-(g_i(x) + \mu_i/c)}, & \text{caso contrario,} \end{cases} \quad (8.194)$$

$i = 1, \dots, m$. Este minimizador es único (ignorando los signos de las coordenadas). Notemos que

$$\begin{aligned} g_i(x) + (t_i(x, \mu, c))^2 &= g_i(x) + \max\{0, -g_i(x) - \mu_i/c\} \\ &= \max\{g_i(x), -\mu_i/c\}. \end{aligned} \quad (8.195)$$

De donde, después de algunas transformaciones simples, obtenemos la Lagrangiana aumentada para el problema (8.168) de la siguiente forma:

$$\begin{aligned} L(\cdot; c) : \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m &\rightarrow \mathbb{R}, \\ L(x, \lambda, \mu; c) &= \min_t \tilde{L}((x, t), (\lambda, \mu); c) \\ &= \tilde{L}((x, t(x, \mu, c)), (\lambda, \mu); c) \\ &= f(x) + \langle \lambda, h(x) \rangle + \frac{c}{2} \|h(x)\|^2 \\ &\quad + \frac{1}{2c} \sum_{i=1}^m ((\max\{0, c g_i(x) + \mu_i\})^2 - \mu_i^2). \end{aligned} \quad (8.196)$$

Por lo tanto, en vez de (8.193), consideramos el problema

$$\min L(x, \lambda, \mu; c), \quad x \in \mathbb{R}^n. \quad (8.197)$$

El Teorema 8.23 a continuación, muestra que puntos KKT del problema original (8.168) corresponden a puntos estacionarios irrestrictos de la Lagrangiana aumentada de este problema, para $c > 0$ cualquiera. Pero primero necesitaremos un resultado auxiliar.

Lema 8.10. Sea $a \in \mathbb{R}$ y $b \in \mathbb{R}$. Entonces

$$a = \max\{0, b\} \quad (8.198)$$

si, y solamente si,

$$a - b \geq 0, \quad a(a - b) = 0, \quad a \geq 0. \quad (8.199)$$

Prueba. Observamos que (8.198) significa que $a \geq 0$, $a \geq b$, y $a = 0$ o $a = b$. Estas condiciones también pueden ser escritas como (8.199). ■

Teorema 8.23 (Puntos estacionarios de la Lagrangiana aumentada). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Entonces para $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}^m$, y $c > 0$ cualquier, el punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$ es una solución del sistema de Karush-Kuhn-Tucker del problema (8.168) si, y solamente si,

$$L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}; c) = 0.$$

Prueba. Tenemos que

$$\begin{aligned} L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}; c) &= f'(\bar{x}) + (h'(\bar{x}))^\top (\bar{\lambda} + c h(\bar{x})) \\ &\quad + \sum_{i=1}^m (\max\{0, c g_i(\bar{x}) + \bar{\mu}_i\}) g'_i(\bar{x}), \end{aligned}$$

$$L'_\lambda(\bar{x}, \bar{\lambda}, \bar{\mu}; c) = h(\bar{x}),$$

$$L'_{\mu_i}(\bar{x}, \bar{\lambda}, \bar{\mu}; c) = \frac{1}{c} (\max\{0, c g_i(\bar{x}) + \bar{\mu}_i\} - \bar{\mu}_i), \quad i = 1, \dots, m.$$

En particular, $L'_\lambda(\bar{x}, \bar{\lambda}, \bar{\mu}; c) = 0$ si, y solamente si, $h(\bar{x}) = 0$. Como $c > 0$, tenemos también que $L'_{\mu_i}(\bar{x}, \bar{\lambda}, \bar{\mu}; c) = 0$ si, y solamente si,

$$\bar{\mu}_i = \max\{0, c g_i(\bar{x}) + \bar{\mu}_i\}, \quad i = 1, \dots, m.$$

Lo cual, por el Lema 8.10, es equivalente a

$$-c g_i(\bar{x}) \geq 0, \quad \bar{\mu}_i(-c g_i(\bar{x})) = 0, \quad \bar{\mu}_i \geq 0, \quad i = 1, \dots, m.$$

Esto, a su vez, es equivalente a la validez de las condiciones de complementariedad

$$g_i(\bar{x}) \leq 0, \quad \bar{\mu}_i g_i(\bar{x}) = 0, \quad \bar{\mu}_i \geq 0, \quad i = 1, \dots, m.$$

Notemos, finalmente, que la derivada de la Lagrangiana aumentada con respecto a las variables primales se reduce a la derivada de la Lagrangiana clásica:

$$\begin{aligned} 0 &= L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}; c) = f'(\bar{x}) + (h'(\bar{x}))^\top \bar{\lambda} + \sum_{i=1}^m \bar{\mu}_i g'_i(\bar{x}) \\ &= L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}), \end{aligned}$$

lo que concluye la prueba. ■

Los dos resultados siguientes son análogos a los Lemas 4.5.3 y 4.5.4, respectivamente.

Lema 8.11. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Entonces, para todo $c > 0$ y cualesquiera $\lambda \in \mathbb{R}^l$ y $\mu \in \mathbb{R}^m$, el punto $\bar{x}$ es un punto estacionario del problema (8.197) con función objetivo definida por la fórmula (8.196), si, y solamente si, el punto $(\bar{x}, t(\bar{x}))$, donde $t(\bar{x}) \in \mathbb{R}^m$ está definido en (8.194), es estacionario para el problema (8.193) con función objetivo dada por (8.192).

Lema 8.12. Para $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ cualesquiera, si para algunos $c > 0$, $\lambda \in \mathbb{R}^l$ y $\mu \in \mathbb{R}^m$ el punto $(\bar{x}, \bar{t}) \in \mathbb{R}^n \times \mathbb{R}^m$ es una solución local del problema (8.193) con función objetivo definida por la fórmula (8.192), entonces $\bar{t}$ coincide (ignorando los signos de las coordenadas) con el punto $t(\bar{x})$, definido de acuerdo con (8.194).

El método de la Lagrangiana aumentada o, aún, el método de los multiplicadores, para el problema (8.168) es el siguiente.

Algoritmo 8.10 (El método de los multiplicadores). Elegir $\lambda^0 \in \mathbb{R}^l, \mu^0 \in \mathbb{R}_+^m, c_0 > 0$, y tomar $k := 0$.

1. Calcular $x^k \in \mathbb{R}^n$, un punto estacionario del problema (8.197), con función objetivo dada por la fórmula (8.196), donde $c = c_k, \lambda = \lambda^k$ y $\mu = \mu^k$.
2. Tomar

$$\begin{aligned}\lambda^{k+1} &= \lambda^k + c_k h(x^k), \\ \mu_i^{k+1} &= \max\{0, c_k g_i(x^k) + \mu_i^k\}, \quad i = 1, \dots, m.\end{aligned}\tag{8.200}$$

3. Elegir $c_{k+1} \geq c_k$. Tomar $k := k + 1$, y retornar al Paso 1.

Comentaremos sobre la fórmula (8.200) para el cálculo de las aproximaciones de los multiplicadores de Lagrange asociados a las restricciones de desigualdad. De acuerdo con el esquema del método para el problema (8.169)-(8.170) con restricciones transformadas en igualdades (vea el Algoritmo 8.6), la fórmula natural sería

$$\mu_i^{k+1} = \mu_i^k + c_k(g_i(x^k) + (t_i(x^k, \mu^k, c_k))^2), \quad i = 1, \dots, m.$$

Pero esto es exactamente (8.200), si tenemos en cuenta (8.195). El resultado siguiente es una extensión del Teorema 4.4.6 al caso de restricciones mixtas.

Teorema 8.24 (Convergencia local del método de los multiplicadores). Supongamos que se satisfacen las hipótesis del Teorema 8.22. Entonces existe una vecindad U del punto $\bar{x}$ y números $\bar{c} \geq 0, \delta > 0$ y $M > 0$ tales que:

- (a) Para todo $(\lambda, \mu, c) \in \Delta(\bar{c}, \delta)$, donde

$$\Delta(\bar{c}, \delta) = \left\{ (\lambda, \mu, c) \in \mathbb{R}^l \times \mathbb{R}^m \times \mathbb{R} \mid \begin{array}{l} \|\lambda - \bar{\lambda}\| < \delta c, \\ \|\mu - \bar{\mu}\| < \delta c, \\ c > \bar{c} \end{array} \right\},$$

el problema (8.197), con función objetivo dada por la fórmula (8.196), posee en U un único punto estacionario $x(\lambda, \mu, c)$, y se tiene que

$$\begin{aligned}\|x(\lambda, \mu, c) - \bar{x}\| &\leq M \frac{\|\lambda - \bar{\lambda}\| + \|\mu - \bar{\mu}\|}{c}, \\ \|\lambda + ch(x(\lambda, \mu, c)) - \bar{\lambda}\| &\leq M \frac{\|\lambda - \bar{\lambda}\| + \|\mu - \bar{\mu}\|}{c}, \\ |\max\{0, c g_i(x(\lambda, \mu, c)) + \mu_i\} - \bar{\mu}_i| &\leq M \frac{\|\lambda - \bar{\lambda}\| + \|\mu - \bar{\mu}\|}{c} \\ &\text{para todo } i = 1, \dots, m;\end{aligned}$$

- (b) Existe $\bar{\delta} \in (0, \delta]$ tal que para toda $\{c_k\} \subset \mathbb{R}_+$ no decreciente y cualquier $\lambda^0 \in \mathbb{R}^l$ y $\mu^0 \in \mathbb{R}^m$ que satisfacen

$$(\lambda^0, \mu^0, c_0) \in \Delta(\bar{c}, \bar{\delta}),$$

las fórmulas

$$\begin{aligned}\lambda^{k+1} &= \lambda^k + c_k h(x(\lambda^k, \mu^k, c_k)), \\ \mu_i^{k+1} &= \max\{0, c_k g_i(\lambda^k, \mu^k, c_k) + \mu_i^k\}, \quad i = 1, \dots, m,\end{aligned}\tag{8.201}$$

donde $k = 0, 1, \dots$, unívocamente definen las secuencias $\{\lambda^k\}$ y $\{\mu^k\}$, en el sentido de que $\{(\lambda^k, \mu^k, c_k)\} \subset \Delta(\bar{c}, \delta)$, i.e., para todo k el punto $x(\lambda^k, \mu^k, c_k)$ está bien definido y $\{\lambda^k\} \rightarrow \bar{\lambda}$, $\{\mu^k\} \rightarrow \bar{\mu}$, $\{x(\lambda^k, \mu^k, c_k)\} \rightarrow \bar{x}$ ($k \rightarrow \infty$). La tasa de convergencia de las secuencias $\{\lambda^k\}$ y $\{\mu^k\}$ es lineal, y si $c_k \rightarrow \infty$ ($k \rightarrow \infty$), la tasa es superlineal.

Notemos el siguiente hecho, complementario con respecto al ítem (b) del Teorema 8.24. Como $\{\mu^k\} \rightarrow \bar{\mu}$, $\{x(\lambda^k, \mu^k, c_k)\} \rightarrow \bar{x}$ ($k \rightarrow \infty$), para todo índice $i \in \{1, \dots, m\}$ tal que $\bar{\mu}_i > 0$, para todo k suficientemente grande, se tiene que $c_k g_i(x(\lambda^k, \mu^k, c_k)) + \mu_i^k > 0$. De donde, utilizando también (8.201), se sigue que $\mu_i^{k+1} = c_k g_i(\lambda^k, \mu^k, c_k) + \mu_i^k$. O sea, las aproximaciones de los multiplicadores que corresponden a las restricciones de desigualdad activas en $\bar{x}$, son exactas (iguales a $\bar{\mu}_i$) después de un número finito de iteraciones.

8.4.5. Penalización exacta diferenciable

Haremos ahora algunos comentarios muy breves sobre la penalización exacta diferenciable para el problema con restricciones mixtas (8.168). De nuevo, primero introducimos las funciones para el problema (8.169)-(8.170), con restricciones de desigualdad transformadas en restricciones de igualdad. Por ejemplo,

$$\begin{aligned}
 \tilde{\varphi}(\cdot; c_1, c_2) &: (\mathbb{R}^n \times \mathbb{R}^m) \times (\mathbb{R}^l \times \mathbb{R}^m) \rightarrow \mathbb{R}, \\
 \tilde{\varphi}((x, t), (\lambda, \mu); c_1, c_2) \\
 &= \tilde{L}((x, t), (\lambda, \mu); c_1) + \frac{c_2}{2} \|\tilde{L}'_{(x,t)}((x, t), (\lambda, \mu))\|^2 \\
 &= L(x, \lambda, \mu) + \sum_{i=1}^m \mu_i t_i^2 \\
 &\quad + \frac{c_1}{2} \left(\|h(x)\|^2 + \sum_{i=1}^m (g_i(x) + t_i^2)^2 \right) \\
 &\quad + \frac{c_2}{2} \left(\|L'_x(x, \lambda, \mu)\|^2 + 4 \sum_{i=1}^m (\mu_i t_i)^2 \right). \tag{8.202}
 \end{aligned}$$

Para $c_1, c_2 > 0$, consideremos el problema

$$\min \tilde{\varphi}((x, t), (\lambda, \mu); c_1, c_2), \quad ((x, t), (\lambda, \mu)) \in (\mathbb{R}^n \times \mathbb{R}^m) \times (\mathbb{R}^l \times \mathbb{R}^m). \tag{8.203}$$

No es difícil ver que para todo $x \in \mathbb{R}^n, \lambda \in \mathbb{R}^l$ y $\mu \in \mathbb{R}^m$ fijos, el mínimo global con respecto a $t \in \mathbb{R}^m$ en (8.203) es alcanzado en el único (ignorando los signos de las coordenadas) punto $t(x, \mu, c_1, c_2)$, donde

$$t_i(x, \mu, c_1, c_2) = \begin{cases} 0, & \text{si } g_i(x) + \mu_i(1 + 2c_2\mu_i)/c_1 > 0, \\ \sqrt{-(g_i(x) + \mu_i(1 + 2c_2\mu_i)/c_1)}, & \text{caso contrario,} \end{cases} \tag{8.204}$$

$i = 1, \dots, m$. Después de algunas transformaciones simples, obtenemos la siguiente función penalizada diferenciable para el problema (8.168):

$$\begin{aligned}
 \varphi(\cdot; c_1, c_2) &: \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R}, \\
 \varphi(x, \lambda, \mu; c_1, c_2) \\
 &= \min_{t \in \mathbb{R}^m} \tilde{\varphi}((x, t), (\lambda, \mu); c_1, c_2) \\
 &= \tilde{\varphi}((x, t(x, \mu, c_1, c_2)), (\lambda, \mu); c_1, c_2) \\
 &= f(x) + \langle \lambda, h(x) \rangle + \frac{c_1}{2} \|h(x)\|^2 + \frac{c_2}{2} \|L'_x(x, \lambda, \mu)\|^2 \\
 &\quad + \frac{1}{2c_1} \sum_{i=1}^m \left((\max\{0, c_1 g_i(x) + \mu_i(1 + 2c_2\mu_i)\})^2 \right. \\
 &\quad \left. - \mu_i^2(1 + 2c_2\mu_i)^2 - 4c_1 c_2 \mu_i^2 g_i(x) \right). \tag{8.205}
 \end{aligned}$$

Consideremos el problema asociado

$$\min \varphi(x, \lambda, \mu; c_1, c_2), \quad (x, \lambda, \mu) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m. \tag{8.206}$$

El siguiente resultado es análogo al del Lema 8.8.

Lema 8.13. Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}, h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Entonces para todo $c_1 > 0$ y $c_2 \geq 0$, y cualesquiera $\lambda \in \mathbb{R}^l, \mu \in \mathbb{R}^m$, el punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$ es estacionario para el problema (8.206) con función objetivo dada por la fórmula (8.205), si, y solamente si, el punto $((\bar{x}, \bar{t}), (\bar{\lambda}, \bar{\mu}))$, donde $\bar{t}(x, \mu, c_1, c_2) \in \mathbb{R}^m$ está definido en (8.204), es estacionario para el problema (8.203) con función objetivo definida por (8.202).

Finalmente, el resultado siguiente generaliza la afirmación (b) del Teorema 4.4.7.

Teorema 8.25. Supongamos que se satisfacen las hipótesis del Teorema 8.22. Entonces existe un número $\bar{c}_2 > 0$ tal que, si $c_2 \in (0, \bar{c}_2]$, entonces una vecindad U del punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$ y un número $\bar{c}_1(c_2) \geq 0$ pueden ser elegidos de tal manera que para todo $c_1 > \bar{c}_1(c_2)$ el problema (8.206), con función objetivo definida por la fórmula (8.205), posee en U un único punto estacionario, que es $(\bar{x}, \bar{\lambda}, \bar{\mu})$.

8.5. Programación cuadrática secuencial

Como sugiere el nombre, los métodos de programación cuadrática secuencial (SQP)⁴ consisten en la resolución de una secuencia de problemas de programación cuadrática (i.e., de minimización de una función cuadrática sujeta a restricciones lineales o afines), aproximando, en cada iteración, un problema original dado. Un problema de programación cuadrática adecuadamente construido puede ser una buena aproximación del problema original, al mismo tiempo que su resolución es relativamente fácil. En particular, los problemas de programación cuadrática admiten varios métodos bien eficientes, inclusive algunos con convergencia finita (vea la ??). Por eso, esta estrategia tiene sentido práctico, a diferencia de la utilización de aproximaciones de tercera orden, cuarta, etc.

Por otro lado, los métodos SQP pueden ser pensados como una generalización natural de la idea fundamental del método de Newton clásico. A propósito, como veremos más adelante, en el caso de restricciones de igualdad, los métodos SQP pueden ser considerados como una implementación específica del método de Newton aplicado al sistema de Lagrange asociado al problema. En el caso en que hay restricciones de desigualdad, esta equivalencia deja de existir, pero la relación con el método de Newton es clara en este caso también.

Los métodos SQP son considerados entre los más eficientes métodos de optimización de uso general. Para resolver un problema dado, sin estructura especial, con frecuencia se eligen métodos de esta clase.

8.5.1. Restricciones de igualdad

Consideremos el problema

$$\min f(x) \quad \text{sujeto a } x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}, \quad (8.207)$$

donde $f: \mathbb{R}^n \rightarrow \mathbb{R}$ y $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ son funciones dos veces diferenciables en $\mathbb{R}^n$.

Sea $x^k \in \mathbb{R}^n$ una aproximación del punto estacionario $\bar{x}$ del problema (8.207). Vamos a aproximar el problema original, en torno a x^k , por un problema de programación cuadrática de la forma

$$\min f(x^k) + \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle H_k(x - x^k), x - x^k \rangle \quad \text{sujeto a } x \in D_k, \quad (8.208)$$

donde $D_k = \{x \in \mathbb{R}^n \mid h(x^k) + h'(x^k)(x - x^k) = 0\}$, y $H_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica.

La primera tentativa, que parece natural, sería utilizar la matriz $H_k = f''(x^k)$, i.e., tomar como función objetivo del subproblema la aproximación pura de segunda orden de la función objetivo f del problema original (comparar con el método de Newton restringido en la ??). Sin embargo, consideraciones más finas muestran que esta elección, aparentemente natural, no es de las mejores. Esto tiene que ver con la siguiente observación. La aproximación lineal de las restricciones no puede proveer información sobre la curvatura de las mismas. Sin embargo, intuitivamente, es claro que esta información de segunda orden sobre las restricciones es tan importante como la información de segunda orden sobre la función objetivo (son dos partes del problema distintas, una tan importante como la otra). Agregar términos cuadráticos a las restricciones de los subproblemas los tornaría mucho más difíciles de resolver. Actualmente existen algunas propuestas de métodos de este tipo, que hasta tienen ciertas ventajas teóricas. Pero por ahora no se puede decir que los subproblemas con restricciones cuadráticas se establecieron como una alternativa práctica a los subproblemas con restricciones lineales de SQP. Felizmente, la información de segunda orden sobre las restricciones puede ser pasada al subproblema de otra manera, bastante natural desde el punto de vista Newtoniano, como veremos a continuación. En particular, la propuesta es elegir

$$H_k = L''_{xx}(x^k, \lambda^k), \quad (8.209)$$

donde $\lambda^k \in \mathbb{R}^l$ es una aproximación al multiplicador de Lagrange $\bar{\lambda}$ asociado al punto estacionario $\bar{x}$, y

$$L: \mathbb{R}^n \times \mathbb{R}^l \rightarrow \mathbb{R}, \quad L(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle,$$

es la Lagrangiana del problema (8.207). O sea, la información de segunda orden sobre las restricciones es pasada al subproblema vía la función objetivo del mismo. Notamos que el subproblema así obtenido continúa siendo de programación cuadrática (con función objetivo dada por la aproximación cuadrática de la función $L(\cdot, \lambda^k)$ en torno a x^k , y con conjunto factible dado por la aproximación lineal de las restricciones en torno a x^k).

Otra motivación para esta elección viene dada por la interpretación del problema (8.208) como una implementación de la iteración de Newton para el sistema de Lagrange del problema original (8.207), que fue considerada en la ??.

⁴En inglés: SQP - *sequential quadratic programming*

Recordamos que el sistema de Lagrange para el problema en cuestión es

$$L'(x, \lambda) = 0, \quad (8.210)$$

y una iteración de Newton para este sistema consiste en la resolución del sistema lineal

$$L''_{xx}(x^k, \lambda^k)(x - x^k) + (h'(x^k))^T(\lambda - \lambda^k) = -f'(x^k) - (h'(x^k))^T \lambda^k, \quad (8.211)$$

$$h'(x^k)(x - x^k) = -h(x^k) \quad (8.212)$$

con respecto a $(x, \lambda) \in \mathbb{R}^n \times \mathbb{R}^l$, donde $(x^k, \lambda^k) \in \mathbb{R}^n \times \mathbb{R}^l$ es una aproximación dada de la solución de (8.210).

Sea $x^{k+1} \in \mathbb{R}^n$ un punto estacionario del problema (8.208) y $\lambda^{k+1} \in \mathbb{R}^l$ un multiplicador de Lagrange asociado. Esto significa que (x^{k+1}, λ^{k+1}) es una solución del sistema

$$\begin{aligned} f'(x^k) + H_k(x - x^k) + (h'(x^k))^T y &= 0, \\ h(x^k) + h'(x^k)(x - x^k) &= 0 \end{aligned}$$

con respecto a $(x, y) \in \mathbb{R}^n \times \mathbb{R}^l$. Comparando este último sistema con (8.211)-(8.212), vemos que ellos coinciden, si la matriz H_k es elegida de acuerdo con (8.209). Por lo tanto, esta es la elección que corresponde a la idea de métodos Newtonianos. Podemos, entonces, esperar convergencia local rápida bajo hipótesis naturales. Formulamos ahora el método de programación cuadrática secuencial (SQP) para problemas con restricciones de igualdad.

Algoritmo 8.11 (El método de programación cuadrática secuencial). Elegir $(x^0, \lambda^0) \in \mathbb{R}^n \times \mathbb{R}^l$ y tomar $k := 0$.

1. Calcular $x^{k+1} \in \mathbb{R}^n$, un punto estacionario del problema (8.208), donde H_k es dada por (8.209), y calcular $y^{k+1} \in \mathbb{R}^l$, un multiplicador de Lagrange asociado a x^{k+1} .
2. Tomar $\lambda^{k+1} = y^{k+1}$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

Por lo expuesto arriba, para un punto inicial (x^0, λ^0) cualquiera, el Algoritmo 8.11 genera la misma secuencia $\{(x^k, \lambda^k)\}$ que el método de Newton puro aplicado al sistema de Lagrange (8.210), ya considerado en la ???. Por eso, no hay necesidad de un nuevo análisis (local) del método SQP en este caso. En particular, si las derivadas segundas de las funciones f e h son continuas en el punto $\bar{x}$, y satisfacen la condición de regularidad de las restricciones (??) y la condición suficiente de segunda orden del ??(b), entonces por el Teorema 8.10, inmediatamente tenemos que el método SQP converge localmente a $(\bar{x}, \bar{\lambda})$ con tasa superlineal. Más aún, si las derivadas segundas de f e h son Lipschitz-continuas en una vecindad de $\bar{x}$, entonces la tasa de convergencia es cuadrática.

Como implementación del método de Newton para el sistema de Lagrange, el método SQP tal vez no sea muy útil (por lo menos en el contexto de un estudio local). Esta interpretación es análoga a la de la ??? en el caso del método de Newton para optimización irrestricta y su interpretación vía minimización de funciones cuadráticas. Sin embargo, estas consideraciones son importantes para sugerir estrategias de globalización del esquema local. Además de esto, el método SQP para problemas con restricciones de igualdad sugiere una generalización muy natural para el caso general, cuando hay también restricciones de desigualdad. Esta generalización será presentada a continuación.

8.5.2. Restricciones mixtas

Consideremos ahora un problema de optimización con restricciones de igualdad y desigualdad

$$\min f(x) \quad \text{sujeto a } x \in D = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0 \end{array} \right\}, \quad (8.213)$$

donde $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ son dos veces diferenciables en $\mathbb{R}^n$.

Sea $x^k \in \mathbb{R}^n$ una aproximación del punto estacionario $\bar{x}$ del problema (8.213). Una generalización natural del subproblema (8.208) para el caso de restricciones mixtas está dada por

$$\min \langle f'(x^k), d \rangle + \frac{1}{2} \langle H_k d, d \rangle \quad \text{sujeto a } d \in D_k, \quad (8.214)$$

$$D_k = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} h(x^k) + h'(x^k)d = 0, \\ g(x^k) + g'(x^k)d \leq 0 \end{array} \right\}. \quad (8.215)$$

El método SQP, por lo tanto, consiste en lo siguiente.

Algoritmo 8.12 (El método de programación cuadrática secuencial). Elegir $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}_+^m$ y tomar $k := 0$.

1. Calcular un punto estacionario $d^k \in \mathbb{R}^n$ del problema (8.214)-(8.215), donde $H_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica, y multiplicadores de Lagrange $y^k \in \mathbb{R}^l, z^k \in \mathbb{R}_+^m$ asociados a d^k .
2. Tomar $x^{k+1} = x^k + d^k, \lambda^{k+1} = y^k, \mu^{k+1} = z^k$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

Por lo observado arriba en el caso de restricciones de igualdad, podemos esperar convergencia rápida del método si elegimos

$$H_k = L''_{xx}(x^k, \lambda^k, \mu^k), \quad (8.216)$$

donde

$$L : \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R}, \quad L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle$$

es la Lagrangiana del problema (8.213). Notemos que si $D_k \neq \emptyset$ y la matriz H_k es definida positiva, el subproblema (8.214)-(8.215) posee una única solución y esta solución también es el único punto estacionario del problema (por el hecho de que la función objetivo es fuertemente convexa y el conjunto factible es convexo). No obstante, cabe mencionar que bajo hipótesis naturales (tales como la condición suficiente de segunda orden para el problema (8.213)) no es posible garantizar que la matriz H_k dada por (8.216) sea definida positiva, aun para x^k próximo a $\bar{x}$, y λ^k, μ^k próximos a $\bar{\lambda}$ y $\bar{\mu}$, respectivamente (comparar con la motivación para la introducción de Lagrangianas aumentadas en la apartado 8.3.3, y con el Ejercicio 8.49). Por eso, la existencia de puntos estacionarios del subproblema (8.214)-(8.215) no es automática y tiene que ser probada como parte del análisis local del método. Además, incluso cuando un punto estacionario existe, él puede no ser único. Por eso, en el análisis local suponemos que d^k sea el punto estacionario del subproblema (8.214)-(8.215) de menor norma. En la práctica, este requerimiento es simplemente ignorado.

Teorema 8.26 (Convergencia local del método SQP). Sean funciones $f : \mathbb{R}^n \rightarrow \mathbb{R}, h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ dos veces diferenciables en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivadas segundas continuas en este punto. Sea $\bar{x}$ un punto estacionario del problema (8.213) que satisface la condición de independencia lineal de los gradientes de las restricciones activas (??). Supongamos que $\bar{x}$, con los (únicos) multiplicadores de Lagrange asociados $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$, satisface la condición suficiente de segunda orden del ??(b). Supongamos, finalmente, la condición de complementariedad estricta

$$\bar{\mu}_i > 0 \quad \forall i \in I(\bar{x}) = \{i = 1, \dots, m \mid g_i(\bar{x}) = 0\}. \quad (8.217)$$

Entonces para cualquier punto inicial $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ suficientemente próximo a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, el Algoritmo 8.12, donde H_k es dada por (8.216) y d^k es el punto estacionario de (8.214)-(8.215) con menor norma, está bien definido. La secuencia generada por el método converge a $(\bar{x}, \bar{\lambda}, \bar{\mu})$. La tasa de convergencia es superlineal. Más aún, si las derivadas segundas de f, h y g son Lipschitz-continuas en una vecindad del punto $\bar{x}$, entonces la tasa de convergencia es cuadrática.

Prueba. Denotamos $U = \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$. Primero, tenemos que probar que para $(x^k, \lambda^k, \mu^k) \in U$ suficientemente próximo a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, el subproblema (8.214)-(8.215) posee un único punto estacionario d^k de menor norma y que este punto tiene un único par de multiplicadores de Lagrange (y^k, z^k) asociado. Consideremos el sistema KKT del subproblema (8.214)-(8.215):

$$f'(x^k) + L''_{xx}(x^k, \lambda^k, \mu^k)d + (h'(x^k))^T y + (g'(x^k))^T z = 0, \quad (8.218)$$

$$h(x^k) + h'(x^k)d = 0, \quad (8.219)$$

$$g(x^k) + g'(x^k)d \leq 0, \quad z \geq 0, \quad (8.220)$$

$$z_i(g_i(x^k) + \langle g'_i(x^k), d \rangle) = 0, \quad i = 1, \dots, m, \quad (8.221)$$

con respecto a $(d, y, z) \in U$. Notemos primero que si x^k es suficientemente próximo a $\bar{x}$ y $d \in \mathbb{R}^n$ tiene norma suficientemente pequeña, no puede existir más de un par de multiplicadores $(y, z) \in \mathbb{R}^l \times \mathbb{R}^m$ tales que el punto (d, y, z) satisfaga (8.218)-(8.221). En efecto, para tales x^k y d , se tiene que

$$g_i(x^k) + \langle g'_i(x^k), d \rangle < 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}),$$

por la continuidad de las funciones involucradas, y de (8.221),

$$z_i = 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}).$$

En particular, para el conjunto de los índices J^k de las restricciones activas en la solución del subproblema (8.214)-(8.215), se tiene que $J^k \subset I(\bar{x})$. Los gradientes de estas restricciones forman, entonces, un subconjunto de

$$\{h'_i(x^k), i = 1, \dots, l\} \cup \{g'_i(x^k), i \in I(\bar{x})\}$$

que es linealmente independiente para x^k próximo a $\bar{x}$ (por la continuidad y por la hipótesis de independencia lineal de los gradientes en el punto $\bar{x}$). Concluimos entonces que los gradientes de las restricciones activas son linealmente independientes en el subproblema (8.214)-(8.215). Esto implica que no puede haber más de un par de multiplicadores de Lagrange en el sistema (8.218)-(8.221).

Definimos la función $\Phi : U \times U \rightarrow U$,

$$\Phi(w, u) = \begin{pmatrix} f'(x) + L''_{xx}(x, \lambda, \mu)d + (h'(x))^T y + (g'(x))^T z \\ h(x) + h'(x)d \\ z_1(g_1(x) + \langle g'_1(x), d \rangle) \\ \vdots \\ z_m(g_m(x) + \langle g'_m(x), d \rangle) \end{pmatrix},$$

$$w = (x, \lambda, \mu), \quad u = (d, y, z).$$

El sistema

$$\Phi(w, u) = 0,$$

donde $w \in U$ hace el papel de parámetro, corresponde a las ecuaciones (8.218), (8.219), (8.221).

Por las definiciones de punto estacionario del problema (8.213) y de multiplicadores de Lagrange asociados, tenemos $\Phi(\bar{w}, \bar{u}) = 0$, donde $\bar{w} = (\bar{x}, \bar{\lambda}, \bar{\mu})$, $\bar{u} = (0, \bar{\lambda}, \bar{\mu})$. Además de eso,

$$\Phi'_u(\bar{w}, \bar{u}) = \begin{pmatrix} L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) & (h'(\bar{x}))^T & (g'(\bar{x}))^T \\ h'(\bar{x}) & 0 & 0 \\ \bar{\mu}_1(g'_1(\bar{x}))^T & 0 & 0 \\ \vdots & \vdots & \vdots \\ \bar{\mu}_m(g'_m(\bar{x}))^T & 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & \text{diag}(g_i(\bar{x})) \end{pmatrix},$$

donde $\text{diag}(g_i(\bar{x}))$ es la matriz diagonal con entradas $g_i(\bar{x})$ para $i = 1, \dots, m$.

Tomamos $\bar{u} = (\bar{d}, \bar{y}, \bar{z}) \in \ker \Phi'_u(\bar{w}, \bar{u})$, arbitrario, i.e.,

$$L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{d} + (h'(\bar{x}))^T \bar{y} + (g'(\bar{x}))^T \bar{z} = 0, \quad (8.222)$$

$$h'(\bar{x})\bar{d} = 0, \quad (8.223)$$

$$\bar{\mu}_i \langle g'_i(\bar{x}), \bar{d} \rangle + g_i(\bar{x})\bar{z}_i = 0, \quad i = 1, \dots, m. \quad (8.224)$$

De (8.224) y de la condición de complementariedad estricta (8.217), tenemos que

$$\bar{z}_i = 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}), \quad \langle g'_i(\bar{x}), \bar{d} \rangle = 0 \quad \forall i \in I(\bar{x}). \quad (8.225)$$

Además de eso, bajo la condición de complementariedad estricta (8.217) tenemos que el cono crítico del problema (8.213) en el punto $\bar{x}$ tiene la siguiente forma:

$$\mathcal{H}(\bar{x}) = \{v \in \ker h'(\bar{x}) \mid \langle g'_i(\bar{x}), v \rangle = 0 \quad \forall i \in I(\bar{x})\}. \quad (8.226)$$

Por tanto, de (8.223) y (8.225), tenemos que $\bar{d} \in \mathcal{H}(\bar{x})$. Multiplicando ambos lados de (8.222) por $\bar{d}$, obtenemos que

$$\begin{aligned} 0 &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{d}, \bar{d} \rangle + \langle \bar{y}, h'(\bar{x})\bar{d} \rangle + \langle \bar{z}, g'(\bar{x})\bar{d} \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{d}, \bar{d} \rangle + \sum_{i=1}^m \bar{z}_i \langle g'_i(\bar{x}), \bar{d} \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\bar{d}, \bar{d} \rangle, \end{aligned}$$

donde utilizamos (8.223) y (8.225). Esto significa que $\bar{d} = 0$ (pues en caso contrario, la condición suficiente de segunda orden en el punto $\bar{x}$ sería violada). De (8.222) y (8.225), ahora se sigue que

$$(h'(\bar{x}))^T \bar{y} + \sum_{i \in I(\bar{x})} \bar{z}_i g'_i(\bar{x}) = 0.$$

Por la condición (??) de independencia lineal de los gradientes de las restricciones activas en $\bar{x}$, obtenemos que $\bar{y} = 0$ y $\bar{z}_i = 0 \forall i \in I(\bar{x})$. Acabamos de probar que $\bar{u} = (\bar{d}, \bar{y}, \bar{z}) = 0$, i.e., la matriz $\Phi'_u(\bar{w}, \bar{u})$ es no-singular.

Aplicando a la función Φ en el punto $(\bar{w}, \bar{u})$ el Teorema de la Función Implícita (??), concluimos que existen vecindades W del punto $\bar{w}$ y V del punto $\bar{u}$ en U , para las cuales existe una única función $\chi(\cdot) = (d(\cdot), y(\cdot), z(\cdot)) : W \rightarrow U$ continua en el punto $\bar{w}$ tal que $\chi(W) \subset V$ y

$$\Phi(w, \chi(w)) = 0 \quad \forall w \in W. \quad (8.227)$$

En particular, $d(\bar{w}) = 0, y(\bar{w}) = \bar{\lambda}, z(\bar{w}) = \bar{\mu}$. De aquí, de la continuidad de $\chi(\cdot)$ en $\bar{w}$, y de la condición de complementariedad estricta (8.217), obtenemos que para una vecindad W suficientemente pequeña, $\forall w = (x, \lambda, \mu) \in W$ se tiene que

$$g_i(x) + \langle g'_i(x), d(w) \rangle < 0 \quad \forall i \in \{1, \dots, m\} \setminus I(\bar{x}), \quad (8.228)$$

$$z_i(w) > 0 \quad \forall i \in I(\bar{x}). \quad (8.229)$$

Teniendo en cuenta la definición de la función Φ , las relaciones (8.227)-(8.229) significan que, para $w^k = (x^k, \lambda^k, \mu^k) \in W$, el sistema (8.218)-(8.221) posee en V una única solución, que es $(d(w^k), y(w^k), z(w^k))$. Por el hecho de que los multiplicadores tienen que ser únicos (ya justificado arriba), podemos afirmar que si la vecindad W es suficientemente pequeña, esta solución es única no solamente en V sino también en el conjunto $\tilde{V} \times \mathbb{R}^l \times \mathbb{R}^m$, donde $\tilde{V}$ es una vecindad de 0 en $\mathbb{R}^n$. De aquí se sigue que $d^k = d(w^k)$ es el único punto estacionario del problema (8.214)-(8.215) de menor norma, y $(y^k, z^k) = (y(w^k), z(w^k))$ es el único par de multiplicadores de Lagrange asociado a d^k .

Observamos que, por (8.228) y (8.229), para $(x^k, \lambda^k, \mu^k) \in W$ las condiciones (8.220) y (8.221) en el sistema (8.218)-(8.221), que define (d^k, y^k, z^k) , pueden ser sustituidas por

$$g_i(x^k) + \langle g'_i(x^k), d \rangle = 0 \quad i \in I(\bar{x}), \quad (8.230)$$

$$z_i = 0 \quad i \in \{1, \dots, m\} \setminus I(\bar{x}). \quad (8.231)$$

En particular, una iteración del método es equivalente al cálculo de la solución (d^k, y^k, z^k) del sistema de ecuaciones lineales (8.218), (8.219), (8.230), (8.231).

Consideremos el problema con restricciones de igualdad

$$\min f(x) \quad \text{sueto a } x \in \bar{D},$$

$$\bar{D} = \{x \in \mathbb{R}^n \mid h(x) = 0, g_i(x) = 0, i \in I(\bar{x})\}.$$

Como es fácil ver, bajo nuestras hipótesis el punto $\bar{x}$ es una solución local de este problema que satisface la condición de regularidad de las restricciones y la condición suficiente de segunda orden (problemas con restricciones de igualdad; vea la ??). Por lo tanto, si agregamos al sistema de Lagrange correspondiente las ecuaciones

$$\mu_i = 0, \quad i \in \{1, \dots, m\} \setminus I(\bar{x}),$$

el sistema de ecuaciones con respecto a $(x, \lambda, \mu) \in U$ así obtenido tendrá una solución $(\bar{x}, \bar{\lambda}, \bar{\mu})$ que es regular (en el sentido de que la derivada de este sistema en esta solución es no-singular). De acuerdo con el ??, el método de Newton para este sistema converge (localmente) a la solución con tasa superlineal, y si las derivadas segundas de f, h y g son Lipschitz-continuas en una vecindad del punto $\bar{x}$, la tasa de convergencia es cuadrática.

Como es fácil ver, para una aproximación (x^k, λ^k, μ^k) dada, una iteración del método de Newton consiste en un paso d^k al punto $(x^k + d^k, y^k, z^k)$, donde (d^k, y^k, z^k) es la solución del sistema que consiste en las ecuaciones (8.219), (8.230), (8.231) y en la ecuación

$$\begin{aligned} L''_{xx}(x^k, \lambda^k, \mu^k)d - \sum_{i=1}^m \mu_i^k g''_i(x^k)d \\ + (h'(x^k))^T y + \sum_{i \in I(\bar{x})} z_i g'_i(x^k) = -f'(x^k). \end{aligned} \quad (8.232)$$

Notemos que la única diferencia entre (8.232) y (8.218) es el segundo término en el lado izquierdo de (8.232) (aquí tomamos en cuenta (8.231)). Pero como $\bar{\mu}_i = 0 \forall i \in \{1, \dots, m\} \setminus I(\bar{x})$, existe un número $M > 0$ tal que para todo $x \in \mathbb{R}^n$

suficientemente próximo a $\bar{x}$ y todo $\mu \in \mathbb{R}^m$ suficientemente próximo a $\bar{\mu}$, se tiene que

$$\left\| \sum_{i=1}^m \mu_i g_i''(x) \right\| \leq \sum_{i \notin I(\bar{x})} |\mu_i - \bar{\mu}_i| \|g_i''(x)\| \leq M \|\mu - \bar{\mu}\|.$$

Esto significa que el algoritmo cuya iteración está dada por las ecuaciones (8.218), (8.219), (8.230) y (8.231), puede ser pensado como un método de Newton inexacto con iteraciones determinadas por las ecuaciones (8.219), (8.230), (8.231) y (8.232). Por el ??, las propiedades locales y la tasa de convergencia de este método son completamente análogas a aquellas del método de Newton^a. ■

^aDe hecho, teniendo en cuenta (8.231), puede verse que para la secuencia $\{(x^k, \lambda^k, \mu^k)\}$ generada por el método, se tiene que $\mu_i^k = 0 \forall i \in \{1, \dots, m\} \setminus I(\bar{x}), \forall k \geq 2$, i.e., ya a partir de la segunda iteración el método funciona como un método de Newton exacto.

Cabe mencionar que la convergencia cuadrática de la secuencia $\{(x^k, \lambda^k, \mu^k)\}$ a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, en principio no implica la convergencia cuadrática (ni siquiera superlineal) de la secuencia $\{x^k\}$ a $\bar{x}$ (vea el ??). Sin embargo, con frecuencia la convergencia rápida en las variables primales es lo que interesa más en las aplicaciones. Este asunto será investigado a continuación. Al mismo tiempo, consideremos la posibilidad de elegir las matrices H_k para satisfacer (8.216) de manera inexacta, siguiendo los principios de la condición de Dennis-Moré (vea el ??). Algunas maneras concretas para construir H_k con tales propiedades pueden ser consultadas en [20].

Teorema 8.27 (Convergencia superlineal primal del método SQP). *Supongamos que valen las hipótesis del Teorema 8.26 con excepción, tal vez, de la condición de complementariedad estricta. Supongamos que la secuencia $\{(x^k, \lambda^k, \mu^k)\}$ del Algoritmo 8.12 converge a $(\bar{x}, \bar{\lambda}, \bar{\mu})$.*

Entonces la tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal si, y solamente si,

$$P_{\mathcal{H}(\bar{x})}((H_k - L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}))(x^{k+1} - x^k)) = o(\|x^{k+1} - x^k\|), \quad (8.233)$$

donde

$$\mathcal{H}(\bar{x}) = \{h \in \ker h'(\bar{x}) \mid \langle g_i(\bar{x}), h \rangle \leq 0 \forall i \in I(\bar{x}), \langle f'(\bar{x}), h \rangle \leq 0\}$$

es el cono crítico del problema (8.213).

Prueba. Recordamos que por la construcción del Algoritmo 8.12, el punto $(d^k, \lambda^{k+1}, \mu^{k+1})$ (donde $d^k = x^{k+1} - x^k$) satisface las condiciones KKT para el problema (8.214)-(8.215), i.e.,

$$f'(x^k) + H_k d^k + (h'(x^k))^T \lambda^{k+1} + (g'(x^k))^T \mu^{k+1} = 0, \quad (8.234)$$

$$h(x^k) + h'(x^k) d^k = 0, \quad (8.235)$$

$$g(x^k) + g'(x^k) d^k \leq 0, \quad \mu^{k+1} \geq 0, \quad (8.236)$$

$$\mu_i^{k+1} (g_i(x^k) + \langle g'_i(x^k), d^k \rangle) = 0, \quad i = 1, \dots, m. \quad (8.237)$$

De (8.234) obtenemos que

$$\begin{aligned} -H_k d^k &= f'(x^k) + (h'(x^k))^T \lambda^{k+1} + (g'(x^k))^T \mu^{k+1} \\ &= L'_x(x^k, \lambda^{k+1}, \mu^{k+1}) \\ &= L'_x(\bar{x}, \lambda^{k+1}, \mu^{k+1}) + L''_{xx}(\bar{x}, \lambda^{k+1}, \mu^{k+1})(x^k - \bar{x}) \\ &\quad + o(\|x^k - \bar{x}\|) \\ &= (h'(\bar{x}))^T (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^T (\mu^{k+1} - \bar{\mu}) \\ &\quad + L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^k - \bar{x}) + o(\|x^k - \bar{x}\|), \end{aligned} \quad (8.238)$$

donde utilizamos las definiciones de punto estacionario del problema (8.213) y de multiplicadores de Lagrange asociados, así como la convergencia de $\{(\lambda^k, \mu^k)\}$ a $(\bar{\lambda}, \bar{\mu})$. De (8.238), obtenemos que

$$\begin{aligned} &(L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k) d^k \\ &= (h'(\bar{x}))^T (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^T (\mu^{k+1} - \bar{\mu}) \\ &\quad + L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^{k+1} - \bar{x}) + o(\|x^k - \bar{x}\|). \end{aligned} \quad (8.239)$$

Supongamos primero que la tasa de convergencia de $\{x^k\}$ a $\bar{x}$ sea superlineal, i.e., $\|x^{k+1} - \bar{x}\| = o(\|x^k - \bar{x}\|)$. En este caso, (8.239) se escribe como

$$\begin{aligned} & (L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k)d^k \\ &= (h'(\bar{x}))^\top(\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^\top(\mu^{k+1} - \bar{\mu}) \\ &+ o(\|x^k - \bar{x}\|). \end{aligned} \quad (8.240)$$

Como $\{d^k\} \rightarrow 0$, $\{\mu^k\} \rightarrow \bar{\mu}$ ($k \rightarrow \infty$), de (8.237) obtenemos que $\mu_i^{k+1} = 0 \ \forall i \in \{1, \dots, m\} \setminus I(\bar{x})$, para todo k suficientemente grande. Utilizando la definición de $\mathcal{H}(\bar{x})$ y la segunda desigualdad en (8.236), obtenemos que $\forall v \in \mathcal{H}(\bar{x})$, se tiene que

$$\begin{aligned} & \langle (h'(\bar{x}))^\top(\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^\top(\mu^{k+1} - \bar{\mu}), v \rangle \\ &= \langle \mu^{k+1}, g'(\bar{x})v \rangle \\ &= \sum_{i \in I(\bar{x})} \mu_i^{k+1} \langle g'_i(\bar{x}), v \rangle \leq 0. \end{aligned} \quad (8.241)$$

Por el ??(c), la última relación implica que

$$P_{\mathcal{H}(\bar{x})}((h'(\bar{x}))^\top(\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^\top(\mu^{k+1} - \bar{\mu})) = 0.$$

De (8.240) obtenemos ahora que

$$P_{\mathcal{H}(\bar{x})}((L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k)d^k) = o(\|x^k - \bar{x}\|). \quad (8.242)$$

Teniendo en cuenta que

$$\|d^k\| \geq \|x^k - \bar{x}\| - \|x^{k+1} - \bar{x}\| = \|x^k - \bar{x}\| + o(\|x^k - \bar{x}\|),$$

la relación (8.242) implica (8.233), porque

$$\frac{o(\|x^k - \bar{x}\|)}{\|d^k\|} \leq \frac{o(\|x^k - \bar{x}\|)}{\|x^k - \bar{x}\| + o(\|x^k - \bar{x}\|)} = \frac{o(\|x^k - \bar{x}\|)/\|x^k - \bar{x}\|}{1 + o(\|x^k - \bar{x}\|)/\|x^k - \bar{x}\|} \rightarrow 0 \quad (k \rightarrow \infty).$$

Supongamos ahora que valga (8.233). Observamos que, por (8.235), se tiene que

$$\begin{aligned} 0 &= h(x^k) + h'(x^k)d^k \\ &= h'(\bar{x})(x^k - \bar{x}) + h'(\bar{x})d^k + o(\|x^k - \bar{x}\|) \\ &= h'(\bar{x})(x^{k+1} - \bar{x}) + \eta^k, \end{aligned} \quad (8.243)$$

donde, tomando en cuenta que $\{x^k\} \rightarrow \bar{x}$,

$$\begin{aligned} \eta^k &= (h'(x^k) - h'(\bar{x}))d^k + o(\|x^k - \bar{x}\|) \\ &= o(\|d^k\|) + o(\|x^k - \bar{x}\|). \end{aligned} \quad (8.244)$$

De modo análogo, de la primera desigualdad en (8.236), de la relación (8.237) y del hecho de que $\{\mu^k\} \rightarrow \bar{\mu}$, obtenemos que

$$0 = g_i(\bar{x}) + \langle g'_i(\bar{x}), x^{k+1} - \bar{x} \rangle + \zeta_i^k \quad \forall i \in I_+(\bar{x}), \quad (8.245)$$

$$0 \geq g_i(\bar{x}) + \langle g'_i(\bar{x}), x^{k+1} - \bar{x} \rangle + \zeta_i^k \quad \forall i \in I_0(\bar{x}), \quad (8.246)$$

$$0 = \mu_i^{k+1}(g_i(\bar{x}) + \langle g'_i(\bar{x}), x^{k+1} - \bar{x} \rangle + \zeta_i^k) \quad \forall i \in I_0(\bar{x}), \quad (8.247)$$

donde $I_+(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i > 0\}$, $I_0(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i = 0\}$, y

$$\zeta_i^k = o(\|d^k\|) + o(\|x^k - \bar{x}\|), \quad i \in I(\bar{x}). \quad (8.248)$$

Por la condición de independencia lineal de los gradientes de las restricciones activas (??) y por las relaciones (8.244) y (8.248), existe un elemento $\xi^k \in \mathbb{R}^n$ tal que

$$h'(\bar{x})\xi^k = \eta^k, \quad \langle g'_i(\bar{x}), \xi^k \rangle = \zeta_i^k \quad \forall i \in I(\bar{x}), \quad (8.249)$$

$$\|\xi^k\| = o(\|d^k\|) + o(\|x^k - \bar{x}\|). \quad (8.250)$$

Definimos $v^k = x^{k+1} - \bar{x} + \xi^k$. De (8.243)-(8.246) y (8.249), tenemos que $v^k \in \mathcal{H}(\bar{x})$. En particular, de modo análogo a (8.241), obtenemos que

$$\begin{aligned} & \langle (h'(\bar{x}))^\top (\lambda^{k+1} - \bar{\lambda}) + (g'(\bar{x}))^\top (\mu^{k+1} - \bar{\mu}), v^k \rangle \\ &= \sum_{i \in I(\bar{x})} \mu_i^{k+1} \langle g'_i(\bar{x}), v^k \rangle = 0, \end{aligned}$$

donde la última igualdad se sigue de (8.245) y (8.247). Multiplicando escalarmente ambos lados de (8.239) por v^k y utilizando la relación arriba, obtenemos

$$\langle (L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k)d^k, v^k \rangle = \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^{k+1} - \bar{x}), v^k \rangle + o(\|x^k - \bar{x}\| \|v^k\|). \quad (8.251)$$

Por la condición suficiente de segunda orden existe un número $\gamma > 0$ tal que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})v, v \rangle \geq \gamma \|v\|^2 \quad \forall v \in \mathcal{H}(\bar{x}).$$

Utilizando también (8.251), obtenemos

$$\begin{aligned} \gamma \|v^k\|^2 &\leq \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})v^k, v^k \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^{k+1} - \bar{x} + \xi^k), v^k \rangle \\ &= \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})(x^{k+1} - \bar{x}), v^k \rangle + \langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})\xi^k, v^k \rangle \\ &= \langle (L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k)d^k, v^k \rangle + o(\|x^k - \bar{x}\| \|v^k\|) \\ &\leq \langle P_{\mathcal{H}(\bar{x})}((L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu}) - H_k)d^k), v^k \rangle \\ &\quad + o(\|d^k\| \|v^k\|) + o(\|x^k - \bar{x}\| \|v^k\|) \\ &= o(\|d^k\| \|v^k\|) + o(\|x^k - \bar{x}\| \|v^k\|), \end{aligned}$$

donde la segunda igualdad se sigue de (8.250), la segunda desigualdad se sigue del ??(c), y la última igualdad se sigue de (8.233). Concluimos que $\|v^k\| = o(\|d^k\|) + o(\|x^k - \bar{x}\|)$. Mas en este caso, por (8.250), obtenemos que

$$\|x^{k+1} - \bar{x}\| = \|v^k - \xi^k\| = o(\|d^k\|) + o(\|x^k - \bar{x}\|).$$

Esto significa que existen secuencias $\{t_k\} \subset \mathbb{R}_+$ y $\{s_k\} \subset \mathbb{R}_+$ tales que $t_k \rightarrow 0$, $s_k \rightarrow 0$ ($k \rightarrow \infty$) y, para todo k ,

$$\begin{aligned} \|x^{k+1} - \bar{x}\| &\leq t_k \|x^{k+1} - x^k\| + s_k \|x^k - \bar{x}\| \\ &\leq \max\{t_k, s_k\} (\|x^{k+1} - \bar{x}\| + 2\|x^k - \bar{x}\|). \end{aligned}$$

De aquí, para todo k suficientemente grande,

$$\|x^{k+1} - \bar{x}\| \leq \frac{2 \max\{t_k, s_k\}}{1 - \max\{t_k, s_k\}} \|x^k - \bar{x}\|,$$

y como $\max\{t_k, s_k\} \rightarrow 0$ ($k \rightarrow \infty$), tenemos que

$$x^{k+1} - \bar{x} = o(\|x^k - \bar{x}\|),$$

i.e., la convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal. ■

Observamos que en el caso de la elección de la matriz H_k de acuerdo con (8.216), la convergencia en las variables primales ciertamente es superlineal, ya que $H_k \rightarrow L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})$ trivialmente cuando $(x^k, \lambda^k, \mu^k) \rightarrow (\bar{x}, \bar{\lambda}, \bar{\mu})$ ($k \rightarrow \infty$) y, por lo tanto, la validez de la condición (8.233) es obvia.

Las hipótesis del Teorema 8.26 que garantizan convergencia local superlineal (en variables primales-duales) del método SQP pueden ser relajadas. Por ejemplo, es posible eliminar la condición de complementariedad estricta, pero a costa de la introducción de una condición de segunda orden más fuerte. Esta condición, llamada condición suficiente de segunda orden fuerte, consiste en lo siguiente:

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})v, v \rangle > 0 \quad \forall v \in \mathcal{H}_+(\bar{x}) \setminus \{0\},$$

donde

$$\mathcal{H}_+(\bar{x}) = \{v \in \ker h'(\bar{x}) \mid \langle g'_i(\bar{x}), v \rangle = 0 \quad \forall i \in I_+(\bar{x})\},$$

$$I_+(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i > 0\}.$$

En el caso de complementariedad estricta, se tiene que $I_+(\bar{x}) = I(\bar{x})$ y, por lo tanto, $\mathcal{K}_+(\bar{x}) = \mathcal{K}(\bar{x})$ y la condición suficiente de segunda orden fuerte coincide con la condición suficiente de segunda orden común.

Investigaciones contemporáneas del método SQP y de diversas modificaciones del mismo tienen por objetivo el relajamiento de las hipótesis utilizadas para garantizar convergencia local superlineal. Desarrollos en esta dirección hacen uso de técnicas mucho más sofisticadas, que están fuera del alcance de este libro. El resultado más fuerte sobre convergencia local superlineal del método SQP (conocido actualmente) está basado en la condición suficiente de segunda orden (común) y en la hipótesis de que el multiplicador de Lagrange asociado a la solución sea único (esta última condición también se llama condición de Mangasarian-Fromovitz estricta; vea [12]).

Finalmente, comentaremos sobre la comparación de los métodos de Newton generalizados para el sistema KKT en la ?? con el método SQP. La convergencia local cuadrática de los métodos de Newton generalizados fue establecida bajo las hipótesis de independencia lineal de los gradientes de las restricciones activas y la condición suficiente de segunda orden fuerte (vea el Teorema 8.19), en cuanto el método SQP precisa de la unicidad del multiplicador de Lagrange y de la condición suficiente de segunda orden común, que son hipótesis mucho más débiles. En compensación, una iteración del método de Newton generalizado consiste en la resolución de un sistema de ecuaciones lineales, lo que tiene un coste computacional mucho menor de lo que la resolución de un problema de programación cuadrática en SQP. Notamos también que la condición (8.147) en el Teorema 8.20, que es necesaria para la convergencia superlineal en variables primales del método de Newton generalizado, es un poco más débil que la condición correspondiente en el caso de SQP (vea el Teorema 8.27). La estructura de SQP permite varias estrategias de globalización bastante naturales (que serán presentadas a continuación). La globalización del método de Newton generalizado también es posible, pero ella es más difícil y generalmente es menos eficiente desde el punto de vista computacional.

8.5.3. Globalización de convergencia de SQP

Para la globalización del método SQP pueden ser utilizadas tanto la estrategia de búsqueda lineal para una función de mérito adecuada, como la estrategia de regiones de confianza. Nosotros vamos a considerar a la primera opción, cuya implementación en el contexto de SQP es un poco más simple. La segunda opción puede ser consultada, por ejemplo, en [20].

De nuevo, consideremos el problema

$$\min f(x) \quad \text{sujeto a } x \in D = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} h(x) = 0, \\ g(x) \leq 0 \end{array} \right\}, \quad (8.252)$$

donde $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones suficientemente suaves. Sea

$$L: \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R},$$

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle,$$

la Lagrangiana del problema (8.252).

Como función de mérito en la búsqueda lineal en los métodos SQP, típicamente es utilizada alguna función de penalización exacta (vea la ??) para el problema (8.252). Por ejemplo, una elección común viene dada por

$$\varphi(\cdot; c): \mathbb{R}^n \rightarrow \mathbb{R}, \quad \varphi(x; c) = f(x) + c\psi(x), \quad (8.253)$$

donde

$$\psi(x) = \|h(x)\|_1 + \sum_{i=1}^m \max\{0, g_i(x)\}, \quad x \in \mathbb{R}^n, \quad (8.254)$$

y $c > 0$ es el parámetro de penalización.

Cabe resaltar que en esta sección, la cuestión de la tasa de convergencia de métodos SQP globalizados no será abordada. El objetivo consiste en garantizar convergencia global, en algún sentido, a puntos estacionarios del problema. El asunto de la interferencia de métodos globalizados con la tasa de convergencia local, así como las posibles modificaciones propuestas para evitar esto, serán considerados en la apartado 8.5.4.

Algoritmo 8.13 (El método SQP globalizado). Elegir los parámetros $\bar{c} > 0$, $\theta \in (0, 1)$ y $\sigma \in (0, 1)$. Elegir $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ y una matriz simétrica $H_0 \in \mathbb{R}^{n \times n}$. Tomar $k := 0$.

1. Calcular $d^k \in \mathbb{R}^n$, un punto estacionario del subproblema de programación cuadrática

$$\min \langle f'(x^k), d \rangle + \frac{1}{2} \langle H_k d, d \rangle \quad \text{sujeto a } d \in D_k, \quad (8.255)$$

$$D_k = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} h(x^k) + h'(x^k)d = 0, \\ g(x^k) + g'(x^k)d \leq 0 \end{array} \right\}, \quad (8.256)$$

y multiplicadores de Lagrange $y^k \in \mathbb{R}^l$ y $z^k \in \mathbb{R}_+^m$ asociados a d^k .

2. Si $d^k = 0$, parar. Caso contrario, elegir

$$c_k \geq \bar{c} + \|(y^k, z^k)\|_\infty \quad (8.257)$$

y calcular

$$\Delta_k = \langle f'(x^k), d^k \rangle - c_k \psi(x^k). \quad (8.258)$$

Tomar $\alpha = 1$.

3. Si la desigualdad

$$\varphi(x^k + \alpha d^k; c_k) \leq \varphi(x^k; c_k) + \sigma \alpha \Delta_k, \quad (8.259)$$

se satisface, tomar $\alpha_k = \alpha$. Caso contrario, tomar $\alpha := \theta \alpha$, verificar la validez de (8.259) de nuevo, etc., hasta que (8.259) se satisfaga.

4. Tomar $x^{k+1} = x^k + \alpha_k d^k$, $\lambda^{k+1} = y^k$, $\mu^{k+1} = z^k$.

5. Tomar $k := k + 1$, elegir una nueva matriz $H_k \in \mathbb{R}^{n \times n}$ simétrica, y retornar al Paso 1.

Observemos que la existencia de multiplicadores de Lagrange asociados a un punto estacionario en subproblemas de SQP es automática, ya que las restricciones de los subproblemas son lineales. Es importante que las normas que aparecen en las definiciones del término penalizador (8.254) y del valor del parámetro de penalización (8.257), estén en relación de dualidad, vea la ???. Si utilizamos alguna otra norma en (8.254), la elección (8.257) tiene que ser modificada para mantener la dualidad.

El Algoritmo 8.13 presupone que los subproblemas (8.255)-(8.256) poseen puntos estacionarios para todo k . En principio, esto no es siempre verdad. Primero, en general, hasta el conjunto factible del subproblema (8.255)-(8.256) puede ser vacío. No obstante, es fácil verificar lo siguiente.

Otra condición que evidentemente garantiza que $D_k \neq \emptyset$ es la independencia lineal de los gradientes $h'_i(x^k)$, $i = 1, \dots, l$, $g'_i(x^k)$, $i = 1, \dots, m$. Pero la validez de esta condición en cada punto de la secuencia $\{x^k\}$ generada por el método es una hipótesis bastante fuerte. Notemos, no obstante, que la viabilidad de los subproblemas puede ser asegurada introduciendo en las restricciones variables de holgura; vea el Ejercicio 8.52 más adelante.

Otra posible dificultad es que la función objetivo del problema (8.255)-(8.256) puede ser ilimitada inferiormente en el conjunto D_k (no vacío). En este caso, la existencia de puntos estacionarios también puede no estar garantizada. Es claro que esta situación no es posible si H_k es una matriz definida positiva. Por eso, realmente es deseable elegir H_k definida positiva, por lo menos mientras estemos lejos de la solución. De acuerdo con el Teorema 8.28 más adelante, para garantizar convergencia global del Algoritmo 8.13, la secuencia $\{H_k\}$ debe ser esencialmente cualquiera, siempre que las matrices sean uniformemente definidas positivas y uniformemente limitadas. En particular, podemos utilizar hasta una matriz fija para todo k , digamos $H_k = E^n$. Por otro lado, desde el punto de vista de convergencia local rápida, la elección deseable es $H_k = L''_{xx}(x^k, \lambda^k, \mu^k)$, vea la ???. Infelizmente, bajo hipótesis naturales sobre la solución del problema, no podemos garantizar que esta matriz sea definida positiva. En este sentido, puede ser útil sustituir la Lagrangiana por la Lagrangiana aumentada, con un valor del parámetro penalizador suficientemente grande (vea el Teorema 8.14 y el Ejercicio 8.49). Otra opción consiste en la modificación directa de las matrices $L''_{xx}(x^k, \lambda^k, \mu^k)$, como en la ???. Además de esto, hay estrategias de actualización de H_k cuasi-Newtonianas. En este caso, la regla de cálculo de la longitud de paso también tiene que ser modificada (vea los comentarios sobre la regla de Wolfe en la ??), para garantizar que H_k sea definida positiva para todo k . Las estrategias cuasi-Newtonianas tienen la ventaja de que ellas evitan el cálculo de las derivadas segundas de f , h y g .

Recordamos que $\psi'(x; d)$, la derivada direccional de la función ψ (dada por (8.254)) en el punto $x \in \mathbb{R}^n$ en la dirección $d \in \mathbb{R}^n$, tiene la siguiente forma (vea el Ejercicio 8.17):

$$\begin{aligned}\psi'(x; d) = & \sum_{j \in J^+(x)} \langle h'_j(x), d \rangle + \sum_{j \in J^0(x)} |\langle h'_j(x), d \rangle| \\ & - \sum_{j \in J^-(x)} \langle h'_j(x), d \rangle + \sum_{i \in I^+(x)} \langle g'_i(x), d \rangle \\ & + \sum_{i \in I(x)} \max\{0, \langle g'_i(x), d \rangle\},\end{aligned}$$

donde

$$\begin{aligned}J^+(x) &= \{j = 1, \dots, l \mid h_j(x) > 0\}, \\ J^0(x) &= \{j = 1, \dots, l \mid h_j(x) = 0\}, \\ J^-(x) &= \{j = 1, \dots, l \mid h_j(x) < 0\}, \\ I^+(x) &= \{i = 1, \dots, m \mid g_i(x) > 0\}, \\ I(x) &= \{i = 1, \dots, m \mid g_i(x) = 0\}.\end{aligned}$$

A continuación, mostramos que cuando H_k es definida positiva, la solución del subproblema del método SQP provee una dirección de descenso para la función de mérito elegida.

Lema 8.14 (Derivada de la función de mérito en la dirección de SQP). Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en el punto $x^k \in \mathbb{R}^n$. Sean $H_k \in \mathbb{R}^{n \times n}$ una matriz simétrica, $d^k \in \mathbb{R}^n$ un punto estacionario del problema (8.255)-(8.256), y $y^k \in \mathbb{R}^l$ y $z^k \in \mathbb{R}_+^m$ multiplicadores de Lagrange asociados, y c_k un número que satisface (8.257). Sean φ y ψ las funciones definidas por (8.253) y (8.254), respectivamente.

Entonces la función $\varphi(\cdot; c_k)$ es diferenciable en el punto x^k en cada dirección, y se tiene que

$$\varphi'((x^k; d^k); c_k) \leq \Delta_k \leq -\langle H_k d^k, d^k \rangle - \bar{c}\psi(x^k), \quad (8.260)$$

donde el número Δ_k está definido en (8.258).

Prueba. Por las condiciones KKT para el problema (8.255)-(8.256), el punto (d^k, y^k, z^k) satisface el sistema

$$f'(x^k) + H_k d^k + (h'(x^k))^T y^k + (g'(x^k))^T z^k = 0, \quad (8.261)$$

$$h(x^k) + h'(x^k) d^k = 0, \quad (8.262)$$

$$g(x^k) + g'(x^k) d^k \leq 0, \quad z^k \geq 0, \quad (8.263)$$

$$z_i^k (g_i(x^k) + \langle g'_i(x^k), d^k \rangle) = 0, \quad i = 1, \dots, m \quad (8.264)$$

(la relación (8.264) no será utilizada en esta demostración, pero será necesaria más adelante). De (8.262) se sigue que

$$\langle h'_j(x^k), d^k \rangle = -h_j(x^k) \quad \forall j = 1, \dots, l,$$

y, por lo tanto,

$$-|h_j(x^k)| = \begin{cases} \langle h'_j(x^k), d^k \rangle, & \text{si } j \in J^+(x^k), \\ |\langle h'_j(x^k), d^k \rangle|, & \text{si } j \in J^0(x^k), \\ -\langle h'_j(x^k), d^k \rangle, & \text{si } j \in J^-(x^k). \end{cases}$$

Además de eso, por la primera desigualdad en (8.263), tenemos que

$$-\max\{0, g_i(x^k)\} = \begin{cases} -g_i(x^k) \geq \langle g'_i(x^k), d^k \rangle, & \text{si } i \in I^+(x^k), \\ 0 = \max\{0, \langle g'_i(x^k), d^k \rangle\}, & \text{si } i \in I(x^k). \end{cases}$$

Utilizando la fórmula de la derivada direccional de la función $\psi(\cdot)$, dada arriba, obtenemos entonces

$$\begin{aligned}
 \varphi'((x^k; d^k); c_k) &= \langle f'(x^k), d^k \rangle + c_k \psi'(x^k; d^k) \\
 &\leq \langle f'(x^k), d^k \rangle - c_k \sum_{j=1}^l |h_j(x^k)| \\
 &\quad - c_k \sum_{i \in I^+(x^k) \cup I(x^k)} \max\{0, g_i(x^k)\} \\
 &= \langle f'(x^k), d^k \rangle - c_k \sum_{j=1}^l |h_j(x^k)| \\
 &\quad - c_k \sum_{i=1}^m \max\{0, g_i(x^k)\} \\
 &= \langle f'(x^k), d^k \rangle - c_k \psi(x^k) \\
 &= \Delta_k,
 \end{aligned}$$

donde la segunda igualdad se sigue del hecho de que para todo índice $i \notin \{1, \dots, m\} \setminus (I^+(x^k) \cup I(x^k))$, se tiene que $\max\{0, g_i(x^k)\} = 0$. Acabamos de probar la primera desigualdad en (8.260).

Multiplicando ambos lados de (8.261) por d^k y haciendo uso de (8.262) y (8.263), obtenemos que

$$\begin{aligned}
 \langle f'(x^k), d^k \rangle &= -\langle H_k d^k, d^k \rangle - \langle y^k, h'(x^k) d^k \rangle - \langle z^k, g'(x^k) d^k \rangle \\
 &= -\langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle + \langle z^k, g(x^k) \rangle \\
 &\leq -\langle H_k d^k, d^k \rangle + \sum_{j=1}^l |y_j^k| |h_j(x^k)| \\
 &\quad + \sum_{i=1}^m z_i^k \max\{0, g_i(x^k)\} \\
 &\leq -\langle H_k d^k, d^k \rangle + \|y^k\|_\infty \|h(x^k)\|_1 \\
 &\quad + \|z^k\|_\infty \sum_{i=1}^m \max\{0, g_i(x^k)\}.
 \end{aligned}$$

De aquí, utilizando (8.254), (8.257) y (8.258), obtenemos

$$\begin{aligned}
 \Delta_k &= \langle f'(x^k), d^k \rangle - c_k \psi(x^k) \\
 &\leq \langle f'(x^k), d^k \rangle - (\bar{c} + \|y^k\|_\infty) \|h(x^k)\|_1 \\
 &\quad - (\bar{c} + \|z^k\|_\infty) \sum_{i=1}^m \max\{0, g_i(x^k)\} \\
 &\leq -\langle H_k d^k, d^k \rangle - \bar{c} \|h(x^k)\|_1 \\
 &\quad - \bar{c} \sum_{i=1}^m \max\{0, g_i(x^k)\} \\
 &= -\langle H_k d^k, d^k \rangle - \bar{c} \psi(x^k),
 \end{aligned}$$

lo que es la segunda desigualdad en (8.260). ■

De la segunda desigualdad en (8.260), concluimos que para todo k , si la matriz H_k es definida positiva y el Algoritmo 8.13 genera $d^k \neq 0$, se tiene que

$$\Delta_k < 0. \quad (8.265)$$

De aquí y de la primera desigualdad en (8.260), es fácil ver que d^k es una dirección de descenso para la función $\varphi(\cdot; c_k)$ en el punto x^k (comparar con el ??). Por lo tanto, la regla de búsqueda lineal en el Paso 2 del método está bien definida, en el sentido de que ella acepta un valor de longitud de paso $\alpha_k > 0$, después de un número finito de disminuciones del valor inicial (comparar con el ??). A propósito, la regla de (8.259) sería una extensión obvia de la desigualdad de Armijo para el caso de una función no-diferenciable (que posee, sin embargo, derivadas direccionales). No obstante, la fórmula para el cálculo de Δ_k es más simple que la fórmula $\varphi'((x^k; d^k); c_k)$. En particular, (8.258) no contiene derivadas de las funciones h y g .

En principio, iteraciones del Algoritmo 8.13 utilizan valores diferentes del parámetro penalizador c_k . En el análisis de convergencia es conveniente admitir que este valor es fijo, por lo menos para todo k suficientemente grande:

$$c_k = c, \quad (8.266)$$

donde c es una constante. Notemos que en este caso, a partir de cierto paso k , el Algoritmo 8.13 puede ser pensado como un método de descenso para el problema irrestricto

$$\min \varphi(x; c), \quad x \in \mathbb{R}^n.$$

Recordamos que, bajo ciertas hipótesis, la penalización es exacta (vea la ??), ya que la validez de (8.257), para un $c_k = c$ fijo y todo k suficientemente grande, indica que el valor de este parámetro es adecuado.

Como es fácil observar de (8.257), la posibilidad de utilizar c_k fijo para todo k suficientemente grande presupone que la secuencia de multiplicadores $\{(y^k, z^k)\}$ generada por el método es limitada. Desde el punto de vista práctico, esto es completamente natural (por lo menos, cuando el conjunto de multiplicadores asociados al punto estacionario del problema original es limitado). De hecho, bajo ciertas hipótesis razonables, podemos garantizar que la secuencia $\{(y^k, z^k)\}$ sea limitada. Sin embargo, para simplificar el análisis, nosotros vamos simplemente a colocar esto como una hipótesis. Así, la validez de (8.266) para algún c y todo k suficientemente grande puede ser garantizada, por ejemplo, por la siguiente regla de elección de valores de c_k . En la primera iteración, tomamos $c_0 = \bar{c} + 1 + \|(y^0, z^0)\|_\infty$. Para cada iteración $k = 1, 2, \dots$, subsecuente, verificamos la validez de (8.257) para $c_k = c_{k-1}$. Si (8.257) se satisface, aceptamos este c_k ; caso contrario tomamos $c_k = \bar{c} + 1 + \|(y^k, z^k)\|_\infty$. Puede verse que si $\{(y^k, z^k)\}$ es limitada, los parámetros c_k así elegidos satisfacen (8.266) para algún c y todo k suficientemente grande.

Teorema 8.28 (Convergencia global del método SQP). Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en $\mathbb{R}^n$, con derivadas Lipschitz-continuas en $\mathbb{R}^n$. Supongamos que en el Algoritmo 8.13 las matrices H_k sean elegidas de tal manera que la secuencia $\{H_k\}$ sea limitada y las matrices sean uniformemente definidas positivas, i.e.,

$$\langle H_k v, v \rangle \geq \gamma \|v\|^2 \quad \forall v \in \mathbb{R}^n, \forall k, \quad (8.267)$$

donde $\gamma > 0$. Sea $\{(x^k, \lambda^k, \mu^k)\}$ una secuencia generada por este algoritmo y supongamos, para todo k suficientemente grande, que se satisfaga la condición (8.266), donde c es una constante.

Cuando $k \rightarrow \infty$, se tiene que o

$$\varphi(x^k; c_k) \rightarrow -\infty, \quad (8.268)$$

o

$$\begin{aligned} \{d^k\} &\rightarrow 0, \\ L'_x(x^k, \lambda^{k+1}, \mu^{k+1}) &\rightarrow 0, \\ h(x^k) &\rightarrow 0, \quad \max\{0, g_i(x^k)\} \rightarrow 0, \quad i = 1, \dots, m, \\ \langle \mu^{k+1}, g(x^k) \rangle &\rightarrow 0. \end{aligned}$$

En particular, si $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ es un punto de acumulación de la secuencia $\{(x^k, \lambda^k, \mu^k)\}$, entonces $\bar{x}$ es un punto estacionario del problema (8.252), en cuanto $\bar{\lambda}$ y $\bar{\mu}$ son multiplicadores de Lagrange asociados.

Prueba. Recordamos que (d^k, y^k, z^k) satisface las condiciones de optimalidad (8.261)-(8.264), para todo k . La segunda o tercera conclusión significan que el punto (x^k, y^k, z^k) resuelve el sistema KKT del problema (8.252), o que $d^k = 0$ da el resultado deseado. De aquí en adelante, suponemos que $d^k \neq 0 \forall k$. Notemos que, por (8.266) y (8.257), las secuencias $\{\lambda^k\}$ y $\{\mu^k\}$ son limitadas.

Primero probaremos que la secuencia de valores de las longitudes de pasos $\{\alpha_k\}$ está limitada inferiormente por un número fijo estrictamente positivo. Sea $\alpha \in (0, 1]$ arbitrario. Sea $M > 0$ el máximo entre los módulos de Lipschitz-continuidad de las derivadas de f, h y g en $\mathbb{R}^n$. Por el ??, para todo k y todo $i = 1, \dots, m$, obtenemos que

$$\begin{aligned} &\max\{0, g_i(x^k + \alpha d^k)\} - \max\{0, g_i(x^k) + \alpha \langle g'_i(x^k), d^k \rangle\} \\ &\leq \max\{0, g_i(x^k + \alpha d^k) - g_i(x^k) - \alpha \langle g'_i(x^k), d^k \rangle\} \\ &\leq |g_i(x^k + \alpha d^k) - g_i(x^k) - \alpha \langle g'_i(x^k), d^k \rangle| \\ &\leq \frac{M\alpha^2}{2} \|d^k\|^2, \end{aligned} \quad (8.269)$$

donde utilizamos los hechos de que, para todo $a, b \in \mathbb{R}$, se tiene que $\max\{0, a\} - \max\{0, b\} \leq \max\{0, a - b\}$ y $\max\{0, a\} \leq |a|$. Además de eso,

$$\begin{aligned} & \max\{0, g_i(x^k) + \alpha \langle g'_i(x^k), d^k \rangle\} \\ &= \max\{0, \alpha(g_i(x^k) + \langle g'_i(x^k), d^k \rangle) + (1 - \alpha)g_i(x^k)\} \\ &\leq \alpha \max\{0, g_i(x^k) + \langle g'_i(x^k), d^k \rangle\} + (1 - \alpha) \max\{0, g_i(x^k)\} \\ &= (1 - \alpha) \max\{0, g_i(x^k)\}, \end{aligned}$$

donde la desigualdad se sigue de la convexidad de la función $\max\{0, \cdot\}$, y la última igualdad se sigue de (8.263). De (8.269) obtenemos entonces que

$$\begin{aligned} \max\{0, g_i(x^k + \alpha d^k)\} &\leq \max\{0, g_i(x^k) + \alpha \langle g'_i(x^k), d^k \rangle\} + \frac{M\alpha^2}{2} \|d^k\|^2 \\ &\leq (1 - \alpha) \max\{0, g_i(x^k)\} + \frac{M\alpha^2}{2} \|d^k\|^2. \end{aligned} \quad (8.270)$$

Por el ??,

$$f(x^k + \alpha d^k) \leq f(x^k) + \alpha \langle f'(x^k), d^k \rangle + \frac{M\alpha^2}{2} \|d^k\|^2. \quad (8.271)$$

De modo similar, de (8.262) y del ??, tenemos que para todo $j = 1, \dots, l$,

$$\begin{aligned} |h_j(x^k + \alpha d^k)| &= |h_j(x^k + \alpha d^k) - \alpha h_j(x^k) - \alpha \langle h'_j(x^k), d^k \rangle| \\ &\leq (1 - \alpha) |h_j(x^k)| + \frac{M\alpha^2}{2} \|d^k\|^2. \end{aligned} \quad (8.272)$$

Utilizando (8.253), (8.254), y combinando las relaciones (8.270)-(8.272), obtenemos

$$\begin{aligned} \varphi(x^k + \alpha d^k; c_k) &= f(x^k + \alpha d^k) + c_k \|h(x^k + \alpha d^k)\|_1 \\ &\quad + c_k \sum_{i=1}^m \max\{0, g_i(x^k + \alpha d^k)\} \\ &\leq f(x^k) + \alpha \langle f'(x^k), d^k \rangle + c_k (1 - \alpha) \|h(x^k)\|_1 \\ &\quad + c_k (1 - \alpha) \sum_{i=1}^m \max\{0, g_i(x^k)\} + C_k \alpha^2 \|d^k\|^2 \\ &= \varphi(x^k; c_k) + \alpha \langle f'(x^k), d^k \rangle - c_k \|h(x^k)\|_1 \\ &\quad - c_k \sum_{i=1}^m \max\{0, g_i(x^k)\} + C_k \alpha^2 \|d^k\|^2 \\ &= \varphi(x^k; c_k) + \alpha \Delta_k + C_k \alpha^2 \|d^k\|^2, \end{aligned} \quad (8.273)$$

donde

$$C_k = M(1 + (l + m)c_k)/2 > 0.$$

Comparando la relación de arriba con (8.259), vemos que la desigualdad de (8.259) será satisfecha si

$$\Delta_k + C_k \alpha \|d^k\|^2 \leq \sigma \Delta_k,$$

o sea, para todo $\alpha \in (0, \bar{\alpha}_k]$, donde

$$\bar{\alpha}_k = \frac{(\sigma - 1)\Delta_k}{C_k \|d^k\|^2}.$$

Por la segunda desigualdad en (8.260) y por (8.267), se tiene que

$$\bar{\alpha}_k \geq (1 - \sigma)\gamma/C_k,$$

donde la secuencia $\{C_k\}$ está limitada, por (8.273) y por la igualdad de (8.266), que vale para todo k suficientemente grande. Concluimos que existe un número $\check{\alpha} > 0$, que no depende de k , tal que

$$\alpha_k \geq \check{\alpha} > 0. \quad (8.274)$$

De las relaciones (8.259), (8.266) y (8.274), obtenemos ahora que, para todo k suficientemente grande,

$$\varphi(x^{k+1}; c_{k+1}) \leq \varphi(x^k; c_k) + \sigma \check{\alpha} \Delta_k. \quad (8.275)$$

Recordamos que vale (8.265). Por lo tanto, la secuencia $\{\varphi(x^k; c_k)\}$ es decreciente. Entonces, o ella es ilimitada inferiormente (vale (8.268)) o ella converge. En este segundo caso, de (8.275) obtenemos que

$$\Delta_k \rightarrow 0 \quad (k \rightarrow \infty). \quad (8.276)$$

De donde, utilizando la segunda desigualdad en (8.260) y (8.267), así como el hecho de que $\{H_k\}$ es limitada, obtenemos

$$\psi(x^k) \rightarrow 0, \quad \{d^k\} \rightarrow 0, \quad \{H_k d^k\} \rightarrow 0 \quad (k \rightarrow \infty). \quad (8.277)$$

En particular, por la definición de $\psi(\cdot)$,

$$\{h(x^k)\} \rightarrow 0, \quad \max\{0, g_i(x^k)\} \rightarrow 0, \quad i = 1, \dots, m, \quad (k \rightarrow \infty). \quad (8.278)$$

Pasando al límite en la relación (8.261) cuando $k \rightarrow \infty$, y utilizando (8.277), obtenemos también que

$$L'_x(x^k, \lambda^{k+1}, \mu^{k+1}) \rightarrow 0 \quad (k \rightarrow \infty).$$

Para concluir la prueba, falta verificar que se satisfaga, asintóticamente, la condición de complementariedad. De (8.258), (8.276) y (8.277), obtenemos que

$$\langle f'(x^k), d^k \rangle = \Delta_k + c_k \psi(x^k) \rightarrow 0 \quad (k \rightarrow \infty).$$

Multiplicando (8.261) por d^k y utilizando la última relación y (8.277), obtenemos

$$\begin{aligned} & \langle \lambda^{k+1}, h'(x^k) d^k \rangle + \langle \mu^{k+1}, g'(x^k) d^k \rangle \\ &= -\langle f'(x^k), d^k \rangle - \langle H_k d^k, d^k \rangle \rightarrow 0 \quad (k \rightarrow \infty). \end{aligned}$$

Como de (8.262) y (8.278) se sigue que

$$h'(x^k) d^k = -h(x^k) \rightarrow 0 \quad (k \rightarrow \infty),$$

recordando que $\{\lambda^k\}$ es limitada, concluimos que

$$\langle \lambda^{k+1}, h'(x^k) d^k \rangle \rightarrow 0 \quad (k \rightarrow \infty).$$

Finalmente, de (8.264), obtenemos que

$$\langle \mu^{k+1}, g'(x^k) d^k \rangle = -\langle \mu^{k+1}, g(x^k) \rangle \rightarrow 0 \quad (k \rightarrow \infty).$$

■

La construcción siguiente es importante en la práctica, para lidiar con situaciones en que los subproblemas de SQP pueden ser inviables (i.e., pueden poseer conjunto factible vacío en algunas iteraciones).

El subproblema (??)-(??) (ver el Ejercicio 8.52), que también es un problema de programación cuadrática, puede servir para el desarrollo de un método SQP globalmente convergente, donde la viabilidad de los subproblemas es automática (vea, por ejemplo, [3; 4]). No obstante, esta ventaja viene con un cierto precio a pagar. Para garantizar convergencia de un método de este tipo, de nuevo precisamos que el valor del parámetro penalizador c_k sea suficientemente grande (en particular, mayor de lo que $\|(\bar{\lambda}, \bar{\mu})\|_1$, para todo k grande). Observamos que en el subproblema (??)-(??), c_k tiene que ser definido antes de la resolución de este subproblema, i.e., cuando las nuevas aproximaciones a los multiplicadores de Lagrange aún no están disponibles. Esto presenta un cierto nivel de dificultad tanto computacional como teórica. Mas existen algunas estrategias satisfactorias para la elección de c_k , por lo menos del punto de vista práctico.

8.5.4. Restauración de la convergencia local superlineal

De acuerdo con el Teorema 8.28, la convergencia global de métodos SQP puede ser garantizada bajo hipótesis bien razonables. Resta, no obstante, investigar la siguiente cuestión natural: ¿estos métodos globalizados preservan (o no) la convergencia local rápida del método SQP original? Cuando hay convergencia, en principio, por el Teorema 8.27 podemos esperar convergencia superlineal a una solución $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ del sistema KKT del problema si las matrices H_k aproximan a la matriz $L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})$ en el sentido de la relación (8.233). Resaltamos que esta aproximación no significa que necesariamente vale $\{H_k\} \rightarrow L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})$ ($k \rightarrow \infty$). Más aún, la validez de la última condición puede

no ser lograda, ya que la matriz $L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})$ puede no ser definida positiva. En cualquier caso, una aproximación adecuada de esta matriz no es suficiente para afirmar la convergencia superlineal del método globalizado: tenemos que garantizar que el valor de la longitud de paso $\alpha_k = 1$ (que corresponde a la iteración del método SQP puro) sea aceptado por la regla de búsqueda lineal, para todo k suficientemente grande. Será que esto es válido si el punto $(x^k, \lambda^k, \mu^k) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$ está próximo a $(\bar{x}, \bar{\lambda}, \bar{\mu})$, y si el punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$ satisface todas las hipótesis para convergencia superlineal del Teorema 8.27? Infelizmente, la respuesta es negativa, como puede ser visto del ejemplo siguiente. Este fenómeno se llama *efecto de Maratos*. Resaltamos que este ejemplo no es patológico o raro.

Ejemplo 8.11 (Efecto de Maratos). Sean $n = 2, l = 1, m = 0$,

$$f(x) = x_1, \quad h(x) = x_1^2 + x_2^2 - 1, \quad x \in \mathbb{R}^2.$$

La solución global del problema (8.252) es el punto $\bar{x} = (-1, 0)$. Este punto satisface la condición de regularidad de las restricciones (??), y el único multiplicador de Lagrange asociado es $\bar{\lambda} = 1/2$. Más aún, se satisface la condición suficiente de segunda orden (??).

Para $x^k \in \mathbb{R}^2$ cualquiera, sea $(d^k, y^k) \in \mathbb{R}^2 \times \mathbb{R}$ la solución del sistema de Lagrange del subproblema (8.255)-(8.256), donde utilizamos la elección $H_k = L''_{xx}(\bar{x}, \bar{\lambda}) = E^2$, i.e.,

$$1 + d_1^k + 2y^k x_1^k = 0, \quad d_2^k + 2y^k x_2^k = 0, \quad (8.279)$$

$$(x_1^k)^2 + (x_2^k)^2 - 1 + 2x_1^k d_1^k + 2x_2^k d_2^k = 0 \quad (8.280)$$

(vea (8.261), (8.262)). Notemos que la matriz H_k es definida positiva y para $x^k \neq 0$, las relaciones (8.279), (8.280), definen (d^k, y^k) unívocamente. Podríamos encontrar los valores de d^k y y^k explícitamente, pero no vamos a hacer esto aquí porque precisaremos solamente de las propiedades siguientes.

Multiplicando ambos lados de la primera igualdad en (8.279) por d_1^k , y de la segunda igualdad por d_2^k , y sumando las relaciones obtenidas, utilizando (8.280) obtenemos que

$$d_1^k = y^k((x_1^k)^2 + (x_2^k)^2 - 1) - (d_1^k)^2 - (d_2^k)^2.$$

Por lo tanto,

$$f(x^k + d^k) - f(x^k) = d_1^k = y^k h(x^k) - \|d^k\|^2.$$

De (8.280), obtenemos que

$$h(x^k + d^k) = (x_1^k + d_1^k)^2 + (x_2^k + d_2^k)^2 - 1 = \|d^k\|^2.$$

Por lo tanto,

$$\begin{aligned} & \varphi(x^k + d^k; c) - \varphi(x^k; c) \\ &= y^k h(x^k) - c|h(x^k)| + (c-1)\|d^k\|^2 > 0, \end{aligned}$$

para todo $c > 1$, si, por ejemplo, $h(x^k) = 0$ y el punto x^k no es estacionario para el problema (8.252) (lo que garantiza que $d^k \neq 0$; vea la demostración del Teorema 8.28). Esto muestra que $\alpha = 1$ no puede satisfacer la desigualdad de Armijo (8.259), ya que vale (8.265).

Notemos que toda vecindad del punto $\bar{x}$ contiene un número infinito de puntos factibles que no son estacionarios para el problema (8.252). De acuerdo con lo expuesto arriba, en todos estos puntos el valor de la longitud de paso $\alpha_k = 1$ no sería aceptado por la regla de búsqueda lineal (8.259).

Notemos que en el ejemplo anterior, para $c \in (1/2, 1)$ el valor de $\alpha_k = 1$ provee, sin embargo, un decrecimiento de la función $\varphi(\cdot; c)$ con respecto a su valor en el punto x^k . Para estos valores del parámetro penalizador, tal vez no haya contradicción entre los requerimientos para convergencia global y para convergencia local superlineal. Pero no es difícil modificar el ejemplo de modo que realmente no haya intervalo de valores del parámetro penalizador que puedan servir tanto para convergencia global como para convergencia local superlineal.

Ejemplo 8.12. En el Ejercicio 8.49, redefinimos

$$f(x) = x_1 + x_1^2 + x_2^2, \quad x \in \mathbb{R}^2.$$

La solución global del problema (8.252) es $\bar{x} = (-1, 0)$, con multiplicador de Lagrange $\bar{\lambda} = -1/2$. Como antes, el punto $\bar{x}$ satisface la condición de regularidad de las restricciones (??) y la condición suficiente de segunda orden (??).

Sea $x^k \in \mathbb{R}^2$ un punto cualquiera que no es un punto estacionario del problema (8.252) y que satisface $h(x^k) = 0$. Sea $(d^k, y^k) \in \mathbb{R}^2 \times \mathbb{R}$ la solución del sistema de Lagrange del subproblema (8.255)-(8.256), con $H_k = L''_{xx}(\bar{x}, \bar{\lambda}) = E^2$,

i.e.,

$$1 + 2x_1^k + d_1^k + 2y^k x_1^k = 0, \quad 2x_2^k + d_2^k + 2y^k x_2^k = 0, \quad (8.281)$$

$$x_1^k d_1^k + x_2^k d_2^k = 0 \quad (8.282)$$

(vea (8.261), (8.262)). Multiplicando la primera igualdad en (8.281) por d_1^k , y la segunda por d_2^k , y sumando las relaciones así obtenidas, utilizando también (8.282), obtenemos que

$$d_1^k + (d_1^k)^2 + (d_2^k)^2 = 0.$$

Por lo tanto,

$$\begin{aligned} f(x^k + d^k) - f(x^k) &= d_1^k + (x_1^k + d_1^k)^2 + (x_2^k + d_2^k)^2 - (x_1^k)^2 - (x_2^k)^2 \\ &= h(x^k + d^k) = (x_1^k + d_1^k)^2 + (x_2^k + d_2^k)^2 - 1 = \|d^k\|^2, \end{aligned}$$

donde de nuevo tomamos en cuenta (8.282). De estas relaciones, obtenemos que

$$\varphi(x^k + d^k; c) - \varphi(x^k; c) = c\|d^k\|^2 > 0 \quad \forall c > 0.$$

El efecto de Maratos puede ser explicado de la manera siguiente. Si un punto x^k está próximo al conjunto factible D , el paso de x^k a $x^k + d^k$ puede hacer aumentar el término penalizador por un valor de la misma magnitud de orden que la disminución de la función objetivo f . Como consecuencia, para c suficientemente grande, el valor de la función penalizada $\varphi(\cdot; c)$ puede aumentar, lo que hace que el valor de la longitud de paso $\alpha = 1$ no sea aceptado. Por eso, la cuestión de la convergencia local rápida de un método SQP globalizado es mucho más compleja que, por ejemplo, la misma cuestión para el método de Newton globalizado en el caso de optimización irrestricta (vea los ???). Para evitar el posible efecto de Maratos, el Algoritmo 8.13 tiene que ser modificado. Hay varias maneras de hacer esto. Una estrategia consiste en el cálculo de la longitud de paso por una búsqueda no lineal. Más precisamente, la búsqueda se hace a lo largo de la frontera del conjunto factible (vea [3; 20]). Vamos a presentar otra estrategia, que consiste en la modificación de la función de mérito. Más precisamente, utilizaremos la Lagrangiana aumentada no-diferenciable.

De aquí en adelante, consideremos el problema con restricciones de igualdad, en vez de (8.252), sea el problema dado por

$$\min f(x) \quad \text{sujeto a } x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}. \quad (8.283)$$

Introducimos la familia de funciones

$$\varphi(\cdot; c, \eta) : \mathbb{R}^n \rightarrow \mathbb{R},$$

$$\varphi(x; c, \eta) = f(x) + \langle \eta, h(x) \rangle + c\|h(x)\|_1, \quad (8.284)$$

donde $c \geq 0$ y $\eta \in \mathbb{R}^l$ son parámetros. La función anterior puede ser pensada como una Lagrangiana clásica del problema (8.283), aumentada por un término penalizador no-diferenciable. Tenemos la propiedad siguiente (comparar con el Corolario 8.1).

Proposición 8.7. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Supongamos que $\bar{x}$ sea un punto estacionario del problema (8.283), que satisface la condición suficiente de segunda orden del ??(b), con multiplicador de Lagrange $\bar{\lambda} \in \mathbb{R}^l$.

Entonces existe un número $\bar{c} \geq 0$ tal que, para todo $c > \bar{c}$ y todo $\eta \in \mathbb{R}^l$ satisfaciendo la desigualdad

$$c > \|\eta - \bar{\lambda}\|_\infty, \quad (8.285)$$

el punto $\bar{x}$ es una solución local estricta del problema

$$\min \varphi(x; c, \eta), \quad x \in \mathbb{R}^n,$$

donde la función objetivo es definida por la fórmula (8.284).

Prueba. Recordando la Lagrangiana aumentada (clásica) para el problema (8.283), y utilizando el Teorema 8.14, para todo $c > 0$ suficientemente grande tenemos que

$$\begin{aligned} \varphi(\bar{x}; c, \eta) &= f(\bar{x}) \\ &= L(\bar{x}, \bar{\lambda}) + \frac{c}{2} \|h(\bar{x})\|^2 \\ &< L(x, \bar{\lambda}) + \frac{c}{2} \|h(x)\|^2, \end{aligned} \quad (8.286)$$

para todo $x \in \mathbb{R}^n \setminus \{\bar{x}\}$ suficientemente próximo a $\bar{x}$. Por otro lado, para todo x suficientemente próximo a $\bar{x}$ (tal que $h(x)$ está suficientemente próximo a cero), se tiene que

$$\|h(x)\|^2 = o(\|h(x)\|_1).$$

Por lo tanto,

$$\begin{aligned} \varphi(x; c, \eta) &= L(x, \lambda) + \langle \eta - \lambda, h(x) \rangle + c\|h(x)\|_1 \\ &\geq L(x, \lambda) + (c - \|\eta - \lambda\|_\infty)\|h(x)\|_1 \\ &\geq L(x, \lambda) + \frac{c}{2}\|h(x)\|^2, \end{aligned} \quad (8.287)$$

donde utilizamos la desigualdad de Cauchy-Schwarz generalizada (??) y (8.285). Finalmente, combinando (8.286) y (8.287), obtenemos el resultado anunciado. ■

Para un iterando $x^k \in \mathbb{R}^n$, definimos

$$D_k = \{d \in \mathbb{R}^n \mid h(x^k) + h'(x^k)d = 0\}. \quad (8.288)$$

Sea $d^k \in \mathbb{R}^n$ un punto estacionario del subproblema de programación cuadrática (8.255), (8.288), y $y^k \in \mathbb{R}^l$ un multiplicador de Lagrange asociado. En particular,

$$f'(x^k) + H_k d^k + (h'(x^k))^T y^k = 0, \quad h(x^k) + h'(x^k)d^k = 0. \quad (8.289)$$

Utilizando el Ejercicio 8.17 y la relación (8.289), y siguiendo el razonamiento de la demostración del Lema 8.14, para toda dirección d^k se tiene la siguiente forma:

$$\varphi'((x^k; d^k); c, \eta) = -\langle H_k d^k, d^k \rangle + \langle y^k - \eta, h(x^k) \rangle - c\|h(x^k)\|_1. \quad (8.290)$$

De donde, si $c \geq \|y^k - \eta\|_\infty$, se tiene que

$$\varphi'((x^k; d^k); c, \eta) \leq -\langle H_k d^k, d^k \rangle. \quad (8.291)$$

Por lo tanto, si la matriz H_k es definida positiva y $d^k \neq 0$, entonces d^k es una dirección de descenso para la función $\varphi(\cdot; c, \eta)$ en el punto x^k .

Podemos entonces construir un método análogo al Algoritmo 8.13, utilizando la función de mérito $\varphi(\cdot; c, \eta)$. La condición (8.257) tiene que ser sustituida por

$$c_k \geq \bar{c} + \|y^k - \eta\|_\infty, \quad (8.292)$$

y la desigualdad (8.259) por

$$\varphi(x^k + \alpha d^k; c_k, \eta_k) \leq \varphi(x^k; c_k, \eta_k) + \sigma \alpha \varphi'((x^k; d^k); c_k, \eta_k). \quad (8.293)$$

El teorema siguiente, en combinación con el Teorema 8.27, muestra que para elecciones adecuadas de las matrices H_k , el método modificado posee tanto convergencia global como convergencia local superlineal. En relación a la condición (8.294), recordamos que bajo la condición suficiente de segunda orden en $\bar{x}$, la matriz $L''_{xx}(\bar{x}, \bar{\lambda}) + c(h'(\bar{x}))^T h'(\bar{x})$ es definida positiva para todo c suficientemente grande (vea el Teorema 8.14). La condición (8.294) para la elección de H_k significa que H_k debe ser una aproximación “superior” de la matriz introducida en el Teorema 8.26 para c suficientemente grande.

Teorema 8.29 (Convergencia local superlineal del método SQP globalizado). Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$ y $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones dos veces diferenciables en una vecindad del punto $\bar{x} \in \mathbb{R}^n$, con derivadas segundas continuas en este punto. Supongamos que $\bar{x}$ satisface la condición de regularidad de las restricciones (??), y que sea un punto estacionario del problema (8.283), con (único) multiplicador de Lagrange $\bar{\lambda} \in \mathbb{R}^l$ asociado. Supongamos que vale la condición suficiente de segunda orden del ??(b).

Supongamos también que $\{x^k\} \subset \mathbb{R}^n$ sea convergente a $\bar{x}$, que $\{d^k, y^k\} \in \mathbb{R}^n \times \mathbb{R}^l$, que $\{d^k\} \rightarrow 0$ (y que 0 es el vector nulo), y que el vector $\eta^k \in \mathbb{R}^l$ satisface (8.289), (8.292). Para todo k suficientemente grande, suponemos que la matriz simétrica $H_k \in \mathbb{R}^{n \times n}$ satisface la condición

$$\langle (H_k - L''_{xx}(\bar{x}, \bar{\lambda}) - c(h'(\bar{x}))^T h'(\bar{x}))d^k, d^k \rangle \geq o(\|d^k\|^2), \quad (8.294)$$

donde el número $c \geq 0$ es tal que la matriz $L''_{xx}(\bar{x}, \bar{\lambda}) + c(h'(\bar{x}))^T h'(\bar{x})$ es definida positiva.

Entonces para todo $\sigma \in (0, 1/2)$ existe $\delta > 0$ tal que para todo k suficientemente grande, la validez de las desigualdades

$$c_k \leq \delta, \quad \|\eta^k - \bar{\lambda}\| \leq \delta \quad (8.295)$$

implica la validez de la desigualdad (8.293) para $\alpha = 1$, donde la función $\varphi(\cdot; c, \eta)$ es dada por (8.284).

Prueba. De la relación (8.294) y de la elección del número c , se sigue que existe un número $\gamma > 0$ tal que, para todo k suficientemente grande,

$$\langle H_k d^k, d^k \rangle \geq \gamma \|d^k\|^2. \quad (8.296)$$

Además de eso, para todo k , de (8.294) y del hecho de que la matriz $(h'(\bar{x}))^\top h'(\bar{x})$ es semidefinida positiva, tenemos que

$$\langle L''_{xx}(\bar{x}, \bar{\lambda}) d^k, d^k \rangle \leq \langle H_k d^k, d^k \rangle + o(\|d^k\|^2). \quad (8.297)$$

De (8.289), obtenemos que

$$\begin{aligned} \langle f'(x^k), d^k \rangle &= -\langle H_k d^k, d^k \rangle - \langle y^k, h'(x^k) d^k \rangle \\ &= -\langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle. \end{aligned}$$

Utilizando el Teorema del Valor Medio y la última igualdad, obtenemos

$$\begin{aligned} f(x^k + d^k) &= f(x^k) + \langle f'(x^k), d^k \rangle + \frac{1}{2} \langle f''(x^k + \tilde{t}_k d^k) d^k, d^k \rangle \\ &= f(x^k) - \langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle \\ &\quad + \frac{1}{2} \langle f''(x^k), d^k \rangle + o(\|d^k\|^2), \end{aligned} \quad (8.298)$$

donde $\tilde{t}_k \in [0, 1]$, y usamos la convergencia de $\{x^k\}$ a $\bar{x}$, y de $\{d^k\}$ a cero. De manera análoga, utilizando la segunda igualdad en (8.289) y el Teorema del Valor Medio, tenemos que

$$\begin{aligned} h_i(x^k + d^k) &= h_i(x^k) + \langle h'_i(x^k), d^k \rangle + \frac{1}{2} \langle h''_i(x^k + \tilde{t}_k d^k) d^k, d^k \rangle \\ &= \frac{1}{2} \langle h''_i(x^k + \tilde{t}_k d^k) d^k, d^k \rangle \\ &= \frac{1}{2} \langle h''_i(\bar{x}) d^k, d^k \rangle + o(\|d^k\|^2). \end{aligned} \quad (8.299)$$

Ahora, combinando la relación (8.298) con la relación (8.299), obtenemos que

$$\begin{aligned} \varphi(x^k + d^k; c_k, \eta^k) &= f(x^k) - \langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle \\ &\quad + \frac{1}{2} \langle f''(\bar{x}) d^k, d^k \rangle + \frac{1}{2} \sum_{i=1}^l \eta_i^k \langle h''_i(\bar{x}) d^k, d^k \rangle \\ &\quad + \frac{c_k}{2} \sum_{i=1}^l |\langle h''_i(\bar{x}) d^k, d^k \rangle| + o(\|d^k\|^2) \\ &= f(x^k) - \langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle \\ &\quad + \frac{1}{2} \langle L''_{xx}(\bar{x}, \eta^k) d^k, d^k \rangle + O(c_k \|d^k\|^2) + o(\|d^k\|^2) \\ &= f(x^k) - \langle H_k d^k, d^k \rangle + \langle y^k, h(x^k) \rangle \\ &\quad + \frac{1}{2} \langle L''_{xx}(\bar{x}, \bar{\lambda}) d^k, d^k \rangle \\ &\quad + O(c_k \|d^k\|^2) + O(\|\eta^k - \bar{\lambda}\| \|d^k\|^2) + o(\|d^k\|^2). \end{aligned}$$

Por lo tanto, haciendo uso también de las relaciones (8.284), (8.290) y (8.297), concluimos que

$$\begin{aligned}
 & \varphi(x^k + d^k; c_k, \eta^k) - \varphi(x^k; c_k, \eta^k) \\
 &= -\langle H_k d^k, d^k \rangle + \frac{1}{2} \langle L''_{xx}(\bar{x}, \bar{\lambda}) d^k, d^k \rangle + \langle y^k - \eta^k, h(x^k) \rangle \\
 &\quad - c_k \|h(x^k)\|_1 + o(\|d^k\|^2) \\
 &= \varphi'((x^k; d^k); c_k, \eta^k) + \frac{1}{2} \langle L''_{xx}(\bar{x}, \bar{\lambda}) d^k, d^k \rangle \\
 &\quad + o(\|d^k\|^2) \\
 &\leq \varphi'((x^k; d^k); c_k, \eta^k) + \frac{1}{2} \langle H_k d^k, d^k \rangle + o(\|d^k\|^2).
 \end{aligned}$$

Ahora, bajo la condición (8.295), podemos escribir

$$\begin{aligned}
 & \varphi(x^k + d^k; c_k, \eta^k) - \varphi(x^k; c_k, \eta^k) \\
 &\leq \varphi'((x^k; d^k); c_k, \eta^k) + \frac{1}{2} \langle H_k d^k, d^k \rangle + O(\delta \|d^k\|^2) \\
 &\leq \sigma \varphi'((x^k; d^k); c_k, \eta^k) - \frac{1-2\sigma}{2} \langle H_k d^k, d^k \rangle + O(\delta \|d^k\|^2) \\
 &\leq \sigma \varphi'((x^k; d^k); c_k, \eta^k) - \frac{\gamma(1-2\sigma)}{2} \|d^k\|^2 + O(\delta \|d^k\|^2) \\
 &\leq \sigma \varphi'((x^k; d^k); c_k, \eta^k),
 \end{aligned}$$

donde la segunda desigualdad se sigue de (8.291), la tercera de (8.296), y la última vale para todo k suficientemente grande, si el número $\delta > 0$ es suficientemente pequeño. ■

Procedimientos concretos de elección de los parámetros c_k y η^k , que garanticen tanto convergencia global del método SQP como convergencia local superlineal, existen y pueden ser consultadas en la literatura especial. Como estos procedimientos son bastante complejos, ellos no serán presentados en este libro.

8.5.5. Otras técnicas de globalización

Para finalizar, mencionaremos algunas otras técnicas de globalización de métodos SQP. Sea $x^k \in \mathbb{R}^n$ una aproximación actual a un punto estacionario del problema. Como en el caso irrestricto, podemos considerar una aproximación del problema original en una vecindad específica (“región de confianza”) de x^k . Así obtenemos el subproblema (8.255), donde el conjunto factible D_k es dado por

$$D_k = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} h(x^k) + h'(x^k)d = 0, g(x^k) + g'(x^k)d \leq 0, \\ \|d\|_\infty \leq \delta_k \end{array} \right\} \quad (8.300)$$

(comparar con (8.256)), y $\delta_k > 0$ define la región de confianza. Sea d^k una solución global de este subproblema. El punto $x^k + d^k$ será aceptado como aproximación siguiente x^{k+1} si el paso de x^k a x^{k+1} provee un decrecimiento suficiente de la función de mérito elegida (típicamente, una función de penalización exacta). Si un decrecimiento suficiente no es alcanzado, el subproblema (8.255), (8.300), es resuelto con un valor del parámetro δ_k menor. La globalización por las técnicas de regiones de confianza presenta esencialmente las mismas dificultades potenciales que la globalización con búsqueda lineal presentada arriba (posible inviabilidad de subproblemas, elección inadecuada del parámetro penalizador, el efecto de Maratos). Hay aún la cuestión adicional del control del parámetro δ_k . Es claro que para un valor de δ_k pequeño, el conjunto D_k en (8.300) puede ser vacío incluso cuando el sistema dado por la linealización de las restricciones (sin la restricción de la región de confianza $\|d\|_\infty \leq \delta_k$) posee soluciones (que se encuentran fuera de esta región de confianza).

Recientemente, fue propuesta una nueva estrategia de globalización, llamada de *estrategia de filtros*. Pensamos en el residuo de las restricciones (por ejemplo, dado por el término penalizador ψ en (8.254)) como un criterio a ser minimizado, adicional a aquel dado por la función objetivo f . De este modo, la minimización de este criterio adicional puede ser considerada hasta más importante que la de f (en muchas aplicaciones, una aproximación a la solución del problema, antes de nada, tiene que ser factible para tener sentido práctico). Notemos que una función penalizada representa el criterio agregado, donde a la parte ψ se le da un peso importante cuando el valor del parámetro penalizador es grande. Por otro lado, podemos pensar en el problema original (8.252) como un problema de optimización multicriterial en $\mathbb{R}^n$ (más precisamente, bicriterial, los criterios siendo f y ψ). En vez de utilizar el valor de una función de mérito escalar (función penalizada) para decidir sobre la aceptación o no de un punto

$\tilde{x}$ como aproximación siguiente x^{k+1} a la solución del problema, podemos mirar separadamente los valores de las funciones f y ψ , y aceptar el punto $\tilde{x}$ si él mejora por lo menos uno de los dos criterios, con respecto a cada punto obtenido anteriormente. El método del filtro, por lo tanto, es un método con memoria. Después de la iteración k , tenemos en la memoria el filtro $\mathcal{F}_k$, i.e., un subconjunto de $\mathbb{R} \times \mathbb{R}$ finito, formado por pares $(f(x^j), \psi(x^j))$ calculados en las (algunas de las) iteraciones anteriores $j \leq k$. Son guardados en la memoria aquellos que no sean dominados por ningún otro par $(a_1, b_1) \in \mathcal{F}_k$ en el sentido de que las desigualdades $a_1 \geq a_2$ y $b_1 \geq b_2$ no pueden ser satisfechas simultáneamente. En particular, un punto $\tilde{x}$ será aceptado como el siguiente iterando x^{k+1} si el par $(f(\tilde{x}), \psi(\tilde{x}))$ no es dominado por ningún par en $\mathcal{F}_k$. Después de la aceptación de x^{k+1} , el nuevo filtro $\mathcal{F}_{k+1}$ es generado de la manera siguiente: el par $(f(\tilde{x}), \psi(\tilde{x}))$ entra en el filtro, mientras que todos los pares dominados por él son excluidos. Si $\tilde{x}$ no fue aceptado por la regla de arriba, disminuimos el valor de la longitud del paso α_k , o el valor del parámetro de la región de confianza δ_k , y probamos la nueva aproximación a la solución así obtenida. Esta descripción bien breve transmite apenas una idea general de la estrategia de filtros. Varios detalles tienen que ser cuidadosamente considerados e implementados para construir un método convergente.

Ejercicios del Capítulo

Sección 4.1: Métodos para conjuntos factibles de estructura simple

Ejercicio 8.1. Probar el Teorema 8.2.

Ejercicio 8.2. Probar las fórmulas siguientes.

- (a) Si $D = B(\hat{x}, \delta)$, donde $\hat{x} \in \mathbb{R}^n$, $\delta > 0$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = \begin{cases} y, & \text{si } y \in D, \\ \hat{x} + \delta(y - \hat{x})/\|y - \hat{x}\|, & \text{si } y \in \mathbb{R}^n \setminus D. \end{cases}$$

- (b) Si $D = \mathbb{R}_+^n$, entonces para todo $y \in \mathbb{R}^n$,

$$(P_D(y))_j = \max\{0, y_j\}, \quad j = 1, \dots, n.$$

- (c) Si $D = \{x \in \mathbb{R}^n \mid x_j \in [a_j, b_j], j = 1, \dots, n\}$, donde $a_j \leq b_j, j = 1, \dots, n$, son números dados, entonces para todo $y \in \mathbb{R}^n$,

$$(P_D(y))_j = \begin{cases} a_j, & \text{si } y_j < a_j, \\ y_j, & \text{si } a_j \leq y_j \leq b_j, \\ b_j, & \text{si } y_j > b_j, \end{cases} \quad j = 1, \dots, n.$$

- (d) Si $D = \{x \in \mathbb{R}^n \mid \langle a, x \rangle = b\}$, donde $a \in \mathbb{R}^n \setminus \{0\}, b \in \mathbb{R}$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = y + \frac{b - \langle a, y \rangle}{\|a\|^2} a.$$

- (e) Si $D = \{x \in \mathbb{R}^n \mid \langle a, x \rangle \leq b\}$, donde $a \in \mathbb{R}^n \setminus \{0\}, b \in \mathbb{R}$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = y + \frac{\min\{0, b - \langle a, y \rangle\}}{\|a\|^2} a.$$

- (f) Si $D = \{x \in \mathbb{R}^n \mid Ax = b\}$, donde $A \in \mathbb{R}^{l \times n}$ tiene rango $l, b \in \mathbb{R}^l$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = y - A^T(AA^T)^{-1}(Ay - b).$$

Ejercicio 8.3. Analizar las propiedades de convergencia del método del gradiente proyectado modificado, descrito en (8.16), suponiendo que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea una función continuamente diferenciable en $\mathbb{R}^n$ y D sea un conjunto convexo y cerrado.

Ejercicio 8.4. A partir del punto inicial $x^0 = (3, 1)$, hacer dos pasos del método del gradiente proyectado, con longitud de paso fijo, para el problema

$$\min x_1 - x_2 \quad \text{sujeto a } 1 \leq x_1 \leq 3, \quad 1 \leq x_2 \leq 2.$$

Ejercicio 8.5. Sea S_0 el conjunto de puntos estacionarios del problema original (8.1). Supongamos que, además de las hipótesis del ??, el conjunto de nivel $L_{f,D}(f(x^0))$ sea acotado. Probar que

$$\text{dist}(x^k, S_0 \cap L_{f,D}(f(x^0))) \rightarrow 0 \quad (k \rightarrow \infty).$$

(comparar con el ??).

Ejercicio 8.6. Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$ una función continuamente diferenciable y $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado. Considerar el método del gradiente proyectado con métrica variable, i.e., el esquema

$$x^{k+1} = x^k + \alpha_k(y^k - x^k),$$

donde $y^k \in \mathbb{R}^n$ es la solución del problema

$$\min \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle Q_k(x - x^k), x - x^k \rangle \quad \text{sujeto a } x \in D,$$

$Q_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, y el valor de la longitud de paso α_k es calculado por la regla de Armijo o por la regla de minimización unidimensional (si $Q_k = f''(x^k)$, obtenemos el método de Newton restringido a ser considerado en la ??). Mostrar que y^k también resuelve el problema

$$\min \|x - (x^k - Q_k^{-1} f'(x^k))\|_{Q_k}^2 \quad \text{sujeto a } x \in D,$$

donde la norma $\|\cdot\|_{Q_k}$ es dada por $\|x\|_{Q_k} = \sqrt{\langle Q_k x, x \rangle}$. Probar que si existen $c_2 \geq c_1 > 0$ tales que

$$c_1 \|x\|^2 \leq \langle Q_k x, x \rangle \leq c_2 \|x\|^2 \quad \forall x \in \mathbb{R}^n, \forall k,$$

entonces todo punto de acumulación de una secuencia $\{x^k\}$ así generada, es un punto estacionario del problema original (8.1).

Ejercicio 8.7. Probar el Lema 8.3 (sobre caracterización de direcciones factibles). Probar también que, en el caso de restricciones lineales (i.e., cuando g es una función afín), las desigualdades estrictas en la afirmación (b) del Lema 8.3 pueden ser sustituidas por desigualdades no estrictas.

Ejercicio 8.8. Sea

$$D = \{x \in \mathbb{R}^n \mid Ax \leq a\},$$

donde $A \in \mathbb{R}^{m \times n}$ es una matriz con filas $A_i, i = 1, \dots, m, a \in \mathbb{R}^m$. Mostrar que para todo $x^k \in D$ y todo $d^k \in \mathcal{V}_D(x^k)$, para $\hat{\alpha}_k$ definido en (8.20) tenemos lo siguiente:

(a) Si $\langle A_i, d^k \rangle > 0$ para por lo menos un $i \in \{1, \dots, m\}$, entonces

$$\hat{\alpha}_k = \min \left\{ \frac{a_i - \langle A_i, x^k \rangle}{\langle A_i, d^k \rangle} \mid i = 1, \dots, m : \langle A_i, d^k \rangle > 0 \right\}.$$

(b) Si $\langle A_i, d^k \rangle \leq 0 \forall i = 1, \dots, m$, entonces $\hat{\alpha}_k = +\infty$.

Ejercicio 8.9. A partir del punto inicial $x^0 = 0$, hacer dos iteraciones del método del gradiente restringido, con longitud de paso calculado por la minimización unidimensional, para el problema

$$\min x_1^2 + 2x_2^2 - 3x_1 + 4x_2 \quad \text{sujeto a } x \in B(0, 2).$$

Ejercicio 8.10. Sea $f: \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable con derivada Lipschitz-continua (con módulo $L > 0$) en el conjunto D que es convexo y compacto. Sea

$$+\infty > R = \max_{x, y \in D} \|x - y\|.$$

Dado un $x^k \in D$, sea $d^k = \bar{x}^k - x^k$, donde $\bar{x}^k$ es una solución del problema (8.21) de linealización de f .

(a) Probar que

$$\min_{\alpha \in [0, 1]} f(x^k + \alpha d^k) \leq f(x^k) + \Delta_k,$$

donde

$$0 \leq \Delta_k = \begin{cases} \frac{1}{2} \langle f'(x^k), d^k \rangle, & \text{si } \langle f'(x^k), d^k \rangle + L \|d^k\|^2 < 0, \\ -\frac{|\langle f'(x^k), d^k \rangle|^2}{2LR^2}, & \text{caso contrario.} \end{cases}$$

- (b) Para el método del gradiente restringido con regla de longitud de paso de minimización unidimensional restringida, mostrar que todo punto de acumulación de la secuencia generada es un punto estacionario del problema de minimizar f en D .

Ejercicio 8.11. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $x^k \in D \subset \mathbb{R}^n$, $f'(x^k) \neq 0$. Probar los siguientes resultados sobre soluciones $\bar{x}^k$ del problema (8.21):

- (a) Si $D = B(\hat{x}, \delta)$, donde $\hat{x} \in \mathbb{R}^n$, $\delta > 0$, entonces

$$\bar{x}^k = \hat{x} - \delta f'(x^k) / \|f'(x^k)\|.$$

- (b) Si $D = \{x \in \mathbb{R}^n \mid x_j \in [a_j, b_j], j = 1, \dots, n\}$, donde se tiene que $a_j \leq b_j, j = 1, \dots, n$, entonces todo $\bar{x}^k$ satisfaciendo

$$\bar{x}_j^k = \begin{cases} a_j, & \text{si } f'_{x_j}(x^k) > 0, \\ b_j, & \text{si } f'_{x_j}(x^k) < 0, \\ \in [a_j, b_j], & \text{si } f'_{x_j}(x^k) = 0, \end{cases}$$

$j = 1, \dots, n$, es una solución.

- (c) Si $D = \{x \in \mathbb{R}^n \mid x \geq 0, \sum_{i=1}^n x_i = c\}$, $c > 0$, entonces todo $\bar{x}^k$ satisfaciendo $\bar{x}_j^k = c$ para algún índice $j \in \{1, \dots, n\}$ tal que

$$f'_{x_j}(x^k) = \min\{f'_{x_i}(x^k) \mid i = 1, \dots, n\},$$

y $\bar{x}_i^k = 0$ para todo $i \in \{1, \dots, n\} \setminus \{j\}$, es una solución.

Ejercicio 8.12. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces continuamente diferenciable, con matriz Hessiana $f''(x)$ definida positiva en todo punto $x \in D$. Sea $\bar{x}$ un minimizador local de f en D . Probar que existe $\delta > 0$ tal que, si $\|x^0 - \bar{x}\| < \delta$, entonces el método de Newton restringido está bien definido y genera una secuencia $\{x^k\}$ satisfaciendo $\|x^k - \bar{x}\| < \delta \forall k$; $\{x^k\} \rightarrow \bar{x} (k \rightarrow \infty)$ y la tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal.

Sección 4.3: Métodos de penalización

Ejercicio 8.13. Probar las afirmaciones del Teorema 8.3, suponiendo que f y ψ son inferiormente semi-continuas en $\mathbb{R}^n$, ψ satisface (8.24), $D \neq \emptyset$ e $\inf_{x \in D} f(x) > -\infty$.

Ejercicio 8.14. Probar resultados análogos a aquellos de la Proposición 8.1 y del Teorema 8.3, para el método de penalización externa parcial.

Ejercicio 8.15. Suponiendo en vez de la existencia de una solución local estricta del problema (8.23), la existencia de un conjunto de soluciones locales compacto y aislado, probar un resultado análogo a aquel del Teorema 8.4. (Entendemos que un conjunto $S \subset \mathbb{R}^n$ de soluciones locales es aislado cuando existe un número $\delta > 0$ tal que la vecindad $U(S, \delta) = \{x \in \mathbb{R}^n \mid \text{dist}(x, S) < \delta\}$ de S no contiene soluciones locales que no pertenezcan a S).

Ejercicio 8.16. Considerar el problema (8.23), donde el conjunto factible D está dado por (8.25). Sean las funciones $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferenciables en una vecindad de una solución local $\bar{x} \in \mathbb{R}^n$ del problema, con derivadas continuas en este punto. Considerando el problema auxiliar

$$\min f(x) + \|x - \bar{x}\|^2 \quad \text{sujeto a } x \in D,$$

y utilizando los resultados del Teorema 8.4 y del ??, probar las condiciones de optimalidad de Fritz John (vea [12]).

Ejercicio 8.17. Sean $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en el punto $x \in \mathbb{R}^n$. Mostrar que la función ψ definida por (8.57) es diferenciable en x en cada dirección $d \in \mathbb{R}^n$, y se tiene que

$$\begin{aligned} \psi'(x; d) = & \sum_{i \in J^+(x)} \langle h'_i(x), d \rangle + \sum_{i \in J^0(x)} |\langle h'_i(x), d \rangle| \\ & - \sum_{i \in J^-(x)} \langle h'_i(x), d \rangle + \sum_{i \in I^+(x)} \langle g'_i(x), d \rangle \\ & + \sum_{i \in I^0(x)} \max\{0, \langle g'_i(x), d \rangle\}, \end{aligned}$$

donde $J^+(x) = \{i \mid h_i(x) > 0\}$, $J^0(x) = \{i \mid h_i(x) = 0\}$, etc.

Ejercicio 8.18. Probar resultados análogos a aquellos de los Teoremas 8.6 a 8.8, para la penalización exacta no-diferenciable dada por (8.60).

Ejercicio 8.19. Probar el mismo resultado del Teorema 8.9 suponiendo que la función f sea semi-continua inferiormente en $\mathbb{R}^n$, siendo las otras hipótesis las mismas del teorema.

Ejercicio 8.20. Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones convexas y diferenciables en $\mathbb{R}^n$. Sea $x(t)$ una solución del problema (8.78). Si la función barrera ψ es dada por (8.75), probar que

$$\bar{v} \leq f(x(t)) \leq \bar{v} + mt.$$

Si la función ψ es dada por (8.76), probar que

$$\bar{v} \leq f(x(t)) \leq \bar{v} - t \sum_{i=1}^m 1/g_i(x(t)).$$

Ejercicio 8.21. Probar análogos de la Proposición 8.3 y del Teorema 8.9 para el caso de la penalización interna parcial.

Sección 4.4: Métodos para problemas con restricciones de igualdad

Ejercicio 8.22. Resolver el problema

$$\min -x_1 x_2 \quad \text{sujeto a } x_1 + x_2 = 2,$$

utilizando el método de Newton para el sistema de Lagrange (el punto inicial puede ser arbitrario).

Ejercicio 8.23. Sean

$$R = \{x \in \mathbb{R}^n \mid \text{rank } h'(x) = l\},$$

$$\lambda_\tau: R \rightarrow \mathbb{R}^l, \quad \lambda_\tau(x) = (h'(x)(h'(x))^\top)^{-1}(\tau h(x) - h'(x)f'(x)),$$

donde $\tau \in \mathbb{R}$ es un parámetro. Suponiendo que $\bar{x}$ sea un punto estacionario del problema (8.86), que satisface la condición de regularidad de las restricciones (?), calcular la derivada de $\lambda_\tau(\cdot)$ en $\bar{x}$. Utilizando el resultado obtenido, construir un método de Newton inexacto para la ecuación

$$L'_x(x, \lambda_\tau(x)) = 0$$

con respecto a $x \in \mathbb{R}^n$. Eligiendo τ de manera adecuada, analizar las propiedades de convergencia de este método.

Ejercicio 8.24. Probar los siguientes hechos que complementan las afirmaciones del Teorema 8.13:

(a) Para todo número $\varepsilon > 0$ existe un número $c(\varepsilon) \geq \bar{c}$ tal que, para todo $c > c(\varepsilon)$, se tiene que

$$\frac{\|(L''_{xx}(\bar{x}, \bar{\lambda}))^{-1}\| \|\bar{\lambda}\| - \varepsilon}{c} \leq \|x(c) - \bar{x}\| \leq \frac{\|(L''_{xx}(\bar{x}, \bar{\lambda}))^{-1}\| \|\bar{\lambda}\| + \varepsilon}{c}.$$

(b) Para todo $c > \bar{c}$ suficientemente grande, se tiene que la matriz $\varphi''(x(c); c)$ es definida positiva, i.e., el punto estacionario $x(c)$ del problema (8.95) satisface la condición suficiente de segunda orden del ??(b).

Ejercicio 8.25. Utilizando el método de penalización cuadrática, resolver el problema

$$\min x \quad \text{sujeto a } x^p = 0,$$

donde $p \geq 2$ es un parámetro entero. Analizar la tasa de convergencia y explicar el fenómeno observado.

Ejercicio 8.26. Utilizando el método de penalización cuadrática, resolver los problemas:

$$\min 2x_1^2 + (x_2 - 1)^2 \quad \text{sujeto a } x \in D = \{x \in \mathbb{R}^2 \mid 2x_1 + x_2 = 0\},$$

$$\min x_1^2 + 2x_2^2 \quad \text{sujeto a } x \in D = \{x \in \mathbb{R}^2 \mid 3x_1 + x_2 = 3\}.$$

Ejercicio 8.27. Probar que, si para algunos $c > 0$ y $\lambda \in \mathbb{R}^l$, $x \in \mathbb{R}^n$ es un punto estacionario para el problema (8.110), y se tiene $\text{rank } h'(x) = l$, entonces

$$\lambda + ch(x) = -(h'(x)(h'(x))^\top)^{-1}h'(x)f'(x)$$

(comparar con el Ejercicio 8.23).

Ejercicio 8.28. Probar el siguiente complemento de la afirmación (a) del Teorema 8.15: para cualquier par $(\lambda, c) \in \Delta(\bar{c}, \delta)$, si c es suficientemente grande, entonces la matriz $L''_{xx}(x(\lambda, c), \lambda; c)$ es definida positiva, i.e., el punto estacionario $x(\lambda, c)$ del problema (8.110) satisface la condición suficiente de segunda orden del ??(b) (comparar con el ítem (b) del Ejercicio 8.24 y con el Teorema 8.14).

Ejercicio 8.29. Probar el ítem (a) del Teorema 8.16.

Ejercicio 8.30. Sea $R \subset \mathbb{R}^n$ el conjunto definido en el Ejercicio 8.23. Definimos

$$C(x) = (h'(x)(h'(x))^T)^{-1}h'(x), \quad \lambda(x) = -C(x)f'(x), \quad x \in R.$$

Mostrar que para la familia de funciones definida en (8.115), vale lo siguiente: para todo c y todo $x \in R$,

$$\min_{\lambda \in \mathbb{R}^l} \varphi(x, \lambda; c+1) = \varphi(x, \lambda(x); c+1) = L(x, \lambda(x); c).$$

Ejercicio 8.31. Construir y analizar métodos de Newton inexactos para los problemas de optimización irrestricta (8.114) y (8.116) con funciones objetivo dadas por las fórmulas (8.113) y (8.115), respectivamente, así como para el problema

$$\min L(x, \lambda(x); c) \quad \text{sueto a } x \in R$$

(en notación del Ejercicio 8.30).

Sección 4.5: Métodos para problemas con restricciones mixtas

Ejercicio 8.32. Mostrar que la función del residuo natural definida en (8.127) y la función de Fischer-Burmeister en (8.128) son efectivamente funciones de complementariedad.

Ejercicio 8.33. Sea $\omega : \mathbb{R} \rightarrow \mathbb{R}$ una función creciente cualquiera, $\omega(0) = 0$. Mostrar que

$$\psi : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}, \quad \psi(a, b) = \omega(|a - b|) - \omega(a) - \omega(b),$$

es una función de complementariedad.

Ejercicio 8.34. Sea $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ una función diferenciable en $\mathbb{R}^n$. Definamos una función $\Phi : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^m$ con componentes

$$\Phi_i(x, \mu) = \psi(-g_i(x), \mu_i), \quad x \in \mathbb{R}^n, \mu \in \mathbb{R}^m, i = 1, \dots, m,$$

donde ψ es la función de complementariedad del residuo natural (8.127). Mostrar que para todo $x \in \mathbb{R}^n$ tal que la derivada de g sea continua en x , y todo $\mu \in \mathbb{R}^m$, el B-diferencial $\partial_B \Phi(x, \mu)$ es el conjunto de matrices de la forma $(-A(x, \mu)g'(x), E^m - A(x, \mu))$, donde $A(x, \mu)$ es la matriz diagonal $m \times m$ con elementos

$$a_i(x, \mu) = \begin{cases} 1, & \text{si } \mu_i > -g_i(x), \\ 0 \text{ o } 1, & \text{si } \mu_i = -g_i(x), \\ 0, & \text{si } \mu_i < -g_i(x), \end{cases} \quad i = 1, \dots, m.$$

Ejercicio 8.35. En las condiciones del Ejercicio 8.34, considerar el caso en que ψ es la función de complementariedad de Fischer-Burmeister. Mostrar que para todo $x \in \mathbb{R}^n$ tal que la derivada de g sea continua en x , y todo $\mu \in \mathbb{R}^m$, $\partial_B \Phi(x, \mu)$ es el conjunto de matrices de la forma $(A(x, \mu)g'(x), B(x, \mu))$, donde $A(x, \mu)$ y $B(x, \mu)$ son las matrices diagonales $m \times m$ con elementos

$$a_i(x, \mu) = \begin{cases} 1 + \frac{g_i(x)}{\sqrt{\mu_i^2 + g_i^2(x)}}, & \text{si } |\mu_i| + |g_i(x)| \neq 0, \\ 1 + \alpha_i, & \text{si } |\mu_i| + |g_i(x)| = 0, \end{cases}$$

$$b_i(x, \mu) = \begin{cases} \frac{\mu_i}{\sqrt{\mu_i^2 + g_i^2(x)}} - 1, & \text{si } |\mu_i| + |g_i(x)| \neq 0, \\ \beta_i - 1, & \text{si } |\mu_i| + |g_i(x)| = 0, \end{cases}$$

con $\alpha_i, \beta_i \in \mathbb{R}, \alpha_i^2 + \beta_i^2 = 1, i = 1, \dots, m$.

Ejercicio 8.36. Mostrar que la función diferenciable $\psi(a, b) = 2ab - (\min\{0, a + b\})^2$ definida en (??) es una función de complementariedad.

Ejercicio 8.37. Utilizando los resultados del ??? (B-diferencial y subdiferencial de Clarke), probar la Proposición 8.4.

Ejercicio 8.38. Probar que para $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ cualesquiera, el punto $\bar{x} \in \mathbb{R}^n$ es una solución local (estricta) del problema (8.168) si, y solamente si, el punto $(\bar{x}, \bar{t})$, donde $\bar{t} \in \mathbb{R}^m$ es dado por (8.171), está bien definido y es una solución local (estricta) del problema (8.169)-(8.170).

Ejercicio 8.39. Probar que para cualesquiera $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferenciables en el punto $x \in \mathbb{R}^n$, la validez de la condición de independencia lineal de los gradientes extendida (8.177) en x implica la condición de regularidad de las restricciones del problema (8.169)-(8.170) en el punto (x, t) para todo $t \in \mathbb{R}^m$ tal que $t_i \neq 0 \forall i \in \{1, \dots, m\} \setminus (I(x) \cup I^+(x))$.

Ejercicio 8.40. Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones continuas en el punto $\bar{x} \in \mathbb{R}^n$. Mostrar que para todo $c \geq 0$, un punto $\bar{x}$ es solución local (estricta) del problema (8.174) con función objetivo dada por (8.173), (8.172), si, y solamente si, el punto $(\bar{x}, t(\bar{x}))$, donde la parte $t(\bar{x}) \in \mathbb{R}^m$ evalúa la holgura óptima definida por (8.184), es solución local (estricta) del problema (8.183) con función objetivo definida por (8.181), (8.182).

Ejercicio 8.41. Utilizando los Lemas 8.7 a 8.9, así como el Teorema 8.13 y el ítem (b) del Ejercicio 8.24, probar el Teorema 8.22.

Ejercicio 8.42. Utilizando el método de penalización cuadrática, resolver el problema

$$\min x^2 - 4x \quad \text{sueto a } x \in D = \{x \in \mathbb{R} \mid x \leq 1\}.$$

Ejercicio 8.43. Probar el Lema 8.11.

Ejercicio 8.44. Probar el Lema 8.12.

Ejercicio 8.45. Utilizando los Lemas 8.7, 8.11 y 8.12, el Teorema 8.15 y el Ejercicio 8.28, probar el Teorema 8.24.

Ejercicio 8.46. Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Mostrar que si $\bar{x}$ es un punto estacionario del problema (8.168), con multiplicadores de Lagrange $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$ asociados, entonces para todo $c_1 > 0$ y $c_2 \geq 0$, el punto $(\bar{x}, \bar{\lambda}, \bar{\mu})$ es estacionario para el problema (8.206) con función objetivo dada por la fórmula (8.205).

Ejercicio 8.47. Probar el Lema 8.13.

Ejercicio 8.48. Utilizando los Lemas 8.7 y 8.13, el Teorema 8.16 y el Ejercicio 8.46, probar el Teorema 8.25.

Sección 4.6: Programación cuadrática secuencial (SQP)

Ejercicio 8.49. Establecer relaciones entre el subproblema definido para (8.208) con la matriz $H_k = L''_{xx}(x^k, \lambda^k)$ dada en (8.209), y el subproblema análogo, donde

$$H_k = L''_{xx}(x^k, \lambda^k) + c_k(h'(x^k))^T h'(x^k),$$

$c_k > 0$. ¿Cuáles son las posibles ventajas de esta segunda elección en el contexto de SQP?

Ejercicio 8.50. Para el problema (8.207), considerar el siguiente método del gradiente proyectado modificado:

$$x^{k+1} = P_{D_k}(x^k - \alpha_k f'(x^k)), \quad k = 0, 1, \dots,$$

donde $\alpha_k > 0$ es el parámetro de longitud de paso, y el conjunto D_k es el mismo de (8.208). Establecer relaciones con el método SQP (con elección de H_k correspondiente). Estudiar convergencia local de este método.

Ejercicio 8.51. Mostrar que si $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ es una función afín, g es una función convexa diferenciable en el punto $x^k \in \mathbb{R}^n$, y el conjunto factible D del problema original (8.252) es no-vacío, entonces el conjunto factible D_k del subproblema (8.255)-(8.256) también es no-vacío, para todo k .

Ejercicio 8.52. Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones dos veces diferenciables. Considerar el problema (??)-(??),

$$\min c_k t + \langle f'(x^k), d \rangle + \frac{1}{2} \langle H_k d, d \rangle \quad \text{sueto a } (t, d) \in U_k,$$

donde $c_k > 0$. Sea la función φ dada por (8.253), donde la función ψ es dada por (8.254). Mostrar que si $d^k \neq 0$, entonces d^k es una dirección de descenso para la función $\varphi(\cdot; c_k)$ en el punto x^k .

9. Métodos para optimización no diferenciable

Este capítulo está dedicado al área de la optimización convexa no diferenciable. Resaltamos que las técnicas que se presentarán son relevantes incluso para la resolución de algunas clases de problemas que son, en principio, diferenciables y/o no convexos. Más precisamente, estamos hablando de aplicaciones prácticas de gran escala cuya resolución emplea estrategias de relajación Lagrangiana¹, así como algunas otras técnicas de descomposición. Como vimos en [SolodovVol1] (véase también la ??), el dual de un problema de optimización cualquiera puede ser considerado como un problema de programación convexa, pero no diferenciable. Con frecuencia, la resolución del problema dual proporciona información muy útil sobre el problema primal y, bajo ciertas condiciones, puede incluso resultar en la resolución exacta del primal. Como veremos a continuación, los problemas no diferenciables necesitan el desarrollo de técnicas computacionales propias, diferentes de aquellas para el caso diferenciable.

Consideremos entonces el problema

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (9.1)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa en $\mathbb{R}^n$. Estamos pensando en situaciones en las que es cierto que f no es diferenciable, o cuando la diferenciable de f difícilmente puede ser esperada.

Por el ??(a), la derivada direccional de la función f en el punto $x \in \mathbb{R}^n$ en la dirección $d \in \mathbb{R}^n$ satisface la condición

$$f'(x; d) = \max\{\langle y, d \rangle \mid y \in \partial f(x)\}, \quad (9.2)$$

donde $\partial f(x)$ es el subdiferencial de f en el punto x , i.e.,

$$\partial f(x) = \{y \in \mathbb{R}^n \mid f(z) \geq f(x) + \langle y, z - x \rangle \quad \forall z \in \mathbb{R}^n\}.$$

De la relación (9.2), obtenemos la siguiente condición que es necesaria y suficiente para que $d \in \mathbb{R}^n$ sea una dirección de descenso de f en el punto x :

$$d \in \mathcal{D}_f(x) \iff \langle y, d \rangle < 0 \quad \forall y \in \partial f(x).$$

Una consecuencia inmediata de esto es el siguiente hecho, claramente desafortunado: para obtener una dirección de descenso de la función f en un punto dado x , necesitamos conocer todo el conjunto subdiferencial $\partial f(x)$ (recordamos que este conjunto siempre es no vacío; véase el ??). En particular, tomando un subgradiente cualquiera, la dirección de anti-subgradiente puede no ser de descenso, como veremos en el siguiente ejemplo.

Ejemplo 9.1. Sea $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, $f(x) = |x_1| + 2|x_2|$. Consideremos un punto $x = (x_1, 0)$, donde $x_1 > 0$ es arbitrario. Como es muy fácil de verificar,

$$y = (1, 2) \in \partial f(x).$$

Sin embargo, para todo $t > 0$ suficientemente pequeño,

$$f(x - ty) = |x_1 - t| + 2|0 - 2t| = x_1 - t + 4t = x_1 + 3t > x_1 = f(x),$$

lo que muestra que

$$-y \notin \mathcal{D}_f(x).$$

Este hecho se ilustra en la figura 9.1.

Es importante resaltar que, en la gran mayoría de las aplicaciones prácticas, conocer todo el conjunto $\partial f(x)$ para cada x , es decir, todos los subgradientes, no puede ser esperado. Un buen ejemplo de esta situación es la relajación

¹En inglés: *Lagrangian relaxation*.




Figura 9.1.: Las curvas de nivel de la función $f(x) = |x_1| + 2|x_2|$, las direcciones de descenso en el punto $x = (x_1, 0)$, donde $x_1 > 0$, y la dirección $-y = -(1, 2)$ que es un anti-subgradiente de f en x pero no es una dirección de descenso de f en x .

Lagrangiana, donde la evaluación de la función dual en un punto dado proporciona, en general, apenas un subgradiente (véase la ??). Es válido afirmar, sin lugar a dudas, que un método para optimización no diferenciable solo puede ser considerado práctico si funciona utilizando información *incompleta*. O sea, para cada punto dado, la información disponible consiste en valores de la función objetivo y de *un* subgradiente en este punto (y de construcciones que pueden ser obtenidas a través de información de este tipo, acumulada a lo largo de iteraciones anteriores).

Lo expuesto arriba ya muestra que la utilización de ideas de descenso, comunes y naturales en el caso diferenciable, va a ser problemática en el caso en consideración. Al menos sin modificaciones bastante profundas.

Otra dificultad importante consiste en la elección de reglas de parada confiables. En el caso de optimización diferenciable, una regla de parada razonable está dada por la condición $\|\nabla f(x^k)\| \leq \varepsilon$, donde $\varepsilon > 0$ es suficientemente pequeño. Es fácil ver que esta regla no puede ser extendida de manera directa al caso no diferenciable (esto tiene que ver con la falta de “continuidad” del operador punto-conjunto $x \mapsto \partial f(x)$). Para ver esto, consideremos el siguiente ejemplo, bien simple.

Ejemplo 9.2. Sean $n = 1$, $f(x) = |x|$, $x \in \mathbb{R}$. Para cualquier punto $x^k \neq 0$, no importa cuán próximo a la solución $\bar{x} = 0$ del problema (9.1), se tiene que $|y| = 1$ para todo $y \in \partial f(x^k)$. O sea, no importa cuán próximo está $x^k \neq 0$ a la solución, en x^k no hay ningún subgradiente con norma pequeña. Más aún, incluso si tuviéramos la suerte de encontrar la solución exacta después de un número finito de iteraciones, i.e., $x^k = 0$ para algún k , este hecho puede no ser reconocido (y el método no va a parar) si conocemos apenas un subgradiente en cada punto. Esto porque la “caja negra”, que calcula subgradiantes, puede proporcionar cualquier $y \in \partial f(0) = [-1, 1]$ y, por lo tanto, $|y|$ puede ser grande.

No entrando en detalles, afirmamos que otros tipos de reglas de parada, comunes en el caso diferenciable, también son completamente inadecuadas en el caso no diferenciable.

En este capítulo, primero consideraremos **métodos de subgradiente**, bien básicos. Entre otras cosas, esto se debe a razones históricas. Sin embargo, es importante dejar claro que los métodos de subgradiente son rústicos y generalmente ineficientes. Aún son utilizados, en gran parte debido a su extrema simplicidad, por personas de otras áreas que con frecuencia no conocen opciones más sofisticadas. Profesionales en optimización emplean métodos de subgradiente solamente en aplicaciones donde una aproximación a la solución bien grosera puede ser aceptable. Notemos también que los métodos de subgradiente no permiten ninguna regla de parada razonable. Este último problema es resuelto con el **método de planos cortantes**, que consideraremos a continuación. Cada iteración de este método consiste en la minimización del máximo de funciones afines, acumuladas en las iteraciones anteriores, que aproximan la función objetivo inferiormente. Notemos que esto puede ser hecho resolviendo un problema de programación lineal. Sin embargo, el método de planos cortantes también tiene algunas deficiencias serias. Por ejemplo, inestabilidad numérica. Los métodos verdaderamente satisfactorios son las versiones estabilizadas del método de planos cortantes, llamados **métodos de haces** (*bundle methods*). Cada iteración de estos métodos consiste en la minimización del máximo de *algunas* de las funciones afines acumuladas en las iteraciones anteriores, más un término cuadrático estabilizador. Notemos que esto puede ser hecho resolviendo un problema de programación

cuadrática. Los métodos de haces ya vienen con reglas de parada confiables, control efectivo del tamaño de los subproblemas a ser resueltos en cada iteración (lo que no es posible en el método de planos cortantes), y eficiencia computacional comprobada. Puede decirse que fue el desarrollo de los métodos de haces lo que posibilitó la resolución de problemas no diferenciables en aplicaciones prácticas, especialmente cuando la precisión es importante.

9.1. Métodos de subgradiente

En los métodos de subgradiente, la dificultad para garantizar el descenso de la función objetivo en cada iteración (véase el Ejemplo 9.1 y los comentarios asociados) es “resuelta” simplemente fijando a priori una sucesión de valores de las longitudes de paso, sin preocuparse por el descenso de la función objetivo (al menos de una iteración para otra). Es bien claro que la fijación de la longitud de paso para una iteración k antes de que el punto x^k sea calculado (así como los valores $f(x^k)$ y $y^k \in \partial f(x^k)$), difícilmente puede dar una buena elección. Por lo tanto, esta manera de sortear la dificultad asociada al descenso de la función objetivo es puramente formal y, aun cuando resuelva la situación en el análisis de convergencia teórica, no es satisfactoria en la realidad.

A continuación introducimos el método de subgradiente básico, donde utilizaremos subgradientes aproximados. Esto torna el esquema un poco más práctico, por lo menos en este aspecto (obviamente, la posibilidad de utilizar subgradientes aproximados no resuelve las dificultades principales, comentadas anteriormente). Recordemos que para $\varepsilon \geq 0$, el ε -subdiferencial de la función f en el punto $x \in \mathbb{R}^n$ (véase ??) viene dado por

$$\partial_\varepsilon f(x) = \{y \in \mathbb{R}^n \mid f(z) \geq f(x) + \langle y, z - x \rangle - \varepsilon \quad \forall z \in \mathbb{R}^n\}. \quad (9.3)$$

El subdiferencial $\partial f(x)$ es obtenido tomando $\varepsilon = 0$.

Algoritmo 5.1.1. (El método de subgradiente)

Elegir sucesiones $\{\varepsilon_k\}, \{\alpha_k\} \subset \mathbb{R}_+$. Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular $d^k \in \partial_{\varepsilon_k} f(x^k)$.

2. Calcular

$$x^{k+1} = x^k - \alpha_k d^k. \quad (9.4)$$

3. Tomar $k := k + 1$ y retornar al Paso 1.

Estudiaremos propiedades de convergencia del Algoritmo 5.1.1.

Teorema 9.1 (Convergencia del método de subgradiente I). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa en $\mathbb{R}^n$. Supongamos que en el Algoritmo 5.1.1 las sucesiones $\{\varepsilon_k\}, \{\alpha_k\}$ y $\{d^k\}$ satisfacen las condiciones

$$\sum_{k=0}^{\infty} \alpha_k = +\infty, \quad (9.5)$$

$$\lim_{k \rightarrow \infty} \varepsilon_k = 0, \quad (9.6)$$

$$\lim_{k \rightarrow \infty} \alpha_k \|d^k\|^2 = 0. \quad (9.7)$$

Entonces, para la sucesión $\{x^k\}$ generada por el Algoritmo 5.1.1, se tiene que

$$\liminf_{k \rightarrow \infty} f(x^k) = \bar{v},$$

donde $\bar{v} = \inf_{x \in \mathbb{R}^n} f(x)$.

Prueba. Por las relaciones (9.3) y (9.4), para cualquier $x \in \mathbb{R}^n$ tenemos que

$$\begin{aligned} \|x^{k+1} - x\|^2 &= \|x^k - x\|^2 + 2\langle x^{k+1} - x^k, x^k - x \rangle + \|x^{k+1} - x^k\|^2 \\ &= \|x^k - x\|^2 + 2\alpha_k \langle d^k, x - x^k \rangle + \alpha_k^2 \|d^k\|^2 \\ &\leq \|x^k - x\|^2 + 2\alpha_k (f(x) - f(x^k) + \varepsilon_k) + \alpha_k^2 \|d^k\|^2. \end{aligned} \quad (9.8)$$

Supongamos que la afirmación no sea verdadera, i.e., que $\liminf_{k \rightarrow \infty} f(x^k) > \bar{v}$. En este caso, existen $x \in \mathbb{R}^n$, un número $\delta > 0$ y un índice $\bar{k}$, tales que

$$f(x) < f(x^k) - \delta \quad \forall k \geq \bar{k}. \quad (9.9)$$

De (9.6) y (9.7), se sigue que podemos tomar $\bar{k}$ suficientemente grande para satisfacer

$$\alpha_k \|d^k\|^2 + 2\varepsilon_k \leq \delta \quad \forall k \geq \bar{k}.$$

Combinando esta última relación con (9.8) y (9.9), obtenemos que

$$\begin{aligned} \|x^{k+1} - x\|^2 &\leq \|x^k - x\|^2 + \alpha_k(2\varepsilon_k + \alpha_k \|d^k\|^2 - 2\delta) \\ &\leq \|x^k - x\|^2 - \delta\alpha_k \quad \forall k \geq \bar{k}. \end{aligned}$$

Por lo tanto,

$$\delta \sum_{i=\bar{k}}^k \alpha_i \leq \sum_{i=\bar{k}}^k (\|x^i - x\|^2 - \|x^{i+1} - x\|^2) = \|x^{\bar{k}} - x\|^2 - \|x^{k+1} - x\|^2 \leq \|x^{\bar{k}} - x\|^2,$$

de donde obtenemos una contradicción con (9.5) cuando $k \rightarrow \infty$. ■

Si hiciéramos una normalización de las direcciones empleadas en el Algoritmo 5.1.1, las afirmaciones sobre convergencia del método pueden ser fortalecidas (para una elección de longitudes de paso más específica, véase (9.10) y (9.12) a continuación). Para simplificar, consideremos el caso de subgradiientes exactos. Obtenemos entonces el esquema siguiente:

$$x^{k+1} = x^k - \beta_k \frac{d^k}{\|d^k\|}, \quad d^k \in \partial f(x^k), \quad k = 0, 1, \dots, \quad (9.10)$$

donde $\beta_k > 0$ es el parámetro de longitud de paso (naturalmente, si en x^k calculamos el subgradiente $d^k = 0$, el método se detiene).

Teorema 9.2 (Convergencia del método de subgradiente II). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa en $\mathbb{R}^n$. Supongamos que el problema (9.1) tenga una solución. Supongamos que en el Algoritmo 5.1.1,

$$\varepsilon_k = 0, \quad \alpha_k = \frac{\beta_k}{\|d^k\|} \quad \forall k, \quad (9.11)$$

lo que corresponde a (9.10), y que la sucesión $\{\beta_k\}$ satisfaga las condiciones

$$\sum_{k=0}^{\infty} \beta_k = +\infty, \quad \sum_{k=0}^{\infty} \beta_k^2 < +\infty. \quad (9.12)$$

Entonces toda sucesión $\{x^k\}$ generada por el Algoritmo 5.1.1 converge a una solución del problema (9.1).

Prueba. Sea $\bar{x} \in \mathbb{R}^n$ una solución del problema (9.1). Obviamente, $f(\bar{x}) \leq f(x^k)$ para todo k . Tomando en (9.8) $x = \bar{x}$, y teniendo en cuenta también (9.11), obtenemos que

$$\|x^{k+1} - \bar{x}\|^2 \leq \|x^k - \bar{x}\|^2 + \beta_k^2.$$

El resto de la demostración es similar a la parte correspondiente del Teorema 3.3. Sea k arbitrario pero fijo. Utilizando la última desigualdad en cadena, para cualquier $j \geq k + 1$, obtenemos

$$\begin{aligned} \|x^j - \bar{x}\|^2 &\leq \|x^k - \bar{x}\|^2 + \sum_{i=k}^{j-1} \beta_i^2 \\ &\leq \|x^k - \bar{x}\|^2 + \sum_{i=0}^{\infty} \beta_i^2 < +\infty, \end{aligned} \quad (9.13)$$

por la segunda relación en (9.12). Concluimos que la sucesión $\{x^k\}$ es acotada. Por lo tanto, por el ??, la sucesión $\{d^k\}$ también es acotada (ya que $d^k \in \partial f(x^k)$ para todo k). Por eso, de (9.11) y (9.12), obtenemos que las relaciones (9.5)-(9.7) se satisfacen. Ahora, por el Teorema 9.1, tenemos que $\liminf_{k \rightarrow \infty} f(x^k) = f(\bar{x})$. Teniendo en cuenta la continuidad de la función f en $\mathbb{R}^n$ (véase el ??) y el hecho de que la sucesión $\{x^k\}$ es acotada, concluimos que $\{x^k\}$ posee un punto de acumulación $\hat{x} \in \mathbb{R}^n$ tal que $f(\hat{x}) = f(\bar{x})$, i.e., $\hat{x}$ es una solución del problema (9.1).

Podemos entonces tomar $\bar{x} = \hat{x}$ en el análisis previo, para concluir, de (9.13), que para todo $j \geq k + 1$

$$\|x^j - \hat{x}\|^2 \leq \|x^k - \hat{x}\|^2 + \sum_{i=k}^{\infty} \beta_i^2, \quad (9.14)$$

donde, de (9.12),

$$\lim_{k \rightarrow \infty} \left(\sum_{i=k}^{\infty} \beta_i^2 \right) = 0.$$

En particular, para todo $\delta > 0$ arbitrariamente pequeño, podemos escoger k suficientemente grande, tal que

$$\delta/2 > \sum_{i=k}^{\infty} \beta_i^2.$$

Como $\hat{x}$ es un punto de acumulación de la sucesión $\{x^k\}$, podemos también escoger un k tal que

$$\delta/2 > \|x^k - \hat{x}\|^2.$$

De (9.14), concluimos que para todo $\delta > 0$, existe k tal que

$$\delta > \|x^j - \hat{x}\|^2 \quad \forall j \geq k+1.$$

Esto significa que $\{x^k\}$ converge a $\hat{x}$, que es una solución del problema. ■

La propiedad que hace a los métodos de subgradiente funcionar es la siguiente. Si $\bar{x}$ es un minimizador de f , de (9.8) tenemos que

$$\|x^{k+1} - \bar{x}\|^2 \leq \|x^k - \bar{x}\|^2 - 2\alpha_k(f(x^k) - f(\bar{x})) + \alpha_k^2\|d^k\|^2,$$

donde $d^k \in \partial f(x^k)$. De donde obtenemos que

$$\|x^{k+1} - \bar{x}\|^2 < \|x^k - \bar{x}\|^2$$

si

$$0 < \alpha_k < \frac{2(f(x^k) - f(\bar{x}))}{\|d^k\|^2}.$$

O sea, para pasos suficientemente cortos, la distancia al conjunto de soluciones disminuye. Sin embargo, cuando no conocemos el valor óptimo del problema, no hay cómo escoger una longitud de paso que garantice esta propiedad. Es por eso que tenemos que emplear reglas del tipo (9.12), para que los valores de las longitudes de paso sean suficientemente cortos asintóticamente.

Introduciendo el operador de proyección, los métodos de subgradiente pueden ser fácilmente extendidos al caso de optimización con restricciones. Naturalmente, estamos hablando de conjuntos viables convexos y, por razones prácticas, de estructura simple (que permita fórmulas de proyección explícitas).

Ejercicio 9.1. Consideremos el problema

$$\min f(x) \quad \text{sujeto a } x \in D,$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa en $\mathbb{R}^n$ y $D \subset \mathbb{R}^n$ es un conjunto convexo y cerrado. Consideremos la modificación del Algoritmo 5.1.1, donde cambiamos la fórmula (9.4) por la fórmula

$$x^{k+1} = P_D(x^k - \alpha_k d^k).$$

Para esta modificación del Algoritmo 5.1.1 y el problema arriba, probar resultados análogos a aquellos de los Teoremas 9.1 y 9.2.

La única atracción de los métodos de subgradiente es su extrema simplicidad (cuando el cálculo de subgradientes es fácil). Infelizmente, como ya comentamos arriba, estos métodos son poco eficientes y, a veces, completamente inútiles. La fijación a priori de valores de longitud de paso es una estrategia pésima. Es verdad que, en principio, podemos intentar definir β_k en la iteración k misma (y no fijar toda la sucesión $\{\beta_k\}$ justo al inicio). Existen algunas sugerencias en este sentido, que hasta pueden funcionar bien en la práctica para algunos tipos de problemas. Sin embargo, no hay nada claro sobre cómo hacer eso de manera matemáticamente sólida (en particular, para satisfacer las condiciones de convergencia del método). En este sentido, podemos afirmar también que las dos condiciones en (9.12) que la sucesión $\{\alpha_k\}$ debe satisfacer son, desde el punto de vista numérico, contradictorias: la segunda condición precisa que $\beta_k \rightarrow 0$ ($k \rightarrow \infty$), lo que torna β_k nulo para k grande en cualquier implementación computacional. Y esto imposibilita la validez de la primera condición en (9.12). Por otro lado, el número de varias sucesiones $\{\beta_k\}$ que satisfacen (9.12) es claramente infinito, y el método no suministra ninguna estrategia para preferir una elección a otra (ni a priori, ni en una iteración k dada). Esto indica que un método así difícilmente puede ser eficiente.

Notemos también que un método con longitudes de paso dados por una regla del tipo (9.12), necesariamente tiene una tasa de convergencia muy lenta; en particular, *sublineal*. Y este es el caso incluso para problemas muy bien

comportados. O sea, no importan las hipótesis y propiedades de un problema dado. La tasa de convergencia siempre es peor que lineal. Es claro que esto no es satisfactorio.

Otra deficiencia, ya mencionada anteriormente, es que los métodos de subgradiente no poseen ninguna regla de parada confiable. La situación en que $\|d^k\| \leq \varepsilon$ puede nunca ocurrir (véase el Ejemplo 9.2). Por otro lado, la situación en que $\|x^{k+1} - x^k\| \leq \varepsilon$ (que es otra regla de parada popular en el caso diferenciable) no significa absolutamente nada en este contexto, ya que $\{\beta_k\} \rightarrow 0$ ($k \rightarrow \infty$) y, por lo tanto, $\|x^{k+1} - x^k\| \rightarrow 0$, independientemente de cualquier cosa.

Existen, sin embargo, unos pocos casos en los que los métodos de subgradiente pueden ser ligeramente mejorados. Una situación de este tipo es cuando el valor óptimo $\bar{v}$ del problema (9.1) es conocido.

Ejercicio 9.2. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa en $\mathbb{R}^n$. Supongamos que el problema (9.1) posee una solución y $\bar{v} = \min_{x \in \mathbb{R}^n} f(x)$. Probar que cualquier sucesión $\{x^k\}$ generada por el esquema (9.10), donde $\beta_k = f(x^k) - \bar{v}$, converge a una solución de (9.1), y se tiene que

$$\liminf_{k \rightarrow \infty} \sqrt{k}(f(x^k) - \bar{v}) = 0.$$

Si, además, la condición de crecimiento lineal de f se satisface, i.e., si existen una vecindad U del conjunto de soluciones S de (9.1) y un número $\gamma > 0$ tales que

$$f(x) - \bar{v} \geq \gamma \text{dist}(x, S) \quad \forall x \in U,$$

entonces la tasa de convergencia (en relación a las variables) es geométrica.

Cuando el valor de $\bar{v}$ no es conocido, podemos intentar modificar el método del Ejercicio 9.2, haciendo actualización dinámica de aproximaciones inferiores para el valor de $\bar{v}$.

9.2. El método de planos cortantes

Consideremos el problema

$$\min f(x) \quad \text{sujeto a} \quad x \in D, \quad (9.15)$$

donde $D \subset \mathbb{R}^n$ es un conjunto convexo y cerrado, y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa en $\mathbb{R}^n$. Supongamos también que D sea acotado, lo que es necesario para garantizar la existencia de soluciones en los subproblemas del método a ser estudiado, principalmente en las iteraciones iniciales (la primera iteración consiste en la minimización de una función afín sobre el conjunto D , que claramente no tiene solución si $D = \mathbb{R}^n$).

La idea principal del método de planos cortantes consiste en la utilización de la información acumulada a lo largo de las iteraciones anteriores para construir una aproximación (inferior) de la función f , lineal por partes, cada vez más precisa. En particular, este método pertenece a la clase de *métodos con memoria* (véase ??). Consideramos que al inicio de la iteración con índice $k + 1$, tenemos la siguiente información en la memoria: $x^i \in \mathbb{R}^n$, $y^i \in \partial f(x^i)$, $i = 0, 1, \dots, k$. La iteración (indexada por $k + 1$) del método de planos cortantes consiste en la resolución del problema

$$\min \psi_k(x) \quad \text{sujeto a} \quad x \in D, \quad (9.16)$$

donde

$$\psi_k : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \psi_k(x) = \max_{i=0,1,\dots,k} \{f(x^i) + \langle y^i, x - x^i \rangle\}. \quad (9.17)$$

Notemos que si D es un conjunto poliedral, (9.16) puede ser escrito en forma del siguiente problema de programación lineal:

$$\min t \quad \text{sujeto a} \quad (t, x) \in U_k, \quad (9.18)$$

$$U_k = \left\{ (t, x) \in \mathbb{R} \times D \mid \begin{array}{l} f(x^i) + \langle y^i, x - x^i \rangle \leq t, \\ i = 0, 1, \dots, k. \end{array} \right\}. \quad (9.19)$$

De la definición del subdiferencial y de (9.17), inmediatamente obtenemos que

$$f(x) \geq \psi_{k+1}(x) \geq \psi_k(x) \quad \forall x \in \mathbb{R}^n. \quad (9.20)$$

A medida que más información es acumulada (o sea, cuando k crece), la aproximación (inferior) (9.17) de la función f se hace cada vez más precisa. Podemos esperar, entonces, que las soluciones de los subproblemas (9.16) aproximen cada vez mejor a las soluciones del problema original (9.15).

Algoritmo 5.2.1. (El método de planos cortantes)

Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular $f(x^k)$ y $y^k \in \partial f(x^k)$.
2. Calcular x^{k+1} , una solución del problema (9.16), donde la función objetivo está dada por (9.17).
3. Tomar $k := k + 1$ y retornar al Paso 1.

Tres iteraciones del método de planos cortantes se ilustran en la figura 9.2.




Figura 9.2.: Tres iteraciones del método de planos cortantes para la función f en el conjunto $D = [0, a]$. Se tiene que x^{k+1} es el minimizador de la aproximación ψ_k en D . Después de cada iteración, un plano cortante más es introducido en la aproximación: $\psi_{k+1}(x) = \max\{\psi_k(x), f(x^{k+1}) + \langle y^{k+1}, x - x^{k+1} \rangle\}$, $y^{k+1} \in \partial f(x^{k+1})$.

La ventaja más importante de este método en comparación con los métodos de subgradiente es la posibilidad de construir una regla de parada informativa. Para todo k , definimos

$$\Delta_k = f(x^{k+1}) - \psi_k(x^{k+1}).$$

De la relación (9.20), se sigue que $\Delta_k \geq 0$ y

$$f(x) \geq \psi_k(x) \geq \psi_k(x^{k+1}) = f(x^{k+1}) - \Delta_k \quad \forall x \in D.$$

Por lo tanto,

$$f(x^{k+1}) \geq \bar{v} \geq f(x^{k+1}) - \Delta_k,$$

donde $\bar{v}$ es el valor óptimo del problema (9.15). Esta última relación significa que es razonable parar el método después de la iteración indexada por $k + 1$, si Δ_k es pequeño (menor que la tolerancia escogida). Como mostraremos más adelante, para un cierto k esto siempre va a ocurrir (véase el Teorema 9.3).

¿Cuáles son las deficiencias del método de planos cortantes? En la práctica, la hipótesis de compacidad de D en general no es muy restrictiva. Por ejemplo, en vez de comenzar por resolver subproblemas (9.16) con $k = 0$, lo que ciertamente puede dar un problema ilimitado inferiormente cuando D es ilimitado, podemos primero tomar unos $k > 0$ puntos (digamos, aleatorios) y solo después de eso comenzar efectivamente el proceso iterativo. Si la aproximación (9.17) contiene un número de puntos significativo, es muy probable que el subproblema asociado ya no sea ilimitado inferiormente, incluso para un conjunto viable D ilimitado.

La primera deficiencia más profunda es que la resolución de los subproblemas se hace más difícil a medida que más puntos se introducen en (9.17). Esto es bien claro, ya que el número de restricciones escalares en el problema de programación lineal (9.18), (9.19), es exactamente el número de puntos anteriores $k + 1$. Notemos que existen algunas estrategias de eliminación de algunos de los puntos anteriores en la aproximación (9.17). Sin embargo, en el caso del método de planos cortantes estas estrategias no son completamente satisfactorias (comparar con los métodos de haces en la apartado 9.3).

Otra deficiencia sería del método de planos cortantes es su inestabilidad numérica. Más precisamente, las sucesiones $\{x^k\}$ y $\{f(x^k)\}$ con frecuencia muestran un comportamiento caótico. Para visualizar esto, basta observar el Algoritmo 5.2.1 cuando es aplicado al problema (9.15), con $n = 1$, $D = [-1, 1]$ y la función objetivo $f(x) = x^2$, $x \in \mathbb{R}$. Véase también la figura 9.3.




Figura 9.3.: La iteración del método de planos cortantes puede generar x^{k+1} para el cual la distancia a la solución y el valor de la función objetivo aumentan en comparación con el iterado anterior x^k .

Aun siendo estos ejemplos muy especiales (en particular, f es diferenciable y no está claro por qué emplear un método de optimización no diferenciable), lo que puede ser observado es relevante para entender las posibles dificultades de la aplicación del método en general. A propósito, el método de planos cortantes es realmente eficiente solamente cuando el problema posee una *única* solución, que satisface la condición de crecimiento lineal (véase el Ejercicio 9.2).

Teorema 9.3 (Convergencia del método de planos cortantes). Sean $D \subset \mathbb{R}^n$ un conjunto convexo compacto y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa en $\mathbb{R}^n$. Entonces, para toda sucesión $\{x^k\}$ generada por el Algoritmo 5.2.1, se tiene que

$$\lim_{k \rightarrow \infty} \psi_k(x^{k+1}) = \bar{v} = \liminf_{k \rightarrow \infty} f(x^k), \quad (9.21)$$

donde $\bar{v} = \min_{x \in D} f(x)$, y las funciones ψ_k están definidas por la fórmula (9.17).

Prueba. De la relación (9.20) se sigue que la sucesión $\{\psi_k(x^{k+1})\}$ es no decreciente y limitada superiormente por $\bar{v}$. Luego, esta sucesión converge. Supongamos que el límite de ella no sea $\bar{v}$, i.e., que exista un número $\delta > 0$ tal que

$$\psi_k(x^{k+1}) \leq \bar{v} - \delta \quad \forall k. \quad (9.22)$$

La sucesión $\{x^k\}$ es acotada (ya que D es compacto). Tomando una subsucesión (si fuera necesario), podemos admitir que $\{x^k\}$ converge. Existe, entonces, un número $M > 0$ tal que, para todo k suficientemente grande, tenemos

$$\|x^{k+1} - x^k\| \leq \frac{\delta}{2M}, \quad \|y^k\| \leq M,$$

donde la segunda desigualdad se sigue del ?? (y del hecho de que $\{x^k\}$ es acotada). Combinando estas desigualdades con (9.17) y (9.22), obtenemos que

$$\begin{aligned} \bar{v} - \delta &\geq \psi_k(x^{k+1}) \\ &\geq f(x^k) + \langle y^k, x^{k+1} - x^k \rangle \\ &\geq \bar{v} - \|y^k\| \|x^{k+1} - x^k\| \\ &\geq \bar{v} - \delta/2, \end{aligned}$$

lo que es una contradicción. Acabamos de mostrar la primera igualdad en (9.21).

Supongamos ahora que la segunda igualdad en (9.21) no sea verdadera, i.e., que exista un número $\delta > 0$ tal que para todo k suficientemente grande se tiene que

$$f(x^k) \geq \bar{v} + \delta.$$

Observamos que, por la definición (9.17),

$$\begin{aligned}\psi_{k+1}(x^{k+1}) &= \max\{\psi_k(x^{k+1}), f(x^{k+1})\} \\ &\geq f(x^{k+1}) \\ &\geq \bar{v} + \delta,\end{aligned}\tag{9.23}$$

para todo k suficientemente grande. Pasando de nuevo a una subsucesión (si es necesario) podemos admitir que

$$\|x^{k+1} - x^k\| \leq \frac{\delta}{2L},$$

donde

$$L = \sup\{\|y\| \mid y \in \cup_{x \in D} \partial f(x)\}.$$

Recordamos que, por el ??, el número L es finito y sirve como módulo de Lipschitz-continuidad de la función f en el conjunto D . Como es fácil ver, L también sirve como módulo de Lipschitz-continuidad de la función ψ_{k+1} en D (véase el ??). Ahora, utilizando también (9.23) y (9.20), obtenemos

$$\begin{aligned}\bar{v} + \delta &\leq \psi_{k+1}(x^{k+1}) \\ &= \psi_{k+1}(x^k) + \psi_{k+1}(x^{k+1}) - \psi_{k+1}(x^k) \\ &\leq \bar{v} + L\|x^{k+1} - x^k\| \\ &\leq \bar{v} + \delta/2,\end{aligned}$$

lo que de nuevo es una contradicción. Esto prueba la segunda igualdad en (9.21). ■

9.3. Métodos de haces

De nuevo consideramos el problema de minimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n,\tag{9.24}$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa en $\mathbb{R}^n$, en general no diferenciable.

Los métodos presentados a continuación se basan en la idea de aproximación lineal por partes (véase apartado 9.2), complementada con un mecanismo de estabilización, una regla de parada altamente confiable, y una técnica que permite control total del tamaño de los subproblemas a ser resueltos. Así llegamos a una clase de métodos verdaderamente eficientes y prácticos.

Primero, vamos a presentar una versión simplificada, para explicar mejor las ideas principales. Sea $x^k \in \mathbb{R}^n$ una aproximación actual de la solución del problema (9.24), en el sentido de que x^k es el “mejor” punto calculado hasta ahora. De nuevo, tenemos en la memoria la información acumulada hasta el inicio de la iteración con índice $k + 1$, que consiste en los puntos $z^i \in \mathbb{R}^n$ y subgradiientes $y^i \in \partial f(z^i)$, $i = 0, 1, \dots, k$. Llamamos a este conjunto de datos el *haz*². Resaltamos que aquí, el último punto calculado z^k no necesariamente coincide con el punto x^k (la diferencia quedará clara a continuación). El iterado siguiente $z^{k+1} \in \mathbb{R}^n$ es calculado resolviendo el problema

$$\min \psi_k(x) + \frac{\gamma_k}{2} \|x - x^k\|^2, \quad x \in \mathbb{R}^n,\tag{9.25}$$

donde

$$\psi_k : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \psi_k(x) = \max_{i=0,1,\dots,k} \{f(z^i) + \langle y^i, x - z^i \rangle\},\tag{9.26}$$

es la aproximación de planos cortantes de la función objetivo f (véase apartado 9.2) y $\gamma_k > 0$ es un parámetro estabilizador (comparar con el subproblema (9.16)). El punto x^k puede ser pensado como centro de estabilización, y el papel del término cuadrático (estabilizador) consiste en no permitir un desplazamiento muy grande del punto z^{k+1} en relación al centro x^k , lo que puede ocurrir en el caso de minimización de la aproximación por planos cortantes.

La idea es cambiar el centro de estabilización solamente cuando eso esté realmente justificado, i.e., cuando el paso de x^k a z^{k+1} resulte en un decrecimiento suficiente de la función objetivo f . Si esto ocurre, tomamos entonces $x^{k+1} = z^{k+1}$. Este tipo de iteración se llama *paso serio*³ (o aun, paso de descenso). Caso contrario, el centro de estabilización (la aproximación actual x^k) no cambia, i.e., tomamos $x^{k+1} = x^k$. Este tipo de iteración se llama *paso*

²En inglés: *bundle*; métodos de haces – *bundle methods*.

³En inglés: *serious step*.

nulo⁴. Subrayamos que la información obtenida a través de la resolución del subproblema (9.25) en un paso nulo no es descartada: ella sirve para mejorar la aproximación de la función f en la siguiente iteración.

Para construir un método verdaderamente práctico, basado en las ideas presentadas, algunos detalles importantes tienen que ser incorporados. Notemos primero que la función ψ_k , definida en (9.26), puede ser escrita de la siguiente manera equivalente:

$$\psi_k(x) = f(x^k) + \max_{i=0,1,\dots,k} \{-e_i^k + \langle y^i, x - x^k \rangle\}, \quad (9.27)$$

donde la expresión está “centrada” en el punto x^k y utiliza los *errores de linealización* en los puntos z^i en relación a x^k :

$$e_i^k := f(x^k) - f(z^i) - \langle y^i, x^k - z^i \rangle \geq 0, \quad i = 0, 1, \dots, k. \quad (9.28)$$

La desigualdad en (9.28) sigue directamente de la definición de subgradiente. Esta representación de la función ψ_k está mejor adaptada a la implementación computacional (entre otras cosas, necesita menos memoria, ya que en vez de vectores $z^i \in \mathbb{R}^n$ utiliza números escalares $e_i^k \in \mathbb{R}$). Como puede ser visto directamente de (9.28) y de la definición del ε -subdiferencial (véase ??), se tiene que

$$y^i \in \partial_{e_i^k} f(x^k), \quad i = 0, 1, \dots, k. \quad (9.29)$$

Notemos que los errores de linealización en (9.28) tienen que ser modificados cada vez que cambia el centro x^k .

Recordamos que la complejidad del subproblema (9.25) está directamente relacionada con el número de planos cortantes que definen ψ_k en (9.26), que es $k + 1$. Como veremos más adelante, este también será el número de restricciones en la reformulación de (9.25) como un problema de programación cuadrática. Por razones prácticas, es altamente deseable mantener el número de restricciones computacionalmente realista. O sea, necesitamos alguna herramienta que permita descartar parte de la información acumulada de manera que, aun así, garantice convergencia del proceso iterativo. La eliminación de alguna información anterior significa la sustitución de la función dada por (9.26) por otra función, definida por un número menor de planos cortantes. Formalmente definimos

$$\psi_k(x) = f(x^k) + \max_{i \in B_k} \{-e_i^k + \langle y^i, x - x^k \rangle\}, \quad (9.30)$$

donde B_k es el conjunto de índices que define el haz actual, y se tiene que

$$y^i \in \partial_{e_i^k} f(x^k), \quad i \in B_k. \quad (9.31)$$

De la ?? del ε -subdiferencial, se tiene que

$$\forall x \in \mathbb{R}^n, \quad f(x) \geq f(x^k) + \langle y^i, x - x^k \rangle - e_i^k, \quad \forall i \in B_k.$$

Por lo tanto, de (9.30) obtenemos que

$$f(x) \geq \psi_k(x) \quad \forall x \in \mathbb{R}^n, \quad k = 0, 1, \dots \quad (9.32)$$

Subrayamos que en la definición arriba, B_k no necesita contener a todos los índices $i = 0, 1, \dots, k$. Además, suponiendo que necesariamente $y^i \in \partial f(z^i)$ para algún índice anterior $i \in \{0, 1, \dots, k\}$, es claro que si no estamos empleando todos los planos cortantes obtenidos en los $k + 1$ puntos anteriores, los ε -subgradiientes en (9.31) tienen que ser contruidos de manera inteligente para no perder aquella información que es esencial. Para este fin, la llamada *función agregada* es fundamental. Esta función es definida a través de la solución del subproblema (9.25), que estudiaremos a continuación.

Evidentemente, la función objetivo del subproblema (9.25) es fuertemente convexa. Por lo tanto, (9.25) posee una solución que es única. Además, como es fácil verificar, el problema (9.25), con ψ_k dada por (9.30), es equivalente al problema de programación cuadrática siguiente:

$$\min t + \frac{\gamma_k}{2} \|x - x^k\|^2 \quad \text{sujeto a} \quad (t, x) \in U_k, \quad (9.33)$$

$$U_k = \{(t, x) \in \mathbb{R} \times \mathbb{R}^n \mid f(x^k) - e_i^k + \langle y^i, x - x^k \rangle \leq t, \quad i \in B_k\}. \quad (9.34)$$

Mencionaremos también que, en vez del problema (9.33)-(9.34), podemos resolver su dual (véase ??), que puede ser escrito como

$$\min \frac{1}{2} \left\| \sum_{i \in B_k} v_i y^i \right\|^2 + \gamma_k \sum_{i \in B_k} v_i e_i^k \quad \text{sujeto a} \quad v \in \mathcal{U}_k, \quad (9.35)$$

⁴En inglés: *null step*.

$$\mathcal{U}_k = \left\{ v \in \mathbb{R}_+^{|B_k|} \mid \sum_{i \in B_k} v_i = 1 \right\}, \quad (9.36)$$

véase el Lema 9.1 a continuación. Por el Teorema de Weierstrass, el problema dual siempre posee solución, ya que su conjunto viable es compacto y la función objetivo es continua. A ventaja del problema dual es que su conjunto viable posee una estructura que permite el uso de métodos computacionales especializados muy eficientes (el simplex estándar).

Lema 9.1 (Dualidad del subproblema). Para el problema (9.33)-(9.34), el dual viene dado por

$$\max f(x^k) - \frac{1}{2\gamma_k} \left\| \sum_{i \in B_k} v_i y^i \right\|^2 - \sum_{i \in B_k} v_i e_i^k \quad \text{sujeto a } v \in \mathcal{U}_k, \quad (9.37)$$

donde el conjunto $\mathcal{U}_k$ está definido en (9.36). Los dos problemas poseen soluciones y no hay brecha de dualidad.

Prueba. El problema primal (9.33)-(9.34) es equivalente a (9.25), que posee una única solución (como ya fue justificado). Ahora, por el ??, el dual no tiene brecha de dualidad (es evidente que el problema primal satisface la condición de regularidad de Slater). Resta mostrar que el dual tiene el formato (9.37). La Lagrangiana viene dada por:

$$\begin{aligned} L(t, x, v) &= t + \frac{\gamma_k}{2} \|x - x^k\|^2 + \sum_{i \in B_k} v_i (f(x^k) - e_i^k + \langle y^i, x - x^k \rangle - t) \\ &= \left(1 - \sum_{i \in B_k} v_i\right) t + \frac{\gamma_k}{2} \|x - x^k\|^2 + \sum_{i \in B_k} v_i \langle y^i, x - x^k \rangle + \sum_{i \in B_k} v_i (f(x^k) - e_i^k). \end{aligned} \quad (9.38)$$

Evidentemente, el ínfimo sobre t es $-\infty$ a menos que $\sum v_i = 1$. Maximizando la función dual sobre x se obtiene la formulación (9.37) luego de completar cuadrados. ■

Lema 9.2 (Propiedades del subproblema de programación cuadrática del método de haces). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Para cualesquiera $x^k \in \mathbb{R}^n$, $y^i \in \partial_{e_i^k} f(x^k)$, $i \in B_k$, y $\gamma_k > 0$, sea

$$d^k = \sum_{i \in B_k} v_i^k y^i, \quad (9.39)$$

donde $v^k \in \mathbb{R}^{|B_k|}$ es una solución del problema dual (9.35)-(9.36). Entonces, la única solución z^{k+1} del problema (9.25) viene dada por

$$z^{k+1} = x^k - \frac{1}{\gamma_k} d^k. \quad (9.40)$$

Además, se tiene que

$$d^k \in \partial_{\varepsilon_k} f(x^k), \quad (9.41)$$

donde

$$\varepsilon_k = \sum_{i \in B_k} v_i^k e_i^k \geq 0. \quad (9.42)$$

Por la definición del subgradiente, a partir del Lema se tiene la relación crítica:

$$d^k \in \partial \psi_k(z^{k+1}). \quad (9.43)$$

Ahora, por la definición del subgradiente, tenemos que

$$f(x) \geq \psi_k(x) \geq \psi_k(z^{k+1}) + \langle d^k, x - z^{k+1} \rangle \quad \forall x \in \mathbb{R}^n, \quad (9.44)$$

donde la primera desigualdad ya fue probada (véase (9.32)). Como no hay brecha de dualidad, el valor óptimo primal y dual coinciden, obteniendo:

$$\psi_k(z^{k+1}) = f(x^k) - \frac{1}{\gamma_k} \|d^k\|^2 - \varepsilon_k. \quad (9.45)$$

Ahora estamos listos para introducir la **función agregada**, mencionada anteriormente:

$$\psi_k^a : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \psi_k^a(x) := f(x^k) - \varepsilon_k + \langle d^k, x - x^k \rangle, \quad (9.46)$$

donde $d^k \in \mathbb{R}^n$ y $\varepsilon_k \geq 0$ son exactamente los definidos en el Lema 9.2. Observamos que esta función está definida a través de la solución del subproblema de programación cuadrática. Notemos también que el Lema 9.2 implica en que

$$f(x) \geq \psi_k^a(x) \quad \forall x \in \mathbb{R}^n, \quad (9.47)$$

i.e., ψ_k^a es una aproximación inferior de la función objetivo f .

Para construir un método bien definido y convergente, precisamos garantizar que si un punto x^k dado no es solución, entonces tras un número finito de pasos nulos obtenemos un paso serio de descenso. Necesitamos entonces remover planos anteriores de manera inteligente, conteniendo toda la información relevante en la *función agregada* de forma tal que se satisfaga la condición:

$$\psi_{k+1}(x) \geq \max\{\psi_k^a(x), f(z^{k+1}) + \langle y^{k+1}, x - z^{k+1} \rangle\} \quad \forall x \in \mathbb{R}^n. \quad (9.48)$$

La condición (9.48) significa que a la hora de definir el nuevo haz, tras un paso nulo, es suficiente incluir el par (y^{k+1}, e_{k+1}^{k+1}) , donde

$$e_{k+1}^{k+1} = f(x^k) - f(z^{k+1}) - \langle y^{k+1}, x^k - z^{k+1} \rangle \geq 0, \quad (9.49)$$

y el par agregado (d^k, ε_k) . Como estrategia extrema, podemos remover todos los pares anteriores y calcular el punto z^{k+2} como solución del problema

$$\min \psi_{k+1}(x) + \frac{\gamma_{k+1}}{2} \|x - x^{k+1}\|^2,$$

donde

$$\psi_{k+1}(x) = \max\{\psi_k^a(x), f(z^{k+1}) + \langle y^{k+1}, x - z^{k+1} \rangle\}. \quad (9.50)$$

Para poder actualizar los errores de linealización cada vez que el centro de estabilización cambia, garantizando la validez de la inclusión, la fórmula siguiente garantiza esto:

$$e_i^{k+1} = e_i^k + f(x^{k+1}) - f(x^k) + \langle y^i, x^k - x^{k+1} \rangle, \quad i \in B_{k+1} \setminus \{k+1\}. \quad (9.51)$$

Ahora ya podemos describir el método formalmente.

Algoritmo 5.3.1. (El método de haces)

Fijar un número entero $M \geq 2$ (el tamaño máximo permitido del haz). Escoger $x^0 \in \mathbb{R}^n$ y tomar $k := 0, K := \emptyset$. Escoger $\sigma \in (0, 1)$. Calcular $f(x^0)$ y $y^0 \in \partial f(x^0)$. Tomar $z^0 := x^0, e_0^0 := 0$. Tomar $B_0 := \{0\}$ y definir el haz inicial, que contiene el único par (y^0, e_0^0) .

1. Escoger $\gamma_k > 0$ y calcular z^{k+1} , la solución del problema (9.25), con función objetivo dada por (9.30).
2. Calcular $f(z^{k+1}), y^{k+1} \in \partial f(z^{k+1})$ y

$$\Delta_k = f(x^k) - \psi_k(z^{k+1}) - \frac{\gamma_k}{2} \|z^{k+1} - x^k\|^2. \quad (9.52)$$

3. Si

$$f(x^k) - f(z^{k+1}) \geq \sigma \Delta_k, \quad (9.53)$$

tomar $x^{k+1} := z^{k+1}$ e incluir el índice k en el conjunto K (**paso serio**).

Caso contrario, tomar $x^{k+1} := x^k$ (**paso nulo**).

4. Si $|B_k| < M$, tomar $B_{k+1} := B_k \cup \{k+1\}$.
Si $|B_k| = M$, escoger dos índices $i_1, i_2 \in B_k$ y tomar $B_{k+1} := (B_k \setminus \{i_2\}) \cup \{k+1\}$, $y^{i_1} := d^k, e_{i_1}^k := \varepsilon_k$, donde $d^k \in \mathbb{R}^n$ y $\varepsilon_k \geq 0$ están definidos en el Lema 9.2.
5. Si $k \in K$, calcular $e_i^{k+1}, i \in B_{k+1} \setminus \{k+1\}$, por la fórmula (9.51). Caso contrario, tomar $e_i^{k+1} := e_i^k, i \in B_{k+1} \setminus \{k+1\}$.
Calcular e_{k+1}^{k+1} por la fórmula (9.49). Definir el nuevo haz como el conjunto de pares $(y^i, e_i^{k+1}), i \in B_{k+1}$.
6. Tomar $k := k+1$ y retornar al Paso 1.

Haremos algunos comentarios sobre la regla de parada. De (9.41), obtenemos que Δ_k se simplifica a

$$\Delta_k = \varepsilon_k + \frac{\|d^k\|^2}{2\gamma_k}. \quad (9.54)$$

Tenemos entonces que $\Delta_k \geq 0$ y, si este número es pequeño, entonces son pequeños $\|d^k\|$ y ε_k . Por lo tanto, la regla de parada basada en la condición de que Δ_k sea suficientemente pequeño, será satisfecha tras un número finito de iteraciones.

Teorema 9.4 (Convergencia de los pasos serios del método de haces). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa en $\mathbb{R}^n$. Supongamos que el Algoritmo 5.3.1 genera una sucesión de iteraciones para las cuales el conjunto K de pasos serios

es infinito. Supongamos que la sucesión $\{\gamma_k\}$ satisfaga la condición

$$\sum_{k \in K} \frac{1}{\gamma_k} = +\infty. \quad (9.55)$$

Entonces, para la sucesión $\{x^k\}$ del Algoritmo 5.3.1 se tiene que

$$\lim_{k \rightarrow \infty} f(x^k) = \bar{v}, \quad (9.56)$$

donde $\bar{v} = \inf_{x \in \mathbb{R}^n} f(x)$, y para $k \in K$ se verifica

$$\Delta_k \rightarrow 0 \quad (k \rightarrow \infty). \quad (9.57)$$

Si el problema (9.24) tiene una solución y

$$\gamma_k \geq \bar{\gamma} > 0 \quad \forall k \in K, \quad (9.58)$$

entonces la sucesión $\{x^k\}$ converge a una solución del problema.

Prueba. Por el Lema 9.2, para todo $k \in K$ se tiene que

$$x^{k+1} = x^k - \frac{1}{\gamma_k} d^k, \quad d^k \in \partial_{\varepsilon_k} f(x^k), \quad (9.59)$$

donde las cantidades $\gamma_k > 0$, $\|d^k\|$, $\Delta_k \geq 0$ y $\varepsilon_k \geq 0$ están relacionadas por (9.54). Si $\bar{v} > -\infty$, tenemos que

$$\sum_{k \in K} \Delta_k \leq \sum_{k \in K} \frac{f(x^k) - f(x^{k+1})}{\sigma} \leq \frac{f(x^0) - \bar{v}}{\sigma} < +\infty. \quad (9.60)$$

De aquí y de (9.54), se sigue que

$$\sum_{k \in K} \varepsilon_k < +\infty, \quad \sum_{k \in K} \frac{\|d^k\|^2}{\gamma_k} < +\infty. \quad (9.61)$$

Ahora, las relaciones (9.55), (9.59) y (9.61), implican la convergencia:

$$\liminf_{k \rightarrow \infty} f(x^k) = \bar{v}.$$

Para todo $k \in K$, siendo que vale (9.59), por el mismo razonamiento usado en la prueba del método de subgradiente, se tiene que

$$\|x^{k+1} - \bar{x}\|^2 \leq \|x^k - \bar{x}\|^2 + \frac{\|d^k\|^2}{\gamma_k^2} + \frac{2\varepsilon_k}{\gamma_k}. \quad (9.62)$$

De (9.58) y (9.61), se sigue que esta condición implica que $\{x^k\}$ converge al minimizador. ■

Teorema 9.5 (Convergencia de pasos nulos del método de haces). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa. Supongamos que el Algoritmo 5.3.1 genera una sucesión para la cual el conjunto de pasos serios K es finito, i.e., $x^k = x^{\bar{k}}$ para algún índice $\bar{k}$. Supongamos que la sucesión $\{\gamma_k\}$ sea limitada y satisfaga la condición

$$\gamma_{k+1} \geq \gamma_k \quad \forall k \geq \bar{k}. \quad (9.63)$$

Entonces, $x^{\bar{k}}$ es una solución del problema (9.24), y la sucesión $\{z^k\}$ converge a $x^{\bar{k}}$.

Prueba. El análisis (que involucra las ecuaciones (9.64) a (??)) muestra que, gracias a la agregación del haz, la sucesión de subgradiantes aproximados fuerza al algoritmo a encontrar que $0 \in \partial f(x^{\bar{k}})$. En particular, la función agregada satisface para todo $x \in \mathbb{R}^n$:

$$\psi_k^a(x) + \frac{\gamma_k}{2} \|x - x^{\bar{k}}\|^2 = \psi_k(z^{k+1}) + \frac{\gamma_k}{2} \|z^{k+1} - x^{\bar{k}}\|^2 + \frac{\gamma_k}{2} \|x - z^{k+1}\|^2. \quad (9.64)$$

Utilizando (9.32), la definición de z^{k+2} , (9.48) y (9.63), obtenemos que la secuencia $\{\psi_k(z^{k+1}) + \gamma_k \|z^{k+1} - x^{\bar{k}}\|^2 / 2\}$ es monótona no decreciente y acotada superiormente. Evaluando el límite de paso nulo (9.53), se concluye que:

$$0 \in \partial f(x^{\bar{k}}), \quad (9.65)$$

lo cual significa que $x^{\bar{k}}$ es solución del problema. ■

Ejercicio 9.3. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones convexas en $\mathbb{R}^n$. Supongamos que la condición de Slater sea satisfecha. Probar que para la familia de funciones parametrizadas

$$\varphi(y; x) = \max \left\{ f(y) - f(x), \max_{i=1, \dots, m} \{0, g_i(y)\} \right\}, \quad (9.66)$$

las afirmaciones siguientes son equivalentes:

- (a) $\bar{x}$ es una solución del problema $\min\{f(x) \mid g(x) \leq 0\}$ (eq. (??));
- (b) $\min\{\varphi(y; \bar{x}) \mid y \in \mathbb{R}^n\} = \varphi(\bar{x}; \bar{x}) = 0$;
- (c) $0 \in \partial\varphi(\bar{x}; \bar{x})$, i.e., $0 \in \partial\psi(\bar{x})$, donde $\psi(\cdot) := \varphi(\cdot; \bar{x})$.

10. Programación lineal y cuadrática

En este último capítulo presentaremos algunos métodos especiales para resolver problemas de programación lineal y de programación cuadrática. La importancia de problemas de este tipo se debe al hecho de que aparecen como subproblemas en varios algoritmos de uso general, como ya hemos visto anteriormente. Sin embargo, nuestra presentación se limitará solo a algunas consideraciones básicas, ya que el tratamiento detallado podría merecer incluso un libro separado.

10.1. Programación lineal

Recordamos que llamamos problema de programación lineal a un problema de optimización donde la función objetivo es lineal y el conjunto viable es un poliedro (o sea, conjunto de soluciones de un sistema de ecuaciones e inecuaciones lineales). En particular, tal problema es convexo. Por lo tanto, toda solución local es global. Más aún, todo punto estacionario es una solución. A continuación, presentaremos un resumen de propiedades de problemas lineales.

10.1.1. Elementos de teoría de la programación lineal

El problema de programación lineal en formato general viene dado por

$$\min \langle c_1, x_1 \rangle + \langle c_2, x_2 \rangle \quad \text{sujeto a} \quad (x_1, x_2) \in D, \quad (10.1)$$

$$D = \left\{ (x_1, x_2) \in \Omega \mid \begin{array}{l} A_{11}x_1 + A_{12}x_2 = b_1, \\ A_{21}x_1 + A_{22}x_2 \geq b_2 \end{array} \right\}, \quad (10.2)$$

donde $c_1 \in \mathbb{R}^{n_1}$, $c_2 \in \mathbb{R}^{n_2}$, $A_{11} \in \mathbb{R}^{l \times n_1}$, $A_{12} \in \mathbb{R}^{l \times n_2}$, $A_{21} \in \mathbb{R}^{m \times n_1}$, $A_{22} \in \mathbb{R}^{m \times n_2}$, $b_1 \in \mathbb{R}^l$, $b_2 \in \mathbb{R}^m$, $\Omega = \mathbb{R}^{n_1} \times \mathbb{R}_+^{n_2}$. El tratamiento de $x_2 \geq 0$ como restricción abstracta es conveniente en este contexto.

Ejercicio 10.1. Sea $X = \{x \in \mathbb{R}^n \mid Ax \geq b\}$ un conjunto acotado con interior no vacío, donde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Formular el problema de incluir en X una bola de radio máximo como un problema de programación lineal.

En la teoría de programación lineal, el problema en formato canónico, donde tomamos en (10.1), (10.2), $n_1 = m = 0$, tiene un papel especial. Simplificando la notación tomando $n = n_2$, el problema canónico puede ser escrito como

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad x \in D = \{x \in \Omega \mid Ax = b\}, \quad (10.3)$$

donde $c = c_2 \in \mathbb{R}^n$, $A = A_{12} \in \mathbb{R}^{l \times n}$, $b = b_1 \in \mathbb{R}^l$, $\Omega = \mathbb{R}_+^n$. Observamos que el problema general (10.1), (10.2), siempre puede ser transformado al formato canónico, introduciendo variables adicionales:

$$\min \langle c_1, u^1 - u^2 \rangle + \langle c_2, x_2 \rangle \quad \text{sujeto a} \quad (u^1, u^2, x_2, y) \in \tilde{D},$$
$$\tilde{D} = \left\{ (u^1, u^2, x_2, y) \in \tilde{\Omega} \mid \begin{array}{l} A_{11}(u^1 - u^2) + A_{12}x_2 = b_1, \\ A_{21}(u^1 - u^2) + A_{22}x_2 - y = b_2 \end{array} \right\},$$

donde $\tilde{\Omega} = \mathbb{R}_+^{n_1} \times \mathbb{R}_+^{n_1} \times \mathbb{R}_+^{n_2} \times \mathbb{R}_+^m$. Los conjuntos viables y de las soluciones del problema anterior y de (10.1), (10.2), están en una correspondencia obvia.

Teorema 10.1 (Existencia de soluciones en un problema de programación lineal). Si el conjunto viable de un problema de programación lineal es no vacío y el valor óptimo es finito, entonces este problema posee una solución.

Prueba. La afirmación es una consecuencia del Teorema 5.1.2 del Volumen 1 (véase [SolodovVol1]), pero reproduciremos la prueba.

Por lo dicho anteriormente sobre la transformación del problema general (10.1), (10.2), en problema canónico, podemos considerar este último. Sea el conjunto viable D del problema (10.3) no vacío y sea

$$\bar{v} = \inf_{x \in D} \langle c, x \rangle < +\infty.$$

Supongamos que la afirmación del teorema no sea verdadera, i.e., que el sistema

$$Ax = b, \quad \langle c, x \rangle = \bar{v}, \quad x \geq 0$$

con respecto a $x \in \mathbb{R}^n$ no tenga solución. Como es fácil ver, este sistema no tiene solución si, y solamente si, el sistema

$$Ax - tb = 0, \quad \langle c, x \rangle - t\bar{v} = 0, \quad x \geq 0, \quad t > 0$$

con respecto a $(x, t) \in \mathbb{R}^n \times \mathbb{R}$ no tiene solución. Aplicando al último sistema el Teorema de la Alternativa de Motzkin (véase el Teorema 3.14 del Volumen 1), concluimos que existe $(y, \tau) \in \mathbb{R}^l \times \mathbb{R}$ tal que

$$A^T y + \tau c \geq 0, \quad \langle b, y \rangle + \tau \bar{v} < 0.$$

Para todo $x \in D$, de la primera relación obtenemos que

$$\langle A^T y, x \rangle + \tau \langle c, x \rangle \geq 0,$$

ya que $x \geq 0$. De donde, utilizando también la segunda relación, tenemos que

$$\tau \langle c, x \rangle \geq -\langle y, Ax \rangle = -\langle y, b \rangle > \tau \bar{v}.$$

Por lo tanto,

$$\inf_{x \in D} \tau \langle c, x \rangle > \tau \bar{v} = \tau \inf_{x \in D} \langle c, x \rangle,$$

lo que es una contradicción, cualquiera que sea el valor de τ . ■

En programación lineal, una solución solo puede no existir cuando el conjunto viable del problema es vacío, o cuando la función objetivo es ilimitada inferiormente en este conjunto. Como sabemos, en el caso no lineal, un problema puede no poseer soluciones incluso cuando la función objetivo es limitada inferiormente en el conjunto viable no vacío.

Por los Teoremas 1.2.3 y 1.3.8, tenemos las siguientes condiciones de optimalidad.

Teorema 10.2 (Condiciones de optimalidad en programación lineal). Sean $c_1 \in \mathbb{R}^{n_1}$, $c_2 \in \mathbb{R}^{n_2}$, $A_{11} \in \mathbb{R}^{l \times n_1}$, $A_{12} \in \mathbb{R}^{l \times n_2}$, $A_{21} \in \mathbb{R}^{m \times n_1}$, $A_{22} \in \mathbb{R}^{m \times n_2}$, $b_1 \in \mathbb{R}^l$, $b_2 \in \mathbb{R}^m$, $\Omega = \mathbb{R}^{n_1} \times \mathbb{R}_+^{n_2}$. El punto $(\bar{x}_1, \bar{x}_2) \in D$ es una solución del problema (10.1), (10.2), si, y solamente si, existen $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$ tales que

$$A_{11}^T \bar{\lambda} + A_{21}^T \bar{\mu} = c_1, \quad A_{12}^T \bar{\lambda} + A_{22}^T \bar{\mu} \leq c_2, \quad (10.4)$$

$$\langle \bar{\mu}, A_{21} \bar{x}_1 + A_{22} \bar{x}_2 - b_2 \rangle = 0, \quad \langle A_{12}^T \bar{\lambda} + A_{22}^T \bar{\mu} - c_2, \bar{x}_2 \rangle = 0. \quad (10.5)$$

A continuación recordamos la noción de vértice del poliedro D . Aquí es conveniente tomar $n_2 = 0$, i.e., considerar el caso donde no hay restricciones abstractas (ellas pueden ser incluidas en las restricciones de desigualdad). Tomando también $n = n_1$, podemos escribir (10.2) en la forma

$$D = \{x \in \mathbb{R}^n \mid A_1 x = b_1, A_2 x \geq b_2\}, \quad (10.6)$$

donde $A_1 = A_{11} \in \mathbb{R}^{l \times n}$, $A_2 = A_{21} \in \mathbb{R}^{m \times n}$. Como siempre, para un punto $x \in \mathbb{R}^n$ cualquiera,

$$I(x) = \{i = 1, \dots, m \mid \langle (A_2)_i, x \rangle = (b_2)_i\}$$

es el conjunto de índices de las restricciones activas en x , donde $(A_2)_1, \dots, (A_2)_m$ son las filas de la matriz A_2 .

Definición 10.1 (Vértice). Un punto $\hat{x} \in D$ se llama **vértice** del poliedro D definido por (10.6), si las filas de la matriz A_1 y las filas de la matriz A_2 indexadas por $i \in I(\hat{x})$, forman en $\mathbb{R}^n$ un sistema de rango n . Si el número de elementos en este sistema es igual a n , entonces el vértice $\hat{x}$ se llama **no degenerado**, y si el número es mayor que n , entonces el vértice es **degenerado**.

La figura 10.1 ilustra esta definición.




Figura 10.1.: Los puntos x^1 , x^2 y x^3 son vértices del conjunto poliedral $D \subset \mathbb{R}^n$, $n = 2$, definido por las desigualdades $\langle B_i, x \rangle \geq b_i$, $i = 1, \dots, 4$. Por ejemplo, se tiene que $I(x^1) = \{1, 2\}$ y los vectores B_1 y B_2 forman una matriz de rango $2 = n$; x^1 es un vértice no degenerado. Se tiene que $I(x^2) = \{2, 3, 4\}$ y los vectores B_2, B_3 y B_4 forman una matriz de rango $2 = n$; x^2 es un vértice degenerado. El punto $y \in D$ no es un vértice: $I(y) = \{2\}$ y el vector B_2 forma una matriz de rango $1 < n = 2$.

En otras palabras, $\hat{x} \in D$ es un vértice del poliedro D dado por (10.6), si $\hat{x}$ es la única solución del sistema lineal

$$A_1 x = b_1, \quad \langle (A_2)_i, x \rangle = (b_2)_i, \quad i \in I(\hat{x}).$$

De aquí, inmediatamente obtenemos el siguiente hecho.

Proposición 10.1. *El número de vértices de un conjunto poliedral cualquiera es finito.*

A continuación presentamos un criterio de existencia de vértices.

Teorema 10.3 (Existencia de vértices de un conjunto poliedral). *Para cualesquiera $A_1 \in \mathbb{R}^{l \times n}$, $A_2 \in \mathbb{R}^{m \times n}$, $b_1 \in \mathbb{R}^l$ y $b_2 \in \mathbb{R}^m$, el poliedro D definido en (10.6) posee al menos un vértice si, y solamente si, $D \neq \emptyset$ y la matriz*

$$A = \begin{pmatrix} A_1 \\ A_2 \end{pmatrix}$$

tiene rango n . Más aún, si $\text{rk } A = n$, entonces para todo punto $x \in D$ existe un vértice $\hat{x}$ tal que $I(x) \subset I(\hat{x})$.

Prueba. El hecho de que las condiciones arriba son necesarias para la existencia de un vértice es obvio. Probaremos que esas condiciones también son suficientes.

Sea $x \in D$ arbitrario. Definimos los conjuntos $I = I(x)$, $J = \{1, \dots, m\} \setminus I$. Si las filas de la matriz A_1 y las filas $(A_2)_i$, $i \in I$, forman en $\mathbb{R}^n$ un sistema de rango n , entonces x es un vértice, por definición. Supongamos que el rango de este sistema sea $r < n$. En este caso, existe un vector $d \in \mathbb{R}^n \setminus \{0\}$ tal que

$$A_1 d = 0, \quad \langle (A_2)_i, d \rangle = 0 \quad \forall i \in I. \quad (10.7)$$

Si $\langle (A_2)_i, d \rangle = 0 \quad \forall i \in J$, obtendremos que $Ad = 0$, en contradicción con la hipótesis de que $\text{rk } A = n$. Por lo tanto, existe un índice $i \in J$ tal que $\langle (A_2)_i, d \rangle \neq 0$. Sin pérdida de generalidad, podemos admitir que $\langle (A_2)_i, d \rangle < 0$.

Para todo $t \geq 0$, consideremos puntos de la forma $x(t) = x + td$. Utilizando (10.7), tenemos que

$$A_1 x(t) = A_1 x + t A_1 d = b_1,$$

$$\langle (A_2)_i, x(t) \rangle = \langle (A_2)_i, x \rangle + t \langle (A_2)_i, d \rangle = (b_2)_i \quad \forall i \in I. \quad (10.8)$$

Por lo tanto, $x(t) \in D$ si, y solamente si,

$$\langle (A_2)_i, x(t) \rangle = \langle (A_2)_i, x \rangle + t \langle (A_2)_i, d \rangle \geq (b_2)_i \quad \forall i \in J.$$

Definimos

$$t_1 = \max\{t \in \mathbb{R}_+ \mid x(t) \in D\}.$$

Como es fácil ver, existe un índice $i_1 \in J$ tal que $\langle (A_2)_{i_1}, d \rangle < 0$ y

$$0 < t_1 = \frac{(b_2)_{i_1} - \langle (A_2)_{i_1}, x \rangle}{\langle (A_2)_{i_1}, d \rangle} \quad (10.9)$$

(comparar con el Ejercicio 4.1.8; notemos que para todo $i \in J$, se tiene que $(b_2)_i - \langle (A_2)_i, x \rangle < 0$). Definimos $x^1 = x(t_1)$, $I_1 = I(x^1)$. De (10.8) se sigue la inclusión

$$I \subset I_1. \quad (10.10)$$

De (10.9) obtenemos

$$\langle (A_2)_{i_1}, x^1 \rangle = \langle (A_2)_{i_1}, x \rangle + \frac{(b_2)_{i_1} - \langle (A_2)_{i_1}, x \rangle}{\langle (A_2)_{i_1}, d \rangle} \langle (A_2)_{i_1}, d \rangle = (b_2)_{i_1},$$

i.e., $i_1 \in I_1$. Si vale

$$(A_2)_{i_1} = A_1^T y + \sum_{i \in I} \beta_i (A_2)_i$$

para algunos $y \in \mathbb{R}^l$ y $\beta_i, i \in I$, de (10.7) se sigue la contradicción

$$0 > \langle (A_2)_{i_1}, d \rangle = \langle y, A_1 d \rangle + \sum_{i \in I} \beta_i \langle (A_2)_i, d \rangle = 0.$$

Concluimos entonces que las filas de la matriz A_1 y $(A_2)_i, i \in I_1$, forman en $\mathbb{R}^n$ un sistema de rango $r_1 > r$.

Si $r_1 = n$, entonces x^1 es un vértice y, teniendo en cuenta (10.10), esto concluye la demostración. Si $r_1 < n$, podemos repetir la construcción anterior, cambiando el punto x por x^1 . Repitiendo la construcción s veces, obtenemos puntos $x, x^1, x^2, \dots, x^s \in D$, satisfaciendo

$$I(x) \subset I(x^1) \subset I(x^2) \subset \dots \subset I(x^s),$$

$$r < r_1 < r_2 < \dots < r_s,$$

donde r_k es el rango de filas de la matriz A_1 , complementadas por $(A_2)_i, i \in I(x^k), k = 1, \dots, s$. Es claro que para algún número s obtendremos $r_s = n$, lo que significa que $\hat{x} = x^s$ es un vértice e $I(x) \subset I(x^s)$. ■

Si queremos encontrar todos los vértices de un poliedro D de la forma (10.6), podemos seguir el esquema siguiente. Para todo conjunto $I \subset \{1, \dots, m\}$ con $(n-l)$ -elementos, resolvemos el sistema lineal

$$A_1 x = b_1, \quad \langle (A_2)_i, x \rangle = (b_2)_i, \quad i \in I.$$

Si la solución existe, es única, y pertenece a D , entonces ella es un vértice de D . Caso contrario, consideramos otro conjunto I .

El conjunto viable del problema canónico (10.3) se llama poliedro canónico (recordamos que en (10.3) $\Omega = \mathbb{R}_+^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$). Para todo $x \in \mathbb{R}^n$, denotamos

$$J(x) = \{j = 1, \dots, n \mid x_j > 0\}.$$

Denotamos por $A^1, \dots, A^n$ las columnas de la matriz A .

Teorema 10.4 (Vértices del poliedro canónico). Para $A \in \mathbb{R}^{l \times n}$ y $b \in \mathbb{R}^l$ cualesquiera, el punto $\hat{x} \in D$ es un vértice del poliedro canónico definido en (10.3) (con $\Omega = \mathbb{R}_+^n$) si, y solamente si, las columnas $A^j, j \in J(\hat{x})$, de la matriz A son linealmente independientes. Si el conjunto $J(\hat{x})$ tiene l elementos, entonces el vértice $\hat{x}$ es no degenerado, y si el número de elementos en $J(\hat{x})$ es menor que l , el vértice es degenerado.

Ejercicio 10.2. Probar el Teorema 10.4.

Una propiedad importante de los poliedros canónicos es la siguiente.

Teorema 10.5 (Existencia de vértices de los poliedros canónicos). Para $A \in \mathbb{R}^{l \times n}$ y $b \in \mathbb{R}^l$ cualesquiera, el poliedro canónico D definido en (10.3) (con $\Omega = \mathbb{R}_+^n$) tiene al menos un vértice. Más aún, para todo punto $x \in D$ existe un vértice $\hat{x}$ del poliedro D tal que $J(x) \supset J(\hat{x})$.

Ejercicio 10.3. Utilizando el Teorema 10.3, probar el Teorema 10.5.

Para encontrar vértices de un poliedro canónico, puede ser empleado el siguiente esquema especial. Para cada conjunto $J \subset \{1, \dots, n\}$ tal que las columnas $A^j, j \in J$, de la matriz A son linealmente independientes, resolvemos el sistema lineal

$$\sum_{j \in J} A^j x_j = b.$$

Si este sistema posee una solución con coordenadas $\hat{x}_j \geq 0 \forall j \in J$, tomando $\hat{x}_j = 0, j \in \{1, \dots, n\} \setminus J$, obtenemos un vértice $\hat{x} = (\hat{x}_1, \dots, \hat{x}_n)$. Caso contrario, consideramos otro conjunto J .

El resultado siguiente, que es un corolario inmediato de los Teorema 10.2 y Teorema 10.3, es importante para el cálculo de soluciones de un problema de programación lineal. La intuición geométrica sugiere que si un problema lineal posee soluciones, una de las soluciones es vértice del conjunto viable del problema (si existen vértices), véase la figura 10.2.




Figura 10.2.: Cuando un problema de programación lineal posee soluciones y el conjunto viable tiene vértices, uno de los vértices es solución del problema (en el dibujo, las rectas paralelas son curvas de nivel de la función objetivo $\langle c, x \rangle$).

Como el número de vértices es finito (Proposición 10.1), la estrategia más obvia es simplemente calcular todos los vértices (por ejemplo, utilizando los esquemas presentados arriba) y escoger uno con el valor mínimo de la función objetivo. Naturalmente, tal estrategia no puede ser eficiente, pero el resultado no deja de ser importante.

Teorema 10.6. Si un problema de programación lineal posee soluciones y si el conjunto viable del problema tiene al menos un vértice, entonces uno de los vértices es solución del problema.

Como es fácil verificar, el problema dual (véase ?? y [SolodovVol1]) del problema (10.1), (10.2) (donde $\Omega = \mathbb{R}^{n_1} \times \mathbb{R}_+^{n_2}$) viene dado por

$$\max \langle b_1, \lambda \rangle + \langle b_2, \mu \rangle \quad \text{sueto a} \quad (\lambda, \mu) \in \Delta, \quad (10.11)$$

$$\Delta = \left\{ (\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m \mid \begin{array}{l} A_{11}^T \lambda + A_{21}^T \mu = c_1, \\ A_{12}^T \lambda + A_{22}^T \mu \leq c_2. \end{array} \right\}. \quad (10.12)$$

Recordamos que el dual del dual de un problema de programación lineal también es un problema de programación lineal. El dual del problema canónico (10.3) (donde $\Omega = \mathbb{R}_+^n$) es

$$\max \langle b, \lambda \rangle \quad \text{sueto a} \quad \lambda \in \Delta = \{ \lambda \in \mathbb{R}^l \mid A^T \lambda \leq c \}.$$

Si colocamos este último problema en la forma (10.1), (10.2), y escribimos su dual de acuerdo con (10.11), (10.12), obtendremos de nuevo el problema en el formato (10.3) (para obtener exactamente (10.3), es necesario transformar maximización en minimización cambiando el signo de la función objetivo). Lo mismo vale también para el problema general (10.1), (10.2). O sea, dualizando el problema dos veces resulta en el problema de la estructura original.

Recordamos que por la relación de dualidad débil (véase el ??), se tiene que

$$\begin{aligned} \langle c_1, x_1 \rangle + \langle c_2, x_2 \rangle &\geq \langle b_1, \lambda \rangle + \langle b_2, \mu \rangle \\ \forall (x_1, x_2) \in D, \quad \forall (\lambda, \mu) \in \Delta, \end{aligned} \quad (10.13)$$

y en particular,

$$\bar{v} \geq \bar{\omega},$$

donde

$$\bar{v} = \inf \{ \langle c_1, x_1 \rangle + \langle c_2, x_2 \rangle \mid (x_1, x_2) \in D \}$$

es el valor óptimo del problema primal y

$$\bar{\omega} = \sup \{ \langle b_1, \lambda \rangle + \langle b_2, \mu \rangle \mid (\lambda, \mu) \in \Delta \}$$

es el valor óptimo del problema dual.

El caso importante es cuando para algunos $(\bar{x}_1, \bar{x}_2) \in D$ y $(\bar{\lambda}, \bar{\mu}) \in \Delta$ se realiza igualdad en la relación (10.13), i.e.,

$$\langle c_1, \bar{x}_1 \rangle + \langle c_2, \bar{x}_2 \rangle = \langle b_1, \bar{\lambda} \rangle + \langle b_2, \bar{\mu} \rangle. \quad (10.14)$$

De (10.13) se sigue que, en este caso, $(\bar{x}_1, \bar{x}_2)$ es una solución del problema primal (10.1), (10.2), e $(\bar{\lambda}, \bar{\mu})$ es una solución del problema dual (10.11), (10.12), y que no hay brecha de dualidad:

$$\bar{v} = \bar{\omega}. \quad (10.15)$$

Lema 10.1. *Bajo las hipótesis del Teorema 10.2, sean D y Δ los conjuntos definidos en (10.2) y (10.12), respectivamente. Para $(\bar{x}_1, \bar{x}_2) \in D$ e $(\bar{\lambda}, \bar{\mu}) \in \Delta$ cualesquiera, la relación (10.14) vale como igualdad si, y solamente si, las condiciones (10.5) se satisfacen.*

Prueba. De $(\bar{x}_1, \bar{x}_2) \in D$ e $(\bar{\lambda}, \bar{\mu}) \in \Delta$ obtenemos que

$$\begin{aligned} \langle c_1, \bar{x}_1 \rangle + \langle c_2, \bar{x}_2 \rangle &\geq \langle A_{11}^T \bar{\lambda} + A_{21}^T \bar{\mu}, \bar{x}_1 \rangle + \langle A_{12}^T \bar{\lambda} + A_{22}^T \bar{\mu}, \bar{x}_2 \rangle \\ &= \langle \bar{\lambda}, A_{11} \bar{x}_1 + A_{12} \bar{x}_2 \rangle + \langle \bar{\mu}, A_{21} \bar{x}_1 + A_{22} \bar{x}_2 \rangle \\ &\geq \langle \bar{\lambda}, b_1 \rangle + \langle \bar{\mu}, b_2 \rangle. \end{aligned}$$

Si vale (10.14), el lado izquierdo es igual al lado derecho en la relación de arriba, y todas las desigualdades valen como igualdades. Es fácil ver que esto solo es posible si valen las condiciones (10.5). Recíprocamente, si vale (10.5), las desigualdades en la relación arriba se vuelven igualdades, lo que resulta en (10.14). ■

Recordamos que (10.5) son *condiciones de complementariedad* para el problema primal. Tenemos entonces que (10.14), o equivalentemente, las condiciones de complementariedad (10.5), son suficientes para optimalidad de puntos viables $(\bar{x}_1, \bar{x}_2)$ en el problema primal y puntos viables $(\bar{\lambda}, \bar{\mu})$ en el problema dual. Para ver que estas condiciones son también necesarias, notemos que la inclusión $(\bar{\lambda}, \bar{\mu}) \in \Delta$ coincide con (10.4), complementada por $\bar{\mu} \geq 0$. De aquí, del Lema 10.1 y del Teorema 10.2, obtenemos condiciones de optimalidad siguientes.

Teorema 10.7. *Bajo las hipótesis del Teorema 10.2, sean D y Δ los conjuntos definidos en (10.2) y (10.12), respectivamente. El punto $(\bar{x}_1, \bar{x}_2) \in D$ es una solución del problema primal (10.1), (10.2), si, y solamente si, existe $(\bar{\lambda}, \bar{\mu}) \in \Delta$ satisfaciendo (10.14) o, equivalentemente, (10.5). En este caso, $(\bar{\lambda}, \bar{\mu})$ es una solución del problema dual (10.11), (10.12).*

El Teorema 10.7 contiene las siguientes dos afirmaciones clásicas.

Teorema 10.8 (Dualidad fuerte). *Un problema de programación lineal posee una solución si, y solamente si, su dual posee una solución. En este caso, los valores óptimos de los dos problemas son iguales.*

Teorema 10.9. *Bajo las hipótesis del Teorema 10.7, los puntos $(\bar{x}_1, \bar{x}_2) \in D$ e $(\bar{\lambda}, \bar{\mu}) \in \Delta$ son soluciones de los problemas (10.1), (10.2), y (10.11), (10.12), si, y solamente si, valen las condiciones de complementariedad (10.5).*

Finalmente, de los Teoremas 10.1 y 10.8 se sigue el siguiente resultado de existencia de soluciones en programación lineal.

Teorema 10.10. *Si los conjuntos viables de un problema de programación lineal y de su dual son no vacíos, entonces ambos problemas tienen solución. Si solo uno de los problemas posee conjunto viable no vacío, entonces el valor óptimo de este problema es infinito.*

Como comentamos en [SolodovVol1], resolver el problema dual de un problema dado (no necesariamente de programación lineal) puede ser bien útil, principalmente cuando él es más simple que el problema original y no hay brecha de dualidad. Esta afirmación queda aún más clara en el caso de programación lineal. Habiendo resuelto el problema dual, esta solución puede ser usada para obtener una solución del problema primal, por ejemplo con ayuda del Teorema 10.9.

Ejercicio 10.4. Haciendo dibujos geométricos, formular hipótesis sobre soluciones de los problemas duales para

$$\begin{aligned} &\min -7x_1 - x_3 + 4x_4 \quad \text{sueto a } x \in D, \\ &D = \{x \in \mathbb{R}_+^4 \mid -x_1 + x_2 - 2x_3 + x_4 \geq -6, -2x_1 - x_2 + x_3 \geq 1\}; \\ &\min 2x_1 + 3x_2 + 2x_3 + 3x_4 \quad \text{sueto a } x \in D, \\ &D = \{x \in \mathbb{R}_+^4 \mid 2x_1 - x_2 - x_3 + x_4 \geq 2, -x_1 - 3x_2 + x_3 + x_4 \geq 1\}. \end{aligned}$$

Verificar las hipótesis y encontrar soluciones de los problemas primales, utilizando el resultado del Teorema 10.9.

Ejercicio 10.5. Encontrar todas las soluciones del problema

$$\min x_1 + x_2 + x_3 + x_4 \quad \text{sujeto a } x \in D,$$

$$D = \{x \in \mathbb{R}_+^4 \mid x_1 - x_2 \geq 0, x_1 + x_2 - x_3 + x_4 \geq 1\}.$$

Ejercicio 10.6. Formular el dual para el problema

$$\min \sum_{j=1}^s \langle c_j, x_j \rangle \quad \text{sujeto a } (x_1, \dots, x_s) \in D,$$

$$D = \left\{ (x_1, \dots, x_s) \in \Omega \mid A_j x_j \geq b_j, j = 1, \dots, s, \sum_{j=1}^s B_j x_j \geq d \right\},$$

donde $c_j \in \mathbb{R}^{n_j}$, $A \in \mathbb{R}^{m_j \times n_j}$, $b_j \in \mathbb{R}^{m_j}$ y $B \in \mathbb{R}^{m \times n_j}$, $j = 1, \dots, s$, $d \in \mathbb{R}^m$, $\Omega = \prod_{j=1}^s \mathbb{R}_+^{n_j}$.

Ejercicio 10.7. Formular el dual para el problema

$$\min \sum_{j=1}^s \langle c_j, x_j \rangle \quad \text{sujeto a } (x_1, \dots, x_s) \in D,$$

$$D = \{(x_1, \dots, x_s) \in \Omega \mid Ax_j \geq x_{j-1}, j = 1, \dots, s\},$$

donde $c_j \in \mathbb{R}^{n_j}$, $j = 1, \dots, s$, $A \in \mathbb{R}^{n \times n}$, $x_0 \in \mathbb{R}^n$ es dado, $\Omega = \prod_{j=1}^s \mathbb{R}_+^{n_j}$.

Ejercicio 10.8. Resolver el problema

$$\min \langle c, x \rangle \quad \text{sujeto a } x \in D = \{x \in \Omega \mid \langle a, x \rangle = b\},$$

donde $c, a \in \mathbb{R}^n$, $b \in \mathbb{R}$, $a > 0$, $b > 0$, $\Omega = \mathbb{R}_+^n$.

Ejercicio 10.9. Resolver el problema

$$\min \sum_{j=1}^n jx_j \quad \text{sujeto a } x \in D,$$

$$D = \left\{ x \in \Omega \mid \sum_{j=1}^i x_j \geq i, i = 1, \dots, n \right\},$$

donde $\Omega = \mathbb{R}_+^n$.

Ejercicio 10.10. El conjunto de soluciones de un problema de programación lineal puede

- (a) contener un solo punto;
- (b) contener más de un punto y ser acotado;
- (c) ser ilimitado.

Construir ejemplos mostrando que para un par de problemas primal y dual, todas las combinaciones de los escenarios de arriba son posibles.

10.1.2. El método del simplex

El método del simplex es históricamente el primer método computacional para optimización con restricciones. Fue él el que permitió la resolución de los primeros problemas de optimización de la “vida real”, dando inicio al desarrollo de métodos computacionales de optimización. Aun siendo el método más “viejo”, implementaciones sofisticadas de la idea básica son bien eficientes y son utilizadas hasta ahora.

El método será presentado para el problema canónico

$$\min \langle c, x \rangle \quad \text{sujeto a } x \in D = \{x \in \Omega \mid Ax = b\}, \quad (10.16)$$

donde $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$, $\Omega = \mathbb{R}_+^n$. Esto no reduce la generalidad, ya que todo problema de programación lineal puede ser escrito en este formato; véase la apartado 10.1.1.

De aquí en adelante,

$$J(x) = \{j = 1, \dots, n \mid x_j > 0\}$$

es el conjunto de las coordenadas positivas del punto $x \in \mathbb{R}^n$, y A^j , $j = 1, \dots, n$, son las columnas de la matriz A .

Basada en la Proposición 10.1 y en los Teoremas 10.5 y 10.6, la estrategia más simple para resolver un problema de programación lineal sería calcular todos los vértices del conjunto viable y escoger aquel con menor valor de la función objetivo. Algunas maneras de hacer esto fueron comentadas en la apartado 10.1.1. Si el problema (10.16) posee soluciones, por lo menos una será encontrada después de un número finito de pasos. Teóricamente, esta estrategia puede ser aplicada a cualquier problema de programación lineal. Sin embargo, ya para dimensiones n y l del orden de algunas docenas (lo que es un problema pequeño), el número de cálculos necesarios torna a este método poco práctico. Por eso, este método no tiene valor práctico. Él, naturalmente, lleva a la idea principal del método del simplex: en vez del cálculo indiscriminado de todos los vértices del conjunto viable, el proceso tiene que ser ordenado de manera inteligente, evitando el cálculo de vértices claramente no óptimos (por ejemplo, con valor de la función objetivo mayor que el ya visto).

Recordamos que, por el Teorema 10.4, el punto $\hat{x} \in D$ es un vértice del poliedro canónico D definido en (10.16) si, y solamente si, las columnas A^j , $j \in J(\hat{x})$, de la matriz A son linealmente independientes. Si el conjunto $J(\hat{x})$ contiene l índices, el vértice es no degenerado; si el número de índices es menor que l , el vértice es degenerado.

Notemos que para todo $x \in D$,

$$b = Ax = \sum_{j=1}^n A^j x_j = \sum_{j \in J(x)} A^j x_j,$$

i.e., el vector b en las restricciones es una combinación lineal de las columnas de la matriz A que corresponden a las coordenadas positivas del punto viable x . Más aún, los multiplicadores en esta combinación son precisamente las coordenadas de x positivas.

Definición 10.2. Dado un vértice $\hat{x}$ del poliedro canónico D definido en (10.16), llamamos **base** del vértice $\hat{x}$ a cualquier conjunto de l columnas linealmente independientes de la matriz A que contiene a todas las columnas A^j , $j \in J(\hat{x})$.

En otras palabras, $\mathcal{B} = \{A^j, j \in J\}$, donde $J \subset \{1, \dots, n\}$, es una base del vértice $\hat{x}$ si, primero, $\mathcal{B}$ es una base de $\mathbb{R}^l$ (en particular, J tiene que contener l elementos) y, segundo, $J \supset J(\hat{x})$. Notemos que para un vértice no degenerado, la única base es $\mathcal{B} = \{A^j, j \in J(\hat{x})\}$. Un vértice degenerado puede poseer tanto más de una base como ninguna.

La existencia de vértices degenerados en el caso de un poliedro canónico no es muy típica, en el sentido siguiente. Si hay un vértice degenerado, el vector b está en un subespacio de $\mathbb{R}^l$ generado por menos de l columnas de la matriz A . Por lo tanto, casi cualquier pequeña perturbación de b eliminaría todos los vértices degenerados.

Recordamos que por el Teorema 10.5, un poliedro canónico no vacío siempre posee al menos un vértice. Como es obvio, un vértice tiene una base si, y solamente si, $\text{rk } A = l$. De aquí en adelante, supongamos que $\text{rk } A = l$, lo que siempre puede ser garantizado eliminando aquellas restricciones de igualdad que son combinaciones lineales de las otras.

El método del simplex es una estrategia especial de generar vértices x^k del conjunto viable D y las bases $\mathcal{B}_k$ asociadas. Para todo k , dependiendo de los signos de ciertos parámetros generados, se hace una de las siguientes tres conclusiones:

1. El punto x^k es una solución del problema (10.16);
2. El problema (10.16) no tiene solución;
3. Existe (y puede ser calculado explícitamente) un vértice x^{k+1} del conjunto D , con base $\mathcal{B}_{k+1}$, tal que

$$x^{k+1} \neq x^k, \quad \langle c, x^{k+1} \rangle < \langle c, x^k \rangle, \quad (10.17)$$

o

$$x^{k+1} = x^k, \quad \mathcal{B}_{k+1} \neq \mathcal{B}_k. \quad (10.18)$$

El método del simplex puede ser interpretado como un método basado en la identificación de las restricciones activas (véase ??). Más precisamente, él determina el conjunto $I(\bar{x}) = \{1, \dots, n\} \setminus J(\bar{x})$ de las coordenadas nulas de un vértice óptimo $\bar{x}$, i.e., el conjunto de las restricciones de desigualdad del problema (10.16), activas en $\bar{x}$. Después de

eso, las coordenadas no nulas de $\bar{x}$ pueden ser calculadas resolviendo el sistema lineal

$$\sum_{j \in J(\bar{x})} A^j x_j = b.$$

En los primeros dos casos listados arriba, el algoritmo, naturalmente, para. Si el vértice x^k es no degenerado y estamos en el Caso 3, siempre se realiza (10.17). Si el vértice x^k es degenerado, puede ocurrir también (10.18). Sin embargo, el método posee mecanismos para evitar la elección cíclica de las bases; en algún momento siempre ocurrirá el caso (10.17), lo que significa que encontramos un nuevo vértice, mejor que el anterior.

Como el número de vértices es finito y, cuando la solución del problema (10.16) existe, una de ellas es vértice, después de un número finito de pasos obtenemos una de las conclusiones 1 o 2. En otras palabras, si el problema (10.16) posee soluciones, una de ellas será encontrada después de un número finito de pasos. Si el problema (10.16) no tiene solución, esto también será descubierto después de un número finito de pasos.

Cabe resaltar que, teóricamente, el método del simplex puede pasar por *todos* los vértices del conjunto viable hasta terminar con la conclusión 1 o 2. O sea, existen ejemplos (¡artificiales!) donde el método no presenta ninguna ventaja con relación a la estrategia del cálculo indiscriminado de todos los vértices del conjunto viable. Sin embargo, en la práctica, el desempeño del método del simplex es mucho mejor que eso. Típicamente, el número de iteraciones queda entre l y $2l$, y el método es muy adecuado para resolver problemas con n y l del orden de algunos miles.

A continuación, presentaremos los detalles del método del simplex. Sean $x^0, x^1, \dots, x^k$ los vértices del poliedro D ya calculados (un método para encontrar el primer vértice x^0 será comentado más adelante). Sea $\mathcal{B}_k = \{A^j, j \in J_k\}$ una base del vértice x^k , donde $J_k \subset \{1, \dots, n\}$. Como tratamos de explicar una iteración del método (la iteración que genera el iterado siguiente x^{k+1}), para simplificar la notación omitimos el índice k , definiendo $x = x^k$, $\mathcal{B} = \mathcal{B}_k$, $J = J_k$.

Como $\mathcal{B}$ es una base de $\mathbb{R}^l$, las columnas de la matriz A son unívocamente representadas en la forma siguiente:

$$A^i = \sum_{j \in J} \gamma_{ji} A^j, \quad i = 1, \dots, n, \quad (10.19)$$

donde los números $\gamma_{ji} \in \mathbb{R}$, $j \in J$, $i = 1, \dots, n$, se llaman **coeficientes de sustitución**. Definimos de qué se llaman **estimaciones de sustitución**:

$$\delta_i = c_i - \sum_{j \in J} c_j \gamma_{ji}, \quad i = 1, \dots, n. \quad (10.20)$$

Notemos que

$$\gamma_{ji} = \begin{cases} 1, & \text{si } j = i, \\ 0, & \text{si } j \in J \setminus \{i\}, \end{cases} \quad \delta_i = 0 \quad \forall i \in J,$$

y para $i \in J$ los coeficientes y las estimaciones de sustitución no contienen información ninguna. Es el análisis de los signos de δ_i y de γ_{ji} con $j \in J$, $i \notin J$, que permite hacer una de las tres conclusiones listadas anteriormente (de aquí en adelante, $i \notin J$ significa que $i \in \{1, \dots, n\} \setminus J$).

A continuación, presentamos el criterio de optimalidad en el método del simplex.

Teorema 10.11 (Criterio de optimalidad en el método del simplex). Para $A \in \mathbb{R}^{l \times n}$ y $b \in \mathbb{R}^l$, sea $x \in D$ un vértice del poliedro D definido en (10.16) con $\Omega = \mathbb{R}_+^n$, y sea $\mathcal{B} = \{A^j, j \in J\}$ una base de este vértice, $J \subset \{1, \dots, n\}$. Si para las estimaciones de sustitución, definidas en (10.19) y (10.20), se tiene que

$$\delta_i \geq 0 \quad \forall i \notin J, \quad (10.21)$$

entonces x es una solución del problema (10.16).

Prueba. Consideremos el dual del problema (10.16), i.e.,

$$\max \langle b, \lambda \rangle \quad \text{sueto a} \quad \lambda \in \Delta = \{\lambda \in \mathbb{R}^l \mid A^T \lambda \leq c\}. \quad (10.22)$$

Por el Teorema 10.7, para probar la afirmación basta construir un punto $\lambda \in \Delta$ tal que

$$\langle c, x \rangle = \langle b, \lambda \rangle. \quad (10.23)$$

Como $\mathcal{B}$ es una base de $\mathbb{R}^l$, existe un único $\lambda \in \mathbb{R}^l$ que satisface el sistema lineal

$$\langle A^j, \lambda \rangle = c_j, \quad j \in J. \quad (10.24)$$

Para este λ , teniendo en cuenta (10.19)-(10.21), obtenemos que para todo $i \notin J$ se tiene que

$$\langle A^i, \lambda \rangle = \sum_{j \in J} \langle A^j, \lambda \rangle \gamma_{ji} = \sum_{j \in J} c_j \gamma_{ji} = c_i - \delta_i \leq c_i.$$

En combinación con (10.24), esto muestra la inclusión $\lambda \in \Delta$. Ahora, como $\mathcal{B}$ es una base del vértice x , se tiene que $J(x) \subset J$, i.e., $x_j = 0 \forall j \notin J$. De aquí, de (10.24) y de la inclusión $x \in D$, obtenemos que

$$\langle c, x \rangle = \sum_{j=1}^n \langle A^j, \lambda \rangle x_j = \left\langle \sum_{j=1}^n A^j x_j, \lambda \right\rangle = \langle Ax, \lambda \rangle = \langle b, \lambda \rangle,$$

o sea, vale (10.23). De la demostración anterior se sigue que, si vale (10.21), entonces una solución del problema dual (10.22) puede ser encontrada resolviendo el sistema lineal (10.24). ■

Lema 10.2. Sean satisfechas las hipótesis del Teorema 10.11. Para todo índice $s \notin J$ y todo $t \geq 0$, el punto $x(t) \in \mathbb{R}^n$ con coordenadas

$$x_j(t) = \begin{cases} x_j - t\gamma_{js}, & \text{si } j \in J, \\ t, & \text{si } j = s, \\ 0, & \text{si } j \notin J, j \neq s, \end{cases} \quad (10.25)$$

satisface las siguientes relaciones:

$$Ax(t) = b, \quad (10.26)$$

$$\langle c, x(t) \rangle = \langle c, x \rangle + t\delta_s. \quad (10.27)$$

Prueba. Utilizando (10.19), (10.20) y (10.25), obtenemos que

$$\begin{aligned} Ax(t) &= \sum_{j=1}^n A^j x_j(t) \\ &= \sum_{j \in J} A^j (x_j - t\gamma_{js}) + tA^s \\ &= \sum_{j \in J} A^j x_j + t \left(A^s - \sum_{j \in J} A^j \gamma_{js} \right) \\ &= \sum_{j=1}^n A^j x_j = Ax = b, \end{aligned}$$

y

$$\begin{aligned} \langle c, x(t) \rangle &= \sum_{j=1}^n c_j x_j(t) \\ &= \sum_{j \in J} c_j (x_j - t\gamma_{js}) + tc_s \\ &= \sum_{j \in J} c_j x_j + t \left(c_s - \sum_{j \in J} c_j \gamma_{js} \right) \\ &= \sum_{j=1}^n c_j x_j + t\delta_s = \langle c, x \rangle + t\delta_s, \end{aligned}$$

lo que verifica (10.26) y (10.27). ■

Presentamos ahora el criterio de insolubilidad en el método del simplex.

Teorema 10.12 (Criterio de insolubilidad en el método del simplex). Supongamos que valen las hipótesis del Teorema 10.11. Si para los coeficientes y las estimaciones de sustitución, definidas en (10.19) y (10.20), existe un índice $s \notin J$ tal que

$$\delta_s < 0, \quad \gamma_{js} \leq 0 \quad \forall j \in J, \quad (10.28)$$

entonces el problema (10.16) no posee solución.

Prueba. De (10.27) y (10.28), para el punto $x(t)$, con coordenadas definidas en (10.25), tenemos que

$$x(t) \geq 0 \quad \forall t \geq 0,$$

$$\langle c, x(t) \rangle = \langle c, x \rangle + t\delta_s \rightarrow -\infty \quad (t \rightarrow +\infty).$$

En combinación con (10.26), estas dos relaciones muestran que $\inf_{x \in D} \langle c, x \rangle = -\infty$. ■

Ejercicio 10.11. Probar el resultado del Teorema 10.12 empleando la teoría de dualidad, sin hacer uso del Lema 10.2.

Supongamos ahora que existan índices $s \notin J$ y $j \in J$ tales que

$$\delta_s < 0, \quad \gamma_{js} > 0. \quad (10.29)$$

La idea de la iteración del método del simplex es la siguiente: procuramos cambiar la base del vértice actual de manera que se garantice que en el vértice nuevo (que corresponde a la nueva base) el valor de la función objetivo sea menor que en el vértice actual. Definimos

$$\tilde{t} = \max\{t \in \mathbb{R}_+ \mid x(t) \geq 0\}. \quad (10.30)$$

De (10.25) queda claro que

$$\tilde{t} = \min \left\{ \frac{x_j}{\gamma_{js}} \mid \gamma_{js} > 0, j \in J \right\}. \quad (10.31)$$

Sea r un índice donde se realiza el mínimo en la definición anterior, i.e.,

$$r \in J, \quad \gamma_{rs} > 0, \quad \frac{x_r}{\gamma_{rs}} = \tilde{t}. \quad (10.32)$$

Definimos también el conjunto

$$\tilde{J} = (J \setminus \{r\}) \cup \{s\}. \quad (10.33)$$

Teorema 10.13 (Iteración del método del simplex). Supongamos que valen las hipótesis del Teorema 10.11. Si para los coeficientes y las estimaciones de sustitución, definidas en (10.19) y (10.20), existen índices $s \notin J$ y $j \in J$ tales que vale (10.29), entonces el punto $\tilde{x} = x(\tilde{t})$, definido por las fórmulas (10.25), (10.31), es un vértice del poliedro D y el sistema $\tilde{\mathcal{B}} = \{A^j, j \in \tilde{J}\}$, donde el conjunto $\tilde{J}$ viene dado por (10.33), es una base de él. Además, si $\tilde{t} > 0$ entonces $\langle c, \tilde{x} \rangle < \langle c, x \rangle$; y si $\tilde{t} = 0$ entonces $\tilde{x} = x$, pero $\tilde{\mathcal{B}} \neq \mathcal{B}$.

Prueba. De (10.25), (10.30) y de la igualdad en (10.32), se sigue que $\tilde{x} \geq 0$ y $\tilde{x}_r = x_r - \tilde{t}\gamma_{rs} = 0$. Por lo tanto, utilizando el Lema 10.2 y (10.33), obtenemos que $\tilde{x} \in D$ y

$$J(\tilde{x}) \subset \tilde{J}. \quad (10.34)$$

Además, de (10.19) tenemos

$$A^s = \sum_{j \in J} \gamma_{js} A^j = \sum_{j \in J \setminus \{r\}} \gamma_{js} A^j + \gamma_{rs} A^r.$$

Como de (10.32) tenemos que $\gamma_{rs} > 0$, concluimos que

$$A^r = \frac{1}{\gamma_{rs}} A^s - \sum_{j \in J \setminus \{r\}} \frac{\gamma_{js}}{\gamma_{rs}} A^j. \quad (10.35)$$

De aquí, de (10.33) y del hecho de que $\mathcal{B}$ es una base de $\mathbb{R}^l$, se sigue que $\tilde{\mathcal{B}}$ también es una base de $\mathbb{R}^l$. Por lo tanto, por (10.34) y por el Teorema 10.4, el punto $\tilde{x}$ es un vértice de D y $\tilde{\mathcal{B}}$ es una base de él. La última afirmación del teorema se sigue de (10.25), (10.27) y (10.29). ■

Observamos que la nueva base $\tilde{\mathcal{B}}$ se obtiene de la base anterior $\mathcal{B}$ sustituyendo la columna A^r por la columna A^s . En otras palabras, la columna A^r está eliminada de la base y la columna A^s está incluida. A veces, el coeficiente de sustitución γ_{rs} se llama elemento principal.

Si x es un vértice no degenerado, se tiene que $J(x) = J$, i.e., $x_j > 0 \forall j \in J$. En este caso, de (10.31) se sigue que $\tilde{t} > 0$. Por lo tanto, en la iteración de este tipo necesariamente se realiza (10.17), i.e., el método genera un nuevo vértice, mejor que el anterior. Iteraciones de este tipo se ilustran en la figura 10.3.

Si x es un vértice degenerado, posiblemente existe un índice $j \in J$ tal que $x_j = 0$ y $\gamma_{js} > 0$. En este caso, de (10.25) y (10.31) se sigue que $\tilde{t} = 0$, $\tilde{x} = x$, i.e., el método no genera un vértice nuevo y la iteración consiste solamente en el cambio de la base $\mathcal{B}$ del vértice x por la base $\tilde{\mathcal{B}}$. Resaltamos que esto también es una operación no trivial, ya que para la nueva base tenemos que recalcular los coeficientes y las estimaciones de sustitución (y, posiblemente, el propio vértice será cambiado en la iteración siguiente). Sin embargo, también puede ocurrir que las iteraciones del método del simplex se reduzcan a la generación de bases para un mismo vértice. Como el número de bases es finito, a partir de un cierto momento ellas serán repetidas. O sea, el método entra en un *ciclo*. Existen ejemplos (¡artificiales!) donde esto realmente ocurre, pero situaciones así no son típicas en la práctica computacional. Recordamos que la propia existencia de vértices degenerados ya es una situación rara, e incluso para un vértice degenerado, típicamente alguna base resulta en la generación de un vértice nuevo.




Figura 10.3.: Dos iteraciones del método del simplex que generan vértices no degenerados (y resultan en un decrecimiento de la función objetivo). El último iterado es la solución del problema.

Además de eso, la iteración del método del simplex puede ser organizada de manera que elimine la posibilidad de ciclo. La idea consiste en la utilización de ciertas estrategias especiales para la elección de columnas que dejan la base y que entran (en los casos cuando hay más de un candidato). Una estrategia más simple es la **regla de Bland**: en el caso cuando (10.29) se satisface, tomamos los menores números s y r entre los posibles, i.e.,

$$s = \min\{i \mid i \notin J, \delta_i < 0\},$$

$$r = \min\{j \mid j \in J, \gamma_{js} > 0, x_j/\gamma_{js} = \tilde{t}\}.$$

Estos últimos comentarios concluyen la descripción de una iteración del método del simplex. En la iteración siguiente, las mismas construcciones se repiten para el vértice $\bar{x}$ y la base de él $\tilde{\mathcal{B}}$. Para eso, primero calculamos los coeficientes $\tilde{\gamma}_{ji}$ y las estimaciones $\tilde{\delta}_i$ de sustitución correspondientes, $j \in \tilde{J}, i = 1, \dots, n$. En principio, para esto necesitamos resolver el sistema lineal correspondiente (véase (10.19)). Sin embargo, no hay necesidad de resolver el sistema, ya que los coeficientes y las estimaciones de sustitución en las dos iteraciones siguientes tienen relaciones explícitas. En particular, utilizando (10.19), (10.20) y (10.35), es fácil verificar que para todo $i = 1, \dots, n$, se tiene que

$$\tilde{\gamma}_{ji} = \begin{cases} \gamma_{ji} - \gamma_{js}\gamma_{ri}/\gamma_{rs}, & \text{si } j \in J \setminus \{r\}, \\ \gamma_{ri}/\gamma_{rs}, & \text{si } j = s, \end{cases}$$

$$\tilde{\delta}_i = \delta_i - \delta_s \frac{\gamma_{ri}}{\gamma_{rs}}.$$

Ejercicio 10.12. Probar las fórmulas de arriba relacionando los coeficientes y las estimaciones de sustitución en las dos iteraciones siguientes del método del simplex.

Ejercicio 10.13. Encontrando todos los vértices del conjunto viable, resolver el problema

$$\min x_1 + 2x_2 + 4x_3 \quad \text{sujeto a } x \in D,$$

$$D = \{x \in \mathbb{R}_+^3 \mid 2x_1 + 3x_2 + 4x_3 = 10, x_1 + x_2 - x_3 = 4\}.$$

Ejercicio 10.14. A partir del vértice $x = (0, 1, 3)$, hacer una iteración del método del simplex para el problema

$$\min -x_1 - x_2 - x_3 \quad \text{sujeto a } x \in D,$$

$$D = \{x \in \mathbb{R}_+^3 \mid -2x_1 + x_2 + x_3 = 4, x_1 - 2x_2 + x_3 = 1\}.$$

Ejercicio 10.15. A partir del vértice $x = (1, 1, 0)$, hacer una iteración del método del simplex para el problema

$$\min -x_1 + 2x_2 - x_3 \quad \text{sujeto a } x \in D,$$

$$D = \{x \in \mathbb{R}_+^3 \mid x_1 - x_2 + 2x_3 = 0, x_1 + x_2 + 5x_3 = 2\}.$$

Ejercicio 10.16. Aplicando el método del simplex a partir del vértice $x = (1, 0, 1, 0)$, resolver el problema

$$\min -x_1 + 3x_2 + 5x_3 + x_4 \quad \text{sujeto a} \quad x \in D,$$

$$D = \{x \in \mathbb{R}_+^4 \mid x_1 + 4x_2 + 4x_3 + x_4 = 5, x_1 + 7x_2 + 8x_3 + 2x_4 = 9\}.$$

Ejercicio 10.17. Aplicando el método del simplex a partir del vértice $x = (0, 0, 1, 3)$, resolver el problema

$$\min -3x_1 - x_2 - x_3 + x_4 \quad \text{sujeto a} \quad x \in D,$$

$$D = \{x \in \mathbb{R}_+^4 \mid x_1 - x_2 + x_3 = 1, 2x_1 + x_2 + x_4 = 3\}.$$

Para finalizar, comentamos el asunto del cálculo de un vértice inicial (que es necesario para comenzar el proceso descrito arriba). A veces, esta tarea no es difícil. Consideremos, por ejemplo, el siguiente problema de programación lineal:

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad x \in D = \{x \in \Omega \mid Ax \geq b\},$$

donde $c \in \mathbb{R}^n, A \in \mathbb{R}^{l \times n}, b \in \mathbb{R}^l, \Omega = \mathbb{R}_+^n$. Consideremos el caso cuando $b \geq 0$. Este problema puede ser transformado al formato canónico:

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad (x, y) \in \tilde{D} = \{z = (x, y) \in \tilde{\Omega} \mid Ax - y = b\}, \quad (10.36)$$

donde $\tilde{\Omega} = \mathbb{R}_+^n \times \mathbb{R}_+^m$. Es fácil ver que el punto $z = (0, b)$ es un vértice del poliedro canónico $\tilde{D}$, y que la base canónica del espacio $\mathbb{R}^m$ es una base de este vértice.

En el caso general, el cálculo de un vértice inicial es comparable en costos computacionales con el método del simplex propiamente dicho. El esquema siguiente para el cálculo de un vértice inicial es llamado **método de base artificial**. De hecho, él es el método del simplex aplicado a un problema auxiliar.

Sin pérdida de generalidad, admitimos que en el problema (10.16) tenemos $b \geq 0$ (esto siempre puede ser garantizado cambiando los signos de las restricciones, donde sea necesario). Consideremos el siguiente problema auxiliar:

$$\min \sum_{i=1}^l y_i \quad \text{sujeto a} \quad (x, y) \in \tilde{D}, \quad (10.37)$$

donde el conjunto $\tilde{D}$ está definido en (10.36). Por lo visto arriba, en este caso sabemos un vértice $z = (0, b)$ del poliedro $\tilde{D}$ y una base de él. A partir de este vértice, aplicamos el método del simplex para resolver el problema (10.36). Como la función objetivo de este problema está limitada inferiormente (por cero) y el conjunto viable $\tilde{D}$ es no vacío, por el Teorema 10.1, el problema (10.37) tiene soluciones. Luego, el método del simplex encontraría una solución $z^0 = (x^0, y^0)$, que es un vértice del poliedro $\tilde{D}$.

Existen dos posibilidades. Si $y^0 \neq 0$, el valor óptimo del problema (10.37) es positivo y el conjunto viable D del problema (10.16) es vacío. En efecto, si un punto $x \in D$ existiera, tendríamos $z = (x, 0) \in \tilde{D}$ con valor de la función objetivo del problema (10.37) nulo en el punto z . Pero esto contradice el hecho de que z^0 es una solución del problema (10.37). Por otro lado, si $y^0 = 0$, se tiene que x^0 es un vértice de D , ya que esto es equivalente a que $(x^0, 0)$ sea un vértice de $\tilde{D}$.

El método de base artificial también puede ser equipado con el cálculo de una base del vértice inicial x^0 .

Ejercicio 10.18. Probar que, bajo las condiciones del Teorema 10.11, si el vértice x es no degenerado, entonces vale la afirmación inversa a aquella del teorema: si x es una solución del problema (10.16), entonces la condición (10.21) se satisface; y si x es una única solución, entonces $\delta_i > 0 \forall i \notin J$.

Construir un ejemplo mostrando que para un vértice degenerado, tal afirmación puede ser falsa.

10.1.3. Métodos de puntos interiores

Los métodos de puntos interiores se volvieron bastante populares a partir de los años 80 del siglo pasado. El interés inicial se debió a la complejidad polinomial de estos métodos, lo que los diferencia del método del simplex que tiene complejidad exponencial (véase comentarios más adelante). Un poco más tarde, fueron desarrolladas versiones de los métodos de puntos interiores bien competitivas también desde el punto de vista computacional. A propósito, actualmente los métodos de puntos interiores son los más indicados para problemas de gran escala. A continuación presentaremos algunas ideas básicas, sin entrar en todos los detalles.

Comenzamos con algunos comentarios sobre la complejidad de algoritmos. Informalmente hablando, por *complejidad* de un método entendemos la dependencia de la cantidad máxima de cálculos (iteraciones, operaciones aritméticas, etc.) necesarias para encontrar una solución exacta del problema en función de las dimensiones del problema de la clase en consideración. Si esta dependencia puede ser acotada superiormente por un polinomio (con respecto a las dimensiones del problema), hablamos de complejidad polinomial. Si la cota superior tiene forma exponencial, hablamos entonces de complejidad exponencial. Resaltamos que en cuestión están estimaciones para “el peor caso posible”, i.e., para los problemas más difíciles de resolver (por el método en consideración).

Los métodos de puntos interiores poseen complejidad polinomial. El método del simplex, por otro lado, tiene complejidad exponencial, ya que la naturaleza de este último tiene aspectos claramente combinatorios (recordamos que para encontrar una solución, el método del simplex puede precisar calcular todos los vértices del conjunto viable).

Consideremos un problema de programación lineal, por ejemplo, en forma canónica:

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}_+^n \mid Ax = b\}, \quad (10.38)$$

donde $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$ son dados. La cantidad de cálculos típicamente es medida en términos de la dimensión del problema (10.38), como se llama al número

$$s = q + n + l,$$

donde q es el número total de bits (en inglés) necesarios para representar elementos de c , A y b , suponiendo que ellos sean números enteros (números reales pueden ser representados por enteros). El significado del número s es el siguiente: 2^s es un número “muy grande”, en el sentido de que es mayor que el resultado de cualquier operación aritmética utilizando los datos del problema. Luego, 2^{-s} es un número “muy pequeño”, que posee las propiedades siguientes. Si $\hat{x}$ es un vértice del poliedro D entonces, primero, $\hat{x}_j \notin (0, 2^{-s}) \forall j = 1, \dots, n$, y segundo, $\langle c, \hat{x} \rangle - \bar{v} \notin (0, 2^{-s})$, donde $\bar{v} = \inf_{x \in D} \langle c, x \rangle$ es el valor óptimo del problema (10.38).

Recordamos que el método del simplex es finito: él encuentra una solución exacta después de un número finito de iteraciones. Como veremos más adelante, los métodos de puntos interiores no tienen convergencia finita, apenas asintótica (ya que ellos siempre generan puntos en el interior del conjunto viable, y la solución de un problema de programación lineal está siempre en la frontera). Sin embargo, teniendo una aproximación a la solución suficientemente buena, la solución exacta puede ser obtenida utilizando la llamada *técnica de purificación*¹, que para un punto $x \in D$ cualquiera encuentra un vértice $\hat{x}$ del poliedro D tal que $\langle c, \hat{x} \rangle \leq \langle c, x \rangle$, en un número de operaciones aritméticas de orden $O(n^3)$. Naturalmente, la técnica de purificación tiene un papel puramente teórico (el de viabilizar una comparación entre el método del simplex, que es finito, y los métodos de puntos interiores, que no son finitos). Ella no es utilizada en la práctica computacional.

Teniendo en cuenta lo dicho arriba, en el análisis de la complejidad de los métodos de puntos interiores se considera que ellos paran cuando un iterado x satisface la desigualdad

$$\langle c, x \rangle - \bar{v} < 2^{-s}. \quad (10.39)$$

Cuando hablamos de la complejidad polinomial de métodos de puntos interiores, entendemos lo siguiente. La cantidad de cálculos necesarios para que el método alcance la propiedad (10.39) puede ser acotada por un polinomio en relación a n . Habiendo calculado un punto x que satisface (10.39), puede ser utilizada la técnica de purificación para encontrar un vértice que es una solución exacta del problema. Como la complejidad de la purificación es polinomial, ella no interfiere en la complejidad polinomial del método como un todo. Naturalmente, versiones diferentes de los métodos de puntos interiores poseen diferentes estimaciones de complejidad. En términos de número de iteraciones, hay estimaciones de orden $O(\sqrt{ns})$, y en términos de operaciones aritméticas, de orden $O(n^{3.5}s)$.

Por otro lado, es claro que el número de vértices del poliedro D puede depender de n de manera exponencial (por ejemplo, una caja en $\mathbb{R}^n$ tiene 2^n vértices). Y como comentamos en la apartado 10.1.2, el método del simplex puede calcular todos los vértices hasta encontrar una solución del problema. Tales ejemplos existen y muestran que la complejidad del método del simplex es exponencial (¡en el sentido del peor caso posible!).

Sin embargo, es importante resaltar lo siguiente. Aunque la complejidad atractiva de un método dado sea ciertamente deseable, ella puede reflejarse muy poco en el desempeño del método cuando es aplicado a problemas típicos o de interés práctico. No es raro que métodos con mejores estimaciones de complejidad sean menos eficientes en la práctica que métodos con propiedades, en principio, peores. Por ejemplo, existen métodos de puntos interiores que poseen complejidad polinomial, pero no tienen ningún valor computacional (en particular, son mucho peores

¹En inglés: *purification procedure*.

que el método del simplex). Por otro lado, hay métodos de puntos interiores muy buenos (en particular, versiones primal-dual) que son computacionalmente eficientes, y actualmente son la elección para problemas muy grandes.

Los métodos de puntos interiores (principalmente, versiones primales) pueden ser pensados como implementaciones aproximadas de los métodos de barreras (véase ??).

A continuación, consideraremos un método de puntos interiores para el problema canónico (10.38). Recordamos que esto no reduce la generalidad. En este contexto, es conveniente tomar

$$\Omega = \{x \in \mathbb{R}^n \mid Ax = b\},$$

tratando las restricciones de igualdad como abstractas, y penalizar las restricciones $x \geq 0$. Supongamos que el conjunto viable D en (10.38) sea acotado y que $D^0 \neq \emptyset$, donde

$$D^0 = \{x \in \Omega \mid x > 0\}. \quad (10.40)$$

Supongamos también que $\text{rk } A = l$, lo que siempre puede ser garantizado eliminando restricciones que son consecuencias de las otras, si fuera necesario.

Definimos la **trayectoria central** (primal) del problema (10.38) como la función $x : (\mathbb{R}_+ \setminus \{0\}) \rightarrow D^0$, donde para todo valor del parámetro $t > 0$ de la penalización, $x(t)$ es la solución del problema

$$\min \varphi(x; t) \quad \text{sujeto a} \quad x \in D^0, \quad (10.41)$$

donde

$$\varphi(\cdot; t) : \{x \in \mathbb{R}^n \mid x > 0\} \rightarrow \mathbb{R}, \quad \varphi(x; t) = \langle c, x \rangle - t \sum_{j=1}^n \log x_j. \quad (10.42)$$

Como la función objetivo en (10.41) es coerciva en el conjunto viable, el problema en cuestión posee solución. Más aún, como el problema es de programación convexa y la función objetivo es estrictamente convexa, la solución es única. Por lo tanto, la trayectoria central está bien definida.

Intuitivamente, parece natural seguir la trayectoria central “comenzando” con $t = +\infty$ hasta $t = 0$. Por eso, es común definir el valor de x para $t = +\infty$ de la manera siguiente. Observemos que para todo $t > 0$, el problema (10.41), con la función objetivo definida en (10.42), tiene la misma solución que

$$\max \sum_{j=1}^n \log x_j - \frac{1}{t} \langle c, x \rangle \quad \text{sujeto a} \quad x \in D^0.$$

Tomando el límite cuando $t \rightarrow +\infty$, obtenemos el problema

$$\max \sum_{j=1}^n \log x_j \quad \text{sujeto a} \quad x \in D^0.$$

Definimos $x(+\infty)$ como la solución de este problema. Este punto inicial de la trayectoria central se llama **centro analítico** del conjunto D definido en (10.38). Notemos que él depende de A y b (i.e., del conjunto viable) y no depende de c (i.e., de la función objetivo). El centro analítico de un conjunto y algunas trayectorias centrales están ilustradas en la figura 10.4.




Figura 10.4.: El centro analítico de D y las trayectorias centrales para dos funciones objetivo diferentes.

Observemos también que para $t > 0$, el punto $x(t)$ es el centro analítico de la intersección del conjunto D con el hiperplano donde la función objetivo del problema (10.38) tiene el valor $\langle c, x(t) \rangle$, i.e., $x(t)$ es la solución del problema

$$\max \sum_{j=1}^n \log x_j \quad \text{sueto a} \quad x \in D_t^0 = \{x \in D^0 \mid \langle c, x \rangle = \langle c, x(t) \rangle\}.$$

Este hecho se ilustra en la figura 10.5.




Figura 10.5.: El punto $x(t)$ de la trayectoria central es el centro analítico de la intersección de D con el hiperplano donde el valor de la función objetivo es $\langle c, x(t) \rangle$.

Puede ser probado que el límite $\lim_{t \rightarrow 0^+} x(t)$ existe y es el centro analítico del conjunto de las soluciones del problema (10.38). No vamos a probar este resultado, porque la justificación del ?? ya sirve como motivación suficiente para intentar encontrar alguna estrategia de seguir la trayectoria central, principalmente si pudimos hacer esto de manera computacionalmente barata, sin precisar calcular valores exactos (o casi exactos) de la función x (o sea, sin resolver los subproblemas penalizados).

El esquema básico de los métodos de puntos interiores (primales) es el siguiente.

Algoritmo 6.1.1. (El método de puntos interiores primal)

Escoger parámetro inicial $t_0 > 0$. Para el conjunto D^0 definido en (10.40), escoger $x^{-1} \in D^0$ y tomar $k := 0$.

1. A partir del punto x^{k-1} , calcular $x^k \in D^0$ dando algunos pasos de un método (típicamente, Newtoniano) para el problema (10.41), donde la función objetivo está dada en (10.42) con $t = t_k$.
2. Escoger $t_{k+1} \in (0, t_k)$.
3. Tomar $k := k + 1$ y retornar al Paso 1.

En este esquema, el punto x^{-1} debe ser suficientemente próximo a $x(t_0)$, y el número de pasos del método interno debe garantizar que, para todo x^{k-1} , el punto siguiente x^k quede suficientemente próximo a $x(t_k)$. Existen métodos con complejidad polinomial que permiten para $t_0 > 0$ arbitrario aproximar $x(t_0)$ con cualquier precisión deseada.

Es claro que el Algoritmo 6.1.1 es solo un esquema básico. Para obtener un método completo, será necesario especificar varios detalles. Por ejemplo, la regla de decrecimiento del parámetro t_k a lo largo de las iteraciones es muy importante. Si la sucesión de parámetros disminuye despacio, entonces para todo k el punto $x(t_k)$ estará próximo a $x(t_{k-1})$, y podemos esperar que unos pocos pasos (tal vez apenas un) del método interno a partir del punto x^{k-1} producirán x^k lo suficientemente próximo a $x(t_k)$ para garantizar convergencia del algoritmo. Un poco más adelante mostraremos que esto realmente ocurre. Sin embargo, esta estrategia puede requerir un número grande de iteraciones (del método externo) para generar un punto $x(t_k)$ próximo al conjunto de soluciones del problema (10.38), ya que muchas actualizaciones serán necesarias para que t_k llegue próximo a cero. La alternativa es disminuir el parámetro más rápidamente, a costa de aumentar el número de iteraciones del método interno. En el primer caso, hablamos de *métodos de pasos cortos*², y en el segundo – de *métodos de pasos largos*³. Consideremos los métodos de pasos cortos, que tienen estimaciones de complejidad mejores. Resaltamos, sin embargo, que las buenas implementaciones de los métodos de pasos largos son, usualmente, más eficientes en la práctica.

²En inglés: *short-step methods*.

³En inglés: *long-step methods*.

Sea $x \in D^0$ la aproximación actual a la solución del problema (10.41). Definimos el paso Newtoniano para este problema: la aproximación siguiente $\tilde{x} \in \mathbb{R}^n$ se calcula como solución del problema

$$\min \langle \varphi'(x; t), \xi - x \rangle + \frac{1}{2} \langle \varphi''(x; t)(\xi - x), \xi - x \rangle \quad \text{sueto a } \xi \in \Omega. \quad (10.43)$$

Si ignoramos en el problema (10.41) las restricciones funcionales $x > 0$ (lo que puede ser hecho, en cierto sentido; véase los comentarios en ??), el problema (10.43) puede ser interpretado como una iteración del método de Newton irrestricto con longitud de paso unitario (véase ??) o, ya que las restricciones que definen Ω son lineales, como una iteración del método de programación cuadrática secuencial (véase ??).

De aquí en adelante, denotamos $e = (1, \dots, 1) \in \mathbb{R}^n$. Para todo $x \in \mathbb{R}^n$, denotamos por $X \in \mathbb{R}^{n \times n}$ la matriz diagonal con coeficientes $(x_1, \dots, x_n)$. Definimos también las siguientes funciones:

$$\lambda : (\mathbb{R}_+ \setminus \{0\}) \times D^0 \rightarrow \mathbb{R}^l, \quad \lambda(t, x) = (AX^2A^T)^{-1}AX(Xc - te), \quad (10.44)$$

$$d : (\mathbb{R}_+ \setminus \{0\}) \times D^0 \rightarrow \mathbb{R}^n, \quad d(t, x) = \frac{1}{t}X(c - A^T\lambda(t, x)) - e. \quad (10.45)$$

Ejercicio 10.19. Para $t > 0$ y $x \in D^0$ dados, sea $\tilde{x} \in \mathbb{R}^n$ la solución del problema (10.43), donde la función $\varphi(\cdot; t)$ está definida en (10.42), $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$, $\Omega = \{x \in \mathbb{R}^n \mid Ax = b\}$, y el conjunto D^0 es dado por (10.40). Sean los vectores $d(t, x) \in \mathbb{R}^n$ y $\lambda(t, x) \in \mathbb{R}^l$ definidos por (10.44), (10.45). Probar que

$$\tilde{x} = x - Xd(t, x),$$

y que $\lambda(t, x)$ es la solución del problema

$$\min \left\| \frac{1}{t}X(c - A^T y) - e \right\|, \quad y \in \mathbb{R}^l.$$

Mostrar que $d(t, x) = 0$ si, y solamente si, x es una solución del problema (10.41).

Por lo tanto, el vector $-d(t, x) = X^{-1}(\tilde{x} - x)$ puede ser considerado como un paso del método de Newton para el problema (10.41) a partir del punto x , preconditionado por la matriz X^{-1} . Como veremos a continuación, $\|d(t, x)\|$ sirve como medida de proximidad de x a $x(t)$. El resultado a ser presentado puede ser pensado también como una caracterización de convergencia del método general de barreras (véase ??) cuando es aplicado al problema de programación lineal (10.38). Para el método de puntos interiores, el resultado es importante porque establece la precisión con la que los subproblemas tienen que ser resueltos para garantizar convergencia del método.

Proposición 10.2. Sean $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$. Sean $\Omega = \{x \in \mathbb{R}^n \mid Ax = b\}$ y D^0 el conjunto definido en (10.40). Sean λ y d las funciones definidas por las fórmulas (10.44), (10.45). Entonces, si para el número $t > 0$ y el punto $x \in D^0$ dados vale que $\|d(t, x)\| < 1$, se tiene que

$$\begin{aligned} \langle c, x \rangle - \bar{v} &\leq \langle c, x \rangle - \langle b, \lambda(t, x) \rangle \\ &\leq t(n + \sqrt{n}\|d(t, x)\|) \\ &< t(n + \sqrt{n}), \end{aligned} \quad (10.46)$$

donde $\bar{v} = \inf_{x \in D} \langle c, x \rangle$.

Prueba. Por (10.45), tenemos que

$$\left\| \frac{1}{t}X(c - A^T\lambda(t, x)) - e \right\| < 1,$$

de donde se sigue que $X(c - A^T\lambda(t, x)) > 0$. De aquí y de la condición $x \in D^0$, obtenemos que

$$c - A^T\lambda(t, x) > 0. \quad (10.47)$$

Por eso, para cualquier solución $\bar{x}$ del problema (10.38), tenemos que

$$\bar{v} = \langle c, \bar{x} \rangle \geq \langle A^T\lambda(t, x), \bar{x} \rangle = \langle \lambda(t, x), A\bar{x} \rangle = \langle \lambda(t, x), b \rangle,$$

donde tuvimos en cuenta que $\bar{x} \in D$. Esto verifica la primera desigualdad en (10.46). Ahora, por la desigualdad de Cauchy-Schwarz, tenemos lo siguiente:

$$\begin{aligned} \langle e, \frac{1}{t}X(c - A^T\lambda(t, x)) - e \rangle &\leq \|e\| \left\| \frac{1}{t}X(c - A^T\lambda(t, x)) - e \right\| \\ &= \sqrt{n} \|d(t, x)\| \\ &< \sqrt{n}. \end{aligned}$$

Por otro lado,

$$\begin{aligned} \langle e, \frac{1}{t}X(c - A^T\lambda(t, x)) - e \rangle &= \frac{1}{t} \langle x, c - A^T\lambda(t, x) \rangle - \|e\|^2 \\ &= \frac{1}{t} (\langle c, x \rangle - \langle b, \lambda(t, x) \rangle) - n, \end{aligned}$$

donde tuvimos en cuenta que $x \in \Omega$. Combinando las dos últimas relaciones, obtenemos las últimas dos desigualdades en (10.46). ■

Recordamos que el punto x en consideración es viable en el problema (10.38). Además de eso, en las condiciones de la Proposición 10.2, vale (10.47). Por eso, el punto $\lambda(t, x)$ es viable en el problema dual de (10.38), i.e., en el problema

$$\max \langle b, \lambda \rangle \quad \text{sujeto a} \quad \lambda \in \Delta = \{\lambda \in \mathbb{R}^l \mid A^T\lambda \leq c\}. \quad (10.48)$$

Más aún, la relación (10.46) proporciona una estimación de proximidad entre los valores $\langle c, x \rangle$ y $\langle b, \lambda(t, x) \rangle$, y la diferencia entre ellos tiende a cero cuando $t \rightarrow 0$ (comparar con el Teorema 10.7).

A continuación, probaremos que el conjunto

$$\{x \in D^0 \mid \|d(t, x)\| < 1\}$$

está contenido en la región de convergencia cuadrática del método Newtoniano para el problema auxiliar (10.41) descrito arriba. Después de eso, mostraremos cómo debe ser actualizado el parámetro de barrera t para garantizar que el iterado siguiente valga lo mismo, i.e., que él también quede en la región de convergencia rápida del método Newtoniano, para el nuevo subproblema (con nuevo valor de t).

Proposición 10.3. *En las condiciones de la Proposición 10.2, si para el número $t > 0$ y el punto $x \in D^0$ dados vale que $\|d(t, x)\| < 1$, entonces el punto $\bar{x} = x - Xd(t, x)$ satisface*

$$\bar{x} \in D^0, \quad \|d(t, \bar{x})\| \leq \|d(t, x)\|^2. \quad (10.49)$$

Prueba. Definimos $z = X(c - A^T\lambda(t, x))/t$. Por (10.45), tenemos que $d(t, x) = z - e$. De la condición $\|d(t, x)\| < 1$ se sigue que $0 < z_j < 2 \forall j = 1, \dots, n$. Además de eso,

$$\bar{x} = x - X(z - e) = 2x - Xz.$$

Por lo tanto, $\bar{x}_j = (2 - z_j)x_j > 0 \forall j = 1, \dots, n$. Por la primera afirmación del Ejercicio 6.1.19, tenemos que $\bar{x} \in \Omega$. Luego, vale la inclusión en (10.49). El punto $\lambda(t, \bar{x})$ es la solución del problema

$$\min \left\| \frac{1}{t} \tilde{X}(c - A^T y) - e \right\|, \quad y \in \mathbb{R}^l$$

(véase el Ejercicio 10.19). Por lo tanto,

$$\begin{aligned} \|d(t, \bar{x})\| &= \left\| \frac{1}{t} \tilde{X}(c - A^T\lambda(t, \bar{x})) - e \right\| \\ &\leq \left\| \frac{1}{t} \tilde{X}(c - A^T\lambda(t, x)) - e \right\| \\ &= \|\tilde{X}X^{-1}z - e\|. \end{aligned}$$

Recordando que $\bar{x} = 2x - Xz$, obtenemos

$$\tilde{X}X^{-1}z = (2X - ZX)X^{-1}z = 2z - Zz.$$

De las dos últimas relaciones se sigue que

$$\begin{aligned}\|d(t, \tilde{x})\|^2 &\leq \|2z - Zz - e\|^2 \\ &= \sum_{j=1}^n (2z_j - z_j^2 - 1)^2 = \sum_{j=1}^n (z_j - 1)^4 \\ &\leq \left(\sum_{j=1}^n (z_j - 1)^2 \right)^2 \\ &= \|z - e\|^4 = \|d(t, x)\|^4,\end{aligned}$$

lo que verifica (10.49). ■

El resultado que acabamos de probar muestra que si $\|d(t, x)\|$ es suficientemente pequeño, después de un paso Newtoniano $\|d(t, \tilde{x})\|$ queda aún menor. Por eso, si el valor $\tilde{t}$ del nuevo parámetro de barrera no es muy diferente de t , podemos esperar que el valor de $\|d(\tilde{t}, \tilde{x})\|$ también sea suficientemente pequeño. Más precisamente, tenemos lo siguiente.

Proposición 10.4. *En las condiciones de la Proposición 10.2, si para el número $t > 0$ y el punto $x \in D^0$ dados vale que $\|d(t, x)\| = \delta < 1$, entonces para cualquier $\theta \in (0, \sqrt{n})$, el número*

$$\tilde{t} = (1 - \theta/\sqrt{n})t \in (0, t) \tag{10.50}$$

y el punto $\tilde{x} = x - Xd(t, x)$ satisfacen

$$\|d(\tilde{t}, \tilde{x})\| \leq \frac{\delta^2 + \theta}{1 - \theta/\sqrt{n}}.$$

En particular, si $\theta \leq \delta(1 - \delta)/(1 + \delta)$, entonces

$$\|d(\tilde{t}, \tilde{x})\| \leq \delta.$$

Prueba. De (10.45), de la desigualdad en (10.49), de (10.50), y del hecho de que $\lambda(\tilde{t}, \tilde{x})$ es la solución del problema

$$\min \left\| \frac{1}{\tilde{t}} \tilde{X}(c - A^T y) - e \right\|, \quad y \in \mathbb{R}^l$$

(véase el Ejercicio 10.19), obtenemos que

$$\begin{aligned}\|d(\tilde{t}, \tilde{x})\| &= \left\| \frac{1}{\tilde{t}} \tilde{X}(c - A^T \lambda(\tilde{t}, \tilde{x})) - e \right\| \\ &\leq \left\| \frac{1}{\tilde{t}} \tilde{X}(c - A^T \lambda(t, \tilde{x})) - e \right\| \\ &= \left\| \frac{\tilde{X}(c - A^T \lambda(t, \tilde{x}))}{(1 - \theta/\sqrt{n})t} - e \right\| \\ &= \left\| \frac{d(t, \tilde{x}) + e}{1 - \theta/\sqrt{n}} - e \right\| \\ &= \frac{\|d(t, \tilde{x}) + \theta e/\sqrt{n}\|}{1 - \theta/\sqrt{n}} \\ &\leq \frac{\|d(t, \tilde{x})\| + \theta \|e\|/\sqrt{n}}{1 - \theta/\sqrt{n}} \\ &\leq \frac{\|d(t, x)\|^2 + \theta}{1 - \theta/\sqrt{n}} \\ &= \frac{\delta^2 + \theta}{1 - \theta/\sqrt{n}},\end{aligned}$$

como fue enunciado. ■

Resumiendo, si tomar x^{-1} suficientemente próximo a $x(t_0)$ y controlar los parámetros de barrera t_k de manera adecuada, para todo k un paso Newtoniano será suficiente para aproximar $x(t_k)$ con precisión satisfactoria. En particular, siempre podemos forzar a que los puntos x^k queden tan próximos a la trayectoria central como deseemos. Como ya fue comentado arriba, esto viene con cierto costo – los parámetros t_k tienen que ser disminuidos lentamente (véase la fórmula (10.50) en la Proposición 10.4). Aun así, los resultados presentados son importantes y sirven como base para el desarrollo de métodos más sofisticados y más prácticos.

Un aspecto importante que está ausente en el Algoritmo 6.1.1 es el preconditionamiento. Notemos que si el punto $x^{k-1} \in D^0$ está próximo a la frontera del ortante no negativo, esto puede llevar a hacer pasos muy cortos, así como a inestabilidad numérica (ya que la matriz X^{k-1} será casi degenerada; véase las fórmulas (10.44), (10.45)). Esta dificultad puede ser aliviada haciendo preconditionamiento del subproblema, por ejemplo de la siguiente manera. En el espacio $\mathbb{R}^n$, aplicamos la transformación lineal de las variables, dada por $(X^{k-1})^{-1}$. El elemento x^{k-1} será transformado en $\xi^{k-1} = e$. Calculamos $-d(t_k, \xi^{k-1})$ como el paso Newtoniano para el problema preconditionado (10.41) con $t = t_k$ (notemos que $X^{k-1} = E^n$). Tomamos $\xi^k = \xi^{k-1} - d(t_k, \xi^{k-1})$, e invertimos la transformación de las variables: $x^k = X^{k-1} \xi^k$. La idea consiste en alejar el punto actual de la frontera de $\mathbb{R}_+^n$, aumentando así el “espacio para maniobra”. Además de eso, varias fórmulas relacionadas a la barrera (y a las derivadas de ella) se simplifican después de esta transformación de las variables.

A continuación, presentamos métodos de puntos interiores *primal-duales*. Por el Teorema 10.2, las condiciones necesarias y suficientes de optimalidad para el problema (10.38) están dadas por el sistema

$$A^T \lambda + z = c, \quad Ax = b, \quad (10.51)$$

$$x \geq 0, \quad z \geq 0, \quad \langle z, x \rangle = 0, \quad (10.52)$$

con respecto a $(x, \lambda, z) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$, donde la variable dual z corresponde a la restricción $x \geq 0$ del problema primal. La idea de los métodos de puntos interiores primal-duales consiste en la modificación del sistema anterior para eliminar el aspecto no diferenciable (o, también, combinatorio) de la condición de complementariedad en (10.52). Para este fin, cambiamos (10.52) por las condiciones siguientes:

$$x_j > 0, \quad z_j > 0, \quad x_j z_j = t, \quad j = 1, \dots, n, \quad (10.53)$$

donde $t > 0$ es un parámetro (que se aproxima a cero a lo largo de las iteraciones). Así, ignorando las desigualdades estrictas, en vez de (10.51), (10.52), obtenemos el sistema

$$A^T \lambda + z = c, \quad Ax = b, \quad XZe = te. \quad (10.54)$$

El problema dual (10.48) puede ser escrito como

$$\max \langle b, \lambda \rangle \quad \text{sujeto a} \quad (\lambda, z) \in \tilde{\Delta}, \quad (6.54)$$

donde

$$\tilde{\Delta} = \{(\lambda, z) \in \mathbb{R}^l \times \mathbb{R}_+^n \mid A^T \lambda + z = c\}. \quad (10.55)$$

Para $t > 0$ fijo, consideremos el siguiente problema auxiliar:

$$\min \varphi(x, z; t), \quad (x, (\lambda, z)) \in D^0 \times \tilde{\Delta}^0, \quad (10.56)$$

donde D^0 está definido en (10.40) con $\Omega = \{x \in \mathbb{R}^n \mid Ax = b\}$,

$$\tilde{\Delta}^0 = \{(\lambda, z) \in \tilde{\Omega} \mid z > 0\}, \quad (10.57)$$

$$\tilde{\Omega} = \{(\lambda, z) \in \mathbb{R}^l \times \mathbb{R}^n \mid A^T \lambda + z = c\}, \quad (10.58)$$

$$\varphi(\cdot; t) : \{x \in \mathbb{R}^n \mid x > 0\} \times \{z \in \mathbb{R}^n \mid z > 0\} \rightarrow \mathbb{R},$$

$$\varphi(x, z; t) = \langle x, z \rangle - t \sum_{j=1}^n \log(z_j x_j). \quad (10.59)$$

La **trayectoria central primal-dual** está definida como la función

$$(x(\cdot), (\nu(\cdot), \zeta(\cdot))) : (\mathbb{R}_+ \setminus \{0\}) \rightarrow D^0 \times \tilde{\Delta}^0,$$

donde para todo $t > 0$ el valor de la función es la solución del problema (10.56).

Ejercicio 10.20. Sean $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$. Sean $\Omega = \{x \in \mathbb{R}^n \mid Ax = b\}$, D^0 el conjunto definido en (10.40) y $\tilde{\Delta}^0$ el conjunto definido por (10.57), (10.58). Mostrar que para todo número $t > 0$ dado, la solución del problema (10.56), con la función objetivo dada por (10.59), está caracterizada por el sistema de ecuaciones (10.53).

Una iteración del método de puntos interiores primal-dual consiste en lo siguiente. Para un parámetro $t_k > 0$ dado, en el punto actual $(x^k, \lambda^k, z^k) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$ tal que $x^k > 0$ y $(\lambda^k, z^k) \in \tilde{\Delta}^0$, definimos la dirección Newtoniana para

el sistema (10.53). Habiendo calculado esta dirección, hacemos una búsqueda lineal para la función de mérito

$$\tilde{\varphi} : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}, \quad \tilde{\varphi}(x, z) = \langle x, z \rangle + \|Ax - b\|, \quad (10.60)$$

disminuyendo el valor de ella, y al mismo tiempo garantizando que la aproximación siguiente $(x^{k+1}, \lambda^{k+1}, z^{k+1})$ satisfaga las desigualdades $x^{k+1} > 0$ y $z^{k+1} > 0$. Notemos que

$$0 < \langle x^k, z^k \rangle = \langle c, x^k \rangle - \langle b, \lambda^k \rangle + \langle b - Ax^k, \lambda^k \rangle.$$

En particular, si $x^k \in \Omega$ (y, por lo tanto, $x^k \in D^0$), se tiene que

$$\tilde{\varphi}(x^k, z^k) = \langle c, x^k \rangle - \langle b, \lambda^k \rangle.$$

En general, la convergencia de $\tilde{\varphi}(x^k, z^k)$ a cero significa que

$$\langle c, x^k \rangle - \langle b, \lambda^k \rangle \rightarrow 0, \quad \{Ax^k\} \rightarrow b \quad (k \rightarrow \infty).$$

Si esto ocurre, del Teorema 10.7 se sigue que todo punto de acumulación de la sucesión $\{(x^k, \lambda^k)\}$ es una solución primal-dual del problema (10.38). Notemos que, como veremos más adelante, la viabilidad primal de puntos de acumulación de la sucesión $\{x^k\}$ no es automática en métodos de este tipo (a diferencia de los métodos de puntos interiores primales). La inclusión del segundo término en la definición de la función de mérito $\tilde{\varphi}$ tiene por objetivo resolver esta dificultad, al menos en el límite.

Algoritmo 6.1.2. (El método de puntos interiores primal-dual)

Escoger un número $t_0 > 0$. Para el conjunto $\tilde{\Delta}^0$ definido por (10.57), (10.58), escoger $(x^0, \lambda^0, z^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$, $x^0 > 0$, $(\lambda^0, z^0) \in \tilde{\Delta}^0$. Tomar $k := 0$.

1. Calcular $(d_x^k, d_\lambda^k, d_z^k) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$, el paso Newtoniano para el sistema (10.53) a partir del punto (x^k, λ^k, z^k) , con $t = t_k$.

2. Tomar

$$(x^{k+1}, \lambda^{k+1}, z^{k+1}) = (x^k, \lambda^k, z^k) + \alpha_k(d_x^k, d_\lambda^k, d_z^k),$$

donde el parámetro de la longitud de paso $\alpha_k \in (0, 1]$ es calculado para satisfacer

$$x^{k+1} > 0, \quad z^{k+1} > 0, \quad \tilde{\varphi}(x^{k+1}, z^{k+1}) < \tilde{\varphi}(x^k, z^k).$$

3. Escoger $t_{k+1} \in (0, t_k)$.
4. Tomar $k := k + 1$ y retornar al Paso 1.

Como fue el caso de los métodos de puntos interiores primales, en la práctica tenemos que agregar al Algoritmo 6.1.2 alguna técnica de preconditionamiento. La descripción y el análisis completo de los métodos de puntos interiores primal-duales requieren muchos detalles técnicos que están fuera del alcance de este libro. Presentaremos apenas algunos pasos, para ayudar a la intuición del lector.

Ejercicio 10.21. Sean $x \in \mathbb{R}^n$, $x > 0$, $(\lambda, z) \in \tilde{\Delta}^0$, donde el conjunto $\tilde{\Delta}^0$ está dado por (10.57), (10.58), $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$. Mostrar que para un número $t > 0$ dado, la dirección Newtoniana $(d_x, d_\lambda, d_z) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$ para el sistema (10.53) a partir del punto (x, λ, z) , viene dada por las ecuaciones

$$\begin{aligned} d_\lambda &= (AZ^{-1}XA^T)^{-1}(AZ^{-1}(XZe - te) + b - Ax), \\ d_z &= -A^T d_\lambda, \\ d_x &= Z^{-1}(te - XZe) - Z^{-1}X d_z. \end{aligned} \quad (10.61)$$

Mostrar que el punto $x + d_x$ es viable en el problema primal (10.38), y que el punto $(\lambda + d_\lambda, z + d_z)$ es viable en el problema dual (6.54), (10.55).

Si en las condiciones del Ejercicio 10.21 el parámetro de la longitud de paso satisface $\alpha \in (0, 1)$, el punto $x + \alpha d_x$ ya puede ser inviable en el problema primal. Pero, como puede ser visto fácilmente, el punto $(\lambda + \alpha d_\lambda, z + \alpha d_z)$ permanece viable en el problema dual. A continuación, mostraremos que un control adecuado de los valores de t y α garantiza el decrecimiento de la función de mérito $\tilde{\varphi}$.

Proposición 10.5. Sean $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$. Sean $x \in \mathbb{R}^n$, $x > 0$, $(\lambda, z) \in \tilde{\Delta}^0$, donde el conjunto $\tilde{\Delta}^0$ está dado por (10.57), (10.58). Para $t > 0$ dado, sea $(d_x, d_\lambda, d_z) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^n$ la dirección Newtoniana para el sistema (10.53) a

partir del punto (x, λ, z) . Entonces para todo $\alpha \in (0, 1]$, se tiene que

$$A(x + \alpha d_x) - b = (1 - \alpha)(Ax - b), \quad (10.62)$$

$$\begin{aligned} \tilde{\varphi}(x + \alpha d_x, z + \alpha d_z) &= \tilde{\varphi}(x, z) + \alpha^2 \langle Ax - b, d_\lambda \rangle \\ &\quad - \alpha(\langle x, z \rangle - nt + \|Ax - b\|), \end{aligned} \quad (10.63)$$

donde la función $\tilde{\varphi}$ está dada por (10.60).

Prueba. La dirección Newtoniana para el sistema (10.53) a partir del punto (x, λ, z) viene dada por las ecuaciones

$$A^T d_\lambda + d_z = 0, \quad Ad_x = b - Ax, \quad Zd_x + Xd_z = te - XZe. \quad (10.64)$$

De la segunda ecuación obtenemos que

$$A(x + \alpha d_x) - b = Ax + \alpha(b - Ax) - b = (1 - \alpha)(Ax - b),$$

lo que prueba (10.62). Además de eso,

$$\langle x + \alpha d_x, z + \alpha d_z \rangle = \langle x, z \rangle + \alpha^2 \langle d_x, d_z \rangle + \alpha(\langle x, d_z \rangle + \langle z, d_x \rangle). \quad (10.65)$$

Multiplicando los lados izquierdo y derecho de la última igualdad en (10.64) por e , obtenemos que

$$\langle x, d_z \rangle + \langle z, d_x \rangle = \langle e, te - XZe \rangle = nt - \langle x, z \rangle.$$

Ahora, utilizando (10.61) y la segunda igualdad en (10.64), tenemos que

$$\langle d_x, d_z \rangle = -\langle d_x, A^T d_\lambda \rangle = \langle Ax - b, d_\lambda \rangle.$$

Las dos últimas relaciones permiten reescribir (10.65) como

$$\langle x + \alpha d_x, z + \alpha d_z \rangle = \langle x, z \rangle - \alpha(\langle x, z \rangle - nt) + \alpha^2 \langle Ax - b, d_\lambda \rangle.$$

De aquí, teniendo también en cuenta (10.60) y (10.62), concluimos que

$$\begin{aligned} \tilde{\varphi}(x + \alpha d_x, z + \alpha d_z) &= \langle x + \alpha d_x, z + \alpha d_z \rangle + \|A(x + \alpha d_x) - b\| \\ &= \langle x, z \rangle - \alpha(\langle x, z \rangle - nt) \\ &\quad + \alpha^2 \langle Ax - b, d_\lambda \rangle + (1 - \alpha)\|Ax - b\|, \end{aligned}$$

lo que verifica (10.63). ■

Como se sigue de (10.62), la medida de inviabilidad en el problema primal está decreciendo para cualquier valor de la longitud de paso $\alpha \in (0, 1]$, si el punto x no es viable en (10.38) (y si x es viable, el punto nuevo $x + \alpha d_x$ también es viable). Además de eso, como se sigue de (10.63), si $t < \langle x, z \rangle / n$, existe un número $\bar{\alpha} > 0$ tal que todo $\alpha \in (0, \bar{\alpha})$ resulta en un decrecimiento de la función $\tilde{\varphi}$.

Una construcción inteligente de las sucesiones $\{t_k\}$ y $\{\alpha_k\}$, además del preconditionamiento, permiten el desarrollo de métodos de puntos interiores primal-duales muy eficientes (véase [20]).

Finalmente, comentaremos que métodos de puntos interiores pueden ser extendidos también a algunas clases de problemas no lineales convexos (véase [10]).

Ejercicio 10.22. Considerar el problema

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid Ax = b, g(x) \leq 0\}, \quad (10.66)$$

donde las funciones $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son convexas y dos veces continuamente diferenciables en $\mathbb{R}^n$, $A \in \mathbb{R}^{l \times n}$, $b \in \mathbb{R}^l$. Sean $\text{rk } A = l$, $\text{rk } g'(x) = m \forall x \in D$. Supongamos que exista un punto $\tilde{x} \in D$ tal que $g(\tilde{x}) < 0$. Definimos la trayectoria central primal-dual como la función

$$(x(\cdot), \nu(\cdot), \zeta(\cdot)) : (\mathbb{R}_+ \setminus \{0\}) \rightarrow \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m,$$

donde para todo $t > 0$ el valor de la función es la solución del sistema

$$f'(x) + A^T \lambda + (g'(x))^T \mu = 0, \quad Ax = b, \quad (10.67)$$

$$g_i(x) < 0, \quad \mu_i > 0, \quad \mu_i g_i(x) = t, \quad i = 1, \dots, m, \quad (10.68)$$

con respecto a $(x, \lambda, \mu) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m$. Probar que las afirmaciones siguientes son equivalentes:

- (a) El conjunto de soluciones del problema (10.66) es no vacío y acotado.
- (b) Para todo $t > 0$, el sistema (10.67), (10.68), posee una única solución (en particular, la trayectoria central primal-dual está bien definida).
- (c) El sistema (10.67), (10.68), tiene una única solución para algún valor de $t > 0$.
- (d) El sistema

$$f'(x) + A^T \lambda + (g'(x))^T \mu = 0, \quad g(x) < 0, \quad \mu > 0$$

tiene una solución.

- (e) El sistema

$$f'(x) + A^T \lambda + (g'(x))^T \mu = 0, \quad \mu > 0$$

tiene una solución.

10.2. Programación cuadrática

Nuestro interés en problemas de programación cuadrática se debe a la misma razón que en el caso de la programación lineal: ellos aparecen como subproblemas en varios métodos para problemas de optimización más generales. Un ejemplo importante es el método de programación cuadrática secuencial, considerado en la ???. Naturalmente, la eficiencia de los métodos de este tipo depende de la eficiencia de resolución de los subproblemas cuadráticos.

Como fue en el caso lineal, en el caso convexo de la programación cuadrática también existen algoritmos con convergencia finita. A continuación presentaremos un método de este tipo, llamado método de puntos especiales. Otros métodos pueden ser consultados en [8]. Problemas de programación cuadrática convexos también pueden ser resueltos por varios algoritmos con convergencia asintótica, bien eficientes. Un ejemplo es el de los métodos de puntos interiores (generalizaciones de aquellos de la apartado 10.1.3 para el caso cuadrático), véase [20].

Consideramos el problema de programación cuadrática

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid Ax \leq b\}, \quad (10.69)$$

donde

$$f : \mathbb{R}^n \rightarrow \mathbb{R}, \quad f(x) = \frac{1}{2} \langle Cx, x \rangle + \langle c, x \rangle,$$

$C \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. El formato de las restricciones no reduce la generalidad, ya que cualesquiera restricciones lineales pueden ser transformadas a esta forma. Notemos también que el método a ser presentado puede ser modificado para resolver un problema donde la matriz C es semidefinida positiva (en vez de definida positiva).

Suponiendo que $D \neq \emptyset$, el problema (10.69) tiene una única solución, ya que la función objetivo del problema es fuertemente convexa en el conjunto viable D que es convexo (véase el ???).

10.2.1. Puntos especiales

Sean A_i , $i = 1, \dots, m$, las filas de la matriz A . El método a ser presentado se basa en la noción siguiente.

Definición 10.3. Un punto $\hat{x} \in D$ se llama **punto especial** del problema (10.69), si existe un conjunto $I \subset \{1, \dots, m\}$ tal que $\hat{x}$ es una solución del problema

$$\min f(x) \quad \text{sujeto a} \quad x \in D_I = \{x \in \mathbb{R}^n \mid \langle A_i, x \rangle = b_i, \quad i \in I\} \quad (10.70)$$

(los casos de $I = \emptyset$ e $I = \{1, \dots, m\}$ no están excluidos).

La solución de un problema de programación cuadrática fuertemente convexo es un punto especial.

Teorema 10.14. Para cualquier matriz $C \in \mathbb{R}^{n \times n}$ simétrica definida positiva, y cualesquiera $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$, el número de puntos especiales en el problema (10.69) es finito. Más aún, la solución de este problema es un punto especial.

Prueba. Es claro que el número de problemas de la forma (10.70) es finito. Como la función objetivo es fuertemente convexa, cada problema no puede poseer más de una solución (para I tales que $D_I = \emptyset$, no hay solución). Por eso, el número de puntos especiales es finito.

Sea $\bar{x} \in \mathbb{R}^n$ la solución del problema (10.69). Como es fácil ver, $\bar{x}$ es una solución local del problema

$$\min f(x) \quad \text{sujeto a} \quad x \in \bar{D} = \{x \in \mathbb{R}^n \mid \langle A_i, x \rangle \leq b_i, i \in I(\bar{x})\},$$

donde $I(\bar{x}) = \{i = 1, \dots, m \mid \langle A_i, \bar{x} \rangle = b_i\}$ es el conjunto de índices de las restricciones activas en $\bar{x}$. Como este problema es convexo, $\bar{x}$ es una solución global de él. Luego, $\bar{x}$ es una solución del problema (10.70) con $I = I(\bar{x})$, ya que el conjunto viable de él es menor. ■

Este resultado muestra que una manera de resolver el problema (10.69) es calcular todos los puntos especiales y escoger aquel con menor valor de la función objetivo. Para encontrar todos los puntos especiales del problema (10.69), es suficiente resolver los problemas (10.70) para todos los conjuntos $I \subset \{1, \dots, m\}$ tales que $D_I \neq \emptyset$, y verificar la viabilidad de las soluciones obtenidas para el problema (10.69).

Con relación a la resolución de un problema de la forma (10.70) (con restricciones de igualdad), notemos que él puede ser reducido a la minimización irrestricta de una función cuadrática fuertemente convexa. Para eso, podemos utilizar la proyección al conjunto D_I , o la representación de puntos del conjunto D_I en la base del subespacio lineal $\{x \in \mathbb{R}^n \mid \langle A_i, x \rangle = 0, i \in I\}$, o la relajación Lagrangiana (véase [20]). El problema de minimización irrestricta de una función cuadrática fuertemente convexa puede ser resuelto en un número de pasos finito, por ejemplo utilizando el método de los gradientes conjugados (??) o métodos del Álgebra Lineal.

El cálculo de todos los puntos especiales es un procedimiento finito. Pero, como también fue en el caso del cálculo de todos los vértices del conjunto viable para encontrar una solución en problemas de programación lineal, él no tiene valor práctico. El número de soluciones de problemas (10.70) es 2^m , y esta estrategia requiere un número de cálculos muy grande ya para n y m modestos. Por eso, como en la construcción del método del simplex, es natural intentar evitar el cálculo indiscriminado de puntos especiales, sustituyéndolo por un proceso más ordenado.

Ejercicio 10.23. Encontrando todos los puntos especiales, resolver los problemas

$$\begin{aligned} \min x_1^2 + x_2^2 \quad \text{sujeto a} \quad x \in D, \\ D = \{x \in \mathbb{R}^2 \mid -x_1 - x_2 \leq -4, x_1 \leq 5, x_2 \leq 3\}; \\ \min (x_1 - 1)^2 + (x_2 + 1)^2 \quad \text{sujeto a} \quad x \in D, \\ D = \{x \in \mathbb{R}^2 \mid -x_1 + x_2 \leq 1, x_1 + x_2 \leq 1, x_2 \geq 0\}. \end{aligned}$$

10.2.2. El método de puntos especiales

El método de puntos especiales calcula puntos especiales del problema (10.69) de manera que el valor de la función objetivo f en cada punto quede menor que en el anterior. Por el Teorema 10.14, este proceso es finito y termina en la solución del problema (10.69).

Sean $x^0, x^1, \dots, x^k$ los puntos especiales ya encontrados. La tarea es verificar si el punto x^k es la solución o no y, en el segundo caso, encontrar otro punto especial x^{k+1} del problema (10.69) tal que

$$f(x^{k+1}) < f(x^k). \quad (10.71)$$

Esto se hace en dos pasos.

El papel del primer paso es encontrar un punto (no necesariamente especial) $\tilde{x}^k \in \mathbb{R}^n$ tal que

$$f(\tilde{x}^k) < f(x^k), \quad \tilde{x}^k \in D, \quad (10.72)$$

o determinar que tal punto no existe (lo que significa que x^k es la solución del problema (10.69)). Esto puede ser hecho de varias maneras. Por ejemplo, podemos hacer una iteración del método de direcciones viables (véase ??) para el problema (10.69) a partir del punto x^k .

Teniendo en cuenta la linealidad de las restricciones en (10.69), en vez de (??), (??), consideremos el subproblema (de programación lineal) simplificado:

$$\min \langle f'(x^k), d \rangle = \langle Cx^k + c, d \rangle \quad \text{sujeto a} \quad d \in D_k, \quad (10.73)$$

$$D_k = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} \langle A_i, d \rangle \leq 0, \quad i \in I(x^k), \\ -1 \leq d_j \leq 1, \quad j = 1, \dots, n \end{array} \right\}. \quad (10.74)$$

Sean d^k una solución de este subproblema y $v_k = \langle f'(x^k), d^k \rangle$ el valor óptimo del mismo. Si $v_k = 0$, el método se detiene.

Ejercicio 10.24. Sean $C \in \mathbb{R}^{n \times n}$ una matriz simétrica semidefinida positiva, $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Mostrar que si en el punto $x^k \in D$, donde el conjunto D está definido en (10.69), el valor óptimo del problema (10.73), (10.74), es cero, entonces x^k es la solución del problema (10.69).

En el caso de $v_k < 0$, de acuerdo con los Lemas ??, ?? y el Ejercicio 4.1.7, se tiene que $d^k \in \mathcal{D}_f(x^k) \cap \mathcal{V}_D(x^k)$, i.e., tenemos una dirección viable de descenso. Por lo tanto, las condiciones (10.72) serán satisfechas para $\tilde{x}^k = x^k + \alpha d^k$ y todo $\alpha > 0$ suficientemente pequeño. El valor concreto $\alpha = \alpha_k$ puede ser escogido de varias maneras. Por ejemplo, haciendo una búsqueda lineal a partir del valor inicial $\hat{\alpha} > 0$, hasta que (10.72) se satisfaga. Podemos también tomar α_k como solución del problema unidimensional

$$\min f(x^k + \alpha d^k) \quad \text{sujeto a} \quad \alpha \in [0, \hat{\alpha}_k], \quad (10.75)$$

donde

$$\begin{aligned} \hat{\alpha}_k &= \max\{\alpha \in \mathbb{R}_+ \mid x^k + \alpha d^k \in D\} \\ &= \min\left\{ \frac{b_i - \langle A_i, x^k \rangle}{\langle A_i, d^k \rangle} \mid \langle A_i, d^k \rangle > 0, \quad i = 1, \dots, m \right\} \end{aligned} \quad (10.76)$$

(la última igualdad es fácil de verificar; comparar con (10.76)). Así, de (10.79)-(10.81) y de la convexidad de la función f , tenemos que

$$f(\xi^{s+1}) \leq t_s f(\tilde{\xi}^s) + (1 - t_s) f(\xi^s) \leq f(\xi^s).$$

*(Nota de traducción: Para resolver (10.75), utilizando los hechos de que f es una función cuadrática y C es una matriz definida positiva, obtenemos la siguiente fórmula explícita para la solución del problema (10.75)):

$$\alpha_k = \min\left\{ -\frac{\langle Cx^k + c, d^k \rangle}{\langle Cd^k, d^k \rangle}, \hat{\alpha}_k \right\}.$$

En el segundo paso (si no paramos en el primero), calculamos un punto especial x^{k+1} del problema (10.69) que satisfaga la desigualdad

$$f(x^{k+1}) \leq f(\tilde{x}^k). \quad (10.77)$$

Para esto, generamos una sucesión auxiliar

$$\xi^0, \tilde{\xi}^0, \xi^1, \tilde{\xi}^1, \dots, \xi^s, \tilde{\xi}^s, \dots \quad (10.78)$$

de puntos en $\mathbb{R}^n$ de la manera especificada a continuación. Tomamos $\xi^0 = \tilde{x}^k$. Sea $\xi^s \in D$ un punto ya construido. Como ξ^s tomamos la solución del problema (10.70) con $I = I(\xi^s)$. Como el punto ξ^s es viable en este problema, se tiene que

$$f(\tilde{\xi}^s) \leq f(\xi^s). \quad (10.79)$$

Hay dos posibilidades. Si $\tilde{\xi}^s \in D$, entonces $\tilde{\xi}^s$ es un punto especial del problema (10.69), por la definición. En este caso, el proceso de construcción de la sucesión (10.78) se detiene: tomamos $x^{k+1} = \tilde{\xi}^s$. Si $\tilde{\xi}^s \notin D$, tomamos como ξ^{s+1} el punto del intervalo con extremos ξ^s y $\tilde{\xi}^s$ que está más próximo a $\tilde{\xi}^s$ entre todos los puntos del intervalo que son viables en el problema (10.69), i.e.,

$$\xi^{s+1} = \xi^s + t_s(\tilde{\xi}^s - \xi^s), \quad (10.80)$$

$$\begin{aligned} t_s &= \max\{t \in [0, 1] \mid \xi^s + t(\tilde{\xi}^s - \xi^s) \in D\} \\ &= \min\left\{ \frac{b_i - \langle A_i, \xi^s \rangle}{\langle A_i, \tilde{\xi}^s - \xi^s \rangle} \mid \langle A_i, \tilde{\xi}^s - \xi^s \rangle > 0, \quad i = 1, \dots, m \right\} \end{aligned} \quad (10.81)$$

(la última igualdad es fácil de verificar; comparar con (10.76)). Así, de (10.79)-(10.81) y de la convexidad de la función f , tenemos que

$$f(\xi^{s+1}) \leq t_s f(\tilde{\xi}^s) + (1 - t_s) f(\xi^s) \leq f(\xi^s). \quad (10.82)$$

Obviamente, $I(\xi^{s+1}) \subset I(\xi^s)$. Sea $i = i_s$ un índice para el cual se realiza el mínimo en (10.81). Se tiene que $i_s \notin I(\xi^s)$ y

$$\langle A_{i_s}, \xi^{s+1} \rangle = \langle A_{i_s}, \xi^s \rangle + \frac{b_{i_s} - \langle A_{i_s}, \xi^s \rangle}{\langle A_{i_s}, \tilde{\xi}^s - \xi^s \rangle} \langle A_{i_s}, \tilde{\xi}^s - \xi^s \rangle = b_{i_s},$$

i.e., $i_s \in I(\xi^{s+1})$ y, en particular, el conjunto $I(\xi^{s+1})$ contiene al menos un elemento más del que $I(\xi^s)$. Pero todos estos conjuntos están contenidos en $\{1, \dots, m\}$. Por lo tanto, para algún s , acontecerá que $\tilde{\xi}^s \in D$, i.e., el proceso de construcción de la sucesión (10.78) es finito. Para el punto especial $x^{k+1} = \tilde{\xi}^s$ así generado, por (10.79) y (10.82), tenemos que

$$f(x^{k+1}) = f(\tilde{\xi}^s) \leq f(\xi^s) \leq f(\xi^{s-1}) \leq \dots \leq f(\xi^0) = f(\tilde{x}^k),$$

i.e., vale (10.77). De la desigualdad en (10.72) y (10.77), obtenemos (10.71). Esto concluye la descripción de una iteración del método.

Como fue en el caso del método del simplex, necesitamos especificar cómo calcular el primer punto especial x^0 . Para eso, podemos primero encontrar un punto $\tilde{x}^{-1} \in D$ viable cualquiera (por ejemplo, empleando el método de base artificial presentado en el apartado 10.1.2), y después utilizar el segundo paso del algoritmo anterior.

En algunos casos, es conveniente aplicar el método de puntos especiales al dual del problema a ser resuelto. Notemos que el dual del problema (10.69) viene dado por

$$\max -\frac{1}{2} \langle AC^{-1}A^T \mu, \mu \rangle - \langle AC^{-1}c + b, \mu \rangle - \frac{1}{2} \langle C^{-1}c, c \rangle, \quad \mu \in \mathbb{R}_+^m. \quad (10.83)$$

Si $\bar{\mu}$ es una solución del problema dual, la única solución del problema primal puede ser calculada por la fórmula explícita:

$$\bar{x} = -C^{-1}(c + A^T \bar{\mu}).$$

En particular, resolviendo el problema dual (10.83), fácilmente obtenemos la solución del problema primal (10.69). Notemos que las restricciones del problema (10.83) son muy simples y varias partes del método de puntos especiales se simplifican. En principio, la matriz $AC^{-1}A^T$ es semidefinida positiva, pero no es definida positiva cuando $\text{rk } A < m$. Sin embargo, como ya fue comentado, el método de puntos especiales puede ser extendido al caso en el que la función objetivo cuadrática es convexa, pero no fuertemente.

Ejercicio 10.25. Para el punto viable $\tilde{x} = (0, 3)$ del problema

$$\min (x_1 - 6)^2 + x_2^2 \quad \text{sueto a } x \in D,$$

$$D = \{x \in \mathbb{R}^2 \mid x_1 + x_2 \leq 4, 3x_1 + 2x_2 \leq 8, -4x_1 + x_2 \leq 4\},$$

aplicar el método de construcción de un punto especial, sin aumentar el valor de la función objetivo (i.e., el segundo paso de una iteración del método de puntos especiales).

Bibliografía

- [Izm20] Mikhail Izmailov Alexey y Solodov. *Otimização: Condições de Otimalidade, Elementos de Análise Convexa e de Dualidade (Volume 1)*. Rio de Janeiro, Brasil: IMPA, 2020 (vid. págs. 1, 73, 83).
- [Roc09] Roger J.-B. Rockafellar R. Tyrrell y Wets. *Variational Analysis*. Vol. 317. Grundlehren der mathematical Sciences. Springer Science & Business Media, 2009 (vid. pág. 1).