




Universidad Nacional de Ingeniería

Facultad de Ciencias

Programación No Lineal – CM4E2

2026-I

Apuntes de Optimalidad y Algoritmos de Optimización

Análisis Convexo, Dualidad y Optimización

Campos Mendoza, D. Daniel

danicampsmen@gmail.pe

Profesor: La Vida

Jefe de Prácticas: El Gato

Referencias Principales

- Mikhail Izmailov Alexey y Solodov. *Otimização: Condições de Otimidade, Elementos de Análise Convexa e de Dualidade (Volume 1)*. Rio de Janeiro, Brasil: IMPA, 2020
- Roger J.-B. Rockafellar R. Tyrrell y Wets. *Variational Analysis*. Vol. 317. Grundlehren der mathematical Sciences. Springer Science & Business Media, 2009
- [bazaraa2013nonlinearprogrammingtheory](#)

Lima, Perú

Última Edición

Fecha: 2026-07-01

Hora: 17:23:17

Versión 2.0 (Refactorizada)

Índice general

I. Condiciones de Optimalidad	1
1. Introducción a la Optimización	2
1.1. Definiciones y algunos hechos básicos	2
1.2. Existencia de soluciones globales	4
1.3. Condiciones de optimalidad para problemas sin restricciones	6
1.4. Condiciones de optimalidad en forma primal para problemas con restricciones. El cono tangente.	8
2. Problemas con Restricciones de Igualdad	13
2.1. El Problema de Optimización y el Subespacio Tangente	13
2.2. Condiciones de Primer Orden y Estructura Afín	16
2.3. Condiciones Diferenciales de Segundo Orden	18
3. Elementos de Análisis Convexo	24
3.1. Definiciones de convexidad. El problema de minimización convexo	24
3.2. Conjuntos convexos y Teoremas de Separación	27
3.2.1. Propiedades básicas de conjuntos convexos	27
3.2.2. Cono de Recesión y Generadores Finitos	29
3.2.3. El operador de proyección	29
3.2.4. Teoremas de Separación	30
3.2.5. Puntos Extremos	30
3.3. Teoremas de alternativa	31
3.4. Funciones convexas	33
3.4.1. Propiedades básicas de las funciones convexas	33
3.4.2. Funciones convexas diferenciables	34
3.4.3. Funciones convexas no diferenciables	34
4. Problemas con Restricciones Mixtas	40
4.1. Cono tangente en el caso de restricciones de igualdad y desigualdad	40
4.2. Condiciones de optimalidad de Karush-Kuhn-Tucker	46
4.3. Condiciones de optimalidad de segundo orden	51
5. Elementos de la Teoría de Dualidad	60
5.1. Dualidad en programación lineal	60
5.2. Dualidad para un problema general	63
5.2.1. Formulación Minimax del Problema Primal	63
5.2.2. El Problema Dual General	64
5.2.3. Teorema de Dualidad Débil	64
5.2.4. Patologías y Casos Límite en la Teoría de Dualidad	65
5.2.5. Teoría de Multiplicadores de Lagrange Globales	66
5.2.6. Dualidad Fuerte y la Condición de Slater	67
5.2.7. El Problema Dual de Wolfe	68
5.2.8. Caracterización mediante Puntos de Silla	68
5.2.9. Subgradiente de la Función Dual	69

II. Métodos Computacionales	73
6. Resumen Teórico y Preliminares Matemáticos	74
6.1. Existencia de soluciones	74
6.2. Condiciones de optimalidad	75
6.3. Convexidad	76
6.4. Dualidad	76
6.5. Herramientas del Análisis y del Álgebra Lineal	77
6.6. Elementos del Análisis no Diferenciable	78
7. Introducción a los Métodos de Optimización	80
7.1. Clasificación de los métodos y nociones de convergencia	80
7.1.1. Estrategia de muestreo: Métodos pasivos vs. secuenciales	80
7.1.2. Estructura del esquema iterativo: Métodos sin memoria vs. con memoria	80
7.1.3. Orden del método	81
7.1.4. Tipos de convergencia	81
7.2. Tasas de convergencia y reglas de parada	82
7.3. Métodos de optimización unidimensional	84
7.3.1. Búsqueda en rejilla (Grid Search)	84
7.3.2. Métodos de exclusión de intervalos	85
7.3.3. Búsquedas en Dominios Semi-infinitos e Intervalos No Unimodales	87
7.3.4. Interpolación polinómica cuadrática y salvaguardas	88
8. Optimización No Restringida	91
8.1. Métodos de descenso	91
8.1.1. Esquema general de los métodos de descenso. Búsqueda lineal	91
8.1.2. El método del gradiente	94
8.2. El método de Newton	96
8.2.1. El método de Newton para ecuaciones	96
8.2.2. El método de Newton para optimización irrestricta	97
8.2.3. Métodos Cuasi-Newton	98
8.3. Estrategias de globalización	101
8.3.1. Métodos con búsqueda lineal	101
8.3.2. Métodos de Regiones de Confianza	103
8.4. Métodos de Direcciones Conjugadas	105
8.4.1. Métodos de direcciones conjugadas para funciones cuadráticas	105
8.4.2. El método de los Gradientes Conjugados	107
8.4.3. Extensión a funciones no lineales generales (No Cuadráticas)	107
8.5. Métodos que no utilizan derivadas	108
8.5.1. Descenso por Coordenadas (Coordinate Descent)	108
8.5.2. Búsqueda Aleatoria (Random Search) y Gradiente Estocástico	108
9. Métodos para Optimización con Restricción	113
9.1. Métodos para conjuntos factibles de estructura simple	113
9.1.1. Métodos del gradiente proyectado	113
9.1.2. Direcciones factibles y métodos de descenso	116
9.1.3. Método del gradiente restringido. Método de Newton restringido	117
9.2. Métodos de direcciones factibles	118
9.3. Métodos de penalización	120
9.3.1. Penalización externa	121
9.3.2. Penalización interna. Métodos de barreras	124
9.4. Lagrangianas aumentadas y funciones de penalización exacta	127
9.4.1. El Método de la Lagrangiana Aumentada	127
9.4.2. Extensión a restricciones mixtas	129

9.5. Programación Cuadrática Secuencial (SQP)	129
9.5.1. El subproblema SQP general	129
9.5.2. Estrategias de Globalización del Método SQP	130
Bibliografía	134

Parte I.

Condiciones de Optimalidad

1. Introducción a la Optimización

Objetivo. Este capítulo establece los fundamentos teóricos de los problemas de optimización. Se presentan los resultados de existencia de soluciones y las condiciones de optimalidad (necesarias y suficientes) para problemas irrestrictos y con restricciones. El análisis de restricciones se desarrollará en su forma primal mediante el uso riguroso de conos y direcciones tangentes, evitando la introducción prematura de hipótesis restrictivas.

Notación. A lo largo de este texto, para una función escalar diferenciable $f : \mathbb{R}^n \rightarrow \mathbb{R}$, denotaremos su vector gradiente (entendido como vector columna) mediante el operador nabla $\nabla f(x)$. Análogamente, su matriz Hessiana de segundas derivadas se denotará por $\nabla^2 f(x)$.

1.1. Definiciones y algunos hechos básicos

Sean dados conjuntos $D \subset \mathbb{R}^n$ y $\Omega \subset \mathbb{R}^n$ tales que $D \subset \Omega$, y una función $f : \Omega \rightarrow \mathbb{R}$. El problema principal a ser considerado en este libro es el de hallar un minimizador de f en el conjunto D . Este problema se escribirá como:

$$\min f(x) \quad \text{sujeto a} \quad x \in D. \quad (1.1)$$

El conjunto D será llamado **conjunto factible** del problema, los puntos de D serán llamados **puntos factibles**, y f será llamada **función objetivo**.

Definición 1.1 (Minimizadores). Dado el problema (1.1), un punto $\bar{x} \in D$ se denomina:


1. **Minimizador global** de (1.1), si

$$f(\bar{x}) \leq f(x) \quad \forall x \in D;$$

2. **Minimizador local** de (1.1), si existe una vecindad U de $\bar{x}$ tal que

$$f(\bar{x}) \leq f(x) \quad \forall x \in D \cap U.$$

De forma equivalente, $\bar{x} \in D$ es minimizador local si existe $\varepsilon > 0$ tal que $f(\bar{x}) \leq f(x)$ para todo $x \in \{x \in D \mid \|x - \bar{x}\| \leq \varepsilon\}$.



Observación. Por la definición, es claro que todo minimizador global también es minimizador local, pero no reciprocamente. Si para todo $x \neq \bar{x}$ la desigualdad correspondiente es estricta, $\bar{x}$ será llamado **minimizador estricto** (global o local, respectivamente).

Definición 1.2 (Valor óptimo). El **valor óptimo** del problema (1.1) es el valor $\bar{v} \in [-\infty, +\infty)$ definido por

$$\bar{v} = \inf_{x \in D} f(x).$$

Observación. Una función puede admitir varios minimizadores globales, pero el valor óptimo (global) del problema, naturalmente, siempre es el mismo.

Cuando existen una vecindad U de $\bar{x} \in D$ y un número $\beta > 0$ tales que

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\| \quad \forall x \in D \cap U,$$

decimos que f satisface la **condición de crecimiento lineal** en el conjunto D en torno a $\bar{x}$. Decimos que f satisface la **condición de crecimiento cuadrático** cuando

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\|^2 \quad \forall x \in D \cap U.$$

Observamos que cualquiera de estas dos condiciones implica que $\bar{x}$ es un minimizador local estricto.

Proposición 1.1. Si la función f satisface la condición de crecimiento lineal o cuadrático en D en torno a $\bar{x}$, entonces $\bar{x}$ es un minimizador local estricto de f .


Prueba. Supongamos que se cumple la condición de crecimiento cuadrático (el análisis para el lineal es análogo). Existe una vecindad U de $\bar{x}$ y $\beta > 0$ tal que $f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\|^2$ para todo $x \in D \cap U$. Sea $x \in D \cap U$ tal que $x \neq \bar{x}$. Dado que la norma es definida positiva, $\|x - \bar{x}\| > 0$, lo que implica que $\beta \|x - \bar{x}\|^2 > 0$. Por lo tanto $f(x) - f(\bar{x}) > 0$, es decir, $f(\bar{x}) < f(x)$. Esto satisface la definición de minimizador local estricto. ■

También es fácil ver que cualquier problema de maximización

$$\max f(x) \quad \text{sujeto a } x \in D \tag{1.2}$$

puede ser transformado en un problema de minimización equivalente:

$$\min -f(x) \quad \text{sujeto a } x \in D.$$



Proposición 1.2 (Equivalencia entre maximización y minimización). Sea el problema de maximización (1.2). Un punto $\bar{x} \in D$ es maximizador de (1.2) si y solo si $\bar{x}$ es minimizador del problema equivalente $\min_{x \in D} -f(x)$. Además, se satisface que $\max_{x \in D} f(x) = -\min_{x \in D} (-f(x))$.

Prueba. Sea $\bar{x}$ un maximizador de f en D . Por definición, $f(\bar{x}) \geq f(x)$ para todo $x \in D$. Multiplicando por -1 , se invierte el orden: $-f(\bar{x}) \leq -f(x)$ para todo $x \in D$. Esto es exactamente la definición de $\bar{x}$ como minimizador de $-f$ en D . La igualdad de los valores óptimos es consecuencia de las propiedades del supremo y el ínfimo: $\sup_{x \in D} f(x) = -\inf_{x \in D} (-f(x))$. ■

En particular, las soluciones locales y globales de ambos problemas son las mismas, con signos opuestos para los valores óptimos. Por eso, desde el punto de vista matemático, no existe ninguna diferencia relevante entre los problemas de minimización y de maximización: todos los resultados obtenidos para una clase de problemas pueden ser extendidos a la otra clase sin dificultad. Por razones de tradición, en este libro consideramos sistemáticamente los problemas de minimización.

Típicamente, el conjunto factible de un problema está definido por un sistema de igualdades y/o desigualdades y/o una inclusión, como, por ejemplo,

$$D = \{x \in \Omega \mid h(x) = 0, g(x) \leq 0\}, \quad (1.3)$$

donde $\Omega \subset \mathbb{R}^n$, $h : \Omega \rightarrow \mathbb{R}^l$ y $g : \Omega \rightarrow \mathbb{R}^m$ (suponemos que la función objetivo f también está definida en el conjunto Ω). El conjunto Ω representa lo que se llama **restricciones directas** y las restricciones de igualdad y desigualdad se llaman **restricciones funcionales**. Cabe resaltar que la separación de las restricciones en directas y funcionales en la mayoría de los casos es solo una cuestión de simple conveniencia. Por ejemplo, la restricción directa $x \in \Omega = \mathbb{R}_+^n$ puede escribirse en el formato funcional $x \in \{x \in \mathbb{R}^n \mid x_i \geq 0, i = 1, \dots, n\}$.

En este libro, casi siempre supondremos que todas las restricciones de un problema dado son de un solo tipo: o directas o funcionales. En principio, las restricciones de igualdad siempre pueden escribirse en forma de desigualdades duplicando el número de restricciones:

$$h_i(x) = 0 \iff h_i(x) \leq 0 \quad \text{y} \quad -h_i(x) \leq 0.$$

Las restricciones de desigualdad también pueden transformarse en igualdades mediante la introducción de variables artificiales, llamadas “de holgura”:

$$g_i(x) \leq 0 \iff g_i(x) + z_i^2 = 0, \quad z_i \in \mathbb{R}.$$

Sin embargo, las transformaciones de este tipo son indeseables, tanto desde el punto de vista teórico como desde el punto de vista computacional. En primer lugar, en muchos casos estas transformaciones llevan a condiciones de optimalidad más débiles que las obtenidas en un análisis directo de las restricciones originales. En segundo lugar, el número de restricciones y/o variables aumenta, lo que hace el problema más difícil de resolver en la práctica. Por estas razones, en capítulos posteriores estudiaremos el formato general de restricciones mixtas (1.3) de forma directa.

Cuando $D = \mathbb{R}^n$, decimos que el problema (1.1) es **irrestringido**, y cuando $D \neq \mathbb{R}^n$ hablamos de **optimización con restricciones**.

Definición 1.3 (Tipos de problemas especiales).

1. Decimos que un conjunto es **poliedral** cuando puede ser representado como el conjunto de las soluciones de un sistema finito de ecuaciones e inecuaciones lineales: $D = \{x \in \mathbb{R}^n \mid Ax = a, Bx \leq b\}$.
2. Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ definida por $f(x) = \frac{1}{2} \langle Qx, x \rangle + \langle q, x \rangle + c$, donde Q es una matriz simétrica, se llama **función cuadrática**.
3. Si D es un conjunto poliedral y f es cuadrática, el problema se llama de **programación cuadrática**. Si f es lineal ($Q = 0$), es de **programación lineal**.
4. Cuando D es un conjunto convexo y f es una función convexa, decimos que el problema es de **programación convexa**.

1.2. Existencia de soluciones globales

Cuando en la Definición 1.2 tenemos $\bar{v} = -\infty$, el problema (1.1) no posee solución global (en este caso f es no acotada inferiormente en el conjunto factible). Pero incluso cuando $\bar{v}$ es finito, el minimizador global puede no existir. Este es el caso en que $\bar{v}$ no es alcanzado en ningún punto factible, es decir, cuando no existe $x \in D$ tal que $f(x) = \bar{v}$.

Por ejemplo, sean $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = e^x$, $D = \mathbb{R}$. Evidentemente, $\bar{v} = \inf_{x \in \mathbb{R}} e^x = 0$. Sin embargo, no existe $x \in \mathbb{R}$ tal que $e^x = 0$. Sean ahora $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = e^x$, $D = (0, 1]$. Se tiene que $\bar{v} = \inf_{x \in (0, 1]} e^x = 1$, pero de nuevo no existe $x \in (0, 1]$ tal que $e^x = 1$. Observamos que la función f es continua en D , pero en el primer ejemplo D no es acotado y en el segundo D no es cerrado.

A continuación estudiaremos algunos criterios que garantizan la existencia de solución global.

Teorema 1.1 (Weierstrass). Sean $D \subset \mathbb{R}^n$ un conjunto compacto no vacío y $f : D \rightarrow \mathbb{R}$ una función continua. Entonces los problemas de minimizar y de maximizar f en D tienen soluciones globales.

Prueba. Por lo observado en la sección anterior, es suficiente probar la existencia de un minimizador. Como la imagen de un conjunto compacto por una función continua es compacta, el conjunto $\{v \in \mathbb{R} \mid v = f(x) \text{ para algún } x \in D\}$ es

compacto. En particular, este conjunto es acotado inferiormente, es decir,

$$-\infty < \bar{v} = \inf_{x \in D} f(x).$$

Por la definición de ínfimo, para todo $k \in \mathbb{N}$ existe un $x^k \in D$ tal que

$$\bar{v} \leq f(x^k) \leq \bar{v} + \frac{1}{k}.$$

Pasando al límite cuando $k \rightarrow \infty$, concluimos que

$$\lim_{k \rightarrow \infty} f(x^k) = \bar{v}. \quad (1.4)$$

Como $\{x^k\} \subset D$ y D es compacto, se sigue que $\{x^k\}$ es una sucesión acotada. Luego, posee una subsucesión $\{x^{k_j}\}$ que converge a un punto de D :

$$\lim_{j \rightarrow \infty} x^{k_j} = \bar{x} \in D.$$

Por la continuidad de f , tenemos $\lim_{j \rightarrow \infty} f(x^{k_j}) = f(\bar{x})$. Usando (1.4), concluimos que $f(\bar{x}) = \bar{v}$, es decir, f asume el valor mínimo en D en el punto $\bar{x} \in D$. En otras palabras, $\bar{x}$ es un minimizador global. ■

La hipótesis de que el conjunto factible sea compacto solo puede ser eliminada en los resultados de existencia de solución al costo de fortalecer las hipótesis sobre la función objetivo. En este sentido, la noción de conjunto de nivel es fundamental.

Definición 1.4 (Conjunto de nivel). El **conjunto de nivel** de la función $f : D \rightarrow \mathbb{R}$ asociado a $c \in \mathbb{R}$ es el conjunto dado por

$$L_{f,D}(c) = \{x \in D \mid f(x) \leq c\}.$$

Corolario 1.1 (Existencia vía compacidad del conjunto de nivel). Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ continua en D . Supongamos que existe $c \in \mathbb{R}$ tal que el conjunto de nivel $L_{f,D}(c)$ sea no vacío y compacto. Entonces el problema de minimizar f en D posee una solución global.

Prueba. Por el Teorema de Weierstrass (Teorema 1.1), el problema $\min f(x)$ sujeto a $x \in L_{f,D}(c)$ tiene una solución global, digamos $\bar{x}$. Para todo $x \in D \setminus L_{f,D}(c)$, tenemos que $f(x) > c \geq f(\bar{x})$, lo que muestra que $\bar{x}$ es un minimizador global de f no solo en $L_{f,D}(c)$, sino también en D . ■

A continuación mostraremos un importante ejemplo de aplicación del Corolario 1.1.

Definición 1.5 (Proyección ortogonal). Dados un conjunto $D \subset \mathbb{R}^n$ y un punto $y \in \mathbb{R}^n$, una **proyección** (ortogonal) de y sobre D es una solución global del problema

$$\min \|x - y\| \quad \text{sujeto a } x \in D.$$

En otras palabras, la proyección de y sobre D es uno de los puntos de D que está más cerca de y .

Corolario 1.2 (Existencia de la proyección). Sea $D \subset \mathbb{R}^n$ un conjunto cerrado no vacío. Entonces la proyección de y sobre D existe para todo punto $y \in \mathbb{R}^n$.

Prueba. Fijemos $y \in \mathbb{R}^n$ arbitrario. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}_+$, $f(x) = \|x - y\|$. Evidentemente, f es continua en $\mathbb{R}^n$ y

$$L_{f,D}(c) = D \cap B(y, c),$$

donde $B(y, c) = \{x \in \mathbb{R}^n \mid \|x - y\| \leq c\}$ es la bola cerrada de centro y y radio c . El conjunto de nivel $L_{f,D}(c)$ es la intersección del conjunto cerrado D con el conjunto compacto $B(y, c)$. Por lo tanto, $L_{f,D}(c)$ es compacto. Además, para $c > 0$ suficientemente grande, es obvio que la bola $B(y, c)$ contiene puntos de D . Luego, $L_{f,D}(c) \neq \emptyset$. La afirmación ahora sigue por el Corolario 1.1. ■

En el problema de minimización del Corolario 1.2, el conjunto factible del problema podría ser ilimitado, pero es cerrado. A continuación consideremos un ejemplo donde el conjunto factible no es ni limitado ni cerrado.

Ejemplo 1.1. Mostraremos que el problema (1.1), donde

$$D = \{x \in \mathbb{R}^2 \mid x_1 + x_2 > 0\}, \quad f : D \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + x_2 + \frac{1}{x_1 + x_2},$$

posee una solución global.

Observamos que D es ilimitado y abierto. Por lo tanto, el Teorema 1.1 no se aplica en este caso. Fijemos $c \in \mathbb{R}$ tal que $L(c) = L_{f,D}(c) \neq \emptyset$ (por ejemplo, tomando $c = f(x)$ para un $x \in D$ cualquiera). Verificaremos que $L(c)$ es compacto (es decir, acotado y cerrado), y aplicaremos el Corolario 1.1.

Supongamos primero que $L(c)$ sea ilimitado, es decir, que exista $\{x^k\} \subset L(c)$ tal que $\|x^k\| \rightarrow \infty$ cuando $k \rightarrow \infty$. Tenemos que $x_1^k + x_2^k > 0$ (porque $x^k \in D$) y $f(x^k) \leq c$ para todo k . Si $|x_1^k| \rightarrow \infty$ cuando $k \rightarrow \infty$, entonces $c \geq f(x^k) > (x_1^k)^2 + x_2^k > (x_1^k)^2 - x_1^k \rightarrow +\infty$, lo que es imposible. Si $\{x_1^k\}$ es acotada, entonces $x_2^k \rightarrow +\infty$ cuando $k \rightarrow \infty$, y para todo k suficientemente grande, tenemos que $c \geq f(x^k) > x_2^k \rightarrow +\infty$, lo que también es imposible. Acabamos de mostrar que $L(c)$ es acotado.

Supongamos ahora que $L(c)$ no sea cerrado, es decir, que exista $\{x^k\} \subset L(c)$ tal que $\{x^k\} \rightarrow x$ cuando $k \rightarrow \infty$, con $x \in \mathbb{R}^2 \setminus L(c)$. La función f es continua en D . Por lo tanto, $f(x^k) \leq c$ implica que $f(x) \leq c$. Entonces, como $x \notin L(c)$, debe ser $x \in \text{cl } D \setminus D$, es decir, $x_1 + x_2 = 0$, pero en este caso $c \geq f(x^k) \rightarrow +\infty$ cuando $k \rightarrow \infty$, lo que es imposible. Acabamos de mostrar entonces que $L(c)$ también es cerrado. Luego $L(c)$ es compacto y la existencia de minimizador global sigue.

A continuación formalizaremos los fenómenos observados en el análisis del Ejemplo 1.1.

Definición 1.6 (Sucesión crítica y coercitividad). Decimos que una sucesión $\{x^k\} \subset \mathbb{R}^n$ es **crítica** en relación al conjunto D , si $\{x^k\} \subset D$ y o bien $\|x^k\| \rightarrow \infty$ o bien $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$ cuando $k \rightarrow \infty$.

Decimos que la función $f : D \rightarrow \mathbb{R}$ es **coercitiva** en el conjunto D , cuando para toda sucesión $\{x^k\}$ crítica en relación a D , se tiene

$$\limsup_{k \rightarrow \infty} f(x^k) = +\infty.$$

En el Ejemplo 1.1, f es coercitiva en el conjunto D . Observamos que cuando D es cerrado, coercitividad de f en D significa que si $x^k \in D$ y $\|x^k\| \rightarrow \infty$ entonces $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$. Cuando D es acotado, coercitividad significa que cuando $x^k \in D$ y $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$, se tiene $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$. Finalmente, cuando D es compacto, no hay sucesiones críticas, por lo que cualquier función $f : D \rightarrow \mathbb{R}$ es coercitiva en D trivialmente.

Corolario 1.3 (Existencia vía coercitividad). Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ una función continua y coercitiva en $D \neq \emptyset$. Entonces el problema de minimizar f en D posee una solución global.

El Teorema de Weierstrass puede ser generalizado ligeramente en relación a las propiedades de continuidad de la función objetivo.

Definición 1.7 (Semicontinuidad). Decimos que la función $f : D \rightarrow \mathbb{R}$ es **semicontinua inferiormente** en el punto $x \in D \subset \mathbb{R}^n$, cuando para cualquier sucesión $\{x^k\} \subset D$ tal que $\{x^k\} \rightarrow x$ cuando $k \rightarrow \infty$, se tiene

$$\liminf_{k \rightarrow \infty} f(x^k) \geq f(x).$$

Decimos que f es **semicontinua superiormente** cuando, en las mismas condiciones,

$$\limsup_{k \rightarrow \infty} f(x^k) \leq f(x).$$

Ejemplo 1.2. Sean $D = [1/2, 2] \subset \mathbb{R}$ y $f : D \rightarrow \mathbb{R}$ dada por

$$f(x) = \begin{cases} 1/x, & x \in [1/2, 1), \\ 2, & x \in [1, 2], \end{cases}$$

El conjunto D es compacto. La función f no es semicontinua inferiormente en D , pues no lo es en el punto $x = 1$. Se tiene que $\bar{v} = 1$, pero no existe $x \in D$ tal que $f(x) = 1$. Sin embargo, es fácil ver que f es semicontinua superiormente y que posee maximizadores globales en D .

1.3. Condiciones de optimalidad para problemas sin restricciones

Consideremos el problema de minimización irrestricta

$$\min f(x), \quad x \in \mathbb{R}^n, \tag{1.5}$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$. A continuación estudiaremos las condiciones que deben ser satisfechas cuando un $\bar{x} \in \mathbb{R}^n$ dado es minimizador (local) del problema (1.5). Condiciones de este tipo se llaman **condiciones necesarias de**

optimalidad. También estudiaremos las condiciones que garantizan que un punto dado es minimizador local del problema (**condiciones suficientes de optimalidad**). Cabe notar que todos los resultados presentados a continuación son también verdaderos para un problema con restricciones $\min_{x \in D} f(x)$ siempre que el punto de interés $\bar{x}$ esté en el interior del conjunto factible D .

Teorema 1.2 (Condición necesaria de primer orden - Fermat). Supongamos que la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un minimizador local irrestricto de f , entonces

$$\nabla f(\bar{x}) = 0. \quad (1.6)$$

Prueba. Sea $d \in \mathbb{R}^n$ arbitrario. Por la definición de minimizador local, existe $\varepsilon > 0$ tal que

$$f(\bar{x}) \leq f(\bar{x} + td) \quad \forall t \in [0, \varepsilon].$$

Por la diferenciabilidad de f en $\bar{x}$,

$$f(\bar{x} + td) = f(\bar{x}) + t\langle \nabla f(\bar{x}), d \rangle + o(t).$$

Luego, $0 \leq t\langle \nabla f(\bar{x}), d \rangle + o(t)$. Dividiendo por $t > 0$ y tomando el límite cuando $t \rightarrow 0^+$, obtenemos

$$0 \leq \langle \nabla f(\bar{x}), d \rangle.$$

Como $d \in \mathbb{R}^n$ es arbitrario, podemos elegir $d = -\nabla f(\bar{x})$, lo que resulta en la condición $0 \leq \langle \nabla f(\bar{x}), -\nabla f(\bar{x}) \rangle = -\|\nabla f(\bar{x})\|^2$. De donde sigue que $\nabla f(\bar{x}) = 0$. ■

Definición 1.8 (Punto estacionario). Decimos que un punto $\bar{x} \in \mathbb{R}^n$ es **estacionario** (o **crítico**) para el problema (1.5), si vale la condición (1.6).

Por lo tanto, si f es diferenciable, las soluciones locales del problema (1.5) deben ser puntos estacionarios. Claramente, lo mismo vale para los problemas de maximización. A continuación, presentamos las condiciones de segundo orden.

Teorema 1.3 (Condición necesaria de segunda orden). Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea dos veces diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un minimizador local irrestricto de f , entonces vale (1.6) y la matriz Hessiana de f en el punto $\bar{x}$ es **semidefinida positiva**, es decir,

$$\langle \nabla^2 f(\bar{x})d, d \rangle \geq 0 \quad \forall d \in \mathbb{R}^n. \quad (1.7)$$

Prueba. La condición (1.6) ya fue obtenida por el Teorema 1.2. Sea $d \in \mathbb{R}^n$ arbitrario. Si $\bar{x}$ es minimizador local del problema (1.5), entonces para todo $t > 0$ suficientemente pequeño

$$0 \leq f(\bar{x} + td) - f(\bar{x}) = \langle \nabla f(\bar{x}), td \rangle + \frac{1}{2} \langle \nabla^2 f(\bar{x})(td), td \rangle + o(t^2) = \frac{t^2}{2} \langle \nabla^2 f(\bar{x})d, d \rangle + o(t^2).$$

Dividiendo ambos lados por $t^2 > 0$ y pasando al límite cuando $t \rightarrow 0^+$, obtenemos (1.7). ■

Si en un punto estacionario $\bar{x}$ en vez de (1.7) vale una condición más fuerte (la matriz Hessiana es definida positiva), podemos afirmar que de hecho $\bar{x}$ es un minimizador local estricto con crecimiento cuadrático.

Teorema 1.4 (Condición suficiente de segunda orden). Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea dos veces diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un punto estacionario (es decir, si vale (1.6)) y si la matriz Hessiana de f en $\bar{x}$ es definida positiva, es decir,

$$\langle \nabla^2 f(\bar{x})d, d \rangle > 0 \quad \forall d \in \mathbb{R}^n \setminus \{0\}, \quad (1.8)$$

entonces f satisface en torno a $\bar{x}$ la condición de crecimiento cuadrático: existen una vecindad U de $\bar{x}$ y un número $\beta > 0$ tales que

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\|^2 \quad \forall x \in U. \quad (1.9)$$

En particular, $\bar{x}$ es minimizador local estricto del problema (1.5). Recíprocamente, si vale (1.9), entonces $\bar{x}$ satisface las condiciones (1.6) y (1.8).

Prueba. Supongamos que valgan las condiciones (1.6) y (1.8), pero no (1.9). Entonces existe $\{x^k\} \subset \mathbb{R}^n \setminus \{\bar{x}\}$ tal que $\{x^k\} \rightarrow \bar{x}$ cuando $k \rightarrow \infty$ y

$$f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|^2 \quad \forall k.$$

Como la sucesión $\{(x^k - \bar{x})/\|x^k - \bar{x}\|\}$ es acotada, posee puntos de acumulación. Escogiendo una subsucesión, podemos admitir que

$$\frac{x^k - \bar{x}}{\|x^k - \bar{x}\|} \rightarrow d \in \mathbb{R}^n \setminus \{0\} \quad (\|d\| = 1).$$

Obtenemos que

$$\frac{1}{k}\|x^k - \bar{x}\|^2 > f(x^k) - f(\bar{x}) = \frac{1}{2}\langle \nabla^2 f(\bar{x})(x^k - \bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|^2),$$

donde usamos (1.6). Dividiendo por $\|x^k - \bar{x}\|^2 > 0$ y tomando el límite cuando $k \rightarrow \infty$, obtenemos

$$0 \geq \frac{1}{2}\langle \nabla^2 f(\bar{x})d, d \rangle,$$

en contradicción con (1.8).

Supongamos ahora que valga la condición de crecimiento cuadrático (1.9). Como ella implica que $\bar{x}$ es un minimizador local, obtenemos (1.6) por el Teorema 1.2. Para cualquier $d \in \mathbb{R}^n$ y $t \in \mathbb{R}$ suficientemente pequeño, $\bar{x} + td \in U$. Utilizando (1.9) y (1.6), obtenemos que

$$\beta t^2 \|d\|^2 \leq f(\bar{x} + td) - f(\bar{x}) = \frac{t^2}{2}\langle \nabla^2 f(\bar{x})d, d \rangle + o(t^2).$$

Dividiendo por $t^2 > 0$ y tomando el límite cuando $t \rightarrow 0$, obtenemos $\beta \|d\|^2 \leq \frac{1}{2}\langle \nabla^2 f(\bar{x})d, d \rangle$, lo que significa que $\nabla^2 f(\bar{x})$ es definida positiva. ■

Cabe resaltar que las condiciones (1.6) y (1.7) no son suficientes para que un punto sea minimizador (ej: $f(x) = x^3$ en $x = 0$). Por otro lado, (1.6) y (1.8) no son necesarias para que un punto sea minimizador (ej: $f(x) = x^4$ en $x = 0$).

Ejemplo 1.3. Encontremos los minimizadores y maximizadores locales irrestrictos de la función $f(x) = x_1^3 + x_2^3 - 3x_1x_2$. Es fácil ver que f no es acotada ni inferior ni superiormente, por lo que no hay óptimos globales. Los puntos estacionarios son $x^1 = (0, 0)$ y $x^2 = (1, 1)$. Las matrices Hessianas son:

$$\nabla^2 f(x^1) = \begin{pmatrix} 0 & -3 \\ -3 & 0 \end{pmatrix}, \quad \nabla^2 f(x^2) = \begin{pmatrix} 6 & -3 \\ -3 & 6 \end{pmatrix}.$$

La matriz $\nabla^2 f(x^1)$ no es ni semidefinida positiva ni semidefinida negativa. Por el Teorema 1.3, x^1 no es ni minimizador ni maximizador. Como la matriz $\nabla^2 f(x^2)$ es definida positiva, por los Teoremas 1.2 y 1.4, x^2 es el único minimizador local estricto.

Ejemplo 1.4. Encontremos las soluciones globales del problema

$$\min f(x) = x_1 + \frac{x_2^2}{4x_1} + \frac{x_3^2}{x_2} + \frac{2}{x_3} \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^3 \mid x_i > 0\}.$$

El conjunto D es abierto, así que todo punto factible pertenece al interior. Resolviendo (1.6), encontramos que el único punto estacionario es $\bar{x} = (1/2, 1, 1)$. Se puede verificar que él es minimizador global comprobando que f es coercitiva en D (véase la Definición 1.6).

1.4. Condiciones de optimalidad en forma primal para problemas con restricciones. El cono tangente.

Consideramos ahora un problema en formato general


$$\min f(x) \quad \text{sujeto a} \quad x \in D, \tag{1.10}$$

donde $D \subset \mathbb{R}^n$ es un conjunto dado (no vacío) y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es la función objetivo. Para desarrollar las condiciones de optimalidad necesitamos estudiar la estructura del conjunto factible mediante **direcciones viables** y **direcciones tangentes**.

Definición 1.9 (Dirección viable). Decimos que $d \in \mathbb{R}^n$ es una **dirección viable** en relación al conjunto D en el punto $\bar{x} \in D$, cuando existe $\varepsilon > 0$ tal que

$$\bar{x} + td \in D \quad \forall t \in [0, \varepsilon].$$

Denotamos por $\mathcal{V}_D(\bar{x})$ el conjunto de todas las direcciones viables en relación al conjunto D en el punto $\bar{x} \in D$.



Definición 1.10 (Cono). Un conjunto $K \subset \mathbb{R}^n$ se llama **cono** cuando

$$d \in K \implies td \in K \quad \forall t \in \mathbb{R}_+.$$

Es fácil ver que para $D \subset \mathbb{R}^n$ y $\bar{x} \in D$ cualesquiera, el conjunto $\mathcal{V}_D(\bar{x})$ siempre es un cono no vacío (al menos, $0 \in \mathcal{V}_D(\bar{x})$).

Definición 1.11 (Dirección de descenso). Decimos que $d \in \mathbb{R}^n$ es una **dirección de descenso** de $f : \mathbb{R}^n \rightarrow \mathbb{R}$ en el punto $\bar{x} \in \mathbb{R}^n$, si existe $\varepsilon > 0$ tal que

$$f(\bar{x} + td) < f(\bar{x}) \quad \forall t \in (0, \varepsilon].$$

Denotamos por $\mathcal{D}_f(\bar{x})$ el conjunto de todas las direcciones de descenso de la función f en el punto $\bar{x}$.

El conjunto $\mathcal{D}_f(\bar{x})$ puede ser vacío, pero el conjunto $\mathcal{D}_f(\bar{x}) \cup \{0\}$ es siempre un cono.

Lema 1.1 (Direcciones de descenso). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Entonces:

1. Para todo $d \in \mathcal{D}_f(\bar{x})$, se tiene que $\langle \nabla f(\bar{x}), d \rangle \leq 0$.
2. Si $d \in \mathbb{R}^n$ satisface $\langle \nabla f(\bar{x}), d \rangle < 0$, entonces $d \in \mathcal{D}_f(\bar{x})$.

Prueba. Sea $d \in \mathcal{D}_f(\bar{x})$. Para todo $t > 0$ suficientemente pequeño, $0 > f(\bar{x} + td) - f(\bar{x}) = t(\langle \nabla f(\bar{x}), d \rangle + o(t)/t)$.

Pasando al límite cuando $t \rightarrow 0^+$, obtenemos $0 \geq \langle \nabla f(\bar{x}), d \rangle$, lo que prueba el ítem (a).

Si $\langle \nabla f(\bar{x}), d \rangle < 0$, tenemos que $f(\bar{x} + td) - f(\bar{x}) = t(\langle \nabla f(\bar{x}), d \rangle + o(t)/t) \leq \frac{t}{2} \langle \nabla f(\bar{x}), d \rangle < 0$ para todo $t > 0$ suficientemente pequeño, implicando que $d \in \mathcal{D}_f(\bar{x})$. ■

Si $\bar{x} \in D$ es un minimizador local de (1.10), obviamente $\mathcal{D}_f(\bar{x}) \cap \mathcal{V}_D(\bar{x}) = \emptyset$. Por el Lema 1.1, tenemos entonces que $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{V}_D(\bar{x})$. Sin embargo, esta condición no siempre proporciona información útil, porque $\mathcal{V}_D(\bar{x})$ puede contener solo al vector nulo. Necesitamos considerar las **direcciones tangentes**.

Definición 1.12 (Dirección tangente y cono tangente). Decimos que $d \in \mathbb{R}^n$ es una **dirección tangente** en relación al conjunto D en el punto $\bar{x} \in D$ cuando

$$\text{dist}(\bar{x} + td, D) = o(t), \quad t \in \mathbb{R}_+.$$

Denotamos por $\mathcal{T}_D(\bar{x})$ el conjunto de todas las direcciones tangentes, el cual forma un cono.

Claramente, $\mathcal{V}_D(\bar{x}) \subset \mathcal{T}_D(\bar{x})$. Otra noción útil es la del **cono de Bouligand**:

$$\mathcal{B}_D(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} \exists \{t_k\} \subset \mathbb{R}_+, \{t_k\} \rightarrow 0^+, \\ \text{dist}(\bar{x} + t_k d, D) = o(t_k) \end{array} \right\}. \quad (1.11)$$

De forma equivalente, $d \in \mathcal{B}_D(\bar{x})$ si existen sucesiones $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$ para todo k . En general, $\mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$.

Ejemplo 1.5. Sean $q \in (0, 1)$ y $D = \{0\} \cup \{q^0, q^1, q^2, \dots\} \subset \mathbb{R}$. En $\bar{x} = 0 \in D$, para todo $d > 0$, eligiendo $t_k = q^k/d$ y $d^k = d$, tenemos $\bar{x} + t_k d^k = q^k \in D$. Así que $d \in \mathcal{B}_D(\bar{x})$ y $\mathcal{B}_D(\bar{x}) = \mathbb{R}_+$. Sin embargo, se puede demostrar analíticamente que $\mathcal{T}_D(\bar{x}) = \{0\}$, probando que $\mathcal{T}_D(\bar{x}) \neq \mathcal{B}_D(\bar{x})$.

Teorema 1.5 (Condición necesaria en forma primal). Sean $D \subset \mathbb{R}^n$ y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en el punto $\bar{x} \in D$. Si $\bar{x}$ es una solución local del problema de minimizar f en D , entonces

$$\langle \nabla f(\bar{x}), d \rangle \geq 0 \quad \forall d \in \mathcal{B}_D(\bar{x}). \quad (1.12)$$

Prueba. Fijemos $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$ y las sucesiones asociadas $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$. Como $\bar{x}$ es un minimizador local, para todo k suficientemente grande:

$$0 \leq f(\bar{x} + t_k d^k) - f(\bar{x}) = t_k \langle \nabla f(\bar{x}), d^k \rangle + o(t_k).$$

Dividiendo por $t_k > 0$ y pasando al límite, obtenemos (1.12). ■

Decimos que $\bar{x} \in \mathbb{R}^n$ es un **punto estacionario** del problema (1.10) si $\bar{x} \in D$ y vale (1.12).

Corolario 1.4. Sea $\bar{x} \in \text{int } D$ una solución local del problema (1.10) tal que f es diferenciable en $\bar{x}$. Entonces $\nabla f(\bar{x}) = 0$.


La condición de optimalidad puede transformarse a la forma primal-dual usando el cono dual.

Definición 1.13 (Cono dual). El **cono dual** de un cono $K \subset \mathbb{R}^n$ se define por

$$K^* = \{y \in \mathbb{R}^n \mid \langle y, d \rangle \leq 0 \quad \forall d \in K\}.$$

Usando esta noción, la condición de optimalidad (1.12) es equivalente a

$$-\nabla f(\bar{x}) \in (\mathcal{B}_D(\bar{x}))^*. \quad (1.13)$$



Teorema 1.6 (Condición suficiente en forma primal). Sean $D \subset \mathbb{R}^n$ y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en $\bar{x} \in D$. Entonces

$$\langle \nabla f(\bar{x}), d \rangle > 0 \quad \forall d \in \mathcal{B}_D(\bar{x}) \setminus \{0\} \quad (1.14)$$

si, y solamente si, f satisface en D en torno a $\bar{x}$ la condición de crecimiento lineal:

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\| \quad \forall x \in D \cap U. \quad (1.15)$$

En particular, (1.15) implica que $\bar{x}$ es minimizador local estricto.

Prueba. Supongamos que (1.14) valga, pero no (1.15). Existe $\{x^k\} \subset D \setminus \{\bar{x}\}$ convergiendo a $\bar{x}$ tal que $f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|$. Definiendo $t_k = \|x^k - \bar{x}\|$ y $d^k = (x^k - \bar{x})/t_k$, podemos extraer una subsucesión convergente $d^k \rightarrow d$ ($\|d\| = 1$). Así $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. Evaluando el gradiente, obtenemos $0 \geq \langle \nabla f(\bar{x}), d \rangle$, en contradicción con (1.14).

El recíproco es directo evaluando (1.15) a lo largo de las trayectorias que definen el cono de Bouligand y tomando el límite para el gradiente. ■

Proposición 1.3 (Relaciones entre conos). Sean $D \subset \mathbb{R}^n$ y $\bar{x} \in D$. Los conos $\mathcal{T}_D(\bar{x})$ y $\mathcal{B}_D(\bar{x})$ son cerrados y se tiene que

$$\{0\} \subset \text{cl } \mathcal{V}_D(\bar{x}) \subset \mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x}).$$

Ejercicios del Capítulo

Parte I: Conceptos Básicos y Existencia de Soluciones

Ejercicio 1.1. Mediante un dibujo geométrico, formular una hipótesis sobre la solución global del problema (1.1), donde:

1. $f(x) = -x_1 + x_2$, $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 \leq 1, x_1 \geq x_2^2, x_1 + x_2 \geq 0\}$;
2. $f(x) = \max\{|x_1 - 2|, |x_2|\}$, $D = \{x \in \mathbb{R}^2 \mid 2|x_1| - |x_2| \leq 2\}$;
3. $f(x) = (x_1 - 1)^2 + x_2^2$, $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 = 2\sigma x_1 x_2\}$ y $\sigma \in \mathbb{R}$ es un parámetro.

Ejercicio 1.2. Mediante un dibujo geométrico, responder a la siguiente pregunta: para qué valores del parámetro $\sigma \in \mathbb{R}$ el problema (1.1) con $f(x) = x_1 + \sigma x_2$ y $D = \{x \in \mathbb{R}^2 \mid x_1^3 + x_2^3 = 3x_1 x_2\}$, tiene una solución global y para cuáles solo una solución local.

Ejercicio 1.3. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función continua. Probar que $\bar{x} \in \mathbb{R}^n$ es un minimizador global de f en $\mathbb{R}^n$ si, y solo si, todo x tal que $f(x) = f(\bar{x})$ es un minimizador local de f .

Ejercicio 1.4. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función cualquiera y $D \subset \mathbb{R}^n$ un conjunto cualquiera. Probar que para cualesquiera $\alpha \in \mathbb{R}_+$ y $c \in \mathbb{R}$, el conjunto de soluciones (locales y globales) del problema $\min \alpha f(x) + c$ sujeto a $x \in D$ es el mismo que el del problema original.

Ejercicio 1.5. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función cualquiera y $D_1, D_2 \subset \mathbb{R}^n$ conjuntos tales que $D_2 \subset D_1$.

1. Mostrar que $\inf_{x \in D_1} f(x) \leq \inf_{x \in D_2} f(x)$.
2. Probar que si $\bar{x}$ es un minimizador de f en D_1 tal que $\bar{x} \in D_2$, entonces $\bar{x}$ también es minimizador de f en D_2 .

Ejercicio 1.6. Probar el Corolario 1.3. (Ayuda: Usar el razonamiento analítico del Ejemplo 1.1).

Ejercicio 1.7. Sea D un conjunto compacto no vacío. Suponiendo que f sea semicontinua inferiormente en D (ver Definición 1.7), probar que existe un minimizador global para el problema (1.1). Suponiendo que f sea semicontinua superiormente en D , probar que existe un maximizador global.

Ejercicio 1.8. Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ una función semicontinua inferiormente y coercitiva en $D \neq \emptyset$. Probar que el problema (1.1) posee una solución global.

Ejercicio 1.9. Sea f una función cuadrática $f(x) = \langle Qx, x \rangle + \langle q, x \rangle + c$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica. Probar:

1. Si el problema de minimización irrestricta de f tiene un minimizador local, entonces la matriz Q es semidefinida positiva y todo minimizador local es global.
2. Si Q es definida positiva, entonces f es coercitiva en $\mathbb{R}^n$. Mostrar que el problema de minimización de f sobre cualquier conjunto D no vacío y cerrado tiene un minimizador global, pero que en general, esto no es verdadero cuando D no es cerrado.

Ejercicio 1.10. Supóngase que el problema de minimización irrestricta de una función continua en $\mathbb{R}^n$ tenga una solución global. Determinar si esto implica o no que f tiene un minimizador global en cualquier conjunto cerrado en $\mathbb{R}^n$.

Ejercicio 1.11. Supóngase que las funciones $f_1, f_2 : \mathbb{R}^n \rightarrow \mathbb{R}$ sean continuas y tengan minimizadores globales. Determinar si esto implica que la suma $f_1(\cdot) + f_2(\cdot)$ también tiene un minimizador global.

Ejercicio 1.12. Probar que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es semicontinua inferiormente en el conjunto cerrado D si, y solo si, sus conjuntos de nivel $L_{f,D}(c)$ son cerrados para todo $c \in \mathbb{R}$.

Parte II: Condiciones de Optimalidad Irrestricta

Ejercicio 1.13. Encontrar todos los valores del parámetro $\sigma \in \mathbb{R}$ para los cuales el problema de minimización irrestricta de la función $f(x) = \sigma x_1^2 + 4x_1x_2 + 4x_2^2 + x_1 + x_2$ tiene una solución.

Ejercicio 1.14. Mostrar que la función $f(x) = (x_2 - x_1^2)^2 + x_1^5$ tiene un único punto estacionario que no es un maximizador ni un minimizador en $\mathbb{R}^2$.

Ejercicio 1.15. Sean $n \geq 2$ y $f(x) = (1 + x_n)^3 \sum_{i=1}^{n-1} x_i^2 + x_n^2$. Mostrar que $\bar{x} = 0$ es el único punto estacionario de f en $\mathbb{R}^n$ y que es un minimizador local estricto, pero no es minimizador global en $\mathbb{R}^n$.

Ejercicio 1.16. Determinar si puede o no existir una función $f : \mathbb{R} \rightarrow \mathbb{R}$ que tiene un único punto estacionario y este punto es minimizador local, pero no minimizador global.

Ejercicio 1.17. Probar que, para cualquier $\sigma > 1$, el sistema de ecuaciones:

$$\sigma \cos x_1 \sin x_2 + x_1 e^{x_1^2 + x_2^2} = 0, \quad \sigma \sin x_1 \cos x_2 + x_2 e^{x_1^2 + x_2^2} = 0$$

posee una solución $x \in \mathbb{R}^2 \setminus \{0\}$.

Parte III: Cono Tangente y Condiciones Primales

Ejercicio 1.18. Sean $K_1 \subset K_2$ dos conos en $\mathbb{R}^n$. Mostrar que su cono dual verifica $K_2^* \subset K_1^*$.

Ejercicio 1.19. Sean K_1 y K_2 conos no vacíos en $\mathbb{R}^n$. Mostrar las siguientes propiedades:

1. $K_1 \times K_2$ es un cono, y $(K_1 \times K_2)^* = K_1^* \times K_2^*$.
2. $K_1 \cup K_2$ es un cono, y $(K_1 \cup K_2)^* = K_1^* \cap K_2^*$.
3. $K_1 + K_2$ es un cono, y $(K_1 + K_2)^* = K_1^* \cap K_2^*$.

Ejercicio 1.20. Mostrar que el cono de Bouligand $\mathcal{B}_D(\bar{x})$ admite la siguiente definición equivalente:

$$\mathcal{B}_D(\bar{x}) = \{0\} \cup \left\{ d \in \mathbb{R}^n \left| \begin{array}{l} \exists \{x^k\} \subset D \text{ tal que } \{x^k\} \rightarrow \bar{x}, \\ \left\{ \frac{x^k - \bar{x}}{\|x^k - \bar{x}\|} \right\} \rightarrow \frac{d}{\|d\|} \end{array} \right. \right\}.$$

Ejercicio 1.21. Mostrar que en $\mathbb{R}^n$ la condición de optimalidad primal (1.12) es equivalente a:

$$\forall \varepsilon > 0, \quad \langle \nabla f(\bar{x}), d \rangle > -\varepsilon \|d\| \quad \forall d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}.$$

Ejercicio 1.22. Sean $C \subset \mathbb{R}^n, D \subset \mathbb{R}^n$ conjuntos cualesquiera. Probar que:

$$\mathcal{B}_{C \cup D}(\bar{x}) = \mathcal{B}_C(\bar{x}) \cup \mathcal{B}_D(\bar{x}), \quad \mathcal{B}_{C \cap D}(\bar{x}) \subset \mathcal{B}_C(\bar{x}) \cap \mathcal{B}_D(\bar{x}).$$

Ejercicio 1.23. Sean $\emptyset \neq D \subset \mathbb{R}^n, C = \mathbb{R}^n \setminus D$. Denotamos por $\text{fr } D$ la frontera de D . Mostrar que si $\bar{x} \in \text{fr } D$, entonces:

$$\mathcal{B}_C(\bar{x}) \cup \mathcal{B}_D(\bar{x}) = \mathbb{R}^n, \quad \mathcal{B}_{\text{fr } D}(\bar{x}) = \mathcal{B}_C(\bar{x}) \cap \mathcal{B}_D(\bar{x}).$$

Ejercicio 1.24. Sean $D \subset \mathbb{R}^n$ un conjunto no vacío y cerrado, y $x \notin D$. Sea $P_D(x)$ el conjunto de proyecciones ortogonales de x sobre D . Mostrar que:

$$x - \bar{x} \in (\mathcal{B}_D(\bar{x}))^* \quad \forall \bar{x} \in P_D(x).$$

2. Problemas con Restricciones de Igualdad

Este capítulo presenta las condiciones teóricas de optimalidad para problemas con restricciones de igualdad, definidos sobre variedades diferenciables. A partir del Teorema de Lyusternik, se establece la relación entre la topología del cono tangente y el núcleo de la matriz Jacobiana, para luego deducir las condiciones de primer y segundo orden mediante multiplicadores de Lagrange.

Notación. Dada una función vectorial diferenciable $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$, denotaremos por $J_h(x) \in \mathbb{R}^{l \times n}$ a su matriz Jacobiana evaluada en el punto x . Consecuentemente, las filas de esta matriz corresponden a los gradientes transpuestos $\nabla h_i(x)^\top$, para $i = 1, \dots, l$.

2.1. El Problema de Optimización y el Subespacio Tangente

Definición 2.1 (Problema con Restricciones de Igualdad). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones de clase $\mathcal{C}^1$ (y de clase $\mathcal{C}^2$ cuando el análisis lo requiera). Se define el **conjunto factible** D como la variedad algebraica descrita por el sistema de igualdades:

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0\}.$$

El **problema de optimización con restricciones de igualdad** consiste en hallar un elemento en D que minimice a la función objetivo f . Este problema se denota formalmente mediante la expresión:

$$\min f(x) \quad \text{sujeto a} \quad x \in D. \quad (2.1)$$

Proposición 2.1. Supóngase que $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es diferenciable en $\bar{x} \in D$. Entonces, el cono de Bouligand está contenido en el núcleo del Jacobiano:

$$\mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x}).$$

Prueba. El vector nulo pertenece a ambos conjuntos. Sea $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. Por definición secuencial, existen sucesiones $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$, tales que $\bar{x} + t_k d^k \in D$ para todo $k \in \mathbb{N}$. Consecuentemente, $h(\bar{x} + t_k d^k) = 0$. Aplicando el desarrollo de Taylor de primer orden a la función vectorial h :

$$0 = h(\bar{x} + t_k d^k) - h(\bar{x}) = t_k J_h(\bar{x}) d^k + o(t_k \|d^k\|).$$

Dividiendo por el escalar $t_k > 0$ y tomando el límite cuando $k \rightarrow \infty$, la convergencia $d^k \rightarrow d$ implica que $J_h(\bar{x})d = 0$. Por consiguiente, $d \in \ker J_h(\bar{x})$. ■

Nota: Interpretación Geométrica del Núcleo

El álgebra lineal indica que $d \in \ker J_h(\bar{x})$ equivale a $\langle \nabla h_i(\bar{x}), d \rangle = 0$ para cada restricción i . Geométricamente, esto significa que cualquier movimiento en la dirección de d debe ser ortogonal a los gradientes de las superficies que definen a D . De este modo, d es tangente a la superficie en primer orden.

Definición 2.2 (Condiciones de Regularidad). Decimos que el punto $\bar{x} \in D$ es **regular** (o satisface una calificación de restricciones) si cumple una de las siguientes propiedades:

- Independencia Lineal de los Gradientes (LICQ):** El operador lineal $J_h(\bar{x})$ es sobreyectivo; esto es, $\text{rk } J_h(\bar{x}) = l$. Algebraicamente, esto equivale a afirmar que la transformación transpuesta es inyectiva: $\ker(J_h(\bar{x})^\top) = \{0\}$. (Nótese que esto exige la condición topológica $l \leq n$).
- Linealidad afín:** La función h es afín, i.e., $h(x) = Ax - a$, con $A \in \mathbb{R}^{l \times n}$ y $a \in \mathbb{R}^l$.

Para establecer la topología local de la variedad, se requiere un resultado analítico preparatorio basado en el Teorema de la Función Implícita clásico.

Lema 2.1 (Existencia de Función Implícita Acotada). Sean $F : \mathbb{R}^s \times \mathbb{R}^n \rightarrow \mathbb{R}^l$ diferenciable en una vecindad de $(\bar{p}, \bar{y})$ y $\nabla_y F$ continua en dicho punto. Supóngase que $F(\bar{p}, \bar{y}) = 0$ y que el rango de la matriz Jacobiana parcial es máximo: $\text{rk } J_y F(\bar{p}, \bar{y}) = l$.

Entonces, existen una vecindad U de $\bar{p}$ y una constante $M > 0$ tales que, para todo $p \in U$, existe un único $y(p) \in \mathbb{R}^n$ que satisface $F(p, y(p)) = 0$ y la acotación:

$$\|y(p) - \bar{y}\| \leq M \|F(p, \bar{y})\|.$$

Prueba. Como $J_y F(\bar{p}, \bar{y}) \in \mathbb{R}^{l \times n}$ tiene rango l , sus filas son linealmente independientes. Sea $A \in \mathbb{R}^{(n-l) \times n}$ una matriz cuyas filas completan una base de $\mathbb{R}^n$. Construimos el operador extendido $\Phi : \mathbb{R}^s \times \mathbb{R}^n \rightarrow \mathbb{R}^l \times \mathbb{R}^{n-l}$ mediante:

$$\Phi(p, y) = \begin{pmatrix} F(p, y) \\ A(y - \bar{y}) \end{pmatrix}.$$

Evaluable en el punto base, $\Phi(\bar{p}, \bar{y}) = 0$. El Jacobiano parcial respecto a y es la matriz cuadrada $J_y \Phi(\bar{p}, \bar{y}) = \begin{pmatrix} J_y F(\bar{p}, \bar{y}) \\ A \end{pmatrix} \in \mathbb{R}^{n \times n}$, la cual es no singular por construcción.

Por el Teorema de la Función Implícita, existe una función diferenciable $y : U \rightarrow \mathbb{R}^n$ definida en una vecindad de $\bar{p}$ tal que $y(\bar{p}) = \bar{y}$ y $\Phi(p, y(p)) = 0$. Esto último implica que $F(p, y(p)) = 0$ y $A(y(p) - \bar{y}) = 0$.

Aplicando el Teorema del Valor Medio sobre el operador inverso local $\Phi(p, \cdot)$ y utilizando la desigualdad triangular para el difeomorfismo continuo, se deduce la existencia de una constante M dependiente de $\|J_y \Phi^{-1}\|$ que satisface la acotación requerida. ■

Nota: Justificación Geométrica de la Corrección Ortogonal

Si un punto x no cumple las restricciones ($h(x) \neq 0$), se busca una corrección Δx tal que $h(x + \Delta x) = 0$. Geométricamente, la trayectoria más corta para retornar a la variedad es ortogonal a ella. Dado que el espacio ortogonal al plano tangente ($\ker J_h$) coincide con la imagen de la matriz transpuesta $(\mathfrak{J}(J)_h^T)$, la corrección óptima tiene la forma $\Delta x = J_h(\bar{x})^T \xi$, donde $\xi \in \mathbb{R}^l$ es un vector de ponderación. Este concepto fundamenta el desarrollo del Teorema de Lyusternik.

Ejemplo 2.1. Para ilustrar el Lema de la Función Implícita Acotada, consideremos la intersección de una circunferencia de radio paramétrico p con la recta vertical $y_1 = 1$. Modelamos esto mediante el campo vectorial $F : \mathbb{R} \times \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dado por:

$$F(p, y) = \begin{pmatrix} y_1^2 + y_2^2 - p^2 \\ y_1 - 1 \end{pmatrix}.$$

Fijemos el parámetro nominal $\bar{p} = \sqrt{2}$ y el punto de solución nominal $\bar{y} = (1, 1)^T$. Se verifica de manera directa que $F(\sqrt{2}, (1, 1)) = 0$.

Evalúamos el Jacobiano parcial respecto a las variables espaciales y :

$$J_y F(p, y) = \begin{pmatrix} 2y_1 & 2y_2 \\ 1 & 0 \end{pmatrix} \implies J_y F(\bar{p}, \bar{y}) = \begin{pmatrix} 2 & 2 \\ 1 & 0 \end{pmatrix}.$$

El determinante de esta matriz es $-2 \neq 0$. Por lo tanto, $\text{rk } J_y F(\bar{p}, \bar{y}) = 2 = l$, por lo que las hipótesis del Lema 2.1 se cumplen.

Si se perturba el radio de la circunferencia ligeramente, pasando a un nuevo parámetro $p \approx \sqrt{2}$ y manteniendo el punto en $\bar{y} = (1, 1)$, el error algebraico inducido es:

$$F(p, \bar{y}) = \begin{pmatrix} 1^2 + 1^2 - p^2 \\ 1 - 1 \end{pmatrix} = \begin{pmatrix} 2 - p^2 \\ 0 \end{pmatrix}.$$

El lema asegura que existe una raíz exacta $y(p)$ para el sistema perturbado, y que la distancia desde el punto antiguo $\bar{y}$ a la nueva raíz $y(p)$ está acotada por este error: $\|y(p) - \bar{y}\| \leq M \|F(p, \bar{y})\| = M |2 - p^2|$. En este caso, la nueva raíz analítica es $y(p) = (1, \sqrt{p^2 - 1})^T$, y mediante el desarrollo de Taylor se verifica que la distancia $|\sqrt{p^2 - 1} - 1|$ decae a la misma velocidad que la perturbación $|p^2 - 2|$.

Teorema 2.1 (Lyusternik: Estimación de Viabilidad). Supóngase que $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es continuamente diferenciable en una vecindad de $\bar{x} \in D$ y que satisface la condición LICQ. Entonces, existen una vecindad U de $\bar{x}$ y una constante $M > 0$ tales que:

$$\text{dist}(x, D) \leq M \|h(x)\| \quad \forall x \in U.$$

Prueba. Definimos el campo paramétrico $F : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}^l$ mediante la traslación $F(x, \xi) = h(x + \xi)$. Tratando a x como el parámetro y a ξ como la variable, evaluamos en el punto base $(\bar{x}, 0)$. Se tiene $F(\bar{x}, 0) = h(\bar{x}) = 0$. El Jacobiano respecto a la variable ξ es $J_\xi F(\bar{x}, 0) = J_h(\bar{x})$, el cual, por la hipótesis LICQ, tiene rango máximo l . Las hipótesis del Lema 2.1 se verifican.

Por consiguiente, existen una vecindad U de $\bar{x}$ y un número $M > 0$ tales que, para cada $x \in U$, existe una perturbación $\xi(x) \in \mathbb{R}^n$ que cumple $0 = F(x, \xi(x)) = h(x + \xi(x))$. Esto asegura que el punto trasladado $x + \xi(x) \in D$. Además, el Lema 2.1 establece la cota $\|\xi(x)\| \leq M \|F(x, 0)\| = M \|h(x)\|$. Por la definición métrica de distancia a un conjunto:

$$\text{dist}(x, D) \leq \|(x + \xi(x)) - x\| = \|\xi(x)\| \leq M \|h(x)\|.$$

■

Ejemplo 2.2 (Acotación de Lyusternik en la Esfera). Considérese la variedad esférica unitaria en $\mathbb{R}^2$, definida por $h(x) = x_1^2 + x_2^2 - 1 = 0 \implies D = \{x \in \mathbb{R}^2 \mid \|x\|^2 = 1\}$. Tomemos un punto nominal en el polo norte, $\bar{x} = (0, 1) \in D$. El Jacobiano evaluado en este punto es $J_h(\bar{x}) = (0, 2)$. Dado que $\text{rk } J_h(\bar{x}) = 1$, la condición LICQ se cumple en $\bar{x}$. El Teorema 2.1 asegura la existencia de una constante $M > 0$ y una vecindad U de $\bar{x}$ tal que $\text{dist}(x, D) \leq M |h(x)|$ para todo $x \in U$.

Analíticamente, para $x \in \mathbb{R}^2 \setminus \{0\}$, la distancia es $\text{dist}(x, D) = \left| \|x\| - 1 \right|$. La violación algebraica es $|h(x)| = \left| \|x\|^2 - 1 \right| = \text{dist}(x, D) \cdot (\|x\| + 1)$. Despejando, obtenemos $\text{dist}(x, D) = \frac{1}{\|x\| + 1} |h(x)|$. En una vecindad U alrededor de $\bar{x} = (0, 1)$, la norma satisface $\|x\| \approx 1$. Si restringimos U a la bola de radio $1/2$ centrada en $\bar{x}$, para todo $x \in U$ se cumple que $\|x\| \geq 1/2$, lo que implica $\frac{1}{\|x\| + 1} \leq \frac{2}{3}$. Así, se obtiene la constante de Lyusternik $M = 2/3$. En este caso, el error algebraico $|h(x)|$ acota la distancia geométrica al conjunto.

Atención: Colapso de la Geometría por falta de Regularidad

La condición LICQ es un requisito fundamental para asegurar la regularidad del punto. Consideremos la restricción escalar $h(x) = x^2 = 0$, con el conjunto $D = \{0\}$. En $\bar{x} = 0$, el gradiente se anula ($h'(0) = 0$), por lo que no se cumple LICQ. Para cualquier $x \notin D$, se tiene:

$$\frac{\text{dist}(x, D)}{\|h(x)\|} = \frac{|x|}{x^2} = \frac{1}{|x|} \rightarrow +\infty \quad \text{cuando } x \rightarrow 0.$$

No existe ninguna constante M finita que acote esta relación, por lo que la equivalencia entre la caracterización algebraica y la topológica deja de cumplirse.

Teorema 2.2 (Teorema del Subespacio Tangente). Sea $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ de clase $\mathcal{C}^1$ en $\bar{x} \in D$.

1. Si se satisface la condición LICQ en $\bar{x}$, entonces los conos topológicos y el subespacio algebraico coinciden:

$$\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \ker J_h(\bar{x}).$$

2. Si las restricciones son afines, se tiene adicionalmente que $\mathcal{V}_D(\bar{x}) = \ker J_h(\bar{x})$.

Prueba. Parte (1): Por la Proposición 2.1, $\mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x})$. Inversamente, sea $d \in \ker J_h(\bar{x})$. Por el Teorema de Lyusternik (Teorema 2.1), para $t > 0$ suficientemente pequeño se tiene $\text{dist}(\bar{x} + td, D) \leq M \|h(\bar{x} + td)\|$. Expandiendo h por Taylor y utilizando que $h(\bar{x}) = 0$ y $J_h(\bar{x})d = 0$:

$$h(\bar{x} + td) = h(\bar{x}) + tJ_h(\bar{x})d + o(t) = o(t).$$

Consecuentemente, $\text{dist}(\bar{x} + td, D) \leq M \|o(t)\| = o(t)$. Esto corresponde a la definición de dirección tangente, por lo que $d \in \mathcal{T}_D(\bar{x})$. De la cadena de inclusiones $\ker J_h(\bar{x}) \subset \mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x})$, se deduce la igualdad de los conjuntos.

Parte (2): Para $h(x) = Ax - a$, se tiene $J_h(\bar{x}) = A$. Si $d \in \ker A$, para cualquier escalar $t \in \mathbb{R}$: $h(\bar{x} + td) = A(\bar{x} + td) - a = (A\bar{x} - a) + tAd = h(\bar{x}) = 0$. Luego $\bar{x} + td \in D$ para todo t , lo que demuestra que $d \in \mathcal{V}_D(\bar{x})$. ■

Ejemplo 2.3 (Colapso Analítico del Cono Tangente en $\mathbb{R}^3$). Considérese la curva en $\mathbb{R}^3$ formada por la intersección de un cilindro parabólico y un plano, definida por el sistema algebraico $h(x) = (x_1^2 - x_2, x_1 + x_3 - 1)^T = 0$. Elegimos

el punto $\bar{x} = (1, 1, 0)^T \in D$. El subespacio nulo del Jacobiano evaluado en $\bar{x}$ está generado por el vector director $d = (1, 2, -1)^T$. Es decir: $\ker J_h(\bar{x}) = \text{span} \langle (1, 2, -1)^T \rangle$.

Verificamos que este vector pertenece a $\mathcal{T}_D(\bar{x})$. Construimos una curva $x(t) \in D$ parametrizada que pase por $\bar{x}$. Tomando $x_1 = 1 + t$, el sistema exige $x_2(t) = 1 + 2t + t^2$ y $x_3(t) = -t$. La curva factible es $x(t) = (1 + t, 1 + 2t + t^2, -t)^T$. Desarrollando: $x(t) = \bar{x} + td + r(t)$, donde el residuo es $r(t) = (0, t^2, 0)^T$. La norma del residuo satisface $\|r(t)\| = o(t)$. Por definición, se tiene que $d \in \mathcal{T}_D(\bar{x})$.

Teorema 2.3 (Condición Necesaria en Forma Primal). Sea $\bar{x} \in D$ un minimizador local del problema (2.1). Si $\bar{x}$ es regular (cumple LICQ o linealidad), entonces el gradiente de la función objetivo se anula a lo largo de todo el subespacio tangente:

$$\langle \nabla f(\bar{x}), d \rangle = 0 \quad \forall d \in \ker J_h(\bar{x}). \quad (2.2)$$

Prueba. De acuerdo con la caracterización general del ??, si $\bar{x}$ es un mínimo local, se cumple que $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{B}_D(\bar{x})$. Por la regularidad y el Teorema 2.2, se tiene $\mathcal{B}_D(\bar{x}) = \ker J_h(\bar{x})$. Esta desigualdad se aplica sobre el subespacio nulo. Dado que $\ker J_h(\bar{x})$ es un subespacio vectorial, si $d \in \ker J_h(\bar{x})$, su opuesto simétrico $-d$ también pertenece a $\ker J_h(\bar{x})$. Evaluando la desigualdad en dicho vector: $\langle \nabla f(\bar{x}), -d \rangle \geq 0 \implies \langle \nabla f(\bar{x}), d \rangle \leq 0$. De ambas desigualdades se deduce la igualdad a cero. ■

Ejemplo 2.4 (Ortogonalidad Primal en el Cilindro). Considérese el problema de minimizar la distancia al origen de un punto restringido a yacer sobre un cilindro desplazado en $\mathbb{R}^3$: $\min \frac{1}{2}(x_1^2 + x_2^2 + x_3^2)$ sujeto a $h(x) = (x_1 - 2)^2 + x_2^2 - 1 = 0$. Geométricamente, el punto del cilindro más cercano al origen es $\bar{x} = (1, 0, 0)^T$. El Jacobiano de la restricción evaluado en $\bar{x}$ es $\nabla h(\bar{x}) = (-2, 0, 0)^T$, por lo que se cumple LICQ. El subespacio tangente en $\bar{x}$ es el plano vertical $x_1 = 1$ generado por $d = (0, d_2, d_3)^T$. El gradiente de la función objetivo en $\bar{x}$ es $\nabla f(\bar{x}) = (1, 0, 0)^T$. El producto interno $\langle \nabla f(\bar{x}), d \rangle = 0$. De este modo se verifica la condición necesaria: el gradiente es ortogonal al subespacio de direcciones tangentes.

Corolario 2.1 (Singularidad Topológica por Exceso de Restricciones). Supóngase que el punto $\bar{x} \in D$ satisface la condición LICQ y que la dimensión de las restricciones es mayor o igual que la dimensión del espacio primal ($l \geq n$). Entonces, $\bar{x}$ es un **punto aislado** del conjunto factible D , y es un minimizador local estricto para cualquier función continua f .

Prueba. Por el Teorema del Rango de Álgebra Lineal, $\dim(\ker J_h(\bar{x})) = n - \text{rk} J_h(\bar{x})$. Bajo LICQ, el rango es máximo: $\text{rk} J_h(\bar{x}) = \min(l, n) = n$. Sustituyendo, se tiene que $\dim(\ker J_h(\bar{x})) = 0$, lo que implica $\ker J_h(\bar{x}) = \{0\}$. Aplicando el Teorema del Subespacio Tangente (Teorema 2.2), los conos topológicos se reducen a $\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \{0\}$. Al no existir direcciones tangentes no nulas, no es posible definir una sucesión en $D \setminus \{\bar{x}\}$ que converja a $\bar{x}$. Por lo tanto, existe una vecindad U de $\bar{x}$ tal que $D \cap U = \{\bar{x}\}$. Al ser el único punto factible en dicha vecindad, la condición $f(\bar{x}) \leq f(x)$ se cumple trivialmente para todo $x \in D \cap U$. ■

2.2. Condiciones de Primer Orden y Estructura Afín

Lema 2.2 (Dualidad del Núcleo). Para cualquier matriz $A \in \mathbb{R}^{l \times n}$, el cono dual de su subespacio nulo coincide con la imagen de su matriz transpuesta:

$$(\ker A)^* = \mathfrak{I}(A)^T.$$

Prueba. Sea $y \in \mathfrak{I}(A)^T$, esto es, $y = A^T \lambda$ para algún $\lambda \in \mathbb{R}^l$. Para todo $x \in \ker A$:

$$\langle y, x \rangle = \langle A^T \lambda, x \rangle = \langle \lambda, Ax \rangle = \langle \lambda, 0 \rangle = 0 \leq 0.$$

Por lo tanto, $\mathfrak{I}(A)^T \subset (\ker A)^*$. Supóngase, por reducción al absurdo, que exista $z \in (\ker A)^* \setminus \mathfrak{I}(A)^T$. Por el Teorema de Proyección Ortogonal en espacios de Hilbert, $\mathbb{R}^n = \ker A \oplus \mathfrak{I}(A)^T$. Existen vectores únicos $u \in \ker A$ y $w \in \mathfrak{I}(A)^T$ tales que $z = u + w$. Como $z \notin \mathfrak{I}(A)^T$, la proyección $u \neq 0$.

Dado que $z \in (\ker A)^*$, se tiene $\langle z, x \rangle \leq 0$ para todo $x \in \ker A$. Evaluando en $x = u$:

$$0 \geq \langle z, u \rangle = \langle u + w, u \rangle = \|u\|^2 + \langle w, u \rangle.$$

Como los subespacios son ortogonales, $\langle w, u \rangle = 0$, lo que implica que $0 \geq \|u\|^2$. Esto fuerza a $u = 0$, lo cual contradice la hipótesis. Luego, $(\ker A)^* \subset \mathfrak{I}(A)^T$. ■

Ejemplo 2.5 (Cálculo Explícito de la Dualidad). Considérese la transformación lineal definida por la matriz fila ($l = 1, n = 3$): $A = (1 \quad -1 \quad 0)$. El subespacio nulo $\ker A$ es el plano generado por $(1, 1, 0)^T$ y $(0, 0, 1)^T$. La imagen de la matriz transpuesta $\mathfrak{I}(A)^T$ es la recta paramétrica $\lambda(1, -1, 0)^T$.

Construimos el cono dual del núcleo $(\ker A)^*$ a partir de la definición de cono dual. Sea $y \in (\ker A)^*$. Debe cumplirse que $\langle y, x \rangle \leq 0$ para todo $x \in \ker A$. Al ser $\ker A$ un subespacio, si $x \in \ker A$, entonces $-x \in \ker A$. Evaluando la desigualdad: $\langle y, x \rangle \leq 0$ y $\langle y, -x \rangle \leq 0 \implies \langle y, x \rangle = 0$. Evaluando la condición de ortogonalidad sobre los vectores que generan el núcleo obtenemos $y_1 + y_2 = 0$ y $y_3 = 0$. Deducimos que todo elemento del cono dual debe tener la forma $y = y_1(1, -1, 0)^T$. Este conjunto coincide con la parametrización de $\mathfrak{F}(A)^T$. Este resultado ilustra el cono dual de un subespacio vectorial y explica por qué los multiplicadores de Lagrange asociados a restricciones de igualdad pertenecen a $\mathbb{R}^l$ sin restricciones de signo.

Definición 2.3 (Función Lagrangiana). Se define la aplicación **Lagrangiana** asociada al problema (2.1), $L : \mathbb{R}^n \times \mathbb{R}^l \rightarrow \mathbb{R}$, como:

$$L(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle.$$

El gradiente respecto al vector primal x se expresa matricialmente mediante:

$$\nabla_x L(x, \lambda) = \nabla f(x) + J_h(x)^T \lambda.$$

Nota: Equilibrio de Fuerzas y Precio Sombra

La ecuación estacionaria $\nabla f(\bar{x}) + \sum \lambda_i \nabla h_i(\bar{x}) = 0$ admite una interpretación física directa. Si se interpreta $-\nabla f$ como una fuerza que actúa sobre una partícula, y cada gradiente ∇h_i como la fuerza normal ejercida por la superficie de la restricción, el multiplicador λ_i representa la magnitud de la fuerza de reacción necesaria para mantener el equilibrio estático de la partícula.

Proposición 2.2 (Estructura Algebraica de los Multiplicadores). Para un punto $\bar{x} \in \mathbb{R}^n$ fijo, definase el conjunto de multiplicadores de Lagrange asociados como:

$$\mathcal{M}(\bar{x}) = \{\lambda \in \mathbb{R}^l \mid \nabla_x L(\bar{x}, \lambda) = 0\}.$$

Si $\mathcal{M}(\bar{x}) \neq \emptyset$ y $\bar{\lambda} \in \mathcal{M}(\bar{x})$ es un elemento particular, entonces $\mathcal{M}(\bar{x})$ constituye una variedad afín parametrizada por:

$$\mathcal{M}(\bar{x}) = \bar{\lambda} + \ker(J_h(\bar{x})^T).$$

Prueba. De acuerdo con la Definición 2.3, la condición de estacionariedad respecto al vector primal x equivale a resolver el sistema lineal $J_h(\bar{x})^T \lambda = -\nabla f(\bar{x})$. Procederemos por doble inclusión:

($\subset$): Sea $\lambda \in \mathcal{M}(\bar{x})$ un multiplicador arbitrario. Entonces, $J_h(\bar{x})^T \lambda = -\nabla f(\bar{x})$. Por hipótesis, disponemos de un elemento $\bar{\lambda} \in \mathcal{M}(\bar{x})$, el cual satisface $J_h(\bar{x})^T \bar{\lambda} = -\nabla f(\bar{x})$. Restando ambas ecuaciones se obtiene $J_h(\bar{x})^T (\lambda - \bar{\lambda}) = 0$. Esto significa que $(\lambda - \bar{\lambda}) \in \ker(J_h(\bar{x})^T)$. Despejando se obtiene $\lambda = \bar{\lambda} + v$ para algún $v \in \ker(J_h(\bar{x})^T)$, lo que demuestra que $\mathcal{M}(\bar{x}) \subset \bar{\lambda} + \ker(J_h(\bar{x})^T)$.

($\supset$): Recíprocamente, sea $\lambda \in \bar{\lambda} + \ker(J_h(\bar{x})^T)$. Esto implica la existencia de un vector $v \in \ker(J_h(\bar{x})^T)$ tal que $\lambda = \bar{\lambda} + v$. Evaluando la transformación lineal: $J_h(\bar{x})^T \lambda = J_h(\bar{x})^T \bar{\lambda} + J_h(\bar{x})^T v = -\nabla f(\bar{x}) + 0 = -\nabla f(\bar{x})$. Esto equivale a $\nabla_x L(\bar{x}, \lambda) = 0$. Por consiguiente, $\lambda \in \mathcal{M}(\bar{x})$, lo que demuestra que $\bar{\lambda} + \ker(J_h(\bar{x})^T) \subset \mathcal{M}(\bar{x})$. ■

Ejemplo 2.6 (Multiplicadores en Ausencia de Regularidad). Considérese el problema de minimizar $f(x) = x_1^2 + x_2^2$ sujeto a un sistema de dos restricciones afines linealmente dependientes en $\mathbb{R}^2$: $h_1(x) = x_1 + x_2 - 1 = 0$ y $h_2(x) = 2x_1 + 2x_2 - 2 = 0$. El minimizador global es $\bar{x} = (1/2, 1/2)^T$. El Jacobiano evaluado en $\bar{x}$ es una matriz cuyas dos filas son $(1, 1)$ y $(2, 2)$. El rango de la matriz es 1. Como $l = 2$, no se cumple la condición LICQ y la matriz transpuesta tiene un núcleo no trivial generado por $(-2, 1)^T$. Determinamos el conjunto de multiplicadores $\mathcal{M}(\bar{x})$ resolviendo $J_h(\bar{x})^T \lambda = -\nabla f(\bar{x})$, resultando $\lambda_1 + 2\lambda_2 = -1$. Un multiplicador particular es $\bar{\lambda} = (-1, 0)^T \in \mathcal{M}(\bar{x})$. La Proposición 2.2 asegura que el conjunto de multiplicadores es la variedad afín:

$$\mathcal{M}(\bar{x}) = \left\{ \begin{pmatrix} -1 - 2t \\ t \end{pmatrix} \mid t \in \mathbb{R} \right\}.$$

La falta de regularidad conduce a la pérdida de la unicidad del multiplicador.

Teorema 2.4 (Condiciones de Optimalidad de Lagrange). Sea $\bar{x} \in D$ un minimizador local del problema de optimización. Si el punto $\bar{x}$ es regular (Definición 2.2), entonces $\mathcal{M}(\bar{x}) \neq \emptyset$. Adicionalmente, si la regularidad proviene de la condición LICQ, el multiplicador es único ($\mathcal{M}(\bar{x}) = \{\bar{\lambda}\}$).

Prueba. Por el Teorema 2.3, el opuesto del gradiente de la función objetivo pertenece al cono dual del núcleo: $-\nabla f(\bar{x}) \in (\ker J_h(\bar{x}))^*$. Invocando el Lema 2.2, obtenemos $-\nabla f(\bar{x}) \in \mathfrak{F}(J_h(\bar{x}))^T$. Por definición, existe un vector

$\bar{\lambda} \in \mathbb{R}^l$ tal que $J_h(\bar{x})^\top \bar{\lambda} = -\nabla f(\bar{x})$, lo cual equivale a $\nabla_x L(\bar{x}, \bar{\lambda}) = 0$. Bajo la hipótesis LICQ, la matriz transpuesta es inyectiva ($\ker(J_h(\bar{x})^\top) = \{0\}$). Aplicando la Proposición 2.2, el subespacio afín $\mathcal{M}(\bar{x})$ se reduce a un único vector. ■

Pregunta de Control

Pregunta: Si se resuelve el sistema de Lagrange y se halla un punto $\bar{x}$ con su respectivo multiplicador $\bar{\lambda}$, ¿es posible asegurar que se trata de un mínimo local?

Respuesta: No. El Teorema de Lagrange establece únicamente una condición necesaria de primer orden. El punto obtenido podría corresponder a un máximo local o a un punto de silla sobre la variedad factible. Para determinar la naturaleza del punto, es indispensable realizar un análisis de segundo orden.

Ejemplo 2.7. Considérese el problema geométrico de proyectar un vector $y \in \mathbb{R}^n$ sobre el hiperplano afín $H = \{x \in \mathbb{R}^n \mid \langle a, x \rangle = c\}$, con $a \neq 0$. Esto se formula como $\min \frac{1}{2} \|x - y\|^2$ sujeto a $\langle a, x \rangle - c = 0$. Al ser la restricción afín, se verifica la condición de regularidad (Definición 2.2). El sistema de Lagrange impone $\nabla_x L(\bar{x}, \bar{\lambda}) = (\bar{x} - y) + \bar{\lambda}a = 0 \implies \bar{x} = y - \bar{\lambda}a$. Utilizando la condición de factibilidad ($\langle a, \bar{x} \rangle = c$) y la linealidad del producto interno, obtenemos $\bar{\lambda} = (\langle y, a \rangle - c)/\|a\|^2$. Sustituyendo este escalar, obtenemos la proyección ortogonal clásica:

$$\bar{x} = y + \left(\frac{c - \langle y, a \rangle}{\|a\|^2} \right) a.$$

Ejemplo 2.8. Determinéense los minimizadores y maximizadores globales de la función $f(x) = \frac{x_1^3}{3} + x_2$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 = 1\}$. El gradiente de la restricción, $\nabla h(x) = 2(x_1, x_2)^\top$, no se anula en D , lo que verifica la condición LICQ. El sistema de Lagrange requiere $x_1^2 + 2\lambda x_1 = 0$ y $1 + 2\lambda x_2 = 0$. La primera ecuación se puede factorizar como $x_1(x_1 + 2\lambda) = 0$, lo que permite dividir el análisis en dos casos:

1. Si $x_1 = 0$, la condición de factibilidad implica $x_2 = \pm 1$. La segunda ecuación determina $\lambda = \mp 1/2$. Esto genera los puntos estacionarios $(0, 1)$ y $(0, -1)$.
2. Si $x_1 \neq 0$, entonces $x_1 = -2\lambda$. La segunda ecuación exige $x_2 = -1/(2\lambda)$. Sustituyendo en la ecuación de la esfera se obtiene $16\lambda^4 - 4\lambda^2 + 1 = 0$. El discriminante de esta ecuación bicuadrática es negativo, por lo que no existen raíces reales en este caso.

Evaluando la función objetivo en los puntos obtenidos, $f(0, 1) = 1$ y $f(0, -1) = -1$, identificamos el máximo y el mínimo global sobre el conjunto factible.

2.3. Condiciones Diferenciales de Segundo Orden

Teorema 2.5 (Condición Necesaria de Segundo Orden). Supóngase que f, h son de clase $\mathcal{C}^2$ en una vecindad de $\bar{x} \in D$, siendo $\bar{x}$ un minimizador local regular. Entonces, para todo $\lambda \in \mathcal{M}(\bar{x})$, el operador Hessiano de la Lagrangiana es semidefinido positivo al restringirse sobre el subespacio tangente:

$$\langle \nabla_{xx}^2 L(\bar{x}, \lambda) d, d \rangle \geq 0 \quad \forall d \in \ker J_h(\bar{x}). \quad (2.3)$$

Prueba. Sea $d \in \ker J_h(\bar{x})$. Por el Teorema del Subespacio Tangente (Teorema 2.2), $d \in \mathcal{T}_D(\bar{x})$. Por definición secuencial, para todo $t \in \mathbb{R}$ suficientemente pequeño, existe un punto $x(t) \in D$ parametrizado por $x(t) = \bar{x} + td + r(t)$, donde $\|r(t)\| = o(t)$. Como la trayectoria yace en la variedad factible, $h(x(t)) = 0$ y $h(\bar{x}) = 0$. Por consiguiente, para cualquier $\lambda \in \mathcal{M}(\bar{x})$, la variación de la función objetivo coincide con la variación de la Lagrangiana: $f(x(t)) - f(\bar{x}) = L(x(t), \lambda) - L(\bar{x}, \lambda)$.

Aplicando el desarrollo de Fréchet de segundo orden a la Lagrangiana en torno a $\bar{x}$ (y denotando $\Delta x = td + r(t)$):

$$L(x(t), \lambda) - L(\bar{x}, \lambda) = \langle \nabla_x L(\bar{x}, \lambda), \Delta x \rangle + \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda) \Delta x, \Delta x \rangle + o(\|\Delta x\|^2).$$

Como $\lambda \in \mathcal{M}(\bar{x})$, el término lineal se anula. Al expandir la forma cuadrática, y dado que $\|r(t)\| = o(t)$, los términos cruzados y dependientes de $r(t)$ se incorporan al término residual $o(t^2)$, obteniéndose $f(x(t)) - f(\bar{x}) = \frac{t^2}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda) d, d \rangle + o(t^2)$. Dado que $\bar{x}$ es un mínimo local, se requiere que $f(x(t)) - f(\bar{x}) \geq 0$. Sustituyendo esta condición, dividiendo por $t^2 > 0$ y tomando el límite cuando $t \rightarrow 0$, se concluye que $\langle \nabla_{xx}^2 L(\bar{x}, \lambda) d, d \rangle \geq 0$. ■

Nota: Propiedad cancelativa de la Lagrangiana

En la demostración anterior ocurre una simplificación relevante. Si se aplicara el desarrollo de Taylor directamente a la función objetivo $f(x(t))$ usando el vector tangente $\Delta x = td + r(t)$, el término lineal $\langle \nabla f(\bar{x}), r(t) \rangle$ introduciría un error de orden $o(t)/t^2$ que no se anula al dividir por t^2 . Al emplear la función Lagrangiana, la condición de primer orden garantiza que $\nabla_x L(\bar{x}, \lambda) = 0$. Este hecho **anula el efecto del término residual** $r(t)$ en primer orden, permitiendo que el término de segundo orden $(\nabla_{xx}^2 L)$ determine el comportamiento asintótico de la función.

Ejemplo 2.9 (La Curvatura de la Restricción Domina). Considérese el problema de maximizar la altura sobre una parábola invertida, equivalente a $\min f(x) = -x_2$ sujeto a $h(x) = x_2 - x_1^2 = 0$. El único punto estacionario geométrico es el vértice de la parábola, $\bar{x} = (0, 0)^\top$. El gradiente de la restricción es $\nabla h(x) = (-2x_1, 1)^\top$. Evaluado en el origen resulta en $(0, 1)^\top \neq 0$, lo que cumple la condición LICQ. Planteamos el sistema de Lagrange de primer orden: $\nabla f(\bar{x}) + \lambda \nabla h(\bar{x}) = (0, -1)^\top + \lambda(0, 1)^\top = (0, 0)^\top$, lo que implica $\bar{\lambda} = 1$.

Evaluamos ahora la Condición Necesaria de Segundo Orden. Las matrices Hessianas de las funciones individuales son nulas o constantes. La matriz Hessiana global de la Lagrangiana evaluada en $(\bar{x}, \bar{\lambda})$ es $\nabla_{xx}^2 L(\bar{x}, \bar{\lambda}) = \begin{pmatrix} -2 & 0 \\ 0 & 0 \end{pmatrix}$. Esta matriz es semidefinida negativa. Calculamos el núcleo de la matriz Jacobiana, obteniendo $\ker J_h(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \in \mathbb{R}\}$. Para una dirección tangente genérica $d = (d_1, 0)^\top$, proyectamos la Hessiana de la Lagrangiana: $\langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda})d, d \rangle = -2d_1^2$. Para todo $d_1 \neq 0$, esta forma cuadrática proyectada resulta en un valor estrictamente negativo. Por lo tanto, la condición necesaria de segundo orden (2.3) **no se cumple**. Se concluye entonces que $\bar{x} = (0, 0)^\top$ no es un mínimo local.

Teorema 2.6 (Condición Suficiente de Segundo Orden). Sea $\bar{x} \in D$, con f, h de clase $\mathcal{C}^2$. Si la estructura diferencial en el punto satisface la condición estrictamente definida positiva sobre el núcleo:

$$\forall d \in \ker J_h(\bar{x}) \setminus \{0\}, \quad \exists \lambda \in \mathcal{M}(\bar{x}) \quad \text{t.q.} \quad \langle \nabla_{xx}^2 L(\bar{x}, \lambda)d, d \rangle > 0, \quad (2.4)$$

entonces $\bar{x}$ es un minimizador local estricto, y satisface la condición de crecimiento cuadrático local sobre D . Recíprocamente, si se verifica una de las condiciones de regularidad y el crecimiento cuadrático local rige, entonces la condición (2.4) se cumple necesariamente.

Prueba. Para demostrar la suficiencia, supóngase por reducción al absurdo que la condición (2.4) se verifica, pero el crecimiento cuadrático no se cumple. En tal caso, existe una sucesión factible $\{x^k\} \subset D \setminus \{\bar{x}\}$ que converge a $\bar{x}$ y que satisface $f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|^2$ para todo $k \in \mathbb{N}$. Por compacidad, se extrae una subsucesión de direcciones normalizadas d^k convergente a un vector unitario $d \in \mathcal{B}_D(\bar{x}) \subset \ker J_h(\bar{x})$.

Sea $\lambda \in \mathcal{M}(\bar{x})$ el multiplicador cuya existencia asegura la hipótesis (2.4) para esta dirección particular. Sustituyendo el desarrollo de Fréchet de la Lagrangiana: $\frac{1}{k} \|x^k - \bar{x}\|^2 > \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda)(x^k - \bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|^2)$. Dividiendo la desigualdad por $\|x^k - \bar{x}\|^2 > 0$ y tomando el límite cuando $k \rightarrow \infty$, se obtiene $0 \geq \langle \nabla_{xx}^2 L(\bar{x}, \lambda)d, d \rangle$, lo cual contradice la hipótesis de positividad estricta.

Para probar el recíproco, supóngase que el crecimiento cuadrático se cumple con una constante $\beta > 0$, se sostiene la condición de regularidad, pero la condición (2.4) no se verifica. Esto implica la existencia de una dirección $d \in \ker J_h(\bar{x}) \setminus \{0\}$ tal que para todo $\lambda \in \mathcal{M}(\bar{x})$, la forma cuadrática es ≤ 0 . Dado que $d \in \mathcal{T}_D(\bar{x})$, existe una trayectoria factible $x(t) = \bar{x} + td + r(t) \in D$. Evaluando la condición de crecimiento cuadrático: $\beta \|td + r(t)\|^2 \leq f(x(t)) - f(\bar{x}) = \frac{t^2}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda)d, d \rangle + o(t^2) \leq o(t^2)$. Dividiendo la ecuación por t^2 y tomando el límite cuando $t \rightarrow 0^+$, el residuo se anula obteniéndose $\beta \|d\|^2 \leq 0$. Como $\beta > 0$, esto implica que $d = 0$, lo cual contradice la elección de un vector $d \neq 0$. ■

Ejemplo 2.10 (La Silla de Montar Restringida). Considérese la minimización de una función de silla clásica sujeta a una restricción lineal: $\min f(x) = x_1^2 - x_2^2$ sujeto a $h(x) = x_1 - x_2 = 0$. El origen $\bar{x} = (0, 0)^\top$ es el único punto de intersección y candidato a análisis. El sistema de Lagrange se cumple para el multiplicador $\bar{\lambda} = 0$. A nivel irrestricto, la matriz Hessiana de la función objetivo es indefinida (con autovalores 2 y -2). Dado que la restricción es afín, $\nabla_{xx}^2 L(\bar{x}, \bar{\lambda}) = \nabla^2 f(\bar{x})$.

Aplicamos el Teorema 2.6 analizando el subespacio tangente (núcleo del Jacobiano), que está generado por $d = (d_1, d_1)^\top$. Evaluando la forma cuadrática proyectada de la Lagrangiana, se obtiene $2d_1^2 - 2d_1^2 = 0$. La forma cuadrática proyectada resulta ser idénticamente cero, por lo que la condición de positividad estricta no se cumple y el análisis diferencial de segundo orden no es concluyente. No obstante, si se sustituye la restricción $x_1 = x_2$

directamente en la función objetivo, se observa que $f(x(t)) = 0$. La función es constante a lo largo del subespacio tangente y el punto es un mínimo global no estricto.

Ejemplo 2.11 (La Hessiana Proyectada Positiva). Considérese el problema: $\min f(x) = x_1^2 - x_2^2$ sujeto a $h(x) = x_2 = 0$. El punto estacionario en el origen es $\bar{x} = (0, 0)^\top$. El sistema de Lagrange evaluado en el origen resulta en $\bar{\lambda} = 0$. La matriz Hessiana de la Lagrangiana es indefinida en el espacio total. Aplicamos el Teorema 2.6 calculando el subespacio tangente: $\ker J_h(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \in \mathbb{R}\}$. Para una dirección tangente no nula, evaluamos la forma cuadrática proyectada obteniendo $2d_1^2 > 0$. Este resultado ilustra la aplicación del teorema: aunque la matriz Hessiana global presenta un autovalor negativo en la dirección de x_2 , la restricción descarta este eje de descenso. En el subespacio tangente permitido, la curvatura es estrictamente positiva. En consecuencia, se concluye que $\bar{x} = (0, 0)^\top$ es un mínimo local estricto.

Atención: Ventaja sobre Criterios Clásicos

La literatura clásica frecuentemente exige una condición suficiente basada en un multiplicador único. Dicha formulación exige utilizar un único multiplicador común para todas las direcciones. El Teorema 2.6 resulta más general, ya que al ser $\mathcal{M}(\bar{x})$ un conjunto afín, permite asociar diferentes multiplicadores a distintas direcciones tangentes para verificar la condición de positividad.

Contraejemplo 2.1 (Colapso del multiplicador uniforme). Sean $f(x) = -x_1^2 - x_2^2$ y $h(x) = (x_1 x_2, x_1^2 - x_2^2)^\top = 0$. El origen $\bar{x} = 0$ es el único punto factible. Los gradientes se anulan en dicho punto, lo que da lugar a $\ker J_h(0) = \mathbb{R}^2$ y $\mathcal{M}(0) = \mathbb{R}^2$. El operador Hessiano de la Lagrangiana tiene traza -4 para cualquier valor de λ . Dado que la traza es negativa, esta matriz no puede ser definida positiva. En consecuencia, no existe un multiplicador único $\bar{\lambda}$ que garantice la positividad de la forma cuadrática para toda dirección d . Sin embargo, para cada dirección específica $d \neq 0$, es posible elegir un vector $\lambda(d)$ adecuado que asegure la positividad de la forma cuadrática.

Ejercicios del Capítulo

Parte I: Mecánica Primal-Dual y Fallas Topológicas

Ejercicio 2.1. Determinéense los minimizadores y maximizadores globales del funcional lineal $f(x) = \sum_{i=1}^n x_i$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^n \mid \|x\|^2 = 1\}$.

Ejercicio 2.2. Hállense los minimizadores de la función $f(x) = \|x\|^2$ sujetos a las siguientes restricciones:

- El hiperplano afín $h(x) = 1 - \sum_{i=1}^n x_i = 0$.
- La superficie cuádrica $h(x) = 1 - \langle Qx, x \rangle = 0$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica.

Ejercicio 2.3. Verifíquese analíticamente que el punto $\bar{x} = (0, 0) \in \mathbb{R}^2$ es la solución global del problema $\min x_2$ sujeto a la intersección de las circunferencias $(x_1 - 1)^2 + x_2^2 = 1$ y $(x_1 + 1)^2 + x_2^2 = 1$. Demuestre que $\bar{x}$ no cumple con las condiciones de regularidad y que el sistema de Lagrange no admite solución en dicho punto.

Ejercicio 2.4. Demuestre que $\bar{x} = (0, 0) \in \mathbb{R}^2$ es la solución global del problema $\min x_1^2 + x_2^2$ sujeto a la restricción $(x_1 - 1)^3 = x_2^2$, y explique por qué las condiciones de optimalidad de Lagrange no se cumplen en este punto debido a la falta de regularidad (falta de LICQ).

Ejercicio 2.5 (Pérdida de la condición LICQ por reformulación no lineal). Sea el conjunto factible $D = \{x \in \mathbb{R}^n \mid h(x) = 0\}$, donde $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ cumple la condición LICQ en todo punto de D . Considérese el problema de minimización de $f(x)$ sobre D . Supóngase que se reformula el problema utilizando la restricción escalar equivalente: $\tilde{h}(x) = \frac{1}{2} \|h(x)\|^2 = 0$.

- Demuestre que el nuevo conjunto factible $\tilde{D} = \{x \in \mathbb{R}^n \mid \tilde{h}(x) = 0\}$ coincide con D .
- Pruebe analíticamente que ningún punto de $\tilde{D}$ cumple la condición de regularidad LICQ para la restricción $\tilde{h}$.
- Explique por qué el sistema de Lagrange asociado a $\tilde{h}$ no permite identificar los puntos óptimos del problema original, analizando la diferencia entre la representación algebraica y el conjunto geométrico.

Ejercicio 2.6 (El Cilindro y el Plano Tangente). Considérese la superficie descrita por $h(x) = x_1^2 + x_2^2 - x_3 = 0$ (un paraboloide).

1. Evalúe el punto $\bar{x} = (1, 1, 2)^\top$. Demuestre que se cumple LICQ y halle una base ortonormal para el subespacio tangente $\ker J_h(\bar{x})$.
2. Considere la curva parametrizada $x(t) = (\cos t, \sin t, 1)^\top$. Verifique que la curva pertenece a la variedad para todo t , y demuestre que el vector velocidad $x'(0)$ es una combinación lineal de los vectores de la base obtenida en el inciso anterior.

Ejercicio 2.7 (Dependencia Funcional y Conjuntos de Nivel). Sea $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ una función escalar de clase $\mathcal{C}^1$. Considérese el problema de minimizar $f(x)$ sujeto a que el punto pertenezca a una curva de nivel de otra función suave: $h(x) = g(x) - c = 0$. Demuestre que, si el punto $\bar{x}$ es un óptimo regular, entonces las curvas de nivel de f y de g que pasan por $\bar{x}$ son tangentes entre sí en dicho punto. Interprete este resultado geoméricamente usando los gradientes.

Ejercicio 2.8 (Intersección de dimensión mixta y puntos aislados). Sea el conjunto factible en $\mathbb{R}^3$ definido por $h_1(x) = x_1^2 + x_2^2 - x_3 = 0$ y $h_2(x) = x_3 = 0$.

1. Describa geoméricamente el conjunto resultante D .
2. Demuestre que el único punto en D es el origen $(0, 0, 0)^\top$.
3. Calcule la matriz Jacobiana $J_h(0)$. Determine si el origen es un punto regular y analice, desde una perspectiva geométrica y topológica, por qué la intersección de estas restricciones produce un punto aislado en lugar de una curva.

Parte II: Condiciones Diferenciales de Segundo Orden y Matriz KKT

Ejercicio 2.9. Determine los extremos locales y globales de la función $f(x) = x_1^3/3 + x_2$ restringida a la esfera $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 = 2\}$.

Ejercicio 2.10 (El Sistema Lineal de Karush-Kuhn-Tucker). Sea el funcional cuadrático generalizado $f(x) = \frac{1}{2}\langle Qx, x \rangle + \langle q, x \rangle$ sujeto a la restricción afín sobreyectiva $Ax = a$. Asumiendo que Q es simétrica y definida positiva, pruébese la unicidad de la solución primal-dual y determínese analíticamente el sistema matricial de bloques (Matriz KKT) que resuelven los vectores x y λ simultáneamente.

Ejercicio 2.11 (No-singularidad Numérica de la Matriz KKT). Generalizando el ejercicio anterior, sea $\bar{x} \in D$ un punto estacionario regular (LICQ) para un problema no lineal de optimización, con multiplicador único $\bar{\lambda}$. Definase el Hessiano $H = \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}) \in \mathbb{R}^{n \times n}$ y el Jacobiano $A = J_h(\bar{x}) \in \mathbb{R}^{l \times n}$. Supóngase que se cumple la condición suficiente de segundo orden estricta: $\langle Hd, d \rangle > 0$ para todo $d \in \ker A \setminus \{0\}$. Demuéstrese que la matriz de bloques KKT:

$$K = \begin{pmatrix} H & A^\top \\ A & 0 \end{pmatrix} \in \mathbb{R}^{(n+l) \times (n+l)}$$

es invertible. (Ayuda: Suponga que $K \begin{pmatrix} d \\ y \end{pmatrix} = 0$, multiplique la primera fila de bloques por $d^\top$ y utilice la condición de positividad sobre el núcleo para deducir que $d = 0$).

Ejercicio 2.12 (Valores Propios como Extremos de Rayleigh). Sea $Q \in \mathbb{R}^{n \times n}$ una matriz simétrica. Utilícese el sistema de optimalidad para encontrar todos los minimizadores y maximizadores de la forma cuadrática $f(x) = \langle Qx, x \rangle$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^n \mid \|x\|^2 = 1\}$. Caracterícese el conjunto de multiplicadores de Lagrange en términos de los autovalores de la matriz Q .

Ejercicio 2.13 (Degeneración de la Condición Necesaria). Considérese el problema $\min f(x) = x_1^4 + x_2^4$ sujeto a $h(x) = x_1 + x_2 = 0$. Verifique analíticamente que $\bar{x} = (0, 0)$ es el minimizador global estricto del problema. Sin embargo, al calcular la matriz Hessiana de la Lagrangiana evaluada sobre el núcleo de la restricción, demuestre que el resultado es la matriz nula. Muestre que cuando las de menor orden se anulan, las aproximaciones cuadráticas no bastan para asegurar la suficiencia analítica de segundo orden.

Ejercicio 2.14 (Descomposición Espectral en Lagrange). Minimice la función $f(x) = x_1^2 + x_2^2 + x_3^2$ sujeta a la restricción no lineal $h(x) = x_1 x_2 x_3 - 1 = 0$.

1. Encuentre todos los puntos estacionarios y sus respectivos multiplicadores de Lagrange.
2. Calcule la matriz Hessiana de la Lagrangiana en dichos puntos.

3. Proyecte la matriz Hessiana sobre el subespacio tangente y utilice el criterio de los autovalores para determinar cuáles puntos son mínimos locales. (Ayuda: Analice la simetría de las coordenadas).

Ejercicio 2.15 (Puntos de Ensilladura Restringidos). Considere el problema $\min x_1 x_2$ sujeto a $x_1 + x_2 = 2$. Demuestre que el único punto estacionario del sistema de Lagrange es $\bar{x} = (1, 1)^T$. Evaluando las condiciones necesarias y suficientes de segundo orden, pruebe que este punto no es un minimizador local, sino que corresponde a un máximo global restringido.

Ejercicio 2.16 (La Matriz Fronteada (Bordered Hessian)). Sea un problema con restricciones afines $Ax = a$. La matriz KKT $K = \begin{pmatrix} H & A^T \\ A & 0 \end{pmatrix}$ es simétrica. Demuestre que, incluso si H es estrictamente definida positiva, la matriz de bloques completa K es siempre indefinida (posee tanto autovalores estrictamente positivos como estrictamente negativos). Este resultado explica por qué los algoritmos de optimización numérica suelen utilizar factorizaciones como LDL^T en lugar de la factorización de Cholesky.

Parte III: Aplicaciones Físicas, Análisis de Sensibilidad y Variedades Matriciales

Ejercicio 2.17 (Precio Sombra y Análisis de Sensibilidad). Considérese el problema parametrizado $\min f(x)$ sujeto a $h(x) = p$, donde $p \in \mathbb{R}^l$ es un vector de perturbaciones de frontera. Sea $\bar{x}$ un mínimo local estricto para el problema nominal ($p = 0$), regular (LICQ) y que satisface las condiciones suficientes de segundo orden con multiplicador único $\bar{\lambda}$. Invocando el Teorema de la Función Implícita sobre el sistema KKT, existe una trayectoria suave de minimizadores locales $x(p)$ con $x(0) = \bar{x}$. Definase la función valor óptimo $v(p) = f(x(p))$. Aplicando la regla de la cadena multivariable y la ecuación estacionaria de Lagrange, demuéstrese rigurosamente que: $\nabla_p v(0) = -\bar{\lambda}$. Interprete este resultado desde una perspectiva geométrica y económica, relacionando el multiplicador de Lagrange con la sensibilidad del valor óptimo frente a variaciones en el término independiente de la restricción.

Ejercicio 2.18 (Problema Isoperimétrico de Herón). Entre todos los triángulos de perímetro fijo $2p > 0$, utilícense las condiciones de optimalidad de Lagrange de primero y segundo orden para demostrar que el triángulo que maximiza el área es el triángulo equilátero. (Ayuda: Modele el problema maximizando el cuadrado del área mediante la fórmula de Herón $f(x, y, z) = p(p-x)(p-y)(p-z)$ sujeto a la restricción afín $x + y + z = 2p$).

Ejercicio 2.19 (Principio de Fermat y la Ley de Snell). Un rayo de luz viaja desde el punto $A = (0, y_A)$ en un medio isótropo con velocidad v_1 , hasta un punto $B = (x_B, y_B)$ en un medio con velocidad v_2 . La interfaz de refracción entre ambos medios es la recta horizontal $y = 0$. Modele el problema buscando el punto de cruce $P = (x, y) \in \mathbb{R}^2$ que minimiza el tiempo total de viaje $T(x, y) = \frac{\|P-A\|}{v_1} + \frac{\|B-P\|}{v_2}$ sujeto a la restricción de frontera $h(x, y) = y = 0$. Resolviendo el sistema de Lagrange, obtégase analíticamente la Ley de Snell.

Ejercicio 2.20 (Distribución Uniforme y Entropía de Shannon). En Teoría de la Información, la entropía de una distribución de probabilidad discreta $x \in \mathbb{R}^n$ (con $x_i > 0$) se define como el funcional $\mathcal{H}(x) = -\sum_{i=1}^n x_i \ln(x_i)$. Demuestre analíticamente que el problema de maximización de entropía $\max \mathcal{H}(x)$ sujeto a $\sum_{i=1}^n x_i = 1$ es resuelto unívocamente por la distribución uniforme $\bar{x}_i = 1/n$ para todo i . Verifique el carácter de máximo global analizando los autovalores de la matriz Hessiana.

Ejercicio 2.21 (Proyección sobre el Grupo Ortogonal: El Problema de Procrustes). Sea el espacio de matrices cuadradas $M_n(\mathbb{R})$ equipado con el producto de Frobenius $\langle X, Y \rangle_F = \text{Tr}(X^T Y)$. Considérese el problema de encontrar la matriz ortogonal más cercana a una matriz dada $A \in M_n(\mathbb{R})$:

$$\min \frac{1}{2} \|X - A\|_F^2 \quad \text{sujeto a} \quad X^T X - I = 0.$$

Haciendo uso de las derivadas de Fréchet para funciones matriciales, defina la Lagrangiana (donde el multiplicador de Lagrange es una matriz simétrica $\Lambda \in M_n(\mathbb{R})$) y derive la ecuación matricial estacionaria.

Ejercicio 2.22 (Mecánica Clásica: El Péndulo Simple). Un péndulo consiste en una masa m sujeta al extremo de una varilla rígida de longitud L sin masa, cuyo otro extremo está fijo en el origen $(0, 0)$. La posición de la masa se denota por (x, y) . La energía potencial es $V(x, y) = mgy$. Modele las posiciones de equilibrio del péndulo determinando los extremos de $V(x, y)$ sujetos a la restricción de longitud $x^2 + y^2 = L^2$. Interprete el multiplicador de Lagrange como la fuerza de tensión en la varilla.

Ejercicio 2.23 (Microeconomía: Maximización de Utilidad). Un consumidor desea maximizar su función de utilidad Cobb-Douglas $U(x_1, x_2) = x_1^\alpha x_2^\beta$ (con $\alpha, \beta > 0$), sujeto a su restricción presupuestaria $p_1 x_1 + p_2 x_2 = I$, donde p_i son los precios e I el ingreso disponible.

1. Encuentre las funciones de demanda marshallianas $x_1(p_1, p_2, I)$ y $x_2(p_1, p_2, I)$ resolviendo el sistema de Lagrange.
2. Calcule el multiplicador de Lagrange óptimo λ^* .
3. Demuestre analíticamente que $\lambda^* = \frac{\partial U^*}{\partial I}$, verificando que el multiplicador representa la “utilidad marginal del ingreso”.

Ejercicio 2.24 (Problema de Optimización de Carteras de Markowitz). Un inversor desea construir un portafolio con n activos financieros. Sea $x \in \mathbb{R}^n$ el vector de ponderación de cada activo (fracción del capital invertido), tal que $\sum x_i = 1$. Sea $\Sigma \in \mathbb{R}^{n \times n}$ la matriz de covarianza de los retornos (simétrica y definida positiva) y $\mu \in \mathbb{R}^n$ el vector de retornos esperados. El inversor desea minimizar la varianza de la cartera $\frac{1}{2} x^\top \Sigma x$, sujeto a obtener un retorno esperado objetivo $\mu^\top x = R$, y a que la suma de las ponderaciones sea igual a 1 ($e^\top x = 1$, donde e es el vector de unos). Escriba el sistema KKT, halle la solución analítica para las ponderaciones óptimas x^* y demuestre que dicha solución es única.

Ejercicio 2.25 (Mínimos Cuadrados Restringidos). En estimación estadística, a menudo se requiere estimar parámetros sujetos a un conjunto de restricciones lineales exactas. Considere el problema de regresión $\min \frac{1}{2} \|Y - X\beta\|^2$ sujeto a $C\beta = d$, donde $Y \in \mathbb{R}^m$, $X \in \mathbb{R}^{m \times n}$ (con rango de columnas completo), $C \in \mathbb{R}^{l \times n}$ (rango de filas completo) y $d \in \mathbb{R}^l$. Encuentre la expresión analítica cerrada del estimador restringido β^* resolviendo el sistema de ecuaciones de Lagrange y compárelo con el estimador de mínimos cuadrados ordinarios irrestricto $\hat{\beta} = (X^\top X)^{-1} X^\top Y$.

3. Elementos de Análisis Convexo

En este capítulo estudiamos conjuntos convexos y funciones convexas. La convexidad es una noción muy importante en la teoría de optimización. Con hipótesis de convexidad, las condiciones necesarias de optimalidad pasan a ser suficientes. En otras palabras, todo punto estacionario se convierte en una solución del problema. En particular, cualquier minimizador local es global. Además, en el caso convexo podemos desarrollar la teoría de dualidad en su forma más completa, es decir, asociar al problema original (primal) otro problema, llamado dual, que bajo ciertas hipótesis es equivalente al original y a veces es más fácil de resolver.

Finalmente, las herramientas del Análisis Convexo serán necesarias para la caracterización del cono dual al cono tangente en el caso de restricciones mixtas (de igualdad y desigualdad), lo que resulta en las condiciones de optimalidad primal-duales de Karush-Kuhn-Tucker. Cabe resaltar que este capítulo no constituye un curso de Análisis Convexo completo; además de resultados básicos, presentamos solo el material que será necesario a lo largo de este libro.

3.1. Definiciones de convexidad. El problema de minimización convexo

Un conjunto convexo se caracteriza por contener todos los segmentos cuyos extremos pertenecen al conjunto.

Definición 3.1 (Conjunto convexo). Un conjunto $D \subset \mathbb{R}^n$ se llama **conjunto convexo** si para cualesquiera $x \in D$, $y \in D$ y $\alpha \in [0, 1]$, se tiene que

$$\alpha x + (1 - \alpha)y \in D.$$

El punto $\alpha x + (1 - \alpha)y$, donde $\alpha \in [0, 1]$, se llama **combinación convexa** de x y y (con parámetro α).

El conjunto vacío, el espacio $\mathbb{R}^n$ y un conjunto que contiene un solo punto son trivialmente convexos. Cualquier conjunto no convexo es trivialmente no convexo.

A continuación mostramos que la dualización de un cono cualquiera (incluso no convexo) siempre produce un cono convexo.

Proposición 3.1. Para todo cono $\emptyset \neq K \subset \mathbb{R}^n$, el cono dual K^* siempre es convexo y cerrado.

Prueba. Sean $x \in K^*$ e $y \in K^*$, es decir, $\langle x, d \rangle \leq 0$ e $\langle y, d \rangle \leq 0$ para todo $d \in K$. Sea $\alpha \in [0, 1]$. Para cualquier $d \in K$, tenemos que:

$$\langle \alpha x + (1 - \alpha)y, d \rangle = \alpha \langle x, d \rangle + (1 - \alpha) \langle y, d \rangle \leq 0,$$

es decir, $\alpha x + (1 - \alpha)y \in K^*$. Por lo tanto, K^* es convexo.

Sea $\{y^k\} \subset K^*$, $\{y^k\} \rightarrow y$ ($k \rightarrow \infty$). Fijando $d \in K$ arbitrario, y pasando al límite cuando $k \rightarrow \infty$ en la relación $\langle y^k, d \rangle \leq 0$, obtenemos que $\langle y, d \rangle \leq 0$. Por lo tanto, como $d \in K$ era arbitrario, $y \in K^*$. Esto muestra que K^* es cerrado. ■

Otros criterios de convexidad de conjuntos se presentarán en la siguiente sección. Mostramos a continuación que, para un conjunto convexo, el cono tangente (usual o de Bouligand) está dado por la clausura de todas las direcciones viables. Pero primero introducimos la siguiente noción.

Definición 3.2 (Cápsula cónica o envoltura cónica). Dado un conjunto $D \subset \mathbb{R}^n$ cualquiera, la **cápsula cónica** de D , denotado por $\text{cone } D$, es el menor cono convexo en $\mathbb{R}^n$ que contiene a D (o, equivalentemente, la intersección de todos los conos convexos en $\mathbb{R}^n$ que contienen a D).

Para un conjunto convexo, la cápsula cónica está compuesto por todos los múltiplos no negativos de elementos del conjunto.

Proposición 3.2 (Cápsula cónica de un conjunto convexo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Se tiene que:

$$\text{cone } D = \{d \in \mathbb{R}^n \mid d = \alpha x, x \in D, \alpha \in \mathbb{R}_+\}.$$

Prueba. Denotamos $C = \{d \in \mathbb{R}^n \mid d = \alpha x, x \in D, \alpha \in \mathbb{R}_+\}$. Como el conjunto cone D es un cono, para todo $x \in D \subset \text{cone } D$, tenemos que $\alpha x \in \text{cone } D$ para todo $\alpha \in \mathbb{R}_+$. Luego, $C \subset \text{cone } D$.

Observamos que C es un cono que contiene a D (basta tomar $\alpha = 1$). Por lo tanto, si demostramos que C es convexo, C será un cono convexo que contiene a D , de donde la inclusión $\text{cone } D \subset C$ será obvia por la Definición 3.2.

Sean $d^1 \in C, d^2 \in C$, es decir, $d^i = \alpha_i x^i, \alpha_i \in \mathbb{R}_+, x^i \in D, i = 1, 2$. Sea $d = td^1 + (1-t)d^2 = t\alpha_1 x^1 + (1-t)\alpha_2 x^2$, con $t \in [0, 1]$. Cuando $t \in \{0, 1\}$ o $\alpha_i = 0$ para algún $i \in \{1, 2\}$, la inclusión $d \in C$ es obvia. Supongamos entonces que $t \in (0, 1), \alpha_i > 0, i = 1, 2$. Definimos:

$$\beta = \left(1 + \frac{\alpha_2(1-t)}{\alpha_1 t}\right)^{-1} \in (0, 1).$$

Por la convexidad de D , tenemos que $x = \beta x^1 + (1-\beta)x^2 \in D$. Además,

$$\frac{\alpha_1 t}{\beta} x = \alpha_1 t(x^1 + (1/\beta - 1)x^2) = t\alpha_1 x^1 + (1-t)\alpha_2 x^2 = d,$$

mostrando que $d \in C$. Esto prueba que C es convexo. ■

A continuación probaremos un resultado importante sobre el cono tangente de un conjunto convexo.

Teorema 3.1 (Direcciones viables y cono tangente de un conjunto convexo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo, $\bar{x} \in D$. Entonces:

$$\mathcal{V}_D(\bar{x}) = \text{cone}(D - \{\bar{x}\}),$$

$$\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \text{cl } \mathcal{V}_D(\bar{x}) = \text{cl } \text{cone}(D - \{\bar{x}\}).$$

En particular, $\mathcal{T}_D(\bar{x})$ es convexo y cerrado.

Prueba. Es fácil ver que el conjunto $D - \{\bar{x}\}$ es convexo. Por lo tanto, por la Proposición 3.2:

$$\text{cone}(D - \{\bar{x}\}) = \{d \in \mathbb{R}^n \mid d = \alpha(x - \bar{x}), x \in D, \alpha \in \mathbb{R}_+\}. \quad (3.1)$$

Sea $d \in \text{cone}(D - \{\bar{x}\}), d \neq 0$ (luego, $\alpha > 0$). Esto significa que $\bar{x} + d/\alpha = x \in D$. Por la convexidad de D , se sigue que $\bar{x} + td \in D$ para todo $t \in [0, 1/\alpha]$, es decir, $d \in \mathcal{V}_D(\bar{x})$. Recíprocamente, para $d \in \mathcal{V}_D(\bar{x})$ se tiene que $\bar{x} + td \in D$ para todo $t \in [0, \epsilon]$. Por lo tanto, existe $x \in D$ tal que $x = \bar{x} + td, t > 0$. Luego, $d = (x - \bar{x})/t$, es decir, $d \in \text{cone}(D - \{\bar{x}\})$. Así, $\mathcal{V}_D(\bar{x}) = \text{cone}(D - \{\bar{x}\})$.

Como se estableció en el Capítulo 1, siempre se tiene que $\text{cl } \mathcal{V}_D(\bar{x}) \subset \mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$. Probamos la afirmación mostrando que $\mathcal{B}_D(\bar{x}) \subset \text{cl } \mathcal{V}_D(\bar{x})$.

Sea $d \in \mathcal{B}_D(\bar{x})$, es decir, existen $\{t_k\} \rightarrow 0+$ e $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$ para todo k . Como ya mostramos, esto significa que $d^k \in \mathcal{V}_D(\bar{x})$. En particular, concluimos que $d = \lim_{k \rightarrow \infty} d^k \in \text{cl } \mathcal{V}_D(\bar{x})$. ■

A continuación mostramos que un cono y su clausura tienen el mismo cono dual.

Proposición 3.3. Sea $K \subset \mathbb{R}^n$ un cono cualquiera. Entonces $\text{cl } K$ es un cono y se tiene que:

$$K^* = (\text{cl } K)^*.$$

En particular, si $D \subset \mathbb{R}^n$ es un conjunto convexo y $\bar{x} \in D$, se tiene que:

$$(\mathcal{T}_D(\bar{x}))^* = (\mathcal{V}_D(\bar{x}))^* = (\text{cone}(D - \{\bar{x}\}))^*.$$

Prueba. El hecho de que $\text{cl } K$ sea un cono es fácil de verificar. Por la definición de cono dual, la inclusión $K \subset \text{cl } K$ implica que $(\text{cl } K)^* \subset K^*$.

Sean $y \in K^*$ y $d \in \text{cl } K$ cualesquiera. Existe $\{d^k\} \subset K$ tal que $\{d^k\} \rightarrow d$. Tenemos que $\langle y, d^k \rangle \leq 0$ para todo k . Pasando al límite cuando $k \rightarrow \infty$, obtenemos que $\langle y, d \rangle \leq 0$. Por lo tanto, $y \in (\text{cl } K)^*$, es decir, $K^* \subset (\text{cl } K)^*$. Ahora, la última afirmación se sigue del ??.

Otra noción útil en Análisis Convexo es la de cono normal.

Definición 3.3 (Cono normal). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y $\bar{x} \in D$. El **cono normal** (o cono de direcciones normales) en el punto $\bar{x}$ con respecto al conjunto D está dado por:

$$\mathcal{N}_D(\bar{x}) = \{d \in \mathbb{R}^n \mid \langle d, x - \bar{x} \rangle \leq 0 \forall x \in D\}.$$

A continuación, mostramos que, en el caso convexo, el dual del cono tangente es exactamente el cono normal.

Teorema 3.2 (El cono normal es el dual del cono tangente). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y $\bar{x} \in D$. Entonces:

$$(\mathcal{T}_D(\bar{x}))^* = (\mathcal{V}_D(\bar{x}))^* = (\text{cone}(D - \{\bar{x}\}))^* = \mathcal{N}_D(\bar{x}).$$

Prueba. Las primeras dos igualdades ya fueron probadas en la Proposición 3.3. Supongamos que $y \in (\text{cone}(D - \{\bar{x}\}))^*$, es decir, $\langle y, d \rangle \leq 0$ para todo $d \in \text{cone}(D - \{\bar{x}\})$. En particular, $\langle y, x - \bar{x} \rangle \leq 0$ para todo $x \in D$, es decir, $y \in \mathcal{N}_D(\bar{x})$. Supongamos que $y \in \mathcal{N}_D(\bar{x})$. Tenemos que $\langle y, x - \bar{x} \rangle \leq 0$ para todo $x \in D$, es decir, $\langle y, d \rangle \leq 0$ para todo $d \in (D - \{\bar{x}\})$. Luego, $\langle y, d \rangle \leq 0$ para todo $d \in \text{cone}(D - \{\bar{x}\})$. Concluimos que $y \in (\text{cone}(D - \{\bar{x}\}))^*$. ■

Como consecuencia de la caracterización del cono tangente y de su dual, obtenemos las siguientes condiciones de optimalidad para un problema con conjunto factible convexo.

Teorema 3.3 (Condición necesaria de primer orden). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $\bar{x} \in D$. Si $\bar{x}$ es un minimizador local de f en el conjunto D , entonces:

$$\langle f'(\bar{x}), x - \bar{x} \rangle \geq 0 \quad \forall x \in D, \quad (3.2)$$

o, equivalentemente,

$$-f'(\bar{x}) \in \mathcal{N}_D(\bar{x}). \quad (3.3)$$

Prueba. Por las condiciones primales de primer orden del Capítulo 1, $\langle f'(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{B}_D(\bar{x})$. Por el ??, tenemos que:

$$\{d \in \mathbb{R}^n \mid d = x - \bar{x}, x \in D\} \subset \text{cone}(D - \{\bar{x}\}) \subset \mathcal{B}_D(\bar{x}),$$

lo que implica (3.2). Por la Definición 3.3, (3.2) y (3.3) son equivalentes. ■

Si la función f es convexa, la condición necesaria de optimalidad dada en el Teorema 3.3 también es suficiente.

Definición 3.4 (Funciones convexas, estrictas y fuertes). Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Se dice que una función $f : D \rightarrow \mathbb{R}$ es **convexa** en D si para cualesquiera $x \in D$, $y \in D$ y $\alpha \in [0, 1]$, se tiene:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y).$$

La función f se dice **estrictamente convexa** cuando la desigualdad anterior es estricta para todos los $x \neq y$ y $\alpha \in (0, 1)$.

La función f se dice **fuertemente convexa** con módulo $\gamma > 0$, cuando para cualesquiera $x, y \in D$ y $\alpha \in [0, 1]$, se tiene:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) - \gamma \alpha(1 - \alpha)\|x - y\|^2.$$

Es obvio que una función fuertemente convexa es estrictamente convexa, y una función estrictamente convexa es convexa. La función $f(x) = x^2$ es fuertemente convexa. La función $f(x) = e^x$ es estrictamente (pero no fuertemente) convexa. Una función afín $f(x) = x$ es convexa (pero no estricta).

Definición 3.5 (Epígrafe). El **epígrafe** de la función $f : D \rightarrow \mathbb{R}$ es el conjunto:

$$E_f = \{(x, c) \in D \times \mathbb{R} \mid f(x) \leq c\}.$$

La relación entre convexidad de conjuntos y de funciones está dada por el siguiente teorema.

Teorema 3.4 (El epígrafe caracteriza la convexidad). Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Una función $f : D \rightarrow \mathbb{R}$ es convexa en D si, y solo si, el epígrafe de f es un conjunto convexo en $\mathbb{R}^n \times \mathbb{R}$.

Prueba. Supongamos primero que E_f es convexo. Sean $x \in D$ y $y \in D$ cualesquiera. Obviamente, $(x, f(x)) \in E_f$ y $(y, f(y)) \in E_f$. Por la convexidad de E_f , para todo $\alpha \in [0, 1]$ tenemos que:

$$\alpha(x, f(x)) + (1 - \alpha)(y, f(y)) \in E_f.$$

Por la definición de epígrafe, esto es equivalente a decir que $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$, es decir, f es convexa.

Supongamos ahora que f es convexa. Sean $(x, c_1) \in E_f$ y $(y, c_2) \in E_f$. Como $f(x) \leq c_1$ y $f(y) \leq c_2$, por la convexidad de f , para todo $\alpha \in [0, 1]$ se tiene $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) \leq \alpha c_1 + (1 - \alpha)c_2$, lo que significa que $(\alpha x + (1 - \alpha)y, \alpha c_1 + (1 - \alpha)c_2) \in E_f$, es decir, E_f es convexo. ■

Decimos que $\min_{x \in D} f(x)$ es un **problema de minimización convexo** cuando $D \subset \mathbb{R}^n$ es un conjunto convexo y $f : D \rightarrow \mathbb{R}$ es una función convexa. La importancia de la convexidad se puede ver en el siguiente resultado.

Teorema 3.5 (Teorema de minimización convexo). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y $f : D \rightarrow \mathbb{R}$ una función convexa en D . Entonces todo minimizador local del problema es global. Además, el conjunto de minimizadores es convexo. Si f es estrictamente convexa, no puede haber más de un minimizador.

Prueba. Supongamos que $\bar{x} \in D$ sea un minimizador local que no es global. Entonces existe $y \in D$ tal que $f(y) < f(\bar{x})$. Definimos $x(\alpha) = \alpha y + (1 - \alpha)\bar{x}$. Por la convexidad de D , $x(\alpha) \in D$ para todo $\alpha \in (0, 1)$. Por la convexidad de f , para todo $\alpha \in (0, 1)$, se tiene:

$$f(x(\alpha)) \leq \alpha f(y) + (1 - \alpha)f(\bar{x}) = f(\bar{x}) + \alpha(f(y) - f(\bar{x})) < f(\bar{x}).$$

Tomando $\alpha > 0$ suficientemente pequeño, $x(\alpha)$ está arbitrariamente próximo al punto $\bar{x}$, y aun así $f(x(\alpha)) < f(\bar{x})$. Esto contradice el hecho de que $\bar{x}$ es un minimizador local.

Sea $S \subset D$ el conjunto de los minimizadores (globales) e $\bar{v} \in \mathbb{R}$ el valor óptimo. Para cualesquiera $x, \bar{x} \in S$ y $\alpha \in [0, 1]$, por la convexidad de f obtenemos $f(\alpha x + (1 - \alpha)\bar{x}) \leq \alpha \bar{v} + (1 - \alpha)\bar{v} = \bar{v}$, lo que implica que de hecho $f(\alpha x + (1 - \alpha)\bar{x}) = \bar{v}$, por lo tanto, la combinación convexa pertenece a S . Luego S es convexo.

Si f es estrictamente convexa y existieran $x, \bar{x} \in S$ distintos, entonces para $\alpha \in (0, 1)$:

$$f(\alpha x + (1 - \alpha)\bar{x}) < \alpha f(x) + (1 - \alpha)f(\bar{x}) = \bar{v},$$

lo que resulta en una contradicción. Concluimos que en este caso el minimizador es único. ■

Definición 3.6 (Función cóncava). Si $D \subset \mathbb{R}^n$ es un conjunto convexo, decimos que una función $f : D \rightarrow \mathbb{R}$ es una **función cóncava** en D , cuando la función $(-f)$ es convexa en D .

Es fácil ver que las afirmaciones del Teorema 3.5 son verdaderas si sustituimos la minimización de una función convexa por la maximización de una función cóncava.

3.2. Conjuntos convexos y Teoremas de Separación

Estudiaremos los conjuntos convexos con más profundidad, abarcando la estructura de conjuntos, la proyección ortogonal y la separación mediante hiperplanos.

3.2.1. Propiedades básicas de conjuntos convexos

Proposición 3.4. Sean $D_i \subset \mathbb{R}^n$, $i \in I$, conjuntos convexos, donde I es un conjunto cualquiera (posiblemente infinito). Entonces la intersección $D = \bigcap_{i \in I} D_i$ también es un conjunto convexo.

Prueba. Sean $x \in D$ e $y \in D$. Por la definición de intersección, $x \in D_i$ e $y \in D_i$ para todo $i \in I$. Como los conjuntos D_i son convexos, $\alpha x + (1 - \alpha)y \in D_i$ para todo $i \in I$. Por la definición de la intersección, se sigue que la combinación convexa pertenece a D , es decir, D es convexo. ■

Corolario 3.1. Un conjunto poliédrico en $\mathbb{R}^n$ es convexo.

Prueba. Un conjunto poliédrico es el conjunto de soluciones de un sistema finito de ecuaciones e inecuaciones lineales, es decir, una intersección de semiespacios e hiperplanos que son conjuntos convexos. Por lo tanto, un conjunto poliédrico es convexo por la Proposición 3.4. ■

A continuación mostramos que la clausura y el interior de un conjunto convexo son conjuntos convexos.

Proposición 3.5. Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Entonces $\text{cl } D$ e $\text{int } D$ son conjuntos convexos.

Prueba. Sean $x, y \in \text{cl } D$, $\alpha \in [0, 1]$. Elegimos secuencias $\{x^k\}, \{y^k\} \subset D$ tales que $\{x^k\} \rightarrow x$ e $\{y^k\} \rightarrow y$. Por la convexidad de D , $\alpha x^k + (1 - \alpha)y^k \in D$. Pasando al límite obtenemos que $\alpha x + (1 - \alpha)y \in \text{cl } D$.

Sean $x, y \in \text{int } D$. Fijamos $\epsilon > 0$ tal que $B(x, \epsilon) \subset D$ y $B(y, \epsilon) \subset D$. Para mostrar que $z = \alpha x + (1 - \alpha)y \in \text{int } D$, tomamos un vector q con $\|q\| \leq \epsilon$. Observamos que $z + q = \alpha(x + q) + (1 - \alpha)(y + q)$. Obviamente, $x + q \in B(x, \epsilon) \subset D$ e $y + q \in B(y, \epsilon) \subset D$. Por la convexidad, concluimos que $z + q \in D$. Por lo tanto, $B(z, \epsilon) \subset D$, lo que significa que $z \in \text{int } D$. ■

Proposición 3.6. Sean $D_i \subset \mathbb{R}^n$, $i = 1, 2$, conjuntos convexos cerrados. Si uno de ellos también es acotado (luego, compacto), entonces la suma de Minkowski $D_1 + D_2$ es convexa y cerrada.

Prueba. Es fácil ver que el conjunto $D = D_1 + D_2$ es convexo. Mostraremos que D es cerrado, suponiendo que D_2 sea acotado.

Sea $\{x^k\} \rightarrow x$, con $x^k \in D$. Para todo k existen $x^{k,1} \in D_1$ e $x^{k,2} \in D_2$ tales que $x^k = x^{k,1} + x^{k,2}$. Es claro que la secuencia $\{x^{k,2}\}$ es acotada. Como la secuencia de la suma converge, se sigue que $\{x^{k,1}\}$ también es acotada. Luego, tiene un punto de acumulación, digamos $\bar{x}^1$. Sea $\{x^{k_j,1}\} \rightarrow \bar{x}^1$. Podemos admitir que $\{x^{k_j,2}\} \rightarrow \bar{x}^2$, eligiendo una subsecuencia si es necesario. Como D_1 y D_2 son cerrados, $\bar{x}^1 \in D_1$ y $\bar{x}^2 \in D_2$. Por lo tanto, $x = \bar{x}^1 + \bar{x}^2 \in D_1 + D_2 = D$, lo que muestra que D es cerrado. ■

Observamos que para D_1 y D_2 convexos y cerrados es posible que $D_1 + D_2$ no sea cerrado si ambos son no acotados (por ejemplo, si D_1 es el eje x_1 y D_2 es el epígrafe de $1/x_1$).

Definición 3.7 (Combinación convexa). Dados $x^i \in \mathbb{R}^n$, $\alpha_i \in [0, 1]$, $i = 1, \dots, p$, tales que $\sum_{i=1}^p \alpha_i = 1$, el punto $\sum_{i=1}^p \alpha_i x^i$ se llama **combinación convexa** de los puntos $x^i \in \mathbb{R}^n$ con parámetros α_i .

Teorema 3.6 (Caracterización por combinaciones convexas). Un conjunto $D \subset \mathbb{R}^n$ es convexo si, y solo si, para cualesquiera $p \in \mathbb{N}$, $x^i \in D$ y $\alpha_i \in [0, 1]$ tales que $\sum_{i=1}^p \alpha_i = 1$, la combinación convexa $\sum_{i=1}^p \alpha_i x^i$ pertenece a D .

Prueba. Si D contiene todas las combinaciones convexas de sus puntos, en particular contiene las combinaciones de dos puntos, luego D es convexo. Supongamos que D sea convexo. La prueba se realiza por inducción en p . Para $p = 1$ es trivial. Supongamos que vale para $j \geq 1$ puntos y consideremos $p = j + 1$. Sea $x = \sum_{i=1}^{j+1} \alpha_i x^i$. Si $\alpha_{j+1} = 1$, entonces $x = x^{j+1} \in D$. Si $\alpha_{j+1} \in [0, 1)$, escribimos

$$x = (1 - \alpha_{j+1})y + \alpha_{j+1}x^{j+1}, \quad (3.4)$$

donde $y = \sum_{i=1}^j \frac{\alpha_i}{1 - \alpha_{j+1}} x^i$. Como los coeficientes de y suman 1, $y \in D$ por hipótesis de inducción. Luego, (3.4) muestra que x es una combinación convexa de dos puntos de D , por lo que $x \in D$. ■

Corolario 3.2 (Desigualdad de Jensen). Sean $D \subset \mathbb{R}^n$ un conjunto convexo y $f : D \rightarrow \mathbb{R}$ una función convexa en D . Entonces para cualesquiera $p \in \mathbb{N}$, $x^i \in D$ y $\alpha_i \in \mathbb{R}_+$ tales que $\sum_{i=1}^p \alpha_i = 1$, se tiene que:

$$f\left(\sum_{i=1}^p \alpha_i x^i\right) \leq \sum_{i=1}^p \alpha_i f(x^i). \quad (3.5)$$

Prueba. Por la definición de epígrafe, $(x^i, f(x^i)) \in E_f$. Por la convexidad de f , E_f es un conjunto convexo en $\mathbb{R}^n \times \mathbb{R}$ (Teorema 3.4). Por el Teorema 3.6, la combinación convexa pertenece a E_f :

$$\left(\sum_{i=1}^p \alpha_i x^i, \sum_{i=1}^p \alpha_i f(x^i)\right) = \sum_{i=1}^p \alpha_i (x^i, f(x^i)) \in E_f.$$

Usando la definición de epígrafe, obtenemos la ecuación (3.5). ■

Teorema 3.7 (Teorema de Carathéodory). Sea $x \in \mathbb{R}^n$ una combinación convexa de puntos del conjunto $D \subset \mathbb{R}^n$. Entonces existen $x^i \in D$ y $\alpha_i \in \mathbb{R}_+$, $i = 1, \dots, n + 1$, tales que $x = \sum_{i=1}^{n+1} \alpha_i x^i$ y $\sum_{i=1}^{n+1} \alpha_i = 1$.

Prueba. Supongamos que x es una combinación convexa de $p > n + 1$ puntos: $x = \sum_{i=1}^p \beta_i x^i$, con $\sum \beta_i = 1$ y $\beta_i > 0$. Como $p > n + 1$, los $p - 1$ vectores $\{x^i - x^p\}$ son linealmente dependientes, es decir, existen γ_i (no todos nulos) tales que $0 = \sum_{i=1}^{p-1} \gamma_i (x^i - x^p)$. Definiendo $\gamma_p = -\sum_{i=1}^{p-1} \gamma_i$, obtenemos $\sum_{i=1}^p \gamma_i = 0$ y $\sum_{i=1}^p \gamma_i x^i = 0$. Podemos admitir que algún $\gamma_j > 0$. Sea j el índice que maximiza la relación γ_i/β_i . Definimos $q_i = \beta_i - (\beta_j/\gamma_j)\gamma_i$. Por construcción, $q_j = 0$, $q_i \geq 0$, $\sum q_i = 1$ y $\sum q_i x^i = x$. Hemos expresado x como una combinación convexa de $p - 1$ puntos. Repitiendo este proceso, llegamos a $n + 1$ puntos. ■

Definición 3.8 (Cierre convexo o envoltura convexa). Sea $D \subset \mathbb{R}^n$ un conjunto cualquiera. El **cierre convexo** de D , denotado por $\text{conv } D$, es el menor conjunto convexo en $\mathbb{R}^n$ que contiene a D (o la intersección de todos los conjuntos convexos que contienen a D).

Proposición 3.7. El cierre convexo $\text{conv } D$ es el conjunto de todas las combinaciones convexas de puntos de D .

Prueba. Sea C el conjunto de todas las combinaciones convexas. Como $\text{conv } D$ es convexo y contiene a D , por el Teorema 3.6 debe contener a C , luego $C \subset \text{conv } D$. Por otro lado, es fácil demostrar que C es convexo (la combinación convexa de dos combinaciones convexas sigue siendo una combinación convexa cuyos coeficientes suman 1). Como $D \subset C$ y C es convexo, $\text{conv } D \subset C$. ■

Proposición 3.8. Sea $D \subset \mathbb{R}^n$ un conjunto compacto. Entonces $\text{conv } D$ es compacto.

Prueba. Primero mostraremos que $\text{conv } D$ es acotado. Todo $x \in \text{conv } D$ es una combinación convexa $\sum \alpha_i x^i$. Por la desigualdad triangular, $\|x\| \leq \sum \alpha_i \|x^i\| \leq \sup_{y \in D} \|y\| < +\infty$.

Para ver que es cerrado, sea $\{y^k\} \rightarrow y$ con $y^k \in \text{conv } D$. Por el Teorema 3.7, $y^k = \sum_{i=1}^{n+1} \alpha_{k,i} x^{k,i}$. Por compacidad, las secuencias $\{x^{k,i}\}$ y $\{\alpha_{k,i}\}$ son acotadas. Pasando a una subsecuencia convergente, los límites $x^i \in D$ y $\alpha_i \geq 0$ satisfacen $\sum \alpha_i = 1$ y $y = \sum \alpha_i x^i \in \text{conv } D$. ■

Proposición 3.9. Sea $K \subset \mathbb{R}^n$ un cono cualquiera. Se tiene:

$$K^* = (\text{cl } K)^* = (\text{conv } K)^*.$$

Prueba. La primera igualdad ya fue establecida en la Proposición 3.3. $\text{conv } K$ es un cono. De la inclusión $K \subset \text{conv } K$ obtenemos $(\text{conv } K)^* \subset K^*$. Si $y \in K^*$, para cualquier $d = \sum \alpha_i d^i \in \text{conv } K$ con $d^i \in K$, se tiene $\langle y, d \rangle = \sum \alpha_i \langle y, d^i \rangle \leq 0$. Luego $K^* \subset (\text{conv } K)^*$. ■

3.2.2. Cono de Recesión y Generadores Finitos

Definición 3.9 (Dirección de recesión). Decimos que $d \in \mathbb{R}^n$ es una **dirección de recesión** del conjunto convexo $D \subset \mathbb{R}^n$ cuando:

$$x + td \in D \quad \forall x \in D, \forall t \in \mathbb{R}_+.$$

Denotamos por $\mathcal{R}_D$ el **cono de recesión**.

Proposición 3.10 (Cono de recesión de un conjunto convexo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo, cerrado y no vacío. Entonces:

- (a) $\mathcal{R}_D$ es un cono convexo, cerrado y no vacío.
- (b) $d \in \mathcal{R}_D$ si, y solo si, existe $x \in D$ tal que $x + td \in D$ para todo $t \in \mathbb{R}_+$.
- (c) $\mathcal{R}_D \neq \{0\}$ si, y solo si, D es ilimitado.

Prueba. (a) Es obvio que $0 \in \mathcal{R}_D$. Si $d^1, d^2 \in \mathcal{R}_D$ y $\alpha \in [0, 1]$, para $x \in D$ y $t \geq 0$, $x + t(\alpha d^1 + (1 - \alpha)d^2) = \alpha(x + td^1) + (1 - \alpha)(x + td^2) \in D$, por lo que es convexo. La cerradura sigue por la cerradura de D .
 (b) Si existe $\bar{x}$ tal que $\bar{x} + td \in D$ para todo t , para cualquier otro $x \in D$ definimos $d^k = \frac{\|d\|}{\|x^k - \bar{x}\|}(x^k - \bar{x})$ donde $x^k = x + ktd \in D$. Se puede demostrar (tomando convexidad con $\bar{x} + td^k$) que en el límite $x + td \in D$.
 (c) Si D contiene una semirrecta, es ilimitado. Si D es ilimitado, tomamos una secuencia $\|x^k - x\| \rightarrow \infty$. Los vectores normalizados $d^k = (x^k - x)/\|x^k - x\|$ tienen un punto de acumulación $d \neq 0$. Por convexidad, $x + td^k \in D$ para k grande. En el límite $x + td \in D$, luego $d \in \mathcal{R}_D$. ■

Definición 3.10 (Cono con número finito de generadores). Un cono $K \subset \mathbb{R}^n$ tiene un **número finito de generadores** cuando existen $a^1, \dots, a^p \in \mathbb{R}^n$ tales que $K = \text{cone}\{a^i, i = 1, \dots, p\}$.

Proposición 3.11. Sean $a^i \in \mathbb{R}^n, i = 1, \dots, p$. Se tiene que:

$$\text{cone}\{a^i, i = 1, \dots, p\} = \left\{ x \in \mathbb{R}^n \mid x = \sum_{i=1}^p \mu_i a^i, \mu_i \geq 0, i = 1, \dots, p \right\}. \quad (3.6)$$

Prueba. Sea C el lado derecho de (3.6). C es un cono convexo y contiene los a^i , por lo que $\text{cone}\{a^i\} \subset C$. Por otro lado, cualquier $x \in C$ con $\sum \mu_i > 0$ se puede escribir como $(\sum \mu_i) \sum \beta_i a^i$, donde $\beta_i = \mu_i / \sum \mu_i$ suman 1. Así, x es un múltiplo positivo de una combinación convexa de los a^i , por lo que $x \in \text{cone}(\text{conv}\{a^i\}) = \text{cone}\{a^i\}$. Luego $C \subset \text{cone}\{a^i\}$. ■

Lema 3.1. Cualquier cono que tiene un número finito de generadores es convexo y cerrado.

Prueba. Se prueba por inducción en p . Para $p = 1$ es una semirrecta cerrada (o $\{0\}$). Para $p + 1$, o bien el cono es un subespacio (que es cerrado), o existe un generador que no puede ser negado dentro del cono. En ese caso, se descompone como $K_{p+1} = K_p + \text{cone}\{a^{p+1}\}$. Resolviendo un problema de minimización sobre la intersección compacta, se acotan los coeficientes y se asegura que el límite de secuencias convergentes pertenece al cono. ■

Definición 3.11 (Cono poliédrico). Decimos que un cono $K \subset \mathbb{R}^n$ es **poliédrico** si es el conjunto de soluciones de un sistema lineal homogéneo: $K = \{x \in \mathbb{R}^n \mid Q_1 x \leq 0, Q_2 x = 0\}$.

Teorema 3.8 (Teorema de Minkowski-Weyl). Un cono $K \subset \mathbb{R}^n$ tiene un número finito de generadores si, y solamente si, K es un cono poliédrico.

3.2.3. El operador de proyección

Teorema 3.9 (Teorema de la Proyección). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado. Para todo $x \in \mathbb{R}^n$, la proyección $P_D(x)$ existe y es única. Además, $\bar{x} = P_D(x)$ si, y solamente si,

$$\bar{x} \in D, \quad \langle x - \bar{x}, y - \bar{x} \rangle \leq 0 \quad \forall y \in D, \quad (3.7)$$

o, equivalentemente, $x - \bar{x} \in \mathcal{N}_D(\bar{x})$.

Prueba. Si $\bar{x}$ resuelve la proyección, para cualquier $y \in D$, el punto $x(\alpha) = (1 - \alpha)\bar{x} + \alpha y \in D$ para $\alpha \in [0, 1]$. Desarrollando $\|x - \bar{x}\|^2 \leq \|x - x(\alpha)\|^2$, dividiendo por α y tomando el límite, se obtiene $\langle x - \bar{x}, y - \bar{x} \rangle \leq 0$.

Si se cumple (3.7), entonces $\|x - y\|^2 = \|x - \bar{x}\|^2 + \|y - \bar{x}\|^2 - 2\langle x - \bar{x}, y - \bar{x} \rangle \geq \|x - \bar{x}\|^2$. Luego $\bar{x}$ minimiza la distancia. Si existiera $\hat{x}$ otra proyección, $\langle x - \bar{x}, \hat{x} - \bar{x} \rangle \leq 0$ y $\langle x - \hat{x}, \bar{x} - \hat{x} \rangle \leq 0$. Sumando obtenemos $-\|\hat{x} - \bar{x}\|^2 \geq 0$, de donde $\hat{x} = \bar{x}$. ■

Corolario 3.3 (Operador de proyección no expansivo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado. Entonces $\forall x, y \in \mathbb{R}^n$:

$$\|P_D(x) - P_D(y)\| \leq \|x - y\|. \quad (3.8)$$

Prueba. Evaluando (3.7) dos veces y sumando, se obtiene $\|P_D(x) - P_D(y)\|^2 \leq \langle x - y, P_D(x) - P_D(y) \rangle$. Aplicando Cauchy-Schwarz, se deduce (3.8). ■

3.2.4. Teoremas de Separación

Definición 3.12 (Hiperplano de separación). El hiperplano $H(a, c) = \{x \in \mathbb{R}^n \mid \langle a, x \rangle = c\}$ separa los conjuntos D_1 y D_2 si:

$$\langle a, x^1 \rangle \leq c \leq \langle a, x^2 \rangle \quad \forall x^1 \in D_1, \forall x^2 \in D_2.$$

La separación es **estricta** cuando las desigualdades son estrictas.

Lema 3.2 (Lema de Minkowski). Sea $D \subset \mathbb{R}^n$ un conjunto convexo no vacío. Si $x \notin \text{cl } D$, entonces existen $a \in \mathbb{R}^n \setminus \{0\}$ y $c \in \mathbb{R}$ tales que:

$$\langle a, x \rangle = c, \quad \langle a, y \rangle > c \quad \forall y \in D.$$

Prueba. Sea $\bar{x} = P_{\text{cl } D}(x)$. Definimos $a = \bar{x} - x \neq 0$ y $c = \langle \bar{x} - x, x \rangle$. Para $y \in D$, por el Teorema 3.9, $\langle a, y \rangle = \langle \bar{x} - x, y \rangle \geq \langle \bar{x} - x, \bar{x} \rangle = c + \|\bar{x} - x\|^2 > c$. ■

Lema 3.3 (Separación en la frontera). Si $x \in \text{fr } D$, entonces existe un **hiperplano de soporte**: $a \in \mathbb{R}^n \setminus \{0\}$ tal que $\langle a, x \rangle = c$ y $\langle a, y \rangle \geq c$ para todo $y \in D$.

Prueba. Tomamos $\{x^k\} \rightarrow x$ con $x^k \notin \text{cl } D$. Por el Lema 3.2, existen a^k (normalizados) y c_k . Extraemos una subsucesión convergente $\{a^k\} \rightarrow a \neq 0$. En el límite, se cumple la separación. ■

Teorema 3.10 (Teorema de Separación). Sean $D_1, D_2 \subset \mathbb{R}^n$ conjuntos convexos disjuntos. Existen $a \in \mathbb{R}^n \setminus \{0\}$ y $c \in \mathbb{R}$ tales que $\langle a, x^1 \rangle \leq c \leq \langle a, x^2 \rangle$ para todo $x^1 \in D_1, x^2 \in D_2$.

Prueba. El conjunto $D = D_2 - D_1$ es convexo y $0 \notin D$. Si $0 \notin \text{cl } D$, aplicamos el Lema 3.2; si $0 \in \text{fr } D$, aplicamos el Lema 3.3. En ambos casos, existe $a \neq 0$ tal que $\langle a, x^2 - x^1 \rangle \geq 0$. Elegimos $c = (\sup_{D_1} \langle a, x^1 \rangle + \inf_{D_2} \langle a, x^2 \rangle)/2$. ■

Teorema 3.11 (Teorema de Separación Estricta). Sean $D_1, D_2 \subset \mathbb{R}^n$ convexos, cerrados y no vacíos, con uno de ellos compacto. Entonces $D_1 \cap D_2 = \emptyset$ si, y solamente si, pueden ser separados estrictamente.

Prueba. Sea D_2 compacto. La función distancia $\text{dist}(x, D_1)$ alcanza su mínimo en D_2 en un punto a^2 . Sea $a^1 = P_{D_1}(a^2)$. Como son disjuntos, $a = a^2 - a^1 \neq 0$. Usando propiedades de proyección para a^1 y a^2 , se demuestra que $\langle a, x^1 \rangle \leq \langle a, a^1 \rangle < \langle a, a^2 \rangle \leq \langle a, x^2 \rangle$, permitiendo una separación estricta con c en el punto medio. ■

Proposición 3.12. Sea $K \subset \mathbb{R}^n$ un cono cualquiera. Se tiene:

$$(K^*)^* = \text{cl conv } K.$$

Si D es convexo y $\bar{x} \in D$, $(\mathcal{N}_D(\bar{x}))^* = \mathcal{T}_D(\bar{x})$.

Prueba. Por definición, $\text{cl conv } K \subset (K^*)^*$. Si $x \notin \text{cl conv } K$, por separación estricta (Teorema 3.11), existe $a \neq 0$ tal que $\langle a, x \rangle > c > \langle a, d \rangle$ para todo $d \in \text{cl conv } K$. Tomando $d = 0$ resulta $c > 0$, por lo que $\langle a, x \rangle > 0$. Para $d \in K$, se deduce que $\langle a, d \rangle \leq 0$ (de lo contrario la semirrecta rompería la cota c). Así, $a \in K^*$, lo que muestra que $x \notin (K^*)^*$. La última afirmación sigue de identificar $\mathcal{N}_D(\bar{x}) = \mathcal{T}_D(\bar{x})^*$. ■

3.2.5. Puntos Extremos

Definición 3.13 (Punto extremo). Decimos que $x \in D$ es un **punto extremo** del conjunto convexo D cuando no puede ser representado por una combinación convexa de dos puntos diferentes de D (es decir, $x = \alpha x^1 + (1 - \alpha)x^2 \implies x = x^1 = x^2$). Denotamos el conjunto por $E(D)$.

Lema 3.4. Sea $D \subset \mathbb{R}^n$ un conjunto convexo no vacío y C un semiespacio cerrado tal que $D \subset C$. Entonces $E(D \cap \text{fr } C) \subset E(D)$.

Prueba. Sea $\bar{x} \in E(D \cap \text{fr } C)$. Si $\bar{x} = \alpha x^1 + (1 - \alpha)x^2$ para $x^i \in D$, evaluando el producto interno que define el hiperplano $\text{fr } C$ se deduce que ambos x^i deben yacer exactamente en la frontera, forzando a que $x^i \in D \cap \text{fr } C$, y por la extremidad relativa, $x^1 = x^2$. ■

Proposición 3.13. Sea $D \subset \mathbb{R}^n$ convexo, cerrado y no vacío. D tiene puntos extremos ($E(D) \neq \emptyset$) si, y solamente si, D no contiene ninguna recta.

Prueba. Si D contiene una recta que pasa por x , x se puede escribir como el punto medio de $x + d$ y $x - d$, por lo que no es extremo. El recíproco se demuestra por inducción en la dimensión n , interceptando el conjunto con hiperplanos de soporte y utilizando el Lema 3.4. ■

Teorema 3.12 (Teorema de Krein-Milman). Sea $D \subset \mathbb{R}^n$ un conjunto convexo compacto. Entonces:

$$D = \text{conv } E(D).$$

Prueba. Por inducción en n . Para $n = 1$ es obvio. Supongamos válido en $\mathbb{R}^n$. Para $D \subset \mathbb{R}^{n+1}$, si $\bar{x} \in \text{fr } D$, el hiperplano de soporte reduce la dimensión del problema, y por hipótesis inductiva y el Lema 3.4, $\bar{x}$ se forma por extremos de D . Si $\bar{x} \in \text{int } D$, cualquier recta que pase por $\bar{x}$ corta a la frontera en dos puntos (por compacidad); como $\bar{x}$ es combinación convexa de ellos, queda probado. ■

Proposición 3.14. Sea $x \in D$, donde $D = \{x \in \mathbb{R}^n \mid B_i x \leq b_i\}$ es un conjunto poliédrico. Entonces x es un vértice (punto extremo) de D si, y solamente si, las filas correspondientes a las restricciones activas ($I(x)$) tienen rango n .

Prueba. Si el rango es n , una perturbación $x \pm d$ viola las restricciones activas salvo que $d = 0$. Si el rango es menor que n , existe $d \in \ker B_I \setminus \{0\}$. Un desplazamiento $x \pm td$ se mantiene en la cara activa, demostrando que x no es extremo. ■

Corolario 3.4. El número de vértices de un conjunto poliédrico cualquiera es finito.

Teorema 3.13 (Representación de conjuntos poliédricos sin rectas). Sea D un conjunto poliédrico que no contiene ninguna recta. Entonces:

$$D = \text{conv } E(D) + \mathcal{R}_D.$$

3.3. Teoremas de alternativa

A continuación, consideramos sistemas de ecuaciones e inecuaciones lineales, relacionados en el sentido de que existen dos alternativas: si un sistema no posee soluciones, entonces el otro posee soluciones, y ambos sistemas no pueden poseer soluciones simultáneamente. Un resultado de este tipo será usado para caracterizar el cono dual del cono tangente en el caso de restricciones mixtas de igualdad y desigualdad y para formular las condiciones de optimalidad en forma primal-dual para problemas con este tipo de restricciones.

Teorema 3.14 (Teorema de la Alternativa de Motzkin). Para cualesquiera matrices $A_i \in \mathbb{R}^{m_i \times n}$, $i = 0, 1, 2$, con $A_0 \neq 0$, uno, y solamente uno, de los dos sistemas siguientes posee solución:

$$A_0 x > 0, \quad A_1 x = 0, \quad A_2 x \geq 0, \quad x \in \mathbb{R}^n, \quad (3.9)$$

o

$$\begin{aligned} A_0^T y^0 + A_1^T y^1 + A_2^T y^2 &= 0, \\ (y^0, y^1, y^2) &\in (\mathbb{R}_+^{m_0} \setminus \{0\}) \times \mathbb{R}^{m_1} \times \mathbb{R}_+^{m_2}. \end{aligned} \quad (3.10)$$

Prueba. Primero supongamos que (3.10) tenga una solución (y^0, y^1, y^2) . Si x fuese solución de (3.9), entonces:

$$0 = \langle A_0^T y^0 + A_1^T y^1 + A_2^T y^2, x \rangle = \langle y^0, A_0 x \rangle + \langle y^1, A_1 x \rangle + \langle y^2, A_2 x \rangle \geq \langle y^0, A_0 x \rangle > 0,$$

donde para obtener la primera desigualdad usamos el hecho de que todas las coordenadas de los vectores involucrados son no negativas, y para obtener la segunda usamos además los hechos de que $y_i^0 \geq 0$, $(A_0 x)_i > 0 \forall i$, y para algún índice la coordenada de y^0 es estrictamente positiva. La contradicción muestra que cuando (3.10) tiene solución, (3.9) no puede tenerla.

Supongamos ahora que (3.10) no tenga solución. Es decir,

$$0 \notin \left\{ z \in \mathbb{R}^n \mid \begin{array}{l} z = A_0^T y^0 + A_1^T y^1 + A_2^T y^2, \\ y^0 \in \mathbb{R}_+^{m_0} \setminus \{0\}, y^1 \in \mathbb{R}^{m_1}, y^2 \in \mathbb{R}_+^{m_2} \end{array} \right\}.$$

Como $y^0 \in \mathbb{R}_+^{m_0} \setminus \{0\}$, dividiendo z por $\sum y_i^0 > 0$, vemos que esta propiedad es equivalente a $0 \notin D$, donde $D = D_1 + D_2$, con:

$$D_1 = \left\{ z \in \mathbb{R}^n \mid z = A_0^T y^0, y^0 \in \mathbb{R}_+^{m_0}, \sum_{i=1}^{m_0} y_i^0 = 1 \right\},$$

$$D_2 = \{ z \in \mathbb{R}^n \mid z = A_1^T y^1 + A_2^T y^2, y^1 \in \mathbb{R}^{m_1}, y^2 \in \mathbb{R}_+^{m_2} \}.$$

El conjunto D_1 es la clausura convexa de las columnas de A_0^T (que son finitas), por lo tanto, es compacto. El conjunto D_2 es un cono con un número finito de generadores; por lo tanto, es convexo y cerrado. La suma $D = D_1 + D_2$ es un conjunto convexo y cerrado (al sumar un compacto y un cerrado).

Como $0 \notin D$, por el Teorema de Separación Estricta, existe un hiperplano que separa 0 de D estrictamente; es decir, existe $x \in \mathbb{R}^n \setminus \{0\}$ y $c \in \mathbb{R}$ tales que:

$$\langle x, z \rangle > c > 0 \quad \forall z \in D.$$

Como D_2 es un cono, si existiera $y \in D_2$ tal que $\langle x, y \rangle < 0$, tomando múltiplos grandes contradeciríamos la separación. Así, $\langle x, y \rangle \geq 0$ para todo $y \in D_2$, lo que implica:

$$A_1 x = 0, \quad A_2 x \geq 0.$$

Finalmente, tomando $y^0 = e^i$ (vectores de la base canónica), deducimos que $\langle e^i, A_0 x \rangle > c > 0$, lo que implica $A_0 x > 0$. Hemos hallado una solución para (3.9). ■

El famoso Lema de Farkas se obtiene como una consecuencia del Teorema de Motzkin.

Lema 3.5 (Lema de Farkas). Para cualquier matriz $A \in \mathbb{R}^{m \times n}$ y cualquier $b \in \mathbb{R}^n$, uno, y solamente uno, de los siguientes sistemas posee solución:

$$Ax \leq 0, \quad \langle b, x \rangle > 0, \quad x \in \mathbb{R}^n, \quad (3.11)$$

o

$$A^T y = b, \quad y \in \mathbb{R}_+^m. \quad (3.12)$$

Prueba. Aplicando el Teorema de Motzkin (Teorema 3.14) con las elecciones $A_0 = b^T \in \mathbb{R}^{1 \times n}$ y $A_2 = -A \in \mathbb{R}^{m \times n}$ (y sin matriz A_1), la alternativa a (3.11) es:

$$y^0 b - A^T y^2 = 0, \quad (y^0, y^2) \in (\mathbb{R}_+ \setminus \{0\}) \times \mathbb{R}_+^m.$$

Como $y^0 > 0$, dividiendo por y^0 y llamando $y = y^2/y^0$, obtenemos exactamente el sistema (3.12). ■

El Lema de Farkas ya permite probar las condiciones de optimalidad en forma primal-dual en el caso especial de restricciones de desigualdad lineales.

Corolario 3.5. Sea $\bar{x} \in \mathbb{R}^n$ una solución local del problema $\min f(x)$ sujeto a $Bx \leq b$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es diferenciable en $\bar{x}$, $B \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Entonces existe $\bar{\mu} \in \mathbb{R}_+^m$ tal que

$$\nabla f(\bar{x}) + B^T \bar{\mu} = 0, \quad \bar{\mu}_i = 0 \text{ para } i \notin I(\bar{x}),$$

donde $I(\bar{x}) = \{i \mid \langle B_i, \bar{x} \rangle = b_i\}$.

Prueba. Sea $C = \{d \in \mathbb{R}^n \mid \langle B_i, d \rangle \leq 0, i \in I(\bar{x})\}$. Para todo $d \in C$, se tiene que $B(\bar{x} + td) \leq b$ para todo $t > 0$ suficientemente pequeño, por lo tanto $d \in \mathcal{V}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$. Por el Teorema de la condición necesaria primal, $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in C$.

Es decir, el sistema $\langle \nabla f(\bar{x}), d \rangle < 0, \langle B_i, d \rangle \leq 0$ para $i \in I(\bar{x})$ no tiene solución. Por el Lema de Farkas, el sistema alternativo $(B_{I(\bar{x})})^T \mu = -\nabla f(\bar{x})$ con $\mu \in \mathbb{R}_+^{|I(\bar{x})|}$ tiene solución. Definiendo $\bar{\mu}_i = 0$ para $i \notin I(\bar{x})$, obtenemos el resultado. ■

Nota: Otros Teoremas de Alternativa

Existen otros teoremas clásicos de alternativa que surgen como variantes lógicas del Lema de Farkas y el Teorema de Motzkin, muy útiles en teoría de juegos y economía matemática:

- **Teorema de Tucker:** Los sistemas $Ax \geq 0, Ax \neq 0$ y $A^T y = 0, y > 0$ son mutuamente excluyentes.
- **Teoremas de Gale:** Alternativas puras sobre igualdades/desigualdades (ej. $Ax = b, x \geq 0$ vs $A^T y \geq 0, \langle b, y \rangle < 0$).
- **Teorema de Gordan:** $Ax < 0$ vs $A^T y = 0, y \in \mathbb{R}_+^m \setminus \{0\}$.

(Las demostraciones de estos teoremas se proponen como ejercicios en la sección final de este capítulo).

3.4. Funciones convexas

Ahora estudiaremos funciones convexas con más profundidad. Trataremos la estructura de estas funciones, caracterizaciones para funciones diferenciables, continuidad, y el concepto de subdiferencial para funciones no diferenciables.

3.4.1. Propiedades básicas de las funciones convexas

Mostramos primero que una suma de múltiplos no negativos de un número finito de funciones convexas es convexa, así como el supremo.

Proposición 3.15 (Convexidad de la suma y el supremo). Sea $D \subset \mathbb{R}^n$ un conjunto convexo y sean $f_i : D \rightarrow \mathbb{R}$ funciones convexas en D .

1. Para cualesquiera $\mu_i \in \mathbb{R}_+$, la función $f(x) = \sum_{i=1}^p \mu_i f_i(x)$ es convexa en D .
2. Si I es un conjunto de índices arbitrario (posiblemente infinito) y existe $\beta \in \mathbb{R}$ tal que $f_i(x) \leq \beta$ para todo $x \in D$ e $i \in I$, entonces la función $f(x) = \sup_{i \in I} f_i(x)$ es convexa en D .

Prueba. (1) Para $x, y \in D$ y $\alpha \in [0, 1]$, se tiene $f(\alpha x + (1-\alpha)y) = \sum \mu_i f_i(\alpha x + (1-\alpha)y) \leq \sum \mu_i (\alpha f_i(x) + (1-\alpha)f_i(y)) = \alpha f(x) + (1-\alpha)f(y)$, ya que $\mu_i \geq 0$.

(2) El epígrafe de un supremo de funciones es la intersección de los epígrafes individuales: $E_f = \{(x, c) \mid \sup f_i(x) \leq c\} = \bigcap_{i \in I} \{(x, c) \mid f_i(x) \leq c\} = \bigcap_{i \in I} E_{f_i}$. Al ser f_i convexas, los E_{f_i} son convexos, y la intersección de conjuntos convexos es convexa. Luego, el epígrafe E_f es convexo, lo que implica que f es convexa. ■

Proposición 3.16 (Composición convexa). Sean $g : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa, y $\psi : \mathbb{R} \rightarrow \mathbb{R}$ una función convexa y no decreciente. Entonces la composición $f(x) = \psi(g(x))$ es convexa en $\mathbb{R}^n$.

Prueba. Por convexidad de g y monotonía de ψ , se tiene $\psi(g(\alpha x + (1-\alpha)y)) \leq \psi(\alpha g(x) + (1-\alpha)g(y))$. Luego, por la convexidad de ψ , esto es $\leq \alpha \psi(g(x)) + (1-\alpha)\psi(g(y))$, demostrando la afirmación. ■

A continuación, mostraremos que los conjuntos de nivel de una función convexa son conjuntos convexos.

Teorema 3.15 (Convexidad de conjuntos de nivel). Supongamos que el conjunto $D \subset \mathbb{R}^n$ sea convexo y la función $f : D \rightarrow \mathbb{R}$ sea convexa en D . Entonces el conjunto de nivel

$$L_{f,D}(c) = \{x \in D \mid f(x) \leq c\}$$

es convexo para todo $c \in \mathbb{R}$.

Prueba. Sean $x, y \in L_{f,D}(c)$. Por definición, $f(x) \leq c$ y $f(y) \leq c$. Por convexidad de D y f , para todo $\alpha \in [0, 1]$ se tiene que $f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha)f(y) \leq \alpha c + (1-\alpha)c = c$. Luego $\alpha x + (1-\alpha)y \in L_{f,D}(c)$. ■

Observación. La convexidad de todos los conjuntos de nivel no es suficiente para afirmar que la función es convexa. Las funciones que cumplen la propiedad de tener todos sus conjuntos de nivel convexos se denominan **funciones cuasiconvexas**. Un ejemplo clásico es $f(x) = x^3$ en $\mathbb{R}$, cuyos conjuntos de nivel son intervalos (luego, convexos), pero la función no es convexa.

Teorema 3.16 (Continuidad de funciones convexas). Sean $D \subset \mathbb{R}^n$ un conjunto convexo abierto y $f : D \rightarrow \mathbb{R}$ convexa. Entonces f es localmente Lipschitz-continua en D . En particular, es continua en D .

Nota de Demostración. La prueba formal construye un simplex cerrado (caja) contenido en D en torno a un punto de interés y utiliza la convexidad para acotar superior e inferiormente las variaciones de f , limitando la constante de Lipschitz mediante el valor máximo de la función en los vértices del simplex. (Ver referencias estándar de Análisis Convexo). ■

El siguiente resultado es crucial computacionalmente, ya que garantiza que si un problema fuertemente convexo tiene solución, el conjunto de nivel se mantiene acotado.

Teorema 3.17 (Compacidad del nivel de funciones fuertemente convexas). Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es fuertemente convexa, entonces para todo $c \in \mathbb{R}$, el conjunto de nivel $L_{f,\mathbb{R}^n}(c)$ es compacto.

Corolario 3.6. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ fuertemente convexa y $\emptyset \neq D \subset \mathbb{R}^n$ un conjunto cerrado. Entonces f tiene un minimizador en D . Si D es convexo, el minimizador es único.

Finalizamos esta subsección con resultados de maximización. El problema de maximizar una función convexa sobre un conjunto convexo tiene una naturaleza diferente al de minimización: la solución tiende a ubicarse en la frontera o vértices.

Teorema 3.18 (Maximización de función convexa). Sea $D \subset \mathbb{R}^n$ convexo compacto y $f : D \rightarrow \mathbb{R}$ convexa. Entonces el problema $\max_{x \in D} f(x)$ tiene solución y se alcanza en un **punto extremo** de D (es decir, en $E(D)$).

Además, si D es polédrico y no contiene rectas, el máximo (si existe) se alcanza en un vértice de D .

3.4.2. Funciones convexas diferenciables

Cuando una función es diferenciable, la convexidad admite varias caracterizaciones algebraicas muy útiles.

Teorema 3.19 (Caracterizaciones de convexidad diferenciable). Sean $D \subset \mathbb{R}^n$ abierto y convexo, y $f : D \rightarrow \mathbb{R}$ diferenciable. Las siguientes propiedades son equivalentes:

1. f es convexa en D .
2. (Desigualdad del subgradiente): Para todo $x, y \in D$, $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$.
3. (Monotonía del gradiente): Para todo $x, y \in D$, $\langle \nabla f(y) - \nabla f(x), y - x \rangle \geq 0$.

Si f es dos veces diferenciable en D , las anteriores son equivalentes a:

4. La matriz Hessiana $\nabla^2 f(x)$ es semidefinida positiva en todo punto de D .

Prueba. (1) $\implies$ (2): Por convexidad, $f(x + \alpha(y - x)) \leq (1 - \alpha)f(x) + \alpha f(y)$. Reorganizando: $f(y) - f(x) \geq \frac{f(x + \alpha(y - x)) - f(x)}{\alpha}$. Tomando límite $\alpha \rightarrow 0^+$, el lado derecho es la derivada direccional $\langle \nabla f(x), y - x \rangle$.
 (2) $\implies$ (3): Evaluando (2) intercambiando x e y : $f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle$. Sumando ambas desigualdades se obtiene $0 \geq \langle \nabla f(x), y - x \rangle + \langle \nabla f(y), x - y \rangle$, de donde se deduce (3).
 (3) $\implies$ (1): Por el Teorema del Valor Medio, integrando la monotonía del gradiente en un segmento se deduce que la función yace por encima de cualquier secante. (La equivalencia con la Hessiana sigue de las propiedades clásicas de formas cuadráticas). ■

Observación (Condiciones para fuerte convexidad). Para funciones fuertemente convexas con módulo $\gamma > 0$, las caracterizaciones se adaptan:

- $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \gamma \|y - x\|^2$.
- $\langle \nabla f(y) - \nabla f(x), y - x \rangle \geq 2\gamma \|y - x\|^2$.
- $\langle \nabla^2 f(x)d, d \rangle \geq 2\gamma \|d\|^2$ (es decir, los autovalores de la Hessiana están acotados por 2γ).

Como ya sabemos, en un problema de minimización convexo, todo minimizador local es global. El siguiente teorema muestra que la condición necesaria de primer orden (Teorema 3.1.3) pasa a ser suficiente.

Teorema 3.20 (Condiciones KKT para problema convexo). Sean $D \subset \mathbb{R}^n$ convexo y f convexa y diferenciable en un abierto que contiene a D . Un punto $\bar{x} \in D$ es minimizador global si, y solo si:

$$\langle \nabla f(\bar{x}), x - \bar{x} \rangle \geq 0 \quad \forall x \in D \iff -\nabla f(\bar{x}) \in \mathcal{N}_D(\bar{x}).$$

Prueba. La necesidad ya fue demostrada en el Capítulo 1 (y Teorema 1.2). Para la suficiencia, usamos la caracterización (2) del Teorema 3.19: $f(x) \geq f(\bar{x}) + \langle \nabla f(\bar{x}), x - \bar{x} \rangle$. Si la condición se cumple, el segundo término es ≥ 0 para todo $x \in D$, luego $f(x) \geq f(\bar{x})$, lo que prueba que $\bar{x}$ es mínimo global. ■

3.4.3. Funciones convexas no diferenciables

Cuando una función convexa pierde la diferenciable (por ejemplo, al tomar el supremo de varias funciones), las derivadas clásicas se reemplazan por derivadas direccionales y subdiferenciales.

Teorema 3.21 (Derivada direccional). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. Entonces para todo $x, d \in \mathbb{R}^n$, el límite

$$f'(x; d) = \lim_{\alpha \rightarrow 0^+} \frac{f(x + \alpha d) - f(x)}{\alpha}$$

siempre existe en $\mathbb{R} \cup \{-\infty, +\infty\}$. (Si f es finita, el límite es finito).

Definición 3.14 (Subgradiente y Subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. Decimos que un vector $y \in \mathbb{R}^n$ es un **subgradiente** de f en el punto x si:

$$f(z) \geq f(x) + \langle y, z - x \rangle \quad \forall z \in \mathbb{R}^n. \quad (3.13)$$

Al conjunto de todos los subgradiientes de f en x se le llama **subdiferencial** y se denota por $\partial f(x)$.

Geométricamente, un subgradiente define un hiperplano afín que soporta al epígrafe de f en el punto $(x, f(x))$ y queda por debajo de la gráfica de la función globalmente.

Teorema 3.22 (Propiedades del Subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa finita en todo el espacio.

1. El conjunto $\partial f(x)$ es convexo, compacto y no vacío para todo $x \in \mathbb{R}^n$.
2. $\bar{x}$ es un minimizador global de f en $\mathbb{R}^n$ si, y solo si, $0 \in \partial f(\bar{x})$.
3. Para un conjunto D convexo cerrado, $\bar{x}$ es solución de $\min_{x \in D} f(x)$ si y solo si $0 \in \partial f(\bar{x}) + \mathcal{N}_D(\bar{x})$.
4. (Regla de la suma): Si f_1, f_2 son convexas en $\mathbb{R}^n$, entonces $\partial(f_1 + f_2)(x) = \partial f_1(x) + \partial f_2(x)$.

Prueba. El ítem (2) es inmediato de la definición (3.13): si $0 \in \partial f(\bar{x})$, entonces $f(z) \geq f(\bar{x}) + \langle 0, z - \bar{x} \rangle = f(\bar{x})$, por lo que $\bar{x}$ es óptimo global. Las demás pruebas requieren teoremas de separación que se omiten aquí por brevedad, pero que siguen estándares del análisis convexo de Rockafellar. ■

Teorema 3.23 (Relación entre derivada direccional y subdiferencial). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa. La derivada direccional en x a lo largo de d equivale al máximo del producto interno sobre el subdiferencial:

$$f'(x; d) = \max_{y \in \partial f(x)} \langle y, d \rangle.$$

Finalmente, para el desarrollo de algoritmos de optimización no diferenciable, es útil relajar la noción de subgradiente.

Definición 3.15 (ϵ -subdiferencial). Para $\epsilon \geq 0$, el vector y es un ϵ -subgradiente de f en x si:

$$f(z) \geq f(x) + \langle y, z - x \rangle - \epsilon \quad \forall z \in \mathbb{R}^n.$$

El conjunto de todos los ϵ -subgradiientes se denota $\partial_\epsilon f(x)$. $\bar{x}$ es un ϵ -minimizador del problema si y solo si $0 \in \partial_\epsilon f(\bar{x})$.

Ejercicios del Capítulo

Parte I: Mecánica Primal-Dual y Fallas Topológicas

Ejercicio 3.1. Determinéense los minimizadores y maximizadores globales del funcional lineal $f(x) = \sum_{i=1}^n x_i$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^n \mid \|x\|^2 = 1\}$.

Ejercicio 3.2. Hállense los minimizadores de la función $f(x) = \|x\|^2$ sujetos a las siguientes restricciones:

- (a) El hiperplano afín $h(x) = 1 - \sum_{i=1}^n x_i = 0$.
- (b) La superficie cuádrica $h(x) = 1 - \langle Qx, x \rangle = 0$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica.

Ejercicio 3.3. Verifíquese analíticamente que el punto $\bar{x} = (0, 0) \in \mathbb{R}^2$ es la solución global del problema $\min x_2$ sujeto a la intersección de las circunferencias $(x_1 - 1)^2 + x_2^2 = 1$ y $(x_1 + 1)^2 + x_2^2 = 1$. Demuestre que $\bar{x}$ no cumple con las condiciones de regularidad y que el sistema de Lagrange no admite solución en dicho punto.

Ejercicio 3.4. Demuestre que $\bar{x} = (0, 0) \in \mathbb{R}^2$ es la solución global del problema $\min x_1^2 + x_2^2$ sujeto a la restricción $(x_1 - 1)^3 = x_2^2$, y explique por qué las condiciones de optimalidad de Lagrange no se cumplen en este punto debido a la falta de regularidad (falla de LICQ).

Ejercicio 3.5 (Pérdida de la condición LICQ por reformulación no lineal). Sea el conjunto factible $D = \{x \in \mathbb{R}^n \mid h(x) = 0\}$, donde $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ cumple la condición LICQ en todo punto de D . Considérese el problema de minimización de $f(x)$ sobre D . Supóngase que se reformula el problema utilizando la restricción escalar equivalente: $\tilde{h}(x) = \frac{1}{2} \|h(x)\|^2 = 0$.

1. Demuestre que el nuevo conjunto factible $\tilde{D} = \{x \in \mathbb{R}^n \mid \tilde{h}(x) = 0\}$ coincide con D .
2. Pruebe analíticamente que ningún punto de $\tilde{D}$ cumple la condición de regularidad LICQ para la restricción $\tilde{h}$.
3. Explique por qué el sistema de Lagrange asociado a $\tilde{h}$ no permite identificar los puntos óptimos del problema original, analizando la diferencia entre la representación algebraica y el conjunto geométrico.

Ejercicio 3.6 (El Cilindro y el Plano Tangente). Considérese la superficie descrita por $h(x) = x_1^2 + x_2^2 - x_3 = 0$ (un paraboloide).

1. Evalúe el punto $\bar{x} = (1, 1, 2)^\top$. Demuestre que se cumple LICQ y halle una base ortonormal para el subespacio tangente $\ker J_h(\bar{x})$.
2. Considere la curva parametrizada $x(t) = (\cos t, \sin t, 1)^\top$. Verifique que la curva pertenece a la variedad para todo t , y demuestre que el vector velocidad $x'(0)$ es una combinación lineal de los vectores de la base obtenida en el inciso anterior.

Ejercicio 3.7 (Dependencia Funcional y Conjuntos de Nivel). Sea $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ una función escalar de clase $\mathcal{C}^1$. Considérese el problema de minimizar $f(x)$ sujeto a que el punto pertenezca a una curva de nivel de otra función suave: $h(x) = g(x) - c = 0$. Demuestre que, si el punto $\bar{x}$ es un óptimo regular, entonces las curvas de nivel de f y de g que pasan por $\bar{x}$ son tangentes entre sí en dicho punto. Interprete este resultado geoméricamente usando los gradientes.

Ejercicio 3.8 (Intersección de dimensión mixta y puntos aislados). Sea el conjunto factible en $\mathbb{R}^3$ definido por $h_1(x) = x_1^2 + x_2^2 - x_3 = 0$ y $h_2(x) = x_3 = 0$.

1. Describa geoméricamente el conjunto resultante D .
2. Demuestre que el único punto en D es el origen $(0, 0, 0)^\top$.
3. Calcule la matriz Jacobiana $J_h(0)$. Determine si el origen es un punto regular y analice, desde una perspectiva geométrica y topológica, por qué la intersección de estas restricciones produce un punto aislado en lugar de una curva.

Parte II: Condiciones Diferenciales de Segundo Orden y Matriz KKT

Ejercicio 3.9. Determine los extremos locales y globales de la función $f(x) = x_1^3/3 + x_2$ restringida a la esfera $D = \{x \in \mathbb{R}^2 \mid x_1^2 + x_2^2 = 2\}$.

Ejercicio 3.10 (El Sistema Lineal de Karush-Kuhn-Tucker). Sea el funcional cuadrático generalizado $f(x) = \frac{1}{2}\langle Qx, x \rangle + \langle q, x \rangle$ sujeto a la restricción afín sobreyectiva $Ax = a$. Asumiendo que Q es simétrica y definida positiva, pruébese la unicidad de la solución primal-dual y determínese analíticamente el sistema matricial de bloques (Matriz KKT) que resuelven los vectores x y λ simultáneamente.

Ejercicio 3.11 (No-singularidad Numérica de la Matriz KKT). Generalizando el ejercicio anterior, sea $\bar{x} \in D$ un punto estacionario regular (LICQ) para un problema no lineal de optimización, con multiplicador único $\bar{\lambda}$. Definase el Hessiano $H = \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}) \in \mathbb{R}^{n \times n}$ y el Jacobiano $A = J_h(\bar{x}) \in \mathbb{R}^{l \times n}$. Supóngase que se cumple la condición suficiente de segundo orden estricta: $\langle Hd, d \rangle > 0$ para todo $d \in \ker A \setminus \{0\}$. Demuéstrese que la matriz de bloques KKT:

$$K = \begin{pmatrix} H & A^\top \\ A & 0 \end{pmatrix} \in \mathbb{R}^{(n+l) \times (n+l)}$$

es invertible. (Ayuda: Suponga que $K \begin{pmatrix} d \\ y \end{pmatrix} = 0$, multiplique la primera fila de bloques por $d^\top$ y utilice la condición de positividad sobre el núcleo para deducir que $d = 0$).

Ejercicio 3.12 (Valores Propios como Extremos de Rayleigh). Sea $Q \in \mathbb{R}^{n \times n}$ una matriz simétrica. Utilícese el sistema de optimalidad para encontrar todos los minimizadores y maximizadores de la forma cuadrática $f(x) = \langle Qx, x \rangle$ sobre la esfera unitaria $D = \{x \in \mathbb{R}^n \mid \|x\|^2 = 1\}$. Caracterícese el conjunto de multiplicadores de Lagrange en términos de los autovalores de la matriz Q .

Ejercicio 3.13 (Degeneración de la Condición Necesaria). Considérese el problema $\min f(x) = x_1^4 + x_2^4$ sujeto a $h(x) = x_1 + x_2 = 0$. Verifique analíticamente que $\bar{x} = (0, 0)$ es el minimizador global estricto del problema. Sin embargo, al calcular la matriz Hessiana de la Lagrangiana evaluada sobre el núcleo de la restricción, demuestre que el resultado es la matriz nula. Muestre que cuando las de menor orden se anulan, las aproximaciones cuadráticas no bastan para asegurar la suficiencia analítica de segundo orden.

Ejercicio 3.14 (Descomposición Espectral en Lagrange). Minimice la función $f(x) = x_1^2 + x_2^2 + x_3^2$ sujeta a la restricción no lineal $h(x) = x_1 x_2 x_3 - 1 = 0$.

1. Encuentre todos los puntos estacionarios y sus respectivos multiplicadores de Lagrange.
2. Calcule la matriz Hessiana de la Lagrangiana en dichos puntos.
3. Proyecte la matriz Hessiana sobre el subespacio tangente y utilice el criterio de los autovalores para determinar cuáles puntos son mínimos locales. (Ayuda: Analice la simetría de las coordenadas).

Ejercicio 3.15 (Puntos de Ensiadura Restringidos). Considere el problema $\min x_1 x_2$ sujeto a $x_1 + x_2 = 2$. Demuestre que el único punto estacionario del sistema de Lagrange es $\bar{x} = (1, 1)^T$. Evaluando las condiciones necesarias y suficientes de segundo orden, pruebe que este punto no es un minimizador local, sino que corresponde a un máximo global restringido.

Ejercicio 3.16 (La Matriz Fronteada (Bordered Hessian)). Sea un problema con restricciones afines $Ax = a$. La matriz KKT $K = \begin{pmatrix} H & A^T \\ A & 0 \end{pmatrix}$ es simétrica. Demuestre que, incluso si H es estrictamente definida positiva, la matriz de bloques completa K es siempre indefinida (posee tanto autovalores estrictamente positivos como estrictamente negativos). Este resultado explica por qué los algoritmos de optimización numérica suelen utilizar factorizaciones como LDL^T en lugar de la factorización de Cholesky.

Parte III: Aplicaciones Físicas, Análisis de Sensibilidad y Variedades Matriciales

Ejercicio 3.17 (Precio Sombra y Análisis de Sensibilidad). Considérese el problema parametrizado $\min f(x)$ sujeto a $h(x) = p$, donde $p \in \mathbb{R}^l$ es un vector de perturbaciones de frontera. Sea $\bar{x}$ un mínimo local estricto para el problema nominal ($p = 0$), regular (LICQ) y que satisface las condiciones suficientes de segundo orden con multiplicador único $\bar{\lambda}$. Invocando el Teorema de la Función Implícita sobre el sistema KKT, existe una trayectoria suave de minimizadores locales $x(p)$ con $x(0) = \bar{x}$. Definase la función valor óptimo $v(p) = f(x(p))$. Aplicando la regla de la cadena multivariable y la ecuación estacionaria de Lagrange, demuéstrese rigurosamente que: $\nabla_p v(0) = -\bar{\lambda}$. Interprete este resultado desde una perspectiva geométrica y económica, relacionando el multiplicador de Lagrange con la sensibilidad del valor óptimo frente a variaciones en el término independiente de la restricción.

Ejercicio 3.18 (Problema Isoperimétrico de Herón). Entre todos los triángulos de perímetro fijo $2p > 0$, utilícense las condiciones de optimalidad de Lagrange de primero y segundo orden para demostrar que el triángulo que maximiza el área es el triángulo equilátero. (Ayuda: Modele el problema maximizando el cuadrado del área mediante la fórmula de Herón $f(x, y, z) = p(p-x)(p-y)(p-z)$ sujeto a la restricción afín $x + y + z = 2p$).

Ejercicio 3.19 (Principio de Fermat y la Ley de Snell). Un rayo de luz viaja desde el punto $A = (0, y_A)$ en un medio isótropo con velocidad v_1 , hasta un punto $B = (x_B, y_B)$ en un medio con velocidad v_2 . La interfaz de refracción entre ambos medios es la recta horizontal $y = 0$. Modele el problema buscando el punto de cruce $P = (x, y) \in \mathbb{R}^2$ que minimiza el tiempo total de viaje $T(x, y) = \frac{\|P-A\|}{v_1} + \frac{\|B-P\|}{v_2}$ sujeto a la restricción de frontera $h(x, y) = y = 0$. Resolviendo el sistema de Lagrange, obténgase analíticamente la Ley de Snell.

Ejercicio 3.20 (Distribución Uniforme y Entropía de Shannon). En Teoría de la Información, la entropía de una distribución de probabilidad discreta $x \in \mathbb{R}^n$ (con $x_i > 0$) se define como el funcional $\mathcal{H}(x) = -\sum_{i=1}^n x_i \ln(x_i)$. Demuestre analíticamente que el problema de maximización de entropía $\max \mathcal{H}(x)$ sujeto a $\sum_{i=1}^n x_i = 1$ es resuelto unívocamente por la distribución uniforme $\bar{x}_i = 1/n$ para todo i . Verifique el carácter de máximo global analizando los autovalores de la matriz Hessiana.

Ejercicio 3.21 (Proyección sobre el Grupo Ortogonal: El Problema de Procrustes). Sea el espacio de matrices cuadradas $M_n(\mathbb{R})$ equipado con el producto de Frobenius $\langle X, Y \rangle_F = \text{Tr}(X^T Y)$. Considérese el problema de encontrar la matriz ortogonal más cercana a una matriz dada $A \in M_n(\mathbb{R})$:

$$\min \frac{1}{2} \|X - A\|_F^2 \quad \text{sujeto a} \quad X^T X - I = 0.$$

Haciendo uso de las derivadas de Fréchet para funciones matriciales, defina la Lagrangiana (donde el multiplicador de Lagrange es una matriz simétrica $\Lambda \in M_n(\mathbb{R})$) y derive la ecuación matricial estacionaria.

Ejercicio 3.22 (Mecánica Clásica: El Péndulo Simple). Un péndulo consiste en una masa m sujeta al extremo de una varilla rígida de longitud L sin masa, cuyo otro extremo está fijo en el origen $(0, 0)$. La posición de la masa se denota por (x, y) . La energía potencial es $V(x, y) = mgy$. Modele las posiciones de equilibrio del péndulo determinando los

extremos de $V(x, y)$ sujetos a la restricción de longitud $x^2 + y^2 = L^2$. Interprete el multiplicador de Lagrange como la fuerza de tensión en la varilla.

Ejercicio 3.23 (Microeconomía: Maximización de Utilidad). Un consumidor desea maximizar su función de utilidad Cobb-Douglas $U(x_1, x_2) = x_1^\alpha x_2^\beta$ (con $\alpha, \beta > 0$), sujeto a su restricción presupuestaria $p_1 x_1 + p_2 x_2 = I$, donde p_i son los precios e I el ingreso disponible.

1. Encuentre las funciones de demanda marshallianas $x_1(p_1, p_2, I)$ y $x_2(p_1, p_2, I)$ resolviendo el sistema de Lagrange.
2. Calcule el multiplicador de Lagrange óptimo λ^* .
3. Demuestre analíticamente que $\lambda^* = \frac{\partial U^*}{\partial I}$, verificando que el multiplicador representa la “utilidad marginal del ingreso”.

Ejercicio 3.24 (Problema de Optimización de Carteras de Markowitz). Un inversor desea construir un portafolio con n activos financieros. Sea $x \in \mathbb{R}^n$ el vector de ponderación de cada activo (fracción del capital invertido), tal que $\sum x_i = 1$. Sea $\Sigma \in \mathbb{R}^{n \times n}$ la matriz de covarianza de los retornos (simétrica y definida positiva) y $\mu \in \mathbb{R}^n$ el vector de retornos esperados. El inversor desea minimizar la varianza de la cartera $\frac{1}{2} x^\top \Sigma x$, sujeto a obtener un retorno esperado objetivo $\mu^\top x = R$, y a que la suma de las ponderaciones sea igual a 1 ($e^\top x = 1$, donde e es el vector de unos). Escriba el sistema KKT, halle la solución analítica para las ponderaciones óptimas x^* y demuestre que dicha solución es única.

Ejercicio 3.25 (Mínimos Cuadrados Restringidos). En estimación estadística, a menudo se requiere estimar parámetros sujetos a un conjunto de restricciones lineales exactas. Considere el problema de regresión $\min \frac{1}{2} \|Y - X\beta\|^2$ sujeto a $C\beta = d$, donde $Y \in \mathbb{R}^m$, $X \in \mathbb{R}^{m \times n}$ (con rango de columnas completo), $C \in \mathbb{R}^{l \times n}$ (rango de filas completo) y $d \in \mathbb{R}^l$. Encuentre la expresión analítica cerrada del estimador restringido β^* resolviendo el sistema de ecuaciones de Lagrange y compárelo con el estimador de mínimos cuadrados ordinarios irrestricto $\hat{\beta} = (X^\top X)^{-1} X^\top Y$.

Parte IV: Teoremas de Alternativa y Análisis Convexo

Ejercicio 3.26 (Teorema de Tucker). Pruebe el Teorema de la Alternativa de Tucker: Para cualesquiera matrices A_i , $i = 0, 1, 2$, con $A_0 \neq 0$, uno y solo uno de los sistemas posee solución:

$$A_0 x \geq 0 \text{ (con } A_0 x \neq 0), \quad A_1 x = 0, \quad A_2 x \geq 0, \quad x \in \mathbb{R}^n;$$

o

$$A_0^\top y^0 + A_1^\top y^1 + A_2^\top y^2 = 0, \quad y^0 > 0, \quad y^2 \geq 0.$$

Ejercicio 3.27 (Teoremas de Gale I y II). Demuestre los Teoremas de Alternativa de Gale:

1. $Ax = a$ ($x \geq 0$) vs $A^\top y \geq 0$ ($\langle a, y \rangle < 0$).
2. $Ax \leq a$ ($x \geq 0$) vs $A^\top y \geq 0$ ($\langle a, y \rangle < 0$, $y \geq 0$).

Ejercicio 3.28 (Teoremas de Gordan y Stiemke). Demuestre los Teoremas de Alternativa:

1. **Gordan:** $Ax < 0$ vs $A^\top y = 0$ ($y \geq 0, y \neq 0$).
2. **Stiemke:** $Ax \leq 0$ ($Ax \neq 0$) vs $A^\top y = 0$ ($y > 0$).

Ejercicio 3.29. Sean $\alpha_i > 0$, $i = 1, \dots, p$. Probar utilizando propiedades de funciones convexas (Cobb-Douglas):

$$\frac{1}{p} \sum_{i=1}^p \alpha_i \geq \left(\prod_{i=1}^p \alpha_i \right)^{1/p}.$$

Ejercicio 3.30. Probar que la función $f(x) = \|x\|^2$ es fuertemente convexa con módulo $\gamma = 1$.

Ejercicio 3.31. Sea f una función convexa y al mismo tiempo cóncava. Mostrar que esto implica que f es una función afín ($f(x) = \langle a, x \rangle + c$).

Ejercicio 3.32. Para qué valores del parámetro $\sigma \in \mathbb{R}$ la función $f(x) = (\sigma + 6)x_1^2 + 2\sigma x_1 x_2 + x_2^2$ es convexa en $\mathbb{R}^2$?

Ejercicio 3.33. Probar que las siguientes funciones son convexas en $\mathbb{R}^n$:

1. $f(x) = \ln(\sum_{i=1}^n e^{x_i})$.
2. $f(x) = e^{\langle Qx, x \rangle}$, donde Q es semidefinida positiva.

Ejercicio 3.34. Resolver de forma analítica el problema $\min f(x)$ sujeto a $x \in D$:

1. $f(x) = 2x_1^2 + 4x_2^2 - 5x_1x_2$, $D = \{x \in \mathbb{R}^2 \mid 0 \leq x_1 \leq 1, 0 \leq x_2 \leq 1\}$.
2. $f(x) = 4x_1^2 - x_1x_2 + 2x_2^2$, $D = \{x \in \mathbb{R}^2 \mid 4 \leq x_1 \leq 8, -1 \leq x_2 \leq 2\}$.

Ejercicio 3.35. Probar que la función $f(x) = \max\{e^x, x^2\} + 1/x$ es convexa en $\mathbb{R}_+ \setminus \{0\}$.

4. Problemas con Restricciones Mixtas

En este capítulo contamos con las herramientas necesarias para abordar el problema de optimización general con restricciones mixtas de igualdad y desigualdad. Estudiaremos la caracterización del cono tangente para los conjuntos definidos por este tipo de restricciones, lo que nos permitirá derivar las condiciones de optimalidad primal-dual de Karush-Kuhn-Tucker (KKT). Asimismo, desarrollaremos las condiciones necesarias y suficientes de segundo orden.

Consideramos el problema de optimización con restricciones mixtas de igualdad y desigualdad:

$$\min f(x) \quad \text{sujeto a} \quad x \in D, \quad (4.1)$$

donde el conjunto factible está dado por:

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\}, \quad (4.2)$$

y $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones dadas.

Nota: Transformación a restricciones de igualdad

Como se mencionó en el Capítulo 1, es posible convertir el problema (4.1)-(4.2) en uno con restricciones exclusivas de igualdad, introduciendo variables de holgura $\sigma \in \mathbb{R}^m$ mediante la siguiente transformación:

$$\tilde{D} = \left\{ (x, \sigma) \in \mathbb{R}^n \times \mathbb{R}^m \mid \begin{array}{l} h(x) = 0, \\ g_i(x) + \sigma_i^2 = 0, \quad i = 1, \dots, m. \end{array} \right\}.$$

Sin embargo, esta aproximación exige hipótesis de regularidad más restrictivas y produce condiciones de optimalidad de segundo orden más débiles que las obtenidas al estudiar las desigualdades de forma directa.

Para el estudio local del problema, es necesario identificar cuáles restricciones de desigualdad determinan la frontera del conjunto factible en un punto dado.

Definición 4.1 (Restricciones activas). Sea $\bar{x} \in D$. Diremos que la restricción de desigualdad correspondiente al índice $i \in \{1, \dots, m\}$ es **activa** en el punto $\bar{x}$ cuando $g_i(\bar{x}) = 0$.

El conjunto de índices de las restricciones activas en el punto $\bar{x} \in D$ se denota por:

$$I(\bar{x}) = \{i \in \{1, \dots, m\} \mid g_i(\bar{x}) = 0\}.$$

Notación. Las restricciones de igualdad no se incluyen en esta definición puesto que, por la propia definición del conjunto D , siempre se satisfacen como igualdades en cualquier punto factible.

4.1. Cono tangente en el caso de restricciones de igualdad y desigualdad

Por continuidad, un minimizador local $\bar{x}$ del problema (4.1)-(4.2) también es minimizador local del problema relajado que omite las restricciones inactivas en $\bar{x}$. Geométricamente, las restricciones activas determinan el comportamiento local del conjunto factible en torno a $\bar{x}$ y, por ende, son las únicas relevantes para el análisis diferencial.

Definición 4.2 (Cono de linealización). Supongamos que h y g son diferenciables en $\bar{x} \in D$. Se define el **cono de linealización** en $\bar{x}$ para las restricciones de igualdad y las desigualdades activas, denotado por $\mathcal{H}(\bar{x})$, como:

$$\mathcal{H}(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{array}{l} \langle \nabla h_i(\bar{x}), d \rangle = 0, \quad i = 1, \dots, l \\ \langle \nabla g_i(\bar{x}), d \rangle \leq 0, \quad \forall i \in I(\bar{x}) \end{array} \right\}. \quad (4.3)$$

De manera equivalente, utilizando la matriz Jacobiana J_h :

$$\mathcal{H}(\bar{x}) = \{d \in \ker J_h(\bar{x}) \mid \langle \nabla g_i(\bar{x}), d \rangle \leq 0 \quad \forall i \in I(\bar{x})\}.$$

Ejemplo 4.1 (Cálculo del cono de linealización). Considérese el conjunto factible en $\mathbb{R}^2$ delimitado por una parábola y el eje horizontal:

$$D = \left\{ x \in \mathbb{R}^2 \mid \begin{array}{l} g_1(x) = x_2 - x_1^2 \leq 0 \\ g_2(x) = -x_2 \leq 0 \end{array} \right\}.$$

El conjunto D consta de un único punto factible, $\bar{x} = (0, 0)^\top$.

Para determinar el cono de linealización $\mathcal{H}(\bar{x})$, evaluamos las restricciones en el origen: $g_1(0, 0) = 0$ y $g_2(0, 0) = 0$, por lo que $I(\bar{x}) = \{1, 2\}$. Los gradientes son:

$$\nabla g_1(\bar{x}) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \nabla g_2(\bar{x}) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}.$$

Por la Definición 4.2, un vector $d = (d_1, d_2)^\top$ pertenece a $\mathcal{H}(\bar{x})$ si satisface:

$$\langle \nabla g_1(\bar{x}), d \rangle = d_2 \leq 0 \quad \text{y} \quad \langle \nabla g_2(\bar{x}), d \rangle = -d_2 \leq 0 \implies d_2 \geq 0.$$

El sistema implica que $d_2 = 0$. La coordenada d_1 no está acotada por las restricciones linealizadas. En consecuencia:

$$\mathcal{H}(\bar{x}) = \left\{ \begin{pmatrix} d_1 \\ 0 \end{pmatrix} \mid d_1 \in \mathbb{R} \right\}.$$

Este caso ilustra una discrepancia entre la topología y el álgebra: el cono tangente geométrico es $\mathcal{T}_D(\bar{x}) = \{0\}$, mientras que el cono de linealización $\mathcal{H}(\bar{x})$ es una recta completa.

Proposición 4.1 (Inclusión de conos). Sea $D \subset \mathbb{R}^n$ el conjunto definido en (4.2). Si las funciones $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son diferenciables en $\bar{x} \in D$, entonces los conos tangentes están contenidos en el cono de linealización:

$$\mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x}) \subset \mathcal{H}(\bar{x}).$$

Prueba. La inclusión $\mathcal{T}_D(\bar{x}) \subset \mathcal{B}_D(\bar{x})$ es una propiedad topológica general. Para la segunda inclusión, es inmediato que $0 \in \mathcal{B}_D(\bar{x}) \cap \mathcal{H}(\bar{x})$.

Sea $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. Existen sucesiones $\{t_k\} \rightarrow 0^+$ y $\{d^k\} \rightarrow d$ tales que $\bar{x} + t_k d^k \in D$ para todo $k \in \mathbb{N}$. La condición de factibilidad exige que para todo k :

$$h(\bar{x} + t_k d^k) = 0 \quad \text{y} \quad g_i(\bar{x} + t_k d^k) \leq 0 \quad \forall i \in I(\bar{x}).$$

Utilizando el desarrollo de Taylor de primer orden en $\bar{x}$:

$$\begin{aligned} 0 &= h(\bar{x} + t_k d^k) - h(\bar{x}) = t_k J_h(\bar{x}) d^k + o(t_k \|d^k\|), \\ 0 &\geq g_i(\bar{x} + t_k d^k) - g_i(\bar{x}) = t_k \langle \nabla g_i(\bar{x}), d^k \rangle + o(t_k \|d^k\|). \end{aligned}$$

Dividiendo por $t_k > 0$ y tomando el límite cuando $k \rightarrow \infty$, se sigue que $d^k \rightarrow d$ y el término residual $\frac{o(t_k \|d^k\|)}{t_k} \rightarrow 0$. Se obtiene:

$$J_h(\bar{x})d = 0 \quad \text{y} \quad \langle \nabla g_i(\bar{x}), d \rangle \leq 0 \quad \forall i \in I(\bar{x}),$$

lo cual demuestra que $d \in \mathcal{H}(\bar{x})$. ■

Contraejemplo 4.1 (Falta de regularidad e inclusión estricta). El siguiente ejemplo muestra que la igualdad $\mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$ requiere hipótesis adicionales. Sea $D \subset \mathbb{R}^2$ definido por:

$$g(x) = -x_1^3 + x_2^2 \leq 0.$$

En el origen $\bar{x} = (0, 0)^\top \in D$, la restricción es activa y su gradiente es $\nabla g(\bar{x}) = (0, 0)^\top$. El cono de linealización es todo el espacio:

$$\mathcal{H}(\bar{x}) = \{d \in \mathbb{R}^2 \mid \langle (0, 0)^\top, d \rangle \leq 0\} = \mathbb{R}^2.$$

Sin embargo, el conjunto D presenta una cúspide orientada hacia la dirección positiva del eje x_1 . La dirección $d = (-1, 0)^\top \in \mathcal{H}(\bar{x})$ no es tangente, ya que para cualquier $t > 0$, evaluando en la restricción se tiene $-(-t)^3 + 0^2 = t^3 > 0$, por lo que $\bar{x} + td \notin D$. Por tanto, $d \notin \mathcal{B}_D(\bar{x})$, verificándose la inclusión estricta $\mathcal{B}_D(\bar{x}) \subsetneq \mathcal{H}(\bar{x})$.

Ejemplo 4.2 (Igualdad de conos bajo regularidad). Considérese el conjunto en $\mathbb{R}^2$ definido por:

$$D = \left\{ x \in \mathbb{R}^2 \mid \begin{array}{l} h(x) = x_2 - x_1^2 = 0 \\ g(x) = x_1 \leq 0 \end{array} \right\}.$$

Tomemos el punto $\bar{x} = (0, 0)^\top$. La restricción de desigualdad es activa ($I(\bar{x}) = \{1\}$). Los gradientes en $\bar{x}$ son $\nabla h(\bar{x}) = (0, 1)^\top$ y $\nabla g(\bar{x}) = (1, 0)^\top$. El cono de linealización $\mathcal{H}(\bar{x})$ requiere $d_2 = 0$ y $d_1 \leq 0$, de donde $\mathcal{H}(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \leq 0\}$.

Para el cono de Bouligand $\mathcal{B}_D(\bar{x})$, dada una sucesión $t_k \rightarrow 0^+$, los puntos de D admiten la forma $(-t_k, t_k^2)^\top$. La dirección secante es:

$$d^k = \frac{1}{t_k} \begin{pmatrix} -t_k \\ t_k^2 \end{pmatrix} = \begin{pmatrix} -1 \\ t_k \end{pmatrix}.$$

En el límite $k \rightarrow \infty$, se obtiene $d = (-1, 0)^\top$. Por homotecia de conos, $\mathcal{B}_D(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \leq 0\}$. Para el cono tangente estricto $\mathcal{T}_D(\bar{x})$, la curva $x(t) = (-t, t^2)^\top$ contenida en D para $t \geq 0$ tiene por vector director $d = (-1, 0)^\top$. Por lo tanto, en este punto se verifica $\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$.

Lema 4.1 (Lema de Farkas Generalizado). Sea $K \subset \mathbb{R}^n$ un cono poliédrico definido por el sistema:

$$K = \{x \in \mathbb{R}^n \mid A_1 x = 0, A_2 x \leq 0\},$$

con matrices $A_1 \in \mathbb{R}^{m_1 \times n}$ y $A_2 \in \mathbb{R}^{m_2 \times n}$.

El cono dual K^* equivale al conjunto de combinaciones lineales de las filas de A_1 y A_2 , donde los coeficientes correspondientes a A_2 son no negativos:

$$K^* = \left\{ z \in \mathbb{R}^n \mid \begin{array}{l} z = A_1^\top \lambda + A_2^\top \mu, \\ \lambda \in \mathbb{R}^{m_1}, \mu \in \mathbb{R}_+^{m_2} \end{array} \right\}. \quad (4.4)$$

Prueba. Sea Q el conjunto de la ecuación (4.4). Para todo $z \in Q$ y todo $x \in K$, existen $\lambda \in \mathbb{R}^{m_1}$ y $\mu \in \mathbb{R}_+^{m_2}$ tales que $\langle z, x \rangle = \langle A_1^\top \lambda + A_2^\top \mu, x \rangle = \langle \lambda, A_1 x \rangle + \langle \mu, A_2 x \rangle$. Dado que $x \in K$, se satisface $A_1 x = 0$ y $A_2 x \leq 0$. Como $\mu \geq 0$, se concluye que $\langle \mu, A_2 x \rangle \leq 0$. Luego, $\langle z, x \rangle \leq 0$, lo que implica la inclusión $Q \subset K^*$.

Para demostrar la inclusión $K^* \subset Q$, supongamos que existe $\xi \in K^*$ tal que $\xi \notin Q$. Al ser Q un cono convexo cerrado, por el Teorema de Separación Estricta (o Lema de Motzkin), existe $x \in \mathbb{R}^n$ que separa ξ de Q : $\langle \xi, x \rangle > 0$ y $\langle z, x \rangle \leq 0$ para todo $z \in Q$. Evaluando la segunda condición: $\langle \lambda, A_1 x \rangle + \langle \mu, A_2 x \rangle \leq 0$ para todo $\lambda \in \mathbb{R}^{m_1}, \mu \in \mathbb{R}_+^{m_2}$. La pertenencia de λ a todo el espacio requiere que $A_1 x = 0$. La condición $\mu \geq 0$ exige que $A_2 x \leq 0$. En consecuencia, $x \in K$. Sin embargo, la desigualdad $\langle \xi, x \rangle > 0$ contradice la hipótesis $\xi \in K^*$, que exige $\langle \xi, x \rangle \leq 0$ para todo $x \in K$. Esta contradicción demuestra que $K^* \subset Q$. ■

Ejemplo 4.3 (Lema de Farkas en $\mathbb{R}^2$). Sea el cono poliédrico $K \subset \mathbb{R}^2$ definido por:

$$A_2 x \leq 0 \implies \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \leq \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies x_1 \geq 0, x_2 \geq 0.$$

El cono primal es $K = \mathbb{R}_+^2$. Por definición, $z \in K^*$ si $z_1 x_1 + z_2 x_2 \leq 0$ para todo $x \in \mathbb{R}_+^2$. Evaluando en la base canónica, se concluye $z_1 \leq 0$ y $z_2 \leq 0$, es decir, $K^* = \mathbb{R}_-^2$.

Aplicando el Lema 4.1, K^* se expresa mediante combinaciones cónicas de las filas de A_2 :

$$K^* = \left\{ \mu_1 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} \mid \mu_1, \mu_2 \geq 0 \right\} = \left\{ \begin{pmatrix} -\mu_1 \\ -\mu_2 \end{pmatrix} \mid \mu_1, \mu_2 \geq 0 \right\} = \mathbb{R}_-^2.$$

Lema 4.2 (Estructura Dual del Cono de Linealización). Sea $\mathcal{H}(\bar{x})$ el cono poliédrico definido en (4.3). El cono dual $\mathcal{H}(\bar{x})^*$ está dado por:

$$\mathcal{H}(\bar{x})^* = \left\{ y \in \mathbb{R}^n \mid \begin{array}{l} y = J_h(\bar{x})^\top \lambda + \sum_{i \in I(\bar{x})} \mu_i \nabla g_i(\bar{x}), \\ \lambda \in \mathbb{R}^l, \mu_i \geq 0 \quad \forall i \in I(\bar{x}) \end{array} \right\}. \quad (4.5)$$

Prueba. El resultado se sigue directamente de la aplicación del Lema de Farkas (Lema 4.1). Definiendo la matriz $A_1 = J_h(\bar{x}) \in \mathbb{R}^{l \times n}$ y construyendo A_2 a partir de los gradientes transpuestos $\nabla g_i(\bar{x})^\top$ para $i \in I(\bar{x})$, un vector $y \in \mathcal{H}(\bar{x})^*$ se descompone como $A_1^\top \lambda + A_2^\top \mu$, con $\mu \geq 0$. ■

Ejemplo 4.4 (Construcción del cono dual). Considérese el origen $\bar{x} = (0, 0, 0)^\top$ en el sistema:

$$D = \left\{ x \in \mathbb{R}^3 \mid \begin{array}{l} h(x) = x_1 - x_2 = 0 \\ g(x) = x_1 + x_2 + x_3 \leq 0 \end{array} \right\}.$$

La desigualdad es activa ($g(0) = 0$). Los gradientes en $\bar{x}$ son $\nabla h(\bar{x}) = (1, -1, 0)^\top$ y $\nabla g(\bar{x}) = (1, 1, 1)^\top$. El cono de linealización $\mathcal{H}(\bar{x})$ requiere $d_1 = d_2$ y $2d_1 + d_3 \leq 0$.

Por el Lema 4.2, su cono dual $\mathcal{H}(\bar{x})^*$ toma la forma:

$$y = \lambda \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} + \mu \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} \lambda + \mu \\ -\lambda + \mu \\ \mu \end{pmatrix}, \quad \lambda \in \mathbb{R}, \mu \geq 0.$$

El parámetro λ , asociado a la igualdad, no tiene restricción de signo y genera un subespacio. La variable μ , asociada a la desigualdad, está restringida a $\mu \geq 0$, lo que define la estructura cónica del conjunto dual.

Teorema 4.1 (Condición suficiente de primer orden). Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ diferenciables en $\bar{x} \in D$. Sea $\mathcal{H}(\bar{x})$ el cono definido en (4.3).

Si se cumple la condición:

$$\langle \nabla f(\bar{x}), d \rangle > 0 \quad \forall d \in \mathcal{H}(\bar{x}) \setminus \{0\}, \quad (4.6)$$

entonces f satisface la **condición de crecimiento lineal** en $\bar{x}$: existen un entorno U de $\bar{x}$ y un escalar $\beta > 0$ tales que

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\| \quad \forall x \in D \cap U.$$

Por lo tanto, $\bar{x}$ es un minimizador local estricto de (4.1).

Prueba. Supongamos, por reducción al absurdo, que se cumple (4.6) pero la condición de crecimiento lineal es falsa. Esto implica la existencia de una sucesión $x^k \in D \setminus \{\bar{x}\}$ convergiendo a $\bar{x}$ tal que

$$f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|.$$

Sea $t_k = \|x^k - \bar{x}\| > 0$ y considérese la dirección normalizada $d^k = (x^k - \bar{x})/t_k$. Por la compacidad de la esfera unitaria, existe una subsucesión convergente $d^k \rightarrow d$, con $\|d\| = 1$ (es decir, $d \neq 0$). Por la definición de direcciones tangentes secuenciales, $d \in \mathcal{B}_D(\bar{x}) \setminus \{0\}$. La inclusión del Proposición 4.1 establece que $d \in \mathcal{H}(\bar{x}) \setminus \{0\}$.

Utilizando el desarrollo de Taylor de primer orden para f :

$$\frac{t_k}{k} > \langle \nabla f(\bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|) = t_k \langle \nabla f(\bar{x}), d^k \rangle + o(t_k).$$

Dividiendo entre t_k y tomando el límite $k \rightarrow \infty$, dado que $o(t_k)/t_k \rightarrow 0$ y $d^k \rightarrow d$, se sigue que $0 \geq \langle \nabla f(\bar{x}), d \rangle$. Este resultado contradice la hipótesis (4.6). Se concluye la existencia de crecimiento lineal, garantizando que $\bar{x}$ es un mínimo estricto. ■

Ejemplo 4.5 (Aplicación de la condición suficiente). Sea el problema:

$$\min f(x) = x_2 \quad \text{sujeto a} \quad D = \left\{ x \in \mathbb{R}^2 \mid \begin{array}{l} g_1(x) = x_1 - x_2 \leq 0 \\ g_2(x) = -x_1 - x_2 \leq 0 \end{array} \right\}.$$

En el origen $\bar{x} = (0, 0)^\top$, ambas restricciones son activas ($I(\bar{x}) = \{1, 2\}$). Los gradientes son $\nabla g_1(\bar{x}) = (1, -1)^\top$ y $\nabla g_2(\bar{x}) = (-1, -1)^\top$. El cono de linealización $\mathcal{H}(\bar{x})$ requiere $d_1 - d_2 \leq 0$ y $-d_1 - d_2 \leq 0$, lo que implica $d_2 \geq |d_1|$.

El gradiente objetivo es $\nabla f(\bar{x}) = (0, 1)^\top$. El producto interno para $d \in \mathcal{H}(\bar{x}) \setminus \{0\}$ es $\langle \nabla f(\bar{x}), d \rangle = d_2$. Al ser $d \neq 0$ y $d_2 \geq |d_1|$, se tiene que $d_2 > 0$. Por tanto, $\langle \nabla f(\bar{x}), d \rangle > 0$ para todo $d \in \mathcal{H}(\bar{x}) \setminus \{0\}$. La condición del Teorema 4.1 se verifica, garantizando que $\bar{x}$ es un mínimo local estricto.

Para caracterizar adecuadamente el cono tangente y establecer $\mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$, se requiere la introducción de condiciones de regularidad.

Definición 4.3 (Condiciones de regularidad). Se dice que el punto $\bar{x} \in D$ es **regular** (o cumple una cualificación de restricciones) si satisface alguna de las siguientes condiciones:

1. **Linealidad:** Las funciones h y g son afines:

$$h(x) = Ax - a, \quad A \in \mathbb{R}^{l \times n}, a \in \mathbb{R}^l; \quad g(x) = Bx - b, \quad B \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m. \quad (4.7)$$

2. **Condición de Mangasarian-Fromovitz (MFCQ):** Los gradientes de igualdad $\{\nabla h_i(\bar{x})\}_{i=1}^l$ son linealmente independientes, y existe una dirección en el espacio nulo de las igualdades que es estrictamente interior para

las restricciones de desigualdad activas:

$$\exists \bar{d} \in \ker J_h(\bar{x}) \quad \text{tal que} \quad \langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0 \quad \forall i \in I(\bar{x}). \quad (4.8)$$

3. Condición de Slater (para problemas convexos): h es afín, g es convexa, y existe un punto que satisface estrictamente las desigualdades:

$$\exists \hat{x} \in \mathbb{R}^n \quad \text{tal que} \quad h(\hat{x}) = 0, \quad g_i(\hat{x}) < 0 \quad \forall i = 1, \dots, m. \quad (4.9)$$

Ejemplo 4.6 (Evaluación de MFCQ). Sea el sistema:

$$D = \left\{ x \in \mathbb{R}^2 \mid g_1(x) = -x_1 \leq 0, \quad g_2(x) = -x_2 \leq 0, \quad g_3(x) = x_1 + x_2 - 1 \leq 0 \right\}.$$

En $\bar{x} = (0, 0)^\top$, los índices activos son $I(\bar{x}) = \{1, 2\}$. Los gradientes activos correspondientes son $\nabla g_1(\bar{x}) = (-1, 0)^\top$ y $\nabla g_2(\bar{x}) = (0, -1)^\top$. El vector $\bar{d} = (1, 1)^\top$ cumple $\langle \nabla g_1, \bar{d} \rangle = -1 < 0$ y $\langle \nabla g_2, \bar{d} \rangle = -1 < 0$, lo que satisface la existencia del vector $\bar{d}$ requerido por la condición MFCQ.

Observación. La condición MFCQ es menos restrictiva que exigir la independencia lineal de todos los gradientes activos (LICQ). Mientras que LICQ garantiza la existencia del vector $\bar{d}$ por resolución de sistemas lineales, MFCQ permite que los gradientes de las desigualdades activas sean linealmente dependientes, lo cual abarca una clase más amplia de problemas.

Proposición 4.2 (Condición dual de MFCQ). El punto $\bar{x} \in D$ cumple la condición MFCQ (4.8) si y solo si el sistema lineal:

$$\sum_{i=1}^l \lambda_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \mu_i \nabla g_i(\bar{x}) = 0, \quad \mu_i \geq 0, \quad i \in I(\bar{x}), \quad (4.10)$$

tiene como única solución $(\lambda, \mu) = (0, 0)$.

Prueba. Supongamos que se cumple MFCQ. Si el sistema (4.10) admitiera una solución con $\mu \in \mathbb{R}_+^{|I(\bar{x})|} \setminus \{0\}$, al realizar el producto escalar de (4.10) con el vector $\bar{d}$ garantizado por (4.8), se obtendría:

$$0 = \sum_{i=1}^l \lambda_i \langle \nabla h_i(\bar{x}), \bar{d} \rangle + \sum_{i \in I(\bar{x})} \mu_i \langle \nabla g_i(\bar{x}), \bar{d} \rangle.$$

Dado que $\langle \nabla h_i(\bar{x}), \bar{d} \rangle = 0$, $\langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0$, y al menos un $\mu_i > 0$, el término derecho es estrictamente negativo, lo que es una contradicción. Si $\mu = 0$, la ecuación requiere que $\sum \lambda_i \nabla h_i = 0$ con $\lambda \neq 0$, lo cual contradice la independencia lineal de $\nabla h_i(\bar{x})$.

Recíprocamente, si la única solución de (4.10) es la nula, el sistema carece de soluciones para $\mu \neq 0$ o $\lambda \neq 0$. Por el Teorema de la Alternativa (Motzkin), esto garantiza la existencia de $\bar{d}$ tal que $\langle \nabla h_i(\bar{x}), \bar{d} \rangle = 0$ y $\langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0$. Además, los gradientes ∇h_i deben ser independientes. Por lo tanto, se satisface MFCQ. ■

Ejemplo 4.7 (Falla de MFCQ). Considérese el sistema:

$$D = \left\{ x \in \mathbb{R}^2 \mid g_1(x) = -x_1^2 + x_2 \leq 0, \quad g_2(x) = -x_2 \leq 0 \right\}.$$

En $\bar{x} = (0, 0)^\top$, los gradientes activos son $\nabla g_1(\bar{x}) = (0, 1)^\top$ y $\nabla g_2(\bar{x}) = (0, -1)^\top$. Resolviendo el sistema dual (4.10) con $\mu \geq 0$:

$$\mu_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \mu_1 = \mu_2.$$

Existen soluciones no nulas (e.g., $\mu_1 = 1, \mu_2 = 1$). Por la Proposición 4.2, el punto no satisface MFCQ. Geométricamente, los gradientes opuestos impiden la existencia de una dirección estrictamente interior.

Teorema 4.2 (Cono tangente para restricciones mixtas). Sea D definido por (4.2). Supongamos que h y g son continuamente diferenciables en $\bar{x} \in D$. Se verifica lo siguiente:

1. $\mathcal{B}_D(\bar{x}) \subset \mathcal{H}(\bar{x})$.
2. Si se cumple MFCQ (4.8):

$$\mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x}).$$

3. Si se cumple la condición de **Slater** (4.9):

$$\text{cl } \mathcal{V}_D(\bar{x}) = \mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x}).$$

4. Si las restricciones son **lineales** (4.7):

$$\mathcal{V}_D(\bar{x}) = \mathcal{T}_D(\bar{x}) = \mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x}).$$

Prueba. (a) Ya demostrado en la Proposición 4.1.

(b) **[MFCQ]:** Sea $\bar{d}$ el vector de (4.8) y $d \in \mathcal{H}(\bar{x})$. Definimos $d(\alpha) = \alpha\bar{d} + (1 - \alpha)d$ para $\alpha \in (0, 1]$. Es claro que $d(\alpha) \in \ker J_h(\bar{x})$. Por el Teorema del Subespacio Tangente en variedades, $d(\alpha)$ es tangente a $h(x) = 0$, lo que implica la existencia de $r(t) = o(t)$ tal que $h(\bar{x} + td(\alpha) + r(t)) = 0$. Para las desigualdades activas $i \in I(\bar{x})$:

$$\langle \nabla g_i(\bar{x}), d(\alpha) \rangle \leq \alpha \langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0.$$

Sustituyendo en la aproximación de primer orden: $g_i(\bar{x} + td(\alpha) + r(t)) = t \langle \nabla g_i(\bar{x}), d(\alpha) \rangle + o(t)$. Para $t > 0$ suficientemente pequeño, $g_i(\bar{x} + td(\alpha) + r(t)) < 0$ debido a que el término de primer orden es estrictamente negativo. Las restricciones inactivas se mantienen en un entorno por continuidad. En conclusión, la curva pertenece a D , lo que muestra $d(\alpha) \in \mathcal{T}_D(\bar{x})$. Tomando el límite $\alpha \rightarrow 0^+$, como el cono tangente es cerrado, se sigue $d \in \mathcal{T}_D(\bar{x})$, demostrando la igualdad de los conos.

(c) **[Slater]:** Considerando $d(\alpha) = \alpha(\hat{x} - \bar{x}) + (1 - \alpha)d$. Por la linealidad de h , la dirección verifica $h(\bar{x} + td(\alpha)) = 0$. Por la desigualdad del subgradiente para funciones convexas, $\langle \nabla g_i(\bar{x}), \hat{x} - \bar{x} \rangle \leq g_i(\hat{x}) < 0$. Evaluando $g_i(\bar{x} + td(\alpha))$ se obtiene que $d(\alpha)$ es una dirección factible. Por lo tanto, $d(\alpha) \in \mathcal{V}_D(\bar{x})$. En el límite, se verifica la densidad y la igualdad de las estructuras.

(d) **[Linealidad]:** Si $h(x) = Ax - a$ y $g(x) = Bx - b$, sea $d \in \mathcal{H}(\bar{x})$. Para todo $t > 0$, la semirrecta $\bar{x} + td$ satisface el sistema algebraico directamente, lo que garantiza $\mathcal{H}(\bar{x}) \subset \mathcal{V}_D(\bar{x})$ y concluye la demostración. ■

Teorema 4.3 (Condición necesaria en forma primal). Supongamos que f y g son diferenciables en $\bar{x}$ y h es continuamente diferenciable en un entorno de $\bar{x}$. Si $\bar{x}$ es un minimizador local del problema (4.1) y se satisface alguna de las condiciones de regularidad de la Definición 4.3, entonces:

$$\langle \nabla f(\bar{x}), d \rangle \geq 0 \quad \forall d \in \mathcal{H}(\bar{x}). \quad (4.11)$$

Prueba. Por las propiedades generales vistas en el Capítulo 1, para todo minimizador local se verifica $\langle \nabla f(\bar{x}), d \rangle \geq 0$ para todo $d \in \mathcal{B}_D(\bar{x})$. Si el punto es regular, el Teorema 4.2 establece $\mathcal{B}_D(\bar{x}) = \mathcal{H}(\bar{x})$, concluyendo la prueba. ■

Ejemplo 4.8. Para minimizar $f(x) = \frac{1}{2}(x_1^2 + x_2^2 + x_3^2)$ sobre el conjunto:

$$h(x) = x_1 + x_2 + x_3 - 1 = 0, \quad g_i(x) = -x_i \leq 0, \quad i = 1, 2, 3.$$

El minimizador global por simetría es $\bar{x} = (1/3, 1/3, 1/3)^\top$. Las desigualdades no son activas ($I(\bar{x}) = \emptyset$). El gradiente de la restricción activa es $\nabla h(\bar{x}) = (1, 1, 1)^\top \neq 0$, cumpliendo la condición de regularidad. El cono de linealización se define exclusivamente por la igualdad:

$$\mathcal{H}(\bar{x}) = \left\{ d \in \mathbb{R}^3 \mid d_1 + d_2 + d_3 = 0 \right\}.$$

Para el gradiente de la función objetivo $\nabla f(\bar{x}) = (1/3, 1/3, 1/3)^\top$, al proyectar sobre $d \in \mathcal{H}(\bar{x})$:

$$\langle \nabla f(\bar{x}), d \rangle = \frac{1}{3}(d_1 + d_2 + d_3) = 0 \geq 0.$$

Se verifica la condición necesaria. Este resultado muestra que la formulación generalizada con desigualdades abarca el caso de restricciones de igualdad como un caso particular.

Teorema 4.4 (Cota de viabilidad de Robinson). Bajo la condición de regularidad MFCQ en $\bar{x} \in D$, existen un entorno U de $\bar{x}$ y una constante $M > 0$ tales que la distancia al conjunto factible satisface:

$$\text{dist}(x, D) \leq M \|\Psi(x)\| \quad \forall x \in U, \quad (4.12)$$

donde la función residual se define como $\Psi(x) = (h(x), \max\{0, g_1(x)\}, \dots, \max\{0, g_m(x)\})$.

Nota. La demostración se omite por requerir resultados de regularidad métrica y multifunciones en espacios de Banach (Teorema de Robinson-Graves). ■

Ejemplo 4.9 (Cota de Robinson). Considérese $D = \mathbb{R}_+^2$ definido por $g_1(x) = -x_1 \leq 0$ y $g_2(x) = -x_2 \leq 0$. El operador residual es $\Psi(x) = (\max\{0, -x_1\}, \max\{0, -x_2\})$. El operador $\max\{0, \cdot\}$ anula los términos correspondientes a las desigualdades que se satisfacen, cuantificando únicamente el error o violación de las restricciones. Por ejemplo, si

$x = (-3, -4)^\top$, $\|\Psi(x)\| = 5$, lo cual coincide exactamente con la distancia del punto a su proyección en el cuadrante $(0, 0)^\top$. En este caso se verifica la cota con $M = 1$.

4.2. Condiciones de optimalidad de Karush-Kuhn-Tucker

En esta sección deducimos las condiciones analíticas de optimalidad de primer orden para problemas con restricciones mixtas a partir de la caracterización del cono tangente desarrollada en la sección anterior. Como se demostró, la condición necesaria primal establece que el opuesto del gradiente pertenece al cono dual del cono de linealización: $-\nabla f(\bar{x}) \in \mathcal{H}(\bar{x})^*$. Utilizando la parametrización de este cono dual obtenida en el Lema 4.2, expresaremos esta relación geométrica como un sistema algebraico de multiplicadores de Lagrange, conocido como condiciones de Karush-Kuhn-Tucker (KKT).

Teorema 4.5 (Condiciones de Karush-Kuhn-Tucker). *Supongamos que $\bar{x} \in D$ es una solución local del problema (4.1)-(4.2), donde f, h, g son funciones continuamente diferenciables en $\bar{x}$.*

Si el punto $\bar{x}$ satisface alguna de las condiciones de regularidad de las restricciones detalladas en la Definición 4.3 (independencia lineal, linealidad afín, Slater o MFCQ), entonces existen multiplicadores $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}^m$ con $\bar{\mu} \geq 0$, tales que:

$$\nabla f(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i=1}^m \bar{\mu}_i \nabla g_i(\bar{x}) = 0, \quad (4.13)$$

$$\bar{\mu}_i g_i(\bar{x}) = 0 \quad \forall i \in \{1, \dots, m\}. \quad (4.14)$$

Prueba. Bajo cualquiera de las condiciones de regularidad supuestas, el Teorema de la Condición Necesaria Primal (Teorema 4.3) establece que la derivada direccional es no negativa sobre todo el cono de linealización, es decir, $\langle \nabla f(\bar{x}), d \rangle \geq 0 \quad \forall d \in \mathcal{H}(\bar{x})$. En términos de conos duales, esto equivale a la afirmación geométrica:

$$-\nabla f(\bar{x}) \in \mathcal{H}(\bar{x})^*.$$

Por el Lema 4.2, conocemos la parametrización de los elementos de $\mathcal{H}(\bar{x})^*$. Por lo tanto, se garantiza la existencia de multiplicadores $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu}_i \geq 0$ para $i \in I(\bar{x})$ tales que:

$$-\nabla f(\bar{x}) = \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i \nabla g_i(\bar{x}).$$

Definimos el vector $\bar{\mu} \in \mathbb{R}^m$ haciendo $\bar{\mu}_i = \bar{\mu}_i$ si $i \in I(\bar{x})$, y $\bar{\mu}_i = 0$ si $i \notin I(\bar{x})$. Al agrupar los términos se obtiene la condición de estacionariedad (4.13).

Por otra parte, si la restricción i es activa ($i \in I(\bar{x})$), se tiene $g_i(\bar{x}) = 0$, lo que anula el producto $\bar{\mu}_i g_i(\bar{x})$. Si es inactiva ($i \notin I(\bar{x})$), por construcción se tiene $\bar{\mu}_i = 0$, lo que también anula el producto. Esto demuestra la condición de complementariedad (4.14). ■

Nota: La condición de holgura complementaria

La condición $\bar{\mu}_i g_i(\bar{x}) = 0$ establece que para cada restricción de desigualdad se debe cumplir al menos una de las dos condiciones siguientes:

- Si la restricción no es activa ($g_i(\bar{x}) < 0$), el multiplicador asociado es nulo ($\bar{\mu}_i = 0$).
- Si el multiplicador es estrictamente positivo ($\bar{\mu}_i > 0$), la restricción debe satisfacerse con igualdad ($g_i(\bar{x}) = 0$).

Esta relación introduce un componente combinatorio en el cálculo de los puntos estacionarios, al requerir el análisis de los distintos casos de restricciones activas e inactivas.

Definición 4.4 (Complementariedad Estricta). Sea $\bar{x}$ un punto estacionario KKT con multiplicadores $(\bar{\lambda}, \bar{\mu})$. Se dice que se satisface la **condición de complementariedad estricta** si:

$$\bar{\mu}_i - g_i(\bar{x}) > 0 \quad \forall i = 1, \dots, m.$$

Esta condición excluye el caso degenerado en el que coinciden $g_i(\bar{x}) = 0$ y $\bar{\mu}_i = 0$. Esto equivale a exigir que toda restricción activa en el punto tenga un multiplicador estrictamente positivo.

Ejemplo 4.10 (Análisis por casos del sistema KKT). Considérese el problema de minimizar la suma de las coordenadas sobre el hemisferio superior de la circunferencia unitaria:

$$\min f(x) = x_1 + x_2 \quad \text{sujeto a} \quad \begin{aligned} h(x) &= x_1^2 + x_2^2 - 1 = 0 \\ g(x) &= -x_2 \leq 0 \end{aligned}$$

El conjunto factible D es el arco semicircular definido por $x_2 \geq 0$. El gradiente de la igualdad es $\nabla h(x) = (2x_1, 2x_2)^\top \neq 0$ en todo punto factible, lo que garantiza la condición LICQ.

Cualquier mínimo local debe cumplir el sistema KKT. Con $\nabla f = (1, 1)^\top$ y $\nabla g = (0, -1)^\top$, el sistema se formula como:

$$\begin{cases} 1. \ 1 + 2\lambda x_1 = 0 \\ 2. \ 1 + 2\lambda x_2 - \mu = 0 \\ 3. \ \mu(-x_2) = 0 \\ 4. \ x_1^2 + x_2^2 = 1, \quad x_2 \geq 0, \quad \mu \geq 0 \end{cases}$$

Analizamos las soluciones mediante los dos casos que define la condición de complementariedad:

Caso 1: Restricción inactiva ($\mu = 0$). Suponiendo $x_2 > 0$, la condición de complementariedad exige $\mu = 0$. Las ecuaciones de estacionariedad se reducen a:

$$1 + 2\lambda x_1 = 0 \implies x_1 = -\frac{1}{2\lambda}, \quad 1 + 2\lambda x_2 = 0 \implies x_2 = -\frac{1}{2\lambda}.$$

Sustituyendo en la ecuación de la circunferencia: $\frac{2}{4\lambda^2} = 1 \implies \lambda = \pm \frac{1}{\sqrt{2}}$. Dado que asumimos $x_2 > 0$, la única raíz compatible es $\lambda = -1/\sqrt{2}$. Obtenemos el primer punto KKT: $\bar{x}^{(1)} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)^\top$, con $\lambda = -\frac{1}{\sqrt{2}}$, $\mu = 0$.

Caso 2: Restricción activa ($\mu > 0$). Esto implica que la restricción se cumple con igualdad, es decir, $x_2 = 0$. Por la ecuación de la circunferencia, se tiene $x_1^2 = 1 \implies x_1 = \pm 1$. Evaluamos ambos casos:

- Si $x_1 = 1, x_2 = 0$: $1 + 2\lambda = 0 \implies \lambda = -1/2$. Sustituyendo se obtiene $1 - \mu = 0 \implies \mu = 1 \geq 0$. Obtenemos: $\bar{x}^{(2)} = (1, 0)^\top$, con $\lambda = -\frac{1}{2}$, $\mu = 1$.
- Si $x_1 = -1, x_2 = 0$: $1 - 2\lambda = 0 \implies \lambda = 1/2$. Sustituyendo resulta $1 - \mu = 0 \implies \mu = 1 \geq 0$. Obtenemos: $\bar{x}^{(3)} = (-1, 0)^\top$, con $\lambda = \frac{1}{2}$, $\mu = 1$.

Evaluando la función objetivo $f(x) = x_1 + x_2$ en los tres puntos obtenidos: $f(\bar{x}^{(1)}) = \sqrt{2} \approx 1.41$, $f(\bar{x}^{(2)}) = 1$, y $f(\bar{x}^{(3)}) = -1$. Por el Teorema de Weierstrass, se concluye que el punto $\bar{x}^{(3)} = (-1, 0)^\top$ es el minimizador global del problema.

Definición 4.5 (Sistema KKT y Lagrangiana). La **función Lagrangiana** $L : \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R}$ para el problema con restricciones mixtas se define como:

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle.$$

El sistema de ecuaciones e inecuaciones:

$$\nabla_x L(x, \lambda, \mu) = 0, \quad h(x) = 0, \quad g(x) \leq 0, \quad \mu \geq 0, \quad \mu_i g_i(x) = 0 \quad \forall i = 1, \dots, m,$$

se denomina **Sistema de Karush-Kuhn-Tucker (KKT)**. El conjunto de todos los multiplicadores asociados a un punto estacionario $\bar{x} \in D$ se denota por:

$$\mathcal{M}(\bar{x}) = \left\{ (\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}^m \mid \begin{aligned} &\nabla_x L(\bar{x}, \lambda, \mu) = 0, \\ &\mu \geq 0, \mu_i g_i(\bar{x}) = 0 \quad \forall i \end{aligned} \right\}.$$

Bajo condiciones de convexidad, las condiciones necesarias de primer orden pasan a ser también suficientes para garantizar la optimalidad global.

Teorema 4.6 (Suficiencia de KKT bajo Convexidad). Sea $\bar{x} \in \mathbb{R}^n$ un punto estacionario del problema (4.1)-(4.2) (es decir, $\mathcal{M}(\bar{x}) \neq \emptyset$).

Si las funciones f y g_i son funciones convexas en $\mathbb{R}^n$, y la función de igualdad h es afín, entonces $\bar{x}$ es un minimizador global del problema.

Prueba. Sea $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$ el vector de multiplicadores asociado. Dado que $\bar{\mu}_i \geq 0$ y las funciones g_i son convexas, la combinación cónica $\sum \bar{\mu}_i g_i(x)$ es convexa. Como h es afín, el término $\sum \bar{\lambda}_i h_i(x)$ también lo es. Por tanto, la función $x \mapsto L(x, \bar{\lambda}, \bar{\mu})$ es convexa en $\mathbb{R}^n$.

Al ser $\bar{x}$ un punto estacionario, se cumple $\nabla_x L(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$. Utilizando la propiedad de primer orden para funciones convexas diferenciables, se tiene:

$$L(x, \bar{\lambda}, \bar{\mu}) \geq L(\bar{x}, \bar{\lambda}, \bar{\mu}) \quad \forall x \in \mathbb{R}^n.$$

Para cualquier punto factible $x \in D$, evaluando las restricciones se cumple $h(x) = 0$ y $g(x) \leq 0$. Puesto que $\bar{\mu} \geq 0$, se verifica:

$$f(x) \geq f(x) + \sum_{i=1}^l \bar{\lambda}_i h_i(x) + \sum_{i=1}^m \bar{\mu}_i g_i(x) = L(x, \bar{\lambda}, \bar{\mu}).$$

Usando la minimalidad de la Lagrangiana en $\bar{x}$ y la condición de complementariedad $\bar{\mu}_i g_i(\bar{x}) = 0$:

$$L(x, \bar{\lambda}, \bar{\mu}) \geq L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x}).$$

Por transitividad, se concluye que $f(x) \geq f(\bar{x})$ para todo punto factible $x \in D$, lo que demuestra que $\bar{x}$ es un minimizador global. ■

Nota: Dualidad y condiciones de punto de silla

La demostración del Teorema 4.6 utiliza la propiedad de punto de silla de la función Lagrangiana:

$$L(\bar{x}, \lambda, \mu) \leq L(\bar{x}, \bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu}) \quad \forall x \in \mathbb{R}^n, \forall \lambda \in \mathbb{R}^l, \forall \mu \in \mathbb{R}_+^m.$$

Esta relación de min-max es fundamental en la teoría de dualidad y en el diseño de algoritmos primal-duales.

Ejemplo 4.11 (Falta de convexidad en las restricciones). Considérese el problema:

$$\min f(x) = x_2 \quad \text{sujeto a} \quad g(x) = -x_1^2 - x_2^2 \leq 0.$$

El conjunto factible es $\mathbb{R}^2$, el cual es convexo. Sin embargo, la función objetivo no está acotada inferiormente en $\mathbb{R}^2$, por lo que no existe un mínimo global.

El origen $\bar{x} = (0, 0)^\top$ es un punto estacionario, puesto que $\nabla g(\bar{x}) = (0, 0)^\top$, y el sistema de primer orden no admite solución con multiplicador estrictamente positivo para la restricción modificada $g(x) = -x_1^2 + x_2 \leq 0$.

No es posible aplicar el Teorema 4.6 en este caso debido a que la función $g(x) = -x_1^2 + x_2$ no es convexa en $\mathbb{R}^2$ (su Hessiano es indefinido). El teorema exige la convexidad de las funciones que definen las restricciones, no únicamente la del conjunto factible resultante.

Ejemplo 4.12 (Resolución de un problema convexo). Minimicemos la función $f(x) = x_1^2 + 3x_2^2$ sujeta a:

$$g_1(x) = 1 - x_1 - 2x_2 \leq 0, \quad g_2(x) = 1 - 2x_1 - x_2 \leq 0.$$

La función objetivo es estrictamente convexa y las restricciones son afines, lo que asegura que se satisfacen las condiciones de regularidad. El sistema KKT está dado por:

$$\begin{cases} 1. \ 2x_1 - \mu_1 - 2\mu_2 = 0 \\ 2. \ 6x_2 - 2\mu_1 - \mu_2 = 0 \\ 3. \ \mu_1(1 - x_1 - 2x_2) = 0 \\ 4. \ \mu_2(1 - 2x_1 - x_2) = 0 \\ 5. \ \mu_1 \geq 0, \ \mu_2 \geq 0 \\ 6. \ g_1(x) \leq 0, \ g_2(x) \leq 0 \end{cases}$$

Analizamos los posibles casos según la complementariedad:

- **Caso 1** ($\mu_1 = 0, \mu_2 = 0$): De las ecuaciones de estacionariedad se obtiene $x_1 = 0, x_2 = 0$. Evaluando las restricciones: $g_1(0, 0) = 1 > 0$, lo que es infactible.
- **Caso 2** ($\mu_1 = 0, \mu_2 > 0$): La complementariedad exige $2x_1 + x_2 = 1$. Con $\mu_1 = 0$, se tiene $2x_1 = 2\mu_2$ y $6x_2 = \mu_2$, de donde $x_1 = 6x_2$. Sustituyendo en la restricción activa se obtiene $x_2 = 1/13$ y $x_1 = 6/13$. Evaluando la restricción inactiva: $g_1(6/13, 1/13) = 5/13 > 0$, lo que es infactible.
- **Caso 3** ($\mu_1 > 0, \mu_2 = 0$): Se requiere $x_1 + 2x_2 = 1$. Las ecuaciones de estacionariedad implican $2x_1 = \mu_1$ y $6x_2 = 2\mu_1$, lo que da $x_1 = 1.5x_2$. Sustituyendo en la restricción se obtiene $x_2 = 2/7$ y $x_1 = 3/7$. Evaluando las condiciones restantes: $g_2(3/7, 2/7) = -1/7 \leq 0$ y el multiplicador es $\mu_1 = 6/7 \geq 0$.

Se verifican todas las condiciones. El punto estacionario único es $\bar{x} = (3/7, 2/7)^T$ con multiplicadores $\bar{\mu} = (6/7, 0)^T$, el cual corresponde al minimizador global.

Las propiedades algebraicas del conjunto de multiplicadores $\mathcal{M}(\bar{x})$ dependen del cumplimiento de las condiciones de regularidad en el punto estacionario.

Definición 4.6 (Condición Estricta de Mangasarian-Fromovitz - SMFCQ). Sea $\bar{x} \in D$ un punto estacionario y sea $\bar{\mu}$ un vector de multiplicadores en $\mathcal{M}(\bar{x})$. Definimos los conjuntos de índices activos según el signo del multiplicador:

$$I_+(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i > 0\}, \quad I_0(\bar{x}) = \{i \in I(\bar{x}) \mid \bar{\mu}_i = 0\}.$$

El punto cumple **SMFCQ** si los gradientes $\{\nabla h_i(\bar{x})\}_{i=1}^l \cup \{\nabla g_i(\bar{x})\}_{i \in I_+(\bar{x})}$ son linealmente independientes y existe un vector $\bar{d} \in \mathbb{R}^n$ tal que $\langle \nabla h_i(\bar{x}), \bar{d} \rangle = 0$, $\langle \nabla g_i(\bar{x}), \bar{d} \rangle = 0$ para $i \in I_+(\bar{x})$, y $\langle \nabla g_i(\bar{x}), \bar{d} \rangle < 0$ para $i \in I_0(\bar{x})$.

Proposición 4.3 (Propiedades del Conjunto de Multiplicadores). Sea $\bar{x} \in \mathbb{R}^n$ un punto estacionario del problema ($\mathcal{M}(\bar{x}) \neq \emptyset$).

1. El conjunto $\mathcal{M}(\bar{x})$ es compacto si y solo si se cumple la condición MFCQ.
2. El conjunto $\mathcal{M}(\bar{x})$ consta de un único punto si y solo si se cumple la condición SMFCQ.

Prueba. Demostramos (a). La propiedad de ser cerrado se deduce directamente de que $\mathcal{M}(\bar{x})$ está definido mediante igualdades e inequaciones continuas. Supongamos, por reducción al absurdo, que el conjunto no está acotado, por lo que existe una sucesión $\{(\lambda^k, \mu^k)\} \subset \mathcal{M}(\bar{x})$ tal que $\|(\lambda^k, \mu^k)\| \rightarrow \infty$.

Dividiendo las ecuaciones del sistema KKT correspondientes a cada k por el escalar $\|(\lambda^k, \mu^k)\| > 0$, se obtiene una sucesión en la esfera unitaria. Por el Teorema de Bolzano-Weierstrass, existe una subsucesión convergente hacia un vector límite $(\tilde{\lambda}, \tilde{\mu}) \in (\mathbb{R}^l \times \mathbb{R}_+^m)$ con $\|(\tilde{\lambda}, \tilde{\mu})\| = 1$. Pasando al límite en la ecuación normalizada, se obtiene:

$$0 = \sum_{i=1}^l \tilde{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \tilde{\mu}_i \nabla g_i(\bar{x}), \quad \text{con } \tilde{\mu}_i \geq 0.$$

Por la caracterización dual de Mangasarian-Fromovitz (Proposición 4.2), si se cumple MFCQ este sistema homogéneo admite únicamente la solución trivial $(\tilde{\lambda}, \tilde{\mu}) = 0$. Esto contradice que el vector límite tiene norma unitaria, concluyendo que el conjunto de multiplicadores es compacto. ■

Ejemplo 4.13 (Geometría del conjunto de multiplicadores). Considérese el problema en $\mathbb{R}^2$ con dos restricciones de desigualdad:

$$\begin{aligned} &\text{minimizar} && f(x) = x_1 \\ &\text{subject to} && g_1(x) = -x_1 + x_2 \leq 0, \\ &&& g_2(x) = -x_1 - x_2 \leq 0 \end{aligned}$$

El mínimo global se alcanza en $\bar{x} = (0, 0)^T$, donde ambas restricciones son activas. Los gradientes son $\nabla g_1 = (-1, 1)^T$ y $\nabla g_2 = (-1, -1)^T$. Dado que son linealmente independientes, se verifican MFCQ y SMFCQ.

Planteando el sistema KKT: $(1, 0)^T + \mu_1(-1, 1)^T + \mu_2(-1, -1)^T = 0$, cuya única solución es $\bar{\mu} = (1/2, 1/2)^T$. En este caso, el conjunto de multiplicadores es un único punto.

1. Incumplimiento de SMFCQ con MFCQ (Compactibilidad):

Añadiendo la restricción redundante $g_3(x) = -x_1 \leq 0$, en el origen se tiene $\nabla g_3 = (-1, 0)^T$. El conjunto de gradientes ya no es linealmente independiente, pero el vector $\bar{d} = (1, 0)^T$ sigue cumpliendo $\langle \nabla g_i, \bar{d} \rangle < 0$ para todo i , por lo que se mantiene MFCQ.

El sistema KKT resulta en:

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} -1 \\ -1 \end{pmatrix} + \mu_3 \begin{pmatrix} -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

De la segunda coordenada se deduce $\mu_1 = \mu_2$. Sustituyendo en la primera se obtiene $\mu_3 = 1 - 2\mu_1$. Dado que los multiplicadores deben ser no negativos, se requiere $0 \leq \mu_1 \leq 1/2$. El conjunto de multiplicadores es:

$$\mathcal{M}(\bar{x}) = \left\{ \begin{pmatrix} \mu_1 \\ \mu_1 \\ 1 - 2\mu_1 \end{pmatrix} \mid \mu_1 \in \left[0, \frac{1}{2}\right] \right\}.$$

Al no cumplirse SMFCQ no se cumple la unicidad, pero bajo MFCQ el conjunto $\mathcal{M}(\bar{x})$ es un segmento de recta compacto en $\mathbb{R}^3$.

2. Falta de acotamiento por incumplimiento de MFCQ:

Sustituyendo la tercera restricción por $g_4(x) = x_1 \leq 0$, se tiene $\nabla g_4 = (1, 0)^\top$. En este caso, cualquier dirección factible con $d_1 > 0$ contradice la restricción g_4 , por lo que no se satisface MFCQ. El sistema KKT es:

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} -1 \\ -1 \end{pmatrix} + \mu_4 \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Esto implica $\mu_1 = \mu_2$ y $\mu_4 = 2\mu_1 - 1$. Como se requiere $\mu_4 \geq 0$, se tiene $\mu_1 \geq 1/2$. El conjunto de multiplicadores es:

$$\mathcal{M}(\bar{x}) = \left\{ \begin{pmatrix} \mu_1 \\ \mu_1 \\ 2\mu_1 - 1 \end{pmatrix} \mid \mu_1 \in \left[\frac{1}{2}, +\infty \right) \right\}.$$

Al no cumplirse MFCQ, el conjunto de multiplicadores es un rayo no acotado.

Si en un mínimo local no se cumple ninguna condición de regularidad, el sistema KKT clásico puede no tener solución. Para tratar estos casos se introducen las condiciones de Fritz John.

Teorema 4.7 (Condiciones de Fritz John). Sea $\bar{x} \in D$ un minimizador local de (4.1)-(4.2). Independientemente de las condiciones de regularidad, existe un vector no nulo $(\lambda_0, \bar{\lambda}, \bar{\mu}) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m$ tal que:

$$\begin{aligned} \lambda_0 \nabla f(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i=1}^m \bar{\mu}_i \nabla g_i(\bar{x}) &= 0, \\ \bar{\mu}_i g_i(\bar{x}) &= 0 \quad \forall i = 1, \dots, m, \\ \lambda_0 \geq 0, \quad \bar{\mu} \geq 0, \quad (\lambda_0, \bar{\lambda}, \bar{\mu}) &\neq 0. \end{aligned} \tag{4.15}$$

Prueba. Consideramos dos casos.

Caso 1: Si se cumple la condición de regularidad MFCQ, por el Teorema 4.5 se garantiza la existencia de multiplicadores KKT $(\bar{\lambda}, \bar{\mu})$. En este caso basta definir $\lambda_0 = 1$ para obtener la solución $(1, \bar{\lambda}, \bar{\mu}) \neq 0$.

Caso 2: Si no se cumple MFCQ, por la Proposición 4.2 existe una solución no nula del sistema dual homogéneo:

$$\sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i \nabla g_i(\bar{x}) = 0, \quad \text{con } \bar{\mu}_i \geq 0 \text{ y } (\bar{\lambda}, \bar{\mu}) \neq 0.$$

Definiendo el escalar $\lambda_0 = 0$ y completando $\bar{\mu}_i = 0$ para $i \notin I(\bar{x})$, se obtiene el vector no nulo $(\lambda_0, \bar{\lambda}, \bar{\mu})$ que satisface el sistema de Fritz John. ■

Ejemplo 4.14 (Puntos estacionarios con $\lambda_0 = 0$). Considérese el problema:

$$\begin{aligned} \text{minimizar} \quad & f(x) = -x_1 \\ \text{subject to} \quad & g_1(x) = -x_1^1 + x_2 \leq 0, \\ & g_2(x) = -x_1 - x_2 \leq 0 \end{aligned}$$

El único punto factible es el origen $\bar{x} = (0, 0)^\top$, que corresponde al mínimo global. Los gradientes activos en este punto son $\nabla g_1(\bar{x}) = (0, 1)^\top$ y $\nabla g_2(\bar{x}) = (0, -1)^\top$. Como se tiene $\nabla g_1 + \nabla g_2 = 0$, los gradientes son linealmente dependientes y no se cumple la condición MFCQ.

Intentando plantear el sistema KKT tradicional ($\lambda_0 = 1$):

$$\nabla f(\bar{x}) + \mu_1 \nabla g_1(\bar{x}) + \mu_2 \nabla g_2(\bar{x}) = \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

La primera ecuación requiere $-1 = 0$, lo que es una contradicción. Por lo tanto, no existen multiplicadores de KKT.

Sin embargo, planteando el sistema de Fritz John con $\lambda_0 = 0$:

$$0 \cdot \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ \mu_1 - \mu_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Cualquier elección con $\mu_1 = \mu_2 > 0$ proporciona una solución válida. El hecho de que $\lambda_0 = 0$ indica que el punto es geoméricamente singular, y el gradiente de la función objetivo no interviene en la estacionariedad.

Atención: Dificultades numéricas en presencia de multiplicadores singulares

Aunque el Teorema de Fritz John garantiza la existencia de multiplicadores en presencia de puntos singulares, este resultado suele ser indeseable desde el punto de vista algorítmico.

Si un método numérico converge a un punto donde $\lambda_0 = 0$, el algoritmo ignora la función objetivo $f(x)$ y realiza iteraciones destinadas únicamente a satisfacer la factibilidad de las restricciones. Por ello, en optimización no lineal es de gran importancia asegurar que se cumplan condiciones de regularidad como MFCQ para garantizar que $\lambda_0 = 1$ y mantener la convergencia hacia el óptimo de la función objetivo.

4.3. Condiciones de optimalidad de segundo orden

En esta sección se presentan las condiciones analíticas necesarias y suficientes de segundo orden para el problema de optimización con restricciones mixtas. Estas condiciones se evalúan sobre un subconjunto de direcciones factibles, denominado *cono crítico*, en el cual la información de primer orden no permite determinar la optimalidad debido a la anulación de las derivadas direccionales.

Definición 4.7 (Cono Crítico). Sea $\bar{x} \in D$ un punto estacionario del problema (4.1)-(4.2). Se define el **cono crítico** (o cono de direcciones críticas) asociado a $\bar{x}$, denotado por $K(\bar{x})$, como el conjunto de direcciones del cono de linealización $\mathcal{H}(\bar{x})$ que satisfacen la condición:

$$K(\bar{x}) = \{d \in \mathcal{H}(\bar{x}) \mid \langle \nabla f(\bar{x}), d \rangle \leq 0\}. \quad (4.16)$$

Utilizando la definición del cono de linealización, este conjunto equivale al sistema poliédrico:

$$K(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{cases} \langle \nabla f(\bar{x}), d \rangle \leq 0, \\ \langle \nabla g_i(\bar{x}), d \rangle \leq 0 \quad \forall i \in I(\bar{x}), \\ \langle \nabla h_i(\bar{x}), d \rangle = 0 \quad \forall i = 1, \dots, l \end{cases} \right\}.$$

Observación. Por la linealidad de las ecuaciones e inecuaciones que lo definen, $K(\bar{x})$ es un cono poliédrico cerrado. En adelante, supondremos que las funciones f, h y g son dos veces diferenciables en el punto $\bar{x}$.

El siguiente lema proporciona caracterizaciones algebraicas alternativas del cono crítico cuando se dispone de un vector de multiplicadores de Lagrange.

Lema 4.3 (Caracterización alternativa del cono crítico). Supongamos que $\bar{x}$ es un punto estacionario de Karush-Kuhn-Tucker y sea $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$ un vector de multiplicadores asociado.

El cono crítico $K(\bar{x})$ admite las siguientes representaciones equivalentes:

$$K(\bar{x}) = \{d \in \mathcal{H}(\bar{x}) \mid \langle \nabla f(\bar{x}), d \rangle = 0\} = \{d \in \mathcal{H}(\bar{x}) \mid \bar{\mu}_i \langle \nabla g_i(\bar{x}), d \rangle = 0 \quad \forall i \in I(\bar{x})\}. \quad (4.17)$$

Prueba. Sea $d \in \mathcal{H}(\bar{x})$. Multiplicando la condición de estacionariedad de KKT por el vector d , se obtiene:

$$\langle \nabla f(\bar{x}), d \rangle = - \left\langle \sum_{i=1}^l \bar{\lambda}_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \bar{\mu}_i \nabla g_i(\bar{x}), d \right\rangle.$$

Dado que $\langle \nabla h_i(\bar{x}), d \rangle = 0$ para todo $d \in \mathcal{H}(\bar{x})$, el primer término es nulo:

$$\langle \nabla f(\bar{x}), d \rangle = - \sum_{i \in I(\bar{x})} \bar{\mu}_i \langle \nabla g_i(\bar{x}), d \rangle.$$

Puesto que $\bar{\mu}_i \geq 0$ por viabilidad dual y $\langle \nabla g_i(\bar{x}), d \rangle \leq 0$ para $d \in \mathcal{H}(\bar{x})$, la suma del miembro derecho es no positiva. Al antecederle el signo negativo, se deduce que $\langle \nabla f(\bar{x}), d \rangle \geq 0$. Por la definición de $K(\bar{x})$ se requiere $\langle \nabla f(\bar{x}), d \rangle \leq 0$, por lo que la única forma de satisfacer ambas condiciones es que $\langle \nabla f(\bar{x}), d \rangle = 0$. Asimismo, para que una suma de términos no negativos sea nula, cada término individual debe ser cero: $\bar{\mu}_i \langle \nabla g_i(\bar{x}), d \rangle = 0$ para todo $i \in I(\bar{x})$, lo que demuestra la caracterización (4.17). ■

Ejemplo 4.15 (Cálculo del cono crítico). Considérese el problema de minimizar una función lineal sobre el primer cuadrante:

$$\begin{aligned} &\text{minimizar} && f(x) = x_1 + x_2 \\ &\text{subject to} && g_1(x) = -x_1 \leq 0, \\ &&& g_2(x) = -x_2 \leq 0 \end{aligned}$$

El mínimo global se alcanza en el origen $\bar{x} = (0, 0)^\top$, donde ambas restricciones son activas ($I(\bar{x}) = \{1, 2\}$). Los gradientes de las restricciones son $\nabla g_1 = (-1, 0)^\top$ y $\nabla g_2 = (0, -1)^\top$. El gradiente de la función objetivo es $\nabla f = (1, 1)^\top$.

Primero, el cono de linealización $\mathcal{H}(\bar{x})$ se define por las condiciones:

$$\langle (-1, 0)^\top, d \rangle = -d_1 \leq 0 \implies d_1 \geq 0, \quad \text{y} \quad -d_2 \leq 0 \implies d_2 \geq 0.$$

Es decir, $\mathcal{H}(\bar{x}) = \mathbb{R}_+^2$. Cualquier dirección con componentes no negativas es una dirección de linealización.

Para construir el cono crítico $K(\bar{x})$ añadimos la condición de no descenso de la función objetivo $\langle \nabla f(\bar{x}), d \rangle \leq 0$:

$$\langle (1, 1)^\top, d \rangle = d_1 + d_2 \leq 0.$$

Dado que $d \in \mathbb{R}_+^2$, la única solución es que ambas componentes sean nulas. Por lo tanto, el cono crítico se reduce al origen: $K(\bar{x}) = \{(0, 0)^\top\}$.

Para verificar la caracterización alternativa del Lema 4.3, resolvemos el sistema de primer orden $\nabla f + \mu_1 \nabla g_1 + \mu_2 \nabla g_2 = 0$:

$$\begin{pmatrix} 1 \\ 1 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \mu_1 = 1, \quad \mu_2 = 1.$$

Al ser ambos multiplicadores estrictamente positivos, las restricciones activas impiden el descenso de la función objetivo en cualquier dirección factible no nula. Dado que el cono crítico se reduce a $\{0\}$, las condiciones de segundo orden se satisfacen de forma vacía.

Corolario 4.1 (Cono crítico bajo complementariedad estricta). Supongamos que el punto estacionario $\bar{x}$ con multiplicador $(\bar{\lambda}, \bar{\mu})$ satisface la condición de complementariedad estricta (Definición 4.4).

Al ser $\bar{\mu}_i > 0$ para todo $i \in I(\bar{x})$, la caracterización del Lema 4.3 implica que $\langle \nabla g_i(\bar{x}), d \rangle = 0$. Bajo esta hipótesis, las restricciones de desigualdad activas se comportan localmente como restricciones de igualdad, por lo que el cono crítico es un subespacio vectorial:

$$K(\bar{x}) = \left\{ d \in \mathbb{R}^n \mid \begin{aligned} &\langle \nabla h_i(\bar{x}), d \rangle = 0 \quad \forall i = 1, \dots, l \\ &\langle \nabla g_i(\bar{x}), d \rangle = 0 \quad \forall i \in I(\bar{x}) \end{aligned} \right\}.$$

Consideramos en primer lugar el caso donde los gradientes de las restricciones activas son linealmente independientes (LICQ) o las restricciones son afines, lo que garantiza la unicidad del vector de multiplicadores.

Teorema 4.8 (Condición necesaria de segundo orden bajo LICQ o linealidad). Supongamos que $\bar{x} \in D$ es un minimizador local del problema y que f, h, g son dos veces diferenciables en $\bar{x}$.

Si el punto satisface la condición de independencia lineal (LICQ) de las restricciones activas, o si todas las restricciones son afines, entonces, para el multiplicador de Lagrange $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$ (el cual es único bajo LICQ), la Hessiana de la función Lagrangiana es semidefinida positiva sobre el cono crítico:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}, \bar{\mu}) d, d \rangle \geq 0 \quad \forall d \in K(\bar{x}). \quad (4.18)$$

Prueba. Fijemos $d \in K(\bar{x})$. Bajo LICQ o linealidad, el cono de Bouligand coincide con el cono de linealización (Teorema 4.2), por lo que $d \in \mathcal{B}_D(\bar{x})$. Esto implica la existencia de una trayectoria factible $x(t) = \bar{x} + td + r(t) \in D$ para $t > 0$ suficientemente pequeño, donde $\|r(t)\| = o(t)$.

Al ser $\bar{x}$ un minimizador local, se tiene $f(x(t)) - f(\bar{x}) \geq 0$. Para el multiplicador $(\bar{\lambda}, \bar{\mu}) \in \mathcal{M}(\bar{x})$, se cumple $\bar{\mu}_i g_i(\bar{x}) = 0$.

Dado que $x(t) \in D$, se verifica $h_i(x(t)) = 0$ y $g_i(x(t)) \leq 0$. Por lo tanto:

$$\begin{aligned} 0 &\leq f(x(t)) - f(\bar{x}) \\ &\leq f(x(t)) - f(\bar{x}) + \sum_{i=1}^l \bar{\lambda}_i h_i(x(t)) + \sum_{i=1}^m \bar{\mu}_i g_i(x(t)) \\ &= L(x(t), \bar{\lambda}, \bar{\mu}) - L(\bar{x}, \bar{\lambda}, \bar{\mu}). \end{aligned}$$

Utilizando el desarrollo de Taylor de la función Lagrangiana en torno a $\bar{x}$:

$$0 \leq \langle \nabla_x L(\bar{x}, \bar{\lambda}, \bar{\mu}), td + r(t) \rangle + \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}, \bar{\mu})(td + r(t)), td + r(t) \rangle + o(t^2).$$

Por la condición de estacionariedad $\nabla_x L(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$, el término de primer orden es nulo. Dividiendo por $t^2 > 0$ y tomando el límite cuando $t \rightarrow 0^+$, los términos dependientes de $r(t)$ se anulan, concluyendo que $\langle \nabla_{xx}^2 L(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle \geq 0$. ■

Ejemplo 4.16 (Hessiana de la Lagrangiana en el cono crítico). Considérese el problema de maximizar la altura sobre una región acotada por una parábola, formulado

$$\begin{aligned} \text{minimizar} \quad & f(x) = -x_2 \\ \text{subject to} \quad & g(x) = x_1^2 - x_2 \leq 0 \end{aligned}$$

El conjunto factible D es el área superior a la parábola $x_2 = x_1^2$. Evaluamos las condiciones en el origen $\bar{x} = (0, 0)^\top$. La restricción es activa ($g(0) = 0$).

El gradiente de la restricción es $\nabla g(x) = (2x_1, -1)^\top$, que en el origen resulta en $\nabla g(\bar{x}) = (0, -1)^\top \neq 0$, por lo que se cumple LICQ. El sistema de primer orden $\nabla f(\bar{x}) + \mu \nabla g(\bar{x}) = 0$ exige $\mu = -1$. Dado que las condiciones KKT requieren $\mu \geq 0$, el punto no satisface las condiciones de primer orden.

Para ilustrar el análisis de segundo orden, modifiquemos el problema a:

$$\begin{aligned} \text{minimizar} \quad & f(x) = x_2 \\ \text{subject to} \quad & g(x) = x_1^2 - x_2 \leq 0. \end{aligned}$$

El sistema KKT es:

$$\begin{pmatrix} 0 \\ 1 \end{pmatrix} + \mu \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \bar{\mu} = 1.$$

El multiplicador es admisible ($\bar{\mu} = 1 \geq 0$). Determinamos el cono crítico $K(\bar{x})$ mediante la caracterización alternativa. Al ser $\bar{\mu} = 1 > 0$, se requiere: $\langle \nabla g(\bar{x}), d \rangle = -d_2 = 0 \implies d_2 = 0$. Por lo tanto, el cono crítico es el eje horizontal: $K(\bar{x}) = \{(d_1, 0)^\top \mid d_1 \in \mathbb{R}\}$.

La Hessiana de la Lagrangiana $L(x, \bar{\mu}) = x_2 + x_1^2 - x_2 = x_1^2$ en $\bar{x}$ está dada por:

$$\nabla_{xx}^2 L(\bar{x}, \bar{\mu}) = \nabla^2 f(\bar{x}) + \bar{\mu} \nabla^2 g(\bar{x}) = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} + (1) \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}.$$

Para cualquier dirección $d \in K(\bar{x})$, evaluamos la forma cuadrática:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\mu})d, d \rangle = \begin{pmatrix} d_1 & 0 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} d_1 \\ 0 \end{pmatrix} = 2d_1^2 \geq 0.$$

La condición necesaria de segundo orden se verifica. Este ejemplo muestra cómo la curvatura de la restricción, representada en el término de segundo orden de la Lagrangiana por el multiplicador positivo, compensa la falta de curvatura de la función objetivo.

Observación (Multiplicadores no únicos bajo MFCQ). La demostración del Teorema 4.8 no se aplica directamente bajo la condición de Mangasarian-Fromovitz (MFCQ), dado que el conjunto de multiplicadores $\mathcal{M}(\bar{x})$ es un poliedro compacto pero no necesariamente un único punto. En este caso, se requiere un análisis basado en desarrollos de segundo orden y teoremas de separación.

Proposición 4.4 (Aproximación de segundo orden de curvas factibles). Sean h y g funciones dos veces diferenciables en $\bar{x} \in D$. Para que exista una sucesión $\{t_k\} \rightarrow 0^+$ tal que un par de vectores $(d, w) \in \mathbb{R}^n \times \mathbb{R}^n$ cumpla:

$$\text{dist}(\bar{x} + t_k d + t_k^2 w, D) = o(t_k^2), \quad (4.19)$$

es necesario que $d \in \mathcal{B}_D(\bar{x})$ y que el vector de segundo orden w satisfaga el sistema:

$$\langle \nabla h_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 h_i(\bar{x})d, d \rangle = 0 \quad \forall i \in \{1, \dots, l\}, \quad (4.20)$$

$$\langle \nabla g_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 g_i(\bar{x})d, d \rangle \leq 0 \quad \forall i \in I(\bar{x}, d), \quad (4.21)$$

donde $I(\bar{x}, d) = \{i \in I(\bar{x}) \mid \langle \nabla g_i(\bar{x}), d \rangle = 0\}$ representa el conjunto de restricciones activas a lo largo de la dirección d .

Prueba. La demostración se omite por brevedad; se basa en la aplicación del desarrollo de Taylor de segundo orden y la condición de factibilidad de la trayectoria $x^k = \bar{x} + t_k d + t_k^2 w + o(t_k^2)$. ■

Nota: Interpretación cinemática

La caracterización de la Proposición 4.4 admite una interpretación física al modelar la trayectoria $x(t)$ como el movimiento de una partícula en el tiempo t :

- El vector $d \in \mathbb{R}^n$ representa la **velocidad** (dirección tangente de primer orden), la cual debe cumplir la condición de no apuntar hacia el exterior del conjunto factible ($\langle \nabla g, d \rangle \leq 0$).
- El vector $w \in \mathbb{R}^n$ representa la **aceleración**. Las condiciones de segundo orden (4.20) y (4.21) determinan la curvatura necesaria de la trayectoria para mantener la factibilidad.

Ejemplo 4.17 (Ejemplo de trayectoria de segundo orden). Analicemos las condiciones de segundo orden para un punto restringido a yacer dentro del disco unitario:

$$D = \left\{ x \in \mathbb{R}^2 \mid g(x) = \frac{1}{2}(x_1^2 + x_2^2 - 1) \leq 0 \right\}.$$

Consideremos el punto $\bar{x} = (0, 1)^\top$, en el cual la restricción es activa ($g(0, 1) = 0$). Evaluando las derivadas en $\bar{x}$:

$$\nabla g(\bar{x}) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \nabla^2 g(\bar{x}) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Buscamos construir una trayectoria $x(t) = \bar{x} + td + t^2 w + o(t^2)$ factible en D para $t > 0$.

1. Dirección de primer orden (Velocidad d):

Por la definición de $d \in \mathcal{H}(\bar{x})$, el vector velocidad debe cumplir $\langle \nabla g(\bar{x}), d \rangle \leq 0 \implies d_2 \leq 0$. Consideremos la dirección horizontal unitaria $d = (1, 0)^\top$, para la cual se tiene $\langle \nabla g(\bar{x}), d \rangle = 0$ (la restricción es activa a lo largo de d).

2. Dirección de segundo orden (Aceleración w):

Como la restricción es activa a lo largo de d , el índice pertenece a $I(\bar{x}, d)$. La Proposición 4.4 requiere que w satisfaga:

$$\langle \nabla g(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 g(\bar{x}) d, d \rangle \leq 0.$$

Sustituyendo los vectores correspondientes:

$$w_2 + \frac{1}{2}(1) \leq 0 \implies w_2 \leq -\frac{1}{2}.$$

Este resultado muestra que para una velocidad horizontal unitaria, la trayectoria requiere una aceleración con componente vertical negativa de al menos 1/2 (aceleración centrípeta) para mantener la factibilidad en D .

Nota: Dificultad del análisis bajo MFCQ

Bajo la condición LICQ, el multiplicador de Lagrange es único, por lo que el análisis de la curvatura se realiza con un único operador. Bajo MFCQ, al no haber unicidad, el conjunto de multiplicadores es un poliedro. El análisis requiere determinar si existe algún multiplicador que satisfaga la condición de semidefinición positiva para cada dirección crítica específica.

Teorema 4.9 (Condición necesaria de segundo orden bajo MFCQ). Sea $\bar{x}$ un minimizador local de (4.1) que satisface la condición de regularidad de Mangasarian-Fromovitz (MFCQ).

Para cada dirección crítica $d \in K(\bar{x})$, existe un vector de multiplicadores de Lagrange $(\lambda, \mu) \in \mathcal{M}(\bar{x})$ tal que:

$$\langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle \geq 0. \quad (4.22)$$

Prueba. Fijemos $d \in K(\bar{x})$. Definimos los conjuntos:

$$S_1(d) = \left\{ (\alpha, y, z) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m \mid \begin{array}{l} \alpha = \langle \nabla f(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 f(\bar{x}) d, d \rangle \\ y_i = \langle \nabla h_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 h_i(\bar{x}) d, d \rangle, \quad i = 1, \dots, l \\ z_i = \langle \nabla g_i(\bar{x}), w \rangle + \frac{1}{2} \langle \nabla^2 g_i(\bar{x}) d, d \rangle, \quad i = 1, \dots, m \\ w \in \mathbb{R}^n \end{array} \right\}$$

$$S_2(d) = \left\{ (\alpha, y, z) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m \mid \alpha < 0, y_i = 0 \forall i, z_i \leq 0 \forall i \in I(\bar{x}, d) \right\}.$$

El conjunto $S_1(d)$ es un espacio afín y $S_2(d)$ es un cono convexo abierto. Si la intersección de ambos fuera no vacía, existiría un vector $w \in \mathbb{R}^n$ tal que satisfaría las condiciones (4.20) y (4.21) con un decremento estricto de segundo orden en la función objetivo, lo que contradice la hipótesis de que $\bar{x}$ es un mínimo local. Por tanto, $S_1(d) \cap S_2(d) = \emptyset$. Por el Teorema de Separación de Conjuntos Convexos, existe un vector no nulo $(\lambda_0, \lambda, \mu) \in \mathbb{R} \times \mathbb{R}^l \times \mathbb{R}^m \setminus \{0\}$ tal que para todo $p_1 \in S_1(d)$ y $p_2 \in S_2(d)$:

$$\langle (\lambda_0, \lambda, \mu), p_2 \rangle \leq 0 \leq \langle (\lambda_0, \lambda, \mu), p_1 \rangle.$$

Analizando la geometría de los conjuntos, se deduce que $\lambda_0 \geq 0$ y $\mu_i \geq 0$ para $i \in I(\bar{x}, d)$, definiendo $\mu_i = 0$ para los índices restantes. Al ser la dirección w libre en el espacio afín, el término que la multiplica debe ser nulo para garantizar la acotación inferior, lo que da:

$$\lambda_0 \nabla f(\bar{x}) + \sum_{i=1}^l \lambda_i \nabla h_i(\bar{x}) + \sum_{i \in I(\bar{x})} \mu_i \nabla g_i(\bar{x}) = 0.$$

Si $\lambda_0 = 0$, se tendría una combinación lineal nula de los gradientes de las restricciones con coeficientes no negativos, lo cual contradice la condición MFCQ (Proposición 4.2). Por lo tanto, $\lambda_0 > 0$. Dividiendo el sistema por λ_0 y redefiniendo las variables duales, se demuestra que (λ, μ) es un vector de multiplicadores en $\mathcal{M}(\bar{x})$.

Evalutando la desigualdad de separación para el término constante de $S_1(d)$ y normalizando por λ_0 , se obtiene:

$$\langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle \geq 0,$$

lo cual concluye la demostración. ■

Ejemplo 4.18 (Análisis de segundo orden bajo MFCQ). Considérese el problema de optimización en $\mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && f(x) = x_1^2 - x_2^2 \\ &\text{subject to} && g_1(x) = x_2 - x_1 \leq 0, \\ &&& g_x(x) = x_2 + x_1^2 \leq 0 \end{aligned}$$

La función objetivo tiene un punto de silla en el origen. Las restricciones exigen que $x_1^2 \leq x_2 \leq -x_1^2$, lo que restringe el conjunto factible al único punto $D = \{(0, 0)^T\}$, el cual es el mínimo global.

Evalamos las restricciones en el origen $\bar{x} = (0, 0)^T$. Ambas son activas. Los gradientes son $\nabla g_1(\bar{x}) = (0, 1)^T$ y $\nabla g_2(\bar{x}) = (0, 1)^T$, por lo que no se satisface LICQ. Sin embargo, el sistema dual $\mu_1(0, 1)^T + \mu_2(0, 1)^T = 0$ con $\mu \geq 0$ tiene por solución única $\mu_1 = \mu_2 = 0$, de donde se verifica MFCQ.

Para el sistema de primer orden en $\bar{x}$, al ser $\nabla f(\bar{x}) = 0$, el único multiplicador de KKT es $\bar{\mu} = (0, 0)^T$. El cono crítico se define por las inecuaciones $\langle \nabla g_i, d \rangle \leq 0$:

$$d_2 \leq 0 \implies K(\bar{x}) = \{(d_1, d_2)^T \mid d_2 \leq 0\}.$$

El cono crítico corresponde al semiplano inferior. La Hessiana de la Lagrangiana en $\bar{x}$ con $\bar{\mu} = 0$ está dada por:

$$\nabla_{xx}^2 L(\bar{x}, \bar{\mu}) = \nabla^2 f(\bar{x}) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}.$$

Evalando la forma cuadrática para $d = (d_1, d_2)^T \in K(\bar{x})$:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\mu}) d, d \rangle = 2d_1^2 - 2d_2^2.$$

En este caso, la condición necesaria del Teorema 4.9 no se cumple para todas las direcciones críticas (por ejemplo, para $d = (0, -1)^T \in K(\bar{x})$ la forma cuadrática es negativa). Esto ocurre debido a la geometría del conjunto factible, el cual está restringido a un único punto, impidiendo la existencia de curvas factibles no triviales en las direcciones críticas.

Ejemplo 4.19 (No existencia de un multiplicador universal). El siguiente ejemplo muestra por qué en el Teorema 4.9 los multiplicadores pueden depender de la dirección crítica considerada. Sea $n = m = 3$, $l = 0$. Consideremos el problema $\min f(x) = x_3$ sujeto a $g(x) \leq 0$, con:

$$g(x) = \begin{pmatrix} 2\sqrt{3}x_1x_2 - 2x_2^2 - x_3 \\ -2\sqrt{3}x_1x_2 - 2x_1^2 - x_3 \\ -3x_1^2 + x_2^2 - x_3 \end{pmatrix} \leq 0.$$

El origen $\bar{x} = (0, 0, 0)^\top$ es el mínimo global. Los gradientes en $\bar{x}$ son $\nabla f(0) = (0, 0, 1)^\top$ y $\nabla g_i(0) = (0, 0, -1)^\top$ para todo i . Se verifica la condición MFCQ (e.g., con $\bar{d} = (0, 0, 1)^\top$, $\langle \nabla g_i, \bar{d} \rangle = -1 < 0$). El conjunto de multiplicadores es:

$$\mathcal{M}(0) = \{\mu \in \mathbb{R}_+^3 \mid \mu_1 + \mu_2 + \mu_3 = 1\}.$$

El cono crítico es $K(0) = \{d \in \mathbb{R}^3 \mid d_3 = 0\}$. Evaluamos las direcciones críticas $d^1 = (1, 0, 0)^\top$ y $d^2 = (0, 1, 0)^\top$. Para un multiplicador $\mu \in \mathcal{M}(0)$, las formas cuadráticas correspondientes son:

$$\langle \nabla_{xx}^2 L(0, \mu) d^1, d^1 \rangle = -4\mu_2 - 6\mu_3,$$

$$\langle \nabla_{xx}^2 L(0, \mu) d^2, d^2 \rangle = -4\mu_1 + 2\mu_3.$$

Para satisfacer la condición necesaria en d^1 se requiere que $-4\mu_2 - 6\mu_3 \geq 0$, lo que implica $\mu_2 = \mu_3 = 0$, y por tanto, $\mu_1 = 1$. Sin embargo, con este multiplicador, la forma cuadrática en la dirección d^2 resulta negativa.

Por lo tanto, no existe un único multiplicador de Lagrange que satisfaga la condición de semidefinición positiva para todas las direcciones críticas simultáneamente, lo que demuestra que la dependencia del multiplicador respecto a la dirección crítica es estructuralmente necesaria bajo MFCQ.

Teorema 4.10 (Condición suficiente de segundo orden). *Supongamos que f, h, g son dos veces diferenciables en $\bar{x} \in D$. Sea $\bar{x}$ un punto estacionario ($\mathcal{M}(\bar{x}) \neq \emptyset$).*

*Si se cumple la **condición de curvatura estricta**:*

$$\forall d \in K(\bar{x}) \setminus \{0\} \quad \exists (\lambda, \mu) \in \mathcal{M}(\bar{x}) \text{ tal que } \langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle > 0, \quad (4.23)$$

*entonces f satisface la condición de **crecimiento cuadrático** en $\bar{x}$: existen una vecindad U de $\bar{x}$ y una constante $\beta > 0$ tales que*

$$f(x) - f(\bar{x}) \geq \beta \|x - \bar{x}\|^2 \quad \forall x \in D \cap U.$$

En consecuencia, $\bar{x}$ es un minimizador local estricto de (4.1).

Prueba. Supongamos, por reducción al absurdo, que se cumple (4.23) pero no el crecimiento cuadrático. Esto implica la existencia de una sucesión $\{x^k\} \subset D \setminus \{\bar{x}\}$ convergiendo a $\bar{x}$ tal que:

$$f(x^k) - f(\bar{x}) < \frac{1}{k} \|x^k - \bar{x}\|^2 \quad \forall k \in \mathbb{N}.$$

Sea $d^k = \frac{x^k - \bar{x}}{\|x^k - \bar{x}\|}$. Por compacidad, existe una subsucesión convergente $d^k \rightarrow d$, con $\|d\| = 1$. Dado que el conjunto factible es regular en el límite, se tiene $d \in \mathcal{H}(\bar{x})$. Tomando el límite se deduce que la derivada direccional satisface $\langle \nabla f(\bar{x}), d \rangle \leq 0$. Por lo tanto, la dirección límite pertenece al cono crítico: $d \in K(\bar{x}) \setminus \{0\}$.

Por la hipótesis (4.23), para esta dirección d existe un multiplicador $(\lambda, \mu) \in \mathcal{M}(\bar{x})$ tal que la Hessiana asociada es estrictamente positiva. Para los puntos de la sucesión se cumple:

$$\sum_{i=1}^l \lambda_i h_i(x^k) + \sum_{i=1}^m \mu_i g_i(x^k) \leq 0.$$

Puesto que en $\bar{x}$ la suma es nula por complementariedad, podemos acotar la diferencia de la función objetivo mediante la diferencia de la Lagrangiana:

$$\frac{1}{k} \|x^k - \bar{x}\|^2 > f(x^k) - f(\bar{x}) \geq L(x^k, \lambda, \mu) - L(\bar{x}, \lambda, \mu).$$

Utilizando el desarrollo de Taylor de segundo orden en $\bar{x}$ y la estacionariedad de la Lagrangiana:

$$\frac{1}{k} \|x^k - \bar{x}\|^2 > \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) (x^k - \bar{x}), x^k - \bar{x} \rangle + o(\|x^k - \bar{x}\|^2).$$

Dividiendo por la norma al cuadrado y calculando el límite para $k \rightarrow \infty$, obtenemos $0 \geq \frac{1}{2} \langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle$, lo cual contradice la hipótesis (4.23). ■

Ejemplo 4.20 (Suficiencia de segundo orden con multiplicadores dependientes). Considérese el problema de optimización en $\mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && f(x) = x_1^2 - x_2^2 \\ &\text{subject to} && g_1(x) = x_2 - x_1^2 \leq 0, \\ &&& g_2(x) = x_1 - x_2^2 \leq 0 \end{aligned}$$

El origen es un punto de silla de la función objetivo, y las restricciones definen una región que acota el conjunto factible en el primer cuadrante. En $\bar{x} = 0$, se satisface LICQ y el sistema KKT da por solución única $\bar{\mu} = (0, 0)^\top$.

El cono crítico se define por las condiciones de linealización: $d_2 \leq 0$ y $d_1 \leq 0 \implies K(\bar{x}) = \{d \in \mathbb{R}^2 \mid d_1 \leq 0, d_2 \leq 0\}$. Dado que $\bar{\mu} = 0$, la Hessiana de la Lagrangiana en $\bar{x}$ coincide con la de la función objetivo:

$$\nabla_{xx}^2 L(\bar{x}, \bar{\mu}) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}.$$

Para cualquier dirección no nula en $K(\bar{x})$ (por ejemplo, $d = (0, -1)^\top$), la forma cuadrática asociada es negativa:

$$\langle \nabla_{xx}^2 L(\bar{x}, \bar{\mu}) d, d \rangle = 2d_1^2 - 2d_2^2 < 0.$$

En este caso, la condición suficiente no se satisface, lo cual es consistente con el hecho de que el origen no es un mínimo local (por ejemplo, para la trayectoria $x(t) = (-t, -t)^\top$ se tiene factibilidad y decremento de la función objetivo). El análisis de segundo orden identifica de este modo la existencia de direcciones de descenso no lineales.

Atención: Casos no concluyentes en el análisis de segundo orden

Al igual que en el cálculo de una variable, existe una diferencia entre las condiciones necesarias y las suficientes de segundo orden. Si para una dirección crítica no nula se cumple que $\langle \nabla_{xx}^2 L(\bar{x}, \lambda, \mu) d, d \rangle = 0$, el término de segundo orden es nulo y el análisis de segundo orden no es concluyente. En este caso, para determinar si el punto es un mínimo, un máximo o un punto de silla, es necesario recurrir a desarrollos de Taylor de orden superior o a análisis topológicos directos.

Ejercicios del Capítulo 4

Parte I: Mecánica Primal-Dual y Condición de Mangasarian-Fromovitz

Ejercicio 4.1. Completar los detalles algebraicos (específicamente la implicación recíproca mediante el Teorema de la Alternativa de Motzkin) omitidos en el texto para la demostración de la Proposición 4.2 (Condición dual de Mangasarian-Fromovitz).

Ejercicio 4.2. Mediante una representación geométrica, formular una hipótesis sobre la solución del problema $\min(x_1 - 1)^2 + (x_2 + 1)^2$ sujeto a $x_1 - x_2 \leq 0$ y $(x_1 - 2)^2 + (x_2 - 1)^2 \leq 1$. Confirmar la hipótesis resolviendo el sistema mediante KKT.

Ejercicio 4.3. Encontrar todos los valores del parámetro $\sigma \in \mathbb{R}$ para los cuales el punto $\bar{x} = (\sqrt{3}/2 + 1, 1/2) \in \mathbb{R}^2$ es una solución del problema $\min x_1 + x_2$ sujeto a $(x_1 - 1)^2 + (x_2 - 1)^2 \leq 1$ y $(x_1 - 2)^2 + x_2^2 \leq 1$.

Ejercicio 4.4. Encontrar todos los valores del parámetro $\sigma \in \mathbb{R}$ para los cuales el punto $\bar{x} = (1, 1) \in \mathbb{R}^2$ es una solución local del problema $\min -x_1 + \sigma x_2$ sujeto a $x_1^2 + x_2^2 \leq 2$ y $x_1^2 - x_2 \leq 0$.

Ejercicio 4.5. Encontrar de manera analítica la solución global del problema $\max 2x_1 + 4x_2 - \frac{1}{2}x_3^2$ sujeto a $x_1^2 + x_2^2 - x_3 \leq 4$ y $x_1 - x_2 + x_3^2 \leq 1$.

Ejercicio 4.6. Demostrar que la solución del problema $\min x_2$ sujeto a $(x_1 - 1)^2 + x_2^2 \leq 1$ y $(x_1 + 1)^2 + x_2^2 \leq 1$ no satisface las condiciones de KKT e interpretar el resultado en relación con el comportamiento con restricciones de igualdad analizado en el Capítulo 2.

Ejercicio 4.7. Sea $\bar{x}$ un minimizador local del problema sobre el simplex escalado: $\min f(x)$ sujeto a $x \geq 0, \sum_{i=1}^n x_i = t$. Demostrar que, si $I_+(\bar{x}) = \{i \mid \bar{x}_i > 0\}$ denota el soporte estrictamente positivo, entonces $\nabla_{x_i} f(\bar{x}) = \min_j \nabla_{x_j} f(\bar{x})$ para todo $i \in I_+(\bar{x})$.

Ejercicio 4.8. Sean $Q \in \mathbb{R}^{n \times n}$, $q \in \mathbb{R}^n$, $B \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$. Demostrar que el conjunto de puntos de KKT de un problema de programación cuadrática constituye una unión finita de conjuntos poliédricos en el espacio extendido $\mathbb{R}^n \times \mathbb{R}^m$.

Ejercicio 4.9. Demostrar que $\bar{x} \in \mathbb{R}^n$ es un punto KKT de $\min f(x)$ sujeto a $h(x) = 0$ y $g(x) \leq 0$ si, y solamente si, existe $(\bar{\beta}, \bar{\gamma}) \in \mathbb{R}^l \times \mathbb{R}^m$ tal que el siguiente sistema no lineal de ecuaciones se anula:

$$F(x, \beta, \gamma) = \begin{pmatrix} \nabla_x L(x, \beta, \max\{0, \gamma\}) \\ h(x) \\ -g(x) + \min\{0, \gamma\} \end{pmatrix} = 0.$$

Ejercicio 4.10. Sea $\bar{x} \in \mathbb{R}^n$ un punto factible de $\min f(x)$ sujeto a $g(x) \leq 0$. Supongamos que $\bar{x}$ satisface MFCQ pero no es estacionario. Demostrar que existe una dirección de descenso para f que apunta hacia el interior del conjunto factible D .

Ejercicio 4.11. Sean $(\bar{x}, \bar{\mu})$ y $(\hat{x}, \hat{\mu})$ dos pares KKT para un problema convexo. Demostrar que los pares cruzados $(\bar{x}, \hat{\mu})$ y $(\hat{x}, \bar{\mu})$ también satisfacen las condiciones KKT.

Ejercicio 4.12. Supongamos que un problema de minimización convexo satisface Slater. Dada una solución $\bar{x}$, determinar un escalar $M > 0$ tal que $\|\bar{\mu}\| \leq M$ para todo multiplicador de Lagrange.

Ejercicio 4.13. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa dos veces diferenciable y $D = \{x \in \mathbb{R}^n \mid Ax = a, x \geq 0\}$ un conjunto poliédrico acotado y no vacío. Demostrar que el problema modificado $\min \|\nabla f(x) + A^T y - z\|^2 + \|Ax - a\|^2 + \langle x, z \rangle^2$ sujeto a $x \geq 0, z \geq 0$ admite por lo menos un punto KKT que resuelve el problema original.

Parte II: Condiciones de Segundo Orden

Ejercicio 4.14. A partir de las demostraciones, demostrar la afirmación recíproca del Teorema 4.10: si $\bar{x}$ satisface MFCQ y la condición de crecimiento cuadrático, entonces se satisface la condición necesaria de segundo orden.

Ejercicio 4.15. Resolver de forma sistemática los siguientes problemas $\min f(x)$ sujeto a $x \in D$:

1. $f(x) = x_1^2 + x_2^2$, con $D = \{x \in \mathbb{R}^2 \mid 2x_1 + x_2 \geq 2, x_1 + 2x_2 \leq \sigma\}$.
2. $f(x) = \log x_1 - x_2$, con $D = \{x \in \mathbb{R}^2 \mid 2x_1 + x_2 \geq 1, -x_1 + x_2 \leq 1, 2x_1 - x_2 \leq 3\}$.
3. $f(x) = 2x_1^2 + x_2^2 + 2x_3^2 - x_1x_3$, con $D = \{x \in \mathbb{R}^3 \mid x_1 - 3x_2 + 2x_3 \leq 1, 2x_1 + x_2 \leq 10\}$.
4. $f(x) = \sum_{j=1}^n (x_j - a_j)^2$, sujeto a $\sum x_j^2 \leq 1$ y $\sum x_j = 0$.

Ejercicio 4.16. Demostrar analíticamente que $\min(x_1 + 1)^3$ sujeto a $0 \leq x_1 + x_2 \leq x_1^3 + \sigma$ tiene soluciones para todo $\sigma \in \mathbb{R}$ y determinar dichas soluciones.

Ejercicio 4.17. Considere un problema de programación cuadrática sobre la bola euclidiana $\|x\| \leq \delta$. Demostrar que $\bar{x}$ es un minimizador global si y solamente si existe $\bar{\mu} \in \mathbb{R}_+$ tal que $(Q + \bar{\mu}I)\bar{x} = -q$, $\|\bar{x}\| \leq \delta$, $\bar{\mu}(\|\bar{x}\| - \delta) = 0$, y la matriz Hessiana $(Q + \bar{\mu}I)$ es semidefinida positiva.

Ejercicio 4.18. Demostrar la desigualdad clásica de las medias aritmética y geométrica utilizando KKT en $\max \prod x_i$ sujeto a $\sum x_i = 1, x_i \geq 0$.

Ejercicio 4.19. Verificar que $\bar{x}$ es una solución local del problema modificado $\min f(x)$ sujeto a $h(x) = 0$ y $g_j(x) + \sigma_j^2 = 0$. Plantee las condiciones de KKT e interprete la pérdida de fuerza en el análisis de segundo orden comparado con el directo.

Parte III: Tópicos Avanzados - Dualidad, Conos Convexos y KKT Singular

Ejercicio 4.20. Considérese $\min x_1x_2$ sujeto a $x_1^2 + x_2^2 \leq 2$. Formule el sistema KKT, demuestre que hay 4 puntos estacionarios, proyecte la Hessiana sobre el cono crítico e identifique mínimos y máximos locales.

Ejercicio 4.21. Demuestre rigurosamente, utilizando la separación de conos convexos cerrados, el Lema de Farkas (Lema 4.1) para el sistema dual homogéneo y explique cómo garantiza la existencia de MFCQ.

Ejercicio 4.22. Sea $\min(x_1 - 2)^2 + x_2^2$ sujeto a $-x_1^3 + x_2 \leq 0$ y $-x_1^3 - x_2 \leq 0$. Demuestre que se viola LICQ, que KKT no tiene solución, y plantee el sistema de Fritz John (Teorema 4.7) hallando $(\lambda_0, \mu_1, \mu_2) \neq 0$.

Ejercicio 4.23. Demuestre, utilizando la regla de la cadena multivariable, que si un problema es sometido a una transformación afín biyectiva $x = Ay + b$, los multiplicadores de Lagrange KKT son invariantes.

Ejercicio 4.24. Considere $\min -x_1$ sujeto a $x_1^2 + x_2^2 = 1$ y su relajación convexa $x_1^2 + x_2^2 \leq 1$. Resuelva ambos sistemas KKT y demuestre por qué la relajación descarta al maximizador del problema original.

5. Elementos de la Teoría de Dualidad

La teoría de dualidad consiste en asociar a un problema de optimización original (primal) un problema alternativo (dual) cuyas propiedades aportan información cuantitativa y cualitativa sobre el primero. En el caso convexo, y muy especialmente en programación lineal, la relación entre ambos es simétrica y permite no solo resolver problemas complejos de forma indirecta, sino también fundamentar las técnicas computacionales. Incluso bajo ausencia de convexidad, el esquema dual proporciona cotas inferiores globales de gran utilidad en la resolución numérica de problemas combinatorios.

5.1. Dualidad en programación lineal

Sea el programa lineal en su forma de minimización, al cual nos referiremos como el **problema primal**:

$$\min \langle c, x \rangle \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid Bx \geq b\}, \quad (5.1)$$

donde $B \in \mathbb{R}^{m \times n}$, $c \in \mathbb{R}^n$ y $b \in \mathbb{R}^m$. El **problema dual** asociado es el programa de maximización:

$$\max \langle b, \mu \rangle \quad \text{sujeto a} \quad \mu \in \Delta = \{\mu \in \mathbb{R}^m \mid B^T \mu = c, \mu \geq 0\}. \quad (5.2)$$

Si el problema primal tiene n variables y m restricciones, el dual se define sobre m variables (una por cada restricción primal) y cuenta con n restricciones de igualdad (una por cada variable primal).

Proposición 5.1 (Teorema de Dualidad Débil). Para cualesquiera puntos factibles $x \in D$ y $\mu \in \Delta$, se cumple:

$$\langle c, x \rangle \geq \langle b, \mu \rangle. \quad (5.3)$$

Prueba. Como $Bx \geq b$ y $\mu \geq 0$, es inmediato que $\langle \mu, Bx \rangle \geq \langle \mu, b \rangle$. Usando la definición de operador adjunto y la restricción dual $B^T \mu = c$:

$$\langle c, x \rangle = \langle B^T \mu, x \rangle = \langle \mu, Bx \rangle \geq \langle \mu, b \rangle = \langle b, \mu \rangle. \quad \blacksquare$$

Cualquier punto factible dual proporciona una cota inferior del valor óptimo primal, y recíprocamente, cualquier punto factible primal acota superiormente al problema dual.

Nota: Interpretación de la Dualidad Débil

Si encontramos $\bar{x} \in D$ y $\bar{\mu} \in \Delta$ tales que $\langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle$, la desigualdad (5.3) fuerza a que $\bar{x}$ sea un mínimo global del primal y $\bar{\mu}$ un máximo global del dual.

Teorema 5.1 (Caracterización de Optimalidad). Un punto $\bar{x}$ es una solución del problema primal (5.1) si, y solo si, existe un punto $\bar{\mu}$ que es factible para el problema dual (5.2) y tal que:

$$\langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle, \quad (5.4)$$

es decir, los valores de las funciones objetivo de ambos problemas coinciden.

Más aún, la última afirmación es equivalente a decir que $\bar{\mu}$ es una solución óptima del problema dual (5.2), o que $\bar{\mu}$ es un multiplicador de Lagrange asociado a la solución $\bar{x}$ del problema primal.

Prueba. Por las condiciones necesarias y suficientes de optimalidad de primer orden para problemas afines, $\bar{x}$ es una solución de (5.1) si, y solo si, existe $\bar{\mu} \in \mathbb{R}_+^m$ tal que:

$$c - B^T \bar{\mu} = 0, \quad b - B\bar{x} \leq 0, \quad \langle \bar{\mu}, b - B\bar{x} \rangle = 0.$$

Observamos de forma inmediata que la primera condición asegura que $\bar{\mu} \in \Delta$. Notemos también que el producto interno de la condición de holgura complementaria se puede expandir mediante la definición del operador adjunto:

$$\langle \bar{\mu}, b - B\bar{x} \rangle = \langle \bar{\mu}, b \rangle - \langle B^T \bar{\mu}, \bar{x} \rangle = \langle b, \bar{\mu} \rangle - \langle c, \bar{x} \rangle.$$

Por lo tanto, concluimos que:

$$\langle \bar{\mu}, b - B\bar{x} \rangle = 0 \iff \langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle.$$

Por último, la relación de dualidad débil de la Proposición 5.1 implica que $\bar{\mu}$ es necesariamente una solución del problema dual (5.2), ya que la función objetivo dual alcanza en el punto $\bar{\mu}$ su cota superior global dentro del conjunto factible. ■

Ejemplo 5.1 (Demostración del Lema de Farkas vía Dualidad). El Lema de Farkas establece que el sistema de desigualdades lineales:

$$Ax \leq 0, \quad \langle b, x \rangle > 0 \quad (5.5)$$

carece de solución $x \in \mathbb{R}^n$ si y solo si el sistema alternativo:

$$A^T \mu = b, \quad \mu \geq 0 \quad (5.6)$$

tiene solución $\mu \in \mathbb{R}^m$.

Para probarlo mediante dualidad, planteamos el problema lineal de minimización:

$$\min \langle -b, x \rangle \quad \text{sujeto a} \quad -Ax \geq 0.$$

El origen $x = 0$ siempre es factible y su valor óptimo es nulo. El sistema (5.5) no tiene solución si y solo si no existe ningún punto factible con valor objetivo estrictamente menor que cero. Esto equivale a decir que $\bar{x} = 0$ es un mínimo global, con valor óptimo $\bar{v} = 0$.

Por el Teorema 5.1, esto ocurre si y solo si el dual:

$$\max \langle 0, \mu \rangle \quad \text{sujeto a} \quad -A^T \mu = -b, \quad \mu \geq 0$$

es factible. La restricción de igualdad es exactamente $A^T \mu = b$. Así, el sistema (5.5) es incompatible si y solo si el sistema dual (5.6) es compatible.

Ejemplo 5.2 (Verificación numérica). Tomemos el problema de minimización:

$$\begin{aligned} &\text{minimizar} && 3x_1 + 4x_2 \\ &\text{subject to} && x_1 + 2x_2 \geq 5, \\ &&& 2x_1 + x_2 \geq 6, \\ &&& x_1, x_2 \geq 0 \end{aligned}$$

En el formato estándar (5.1), definimos:

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad c = \begin{pmatrix} 3 \\ 4 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 0 & 0 \end{pmatrix}, \quad b = \begin{pmatrix} 5 \\ 6 \\ 0 \end{pmatrix}.$$

La intersección de las dos restricciones activas proporciona el mínimo global $\bar{x} = (7/3, 4/3)^T$, con valor óptimo primal $\langle c, \bar{x} \rangle = 37/3$.

Buscamos un punto dual factible $\bar{\mu} \in \mathbb{R}^4$ tal que coincidan los objetivos. Dado que las restricciones de no negatividad no están activas en $\bar{x}$, sus multiplicadores asociados deben ser nulos por holgura complementaria: $\bar{\mu}_3 = 0$ y $\bar{\mu}_4 = 0$. Resolvemos la factibilidad dual $B^T \bar{\mu} = c$ para los componentes restantes:

$$\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} \bar{\mu}_1 \\ \bar{\mu}_2 \end{pmatrix} = \begin{pmatrix} 3 \\ 4 \end{pmatrix} \implies \bar{\mu}_1 = \frac{5}{3}, \quad \bar{\mu}_2 = \frac{2}{3}.$$

El vector $\bar{\mu} = (5/3, 2/3, 0, 0)^T$ es no negativo, por lo que es factible para el dual. Evaluando el objetivo dual en este punto:

$$\langle b, \bar{\mu} \rangle = 5\left(\frac{5}{3}\right) + 6\left(\frac{2}{3}\right) = \frac{37}{3}.$$

Al cumplirse $\langle c, \bar{x} \rangle = \langle b, \bar{\mu} \rangle = 37/3$, el Teorema 5.1 garantiza que $\bar{x}$ y $\bar{\mu}$ son soluciones óptimas globales de sus respectivos problemas.

Teorema 5.2 (Teorema de Dualidad en Programación Lineal). Para cualquier par de problemas primal (5.1) y dual (5.2), se cumple exactamente una de las siguientes afirmaciones:

1. Ambos problemas son infactibles ($D = \emptyset$ y $\Delta = \emptyset$).
2. Uno de los problemas es ilimitado y el otro es infactible.
3. Ambos problemas son factibles. En este caso, ambos poseen soluciones óptimas y sus valores óptimos coinciden:

$$\min_{x \in D} \langle c, x \rangle = \max_{\mu \in \Delta} \langle b, \mu \rangle. \quad (5.7)$$

Prueba. Para comprobar la existencia del caso (1), basta definir un problema con $n = m = 1$ mediante $B = 0$, $b = 1$, $c = 1$. Aquí $D = \{x \in \mathbb{R} \mid 0 \geq 1\} = \emptyset$ y $\Delta = \{\mu \in \mathbb{R} \mid 0 = 1, \mu \geq 0\} = \emptyset$.

En el caso (2), si el primal es ilimitado ($\bar{v} = \inf_{x \in D} \langle c, x \rangle = -\infty$), la existencia de un punto factible dual $\mu \in \Delta$ contradice el teorema de dualidad débil, pues exigiría que $-\infty \geq \langle b, \mu \rangle$. Por tanto, $\Delta = \emptyset$. El razonamiento es análogo si el dual es ilimitado.

Para el caso (3), supongamos que $D \neq \emptyset$ y $\Delta \neq \emptyset$. Por dualidad débil, el valor óptimo primal es finito: $\bar{v} = \inf_{x \in D} \langle c, x \rangle > -\infty$. El sistema de desigualdades:

$$Bx \geq b, \quad \langle -c, x \rangle > -\bar{v} \quad (5.8)$$

no tiene solución por la definición de ínfimo. Al aplicar el Teorema de la Alternativa de Motzkin, la incompatibilidad de (5.8) implica que el sistema dual homogéneo asociado:

$$B^T \mu - y c = 0, \quad -\langle b, \mu \rangle + y \bar{v} + \eta = 0, \quad \mu \geq 0, \quad y \geq 0, \quad \eta \geq 0 \quad (5.9)$$

admite una solución con $(\mu, y, \eta) \neq 0$ tal que $(y, \eta) \geq 0$ no son nulos de manera simultánea.

Analizamos las posibilidades para el escalar y :

- Si $y = 0$, se requiere que $\eta > 0$. De (5.9) se obtiene el sistema homogéneo $B^T \mu = 0$, $\langle b, \mu \rangle = \eta > 0$, $\mu \geq 0$. Aplicando de nuevo el Teorema de la Alternativa de Motzkin, el sistema $z^0 b + Bz^1 + z^2 = 0$ no posee solución. Sin embargo, al tomar un punto factible $x_0 \in D$ y definir $z^1 = -x_0$, $z^0 = 1 > 0$ y $z^2 = Bx_0 - b \geq 0$, evaluamos $b + B(-x_0) + (Bx_0 - b) = 0$, lo que resulta en una contradicción directa. Así, es obligatorio que $y > 0$.
- Si $y > 0$, dividimos por y y definimos $\bar{\mu} = \mu/y$ y $\bar{\eta} = \eta/y$. Obtenemos $B^T \bar{\mu} = c$, $\bar{\mu} \geq 0$ y $\langle b, \bar{\mu} \rangle = \bar{v} + \bar{\eta}$. Esto demuestra que $\bar{\mu}$ es factible para el dual. Como $\bar{\eta} \geq 0$, se tiene $\langle b, \bar{\mu} \rangle \geq \bar{v}$. Por dualidad débil, debe cumplirse simultáneamente que $\langle b, \bar{\mu} \rangle \leq \bar{v}$, lo que fuerza a que $\bar{\eta} = 0$ y, por ende, $\langle b, \bar{\mu} \rangle = \bar{v}$.

La igualdad de los valores objetivos demuestra la existencia de soluciones óptimas con salto de dualidad nulo. ■

Ejemplo 5.3 (Problemas ilimitados e infactibles). Para ilustrar el caso (2) del teorema de dualidad, consideremos el programa lineal primal:

$$\begin{aligned} &\text{minimizar} && -x_1 \\ &\text{subject to} && -x_1 + x_2 \geq -1, \\ &&& x_1, x_2 \geq 0 \end{aligned}$$

La trayectoria paramétrica $x(t) = (t, t)^T$ con $t \geq 0$ es factible para cualquier valor de t . Al evaluar el objetivo en dicha dirección, obtenemos $\lim_{t \rightarrow \infty} (-t) = -\infty$, de modo que el problema primal es **ilimitado**.

El problema dual asociado viene dado por:

$$\begin{aligned} &\text{maximizar} && -\mu_1 \\ &\text{subject to} && -\mu_1 + \mu_2 = -1, \\ &&& \mu_1 + \mu_3 = 0, \\ &&& \mu_1, \mu_2, \mu_3 \geq 0 \end{aligned}$$

La condición $\mu_1 + \mu_3 = 0$ junto con la no negatividad de las variables fuerza a que $\mu_1 = 0$ y $\mu_3 = 0$. Al sustituir $\mu_1 = 0$ en la primera restricción, se obtiene $\mu_2 = -1$, lo cual es incompatible con la condición $\mu_2 \geq 0$. El problema dual es, por tanto, **infactible**.

Pregunta de Control: Verificación de dualidad

¿Es posible que un problema primal lineal de minimización tenga un punto factible con valor objetivo 10 y su dual correspondiente tenga un punto factible con valor objetivo 15? Justifique su respuesta utilizando la relación de dualidad débil.

Nota: Precios sombra

En economía, los multiplicadores óptimos del dual, $\bar{\mu}_i$, se interpretan como los **precios sombra** de los recursos. Representan la tasa de cambio marginal del valor óptimo de la función objetivo ante variaciones infinitesimales en la disponibilidad de los recursos correspondientes (b_i).

5.2. Dualidad para un problema general

El análisis de dualidad se extiende a problemas con restricciones no lineales de igualdad y desigualdad mediante la función Lagrangiana. Dado el problema general de optimización, al cual llamaremos **problema primal**:

$$\begin{aligned} & \underset{x}{\text{minimizar}} && f(x) \\ & \text{subject to} && x \in D = \{x \in \Omega \mid h(x) = 0, g(x) \leq 0\} \end{aligned} \quad (5.10)$$

donde $\Omega \subset \mathbb{R}^n$, $f: \Omega \rightarrow \mathbb{R}$, $h: \Omega \rightarrow \mathbb{R}^l$ y $g: \Omega \rightarrow \mathbb{R}^m$.

Definición 5.1 (Función Lagrangiana). Asociada al problema primal (5.10), se define la **función Lagrangiana** con respecto a las restricciones funcionales como la aplicación $L: \Omega \times \mathbb{R}^l \times \mathbb{R}^m \rightarrow \mathbb{R}$ dada por:

$$L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle, \quad (5.11)$$

donde los vectores $\lambda \in \mathbb{R}^l$ y $\mu \in \mathbb{R}^m$ reciben el nombre de **multiplicadores de Lagrange**.

5.2.1. Formulación Minimax del Problema Primal

La Lagrangiana penaliza implícitamente la violación de las restricciones funcionales al buscar el peor escenario respecto a las variables duales.

Lema 5.1 (Penalización implícita). Para cualquier $x \in \Omega$, se verifica:

$$\sup_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} L(x, \lambda, \mu) = \begin{cases} f(x) & \text{si } x \in D, \\ +\infty & \text{si } x \in \Omega \setminus D. \end{cases} \quad (5.12)$$

Prueba. Si $x \in D$, entonces $h(x) = 0$ y $g(x) \leq 0$. Como $\mu \geq 0$, el término $\langle \mu, g(x) \rangle \leq 0$. El valor máximo de la Lagrangiana se alcanza de forma única con $\mu = 0$ (o en cualquier multiplicador si $g_i(x) = 0$), resultando $\sup L = f(x)$. Si $x \notin D$, alguna restricción se infringe. Si $h_j(x) \neq 0$, basta con tomar $\lambda_j = t \cdot \text{sgn}(h_j(x))$ con $t \rightarrow \infty$. Si $g_i(x) > 0$, tomamos $\mu_i = t \rightarrow \infty$. En ambos casos, el supremo diverge a $+\infty$. ■

Observación. El Lema 5.1 permite reescribir de forma equivalente el problema primal (5.10) como un problema (tipo minimax) sin restricciones funcionales, sobre el conjunto base Ω :

$$\min \left\{ \sup_{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m} L(x, \lambda, \mu) \right\} \quad \text{sujeto a } x \in \Omega. \quad (5.13)$$

Además, el **valor óptimo primal** $\bar{v}$ queda caracterizado por la ecuación:

$$\bar{v} = \inf_{x \in \Omega} \left\{ \sup_{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m} L(x, \lambda, \mu) \right\}, \quad (5.14)$$

donde es obligatorio el uso del operador ínfimo (inf), ya que, en ausencia de compacidad en Ω , el mínimo global podría no alcanzarse.

Ejemplo 5.4 (Evaluación del supremo de la Lagrangiana). Dado el problema en $\Omega = \mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && x_1 + x_2 \\ &\text{subject to} && x_1^2 + x_2^2 - 1 = 0, \\ &&& -x_1 \leq 0 \end{aligned}$$

la Lagrangiana asociada es $L(x, \lambda, \mu) = x_1 + x_2 + \lambda(x_1^2 + x_2^2 - 1) - \mu x_1$.

1. Para el punto factible $x^A = (1, 0)^T \in D$, se tiene $L(x^A, \lambda, \mu) = 1 - \mu$. Su supremo sobre $\mu \geq 0$ se alcanza en $\bar{\mu} = 0$, resultando $f(x^A) = 1$.
2. Para el punto infactible de igualdad $x^B = (2, 0)^T$, se tiene $L(x^B, \lambda, \mu) = 2 + 3\lambda - 2\mu$. El supremo respecto a $\lambda \in \mathbb{R}$ diverge trivialmente a $+\infty$.
3. Para el punto infactible de desigualdad $x^C = (-1, 0)^T$, se tiene $L(x^C, \lambda, \mu) = -1 + \mu$. Como la variable μ puede ser arbitrariamente grande, el supremo sobre $\mu \geq 0$ es $+\infty$.

5.2.2. El Problema Dual General

El **problema dual** se define alternando el orden de los operadores de optimización en la formulación minimax del primal (5.13):

$$\bar{w} = \max_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} \left\{ \inf_{x \in \Omega} L(x, \lambda, \mu) \right\}. \quad (5.15)$$

Para simplificar su análisis, introducimos la **función dual** $\varphi : \mathbb{R}^l \times \mathbb{R}^m \rightarrow [-\infty, +\infty)$ como el ínfimo parcial respecto a las variables primales:

$$\varphi(\lambda, \mu) = \inf_{x \in \Omega} L(x, \lambda, \mu). \quad (5.16)$$

El dominio de factibilidad dual es el conjunto $\Delta = \{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}^m \mid \mu \geq 0, \varphi(\lambda, \mu) > -\infty\}$, de modo que el problema dual se expresa como:

$$\max \varphi(\lambda, \mu) \quad \text{sujeto a} \quad (\lambda, \mu) \in \Delta. \quad (5.17)$$

Teorema 5.3 (Propiedades de la función dual). El conjunto de factibilidad dual Δ es convexo y la función dual φ es cóncava sobre Δ .

Prueba. Para cada punto fijo $x \in \Omega$, la función de multiplicadores $(\lambda, \mu) \mapsto L(x, \lambda, \mu)$ es afín y, por ende, cóncava. Como la función dual φ es el ínfimo puntual de una familia de funciones afines continuas, conserva la concavidad de estas. La convexidad del dominio Δ se deduce de forma inmediata al ser el dominio de definición de una función cóncava propia. ■

El problema dual siempre es un problema de optimización convexa (maximización de una función cóncava sobre un conjunto convexo), con independencia de las propiedades topológicas o de convexidad del problema primal original.

5.2.3. Teorema de Dualidad Débil

Teorema 5.4 (Teorema de Dualidad Débil). Para cualquier punto factible primal $x \in D$ y cualquier punto factible dual $(\lambda, \mu) \in \Delta$, se cumple:

$$\varphi(\lambda, \mu) \leq f(x). \quad (5.18)$$

Prueba. Evaluando el ínfimo parcial en el punto particular $x \in D$:

$$\varphi(\lambda, \mu) = \inf_{z \in \Omega} L(z, \lambda, \mu) \leq L(x, \lambda, \mu).$$

Como $h(x) = 0$ y $\langle \mu, g(x) \rangle \leq 0$ para todo $\mu \geq 0$, se deduce que $L(x, \lambda, \mu) \leq f(x)$. ■

Ejemplo 5.5 (Obtención analítica de la función dual). Sea el problema de optimización:

$$\min x^2 \quad \text{sujeto a} \quad x - 2 \leq 0.$$

La Lagrangiana para $\mu \geq 0$ es $L(x, \mu) = x^2 + \mu x - 2\mu$. Resolvemos el ínfimo sobre $\Omega = \mathbb{R}$ igualando la derivada respecto a x a cero:

$$2x + \mu = 0 \implies x^*(\mu) = -\frac{\mu}{2}.$$

Sustituyendo x^* en la Lagrangiana, se obtiene la función dual:

$$\varphi(\mu) = -\frac{\mu^2}{4} - 2\mu.$$

Dado que el ínfimo es finito para todo μ , el dominio dual es $\Delta = [0, +\infty)$, el cual es convexo. Además, $\varphi''(\mu) = -1/2 < 0$, confirmando que la función dual es estrictamente cóncava sobre su dominio.

Definición 5.2. La diferencia entre el valor óptimo primal $\bar{v}$ y el dual $\bar{w}$ se llama **salto de dualidad** ($\bar{v} - \bar{w} \geq 0$).

Corolario 5.1 (Ausencia de salto de dualidad). Si existen puntos factibles $\bar{x} \in D$ y $(\bar{\lambda}, \bar{\mu}) \in \Delta$ tales que $f(\bar{x}) = \varphi(\bar{\lambda}, \bar{\mu})$, entonces $\bar{x}$ y $(\bar{\lambda}, \bar{\mu})$ son soluciones óptimas globales de sus respectivos problemas, y el salto de dualidad es nulo.

5.2.4. Patologías y Casos Límite en la Teoría de Dualidad

Los siguientes tres ejemplos ilustran cómo la falta de convexidad o la estructura de los dominios pueden impedir el alcance de los óptimos o dar lugar a saltos de dualidad estrictamente positivos.

Ejemplo 5.6 (Mínimo primal no alcanzado, sin salto de dualidad). Sea el problema de optimización definido sobre el conjunto base abierto $\Omega = (0, +\infty)$:

$$\begin{aligned} &\text{minimizar} && 1/x \\ &\text{subject to} && -x \leq 0 \end{aligned}$$

El dominio factible es $D = (0, +\infty)$. El valor del ínfimo primal es $\bar{v} = 0$, pero no se alcanza para ningún x finito. El problema primal no tiene solución.

Para cualquier $\mu \geq 0$, la Lagrangiana es $L(x, \mu) = 1/x - \mu x$. Evaluamos la función dual $\varphi(\mu) = \inf_{x>0} (1/x - \mu x)$:

- Si $\mu > 0$, tomando $x \rightarrow \infty$ el término $-\mu x$ decae sin límite inferior, resultando $\varphi(\mu) = -\infty$.
- Si $\mu = 0$, se tiene $\varphi(0) = \inf_{x>0} 1/x = 0$.

Así, el dominio dual es el conjunto unitario $\Delta = \{0\}$. El problema dual consiste en evaluar $\varphi(0) = 0$, con valor óptimo dual $\bar{w} = 0$. No existe salto de dualidad ($\bar{v} = \bar{w} = 0$) y el dual admite solución óptima en $\bar{\mu} = 0$, pero el primal no es soluble.

Ejemplo 5.7 (Óptimo primal existente, sin salto, pero dual no soluble). Sea el problema en $\Omega = \mathbb{R}$:

$$\begin{aligned} &\text{minimizar} && x \\ &\text{subject to} && x^2 \leq 0 \end{aligned}$$

El único punto factible es $\bar{x} = 0$, por lo que $\bar{v} = f(0) = 0$. La Lagrangiana es $L(x, \mu) = x + \mu x^2$. Calculamos la función dual $\varphi(\mu) = \inf_{x \in \mathbb{R}} (x + \mu x^2)$:

- Si $\mu > 0$, el mínimo de la parábola se alcanza en $x = -1/(2\mu)$, dando $\varphi(\mu) = -1/(4\mu)$.
- Si $\mu = 0$, el ínfimo de la función lineal en $\mathbb{R}$ es $\varphi(0) = -\infty$.

El conjunto de factibilidad dual es el intervalo abierto $\Delta = (0, +\infty)$. El problema dual es $\max_{\mu>0} (-1/(4\mu))$. Al aproximar $\mu \rightarrow \infty$, el supremo es $\bar{w} = 0$. Sin embargo, este valor no se alcanza para ningún multiplicador finito en el dominio abierto Δ . El salto de dualidad es nulo, pero el problema dual no posee solución.

Ejemplo 5.8 (Salto de dualidad estrictamente positivo). Tomemos el problema de optimización discreta sobre el conjunto no convexo $\Omega = \{0, 1\}$:

$$\begin{aligned} &\text{minimizar} && x_1 + x_2 \\ &\text{subject to} && x_1^2 + x_2^2 - 2 \leq 0. \end{aligned}$$

El único punto factible es $\bar{x} = 0$, lo que determina un valor óptimo primal $\bar{v} = f(0) = 0$.

Para $\mu \geq 0$, la Lagrangiana es $L(x, \mu) = -x + \mu(x - 1/2)$. Evaluamos la función dual $\varphi(\mu)$ seleccionando el mínimo en el conjunto discreto Ω :

$$\varphi(\mu) = \min_{x \in \{0,1\}} L(x, \mu) = \min \left\{ -\frac{1}{2}\mu, \frac{1}{2}\mu - 1 \right\}.$$

El máximo de esta función cóncava y continua por partes se localiza en la intersección de ambas rectas:

$$-\frac{1}{2}\mu = \frac{1}{2}\mu - 1 \implies \bar{\mu} = 1.$$

El valor óptimo dual es $\bar{w} = \varphi(1) = -1/2$. Obtenemos un salto de dualidad estrictamente positivo:

$$\bar{v} - \bar{w} = 0 - \left(-\frac{1}{2}\right) = \frac{1}{2} > 0.$$

5.2.5. Teoría de Multiplicadores de Lagrange Globales

Definición 5.3 (Multiplicador de Lagrange Global). Un vector $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}_+^m$ es un **multiplicador de Lagrange global** para el problema primal (5.10) si cumple:

$$\bar{v} = \inf_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu}). \quad (5.19)$$

Esta definición establece que las penalizaciones óptimas permiten hallar el valor óptimo del problema original mediante una minimización no restringida de la Lagrangiana sobre el conjunto base Ω .

Proposición 5.2 (Identidad entre Multiplicadores y Soluciones Duales). Supóngase que el valor óptimo primal $\bar{v}$ es finito y que el salto de dualidad es nulo. El conjunto de multiplicadores de Lagrange del problema primal coincide entonces con el conjunto de soluciones óptimas del problema dual.

Prueba. Si $(\bar{\lambda}, \bar{\mu})$ es un multiplicador de Lagrange, se tiene $\bar{\mu} \geq 0$ y $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{v}$. Como el salto de dualidad es nulo, se cumple $\bar{v} = \bar{w}$, lo que da $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{w}$. Esto demuestra que el par maximiza la función dual. Recíprocamente, si $(\bar{\lambda}, \bar{\mu}) \in \Delta$ es óptimo dual, entonces $\bar{\mu} \geq 0$ y $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{w}$. Al cumplirse $\bar{w} = \bar{v}$, resulta inmediato que $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{v}$, satisfaciendo la definición de multiplicador. ■

Ejemplo 5.9 (Identidad en un problema cuadrático bidimensional). Consideremos la minimización de una función afín sobre un disco euclidiano compacto en $\Omega = \mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && x_1 - x_2 \\ &\text{subject to} && x_1 + x_2 \leq 0. \end{aligned}$$

El mínimo de esta función sobre el disco de radio $\sqrt{2}$ se alcanza en $\bar{x} = (-1, -1)^\top$. En consecuencia, el **valor óptimo primal** está dado por $\bar{v} = f(-1, -1) = -2$.

Para cualquier escalar $\mu \geq 0$, la Lagrangiana es $L(x, \mu) = x_1 + x_2 + \mu(x_1^2 + x_2^2 - 2)$. Si $\mu = 0$, $\varphi(0) = -\infty$. Para $\mu > 0$, la función es estrictamente convexa. Anulando el gradiente respecto a x :

$$\nabla_x L(x, \mu) = \begin{pmatrix} 1 + 2\mu x_1 \\ 1 + 2\mu x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies x_1^*(\mu) = x_2^*(\mu) = -\frac{1}{2\mu}.$$

Sustituyendo, obtenemos la función dual $\varphi(\mu) = -\frac{1}{2\mu} - 2\mu$.

El problema dual exige maximizar esta función cóncava sobre el dominio $\mu > 0$. Derivando e igualando a cero: $\varphi'(\mu) = \frac{1}{2\mu^2} - 2 = 0 \implies \mu^2 = 1/4$. El único candidato admisible es $\bar{\mu} = 1/2$. Al evaluar, confirmamos que el **valor óptimo dual** es: $\bar{w} = \varphi(1/2) = -2$.

Observamos empíricamente que $\bar{v} = \bar{w} = -2$ (brecha nula). El óptimo dual $\bar{\mu} = 1/2$ debe satisfacer la definición topológica de un multiplicador global (Definición 5.3). Comprobémoslo:

$$\inf_{x \in \mathbb{R}^2} L\left(x, \frac{1}{2}\right) = \inf_{x \in \mathbb{R}^2} \left[\frac{1}{2}(x_1 + 1)^2 + \frac{1}{2}(x_2 + 1)^2 - 2 \right].$$

Es evidente que el valor mínimo de esta suma de cuadrados es -2 , alcanzado en $x = (-1, -1)^\top$. Hemos demostrado que el conjunto de multiplicadores de Lagrange y el de soluciones duales son idénticos.

Teorema 5.5 (Garantía de Existencia de Solución Dual). Supóngase que el conjunto factible del problema primal es no vacío ($D \neq \emptyset$) y que el problema primal posee al menos un multiplicador de Lagrange global.

1. Si el conjunto de factibilidad dual es no vacío ($\Delta \neq \emptyset$), entonces el problema dual posee una solución óptima.
2. Si el conjunto de factibilidad dual es vacío ($\Delta = \emptyset$), entonces el valor óptimo del problema primal es infinito negativo ($\bar{v} = -\infty$).

Prueba. Sea $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}_+^m$ un multiplicador de Lagrange. Por definición (Definición 5.3), $\varphi(\bar{\lambda}, \bar{\mu}) = \bar{v}$.

Si $\Delta \neq \emptyset$, por el Teorema de Dualidad Débil (Teorema 5.4), $\bar{v}$ acota superiormente a cualquier valor factible dual.

Puesto que el par $(\bar{\lambda}, \bar{\mu})$ alcanza este límite superior, pertenece a Δ y es un maximizador global de la función dual.

Si $\Delta = \emptyset$, implica que para todo par (λ, μ) se tiene $\varphi(\lambda, \mu) = -\infty$. Evaluando en el multiplicador garantizado por hipótesis, obtenemos $\varphi(\bar{\lambda}, \bar{\mu}) = -\infty$. Por ende, $\bar{v} = -\infty$. ■

Ejemplo 5.10 (Infactibilidad dual y divergencia primal). Consideremos el siguiente problema lineal sobre $\Omega = \mathbb{R}^2$:

$$\begin{aligned} &\text{minimizar} && x_1 - x_2 \\ &\text{subject to} && x_1 + x_2 \leq 0. \end{aligned}$$

El dominio factible D contiene a $(0, 0)$. Tomando $x(t) = (-t, t)^T$ para $t > 0$, la función objetivo evaluada en esta trayectoria es $-2t$. Al hacer $t \rightarrow \infty$, el problema es ilimitado: $\bar{v} = -\infty$.

Construyamos la función Lagrangiana para $\mu \geq 0$: $L(x, \mu) = x_1(1 + \mu) + x_2(\mu - 1)$. Para que el ínfimo sea finito, se requeriría $1 + \mu = 0$ y $\mu - 1 = 0$, lo cual es una contradicción. Concluimos que para cualquier $\mu \geq 0$, $\varphi(\mu) = -\infty$. Por tanto, $\Delta = \emptyset$, lo que corrobora el Teorema 5.5.

Teorema 5.6 (Condiciones de Kuhn-Tucker No Diferenciables). Un punto $\bar{x} \in D$ es solución óptima del problema primal y $(\bar{\lambda}, \bar{\mu})$ es un multiplicador de Lagrange si y solo si se cumplen las condiciones:

$$L(\bar{x}, \bar{\lambda}, \bar{\mu}) = \min_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu}), \quad (5.20)$$

$$\bar{\mu}_i g_i(\bar{x}) = 0, \quad \forall i = 1, \dots, m. \quad (5.21)$$

Prueba. ($\Rightarrow$) Como $\bar{x}$ es óptimo y $(\bar{\lambda}, \bar{\mu})$ es multiplicador, se tiene $f(\bar{x}) = \inf_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu})$. Como $\bar{x} \in D$, resulta $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x}) + \langle \bar{\mu}, g(\bar{x}) \rangle$. La condición $\bar{\mu} \geq 0, g(\bar{x}) \leq 0$ exige que $\langle \bar{\mu}, g(\bar{x}) \rangle \leq 0$. Al ser el ínfimo $f(\bar{x})$, se debe verificar de forma obligatoria que $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x})$, lo que prueba (5.20) y requiere $\bar{\mu}_i g_i(\bar{x}) = 0$.

($\Leftarrow$) Por holgura complementaria y factibilidad, se tiene $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x})$. Sustituyendo en la minimización global (5.20), resulta $f(\bar{x}) = \inf_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu})$, lo cual demuestra que $(\bar{\lambda}, \bar{\mu})$ es un multiplicador y $\bar{x}$ es óptimo global. ■

5.2.6. Dualidad Fuerte y la Condición de Slater

Definición 5.4 (Condición de Regularidad de Slater). Se dice que el problema primal (5.10) satisface la **condición de Slater** si las restricciones de igualdad son afines ($h(x) = Ax - a$), las restricciones de desigualdad g_i son funciones convexas en Ω , y existe un punto de regularidad $\hat{x} \in \text{int } \Omega$ tal que:

$$A\hat{x} - a = 0 \quad \text{y} \quad g_i(\hat{x}) < 0 \quad \forall i = 1, \dots, m. \quad (5.22)$$

Teorema 5.7 (Teorema de Dualidad Fuerte de Slater). Supóngase que en el problema primal (5.10) las funciones f y g_i son convexas, las restricciones de igualdad son afines dadas por $h(x) = Ax - a$ con $A \in \mathbb{R}^{l \times n}$, y el valor óptimo primal $\bar{v}$ es finito. Si se satisface la condición de regularidad de Slater (Definición 5.4), entonces el salto de dualidad es nulo ($\bar{v} = \bar{w}$), y el problema dual admite al menos una solución óptima $(\bar{\lambda}, \bar{\mu}) \in \Delta$.

Prueba. Supongamos, sin pérdida de generalidad, que las filas de la matriz A son linealmente independientes. Definamos el conjunto de valores admisibles para la función objetivo y las perturbaciones de las restricciones primales:

$$C = \left\{ (y, z, c) \in \mathbb{R} \times \mathbb{R}^m \times \mathbb{R}^l \mid \exists x \in \Omega \text{ t.q. } f(x) \leq y, g(x) \leq z, Ax - a = c \right\}.$$

La convexidad de f y g_i , sumada al carácter afín de h , garantizan que C es un conjunto convexo en $\mathbb{R} \times \mathbb{R}^m \times \mathbb{R}^l$. Dado que $\bar{v}$ es el valor óptimo primal, el punto $(\bar{v}, 0, 0)$ se encuentra en la frontera del conjunto convexo C .

Aplicamos el Teorema de Separación de Conjuntos Convexos (Lema de Minkowski). Existe un hiperplano de soporte en $(\bar{v}, 0, 0)$, caracterizado por un vector normal no nulo $(\beta, \bar{\mu}, \bar{\lambda}) \in \mathbb{R} \times \mathbb{R}^m \times \mathbb{R}^l$, tal que:

$$\beta \bar{v} \leq \beta y + \langle \bar{\mu}, z \rangle + \langle \bar{\lambda}, c \rangle \quad \forall (y, z, c) \in C. \quad (5.23)$$

Para que la desigualdad se cumpla asintóticamente es necesario que $\beta \geq 0$ y $\bar{\mu} \geq 0$.

Asumamos que $\beta = 0$. Evaluando (5.23) en el punto factible de Slater $\hat{x}$, se obtiene $0 \leq \langle \bar{\mu}, g(\hat{x}) \rangle$. Dado que $\bar{\mu} \geq 0$ y cada componente $g_i(\hat{x}) < 0$, la única posibilidad es que $\bar{\mu} = 0$. Sustituyendo $\beta = 0$ y $\bar{\mu} = 0$, nos queda $0 \leq \langle \bar{\lambda}, c \rangle$ para todo c factible. Como A tiene rango completo, esto es posible solo si $\bar{\lambda} = 0$. Esto implica que el vector normal es nulo, contradiciendo el Teorema de Separación. Por consiguiente, $\beta > 0$.

Dividiendo (5.23) por β y definiendo $\lambda^* = \bar{\lambda}/\beta \in \mathbb{R}^l$ y $\mu^* = \bar{\mu}/\beta \in \mathbb{R}_+^m$. Tomando $(y, z, c) = (f(x), g(x), Ax - a) \in C$, la inecuación se reduce a:

$$\bar{v} \leq f(x) + \langle \mu^*, g(x) \rangle + \langle \lambda^*, Ax - a \rangle = L(x, \lambda^*, \mu^*).$$

Tomando el ínfimo sobre todo $x \in \Omega$, concluimos que $\bar{v} \leq \varphi(\lambda^*, \mu^*)$. A su vez, por Dualidad Débil (Teorema 5.4), sabemos que $\varphi(\lambda^*, \mu^*) \leq \bar{v}$. Así, $\varphi(\lambda^*, \mu^*) = \bar{v}$, probando que no hay salto de dualidad y el óptimo dual se alcanza. ■

Ejemplo 5.11 (Verificación de la dualidad fuerte). Sea el problema de optimización en $\Omega = \mathbb{R}$:

$$\begin{aligned} &\text{minimizar} \quad (x - 3)^2 \\ &\text{subject to} \quad x - 2 \leq 0 \end{aligned}$$

El origen $\hat{x} = 0 \in \text{int } \mathbb{R}$ cumple $g(0) = -2 < 0$, satisfaciendo la condición de Slater. El mínimo restringido se alcanza en la frontera $\bar{x} = 2$, dando $\bar{v} = 1$.

Construimos la función dual para $\mu \geq 0$: $\varphi(\mu) = \inf_{x \in \mathbb{R}} \{(x - 3)^2 + \mu(x - 2)\} = -\frac{\mu^2}{4} + \mu$. Maximizando la función dual, calculamos el óptimo $\bar{\mu} = 2$. El valor óptimo dual es $\bar{w} = \varphi(2) = 1$. Verificamos que $\bar{v} = \bar{w} = 1$.

5.2.7. El Problema Dual de Wolfe

Definición 5.5 (Problema Dual de Wolfe). Asociado al problema primal (5.10), asumiendo que Ω es abierto en $\mathbb{R}^n$ y que f, g, h son continuamente diferenciables, el **problema dual de Wolfe** se define como:

$$\max_{\substack{x \in \Omega, \lambda \in \mathbb{R}^l \\ \mu \geq 0}} L(x, \lambda, \mu) \quad \text{sujeto a} \quad \nabla_x L(x, \lambda, \mu) = 0. \quad (5.24)$$

Denotaremos al conjunto de factibilidad de este problema como W .

Teorema 5.8 (Dualidad Débil de Wolfe). Si el problema primal original es de minimización convexa (es decir, f y g_i son convexas, y h es afín), entonces para cualquier punto factible primal $\bar{x} \in D$ y cualquier punto factible del dual de Wolfe $(x, \lambda, \mu) \in W$, se verifica que:

$$L(x, \lambda, \mu) \leq f(\bar{x}). \quad (5.25)$$

Prueba. Dado que f y g_i son convexas y h es afín, la Lagrangiana $x \mapsto L(x, \lambda, \mu)$ preserva la convexidad. Por la definición de W , sabemos que $\nabla_x L(x, \lambda, \mu) = 0$. En funciones convexas, la anulación del gradiente garantiza que x es un minimizador global: $L(x, \lambda, \mu) = \inf_{z \in \Omega} L(z, \lambda, \mu) = \varphi(\lambda, \mu)$. Aplicando el Teorema de Dualidad Débil General (Teorema 5.4), sabemos que $\varphi(\lambda, \mu) \leq f(\bar{x})$. Sustituyendo la igualdad previa, se concluye: $L(x, \lambda, \mu) \leq f(\bar{x})$. ■

Ejemplo 5.12 (Coincidencia del Dual de Wolfe en Programación Lineal). Sea el programa primal lineal: $\min \langle c, x \rangle$ sujeto a $Bx \geq b$. Adaptando a $g(x) = b - Bx \leq 0$, la Lagrangiana es $L(x, \mu) = \langle c - B^T \mu, x \rangle + \langle b, \mu \rangle$. La restricción del dual de Wolfe es $\nabla_x L(x, \mu) = 0$, lo que equivale a $c - B^T \mu = 0$. Evaluando la función objetivo $L(x, \mu)$ bajo esta condición, el término con x se anula, resultando $L(x, \mu) = \langle b, \mu \rangle$. El dual de Wolfe se simplifica a maximizar $\langle b, \mu \rangle$ sujeto a $B^T \mu = c$ y $\mu \geq 0$, que es la formulación dual estándar planteada en (5.2).

5.2.8. Caracterización mediante Puntos de Silla

Definición 5.6 (Punto de Silla). Un punto $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in \Omega \times \mathbb{R}^l \times \mathbb{R}_+^m$ es un **punto de silla** de la Lagrangiana si verifica la doble desigualdad topológica:

$$L(\bar{x}, \lambda, \mu) \leq L(\bar{x}, \bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu}) \quad (5.26)$$

para todo $x \in \Omega$, todo $\lambda \in \mathbb{R}^l$ y todo $\mu \geq 0$.

Teorema 5.9 (Teorema del Punto de Silla). Un punto $\bar{x} \in \Omega$ es solución óptima del problema primal y $(\bar{\lambda}, \bar{\mu})$ es solución óptima del problema dual asociado con salto de dualidad nulo si y solo si $(\bar{x}, \bar{\lambda}, \bar{\mu})$ es un punto de silla de la Lagrangiana.

Prueba. ($\Rightarrow$) : Por el Lema 5.1 y la factibilidad de $\bar{x}$, se tiene $L(\bar{x}, \lambda, \mu) \leq f(\bar{x}) = L(\bar{x}, \bar{\lambda}, \bar{\mu})$, probando la primera desigualdad. Para la segunda, la dualidad fuerte implica $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = \varphi(\bar{\lambda}, \bar{\mu}) \leq L(x, \bar{\lambda}, \bar{\mu})$.

($\Leftarrow$) : Si es un punto de silla, al tomar el supremo en las variables duales de la primera desigualdad: $\sup L(\bar{x}, \lambda, \mu) \leq L(\bar{x}, \bar{\lambda}, \bar{\mu}) < +\infty$. Por el Lema 5.1, esto fuerza a que $\bar{x} \in D$ y $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = f(\bar{x})$. De la segunda desigualdad, $f(\bar{x}) \leq L(x, \bar{\lambda}, \bar{\mu})$. Tomando el ínfimo sobre $x \in \Omega$, resulta $f(\bar{x}) \leq \varphi(\bar{\lambda}, \bar{\mu})$. Por el Teorema de Dualidad Débil, esto obliga a que $f(\bar{x}) = \varphi(\bar{\lambda}, \bar{\mu})$, anulando el salto de dualidad. ■

Ejemplo 5.13 (Punto de silla de la Lagrangiana). Tomemos el problema: $\min x^2 - 4x$ sujeto a $x - 1 \leq 0$. El mínimo restringido en $D = (-\infty, 1]$ se alcanza en $\bar{x} = 1$, con $\bar{v} = -3$. La Lagrangiana es $L(x, \mu) = x^2 - 4x + \mu(x - 1)$. Igualando a cero la derivada en $\bar{x} = 1$, obtenemos $\bar{\mu} = 2$.

Verificamos las condiciones de punto de silla para $(\bar{x}, \bar{\mu}) = (1, 2)$:

1. **Izquierda:** Para cualquier $\mu \geq 0$, $L(1, \mu) = -3 \leq L(1, 2) = -3$, lo cual se cumple.
2. **Derecha:** Para cualquier $x \in \mathbb{R}$, $L(1, 2) \leq L(x, 2) \implies -3 \leq x^2 - 2x - 2 \implies (x - 1)^2 \geq 0$, la cual se verifica siempre.

Esto confirma que la terna constituye un punto de silla de la Lagrangiana.

5.2.9. Subgradiente de la Función Dual

Proposición 5.3 (Subgradiente de la Función Dual). Sean $(\lambda, \mu) \in \Delta$ y sea $x(\lambda, \mu) \in \Omega$ tal que se alcanza el ínfimo parcial, es decir, $\varphi(\lambda, \mu) = L(x(\lambda, \mu), \lambda, \mu)$. El vector de violaciones funcionales:

$$-\begin{pmatrix} h(x(\lambda, \mu)) \\ g(x(\lambda, \mu)) \end{pmatrix} \in \partial(-\varphi)(\lambda, \mu) \quad (5.27)$$

es un subgradiente de la función dual negativa $-\varphi$ en el punto (λ, μ) .

Prueba. Un vector s es un subgradiente si $\varphi(\eta, \nu) \leq \varphi(\lambda, \mu) - \langle s, (\eta - \lambda, \nu - \mu)^T \rangle$. Partiendo de la definición de la función dual en un punto genérico $(\eta, \nu) \in \Delta$:

$$\varphi(\eta, \nu) = \inf_{z \in \Omega} L(z, \eta, \nu) \leq L(x(\lambda, \mu), \eta, \nu).$$

Desarrollando la expresión de la Lagrangiana evaluada en $x(\lambda, \mu)$:

$$L(x(\lambda, \mu), \eta, \nu) = \varphi(\lambda, \mu) + \langle \eta - \lambda, h(x(\lambda, \mu)) \rangle + \langle \nu - \mu, g(x(\lambda, \mu)) \rangle.$$

Esto verifica la desigualdad del subgradiente al tomar $s = -(h(x(\lambda, \mu)), g(x(\lambda, \mu)))^T$. ■

Pregunta de Control: Interpretación de puntos de silla

Si se encuentra un punto de silla para la función Lagrangiana de un problema no convexo, ¿se puede asegurar que dicho punto define la solución global del problema primal? Justifique su respuesta basándose en las hipótesis del Teorema 5.9.

Nota: Relajación Lagrangiana

El Teorema de Dualidad Débil sustenta la técnica conocida como **relajación Lagrangiana**, utilizada en optimización entera y combinatoria. Al trasladar restricciones difíciles a la función objetivo mediante multiplicadores fijos $\mu \geq 0$, se obtiene un problema relajado fácil de resolver cuyo óptimo proporciona siempre una cota inferior rigurosa para el valor mínimo del problema original.

Ejercicios del Capítulo 5

Parte I: Dualidad en Programación Lineal

Ejercicio 5.1 (Dualidad en formato lineal general). Sea el problema de programación lineal en formato general:

$$\begin{aligned} &\text{minimizar} && \langle c_1, x_1 \rangle + \langle c_2, x_2 \rangle \\ &\text{subject to} && (x_1, x_2) \in D \end{aligned}$$

donde el conjunto factible D está definido por:

$$D = \left\{ (x_1, x_2) \in \mathbb{R}^{n_1} \times \mathbb{R}_+^{n_2} \mid \begin{aligned} B_{11}x_1 + B_{12}x_2 &= b_1, \\ B_{21}x_1 + B_{22}x_2 &\geq b_2 \end{aligned} \right\},$$

con $c_1 \in \mathbb{R}^{n_1}$, $c_2 \in \mathbb{R}^{n_2}$, $B_{11} \in \mathbb{R}^{l \times n_1}$, $B_{12} \in \mathbb{R}^{l \times n_2}$, $B_{21} \in \mathbb{R}^{m \times n_1}$, $B_{22} \in \mathbb{R}^{m \times n_2}$, $b_1 \in \mathbb{R}^l$ y $b_2 \in \mathbb{R}^m$.

Demuestre que el problema dual asociado viene dado por:

$$\begin{aligned} &\text{maximizar} \quad \langle b_1, \lambda \rangle \\ &\text{subject to} \quad (\lambda, \mu) \in \Delta \end{aligned}$$

donde el conjunto factible dual es:

$$\Delta = \left\{ (\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m \mid \begin{array}{l} B_{11}^\top \lambda + B_{21}^\top \mu = c_1, \\ B_{12}^\top \lambda + B_{22}^\top \mu \leq c_2 \end{array} \right\},$$

y verifique que se cumplen todas las relaciones de dualidad débil y fuerte para este par de problemas.

Ejercicio 5.2 (Verificación numérica de dualidad). Dado el problema de programación lineal de maximización:

$$\begin{aligned} &\text{maximizar} \quad \langle c, x \rangle \\ &\text{subject to} \quad Bx \leq b, \\ &\quad \quad \quad x \geq 0 \end{aligned}$$

donde:

$$B = \begin{pmatrix} 2 & 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 \end{pmatrix}, \quad c = \begin{pmatrix} 4 \\ 5 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \quad b = \begin{pmatrix} 8 \\ 7 \\ 3 \end{pmatrix}.$$

Formule el problema dual de minimización correspondiente y verifique que los puntos $\bar{x} = (3, 2, 0, 0, 1)^\top$ y $\bar{\mu} = (1, 2, 0)^\top$ son las soluciones óptimas de los problemas primal y dual, respectivamente.

Ejercicio 5.3 (Acotamiento y optimalidad en sistemas homogéneos). Demuestre que el problema de maximización lineal $\max \langle c, x \rangle$ sujeto a $Ax = 0, x \geq 0$ tiene un valor óptimo finito si y solo si $\bar{x} = 0$ es una solución óptima del problema.

Ejercicio 5.4 (Análisis de sensibilidad paramétrica). Para el problema lineal paramétrico:

$$\begin{aligned} &\text{minimizar} \quad 3x_1 + 4x_2 + x_3 + x_4 \\ &\text{subject to} \quad \begin{array}{l} x_1 + x_2 + x_3 - x_4 \geq 2, \\ -2x_1 + 2x_2 + x_3 + x_4 \geq \sigma, \\ x_i \geq 0, \quad i = 1, \dots, 4 \end{array} \end{aligned}$$

donde $\sigma \in \mathbb{R}$ es un parámetro real.

1. Formule el problema dual asociado.
2. Resuelva el problema dual analíticamente para cada valor posible de σ .
3. Utilizando la solución dual, determine el valor óptimo del problema primal en función de σ .

Parte II: Dualidad en Problemas Generales y Puntos de Silla

Ejercicio 5.5 (Dual de un problema de programación cuadrática). Dado el problema de programación cuadrática $\min \frac{1}{2} \langle Qx, x \rangle + \langle q, x \rangle$ sujeto a $Bx \leq b$, donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, $q \in \mathbb{R}^n$, $B \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$.

Demuestre que el problema dual asociado puede formularse como el siguiente problema de maximización cuadrática sobre el ortante no negativo:

$$\text{maximizar}_{\mu \geq 0} \quad \left\{ -\frac{1}{2} \langle (BQ^{-1}B^\top \mu), \mu \rangle - \langle b + BQ^{-1}q, \mu \rangle - \frac{1}{2} \langle Q^{-1}q, q \rangle \right\}$$

Ejercicio 5.6 (Cálculo analítico de la función dual). Calcule analíticamente la función dual $\varphi(\mu)$ y resuelva de forma exacta el problema dual del problema general $\min f(x)$ sujeto a $x \in \Omega$ con $g(x) \leq 0$, para cada uno de los siguientes casos:

1. $f(x) = x_1 - x_2$, $g(x) = x_1 + x_2 - 1$, $\Omega = \mathbb{R}_+^2$.
2. $f(x) = \frac{1}{2}(x_1^2 + x_2^2)$, $g(x) = x_1 - 1$, $\Omega = \mathbb{R}^2$.
3. $f(x) = x$, $g(x) = x^2$, $\Omega = \mathbb{R}$.

En cada caso, determine si existe salto de dualidad.

Ejercicio 5.7 (Dualidad en problemas de proyección). Sean $A \in \mathbb{R}^{m \times n}$ una matriz de rango completo de filas y $z \in \mathbb{R}^n$ un punto de proyección fijo. Demuestre que el problema dual asociado al problema de proyección ortogonal $\min \frac{1}{2\|z-x\|^2}$ sujeto a $Ax = 0$ es equivalente a un problema de proyección de un vector transformado sobre la imagen de la matriz transpuesta A^T (un subespacio afín).

Ejercicio 5.8 (Invariancia y dependencia de la formación dual). Considere las dos formulaciones matemáticamente equivalentes del mismo problema geométrico:

$$(P1) \quad \min \langle a, x \rangle \quad \text{sujeto a} \quad \|x\| \leq 1,$$

$$(P2) \quad \min \langle a, x \rangle \quad \text{sujeto a} \quad \|x\|^2 \leq 1.$$

Demuestre que sus respectivos problemas duales de Lagrange son algebraicamente diferentes y analice cómo influye la elección de la función de restricción en la suavidad de la función dual.

Ejercicio 5.9 (Teorema de Everett). Sean $(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m$ y sea $x(\lambda, \mu) \in \Omega$ una solución óptima del problema de optimización no restringido de la Lagrangiana $\min_{x \in D} L(x, \lambda, \mu)$. Demuestre que el punto $x(\lambda, \mu)$ es una solución óptima del problema perturbado $\min f(x)$ sujeto a $h(x) = y$ y $g(x) \leq z$, donde los vectores de perturbación están definidos por $y = h(x(\lambda, \mu))$ y $z_j = g_j(x(\lambda, \mu))$ si $\mu_j > 0$, o $z_j \geq g_j(x(\lambda, \mu))$ si $\mu_j = 0$.

Ejercicio 5.10 (Puntos de Silla e Igualdad Minimax). Demuestre algebraicamente que $(\bar{x}, \bar{\lambda}, \bar{\mu}) \in \Omega \times \mathbb{R}^l \times \mathbb{R}_+^m$ es un punto de silla de la Lagrangiana si y solo si se verifica la igualdad de los valores minimax:

$$\min_{x \in \Omega} \sup_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} L(x, \lambda, \mu) = \max_{\substack{\lambda \in \mathbb{R}^l \\ \mu \geq 0}} \inf_{x \in \Omega} L(x, \lambda, \mu) = L(\bar{x}, \bar{\lambda}, \bar{\mu}).$$

Ejercicio 5.11 (Proyección sobre un semiespacio). Sean $a \in \mathbb{R}^n \setminus \{0\}$ y $b \in \mathbb{R}^n$. Formule y resuelva de manera analítica el problema dual asociado al problema de minimización $\min \frac{1}{2}\|x\|^2 - \langle b, x \rangle$ sujeto a $\langle a, x \rangle \leq 0$. Utilice la solución del problema dual para obtener la solución óptima del problema primal.

Ejercicio 5.12 (Descomposición dual en optimización separable). Considere un problema con estructura separable donde las variables y las funciones pueden dividirse en p bloques independientes:

$$\begin{aligned} & \text{minimizar} \quad \sum_{j=1}^p f_j(x_j) \\ & \text{subject to} \quad \sum_{j=1}^p h_j(x_j) = 0, \\ & \quad \quad \quad \sum_{j=1}^p g_j(x_j) \leq 0, \\ & \quad \quad \quad x_j \in \Omega_j, \quad j = 1, \dots, p \end{aligned}$$

donde $\Omega_j \subset \mathbb{R}^{n_j}$, $f_j : \Omega_j \rightarrow \mathbb{R}$, $h_j : \Omega_j \rightarrow \mathbb{R}^l$ y $g_j : \Omega_j \rightarrow \mathbb{R}^m$.

Demuestre que la función dual $\varphi(\lambda, \mu)$ de este problema general puede descomponerse en la suma de p funciones duales independientes $\varphi(\lambda, \mu) = \sum_{j=1}^p \varphi_j(\lambda, \mu)$, donde cada componente se calcula resolviendo un subproblema local:

$$\varphi_j(\lambda, \mu) = \inf_{x_j \in \Omega_j} \{f_j(x_j) + \langle \lambda, h_j(x_j) \rangle + \langle \mu, g_j(x_j) \rangle\}.$$

Explique la importancia de esta propiedad en el desarrollo de algoritmos de optimización distribuida (descomposición dual).

Ejercicio 5.13 (Formulación de Consenso y Descomposición Dual). Considere el problema de optimización no separable con acoplamiento por la variable de decisión única x :

$$\begin{aligned} & \text{minimizar} && \sum_{i=0}^m f_i(x) \\ & \text{subject to} && x \in D_i, \quad i = 0, \dots, m \end{aligned}$$

donde $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ son funciones convexas y $D_i \subset \mathbb{R}^n$ son conjuntos poliedrales acotados tales que $\bigcap_{i=0}^m D_i \neq \emptyset$.

Para transformar este problema primal en uno con estructura separable, introducimos variables locales independientes $x_i \in \mathbb{R}^n$ para cada bloque ($i = 1, \dots, m$) junto con una variable de consenso global $x_0 \in \mathbb{R}^n$, imponiendo las restricciones de acoplamiento $x_i = x_0$:

$$\begin{aligned} & \text{minimizar}_{x_0, x_1, \dots, x_m \in \mathbb{R}^n} && \sum_{i=0}^m f_i(x_i) \\ & \text{subject to} && x_i - x_0 = 0, \quad i = 1, \dots, m, \\ & && x_i \in D_i, \quad i = 0, \dots, m \end{aligned}$$

1. Demuestre que el problema dual de Lagrange asociado a esta formulación se puede escribir de la forma:

$$\max_{\lambda_1, \dots, \lambda_m \in \mathbb{R}^n} \left\{ \varphi_0 \left(\sum_{i=1}^m \lambda_i \right) + \sum_{i=1}^m \varphi_i(\lambda_i) \right\},$$

donde las funciones duales componentes vienen dadas por:

$$\varphi_0(u) = \min_{x_0 \in D_0} \{f_0(x_0) - \langle u, x_0 \rangle\}, \quad \varphi_i(\lambda_i) = \min_{x_i \in D_i} \{f_i(x_i) + \langle \lambda_i, x_i \rangle\}, \quad i = 1, \dots, m.$$

2. Demuestre que este par de problemas satisface la dualidad fuerte, justificando la nulidad del salto de dualidad.

Parte II.

Métodos Computacionales

6. Resumen Teórico y Preliminares Matemáticos

En este capítulo recordamos varios hechos fundamentales de la teoría de Optimización, tales como la existencia de soluciones, las condiciones de regularidad de las restricciones y de optimalidad, la convexidad de conjuntos y de funciones, y elementos de la teoría de dualidad. El objetivo es facilitar las referencias futuras a lo largo de este volumen.

Las demostraciones de estos resultados no serán presentadas aquí, ya que se espera que el lector haya asimilado el primer volumen de esta obra [Izm20]. Presentaremos también algunos hechos auxiliares del Análisis y del Álgebra Lineal, que serán utilizados intensivamente en el diseño de los métodos computacionales.

6.1. Existencia de soluciones

Sean dados un conjunto $D \subset \mathbb{R}^n$ y una función $f : \Omega \rightarrow \mathbb{R}$, donde $D \subset \Omega$. Los métodos computacionales que estudiaremos están dedicados al problema de hallar un minimizador de f en el conjunto D . Este problema se escribirá como:

$$\min f(x) \quad \text{sujeto a} \quad x \in D. \quad (6.1)$$

El conjunto D será llamado **conjunto factible** del problema, los puntos de D serán llamados **puntos factibles**, y f será llamada **función objetivo**.

Definición 6.1 (Tipos de minimizadores). Decimos que un punto $\bar{x} \in D$ es:

1. **Minimizador global** de (6.1), si $f(\bar{x}) \leq f(x)$ para todo $x \in D$.
2. **Minimizador local** de (6.1), si existe una vecindad U de $\bar{x}$ tal que $f(\bar{x}) \leq f(x)$ para todo $x \in D \cap U$.

Si para todo $x \neq \bar{x}$ la desigualdad correspondiente es estricta, $\bar{x}$ será llamado **minimizador estricto**.

Definición 6.2 (Valor óptimo). Decimos que $\bar{v} \in [-\infty, +\infty]$ definido por $\bar{v} = \inf\{f(x) \mid x \in D\}$ es el **valor óptimo** del problema (6.1), donde entendemos que $\bar{v} = +\infty$ si $D = \emptyset$.

Una función puede admitir varios minimizadores globales, pero el valor óptimo (global) del problema siempre es único. Cuando $\bar{v} = +\infty$ o $\bar{v} = -\infty$, el problema no posee solución global. Pero incluso cuando $\bar{v}$ es finito, el minimizador global puede no existir (por ejemplo, minimizar $f(x) = e^x$ en $\mathbb{R}$).

Algunas de las condiciones que garantizan la existencia de solución global son las siguientes.

Teorema 6.1 (Teorema de Weierstrass). Sean $D \subset \mathbb{R}^n$ un conjunto compacto no vacío y $f : D \rightarrow \mathbb{R}$ una función continua. Entonces, el problema de minimizar f en D tiene una solución global.

Otro resultado importante se basa en la noción de conjunto de nivel de una función.

Definición 6.3 (Conjunto de nivel). El **conjunto de nivel** de la función $f : D \rightarrow \mathbb{R}$ asociado a un escalar $c \in \mathbb{R}$, es el conjunto dado por $L_{f,D}(c) = \{x \in D \mid f(x) \leq c\}$.

Corolario 6.1 (Compacidad del conjunto de nivel). Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ continua en D . Supongamos que existe $c \in \mathbb{R}$ tal que el conjunto de nivel $L_{f,D}(c)$ sea no vacío y compacto. Entonces, el problema de minimizar f en D posee una solución global.

Otro resultado de existencia utiliza la noción de función coercitiva.

Definición 6.4 (Coercitividad). Decimos que la función $f : D \rightarrow \mathbb{R}$ es **coercitiva** en el conjunto D , cuando para cada secuencia $\{x^k\} \subset D$ tal que $\|x^k\| \rightarrow \infty$ o $\{x^k\} \rightarrow x \in \text{cl } D \setminus D$ ($k \rightarrow \infty$), se tiene que $\limsup_{k \rightarrow \infty} f(x^k) = +\infty$.

Corolario 6.2 (Existencia por coercitividad). Sean $D \subset \mathbb{R}^n$ y $f : D \rightarrow \mathbb{R}$ una función continua y coercitiva en D . Entonces, el problema de minimizar f en D posee una solución global.

6.2. Condiciones de optimalidad

Cuando $D = \mathbb{R}^n$, decimos que el problema (6.1) es **irrestringido**, y cuando $D \neq \mathbb{R}^n$ hablamos de optimización con restricciones. Cabe notar que los resultados de problemas irrestringidos son verdaderos para problemas con restricciones siempre que el punto de interés $\bar{x}$ esté en el interior del conjunto factible ($\bar{x} \in \text{int } D$).

Teorema 6.2 (Condiciones en el caso irrestringido). (a) Supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea diferenciable en el punto $\bar{x} \in \mathbb{R}^n$. Si $\bar{x}$ es un minimizador local, entonces $f'(\bar{x}) = 0$. Si f es dos veces diferenciable en $\bar{x}$, entonces la matriz Hessiana de f en $\bar{x}$ es semidefinida positiva: $\langle f''(\bar{x})d, d \rangle \geq 0$ para todo $d \in \mathbb{R}^n$.

(b) Supongamos que f sea dos veces diferenciable en $\bar{x}$. Si $f'(\bar{x}) = 0$ y la matriz Hessiana es definida positiva (existe $\gamma > 0$ tal que $\langle f''(\bar{x})d, d \rangle \geq \gamma \|d\|^2$ para todo $d \in \mathbb{R}^n$), entonces $\bar{x}$ es minimizador local estricto.

A continuación recordamos las condiciones de optimalidad para el caso de **restricciones de igualdad**:

$$\min f(x) \quad \text{sueto a} \quad x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}, \quad (6.2)$$

donde la Lagrangiana está dada por $L(x, \lambda) = f(x) + \langle \lambda, h(x) \rangle$. Las condiciones de regularidad clásicas son la independencia lineal de los gradientes (LICQ) o la linealidad afín de h .

Teorema 6.3 (Condiciones en el caso de restricciones de igualdad). (a) Si $\bar{x}$ es un minimizador local y vale LICQ o linealidad, entonces existe $\bar{\lambda} \in \mathbb{R}^l$ tal que $L'_x(\bar{x}, \bar{\lambda}) = 0$. Bajo LICQ, $\bar{\lambda}$ es único. Además, $\langle L''_{xx}(\bar{x}, \bar{\lambda})d, d \rangle \geq 0$ para todo $d \in \ker h'(\bar{x})$.

(b) Si $\bar{x} \in D$ y existen $\bar{\lambda} \in \mathbb{R}^l$ y $\gamma > 0$ tales que $L'_x(\bar{x}, \bar{\lambda}) = 0$ y $\langle L''_{xx}(\bar{x}, \bar{\lambda})d, d \rangle \geq \gamma \|d\|^2$ para todo $d \in \ker h'(\bar{x})$, entonces $\bar{x}$ es un minimizador local estricto.

Finalmente, consideramos el caso general con **restricciones mixtas**:

$$\min f(x) \quad \text{sueto a} \quad x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\}. \quad (6.3)$$

La Lagrangiana está dada por $L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle$. El conjunto de los índices de las restricciones activas de desigualdad en $\bar{x} \in D$ se denota por $I(\bar{x}) = \{i \mid g_i(\bar{x}) = 0\}$.

Las condiciones de regularidad para este problema son: linealidad afín, la condición de **Mangasarian-Fromovitz (MFCQ)** (independencia lineal de igualdades y existencia de dirección de descenso interior para desigualdades activas), LICQ, y la condición de Slater para convexidad. El **cono crítico** $K(\bar{x})$ es el conjunto de direcciones d tales que $\langle f'(\bar{x}), d \rangle \leq 0$, $\langle g'_i(\bar{x}), d \rangle \leq 0$ para activos y $\langle h'_i(\bar{x}), d \rangle = 0$.

Teorema 6.4 (Condiciones de optimalidad en el caso de restricciones mixtas). (a) Si $\bar{x}$ es minimizador local y cumple alguna regularidad (linealidad, MFCQ, o Slater), existen $\bar{\lambda} \in \mathbb{R}^l$ y $\bar{\mu} \in \mathbb{R}_+^m$ tales que $L'_x(\bar{x}, \bar{\lambda}, \bar{\mu}) = 0$ y $\bar{\mu}_i g_i(\bar{x}) = 0$ para todo i (**Condiciones KKT**). Bajo LICQ, los multiplicadores son únicos, y vale la condición de segundo orden: $\langle L''_{xx}(\bar{x}, \bar{\lambda}, \bar{\mu})d, d \rangle \geq 0$ para todo $d \in K(\bar{x})$.

(b) Si existen multiplicadores KKT y la Hessiana de la Lagrangiana es definida positiva en el cono crítico, entonces $\bar{x}$ es un minimizador local estricto.

Decimos que el punto estacionario $\bar{x}$ satisface la **condición de complementariedad estricta** si $\bar{\mu}_i > 0$ para todo $i \in I(\bar{x})$.

Proposición 6.1 (Compacidad de los multiplicadores). Sea $\bar{x}$ un punto estacionario del problema. El conjunto de multiplicadores de Lagrange asociados a $\bar{x}$ es compacto si, y solamente si, la condición de regularidad de Mangasarian-Fromovitz (MFCQ) es satisfecha.

6.3. Convexidad

Definición 6.5 (Conjunto Convexo). Un conjunto $D \subset \mathbb{R}^n$ es llamado **conjunto convexo** si para cualesquiera $x \in D$, $y \in D$ y $\alpha \in [0, 1]$, se tiene que $\alpha x + (1 - \alpha)y \in D$.

Una **proyección** (ortogonal) del punto $x \in \mathbb{R}^n$ sobre un conjunto $D \subset \mathbb{R}^n$ es una solución (global) del problema $\min \|y - x\|$ sujeto a $y \in D$.

Teorema 6.5 (Teorema de la proyección). Sea $D \subset \mathbb{R}^n$ un conjunto cerrado y convexo. Para todo $x \in \mathbb{R}^n$ la proyección de x sobre D , denotada por $P_D(x)$, existe y es única. Además, $\bar{x} = P_D(x)$ si, y solamente si,

$$\bar{x} \in D, \quad \langle x - \bar{x}, y - \bar{x} \rangle \leq 0 \quad \forall y \in D.$$

El operador es no expansivo: $\|P_D(x) - P_D(y)\| \leq \|x - y\|$ para todo x, y .

Definición 6.6 (Función Convexa). Una función $f : D \rightarrow \mathbb{R}$ (con D convexo) es **convexa** si para cualesquiera $x, y \in D$ y $\alpha \in [0, 1]$, $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$. Es **fuertemente convexa** con módulo $\gamma > 0$, si la cota mejora a $\alpha f(x) + (1 - \alpha)f(y) - \gamma\alpha(1 - \alpha)\|x - y\|^2$. Una función es **cóncava** si $(-f)$ es convexa.

Teorema 6.6 (Teorema de minimización convexa). Sean $D \subset \mathbb{R}^n$ convexo y $f : D \rightarrow \mathbb{R}$ convexa. Entonces todo minimizador local del problema es global y el conjunto de minimizadores es convexo. Si f es estrictamente convexa, el minimizador es único.

Teorema 6.7 (Continuidad y Compacidad). Una función convexa es localmente Lipschitz-continua en el interior de su dominio. Si f es fuertemente convexa en $\mathbb{R}^n$, sus conjuntos de nivel $L_{f, \mathbb{R}^n}(c)$ son compactos para todo $c \in \mathbb{R}$, lo que garantiza existencia y unicidad de soluciones en cualquier cerrado D .

Cuando una función es diferenciable, la convexidad admite varias caracterizaciones (desigualdad del subgradiente, monotonía del gradiente, y Hessiana semidefinida positiva o definida positiva para la fuerte convexidad).

Teorema 6.8 (Optimalidad primal convexa). Sea $D \subset \mathbb{R}^n$ convexo y cerrado, y f diferenciable. Si $\bar{x} \in D$ es un minimizador local, entonces $\langle f'(\bar{x}), x - \bar{x} \rangle \geq 0$ para todo $x \in D$. Equivalentemente, $\bar{x} = P_D(\bar{x} - \alpha f'(\bar{x}))$ para todo $\alpha \in \mathbb{R}_+$. Si f es convexa, esta condición es también suficiente.

Teorema 6.9 (Suficiencia de KKT). Si f y g son convexas y h es afín, entonces cualquier punto estacionario $\bar{x}$ que satisfaga las condiciones de KKT es un minimizador global del problema con restricciones mixtas.

En el análisis no diferenciable, la derivada se reemplaza por el subdiferencial.

Definición 6.7 (Subdiferencial). El **subdiferencial** de f convexa en x , denotado $\partial f(x)$, es el conjunto de vectores $y \in \mathbb{R}^n$ tales que $f(z) \geq f(x) + \langle y, z - x \rangle$ para todo $z \in \mathbb{R}^n$. Un punto $\bar{x}$ es minimizador global si y solo si $0 \in \partial f(\bar{x})$. Si se relaja la desigualdad restando una tolerancia $\varepsilon \geq 0$, se obtiene el **ε -subdiferencial** $\partial_\varepsilon f(x)$.

6.4. Dualidad

Consideramos un problema en formato general (Problema Primal):

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \Omega \mid h(x) = 0, g(x) \leq 0\}. \quad (6.4)$$

La Lagrangiana está dada por $L(x, \lambda, \mu) = f(x) + \langle \lambda, h(x) \rangle + \langle \mu, g(x) \rangle$. El problema primal puede ser escrito formalmente como una formulación minimax: $\min_{x \in \Omega} \sup_{(\lambda, \mu)} L(x, \lambda, \mu)$.

El **problema dual** se obtiene cambiando el orden de la optimización:

$$\max \varphi(\lambda, \mu) \quad \text{sujeto a} \quad (\lambda, \mu) \in \Delta, \quad (6.5)$$

donde la **función dual** es $\varphi(\lambda, \mu) = \inf_{x \in \Omega} L(x, \lambda, \mu)$ y el dominio dual es $\Delta = \{(\lambda, \mu) \in \mathbb{R}^l \times \mathbb{R}_+^m \mid \varphi(\lambda, \mu) > -\infty\}$.

Teorema 6.10 (Propiedades del problema Dual). El conjunto factible dual Δ es convexo y la función dual φ es siempre cóncava. Además, vale el **Teorema de Dualidad Débil**:

$$\bar{w} = \sup_{(\lambda, \mu) \in \Delta} \varphi(\lambda, \mu) \leq \inf_{x \in D} f(x) = \bar{v}.$$

Cualquier punto factible dual provee una cota inferior para el óptimo primal.

Cuando $\bar{v} > \bar{w}$ decimos que hay una brecha de dualidad (duality gap). Para garantizar la igualdad de estos valores, necesitamos hipótesis de convexidad.

Teorema 6.11 (Teorema de la Dualidad Fuerte). Sean $\Omega = \mathbb{R}^n$, f y g funciones convexas y h una función afín. Supongamos que el problema primal satisface la condición de Slater. Si el valor óptimo primal es finito ($\bar{v} > -\infty$), entonces el problema dual posee una solución y no hay brecha de dualidad ($\bar{v} = \bar{w}$).

Teorema 6.12 (Teorema del Punto de Silla de Kuhn-Tucker). Bajo las hipótesis de convexidad y Slater, $\bar{x} \in D$ es solución del problema primal si, y solamente si, existe $(\bar{\lambda}, \bar{\mu}) \in \mathbb{R}^l \times \mathbb{R}_+^m$ tal que $L(\bar{x}, \bar{\lambda}, \bar{\mu}) = \min_{x \in \Omega} L(x, \bar{\lambda}, \bar{\mu})$ y $\bar{\mu}_i g_i(\bar{x}) = 0$. El conjunto de pares $(\bar{\lambda}, \bar{\mu})$ coincide con las soluciones del problema dual.

El siguiente resultado es fundamental para el diseño de algoritmos de optimización dual, ya que permite calcular un subgradiente de la función dual "gratis" al resolver el subproblema Lagrangiano.

Proposición 6.2 (Subgradiente de la función dual). Sean $(\lambda, \mu) \in \Delta$ y $x(\lambda, \mu) \in \Omega$ el punto donde se alcanza el ínfimo de la Lagrangiana. Entonces, el vector de violaciones de las restricciones es un subgradiente de la función dual (negativa):

$$-(h(x(\lambda, \mu)), g(x(\lambda, \mu))) \in \partial(-\varphi)(\lambda, \mu).$$

6.5. Herramientas del Análisis y del Álgebra Lineal

En esta sección agrupamos resultados analíticos y algebraicos cruciales para el desarrollo de los algoritmos computacionales.

Lema 6.1 (Desigualdad de Cauchy-Schwarz generalizada). Para una norma $\|\cdot\|_p$ y su dual $\|\cdot\|_D = \sup\{\langle \cdot, y \rangle \mid \|y\|_p = 1\}$, se tiene que

$$|\langle x, y \rangle| \leq \|x\|_p \|y\|_D \quad \forall x, y \in \mathbb{R}^n.$$

Teorema 6.13 (Perturbación de matrices no singulares). Sea $\bar{A}$ no singular. Para toda matriz A tal que $\|A - \bar{A}\| < 1/\|\bar{A}^{-1}\|$, la matriz A es no singular y su inversa está acotada por:

$$\|A^{-1} - \bar{A}^{-1}\| \leq \frac{\|\bar{A}^{-1}\|^2 \|A - \bar{A}\|}{1 - \|\bar{A}^{-1}\| \|A - \bar{A}\|}.$$

El siguiente lema será fundamental para establecer las propiedades de las Lagrangianas Aumentadas.

Lema 6.2 (Lema de Debreu). Sean $A \in \mathbb{R}^{l \times n}$ y $B \in \mathbb{R}^{n \times n}$ matrices tales que $\langle Bd, d \rangle > 0$ para todo $d \in \ker A \setminus \{0\}$. Entonces existe $\bar{c} > 0$ tal que la matriz $B + cA^T A$ es definida positiva para todo $c \geq \bar{c}$.

Lema 6.3 (Lema de Gronwall en versión discreta). Supongamos que los escalares θ_i cumplen $0 \leq \theta_0 \leq a$, y $0 \leq \theta_{i+1} \leq a + b \sum_{j=0}^i \theta_j$. Entonces $\theta_i \leq a(1 + b)^i$ para todo i .

Teorema 6.14 (Fórmula de Newton-Leibniz). Sea $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ continuamente diferenciable. Entonces $F(x + y) = F(x) + \int_0^1 F'(x + ty)y dt$.

Lema 6.4 (Acotación del error de linealización). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ con gradiente Lipschitz-continuo con módulo $L > 0$. Entonces el error de su aproximación de primer orden satisface $|f(x + d) - f(x) - \langle f'(x), d \rangle| \leq \frac{L}{2} \|d\|^2$.

Los métodos de programación cuadrática secuencial (SQP) y las regiones de confianza dependen del control de la factibilidad mediante la Función Implícita.

Teorema 6.15 (Teorema de la Función Implícita y Estimativa Local). Si $F(\bar{u}, \bar{x}) = 0$ y $F'_x(\bar{u}, \bar{x})$ es no singular, existe una trayectoria implícita $\chi(u)$ tal que $F(u, \chi(u)) = 0$. Si la matriz jacobiana parcial no es cuadrada pero tiene rango máximo por filas ($\text{rank } F'_x(\bar{u}, \bar{x}) = l$), entonces existe la función implícita χ y un escalar $M > 0$ tal que la corrección está acotada por el residuo: $\|\chi(u) - \bar{x}\| \leq M \|F(u, \bar{x})\|$.

Teorema 6.16 (Teorema de Robinson). Bajo la condición de regularidad de Mangasarian-Fromovitz (MFCQ), la distancia de un punto en una vecindad U al conjunto factible D está acotada métricamente por la norma de la violación de sus restricciones (residual natural): $\text{dist}(x, D) \leq M \|\Psi(x)\|$.

6.6. Elementos del Análisis no Diferenciable

En optimización, el interés en funciones no diferenciables proviene del hecho de que las condiciones KKT poseen naturaleza esencialmente no diferenciable. La condición de complementariedad $\bar{\mu}_i \geq 0$, $g_i(\bar{x}) \leq 0$, y $\bar{\mu}_i g_i(\bar{x}) = 0$ se puede reescribir mediante **funciones de complementariedad** $\psi(a, b)$ tales que $\psi(a, b) = 0 \iff a \geq 0, b \geq 0, ab = 0$.

Entre las elecciones más populares destacan el **residuo natural** $\psi(a, b) = \min\{a, b\}$ y la función de **Fischer-Burmeister** $\psi(a, b) = \sqrt{a^2 + b^2} - a - b$. Ambas son no diferenciables en el origen $(0, 0)$, lo que ocurre si el problema carece de complementariedad estricta (restricciones activas con multiplicador nulo).

Teorema 6.17 (Teorema de Rademacher). *Toda función Lipschitz-continua $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ en un conjunto abierto V es diferenciable en casi todo punto (la medida de Lebesgue del conjunto de puntos de no diferenciableidad es nula).*

Esto permite definir el **B-diferencial** (Bouligand-differential) como los límites de los jacobianos clásicos:

$$\partial_B F(x) = \{H \in \mathbb{R}^{l \times n} \mid \exists \{x^k\} \rightarrow x, \{F'(x^k)\} \rightarrow H\}.$$

El **diferencial de Clarke** es la envoltura convexa del B-diferencial: $\partial F(x) = \text{conv } \partial_B F(x)$.

Teorema 6.18 (Subdiferencial del Mínimo). *Si $f(x) = \min_i f_i(x)$ para funciones suaves, el B-diferencial de f está contenido en el conjunto de los gradientes de las funciones que empatan en el mínimo: $\partial_B f(x) \subset \{f'_i(x) \mid f_i(x) = f(x)\}$.*

Para la convergencia de métodos de Newton generalizados, necesitamos que la función no diferenciable aproxime bien a una función lineal. Decimos que F satisface la condición de Kummer si $\sup_{H \in \partial F(x+d)} \|F(x+d) - F(x) - Hd\| = o(\|d\|)$, y la **condición de Kummer fuerte** si el residuo es de orden $O(\|d\|^2)$.

La propiedad de **semi-diferenciabilidad** unifica la Lipschitz-continuidad, la existencia de derivadas direccionales y las condiciones de Kummer. Una función semi-diferenciable permite que el límite $\lim_{\xi \rightarrow d, t \rightarrow 0^+} H\xi$ (donde $H \in \partial F(x + t\xi)$) coincida con la derivada direccional clásica $F'(x; d)$.

Para finalizar, presentamos una estimativa para la distancia a la solución de la ecuación $\Phi(x) = 0$, que será utilizada posteriormente para probar convergencia superlineal. Suponiendo que $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ sea diferenciable en el punto $\bar{x} \in \mathbb{R}^n$ en cada dirección, decimos que Φ satisface la R_0 -condición si

$$\{d \in \mathbb{R}^n \mid \Phi'(\bar{x}; d) = 0\} = \{0\}.$$

Notemos que si Φ además de ser diferenciable en cada dirección también es Lipschitz-continua en una vecindad de $\bar{x}$, entonces la BD -regularidad de Φ en $\bar{x}$ (es decir, la no-singularidad de todo elemento de $\partial_B \Phi(\bar{x})$) implica la R_0 -condición en este punto.

Teorema 6.19 (Teorema de la R_0 -condición). *Sea $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ una función Lipschitz-continua con módulo $L > 0$ en una vecindad del punto $\bar{x} \in \mathbb{R}^n$ tal que $\Phi(\bar{x}) = 0$. Sea Φ diferenciable en este punto en cada dirección.*

Entonces Φ satisface en $\bar{x}$ la R_0 -condición si, y solamente si, existe una vecindad U del punto $\bar{x}$ en $\mathbb{R}^n$ y un número $M > 0$ tales que

$$\|x - \bar{x}\| \leq M\|\Phi(x)\| \quad \forall x \in U.$$

Prueba. Supongamos que Φ satisface en $\bar{x}$ la R_0 -condición, mas exista una secuencia $\{x^k\} \subset \mathbb{R}^n$ tal que $\{x^k\} \rightarrow \bar{x}$ ($k \rightarrow \infty$), $x^k \neq \bar{x} \quad \forall k$, y

$$\frac{\|\Phi(x^k)\|}{\|x^k - \bar{x}\|} \rightarrow 0 \quad (k \rightarrow \infty).$$

Para todo k , definimos $d^k = (x^k - \bar{x})/\|x^k - \bar{x}\|$, y $t_k = \|x^k - \bar{x}\|$. Podemos admitir, sin pérdida de generalidad, que la secuencia $\{d^k\}$ converge a un cierto $d \in \mathbb{R}^n$, $\|d\| = 1$. Entonces, para todo k ,

$$\begin{aligned} \frac{\|\Phi(\bar{x} + t_k d)\|}{t_k} &\leq \frac{\|\Phi(\bar{x} + t_k d) - \Phi(\bar{x} + t_k d^k)\|}{t_k} + \frac{\|\Phi(\bar{x} + t_k d^k)\|}{t_k} \\ &\leq L\|d^k - d\| + \frac{\|\Phi(x^k)\|}{\|x^k - \bar{x}\|} \rightarrow 0 \quad (k \rightarrow \infty), \end{aligned}$$

de donde se sigue que $\Phi'(\bar{x}; d) = 0$, en contradicción con la R_0 -condición.

Para probar la afirmación recíproca, consideremos cualquier $d \in \mathbb{R}^n$ tal que $\Phi'(\bar{x}; d) = 0$. Si existen una vecindad U del punto $\bar{x}$ y un número $M > 0$ con las propiedades de arriba, entonces para todo $t > 0$ suficientemente pequeño

tenemos:

$$\begin{aligned} t\|d\| &= \|\bar{x} + td - \bar{x}\| \leq M\|\Phi(\bar{x} + td)\| \\ &= M\|\Phi(\bar{x} + td) - \Phi(\bar{x})\| = M\|t\Phi'(\bar{x}; d)\| + o(t) = o(t), \end{aligned}$$

lo que solo puede valer para $d = 0$. ■

Ejercicios de Preliminares Teóricos

Parte I: Álgebra Lineal y Teoría Analítica

Ejercicio 6.1 (Lema de Gronwall). Supongamos que los números $\theta_0, \theta_1, \dots, \theta_N$, a y b satisfacen las siguientes cotas recursivas:

$$0 \leq \theta_0 \leq a, \quad 0 \leq \theta_{i+1} \leq a + b \sum_{j=0}^i \theta_j \quad \forall i = 0, 1, \dots, N-1.$$

Probar utilizando la técnica de inducción matemática que la sucesión está acotada geométricamente por $\theta_i \leq a(1+b)^i$ para todo $i = 0, 1, \dots, N$.

Parte II: Elementos de Análisis No Diferenciable

Ejercicio 6.2 (Compacidad del Diferencial de Clarke). Probar que si el operador no lineal $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$ es Lipschitz-continuo con módulo $L > 0$ en una vecindad del punto $x \in \mathbb{R}^n$, entonces su diferencial de Clarke $\partial F(x)$ es un conjunto compacto, no vacío y uniformemente acotado tal que $\|H\| \leq L$ para todo $H \in \partial F(x)$.

Ejercicio 6.3 (Semi-diferenciabilidad de funciones convexas). Probar que si la función escalar $F : \mathbb{R}^n \rightarrow \mathbb{R}$ es convexa en una vecindad (convexa) del punto $x \in \mathbb{R}^n$, entonces F es automáticamente semi-diferenciable en el punto x .

Ejercicio 6.4 (Álgebra de funciones semi-diferenciables). Probar que si las funciones vectoriales $F_1, F_2 : \mathbb{R}^n \rightarrow \mathbb{R}^l$ son semi-diferenciables en el punto $x \in \mathbb{R}^n$, entonces las operaciones algebraicas elementales preservan esta propiedad. Demostrar que las siguientes funciones son semi-diferenciables en x :

1. Producto interno: $F : \mathbb{R}^n \rightarrow \mathbb{R}$, $F(x) = \langle F_1(x), F_2(x) \rangle$.
2. Suma vectorial: $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$, $F(x) = F_1(x) + F_2(x)$.
3. Máximo componente a componente: $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$, $F_i(x) = \max\{(F_1(x))_i, (F_2(x))_i\}$.
4. Mínimo componente a componente: $F : \mathbb{R}^n \rightarrow \mathbb{R}^l$, $F_i(x) = \min\{(F_1(x))_i, (F_2(x))_i\}$.

Ejercicio 6.5 (Semi-diferenciabilidad en el producto cartesiano). Probar que si las funciones de bloques $F_1 : \mathbb{R}^n \rightarrow \mathbb{R}^{l_1}$ y $F_2 : \mathbb{R}^n \rightarrow \mathbb{R}^{l_2}$ son semi-diferenciables en el punto $x \in \mathbb{R}^n$, entonces la función combinada $F : \mathbb{R}^n \rightarrow \mathbb{R}^{l_1} \times \mathbb{R}^{l_2}$, definida como $F(x) = (F_1(x), F_2(x))$, es semi-diferenciable en x .

Ejercicio 6.6 (Regla de la cadena para semi-diferenciabilidad). Probar la extensión del Teorema de Composición: si la función base $F_1 : \mathbb{R}^n \rightarrow \mathbb{R}^{l_1}$ es semi-diferenciable en el punto $x \in \mathbb{R}^n$, y el operador envolvente $F_2 : \mathbb{R}^{l_1} \rightarrow \mathbb{R}^{l_2}$ es semi-diferenciable en la imagen $F_1(x)$, entonces la composición iterada $F : \mathbb{R}^n \rightarrow \mathbb{R}^{l_2}$ dada por $F(x) = F_2(F_1(x))$ es semi-diferenciable en x .

7. Introducción a los Métodos de Optimización

La optimización matemática continua estudia el problema de minimizar una función sobre un dominio delimitado por restricciones. Representamos este modelo mediante la estructura general:

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\}, \quad (7.1)$$

donde $\mathbb{R}^n$ es el espacio base, la función objetivo es $f : \mathbb{R}^n \rightarrow \mathbb{R}$, y las restricciones de igualdad y desigualdad vienen dadas por los operadores $h : \mathbb{R}^n \rightarrow \mathbb{R}^l$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$, respectivamente.

La resolución numérica de (7.1) requiere evaluar de forma sistemática los valores de la función objetivo, de las restricciones y, de forma habitual, de sus respectivas derivadas. Para estructurar el estudio teórico de estos algoritmos, presentaremos primero una clasificación sistemática de los métodos numéricos de optimización.

7.1. Clasificación de los métodos y nociones de convergencia

Los métodos de optimización se clasifican atendiendo a tres criterios fundamentales: la dependencia de la información obtenida en iteraciones previas (métodos pasivos o secuenciales), la cantidad de información histórica acumulada (esquemas con o sin memoria) y el orden máximo de las derivadas utilizadas.

7.1.1. Estrategia de muestreo: Métodos pasivos vs. secuenciales

Atendiendo al papel que desempeña la información obtenida durante el proceso de cálculo, distinguimos dos clases de métodos:

- **Método pasivo:** La secuencia de puntos de evaluación se elige y predetermina completamente a priori, de forma que la elección de cada candidato no se beneficia de la información obtenida en las iteraciones previas (por ejemplo, la búsqueda en rejilla o *grid search*).
- **Método secuencial:** Cada nuevo punto de la secuencia se determina utilizando los valores de la función objetivo, las restricciones o sus derivadas calculados en pasos anteriores. Esta clase resulta considerablemente más eficiente y abarca a la gran mayoría de los algoritmos computacionales prácticos.

7.1.2. Estructura del esquema iterativo: Métodos sin memoria vs. con memoria

Un método secuencial genera una secuencia de puntos en $\mathbb{R}^n$, denotada por $\{x^1, x^2, \dots, x^k, \dots\}$, a los que se denomina aproximaciones o iterados del método. Esta secuencia (llamada también **trayectoria**) se describe mediante un esquema iterativo.

Si denotamos por Ψ_k al operador de transición definido sobre conjuntos $U_k \subset \mathbb{R}^n$, la generación de un nuevo iterado se expresa como:

$$x^{k+1} = \Psi_k(x^k), \quad k = 0, 1, \dots \quad (7.2)$$

Para que el esquema esté bien definido a partir de un punto inicial $x^0 \in U_0$, los sucesivos iterados deben permanecer dentro de los dominios de definición de los operadores correspondientes. Esta condición de compatibilidad se expresa como:

$$\Psi_{k-1}(\Psi_{k-2}(\dots \Psi_0(x^0) \dots)) \in U_k \quad \forall k = 1, 2, \dots$$

Dependiendo de la cantidad de información histórica que requiera el operador Ψ_k , clasificamos los esquemas iterativos en:

- **Esquema sin memoria:** El operador Ψ_k depende únicamente de la aproximación actual x^k .
- **Esquema con memoria:** El operador utiliza información del iterado actual x^k y de puntos anteriores de la trayectoria $(x^{k-1}, x^{k-2}, \dots)$.

7.1.3. Orden del método

El tercer criterio clasifica los algoritmos según la información diferencial que emplean.

Definición 7.1 (Orden de un método). El orden de un método es el orden máximo de las derivadas de la función objetivo y de las restricciones utilizadas en cada iteración del algoritmo.

1. **Métodos de orden cero (o directos):** Aquellos que solo evalúan funcionalmente f , g o h , sin utilizar derivadas.
2. **Métodos de primer orden:** Aquellos que basan sus decisiones en la evaluación de las primeras derivadas (vectores gradientes, ∇f).
3. **Métodos de segundo orden:** Aquellos que requieren el cálculo de segundas derivadas (matrices Hessianas, $\nabla^2 f$).

7.1.4. Tipos de convergencia

El comportamiento asintótico de la trayectoria $\{x^k\}$ define las propiedades de convergencia del algoritmo. Distinguimos entre **convergencia finita** (cuando la trayectoria alcanza una solución exacta en un número finito de pasos, es decir, $x^k \in S$ para algún $k < \infty$) y **convergencia asintótica**.

En problemas no lineales generales, el análisis se centra rigurosamente en la convergencia asintótica. Dependiendo de la métrica y del espacio considerados, distinguimos cuatro tipos de convergencia:

1. **Convergencia en relación a las variables (o puntual):** La sucesión de iterados converge a una solución del problema:

$$x^k \rightarrow \bar{x} \quad (k \rightarrow \infty), \quad \text{con } \bar{x} \in S.$$

Esta propiedad suele requerir hipótesis restrictivas (como convexidad estricta o unicidad de solución) para poder ser demostrada de forma directa.

2. **Convergencia al conjunto de soluciones S :** La distancia de la trayectoria al conjunto de soluciones tiende a cero:

$$\text{dist}(x^k, S) \rightarrow 0 \quad (k \rightarrow \infty).$$

Si el conjunto S es compacto, esto asegura que el conjunto de puntos de acumulación de $\{x^k\}$ es no vacío y está contenido en S . Si S es ilimitado, es posible que la distancia tienda a cero sin que existan puntos de acumulación.

3. **Convergencia en relación a la función objetivo (o al valor óptimo):** La sucesión de valores de la función converge al valor mínimo $\bar{v}$, garantizando simultáneamente la aproximación al conjunto factible D :

$$\text{dist}(x^k, D) \rightarrow 0 \quad \text{y} \quad f(x^k) \rightarrow \bar{v} \quad (k \rightarrow \infty).$$

Este tipo de convergencia no implica necesariamente que la trayectoria de las variables $\{x^k\}$ sea convergente en el espacio $\mathbb{R}^n$.

4. **Convergencia en relación al gradiente:** En optimización irrestricta con funciones no convexas, es muy difícil garantizar la convergencia hacia un mínimo global. Por ello, el análisis se suele centrar en demostrar que la norma del gradiente converge a cero:

$$\|\nabla f(x^k)\| \rightarrow 0 \quad (k \rightarrow \infty).$$

Bajo esta condición, cualquier punto de acumulación $\bar{x}$ de la trayectoria es, por lo menos, un punto estacionario del problema ($\nabla f(\bar{x}) = 0$).

Distinguimos también entre **convergencia global** y **convergencia local**. Un método tiene *convergencia global* si la trayectoria converge a una solución para cualquier punto inicial x^0 . Por el contrario, un método *local* requiere que x^0 se sitúe suficientemente cerca de la solución para garantizar su convergencia.

Frecuentemente, la resolución de un problema complejo se basa en reducirlo a una secuencia de problemas más simples. Por ejemplo, el método de Newton aproxima un sistema no lineal mediante sistemas lineales. De igual modo, muchos algoritmos multidimensionales se apoyan internamente en la resolución iterativa de problemas unidimensionales a lo largo de direcciones específicas (búsqueda lineal).

Nota: El problema de la Optimización Global

Para problemas fuertemente no convexos, hallar el mínimo global es, en general, analíticamente imposible. El enfoque ingenuo de evaluar una red muy fina sobre el conjunto factible sufre la llamada *maldición de la dimensionalidad*.

Un enfoque heurístico más eficiente es la estrategia de **múltiple partida (multi-start)**. Esta estrategia superpone una red discreta gruesa sobre el conjunto factible y ejecuta un método de optimización local rápido desde cada nodo. La aproximación a la solución global se obtiene comparando los valores de los óptimos locales alcanzados por cada trayectoria.

7.2. Tasas de convergencia y reglas de parada

Para evaluar cuantitativamente la eficiencia de un método de optimización con convergencia asintótica, caracterizamos la velocidad con la que el error (la distancia al óptimo), definido por $e_k = \|x^k - \bar{x}\|$, se reduce iteración tras iteración.

Asumiendo que $x^k \neq \bar{x}$ para todo $k \geq 0$, la velocidad de convergencia se clasifica principalmente según el límite del cociente de errores sucesivos.

Definición 7.2 (Tasa de convergencia). Se dice que la sucesión $\{x^k\}$ converge a $\bar{x}$ con una tasa:

1. **Lineal:** Si existe una constante $q \in (0, 1)$ tal que el cociente asintótico está acotado por q :

$$\limsup_{k \rightarrow \infty} \frac{\|x^{k+1} - \bar{x}\|}{\|x^k - \bar{x}\|} = q. \quad (7.3)$$

Una tasa lineal implica que el error decae exponencialmente (existe $C > 0$ tal que $\|x^k - \bar{x}\| \leq Cq^k$), pero la implicación recíproca no siempre es cierta (la sucesión podría estar acotada por una envolvente exponencial sin que el límite del cociente exista o sea regular).

2. **Superlineal:** Si el límite del cociente de errores es estrictamente nulo:

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - \bar{x}\|}{\|x^k - \bar{x}\|} = 0. \quad (7.4)$$

Esto significa que la convergencia es eventualmente más rápida que cualquier progresión geométrica.

Un caso particular sumamente importante es la **convergencia cuadrática** (orden 2), que verifica la relación:

$$\limsup_{k \rightarrow \infty} \frac{\|x^{k+1} - \bar{x}\|}{\|x^k - \bar{x}\|^2} \leq C, \quad \text{con } C > 0. \quad (7.5)$$

En este escenario, el número de decimales correctos de la aproximación se duplica (aproximadamente) en cada iteración.

3. **Sublineal:** Si el límite de la relación de errores es igual a 1 (es decir, $q = 1$). Un ejemplo clásico es la **convergencia aritmética**, donde existe una constante $C > 0$ tal que:

$$\limsup_{k \rightarrow \infty} k\|x^k - \bar{x}\| \leq C. \quad (7.6)$$

Definición 7.3 (Convergencia geométrica). Se dice que $\{x^k\}$ converge geoméricamente a $\bar{x}$ si existen constantes $q \in (0, 1)$ y $C > 0$ tales que:

$$\limsup_{k \rightarrow \infty} \frac{\|x^k - \bar{x}\|}{q^k} \leq C. \quad (7.7)$$

Observación. Como se señaló en la Definición 7.2, la convergencia lineal implica convergencia geométrica, pero el recíproco en general no es cierto.

Es importante notar que el análisis de la tasa de convergencia de una sucesión vectorial se rige por su comportamiento global (su norma). El comportamiento aislado de las componentes individuales puede ser engañoso.

Contraejemplo 7.1 (Independencia de la tasa cuadrática en las componentes). La convergencia cuadrática de una sucesión vectorial hacia $\bar{x}$ no exige que cada componente individual converja con tasa superlineal o cuadrática.

Consideremos la trayectoria $\{x^k\} \subset \mathbb{R}^2$ que converge al origen $\bar{x} = (0, 0)^\top$. Fijamos el valor inicial de la segunda componente $x_2^1 \in (0, 1)$. Para todo $k \geq 1$, definimos recursivamente la segunda componente como $x_2^{k+1} = (x_2^k)^2$. Para la primera componente, el comportamiento se acopla según la paridad de la iteración:

$$x_1^{k+1} = \begin{cases} x_1^k & \text{si } k \text{ es impar,} \\ (x_2^{k+1})^2 & \text{si } k \text{ es par.} \end{cases}$$

Para un punto inicial $x^1 = (b^4, b)^\top$ con $b \in (0, 1)$, los primeros términos generados son:

$$\begin{aligned} x^2 &= (b^4, b^2)^\top && \text{(paso impar, por lo que } x_1^2 = x_1^1) \\ x^3 &= (b^8, b^4)^\top && \text{(paso par, por lo que } x_1^3 = (x_2^2)^2) \\ x^4 &= (b^8, b^8)^\top && \text{(paso impar, por lo que } x_1^4 = x_1^3). \end{aligned}$$

La norma del error en cada iteración, $\|x^k\| = \sqrt{(x_1^k)^2 + (x_2^k)^2}$, decae asintóticamente a tasa cuadrática. Sin embargo, al aislar la primera componente en los pasos de paridad impar (por ejemplo, de $k = 3$ a $k = 4$), se observa que $x_1^4 = x_1^3$, por lo que la relación del error marginal es exactamente 1.

Esto demuestra que una componente unidimensional puede estancarse temporalmente (tasa de convergencia 1, ni siquiera lineal), a pesar de que el vector global converge rigurosamente con tasa cuadrática.

La tasa de convergencia asintótica no es el único criterio de eficiencia para seleccionar un algoritmo. Un método con convergencia cuadrática (como el método de Newton) puede requerir mucho más tiempo de cómputo total que un método de gradiente (lineal) si el costo computacional de evaluar y resolver el sistema de ecuaciones con la matriz Hessiana en cada iteración es exorbitantemente elevado. La estabilidad numérica y la viabilidad de los iterados dentro del conjunto factible también influyen dramáticamente en el éxito del algoritmo.

Para equilibrar las propiedades de convergencia global y local, se suelen utilizar **estrategias de globalización**. Se inicia el proceso con un método de convergencia global y robusto; una vez que el residuo del gradiente indica que el iterado está suficientemente cerca de la solución, el algoritmo cambia a un método de orden superior para aprovechar su aceleración local.

Dado que las implementaciones reales no pueden ejecutarse hasta el infinito, el proceso debe detenerse tras un tiempo finito. Para ello se utilizan **criterios de parada**, generalmente basados en el estancamiento de la trayectoria o en tolerancias estrictas de la función y del gradiente:

$$\|x^{k+1} - x^k\| \leq \epsilon, \quad (7.8)$$

$$|f(x^{k+1}) - f(x^k)| \leq \epsilon, \quad (7.9)$$

$$\|\nabla f(x^k)\| \leq \epsilon. \quad (7.10)$$

No obstante, estas condiciones de parada pueden resultar gravemente engañosas si se evalúan de forma aislada.

Contraejemplo 7.2 (Falsas convergencias en algoritmos de optimización). La condición de estancamiento del paso, $\lim_{k \rightarrow \infty} \|x^{k+1} - x^k\| = 0$, no garantiza en absoluto la convergencia hacia un punto límite estacionario. Consideremos dos trayectorias patológicas en $\mathbb{R}$:

1. **Divergencia monótona lenta:** Si $x^k = \sqrt{k}$, la distancia entre pasos decrece asintóticamente a cero, ya que $\sqrt{k+1} - \sqrt{k} \rightarrow 0$. Esto eventualmente satisfará cualquier tolerancia $\epsilon > 0$ en la condición (7.8), engañando al algoritmo para que se detenga. Sin embargo, la trayectoria diverge hacia $+\infty$.
2. **Oscilación acotada no convergente:** Si la secuencia es $x^k = \sin(\sqrt{k})$, la distancia entre pasos también decrece a cero. Activa el criterio de parada (7.8), pero la trayectoria no converge en absoluto; en su lugar, se mantiene orbitando densamente en el intervalo $[-1, 1]$.

Por estas razones, los programas y bibliotecas de optimización robustos siempre combinan varios criterios de parada de forma simultánea, junto con un límite estricto en el número máximo de iteraciones y de evaluaciones de la función objetivo.

Comentario. Como señala la literatura especializada [Izm20], la definición de la jerarquía de las reglas de parada y la calibración fina de sus parámetros numéricos (ϵ) es, en última instancia, “una cuestión de experiencia computacional y heurística más que de ciencia exacta”.

7.3. Métodos de optimización unidimensional

La optimización unidimensional (conocida comúnmente como *búsqueda de línea* o *line search*) es un componente estructural crítico en la gran mayoría de los métodos multivariables. Tras calcular una dirección de descenso $d^k \in \mathbb{R}^n$ desde el punto actual x^k , la determinación del tamaño de paso α requiere resolver (exacta o aproximadamente) el siguiente subproblema:

$$\min f(x) \quad \text{sujeto a } x \in [a, b], \quad (7.11)$$

donde $a < b$ y $f : [a, b] \rightarrow \mathbb{R}$ es una función continua.

Los algoritmos que presentaremos en esta sección son de **orden cero**, lo que significa que no exigen el cálculo de la derivada de f . Iniciaremos con el método de rejilla (un enfoque pasivo) y luego avanzaremos hacia los métodos secuenciales, que permiten aproximar la solución con un costo computacional mucho menor.

7.3.1. Búsqueda en rejilla (Grid Search)

El enfoque pasivo más intuitivo consiste en evaluar la función objetivo sobre una discretización uniforme del intervalo de búsqueda.

Algoritmo 7.1 (Búsqueda en rejilla). Fijamos un número entero $N \geq 1$ de puntos de evaluación permitidos.

1. Definimos el tamaño del incremento (resolución) de la rejilla como $\delta_N = (b - a)/N$.
2. Calculamos los puntos de muestreo distribuidos simétricamente en el intervalo:

$$x_i^N = a + i\delta_N - \frac{\delta_N}{2}, \quad i = 1, \dots, N. \quad (7.12)$$

3. Determinamos la aproximación devolviendo el valor mínimo obtenido tras evaluar los N puntos:

$$v_N = \min_{i=1, \dots, N} f(x_i^N). \quad (7.13)$$

Si la función f es Lipschitz continua en el intervalo con constante de Lipschitz $L > 0$ (es decir, $|f(y) - f(z)| \leq L|y - z|$ para todo $y, z \in [a, b]$), el error analítico de la aproximación está rigurosamente acotado.

Dado que cualquier minimizador global exacto $\bar{x} \in [a, b]$ dista a lo sumo la mitad de la resolución de la rejilla ($\delta_N/2$) del nodo de evaluación más cercano x_j^N , el error funcional del método satisface:

$$v_N - \bar{v} \leq f(x_j^N) - f(\bar{x}) \leq L|x_j^N - \bar{x}| \leq \frac{L(b - a)}{2N}. \quad (7.14)$$

Nota: Características de la Búsqueda en Rejilla

1. **Precisión óptima del error:** La cota de error obtenida en (7.14) es ajustada (*sharp*). Para todo número entero N existe una función f , Lipschitz continua con constante L , tal que el error real de aproximación es exactamente igual a la cota teórica. Esto demuestra que, dentro de la clase de métodos **pasivos** de orden cero, el algoritmo de rejilla es óptimo en el sentido minimax.
2. **Dificultad de estimación práctica:** La principal limitación práctica para definir a priori el número N que garantiza una precisión funcional ϵ consiste en estimar adecuadamente el valor de la constante de Lipschitz L . En la gran mayoría de los casos reales, esta tarea no es trivial y puede resultar analíticamente tan compleja como resolver el propio problema de optimización original. Por lo tanto, el Algoritmo 7.1

suele tener utilidad computacional principalmente cuando L es conocido por la física del problema o puede estimarse con un costo muy bajo.

7.3.2. Métodos de exclusión de intervalos

Los métodos secuenciales operan bajo un principio diferente: reducen la longitud del intervalo de incertidumbre de forma iterativa y adaptativa. Su análisis y garantía de convergencia requiere habitualmente que la función sea **unimodal**; es decir, que posea un único valle.

Definición 7.4 (Función unimodal). Se dice que una función continua $f : [a, b] \rightarrow \mathbb{R}$ es **unimodal** en $[a, b]$ si posee un único minimizador global $\bar{x} \in [a, b]$ y satisface dos condiciones de monotonía:

- Es estrictamente decreciente en el intervalo izquierdo $[a, \bar{x}]$.
- Es estrictamente creciente en el intervalo derecho $[\bar{x}, b]$.

Observación. De la Definición 7.4 se deducen propiedades fundamentales:

1. Una función continua en $[a, b]$ es unimodal si, y solamente si, posee un **único minimizador local** en todo el dominio (el cual forzosamente coincide con el mínimo global).
2. Toda función continua que sea **fuertemente convexa** en el intervalo $[a, b]$ es automáticamente unimodal.
3. La unimodalidad es un concepto topológico **más débil que la convexidad**. Existen múltiples funciones unimodales que son estrictamente no convexas. Por ello, los métodos de exclusión de intervalos que presentaremos tienen un campo de aplicación mucho más amplio que las técnicas basadas únicamente en Análisis Convexo.

El fundamento analítico subyacente de los métodos de exclusión (como Bisección o la Sección Áurea) radica en que la simple comparación ordinal de la función evaluada en dos puntos interiores permite acotar y garantizar la ubicación del mínimo global en un subintervalo estrictamente menor:

Lema 7.1 (Exclusión de intervalos). Sea $f : [a, b] \rightarrow \mathbb{R}$ una función unimodal con minimizador global en $\bar{x} \in [a, b]$. Para cualesquiera dos puntos de prueba interiores $y, z \in [a, b]$ tales que $y < z$, se verifica inexorablemente la siguiente alternativa lógica:

1. Si $f(y) \leq f(z)$, entonces el mínimo global se encuentra contenido en $\bar{x} \in [a, z]$.
2. Si $f(y) \geq f(z)$, entonces el mínimo global se encuentra contenido en $\bar{x} \in [y, b]$.

Prueba. Demostraremos el caso (1) procediendo por reducción al absurdo.

Supongamos que se cumple $f(y) \leq f(z)$, pero asumamos falsamente que el mínimo global $\bar{x}$ se encuentra estrictamente a la derecha del punto de corte z (es decir, $\bar{x} > z$). En este escenario geométrico, los puntos mantienen el orden estricto $y < z < \bar{x}$.

Invocando la definición de unimodalidad (Definición 7.4), sabemos que la función f debe ser **estrictamente decreciente** en todo el segmento anterior al mínimo $[a, \bar{x}]$. Como los puntos y y z pertenecen a este segmento de descenso, la relación espacial $y < z$ implica forzosamente que el valor funcional desciende: $f(y) > f(z)$.

Esto contradice frontalmente nuestra premisa inicial ($f(y) \leq f(z)$). Por consiguiente, la asunción inicial era falsa y el mínimo global $\bar{x}$ no puede estar a la derecha de z . Debe pertenecer al intervalo cerrado $[a, z]$.

La demostración del caso (2) es completamente análoga, apelando a la condición de crecimiento estricto en el segmento posterior al mínimo. ■

Método de Bisección

El método de bisección divide sistemáticamente el dominio de búsqueda a la mitad, requiriendo evaluar la función en nuevos puntos centrales.

Algoritmo 7.2 (Método de bisección). Fijamos los bordes $a_1 = a$, $b_1 = b$. Calculamos el centro inicial $c_1 = (a + b)/2$ y evaluamos funcionalmente $f(c_1)$. Para cada iteración $k \geq 1$:

1. Definimos el punto de prueba en el subintervalo izquierdo $y_k = (a_k + c_k)/2$ y evaluamos $f(y_k)$.

2. Si se cumple $f(y_k) \leq f(c_k)$, el Lema 7.1 garantiza que el mínimo está a la izquierda de c_k . El nuevo intervalo de incertidumbre es $[a_k, c_k]$. Actualizamos las variables:

$$a_{k+1} = a_k, \quad b_{k+1} = c_k, \quad c_{k+1} = y_k.$$

Saltamos directamente al paso de incremento (Paso 5).

3. Si $f(y_k) > f(c_k)$, el mínimo debe estar a la derecha de y_k . Para decidir entre el bloque central y el derecho, definimos un punto de prueba en el subintervalo derecho $z_k = (c_k + b_k)/2$ y evaluamos $f(z_k)$.
4. Si $f(c_k) \leq f(z_k)$, actualizamos con el bloque central:

$$a_{k+1} = y_k, \quad b_{k+1} = z_k, \quad c_{k+1} = c_k.$$

Si $f(c_k) > f(z_k)$, actualizamos con el bloque derecho:

$$a_{k+1} = c_k, \quad b_{k+1} = b_k, \quad c_{k+1} = z_k.$$

5. Incrementamos el contador de iteraciones $k \leftarrow k + 1$ y volvemos al Paso 1 hasta satisfacer una tolerancia ϵ .

La longitud del intervalo de incertidumbre se reduce a la mitad en cada paso ($b_{k+1} - a_{k+1} = (b_k - a_k)/2$). Sin embargo, la cantidad de evaluaciones de función requeridas es variable (a veces 1, a veces 2 por iteración).

Si suponemos, por conveniencia algorítmica, que el presupuesto total de evaluaciones permitidas N es un número impar, podemos realizar exactamente $k = (N - 1)/2$ iteraciones completas. La cota de reducción del intervalo final sigue una progresión geométrica dictada por el factor $(1/2)^{1/2} \approx 0.707$:

$$\text{Longitud Final} \leq \frac{1}{2^{(N-1)/2}}(b - a) \approx (0.707)^{N-1}(b - a). \quad (7.15)$$

Método de la Sección Áurea

Para maximizar la eficiencia computacional y garantizar que se requiera **exactamente una única evaluación de función** por cada iteración, se deben seleccionar los puntos de prueba interiores y y z manteniendo una proporción de invarianza geométrica constante τ .

Esta partición inteligente exige que la relación entre la longitud del intervalo original y el subintervalo mayor sea topológicamente idéntica a la relación entre el subintervalo mayor y el menor:

$$\frac{b - a}{b - y} = \frac{b - y}{y - a}. \quad (7.16)$$

Al resolver esta ecuación cuadrática de proporcionalidad, se obtiene que la constante de partición es el inverso de la proporción áurea (el límite de los cocientes de la sucesión de Fibonacci):

$$\tau = \frac{\sqrt{5} - 1}{2} \approx 0.618. \quad (7.17)$$

Para garantizar la validez del reciclaje de puntos internos sin necesidad de recalcularlos en cada paso, el Algoritmo 7.3 se apoya en el siguiente lema geométrico.

Lema 7.2 (Simetría e Invarianza de la Sección Áurea). Sean y y z el menor y el mayor punto interior de la partición áurea del intervalo $[a, b]$, respectivamente. Entonces se verifica:

1. La distancia a los bordes es simétrica: $z - a = b - y = \tau(b - a)$.
2. La propiedad de anidamiento fractal: el punto y es exactamente el mayor punto interno de la partición de la sección áurea del subintervalo izquierdo $[a, z]$. Del mismo modo, z es exactamente el menor punto interno de la partición áurea del subintervalo derecho $[y, b]$.

Prueba. La demostración exige una manipulación algebraica directa basada en las definiciones de y y z , y se propone como el Ejercicio 7.8 al final del capítulo. ■

Los puntos de prueba áureos para cualquier intervalo $[a, b]$ se calculan de forma exacta como:

$$y(a, b) = a + \frac{3 - \sqrt{5}}{2}(b - a) \approx a + 0.382(b - a), \quad (7.18)$$

$$z(a, b) = a + \frac{\sqrt{5} - 1}{2}(b - a) \approx a + 0.618(b - a). \quad (7.19)$$

Algoritmo 7.3 (Método de la sección áurea). Fijamos los bordes $a_1 = a$, $b_1 = b$. Calculamos los dos puntos internos iniciales $y_1 = y(a_1, b_1)$ y $z_1 = z(a_1, b_1)$ mediante (7.18)-(7.19) y realizamos la primera evaluación dual $f(y_1)$ y $f(z_1)$. Tomamos el contador $k := 1$.

1. Para las iteraciones subsecuentes, **evaluamos únicamente** aquel punto interno (entre y_k y z_k) cuyo valor de la función aún no haya sido calculado previamente.
2. Invocamos el Lema 7.1. Si $f(y_k) \leq f(z_k)$, el mínimo está en $[a_k, z_k]$. Actualizamos los límites y reciclamos el punto interno evaluado (invocando el Lema 7.2):

$$a_{k+1} = a_k, \quad b_{k+1} = z_k, \quad z_{k+1} = y_k.$$

Calculamos únicamente la coordenada del nuevo punto menor $y_{k+1} = y(a_{k+1}, b_{k+1})$.

3. Si $f(y_k) > f(z_k)$, el mínimo está en $[y_k, b_k]$. Actualizamos y reciclamos en sentido inverso:

$$a_{k+1} = y_k, \quad b_{k+1} = b_k, \quad y_{k+1} = z_k.$$

Calculamos únicamente la coordenada del nuevo punto mayor $z_{k+1} = z(a_{k+1}, b_{k+1})$.

4. Incrementamos $k \leftarrow k + 1$ y volvemos al Paso 1.

Al reciclar inteligentemente las evaluaciones funcionales, el factor de reducción del intervalo de incertidumbre por cada nueva función calculada es exactamente $\tau \approx 0.618$. El error final absoluto tras ejecutar un presupuesto de N evaluaciones decae de manera geométrica:

$$|x^N - \bar{x}| \leq b_{k+1} - a_{k+1} = \left(\frac{\sqrt{5} - 1}{2} \right)^{N-1} (b - a) \approx 0.618^{N-1}(b - a). \quad (7.20)$$

7.3.3. Búsquedas en Dominios Semi-infinitos e Intervalos No Unimodales

Fase de acotamiento en intervalos semi-infinitos

En las implementaciones reales de métodos de gradiente, rara vez se conoce a priori un límite superior para la búsqueda de línea a lo largo de una dirección de descenso. Se requiere minimizar la función f sobre una semirrecta unidimensional semi-infinita $[a, +\infty)$. Para poder instanciar el método de bisección o la sección áurea, la primera fase obliga a aislar topológicamente el mínimo en un intervalo acotado estricto $[a, a + T]$.

Esta **fase de acotamiento (bracketing)** funciona así: fijamos un tamaño de paso inicial exploratorio $\delta > 0$ y evaluamos la función en la secuencia de puntos equidistantes $z_k = a + k\delta$ para $k = 0, 1, 2, \dots$.

Determinamos el menor índice entero $k \geq 0$ en el cual se viole la condición de descenso funcional, es decir:

$$f(a + k\delta) \leq f(a + (k + 1)\delta). \quad (7.21)$$

Bajo la hipótesis analítica de que f mantiene su propiedad de unimodalidad a lo largo de toda la semirrecta, el mínimo global $\bar{x}$ pertenecerá invariablemente a la ventana acotada detectada:

$$\bar{x} \in \begin{cases} [a, a + \delta] & \text{si } k = 0, \\ [a + (k - 1)\delta, a + (k + 1)\delta] & \text{si } k \geq 1. \end{cases} \quad (7.22)$$

Si el algoritmo fuera incapaz de encontrar dicho índice k tras sucesivas evaluaciones (es decir, f decrece asintóticamente al infinito), se concluiría matemáticamente que el problema unidimensional original es ilimitado y carece de minimizador finito.

Robustez ante funciones no unimodales

Un teorema pragmático de gran relevancia computacional dicta que si la función objetivo f es continua en el intervalo cerrado $[a, b]$ pero **no es unimodal** (tiene múltiples valles locales y crestas), los algoritmos de Bisección (Algoritmo 7.2) y Sección Áurea (Algoritmo 7.3) no colapsan ni arrojan errores de división por cero.

En este escenario general caótico, los algoritmos operarán de forma ciega pero robusta, garantizando asintóticamente la convergencia hacia **al menos un minimizador local** (el cual depende estrictamente de los parámetros iniciales de partición) en el subespacio unidimensional.

7.3.4. Interpolación polinómica cuadrática y salvaguardas

Si la función objetivo f es suficientemente suave (dos veces continuamente diferenciable), se puede abandonar la reducción geométrica pasiva y aproximar la topología del valle localmente mediante un polinomio cuadrático $P(x)$, tomando el vértice exacto de dicha parábola como la siguiente aproximación del mínimo.

Este método requiere evaluar y mantener en memoria una terna de puntos $a_k < b_k < c_k$ que certifiquen el valle. A esta propiedad se le denomina **condición de sándwich**:

$$a_k < b_k < c_k, \quad f(a_k) > f(b_k), \quad f(b_k) < f(c_k). \quad (7.23)$$

Algoritmo 7.4 (Interpolación cuadrática sucesiva). Partiendo de una terna de puntos iniciales $a_1 < b_1 < c_1$ que garantice el cumplimiento de la condición de sándwich (7.23), definimos el iterador $k := 1$:

1. Calculamos algebraicamente la abscisa del vértice x_k de la parábola única que interpola los tres puntos:

$$x_k = \frac{1}{2} \frac{f(a_k)(c_k^2 - b_k^2) + f(b_k)(a_k^2 - c_k^2) + f(c_k)(b_k^2 - a_k^2)}{f(a_k)(c_k - b_k) + f(b_k)(a_k - c_k) + f(c_k)(b_k - a_k)}. \quad (7.24)$$

2. Evaluamos computacionalmente la función objetivo en la nueva abscisa del vértice, es decir, obtenemos $f(x_k)$.
3. Determinamos la topología del nuevo valle y actualizamos la terna analizando el árbol de decisiones lógicas:

- **Rama Derecha Inferior:** Si $x_k > b_k$ y $f(x_k) < f(b_k)$:

$$a_{k+1} = b_k, \quad b_{k+1} = x_k, \quad c_{k+1} = c_k.$$

- **Rama Derecha Superior:** Si $x_k > b_k$ y $f(x_k) \geq f(b_k)$:

$$a_{k+1} = a_k, \quad b_{k+1} = b_k, \quad c_{k+1} = x_k.$$

- **Rama Izquierda Inferior:** Si $x_k < b_k$ y $f(x_k) < f(b_k)$:

$$a_{k+1} = a_k, \quad b_{k+1} = x_k, \quad c_{k+1} = b_k.$$

- **Rama Izquierda Superior:** Si $x_k < b_k$ y $f(x_k) \geq f(b_k)$:

$$a_{k+1} = x_k, \quad b_{k+1} = b_k, \quad c_{k+1} = c_k.$$

4. Incrementamos $k \leftarrow k + 1$ y volvemos al Paso 1.

Bajo condiciones de regularidad local severas, el Algoritmo 7.4 alcanza asintóticamente una tasa de convergencia **superlineal** de orden ≈ 1.32 (mucho más rápida que la constante de la Sección Áurea).

Atención: El colapso de la interpolación cuadrática

A diferencia de los métodos pasivos de exclusión de intervalos (que están ciegamente garantizados), la evaluación iterativa del denominador en la ecuación (7.24) introduce una falla catastrófica potencial.

Si los puntos de evaluación se alinean casi colinealmente, la curvatura de la parábola tiende a cero y el denominador experimenta un desbordamiento numérico. El vértice x_k predicho puede ser arrojado violentamente fuera del intervalo de interés original.

Para evitar el colapso numérico, el conocido **Método de Brent** combina lo mejor de ambos mundos: intenta realizar un paso de interpolación cuadrática rápida, pero mantiene un estricto monitoreo. Si el paso cuadrático no resulta en una contracción suficiente o el vértice explota fuera de los límites, el algoritmo ejecuta una *salvaguarda* recurriendo a un paso ciego y seguro del método de la Sección Áurea.

Ejercicios del Capítulo

Parte I: Propiedades de Lipschitz e Intervalos

Ejercicio 7.1 (Constante de Lipschitz en funciones seccionadas). Sean $a, b, c \in \mathbb{R}$ tales que $a < c < b$. Supóngase que la función $f : [a, b] \rightarrow \mathbb{R}$ es Lipschitz continua en el intervalo $[a, c]$ con constante $L_1 > 0$, y es Lipschitz continua en $[c, b]$ con constante $L_2 > 0$. Demuestre rigurosamente que f es Lipschitz continua en todo el intervalo $[a, b]$ con constante global de Lipschitz:

$$L = \max\{L_1, L_2\}.$$

Ejercicio 7.2 (Acotación del gradiente y propiedad de Lipschitz). Sea $f : [a, b] \rightarrow \mathbb{R}$ una función continua en el intervalo compacto $[a, b]$ y diferenciable en el conjunto interior $[a, b] \setminus \{c_1, \dots, c_s\}$, donde $\{c_1, \dots, c_s\}$ es un conjunto finito de puntos de no diferenciabilidad (por ejemplo, puntos de cúspide). Si se cumple la acotación de la norma:

$$L = \sup\{|f'(x)| \mid x \in [a, b] \setminus \{c_1, \dots, c_s\}\} < \infty,$$

demuestre mediante el uso del Teorema del Valor Medio que f es Lipschitz continua en $[a, b]$ con constante L .

Ejercicio 7.3 (Álgebra de funciones de Lipschitz). Sean $f_1, f_2 : [a, b] \rightarrow \mathbb{R}$ dos funciones Lipschitz continuas en el intervalo $[a, b]$ con constantes garantizadas $L_1 > 0$ y $L_2 > 0$, respectivamente. Demuestre las siguientes propiedades algebraicas de la clase de funciones de Lipschitz:

1. La función suma $f_1 + f_2$ es Lipschitz continua en $[a, b]$ con constante acotada por $L_1 + L_2$.
2. La función envolvente máximo puntual $g(x) = \max\{f_1(x), f_2(x)\}$ es Lipschitz continua en $[a, b]$ con constante de Lipschitz acotada por $\max\{L_1, L_2\}$.

Ejercicio 7.4 (Existencia de funciones continuas no Lipschitz). El Teorema de Weierstrass garantiza mínimos para funciones continuas, pero no la tasa de variación. Proporcione un ejemplo analítico explícito de una función $f : [0, 1] \rightarrow \mathbb{R}$ que cumpla con ser continuamente diferenciable en el intervalo abierto $(0, 1)$ y absolutamente continua en los bordes cerrados $[0, 1]$, pero que **no** sea Lipschitz continua en $[0, 1]$. Justifique su demostración estudiando el límite del gradiente.

Parte II: Unimodalidad y Exclusión de Intervalos

Ejercicio 7.5 (Unimodalidad y Cuasiconvexidad Estricta). Sea el dominio $X \subset \mathbb{R}^n$ un conjunto topológico convexo. Se dice en Análisis Convexo que una función $f : X \rightarrow \mathbb{R}$ es **estrictamente cuasiconvexa** en X si, para cualquier par de puntos base $x^1, x^2 \in X$ con $x^1 \neq x^2$ y para cualquier interpolador $t \in (0, 1)$, se verifica la cota estricta:

$$f(tx^1 + (1-t)x^2) < \max\{f(x^1), f(x^2)\}. \quad (7.25)$$

Restrinja el estudio al caso donde el dominio es el intervalo unidimensional cerrado $X = [a, b]$. Demuestre analíticamente que una función continua $f : [a, b] \rightarrow \mathbb{R}$ cumple con ser topológicamente unimodal (Definición 7.4) si y solo si es estrictamente cuasiconvexa en dicho intervalo.

Ejercicio 7.6 (Preservación de la unimodalidad). Sean $f_1, f_2 : [a, b] \rightarrow \mathbb{R}$ dos funciones que garantizan la propiedad de unimodalidad en el intervalo $[a, b]$. Analice bajo qué escenarios analíticos restrictivos la función suma lineal $f_1 + f_2$ y la función máximo puntual $g(x) = \max\{f_1(x), f_2(x)\}$ preservan también la propiedad de unimodalidad.

Proporcione contraejemplos visuales o algebraicos detallados para demostrar por qué la suma y el máximo de funciones unimodales **no generan siempre** funciones unimodales en el caso general.

Ejercicio 7.7 (Simulación numérica del método de Bisección). Considere el siguiente problema de optimización polinómica unidimensional:

$$\underset{x \in [1,5]}{\text{minimizar}} \quad f(x) = 2x^2 - 7x + 1$$

Procediendo sin el uso de derivadas de primer orden:

1. Inicialice el Algoritmo 7.2. Realice de forma manual y documentada **dos iteraciones completas** para reducir y localizar el nuevo intervalo de incertidumbre del mínimo global.
2. Demuestre mediante la condición de primer orden del Capítulo 1 cuál es la solución analítica exacta $\bar{x}$, y compare el error residual de sus límites calculados.

Parte III: Demostraciones algebraicas de los Métodos

Ejercicio 7.8 (Verificación del Lema de la Sección Áurea). El Algoritmo 7.3 asume una propiedad de invarianza. Utilizando las definiciones exactas algebraicas de los puntos áureos fraccionarios $y(a, b)$ y $z(a, b)$ dados por las ecuaciones (7.18)-(7.19), demuestre por cálculo de reducción directa las propiedades declaradas en el Lema 7.2:

1. Pruebe rigurosamente que la longitud escalar de los subintervalos laterales es idéntica y satisface la simetría:

$$z - a = b - y = \tau(b - a),$$

donde $\tau = (\sqrt{5} - 1)/2$.

2. Pruebe que la proporción se anida. Es decir, al recortar el intervalo de incertidumbre original por la derecha, asignando el nuevo límite superior como $b_{new} = z$, el antiguo punto menor y original se convierte, sin error de truncamiento, exactamente en el punto de prueba mayor del nuevo intervalo acotado:

$$y = a + \tau(z - a).$$

Ejercicio 7.9 (Vértice del polinomio interpolador cuadrático). Demuestre de forma algebraica que el cálculo de la abscisa del vértice x_k provisto en la ecuación (7.24) del Algoritmo 7.4 no es heurístico.

Pruebe mediante la manipulación del determinante de Vandermonde o mediante sistemas lineales, que x_k es, en efecto, el único minimizador (si el denominador es positivo) del polinomio cuadrático exacto:

$$P(x) = \alpha x^2 + \beta x + \gamma$$

que interpola fielmente a la función objetivo f en los tres puntos de evaluación preexistentes $a_k < b_k < c_k$.

8. Optimización No Restringida

En este capítulo, presentamos algoritmos para minimizar, sin restricciones, funciones una o dos veces diferenciables. Nuestra intención es, como siempre, explicar las ideas principales y los fundamentos matemáticos del desarrollo y del análisis de los algoritmos. Los aspectos puramente de implementación, aunque son un tema de extrema importancia, se presentarán únicamente cuando sean relevantes o reveladores desde el punto de vista matemático.

Se abordarán los métodos de descenso y las técnicas de búsqueda lineal, que representan ideas fundamentales en la optimización computacional, incluso para problemas con restricciones (como veremos en capítulos posteriores). También presentaremos el método de Newton, el cual representa el estándar de oro para el desarrollo de algoritmos con convergencia rápida. No obstante, los métodos cuasi-Newton, que son aún más importantes en la práctica, se tratarán como una realización inexacta y económica del esquema básico del método de Newton. El mismo comentario es válido para los métodos de gradientes conjugados en el caso de funciones no lineales generales.

8.1. Métodos de descenso

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dada. Una de las estrategias más naturales para resolver el problema irrestricto

$$\min f(x), \quad x \in \mathbb{R}^n, \quad (8.1)$$

es la siguiente: dada una aproximación $x^k \in \mathbb{R}^n$ de la solución del problema, encontramos un punto $x^{k+1} \in \mathbb{R}^n$ tal que

$$f(x^{k+1}) < f(x^k).$$

Una realización de esta estrategia básica consiste en tomar una dirección $d^k \in \mathbb{R}^n$ tal que f sea decreciente (al menos para pasos cortos) a partir del punto x^k en esa dirección, y calcular una longitud de paso $\alpha_k > 0$ que proporcione un valor de f estrictamente menor que en el punto x^k :

$$f(x^k + \alpha_k d^k) < f(x^k).$$

Así obtenemos el siguiente iterado $x^{k+1} = x^k + \alpha_k d^k$. Repetimos el proceso para el nuevo punto x^{k+1} . Los métodos de este tipo se denominan **métodos de descenso** y los formalizamos a continuación.

8.1.1. Esquema general de los métodos de descenso. Búsqueda lineal

Sea $x \in \mathbb{R}^n$ un punto cualquiera tal que $f'(x) \neq 0$. Consideremos los puntos de la forma $x + td$, donde $d = -f'(x)$. Por la Fórmula de Taylor de primer orden, para todo $t \geq 0$ tenemos que:

$$\begin{aligned} f(x + td) &= f(x) - t\|f'(x)\|^2 + o(t\|f'(x)\|) \\ &= f(x) - t\left(\|f'(x)\|^2 + \frac{o(t)}{t}\right). \end{aligned}$$

Como para valores de $t > 0$ suficientemente pequeños se tiene que $\|f'(x)\|^2 > o(t)/t$, para estos valores se cumple que $f(x + td) < f(x)$. De hecho, el mismo razonamiento se puede utilizar para cualquier dirección $d \in \mathbb{R}^n$ que satisfaga $\langle f'(x), d \rangle < 0$.

Definición 8.1 (Dirección de descenso). Decimos que $d \in \mathbb{R}^n$ es una **dirección de descenso** de la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ en el punto $x \in \mathbb{R}^n$ si existe $\epsilon > 0$ tal que

$$f(x + td) < f(x) \quad \forall t \in (0, \epsilon].$$

Denotamos por $\mathcal{D}_f(x)$ al conjunto de todas las direcciones de descenso de la función f en el punto x .

En otras palabras, $d \in \mathcal{D}_f(x)$ si y solo si cualquier paso suficientemente corto a partir de x en la dirección d resulta en un decremento estricto de la función f . Es evidente que $\mathcal{D}_f(x)$ puede ser vacío, y que el conjunto $\mathcal{D}_f(x) \cup \{0\}$ es un cono.

Lema 8.1 (Caracterización de Direcciones de descenso). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $x \in \mathbb{R}^n$. Entonces:

1. Para todo $d \in \mathcal{D}_f(x)$, se tiene $\langle f'(x), d \rangle \leq 0$.
2. Si $d \in \mathbb{R}^n$ satisface $\langle f'(x), d \rangle < 0$, se tiene que $d \in \mathcal{D}_f(x)$.

Prueba. Sea $d \in \mathcal{D}_f(x)$. Para todo $t > 0$ suficientemente pequeño, por la diferenciabilidad de f en x :

$$0 > f(x + td) - f(x) = t \left(\langle f'(x), d \rangle + \frac{o(t)}{t} \right).$$

Dividiendo ambos lados de la desigualdad por $t > 0$ y pasando al límite cuando $t \rightarrow 0^+$, obtenemos $0 \geq \langle f'(x), d \rangle$, lo que demuestra el inciso (1).

Supongamos ahora que $\langle f'(x), d \rangle < 0$. Tenemos que

$$f(x + td) - f(x) = t \left(\langle f'(x), d \rangle + \frac{o(t)}{t} \right).$$

Para todo $t > 0$ suficientemente pequeño, tenemos $\langle f'(x), d \rangle + \frac{o(t)}{t} \leq \frac{1}{2} \langle f'(x), d \rangle < 0$, lo que implica que $f(x + td) - f(x) < 0$, es decir, $d \in \mathcal{D}_f(x)$. ■

El esquema iterativo general de los métodos de descenso consiste en lo siguiente:

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k \in \mathcal{D}_f(x^k), \quad k = 0, 1, \dots \quad (8.2)$$

donde los valores de la longitud del paso $\alpha_k > 0$ se eligen para satisfacer, al menos, la condición de descenso estricto:

$$f(x^{k+1}) < f(x^k). \quad (8.3)$$

El análisis asume que $\mathcal{D}_f(x^k) \neq \emptyset$. En particular, el método se detiene si $\mathcal{D}_f(x^k) = \emptyset$ en alguna iteración. Debido a que $d^k \in \mathcal{D}_f(x^k)$, siempre existe un número $\alpha_k > 0$ que satisface (8.3).

Por el Lema 8.1, la elección más obvia de una dirección de descenso viene dada por $d^k = -f'(x^k)$ (el antigradiente). Sin embargo, esta elección es poco eficiente cuando las curvas de nivel son “alargadas”, generando trayectorias en zig-zag. Desde el punto de vista práctico, es mucho más importante considerar métodos de la forma $d^k = -Q_k f'(x^k)$, donde Q_k es una matriz definida positiva que adapta la métrica del espacio (véase el método de Newton).

A continuación, presentamos las principales **reglas de búsqueda lineal** (linesearch), asumiendo que ya se ha elegido una dirección $d^k \in \mathcal{D}_f(x^k)$.

1. Regla de minimización unidimensional (Exact Line Search)

Una estrategia natural es minimizar la función objetivo a lo largo de la semirrecta. La longitud de paso α_k se obtiene resolviendo:

$$\min_{\alpha \geq 0} \varphi_k(\alpha) = f(x^k + \alpha d^k). \quad (8.4)$$

Si la función f es diferenciable, del Teorema de Optimalidad de primer orden se deduce la condición de ortogonalidad:

$$0 = \varphi'_k(\alpha_k) = \langle f'(x^{k+1}), d^k \rangle. \quad (8.5)$$

En el caso general, la resolución exacta unidimensional es muy costosa. Prácticamente, esta regla se sustituye por las heurísticas de decremento suficiente.

2. Regla de Armijo

Esta estrategia calcula una longitud de paso que resulte en un decremento suficiente de f , siendo mucho más económica. Fijamos los parámetros $\hat{\alpha} > 0$ (paso inicial), y $\sigma, \theta \in (0, 1)$. Tomamos $\alpha := \hat{\alpha}$.

1. Verificamos si se satisface la **Condición de Armijo**:

$$f(x^k + \alpha d^k) \leq f(x^k) + \sigma \alpha \langle f'(x^k), d^k \rangle. \quad (8.6)$$

2. Si (8.6) no se satisface, reducimos el paso tomando $\alpha := \theta\alpha$ y regresamos al Paso 1. De lo contrario, aceptamos $\alpha_k := \alpha$.

Lema 8.2 (La regla de Armijo está bien definida). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en x^k . Si d^k satisface la condición de descenso $\langle f'(x^k), d^k \rangle < 0$, entonces la desigualdad (8.6) se satisface para todo $\alpha > 0$ suficientemente pequeño. En particular, la regla de Armijo termina en un número finito de reducciones.

Prueba. Por el desarrollo de Taylor, para todo $\alpha > 0$ suficientemente pequeño:

$$\begin{aligned} f(x^k + \alpha d^k) - f(x^k) &= \alpha \langle f'(x^k), d^k \rangle + o(\alpha) \\ &= \sigma \alpha \langle f'(x^k), d^k \rangle + \alpha \left((1 - \sigma) \langle f'(x^k), d^k \rangle + \frac{o(\alpha)}{\alpha} \right). \end{aligned}$$

Como $\sigma \in (0, 1)$ y la derivada direccional es negativa, el término $(1 - \sigma) \langle f'(x^k), d^k \rangle + \frac{o(\alpha)}{\alpha} < 0$ para α cercano a 0.

Luego $f(x^k + \alpha d^k) - f(x^k) \leq \sigma \alpha \langle f'(x^k), d^k \rangle$. ■

Lema 8.3 (Cota inferior para el paso de Armijo). Sea f diferenciable con gradiente Lipschitz-continuo (constante $L > 0$). Si $\langle f'(x^k), d^k \rangle < 0$, entonces la desigualdad (8.6) es válida para todo $\alpha \in (0, \bar{\alpha}_k]$, donde:

$$\bar{\alpha}_k = -\frac{2(1 - \sigma) \langle f'(x^k), d^k \rangle}{L \|d^k\|^2} > 0. \quad (8.7)$$

Prueba. Utilizando la cota cuadrática para gradientes Lipschitz Lema 6.4:

$$\begin{aligned} f(x^k + \alpha d^k) - f(x^k) &\leq \alpha \langle f'(x^k), d^k \rangle + \frac{L}{2} \alpha^2 \|d^k\|^2 \\ &= \alpha \left(\langle f'(x^k), d^k \rangle + \frac{L}{2} \alpha \|d^k\|^2 \right) \leq \sigma \alpha \langle f'(x^k), d^k \rangle, \end{aligned}$$

donde la última desigualdad se cumple exactamente para $\alpha \leq \bar{\alpha}_k$. ■

3. Regla de Goldstein y Wolfe

La regla de **Goldstein** impone que la reducción no sea ni muy pequeña (Armijo) ni excesivamente grande, acotando el descenso por una franja lineal con constantes $0 < \sigma_1 < \sigma_2 < 1$.

La regla de **Wolfe** es habitualmente la más eficiente en la práctica para métodos cuasi-Newton. Exige satisfacer simultáneamente Armijo y una condición de curvatura:

$$f(x^k + \alpha d^k) \leq f(x^k) + \sigma_1 \alpha \langle f'(x^k), d^k \rangle, \quad (8.8)$$

$$\langle f'(x^k + \alpha d^k), d^k \rangle \geq \sigma_2 \langle f'(x^k), d^k \rangle. \quad (8.9)$$

La segunda condición controla la precisión de la minimización a lo largo de la línea. Se puede demostrar que para funciones acotadas inferiormente, la regla de Wolfe está siempre bien definida.

Lema 8.4 (La regla de Wolfe está bien definida). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función acotada inferiormente en $\mathbb{R}^n$, de clase $\mathcal{C}^1$. Supongamos que $x^k \in \mathbb{R}^n$ y $d^k \in \mathbb{R}^n$ satisfacen la condición suficiente de descenso $\langle f'(x^k), d^k \rangle < 0$.

Entonces, cualquier implementación de la regla de Wolfe, para la cual se tiene que el límite superior del intervalo de búsqueda $\bar{\alpha} \rightarrow +\infty$ en el caso de un número infinito de extrapolaciones, y $(\bar{\alpha} - \hat{\alpha}) \rightarrow 0$ en el caso de un número infinito de interpolaciones, está bien definida, en el sentido de que termina con un valor de longitud de paso $\alpha_k > 0$.

Prueba. Supongamos primero que el número de extrapolaciones es infinito. En este caso, tenemos una sucesión de valores $\bar{\alpha} \rightarrow +\infty$, para los cuales

$$f(x^k + \bar{\alpha} d^k) \leq f(x^k) + \sigma_1 \bar{\alpha} \langle f'(x^k), d^k \rangle. \quad (8.10)$$

Teniendo en cuenta el descenso estricto, esto contradice el hecho de que f está acotada inferiormente. Por lo tanto, el número de extrapolaciones es finito.

Supongamos ahora que el número de interpolaciones es infinito. En este caso, las sucesiones monótonas de valores de $\bar{\alpha}$ y de $\hat{\alpha}$ convergen a un límite común $\tilde{\alpha}$. Además, los elementos de la primera sucesión satisfacen (8.10) y

$$\langle f'(x^k + \tilde{\alpha} d^k), d^k \rangle < \sigma_2 \langle f'(x^k), d^k \rangle, \quad (8.11)$$

y los elementos de la segunda sucesión satisfacen

$$f(x^k + \tilde{\alpha} d^k) > f(x^k) + \sigma_1 \tilde{\alpha} \langle f'(x^k), d^k \rangle. \quad (8.12)$$

Pasando al límite en ambas, obtenemos la igualdad

$$f(x^k + \tilde{\alpha}d^k) = f(x^k) + \sigma_1 \tilde{\alpha} \langle f'(x^k), d^k \rangle. \quad (8.13)$$

Teniendo en cuenta (8.12) y que los valores de $\hat{\alpha}$ son decrecientes, estos se mantienen estrictamente mayores que $\tilde{\alpha}$. Usando (8.13), escribimos (8.12) como

$$\begin{aligned} f(x^k + \hat{\alpha}d^k) &> f(x^k) + \sigma_1(\tilde{\alpha} + \hat{\alpha} - \tilde{\alpha}) \langle f'(x^k), d^k \rangle \\ &= f(x^k + \tilde{\alpha}d^k) + \sigma_1(\hat{\alpha} - \tilde{\alpha}) \langle f'(x^k), d^k \rangle. \end{aligned}$$

Como $\hat{\alpha} - \tilde{\alpha} > 0$, tenemos que

$$\frac{f(x^k + \hat{\alpha}d^k) - f(x^k + \tilde{\alpha}d^k)}{\hat{\alpha} - \tilde{\alpha}} > \sigma_1 \langle f'(x^k), d^k \rangle.$$

Pasando al límite (cuando $(\hat{\alpha} - \tilde{\alpha}) \rightarrow 0$) y usando que $\sigma_1 < \sigma_2$, obtenemos

$$\langle f'(x^k + \tilde{\alpha}d^k), d^k \rangle \geq \sigma_1 \langle f'(x^k), d^k \rangle > \sigma_2 \langle f'(x^k), d^k \rangle. \quad (8.14)$$

Por otro lado, pasando al límite en (8.11), obtenemos la desigualdad $\langle f'(x^k + \tilde{\alpha}d^k), d^k \rangle \leq \sigma_2 \langle f'(x^k), d^k \rangle$, en franca contradicción con (8.14). ■

8.1.2. El método del gradiente

Hablamos del **método del gradiente** cuando la dirección de descenso d^k se elige exactamente como el antigradiente de la función en el punto actual: $d^k = -f'(x^k)$. En particular, el esquema se reduce a:

$$x^{k+1} = x^k - \alpha_k f'(x^k), \quad k = 0, 1, \dots \quad (8.15)$$

El método del gradiente es de primer orden y, en general, es poco eficiente para resolver problemas mal condicionados. Aun así, su estudio es un pilar teórico fundamental.

Algoritmo 8.1 (Método del gradiente). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$. Elegir una regla de búsqueda lineal (Armijo o paso fijo).

1. Calcular la longitud de paso α_k en la dirección $d^k = -f'(x^k)$ de acuerdo con la regla elegida. (Si $f'(x^k) = 0$, el método se detiene al alcanzar un punto estacionario).
2. Calcular el nuevo iterado mediante $x^{k+1} = x^k - \alpha_k f'(x^k)$.
3. Incrementar $k \leftarrow k + 1$ y retornar al Paso 1.

Cuando se usa minimización unidimensional exacta, se le conoce como *método de máximo descenso*. Las propiedades de convergencia global para la regla de Armijo son sólidas. Por el Lema 8.3, el paso de Armijo está uniformemente acotado inferiormente por:

$$\tilde{\alpha}_k = \frac{2(1 - \sigma)}{L} \implies \alpha_k \geq \tilde{\alpha} > 0. \quad (8.16)$$

Teorema 8.1 (Convergencia global del método del gradiente I). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable con gradiente Lipschitz-continuo (constante $L > 0$). En el caso de usar longitud de paso fijo, supongamos que $\tilde{\alpha} < 2/L$.

Entonces, todo punto de acumulación de cualquier secuencia $\{x^k\}$ generada por el Algoritmo 8.1 es un punto estacionario del problema. Si existe un punto de acumulación, o si f es acotada inferiormente en $\mathbb{R}^n$, entonces:

$$\|f'(x^k)\| \rightarrow 0 \quad (k \rightarrow \infty). \quad (8.17)$$

Prueba. Consideramos la regla de Armijo. La secuencia $\{f(x^k)\}$ es monótona decreciente y acotada inferiormente (ya sea por hipótesis o por la continuidad en el punto de acumulación). Por lo tanto, $f(x^k) - f(x^{k+1}) \rightarrow 0$. Por la desigualdad de Armijo y la cota inferior $\alpha_k \geq \tilde{\alpha}$:

$$f(x^k) - f(x^{k+1}) \geq \sigma \alpha_k \|f'(x^k)\|^2 \geq \sigma \tilde{\alpha} \|f'(x^k)\|^2.$$

Esto fuerza a que $\|f'(x^k)\| \rightarrow 0$. Para el paso fijo, si $\tilde{\alpha} < 2/L$, es algebraicamente equivalente a un paso de Armijo satisfactorio. ■

Teorema 8.2 (Convergencia global del método del gradiente II). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función de clase $\mathcal{C}^1$ en $\mathbb{R}^n$. Supongamos que el método utiliza minimización unidimensional o la regla de Armijo. Si cada punto de acumulación

de cualquier secuencia $\{x^k\}$ generada por el algoritmo es un punto estacionario del problema y si la secuencia $\{x^k\}$ es acotada, entonces se cumple $\|f'(x^k)\| \rightarrow 0$ cuando $k \rightarrow \infty$.

Prueba. Consideraremos únicamente la regla de Armijo, ya que la minimización unidimensional se reduce a ella. Supongamos que la secuencia $\{x^k\}$ tenga un punto de acumulación $\bar{x} \in \mathbb{R}^n$, y que $f'(\bar{x}) \neq 0$ para todo k . Sea $\{x^{k_j}\} \rightarrow \bar{x}$. En el caso en que exista $\tilde{\alpha} > 0$ tal que $\alpha_{k_j} \geq \tilde{\alpha}$, el análisis es análogo al primer teorema. Por lo tanto, tomando una subsecuencia si es necesario, consideremos el caso $\{\alpha_{k_j}\} \rightarrow 0$ cuando $j \rightarrow \infty$. En este caso, para todo j grande, el valor de $\alpha = \theta^{-1}\alpha_{k_j} > \alpha_{k_j}$ no satisfizo la desigualdad de Armijo:

$$f(x^{k_j} - \theta^{-1}\alpha_{k_j}f'(x^{k_j})) > f(x^{k_j}) - \sigma\theta^{-1}\alpha_{k_j}\|f'(x^{k_j})\|^2.$$

Denotando $\tilde{\alpha}_{k_j} = \theta^{-1}\alpha_{k_j}\|f'(x^{k_j})\|$, y dividiendo la desigualdad, obtenemos:

$$\frac{f(x^{k_j} - \tilde{\alpha}_{k_j} \frac{f'(x^{k_j})}{\|f'(x^{k_j})\|}) - f(x^{k_j})}{\tilde{\alpha}_{k_j}} > -\sigma\|f'(x^{k_j})\|.$$

Observamos que $\{\tilde{\alpha}_{k_j}\} \rightarrow 0$. Pasando al límite cuando $j \rightarrow \infty$ y utilizando el Teorema del Valor Medio, obtenemos que:

$$-\|f'(\bar{x})\| = \langle f'(\bar{x}), -\frac{f'(\bar{x})}{\|f'(\bar{x})\|} \rangle \geq -\sigma\|f'(\bar{x})\|.$$

Como $\sigma \in (0, 1)$, esto solo es posible cuando $f'(\bar{x}) = 0$. La última afirmación del teorema es consecuencia obvia de la primera. ■

Teorema 8.3 (Convergencia global del método del gradiente en el caso convexo). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ convexa y diferenciable, con gradiente Lipschitz-continuo. Supongamos que el Algoritmo 8.1 utiliza la regla de Armijo con $\hat{\alpha} \leq 1$.

Si el conjunto de minimizadores irrestrictos de f es no vacío, entonces toda secuencia $\{x^k\}$ generada por el método **converge** a una solución global del problema.

Para analizar el **comportamiento local** del método, suponemos que f es dos veces diferenciable en un minimizador local estricto $\bar{x}$ que satisface la condición suficiente de segundo orden (matriz Hessiana definida positiva). En este caso, f posee **crecimiento cuadrático local** (ver [Izm20, Teorema 1.2.1]):

$$f(x) - f(\bar{x}) \geq \beta\|x - \bar{x}\|^2 \quad \forall x \in U. \quad (8.18)$$

Lema 8.5 (Cota del gradiente por crecimiento cuadrático). Bajo las hipótesis anteriores, para cualquier número $\nu \in (0, 4)$ existe una vecindad U de $\bar{x}$ tal que:

$$\|f'(x)\|^2 \geq \nu\beta(f(x) - f(\bar{x})) \quad \forall x \in U. \quad (8.19)$$

Teorema 8.4 (Convergencia local del método del gradiente I). Supongamos que $\bar{x}$ es un punto estacionario que satisface la condición suficiente de segundo orden. Entonces:

1. Para cualquier x^0 suficientemente próximo a $\bar{x}$, la secuencia generada por el método converge a $\bar{x}$.
2. La **tasa de convergencia es lineal** en relación a la función objetivo, y **geométrica** en relación a las variables:

$$f(x^{k+1}) - f(\bar{x}) \leq q(f(x^k) - f(\bar{x})), \quad (8.20)$$

$$\|x^k - \bar{x}\| \leq \Gamma\sqrt{f(x^k) - f(\bar{x})} \leq (\sqrt{q})^k\Gamma\sqrt{f(x^0) - f(\bar{x})}, \quad (8.21)$$

donde $q \in [0, 1)$ y $\Gamma > 0$.

Prueba. Sustituyendo el paso de Armijo en el decaimiento de f y aplicando el Lema 8.5:

$$\begin{aligned} f(x^{k+1}) - f(\bar{x}) &\leq f(x^k) - f(\bar{x}) - \sigma\alpha_k\|f'(x^k)\|^2 \\ &\leq (1 - \sigma\tilde{\alpha}\nu\beta)(f(x^k) - f(\bar{x})). \end{aligned}$$

Definiendo $q = 1 - \sigma\tilde{\alpha}\nu\beta < 1$, se prueba la convergencia lineal. Un análisis de la acotación de $\|x^{k+1} - \bar{x}\|$ a través del crecimiento cuadrático garantiza que el iterado nunca abandona la vecindad U , completando la prueba topológica. ■

Teorema 8.5 (Convergencia local del método del gradiente II). Además de las hipótesis de diferenciabilidad de Lipschitz de f , supongamos que el valor óptimo del problema sea finito, y que la estimación de la distancia al conjunto

de puntos estacionarios S_0 cumpla:

$$\|f'(x)\| \geq \gamma \text{dist}(x, S_0) \quad \forall x \in L_{\|f'(\cdot)\|, \mathbb{R}^n}(\delta)$$

con algunos $\delta > 0$ y $\gamma > 0$. Sea satisfecha también la condición de separación de superficies de nivel críticas de f .

Entonces, cualquier secuencia $\{x^k\}$ generada por el método (con Armijo o paso fijo) converge a un punto estacionario del problema. La tasa de convergencia es lineal en relación a la función y geométrica en relación a las variables.

Prueba. Consideremos únicamente la regla de Armijo. Para todo k , se tiene que:

$$f(x^k) - f(x^{k+1}) \geq \sigma \|x^{k+1} - x^k\|^2 / \hat{\alpha}. \quad (8.22)$$

Como el valor óptimo es finito, la secuencia $\{f(x^k)\}$ converge. De la ecuación obtenemos que $\|x^{k+1} - x^k\| \rightarrow 0$. Usando la cota de paso largo $\hat{\alpha}$, concluimos que $\hat{\alpha} \|f'(x^k)\| \leq \alpha_k \|f'(x^k)\| = \|x^{k+1} - x^k\| \rightarrow 0$.

Por lo tanto, x^k entra en el conjunto de nivel para k suficientemente grande. Esto y la estimación de distancia resultan en:

$$\|x^k - \bar{x}^k\| \leq \text{dist}(x^k, S_0) \leq \frac{1}{\gamma} \|f'(x^k)\| \leq \frac{1}{\hat{\alpha}\gamma} \|x^{k+1} - x^k\| \rightarrow 0, \quad (8.23)$$

donde $\bar{x}^k$ es una proyección sobre S_0 . Por la condición de separación de superficies, existe un valor crítico v tal que $f(\bar{x}^k) = v$. Por el Lema del gradiente Lipschitz, obtenemos:

$$|f(x^{k+1}) - v| \leq \frac{L}{2} \left(1 + \frac{1}{\hat{\alpha}\gamma}\right)^2 \|x^{k+1} - x^k\|^2.$$

Teniendo en cuenta que $\{f(x^k)\}$ es decreciente y usando (8.22), obtenemos $0 \leq f(x^{k+1}) - v \leq q(f(x^k) - v)$, con $q \in (0, 1)$, lo que demuestra convergencia lineal de f . Sustituyendo esto iterativamente en la norma, se prueba que la secuencia $\{x^k\}$ es de Cauchy y converge geoméricamente a $\bar{x} \in S_0$. ■

Nota: Condicionamiento y Zig-Zag

Aunque la convergencia local del gradiente está garantizada asintóticamente como lineal, si la matriz Hessiana está mal condicionada (su autovalor máximo ρ_n es mucho mayor que el mínimo ρ_1), la razón $q \approx 1 - \rho_1/\rho_n$ se acercará peligrosamente a 1. Esto produce el famoso efecto de “zig-zag” que hace al método impracticable frente a alternativas de segundo orden.

8.2. El método de Newton

La idea principal del método de Newton es fundamental en la matemática computacional. En su forma básica, es una herramienta para resolver **sistemas de ecuaciones no lineales**. Al aplicarlo a optimización (buscando raíces del gradiente), su rápida convergencia superlineal (o cuadrática) se debe a que incorpora información de la curvatura local (Hessiana).

8.2.1. El método de Newton para ecuaciones

El problema clásico consiste en hallar una raíz $x \in \mathbb{R}^n$ tal que $\Phi(x) = 0$, donde $\Phi: \mathbb{R}^n \rightarrow \mathbb{R}^n$ es diferenciable. Dada una aproximación x^k , el método linealiza el sistema mediante la serie de Taylor de primer orden:

$$\Phi(x^k) + \Phi'(x^k)(x - x^k) = 0. \quad (8.24)$$

Algoritmo 8.2 (El método de Newton). Elegir $x^0 \in \mathbb{R}^n$ y tomar $k := 0$.

1. Calcular $x^{k+1} \in \mathbb{R}^n$ como la solución exacta del sistema lineal (8.24).
2. Incrementar $k \leftarrow k + 1$ y regresar al Paso 1.

Suponiendo que el Jacobiano $\Phi'(x^k)$ es no singular, la iteración del método de Newton se expresa explícitamente como:

$$x^{k+1} = x^k - (\Phi'(x^k))^{-1} \Phi(x^k), \quad k = 0, 1, \dots \quad (8.25)$$

Teorema 8.6 (Convergencia local del método de Newton). Sea $\Phi: \mathbb{R}^n \rightarrow \mathbb{R}^n$ diferenciable en una vecindad de la raíz $\bar{x}$, con derivada continua en este punto. Supongamos que la matriz $\Phi'(\bar{x})$ es no singular ($\det \Phi'(\bar{x}) \neq 0$).

Entonces, para cualquier x^0 suficientemente próximo a $\bar{x}$, el método genera una secuencia bien definida que converge a $\bar{x}$. La **tasa de convergencia es superlineal**. Además, si la derivada Φ' es Lipschitz-continua en la vecindad de $\bar{x}$, la tasa de convergencia es **cuadrática**.

Prueba. Por el teorema de perturbaciones continuas de matrices no singulares (Teorema 6.13), en una vecindad U de $\bar{x}$ la matriz $\Phi'(x)$ se mantiene invertida y acotada: $\|(\Phi'(x))^{-1}\| \leq M$. Por lo tanto, si $x^k \in U$, el paso de Newton está bien definido.

Evaluyendo el error del siguiente paso:

$$\begin{aligned}\|x^{k+1} - \bar{x}\| &= \|x^k - \bar{x} - (\Phi'(x^k))^{-1}\Phi(x^k)\| \\ &= \|(\Phi'(x^k))^{-1}[\Phi(x^k) - \Phi(\bar{x}) - \Phi'(x^k)(x^k - \bar{x})]\| \\ &\leq M\|\Phi(x^k) - \Phi(\bar{x}) - \Phi'(x^k)(x^k - \bar{x})\|.\end{aligned}\quad (8.26)$$

Por la definición de diferenciabilidad de Fréchet, el término en el interior de la norma es de orden $o(\|x^k - \bar{x}\|)$. Por tanto, $\|x^{k+1} - \bar{x}\| = o(\|x^k - \bar{x}\|)$, lo que define una convergencia **superlineal**.

Si Φ' es Lipschitz con constante L , el Lema de la aproximación de Taylor acota el residuo por $\frac{L}{2}\|x^k - \bar{x}\|^2$. Sustituyendo, se tiene $\|x^{k+1} - \bar{x}\| \leq \frac{ML}{2}\|x^k - \bar{x}\|^2$, demostrando la convergencia **cuadrática**. ■

Corolario 8.1 (Método de Newton Inexacto). Si reemplazamos $\Phi'(x^k)$ en (8.25) por una matriz aproximada $\Psi(x^k)$ que cumpla $\|\Psi(x) - \Phi'(x)\| \rightarrow 0$ cuando $x \rightarrow \bar{x}$, el método retiene la convergencia local superlineal.

8.2.2. El método de Newton para optimización irrestricta

Consideremos el problema de minimización $\min f(x)$ con f dos veces diferenciable. Los puntos estacionarios satisfacen el sistema $\Phi(x) = f'(x) = 0$.

Aplicando el método de Newton a este gradiente, el iterado siguiente se computa como solución del sistema de ecuaciones:

$$f'(x^k) + f''(x^k)(x - x^k) = 0 \implies x^{k+1} = x^k - (f''(x^k))^{-1}f'(x^k). \quad (8.27)$$

Geométricamente, esto equivale a minimizar de forma analítica el modelo cuadrático local de Taylor:

$$\min_{x \in \mathbb{R}^n} \left\{ f(x^k) + \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle f''(x^k)(x - x^k), x - x^k \rangle \right\}. \quad (8.28)$$

Corolario 8.2. Si $\bar{x}$ satisface la condición suficiente de segundo orden ($f''(\bar{x})$ es definida positiva), entonces a partir de un x^0 suficientemente cercano, el método de Newton en optimización converge de forma cuadrática.

Observación (Factorización de Cholesky y Regularización en la Práctica). Bajo las condiciones del Teorema de Newton local, uno de los métodos más eficientes para resolver el sistema de ecuaciones lineales es el método de Cholesky. Este método permite obtener la factorización LL^T de una matriz simétrica definida positiva en un orden de $n^3/6$ operaciones de punto flotante (L es una matriz triangular con elementos positivos en la diagonal).

Cuando $f''(x^k)$ no es definida positiva, este esquema se modifica introduciendo una matriz definida positiva compensatoria (por ejemplo, sumando un múltiplo de la identidad $f''(x^k) + \gamma I$, con $\gamma > 0$ suficientemente grande). Esto garantiza la resolución del sistema y dota al método de capacidades globales, concepto que desarrollaremos formalmente más adelante.

Ejemplo 8.1 (Falla analítica de Newton en no convexidad). El método de Newton, sin regularización, puede no poseer convergencia global incluso para funciones muy bien comportadas si se arranca lejos del óptimo. Consideremos la función continua de clase $\mathcal{C}^2$ parametrizada por $\tau > 0$:

$$f : \mathbb{R} \rightarrow \mathbb{R}, \quad f(x) = \begin{cases} -x^4/(4\tau^3) + (1 + 3/\tau)x^2/2, & \text{si } |x| \leq \tau, \\ x^2/2 + 2|x| - 3\tau/4, & \text{si } |x| > \tau. \end{cases}$$

Como es fácil de verificar, para cualquier $\tau > 0$, el problema tiene un único punto estacionario $\bar{x} = 0$, y se tiene que $f''(\bar{x}) = 1 + 3/\tau > 0$. En particular, se satisfacen todas las hipótesis para la convergencia cuadrática local.

Sin embargo, tomaremos un punto inicial en el borde del segmento, $x^0 = \tau$. Una secuencia $\{x^k\}$ generada por el método de Newton puro se obtiene resolviendo $x^{k+1} = x^k - f'(x^k)/f''(x^k)$. Para esta función, la trayectoria iterativa adopta la forma de ciclo infinito oscilante:

$$x^k = \tau(-1)^k, \quad k = 1, 2, \dots$$

En particular, $\bar{x} = 0$ no es un punto de acumulación de $\{x^k\}$, independientemente de cuán pequeño sea el parámetro τ (es decir, cuán próximo parezca estar el punto inicial x^0 de $\bar{x}$).

Atención: Falla topológica del método de Newton puro

La principal desventaja de Newton puro es la **falta de convergencia global**. Si se arranca fuera de la región de atracción local, el modelo cuadrático puede guiar la búsqueda hacia un punto de silla, o la matriz Hessiana puede no ser invertible. Peor aún, puede crear ciclos divergentes.

Por ejemplo, para la función $f(x) = x^4/4 - x^2/2$ (con mínimos en ± 1), si arrancamos en un punto cóncavo (donde el Hessiano es negativo), Newton caminará en dirección de ascenso buscando un máximo.

8.2.3. Métodos Cuasi-Newton

Una clase importante de métodos de optimización irrestricta está dada por el siguiente esquema iterativo:

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k = -Q_k f'(x^k), \quad k = 0, 1, \dots, \quad (8.29)$$

donde, para todo k , $Q_k \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva, y $\alpha_k > 0$ es la longitud de paso calculada utilizando una de las reglas de búsqueda lineal presentadas en la sección anterior.

Notemos que el método (8.29) es, por construcción, un método de descenso. En efecto, si x^k no es un punto estacionario del problema, como Q_k es definida positiva, se tiene que:

$$\langle f'(x^k), d^k \rangle = -\langle Q_k f'(x^k), f'(x^k) \rangle < 0,$$

y por lo tanto, por el Lema 8.1, d^k es una dirección de descenso de f en x^k , es decir, $d^k \in \mathcal{D}_f(x^k)$. En el caso de $Q_k = I$ (matriz identidad), el esquema (8.29) se reduce a un método de gradiente; y en el caso de $Q_k = (f''(x^k))^{-1}$ con $\alpha_k = 1$, obtenemos el método de Newton puro. Existen, sin embargo, otras posibilidades que son computacionalmente mucho más atractivas que las dos opciones obvias mencionadas.

Algoritmo 8.3 (Método de descenso con métrica variable). Elegir un punto inicial $x^0 \in \mathbb{R}^n$ y tomar $k := 0$. Elegir una de las reglas de búsqueda lineal (Armijo, Wolfe o minimización unidimensional) y sus parámetros asociados.

1. Elegir una matriz simétrica definida positiva $Q_k \in \mathbb{R}^{n \times n}$ y tomar $d^k = -Q_k f'(x^k)$. Calcular la longitud del paso α_k en la dirección d^k , por la regla de búsqueda lineal elegida. (Si $f'(x^k) = 0$, el método se detiene).
2. Tomar $x^{k+1} = x^k + \alpha_k d^k$.
3. Incrementar $k \leftarrow k + 1$ y retornar al Paso 1.

Los métodos cuasi-Newton son métodos de la forma (8.29), donde las matrices Q_k son elegidas para aproximar, en un cierto sentido, la matriz $(f''(\bar{x}))^{-1}$ para alguna solución $\bar{x}$. Más precisamente, la secuencia $\{Q_k\}$ debe satisfacer la **condición de Dennis-Moré**, dada en el siguiente teorema.

Teorema 8.7 (Teorema de Dennis-Moré). Supongamos que f es dos veces diferenciable, $\bar{x}$ es un punto estacionario y la Hessiana $f''(\bar{x})$ es definida positiva (condición suficiente de segundo orden). Además, supongamos que la secuencia $\{x^k\}$, generada por el Algoritmo 8.3 utilizando la regla de Armijo con $\hat{\alpha} = 1$ y $\sigma \in (0, 1/2)$, converge a $\bar{x}$.

Entonces, las siguientes dos afirmaciones son equivalentes:

- (1) La tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es **superlineal**, el paso $\alpha_k = 1$ es aceptado para todo k suficientemente grande, y se cumple que

$$\|Q_k f'(x^k) - (f''(\bar{x}))^{-1} f'(x^k)\| \leq M \|f'(x^k)\| \quad \forall k = 0, 1, \dots, \quad (8.30)$$

donde $M > 0$ es una constante que no depende de k .

- (2) El error de aproximación en la dirección del gradiente es asintóticamente sublineal:

$$(Q_k - (f''(\bar{x}))^{-1}) f'(x^k) = o(\|f'(x^k)\|). \quad (8.31)$$

Prueba. Primero, supongamos que la afirmación (1) se satisface. Teniendo en cuenta que $\alpha_k = 1$ para todo k suficientemente grande, tenemos que:

$$\begin{aligned} ((f''(\bar{x}))^{-1} - Q_k)f'(x^k) &= (f''(\bar{x}))^{-1}f'(x^k) - Q_kf'(x^k) \\ &= (f''(\bar{x}))^{-1}f'(x^k) + (x^{k+1} - x^k) \\ &= (f''(\bar{x}))^{-1}(f'(x^k) - f''(\bar{x})(x^k - \bar{x})) + (x^{k+1} - \bar{x}) \\ &= o(\|x^k - \bar{x}\|), \end{aligned} \quad (8.32)$$

donde la última igualdad se sigue de la Fórmula de Taylor y de la convergencia superlineal de $\{x^k\}$ a $\bar{x}$.

De (8.30), obtenemos que:

$$M\|f'(x^k)\| \geq \|Q_kf'(x^k)\| = \|x^{k+1} - x^k\| \geq \|x^k - \bar{x}\| - \|x^{k+1} - \bar{x}\| = \|x^k - \bar{x}\| + o(\|x^k - \bar{x}\|).$$

Por lo tanto,

$$\frac{o(\|x^k - \bar{x}\|)}{\|f'(x^k)\|} \leq \frac{o(\|x^k - \bar{x}\|)}{\|x^k - \bar{x}\|/M + o(\|x^k - \bar{x}\|)/M} = \frac{o(\|x^k - \bar{x}\|)/\|x^k - \bar{x}\|}{1/M + o(\|x^k - \bar{x}\|)/\|x^k - \bar{x}\|} \rightarrow 0 \quad \text{cuando } k \rightarrow \infty.$$

Combinando esta última relación con (8.32), obtenemos exactamente (8.31).

Ahora supongamos que la afirmación (2) se satisface. La condición (8.30) se sigue trivialmente (si no, obtendríamos una contradicción obvia con (8.31)). Probaremos que el paso de Newton $\alpha_k = 1$ es aceptado para todo k suficientemente grande. Por el Teorema del Valor Medio, existe $\tilde{t}_k \in [0, 1]$ tal que:

$$f(x^k - Q_kf'(x^k)) = f(x^k) - \langle f'(x^k), Q_kf'(x^k) \rangle + \frac{1}{2} \langle f''(\bar{x})Q_kf'(x^k), Q_kf'(x^k) \rangle,$$

donde $\bar{x}^k = x^k - \tilde{t}_k Q_kf'(x^k)$. Para verificar que $\alpha_k = 1$ satisface la regla de Armijo, basta mostrar que:

$$\langle f'(x^k), Q_kf'(x^k) \rangle - \frac{1}{2} \langle f''(\bar{x})Q_kf'(x^k), Q_kf'(x^k) \rangle \geq \sigma \langle f'(x^k), Q_kf'(x^k) \rangle. \quad (8.33)$$

Observamos que $\{\bar{x}^k\} \rightarrow \bar{x}$ cuando $k \rightarrow \infty$, porque $\{x^k\} \rightarrow \bar{x}$ y $\{Q_kf'(x^k)\} \rightarrow 0$ (la última propiedad se sigue de (8.30)). Por lo tanto, usando (8.31), la desigualdad (8.33) puede reescribirse asintóticamente como:

$$(1 - \sigma) \langle f'(x^k), (f''(\bar{x}))^{-1}f'(x^k) \rangle \geq \frac{1}{2} \langle f'(x^k), (f''(\bar{x}))^{-1}f'(x^k) \rangle + o(\|f'(x^k)\|^2),$$

lo cual equivale a:

$$(1/2 - \sigma) \langle f'(x^k), (f''(\bar{x}))^{-1}f'(x^k) \rangle \geq o(\|f'(x^k)\|^2).$$

Esta última desigualdad se satisface estrictamente para todo k suficientemente grande, dado que $\sigma \in (0, 1/2)$, y el hecho de que $f''(\bar{x})$ sea definida positiva implica que $(f''(\bar{x}))^{-1}$ también es definida positiva; por lo tanto, existe $\gamma > 0$ tal que el lado izquierdo está acotado inferiormente por $\gamma(1/2 - \sigma)\|f'(x^k)\|^2$, superando holgadamente al término $o(\|f'(x^k)\|^2)$.

Finalmente, probaremos que la tasa de convergencia de $\{x^k\}$ es superlineal. Para k suficientemente grande, con $\alpha_k = 1$ y usando (8.30), obtenemos:

$$\begin{aligned} \|x^{k+1} - \bar{x}\| &= \|x^k - \bar{x} - Q_kf'(x^k)\| \\ &= \|x^k - \bar{x} - (f''(\bar{x}))^{-1}f'(x^k) + (f''(\bar{x}))^{-1}f'(x^k) - Q_kf'(x^k)\| \\ &\leq \|(f''(\bar{x}))^{-1}(f''(\bar{x})(x^k - \bar{x}) - f'(x^k))\| + \|(f''(\bar{x}))^{-1} - Q_k\| \|f'(x^k)\| \\ &= o(\|x^k - \bar{x}\|), \end{aligned}$$

lo que concluye la demostración. ■

Una de las conclusiones teóricas más importantes del Teorema de Dennis-Moré es la siguiente: en la optimización de funciones dos veces diferenciables, **para ser eficiente y superlineal, un método debe incorporar implícitamente información de segundo orden**. En particular, los métodos que utilizan apenas información pura de primer orden (como el método del gradiente) no pueden alcanzar convergencia superlineal.

Sin embargo, esta información de segundo orden puede ser construida dinámicamente sin el cálculo analítico ni la evaluación directa de la matriz Hessiana. Esta es la idea principal de los **métodos cuasi-Newton**: sustituir la resolución costosa del sistema con la Hessiana verdadera por una aproximación directa de la matriz inversa $Q_k \approx (f''(x^k))^{-1}$.

La Ecuación de la Secante (Ecuación Cuasi-Newton)

Para todo paso k , definimos los vectores de variación en la posición y en el gradiente:

$$r^k = x^{k+1} - x^k, \quad s^k = f'(x^{k+1}) - f'(x^k). \quad (8.34)$$

Notamos que esta información ya está disponible tras calcular el nuevo iterado. Como queremos que Q_{k+1} aproxime la inversa de la Hessiana, invocando el Teorema Fundamental del Cálculo a lo largo de la trayectoria del paso, exigimos que la nueva matriz satisfaga la **Ecuación Cuasi-Newton** (o Ecuación de la Secante):

$$Q_{k+1}s^k = r^k. \quad (8.35)$$

Esta ecuación representa un sistema lineal subdeterminado (hay múltiples matrices Q_{k+1} simétricas y definidas positivas que satisfacen esto para $n > 1$). La estrategia general consiste en actualizar la matriz anterior Q_k sumándole una corrección de rango bajo (rango 1 o rango 2) que sea “mínima” bajo alguna norma matricial, preservando la simetría y la condición definida positiva.

Método DFP (Davidon-Fletcher-Powell)

Históricamente, el primer método cuasi-Newton exitoso es el método DFP. Toma Q_0 como una matriz simétrica definida positiva arbitraria (típicamente $Q_0 = I$), y para todo k actualiza la métrica mediante una corrección de rango 2:

$$Q_{k+1} = Q_k + \frac{r^k(r^k)^T}{\langle r^k, s^k \rangle} - \frac{(Q_k s^k)(Q_k s^k)^T}{\langle Q_k s^k, s^k \rangle}. \quad (8.36)$$

Todas las matrices así generadas serán simétricas. Además, la ecuación secante (8.35) se satisface analíticamente:

$$\begin{aligned} Q_{k+1}s^k &= Q_k s^k + \frac{r^k(r^k)^T s^k}{\langle r^k, s^k \rangle} - \frac{(Q_k s^k)(Q_k s^k)^T s^k}{\langle Q_k s^k, s^k \rangle} \\ &= Q_k s^k + r^k - Q_k s^k = r^k. \end{aligned}$$

Para que el esquema cuasi-Newton sea robusto, requerimos que Q_{k+1} sea estrictamente definida positiva. Esta propiedad no solo depende de la fórmula (8.36), sino también de la estrictez de la búsqueda lineal subyacente.

Proposición 8.1 (Mantenimiento de la matriz definida positiva). Sea $Q_k \in \mathbb{R}^{n \times n}$ una matriz simétrica definida positiva. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ diferenciable en $x^k, x^{k+1} \in \mathbb{R}^n$, satisfaciendo una condición de descenso con longitud de paso $\alpha_k > 0$.

Entonces, la matriz Q_{k+1} dada por la fórmula DFP (8.36) está bien definida y es **definida positiva** si, y solamente si, se satisface la **condición de curvatura**:

$$\langle f'(x^{k+1}), d^k \rangle > \langle f'(x^k), d^k \rangle. \quad (8.37)$$

Prueba. Supongamos que Q_{k+1} sea definida positiva. Usando (8.34), (8.36) y (8.35), obtenemos:

$$\begin{aligned} \langle d^k, f'(x^{k+1}) - f'(x^k) \rangle &= \frac{1}{\alpha_k} \langle r^k, s^k \rangle \\ &= \frac{1}{\alpha_k} \langle Q_{k+1}s^k, s^k \rangle > 0, \end{aligned}$$

donde la desigualdad estricta es válida asumiendo que $s^k \neq 0$ (en caso contrario, Q_{k+1} en (8.36) no estaría bien definida). Al expandir la parte izquierda, obtenemos exactamente (8.37).

Supongamos ahora que (8.37) se satisface. Utilizando la definición de s^k y r^k , esto garantiza que:

$$\langle r^k, s^k \rangle = \alpha_k (\langle d^k, f'(x^{k+1}) - f'(x^k) \rangle) > 0. \quad (8.38)$$

En particular, $s^k \neq 0$. Por el hecho de que Q_k es definida positiva, $\langle Q_k s^k, s^k \rangle > 0$. Esto demuestra que el denominador en (8.36) nunca se anula y Q_{k+1} está bien definida.

Para cualquier vector $\xi \in \mathbb{R}^n$, utilizando la actualización DFP (8.36), obtenemos:

$$\begin{aligned} \langle Q_{k+1}\xi, \xi \rangle &= \langle Q_k \xi, \xi \rangle + \frac{\langle r^k, \xi \rangle^2}{\langle r^k, s^k \rangle} - \frac{\langle Q_k s^k, \xi \rangle^2}{\langle Q_k s^k, s^k \rangle} \\ &= \frac{\|Q_k^{1/2}\xi\|^2 \|Q_k^{1/2}s^k\|^2 - \langle Q_k^{1/2}\xi, Q_k^{1/2}s^k \rangle^2}{\|Q_k^{1/2}s^k\|^2} + \frac{\langle r^k, \xi \rangle^2}{\langle r^k, s^k \rangle} \geq 0. \end{aligned}$$

La desigualdad ≥ 0 se sigue rigurosamente de la desigualdad de Cauchy-Schwarz aplicada al primer término y de la condición (8.38) en el segundo. Además, la igualdad $\langle Q_{k+1}\xi, \xi \rangle = 0$ solamente puede ocurrir cuando ambos términos fraccionarios se anulan independientemente, es decir, cuando:

$$\langle r^k, \xi \rangle = 0 \quad \text{y} \quad \|Q_k^{1/2}\xi\|^2 \|Q_k^{1/2}s^k\|^2 - \langle Q_k^{1/2}\xi, Q_k^{1/2}s^k \rangle^2 = 0.$$

La segunda igualdad (caso de igualdad en Cauchy-Schwarz) exige que los vectores sean colineales: $Q_k^{1/2}\xi = t(Q_k^{1/2}s^k)$ para algún escalar $t \in \mathbb{R}$. Como la matriz $Q_k^{1/2}$ es no singular, esto implica directamente que $\xi = ts^k$. Sustituyendo esto en la primera condición obtenemos:

$$0 = \langle r^k, \xi \rangle = t \langle r^k, s^k \rangle.$$

Puesto que demostramos en (8.38) que $\langle r^k, s^k \rangle > 0$, la única solución a la ecuación anterior es $t = 0$, lo que implica que $\xi = 0$. Por lo tanto, la forma cuadrática es estrictamente positiva para cualquier $\xi \neq 0$, demostrando que Q_{k+1} es definida positiva. ■

Observación (La Regla de Wolfe es mandataria en Cuasi-Newton). Si se utiliza una minimización unidimensional exacta en el paso, se garantiza geoméricamente que $\langle f'(x^{k+1}), d^k \rangle = 0$. Puesto que $\langle f'(x^k), d^k \rangle < 0$, la condición de curvatura (8.37) se cumple automáticamente. Sin embargo, si se utilizan reglas prácticas de retroceso, **la regla de Armijo por sí sola no garantiza la condición de curvatura**. Es precisamente por este motivo que la **regla de Wolfe** exige explícitamente la condición dual (8.9):

$$\langle f'(x^{k+1}), d^k \rangle \geq \sigma_2 \langle f'(x^k), d^k \rangle > \langle f'(x^k), d^k \rangle,$$

(ya que $\sigma_2 < 1$ y la derivada es negativa). Esta es la razón técnica central por la cual la regla de Wolfe es el estándar de oro en las implementaciones de los métodos cuasi-Newton computacionales.

Método BFGS (Broyden-Fletcher-Goldfarb-Shanno)

En la práctica moderna, el método BFGS se considera ampliamente superior y es el algoritmo cuasi-Newton más utilizado en optimización irrestricta. En lugar de actualizar la inversa de la Hessiana, se puede formular la actualización dual. La fórmula de corrección BFGS para la matriz inversa de la Hessiana Q_k viene dada por:

$$Q_{k+1} = Q_k + \frac{(r^k - Q_k s^k)(r^k)^\top + r^k(r^k - Q_k s^k)^\top}{\langle r^k, s^k \rangle} - \frac{\langle r^k - Q_k s^k, s^k \rangle (r^k)(r^k)^\top}{\langle r^k, s^k \rangle^2}. \quad (8.39)$$

Se puede demostrar analíticamente que las matrices BFGS preservan la simetría, satisfacen la ecuación de la secante y que la corrección es de rango 2. Además, existe una profunda relación de dualidad algebraica entre las fórmulas de actualización de DFP y BFGS (que se explorará en el Ejercicio 8.29).

Para funciones cuadráticas estrictamente convexas, acompañadas de una búsqueda lineal exacta, se puede demostrar que tanto DFP como BFGS convergen al mínimo global en **exactamente n iteraciones** (donde n es la dimensión del espacio), generando en el proceso la matriz inversa de la Hessiana exacta.

8.3. Estrategias de globalización

Como hemos visto, los métodos Newtonianos y cuasi-Newtonianos poseen propiedades teóricas de convergencia local extremadamente rápidas, pero en general carecen de garantías de convergencia global (a partir de un punto inicial arbitrario el método puede divergir, ciclar o fallar).

Para construir un optimizador robusto, es imperativo diseñar un algoritmo híbrido que garantice la convergencia asintótica desde cualquier punto inicial (comportamiento global) al mismo tiempo que hereda la tasa de convergencia superlineal cuando el iterado ingresa a la cuenca de atracción del mínimo (comportamiento local).

8.3.1. Métodos con búsqueda lineal

La estrategia más directa es introducir una técnica de búsqueda lineal (como Armijo o Wolfe) en la dirección calculada por el modelo de Newton. Si el “paso completo” de Newton (con longitud $\alpha_k = 1$) provoca un incremento en la función objetivo, el método de búsqueda lineal reduce el paso hasta garantizar la monotonicidad. Si logramos probar que el paso completo $\alpha_k = 1$ es aceptado asintóticamente (para todo k suficientemente grande), el método preservará su tasa de convergencia veloz.

Consideremos un problema de minimización irrestricta $\min f(x)$, donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es dos veces de clase $\mathcal{C}^1$. Analizaremos el esquema general:

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k = -Q_k f'(x^k), \quad k = 0, 1, \dots \quad (8.40)$$

Para asegurar que d^k sea una dirección de descenso y la matriz no se vuelva singular ni explote numéricamente, exigimos que la secuencia de matrices $\{Q_k\}$ esté uniformemente acotada y sea uniformemente definida positiva. Es decir, exigimos que existan constantes $\Gamma > 0$ y $\gamma > 0$ tales que para todo iterado k :

$$\|Q_k\| \leq \Gamma, \quad \langle Q_k d, d \rangle \geq \gamma \|d\|^2 \quad \forall d \in \mathbb{R}^n. \quad (8.41)$$

Utilizando (8.40) y (8.41), obtenemos una cota estricta para la calidad de la dirección de descenso:

$$\frac{\langle f'(x^k), d^k \rangle}{\|d^k\|^2} = \frac{-\langle f'(x^k), Q_k f'(x^k) \rangle}{\|Q_k f'(x^k)\|^2} \leq -\frac{\gamma}{\Gamma^2} < 0. \quad (8.42)$$

Esta desigualdad establece que el ángulo entre el gradiente y la dirección de búsqueda se mantiene alejado de la ortogonalidad. A partir de esto, se puede deducir que existe una constante $\check{\alpha} > 0$ independiente de k , tal que el paso de Armijo está uniformemente acotado inferiormente ($\alpha_k \geq \check{\alpha} > 0$).

Teorema 8.8 (Convergencia global de Newton con Búsqueda Lineal). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ de clase $\mathcal{C}^1$ en $\mathbb{R}^n$, con gradiente Lipschitz-continuo. Supongamos que el esquema utiliza la regla de Armijo y que la secuencia de matrices $\{Q_k\}$ satisface la condición de acotamiento uniforme (8.41) para ciertas constantes $\Gamma, \gamma > 0$.

Entonces, todo punto de acumulación de la secuencia $\{x^k\}$ generada por el método es un punto estacionario del problema. Si existe un punto de acumulación (o si la función f es acotada inferiormente), entonces el gradiente converge a cero:

$$\|f'(x^k)\| \rightarrow 0 \quad \text{cuando } k \rightarrow \infty.$$

Prueba. Supongamos que $f'(x^k) \neq 0$ para todo k . Por la desigualdad de reducción de Armijo (8.6), se tiene que:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) + \sigma \alpha_k \langle f'(x^k), d^k \rangle \\ &\leq f(x^k) + \sigma \check{\alpha} \langle f'(x^k), d^k \rangle, \end{aligned}$$

donde se utilizó el hecho de que $\alpha_k \geq \check{\alpha}$ y el producto interno es estrictamente negativo.

Por lo tanto, la secuencia de la función objetivo $\{f(x^k)\}$ es monótona decreciente. Si f está acotada inferiormente, la secuencia converge. Como consecuencia matemática, la diferencia entre iterados funcionales consecutivos tiende a cero: $f(x^{k+1}) - f(x^k) \rightarrow 0$. De la desigualdad anterior, esto fuerza a que:

$$\langle f'(x^k), d^k \rangle \rightarrow 0 \quad (k \rightarrow \infty).$$

Como $f'(x^k) = -Q_k^{-1} d^k$ y las matrices inversas $\{Q_k^{-1}\}$ también están uniformemente acotadas por hipótesis, esto implica inequívocamente que $\|f'(x^k)\| \rightarrow 0$. ■

Observación (La necesidad de regularización de la Hessiana). En el método de Newton puro, elegimos $Q_k = (f''(x^k))^{-1}$. Sin embargo, en zonas no convexas del dominio, la Hessiana puede tener autovalores negativos (no siendo definida positiva) o ser singular (violando la cota Γ).

Para globalizar el método de Newton, cuando $f''(x^k)$ no es "suficientemente" definida positiva, se aplica una técnica de **regularización** (Modificación de Cholesky o Levenberg-Marquardt), que consiste en sustituir la matriz exacta por una perturbada:

$$Q_k = (f''(x^k) + \tau_k I)^{-1},$$

donde el escalar $\tau_k > 0$ se elige iterativamente lo suficientemente grande como para hacer que la matriz sea definida positiva y satisfaga la condición (8.41), permitiendo que el Teorema 8.8 entre en vigor.

Extensión a sistemas de ecuaciones (Funciones de Mérito)

Las estrategias de globalización de búsqueda lineal también se extienden de manera natural para resolver sistemas de ecuaciones no lineales $\Phi(x) = 0$. Dado que un sistema de ecuaciones no tiene un "valor objetivo" nativo que deba disminuir monótonamente, se recurre a definir una **función de mérito** auxiliar que cuantifique el residuo del sistema.

Una elección clásica y universal es la norma de mínimos cuadrados:

$$\varphi(x) = \frac{1}{2} \|\Phi(x)\|^2. \quad (8.43)$$

Para esta función de mérito escalar, el gradiente viene dado por:

$$\nabla \varphi(x) = (\Phi'(x))^T \Phi(x). \quad (8.44)$$

Si $\Phi'(x)$ es una matriz no singular y calculamos el paso de Newton para el sistema ($d = -(\Phi'(x))^{-1}\Phi(x)$), este vector es automáticamente una dirección de descenso para la función de mérito φ , ya que:

$$\begin{aligned} \langle \nabla \varphi(x), d \rangle &= \langle (\Phi'(x))^T \Phi(x), -(\Phi'(x))^{-1}\Phi(x) \rangle \\ &= -\langle \Phi(x), \Phi(x) \rangle = -\|\Phi(x)\|^2 < 0. \end{aligned}$$

Este hecho garantiza que las iteraciones de Newton, combinadas con una búsqueda de línea sobre $\varphi(x)$, generarán un algoritmo globalmente convergente hacia los puntos estacionarios del residuo.

8.3.2. Métodos de Regiones de Confianza

A diferencia de la búsqueda lineal, que primero fija una dirección y luego busca la longitud de paso adecuada, los métodos de **regiones de confianza** (Trust-Region methods) utilizan una filosofía dual: primero definen un radio máximo de "confianza" en la aproximación de Taylor, y luego calculan simultáneamente la dirección y el tamaño del paso óptimos dentro de esa región.

Dada una aproximación actual x^k a la solución del problema $\min f(x)$, un método de segundo orden se basa en minimizar un modelo cuadrático local $m_k(d)$. Los métodos de regiones de confianza imponen explícitamente una restricción espacial a este modelo:

$$\min_{d \in \mathbb{R}^n} m_k(d) = f(x^k) + \langle f'(x^k), d \rangle + \frac{1}{2} \langle H_k d, d \rangle \quad \text{sueto a} \quad \|d\| \leq \delta_k, \quad (8.45)$$

donde H_k es una matriz simétrica (típicamente $H_k = \nabla^2 f(x^k)$) y $\delta_k > 0$ es el **radio de la región de confianza**. La elección adaptativa y algorítmica de este parámetro δ_k es el núcleo del método.

El modelo $m_k(d)$ es, por diseño, una buena aproximación de $f(x^k + d)$ solo si $\|d\|$ es suficientemente pequeño. Si el paso propuesto proporciona una buena concordancia entre la reducción predicha por el modelo cuadrático y la reducción real de la función no lineal, la región de confianza se expande o se mantiene. Si la concordancia es mala, el paso se rechaza y el radio δ_k se contrae.

Nota: Ventaja Topológica: Manejo de Curvatura Negativa

A diferencia de la búsqueda lineal (que colapsa si H_k no es definida positiva y requiere regularización artificial), el subproblema de la región de confianza (8.45) **siempre está bien definido y posee solución global**, sin importar si la matriz H_k tiene autovalores negativos (curvatura negativa) o es singular, debido a que estamos minimizando una función continua sobre una bola topológicamente compacta.

Sea $\bar{d}^k$ la solución global del subproblema (8.45). Basados en el teorema de optimalidad de Lagrange para la esfera (y asumiendo norma euclidiana), se puede demostrar que $\bar{d}^k$ satisface la ecuación parametrizada:

$$(H_k + \mu_k I) \bar{d}^k = -f'(x^k), \quad (8.46)$$

donde $\mu_k \geq 0$ es un multiplicador de Lagrange tal que $\mu_k(\|\bar{d}^k\| - \delta_k) = 0$, y la matriz corregida $(H_k + \mu_k I)$ resulta ser **semidefinida positiva**.

Si el paso de Newton puro irrestricto (con $\mu_k = 0$) recae estrictamente en el interior de la bola ($\| -H_k^{-1} f'(x^k) \| \leq \delta_k$), este se toma como el paso óptimo. En caso contrario, la solución ocurre en la frontera exacta ($\|\bar{d}^k\| = \delta_k$) y $\mu_k > 0$ actúa implícita y dinámicamente como un parámetro de regularización tipo Levenberg-Marquardt.

A continuación, presentamos la estructura fundamental de un algoritmo iterativo de regiones de confianza.

Algoritmo 8.4 (Método de Regiones de Confianza). Elegir un iterado inicial $x^0 \in \mathbb{R}^n$ y tomar $k := 0$. Definir un radio inicial $\bar{\delta} \geq \bar{\delta} > 0$ y los hiperparámetros de aceptación $\sigma, \theta_1, \theta_2 \in (0, 1)$ tales que $\theta_1 < \theta_2$.

1. Asignar el radio iterativo $\delta_k := \delta$.
2. Calcular $\bar{d}^k \in \mathbb{R}^n$, la solución global (o una aproximación suficientemente buena) del subproblema cuadrático (8.45) restringido a la bola $\|d\| \leq \delta_k$.
3. Si $\bar{d}^k = 0$, hemos alcanzado un punto estacionario y el método se detiene. En caso contrario, evaluar el **ratio de concordancia** calculando la reducción real de la función frente a la reducción predicha:

$$\rho_k = \frac{f(x^k) - f(x^k + \bar{d}^k)}{m_k(0) - m_k(\bar{d}^k)}. \quad (8.47)$$

Verificamos la condición de aceptación análoga a Armijo: ¿ $\rho_k \geq \sigma$?

4. Si la desigualdad **se satisface** (concordancia aceptable), el paso es exitoso. Tomamos $x^{k+1} = x^k + \bar{d}^k$. Opcionalmente, podemos expandir el radio de confianza para la siguiente iteración. Incrementamos $k \leftarrow k + 1$ y volvemos al Paso 1.
5. Si la desigualdad **falla** (concordancia pobre), el paso es rechazado. Contraemos el radio de confianza eligiendo un nuevo $\delta \in [\theta_1 \|\bar{d}^k\|, \theta_2 \delta_k]$ y regresamos inmediatamente al Paso 2, resolviendo el subproblema en una región más conservadora sin avanzar el iterado.

Primero demostramos la viabilidad algorítmica: el ciclo interno de contracción de radio nunca entra en un bucle infinito, y la iteración eventualmente produce un descenso aceptable.

Proposición 8.2 (Viabilidad de la Región de Confianza). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces de clase $\mathcal{C}^1$. Supongamos que $x^k \in \mathbb{R}^n$ no es un punto estacionario de primer orden ($f'(x^k) \neq 0$), o que no satisface la condición necesaria de segundo orden (la matriz $f''(x^k)$ posee autovalores negativos).

Entonces, el ciclo interno de contracción del Algoritmo 8.4 está bien definido y termina en un número finito de pasos, generando un paso exitoso tal que $f(x^{k+1}) < f(x^k)$.

Prueba. Es suficiente probar que cuando el radio $\delta \rightarrow 0^+$, el ratio de concordancia converge a 1:

$$\liminf_{\delta \rightarrow 0^+} \rho(\delta) = 1. \quad (8.48)$$

Esto garantizaría que para radios suficientemente pequeños, $\rho(\delta) \geq \sigma$ (dado que el hiperparámetro $\sigma \in (0, 1)$), permitiendo que la condición de aceptación del Paso 3 se cumpla.

Analicemos el caso donde el gradiente no es nulo ($f'(x^k) \neq 0$). Elegimos la dirección normada de descenso máximo $d = -f'(x^k)/\|f'(x^k)\|$. Evaluando el modelo cuadrático a lo largo de este vector en la frontera de la bola (δd):

$$\begin{aligned} m_k(\bar{d}(\delta)) &\leq m_k(\delta d) \\ &= f(x^k) - \delta \|f'(x^k)\| + \frac{\delta^2}{2} \langle H_k d, d \rangle. \end{aligned}$$

Restando $f(x^k)$, el decrecimiento predicho por el modelo asintóticamente decae a tasa lineal:

$$f(x^k) - m_k(\bar{d}(\delta)) \geq \delta \left(\|f'(x^k)\| - \frac{\delta}{2} \|H_k\| \right) \geq \frac{\delta}{2} \|f'(x^k)\| > 0.$$

Por otro lado, por el teorema de Taylor de segundo orden aplicado a la función real f , el error de aproximación entre la función verdadera y su modelo cuadrático m_k a una distancia δ es rigurosamente del orden de $o(\delta^2)$.

Calculando el error del ratio de concordancia:

$$|1 - \rho(\delta)| = \left| \frac{f(x^k + \bar{d}(\delta)) - m_k(\bar{d}(\delta))}{f(x^k) - m_k(\bar{d}(\delta))} \right| \leq \frac{o(\delta^2)}{\frac{\delta}{2} \|f'(x^k)\|} = o(\delta) \rightarrow 0,$$

lo cual implica directamente que $\rho(\delta) \rightarrow 1$. Un análisis analítico paralelo demuestra que la propiedad también se cumple en el caso donde $f'(x^k) = 0$ pero el Hessiano exhibe direcciones de curvatura estricta negativa. ■

Una de las ventajas teóricas más formidables de los métodos de regiones de confianza es que no solo convergen asintóticamente a puntos estacionarios de primer orden, sino que evitan activamente puntos de ensilladura y máximos locales, garantizando la convergencia hacia puntos que satisfacen las condiciones necesarias de segundo orden.

Teorema 8.9 (Convergencia global a condiciones de segundo orden). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces continuamente diferenciable. Supongamos que la secuencia de matrices $\{H_k\}$ corresponde a las Hessianas exactas $f''(x^k)$, acotadas uniformemente.

Entonces, todo punto de acumulación $\bar{x} \in \mathbb{R}^n$ de cualquier secuencia $\{x^k\}$ generada por el Algoritmo 8.4 es un punto estacionario ($f'(\bar{x}) = 0$) y, adicionalmente, **satisface la condición necesaria de segundo orden** (la matriz $f''(\bar{x})$ es semidefinida positiva).

Prueba. La prueba es muy extensa y técnica, apoyándose en un análisis de límites sobre dos subcasos del comportamiento asintótico de los radios de confianza: el caso donde el radio converge a cero ($\liminf \delta_k = 0$) y el caso en que se mantiene estrictamente positivo ($\liminf \delta_k > 0$). En ambos casos, las propiedades topológicas del subproblema sobre la bola aseguran que si el punto límite presentara una dirección de curvatura negativa, el paso asintótico proporcionaría un descenso cuadrático estrictamente positivo, lo que forzaría un decrecimiento adicional, contradiciendo el hecho de que se trata de un punto de acumulación estabilizado. ■

8.4. Métodos de Direcciones Conjugadas

Presentamos a continuación otra clase importante de métodos que buscan alcanzar una convergencia más rápida que la de los métodos del gradiente puro, pero reduciendo drásticamente el costo computacional respecto al método de Newton y cuasi-Newton (ya que no requieren almacenar ni actualizar matrices).

En particular, son métodos de primer orden (que no usan derivadas segundas de forma explícita), pero están fundamentados en propiedades algebraicas y geométricas distintas.

8.4.1. Métodos de direcciones conjugadas para funciones cuadráticas

Los métodos de direcciones conjugadas se introducen clásicamente analizando el problema de minimización irrestricta $\min f(x)$, con la función objetivo $f : \mathbb{R}^n \rightarrow \mathbb{R}$ siendo cuadrática y fuertemente convexa:

$$f(x) = \frac{1}{2} \langle Qx, x \rangle + \langle q, x \rangle, \quad x \in \mathbb{R}^n, \quad (8.49)$$

donde $Q \in \mathbb{R}^{n \times n}$ es una matriz simétrica definida positiva y $q \in \mathbb{R}^n$.

Para motivar el desarrollo, consideremos un iterado x^k , una dirección d^k , y el iterado siguiente x^{k+1} calculado mediante minimización unidimensional exacta. Como sabemos, en el caso cuadrático el tamaño de paso óptimo se determina analíticamente y se cumple la condición de ortogonalidad:

$$0 = \langle f'(x^{k+1}), d^k \rangle = \langle Qx^{k+1} + q, d^k \rangle. \quad (8.50)$$

Sea $\bar{x}$ el minimizador global único de f . En particular, $f'(\bar{x}) = Q\bar{x} + q = 0$. Por lo tanto, trivialmente:

$$0 = \langle Q\bar{x} + q, d^k \rangle. \quad (8.51)$$

Restando esta última ecuación de (8.50), obtenemos:

$$0 = \langle Q(x^{k+1} - \bar{x}), d^k \rangle. \quad (8.52)$$

La idea fundamental de este método es exigir que la dirección siguiente d^{k+1} satisfaga exactamente la misma condición que la dirección “ideal” ($x^{k+1} - \bar{x}$) que apuntaría directamente hacia la solución óptima. Es decir, exigimos que:

$$\langle Qd^{k+1}, d^k \rangle = 0. \quad (8.53)$$

Definición 8.2 (Direcciones Q-Conjugadas). Un conjunto de vectores no nulos $\{d^0, \dots, d^k\} \subset \mathbb{R}^n \setminus \{0\}$ se llama **Q-conjugado** (o conjugado respecto a la matriz Q) si satisfacen la ortogonalidad generalizada:

$$\langle Qd^i, d^j \rangle = 0 \quad \forall i, j = 0, 1, \dots, k, \quad \text{con } i \neq j. \quad (8.54)$$

Observamos que esta noción generaliza la ortogonalidad euclidiana clásica (la cual corresponde al caso especial $Q = I$).

Lema 8.6 (Independencia lineal de las direcciones conjugadas). Para cualquier matriz $Q \in \mathbb{R}^{n \times n}$ simétrica definida positiva, cualquier conjunto de direcciones Q-conjugadas es linealmente independiente.

Prueba. Supongamos, por reducción al absurdo, que uno de los vectores del conjunto Q -conjugado pueda ser expresado como combinación lineal del resto. Por ejemplo, el vector d^0 :

$$d^0 = \sum_{i=1}^k \beta_i d^i, \quad \text{donde } \beta_i \in \mathbb{R}.$$

Multiplicando escalarmente ambos lados de esta ecuación por el vector Qd^0 , y utilizando el hecho de que Q es definida positiva y $d^0 \neq 0$:

$$0 < \langle Qd^0, d^0 \rangle = \sum_{i=1}^k \beta_i \langle Qd^0, d^i \rangle = 0,$$

ya que $\langle Qd^0, d^i \rangle = 0$ para todo $i \neq 0$. Esto es una contradicción evidente, lo que demuestra la independencia lineal. ■

Como corolario inmediato, un conjunto de vectores Q -conjugados en $\mathbb{R}^n$ no puede contener más de n elementos. El esquema general de los métodos de direcciones conjugadas para funciones cuadráticas toma la siguiente forma:

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, 1, \dots, n-1, \quad (8.55)$$

donde $\{d^0, d^1, \dots, d^{n-1}\}$ es un conjunto base de direcciones Q -conjugadas, y los valores de la longitud de paso α_k son calculados para satisfacer la minimización unidimensional exacta:

$$f(x^k + \alpha_k d^k) = \min_{\alpha \in \mathbb{R}} f(x^k + \alpha d^k), \quad (8.56)$$

lo que analíticamente equivale a:

$$\alpha_k = -\frac{\langle f'(x^k), d^k \rangle}{\langle Qd^k, d^k \rangle} = -\frac{\langle Qx^k + q, d^k \rangle}{\langle Qd^k, d^k \rangle}. \quad (8.57)$$

El mínimo unidimensional en (8.56) se calcula sobre todo $\mathbb{R}$ (no solo $\mathbb{R}_+$), dado que en este esquema algebraico la dirección d^k podría no ser estrictamente una dirección de descenso a priori. Por lo tanto, los métodos de direcciones conjugadas, en su concepción teórica inicial, no son estrictamente métodos de descenso monótono, sino de **proyección ortogonal sucesiva**.

Teorema 8.10 (Convergencia finita en cuadráticas). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ definida por (8.49), con Q simétrica definida positiva. Entonces, para cualquier punto inicial $x^0 \in \mathbb{R}^n$, el punto x^n obtenido de acuerdo con el esquema iterativo tras exactamente n iteraciones es el minimizador global exacto del problema.

Prueba. Como Q es definida positiva, el único punto estacionario y minimizador global $\bar{x}$ está caracterizado por $Q\bar{x} + q = 0$. Por el Lema 8.6, los n vectores Q -conjugados forman una base de $\mathbb{R}^n$. Por lo tanto, el vector que separa la aproximación inicial del óptimo se puede escribir como una combinación lineal única en esta base:

$$\bar{x} - x^0 = \sum_{k=0}^{n-1} \beta_k d^k. \quad (8.58)$$

Por otro lado, desenrollando recursivamente el esquema iterativo (8.55), el iterado n -ésimo es:

$$x^n = x^0 + \sum_{k=0}^{n-1} \alpha_k d^k.$$

La demostración se reduce a probar que los coeficientes escalares coinciden ($\beta_k = \alpha_k$ para todo k).

Multiplicando (8.58) por Q y proyectando escalarmente sobre la dirección d^k , la ortogonalidad Q -conjugada anula todos los términos de la sumatoria excepto el k -ésimo:

$$\langle Q(\bar{x} - x^0), d^k \rangle = \langle Q \left(\sum_{i=0}^{n-1} \beta_i d^i \right), d^k \rangle = \beta_k \langle Qd^k, d^k \rangle.$$

Como $Q\bar{x} = -q$, sustituimos y despejamos β_k :

$$\beta_k = \frac{\langle -q - Qx^0, d^k \rangle}{\langle Qd^k, d^k \rangle} = -\frac{\langle Qx^0 + q, d^k \rangle}{\langle Qd^k, d^k \rangle}. \quad (8.59)$$

Finalmente, evaluando el gradiente en $x^k = x^0 + \sum_{i=0}^{k-1} \alpha_i d^i$ proyectado sobre d^k :

$$\begin{aligned}\langle f'(x^k), d^k \rangle &= \langle Q \left(x^0 + \sum_{i=0}^{k-1} \alpha_i d^i \right) + q, d^k \rangle \\ &= \langle Qx^0 + q, d^k \rangle + \sum_{i=0}^{k-1} \alpha_i \langle Qd^i, d^k \rangle \\ &= \langle Qx^0 + q, d^k \rangle,\end{aligned}$$

dado que d^k es Q -ortogonal a todas las direcciones previas $d^0, \dots, d^{k-1}$. Sustituyendo esto en la fórmula (8.57) de α_k , obtenemos exactamente la misma expresión que para β_k . En consecuencia, $x^n = \bar{x}$. ■

Teorema 8.11 (Minimización exacta en el subespacio afín). *Bajo las hipótesis del teorema anterior, el iterado x^{k+1} generado por el método de direcciones conjugadas es el minimizador global exacto de la función f sobre la variedad afín de dimensión $k+1$:*

$$D_k = x^0 + \text{span}\{d^0, d^1, \dots, d^k\}.$$

8.4.2. El método de los Gradientes Conjugados

El **método de los gradientes conjugados** resuelve elegantemente la necesidad de generar una base Q -conjugada de forma eficiente y progresiva, definiendo cada nueva dirección como una combinación del antigradiente actual y la dirección conjugada inmediatamente anterior:

$$d^0 = -f'(x^0), \quad d^k = -f'(x^k) + \beta_{k-1} d^{k-1}, \quad k = 1, \dots, n-1, \quad (8.60)$$

donde el escalar β_{k-1} se diseña forzando algebraicamente a que las direcciones adyacentes d^{k-1} y d^k sean Q -ortogonales:

$$0 = \langle Qd^{k-1}, d^k \rangle = -\langle Qd^{k-1}, f'(x^k) \rangle + \beta_{k-1} \langle Qd^{k-1}, d^{k-1} \rangle \implies \beta_{k-1} = \frac{\langle Qd^{k-1}, f'(x^k) \rangle}{\langle Qd^{k-1}, d^{k-1} \rangle}.$$

Algoritmo 8.5 (Método de los Gradientes Conjugados). Elegir $x^0 \in \mathbb{R}^n$, computar $d^0 = -f'(x^0)$ y tomar $k := 0$.

1. Si $\|f'(x^k)\| \leq \epsilon$, el método se detiene.
2. Calcular la longitud del paso exacto α_k mediante (8.57).
3. Actualizar el punto $x^{k+1} = x^k + \alpha_k d^k$.
4. Si $k < n-1$, calcular el factor de conjugación β_k y generar la nueva dirección $d^{k+1} = -f'(x^{k+1}) + \beta_k d^k$.
5. Incrementar $k \leftarrow k+1$ y regresar al Paso 1.

Teorema 8.12. *El Algoritmo 8.5 produce efectivamente un conjunto de vectores $d^0, d^1, \dots, d^{n-1}$ que son Q -conjugados. Sorprendentemente, los gradientes sucesivos generados $f'(x^0), f'(x^1), \dots, f'(x^{n-1})$ son mutuamente **ortogonales** en la métrica euclidiana normal.*

8.4.3. Extensión a funciones no lineales generales (No Cuadráticas)

Para funciones no cuadráticas, la matriz Hessiana $Q = \nabla^2 f(x)$ no es constante. Por lo tanto, el cálculo del coeficiente β_k que incluye a la matriz Q sería costoso y anularía la principal ventaja de este método. Afortunadamente, se puede demostrar algebraicamente que (en el caso cuadrático) la fórmula de β_k es matemáticamente equivalente a las siguientes formas de **Fletcher-Reeves (FR)** y **Polak-Ribière (PR)**, las cuales solo requieren evaluar gradientes:

$$\beta_{k-1}^{FR} = \frac{\|f'(x^k)\|^2}{\|f'(x^{k-1})\|^2} \quad \text{y} \quad \beta_{k-1}^{PR} = \frac{\langle f'(x^k), f'(x^k) - f'(x^{k-1}) \rangle}{\|f'(x^{k-1})\|^2}.$$

En la optimización práctica de sistemas no lineales, el método de gradientes conjugados con las fórmulas anteriores (combinado con una búsqueda de línea de Wolfe en lugar del paso exacto) es extremadamente eficiente y su consumo de memoria es de $O(n)$, siendo la herramienta de elección para sistemas a gran escala donde la matriz Hessiana no cabe en la memoria.

8.5. Métodos que no utilizan derivadas

Esta sección presenta una breve mención a métodos de optimización de orden cero (que no utilizan información diferencial en absoluto). El análisis teórico de su convergencia en la literatura es complejo y en muchos casos de naturaleza probabilística, pero poseen una gran importancia práctica cuando la función objetivo es el resultado de simulaciones de caja negra (black-box), cuando la función presenta ruido, o cuando su gradiente no está analíticamente disponible.

8.5.1. Descenso por Coordenadas (Coordinate Descent)

En el método de descenso cíclico por coordenadas, las direcciones de búsqueda se restringen exclusivamente a la base canónica ortogonal del espacio dimensional:

$$d^0 = e^1, d^1 = e^2, \dots, d^{n-1} = e^n, d^n = e^1, \dots$$

El tamaño de paso se calcula iterativamente mediante una minimización unidimensional a lo largo del eje seleccionado. Esto equivale a minimizar la función cambiando el valor de una sola variable a la vez, manteniendo el resto de las variables estrictamente congeladas.

Aunque es sumamente intuitivo y muy fácil de programar, este método carece de garantías de convergencia global (incluso para funciones suaves) si no se imponen fuertes condiciones adicionales sobre la función, como la separabilidad estricta de las variables o una condición de convexidad fuerte. En la presencia de valles alargados o funciones no diferenciables, el método de descenso por coordenadas puede detenerse en puntos no estacionarios.

8.5.2. Búsqueda Aleatoria (Random Search) y Gradiente Estocástico

Si se carece completamente de derivadas y el espacio de búsqueda es complejo, una estrategia heurística ampliamente utilizada es la **Búsqueda Aleatoria**. En este enfoque, la dirección de prueba d^k se elige mediante la realización de una variable aleatoria uniformemente distribuida sobre la esfera unitaria de $\mathbb{R}^n$.

El algoritmo procede de la siguiente manera:

- Si la evaluación de la función objetivo en el punto de prueba $f(x^k + \alpha d^k)$ proporciona un descenso aceptable, la dirección y el paso se aceptan y se actualiza el iterado.
- Si no proporciona descenso, se reduce la longitud del paso o simplemente se rechaza y se sortea una nueva dirección aleatoria.

Para funciones que son topológicamente no diferenciables (pero que cumplen con ser localmente Lipschitz continuas), el Teorema de Rademacher asegura que la función es diferenciable en casi todo punto del dominio. Este poderoso hecho analítico sustenta el método de **Diferencias Finitas Estocásticas**, donde el gradiente se estima numéricamente en cada paso mediante pequeñas perturbaciones en direcciones coordinadas o aleatorias:

$$g_j^k \approx \frac{f(x^k + t_k e^j) - f(x^k)}{t_k}.$$

Coordinando matemáticamente las secuencias de las longitudes de paso de actualización y las magnitudes de las perturbaciones aleatorias t_k , es posible probar rigurosamente la convergencia estocástica asintótica del algoritmo hacia el conjunto de puntos estacionarios con probabilidad 1 (casi seguramente).

Ejercicios del Capítulo 7

Sección I: Métodos de Descenso y Gradiente

Ejercicio 8.1 (Caracterizaciones adicionales de direcciones de descenso). Probar los siguientes hechos, que pueden considerarse como caracterizaciones adicionales de las direcciones de descenso. Si la función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es dos veces diferenciable en el punto $x \in \mathbb{R}^n$, entonces:

1. Para todo $d \in \mathcal{D}_f(x)$ que cumple $\langle f'(x), d \rangle = 0$, se tiene que $\langle f''(x)d, d \rangle \leq 0$.
2. Si $d \in \mathbb{R}^n$ satisface $\langle f'(x), d \rangle = 0$ y $\langle f''(x)d, d \rangle < 0$, se tiene que $d \in \mathcal{D}_f(x)$.

Ejercicio 8.2 (Modificación de la regla de Armijo). Suponiendo que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es continuamente diferenciable en el punto x^k y que $d^k \in \mathcal{D}_f(x^k)$, probar que la modificación de la regla de Armijo donde la desigualdad clásica es reemplazada por:

$$f(x^k + \alpha d^k) \leq f(x^k) + \sigma \alpha^2 \langle f'(x^k), d^k \rangle,$$

con $\sigma > 0$, está bien definida (es decir, existe un $\tilde{\alpha}_k > 0$ tal que la condición anterior se cumple para todo $\alpha \in [0, \tilde{\alpha}_k]$). Hacer un dibujo geométrico para ilustrar esta regla de búsqueda lineal.

Ejercicio 8.3 (Implementación de la regla de Goldstein). Bajo las mismas hipótesis, probar que la implementación iterativa de la regla de Goldstein, análoga a la presentada para la regla de Wolfe mediante interpolación, está bien definida.

Ejercicio 8.4 (Probar los incisos asintóticos del Teorema de Newton). Probar algebraicamente los incisos asintóticos restantes del Teorema de convergencia local del método del gradiente para garantizar la reducción del error.

Ejercicio 8.5 (Relajación de hipótesis de Lipschitz). Probar que en el Teorema de convergencia local del gradiente, la hipótesis de diferenciabilidad de la función f en todo $\mathbb{R}^n$, así como la hipótesis de continuidad de Lipschitz de la derivada de f en $\mathbb{R}^n$, pueden ser relajadas, suponiendo estas propiedades únicamente en una vecindad del punto $\bar{x}$.

Ejercicio 8.6 (Convergencia del método del gradiente con Goldstein y Wolfe). Probar afirmaciones analíticas análogas a las del Teorema de convergencia global para el método del gradiente utilizando búsqueda lineal de Goldstein y búsqueda lineal de Wolfe.

Ejercicio 8.7 (Convergencia al conjunto de puntos estacionarios). Suponiendo las hipótesis del Teorema de convergencia global y que el conjunto de nivel $\text{lev}_{\leq f(x^0)} f$ sea acotado, probar formalmente que:

$$\text{dist}(x^k, S_0) \rightarrow 0 \quad (k \rightarrow \infty),$$

donde $S_0 = S_0(x^0) = \{x \in \text{lev}_{\leq f(x^0)} f \mid f'(x) = 0\}$.

Ejercicio 8.8 (Esquema iterativo general con direcciones de descenso). Considerar el esquema iterativo general dado por $x^{k+1} = x^k + \alpha_k d^k$, donde

$$c_1 \|f'(x^k)\|^{p_1} \leq -\langle f'(x^k), d^k \rangle, \quad \|d^k\| \leq c_2 \|f'(x^k)\|^{p_2},$$

con $c_1, c_2 > 0$, $p_1, p_2 \geq 0$, y la longitud del paso α_k se calcula mediante la regla de minimización unidimensional o por la regla de Armijo. Suponiendo que la función f sea continuamente diferenciable, probar que todo punto de acumulación de la secuencia $\{x^k\}$ es un punto estacionario del problema.

Ejercicio 8.9 (Método del gradiente con perturbaciones). Sea $\{x^k\}$ una secuencia generada por $x^{k+1} = x^k + \alpha_k d^k$, donde

$$d^k = -f'(x^k) + \varepsilon^k, \quad \|\varepsilon^k\| \leq \delta \quad \forall k.$$

Supongamos que la secuencia $\{x^k\}$ es acotada. Probar que para todo $c > \delta$, existen $c_2 \geq c_1 > 0$ tales que si $\alpha_k \in [c_1, c_2]$, entonces la secuencia $\{x^k\}$ posee un punto de acumulación que pertenece al conjunto $\{x \in \mathbb{R}^n \mid \|f'(x)\| \leq c\}$.

Ejercicio 8.10 (Método de descenso por coordenadas con Armijo). Sea $\{x^k\}$ una secuencia generada por $x^{k+1} = x^k + \alpha_k d^k$, donde α_k es calculado por la regla de Armijo y

$$d^k = -(0, \dots, 0, f'_{i_k}(x^k), 0, \dots, 0),$$

y el índice activo satisface $|f'_{i_k}(x^k)| = \max_{j=1, \dots, n} |f'_j(x^k)|$. Probar que todo punto de acumulación de $\{x^k\}$ es un punto estacionario.

Ejercicio 8.11 (Dirección de descenso con control de subsecuencias). Sea f continuamente diferenciable. Supongamos que, dado un punto x^k , la dirección d^k sea elegida de manera que garantice que cuando una subsecuencia $\{x^{k_j}\}$ converge a un punto no estacionario, entonces $\liminf_{j \rightarrow \infty} \langle f'(x^{k_j}), d^{k_j} \rangle < 0$. Probar que todo punto de acumulación generado con Armijo es estacionario.

Ejercicio 8.12 (Dos iteraciones del método de máximo descenso). Tomando $x^0 = (-2, 1)$, realizar manualmente dos iteraciones exactas del método de máximo descenso para la función:

$$f(x) = x_1^2 + x_1x_2 + 2x_2^2 + x_1.$$

Ejercicio 8.13 (Una iteración del método del gradiente con Armijo). Tomando $x^0 = (1, -1)$, realizar una iteración del método del gradiente para la función $f(x) = 2x_1^2 + x_1x_2 + 3x_2^2$, utilizando una regla de Armijo, con parámetros siendo $\hat{\alpha} = 1$ y $\sigma = 1/2$.

Ejercicio 8.14 (Convergencia de un esquema con pasos decrecientes). Sea el esquema donde $c_1\|f'(x^k)\|^2 \leq -\langle f'(x^k), d^k \rangle$ y $\|d^k\| \leq c_2\|f'(x^k)\|$, y la secuencia de longitudes satisface la condición estocástica:

$$\lim_{k \rightarrow \infty} \alpha_k = 0, \quad \sum_{k=0}^{\infty} \alpha_k = +\infty.$$

Probar que la secuencia $\{f(x^k)\}$ converge y que $\liminf_{k \rightarrow \infty} \|f'(x^k)\| = 0$.

Ejercicio 8.15 (Crecimiento cuadrático y estimación del gradiente). Siguiendo la demostración teórica vista, probar que si f es tres veces diferenciable con derivada tercera acotada, y satisface la condición de crecimiento cuadrático de conjunto, entonces para todo $v \in (0, 4)$ existe $r > 0$ tal que $\|f'(x)\|^2 \geq v\gamma(f(x) - \bar{v})$ en la vecindad.

Ejercicio 8.16 (Separación de superficies de nivel críticas). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ con derivada Lipschitz-continua. Mostrar que si f asume en su conjunto de puntos estacionarios un número finito de valores diferentes, la condición de separación de superficies de nivel críticas se satisface automáticamente.

Ejercicio 8.17 (Cuadráticas y condiciones de separación). Mostrar que toda función cuadrática que posee un punto estacionario satisface globalmente la desigualdad de gradiente estacionario.

Sección II: Método de Newton y Cuasi-Newton

Ejercicio 8.18 (Método de Newton inexacto). Probar el corolario que establece la preservación de la tasa de convergencia superlineal cuando el Hessiano exacto es reemplazado por una matriz de aproximación asintótica.

Ejercicio 8.19 (Newton truncado con tolerancias decrecientes). Probar que una secuencia $\{x^k\}$ que satisface la condición de tolerancia $\|f'(x^k) + f''(x^k)d^k\| \leq \sigma_k\|f'(x^k)\|$, donde $\sigma_k \rightarrow 0$, converge a $\bar{x}$ con tasa superlineal.

Ejercicio 8.20 (Newton modificado/simplificado). Probar que el método dado por $x^{k+1} = x^k - (f''(x^0))^{-1}f'(x^k)$ (donde la matriz Hessiana se congela en la iteración inicial) converge localmente a $\bar{x}$ con tasa estrictamente lineal.

Ejercicio 8.21 (Raíz múltiple y Newton con paso variable). A partir de $x^0 = 1$, realizar dos iteraciones del método de Newton para la ecuación escalar $x^p = 0$, con $p \geq 2$. Analizar la degradación de la tasa de convergencia y explicar cómo restaurarla introduciendo un multiplicador de paso $\alpha = p$.

Ejercicio 8.22 (Raíz de orden p y convergencia lineal generalizada). Probar formalmente la afirmación del ejercicio anterior mediante cálculo de Taylor: si una función tiene una raíz múltiple de multiplicidad p , el método de Newton clásico degenera en tasa lineal.

Ejercicio 8.23 (Invarianza de Newton ante transformaciones afines). Mostrar que el método de Newton es invariante en relación a transformaciones lineales de variables $x = Ay$. Demuestre que la trayectoria transformada $y^k = A^{-1}x^k$ coincide exactamente con la trayectoria computada directamente en el nuevo espacio.

Ejercicio 8.24 (Newton para minimización de $x_1^2 + e^{x_2^2}$). Realizar dos iteraciones del método de minimización irrestricta de la función

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad f(x) = x_1^2 + e^{x_2^2},$$

a partir del punto $x^0 = (1, 1)$. Analizar la tasa de convergencia. Mostrar que, en este caso, el método de Newton posee convergencia global.

Ejercicio 8.25 (Falsa convergencia local en Newton). Considere la aplicación del método de Newton irrestricto para minimizar la función no convexa:

$$f(x) = x^2 + \cos x.$$

Verifique analíticamente que la solución global $\bar{x} = 0$ satisface todas las hipótesis suficientes de segundo orden (Corolario 8.2). Sin embargo, si se elige patológicamente el punto inicial alejado del origen $x^0 = 2\pi i$ (con $i \in \mathbb{N}, i \geq 1$), demuestre desarrollando las iteraciones exactas que el método de Newton puro entra en un ciclo o diverge, fallando estrepitosamente en alcanzar el mínimo.

Ejercicio 8.26 (Newton para $\|x\|^3$). Aplicar el método de Newton para minimizar la función

$$f : \mathbb{R}^n \rightarrow \mathbb{R}, \quad f(x) = \|x\|^3.$$

Analizar la tasa de convergencia y explicar lo observado.

Ejercicio 8.27 (Equivalencia algebraica de Dennis-Moré). Demuestre, manipulando los límites asintóticos y normando por $Q_k f'(x^k)$, que si se cumplen estrictamente las hipótesis del Teorema de Dennis-Moré (Teorema 8.7), la condición residual en el espacio primario:

$$(Q_k - (f''(\bar{x}))^{-1})f'(x^k) = o(\|f'(x^k)\|)$$

es matemáticamente equivalente a exigir que el residuo en el espacio pre-condicionado tienda a cero súper-linealmente:

$$(Q_k^{-1} - f''(\bar{x}))Q_k f'(x^k) = o(\|Q_k f'(x^k)\|).$$

Ejercicio 8.28 (Dennis-Moré para búsqueda de Goldstein). Para el caso de utilización de la regla de búsqueda lineal de Goldstein con el valor inicial de la longitud de paso $\hat{\alpha} = 1$, probar afirmaciones análogas a las del Teorema de Dennis-Moré.

Ejercicio 8.29 (Dualidad matricial DFP-BFGS y positividad). Existe una profunda simetría algebraica entre las correcciones DFP y BFGS. Definiendo $H_k = Q_k^{-1}$ como la matriz Hessiana directa aproximada en la iteración k .

Tome la actualización matricial BFGS que calcula la inversa Q_{k+1} . Demuestre utilizando el lema de inversión de matrices de Sherman-Morrison-Woodbury que la actualización de la matriz Hessiana directa H_{k+1} asociada al algoritmo BFGS adopta exactamente la forma de la ecuación de DFP (intercambiando los vectores r^k y s^k).

A partir de este isomorfismo, complete la prueba de preservación para demostrar que BFGS también preserva invariablemente el carácter definido positivo de las matrices.

Sección III: Métodos sin Derivadas y Direcciones Conjugadas

Ejercicio 8.30 (Fórmulas alternativas para gradientes conjugados). Mostrar que la fórmula analítica original de actualización β_k puede ser reescrita algebraicamente (bajo la hipótesis de búsqueda lineal exacta) en las formas de Fletcher-Reeves y Polak-Ribière.

Ejercicio 8.31 (Gradientes conjugados como caso particular de BFGS). Mostrar que la dirección de búsqueda del método de gradientes conjugados de Polak-Ribière puede representarse algebraicamente como $d^{k+1} = -Q_{k+1}f'(x^{k+1})$, donde Q_{k+1} resulta de aplicar la fórmula de actualización de BFGS reiniciando desde la matriz identidad en cada iteración ($Q_k = I$).

Ejercicio 8.32 (Cota de convergencia para gradientes conjugados). Sea $Q \in \mathbb{R}^{n \times n}$ dada por $Q = A + \sum_{i=1}^m y^i (y^i)^T$, donde A es definida positiva y y^i son vectores arbitrarios. Mostrar que el iterado x^{k+1} generado por gradientes conjugados satisface la relación

$$f(x^{k+1}) \leq \left(\frac{c_n - c_1}{c_n + c_1} \right)^2 f(x^0),$$

donde c_n y c_1 son el mayor y el menor autovalor de la matriz A , respectivamente.

Ejercicio 8.33 (Interpretación de Krylov de los gradientes conjugados). Para el método de gradientes conjugados aplicado a la función $f(x) = \frac{1}{2} \langle Qx, x \rangle + \langle q, x \rangle$, donde Q es definida positiva, probar que el iterado x^k minimiza f en el conjunto $x^0 + \text{span}\{f'(x^0), Qf'(x^0), \dots, Q^{k-1}f'(x^0)\}$.

Ejercicio 8.34 (Dos pasos de descenso por coordenadas con minimización exacta). A partir del punto inicial $x^0 = 0$, realizar de forma analítica dos pasos completos del método de Descenso por Coordenadas para minimizar la función $f(x) = x_1^2 + 2x_1x_2 + 3x_2^2 + 4x_1$.

Ejercicio 8.35 (Descenso por coordenadas para una cuadrática). Hacer lo mismo para la función $f(x) = 2x_1^2 - x_1x_2 + x_2^2$, a partir del punto $x^0 = (2, 0)$.

9. Métodos para Optimización con Restricción

Este capítulo constituye la parte principal del libro. De cierto modo, el material de los otros capítulos es preparatorio, auxiliar o adicional en relación a métodos para la resolución de problemas de optimización con restricciones.

9.1. Métodos para conjuntos factibles de estructura simple

Comenzaremos el desarrollo de métodos para problemas de optimización con restricciones en el caso en que el conjunto factible tenga descripción abstracta:

$$\min f(x) \quad \text{sujeto a } x \in D, \quad (9.1)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función diferenciable y $D \subset \mathbb{R}^n$. Por razones de aplicación práctica, entendemos que el conjunto D posee una estructura simple (por lo menos, D es convexo y cerrado).

Con frecuencia, problemas con restricciones simples aparecen como subproblemas en métodos para la resolución de problemas con restricciones más complejas. Notamos que cuando el conjunto D es convexo y cerrado, para todo punto $x \in \mathbb{R}^n$ existe una proyección $P_D(x)$ de x sobre D que es única (vea el Teorema 1.3.1). Recordamos también que el punto $\bar{x} \in D$ es un punto estacionario del problema (9.1) cuando

$$\langle f'(\bar{x}), x - \bar{x} \rangle \geq 0 \quad \forall x \in D, \quad (9.2)$$

o, equivalentemente,

$$P_D(\bar{x} - \alpha f'(\bar{x})) = \bar{x} \quad (9.3)$$

para algún $\alpha > 0$ (vea el Teorema 1.3.7). Más aún, la validez de (9.3) para algún $\alpha > 0$ implica la validez de esta relación para todo $\alpha > 0$.

9.1.1. Métodos del gradiente proyectado

Los métodos del gradiente proyectado pueden ser pensados como una combinación natural de métodos del gradiente para optimización irrestricta con proyección de iteraciones así obtenidas en el conjunto factible del problema. Esto resulta en el esquema siguiente:

$$x^{k+1} = P_D(x^k - \alpha_k f'(x^k)), \quad k = 0, 1, \dots, \quad (9.4)$$

donde $x^0 \in D$, y los parámetros de longitud de paso $\alpha_k > 0$ son calculados utilizando extensiones de técnicas de búsqueda lineal de § 3.1.1 para el caso con restricciones. En particular, el valor de longitud de paso es calculado para obtener decrecimiento de la función

$$\varphi_k : \mathbb{R}_+ \rightarrow \mathbb{R}, \quad \varphi_k(\alpha) = f(x^k(\alpha)),$$

donde

$$x^k(\alpha) = P_D(x^k - \alpha f'(x^k)) \quad (9.5)$$

es el arco de proyección (vea Figura 4.1.1).

Por ejemplo, en el caso de la minimización unidimensional, α_k es una solución del problema

$$\min \varphi_k(\alpha) \quad \text{sujeto a } \alpha \in \mathbb{R}_+,$$

o del problema

$$\min \varphi_k(\alpha) \quad \text{sujeto a} \quad \alpha \in [0, \hat{\alpha}],$$

donde $\hat{\alpha} > 0$ es un parámetro. Sin embargo, como en el caso irrestricto, las reglas de minimización unidimensional no son muy atractivas desde el punto de vista práctico.

Más interesantes son las extensiones de la regla de Armijo. Esto puede ser hecho, por ejemplo, por el mismo esquema que fue considerado en § 3.1.1, sustituyendo la condición (3.6) por

$$f(x^k(\alpha)) \leq f(x^k) + \sigma \langle f'(x^k), x^k(\alpha) - x^k \rangle. \quad (9.6)$$

Recordamos que, para comenzar el proceso, deben ser elegidos un parámetro $\sigma \in (0, 1)$, el valor inicial de la longitud de paso $\hat{\alpha} > 0$ y el parámetro de reducción del paso $\theta \in (0, 1)$. En particular, α_k es calculado como el mayor entre todos los números de la forma $\alpha = \hat{\alpha}\theta^s$, $s \in \mathbb{N}$, satisfaciendo la desigualdad (9.6). Como es fácil ver, en el caso cuando $D = \mathbb{R}^n$, la desigualdad (9.6) se reduce a la condición de Armijo (3.6) en el caso irrestricto.

Existen también varias modificaciones de la regla de Armijo (por ejemplo, similares a la regla de Goldstein). Podríamos considerar también la regla de longitud de paso fijo, donde $\alpha_k = \bar{\alpha}$ para todo k , con $\bar{\alpha} > 0$ fijo.

Algoritmo 9.1 (Método del gradiente proyectado). Elegir $x^0 \in D$ y tomar $k := 0$. Elegir una de las tres reglas de cálculo de longitud de paso a ser utilizada, y los parámetros asociados: $\hat{\alpha} > 0$ (o $\hat{\alpha} = +\infty$) en el caso de minimización unidimensional, $\hat{\alpha} > 0$, $\sigma, \theta \in (0, 1)$ en el caso de la regla de Armijo, $\bar{\alpha} > 0$ en el caso de longitud de paso fijo.

1. Calcular α_k de acuerdo con la regla elegida.
2. Calcular x^{k+1} utilizando la fórmula (9.4).
3. Tomar $k := k + 1$ y retornar al Paso 1.

El Algoritmo 4.1.1 está ilustrado en la Figura 4.1.1.

Observamos que si para algún k el punto x^k es estacionario para el problema (9.1), entonces el método genera $x^k = x^{k+1} = \dots$, cualquiera que sea la longitud de paso α_k . Notamos también que para $D = \mathbb{R}^n$, un método del gradiente proyectado se reduce al método del gradiente (irrestricto) correspondiente. Las propiedades de convergencia de métodos del gradiente proyectado son muy parecidas a las propiedades de métodos del gradiente. A continuación, presentaremos dos resultados que son generalizaciones de los Teoremas 3.1.1 y 3.1.5, respectivamente.

En el análisis a seguir, la siguiente desigualdad tiene un papel importante:

$$\langle f'(x^k), x^k(\alpha) - x^k \rangle \leq -\frac{1}{\alpha} \|x^k(\alpha) - x^k\|^2 \quad \forall \alpha > 0. \quad (9.7)$$

Para probar esta desigualdad, notamos que para todo $\alpha > 0$,

$$\begin{aligned} \langle f'(x^k), x^k(\alpha) - x^k \rangle &= \frac{1}{\alpha} \langle x^k + \alpha f'(x^k) - x^k, x^k(\alpha) - x^k \rangle \\ &= \frac{1}{\alpha} \langle x^k - x^k(\alpha), x^k(\alpha) - x^k \rangle + \frac{1}{\alpha} \langle x^k(\alpha) - (x^k - \alpha f'(x^k)), x^k(\alpha) - x^k \rangle \\ &\leq -\frac{1}{\alpha} \|x^k(\alpha) - x^k\|^2, \end{aligned}$$

donde el Teorema 1.3.1 fue utilizado.

Lema 9.1. Sean $D \subset \mathbb{R}^n$ un conjunto cerrado y convexo, y $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$.

Entonces para cualquier $x^k \in \mathbb{R}^n$ la desigualdad (9.6) es satisfecha para todo $\alpha \in (0, \bar{\alpha}]$, donde

$$\bar{\alpha} = 2(1 - \sigma)/L > 0. \quad (9.8)$$

Prueba. Utilizando el Lema 1.5.4 y las desigualdades (9.7) y (9.8), para todo $\alpha \in (0, \bar{\alpha}]$ obtenemos que

$$\begin{aligned} f(x^k(\alpha)) - f(x^k) &\leq \langle f'(x^k), x^k(\alpha) - x^k \rangle + \frac{L}{2} \|x^k(\alpha) - x^k\|^2 \\ &\leq \sigma \langle f'(x^k), x^k(\alpha) - x^k \rangle + \left(\frac{L}{2} - \frac{1 - \sigma}{\alpha} \right) \|x^k(\alpha) - x^k\|^2 \\ &\leq \sigma \langle f'(x^k), x^k(\alpha) - x^k \rangle, \end{aligned}$$

lo que es justamente el resultado anunciado. ■

El resultado del Lema 4.1.1 implica en que, bajo las hipótesis correspondientes, los valores de longitud de paso calculados por la regla de Armijo son limitados inferiormente por un número que no depende de k , i.e.,

$$\alpha_k \geq \check{\alpha} > 0 \quad \forall k. \quad (9.9)$$

Observamos también que la utilización de longitud de paso fijo, suponiendo que

$$\bar{\alpha} < 2/L, \quad (9.10)$$

es equivalente a la regla de Armijo con $\hat{\alpha} = \bar{\alpha}$ y $\sigma > 0$ suficientemente pequeño. Por lo tanto, este caso no requiere análisis separado.

Teorema 9.1 (Convergencia del método del gradiente proyectado). Sean $D \subset \mathbb{R}^n$ un conjunto cerrado y convexo, $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en $\mathbb{R}^n$, con derivada Lipschitz-continua en $\mathbb{R}^n$ con módulo $L > 0$.

Entonces cada punto de acumulación de cualquier secuencia $\{x^k\}$ generada por el Algoritmo 4.1.1 es un punto estacionario del problema (9.1). Si un punto de acumulación existe, o si la función f es limitada inferiormente en D , entonces para cualquier secuencia limitada $\{t_k\} \subset \mathbb{R}_+$ se tiene que

$$\|x^k - P_D(x^k - t_k f'(x^k))\| \rightarrow 0 \quad (k \rightarrow \infty). \quad (9.11)$$

Prueba. Consideremos el caso de la regla de Armijo. Por (9.7), para todo k tenemos que

$$\begin{aligned} f(x^k) - f(x^{k+1}) &\geq -\sigma \langle f'(x^k), x^{k+1} - x^k \rangle \\ &\geq \frac{\sigma}{\alpha_k} \|x^{k+1} - x^k\|^2 \\ &\geq \frac{\sigma}{\check{\alpha}} \|x^{k+1} - x^k\|^2. \end{aligned} \quad (9.12)$$

Si x^k no es un punto estacionario del problema (9.1), se tiene que

$$\|x^{k+1} - x^k\| = \|P_D(x^k - \alpha_k f'(x^k)) - x^k\| > 0,$$

porque $\alpha_k > 0$. Por eso, de (9.12) obtenemos que la secuencia $\{f(x^k)\}$ es decreciente. Supongamos que la secuencia $\{x^k\}$ posea un punto de acumulación $\bar{x} \in \mathbb{R}^n$. En este caso, por el hecho de que la secuencia $\{f(x^k)\}$ es decreciente, obtenemos que ella es limitada inferiormente (por $f(\bar{x})$), y por lo tanto converge (cuando la función f es limitada inferiormente en $\mathbb{R}^n$, esto vale aun cuando $\{x^k\}$ no tiene puntos de acumulación). Concluimos que

$$f(x^k) - f(x^{k+1}) \rightarrow 0 \quad (k \rightarrow \infty),$$

y, de (9.12), obtenemos que

$$\|x^{k+1} - x^k\| \rightarrow 0 \quad (k \rightarrow \infty). \quad (9.13)$$

Sea la secuencia $\{t_k\} \subset \mathbb{R}_+$ limitada superiormente por un número $\hat{t}$. Por el Teorema 1.3.1, utilizando también (9.9) y (9.13), obtenemos que

$$\begin{aligned} \|x^k(t_k) - x^k\| &\leq \max\{1, t_k/\alpha_k\} \|x^k(\alpha_k) - x^k\| \\ &\leq \max\{1, \hat{t}/\check{\alpha}\} \|x^{k+1} - x^k\| \rightarrow 0 \quad (k \rightarrow \infty), \end{aligned}$$

lo que prueba (9.11).

Sea $\{x^{k_j}\}$ una subsecuencia de la secuencia $\{x^k\}$ que converge a $\bar{x}$. Pasando al límite cuando $j \rightarrow \infty$ en (9.11), donde tomamos $t_k = t \forall k$, siendo $t > 0$ un número arbitrario, teniendo en cuenta la continuidad del operador de proyección (vea el Teorema 1.3.1), obtenemos (9.3), mostrando que $\bar{x}$ es un punto estacionario.

La consideración del caso de utilización de la minimización unidimensional se reduce a la regla de Armijo de la misma manera que en el Teorema 3.1.1. ■

Sea S_0 el conjunto de puntos estacionarios del problema (9.1). Supongamos que valga la condición de separación de superficies de nivel críticas, que tiene la misma forma que en § 3.1.2 (pero con la nueva definición de S_0 , claro). Supongamos que vale la estimativa

$$\|x - P_D(x - f'(x))\| \geq \gamma \text{dist}(x, S_0) \quad \forall x \in U, \quad (9.14)$$

donde

$$U = \{x \in \mathbb{R}^n \mid \|x - P_D(x - f'(x))\| < \delta\}, \quad (9.15)$$

con constantes $\delta > 0$ y $\gamma > 0$. En el caso de $D = \mathbb{R}^n$, estas condiciones ya fueron consideradas en § 3.1.2. Sin entrar en detalles, mencionamos que ambas son satisfechas si, por ejemplo, f es una función cuadrática, D es un conjunto poliédrico, y $S_0 \neq \emptyset$ (comparar con el Ejercicio 3.1.11).

Teorema 9.2 (Convergencia lineal del método del gradiente proyectado). *Además de las hipótesis del Teorema 4.1.1, supongamos que el valor óptimo del problema (9.1) sea finito y valga la condición (9.14), con U definido en (9.15) y algunos $\delta > 0$ y $\gamma > 0$. Supongamos también que valga la condición de separación de superficies de nivel críticas.*

Entonces cualquier secuencia $\{x^k\}$ generada por el Algoritmo 4.1.1 converge a un punto estacionario del problema (9.1). La tasa de convergencia con respecto a la función es lineal, y con respecto a las variables la tasa es geométrica.

La demostración de este teorema puede ser hecha por la modificación relativamente obvia de la demostración del Teorema 3.1.5. Mencionemos apenas que aquí deben ser también utilizados los resultados de los Teoremas 1.3.1 y 1.3.7.

Cada iteración de un método del gradiente proyectado requiere el cálculo de proyecciones sobre el conjunto D (una vez, o más, dependiendo de la regla para la longitud de paso). Esto indica que el método sólo puede ser práctico cuando el cálculo de proyecciones tiene un costo computacional relativamente bajo. Por ejemplo, cuando D es un conjunto poliédrico, el problema de encontrar una proyección es de programación cuadrática (vea § 6.2), lo que es considerado aceptable. Difícilmente puede tener sentido utilizar técnicas de proyección en el caso más general, i.e., de restricciones no lineales. A veces, el cálculo de proyecciones no requiere resolución numérica de problemas de optimización, porque existen fórmulas explícitas.

Existen modificaciones de métodos del gradiente proyectado que requieren, en cada iteración, una proyección apenas. Por ejemplo, en vez del esquema (9.4) basado en el arco de proyección (9.5), podemos utilizar el intervalo

$$x^k(\alpha) = (1 - \alpha)x^k + \alpha P_D(x^k - \beta_k f'(x^k)).$$

Esto resulta en el esquema

$$x^{k+1} = (1 - \alpha_k)x^k + \alpha_k P_D(x^k - \beta_k f'(x^k)), \quad k = 0, 1, \dots, \quad (9.16)$$

donde $x^0 \in D$, los parámetros $\beta_k > 0$ pueden ser elegidos más o menos arbitrariamente (desde que $0 < c_1 \leq \beta_k \leq c_2$), y el parámetro de longitud de paso α_k es calculado por la regla de Armijo (9.6) con $\hat{\alpha} = 1$. Las reglas de minimización unidimensional pueden ser adaptadas análogamente.

Observamos que si $x^k \in D$ entonces, por la convexidad de D ,

$$d^k = P_D(x^k - \beta_k f'(x^k)) - x^k$$

es una dirección factible en el punto x^k con respecto al conjunto D y, en particular, $x^k(\alpha) = x^k + \alpha d^k \in D$ para todo $\alpha \in [0, 1]$. Este intervalo está ilustrado en la Figura 4.1.2.

Además de eso, por (9.7), d^k es una dirección de descenso de la función f en el punto x^k . Tenemos entonces una dirección de descenso que es factible. A partir de eso, es fácil probar que, si la secuencia $\{\beta_k\}$ es limitada inferiormente por un número positivo, este esquema posee convergencia global en el sentido del Teorema 4.1.1. Sin embargo, probar la tasa de convergencia lineal para este esquema ya no es posible, por lo menos bajo las hipótesis usuales.

La importancia teórica de métodos del gradiente proyectado consiste principalmente en el hecho de que varios otros métodos que generan iteraciones factibles y son métodos de descenso, pueden ser interpretados como versiones inexactas o modificadas de algún método del gradiente proyectado.

9.1.2. Direcciones factibles y métodos de descenso

Dada una aproximación x^k a la solución del problema, una idea natural consiste en definir una dirección que, al mismo tiempo, es factible en x^k con respecto al conjunto D y es de descenso para la función objetivo f . A propósito, un método de este tipo ya fue presentado arriba, como modificación (9.16) del método del gradiente proyectado. A continuación, consideraremos algunas otras posibilidades.

Primero, recordamos la noción de direcciones factibles (vea [12]).

Definición 9.1. Un vector $d \in \mathbb{R}^n$ se llama *dirección factible* en el punto $x \in D$ con respecto a D , si para todo $t > 0$ suficientemente pequeño se tiene que $x + td \in D$.

Recordamos también que el conjunto de todas las direcciones factibles en $x \in D$ con respecto a D es un cono que denotamos $V_D(x)$. Entonces, $d \in V_D(x)$ si, y solamente si, todo paso suficientemente corto a partir de x en

la dirección d resulta en un punto que pertenece a D . Tenemos que $0 \in V_D(x)$ trivialmente. Los dos resultados siguientes proporcionan condiciones suficientes para que una dirección dada sea factible. Las demostraciones de estos resultados están contenidas en las demostraciones de resultados más generales (sobre la caracterización de direcciones tangentes) en [12, Teorema 4.1.2].

Lema 9.2. Sea $D \subset \mathbb{R}^n$ un conjunto convexo. Entonces

$$y - x \in V_D(x) \quad \forall x, y \in D.$$

Lema 9.3. Sea

$$D = \{x \in \mathbb{R}^n \mid g(x) \leq 0\},$$

donde la función $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ es diferenciable en el punto $y \in D$. Entonces:

- (a) Para todo $d \in V_D(y)$ se tiene que $\langle g'_i(y), d \rangle \leq 0 \forall i \in I(y)$, donde $I(y) = \{i = 1, \dots, m \mid g_i(y) = 0\}$ es el conjunto de índices de las restricciones activas en y .
- (b) Si $d \in \mathbb{R}^n$ satisface $\langle g'_i(y), d \rangle < 0 \forall i \in I(y)$, se tiene que $d \in V_D(y)$.

Métodos de descenso pueden ser definidos para un problema general

$$\min f(x) \quad \text{sujeto a} \quad x \in D, \quad (9.17)$$

donde, en principio, el conjunto factible $D \subset \mathbb{R}^n$ no necesita ser ni convexo ni cerrado, y la función objetivo no necesita ser diferenciable. El esquema general es el siguiente:

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k \in D_f(x^k) \cap V_D(x^k), \quad k = 0, 1, \dots, \quad (9.18)$$

donde $x^0 \in D$, y los parámetros de longitud de paso $\alpha_k > 0$ tienen que satisfacer, por lo menos, las condiciones

$$f(x^{k+1}) < f(x^k), \quad x^{k+1} \in D. \quad (9.19)$$

Como $d^k \in D_f(x^k) \cap V_D(x^k)$ por la definición, las condiciones (9.19) serán satisfechas para todo $\alpha_k > 0$ suficientemente pequeño. Entendemos que cuando $D_f(x^k) \cap V_D(x^k) = \emptyset$, el método para. Así, se está realizando un descenso para superficies de nivel de la función objetivo con valores cada vez más bajos, manteniendo también la viabilidad. Cada método específico es caracterizado por la manera concreta de la elección de la dirección d^k y del cálculo de la longitud de paso α_k en esta dirección. Para $D = \mathbb{R}^n$, el esquema (9.18), (9.19) coincide con el esquema general de los métodos de descenso para optimización irrestricta presentado en § 3.1.1.

Si D es un conjunto convexo y cerrado, la segunda condición en (9.19) es satisfecha para todo $\alpha \in [0, \hat{\alpha}_k]$, donde

$$0 < \hat{\alpha}_k = \sup\{\alpha \in \mathbb{R}_+ \mid x^k + \alpha d^k \in D\} \quad (9.20)$$

(si $\hat{\alpha}_k = +\infty$, la segunda condición en (9.19) es satisfecha para todo $\alpha_k \geq 0$). Para determinar α_k que garantice la disminución de la función objetivo f , pueden ser utilizadas las mismas técnicas de minimización unidimensional consideradas en § 3.1.1, llevando en cuenta la restricción adicional $\alpha_k \leq \hat{\alpha}_k$. Los cálculos son bien más simples cuando $\hat{\alpha}_k$ puede ser determinado explícitamente, o cuando una cota inferior para $\hat{\alpha}_k$ puede ser obtenida fácilmente.

A continuación, presentaremos dos ejemplos de métodos de descenso para problemas con restricciones simples.

9.1.3. Método del gradiente restringido. Método de Newton restringido

Supongamos que el conjunto factible D del problema (9.1), además de cerrado y convexo, sea también limitado (esta última hipótesis sirve para garantizar la existencia de soluciones en el subproblema (9.21) del método descrito a continuación). Los métodos del gradiente restringido son dados por la siguiente manera de elegir una dirección de descenso en el esquema (9.18): para $x^k \in D$, resolvemos el problema

$$\min \langle f'(x^k), x - x^k \rangle \quad \text{sujeto a} \quad x \in D, \quad (9.21)$$

obtenido por la linealización de la función objetivo del problema (9.1) en el punto x^k (la constante $f(x^k)$ es desconsiderada en (9.21)). Sea $\bar{x}^k \in D$ una solución del problema (9.21) y $v_k = \langle f'(x^k), \bar{x}^k - x^k \rangle$ el valor óptimo (una solución existe, por el Teorema de Weierstrass 1.1.1). Observamos que $v_k \leq \langle f'(x^k), x^k - x^k \rangle = 0$, porque $x^k \in D$. Si $v_k = 0$, tenemos que

$$\langle f'(x^k), x - x^k \rangle \geq v_k = 0 \quad \forall x \in D,$$

i.e., x^k es un punto estacionario del problema (9.1) (vea (9.2)). En este caso, el método para. Si $v_k < 0$, por los Lemas 3.1.1 y 4.1.2, para la dirección $d^k = \bar{x}^k - x^k$ tenemos que $d^k \in D_f(x^k) \cap V_D(x^k)$. Tal dirección d^k es llamada *anti-gradiente restringido* de la función f en el punto x^k con respecto al conjunto D .

Es fácil ver que para esta elección de d^k , el valor de $\hat{\alpha}_k$ definido en (9.20) es igual a 1. Así el cálculo de la longitud de paso α_k queda facilitado.

Para métodos del gradiente restringido pueden ser obtenidos resultados análogos a aquellos del Teorema 4.1.1 (vea [4]). Además de eso, bajo la hipótesis adicional de que f sea convexa en D , puede ser probada convergencia aritmética (vea [22]), que garantiza una tasa apenas sublineal. Siendo una extensión obvia del método del gradiente para el caso irrestricto, este algoritmo no es rápido.

Es claro también que métodos de este tipo sólo pueden tener alguna utilidad cuando la resolución de subproblemas de forma (9.21) con función objetivo lineal sea fácil. Si D es un conjunto poliédrico, (9.21) es un problema de programación lineal, vea § 6.1, lo que es un problema simple.

A pesar de la relativamente pequeña área de aplicación y de la lenta convergencia, los métodos del gradiente restringido tienen un cierto interés teórico por consistir en una implementación (sin embargo, bastante simple) de la importante idea de linealización de las funciones que definen un problema de optimización. Una implementación más adecuada de esta idea será presentada en § 4.2 para problemas con restricciones de desigualdad, donde tanto la función objetivo como las restricciones serán linealizadas en cada iteración.

Otra idea natural es utilizar, en vez de la aproximación lineal, la aproximación cuadrática de la función objetivo. Esquemas de este tipo se llaman *métodos de Newton restringido*, donde en (9.18) tenemos $d^k = \bar{x}^k - x^k$ y $\bar{x}^k$ es una solución del problema

$$\min \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle f''(x^k)(x - x^k), x - x^k \rangle \quad \text{sujeto a } x \in D. \quad (9.22)$$

Cuando D es un conjunto poliédrico, (9.22) es un problema de programación cuadrática (vea § 6.2). En otros casos (i.e., de restricciones no lineales), la resolución de (9.22) puede no ser mucho más fácil que la resolución del problema original (9.1), lo que torna el método poco atractivo. Para simplificar el subproblema, parece natural combinar la aproximación de segunda orden de la función objetivo con la linealización de las restricciones. Sin embargo, como veremos más adelante, en este caso es recomendable utilizar otro término cuadrático en la función objetivo de los subproblemas. Para garantizar convergencia global, en principio podemos utilizar (en vez de $f''(x^k)$) hasta una matriz definida positiva cualquiera. Pero para conseguir convergencia local rápida, la matriz en cuestión tiene que incorporar la información de segunda orden tanto sobre la función objetivo como sobre las restricciones del problema. Métodos de este tipo son bien eficientes. Ellos se llaman de *programación cuadrática secuencial* y serán presentados en § 4.6.

9.2. Métodos de direcciones factibles

En cada iteración de los métodos considerados en § 4.1, el conjunto factible del problema no es aproximado/simplificado de manera alguna. En métodos del gradiente proyectado, el conjunto aparece en la operación de proyección. En métodos del gradiente y de Newton restringidos, el conjunto factible original es pasado directamente para los subproblemas. Es claro que eso sólo puede tener sentido computacional cuando el conjunto en cuestión es bien simple.

Para problemas más complejos, es razonable intentar utilizar aproximaciones locales de todos los datos del problema. Esta es la idea básica de los *métodos de direcciones factibles*, que son métodos de descenso para problemas con restricciones de desigualdad. Consideraremos entonces el problema

$$\min f(x) \quad \text{sujeto a } x \in D = \{x \in \mathbb{R}^n \mid g(x) \leq 0\}, \quad (9.23)$$

donde las funciones $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son diferenciables.

De § 4.1.2, recordamos el esquema general de los métodos de descenso para problemas con restricciones:

$$x^{k+1} = x^k + \alpha_k d^k, \quad d^k \in D_f(x^k) \cap V_D(x^k), \quad k = 0, 1, \dots, \quad (9.24)$$

donde $x^0 \in D$, y los parámetros de longitud de paso $\alpha_k > 0$ son calculados para satisfacer, por lo menos, la condición

$$f(x^{k+1}) < f(x^k), \quad x^{k+1} \in D. \quad (9.25)$$

Resaltamos que, en el caso de restricciones de igualdad no lineales, en situaciones típicas el cono de direcciones factibles con respecto al conjunto en cuestión es vacío ([12, § 1.4]). Es por eso que el desarrollo a seguir es hecho para restricciones de desigualdad. El método puede ser extendido fácilmente al caso en que hay restricciones de igualdad, desde que ellas sean lineales.

La realización básica de los métodos de direcciones factibles consiste en la elección siguiente de la dirección en (9.24). Para un $x^k \in D$ dado, resolvemos el problema

$$\min \max \left\{ \langle f'(x^k), d \rangle; \max_{i \in I_k} \langle g'_i(x^k), d \rangle \right\} \quad \text{sujeto a} \quad \|d\|_\infty \leq 1,$$

donde $I_k = I(x^k) = \{i = 1, \dots, m \mid g_i(x^k) = 0\}$ es el conjunto de los índices de las restricciones del problema (9.23) que son activas en el punto x^k . Este problema puede ser resuelto como el problema de programación lineal

$$\min t \quad \text{sujeto a} \quad (t, d) \in U_k, \quad (9.26)$$

$$U_k = \left\{ u = (t, d) \in \mathbb{R} \times \mathbb{R}^n \mid \begin{array}{l} \langle f'(x^k), d \rangle \leq t, \\ \langle g'_i(x^k), d \rangle \leq t, \quad i \in I_k, \\ -1 \leq d_j \leq 1, \quad j = 1, \dots, n. \end{array} \right\}. \quad (9.27)$$

En la definición del conjunto U_k , las restricciones $-1 \leq d_j \leq 1$ sirven para garantizar que el subproblema (9.26), (9.27), tenga una solución. Con efecto, $(0, 0) \in U_k$, i.e., $U_k \neq \emptyset$, y el hecho de que (9.26), (9.27), posee una solución se sigue del Corolario 1.1.1.

Sea $u^k = (t_k, d^k)$ una solución de (9.26), (9.27). Claramente, $t_k \leq 0$, porque en el punto factible $(0, 0)$ la función objetivo del problema (9.26), (9.27), tiene valor nulo. Si $t_k = 0$, el método para.

Proposición 9.1. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ funciones diferenciables en el punto $x^k \in D$, donde el conjunto D es definido en (9.23). Supongamos que el punto x^k satisfaga la condición de regularidad de Mangasarian-Fromovitz (1.16).

Si $(0, d^k)$ es una solución del problema (9.26), (9.27), con $I_k = I(x^k)$, entonces x^k es un punto estacionario del problema (9.23).

Prueba. Recordamos que la condición de Mangasarian-Fromovitz, en el caso en consideración, consiste en la existencia de $\bar{d} \in \mathbb{R}^n$ tal que

$$\langle g'_i(x^k), \bar{d} \rangle < 0 \quad \forall i \in I(x^k) = I_k. \quad (9.28)$$

Si el punto $(0, d^k)$ es una solución del problema (9.26), (9.27), el punto $(0, 0)$ también es solución de este problema (porque él es factible y proporciona el mismo valor de la función objetivo). Como las restricciones de este problema son lineales, podemos aplicar el Teorema 1.2.3 en el punto $(0, 0)$. Así obtenemos que existen $\mu_0 \geq 0$ y $\mu_i \geq 0$, $i \in I_k$, tales que

$$1 - \mu_0 - \sum_{i \in I_k} \mu_i = 0, \quad (9.29)$$

$$\mu_0 f'(x^k) + \sum_{i \in I_k} \mu_i g'_i(x^k) = 0. \quad (9.30)$$

Supongamos que $\mu_0 = 0$. En este caso, (9.29) implica en que entre los números $\mu_i \geq 0$, $i \in I_k$, hay algunos estrictamente positivos. Multiplicando ambos lados de la ecuación (9.30) por $\bar{d}$ y utilizando (9.28), obtenemos la contradicción

$$0 = \sum_{i \in I_k} \mu_i \langle g'_i(x^k), \bar{d} \rangle < 0.$$

Concluimos que $\mu_0 > 0$.

Dividiendo ahora ambos lados de (9.30) por μ_0 , obtenemos

$$f'(x^k) + \sum_{i \in I_k} \bar{\mu}_i g'_i(x^k) = 0,$$

donde $\bar{\mu}_i = \mu_i / \mu_0 \geq 0$, $i \in I_k$. Por lo tanto, x^k es un punto estacionario del problema (9.23). ■

Ahora, si $t_k < 0$, utilizando los Lemas 3.1.1 y 4.1.3 concluimos que $d^k \in D_f(x^k) \cap V_D(x^k)$. De hecho, la naturaleza del subproblema (9.26), (9.27), es la siguiente: a medida que t disminuye, el componente d del punto factible (t, d) de este subproblema obtiene características más claras de una dirección factible de descenso. En particular, cuando $I(x^k) = \emptyset$, d^k queda en la dirección del anti-gradiente de la función f en el punto x^k .

El cálculo de los parámetros de longitud de paso α_k puede ser hecho por las técnicas de § 3.1.1, llevando en cuenta la restricción adicional $\alpha_k \leq \hat{\alpha}_k$, donde $\hat{\alpha}_k > 0$ es el mayor número satisfaciendo $x^k + \alpha d^k \in D \quad \forall \alpha \in [0, \hat{\alpha}_k]$. Esta

restricción garantiza la validez de la segunda condición en (9.25). Si el conjunto D es convexo (por ejemplo, si las funciones g_i , $i = 1, \dots, m$, son convexas), el número $\hat{\alpha}_k$ es dado por la fórmula

$$\hat{\alpha}_k = \sup\{\alpha \in \mathbb{R}_+ \mid x^k + \alpha d^k \in D\}.$$

Pero aun en el caso no convexo, $\hat{\alpha}_k$ puede ser calculado o estimado solamente en casos bien especiales; vea § 4.1.2. Cuando el conjunto D no es convexo, difícilmente puede existir una estrategia razonable de cálculo de longitud de paso para esquemas de este tipo.

Más aún, mismo suponiendo que $\hat{\alpha}_k$ sea conocido para todo k , e incluso bajo hipótesis muy fuertes, los métodos de direcciones factibles presentados arriba pueden no poseer convergencia garantizada. La dificultad principal, tanto en el sentido práctico como en el teórico, es la siguiente. Para $I_k = I(x^k)$, el subproblema (9.26), (9.27), no toma en cuenta las restricciones del problema original (9.23) que no son activas en x^k , pero son "casi-activas" en este punto. Esto puede hacer con que, para la dirección d^k elegida, el valor de $\hat{\alpha}_k$ sea muy pequeño, mismo que existan otras direcciones factibles y de descenso que permitan pasos mucho más largos. La disminución indebida de los valores de $\hat{\alpha}_k$ puede resultar en la convergencia del método a puntos no estacionarios del problema (vea [2]).

La idea de tener en cuenta restricciones casi-activas puede ser implementada de la manera siguiente. Fijamos $\delta_0 > 0$ y $\theta \in (0, 1)$. Para todo k , definimos

$$I_k = \{i = 1, \dots, m \mid g_i(x^k) \geq -\delta_k\}.$$

Si para la solución $u^k = (t_k, d^k)$ del subproblema correspondiente (9.26), (9.27), tenemos que $t_k \leq -\delta_k$, aceptamos d^k como la dirección factible de descenso. Caso contrario, cambiamos δ_k por $\theta\delta_k$ y repetimos el cálculo de d^k , con el nuevo I_k . Esta modificación, con la elección adecuada de los parámetros involucrados, ya permite probar convergencia al conjunto de puntos estacionarios del problema.

Notemos que, como los métodos del gradiente proyectado, métodos de descenso con direcciones factibles necesitan un punto inicial factible. En el caso de un conjunto factible de estructura simple, como en § 4.1, el cálculo de un punto $x^0 \in D$ no presenta dificultades. En casos más generales, pueden ser utilizados algunos métodos especiales, desarrollados para este fin [4]. Sin embargo, en general, la tarea de computar un punto factible puede ser casi tan difícil como la resolución del problema original (9.23).

Nosotros no vamos a presentar más detalles sobre algoritmos de direcciones factibles, porque aun siendo naturales y de cierto interés teórico, estos métodos no pueden ser considerados como un abordaje correcto al caso de restricciones no lineales. Además de eso, ellos no pueden ser aplicados cuando hay restricciones no lineales de igualdad. A continuación, vamos a concentrarnos en la descripción de algunos métodos que son más eficientes y más utilizados en la práctica computacional.

9.3. Métodos de penalización

La penalización tiene por objetivo aproximar un problema con restricciones por una secuencia de problemas irrestrictos, teniendo en vista la aplicación de técnicas computacionales ya desarrolladas. La idea de convertir un problema de optimización con restricciones en un problema (o una secuencia de problemas) sin restricciones es natural y es usada en la construcción de varios algoritmos.

En la penalización externa, a la función objetivo se le añade un término cuyo valor es nulo en todos los puntos factibles y es positivo para los no factibles. En general, la solución de un problema así penalizado está fuera del conjunto factible, lo que explica el nombre de penalización "externa". Para obtener convergencia a la solución del problema original (que, obviamente, tiene que ser factible), el parámetro escalar que multiplica el término penalizador tiene que crecer a más infinito. Una excepción importante a esta regla es la *penalización exacta*, donde un valor del parámetro penalizador suficientemente grande (pero fijo) permite la recuperación exacta de una solución del problema original. Típicamente, esto solo es posible a costa de la utilización de términos penalizadores no diferenciables. La penalización exacta será presentada un poco más adelante, en § 4.3.2.

En la penalización interna, a la función objetivo se le añade un término cuyo valor tiende a más infinito cuando los puntos factibles se aproximan a la frontera del conjunto factible del problema. Tenemos entonces una "barrera" que no permite a las soluciones de problemas así penalizados dejar el interior del conjunto factible. Esto explica el nombre de penalización "interna" o, también, de métodos de "barreras". Para obtener convergencia a la solución del

problema original (que, típicamente, está justamente en la frontera del conjunto factible), el parámetro escalar que multiplica el término penalizador tiene que decrecer a cero.

Las técnicas de penalización son bien simples y universales. Sin embargo, ellas no son muy usadas en forma pura, debido a la necesidad de la utilización de valores del parámetro penalizador muy grandes (en el caso de la penalización externa) o muy pequeños (en el caso de la penalización interna), lo que tiende a provocar inestabilidad numérica. Mismo así, la penalización tiene una cierta importancia histórica, y es útil para el entendimiento de estrategias más sofisticadas. Además de eso, la penalización exacta proporciona una de las técnicas más eficientes para la globalización de métodos de programación cuadrática secuencial, que será desarrollada en § 4.6.

9.3.1. Penalización externa

Consideremos un problema en formato general

$$\min f(x) \quad \text{sueto a } x \in D, \quad (9.31)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $D \subset \mathbb{R}^n$ es un conjunto cualquiera. Como ya fue anunciado, introduciremos un término que tiene por objetivo penalizar la violación de las restricciones, i.e., una función $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$, continua en $\mathbb{R}^n$, tal que

$$\psi(x) = \begin{cases} 0 & \forall x \in D, \\ > 0 & \forall x \in \mathbb{R}^n \setminus D. \end{cases} \quad (9.32)$$

Por ejemplo, si

$$D = \{x \in \mathbb{R}^n \mid h(x) = 0, g(x) \leq 0\}, \quad (9.33)$$

es conveniente definir

$$\Psi : \mathbb{R}^n \rightarrow \mathbb{R}^l \times \mathbb{R}^m,$$

$$\Psi(x) = (h(x), (\max\{0, g_1(x)\}, \dots, \max\{0, g_m(x)\})), \quad (9.34)$$

$$\psi(x) = \|\Psi(x)\|^p, \quad x \in \mathbb{R}^n, \quad (9.35)$$

donde $p > 0$. En (9.35), además de la norma Euclidiana $\|\cdot\| = \|\cdot\|_2$, pueden ser utilizadas también $\|\cdot\|_p$, o $\|\cdot\|_\infty$ (para $p \in (0, 1)$, $\|\cdot\|_p$ no define una norma, pero en este contexto es conveniente utilizar la misma notación). Estas elecciones resultan en

$$\psi(x) = \|\Psi(x)\|_p^p = \|h(x)\|_p^p + \sum_{i=1}^m (\max\{g_i(x), 0\})^p, \quad (9.36)$$

o

$$\psi(x) = \|\Psi(x)\|_\infty^p = (\max\{\|h(x)\|_\infty, 0, g_1(x), \dots, g_m(x)\})^p. \quad (9.37)$$

Notamos que para h y g diferenciables, la función ψ definida por (9.36) es diferenciable cuando $p > 1$, y no es diferenciable en caso contrario. La función ψ dada por (9.37) no es diferenciable, mismo cuando h y g son diferenciables. Como veremos más adelante, existen algunas diferencias importantes entre propiedades de penalizadores diferenciables y no diferenciables.

Consideremos una familia de problemas irrestrictos

$$\min \varphi(x; c), \quad x \in \mathbb{R}^n, \quad (9.38)$$

donde

$$\varphi(\cdot; c) : \mathbb{R}^n \rightarrow \mathbb{R}, \quad \varphi(x; c) = f(x) + c\psi(x), \quad (9.39)$$

y $c > 0$ es el parámetro penalizador.

La idea es que en la medida en que el valor de c aumenta, la violación de las restricciones se vuelve cada vez más cara. Podemos esperar, entonces, que las soluciones de los problemas irrestrictos (9.38) se aproximen al conjunto factible cuando $c \rightarrow +\infty$ y sus puntos de acumulación resuelvan el problema original (9.31).

Algoritmo 9.2 (Método de penalización externa). Elegir una función $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$, penalizador externo para el conjunto D . Elegir $c_0 > 0$. Tomar $k := 0$.

1. Calcular $x^k = x(c_k)$, una solución del problema (9.38), donde la función objetivo es dada por la fórmula (9.39) con $c = c_k$.
2. Elegir $c_{k+1} > c_k$, tomar $k := k + 1$. Retornar al Paso 1.

Mencionamos que, por razones obvias, es natural utilizar el punto x^{k-1} como punto inicial del método aplicado para minimizar la función $\varphi(\cdot; c_k)$ en la iteración k .

Notemos que la mayoría de los resultados de convergencia de métodos de este tipo se refiere a la secuencia de soluciones globales de los problemas (9.38), suponiendo que ellas existan. Por lo tanto, fuera del caso convexo, la aplicación de métodos de penalización puros no viene con convergencia garantizada, ya que en el caso no convexo no hay cómo calcular soluciones globales. El asunto de la utilización de soluciones locales será considerado también, más adelante.

A continuación, veremos algunos ejemplos de aplicación del Algoritmo 4.3.1.

Ejemplo 9.1. Consideremos el problema

$$\min x_1^2 - x_2 \quad \text{sujeto a} \quad x_1 + x_2 - 1 = 0, \quad x_1 \geq 0.$$

Este es un problema de programación convexa, y la única solución es $\bar{x} = (0, 1)$.

Eligiendo el término penalizador (9.36) con $p = 2$, obtenemos

$$\varphi(x; c) = x_1^2 - x_2 + c(x_1 + x_2 - 1)^2 + c(\max\{-x_1, 0\})^2.$$

Como es fácil ver, esta función es convexa, diferenciable, y su (único) minimizador (global) irrestricto es caracterizado por el sistema de ecuaciones

$$0 = \varphi'(x; c) = \begin{pmatrix} 2x_1 + 2c(x_1 + x_2 - 1) - 2c \max\{-x_1, 0\} \\ -1 + 2c(x_1 + x_2 - 1) \end{pmatrix},$$

donde $\varphi'(x; c)$ es el gradiente de $\varphi(\cdot; c)$ en x (creemos que no debe haber confusión con la notación de la derivada direccional). De donde obtenemos que

$$2x_1 + 1 - 2c \max\{-x_1, 0\} = 0.$$

La última ecuación no posee solución si $x_1 \geq 0$. Resolviendo el sistema para $x_1 < 0$, obtenemos

$$x_1(c) = -1/(2(1+c)), \quad x_2(c) = 1 + 1/(2c) + 1/(2(1+c)).$$

En particular, tenemos que

$$x(c) = (x_1(c), x_2(c)) \rightarrow (0, 1) = \bar{x} \quad (c \rightarrow +\infty).$$

Observemos que para todo $c > 0$, el punto $x(c)$ no es factible. La Figura 4.3.4 ilustra la trayectoria $x(c)$ de las soluciones de los problemas penalizados.

El ejemplo de arriba muestra que, en general, las soluciones de problemas penalizados no son puntos factibles del problema original y, por lo tanto, para métodos de este tipo solo podemos esperar convergencia asintótica. El ejemplo siguiente muestra que, en principio, es posible que alguna solución del problema penalizado sea factible y que, en este caso, ella es la solución del problema original. Resaltamos, no obstante, que tal situación es bastante atípica en el caso de la utilización de penalizadores diferenciables.

Ejemplo 9.2. Consideremos el problema

$$\min x^2 \quad \text{sujeto a} \quad x \geq -1.$$

La solución de este problema es $\bar{x} = 0$.

Eligiendo el término penalizador (9.36) con $p = 2$, obtenemos

$$\varphi(x; c) = x^2 + c(\max\{-x - 1, 0\})^2.$$

Como es fácil ver, esta función es convexa, diferenciable, y su (único) minimizador (global) irrestricto es caracterizado por

$$0 = \varphi'(x; c) = 2x - 2c \max\{-x - 1, 0\}.$$

La única solución de esta ecuación es $x(c) = 0$. Observemos que $x(c)$ es un punto factible y que $x(c) = \bar{x}$.

A continuación, probaremos las propiedades de convergencia del Algoritmo 4.3.1, ya observadas en los Ejemplos 4.3.1 y 4.3.2.

Proposición 9.2. Sea $\{x^k\}$ una secuencia generada por el Algoritmo 4.3.1, donde x^k es una solución global de (9.38) con $c = c_k$. Entonces, para todo k , se tiene que

$$\varphi(x^{k+1}; c_{k+1}) \geq \varphi(x^k; c_k), \quad (9.40)$$

$$\psi(x^{k+1}) \leq \psi(x^k), \quad (9.41)$$

$$f(x^{k+1}) \geq f(x^k). \quad (9.42)$$

Prueba. Por la optimalidad de x^k en (9.38) con $c = c_k$, tenemos que

$$\begin{aligned} \varphi(x^k; c_k) &\leq \varphi(x^{k+1}; c_k) \\ &= f(x^{k+1}) + c_k \psi(x^{k+1}) \\ &\leq f(x^{k+1}) + c_{k+1} \psi(x^{k+1}) \\ &= \varphi(x^{k+1}; c_{k+1}) \\ &\leq \varphi(x^k; c_{k+1}), \end{aligned} \quad (9.43)$$

donde también utilizamos que $c_{k+1} > c_k$ y $\psi(x^{k+1}) \geq 0$. Acabamos de mostrar (9.40).

De (9.43), tenemos

$$\begin{aligned} f(x^k) + c_k \psi(x^k) &\leq f(x^{k+1}) + c_k \psi(x^{k+1}), \\ f(x^{k+1}) + c_{k+1} \psi(x^{k+1}) &\leq f(x^k) + c_{k+1} \psi(x^k). \end{aligned}$$

Sumando las dos últimas desigualdades, obtenemos

$$(c_k - c_{k+1})\psi(x^k) \leq (c_k - c_{k+1})\psi(x^{k+1}),$$

de donde, teniendo en cuenta que $c_{k+1} > c_k$, se sigue (9.41).

Ahora, utilizando (9.41) y (9.43), de

$$\begin{aligned} f(x^k) + c_k \psi(x^k) &\leq f(x^{k+1}) + c_k \psi(x^{k+1}) \\ &\leq f(x^{k+1}) + c_k \psi(x^k), \end{aligned}$$

obtenemos (9.42). ■

El resultado siguiente prueba la convergencia asintótica del Algoritmo 4.3.1, además de mostrar que, en general, los puntos x^k generados no son factibles. Con efecto, si el método genera un punto factible, él ya es una solución del problema original. No obstante, es claro que tal situación no puede ser esperada en general.

Teorema 9.3 (Convergencia global del método de penalización externa). Sea $\{x^k\}$ una secuencia generada por el Algoritmo 4.3.1, donde x^k es una solución global de (9.38) con $c = c_k$. Entonces $x^k \in D$ si, y solamente si, x^k es una solución global del problema (9.31).

Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $\psi : \mathbb{R}^n \rightarrow \mathbb{R}_+$ funciones continuas en $\mathbb{R}^n$, y sea $\bar{v} > -\infty$ el valor óptimo del problema (9.31). Si $c_k \rightarrow +\infty$ ($k \rightarrow \infty$), entonces todo punto de acumulación de la secuencia $\{x^k\}$ es una solución global del problema (9.31).

Prueba. Primero, es fácil ver que para todo punto $x \in D$,

$$\begin{aligned} f(x^k) &\leq f(x^k) + c_k \psi(x^k) \\ &= \varphi(x^k; c_k) \\ &\leq \varphi(x; c_k) \\ &= f(x), \end{aligned}$$

donde utilizamos que $c_k > 0$, $\psi(x^k) \geq 0$, que x^k es una solución global de (9.38) con $c = c_k$, y que $\psi(x) = 0$ para todo $x \in D$. Concluimos que, para todo k ,

$$f(x^k) \leq \varphi(x^k; c_k) \leq \bar{v} = \inf_{x \in D} f(x). \quad (9.44)$$

Si $x^k \in D$, obtenemos entonces que x^k es una solución del problema (9.31).

Por la Proposición 4.3.1, la secuencia $\{\varphi(x^k; c_k)\}$ es no decreciente. Por (9.44), ella es limitada superiormente por $\bar{v}$. Luego, ella converge y se tiene que

$$\lim_{k \rightarrow \infty} \varphi(x^k; c_k) = \lim_{k \rightarrow \infty} (f(x^k) + c_k \psi(x^k)) \leq \bar{v}. \quad (9.45)$$

Sea $\bar{x}$ un punto de acumulación de la secuencia $\{x^k\}$, $\{x^{k_j}\} \rightarrow \bar{x}$ ($j \rightarrow \infty$). Por la continuidad de f , tenemos que $f(x^{k_j}) \rightarrow f(\bar{x})$ ($j \rightarrow \infty$). De (9.45), obtenemos entonces que

$$\lim_{j \rightarrow \infty} c_{k_j} \psi(x^{k_j}) \leq \bar{v} - f(\bar{x}).$$

De donde, como $c_k \rightarrow +\infty$ y $\psi(x^{k_j}) \geq 0$, se sigue que

$$\lim_{j \rightarrow \infty} \psi(x^{k_j}) = 0.$$

Por la continuidad de ψ , concluimos que $\psi(\bar{x}) = 0$, i.e., $\bar{x} \in D$.

Ahora, pasando al límite en (9.44), obtenemos

$$\lim_{j \rightarrow \infty} f(x^{k_j}) \leq \bar{v},$$

lo que (teniendo en cuenta que $\bar{x} \in D$), muestra que $\bar{x}$ es una solución de (9.31). ■

El Teorema 4.3.1 puede ser ligeramente generalizado en relación a las hipótesis de continuidad de las funciones f y ψ .

9.3.2. Penalización interna. Métodos de barreras

Los métodos de penalización interna (o métodos de barreras) abandonan por completo el enfoque de evaluar puntos no factibles y se diseñan para operar exclusivamente dentro del volumen permitido. Tratan problemas con desigualdades puras de la forma:

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid g(x) \leq 0\}, \quad (9.46)$$

donde las variables y las funciones obedecen las directrices topológicas de un sistema analítico de clase suave tal que asumiendo validaciones rigurosas topológicamente al sistema se exija la factibilidad estricta. Supondremos que el “interior” del conjunto factible es robusto y no vacío:

$$D^0 = \{x \in \mathbb{R}^n \mid g(x) < 0\} \neq \emptyset. \quad (9.47)$$

Supongamos, además, una condición analítica topológica estricta para el diseño robusto asintótico que garantiza la homogeneidad y continuidad en los bordes del problema:

$$\inf_{x \in D^0} f(x) = \inf_{x \in D} f(x) = \bar{v} > -\infty, \quad (9.48)$$

es decir, el ínfimo límite y asintótico aproximado analíticamente a lo largo y ancho evaluando el conjunto puro interior D^0 converge exactamente y topológicamente igual al valor óptimo global absoluto del problema. Esta hipótesis tiene por objetivo eliminar los casos patológicos donde una porción o lóbulo del conjunto factible está conectada únicamente por una línea de grosor cero (donde el interior estricto no puede acceder topológicamente).

La idea de los métodos de barrera es blindar la frontera $D \setminus D^0$ añadiendo un término matemático a la función objetivo cuyo valor analítico explote y tienda a más infinito (de forma asintótica paramétrica y continua) siempre y cuando cualquier trayectoria u optimizador algorítmico evalúe o intente empujar la secuencia de aproximación de iterados para que se acerquen iterativamente de forma crítica a las superficies o planos límite de corte de la frontera analítica y geométrica del problema.

Definición 9.2 (Función barrera). Una función escalar $\psi : D^0 \rightarrow \mathbb{R}_+$ se llama **barrera** para el conjunto D definido en (9.46), si ella es invariablemente y rigurosamente continua paramétricamente en el conjunto D^0 , y para toda secuencia limitante iterativa de puntos $\{x^k\} \in D^0$ tal que sus evaluaciones asintóticas reduzcan la holgura en un límite tal que $g_i(x^k) \rightarrow 0$ para algún componente vectorial o restricción $i \in \{1, \dots, m\}$, la evaluación rigurosa asintótica sobre el término analítico diverge explosivamente imponiendo la condición topológica extrema $\psi(x^k) \rightarrow +\infty$ cuando ($k \rightarrow \infty$).

Las elecciones algorítmicas más clásicas y de mayor interés computacional general son la **barrera logarítmica**:

$$\psi(x) = -\sum_{i=1}^m \log(-g_i(x)), \quad x \in D^0, \quad (9.49)$$

y la **barrera inversa** (o de Carroll):

$$\psi(x) = -\sum_{i=1}^m \frac{1}{g_i(x)}, \quad x \in D^0. \quad (9.50)$$

Consideremos una familia analítica y topológica de funciones agregadas y parametrizadas para establecer un marco irrestricto de búsqueda y convergencia global:

$$\varphi(\cdot; t) : D^0 \rightarrow \mathbb{R}, \quad \varphi(x; t) = f(x) + t\psi(x), \quad (9.51)$$

donde el escalar paramétrico continuo o estipulador de reducción limitante y asintótica $t > 0$ es el **parámetro de barrera**. Generamos así la familia de problemas o sub-problemas anidados:

$$\min \varphi(x; t) \quad \text{sueto a} \quad x \in D^0. \quad (9.52)$$

Podemos pensar en el problema de optimización en (9.52) estrictamente y puramente como un equivalente asintótico y de equivalencia analítica completa u operando a los esquemas de optimización paramétrica escalar de base algorítmica irrestricta. Es bien claro u obvio deducir lógicamente y a nivel de análisis numérico paramétrico asumiendo y deduciendo (ignorando topológicamente y por asunción matemática y completamente las formulaciones u opciones que nos impusiesen lógicamente la delimitación natural o acotación a las restricciones explícitas de la formulación escalar y minimización paramétrica general y si resolvemos paramétricamente):

$$\min_{x \in \mathbb{R}^n} \varphi(x; t),$$

aplicando cualquier método iterativo a partir de un punto inicial estricto en el dominio $x^0 \in D^0$, la curva o sucesión topológica general y algorítmica permanecerá anidada y blindada asintóticamente retenida dentro del interior topológico D^0 . Esto es garantizado algorítmica e innegablemente pues la formulación y explosión asintótica (barrera) evalúa con un repudio analítico extremo (con limitante $\varphi(\cdot; t) \rightarrow +\infty$) los entornos y puntos limitantes que rocen y violen la topología o superficie anclada y restrictiva al estar localizados de manera colindante o tocando a la frontera límite analítica topológica. Al ser el objetivo de los métodos de optimización y convergencia una búsqueda estricta de descenso acotado en la minimización o caída asintótica, el modelo computacional será invariablemente y puramente rebotado u obligado a retornar al interior por la repulsión matemática extrema operada.

Algoritmo 9.3 (El método de barreras). Elegir una función de la clase asintótica u operador general barrera estipulando en rigor una formulación limitante escalar topológicamente válida y evaluada $\psi : D^0 \rightarrow \mathbb{R}$ para conformar el recubrimiento interior de la frontera al evaluar de cerca al conjunto rígido topológicamente definido estipulado algebraicamente y restringido según el marco base acotado D . Definir un valor atenuante, el parámetro inicial o punto de arranque escalar analítico de penalización atenuante $t_0 > 0$ y tomar $k := 0$.

1. Calcular analíticamente el estimador paramétrico iterativo o solución convergente a un valor estacionario estipulado iterativamente por sub-cálculo riguroso, localizando y determinando en rigor y con precisión el punto $x^k \in D^0$ asumiéndose y comportándose iterativamente como una solución (aproximación garantizada a minimización asintótica incondicional o local de optimización) anidando sobre el parámetro al problema de frontera (9.52), donde el término de función objetivo agregado se estipula evaluando matemáticamente y rígidamente por la función barrera o modelo paramétrico topológico acotado de la formulación (9.51) sustituyendo el ponderador límite evaluando como atenuante el escalar $t = t_k$.
2. Elegir una cota de parámetro a un valor más pequeño estipulando la relajación de atenuación o límite $t_{k+1} < t_k$ acercando iterativamente su valor a cero y tomar $k := k + 1$. Retornar al Paso 1.

Observemos que, dada la naturaleza fundamental del análisis de las restricciones, el mínimo de una función objetivo suele localizarse analíticamente y forzosamente en las cotas, los bordes o descansando topológicamente a lo largo de las superficies y planos envolventes de la frontera estipulando el conjunto $D \setminus D^0$. Queda analíticamente claro y rigurosamente justificado desde un enfoque teórico global que para que estos métodos convergentes y sub-algorítmicos

en general aproximen el valor u óptimo riguroso y para que la secuencia de atenuación permita al iterado adherirse lentamente a la solución limítrofe original, es condición algorítmica y asintóticamente necesaria exigir sin concesión o limitación rigurosamente válida que la sucesión o decaimiento de los valores escalares estipulando y operados analíticamente en el parámetro atenuante descienda estrictamente a su cota final asintótica $t \rightarrow 0$. Esto permite menguar y evaporar analíticamente el efecto de penalización en los bordes internos, autorizando a que los sistemas o simuladores numéricos acerquen sistemáticamente la búsqueda de óptimos a los muros limitantes permitiendo u otorgando finalmente en la progresión la aproximación o llegada matemática formal topológicamente válida y esperada a los vectores limítrofes u óptimos reales.

Ejemplo 9.3 (Barrera Inversa en $\mathbb{R}$). Consideremos el problema geoméricamente simplificado:

$$\min x \quad \text{sujeto a} \quad x \geq 0.$$

La única solución global es el punto colindante al límite inferior o borde del intervalo analítico $\bar{x} = 0$.

Eligiendo la penalización por barrera inversa general paramétricamente escalar, formulada de acuerdo a las directrices algebraicas (9.50), instanciamos y armamos iterativamente el modelo irrestricto auxiliar topológicamente continuo y de descenso o minimización paramétrico analítico:

$$\varphi(x; t) = x + \frac{t}{x}, \quad t > 0.$$

Buscamos un mínimo en el espacio base del conjunto abierto interior o de factibilidad $D^0 = \{x \in \mathbb{R} \mid x > 0\}$. Anulando analíticamente su función derivada generalizada de parámetro escalar, y asumiendo una resolución paramétrica algorítmica del primer orden obtenemos rigurosamente:

$$0 = \varphi'(x; t) = 1 - \frac{t}{x^2}.$$

Despejando analíticamente las raíces admitidas asumiendo un iterado real (topológicamente admisible):

$$x(t) = \sqrt{t} \in D^0.$$

A medida que la regla o atenuación escalar avanza iterativamente o exige el decremento analítico paramétrico hacia asintotismo cero ($t \rightarrow 0$), el límite iterativo de las secuencias y funciones o trayectorias de optimización se rige innegablemente demostrando convergencia pura: $x(t) \rightarrow 0 = \bar{x}$.

Al igual que en el caso de la penalización externa, el éxito topológico final en los modelos anidados iterativos garantiza asintóticamente la minimización algorítmica.

Teorema 9.4 (Convergencia de los métodos de penalización interna). Sean las condiciones analíticas de continuidad y viabilidad garantizadas u operadas sobre $f: \mathbb{R}^n \rightarrow \mathbb{R}$ y $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$, definidas u operadas de manera continua y continua en general en las variables base y paramétricas asumiendo espacios euclidianos y conjuntos de optimización vectoriales estipulados y formulados analíticamente continuos en $\mathbb{R}^n$. Supongamos a manera de limitante que los conjuntos e iteraciones anclados topológicamente y evaluados en el conjunto u operando D y D^0 definido a priori en el contexto algorítmico asumiendo las cotas u operando (9.46) satisfaga de plano la asimetría topológica rigurosamente verificable de las condiciones interiores innegables y evaluando acotadas a lo ancho parametrizando o acotando (4.83) y la preservación o igualdad continua paramétrica (4.84).

Entonces todo punto o agrupación geométrica limitante conformando en conjunto rigurosamente a cualquier vector acumulativo asintótico de las sucesiones y curvas paramétricas estipuladas vectorialmente por la secuencia topológica de descenso limitante o convergente $\{x^k\}$, rigurosamente calculada de modo analítico computacional a nivel del algoritmo interno u Algoritmo 9.3, a lo largo de cuyas pautas el sub-iterador paramétrico y general de trayectoria pura acoplada converge o se genera estipulando explícita u orgánicamente donde y como x^k evalúa como solución de aproximación a mínimos y a puntos óptimos de resolución paramétrica analítica innegables como una solución limitante paramétricamente definida algorítmica global al descenso del problema (9.52) evaluando iterativamente al escalar limitador o parámetro atenuante estipulando la convergencia o descenso $t = t_k$ y $t_k \rightarrow 0$ al escalarlo al infinito iterativamente ($k \rightarrow \infty$), conforma, garantiza y es rigurosamente a efectos matemáticos comprobables como una o cualquier **solución y minimización convergente asintóticamente al punto óptimo algorítmico global** del marco o problema base paramétrico original.

Prueba. El bosquejo de la demostración asintótica se basa en que las soluciones $\{x^k\} \subset D^0$ fuerzan una sucesión de valores decrecientes $\{f(x^k)\}$ y valores crecientes para la barrera $\psi(x^k)$. Para cualquier punto y perturbación del interior (donde ψ es finita), la acotación de $\varphi(x^k; t_k)$ y el descenso del parámetro atenuante $t_k \rightarrow 0$ ahoga algebraicamente el término de la barrera, forzando a que los puntos de acumulación de f converjan rigurosamente e innegablemente al límite y valor óptimo inferior original $\bar{v}$ (limitante paramétrico base analizado mediante el axioma de acotamiento paramétrico y topológico). ■

9.4. Lagrangianas aumentadas y funciones de penalización exacta

Como se analizó en la sección de penalización externa cuadrática, una severa limitación práctica de dichos métodos radica en el mal condicionamiento numérico de la matriz Hessiana a medida que el parámetro de penalización $c \rightarrow +\infty$.

Una manera de evitar el crecimiento ilimitado del parámetro de penalización es añadir un término de penalización diferenciable (por ejemplo, cuadrático) a la Lagrangiana clásica del problema, en lugar de agregarlo únicamente a la función objetivo.

Consideraremos el problema de optimización con restricciones de igualdad:

$$\min f(x) \quad \text{sujeto a} \quad x \in D = \{x \in \mathbb{R}^n \mid h(x) = 0\}, \quad (9.53)$$

donde $f: \mathbb{R}^n \rightarrow \mathbb{R}$ y $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ son funciones diferenciables.

9.4.1. El Método de la Lagrangiana Aumentada

Introducimos una familia paramétrica de **Lagrangianas aumentadas** asociadas al problema (9.53):

$$\begin{aligned} L(x, \lambda; c) &= L(x, \lambda) + \frac{c}{2} \|h(x)\|^2 \\ &= f(x) + \langle \lambda, h(x) \rangle + \frac{c}{2} \|h(x)\|^2, \end{aligned} \quad (9.54)$$

donde $c \geq 0$ es un escalar de penalización. Notamos que la Lagrangiana clásica se recupera cuando $c = 0$, es decir, $L(x, \lambda) := L(x, \lambda; 0)$.

El problema original (9.53) es trivial y algebraicamente equivalente al problema modificado:

$$\min \left(f(x) + \frac{c}{2} \|h(x)\|^2 \right) \quad \text{sujeto a} \quad x \in D, \quad (9.55)$$

ya que el término penalizador se anula exactamente para todo punto factible. Desde esta perspectiva geométrica, la Lagrangiana aumentada (9.54) es simplemente la Lagrangiana clásica asociada al problema equivalente (9.55).

Nota: Propiedad Diferencial Fundamental

En la formulación de derivadas respecto a las variables primales, la evaluación sobre el conjunto factible D anula la contribución del gradiente de la penalización. Para todo $c \geq 0$, se cumple:

$$\begin{aligned} L'_x(x, \lambda; c) &= L'_x(x, \lambda) + c \cdot h'(x)^T h(x) \\ &= L'_x(x, \lambda) \quad \forall x \in D, \forall \lambda \in \mathbb{R}^l. \end{aligned}$$

En consecuencia, el conjunto de soluciones de la ecuación de primer orden $L'_x(x, \lambda; c) = 0$ coincide exactamente con los puntos estacionarios del sistema de Lagrange clásico del problema.

La ventaja topológica decisiva de esta formulación se refleja en las propiedades de segundo orden (la curvatura del subproblema irrestricto).

Teorema 9.5 (Suficiencia de Segundo Orden de la Lagrangiana Aumentada). Sean $f: \mathbb{R}^n \rightarrow \mathbb{R}$ e $h: \mathbb{R}^n \rightarrow \mathbb{R}^l$ funciones dos veces diferenciables en el punto $\bar{x} \in \mathbb{R}^n$. Sea $\bar{x}$ un punto estacionario del problema (9.53) que satisface la condición suficiente de segundo orden clásica, con multiplicador de Lagrange asociado $\bar{\lambda} \in \mathbb{R}^l$.

Entonces, para todo número de penalización c suficientemente grande ($c \geq \bar{c}$), la matriz Hessiana de la Lagrangiana aumentada:

$$L''_{xx}(\bar{x}, \bar{\lambda}; c) = L''_{xx}(\bar{x}, \bar{\lambda}) + c(h'(\bar{x}))^T h'(\bar{x}) \quad (9.56)$$

es **definida positiva**. En particular, $\bar{x}$ se convierte en un minimizador local estricto del problema irrestricto:

$$\min_{x \in \mathbb{R}^n} L(x, \bar{\lambda}; c). \quad (9.57)$$

Prueba. Bajo la condición de suficiencia de segundo orden del problema original, sabemos que la forma cuadrática $\langle L''_{xx}(\bar{x}, \bar{\lambda})d, d \rangle > 0$ para todo $d \in \ker h'(\bar{x}) \setminus \{0\}$.

Invocando el Lema de Debreu (Lema 6.2) de las herramientas algebraicas, identificamos la matriz $B = L''_{xx}$ y la matriz $A = h'(\bar{x})$. El Lema garantiza inmediatamente la existencia de una constante umbral $\bar{c} > 0$ tal que la suma matricial $B + cA^T A$ es definida positiva para todo $c \geq \bar{c}$. Al ser el gradiente nulo y la matriz Hessiana definida positiva, $\bar{x}$ es solución estricta de (9.57). ■

Este teorema sustenta el desarrollo del **Método de los Multiplicadores** (o método de la Lagrangiana Aumentada). Consiste en minimizar irrestrictamente la Lagrangiana aumentada con un parámetro c_k finito, y en lugar de hacer crecer $c_k \rightarrow \infty$, se actualiza de manera analítica la estimación del multiplicador dual λ^k .

Algoritmo 9.4 (Método de la Lagrangiana Aumentada (Método de los Multiplicadores)). Elegir un estimador inicial $\lambda^0 \in \mathbb{R}^l$ y un parámetro de penalización $c_0 > 0$. Tomar el contador $k := 0$.

1. **Fase Primal:** Calcular $x^k \in \mathbb{R}^n$ resolviendo (exacta o aproximadamente) el problema de optimización irrestricta:

$$\min_{x \in \mathbb{R}^n} L(x, \lambda^k; c_k),$$

donde la función a minimizar viene dada por (9.54).

2. **Fase Dual:** Actualizar el vector de multiplicadores de Lagrange utilizando la regla de actualización natural de primer orden (Regla de Hestenes-Powell):

$$\lambda^{k+1} = \lambda^k + c_k h(x^k). \quad (9.58)$$

3. **Fase de Penalización:** Elegir el siguiente peso penal $c_{k+1} \geq c_k$ (si el descenso en la factibilidad $\|h(x^k)\|$ no es suficiente, se incrementa c ; en caso contrario se mantiene constante). Tomar $k \leftarrow k + 1$ y retornar al Paso 1.

La justificación fundamental de la regla de actualización (9.58) proviene de la condición de estacionariedad del subproblema en el Paso 1. Dado que x^k minimiza la Lagrangiana aumentada, su gradiente se anula:

$$\begin{aligned} 0 &= \nabla_x L(x^k, \lambda^k; c_k) \\ &= f'(x^k) + h'(x^k)^\top \lambda^k + c_k h'(x^k)^\top h(x^k) \\ &= f'(x^k) + h'(x^k)^\top (\lambda^k + c_k h(x^k)). \end{aligned}$$

Si definimos $\lambda^{k+1} = \lambda^k + c_k h(x^k)$, observamos que x^k y λ^{k+1} satisfacen la ecuación estacionaria de la Lagrangiana clásica:

$$f'(x^k) + h'(x^k)^\top \lambda^{k+1} = 0.$$

Si la trayectoria x^k converge a una solución $\bar{x}$, entonces forzosamente el multiplicador construido λ^{k+1} convergerá al multiplicador exacto $\bar{\lambda}$.

Teorema 9.6 (Convergencia Local del Método de los Multiplicadores). Bajo las hipótesis de la condición de independencia lineal (LICQ) y la condición suficiente de segunda orden en la solución exacta $\bar{x}$, existe un umbral $\bar{c} \geq 0$ tal que si la penalización permanece fija $c_k = c > \bar{c}$, la iteración dual generada por:

$$\lambda^{k+1} = \lambda^k + c \cdot h(x(\lambda^k, c))$$

converge **linealmente** al multiplicador exacto $\bar{\lambda}$. Además, si la secuencia de penalizaciones cumple $c_k \rightarrow \infty$, la tasa de convergencia local sobre las variables primales y duales es **superlineal**.

Esta propiedad excepcional garantiza que no es obligatorio que el parámetro de penalización c_k explote asintóticamente hacia $+\infty$ para lograr la convergencia exacta. Un valor de c lo suficientemente alto (pero estático) ancla la concavidad local permitiendo que la iteración dual atrape al óptimo, erradicando los problemas agudos de mal condicionamiento en la resolución irrestricta del Paso 1.

9.4.2. Extensión a restricciones mixtas

En el caso general con restricciones mixtas (igualdades $h(x) = 0$ y desigualdades $g(x) \leq 0$), el método se extiende recurriendo teóricamente al concepto de variables de holgura. Las restricciones $g_i(x) \leq 0$ se transforman en igualdades $g_i(x) + t_i^2 = 0$.

Al realizar la minimización analítica exacta respecto al vector de holgura t , la variable auxiliar desaparece algebraicamente y la actualización dual para los multiplicadores de desigualdad $\mu^k \geq 0$ toma la forma iterativa acotada de la proyección sobre el ortante positivo:

$$\mu_i^{k+1} = \max\{0, \mu_i^k + c_k g_i(x^k)\}, \quad i = 1, \dots, m. \quad (9.59)$$

Si el argumento escalar resulta negativo, la restricción se considera inactiva y el multiplicador colapsa exactamente a 0 de acuerdo con la teoría de holgura complementaria KKT, manteniendo la integridad rigurosa de las condiciones de optimalidad.

9.5. Programación Cuadrática Secuencial (SQP)

Como su nombre indica, los métodos de Programación Cuadrática Secuencial (SQP, por sus siglas en inglés: *Sequential Quadratic Programming*) consisten en la resolución de una sucesión de problemas de programación cuadrática, que aproximan en cada iteración la topología local del problema no lineal subyacente.

Un problema de programación cuadrática (minimizar una función cuadrática bajo restricciones afines) puede ser resuelto eficientemente de manera analítica o con algoritmos de complejidad polinómica finita. Esta estrategia es el generalizador natural de la idea del método de Newton clásico para problemas con restricciones.

9.5.1. El subproblema SQP general

Dada una aproximación del iterado primal x^k , y sus multiplicadores duales asociados λ^k y μ^k , la función objetivo se modela como una aproximación de Taylor de segundo orden y las restricciones (igualdad h y desigualdad g) se relajan mediante expansiones afines de primer orden.

El subproblema de programación cuadrática estándar para determinar la dirección de búsqueda $d \in \mathbb{R}^n$ se formula explícitamente como:

$$\min_{d \in \mathbb{R}^n} \langle f'(x^k), d \rangle + \frac{1}{2} \langle H_k d, d \rangle \quad (9.60)$$

sueto a las restricciones linealizadas que definen el poliedro de avance D_k :

$$h(x^k) + J_h(x^k)d = 0, \quad (9.61)$$

$$g(x^k) + J_g(x^k)d \leq 0. \quad (9.62)$$

El bloque analítico crítico recae sobre la construcción y determinación de la matriz simétrica de curvatura $H_k \in \mathbb{R}^{n \times n}$. Un análisis puramente geométrico podría sugerir usar $H_k = \nabla^2 f(x^k)$. Sin embargo, dicha elección omite completamente la aceleración centrípeta y la curvatura no lineal que dictan las fronteras del conjunto factible D .

La justificación Newtoniana formal exige que la curvatura global considere simultáneamente la topología de la función y de las restricciones, siendo la matriz de diseño óptimo asintótica:

$$H_k = \nabla_{xx}^2 L(x^k, \lambda^k, \mu^k), \quad (9.63)$$

donde L es la función Lagrangiana clásica.

Algoritmo 9.5 (El método SQP general). Elegir un punto de partida $(x^0, \lambda^0, \mu^0) \in \mathbb{R}^n \times \mathbb{R}^l \times \mathbb{R}_+^m$ y una matriz de curvatura H_0 . Tomar $k := 0$.

1. Calcular la dirección óptima $d^k \in \mathbb{R}^n$ resolviendo el programa cuadrático exacto dictado por (9.60)-(9.62). Se obtienen de manera paralela y simultánea los nuevos multiplicadores de Lagrange óptimos (y^k, z^k) asociados a las restricciones linealizadas del subproblema.

2. Tomar el paso completo de Newton sobre el espacio primal y reemplazar los multiplicadores duales:

$$x^{k+1} = x^k + d^k, \quad \lambda^{k+1} = y^k, \quad \mu^{k+1} = z^k.$$

3. Actualizar la matriz H_{k+1} evaluando la nueva Hessiana de la Lagrangiana (o aplicando una actualización Cuasi-Newton tipo BFGS amortiguada). Incrementar $k \leftarrow k + 1$ y regresar al Paso 1.

Teorema 9.7 (Convergencia local superlineal del método SQP). *Supongamos que $\bar{x}$ es un punto estacionario del problema original que cumple estrictamente la Independencia Lineal de Gradientes Activos (LICQ), la condición Suficiente de Segundo Orden, y exhibe Complementariedad Estricta ($\bar{\mu}_i > 0 \forall i \in I(\bar{x})$).*

*Si se utiliza la Hessiana de la Lagrangiana exacta (9.63), entonces para cualquier punto de partida (x^0, λ^0, μ^0) suficientemente cercano a la solución analítica, el Algoritmo 9.5 está bien definido (los subproblemas no colapsan y admiten solución) y converge a la solución óptima $(\bar{x}, \bar{\lambda}, \bar{\mu})$ con **tasa de convergencia cuadrática**.*

9.5.2. Estrategias de Globalización del Método SQP

A grandes rasgos, el esquema SQP base del Algoritmo 9.5 adolece de las mismas fallas analíticas que el método de Newton puro sin regularizar: no tiene garantía de convergencia si se inicializa fuera de la vecindad de atracción del óptimo, y el subproblema (9.60) puede divergir si la matriz H_k asume autovalores negativos (o si las restricciones linealizadas resultan ser mutuamente incompatibles, haciendo que $D_k = \emptyset$).

Para dotar al algoritmo SQP de garantías de convergencia global, se implementa obligatoriamente un proceso de búsqueda lineal (Line Search) o de regiones de confianza. Esto se logra acoplando y guiando el descenso mediante una **Función de Mérito**.

La Función de Mérito Penalizada Exacta

Dado que en optimización restringida debemos equilibrar la reducción de $f(x)$ con la eliminación progresiva de la violación topológica de la factibilidad, introducimos una función de mérito escalar exacta L_1 :

$$\varphi(x; c) = f(x) + c \left(\|h(x)\|_1 + \sum_{i=1}^m \max\{0, g_i(x)\} \right), \quad (9.64)$$

donde el peso penalizador $c > 0$ es un parámetro dinámico que debe exceder el límite superior de los multiplicadores (es decir, $c > \|(\lambda, \mu)\|_\infty$).

Se puede demostrar rigurosamente que si la matriz de curvatura H_k es simétrica definida positiva, la dirección d^k producida por el subproblema SQP es consistentemente una **dirección de descenso garantizada** para la función de mérito φ . Esto autoriza la implementación segura de la regla de Armijo y evita la in-factibilidad general.

El Efecto Maratos y las fallas de la tasa superlineal

La convergencia superlineal rápida del método SQP requiere asintóticamente que la búsqueda lineal permita tomar pasos puros completos (es decir, $\alpha_k = 1$). Sin embargo, existe una patología topológica conocida como el **Efecto Maratos**.

En problemas reales, si el iterado x^k se ubica peligrosamente cerca de la frontera factible curvada, dar un paso completo tangente d^k puede resultar topológicamente en un leve alejamiento (incremento residual) de la frontera factible curva. Este minúsculo incremento residual penalizado impacta desproporcionadamente en la función de mérito exacta L_1 , causando que $\varphi(x^k + d^k; c) > \varphi(x^k; c)$.

En respuesta, el algoritmo rechaza iterativamente el paso completo (exigiendo $\alpha_k < 1$), destruyendo estrepitosamente la tasa cuadrática de convergencia y obligando al método a avanzar con extrema lentitud. Este efecto perturbador y su mitigación (utilizando pasos de corrección de segundo orden transversales o relajando condicionalmente las funciones de mérito) es un tema crucial y altamente activo en el diseño práctico de rutinas comerciales tipo *fmincon* en el estado de arte del análisis matemático no lineal.

Ejercicio 9.1. Probar el Teorema 4.1.2.

Ejercicio 9.2. Probar las fórmulas siguientes.

(a) Si $D = B(\hat{x}, \delta)$, donde $\hat{x} \in \mathbb{R}^n$, $\delta > 0$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = \begin{cases} y, & \text{si } y \in D, \\ \hat{x} + \delta(y - \hat{x})/\|\hat{x} - y\|, & \text{si } y \in \mathbb{R}^n \setminus D. \end{cases}$$

(b) Si $D = \mathbb{R}_+^n$, entonces para todo $y \in \mathbb{R}^n$,

$$(P_D(y))_j = \max\{0, y_j\}, \quad j = 1, \dots, n.$$

(c) Si $D = \{x \in \mathbb{R}^n \mid x_j \in [a_j, b_j], j = 1, \dots, n\}$, donde $a_j \leq b_j$, $j = 1, \dots, n$, son números dados, entonces para todo $y \in \mathbb{R}^n$,

$$(P_D(y))_j = \begin{cases} a_j, & \text{si } y_j < a_j, \\ y_j, & \text{si } a_j \leq y_j \leq b_j, \\ b_j, & \text{si } y_j > b_j. \end{cases} \quad j = 1, \dots, n,$$

(d) Si $D = \{x \in \mathbb{R}^n \mid \langle a, x \rangle = b\}$, donde $a \in \mathbb{R}^n \setminus \{0\}$, $b \in \mathbb{R}$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = y + \frac{b - \langle a, y \rangle}{\|a\|^2} a.$$

(e) Si $D = \{x \in \mathbb{R}^n \mid \langle a, x \rangle \leq b\}$, donde $a \in \mathbb{R}^n \setminus \{0\}$, $b \in \mathbb{R}$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = y + \frac{\min\{0, b - \langle a, y \rangle\}}{\|a\|^2} a.$$

(f) Si $D = \{x \in \mathbb{R}^n \mid Ax = b\}$, donde $A \in \mathbb{R}(l, n)$ tiene rango l , $b \in \mathbb{R}^l$, entonces para todo $y \in \mathbb{R}^n$,

$$P_D(y) = y - A^T(AA^T)^{-1}(Ay - b).$$

Ejercicio 9.3. Analizar propiedades de convergencia del método del gradiente proyectado modificado, descrito arriba (vea (9.16)), suponiendo que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sea una función continuamente diferenciable en $\mathbb{R}^n$ y D sea un conjunto convexo y cerrado.

Ejercicio 9.4. A partir del punto inicial $x^0 = (3, 1)$, hacer dos pasos del método del gradiente proyectado, con longitud de paso fijo, para el problema

$$\min x_1 - x_2 \quad \text{sujeto a} \quad 1 \leq x_1 \leq 3, \quad 1 \leq x_2 \leq 2.$$

Ejercicio 9.5. Sea S_0 el conjunto de puntos estacionarios del problema (9.1). Supongamos que, además de las hipótesis del Teorema 3.1.2, el conjunto $L_{f,D}(f(x^0))$ sea limitado. Probar que

$$\text{dist}(x^k, S_0 \cap L_{f,D}(f(x^0))) \rightarrow 0 \quad (k \rightarrow \infty)$$

(comparar con el Ejercicio 3.1.5).

Ejercicio 9.6. Sean $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función continuamente diferenciable y $D \subset \mathbb{R}^n$ un conjunto convexo y cerrado. Considerar el método del gradiente proyectado con métrica variable, i.e., el esquema

$$x^{k+1} = x^k + \alpha_k(y^k - x^k),$$

donde $y^k \in \mathbb{R}^n$ es la solución del problema

$$\min \langle f'(x^k), x - x^k \rangle + \frac{1}{2} \langle Q_k(x - x^k), x - x^k \rangle \quad \text{sujeto a} \quad x \in D,$$

$Q_k \in \mathbb{R}(n, n)$ es una matriz simétrica definida positiva, y el valor de longitud de paso α_k es calculado por la regla de Armijo o por la regla de minimización unidimensional (si $Q_k = f''(x^k)$, obtenemos el método de Newton restringido, a ser considerado en § 4.1.3).

Mostrar que y^k también resuelve el problema

$$\min \|x - (x^k - Q_k^{-1} f'(x^k))\|_{Q_k}^2 \quad \text{sujeto a} \quad x \in D,$$

donde la norma $\|\cdot\|_{Q_k}$ es dada por $\|x\|_{Q_k} = \sqrt{\langle Q_k x, x \rangle}$.

Probar que si existen $c_2 \geq c_1 > 0$ tales que

$$c_1 \|x\|^2 \leq \langle Q_k x, x \rangle \leq c_2 \|x\|^2 \quad \forall x \in \mathbb{R}^n, \quad \forall k,$$

entonces todo punto de acumulación de una secuencia $\{x^k\}$ así generada, es un punto estacionario del problema (9.1).

TODO Segundo Bloque de Ejercicios

Ejercicio 9.7. Probar el Lema 4.1.3. Probar también que, en el caso de restricciones lineales (i.e., cuando g es una función afin), las desigualdades estrictas en la afirmación (b) del Lema 4.1.3 pueden ser sustituidas por desigualdades no estrictas.

Ejercicio 9.8. Sea

$$D = \{x \in \mathbb{R}^n \mid Ax \leq a\},$$

donde $A \in \mathbb{R}(m, n)$ es una matriz con filas $A_i, i = 1, \dots, m$, y $a \in \mathbb{R}^m$. Mostrar que para todo $x^k \in D$ y todo $d^k \in V_D(x^k)$, para $\hat{\alpha}_k$ definido en (9.20) tenemos lo siguiente:

(a) Si $\langle A_i, d^k \rangle > 0$ para por lo menos un $i \in \{1, \dots, m\}$, entonces

$$\hat{\alpha}_k = \min \left\{ \frac{a_i - \langle A_i, x^k \rangle}{\langle A_i, d^k \rangle} \mid i = 1, \dots, m : \langle A_i, d^k \rangle > 0 \right\}.$$

(b) Si $\langle A_i, d^k \rangle \leq 0 \forall i = 1, \dots, m$, entonces $\hat{\alpha}_k = +\infty$.

Ejercicio 9.9. A partir del punto inicial $x^0 = 0$, hacer dos iteraciones del método del gradiente restringido, con longitud de paso calculado por la minimización unidimensional, para el problema

$$\min x_1^2 + 2x_2^2 - 3x_1 + 4x_2 \quad \text{sujeto a } x \in B(0, 2).$$

Ejercicio 9.10. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable con derivada Lipschitz-continua (con módulo $L > 0$) en el conjunto D que es convexo y compacto. Sea

$$+\infty > R = \max_{x, y \in D} \|x - y\|.$$

Dado un $x^k \in D$, sea $d^k = \bar{x}^k - x^k$, donde $\bar{x}^k$ es una solución del problema (9.21).

(a) Probar que

$$\min_{\alpha \in [0, 1]} f(x^k + \alpha d^k) \leq f(x^k) + \Delta_k,$$

donde

$$0 \leq \Delta_k = \begin{cases} \frac{1}{2} \langle f'(x^k), d^k \rangle, & \text{si } \langle f'(x^k), d^k \rangle + L \|d^k\|^2 < 0, \\ -\frac{|\langle f'(x^k), d^k \rangle|^2}{2LR^2}, & \text{caso contrario.} \end{cases}$$

(b) Para el método del gradiente restringido con regla de longitud de paso de minimización unidimensional restringida, mostrar que todo punto de acumulación de la secuencia generada es un punto estacionario del problema de minimizar f en D .

Ejercicio 9.11. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función diferenciable en el punto $x^k \in D \subset \mathbb{R}^n$, $f'(x^k) \neq 0$. Probar los siguientes resultados sobre soluciones $\bar{x}^k$ del problema (9.21).

(a) Si $D = B(\hat{x}, \delta)$, donde $\hat{x} \in \mathbb{R}^n$, $\delta > 0$, entonces

$$\bar{x}^k = \hat{x} - \delta f'(x^k) / \|f'(x^k)\|.$$

(b) Si $D = \{x \in \mathbb{R}^n \mid x_j \in [a_j, b_j], j = 1, \dots, n\}$, donde se tiene que $a_j \leq b_j, j = 1, \dots, n$, entonces todo $\bar{x}^k$ satisfaciendo

$$\begin{cases} \bar{x}_j^k = a_j, & \text{si } f'_{x_j}(x^k) > 0, \\ \bar{x}_j^k = b_j, & \text{si } f'_{x_j}(x^k) < 0, \\ \bar{x}_j^k \in [a_j, b_j], & \text{si } f'_{x_j}(x^k) = 0, \end{cases}$$

$j = 1, \dots, n$, es una solución de (9.21).

(c) Si $D = \{x \in \mathbb{R}^n \mid x \geq 0, \sum_{i=1}^n x_i = c\}$, $c > 0$, entonces todo $\bar{x}^k$ satisfaciendo $\bar{x}_j^k = c$ para algún índice $j \in \{1, \dots, n\}$ tal que

$$f'_{x_j}(x^k) = \min\{f'_{x_i}(x^k) \mid i = 1, \dots, n\},$$

$\bar{x}_i^k = 0$ para todo $i \in \{1, \dots, n\} \setminus \{j\}$, es una solución de (9.21).

Ejercicio 9.12. Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función dos veces continuamente diferenciable, con matriz Hessiana $f''(x)$ definida positiva en todo punto $x \in D$. Sea $\bar{x}$ un minimizador local de f en D .

Probar que existe $\delta > 0$ tal que, si $\|x^0 - \bar{x}\| < \delta$, entonces el método de Newton restringido está bien definido y genera una secuencia $\{x^k\}$ satisfaciendo $\|x^k - \bar{x}\| < \delta \forall k$; $x^k \rightarrow \bar{x}$ ($k \rightarrow \infty$) y la tasa de convergencia de $\{x^k\}$ a $\bar{x}$ es superlineal.

TODO Tercer Bloque de Ejercicios

Ejercicio 9.13. Probar las afirmaciones del Teorema 4.3.1, suponiendo que f y ψ son inferiormente semi-continuas en $\mathbb{R}^n$, ψ satisface (9.32), $D \neq \emptyset$ e $\inf_{x \in D} f(x) > -\infty$.

TODO Cuarto Bloque de Ejercicios

Bibliografía

- [Izm20] Mikhail Izmailov Alexey y Solodov. *Otimização: Condições de Otimalidade, Elementos de Análise Convexa e de Dualidade (Volume 1)*. Rio de Janeiro, Brasil: IMPA, 2020 (vid. págs. 1, 74, 84, 95).
- [Roc09] Roger J.-B. Rockafellar R. Tyrrell y Wets. *Variational Analysis*. Vol. 317. Grundlehren der mathematical Sciences. Springer Science & Business Media, 2009 (vid. pág. 1).